分类号：F830　　单位代码：11407
密　级：公开　　学　　号：20237290

# 北方民族大学

专业学位论文

# 基于 ATT-BiLSTM 模型的投资者情感与股价预测研究

**Research on Investor Sentiment and Stock Price Prediction Based on ATT-BiLSTM Model**

学　位　申　请　人：陈妍
指　导　教　师：王小刚　教授
申请的学位门类：应用统计专业硕士
专　业　名　称：应用统计
研　究　方　向：社会经济统计
所　在　学　院：数学与信息科学学院
论文完成日期：2026 年 5 月

中国知网　https://www.cnki.net

# 摘要

股票市场，作为金融市场的一部分，是我国实体经济发展的资源配置工具。预测股票价格对居民的微观金融行为研究、企业的投资决策开展、管理部门的宏观经济政策制定等都具有重要的现实意义。随着互联网技术的发展、金融市场活跃度提升，投资者情感逐渐成为股票价格预测的重要影响因素。因此，在股价预测研究中融入投资者情感，具有重要的理论意义与实践价值。

论文结合了自然语言处理技术和金融情感分析，构建了投资者情感指标，并使用改进的 ATT-BiLSTM 神经网络模型，对研究周期的上证指数价格进行预测，并在多只股价上验证鲁棒性。论文的研究内容如下：

通过爬取东方财富股吧投资者的讨论文本，借助预先构建的金融情感词典进行文本分词、情感倾向匹配处理来量化投资者情感指标，弥补了以往研究忽略市场投资者情感的不足；综合考虑对股价有影响的因素，整合基本指标（如开盘价、成交额等）、技术指标（如 KDJ、MACD 等）等核心指标 25 个，利用随机森林算法对特征进行降维，最终筛选出 5 个影响股价的关键指标；在此基础上，改进了传统的机器学习模型，优化了输入指标的权重分配问题：使用基于融合注意力机制的双向长短期记忆网络模型（ATT-BiLSTM）对上证指数短期的收盘价进行了预测，并分析结果。随后，在多只个股上进行实证检验，来验证模型的泛化能力与稳定性。论文得到如下结论：第一，ATT-BiLSTM 模型能更好地捕捉关键特征的权重，短期股价预测精度优于传统机器学习模型。优化后的模型$R^2$达到0.95，较传统 LSTM 模型高 0.11，MSE 降低约 76.76%，且远高于 XGBoost（0.89）、随机森林（0.88）、SVR（0.81）。第二，投资者情感可以捕捉部分市场非理性信息，从而提升模型对短期价格波动的预测能力。在引入情感特征后模型误差明显下降（MSE 降低了 52.17%；MAE 降低了 10.67%），并在多只个股上表现优秀。针对上述结论提出如下建议：在金融时序的预测任务中可以使用注意力机制和双向神经网络结构的 ALL-BiLSTM 模型，其能捕捉股价数据特征中的关键信息，能更精准地进行股价预测；加强对投资者情感信息的挖掘与应用，因其是股价预测中重要的解释变量，能提高股价预测的准确性与稳定性。

**关键词：**股价预测，注意力机制，LSTM 模型，投资者情感



中国知网 https://www.cnki.net

# Abstract

As a component of the financial market, the stock market serves as a resource allocation tool for the China's economic development and is one of the important pillars of the national economic operation. Stock price prediction is of great practical significance for the research on studying individual financial behavior, guiding corporate investment decisions, and informing macroeconomic policies formulation by regulatory authorities. With the development of the Internet and the increase in the activity of the financial market, investors' emotions have gradually become important factors in stock price prediction. Therefore, research on stock price prediction based on investor sentiment has important theoretical and practical value in the financial industry.

This study combines financial sentiment analysis with natural language processing technology(NLP) to construct an ATT-BiLSTM neural network model to assist stock price prediction. The core research content is specifically expanded as follows:

First, this thesis obtains individual investors' comment posts from stock forums through web crawlers, process the texts through word segmentation, sentiment tendency matching, semantic correction, etc., with the help of pre-constructed financial sentiment dictionaries, degree adverb dictionaries, and negation and stop-word lists, and calculate the sentiment scores that reflect investors' emotions. Second, a multi-category feature system is constructed, a total of 25 indicators are incorporated, including basic indicators (such as opening price, trading volume, etc.), and technical indicators (such as KDJ, MACD, etc.). Then, using the Random Forest algorithm to reduce the dimensionality of high-dimensional features, screen out 5 key features which are more significant on stock prices. Finally, an improved bidirectional long short-term memory model augmented with the attention mechanism is built to forecast short-term Shanghai Composite Index prices. Furthermore, empirical research is conducted on diverse stocks to test the model’s generalization capacity and robustness.

To sum up, the following findings can be summarized: First, the ATT-BiLSTM model can capture the weights of key features more precisely, and its prediction accuracy for short-



中国知网 https://www.cnki.net

term stock prices is superior to traditional machine learning models. The optimized model obtains an $R^2$ of 0.95, which is 0.11 higher than the traditional LSTM model's, with an approximately 76.76% reduction in MSE. It also significantly outperforms XGBoost (0.89), Random Forest (0.88), and SVR (0.81). Second, individual investors' sentiment factors play a crucial role in stock prices, and the model error drops notably after introducing sentimental features (MSE decreases by 52.17%; MAE by 10.67%). The investor sentiment score measured from stock forum texts can ably reflect market sentiment uncertainty and is an necessary supplement for stock price prediction.

On the basis of these findings, the following recommendations are offered: Embedding an attention mechanism and a bidirectional neural network structure (ATT-BiLSTM) can capture critical information in stock data features better, forecasting more precisely stock price. Investor sentiment caters to the need for stock price prediction as a core-explanatory variable, improving prediction preciseness and robustness.

**Key words:** Stock Price Prediction, Attention Mechanism, LSTM Model, Investor Sentiment



中国知网 https://www.cnki.net

# 目　录

第一章 绪论.....5
第一节 研究背景与意义.....5
第二节 研究现状.....7
第三节 研究内容.....13
第四节 研究创新与不足.....16
第二章 理论基础与机器学习算法.....18
第一节 行为金融学理论.....18
第二节 随机森林.....19
第三节 长短期记忆网络(LSTM).....20
第四节 注意力机制.....23
第三章 投资者情感指标构建.....25
第一节 投资者情感数据收集与预处理.....25
第二节 金融领域情感词典构建.....29
第三节 投资者情感指标量化.....31
第四节 股评文本情感分数量化.....33
第四章 基于 ATT-BiLSTM 模型的股票价格预测.....35
第一节 多类别特征体系构建与特征筛选.....35
第二节 ATT-BiLSTM 模型参数设置.....43
第三节 基于 ATT-BiLSTM 模型的股价预测结果分析.....47
第四节 不同预测长度与个股差异下的预测结果对比.....53
第五节 融入投资者情感的模型预测.....59
第五章 结论与建议.....62
第一节 结论.....62
第二节 对策建议.....63
参考文献.....64

中国知网 https://www.cnki.net

# 第一章 绪论

## 第一节 研究背景与意义

### 一、研究背景

金融市场是我国经济发展的资源配置工具，并且还是国家经济运行过程中的重要支柱之一。党的二十大以来，我国始终坚持“把金融服务实体经济作为根本宗旨”，这也是中国特色金融发展之路中的重要内容。在 2025 年 12 月召开的中央经济工作会议当中，习近平总书记明确指出，要“强化系统观念，加强财政政策与金融政策协同”。由此可见，金融市场在经济发展当中有着举足轻重的地位。

股票市场作为金融市场的重要组成部分，也是配置社会资本、调整消费结构的重要场所。股票市场的存在，不仅仅满足了投资者的多样化投资需求，也为企业提供了有效的融资渠道，更是在国家级重大战略目标的实现中起到了推动作用。对于企业而言，上市企业通过发行股票来吸引社会资本，从而得以实现扩张、优化融资结构的目标。此外，股票市场还对企业的经营管理起到了监督、规范作用。其促使企业进行信息披露，并规范化运作。对于广大投资者来说，股市则是一个能带来高收益的投资渠道。但与此同时，它的高收益往往会伴随着不确定性——股价的剧烈波动不仅可能会对投资者造成经济方面的损失，还可能对上市企业的声誉以及经营产生不利影响，严重时甚至会爆发系统性的金融风险。例如在 2022 年，俄乌冲突爆发，全球资本市场在短期内剧烈震荡，大宗商品价格飙升、避险资产上涨、股票市场风险偏好快速下降。投资者情感显著地由乐观转向悲观。因此，如何准确把握股票价格规律不仅有助于监管部门稳定市场预期、防范金融风险，也可为企业经营决策与投资者资产配置提供科学依据，在金融研究领域的重要性不言而喻。

股票市场作为一个公共市场，这意味着广大普通投资者都可以在此购入和抛出上市公司的股票。根据中国证券登记结算有限公司发布的数据显示，截止 2025 年 6 月末，A 股投资者总数已突破 2.4 亿。并且截至 2024 年底，个人投资者占比已超 99.76%——这说明，个人投资者在此其中占据了“绝对主导”的地位。在 2025 年上



中国知网 https://www.cnki.net

半年新增开户中，个人占比仍维持着 99.63%的高位。与之相对的，机构投资者占比不足 0.24%，且新增数量在逐年下降。因此，个人投资者在股价的波动过程中毋庸置疑扮演着重要角色。相较于机构投资者而言，个人投资者在信息获取、风险识别与专业分析能力方面相对有限，且往往会对股票市场的未来走势抱有相当程度的主观预期。因此，其决策更容易受到市场情绪、舆论环境及短期价格波动的影响。在个人投资者占比较高的市场环境下，投资者情感已成为了影响股票收益波动和市场稳定性的重要因素，具有不可忽视的现实意义。如何能更好地刻画投资者情感在股票价格预测中的影响，为构建更加有效的股价预测模型提供了新的研究视角。

## 二、研究意义

如何更好地预测股票市场，不仅能为金融研究提供新的预测思路与方法，还能为投资决策、企业战略和政策调控提供科学依据，具有重要的理论意义和现实价值。

### （一）理论意义

本研究在理论层面上的意义主要体现在以下两个方面：

第一，以往关于股票价格预测的研究大多集中在对预测模型本身的优化和算法改进的方面上，研究者普遍依赖于传统的量化指标，而市场参与者的情绪与认知却鲜少被纳入考虑范围之中。实际上，互联网上存在着海量股评、评论与新闻舆情。这些文本并非噪音，其折射了投资者对市场的态度和预期，往往会对股价的走势产生重要影响。本文正是鉴于这一客观现实，引入了对股评文本的情感分析研究，通过计算投资者情感得分来构建出一个新的情感指标，并把它作为预测模型中的重要核心解释变量，从而为股票价格预测的理论体系注入了新维度。在这一过程中，投资者情感对资产定价的影响被进一步检验，并为其提供了一种可行的量化路径。论文某种程度上将行为金融学说当中的定性描述转化为可操作、可计算的数据指标，为相关领域的后续研究提供了理论参考以及研究依据。

第二，在算法设计层面上。论文在深度学习的框架当中嵌入了注意力机制层和双向神经网络层，使得模型能够自动甄别和对焦于对预测结果更有价值的特征信息，从而得以提升特征提取的有效性和预测的准确度。这一方法为多模态时间序列建模提供了一种可行思路，并进一步推广了注意力机制和双向神经网络在金融时间序列



中国知网 https://www.cnki.net

领域的应用场景和其在非文本序列数据中的应用范围。这种方式也为当前金融时间序列领域的研究理解情绪信息与价格波动之间的关系提供了参考，在一定程度上为模型的可解释性提供了理论依据。

（二）现实意义

本研究在现实层面的价值主要体现在以下方面：

从宏观层面看，股票市场的运行脉络与宏观经济的整体走势深度交织。对股票指数的价格施行有效预测，有助于相关部门及时掌握市场信号，也为宏观的经济调控提供了量化层面的支撑。

从金融行业角度出发，股价预测在维护金融市场平稳运行的方面具有积极的作用。因为股价预测可以帮助金融行业部门及时地察觉到异常波动的苗头以及潜在的系统性风险。此外，在行业内部，以证券公司、基金公司等等为代表的金融机构，使用机器学习的方法构建预测模型并应用于投资决策中，布局以 AI 赋能的咨询业务、通过数智化转型提质增效，为数据驱动的决策逻辑奠定了更为坚实的技术底座。

从普通投资者的角度来看，股票价格指数的预测结果能够为投资者决策提供重要参考依据。很多股民缺乏长期稳定的投资观念，而可靠的价格预测信息意味着股民在买入、持有与卖出之间多了一份参考坐标，从而能优化股民的资产配置并加强风险控制，提升整体投资效果。鉴于股票市场本身存在较强的不确定性，较为可靠的价格预测有助于投资者提前识别潜在市场风险，并采取相应的应对措施，以降低损失概率，为资产安全保障兜底。

综上所述，股票指数价格预测在理论层面具有重要的意义，在现实层面具有重要应用价值。

## 第二节 研究现状

### 一、股价预测理论与研究方法

在过去几十年中，传统理论中关于股价预测的研究存在两种分析范式：基本面分析和技术分析。基本面分析由 Graham 的《证券分析》中系统化提出，后由 Damodaran（2012）总结了现代估值分析框架，包括现金流折现、相对估值等基本



中国知网 https://www.cnki.net

面工具，奠定了现代价值投资理论基础。基本面分析方法通过分析宏观经济政策、行业前景、公司业绩、财务结构等因素，从而判断股价的涨跌趋势。该方法的理论基础扎实，适用于中长期的投资决策，但对于短期波动的解释能力有限。技术分析理论最早可追溯至 19 世纪的道氏理论，后由 Murphy（1999）提出了全面的金融市场技术分析方法。技术分析方法通过分析股票历史价格和成交量等数据，提取技术指标，来预测价格短期内的趋势，该方法在短期预测中具有较强操作性。因此，本文即是基于技术分析理论的基础进行研究。

在方法层面上，早期有模型结构的均值建模、方差建模模型被广泛应用于股价时间序列预测，常见的模型包括 ARIMA，GARCH 及 VAR 等。

（一）基于统计学和计量经济学的模型

研究表明，金融市场受随机因素干扰，但价格波动仍具备一定内在规律。自 20 世纪 80 年代起，在金融预测研究中，均值建模模型被广泛应用，这些模型通常会对数据结构和分布的要求较高。例如：差分自回归移动平均模型（ARIMA）、资本资产定价模型（CAPM）等。Caginalp 等（1995）利用 ARIMA 模型对基金价格变动进行预测检验，验证了价格序列中显著的自相关与动量特征。Emenike（2010）使用 ARIMA 模型，对尼日利亚证券交易所的股价进行建模和预测。Gilberto 等（2023）使用 ARIMA 模型，对巴西 IBX50 股指的收盘价进行预测，研究发现该模型在预测点数据的方面表现良好。查正洪（1999）利用 ARIMA 模型对上证 A 股指数进行了分析；吴玉霞和温欣（2016）进一步利用 ARIMA 模型对短期股票价格进行了预测；杨宇塬和张梅（2021）利用选取的 ARIMA 模型预测大众公用股票 9 天的开盘价。

以上研究都是利用 ARIMA 模型对股价相关数据进行预测，研究证明：在短期内，ARIMA 模型可以对股价的预测与拟合提供一定的参考。

由于传统的统计模型要求方差是恒定的，但实际在金融时间序列的过程中并非如此。因此，自回归条件异方差（ARCH）以及广义自回归条件异方差模型（GARCH）等模型被广泛应用。White（2000）通过系统性的对比研究，深入评估了 GARCH (1,1) 模型与多种备择模型的表现。于志军和杨善林（2013）将误差校正方法引入 GARCH 模型以提高股票价格预测精度。杨琦和曹显兵（2016）则将



中国知网 https://www.cnki.net

ARMA-GARCH 模型融合应用于股票价格分析。程思睿（2024）对比了 ARIMA - GARCH 模型和长短期记忆网络，以比较它们的预测性能，并分析有效性评估中的异质性。此外，还有研究者还采用了回归分析（陈璐璐，2016）以及马尔可夫链方法（李东等，2013）等多种手段，从不同角度探讨股票价格的动态变化与趋势预测。

此外，模型结构限制变弱的半参数、非参数模型也有相关应用。例如，厉益洲等（2013）利用非参数核密度拟合了沪深 300 股指期货收益率的分布。金成晓和曹阳（2014）基于非参数 ARCH 模型对沪深指数的波动性进行研究。任燕燕和李劭珉（2017）基于分位数回归模型对中国股市收益率与成交量的作用。

上述研究利用了半结构化的统计学模型来解决金融时间序列的预测问题，理论基础扎实，解释性强，能够较为深入的捕捉股价的趋势性特征。但是，其对数据的假设要求严格，并且相对难以捕捉对复杂的非线性关系。因此，最近几年在股价预测的领域，学者们开始使用机器学习模型。

（二）基于机器学习模型的股价预测

随着人工智能与大数据技术的发展，基于机器学习和深度学习的预测模型逐渐成为研究热点，尤其在处理金融数据固有的非线性、非平稳的特点中表现突出。

Nosratabadi 等（2020）对近几年应用深度学习模型，在股票市场进行预测的研究进行了系统性的分析。文章指出，在 2010 年到 2020 年，随着计算机算力的提高，支持向量机（SVM）和人工神经网络（ANN），开始被用于金融世界序列的预测中。而直到 2020 年左右，循环神经网络（RNN）以及其变体长短期记忆网络（LSTM），在金融时间序列预测领域取得了巨大进展。

Thomas 和 Christopher（2018）利用 LSTM 网络对标普 500 成分股的价格涨跌进行预测，结果表明 LSTM 模型的预测准确率显著高于随机森林（Random Forest, RF）、深度神经网络（DNN）及逻辑回归模型。Nabipour 等（2020）基于德国股票市场群体数据，利用十种技术指标作为输入特征，对比多种传统机器学习模型与深度学习模型（ANN、RNN、LSTM）的预测表现，结果也显示 LSTM 模型的拟合精度最高。



中国知网 https://www.cnki.net

LSTM 模型的算法也被研究学者不断地优化改进中：Wei 等（2017）提出结合 Haar 离散小波去噪与堆叠自编码器（SAE）特征提取的 LSTM 模型，对全球六大股指进行预测，验证了该方法的有效性。Saurav 等（2018）构建了基于 Adam 优化算法的 LSTM 递归神经网络，用于预测纳斯达克交易所 AAPL 股票价格，结果进一步证明 LSTM 在捕捉复杂时序关系方面的优势。为克服传统预测模型精度不足、参数调优复杂等问题，宁昱博和张玉军（2019）提出利用自适应增强算法（AdaBoost）优化 LSTM 模型参数，从而使预测精度提升了约 7 个百分点。

综上所述，机器学习模型在捕捉股票价格中的非线性关系、提取高维特征及自适应学习能力方面表现突出，其为金融市场的时间序列数据的预测提供了一种新思路。传统统计学模型高度依赖于平稳性、线性等严格的时间序列假设，而 RNN 等传统机器学习模型，在处理时间序列的过程中会丢失时间序列的顺序结构，并且对与长程信息的处理能力也较为有限，而 LSTM 模型能在保留时序结构的同时进行多层的非线性变换，并且解决了 RNN 的梯度消失问题，这是 LSTM 模型与其他模型的本质不同，也是其优势所在。

因此，本文建立在这样的研究基础上进行进一步的探索。但现有的研究仍存在一定不足：一方面，部分研究在特征选择的方面相对薄弱，并且仅能单项的捕捉时序特征；另一方面，多数模型在预测过程中的动态重要性关注不足，难以充分反映市场信息在不同时期对股价形成的差异化影响。

基于上述研究现状，本文在已有深度学习模型研究成果的基础上，引入了注意力机制，对特征权重进行动态分配，以强化关键信息对预测结果的影响，并且使用了双向的 LSTM 序列结构，使得模型可以同时关注前向和后向的数据。

### 二、股价预测影响因素研究

多数股价趋势预测研究中所采用的金融时序数据是关于个股的价格与技术指标数据。总的来说，常被用来预测股价趋势的数据特征有以下几种。

（一）股票历史价格数据和交易量数据

包括开盘价、收盘价、最高价、最低价、成交额等。这些基础数据是预测趋势的重要基础，能够反映市场的波动规律和趋势走向。例如 Lin 等（2021）利用开盘



中国知网 https://www.cnki.net

价、最高价、最低价、收盘价及成交量等基础数据构建特征，构建了一种集成机器学习算法的股票趋势预测方法。该方法在股票涨跌趋势预测任务中具有较好的预测性能。

由基础数据计算得到的技术指标数据。包括移动平均线（MA）、相对强弱指数（RSI）、布林带（Bollinger Bands）、随机指标（KDJ）等技术指标。这些指标旨在捕捉市场动量、超买超卖的状况及价格趋势的潜在变化。例如 Kumar 等（2020）、Thakkar 和 Chaudhari（2021）运用多种人工智能算法，对技术指标和基本面指标进行了综合分析。

（二）与公司经营状况相关的财务数据

如收入、利润、每股收益（EPS）、市盈率（P/E Ratio）、净资产收益率（ROE）、负债水平等。这类数据能够反映公司的基本面强弱，帮助分析投资价值。例如，Dutta 等（2021）利用逻辑回归模型对印度股票市场的股票表现进行预测，以市值、市盈率、市净率及资产负债率等公司财务指标作为输入指标，将股票表现划分为“良好”和“较差”两类。研究结果表明，该模型能够以约 74.6%的准确率对股票表现进行分类，说明企业财务指标在股票表现预测中具有一定的解释能力。

（三）宏观经济数据

包括利率、通货膨胀率、失业率、GDP 增长率、货币政策等。这些因素在较大范围内影响市场资金流动性和投资者的信心，进而对股价产生间接影响。例如，Lee 等（2023）提出一种基于多模态融合 Transformer 的股票方向预测方法，通过融合宏观经济指标、股票市场数据及时间特征，实现多源信息的联合建模。实验结果表明，该方法在 50 只股票数据集上取得了显著优于传统模型的预测效果。

由于技术缺陷、互联网算法的不普及等等，上述研究多局限于使用上市公司的财务报告、股票市场指标等等结构化的数据。该类数据的优点是结构清晰、获取方便，并且易于量化，但可能不会反映出股票市场中丰富的舆论信息和情感信息。因此，本文借助于此类基本数据的框架下，又额外引入了投资者情感指标，对股票价格进行预测。



中国知网 https://www.cnki.net

近几年来，得益于计算机技术的进步，文本大数据在经济学和金融学领域方兴未艾，文本分析也广泛应用于市场研究、社交媒体分析等领域。文本分析是从非结构化的文本数据中提取有意义信息的过程，文本分析的目标通常为上市公司的披露文本、财经新闻的报道等等，其具有数据来源多样化、形式丰富多样、时频高的特点。

情感词典法是一种传统的、无监督的、文本大数据的文本分析方法。该方法从预先设定好的词典中，通过统计文本数据中不同类别词语的出现的次数，结合不同的加权方法来提取文本信息。在金融领域，使用文本词典分析的研究得到广泛的应用。例如，在英文语境中，由 Henry 等（2008）通过参考了上市公司的盈利披露电话会议文字稿等资料，构建了专门为金融文本的词典。Loughran 和 McDonald (2011) 从上市公司的 10-K 文件中人工收集并整理文本数据，构造了 Loughran and McDonald（简称 LM）词典，并被很多在金融、会计领域的词典法的研究中所运用。例如，Zhang 等（2016）发现，在上市公司的相关新闻报道中，正面和负面词语比例对股票市场变量（收益率、波动率、交易量）间的影响存在着影响。近些年来，国外对度量投资者的文本情感的研究十分丰富。

Tsukioka 等（2018）对 2001 至 2010 十年的雅虎财经日本股票板块的数据源收集到的 654 家公司相关的帖子数据进行情感指数的分析，研究发现投资者情感可用于解释 IPO 抑价现象。Gao 等（2019）针对 2004—2014 年谷歌的词搜索频率文本，提取了周度的国别投资者情感指数，研究表明：投资者的情感指数能预测未来一周股票市场的收益率。

国内关于基于文本的金融研究材料也十分丰富。但是相较于英文语境，在中文语境下直接采用英文情感词典往往并不理想。Li 等（2019）从股票论坛 2008—2018 年的帖子中，随机抽取了四万条文本，通过人工标注正负情感词汇，构建了更贴合中国股吧语境的金融情感词典。该词典的情感分类的准确率，相比直接翻译 LM 词典的准确率能提升约 30%。

在中文语境下的情感文本研究中，有不少国内学者也会针对具体场景自行构建中文词典。例如，汪昌云和武佳薇（2015）基于新闻报道，结合《现代汉语词典》、



中国知网 https://www.cnki.net

《最新汉英经济金融常用术语》、知网中文信息结构库等词库，建立了财经媒体领域的正负面情感词库；王靖一和黄益平（2018）则依据科技论坛、财经新闻网站上的新闻标题内容，构建了适用于金融科技的情感词典。

更多的研究者选择直接采用了现有通用词典，如：利用知网情感词典进行文本情感判断（朱梦珺等，2016），或借助极性词典处理股评文本而进行情感分类（戴德宝等，2019）。还有学者针对特定应用扩展现有资源，例如基于台湾大学情感词典扩展领域词汇（饶东宁等，2017），或专门开发用于财经新闻或投资分析的金融情感词库（顾文涛等，2020）。

综上所述，以情感词典法为首的基于文本分析的方法，为金融市场中投资者情感的度量，提供了重要的思路。基于这种方法，本研究在既有金融情感词典研究成果的基础上，综合借鉴多种成熟的词典资源，对金融领域的情感词典进行了整合与优化，在一定程度上避免单一词典可能带来的偏差问题，使所构建的情感指标更能反映金融文本中的整体情感特征。

## 第三节 研究内容

本文从多源信息融合的角度出发，基于股价基本指标、技术指标以及由文本分析得到的投资者情感等不同类型的信息，构建了一种影响股票价格的多类别特征体系，并将其作为输入指标，使用改进的机器学习模型对上证指数短期的股票价格进行预测，随后在 4 支具有代表性的个股上进行多步预测，以验证模型的适用性。

在第三章，论文针对爬取到的东方财富网上证指数吧评论文本进行情感分析，构建了投资者情感指标，论文借助自然语言处理（NLP）技术对股评文本进行情感识别，根据搭建的金融情感词典匹配投资者的情感倾向，并最终计算得到日频情感得分数据。与传统依赖价格、成交量等客观交易数据的预测模式相比，引入投资者情感能反映市场参与者的心理预期，能弥补传统的量化指标之外的补充维度，从而为股票价格预测模型提供更全面的参考信息。

在第四章，为了进一步提升特征提取的有效性，论文首先纳入了传统的股票基本指标（开盘价、最高价、最低价等）、技术指标（EMA、RSI 等）。在考虑到指标之间的冗余和共线性问题，本文采用随机森林的方法对收集到的 25 个多维特征进



中国知网 https://www.cnki.net

行降维处理，来减小各类指标之间的相互影响，辅之以时间序列交叉验证的方法对指标选取的个数进行验证，最终筛选出 5 个关键特征作为模型输入指标。

随后，论文将经过筛选后的关键特征作为自变量引入所构建的机器学习模型。在模型设计上，论文对神经网络结构进行了优化，引入 Attention 机制和 BiLSTM 神经网络，构建了基于 ATT-BiLSTM 的预测模型。该模型能够在时间序列学习中更好地捕捉关键特征，并能同时处理时间序列的前向与后向的关系。论文的研究对象选取了具有代表性的国内股票指数——上证指数，通过对其进行短期价格预测，检验模型的有效性。

在第四章实证评估的后半部分，论文采用多种评价指标（RMSE、MAE 等），将改进后的 ATT-BiLSTM 模型与未改进的机器学习模型和传统机器学习模型进行对比，包括单一的 LSTM 模型、支持向量回归（SVR）模型等，并根据多只股票的收盘价在不同预测日期进行预测，以验证其鲁棒性。最后，通过消融实验对比了加入情感指标前后的模型预测效果，说明情感指标的引入的必要性。

在第五章的结论与建议中，结果表明引入股评情感指标并结合注意力机制的 ATT-BiLSTM 模型，在短期股价预测中表现出更高的预测精度和更小的误差，验证了本模型在股票价格预测中的显著作用。

本研究的技术路线图，如图 1-1 所示。



中国知网 https://www.cnki.net

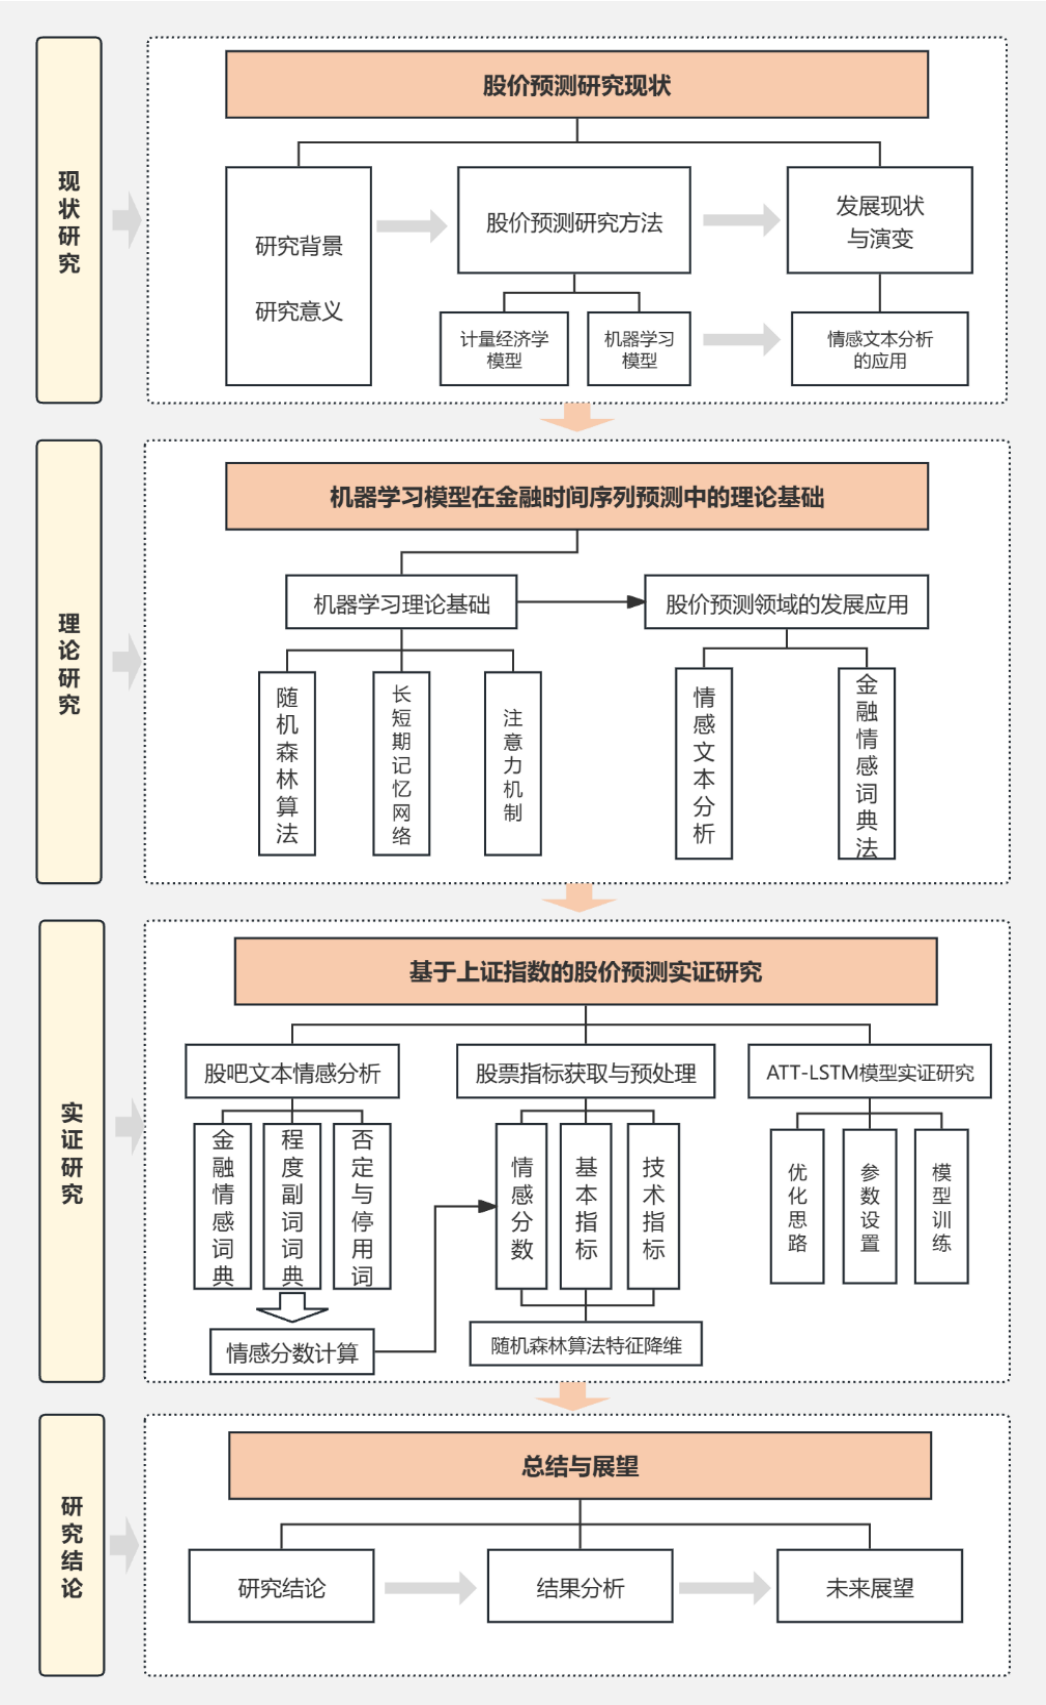



图 1-1 技术路线图



中国知网 https://www.cnki.net

## 第四节 研究创新与不足

### 一、创新点

综合目前已有的研究理论和研究现状，结合本文的研究结构和研究内容，本文的创新主要体现在以下几个方面：

首先，融合注意力机制以及双向 LSTM 的机器学习模型。传统 LSTM 模型默认各特征的重要性是一致的，然而在实际的金融数据中，不同输入特征的作用强弱、不同时期的数据的重要性也不尽相同。为此，本文引入了注意力机制，对输入特征进行权重的再分配，从而突出了关键特征。同时，普通的 LSTM 模型只能沿时间正向地提取信息，本文进一步采用双向的 LSTM 模型，使模型能够同时从时间序列的正向与反向获取特征信息，并据此构建了 ATT-BiLSTM 组合模型，使得预测精度较以往的机器学习模型以及传统的 LSTM 模型有所提升。

其次，引入情感文本分析构建情感指数。在以往的研究中，股价的影响因素通常只是基于基础指标和技术指标而构建的。但是，这类结构往往只能捕捉到客观的价格和成交趋势层面的信息，难以反映市场的情绪波动与预期变化。因此，为了提升特征维度的全面性，本文将情感文本分析加入了模型的前置训练流程。本文基于网络舆情文本信息，提取了情感指数，使其成为与基础指标、技术指标并行的补充特征，从而能更准确刻画市场行为。

### 二、不足之处

本文在模型设计和特征构建方面存在着一些局限性，具体体现在以下几个方面：

首先，本文虽然综合考虑了基本指标、技术指标以及情感指标，但没有纳入宏观经济指标和公司的基本面分析指标。其原因在于股票价格和情感指标数据主要为日频数据，而宏观经济指标一般由权威统计机构以季度或者年度的形式发布，存在着频率不匹配的问题，若直接融合，可能会导致宏观变量在短期预测的过程中信息更新不足，也会对模型的训练产生影响。因此，在未来的研究中，可尝试将宏观经济数据以其他方式纳入到指标体系和模型中，例如混频数据建模方法（MIDAS）等等，以提升股票趋势预测的全面性和可靠性。



中国知网 https://www.cnki.net

其次，ATT-BiLSTM 在短期和中短期的预测任务中整体表现较为理想，但面对突发的结构性涨跌等高度不明确的因素的时候，模型在极端情况下的泛化性能仍可能会受到一些影响。不仅如此，股票市场在牛市、熊市不同状态下，波动幅度与趋势持续性也会存在差异，围绕这一问题更多优化算法有待挖掘。

与此同时，本文的数据层面聚焦于预测收盘价的预测问题，未进一步延伸至股价的涨跌趋势判别、投资组合策略等等问题，在未来进一步的研究中，可以在此基础上进行延伸，并就市场状态对样本区间进行划分，分别评估模型在不同行情环境下的预测精度，以进一步提升研究的应用价值。



中国知网 https://www.cnki.net

# 第二章 理论基础与机器学习算法

本章围绕着涉及到的经济理论和机器学习模型核心算法与结构，对行为金融学理论、随机森林、长短期记忆网络以及注意力机制的理论基础进行了系统性阐述。介绍了部分行为金融学理论的内容，再次表明投资者情感在股价预测领域的重要性。以及介绍了随机森林算法的基本原理，为后续输入指标的筛选与降维处理提供了理论依据。详细分析了长短期记忆网络的结构特点和门控机制，以及其在处理时间序列数据、刻画长期依赖关系方面的优势。对注意力机制的理论来源与实现原理进行了说明，论证了其在强化关键特征权重、提升模型表达能力方面的重要作用。

## 第一节 行为金融学理论

以往对投资者情感的研究中，主要涉及到了行为金融学（Behavioral Finance）理论。其融合了心理学理论和金融决策的领域，起源于 20 世纪 60 年代。行为金融学理论包括羊群效应和过度自信。羊群效应是指投资者倾向于从众行为，其本质原因如下：个人投资者，相较于机构投资者而言，受教育水平、认知、性格等等个人因素的作用，在信息不对称、不确定极大的时候，就会放弃独立思考，盲目跟随大众或市场主流趋势的非理性行为。Shiller（2000）将羊群效应认定为经济泡沫的主要原因，记录了集体过度自信在将科技类股价的估值提升至正常水平的 5 至 10 倍，并最终使得纳斯达克指数在 2000 年 3 月下跌了 78%。而过度自信理论是投资者在判断过程中对自身能力和知识持有虚高评估的认知偏差，这会导致部分投资者过度交易、承担过高的风险。

综上所述，投资者情感的研究是行为金融学理论的一个重要分支。近年来，社交媒体兴起，投资者情感更易受到新闻报道、社交舆论的影响，进而投资者对股票市场的预期也会随之波动。因此，研究投资者的情绪行为，并将其纳入股票价格的指标体系中，也成为了金融学领域的一个研究热点。



中国知网 https://www.cnki.net

## 第二节　随机森林

由 Breiman 和 Cutler 在 2001 年提出的随机森林算法（Random Forest, RF）是一种基于集成学习的算法。其核心思想——集成学习，是指结合多个简单的弱机器学习算法，来做出更可靠的决策。随机森林通过 Bagging 抽样，构造多个并行的数据集的决策树，而每个决策树的运行结果共同决定了最终的预测结果。

随机森林的应用场景十分广泛：其既可用于解决分类问题，也适用于解决回归分析的问题，在分类任务中采用决策树多数投票的方式，而回归任务则是取预测的均值来得到最终的结果。不同的决策树之间是独立的。集成学习策略，作为一种经典的机器学习算法，通过整合多个具有不同特征和结构的决策树，不仅提高了预测性能，还增强了算法的鲁棒性。其对数据扰动与噪声的容忍度也随之提升。因此，它能够在各种复杂场景下保持较高的预测准确率。此外，随机森林还能有效处理高维特征数据，因为它能够自适应地减少对非关键特征的依赖，从而避免过拟合现象。

随机森林模型的决策步骤结构示意如图 2-1 所示。

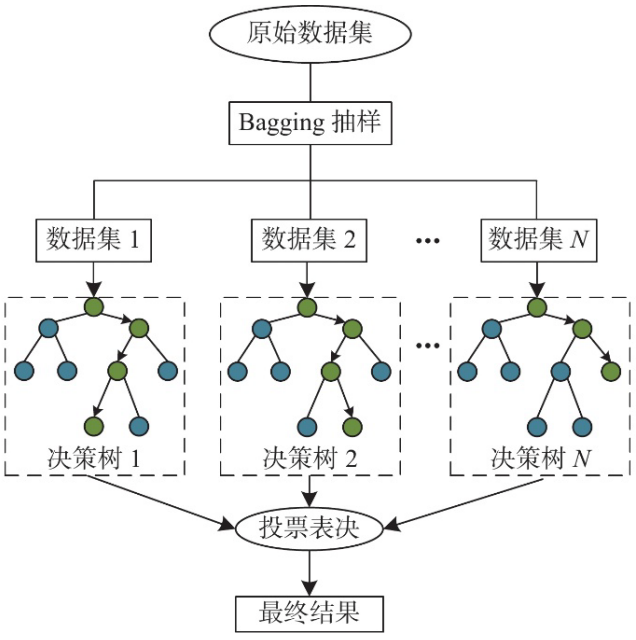



图 2-1 随机森林结构示意图

随机森林每棵决策树的构建过程中包含着两层随机化操作：在数据层面上，随机森林算法会从全量的数据中有放回地进行随机抽样（Bagging），其结果构成了每一棵树的训练子集，同一个样本有可能会在训练集中反复出现。而后，在特征层面，



中国知网　https://www.cnki.net

每次节点分裂之前，算法会从全部特征中随机抽取一个子集作为备选，从而筛选出用于分裂的最佳特征。

这种方法被称为随机子空间法，其核心作用在于增强决策树的多样性和随机性。在训练过程中，随机森林会并行地构建多棵决策树，每棵树的“生长”都会受到停止条件的约束——约束条件包括树的大小、节点最小样本数、分裂阈值以及分类误差率等等。一旦达到了停止条件，决策树的构建就会停止。

随机森林算法的具体步骤如下：

随机抽样训练集：先从原始数据集 $D = \{(x_i, y_i)\}_{i=1}^{N}$ 中随机选择 $n$ 个样本对（可以复抽样），作为该棵树的训练集；

$$D_b = \left\{ \left(x_{i_b}, y_{i_b}\right) \mid i_b \sim \text{Uniform}(1, N) \right\}.$$

其中，$D_b$ 表示第 $b$ 棵树的训练集，$(x_{i_b}, y_{i_b})$ 表示第 $b$ 棵树的样本对。

随机选择特征：从总特征集 $M$ 中随机选择 k 个特征作为候选特征，用于该树的节点划分，$k \ll M$；

使用选定的样本和特征子集来构建决策树，并在每个节点上挑选能最大化信息增益的最佳特征进行分裂，这种过程会一直持续到满足停止条件为止。通过这种方式构建的决策树被称为随机决策树，重复上述步骤构建 $B$ 棵决策树，形成随机森林。

集成之后的随机森林融合了多个随机决策树，协助完成分类或回归任务。最终，随机森林的输出结果是基于所有决策树的投票结果（分类问题）或平均预测值（回归问题）计算得出的，正是这种“少数服从多数”的机制，确保了预测结果的准确性和可靠性。

## 第三节　长短期记忆网络（LSTM）

循环神经网络（Recurrent Neural Network, RNN）是一种用于处理序列数据的神经网络模型，相比一般的神经网络来说，它能够处理序列变化的数据，但由于 RNN 存在“梯度消失”，使其不能处理时间序列的“长依赖”问题。而为了解决长序列训练过程中的梯度消失和梯度爆炸问题，长短期记忆（Long short-term memory, LSTM）模型最早由 S. Hochreiter 和 J. Schmid Huber 于 1997 年提出，它是一种特殊



中国知网　https://www.cnki.net

的 RNN 模型，包含了单元（cells），输入门（input gates）以及输出门（output gates）。

LSTM 作为一种能捕捉长期序列的神经网络模型，近年来被广泛应用与自然语言处理（NLP）和时间序列预测等领域，例如：文本分类、翻译、语音识别、经济指标预测等等。

LSTM 通过其特有的门控结构，实现了对信息流动的精准记忆与选择性调控。该结构主要由遗忘门 $f_t$、输入门 $i_t$、$\tilde{C}_t$与输出门 $o_t$组成，各门控模块协同作用，从而形成动态的信息筛选机制。在多数情况下，这些门控结构均采用 Sigmoid 激活函数，将全连接层的输出映射到 [0,1] 区间，以控制信息的通过比例，即决定当前信息是否需要传递以及其通过强度。具体而言，输入门负责确定哪些新信息被写入单元状态；遗忘门用于判断历史信息的保留或舍弃；而输出门则控制哪些单元状态信息被传递至下一时刻或上层网络。LSTM 的整体结构如图 2-2 所示。

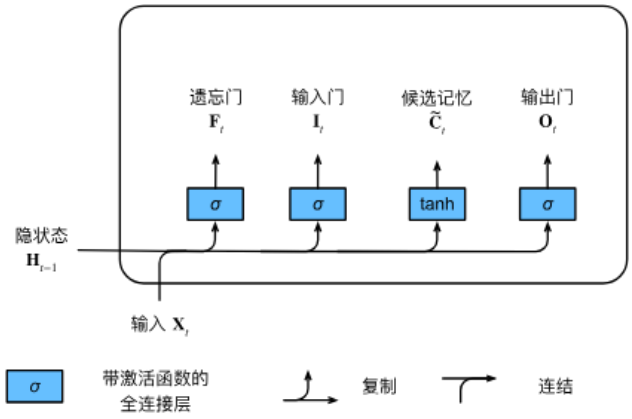



图 2-2 LSTM 结构图

## 一、遗忘门

在长短期记忆网络（LSTM）中，遗忘门承担着细胞状态信息的“管理”功能。遗忘门的核心作用在于根据当前输入$x_t$与上一时刻的隐藏状态$h_{t-1}$，动态决定哪些上一时刻的历史信息需要保留，哪些需要削弱或舍弃。遗忘门内部采用了 Sigmoid 激活函数，将线性变换后的结果映射至[0,1]区间。该输出可视为对历史信息的重要性权重。当其值接近 0 时，对应的历史信息将被大幅削弱或完全遗忘；当其值接近 1 时，信息则被完整保留。随后，遗忘门通过元素级乘法将该权重应用于上



中国知网　https://www.cnki.net

一时刻的细胞状态，使网络能够灵活调控历史记忆的保留程度。借助这一机制，LSTM 得以在序列建模中有效捕捉长期依赖关系。其计算过程可表示为：

$$f_t = \sigma\left(W_f[h_{t-1}, x_t] + b_f\right)$$

其中，$W_f$为$h_{t-1}$与$x_t$到遗忘门的权重矩阵，$b_f$为偏置 0。

二、输入门

在 LSTM 中，输入门被用作决定新信息融入长期记忆状态 $C$ 的程度。其计算过程为：首先输入门权重矩阵$W_i$和 Sigmoid 激活函数共同作用，结果生成输入门权重$i_t$，该权重位于[0,1]的区间，其作用是调节新信息输入记忆单元的比例。然后通过$tanh$函数与候选记忆权重矩阵$W_C$得到候选记忆向量$\tilde{C}_t$，并且当前时刻的输入为$x_t$，上一时刻隐藏状态为 $h_{t-1}$。最终，由计算后的输入门权重$i_t$与候选记忆$\tilde{C}_t$共同决定新信息选择性输入的部分。其具体计算过程如下：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i),$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C),$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t.$$

其中，$W_i$ 与 $W_C$分别为输入门与候选记忆的权重矩阵；$b_i$、$b_C$ 为对应的偏置项。

三、输出门

输出门的主要负责调控当前时间步隐藏状态的生成过程，并且从每层细胞状态 $C$ 中筛选出对最终输出的信息有实质影响的内容。输出门的门控价值最先使用 Sigmoid 激活函数对隐藏状态中需激活的分量进行选择性过滤计算出$o_t$；与此同时，Tanh 会将细胞状态$C_t$映射到$[-1,1]$的区间，输出门再将二者逐元素相乘。只有被 Sigmoid“选择”的信息才会同步更新隐藏状态，进而影响 LSTM 神经元在当前时间步的输出。上述机制赋予了 LSTM 依据细胞状态动态调整输出$h_t$的能力，从而增强其对序列数据的建模效果。

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o),$$

$$h_t = o_t * \tanh(C_t).$$



中国知网　https://www.cnki.net

其中，$o_t$是当前时刻的输出门激活值，$W_o$是输出门权重矩阵，$b_o$是输出门的偏置项。$h_t$ 是当前时刻的隐藏状态，也是 LSTM 的输出，会传递给下一层网络。

## 第四节 注意力机制

注意力机制（attention-mechanism）是一类用于引导深度学习模型在输入序列中选择性聚焦关键信息的机器学习技术。其核心思想在于，通过对输入序列中的不同的输入部分设置差异化的权重，使得模型能够突出最具有贡献力的特征，同时压低与当前任务关联不大的噪声。

注意力机制的提出奠定了现代大型语言模型（LLM）的根基。其设计灵感却来源于人类普遍存在的生物特征。例如人在看书的时候，眼睛可以在迅速扫过一页文字，却能自动聚焦于关键词——人类与动物在处理感知输入时，会在全量信息中优先关注更具显著性或更具任务相关性的部分，以提升信息处理效率、避免细节丢失。

注意力机制通过分配不同权重来模拟这种生物特征：计算一组注意力权重（attention weights），量化输入序列中的元素相对于当前预测目标的相对贡献。随后，这些权重用于对输入表示进行加权组合，权重高的区域在模型内部被强化，权重低的则被淡化。在训练过程中，模型借由“监督学习”的方法自动分配这些权重，从而逐步形成有效的注意力模式。

注意力机制最初由 Bahdanau 等（2014）引入，弥补了循环神经网络（RNN）在机器翻译任务中的长距离依赖的缺陷。后续研究将其与卷积神经网络（CNN）结合，应用又推广到了图像字幕生成、视觉问答等任务。

2017 年，Vaswani 等发布的《Attention Is All You Need》中提出纯注意力架构 Transformer，完全摒弃了循环与卷积结构，仅依赖多头注意力层与前馈网络即可建模长程依赖关系。这一设计的影响很快蔓延至整个深度学习领域——今时今日几乎所有的主流大模型，都能在架构上找到 Transformer 的影子。不仅限于 NLP，主流图像生成的扩散模型的核心模块中都大量使用了注意力机制，视觉 Transformer（ViT）在目标检测、图像分割与视觉问答等任务上也有突破，这些例子进一步证明了注意力机制的通用性与强大表达能力。



中国知网 https://www.cnki.net

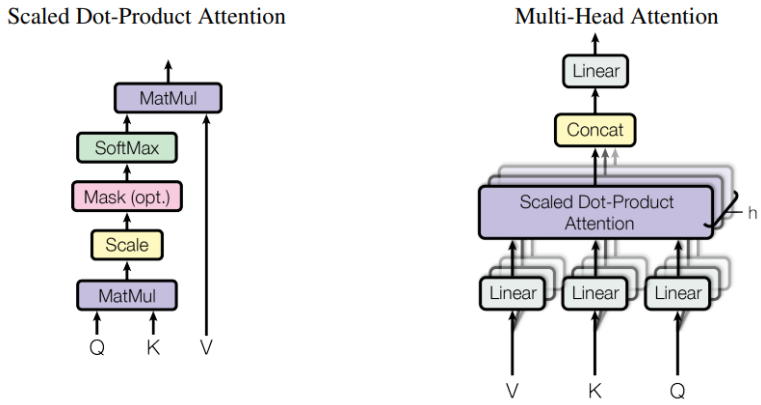



图 2-3　注意力机制结构图

落实在计算层面，注意力机制的运作步骤如下：首先，计算权重：对于给定的查询（Query）和一组键（Key），计算它们之间的相似度或相关性得分$e_i$。

$$e_i = f(Q, Ki).$$

其中，$Q$为查询向量，$K_i$为键向量，$f$是相似度函数，最常用的是点积函数。

其次，归一化：使用 softmax 函数对得分进行归一化处理，得到每个键对应的权重。

$$\alpha_i = \frac{\exp(e_i)}{\sum_j \exp(e_j)}.$$

其中，$\alpha_i$为注意力权重，表示第 $i$个 Key 的重要程度。

最后，加权求和：根据权重对相应的值（Value）进行加权求和，得到最终的注意力输出。

$$Attention(Q, K, V) = \sum_i \alpha_i V_i.$$

其中，$V_i$为值向量，即为存储输入的实际信息，$Attention(Q, K, V)$为最终输出。



中国知网　https://www.cnki.net

# 第三章 投资者情感指标构建

在股票市场中，情感分析可以帮助投资者更直观地把握市场情感对股价波动的影响。投资者的心理状态（例如积极、消极情感）对于股票价格的推动亦有影响。因此，为了捕捉这些情感信息并将其转化为模型可以理解的量化指标，本章节采用了情感词典的方法。针对常见的东方财富网平台上的论坛文本进行自然语言处理，并进行情感分析，旨在识别股票市场中投资者所传达的态度，从而提供更深入的市场洞察，也为后续模型的 预测提供数据支撑。

## 第一节 投资者情感数据收集与预处理

在构建情感指标的过程中，文本信源的质量直接决定了研究结论的可靠性。因此，本章的研究核心之一在于如何从真实可靠的数据源出发，精准、系统地刻画投资者情感，并将其有效地融入股价预测模型之中。

投资者情感作为一种非结构化的文本信息，具有主观性强，波动频繁，难以量化的特点。因此，本章旨在选择具有代表性的股吧文本信息，并进行情感分析。

与新浪微博、知乎等综合性的社交平台相比，股吧论坛在金融情感研究中更具优势，也是很多以往的研究中所参考的对象，原因主要有以下几点：其一，股吧作为专门的证券交流平台，其讨论主题高度集中于金融市场。因此，股吧的文本包含着更多基于股票市场的情感信息。而微博、知乎等平台信息噪声较多，往往需要额外的清洗与筛选。其二，股吧的用户群体以股民为主，帖文内容更能反映金融市场实际参与者的真实情绪。相比之下，微博等平台的用户构成更加多元，股票投资者的相关言论占比有限。其三，股吧贴文带有明确的时间节点，便于与股价数据进行时间序列上的精确匹配，并且数据结构较为统一，便于规模化采集和处理，而微博、知乎的接口限制和内容多样性则提高了数据获取与建模的难度。

### 一、数据来源

综合考虑时效性、影响力、在线人数等等因素，本文选择了东方财富网的上证指数股吧中帖子的标题作为文本信息，本文所用数据覆盖近十年，时间跨度较长。



中国知网 https://www.cnki.net

在“东方财富网”股吧中，上证指数的评论数据相对完整，而其他股指的评论数量偏少且时间不均衡。鉴于上证指数在我国股市中的代表性，本研究优先选取了上证指数作为研究对象。

本文采用了网络爬虫的方式，使用 python 3.0 语言，对 2014 年 11 月到 2024 年 10 月的上证指数股吧的逐条评论的发帖时间、评论标题、阅读、讨论量进行了批量爬取。具体的操作步骤分为以下三个部分：

1.通过股票代码与评论页面，生成待爬取的目标网址 URL。利用 selenium 库调用 Chrome 类，并通过 Chrome driver 建立连接，启动一个不含用户信息的浏览器窗口。结合源码解析的方法获取股吧帖子信息。

2.通过 HTML 标签结构提取需要爬取的部分，包括帖子主题、作者、评论数、发帖时间等等关键信息，并对异常链接等进行清理。

3.将获取到的作者、发帖时间及帖子正文等文本信息存入 MongoDB 数据库，形成涵盖较长时间跨度的结构化数据集。为后续的情感分析和股票预测研究提供数据支持。

## 二、数据预处理

本文总共爬取到的股评文本数据有 581.18 万条，时间范围从 2014 年 11 月到 2024 年 10 月。对发帖内容、发帖人、发帖时间均一致的文本信息进行了去重，得到去重后的数据规模约 538.57 万条，提取了去重之后的数据中的发帖内容、浏览数、评论数、发帖日期、发帖时间。部分股吧评论内容见表格 3-1 所示。

**表 3-1 股吧评论节选**

| 评论标题 | 浏览量 | 评论时间 |
|---|---|---|
| 上证指数放量突破，后市将会创出今年新高！ | 256 | 2020-11-23 |
| 大 A 指数反弹明显，个股赚钱效应并不明显，国家的政策决定反弹高度，预测元旦节后连涨 | 221 | 30/12/2023 |
| 这个 8 月也跌了整整半个多月，再跌十天就能看到跌到月底就能看见 2800 了 | 39 | 21/8/2023 |



中国知网 https://www.cnki.net

| | | |
|---|---|---|
| 讲真的，现在的市场有点看不懂了，一天一个行情，总是出其不意。 | 397 | 18/2/2021 |

根据李合龙等（2023）的金融市场文本情感研究综述，获取的文本通常需要进行预处理，以达到缩减篇幅、提高后续处理效率的目的。常见的数据预处理步骤包括停用词删减、否定词处理、短语切分等等。例如黄创霞等（2020）基于个体投资者情感与股票价格行为的互动关系研究，Li 和 Kong（2022）基于金融词典结合 Bert-DCA 模型的情感分析研究，等等。本文借鉴了近年来常见的文本预处理方法，进行下述的处理：

对所得到的文本信息进行分词处理。常用的中文分词工具有 jieba （结巴分词）、HanLP、SnowNLP 等。这些工具在自然语言处理领域用于将中文文本切分成有意义的词语或词组，方便进行文本分析和信息提取。本文选取了开源的 jieba 分词工具中的精确模式作为分词模式的样本。

对得到的分词去除部分停用词。根据以往经验，在文本信息中，往往存在大量对情感分析结果影响甚微，甚至无关的词语。例如：“哦”、“呢”等日常口语化表达，以及一些语气助词、虚词等等。这类词汇在情感分析层面上缺乏实际价值。为了降低到后续情感计算的工作量，减少后续特征提取与建模的负担，在文本处理阶段，有必要对这些无效词汇进行剔除。

本文将经过分词的股评文本与停用词典进行匹配，凡是出现在停用词库中的词汇均予以删除。通过这一预处理环节，既能保证情感得分计算的精确性，又能有效降低冗余特征，提升整体分析效率，为后续的情感建模和预测提供更加干净的输入数据。本文参考合并去重了在情感分析中通用的中文停用词典，包括：中文停用词表、哈工大停用词表、百度停用词表、四川大学机器智能实验室停用词库（累计 1426 词），将股评文本的分词与停用词进行比较，如果文本的分词出现在停用词词典中，则删除该分词。得到的分词结果的词云图如图 3-1 所示，部分分词结果如图表 3-2 所示。



中国知网 https://www.cnki.net




图 3-1　股票评论词云图

表 3-2　部分评论分词结果

| 单词 | 词频 | 单词 | 词频 |
|---|---|---|---|
| 大盘 | 28216 | 指数 | 12514 |
| 不 | 27060 | A 股 | 11993 |
| 今天 | 23618 | 股票 | 11349 |
| 点 | 21431 | 月 | 11143 |
| 股市 | 19283 | 大笑 | 11077 |
| 跌 | 18222 | 会 | 11062 |
| 明天 | 14653 | 上证指数 | 10964 |
| 涨 | 13315 | 中国 | 10658 |
| 还 | 12819 | 好 | 10634 |
| …… | …… | …… | …… |

由图 3-1 和表 3-2 可以看出，频率出现较高的情感类词汇有：涨、跌、大笑、好，等等。这说明股吧评论中不仅包含客观信息，还蕴含了大量的投资者情感与态度表达，因此，将情感特征纳入股价预测模型具有一定的现实意义。



中国知网　https://www.cnki.net

## 第二节　金融领域情感词典构建

在深入分析股票评论文本结构的基础上，给出两方面的情感词分值优化策略：一方面，保留原有情感词的基础分值；另一方面，引入修饰词的影响权重，建立修饰词分值的计算规则，以更准确地反映其对情感词的修正作用。

基于上述规则，本文构建了优化后的股票评论文本情感得分计算流程，其整体框架如图 3-2 所示。

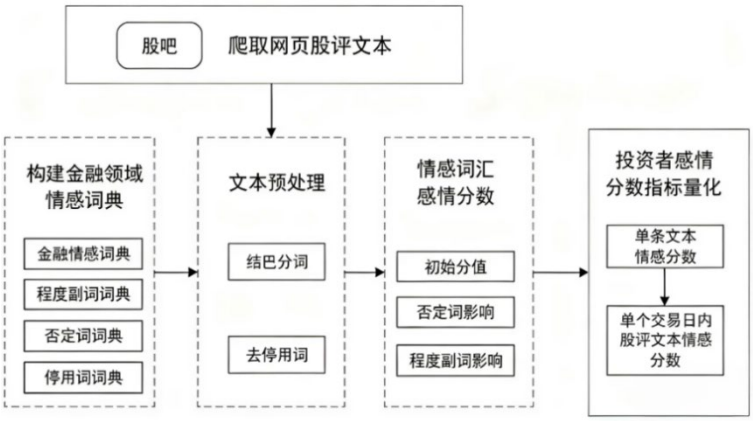



图 3-2 股票评论文本情感得分计算流程

### 一、金融情感词典构建

构建情感词典指的是对日常生活或工作中常见的带有感情色彩的词汇加以整理和分类的过程。股票评论文本具有较强的专业性，比如“暴涨”、“触底反弹”、“贬值”和“崩盘”等，此类词汇在通用情感词典中往往缺失相应的情感值。因此，只依赖通用情感词典对股吧评论文本进行情感分析，存在着局限性。

参考姚加权等（2021）和姜富伟等（2020）金融领域的情感词典中的非正式文本词典，进行情感词的合并，并删除了重复值，构建了专门适用于股吧和社交媒体等金融领域文本的情感分析的情感词典，共计 9822 词。部分情感词如表 3-3 所示。

表 3-3 情感词典节选

| | 普通情感分析领域 | 金融情感分析领域 |
|---|---|---|
| 积极情感词汇 | 好、棒、太棒了、完美、厉害等 | 狂拉、暴涨、突破颈线、上扬、涨停、利好等 |
| 消极情感词汇 | 差，烂，坏，死气沉沉等 | 下跌、暴跌、下挫、贬值、不景气、跌停、跳水等 |



中国知网　https://www.cnki.net

## 二、程度副词词典构建

在情感分析过程中，只凭借单一的情感词汇往往不足以全面反映文本中所蕴含的情感强度。事实上，程度副词作为情感词的重要修饰成分，会显著影响最终的情感极性计算结果。若忽视其作用，势必导致情感分值的偏差。例如股吧来自 2016-05-11 的一条评论：“A 股涨一个点都无比艰难！”消极情感词汇是“艰难”，而程度副词“无比”对其进行修饰，使得情绪表达的强度被明显放大。由此可得，程度副词在情感分数的精确计算中起着不可忽视的作用。为了更好地量化这种作用，本文参考了知网 HowNet 情感分析用词典中的程度副词词典，共 189 个词。

在该词典中，程度副词按照作用强度被划分为若干类别，如“极其”、“很”、“较”、“稍”、“欠”等，并为每一类词汇设置了相应的权重。部分程度副词如表 3-4 所示。

表 3-4 程度副词节选

| 程度 | 个数 | 权重 | 词汇 |
|---|---|---|---|
| 极其\|extreme/最\|most | 69 | 4 | 百分之百，倍加，备至，不得了，不堪，不折不扣…… |
| 很\|very | 42 | 3 | 不过，不少，不胜，出奇，大为…… |
| 较\|more | 37 | 2 | 大不了，更，更加，更进一步，更为，还，还要…… |
| 稍\|-ish | 29 | 1 | 怪，好生，还，或多或少，略，略加…… |
| 欠\|insufficiently | 12 | 0.5 | 半点，不大，不丁点儿，不甚，不怎么，没怎么，轻度…… |

## 三、否定词词典构建

在股评文本信息感情分数的计算中，构建否定词词典旨在对文本中出现的否定词进行有效地识别。在此基础上，完成对文本中所有否定词的分值的量化。本文最终构建的否定词典中收录了 711 个否定词汇，涵盖了“不用”、“不是”、“不能”、“反对”、“缺少”等典型否定词。否定词的出现会使得其修饰的情感词汇表现出相反的情感，所以统一将其权重值设定为-1。

基于情感词典的处理方法在一定程度上也存在着局限性，由于社交媒体的文本数据存在着非规范的特点（例如包含一些反讽语气、缩写词、网络用语等等），情



中国知网　https://www.cnki.net

感量化的准确性仍有提升空间，未来研究可考虑引入基于预训练语言的大模型或人工标注的方式作为辅助判断，以增强对这类非规范语言文本的识别能力。

## 第三节 投资者情感指标量化

本文以上所述的情感词典为基准，确定情感词汇的初始分值（记为$s_{i1}$）。对经分词与停用词去除后的股评文本词汇，逐一与金融情感词典进行匹配：若匹配结果为积极情感词汇（如“上涨”“盈利”“利好”），则其初始情感分值设定为$s_{i1}=1$；若匹配结果为消极情感词汇（如“下跌”“亏损”“利空”），则其初始情感分值设定为$s_{i1}=-1$；若词汇未出现在金融情感词典中，则判定为非情感词汇，不参与情感分值计算。

在股评文本中，情感词汇常受否定词、程度副词等修饰词影响，导致其实际表达的情感倾向可能被增强、削弱或倒置（如“不上涨”“猛烈下跌”），与初始的情感倾向产生偏差。因此，本文将修饰词对情感词汇的有效影响范围设定为情感词汇的前 3 个词汇窗口，对该窗口内的否定词与程度副词进行识别与计算。

在无修饰词场景下，若情感词汇前 3 个词汇窗口内，无任何否定词或程度副词，则该情感词汇的实际分值等于其初始分值，可表示为：

$$s_i = s_{i1}. \tag{3.1}$$

例如，在句子“今日股价上涨”中，“上涨”为积极情感词汇，前 3 个窗口内无修饰词，故其实际情感得分为+1。

在含程度副词场景下，若情感词汇前 3 个词汇窗口内存在程度副词（如“非常”“过于”“略微”），则需通过程度副词的等级权重（记为$d_i$，由预先构建的金融领域程度副词词典确定），对初始分值进行强度修正，可表示为：

$$s_i = s_{i1} \times d_i. \tag{3.2}$$

例如，“今日盈利非常显著”中，“显著”为积极情感词汇（$s_{i1}=+1$），“非常”的等级权重$d_i=4$，故实际情感得分的分值为 4，情感积极强度被增强。

在含否定词场景下，若情感词汇前 3 个词汇窗口内存在否定词（如 “不”“无”“未”），则需通过否定词个数（记为$n_i$）对初始分值的情感倾向进行反转修正，可表示为：



中国知网 https://www.cnki.net

$$s_i = s_{i1} \times (-1)^{n_i}. \tag{3.3}$$

例如，在评论句子“今日股价未下跌”中，“下跌”为消极情感词汇（$s_{i1} = -1$），“未”为 1 个否定词（$n_i = 1$），经否定修正后，该情感词汇的实际情感得分为$+1$，表明情感倾向由消极转为积极。

在否定词与程度副词共存的场景下，若情感词汇前 3 个词汇窗口内同时存在否定词与程度副词，则需综合两者的调节作用，最终实际分值计算公式为：

$$s_i = s_{i1} \times (-1)^{n_i} \times d_i. \tag{3.4}$$

其中，$s_{i1}$为情感词汇初始分值，$n_i$为否定词个数，$d_i$为程度副词等级权重。

例如，在评论“今日业绩过于不理想”中，“理想” 为积极情感词汇（$s_{i1}$=1），“不”否定词的个数为 1，“过于”的等级权重$d_i$=2.0，故其实际分值为$-2.0$，情感消极强度被增强，符合文本真实情感倾向。

通过上述初始分值设定与语义规则优化，可有效消除修饰词对情感词汇表达的干扰，精准计算出每个情感词汇在股评文本具体语境下的实际情感分值，为后续股评文本整体情感评分的量化奠定基础。经过预处理与清洗后的有效数据中，部分评论的分词结果及对应情感得分计算结果如表 3-5 所示。

**表 3-5 部分评论分词结果与情感分数计算结果**

| 评论标题 | 评论时间 | 分词结果 | 情感分数 |
|---|---|---|---|
| 接下来科技人工智能医药将引领大盘向上 这才是有逻辑的方向良性上涨 | 8/8/2023 | [’接下来’, ’科技’, ’人工智能’, ’医药’, ’引领’, ’大盘’, ’向上’, ’这才’, ’逻辑’, ’方向’, ’良性’, ’上涨’] | 6 |
| 这是要暴跌的走势，快跑吧 | 10/4/2017 | [’暴跌’, ’走势’, ’快’, ’跑’] | -1 |
| 今天大盘暴跌，暴跌，暴暴跌，暴暴暴跌 | 18/2/2011 | [’今天’, ’大盘’, ’暴跌’, ’暴跌’, ’暴’, ’暴跌’, ’暴暴’, ’暴跌’] | -4 |



中国知网 https://www.cnki.net

考虑到原始数据中存在因网络波动、网页结构异常等爬取错误导致的异常情感值，会对后续模型训练与实证分析结果产生干扰，因此本文对极大、极小的异常情感值进行了剔除。

## 第四节　股评文本情感分数量化

基于第三节的情感词汇分值优化方法，可得到股评文本中每个情感词汇的实际分值（$s_i$），在此基础上，通过“单个词-单条评论-单日汇总”，实现股评文本情感分数的分层计算。

首先，将单条股评文本的情感分数（记为$s_{sen}$），通过对该文本分词后所有情感词汇的实际分值（$s_i$）进行求和得到，计算公式为：

$$s_{sen} = \sum_{i=1}^{k} s_i \tag{3.5}$$

其中，k为单条股评文本中情感词汇的总个数。若文本中无情感词汇，则其情感分数$s_{sen} = 0$，表示文本无明确情感倾向。

为反映单个交易日内某只股票对应的所有股评文本的整体情感倾向，需对该交易日内所有单条股评文本的情感分数进行汇总计算。

首先，收集了单个交易日内目标股票对应的所有有效股评文本（剔除无意义文本、重复文本），设文本总数为 m，计算每一条文本的情感分数$s_{sen1}, s_{sen2} \cdots, s_{sen,m}$，对所有单条文本情感分数进行求均值计算，得到该交易日的目标股票的单日股评文本情感分数（记为$s_{day}$），计算公式为：

$$s_{day} = \frac{\sum_{j=1}^{m} s_{sen,j}}{m}. \tag{3.6}$$

$s_{day}$的正负与大小可直接反映单日股评文本的整体情感倾向：$s_{day} > 0$表示该交易日的整体情感偏向积极，数值越大积极程度越强；$s_{day} < 0$表示整体情感偏向消极，数值越小消极程度越强；$s_{day} = 0$表示整体情感中立。本文受限于数据处理复杂度和爬取的信息完整度，未根据帖子的评论、浏览数进行影响力加权处理，采用了等权平均作为基准方案，后续的研究中有待优化。

在完成网络爬虫对目标平台帖子的批量获取后，首先对原始文本数据进行中文分词处理，将连续的文本字符串切分为具有语义信息的词语序列，为后续情感分析



中国知网　https://www.cnki.net

奠定基础。在得到标准化的分词结果后，依据前文所构建的情感计算规则，对每条文本进行情感得分量化计算。根据计算结果对文本情感倾向进行划分：将情感得分大于 0 的帖子标记为积极情感倾向，将情感得分小于 0 的帖子标记为消极情感倾向，而情感得分等于 0 的帖子则判定为无明显情感倾向。

经过计算，得到的部分日期的情感分数值如表 3-6 所示，为更好地观测数据，所得到情感分数值按月份均值，得到情感分数走势图如图 3-2 所示。由图 3-2 可以看出，情感得分长期在-0.2 到 0.3 之间波动，并且和市场行情基本同步。例如，在 2012-2014 年情感得分偏负，这与当时市场持续低迷是吻合的，而 2021-2022 年的情感分数持续走高，这与新能源、消费等赛道热度持续增高，结构性牛市的出现也互相匹配。

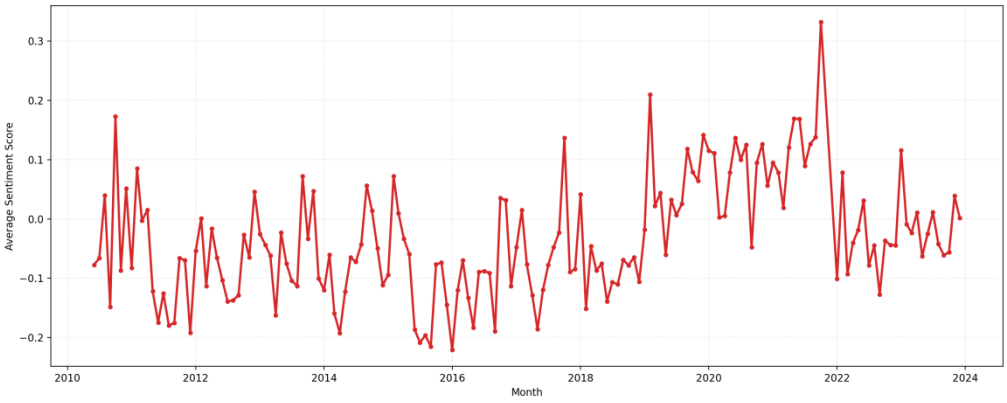



图 3-2 情感分数月度均值变化图

表 3-6 部分日期情感分数

| 日期 | 情感分数 |
|---|---|
| 26/4/2024 | 0.16 |
| 27/4/2024 | 0.2 |
| 28/4/2024 | 0.65 |
| 29/4/2024 | 0.17 |
| 30/4/2024 | -0.11 |
| 1/5/2024 | 0.06 |
| 2/5/2024 | 0.39 |
| 3/5/2024 | 0.88 |
| …… | …… |



中国知网 https://www.cnki.net

# 第四章　基于 ATT-BiLSTM 模型的股票价格预测

第三章构建和计算了投资者情感分数，本章将进一步构建一个股价预测的多类别输入体系，根据前文所构建的输入指标输入到文中设计的 ATT-BiLSTM 模型中，对上证指数未来短期股票收盘价，进行训练与预测。随后在相同环境下构建模型验证 ATT-BiLSTM 模型在上证指数短期股价预测问题上的有效性。

## 第一节　多类别特征体系构建与特征筛选

在现代金融体系中，股票市场被广大投资者所关注最多，同时也是交易最频繁的领域。其价格变化难以预测、影响因素众多。机器学习算法的发展为股价预测研究带来了很多新方向。为了在这一背景下更准确地刻画市场走势，本文在模型构建阶段对指标体系进行了筛选。

具体而言，八项常用的基础指标，包括开盘价、收盘价、最高价、最低价、成交量、成交额、涨跌额和涨跌幅，被选取。以反映市场的基本运行状态。其次，进一步的，九个反映市场趋势与交易心理的技术指标，如 KDJ、RSI、MACD、BOLL 等，被引入。这些指标综合考虑了价格波动的趋势性、资金流动的方向性以及市场情绪的强弱，使模型能够从多维度捕捉市场信号。

此外，为避免个股价格因操纵、消息面波动等偶发因素导致的失真，本文选取了上海证券交易所综合股价指数，即上证指数（SSE Composite Index）作为主要研究对象。它是一种市值加权指数，是反应挂牌股票总体走势的统计指标。该指数涵盖了在上海证券交易所上市的全部股票，能够较为全面地反映中国 A 股市场的整体走势。相较于单只股票研究，以指数为基础不仅可以减少随机噪声，还能在宏观层面提升预测模型的稳定性与普适性。因此，上证指数的选取具有重要的研究意义与现实参考价值。

本研究的股票相关数据来源为东方财富网和新浪财经网站。股票数据集为上证指数近十五年的数据，累计 3377 条。选取的时间范围从 2010 年 6 月覆盖到 2024 年 9 月。



中国知网　https://www.cnki.net

## 一、指标选择

为了更好地提取股票的数据特征，首先要构建股票的特征指标体系。指标体系包括 8 个常见的股票基础指标和 9 个技术指标。

（一）基础指标

基础指标是反映该只股票的运行状态、价格行为与交易特征的核心变量，是相对与技术指标而言的。其包括了该只股票最基本的信息。主要包括：价格类指标、收益类指标、成交量类指标与波动类指标。本文参考了武蓉（2023）基于神经网络的沪深指数预测，以日度为单位，选取了以下基础指标：

1. 开盘价（Open）：股票当天价格的初始值；

2. 收盘价（Close）：股票当天价格的结束值；

3. 最高价（High）：股票当天价格最大值；

4. 最低价（Low）：股票当天价格最小值；

5. 成交量（Volume）：当天股票买卖双方达成交易的数量；

6. 成交金额（Turnover）：当天股票买卖双方达成交易的成交金额；

7. 涨跌额：当日股票价格与前一日收盘价格（或前一日收盘指数）相比的涨跌数值的差值；

8. 涨跌幅：当日股票价格与前一日收盘价格（或前一日收盘指数）相比的涨跌数值的比值。

（二）技术指标

技术分析是投资者用来预测股价走势的一种重要方法，作为技术分析的核心工具，技术指标能够帮助散户股民识别市场趋势，即俗称的“看盘”。本研究选取的技术指标包括：

1. 指数移动平均线（Exponential Moving Average，EMA）：它通过计算一定时期内股价的加权平均值来平滑价格波动，帮助投资者识别一定时间内，股票是上涨还是下跌的趋势。它是一种趋势类的指标。相较于简单移动平均线（SMA），它具有对近期价格变化的反应更灵敏，能更及时地捕捉市场趋势的优点。常见的有



中国知网　https://www.cnki.net

EMA5，EMA10，EMA20，EMA60，对应着周期为 N=5，20，60 天的移动平均周期。可以分别选取 EMA5，EMA20，EMA60 作为指标。计算公式如下。

$$EMA_N = \frac{2}{N+1} \cdot close + \frac{N-1}{N+1} \cdot EMA_{N-1}, \tag{4.1}$$

其中，$EMA_N$为第 N 日的指数移动平均线，$close$为当日收盘价，$EMA_{N-1}$为前一日的指数移动平均线，N 为周期。

2. 相对强弱指数（Relative Strength Index，RSI）：RSI 是衡量市场买卖力量相对强弱的震荡类技术指标，根据一定时期内上涨点数和涨跌点数之和的比率制作出的一种技术曲线。能够反映出市场在一定时期内的景气程度，选取常见的 6 日、12 日 RSI 作为指标。RSI 的计算公式如下：首先计算相对强度（RS），再计算相对强弱指数。

$$RS = \frac{N\text{日内收盘价涨数的均值}}{N\text{日内收盘价跌数的均值}}, \tag{4.2}$$

$$RSI = 100 - \frac{100}{(1+RS)}. \tag{4.3}$$

3. 动量线指标（Momentum，MOM）：MOM 是一种动量指标，表示一段时间内股票收盘价的差值，用来刻画一段时间内股票的涨跌速度，直接反映股价在特定时间内的变动幅度与趋势强弱，以此来判断股票是否超买或超卖。本文考虑一周内股票的涨跌速度，计算公式如下。

$$MOM = close - close5. \tag{4.4}$$

其中，$close$为当日收盘价，$close5$为 5 日前的收盘价。

如果当前的收盘价持续大于 5 天前的收盘价，且 MOM 愈来愈大，则说明此时市势加速上升；反之，如果当前的收盘价持续小于 5 天前的收盘价，且 MOM 愈来愈大，则说明此时市势加速下降。MOM 上穿 0 轴为买入信号，跌破 0 轴为卖出信号。

4. 变动率指标（Rate of Change，ROC）：ROC 重点研究股价一定周期内的变动幅度和变动的动力大小。它计算某一时期内收盘价的百分比变化，以此来判断趋势并识别超买和超卖状态，它同时也能判断股价趋势的持续性与反转信号，是股价预测初始特征体系中补充动量维度的重要指标。本文结合金融市场常用周期，主要考虑 12 日和 25 日的 ROC，其计算公式如下。



中国知网　https://www.cnki.net

$$\mathrm{ROC} = \frac{close - close_n}{close_n}. \tag{4.5}$$

其中，$close$为当日收盘价，$close_n$为 n 日前的收盘价，本文取$n = 12, 25$.

一般来说，ROC 的正负性显示价格是上升还是下降。当 ROC 由负变正，表明股价由跌转涨，投资者可适当建仓，而当 ROC 向下由正变负后，表明股价由涨转跌，投资者可适当减仓，同时，若 ROC 线突破 0 轴后持续走高或状态稳定，表明股票上涨趋势强劲，为持股信号，若 ROC 线跌破 0 轴后持续走低，表明股票处于弱势状态，为持币信号。

5. 随机指标（Stochastic Oscillator，KDJ）： KDJ 指标是一种动量摆动指标，由 George 等在 1950 年代推广使用。它通过计算股价在近期波动区间内的相对位置，精准识别短期超买、超卖状态及趋势反转信号。计算公式如下：首先要计算周期（n 日）的 RSV 值，即未成熟随机值，然后再计算 K 值、D 值、J 值等。一般 n 取 9、14 日等，本文取 9 日为周期。

$$RSV = (close_9 - low_9)/(high_9 - low_9) \times 100. \tag{4.6}$$

其中，$close_9$为第 9 日收盘价；$low_9$为 9 日内的最低价；$high_9$为 9 日内的最高价。

RSV 数值越高，表示收盘价越接近 9 日的最高价，买方力量越强；反之则卖方力量越强。接下来计算 KDJ 值：

$$K_N = \frac{2}{3} \cdot K_{N-1} + \frac{1}{3} \cdot RSV, \tag{4.7}$$

$$D_N = \frac{2}{3} \cdot D_{N-1} + \frac{1}{3} \cdot K_N, \tag{4.8}$$

$$J_N = 3K_N - 2D_N. \tag{4.9}$$

其中，$K_N$、$D_N$、$J_N$为第 N 日的 K、D、J 值，$K_{N-1}$、$D_{N-1}$为前一日 K、D 值，初始 K 、D 值一般取 50。

K、D 值取值范围为 0~100，K/D＞80 为超买区间，表明买方力量过度聚集，股价短期上涨幅度过大，为潜在卖出信号；K/D＜20 为超卖区间，表明卖方力量过度释放，股价短期下跌幅度过大，为潜在买入信号；20＜K/D＜80 为中性区间，股价维持原有趋势。



中国知网　https://www.cnki.net

6. 布林线（Bollinger Bands，BOLL）：BOLL 由美国股票分析师 Bollinger 在 80 年代创立，由三条轨道线组成：中轨是移动平均线（SMA），上轨线（Upper）、下轨线（Lower）则根据股价波动率计算得出。布林线可以用来判断股价的波动范围和潜在的反转点。本文选取金融市场通用的 20 日为计算周期，计算公式如下。

$$\text{中轨线} = 20\text{ 日的移动平均线}(SMA), \tag{4.10}$$

$$\text{上轨线} = \text{中轨线} + \text{两倍的标准差}, \tag{4.11}$$

$$\text{下轨线} = \text{中轨线} - \text{两倍的标准差}. \tag{4.12}$$

7. 平滑异同移动平均线（Moving Average Convergence and Divergence，MACD）：MACD 线通过计算短期与长期指数移动平均线的差值，刻画股价趋势的快慢变化，能精准识别趋势延续与反转信号，是本文股价预测初始特征体系中核心的趋势动量类指标。

MACD 指标，由 DIF 线（差离值）、DEA 线（信号线）、MACD 柱状图（Hist）三部分组成。第一部分通过快速指数移动平均值（一般取 12 日）减去慢速指数移动平均值（一般取 26 日），一般称为 DIF 线。第二条线是 DEA 线，是 DIF 的指数移动平均值（一般取 9 日）。最后一个组成部分是 MACD 柱状图，它的值是 DIF 和 DEA 之间的差值。MACD 的计算公式如下：

$$DIF = EMA_{12} - EMA_{26}, \tag{4.13}$$

$$DEA = \frac{2}{9+1} * DIF + \frac{9-1}{9+1} * DEA_{N-1}, \tag{4.14}$$

$$Hist = DIF - DEA. \tag{4.15}$$

其中，$EMA_{12}$、$EMA_{26}$是 12、26 日的指数移动平均线，$DEA_{N-1}$为前一日的 DEA 值。

## 二、输入指标及其预处理

数据选取指标的类型，结合了前文提到的上述基本指标以及技术指标，对少数数据缺失的指标进行了剔除，最终选取的指标如表 4-1 所示。

表 4-1 输入指标名称

| 序号 | 输入指标 | 序号 | 输入指标 |
|---|---|---|---|
| 1 | 开盘价 | 13 | MOM 5 |
| 2 | 涨跌额 | 14 | ROC 12 |
| 3 | 涨跌幅 | 15 | ROC 25 |



中国知网 https://www.cnki.net

| | | | |
|---|---|---|---|
| 4 | 最高价 | 16 | K |
| 5 | 最低价 | 17 | D |
| 6 | 成交量 | 18 | J |
| 7 | 成交金额 | 19 | Upper (BOLL) |
| 8 | EMA 5 | 20 | SMA(BOLL) |
| 9 | EMA 10 | 21 | Lower(BOLL) |
| 10 | EMA 60 | 22 | DIF(MACD) |
| 11 | RSI 6 | 23 | DEA(MACD) |
| 12 | RSI 12 | 24 | Hist (MACD) |

收集到的具体指标数据如表 4-2 所示。

表 4-2 部分输入指标

| 日期 | 开盘价 | 涨跌额 | … | DIF | DEA |
|---|---|---|---|---|---|
| 1/11/2023 | 3038.18 | 4.31 | … | -45.3216 | -38.4481 |
| 2/11/2023 | 3028.66 | -13.67 | … | -45.1079 | -39.1141 |
| 3/11/2023 | 3012.47 | 21.39 | … | -43.9362 | -39.5963 |
| 6/11/2023 | 3047.13 | 27.61 | … | -41.6683 | -39.8035 |
| 7/11/2023 | 3052.92 | -1.14 | … | -39.5791 | -39.7810 |

基础指标中的收盘价格作为预测变量$Y$，其余指标作为输入指标$X$。

各指标之间的相关系数图见图 4-1。可以看出，部分指标之间存在较大的相关性，还有指标与收盘价之间相关性极弱。这意味着指标间存在冗余，或是指标对于预测影响甚微。如果不加筛选，将所有的指标都直接输入模型，不仅仅会增加计算的复杂度，还可能因为冗余信息干扰了模型的学习，从而降低了预测的性能。

因此，本文采用了基于随机森林的特征选择算法，对输入指标进行特征降维。



中国知网　https://www.cnki.net

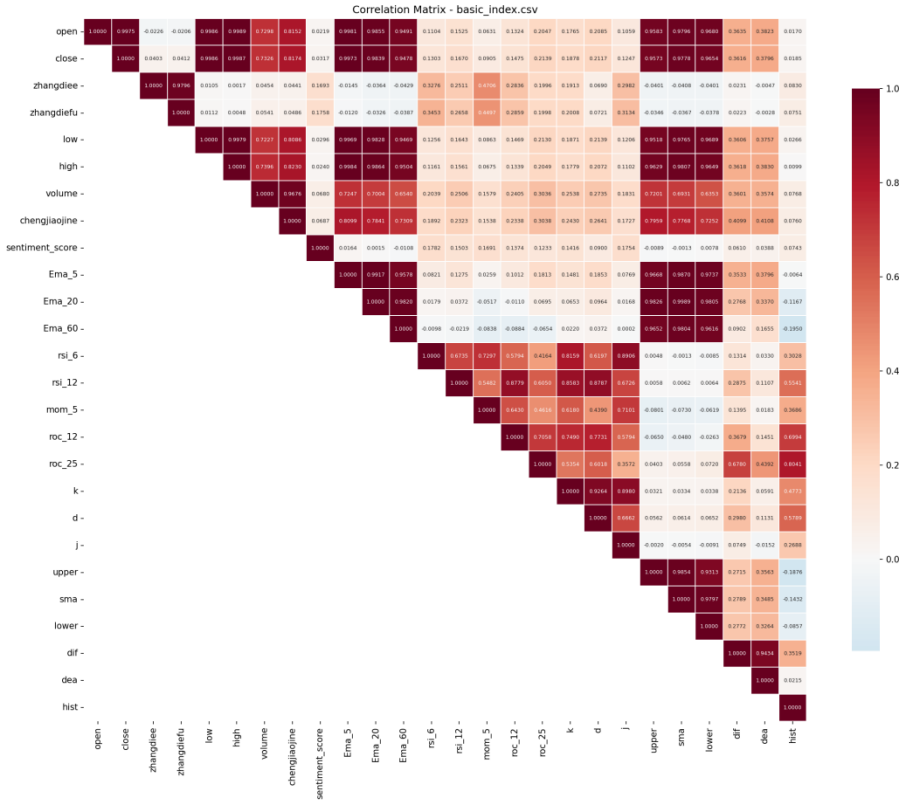



图 4-1 各指标相关性矩阵示意图

## 三、基于随机森林的特征处理

由于选取的特征指标数据量巨大，且包含冗余和噪声，为了筛选出最能影响收盘价的数据特征，本章对包含 24 个特征的股票指标采用随机森林算法，进行特征降维处理。

为了预测股票的收盘价，本文将从若干的候选特征中筛出“对预测最有用的一部分”。用全部候选特征（open、high、volume 等等）拟合随机森林，划分出 80%的训练集和 20%的测试集，得到每个特征的重要性，并且按照重要性排序。详细的数据指标如表格 4-3 所示。

表 4-3 特征重要性排序

| 特征 | 重要性 | 排序 |
|---|---|---|
| high | 0.4516 | 1 |
| low | 0.3083 | 2 |
| Ema_5 | 0.1025 | 3 |
| dif | 0.1014 | 4 |
| open | 0.0059 | 5 |



中国知网 https://www.cnki.net

| ..... | ..... | ..... |
|---|---|---|
| rsi_6 | 0.00023472 | 21 |
| d | 0.00022419 | 22 |
| sma | 0.00022259 | 23 |
| volume | 0.00021221 | 24 |
| k | 0.00016484 | 25 |

为了进一步选取合适的特征，使用时序交叉验证的方法在不同的“前 $n$ 个特征”子集上对模型拟合的 $R^2$ 进行评估。由于股票价格数据是金融时间序列数据，如果使用普通的交叉验证方法，会打乱数据的前后顺序。因此，本文使用了 K 折时间序列交叉验证（Timeseries Split）逐步前滚的验证法则，具体的评估步骤如下：

首先，根据排序结果，分别设定特征候选个数$n = 5$、10、15、20 的子集。对于每个 n，提取重要性排序前 n 的特征构建特征子集，作为模型的输入指标。其次，在每个子集上采用 K 折时间序列划分。在每一折验证中，利用训练集进行模型拟合，并在验证段计算拟合优度系数 $R^2$。通对求各折 $R^2$ 的平均，作为该特征规模 n 下的综合得分，并且选择平均 $R^2$ 最好的 n。依照此方法，得出的各项数据如表 4-4 所示。由表 4-4 可以看出，当 n=5 时，五折平均 $R^2$ 计算得 0.8526，高于 n=10、15、20 时对应的平均 $R^2$（0.8501、0.8492、0.8474）。此外从特征重要性来看，前五个特征累积覆盖了特征重要性总量的 90%以上，并同时参考了相关系数矩阵图的结果，在一定程度上验证了随机森林特征选择结果的稳健性。综上所述，本文最终选择了重要性排序前 5 的特征用于建模，即为最高价、最低价、Ema_5、开盘价和 DIF。

**表 4-4 时间序列交叉验证结果**

| c | 折数 | $R^2$ | n | 折数 | $R^2$ |
|---|---|---|---|---|---|
| 5 | 1 | 0.987304 | 15 | 1 | 0.985398 |
| 5 | 2 | 0.283303 | 15 | 2 | 0.268925 |
| 5 | 3 | 0.99831 | 15 | 3 | 0.998101 |
| 5 | 4 | 0.997647 | 15 | 4 | 0.996957 |
| 5 | 5 | 0.996278 | 15 | 5 | 0.996402 |
| 10 | 1 | 0.986199 | 20 | 1 | 0.978022 |
| 10 | 2 | 0.272556 | 20 | 2 | 0.267405 |
| 10 | 3 | 0.998115 | 20 | 3 | 0.998101 |
| 10 | 4 | 0.996967 | 20 | 4 | 0.996876 |



中国知网　https://www.cnki.net

| | | | | | |
|---|---|---|---|---|---|
| 10 | 5 | 0.996453 | 20 | 5 | 0.996348 |

## 第二节　ATT-BiLSTM 模型参数设置

在确定输入指标后，进入模型的构建与预测环节。

本研究所有的方法都基于 Python 上进行，深度学习框架为 TensorFlow。同时为了验证 ATT-BiLSTM 的可行性，本文对比模型与 ATT-BiLSTM 使用相同的训练集和测试集以及运行环境，具体的参数如表 4-5 所示。

表 4-5 模型运行环境参数

| 环境配置 | 参数 |
|---|---|
| PyCharm | 2024.1.1 community edition |
| Python | 3.10.1 |
| CPU Intel(R) Core(TM) | i9-10980HK |
| GPU | NVIDIA GeForce RTX 2070 |
| 内存大小 | 16G |

本文的股票数据集为上证指数近十五年的数据累计 3377 条，原始数据集中包括了基本的数据指标，后又添加了技术指标和关键转折点信息。最后在此数据集的基础上对数据进行特征降维，将降维后的数据前 80%作为训练集，剩下的 20%作为测试集，利用 ATT-BiLSTM 模型进行训练。

在本文股价预测研究中，采用滑动窗口滚动的方法来预测未来短期股票收盘价，即用过去一段时间内上证指数的相关输入数据，预测未来一天的收盘价。

设置模型参数，调整模型。模型参数主要包括输入数据的滑动窗口大小（Timestep），batch size 和 epoch 的选择，输入层、输出层的节点数、BiLSTM 网络的隐藏层数量的确定。

利用构建的 ATT-BiLSTM 优化模型分别预测上证指数未来 1 日的收盘价，并利用相关评价指标验证本文所建 ATT-BiLSTM 模型的有效性。在各种参数及运行环境不变的情况下，分别用 LSTM，BiLSTM 模型以及其他时间序列预测模型进行训练，并预测上证指数未来 1 日的收盘价，从而通过比较证明 ATT-BiLSTM 模型的优越性。

运用构建的 ATT-BiLSTM 优化模型（分别设置“加入情感分数”与“不加入情感分数”两组实验），分别对上证指数未来 1 日的收盘价进行预测，同时借助相关



中国知网　https://www.cnki.net

评价指标（如 MAE、RMSE 等），对比两组实验的结果，验证“引入情感分数”对 ATT-BiLSTM 模型有效性的影响。

本文的预测结果采用滑动式预测的方式。设 T 为基准预测时间节点，构建第 $T$ 天的输入数据组成的 n 维特征向量：

$$X_T = \{x_{T1}, x_{T2}, \dots, x_{Tn}\}.$$

其中$x_{T1}, x_{T2}, \dots, x_{Tn}$为第 T 日的经过筛选后的输入特征，如开盘价、最高价等等。

设 Timestep 为滑动窗口的长度，则输入的数据可表示为连续时间窗口特征向量的集合：

$$X = \{X_T, X_{T+1}, X_{T+2}, \dots X_{T+Timestep-1}\}.$$

输出值为股票未来 1 日的收盘价$Y_{T+Timestep}$。如果 Timestep 的值 15，则表示用前 15 天的指标数据预测第 16 天的股票收盘价，如图 4-2 所示。

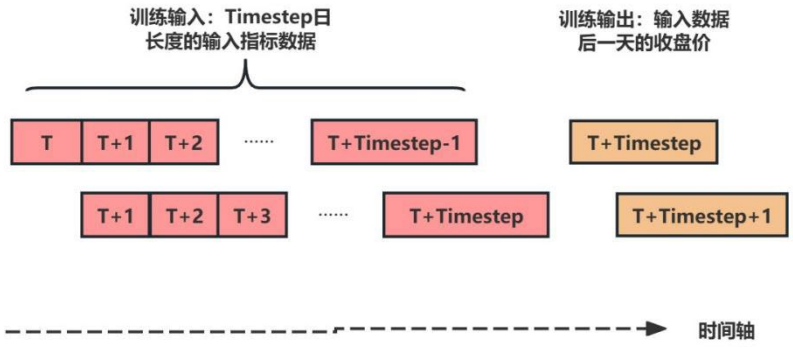



图 4-2 时间序列滑动预测示意图

**一、数据预处理**

在使用 ATT-BiLSTM 深度学习模型之前，本文对所收集到的特征数据进行了预处理，步骤具体如下：

首先是数据导入，本文读取了上一章节中选定的候选特征列表，将训练所需数据（即“输入特征向量的集合”与 “对应日期的股票收盘价”）载入模型。输入数据按时间顺序排列，确保时序数据的连续性。

将时序数据转换为模型所需的序列格式：输入序列$X$的形状为（样本数，timestep，特征维度的个数 n），输出标签$Y$的形状为（样本数，1），对应未来 1 日



中国知网 https://www.cnki.net

的收盘价。对 ATT-BiLSTM 各层的权重与偏差参数进行初始化，将数据集划分为 80%的训练集和 20%的测试集。

其次，数据标准化：为了消除不同特征之间的量纲差异，避免数值尺度对模型训练造成干扰，并提升模型的收敛速度与预测稳定性，本文采用了 Z-score 标准化方法对输入特征进行标准化的预处理，其计算公式如下：

$$x^* = \frac{x-\mu}{\sigma}. \tag{4.15}$$

其中，$x^*$是标准化后的值，$x$是原始输入数据，$\mu$是输入数据的均值，$\sigma$是输入数据的标准差。

处理之后的各特征均被映射到以 0 为均值、1 为标准差的统一尺度，有利于模型在训练过程中更有效地学习特征之间的相对关系。

二、ATT-BiLSTM 模型架构设计

本文构建的神经网络模型以双向长短期记忆网络为基础模型，并融合注意力机制层，实现对时序数据的深度特征挖掘与加权聚合，最终完成上证指数收盘价的预测任务。神经网络的结构示意图如图 4-3 所示。

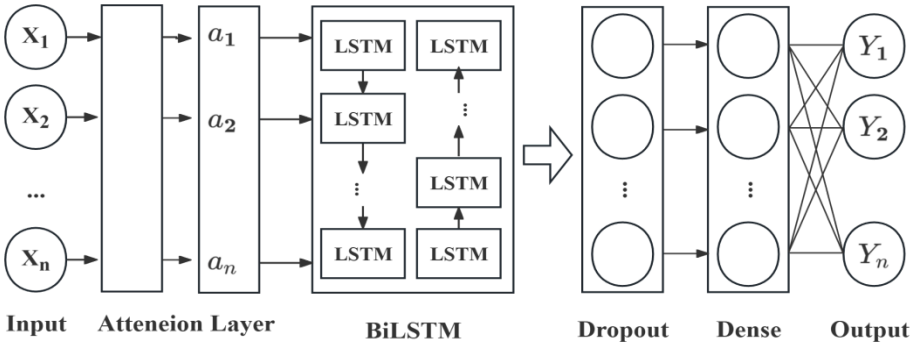



图 4-3 神经网落结构示意图

模型的具体层级结构与功能设计如下：

输入层：主要功能是由第四章第一节所提到的，将特征数据进行预处理，为后续特征提取与建模提供规范化的输入基础。输入序列$X = \{X_1, X_2, \ldots X_n\}$，每一层的权重设置初始化。

注意力机制（ATT 层）计算：由第二章的理论知识提到的，注意力机制层对经过初始化处理的输出特征数据进行关键信息的甄别与权重的动态重新分配。这一步



中国知网　https://www.cnki.net

的操作可以强化对股价预测影响力更高的特征分量，弱化无关或低价值的冗余特征。该层会最终生成融合了特征重要性权重的输出结果。其具体步骤可以简单分为注意力机制得分的计算和注意力权重的获取。对每个$X_i(i=1,2,\ldots\ldots,n)$计算注意力得分$e_i$，再通过函数进行归一化，得到注意力权重$a_i$，它的值越大，说明该部分的对最终预测贡献越大。最终输出加权后的变量$\tilde{X}_i = \alpha_i \cdot X_i$。

双向 LSTM 层：由第二章的理论知识可得，BiLSTM 层通过同时构建正向与反向两个 LSTM 网络，对金融时间序列数据的前向与后向依赖关系进行联合建模。该结构能够在同一时间步综合利用历史信息与未来上下文特征，从而更全面地刻画股价序列的动态变化特征，增强模型对趋势结构、长期依赖关系及非线性时序特征的学习能力。以前向为例，输入加权后的$\tilde{X}_i$，得到隐藏层向量$H_i$。

Dropout 层：以 20% 的概率随机丢弃 BiLSTM 层中的部分神经元，防止过拟合，提高模型在测试集上的泛化能力。

Dense 层：在完成上述步骤后，通过输出层对特征进行映射，得到与股价预测目标相匹配的输出维度。

输出层：根据 Dense 层的结果，得到模型的输出值 $Y$。

### 三、预测效果评价指标

为了更为精确地测定股价预测模型的有效性，本文研究选定了以下三项核心评估指标：均方根误差（RMSE）、平均绝对误差（MAE）以及拟合优度系数（$R^2$）。

（一）均方根误差（RMSE）

在量化预测误差方面，RMSE 通过预测值与实际值间差的平方后求平均，并计算该值的平方根，从而得到误差量。RMSE 对较大的误差特别敏感，它能够精确地展示模型在面对极端条件时的预测准确性。RMSE 的值越小，表示模型的预测误差越小，RMSE 的具体计算公式如下：

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(Y_i - \hat{Y}_i\right)^2}. \tag{4.16}$$

（二）平均绝对误差（MAE）



中国知网　https://www.cnki.net

股价预测中可能包含异常值（如极端涨跌），MAE 对所有误差给予相同权重，能够减少这些异常值对模型评价的影响，提供了稳健的评估结果，MAE 越小越好，其计算公式为：

$$MAE = \frac{1}{n}\sum_{i=1}^{n} \left|Y_i - \hat{Y}_i\right|. \tag{4.17}$$

（三）拟合优度系数（$R^2$）

在股价预测中，投资者不仅关心模型的预测精度，还关心模型是否能够捕捉到股价波动的趋势和模式。$R^2$ 能够较好地反映这一点，因为它衡量的是自变量（如历史股价、交易量等）对因变量（未来股价）的解释程度，提供了全面的模型拟合效果评估，$R^2$ 越接近 1 越好，其计算公式为：

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{\sum_{i=1}^{n}(Y_i - \bar{Y}_i)^2}. \tag{4.18}$$

（四）平均绝对百分比误差（MAPE）

对于不同股票，由于价格量级的不同，仅仅通过上述指标无法直观对比，因此本文额外加入 MAPE 平均指标，适合不同尺度序列对比。MAPE 越小，代表模型预测精度越高。其计算公式为：

$$MAPE = \frac{100\%}{n}\sum_{i=1}^{n} \left|\frac{Y_i - \hat{Y}_i}{Y_i}\right|. \tag{4.19}$$

其中，上述公式中的 $Y_i$ 为第 $i$ 个样本收盘价的真实值，$\hat{Y}_i$ 为第 $i$ 个样本收盘价的预测值，$\bar{Y}_i$ 为样本收盘价的平均值。

## 第三节　基于 ATT-BiLSTM 模型的股价预测结果分析

### 一、神经网络模型超参数设定

在构建 ATT-BiLSTM 模型时，各项超参数的设定综合考虑了已有研究经验、本研究数据特征以及多轮实验结果，具体的参数如表 4-6 所示。

表 4-6 实验参数设计

| 超参数 | 设定值 |
|---|---|
| 滑动窗口长度（Timestep） | 30 |
| 输入层节点 | 5 |



中国知网　https://www.cnki.net

| | |
|---|---|
| 输出层节点 | 1 |
| 批次大小（batch size） | 32 |
| 训练轮数（epoch） | 200 |

首先，确定滑动窗口大小。在金融时间序列建模中，滑动窗口大小决定了模型每次能够利用的历史信息长度。若窗口过短，模型会难以刻画输出变量与输入变量在中长期内的动态关系；若过长，则会引入过多噪声并增加训练难度。结合股票市场一个月左右的交易周期特征，以及已有的研究的常用取值区间（10～60 个时间步），本文最终将滑动窗口长度设定为 30。通过使用过去 30 个交易日的特征序列，来预测下一期的收盘价。

其次，确定每层的节点数。模型的输入层与输出层节点数由问题本身自然决定：输入层节点数等于选取的特征维度数 n（本研究依据随机森林特征选择的结果的集合），输出层仅预测下一期的单一收盘价，因此输出层节点数为 1。

BiLSTM 隐藏层的层数与每层节点数则在模型表达能力与过拟合风险之间权衡确定。一般而言，隐藏层越深、节点数越多，模型拟合能力越强，但参数规模迅速膨胀、对样本量要求更高、训练不稳定性增加。结合本研究样本规模以及训练效果，本文采用两层双向 LSTM 结构，第一层设置 64 个隐藏单元、第二层设置 32 个隐藏单元，使网络在保持较强特征提取能力的同时，避免参数量过大。学习率设置为 0.001，这是 Adam 优化器在时间序列预测任务中的常用初始值。本文在预实验阶段对 0.01、0.001、0.0001 三个候选值进行了对比，而 0.001 在收敛速度与训练稳定性之间取得了较好的平衡，在 200 轮训练内可以保证充分收敛。

最后，确定批次大小（batch size）和训练轮数（epoch）。在训练策略方面，batch size 和 epoch 直接影响模型收敛效率与泛化性能。过小的 batch size 会导致梯度波动大、训练时间长；过大的 batch size 虽然单次更新更稳定，但容易陷入局部最优的结果。本文将 batch size 设为 32，这是深度学习实践中常用且在多次预实验中表现较为稳定的取值。在训练轮数方面，若 epoch 过少，模型尚未充分学习；过多则易过拟合。为此，本文将最大训练轮数设置为 200，并引入基于验证集损失的早停机



中国知网　https://www.cnki.net

制，当验证损失在若干轮内不再下降时提前终止训练，从而在保证模型充分收敛的前提下自动控制有效训练轮数。

总体而言，各项参数的选取均在文献经验指导下，通过多组对比实验不断调优，最终在模型复杂度、训练可行性与预测精度之间取得较为合理的平衡。

## 二、模型的预测结果及改进的模型机制预测结果对比

针对上一小节构建的 ATT-BiLSTM 股价预测模型，将数据集划分为 80%的训练集和 20%的测试集。将股票数据输入模型进行训练。通过多轮训练，神经网络反复比较预测结果与真实值之间的差别，并不断修正模型参数，使得在训练集上的预测结果逐渐逼近股价真实值，得到预测结果。而预测结果又经过反归一化处理后，得到最终的股价预测值。研究得到的预测结果的示意图，如图 4-4 所示。得到的部分预测值与真实值，如表 4-7 所示。

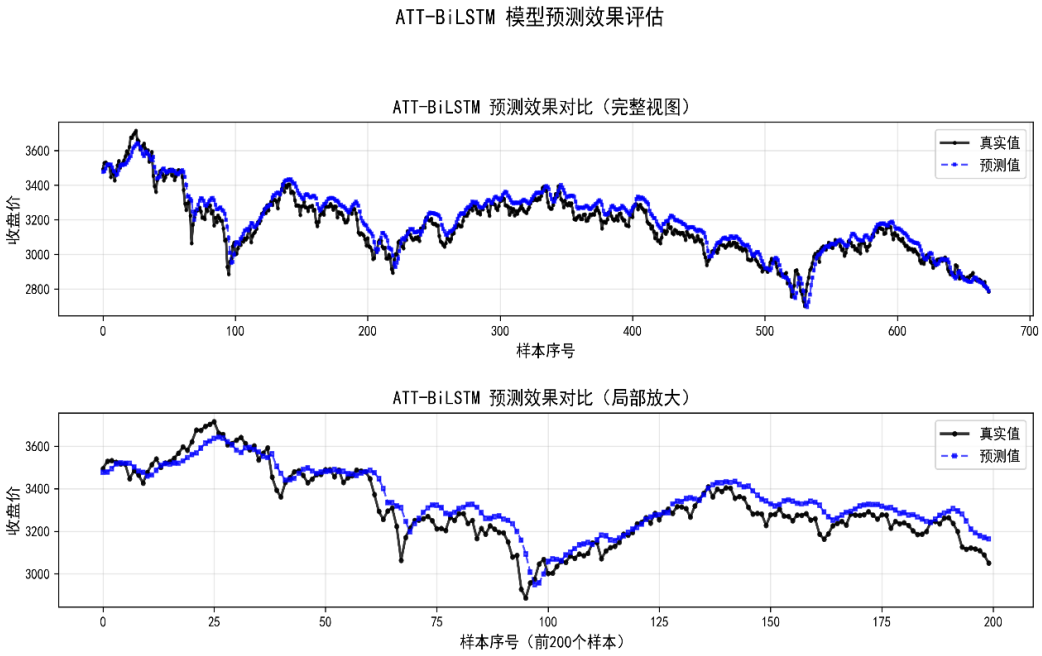



图 4-4　ATT-BiLSTM 模型预测结果示意图

表 4-7　部分预测值与真实值

| 时间 | 收盘价真实值 | 收盘价预测值 |
|---|---|---|
| 9/8/2021 | 3494.63 | 3477.26 |
| 10/8/2021 | 3529.93 | 3479.53 |



中国知网　https://www.cnki.net

| | | |
|---|---|---|
| 11/8/2021 | 3532.62 | 3495.39 |
| 12/8/2021 | 3524.74 | 3516.69 |
| 13/8/2021 | 3516.3 | 3521.93 |
| …… | …… | …… |

由图 4-4 可以看出，横坐标代表日期序列，纵坐标代表收盘价格。蓝色虚线表示由 ATT-BiLSTM 模型所做出的预测，首先可以观察到预测曲线与真实值曲线高度贴合，与真实值较为接近，说明模型对平稳行情的细节捕捉能力较强；但模型对价格快速上升或者下降的波动时的预测值略有滞后，但在可接受的范围之内。

图 4-4 中的局部放大视图（前 200 个测试集样本）显示，模型对短期股价的小幅震荡与趋势反转均有精准响应，例如在样本序号 50 左右，预测值同步跟进且偏差控制在合理范围，验证了模型对短期时序特征的捕捉能力。

但在较为剧烈的突发波动发生时，模型也会存在小的偏差，例如在样本 75-100 的区间之间，真实值经历了较明显的下行，而预测值普遍在真实值之上。这说明在复杂的震荡行情下，模型的预测稍显不足。

由表 4-7 中节选的预测数据可以得知，模型预测的相对误差多数控制在 1.5% 以内，整体的预测精度能满足短期股价预测的实际要求。

为了进一步验证本文所引进的注意力机制与双向长短期记忆网络的优越性，本文在保证其他超参数不变的情况下，分别使用了以下模型进行消融实验：

1. 普通的单向 LSTM 模型；
2. ATT-LSTM 模型，即只添加了注意力层的单向长短期记忆网络模型；
3. BiLSTM 模型，即单独的双向长短期记忆网络。

通过以上三个模型作为对比模型，本文得到的预测结果及对应评价指标如表 4-8 所示，预测结果的示意图如图 4-5 所示。



中国知网　https://www.cnki.net

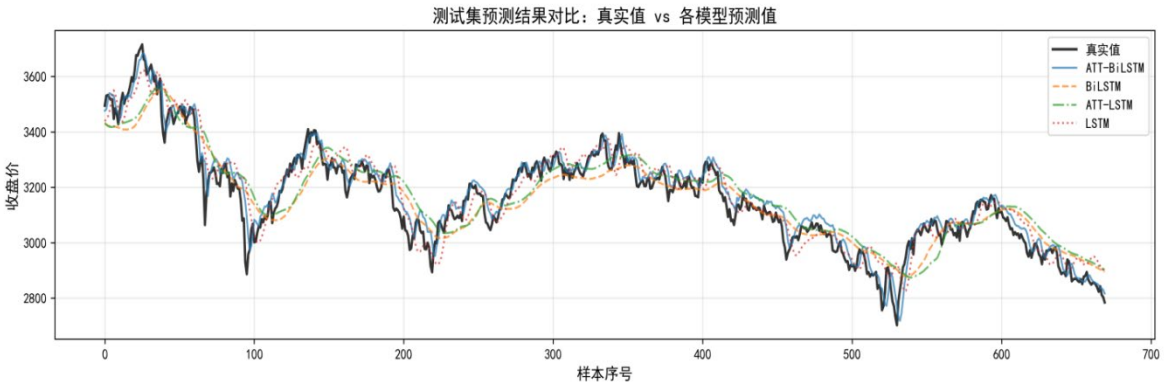



图 4-5　不同改进机制的模型预测结果示意图

表 4-8　改进的模型与未改进的模型的评价指标结果对比

| | $R^2$ | MAE | RMSE |
|---|---|---|---|
| ATT-BiLSTM | 0.952395 | 30.62665 | 39.54964 |
| BiLSTM | 0.874755 | 47.70149 | 64.15023 |
| ATT-LSTM | 0.848046 | 54.80408 | 70.66000 |
| LSTM | 0.795126 | 64.95666 | 82.04659 |

从表 4-8 的模型评估结果和图 4-5 的评估效果来看，可以更细致地解读出以下信息：

代表 ATT-BiLSTM 模型的蓝色实线与真实值的黑色实线的拟合程度是最贴合的，而其余拟合线则次之。图片直观反映了模型的预测“优劣性”。

结合 $R^2$、RMSE、MAE 等指标结果，模型表现从优到差的优先级为：ATT-BiLSTM > BiLSTM > ATT-LSTM > LSTM。首先，这说明双向结构和注意力机制的加入，的确对提升股价预测模型的性能效果有显著影响。

对比“BiLSTM 与 LSTM”和“ATT-BiLSTM 与 ATT-LSTM”这两对组合。BiLSTM 的 $R^2$比 LSTM 高 0.0797，MAE 降低 26.56%，RMSE 降低 21.8%；ATT-BiLSTM 比 ATT-LSTM 高 0.1043，MAE 降低了 44.11%，RMSE 降低了 44.0%。在加入双向结构后，$R^2$ 有明显提升，同时误差指标有所降低。这说明双向结构能更全面地捕捉股价时间序列的前后依赖关系，对模型的影响力更大，具有核心价值。

对比“ATT-LSTM 与 LSTM”和“ATT-BiLSTM 与 BiLSTM ”这两对组合。ATT-LSTM 的 $R^2$较 LSTM 提升 0.0529，MAE 降低了 15.63%，RMSE 降低了 13.9%。ATT-



中国知网　https://www.cnki.net

BiLSTM 的 $R^2$ 较 BiLSTM 提升 0.0776，MAE 降低了 25.76%，RMSE 降低了 38.4%。这一结果验证了注意力机制的有效性，相较于双向结构的引入具有补充价值。

### 三、与传统机器学习模型的预测对比

为全面评估 ATT-BiLSTM 模型在股价预测任务中的性能，本文也将其与多种主流的机器学习预测模型进行了对比，例如支持向量机回归模型（SVR）、随机森林回归（Random Forest Regressor）、XGBoost。模型的预测结果示意图如图 4-6 所示，评价指标对比结果如表 4-9 所示。

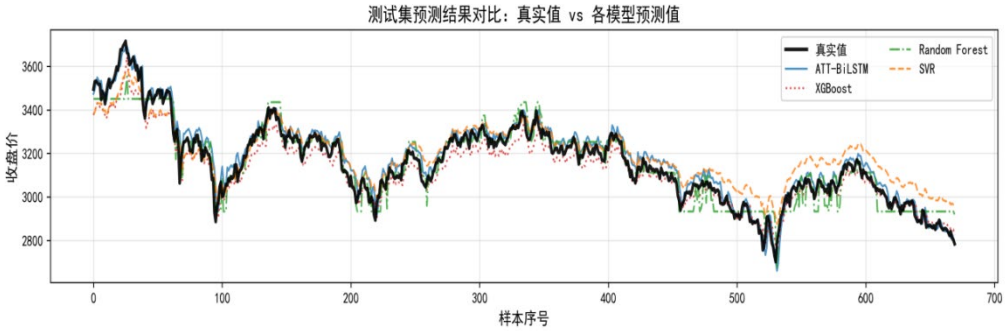



图 4-6　与传统机器学习模型对比的预测结果示意图

表 4-9 改进的模型与其他传统模型的评价指标结果对比

| | $R^2$ | MAE | RMSE |
|---|---|---|---|
| ATT-BiLSTM | 0.952395 | 30.62665 | 39.54964 |
| XGBoost | 0.89943 | 46.13987 | 64.15023 |
| Random Forest | 0.882614 | 46.125097 | 70.66000 |
| SVR | 0.812672 | 64.704128 | 82.04659 |

结合图 4-6 的预测结果与表 4-9 的各项指标，可以看出：ATT-BiLSTM 模型在整体预测性能方面显著优于对比的传统机器学习模型。

首先，通过图 4-6 可以反映出：ATT-BiLSTM 在所有行情下都基本表现为最优模型，与真实值的拟合程度最高。而 XGBoost、随机森林在平稳行情的情况下表现较好，但在极端行情时偏差明显增大， SVR 模型则与真实值的拟合程度最低，在股价上涨时，预测值持续低估，而在股价下降时，预测值持续高估。



中国知网　https://www.cnki.net

通过表 4-9 可以进一步看出：ATT-BiLSTM 模型的 $R^2$ 指标达到了 0.95，明显高于 XGBoost（0.89）、随机森林（0.88）以及 SVR （0.81）等模型。这表明该模型在短期的股价预测的领域具有更强的预测能力。而 MAE、RMSE 各项指标也均比 SVR 等传统的机器学习模型更低。这说明改进后的机器学习模型，在预测精度和稳定性上均表现出更优的效果，预测结果与真实值之间的偏差更小。

传统机器学习模型中，XGBoost 与随机森林的表现相对更优，这得益于其集成学习的特性。但此类模型仍难以处理时序数据的动态依赖关系，导致在短期股价波动预测中误差较大。而 SVR 模型表现较差，这也许是因为 SVR 对高维非线性数据的预测能力较为有限。

因此，相比于传统的机器学习模型，ATT-BiLSTM 能够在更复杂的、具有非线性的股价时间序列中取得更优的表现。

## 第四节　不同预测长度与个股差异下的预测结果对比

为了验证 ATT-BiLSTM 模型的泛化能力，本文参考了盘世康（2024）融合多源文本情绪数据的个股股价预测等研究，综合考虑并选取了数据完整的、市场流动性好、行业代表性强的以下几只个股的相同时间范围的数据作为研究对象：贵州茅台（600519）、招商银行（600036）、宁德时代（300750）、中际旭创（300308）。

具体而言，所选择的个股满足以下条件：

1.历史交易数据连续，以保证模型可以充分利用股票数据加以训练；

2.成交活跃、换手率高，能够较为及时的反应市场的波动状况以及投资者的情绪；

3.在所属的行业属于龙头企业，具有一定的代表性。

所选四只股票分别覆盖了消费（贵州茅台）、金融（招商银行）、新能源（宁德时代）和科技（中际旭创）四大行业，且其市值规模大部分在万亿级（除招商银行在千亿级），因此具有一定代表性。通过选择行业龙头和具有显著规模的企业，研究能够在有限样本下较好地反映不同领域的市场特征和波动。值得补充的是，本研究仅选取了四只股票作为示例，结果可能受限于个股特性。在未来研究中可考虑扩大选股样本数，包括更多行业和规模层级，以提高分析结论的稳健性和普适性。



中国知网　https://www.cnki.net

本节延续第三节中的研究内容，依旧选取并计算了各股票基本指标以及技术指标的值，时间范围从 2020 年 1 月到 2025 年 12 月，共计 5824 条数据，数据来源依旧为东方财富网和新浪财经网。

所选取股票价格的收盘价趋势如图 4-7 所示。由于股票价格之间各有不同，为了消除量纲差异，更好的观察股价的涨跌幅走势。本文又以首日的价格为基准，以每一天的收盘价除以各自基准价，绘制了股价相对首日价格的涨跌趋势图。可以看出，四只股票具有一定的价格差异，其中贵州茅台作为 A 股白酒龙头行业，价格水平最高，并且走势稳定。宁德时代随着 2020 到 2023 年新能源行业的迅速发展股价趋势有较大水平的提升。中际旭创长期处于低价区间，但自 2025 年起伴随 AI 算力与光模块需求爆发，出现显著的拉升行情，涨幅最为突出。而招商银行则在整个观测区间走势最为平稳，波动幅度也最小。

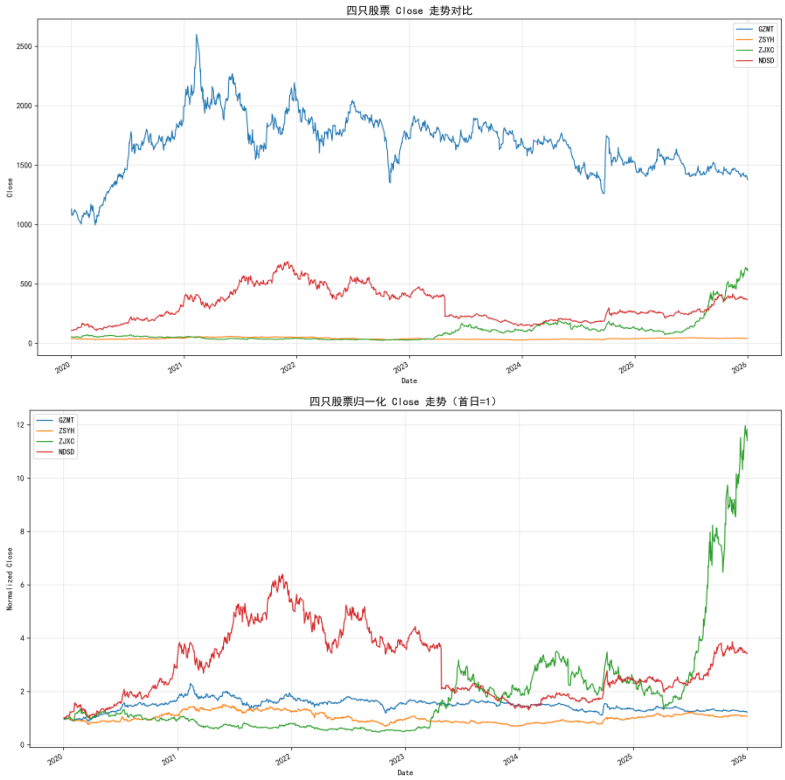



图 4-7 股票价格的收盘价趋势

在预测实验设计方面，本文分别设置不同的预测长度（1 日、3 日和 5 日）以对比刻画短期与中短期预测效果，同时结合了四只个股之间的特征差异，对模型的预测性能进行横向与纵向对比分析。其中，横向对比是指在不同个股之间的预测精度



中国知网　https://www.cnki.net

的差异，旨在检验模型对不同市场特征的适应能力；纵向对比则通过不同预测步长下的结果变化，分析预测区间延长对模型性能的影响。预测的结果与各项指标由表 4-10 和图 4-8 至图 4-11 所示。

表 4-10 不同预测长度与个股差异下的预测结果对比

| | 预测天数 | $R^2$ | RMSE | MAE | MAPE（%） |
|---|---|---|---|---|---|
| 贵州茅台 | 1 | 0.932421 | 15.69919 | 12.6026 | 0.844957 |
| | 3 | 0.913497 | 17.76181 | 14.7133 | 0.989021 |
| | 5 | 0.862378 | 22.37716 | 18.11 | 1.214301 |
| 招商银行 | 1 | 0.952747 | 0.553567 | 0.447318 | 1.049487 |
| | 3 | 0.930419 | 0.729746 | 0.506346 | 1.202884 |
| | 5 | 0.892319 | 0.834211 | 0.670943 | 1.589861 |
| 宁德时代 | 1 | 0.986738 | 6.251943 | 4.743792 | 1.284585 |
| | 3 | 0.953655 | 11.68719 | 8.62144 | 1.524023 |
| | 5 | 0.916018 | 15.74855 | 12.60454 | 1.713742 |
| 中际旭创 | 1 | 0.975240 | 26.600964 | 16.462505 | 1.723147 |
| | 3 | 0.949530 | 37.97839 | 23.665743 | 1.967539 |
| | 5 | 0.923788 | 46.554111 | 29.765533 | 2.263623 |

由表 4-10 展示了基于 ATT-BiLSTM 模型对四只股票在 1 天、3 天、5 天三个日期的拟合程度，评估指标包括 $R^2$、RMSE、MAE 和 MAPE。

由表格可以看出，对于贵州茅台、招商银行、宁德时代和中际旭创四只股票，模型的预测效果都比较优秀。首先对同一只股票进行纵向对比：预测日期越长，则模型精度衰减。1 天的各股票预测的 $R^2$都在 0.93 以上，且 MAPE 控制在 1.6%之内。这说明 ATT-BiLSTM 模型可以较为精准地捕捉这些股票价格短期内的收盘价的趋势。而随着预测日期的增长，在预测日期为 5 天的情况下，$R^2$会下降至在 0.9 左右，而 MAPE 也会增加至 2%左右，RMSE、MAE 也均会逐步上升。这说明预测的时间区间越大，则不确定性越高，预测精度也越低。这也符合时间序列预测过程中的一般规律。



中国知网　https://www.cnki.net

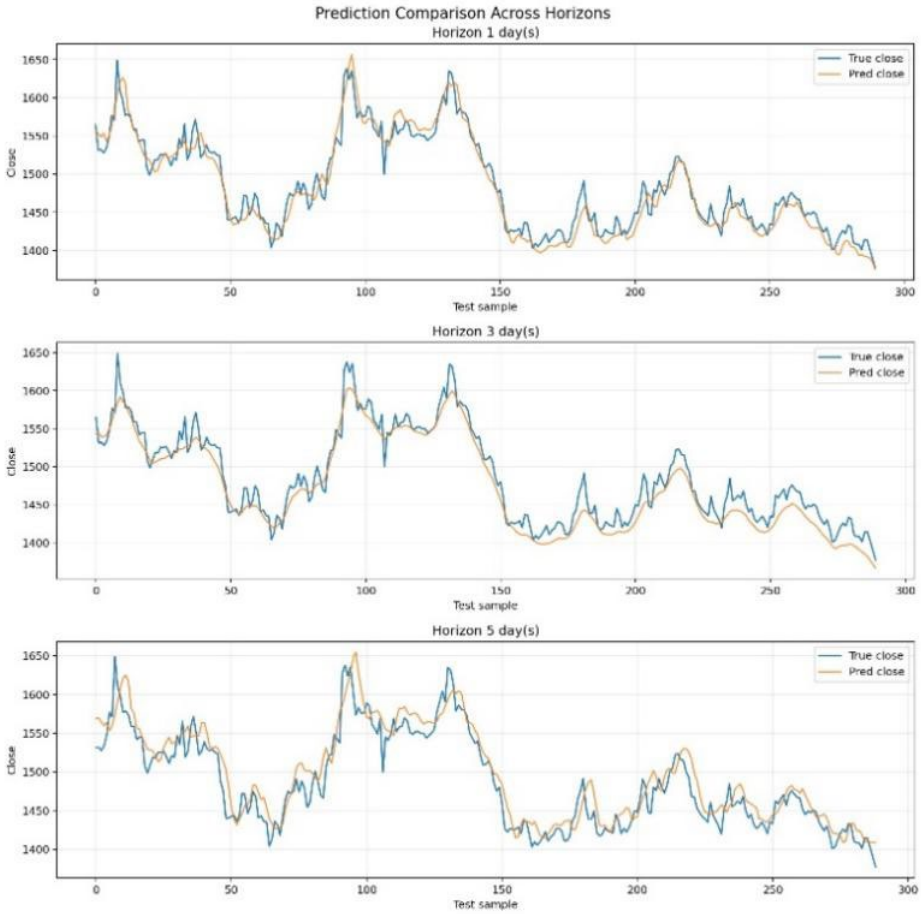



图 4-8 贵州茅台 1、3、5 日的预测结果示意图

结合个股的预测趋势图纵向观察研究结果。由图 4-8 可以看出，贵州茅台的 1 天预测与真实值最为接近，而在 3、5 天的预测周期中，图像在急涨急跌转折点处（如预测图的第 100 个样本左右的区域）会出现一定的偏差。贵州茅台股票的收盘价绝对值较高，但是其波动相较于其他三只股票是最为稳定的，在此情况下 ATT-BiLSTM 模型的预测能力也是相对较优的。



中国知网　https://www.cnki.net

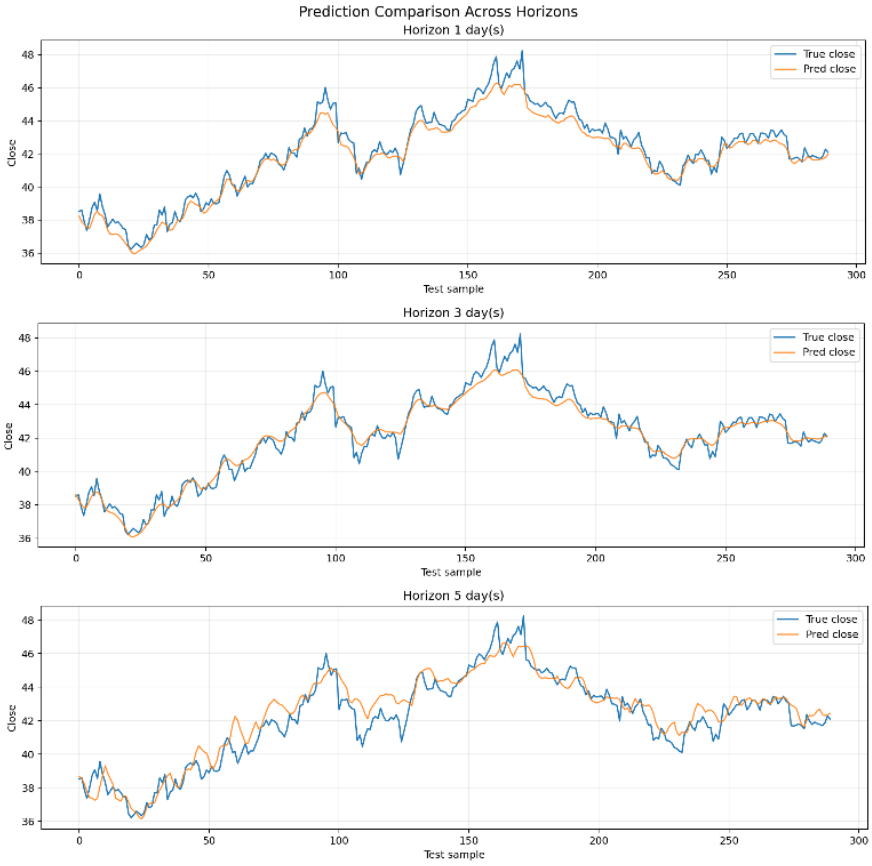



图 4-9 招商银行 1、3、5 日的预测结果示意图

由图 4-9 可以看出，在招商银行股价波动的绝对值区间较窄（35～48）的情况下，由前 1、3 日的预测结果图可以看出，模型预测曲线与真实值仍旧较为贴合，在约 100 个样本的区间上股价的转折均可以被模型捕捉。但在 5 天的预测图中，虽然预测的趋势方向基本正确，曲线在第 100 样本后的下行段及后续回升段均存在一定的滞后，波动细节损失明显，对应 $R^2$=0.892、MAPE=1.59%明显增加，预测精度下降的程度较高。因此，ATT-BiLSTM 在招商银行股价上的预测短期精准，长期趋势表现不如其他的股票，但是总体预测表现仍旧处于较优水平，模型在精度与稳定性之间取得了较好的平衡，体现出良好的鲁棒性与应用潜力。



中国知网　https://www.cnki.net




图 4-10 宁德时代 1、3、5 日的预测结果示意图

由图 4-10 观察宁德时代股价的预测情况，ATT-BiLSTM 模型预测的总体 $R^2$都保持在 0.91 以上，1 日预测的 $R^2$更是高达 0.98，模型的总体预测效果优秀。

可以看出，在前 200 个样本（价格相对平稳区间）内，1、3、5 日的模型预测曲线与真实曲线都贴合紧密，但在 200 个样本之后股价迅速上升的区间里，3、5 日的预测曲线会有略微滞后的现象，预测值较真实值更低。尤其在 5 日预测结果中，预测值与真实值出现大范围的偏离，对应的 RMSE 升至 15.75、MAPE 升至 2.11%。因此，宁德时代总体综合表现是最优，但也存在股价波动处的小幅预测偏差。

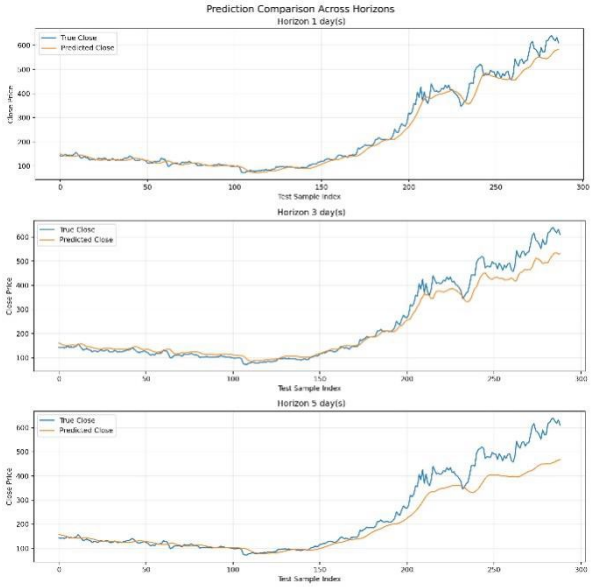



图 4-11 中际旭创 1、3、5 日的预测结果示意图



中国知网　https://www.cnki.net

最后，综合观察中际旭创的预测情况。图 4-11 中，第 0～120 个样本的前半段预测曲线与真实曲线几乎完全重叠，两条曲线紧密贴合，模型在这一阶段表现近乎完美，误差极小。但在 120 个样本之后的后半段，3、5 日的预测值的出现系统性低估的情况。$R^2$也从 0.975 下降至 0.924，RMSE 从 26.6 扩大至 46.6。

综上所述，针对贵州茅台、招商银行这类波动较为规律、发展较为稳定的个股，模型在三个预测周期下都表现得均衡稳定，预测曲线与真实曲线贴合紧密。即便是在 5 天的预测情况下，ATT-BiLSTM 模型仍能准确把握中期趋势方向，仅在急涨急跌转折点处存在轻微滞后，具有鲁棒性，这进一步说明了双向神经网络和注意力机制的优越性。

而类似于宁德时代、中际旭创这类近期存在着一定波动性的股票而言，ATT-BiLSTM 模型对其平稳区间的预测表现优异，在后期快速地拉升阶段也能基本跟随趋势方向。这说明 ATT-BiLSTM 对高波动但趋势性强的股票同样具备良好的适应能力。但是，对于结构性突变的股价行情而言，预测水平存在一定幅度的低估，预测能力仍旧有提升空间。

通过上述实验，进一步论证了 ATT-BiLSTM 模型的优越性：双向神经网络的机制通过读取时间序列的前向与后向依赖关系，更充分地挖掘了股价数据中的时序特征。而注意力机制则对不同特征及时间步的重要性进行动态加权，强化了关键信息的表达并抑制了冗余与噪声干扰。在此基础上，情感因子的融合进一步补充了市场情感维度，使模型能够更有效地捕捉投资者心理变化对股价波动的驱动作用。

## 第五节　融入投资者情感的模型预测

在股票价格预测研究中，单一的基础指标和技术指标，往往难以充分地刻画金融市场所呈现的高度复杂性与动态变化特征。

因此，本文基于互联网所具有的丰富的文本材料这一背景，将投资者文本所产生的情感指标相关因素作为输入指标，引入本章第二节构建完成的 ATT-BiLSTM 机器学习模型。新的模型输入因素除了经过随机森林所筛选的各项基础指标与技术指标之外，还包含了由实时股吧评论所计算而来的投资者情感分数。在这种情况下，



中国知网　https://www.cnki.net

与之前搭建的 ATT-BiLSTM 在相同的参数与环境的情况下进行综合建模，尝试从多维信息视角下，构建更为系统的预测框架。

模型所得到的预测结果示意图如图 4-12 所示，所得到的各项指标评价结果对比如表 4-11 所示。

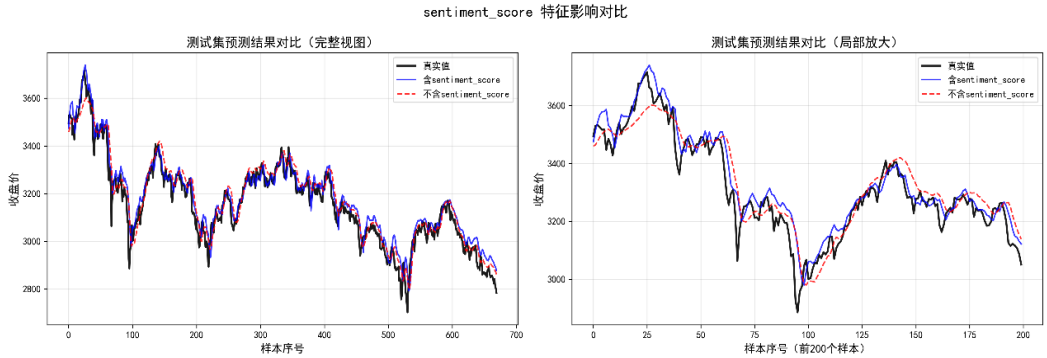



图 4-12 融入股民情感与否的模型预测示意图

表 4-11 指数融入股民情感与否的模型评价指标结果对比

| | $R^2$ | MAE | RMSE |
|---|---|---|---|
| 融入投资者情感的 ATT-BiLSTM 模型 | 0.960514 | 27.35084 | 27.35089 |
| 未融入投资者情感的 ATT-BiLSTM 模型 | 0.952395 | 30.62665 | 39.54964 |

实验结果表明，在引入了情感因子后，模型在各项误差指标上均表现出更进一步的优化。融入情感因子的蓝色实线与真实值的重叠度较高于红色虚线，在股价波动较大的区间，蓝色实线的偏差更小。例如图 4-12 局部放大后的预测对比图中，由 0-50 以及 125-150 这两个样本区间可以看出，在加入了情感因子之后，模型的预测值与真实值之间的贴合程度更为紧密。而未加入情感因子的预测曲线在多个转折点处会出现明显的滞后，这说明含情感特征的模型的响应会更加的敏锐。

在未进行特征优化的条件下，基础模型的 $R^2$=0.95，RMSE=39.55，MAE=0.95，在预测精度与稳定性方面均表现出较优水平，能够较为有效地刻画了股价时间序列的变化趋势。而在融合情感因子后，模型性能有进一步的改善，RMSE 降低了 30.84%；MAE 降低了 10.67%；$R^2$增加到了 0.96，增加了 00.85%。这一结果表明，情感因子的引入仍能提升模型的预测能力，但优化空间仍然是有限的。



中国知网 https://www.cnki.net

实验数据表明，模型的优化与情感因子的融合均能有效提升模型的预测能力，ATT-BiLSTM 模型本身的架构就已经具有较强的趋势捕捉的能力，而投资者情感的纳入可以使得模型曲线的波动更加平滑，与真实值的偏差更小，两者的结合效果最为显著。

同样针对四只个股（如贵州茅台、宁德时代等）进行对比试验，投资者情感指标的依旧遵循第三章的规则。数据来源为各个股票名称的股吧评论数据，收集到与交易日同步的股吧评论进行文本预处理、情感量化、指标合成等等操作，所得到的各个股融入情感前后评价指标对比如表 4-12 所示。

表 4-12 个股融入股民情感与否的模型评价指标结果对比

| | | $R^2$ | RMSE | MAE | MAPE |
|---|---|---|---|---|---|
| 贵州茅台 | 未融入投资者情感 | 0.932421 | 15.699190 | 12.602600 | 0.844957 |
| | 融入投资者情感 | 0.941836 | 14.862374 | 11.874296 | 0.811532 |
| 招商银行 | 未融入投资者情感 | 0.952747 | 0.553567 | 0.447318 | 1.049487 |
| | 融入投资者情感 | 0.958921 | 0.521438 | 0.421673 | 1.012364 |
| 宁德时代 | 未融入投资者情感 | 0.986738 | 6.251943 | 4.743792 | 1.284585 |
| | 融入投资者情感 | 0.987214 | 5.781362 | 4.381927 | 1.240816 |
| 中际旭创 | 未融入投资者情感 | 0.975240 | 26.600964 | 16.462505 | 1.723147 |
| | 融入投资者情感 | 0.981643 | 24.972851 | 15.371928 | 1.658203 |

如表 4-12 所示，选取了 1 日的预测步长，对比了四支代表性个股在是否加入投资者情感的两种情况下的模型表现。在引入投资者情感之后，所有测试的个股的 $R^2$ 均有不同程度的提升，平均增幅约为0.56%，贵州茅台的拟合优度提升最为直观。而 RMSE 平均下降 6.20%，MAE 平均下降 6.44%，MAPE 平均下降 3.67%，宁德时代和中际旭创的 RMSE 降幅则更加明显。

上述指标说明，在融入投资者情感后，模型的预测值不仅仅是偶然更加贴近了真实值，而是系统性的减少了预测的偏差。因此，这也证明股吧评论所包含的情感内容的确能弥补一部分传统的量化指标无法涵盖的缺陷。但是，由于模型本身的预测精度已经逼近了短期预测的较优水平，融入投资者情感的优化空间是较为有限的。



中国知网　https://www.cnki.net

# 第五章 结论与建议

## 第一节 结论

论文围绕投资者情感与机器学习方法相融合的方法，对股价预测问题展开研究。首先，利用词典法计算代表投资者情感的股吧评论情感分数，并借此计算单日的股评文本整体情感分数。随后，使用随机森林算法对收集到的基础指标、技术指标进行特征提取，特征降维。最后，进一步引入注意力机制和双向长短期记忆网络，将改进后的机器学习模型作为预测上证指数收盘价的工具。所得到的结论如下：

首先，在投资者情感量化方面：本文通过构建一种金融领域的文本情感词典，对股吧评论信息进行情感计算，形成可以量化的投资者情感分数，构建了新的情感指标，完善了股价预测的指标体系。实验结果表明，加入情感分数作为输入指标的神经网络模型，$R^2$提升至 0.96，MSE 降低了 52.17%；MAE 降低了 10.67%，进一步在拟合程度和预测误差水平优于未加入情感分数的对比模型，验证了模型的有效性与可行性。该情感指数能够有效反映市场情感变化，为股票价格预测提供了重要的补充信息，也为量化投资者情感提供了一种可行的方法。

其次，在股价预测模型方面：本文所构建的 ATT-BiLSTM 模型，相比以往的用来预测金融时间序列的传统机器学习模型而言，对特征维度和空间维度特征进行了加权优化，从而增强了模型对关键信息的关注能力，使得构建模型的输入指标体系更加的完善。实验结果显示，在引入双向注意力机制后，模型性能进一步提升，$R^2$提升至 0.95，比传统的 LSTM 模型的 $R^2$高 0.11，MSE 降低约 76.76%，且远高于 XGBoost（0.89）、随机森林（0.88）、SVR（0.81）。模型与未改进的机器学习模型、传统的机器学习模型对比，在指数及多只个股上的多项评价指标中都能表现出更优的预测效果。

综上所述，本文围绕股票价格预测问题，从数据处理、模型构建与实证研究等多个方面展开研究，提出的预测方法在理论分析与实证结果上均表现出较好的性能，为投资决策提供了一定的参考价值，也为后续基于投资者情感的金融预测研究提供了新的思路。



中国知网 https://www.cnki.net

## 第二节 对策建议

基于论文的研究结论，提出如下建议：

第一，加强对投资者情感信息的挖掘与应用。

研究结果显示，投资者情感指数能够在一定程度上捕捉市场情感的变化，并对股票价格预测产生积极影响。纵观现有的股价预测研究，其所采用的数据来源多集中在股票的基本指标、技术指标数据和公司的财报数据，而对社交媒体文本信息数据的挖掘还远远不够。针对这一现状，金融机构和研究人员可以进一步加大对网络评论、股吧信息及社交媒体数据的挖掘力度，借助情感分析、LDA 主题建模等 NLP 技术和 TF-IDF 算法等等统计方法，对投资者的情感进行进一步的量化，并将其作为金融市场分析的有效补充维度——甚至可以尝试构建动态的情感检测体系，以辅助投资策略的制定提供实时的参考。与此同时，监管部门也可从新闻、社交舆论的领域重点关注投资者情感波动对市场稳定性的影响，构建市场情绪的实时追踪与预警。公众情感的波动往往是潜在的非理性市场行为的前兆，若能从投资者情感层面建立追踪和预警机制，更好地把握市场运行情况，也间接有助于从宏观层面上提升对股价市场和金融市场调控的能力。

第二，在金融预测中积极地引入深度学习模型。

本文构建的 ATT-BiLSTM 模型在预测精度上优于传统机器学习模型，充分表明了深度学习方法在处理复杂金融时间序列数据时的确具有一定的过人之处。随着算力的持续提升、人工智能技术的日趋成熟，机器学习技术的应用场景遍及大众日常的方方面面，应用门槛也正在逐步降低，这为其在金融预测领域的推广应用创造了有利的条件。因此，对于金融机构和量化研究的团队而言，在预测股票价格趋势走向、风险评估、资产配置等等相关问题和研究中，深度学习模型已经具备了较强的实用价值。可以进一步推广和使用深度学习模型的应用。具体而言，可以结合注意力机制、图神经网络、Transformer 等前沿技术，提升模型预测结果的可信度与实用性，使其能够真正服务于实际投资决策场景，而不只是停留于理论研究的领域。



中国知网 https://www.cnki.net

# 参考文献

[1] Robert R. the Dow theory[M]. New York: Barron’s, 1932.

[2] Graham B, Dodd D. Security Analysis[M]. New York: McGraw-Hill, 1934.

[3] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.

[4] Damodaran A. Investment Valuation: Tools and Techniques for Determining the Value of Any Asset[M].3rd Edition, Hoboken: Wiley, 2012.

[5] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

[6] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[C]. International Conference on Learning Representations (ICLR). 2015.

[7] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems. 2017.

[8] Ani D, Ionel V C. Effectiveness of various types of analysis in investment decisions on the stock market: Fundamental analysis and technical analysis[J]. Ovidius University Annals, E-economic Sciences Series, 2012, 7(1): 1114-1119.

[9] Nosratabadi S, Mosavi A, Duan P, et al. Data Science in Economics: Comprehensive Review of Advanced Machine Learning and Deep Learning Methods[J]. Mathematics, 2020, 8(10): 1799.

[10]Fischer T, Krauss C. Deep learning with long short-term memory networks for financial market predictions[J]. European Journal of Operational Research, 2018, 270(2): 654-669.

[11]Bao W, Yue J, Rao Y. A deep learning framework for financial time series using stacked autoencoders and long-short term memory[J]. PloS ONE, 2017, 12(7): e0180944.

[12]Kumar S, Ningombam D. Short-term forecasting of stock prices using long short term memory[C]. Proceedings of 2018 International Conference on Information Technology (ICIT), 2018: 182-186.



中国知网 https://www.cnki.net

[13]Kim T, Kim H. Forecasting stock prices with a feature fusion LSTM-CNN model using different representations of the same data[J]. PLoS ONE, 2019, 14(2): e0212320.

[14]Thakkar A, Chaudhari K. Fusion in stock market prediction: a decade survey on the necessity, recent developments, and potential future directions[J]. Information Fusion, 2021, 65: 95-107.

[15]Ding G, Qin L. Study on the prediction of stock price based on the associated network model of LSTM[J]. International Journal of Machine Learning and Cybernetics, 2020, 11(6): 1307-1317.

[16]Wu J, Li Z, Srivastava G. A graph - based convolutional neural network stock price prediction with leading indicators[J]. Software: Practice and Experience, 2021, 51(3): 628-644.

[17]Liu H, Qi L, Sun M. Short-Term Stock Price Prediction Based on CAE-LSTM Method[J]. Wireless Communications and Mobile Computing, 2022 (S1):1-7.

[18]Sunny M, Maswood M, Alharbi A G. Deep Learning-Based Stock Price Prediction Using LSTM and Bi-Directional LSTM Model[C]. 2020 2nd Novel Intelligent and Leading Emerging Sciences Conference (NILES). 2020.

[19]Yang S, Guo H, Li J. CNN-GRUA-FC stock price forecast model based on multi-factor analysis[J]. Journal of Advanced Computational Intelligence and Intelligent Informatics, 2022, 26(4): 600-608.

[20]Ting X, Ling L, Yong H. A stock market trend forecasting method based on stock sentiment analysis[J]. Application of Electronic Technique, 2019, 45(3): 13-17.

[21]Salim L. Minute-ahead stock price forecasting based on singular spectrum analysis and support vector regression[J]. Applied Mathematics and Computation, 2018, 320: 444-451.

[22]Tsang P M, Kwok P, Choy S O, et al. Design and implementation of NN5 for Hong Kong stock price forecasting[J]. Engineering Applications of Artificial Intelligence, 2006, 20(4): 453-461.



中国知网 https://www.cnki.net

[23]Henry E. Are Investors Influenced by How Earnings Press Releases are Written? [J]. Journal of Business Communication, 2008, 45(4): 363-407.

[24]Zhang J L, et al. Distillation of News Flow into Analysis of Stock Reactions [J]. Journal of Business & Economic Statistics, 2016, 34(4): 547-563.

[25]Nti I K, Adekoya A F, Weyori B A. A systematic review of fundamental and technical analysis of stock market predictions[J]. Artificial Intelligence Review, 2020, 53: 3007-3057.

[26]Htun H H, Biehl M, Petkov N. Survey of feature selection and extraction techniques for stock market prediction[J]. Financial Innovation, 2023, 9: 26.

[27]Lee T W, Teisseyre P, Lee J. Effective exploitation of macroeconomic indicators for stock direction classification using the multimodal fusion transformer[J]. IEEE Access, 2023, 11: 10275-10287.

[28]Dutta A, Bandopadhyay G, Sengupta S. Prediction of Stock Performance in the Indian Stock Market Using Logistic Regression[J]. International Journal of Business and Information, 2012, 7(1): 105–136.

[29]Cheng S. Heterogeneity in Stock Price Forecasting-Based on the ARIMA-GARCH Model And PCA-LSTM Model[J]. Highlights in Science, Engineering and Technology, 2024, 88: 39-46.

[30]Wang Z. Stock price prediction using LSTM neural networks: Techniques and applications[J]. Applied and Computational Engineering, 2024, 86(1): 294-300.

[31]Dudek G, Fiszeder P, Kobus P, et al. Forecasting cryptocurrencies volatility using statistical and machine learning methods: A comparative study[J]. Applied Soft Computing, 2024, 151: 111132.

[32]Meng X. An analysis of machine learning's role in stock price prediction[J]. Applied and Computational Engineering, 2024, 92(1): 115-120.

[33]Cheng T, Gao J, Linton O, et al. Nonparametric predictive regression for stock return prediction[J]. Econometric Reviews, 2025, 44(10):1462-1493.



中国知网 https://www.cnki.net

[34]Shiller RJ. Irrational exuberance[M]. New York: Broadway Books, 2000.

[35]查正洪. 上证综合指数的统计分析与预测[J]. 上海海运学院学报, 1999(04): 82-89.

[36]易丹辉, 王燕. 应用时间序列分析(第 5 版)[M]. 北京: 中国人民大学出版社, 2019: 1-7.

[37]冯盼, 曹显兵. 基于 ARMA 模型的股价分析与预测的实证研究[J]. 数学的实践与认识, 2011, 41(22): 84-90.

[38]杨琦, 曹显兵. 基于 ARMA-GARCH 模型的股票价格分析与预测[J]. 数学的实践与认识, 2016, 46(06): 80-86.

[39]杨宇塬,张梅. 基于 ARIMA 模型的股票价格实证分析[J].科技资讯,2021,19(29):121-123.

[40]于志军, 杨善林. 基于误差校正的 GARCH 股票价格预测模型[J]. 中国管理科学, 2013, 21(S1): 341-345.

[41]孔令森, 阎虎勤. 对我国中小板股指预测的可行性研究——基于 GM(1,1)和 GM(2,1)灰色模型[J]. 统计学与应用, 2020, 9(3): 403-411.

[42]陈璐璐. 基于多元线性回归分析的股价预测——以中信银行为例[J]. 经济研究导刊, 2016(19): 75-76.

[43]李东, 苏小红, 马双玉. 基于新维灰色马尔科夫模型的股价预测算法[J]. 哈尔滨工业大学学报, 2003(02): 244-248.

[44]宁昱博, 张玉军. LSTM-Ada boost 股价预测模型[J]. 辽宁科技大学学报, 2019, 42(05): 383-388.

[45]姚加权, 冯绪, 王赞钧, 等. 语调、情绪及市场影响: 基于金融情绪词典[J]. 管理科学学报, 2021, 24(05): 26-46.

[46]姜富伟, 孟令超, 唐国豪. 媒体文本情绪与股票回报预测[J]. 经济学(季刊), 2021, 20(04): 1323-1344.

[47]沈艳, 陈赟, 黄卓.文本大数据分析在经济学和金融学中的应用:一个文献综述[J]. 经济学（季刊）,2019,18(4):1153-1186.



中国知网 https://www.cnki.net

[48]李合龙,任昌松,柳欣茹,等.金融市场文本情绪研究综述[J].数据分析与知识发现,2023,7(12):22-39.

[49]朱梦珺,蒋洪迅,许伟.基于金融微博情感与传播效果的股票价格预测[J].山东大学学报 (理学版),2016,51(11)：13-25.

[50]戴德宝,兰玉森,范体军,等.基于文本挖掘和机器学习的股指预测与决策研究[J].中国软科学,2019(04)：166-175.

[51]董理,王中卿,熊德意.基于文本信息的股票指数预测[J].北京大学学报(自然科学版),2017,53(02)：273-278.

[52]饶东宁,邓福栋,蒋志华.基于多信息源的股价趋势预测[J].计算机科学,2017,44(10)：193-202.

[53]顾文涛,王儒,郑肃豪,等.金融市场收益率方向预测模型研究——基于文本大数据方法[J].统计研究,2020,37(11)：68-79.

[54]上海证券交易所. 上海证券交易所年鉴（2025 卷） [M]. 上海: 中国金融出版社, 2025.

[55]张明德,张燕群,罗祥国,等.中国股票市场的作用及其条件[J].经济科学,1991,13(03):23-26.

[56]黄创霞,温石刚,杨鑫,等.个体投资者情绪与股票价格行为的互动关系研究[J].中国管理科学,2020,28(03):191-200.

[57]盘世康. 融合多源文本情绪数据的光伏个股股价预测——基于 BERT-OATM-SA-LSTM 模型[D]. 上海: 上海师范大学, 2024.

[58]武蓉. 基于注意力机制的 BiLSTM 沪深 300 指数预测[D].兰州: 兰州大学, 2022.

[59]刘玉敏,李洋,赵哲耘.基于特征选择的 RF-LSTM 模型成分股价格趋势预测[J].统计与决策,2021,37(01):157-160.

[60]厉益洲,张泓屿,王耶李.中美股市收益率波动特征比较分析——基于非参数检验及其分布的核密度估计[J].中国外资,2013,(20):1-4.

[61]金成晓,曹阳.基于非参数 ARCH 模型的沪深指数波动性研究[J].山西大学学报(哲学社会科学版),2014,37(03):62-67.



中国知网 https://www.cnki.net

[62]任燕燕,李劭珉.中国股市收益率与成交量动态关系的研究——基于工具变量的分位数回归(IVQR)模型[J].中国管理科学,2017,25(08):11-18.



中国知网 https://www.cnki.net