江西财经大学
JIANGXI UNIVERSITY OF FINANCE AND ECONOMICS

学校代码 _____
密　　级 _____
中图分类号 _____
UDC _____

硕士学位论文
MASTER DISSERTATION

论文题目(中文) 基于大模型情绪增强的 TCN-Informer 股票价格预测研究

论文题目(英文) Research on Stock Price Prediction Based on TCN-Informer Enhanced by Large Language Model Sentiment

作　　者 杨美锋　　导　　师 罗良清

申请学位 硕士　　培养单位 统计与数据科学学院

学科专业 统计学　　研究方向 机器学习与大数据

二〇二六 年 六 月

中国知网 https://www.cnki.net

摘　要

在数字经济飞速发展与金融科技深度渗透的背景下，中国股票市场呈现出显著的散户主导与高噪声特征，单纯依赖历史交易数据的传统预测模型难以有效捕捉由非理性心理引发的市场波动。本文立足于多源信息融合视角，通过引入大语言模型增强舆情挖掘深度并改良深度学习架构以适应金融时间序列的长记忆性与高频突变特性，从而构建一种高精度的股价预测框架。

本文的核心在于构建了一套从非结构化文本提炼为结构化量化指标的特征工程流程，并设计了混合深度学习模型。本文利用具备深层语义推理能力的通义千问大语言模型对海量社交媒体评论进行精细的情感标注，通过其卓越的上下文理解能力，精准识别金融语境下的隐喻与反讽，解决了传统方法难以跨越的语义理解瓶颈。为了量化不同舆论的影响力差异，本文结合投资者注意力理论设计了基于阅读量与评论量的加权算法，并构建日度加权情绪指标。在预测模型设计上，本文提出 TCN-Informer 这一混合深度学习模型，通过并行引入时间卷积网络的因果扩张卷积模块，弥补了自注意力机制在提取局部微观特征上的短板，实现了对市场全局发展趋势与局部波动感知的非线性整合。

在实证分析阶段，本文选取了深证市场中具有行业代表性的宁德时代、美的集团及立讯精密三家公司作为研究对象，采集了从 2020 年 11 月至 2025 年 10 月跨度长达五年的东方财富股吧评论与日度交易数据集。实证结果分为两个层级：在情感标注任务中，相较于受静态词向量局限的传统模型，Qwen-3 精准解析了反讽等复杂金融语境，准确率与 F1-Score 双双达到 90%，提取了高信噪比的情绪特征；在日度预测任务中，融合了情绪因子的混合模型在均方误差、平均绝对误差及决定系数等核心评估指标上均显著优于传统模型。进一步的消融实验证实，大模型情绪指标有效修正了市场转折点处的预测滞后，并行 TCN 模块弥补了自注意力缺乏局部突变感知的短板，两者协同使均方误差降至最低。在泛化与鲁棒性验证中，模型面对稳健、成长与激进三类资产的拟合优度均高于 0.95。在未来 5 日多步预测中拟合优度仍维持 0.905 且平均绝对百分比误差大幅下降，证明情绪特征能有效对抗误差累积，为复杂时序预测提供了可靠的量化择时依据。

本文不仅从理论上丰富了行为金融学中关于“情绪驱动价格”的实证范式，也在实践层面证明了将人工智能深度语义挖掘与先进深度学习算法相结合，能够深刻揭示金融市场的定价规律。这一成果为量化投资实践中的因子挖掘与复杂行情下的智能决策提供了可靠的技术参考。

关键词：股票价格预测；大语言模型；投资者情绪；TCN-Informer

中国知网　https://www.cnki.net

Abstract

Against the backdrop of the rapid expansion of the digital economy and the deep penetration of financial technology, the Chinese stock market exhibits prominent retail-investor dominance and high-noise characteristics. Conventional prediction models, relying exclusively on historical trading data, struggle to effectively capture market volatility triggered by irrational investor psychology. This thesis establishes a high-precision stock price prediction framework from a multi-source information fusion perspective. By introducing a Large Language Model (LLM) to deepen sentiment mining and refining deep learning architectures to accommodate the long-range dependence and high-frequency mutation characteristics of financial time series, the study seeks to optimize forecasting performance.

The core contribution of this thesis lies in the construction of a feature engineering process that transforms unstructured text into structured quantitative indicators, alongside the design of a corresponding hybrid deep learning model. This thesis utilizes the Qwen (Tongyi Qianwen) LLM, which possesses advanced semantic reasoning capabilities, to perform fine-grained sentiment annotation on massive social media comments. By leveraging its superior contextual understanding, the model accurately identifies metaphors and irony within financial contexts, thereby surmounting the semantic bottlenecks inherent in traditional methods. Furthermore, drawing on Investor Attention Theory, a weighting algorithm based on read counts and comment volumes is designed to construct a daily weighted sentiment index that quantifies the varying influence of public opinions. Regarding model architecture, the TCN-Informer hybrid model is proposed. By concurrently integrating the causal dilated convolution module of the Temporal Convolutional Network, the model compensates for the self-attention mechanism's limitations in extracting local micro-features, achieving a non-linear integration of global trend awareness and local volatility perception.

In the empirical analysis stage, three representative companies in the Shenzhen market—CATL, Midea Group, and Luxshare Precision—were selected as research subjects. A dataset spanning five years, from November 2020 to October 2025, was collected, comprising East Money Stock Bar comments and daily trading data. The empirical results are categorized into two levels: In the sentiment annotation task, compared to traditional models limited by static word vectors, Qwen-3 precisely decoded complex financial semantics such as irony, with Accuracy and F1-Score both exceeding 90%, thereby extracting high

中国知网 https://www.cnki.net

signal-to-noise ratio sentiment features. In the daily prediction task, the sentiment-enhanced hybrid model significantly outperformed traditional models across core metrics including Mean Squared Error, Mean Absolute Error, and the Coefficient of Determination. Further ablation experiments confirmed that the Large Language Model derived sentiment index effectively corrected prediction lags at market turning points, while the parallel Temporal Convolutional Network module addressed the lack of local mutation perception in self-attention. Their synergy minimized the Mean Squared Error. In the validation of generalization and robustness, the model achieved a Coefficient of Determination exceeding 0.95 across three categories of assets characterized by stable, growth, and aggressive volatility profiles. In the five-day multi-step forecasting task, the Coefficient of Determination was maintained at 0.905, accompanied by a significant reduction in the Mean Absolute Percentage Error. This demonstrates that sentiment features effectively counteract error accumulation, providing a reliable quantitative basis for market timing in complex time series forecasting.

This thesis enriches the empirical paradigm of "sentiment-driven prices" in behavioral finance and demonstrates that the combination of deep semantic mining with advanced deep learning algorithms can profoundly reveal market pricing mechanisms. These findings provide a robust technical reference for factor mining and intelligent decision-making in quantitative investment practice.

Key Words: Stock Price Prediction; Large Language Model; Investor Sentiment; TCN-Informer

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 研究背景及意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....2
1.2 文献综述.....2
1.2.1 投资者情绪研究综述.....2
1.2.2 股票价格预测模型演进.....4
1.2.3 文献评述.....5
1.3 研究内容.....7
1.4 创新点.....8
2 理论基础与方法.....9
2.1 行为金融学与资产定价相关理论.....9
2.1.1 有效市场假说与信息反映机制.....9
2.1.2 行为金融学与投资者情绪偏差.....9
2.1.3 文本情绪影响股价的传导机制.....10
2.1.4 投资者注意力假说与舆论影响力.....11
2.2 大语言模型.....11
2.2.1 大语言模型概述.....11
2.2.2 Transformer.....12
2.2.3 通义千问.....14
2.3 深度学习.....16
2.3.1 TCN.....16
2.3.2 Informer.....18
2.4 本章小结.....19
3 大模型情绪增强的 TCN-Informer 模型.....20
3.1 基于大语言模型的日度情绪指标构建.....20
3.1.1 大语言模型情绪标注.....20
3.1.2 日度情绪指标构建.....21
3.2 大模型情绪增强的 TCN-Informer 模型结构.....22
3.2.1 融合情绪特征的多源信息预测机制.....22
3.2.2 TCN-Informer.....23
3.3 本章小结.....25
4 实证分析.....26
4.1 数据来源与样本获取.....26

中国知网　https://www.cnki.net

4.1.1 股票的选取.....26
4.1.2 股票评论文本数据.....26
4.1.3 股票日度数据.....27
4.2 数据预处理.....28
4.2.1 文本数据预处理.....28
4.2.2 股票数据预处理.....28
4.3 模型评估指标.....29
4.3.1 回归类误差指标.....29
4.3.2 分类评价指标.....29
4.4 大模型情绪标注效果评估与日度指标构建.....30
4.4.1 情绪标注效果检验.....30
4.4.2 日度情绪指标构建.....31
4.5 大模型情绪增强的 TCN-Informer 模型实证结果.....32
4.5.1 实验设置.....32
4.5.2 预测性能对比.....33
4.5.3 消融实验.....33
4.5.4 模型泛化能力验证.....34
4.6 本章小结.....38
5 结论与展望.....39
5.1 结论.....39
5.2 展望.....40
参考文献.....41

中国知网 https://www.cnki.net

图目录

图 1.1 论文组织框架 7
图 2.1 Transformer 模型结构 12
图 2.2 多头注意力机制示意图 13
图 2.3 Qwen 模块示意图 14
图 2.4 因果卷积示意图 16
图 2.5 扩张卷积示意图 17
图 2.6 Informer 模型结构 18
图 3.1 TCN-Informer 模型 23
图 4.1 美的集团预测结果 35
图 4.2 宁德时代预测结果 36
图 4.3 立讯精密预测结果 36

中国知网 https://www.cnki.net

表目录

表 3.1 大语言模型提示词设计 21
表 4.1 股票基本信息 26
表 4.2 股票评论文本样例 27
表 4.3 宁德时代原始日度数据 27
表 4.4 多模型情绪标注结果 30
表 4.5 LLM 情绪标注效果比较 30
表 4.6 股评情绪标注结果及权重 31
表 4.7 多维融合数据集——以宁德时代为例 32
表 4.8 模型核心超参数设置 32
表 4.9 股价预测性能对比——以宁德时代为例 33
表 4.10 消融实验结果比较——以宁德时代为例 34
表 4.11 模型跨标的资产预测性能比较 35
表 4.12 不同预测步长下预测性能衰减比较——以宁德时代为例 37

中国知网 https://www.cnki.net

1 绪论

中国股市散户化与非理性波动特征显著，传统量价模型难以捕捉舆情引发的震荡。本章立足于文本情绪挖掘与深度学习的融合路径，剖析“语义鸿沟”及“长短时序建模局限”等痛点，并明确研究目标与创新点。通过构建大模型情绪增强的 TCN-Informer 预测框架，旨在提升股价预测精度，为全文实证分析奠定逻辑起点。

1.1 研究背景及意义

1.1.1 研究背景

中国股票市场的定价机制在很大程度上受制于其独特的投资者结构，其中个体投资者占据了极高的交易比例。这种高度“散户化”的市场特征，使得股价波动不仅受到宏观经济指标与公司基本面的约束，更显著地表现出由群体心理驱动的非理性特征。在这一环境下，投资者的预期、情绪以及对信息的反应偏差往往会转化为实际的交易行为，进而导致资产价格在短期内剧烈偏离其内在价值。

长期以来，基于历史交易数据的定量分析一直是市场预测的主流方向，但单纯依赖价格与成交量等滞后指标，往往难以在市场发生逻辑转换或情绪拐点时提供前瞻性的指引。随着互联网技术的深入普及，东方财富股吧、雪球等社交平台已成为投资者表达观点、释放情绪的主要阵地。这些平台产生的海量非结构化文本中蕴含了大量的市场前瞻性信号，如何从这些碎片化且充满噪声的语言中提取出真实的心理预期，已成为当前金融数据科学领域亟待解决的关键难题。

在处理中国语境下的金融文本时，传统的词典法或浅层机器学习技术表现出明显的局限性。中国股民的语言表达往往包含复杂的讽刺、隐喻以及特定行业术语的重构，这种高度依赖语境的语义逻辑使得传统方法难以实现对情绪极性的精准识别。一旦情绪特征的提取存在偏差，后续的股价预测模型便会因输入信号的失真而失去鲁棒性。与此同时，金融时间序列本身具备的长程依赖关系，要求预测模型不仅要能捕捉瞬时的情绪波动，还必须具备处理多尺度时序演化规律的能力。

随着大语言模型在自然语言处理领域的突破，其展现出的深层语义感知能力为金融文本的“情绪增强”提供了新的技术路径。大模型能够更细腻地解析中国投资者在复杂语境下的真实心态，从而为预测模型提供更高维度的非结构化特征。将这种经过大模型增强后的情绪指标，引入到具备高效时序捕获能力的深度学习框架中，构建一个能够统筹心理变量与量化指标的综合预测体系，已成为提升金融预测准确度的必然趋势。

中国知网 https://www.cnki.net

1.1.2 研究意义

立足于大数据与人工智能高速发展的背景，针对中国股票市场的情绪化特征与长时序预测的技术瓶颈，本文探讨了大语言模型与改进型深度学习架构的融合应用，其研究价值主要体现于理论拓展与实践应用两个维度。

在理论层面，本研究尝试在非结构化数据统计建模与复杂时序预测之间建立深层逻辑连接。针对传统行为金融实证中情绪量化的“语义鸿沟”挑战，引入大语言模型作为特征提取引擎，有效突破了词典法基于孤立词汇匹配的局限，验证了深度语义理解在提升金融文本量化精度方面的显著潜力，并为自然语言特征向可计算指标的映射提供了方法论支持。同时，针对金融日度数据兼具长记忆性与局部高波动的特征，本研究提出的混合模型实现了卷积网络局部捕捉力与 Informer 模型长序列建模能力的有机融合，从理论上缓解了时序预测中的“长短依赖权衡”难题，为深度学习模型在非平稳金融数据上的结构优化提供了实证支撑。

从实践角度看，本研究为量化投资领域的因子挖掘提供了全新的工程化范式。在 A 股量价因子同质化竞争加剧的背景下，利用大模型提炼的高频情绪指标作为“另类数据”，能够提供涵盖市场博弈与非理性预期的增量信息，成为独立于财务报表之外的全新 Alpha 来源。此外，该框架整合了舆论实时热度与情感倾向，可作为数字化的“市场情绪晴雨表”，辅助感知潜在风险或反转信号，有效弥补了传统风控模型依赖历史波动率的滞后性缺陷。在技术落地层面，研究验证了“大语言模型+深度时序网络”复合架构在金融场景中的可行性与经济性。相比低效的人工标注模式，利用大模型进行少样本推理显著降低了特征提取的边际成本，为金融机构处理海量文本大数据提供了可复用的解决方案。

1.2 文献综述

1.2.1 投资者情绪研究综述

投资者情绪作为一种难以直接观测的心理变量，其科学测度一直是行为金融研究中的核心问题。相关研究通常通过投资者行为和信息表达的可观测结果，对市场情绪进行间接刻画。

在国内研究中，主要依托市场交易行为数据构建情绪代理变量。张宗新等（2013）通过构建理论模型论证投资者情绪、信念调整和市场波动之间的内在机理，考察投资者主观信念调整对投资者预期改变和市场冲击的过程[1]。文凤华等（2014）在此基础上将情绪区分为积极情绪和消极情绪，探讨积极和消极两种不同情绪特征下的投资者行为特点[2]。随着非结构化数据的广泛应用，研究逐渐引入文本信息对投资者情绪进行刻画。部慧等（2018）结合股吧帖子构建投资者情绪指数，利用格兰杰因果检验等方法，探讨

中国知网 https://www.cnki.net

了投资者情绪对于我国股票收益率、交易量和波动性的影响[3]。戴德宝等（2019）通过抓取网络论坛情绪文本，并基于 SVM 的上证投资者情绪综合指数模型进行股指预测，发现情绪对中小盘股指的预测能力优于大盘指数[4]。在高频视角下，情绪测度逐步细化至日内层面，尹海员等（2024）利用高频数据构建投资者情绪指标，发现在实行注册制的创业板中，投资者情绪与股票定价效率之间存在显著的正相关关系[5]。近年来，情绪测度方法呈现出更加精细化的发展趋势。黄创霞等（2020）通过改进的个体投资者情绪度量的 SO-LNPMI 算法，证明网络论坛中的有效信息可以传递到股票市场，影响资产收益和成交量[6]。姜富伟等（2021）构建了中文金融情感词典，并探讨了媒体文本情绪与金融市场回报间的预测关系[7]。谢世清等（2021）则结合宏观经济变量，通过主成分分析提取综合情绪指标，验证了投资者情绪可能会带来市场的系统性偏离[8]。

在国际研究中，Da 等（2015）基于互联网搜索行为构建 FEARS 指数，为情绪测度提供了新的数据视角。FEARS 指数不仅对当期市场表现有显著影响，其滞后值同样能有效解释未来资产价格的变动[9]。Huang 等（2015）通过“情绪对齐”方法剔除传统情绪指标中的噪声成分，显著提升了预测能力[10]。Sun 等（2016）基于高频文本数据构建投资者情绪指标，将情绪测度细化至日内层面[11]。Renault（2017）利用词典法从推特平台用户发言中提取投资者情绪，验证了在线情绪指标在短期收益预测中的有效性[12]。Heston 等（2017）从新闻文本角度出发，分析新闻情绪在股票收益预测中的作用，进一步拓展了投资者情绪测度的数据来源[13]。在情绪测度不断完善的基础上，相关研究逐步转向探讨投资者情绪影响市场运行的内在机制。Mu 等（2023）通过 MS-SSA-LSTM 框架与定制词典，验证了情绪与量价融合的有效性[14]。针对词典法的噪声局限，Li 等（2024）利用 CausalStock 架构引入 LLM 进行深度去噪与因果发现，提升了预测精度与可解释性[15]。Talazadeh 等（2024）则结合 FinGPT 与技术指标，使美股预测准确率提升 9.23%[16]。

从行为金融理论出发，胡昌生等（2013）以资产估值水平为切入点，研究了理性情绪、非理性情绪与波动性之间的关系[17]。陈健等（2018）发现投资者情绪加剧了股价波动，但融资融券交易制度的引入弱化了投资者情绪对股票价格波动的影响[18]。唐志武等（2020）从股指期货市场视角出发，研究投资者情绪与沪深 300 股指期货定价偏差之间的关系，研究发现投资者情绪与股指期货定价偏差构成因果关系，且投资者情绪长期正向影响股指期货定价偏差[19]。在更广泛的市场互动层面，姜尚伟等（2020）将空间交互因素引入分析框架，发现投资者情绪不仅影响个体股票价格，还会通过空间关联在股票之间产生溢出效应[20]。张博等（2021）建立了投资者预期生成机理概念模型，认为货币环境、市场收益、市场波动、相关资产收益等因素可以通过市场投资价值、市场预期的中介作用影响投资者情绪[21]。朱莉等（2022）借鉴 Baker 和 Wurgler 的思路构建了投资者情绪指数，指出情绪变化会影响期现市场的联动程度及价格发现能力[22]。

围绕投资者情绪的市场后果，相关研究主要集中于股票收益、市场波动、流动性以

中国知网 https://www.cnki.net

及价格发现等方面。Bartov 等（2018）则利用社交媒体数据，验证了推文情绪在预测公司盈利及公告期股票回报方面的有效性[23]。童元松（2021）通过中介效应模型实证检验了投资者情绪、股市流动性及波动性三者之间的关系，这三者都有自身运行的较强的惯性，共同形成了一个互相影响的动态系统[24]。胡昌生等（2023）在其后续研究进一步强调，A 股市场中投资者情绪具有累积效应，并且在持续的高情绪累积下，市场中的资金会涌入波动水平低、流动性好的资产，而在持续的低情绪累积下，资金会选择投机性更强的资产[25]。Audrino 等（2020）在此基础上结合社交媒体、新闻文章等数据分析情绪和注意力变量对股市波动的影响，表明相关变量能够在一定程度上改善波动率预测效果[26]。在高频视角下，尹海员（2019）利用“金融界”股票论坛中的发帖信息构建了上证指数的日内高频投资者情绪指标，从多个维度研究了中国股市中投资者情绪对股票日内收益的预测效应，并从交易量和市场长期收益反转的角度探讨了噪音交易在这一过程中所扮演的角色[27]。

1.2.2 股票价格预测模型演进

股票价格预测一直是金融工程与金融计量领域的重要研究方向。随着金融市场复杂性和非线性特征的不断增强，预测模型在方法框架与技术路径上经历了由传统统计模型向机器学习与深度学习模型的持续演进。

早期股票价格预测研究主要依托统计建模思想，侧重刻画时间序列的线性结构和波动特征。赵进文、王倩（2008）基于 GARCH 族模型对上证指数进行仿真研究，得出我国股票市场有非常明显的 GARCH 效应和弱杠杆效应[28]。辛治运、顾明（2008）提出基于最小二乘支持向量机的金融时间序列预测方法，通过将不等式约束转化为等式约束显著提升计算效率[29]。在此基础上，于志军与杨善林（2013）将误差校正思想引入 GARCH 预测框架，通过对残差序列进行建模修正原始预测结果，显著提高了模型的预测精度，但实验仍然只能对短期价格进行预测[30]。吴玉霞等（2016）进一步基于 ARIMA 模型对股票价格短期走势进行预测，获得了较好的短期动态及静态预测效果[31]。

随着计算能力提升，研究开始引入机器学习方法以应对金融时间序列的非线性问题。Zhong 等（2017）构建基于 PCA 降维与人工神经网络的股票收益方向预测流程，以此实现对标普 500ETF 涨跌方向的预测[32]。Fischer 等（2018）将 LSTM 引入股票方向预测，并在标准普尔 500 指数成分股样本上获得较高的样本外收益表现[33]。在国内研究中，宋刚等（2019）通过自适应学习策略的 PSO 算法对 LSTM 网络结构进行优化，提高了模型的准确度与普适性[34]。Vijh 等（2020）则分别使用 ANN 与随机森林预测多家公司次日收盘价，验证了机器学习模型在短期预测任务中的可行性[35]。闫洪举（2020）构建 CNN-GRU 网络并结合 EEMD 分解进行集成预测，将金融数据之间的序列依赖关系和不同金融市场的时间序列数据之间的关联特征结合[36]。贺毅岳、韩进博（2020）提出股市指数集成预测建模方法 CEEMDAN-LSTM，并以沪深 300 等 5 个代表性股市指数为测试

中国知网 https://www.cnki.net

数据，使其预测结果误差小、精度高、滞后性更低[37]。Moghar 等（2020）提出以 LSTM 为基础的 RNN 模型来预测股票的收益率，并强调模型参数设置对预测效果的影响[38]。任君等（2018）使用正则化 LSTM 模型对道琼斯指数进行预测，通过对比四种 LSTM 模型实验，发现弹性网正则化 LSTM 模型的预测性能最为出色[39]。

为进一步提升预测性能，研究开始探索多模型融合与多源信息引入路径。Cao 等（2018）提出 EMD-LSTM 与 CEEMDAN-LSTM 混合框架，通过“分解—预测—重构”机制提升一步预测精度[40]。曹超凡等（2022）将构建的 MDT-CNN-LSTM 预测方法用于 48 家主流上市公司进行股价预测，发现使用 MDT 技术对输入数据进行处理后模型预测精度与时效性得到了提升[41]。陈炜等（2021）构建了基于误差修正和分解的区间值股价预测模型，利用上下界信息刻画价格波动不确定性，有效地预测股价的变化范围[42]。Hoseinzade 等（2019）提出 CNNpred 框架，利用跨市场相关性特征提升标普 500 等指数的方向预测能力[43]。Henrique 等（2019）进一步将时间序列与图像特征融合，验证多模态信息在降低预测误差方面的有效性[44]。近年来，Transformer 模型逐渐成为股票价格预测的重要研究方向。任佳屹和王爱银（2023）将因果自注意力机制与趋势增强模块引入传统 Transformer 进行股票预测，其预测误差指标相较经典 Transformer 显著降低[45]。陈东洋与毛力（2024）提出一种基于增量学习算法与 Transformer 框架的在线预测模型 Increformer，引入了持续自注意力机制挖掘特征变量之间的时序依赖关系，采用持续归一化机制为模型提供增量场景下的数据平稳化方案[46]。Li 等（2024）提出基于相空间重构补偿的 PSR-LSTM 模型，通过结合短期 LSTM 预测与长期结构恢复提升多变量预测能力[47]。宋凌云等（2024）则综述了时序图神经网络在金融风险预测中的应用，指出结构化关系建模是未来发展的重要方向[48]。

1.2.3 文献评述

综合已有研究可以发现，投资者情绪研究与股票价格预测模型研究在近年来呈现出明显的交叉融合趋势，两条研究主线分别从行为金融视角和方法技术视角不断深化，对理解股票价格形成机制与提升预测性能均提供了重要支持。

从投资者情绪研究来看，现有文献已在情绪测度、作用机制和市场结果三个层面形成较为系统的研究框架。在情绪测度方面，研究路径经历了由市场交易指标代理向文本信息、高频数据及多源综合指标的演进，情绪刻画逐渐由粗粒度走向精细化。文本挖掘、搜索行为与社交媒体数据的引入显著拓展了情绪信息来源，提高了情绪变量对市场心理波动的反映能力。在作用机制层面，相关研究普遍认为投资者情绪通过影响主观预期、风险偏好与交易行为，引发资产价格对基本价值的系统性偏离，并可能通过空间溢出、跨市场传导以及制度约束等路径放大市场波动。部分研究进一步从生成机理角度出发，尝试刻画宏观环境、市场预期与情绪形成之间的内在联系，使情绪研究由“结果解释”

中国知网 https://www.cnki.net

逐步走向“过程分析”。尽管如此，情绪作用路径在不同市场状态和制度背景下的稳定性仍有待进一步检验。在市场结果方面，大量实证研究表明投资者情绪对股票收益、价格波动、流动性及价格发现过程均具有显著影响，且这种影响往往呈现非对称性和阶段性特征。高频研究显示，情绪对短期收益具有一定预测能力，但持续时间有限，更多反映噪声交易行为特征。整体而言，现有研究已在多个层面验证了投资者情绪在资产定价中的重要性，但对其长期效应和跨周期影响的认识仍不充分。与行为金融视角并行发展的，是股票价格预测模型在方法体系上的持续演进。早期研究主要依赖统计计量模型和波动模型，通过刻画线性关系与条件异方差特征对价格走势进行预测，但在面对非线性和非平稳特征时表现出明显局限。随着计算能力提升，机器学习方法逐渐被引入预测研究，支持向量机、人工神经网络等模型在一定程度上改善了预测精度，但模型对复杂时序依赖关系的刻画能力仍然有限。

深度学习模型的引入显著推动了股票价格预测研究的发展。LSTM、GRU 等时序模型在捕捉长期依赖关系方面表现出优势，成为价格预测研究的核心工具。在此基础上，多尺度分解、误差修正与模型集成等策略被广泛应用，以缓解噪声干扰并提升预测稳定性。进一步的研究开始关注多源信息融合，通过引入图像化时间序列、跨市场数据和事件信息，构建 CNN-LSTM 等混合模型，从特征表达层面增强模型对市场结构信息的刻画能力。近年来，Transformer 模型及其扩展模型逐渐成为预测研究的新方向。基于自注意力机制的模型在并行建模和长期依赖捕捉方面展现出潜力，并通过引入因果注意力、增量学习和结构化关系建模等机制，提升了对非平稳金融时间序列的适应能力。同时，时序图神经网络等方法开始关注金融实体间的关系结构，为价格预测提供了新的建模思路。然而，这类模型普遍面临计算复杂度高、可解释性不足等问题，其在真实交易环境中的稳健性仍需进一步验证。

综上所述，现有研究在投资者情绪刻画与股票价格预测方法两个维度均取得了丰富成果，但两者在系统融合层面仍存在一定不足。一方面，投资者情绪研究多停留在解释和检验层面，情绪信息在预测模型中的结构化嵌入方式尚不统一；另一方面，价格预测模型虽然在方法上不断演进，但对情绪等行为因素的利用仍相对分散，未能充分体现情绪在价格形成过程中的动态作用机制。

中国知网 https://www.cnki.net

1.3 研究内容

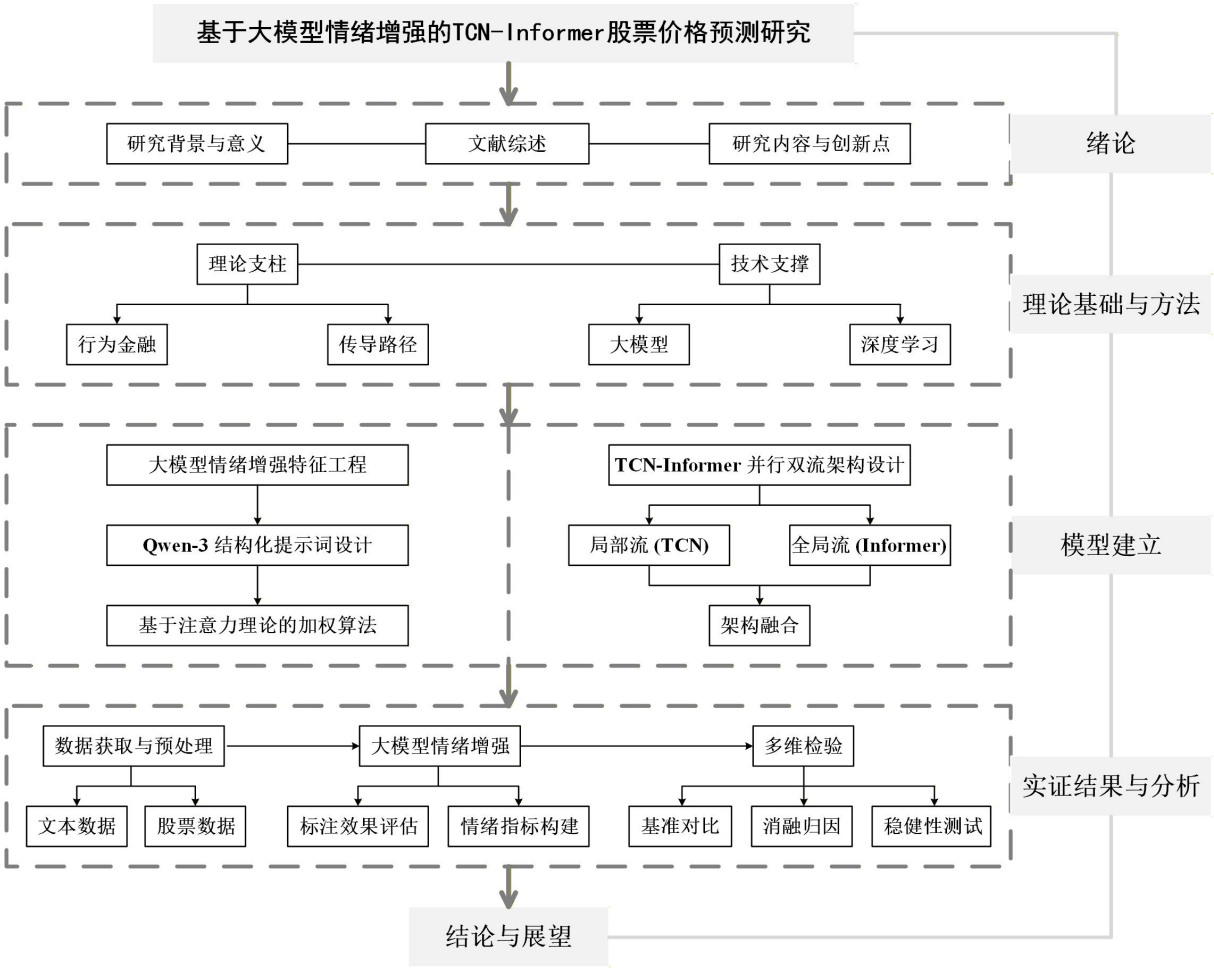


图 1.1 论文组织框架

Fig. 1.1 Thesis Organization Framework

如图 1.1 所示，为了系统性地论证大语言模型赋能下的股价预测效度，本文遵循“理论分析—模型构建—实证检验—结论展望”的逻辑主线，全书共分为五章，各章节的具体研究内容安排如下：

第一章，绪论。结合金融数字化转型与人工智能技术背景，阐述挖掘非结构化舆情数据对股价预测的现实意义。通过综述国内外相关文献，识别当前研究在语义理解与时序预测中的瓶颈，明确本文的研究内容、技术路线及核心创新点。

第二章，理论基础与方法。本章为全书的奠基部分，涵盖有效市场假说、行为金融偏差及投资者注意力等金融理论，并解析大语言模型、TCN 的卷积特性及 Informer 的概率稀疏自注意力机制等技术原理，为后续建模奠定基础。

第三章，大模型情绪增强的 TCN-Informer 模型构建。阐述利用大语言模型实现金融文本精细化情感标注的过程，提出基于阅读量加权的日度情绪指标。在此基础上，设

中国知网 https://www.cnki.net

计 TCN-Informer 模型结构，构建多源信息融合驱动的股价预测机制。

第四章，实证分析。本章是本文的实证核心，通过对比实验确立大模型情感标注的优势，并选取典型标的资产进行多维度测试，包括主流模型性能对比、各模块贡献的消融实验、长周期预测步长测试以及针对不同特征资产的泛化能力验证。

第五章，结论与展望。本章归纳全书研究成果，总结大模型赋能舆情挖掘的核心价值及 TCN-Informer 模型在复杂时序建模中的表现。客观审视研究局限性，并从多模态数据融合、垂直领域模型微调及实盘策略优化等维度提出未来研究方向。

1.4 创新点

本文立足于大数据与人工智能的交叉前沿，在非结构化数据深度挖掘与复杂神经网络结构优化两个维度实现了突破，主要创新体现在以下方面：

其一，构建了基于大语言模型与投资者注意力理论的加权情绪指标。针对传统情感分析在复杂语义识别与权重分配上的局限，本文引入大语言模型作为特征提取器，利用其深层推理能力精准量化金融语境下的反讽与隐喻。同时，结合“阅读—评论”互动数据设计均值比率插补与平滑加权算法，有效剔除噪声干扰，构建出内嵌市场共识的高质量情绪因子，弥补了传统算术平均法无法体现舆论影响力差异的缺陷。

其二，设计了 TCN-Informer 并行双流混合模型架构。针对 Informer 模型在长序列预测中易忽略局部邻域信息、对剧烈波动反应迟钝的短板，本文提出一种并行的特征提取架构：在保留 Informer 全局长程建模优势的同时，并行引入 TCN 模块捕捉微观价格跳变与高频情绪冲击。该结构实现了“宏观视野”与“微观感知”的非线性融合，显著提升了模型在复杂震荡行情中的拟合精度与收敛稳定性。

其三，验证了情绪因子作为外生先行指标的有效性及其量化贡献。不同于单一数据源研究，本文将大模型提炼的情绪特征与高频量价数据进行深度融合，验证了情绪因子作为先行指标的有效性。更重要的是，通过层层递进的消融实验，定量测算了各创新组件对预测精度的边际贡献，实现了从“黑箱预测”向“可解释归因”的转变，为金融统计建模从单一驱动向多模态驱动转型提供了可靠参考。

中国知网 https://www.cnki.net

2 理论基础与方法

构建高效预测模型需理论支撑与算法赋能，本章在金融理论层面，通过剖析有效市场假说局限及有限关注理论，阐明文本情绪影响定价的内在机制，为引入情绪因子提供依据；同时在技术维度，解析大语言模型处理复杂语义的优势，并探讨 TCN 与 Informer 在捕捉局部波动与全局趋势上的互补性。上述理论梳理旨在为后续模型设计与实证分析提供方法论指导。

2.1 行为金融学与资产定价相关理论

2.1.1 有效市场假说与信息反映机制

尤金 •法马（Eugene Fama）提出的有效市场假说（Efficient Market Hypothesis，EMH）认为，资产价格能够充分且即时地反映所有可获得的信息。根据信息反映范畴的差异，有效市场通常被划分为弱式、半强式与强式三个递进层次，分别代表价格对历史量价、公开信息及内幕信息的涵盖程度，构成了现代资产定价研究的理论基石。若市场达到强式有效，价格序列将遵循随机游走过程反映所有与其有关的信息，不仅包括公开信息，还包括私有信息。然而，中国股票市场由于投资者结构以散户为主、信息传递存在摩擦以及制度性约束，价格反映机制往往表现出显著的非对称性与滞后性。这种“非完全有效性”构成了预测的逻辑前提，即市场信息在转化为价格信号的过程中存在时间上的错位与空间上的非线性关联。

信息反映机制描述了新信息如何被纳入定价的动态演化过程。在理想状态下，理性投资者的套利交易促使价格瞬时调整至新均衡，这一过程依赖于信息的即时传播与无偏处理。然而，在现实市场中信息不对称广泛存在，加之市场流动性限制与交易成本等因素的制约，信息往往难以在第一时间被价格完全吸收。这种滞后或过度反应的现象在制度尚不完善的新兴市场中尤为显著，表现为价格对价值的系统性偏离。

2.1.2 行为金融学与投资者情绪偏差

行为金融学（Behavioral Finance）指出，投资者的心理、情绪和行为会影响资产定价效率，非理性情绪和行为会导致股票价格与内在价值的偏离。当股票市场存在大量噪音交易者，而且套利受到限制时，投资者情绪成为影响股票价格波动的重要因素。

在行为金融学中，过度自信、从众行为和情绪波动是最常讨论的三种情绪偏差。过度自信指的是投资者高估自己对市场走势的判断能力，往往导致过度交易和过高的风险暴露。这种偏差使得投资者在面对不确定性时，做出过于乐观的投资决策，导致市场价格偏离其基本价值。与之相反，从众行为则表现为投资者在决策时受到他人行为的强烈

中国知网 https://www.cnki.net

影响，忽视自己的独立判断，从而加剧市场的波动性。例如，在牛市或熊市中，投资者常因跟随市场情绪而非理性分析做出决策，形成价格的泡沫或崩盘。情绪波动则是另一种关键的投资者偏差。在市场不确定性加剧时，投资者情绪容易受到恐惧或贪婪的驱使，进而导致情绪化的决策。

当市场参与者做出决策时，他们的情绪和心理偏差常常导致信息传递的失真和市场反应的滞后。过度自信的投资者可能会因高估自身信息处理能力而导致过度交易，而从众行为则可能引发资产价格的集体失真。然而，情绪的影响也并非总是负面或完全不理性，适度的情绪波动可以反映市场对新信息的真实反应，尤其是在重大经济事件或政策发布时，投资者的情绪波动可能是市场效率的正常组成部分。因此，情绪不仅仅是市场失效的标志，它也能在一定程度上提供关于市场变化的关键信息。

总体而言，行为金融学强调的情绪偏差显著影响市场效率，尤其在情绪波动剧烈的时期，投资者的非理性行为往往导致股价和市场的非理性波动。虽然有效市场假说为理解市场运作提供了一个基础框架，但行为金融学的研究揭示了市场效率的局限性，并为理解市场价格的异常波动提供了更为丰富的理论视角。

2.1.3　文本情绪影响股价的传导机制

建立在有效市场假说基础上的传统金融理论认为股票的价格只由股票的基本价值即预期股息的现期贴现值之和所决定，但行为金融学把投资行为看成一个心理过程，认为除了股票的基本价值之外，投资者的心理因素和行为特征也会对股票的价格产生重要影响。情绪变化不仅直接影响投资者对市场前景的预期，还通过调节投资者的风险溢价要求，进而影响股票价格的波动性与定价。

在预期路径中，情绪极性直接干预投资者对未来盈利的预判：乐观情绪往往诱发对经济前景及企业盈利的高估，驱动股价上行；而悲观情绪则伴随着预期的下修与股价下跌。在风险溢价路径中，情绪通过调节风险厌恶程度发挥作用。投资者情绪显著正向影响股价崩盘风险，当期投资者情绪越乐观，未来股价崩盘风险越大。当情绪高涨时，投资者对风险的感知与厌恶减弱，要求的额外回报随之降低，从而提振高风险资产价格；反之，情绪转悲则显著提升风险厌恶水平，促使投资者要求更高的风险补偿，进而推低股价。此外，更为高涨的投资者情绪会导致股票流动性水平下降，进而加剧了情绪对股价崩盘风险的影响效应[49]。

此外，情绪对市场流动性同步性的影响具有明显的阶段性特征。相较于牛市，市场处于熊市时，股票的流动性同步性更高；投资者情绪越高，股票的流动性同步性越小。而当市场进入牛市或情绪上升阶段，个股表现的独立性与差异性随之增加，同步性显著下降[50]。

中国知网　https://www.cnki.net

2.1.4 投资者注意力假说与舆论影响力

在传统有效市场假说的框架下，信息被假定为能够瞬间、无成本地被所有投资者接收并处理。然而，注意力是一种稀缺的认知资源，在信息爆炸的金融市场中投资者面对海量的公告与资讯不可能处理所有信息，而只能选择性地关注那些最具显著性的内容。基于此，“投资者注意力假说”认为当面对大量异质信息特别是大量无关信息时，投资者的关注程度极易被分散，只有被投资者关注到的资产或信息，才能真正进入其决策集合，进而对资产价格产生实质性影响。

在互联网社交媒体环境下，投资者注意力的分配机制发生了显著变化。股评文本的阅读量与评论量不再仅仅是简单的交互统计，而是成为了衡量信息显著性与传播深度的核心代理变量，个人投资者在买入决策时极度依赖注意力的驱动，他们倾向于交易那些处于舆论焦点或具有高曝光度的股票。具体而言，一条拥有高阅读量与高评论量的评论，通常意味着其观点触发了广泛的情感共鸣或被市场视为主流共识。这种“高关注度”的文本具有更强的情绪传染力，能够迅速在投资者群体中引发羊群效应，从而在短期内形成一致性的买卖压力。相反，那些无人问津的低互动评论，即便包含了真实的基本面分析，由于未能争夺到稀缺的注意力资源，其包含的信息很难被定价系统所吸收。

因此，构建情绪指标若采用算术平均，则忽视了注意力分配的非均匀性。基于投资者注意力理论对高互动文本加权，不仅符合行为金融学逻辑，更能精准捕捉驱动市场波动的“有效情绪”，提升指标的定价解释力。

2.2 大语言模型

2.2.1 大语言模型概述

大语言模型（Large Language Model，LLM）是一种基于深度学习的自然语言处理模型，模型参数可达千亿级别。基于大规模原始文本语料库的预训练和来自人类反馈的强化学习，大语言模型能够捕捉到语言背后深层的统计规律、逻辑关联及世界知识。相较于早期的循环神经网络或判别式模型，LLM 在处理复杂文本时展现出显著的优越性。其核心价值在于当模型参数规模跨越临界点后产生的“涌现能力”，这使得模型不仅具备了强大的上下文学习能力，还能在无需大规模参数微调的前提下，通过提示词工程在零样本或少样本场景中高质量地完成各类下游任务。

在金融文本处理领域，LLM 的语义理解深度为解析高噪声、高专业性的舆情数据提供了新途径。传统的情感分析方法往往受限于关键词匹配或浅层语义特征，难以有效识别金融评论中广泛存在的反讽、修辞以及隐含的逻辑推演。而 LLM 凭借其复杂的注意力机制，能够精准捕捉文本中的非线性语义特征。以通义千问为代表的国产大语言模型，由于在中文语料及本土金融文化语境下的深度优化，在处理中文金融文本时展现出

中国知网 https://www.cnki.net

了极强的语义对齐能力与逻辑推理性能，为金融市场的非结构化数据分析提供了重要的技术支撑。

2.2.2　Transformer

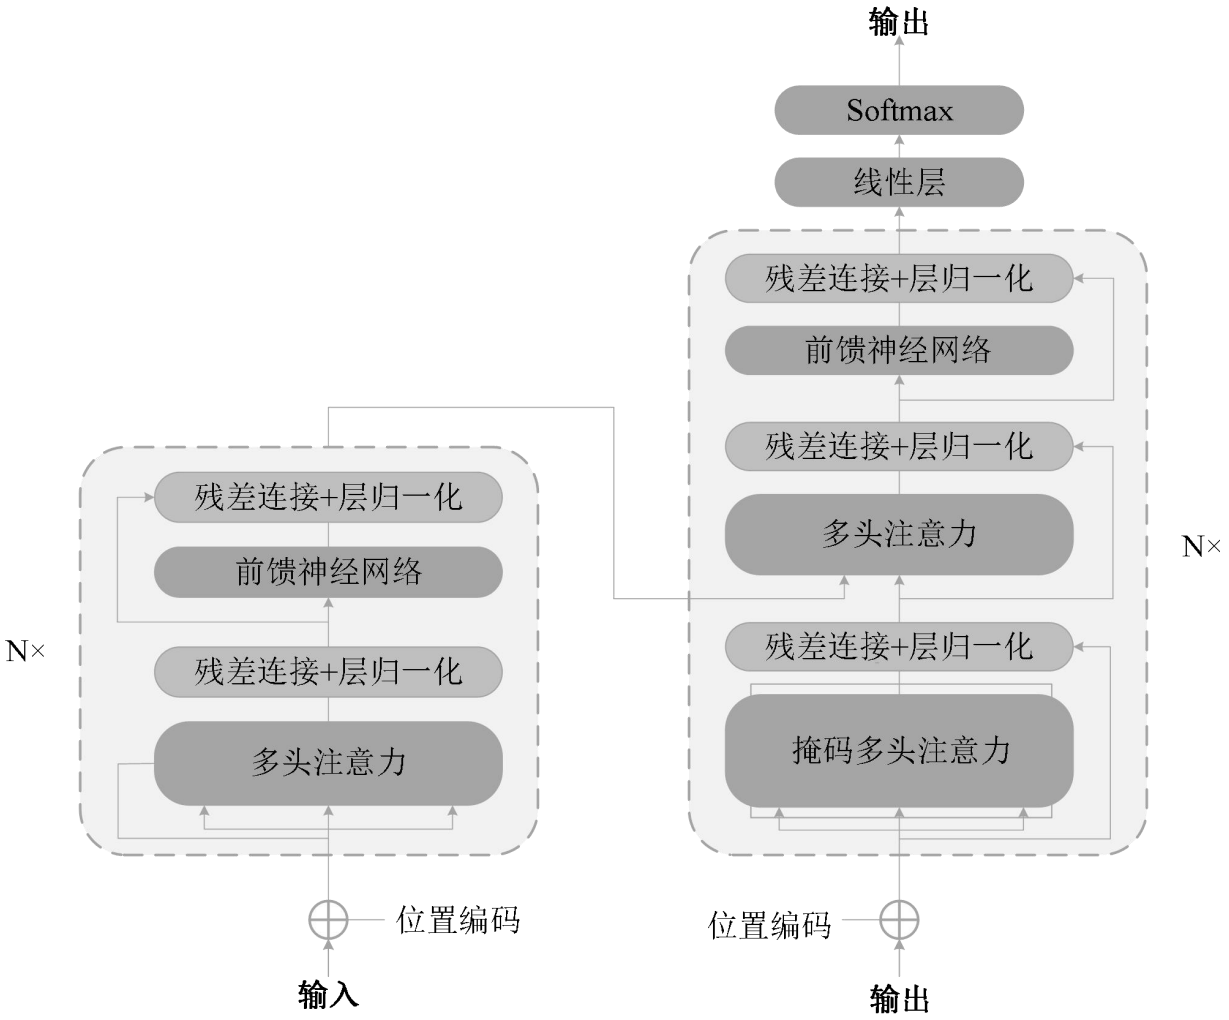


图 2.1 Transformer 模型结构

Fig. 2.1 Architecture of the Transformer Model

Transformer 模型是由 Google 的研究团队在 2017 年提出的，其核心在于多头注意力机制，其数学本质是对输入序列进行加权聚合，以计算序列中每个元素与其他所有元素的相关性。对于输入序列中的每一个位置，模型将其映射为三个向量：查询向量（Query, Q）、键向量（Key, K）和值向量（Value, V）。注意力权重的计算基于查询向量与键向量的相似度。

中国知网　https://www.cnki.net

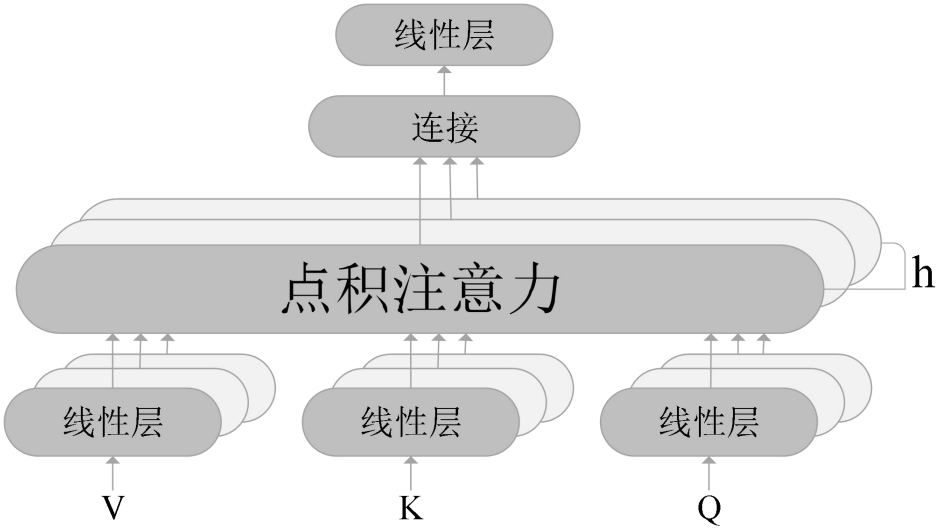


图 2.2 多头注意力机制示意图

Fig. 2.2 Schematic Diagram of Multi-Head Attention Mechanism

具体而言，模型首先计算Q与K的转置矩阵的点积，并通过缩放因子$\sqrt{d_k}$中d_k为量度行归一化，以防止点积结果过大导致 Softmax 函数进入梯度极小的饱和区。随后经 Softmax 归一化获取概率权重，对值向量V进行加权求和。该过程的形式化表达如下：

$$\text{Attention}\left(Q,K,V\right)=\text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V\,, \tag{2.1}$$

为增强多子空间语义捕捉能力，Transformer 引入了多头注意力机制。该机制将Q、K和V通过线性变换投影至h个特征空间独立计算，最后将各头输出拼接并经线性变换输出。其公式如下：

$$\text{MultiHead}\left(Q,K,V\right)=\text{Concat}\left(\text{head}_1,\ldots,\text{head}_h\right)W^O\,, \tag{2.2}$$

$$\text{where head}_i=\text{Attention}\left(QW_i^Q,KW_i^K,VW_i^V\right), \tag{2.3}$$

其中，W_i^Q,W_i^K,W_i^V分别为第i个头的投影矩阵，W^O为输出变换矩阵。由于 Transformer 缺乏循环或卷积结构，模型在输入嵌入中加入了正余弦位置编码，确保模型能够利用相对位置或绝对位置信息：

$$PE_{(pos,2i)}=\sin\left(pos/10000^{2i/d_{\text{model}}}\right), \tag{2.4}$$

$$PE_{(pos,2i+1)}=\cos\left(pos/10000^{2i/d_{\text{model}}}\right), \tag{2.5}$$

其中pos表示位置，i表示维度索引。这种编码方式使得模型能够轻易学习到相对位置的线性关系，对于理解文本时序逻辑至关重要。在每个注意力层之后，Transformer 包含一个全连接的前馈网络（FFN），由两个线性变换和一个 ReLU 激活函数组成：

$$\text{FFN}\left(x\right)=\max\left(0,xW_1+b_1\right)W_2+b_2\,. \tag{2.6}$$

中国知网 https://www.cnki.net

此外，为了解决深层网络中的退化问题，每个子层都采用了残差连接和层归一化，这一设计保证了梯度在反向传播中的有效流动，使得构建极深的大语言模型成为可能。

2.2.3　通义千问

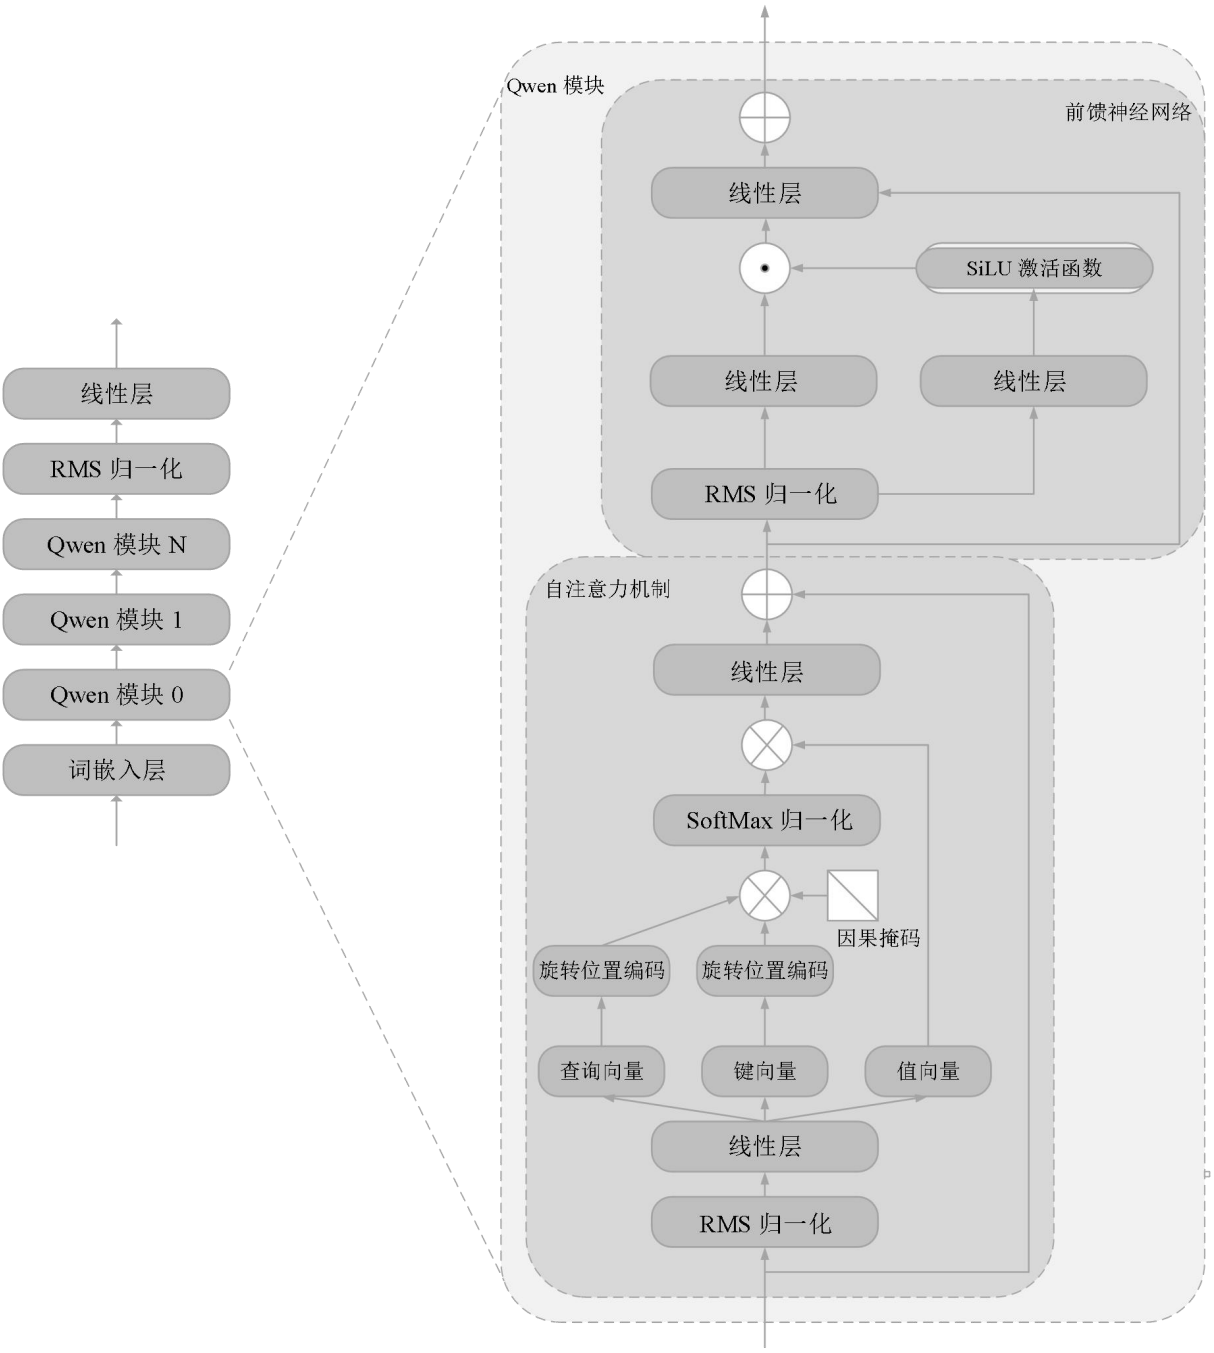


图 2.3 Qwen 模块示意图

Fig. 2.3 Schematic Diagram of the Qwen Module

通义千问（Qwen）是基于 Transformer 解码器构建的生成式预训练模型。相较于 2.2.2 节所述的原始 Transformer 结构，Qwen 为了提升在大规模参数下的训练稳定性与推理性

中国知网　https://www.cnki.net

能，在位置编码、激活函数及归一化策略等关键组件上进行了针对性的数学优化。

不同于原始 Transformer 采用的绝对正弦位置编码，Qwen 引入了旋转位置编码（RoPE），对嵌入向量进行位置相关的旋转变换，有效地捕捉词元之间的相对位置关系，从而提升模型在建模上下文依赖、特别是长距离依赖方面的表现。对于二维子空间中的特征向量，RoPE 通过一个旋转矩阵实现位置编码。假设 m 为绝对位置，θ 为预设参数，变换后的向量可以表示为：

$$f\left(\mathbf{x},m\right)=\begin{pmatrix}\cos m\theta & -\sin m\theta\\ \sin m\theta & \cos m\theta\end{pmatrix}\begin{pmatrix}x_0\\ x_1\end{pmatrix}. \tag{2.7}$$

在多头注意力机制中，这种旋转操作被应用到每个注意力头的子维度上。RoPE 的优势在于，当计算两个位置 m 和 n 的注意力分数时，其内积 $f\left(\mathbf{q},m\right),f\left(\mathbf{k},n\right)$ 仅依赖于相对距离 $m-n$。这一特性赋予了通义千问极强的长序列外推能力，使其在处理超越训练长度的金融长文本时仍能保持语义连贯性。

在前馈神经网络层，Qwen 摒弃了传统的 ReLU 或 GELU 激活函数，转而采用 SwiGLU 变体。这是一种基于门控机制的非线性激活函数，结合了 Swish 函数与线性门控单元。其数学形式定义为：

$$\mathrm{SwiGLU}\left(x\right)=\mathrm{Swish}_{\beta}\left(xW\right)\odot\left(xV\right), \tag{2.8}$$

其中，$\odot$ 表示逐元素乘法，W 和 V 为可学习的权重矩阵，$\mathrm{Swish}_{\beta}\left(z\right)=z\cdot\sigma\left(\beta z\right)$（$\sigma$ 为 Sigmoid 函数）。相比于传统的激活函数，SwiGLU 引入了额外的参数矩阵 V 来帮助网络更好地捕捉输入中的有用信息，提高网络的特征表达能力，有助于模型理解复杂的金融语义逻辑。

为了解决深层 Transformer 训练过程中的梯度爆炸问题并加速收敛，Qwen 采用了均方根层归一化（Root Mean Square Layer Normalization，RMSNorm）替代层归一化，以确保训练的高效性。其计算公式如下：

$$\mathrm{RMSNorm}\left(\mathbf{x}\right)=\frac{\mathbf{x}}{\sqrt{\frac{1}{d}\sum_{i=1}^{d}x_i^2+\epsilon}}\cdot\mathbf{g}, \tag{2.9}$$

其中 $\mathbf{g}$ 为可学习的缩放参数，ϵ 为防止分母为零的微小常数。这种简化不仅降低了计算开销，还使得模型在训练初期更加稳定。

在训练流程上，通义千问遵循标准的自回归语言建模范式。给定一个由文本序列构成的语料库 $\mathcal{U}=\left\{u_1,u_2,\ldots,u_n\right\}$，模型的优化目标是最大化似然函数，即根据已知的上文预测下一个词元：

中国知网 https://www.cnki.net

$$\mathcal{L}(\Theta)=\sum_{i}\log P\left(u_i|\ u_{i-k},\ldots,u_{i-1};\Theta\right),\tag{2.10}$$

其中k为上下文窗口大小，Θ为模型参数。通过在海量的多语言及金融垂直语料上优化该目标函数，模型习得了丰富的语义表征与知识推理能力，从而能够胜任本文中对股评文本的高精度情绪识别任务。

2.3　深度学习

2.3.1　TCN

时间卷积网络（Temporal Convolutional Network，TCN）是由 Bai 等人从卷积神经网络（CNN）进行改进所得到的一种网络。TCN 独特的卷积方式可以获得指数级增长的感受野，使得其在处理时序数据的应用中表现出色。TCN 的核心架构主要由因果卷积、扩张卷积与残差连接三个关键模块构成。

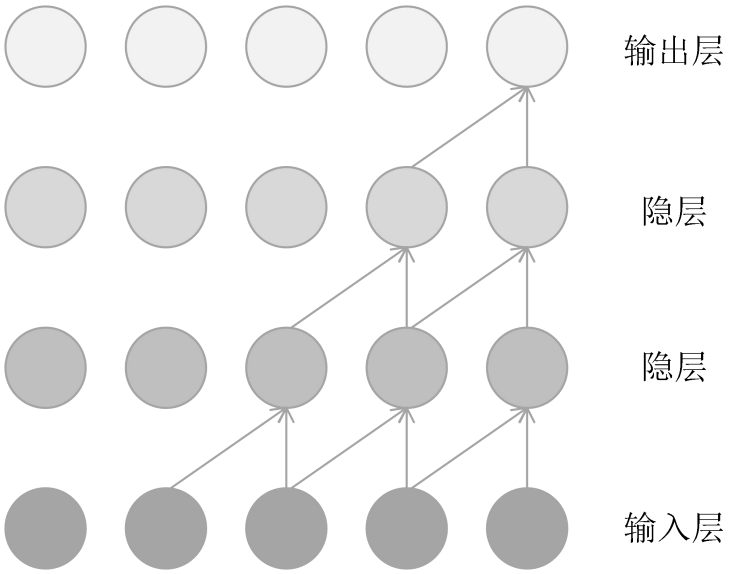


图 2.4 因果卷积示意图

Fig. 2.4 Schematic Diagram of Causal Convolution

因果卷积确保了在时刻t的输出y_t仅依赖于时刻t及其之前的历史输入$\{x_t,x_{t-1},\ldots\}$，而完全屏蔽$t+1$之后的未来数据。这种单向的结构设计使得 TCN 能够模拟自回归模型的生成过程，即$p(\mathbf{x})=\prod_{t}p\left(x_t|\ x_{0:t-1}\right)$，从而在数学逻辑上保证了序列预测的合法性。

中国知网　https://www.cnki.net

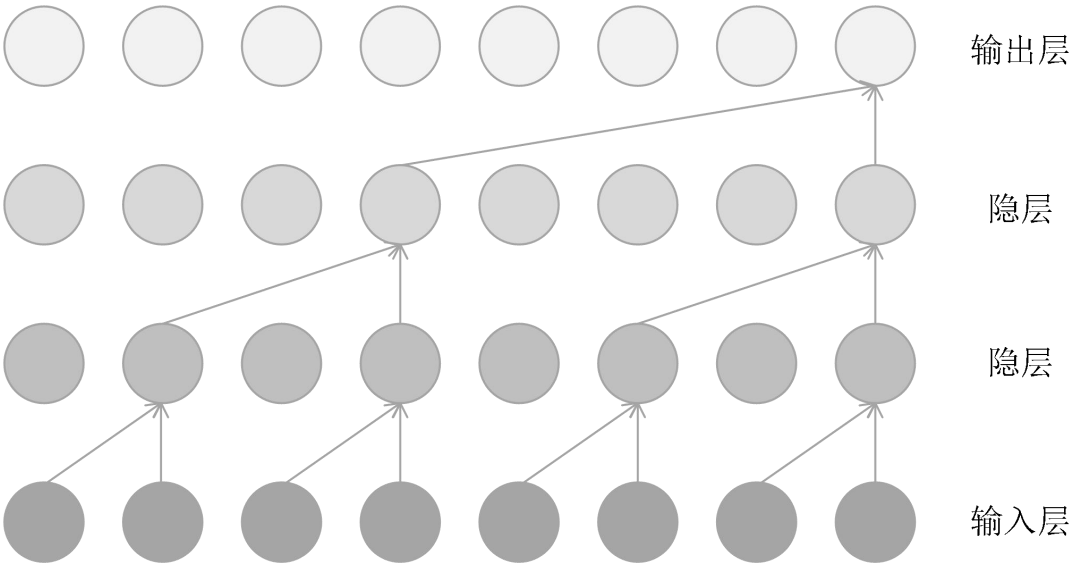


图 2.5 扩张卷积示意图

Fig. 2.5 Schematic Diagram of Dilated Convolution

扩张卷积在卷积核的采样点之间插入固定间距的“空洞”，从而在不增加参数量的前提下扩大单层网络的覆盖范围，有效避免高昂计算成本以及精度损失的问题，对于一维输入序列 $\mathbf{x}\in\mathbb{R}^n$ 和卷积核 $f:\{0,\ldots,k-1\}\to\mathbb{R}$，定义扩张因子为 d 的扩张卷积操作 F 在时刻 s 的输出为：

$$F(s)=(\mathbf{x}*_d f)(s)=\sum_{i=0}^{k-1} f(i)\cdot \mathbf{x}_{s-d\cdot i}, \tag{2.11}$$

其中 k 为卷积核大小，$s-d\cdot i$ 表示采样的历史时刻。在 TCN 的网络设计中，扩张因子 d 通常随着层数 i 的增加呈指数级增长（即 $d=2^i$）。这种设计使得网络的有效历史记忆长度随层数呈指数级扩展，从而能够用较浅的网络深度覆盖极长的历史时间窗口，高效提取长周期的趋势特征。

为了进一步增强模型的非线性表达能力，通常需要构建较深的网络结构，但随着深度的增加，非凸优化中的梯度消失问题会严重阻碍模型的收敛。残差连接可以缓解由网络深度增加而导致的梯度消失与爆炸问题，TCN 通过引入残差连接，可以拥有更深的网络结构。每个残差块包含两层扩张卷积和非线性激活函数，并引入权重归一化与 Dropout 以防止过拟合。残差块的输出 o 定义为输入 $\mathbf{x}$ 与变换函数 $\mathcal{F}(\mathbf{x})$ 的叠加：

$$o=\mathrm{Activation}\left(\mathbf{x}+\mathcal{F}(\mathbf{x})\right). \tag{2.12}$$

中国知网 https://www.cnki.net

2.3.2　Informer

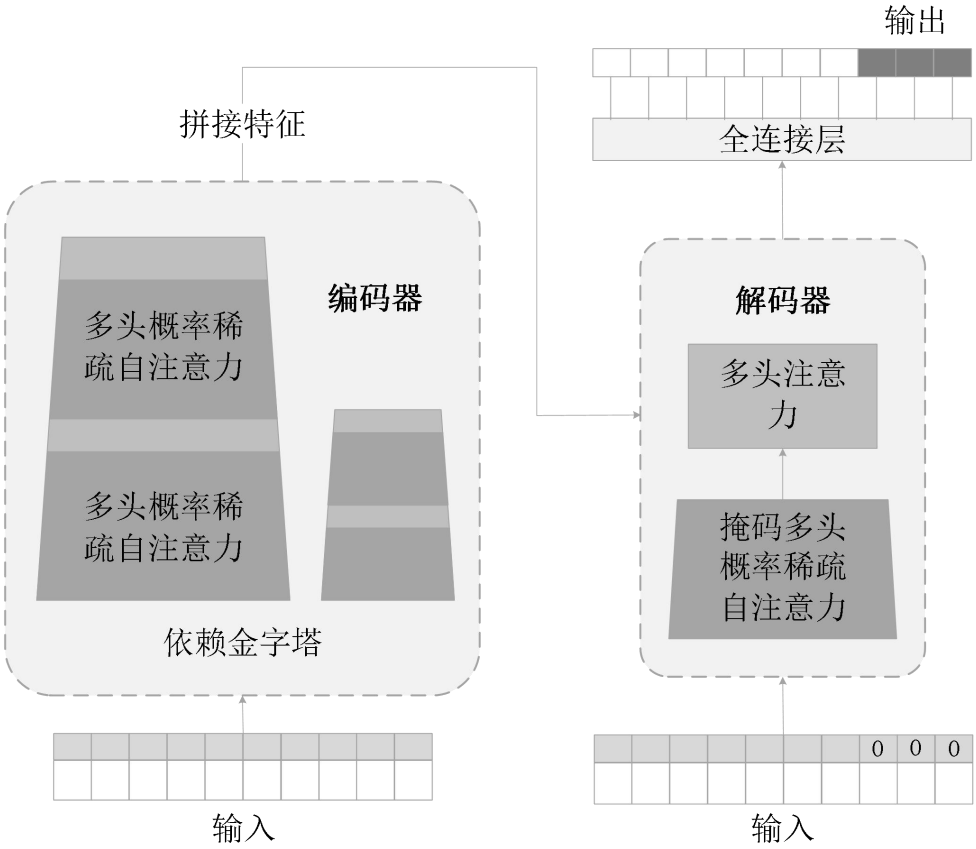


图 2.6 Informer 模型结构

Fig. 2.6 Informer Model Architecture

Informer 模型是 Zhou 等于 2021 年提出的一种基于注意力机制的长时间序列预测模型。该模型在保留 Encoder-Decoder 残差结构的基础上，通过引入概率稀疏注意力机制、自注意力蒸馏操作以及生成式解码器，成为当前时序预测领域的基准模型之一。Informer 提出利用 Kullback-Leibler（KL）散度来度量注意力分布与均匀分布之间的差异。KL 散度大的查询向量对应重要特征，依据 KL 散度筛选关键查询向量，仅计算与这些查询向量相关的注意力值。定义第 i 个查询向量 $\mathbf{q}_i$ 的稀疏性度量 $M\left(\mathbf{q}_i,\mathbf{K}\right)$ 为其概率分布 p 与均匀分布 q 之间的 KL 散度近似：

$$M\left(\mathbf{q}_i,\mathbf{K}\right)\approx \ln\sum_{j=1}^{L} e^{\frac{\mathbf{q}_i\mathbf{k}_j^T}{\sqrt{d}}}-\frac{1}{L}\sum_{j=1}^{L}\frac{\mathbf{q}_i\mathbf{k}_j^T}{\sqrt{d}}. \tag{2.13}$$

基于该度量，模型仅保留 Top-u 个稀疏度最高的查询向量参与点积运算，而将其他查询向量的注意力值置为均值。ProbSparse 注意力机制的形式化表达为：

中国知网　https://www.cnki.net

$$\text{Attention}\left(\mathbf{Q},\mathbf{K},\mathbf{V}\right)=\text{Softmax}\left(\frac{\overline{\mathbf{Q}}\mathbf{K}^{T}}{\sqrt{d}}\right)\mathbf{V}\ , \tag{2.14}$$

其中 $\overline{\mathbf{Q}}$ 为筛选后的稀疏查询矩阵。这种机制在保证信息提取有效性的同时，显著降低了长序列计算的冗余度。

为了进一步压缩特征维度并提取高层级的时序依赖，Informer 在编码器层级之间引入了蒸馏操作。由于概率稀疏机制虽然减少了点积计算，但特征映射在层级传递过程中仍保留了原始的时间维度 L，导致深层网络的内存占用依然庞大。蒸馏操作通过引入一维卷积与最大池化，构建了一种类似于金字塔的特征提取结构。

具体而言，从第 j 层到第 $j+1$ 层的映射过程可以表示为：

$$\mathbf{X}_{j+1}=\text{MaxPool}\left(\text{ELU}\left(\text{Conv1D}\left(\left[\mathbf{X}_{j}\right]_{\text{AB}}\right)\right)\right), \tag{2.15}$$

其中 $[\cdot]_{\text{AB}}$ 表示注意力模块的输出，激活函数采用 ELU。通常设置卷积步长为 1，最大池化步长为 2，这意味着每经过一个蒸馏层，序列的时间维度将减半。通过逐层减半输入序列长度，过滤冗余信息以突出重要特征，进一步降低计算成本。

在推断阶段，Informer 摒弃了传统 Transformer 逐点自回归的预测方式，转而采用生成式解码策略。这种解码器接收两部分输入：一部分是作为引导信号的历史序列片段 $\mathbf{X}_{\text{token}}$，另一部分是用于占位的零填充序列 $\mathbf{X}_{0}$。

$$\mathbf{X}_{\text{feed_de}}=\left\{\mathbf{X}_{\text{token}},\mathbf{X}_{0}\right\}. \tag{2.16}$$

通过一次前向传播，解码器能够利用概率稀疏注意力机制处理历史引导信息，并一次性输出未来所有时间步的预测结果。这种非自回归的生成模式不仅极大地提升了长序列预测的推理速度，还有效避免了传统步进式预测中常见的误差累积问题，使其在处理非平稳时间序列时表现出更强的鲁棒性。

2.4 本章小结

本章系统梳理了研究的理论基础与核心算法。金融层面，基于行为金融与投资者注意力理论，阐明非结构化情绪影响股价的内在逻辑，支撑后续加权情绪指标的构建；文本层面，论证了通义千问大模型解析 A 股复杂语境及提取深层情绪特征的技术优势；建模层面，剖析了 TCN 捕捉局部微观跳变与 Informer 处理长序列全局依赖的互补机理。综上，本章理清了“情绪驱动价格”脉络并确立了深度学习工具，为构建大模型情绪增强的 TCN-Informer 预测框架奠定了基础。

中国知网 https://www.cnki.net

3　大模型情绪增强的 TCN-Informer 模型

针对现有研究在非结构化文本挖掘深度不足以及单一预测模型难以兼顾长短时序特征的局限性，本章将重点阐述本文提出的核心方法论框架。在特征构建层面，本章将详细介绍如何利用通义千问大语言模型对海量股评进行深层语义标注，并结合投资者注意力理论，设计基于“阅读—评论”互动数据的加权算法，构建出内嵌市场主流共识的日度情绪指标，以解决传统情感分析方法存在的语境缺失问题。在模型构建层面，针对股票日度数据兼具长期趋势与短期突变的统计特性，本章提出 TCN-Informer 模型，该模型通过并行引入 TCN 模块来弥补 Informer 在局部微观特征提取上的短板，旨在实现“宏观全局视野”与“微观局部感知”的非线性融合。

3.1　基于大语言模型的日度情绪指标构建

3.1.1　大语言模型情绪标注

考虑到中文财经文本中存在大量隐喻、反讽及特定的市场术语，本文选用了阿里通义实验室研发的 Qwen-3 大语言模型作为核心分析工具。作为当前中文语境下表现最优的通用大模型之一，Qwen-3 在海量中文金融语料的预训练基础上，经过了指令微调与人类反馈对齐，具备卓越的上下文理解能力与逻辑推理能力。相较于 BERT 等判别式模型，生成式的 Qwen-3 能够更精准地捕捉长文本中的细微情绪转折。

提示词的设计直接决定了模型输出的质量与格式规范。为了引导 Qwen-3 准确执行金融情感分类任务，本文采用了一种包含“角色设定—任务描述—输出约束”三要素的结构化提示策略。

首先，赋予模型“专业金融文本情感分析专家”的角色，以激活其在金融领域的潜在知识库。其次，明确定义情感分类标准：将任务简化为二分类问题即消极与积极，分别映射为数值标签“0”与“1”。这种二元划分能够最大化地保留市场情绪的极性特征，同时减少模棱两可的中性样本对预测模型的干扰。最后，为了便于后续的数据清洗与格式化，加入了严格的输出约束，禁止模型输出任何推理过程或标点符号。

具体的系统级提示词设计如下表 3.1 所示。

中国知网　https://www.cnki.net

表 3.1 大语言模型提示词设计

Tab. 3.1 Prompt Design for Large Language Models

说明	提示词内容与逻辑配置
预设场景	你是一个专业的金融文本情感分析专家。你的任务是分析给定的一组 A 股市场股评文本的情感倾向，以辅助构建量化投资情绪指标。你需要深入理解中文金融语境下的术语、隐喻（如“跳水”、“割肉”）及反讽表达，准确判断投资者对股价未来走势的预期。
判别规则	负面判定：如果文本表现出负面、消极、悲观或利空的情感，标记为 0。 正面判定：如果文本表现出正面、积极、乐观或利好的情感，标记为 1。严格对应：必须严格按照输入文本的顺序进行分析，确保输出列表长度与输入列表长度完全一致。
少样本示例	示例 1 输入文本：“宁德时代业绩大超预期，明天一字板预定！”情感标记：1 示例 2 输入文本：“主力资金在诱多出货，大家快跑，不要接盘。”情感标记：0 示例 3 输入文本：“利好出尽是利空即使高开也要坚决离场”情感标记：0
用户交互流程	<系统指令>我会给你一组文本，请分析每条文本的情感倾向。 <当前输入>输入文本列表：['文本 1 内容...', '文本 2 内容...', ..., '文本 N 内容...']
输出要求	请严格按照文本的顺序，返回一个包含 0 和 1 的 JSON 列表。 格式示例：[0, 1, 0, 1, 1, 0, 0, 1, 0, 1] 禁止冗余：不要返回任何其他解释、背景分析、标点符号或文字说明，只返回 JSON 列表。

为了进一步提升模型在处理复杂文本时的稳定性，提示词中还引入了少样本学习机制。在系统提示词后，附带了 3 个典型样本作为上下文示例，涵盖了显性利好、显性利空以及含有反讽语气的隐性利空样本。这种“上下文学习”范式显著提升了模型对 A 股特有表达方式的理解准确率。

3.1.2 日度情绪指标构建

在完成基于大语言模型的文本情感标注后，本文获得了每一条评论的情感倾向标签。然而，原始的离散标签序列无法直接作为连续变量输入时间序列预测模型，且简单的算术平均法忽略了不同舆论个体在市场影响力上的显著异质性。基于前文阐述的投资者注意力理论，本文通过极性映射与加权聚合两个步骤，构建了更能反映市场主流共识的日度加权情绪指标。

阅读量与评论量能够量化特定观点在投资者群体中的关注程度与认同广度。一条高阅读、高评论量的评论往往代表了市场的主流共识或情绪爆发点，具有更高的信号信噪比。考虑到社交媒体数据存在典型的“长尾分布”特征，即少数热门帖子的阅读量与评论量远超平均水平，若直接使用原始互动数据作为权重，极易导致指标被个别极端样本所主导，产生统计噪声。本文采用了更为严谨的均值比率插补法进行修正，具体而言，

中国知网 https://www.cnki.net

利用数据集中评论量与阅读量均完整的样本子集，计算全局的“阅读—评论转化率”γ：

$$\gamma = \frac{\sum_{i \in \Omega_{obs}} Comment_i}{\sum_{i \in \Omega_{obs}} Read_i}, \tag{3.1}$$

其中Ω_{obs}为观测完整的样本集合。对于评论量缺失的样本，利用该比率将其阅读量映射为估计评论量$\widehat{Comment}_{i,t} = Read_{i,t} \times \gamma$，从而在保留高阅读量样本关注度价值的同时，实现了权重量纲的严格对齐。

在解决数据缺失问题后，为了防止情绪指标被极少数超高热度的“病毒式”帖子主导，对修正后的评论量进行了对数平滑处理，构建最终权重$w_{t,i}$：

$$w_{t,i} = \ln\left(1 + Comment^{*}_{i,t}\right), \tag{3.2}$$

其中$Comment^{*}_{i,t}$为真实评论量或经插补后的估计值。最后，采用加权平均法聚合当日的市场总情绪，日度情绪指标$DailySentiment_t$的形式化定义如下：

$$DailySentiment_t = \frac{\sum_{i=1}^{N_t} (S_{i,t} \times w_{i,t})}{\sum_{i=1}^{N_t} w_{i,t}}, \tag{3.3}$$

其中，$S_{i,t}$为大模型标注的情感极性，N_t为t日内的总评论量。通过这一构建体系，本文得到了一个时间跨度与股票交易数据完全对齐的连续时间序列。该指标有效过滤了低关注度的噪声评论，为后续 TCN-Informer 模型提供了一个高质量的、内嵌了投资者注意力的外生输入特征。

3.2　大模型情绪增强的 TCN-Informer 模型结构

3.2.1　融合情绪特征的多源信息预测机制

股票市场的时间序列变化不仅受到历史价格、成交量等内生数值特征的驱动，更受到市场预期、投资者情绪等外生突发因素的显著冲击。传统的深度学习时间序列预测模型通常仅依赖于结构化的历史交易数据，这种“闭门造车”式的建模忽略了非结构化互联网舆论对市场走势的潜在先导作用。事实上，投资者情绪是反映市场心理博弈和风险偏好的核心指标，其对资产价格的短期异常波动与长期趋势反转均具有不可忽视的解释力。

为此，本文在预测框架中提出了一种多源信息融合机制，将 3.1 节中基于大语言模型与投资者注意力理论构建的日度加权情绪指标$DailySentiment_t$，作为一种辅助前瞻特征引入 TCN-Informer 模型，参与时间序列的联合建模。

在具体的数据融合层面，日度情绪指标与传统的交易序列（如开盘价、收盘价、最高价、最低价、成交量等）在时间维度t上进行了严格的对齐拼接。情绪指标的引入，

中国知网　https://www.cnki.net

实质上是为预测模型提供了一个独立于量价特征的“增量信息源”。在本文提出的大模型情绪增强的 TCN-Informer（LLM-TCN-Informer）模型中，情绪特征与量价特征共同构成了多维输入张量，并在模型中发挥着双重协同作用：

一方面，情绪特征显著提升了模型对短期波动的敏感性。股票市场中因突发利好或利空引发的情绪骤变，往往先于价格反应。TCN 模块通过因果扩张卷积，能够敏锐地捕捉这种由情绪冲击带来的高频价格跳变。

另一方面，情绪数据辅助了长程趋势的均衡建模。市场情绪的周期性演变与价格具有长期的协整关系。Informer 模块通过概率稀疏全局注意力机制，能够更好地整合“长期情绪积淀”与“价格趋势”之间的深层映射规律，从而有效修正传统模型在市场转折点处容易出现的预测滞后问题。

3.2.2 TCN-Informer

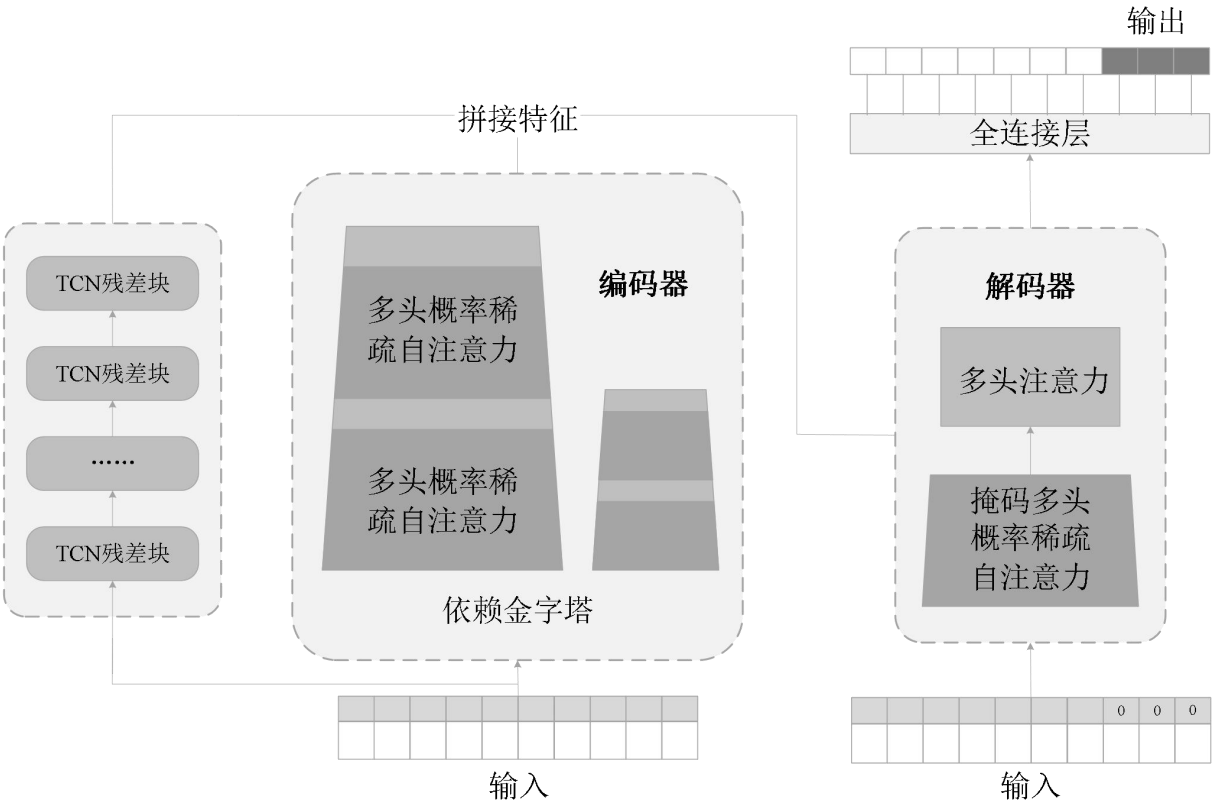


图 3.1 TCN-Informer 模型

Fig. 3.1 Architecture of the TCN-Informer Model

本文提出的 TCN-Informer 模型旨在通过并行双流架构，实现对高维非平稳股票日度数据中长短周期特征的有效解耦与重构。在统计学习框架下，这本质上是求解一个从历史多变量量价状态空间 $\mathcal{X}$ 到未来收益率空间 $\mathcal{Y}$ 的高维非线性映射泛函 $\Phi(\cdot;\Theta)$。

结合图 3.1 所示的模型结构，设模型的初始输入为一个时间窗口长度为 L、特征维

中国知网 https://www.cnki.net

度为 d_{in} 的多变量张量 $\mathbf{X}\in\mathbb{R}^{L\times d_{in}}$，涵盖开盘价、收盘价、成交量等核心微观流动性指标以及日度情绪指标。为消除量纲造成的非凸优化障碍，对 $\mathbf{X}$ 加 Z-Score 标准化并通过共享的线性嵌入层与周期性位置编码机制将离散的物理特征映射至连续的统一隐语义空间：

$$\mathbf{E}=\mathbf{X}\mathbf{W}_{emb}+\mathbf{P}_{pos}\in\mathbb{R}^{L\times d_{model}}, \tag{3.4}$$

其中，$\mathbf{W}_{emb}\in\mathbb{R}^{d_{in}\times d_{model}}$ 为特征提纯矩阵，$\mathbf{P}_{pos}$ 的第 t 行、第 $2i$ 与 $2i+1$ 列由正余弦函数 $\sin\left(t/10000^{2i/d_{model}}\right)$ 与 $\cos\left(t/10000^{2i/d_{model}}\right)$ 严格定义，从而为时间序列赋予绝对的相位顺序。隐变量 $\mathbf{E}$ 随后被平行送入 TCN 分支与 Informer 分支这两个具有不同数学特性的特征提取器中。

TCN 分支专注于捕获由资金博弈引发的高频价格跳变。为严格杜绝时间序列预测中的前视偏差，该分支的拓扑结构被限制为因果映射。定义膨胀系数 $d=2^{l}$（l 为残差块层数），一维扩张因果卷积算子在时间维度 t 的定义为：

$$\mathbf{H}_{conv}^{(l)}(t)=(\mathbf{E}*_{d}f)(t)=\sum_{i=0}^{k-1}f(i)\cdot\mathbf{E}_{t-d\,i}, \tag{3.5}$$

其中 k 卷积核大小。鉴于金融序列的强异方差性，极易引发深层网络的梯度爆炸，TCN 内部摒弃了常规的特征空间归一化，转而采用参数空间的权重归一化。即对卷积权重向量 $\mathbf{v}$，引入标量 g 进行重参数化：

$$\mathbf{w}=\frac{g}{\|\mathbf{v}\|_{2}}\mathbf{v}. \tag{3.6}$$

结合残差连接，TCN 算子的最终映射可表示为：

$$\mathbf{H}_{TCN}=\mathrm{ReLU}(\mathbf{E}\,|\,\mathcal{G}_{conv}(\frac{g}{\|\mathbf{v}\|_{2}}\mathbf{v}\,|\,\mathbf{E}))\in\mathbb{R}^{L\times d_{model}}. \tag{3.7}$$

Informer 分支旨在跨越较长的时间跨度，识别股价的长期趋势与周期性反转。首先，针对传统自注意力矩阵 $\mathcal{O}\left(L^{2}\right)$ 的冗余计算，模型计算第 i 个查询向量 $\mathbf{q}_{i}$ 的注意力概率分布与均匀分布之间的 KL 散度，定义稀疏性度量 $M\left(\mathbf{q}_{i},\mathbf{K}\right)$：

$$M\left(\mathbf{q}_{i},\mathbf{K}\right)\approx\ln\sum_{j=1}^{L}\exp\left|\frac{\mathbf{q}_{i}\mathbf{k}_{j}^{\top}}{\sqrt{d_{k}}}\right|-\frac{1}{L}\sum_{j=1}^{L}\frac{\mathbf{q}_{i}\mathbf{k}_{j}^{\top}}{\sqrt{d_{k}}}. \tag{3.8}$$

基于此度量筛选出蕴含最大信息熵的 Top-u 个活跃查询形成 $\overline{\mathbf{Q}}$，计算稀疏注意力特征：

$$\mathbf{H}_{Attn}=\mathrm{Softmax}\left|\frac{\overline{\mathbf{Q}}\mathbf{K}^{\top}}{\sqrt{d_{k}}}\right|\mathbf{V}. \tag{3.9}$$

随后，特征进入依赖金字塔，逐层剔除高频交易噪声并压缩时间维度：

中国知网　https://www.cnki.net

$$\mathbf{H}_{Enc}^{(j|1)} = \mathrm{MaxPool}\left(\mathrm{ELU}\left(\mathrm{Conv1D}_{k=3}\left(\mathbf{H}_{Attn}^{(j)}\right)\right)\right)_{stride=2}. \quad (3.10)$$

最终，编码器输出高度浓缩的全局特征矩阵 $\mathbf{H}_{Enc} \in \mathbb{R}^{L' \times d_{model}}$（其中，$L' < L$）。

在双流提取完成后，**Z** 模型通过通道对齐算子将局部特征 $\mathbf{H}_{TCN}$ 与全局特征 $\mathbf{H}_{Enc}$ 映射至相等的时序维度，并执行特征维度拼接：

$$\mathbf{Z} = \left(\mathbf{H}_{TCN} \oplus \mathbf{H}_{Enc}\right)\mathbf{W}_{fuse} + \mathbf{b}_{fuse}. \quad (3.11)$$

融合矩阵 $\mathbf{Z}$ 随后作为交叉注意力的键值对传入解码器。解码器的输入由已知历史片段 $\mathbf{X}_{token}$ 未来预测占位符 $\mathbf{X}_0$ 拼接而成。为保证自回归推断的理论合理性，数据首先通过掩码多头概率稀疏自注意力。通过引入下三角掩码矩阵 $\mathbf{M}$ 强制截断未来信息的逆向传播：

$$\mathbf{H}_{mask} = \mathrm{Softmax}\left(\frac{\overline{\mathbf{Q}}_d \mathbf{K}_d^{\top}}{\sqrt{d_k}} | \mathbf{M}\right)\mathbf{V}_d. \quad (3.12)$$

随后，$\mathbf{H}_{mask}$ 转化为查询向量，在多头注意力层中与编码端传递来的拼接特征图进行交叉内积运算。最后，解码后的高维语义向量通过全连接层映射回低维预测空间，一次性生成未来 H 步的股票价格预测：

$$\hat{\mathbf{Y}} = \mathbf{H}_{decode}\mathbf{W}_{out} + \mathbf{b}_{out} \in \mathbb{R}^{H \times 1}. \quad (3.13)$$

3.3 本章小结

本章阐述了核心方法论框架，构建了从文本情绪量化到深度学习预测网络的设计闭环。针对金融语义瓶颈，依托通义千问大模型实现高精度标注；结合投资者注意力理论，利用交互数据与平滑加权算法，将离散评论文本提炼为反映市场共识的日度情绪指标。

在此基础上，针对股价长程趋势与高频突变特性，设计了融合情绪特征的 TCN-Informer 模型：并行 TCN 分支利用因果扩张卷积捕捉短期价格跳变并规避前视偏差；Informer 分支通过概率稀疏自注意力机制整合长周期规律。

中国知网 https://www.cnki.net

4　实证分析

基于前文理论框架与模型设计，本章通过严谨的数据实验全方位评估所提方法的有效性与稳健性。实验体系从验证大语言模型在金融情绪标注任务中的精度优势出发，在融入高质量情绪指标后，深度考察 LLM-TCN-Informer 模型相较于传统预测模型在拟合优度等指标上的表现差异。通过消融实验定量测算情绪特征与 TCN 模块的边际贡献，并结合跨标的资产与多步预测检验模型的泛化边界。

4.1　数据来源与样本获取

4.1.1　股票的选取

为了确保实证结果兼具统计显著性与市场代表性，本文在构建样本池时遵循了“指数权重突出”、“行业赛道领军”以及“舆论数据富集”三大核心原则。基于此标准，本文选取了深证市场中极具影响力的三家上市公司作为具体研究对象，分别是：宁德时代、美的集团与立讯精密。

表 4.1 股票基本信息

Tab. 4.1 Basic Information of Stocks

股票名称	股票代码	所属行业
宁德时代	300750.SZ	电池-锂电池
美的集团	000333.SZ	白色家电-空调
立讯精密	002475.SZ	消费电子-消费电子零部件及组装

这三家上市公司均为深证 100 指数的核心成份股，分别在新能源电池、先进制造与消费电子领域占据龙头地位，其合计权重在指数中占比显著，很大程度上能够代表深市新兴产业的整体走势。同时，这些公司在东方财富、雪球等社区讨论热度长期居前，持续的高频文本流确保了情绪指标提取的密集性与精细度。这种兼具高质量交易数据与海量舆情特征的样本选择，为验证本文多源信息融合策略在提升预测精度方面的效用提供了坚实支撑。

4.1.2　股票评论文本数据

本文选取的非结构化文本数据主要来源于东方财富网股吧。作为国内散户活跃度最高、信息交互最密集的证券投资者社区之一，该平台汇聚了海量的个人投资者观点与即时市场情绪反馈，具有极高的样本代表性。针对前文选定的宁德时代、美的集团与立讯精密三只核心标的，本文通过网络爬虫技术，系统性地爬取了 2020 年 11 月至 2025 年 10 月期间的所有相关发帖数据。采集字段不仅包含帖子的评论，还同步获取了发帖时间、

中国知网　https://www.cnki.net

阅读量以及评论量等关键元数据。部分典型的股评文本数据样本如表 4.2 所示。

表 4.2 股票评论文本样例

Tab. 4.2 Examples of Stock Comment Texts

阅读量	评论量	评论	ID	日期
570	10	清仓，希望有低点接回来，祝好。	南京炒家南京炒家	10-28 09:40
351	7	今天摸一下 400 哈哈。	迷人的谷翼扬	10-28 10:06
44	0	如果不快速拉升，一会就又回到原点	股友 eu26936559	10-28 10:13
36	0	炒股就炒宁大哥！	黄金多 99999	10-28 10:17
40	0	宁王蚂蚁上树	达者之路	10-28 10:25

股评数据虽无直接价格信号，但能直观折射投资者的心理预期与情绪宣泄。这些非结构化文本不仅包含对基本面的解读，更构成了驱动资产短期波动的重要外生变量，是对传统定量交易数据的有效补充。

4.1.3 股票日度数据

本文的结构化交易数据主要来源于 AkShare 开源金融数据接口库。针对前文确定的宁德时代、美的集团与立讯精密三只样本股，本文通过该接口系统性地调取了 2020 年 11 月至 2025 年 10 月期间的完整日线数据。以宁德时代日度数据为例，原始数据如表 4.3 所示。

表 4.3 宁德时代原始日度数据

Tab. 4.3 Raw Daily Stock Data of CATL

日期	开盘价（元）	最高价（元）	最低价（元）	收盘价（元）	成交量	成交额
2020-11-02	247.00	265.50	244.5	260.14	18946131	4851443508.00
2020-11-03	260.00	260.00	247.18	256.02	18456665	4678655503.00
...	...	...	...	...	...	...
2025-10-30	405.98	409.08	396.83	398.29	34306088	13797530228.70
2025-10-31	398.00	406.80	388.20	388.77	34048350	13515773431.18

在具体的数据维度选取上，原始数据集涵盖了能够完整描述资产价格行为与市场流动性的核心变量，具体包括交易日期以及开盘价、最高价、最低价、收盘价四类价格指标。这四组价格数据共同构成了日内波动的完整区间，能够反映多空双方在当日常态交易中的博弈边界与最终定价。此外，本文还选取了成交量与成交额作为衡量市场活跃度的关键指标。成交量直观体现了资金的参与热度，而结合成交额可以有效辅助判断市场的分歧程度与流动性状况。鉴于收盘价在金融时间序列分析中具有较高的信息含量与基准价格地位，本文将其作为预测目标。

中国知网 https://www.cnki.net

4.2 数据预处理

4.2.1 文本数据预处理

原始爬取的股评文本普遍存在格式混乱、噪声冗余及部分时间信息缺失等问题。为确保大语言模型输入的语义有效性，并与后续的日度交易数据在时间面板上严格匹配，本文设计了包含文本去噪、时间标准化与交易日映射的三步预处理流程。

网络论坛数据往往夹杂大量无意义的噪音。本文首先清洗了文本中的特殊符号、URL 链接及无实际金融语义的语气词；其次，设定长度阈值，直接剔除字符过短且无明确观点的“灌水”评论；最后，针对机器水军刷屏现象对高度同质化的重复发帖进行精准合并与去重。

针对部分原始评论仅显示月、日与时间而缺失年份的现象，直接剔除会导致严重的信息流失。本文结合数据抓取时的物理时间轴与前后评论的时间连贯逻辑，通过上下文推断精准补全了缺失的年份信息，并将所有时间字段统一转换为“YYYY-MM-DD HH:MM:SS”的标准格式，保证了时间序列的绝对连续性。

为解决股评文本与股票交易数据之间的错配问题，本文引入了“信息累积—延迟释放”的时间对齐机制。具体映射逻辑为：当日 09:30 前发布的评论归入当日交易窗口，视为影响当日盘面的即时情绪；而当日 15:00 收盘后及周末、节假日发布的信息，因无法在当天市场中兑现，统一映射至下一个最近的有效交易日。

4.2.2 股票数据预处理

在建模前，本文首先对原始数据集进行了完整性与一致性检验，涵盖缺失值扫描、重复记录排查以及异常值检测。本文所选取的宁德时代、美的集团与立讯精密在样本区间内的数据质量较高，未发现字段缺失或重复录入的情况，且开盘价、收盘价等核心指标的数值分布均处于合理的波动范围内，无明显的逻辑错误。因此，本环节未执行插值填补或异常剔除操作，最大程度地保留了市场的原始交易痕迹。

在时间维度的处理上，鉴于 A 股市场采用特定的交易日制度，日期字段不参与具体的数值运算，而是作为时间序列的唯一索引。在周末及法定节假日等非交易时段，数据在时间轴上会呈现出自然的非连续性跳跃。本文在建模时遵循“交易连续性”而非“日历连续性”原则，即模型将相邻的两个交易日视为连续的时间步。

由于股票数据中不同特征的量纲与数量级存在显著差异，本文采用了 Z-Score 标准化方法对所有数值型特征进行变换。具体而言，针对开盘价等字段，分别计算其均值 μ 与标准差 σ，并将原始数据 x 映射为符合标准正态分布的新数值 z：

$$z = \frac{x - \mu}{\sigma}. \tag{4.1}$$

中国知网 https://www.cnki.net

4.3 模型评估指标

4.3.1 回归类误差指标

为了衡量预测模型的性能，本文选用 4 类误差指标进行评估。均方误差（Mean Squared Error, MSE）对预测偏差进行平方处理，其计算公式为：

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 . \tag{4.2}$$

通过比较平均绝对误差（Mean Absolute Error, MAE）与 MSE 的差异，可以判断模型的误差主要来源于整体的系统性偏差还是少数极端样本的预测失效。MAE 的计算公式如下：

$$MAE = \frac{1}{N}\sum_{i=1}^{N}| y_i - \hat{y}_i| . \tag{4.3}$$

平均绝对百分比误差（Mean Absolute Percentage Error, MAPE）计算偏差占真实值的比例，公式为：

$$MAPE = \frac{1}{N}\sum_{i=1}^{N}|\frac{y_i - \hat{y}_i}{y_i}|\times 100\% . \tag{4.4}$$

决定系数（R^2）用于模型的拟合程度，该指标越接近 1，表明模型越能有效捕捉到股票价格中的规律性成分，其公式为：

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2} . \tag{4.5}$$

4.3.2 分类评价指标

为了衡量情绪标注的二分类效果，本文选用 4 项误差指标进行评价。准确率（Accuracy）是衡量文本分类性能最直观的指标，它反映了模型对评论语料正负极性正确判断的样本占总测试样本的比例。假设真阳性（TP）为正确识别的积极评论量，真阴性（TN）为正确识别的消极评论量，假阳性（FP）与假阴性（FN）分别为误报与漏报的评论量，则准确率定义为：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} . \tag{4.6}$$

精确率（Precision）衡量了在模型预测为“积极”的所有评论中，实际确实为积极的比例，其公式为：

$$\text{Precision} = \frac{TP}{TP + FP} . \tag{4.7}$$

召回率（Recall）衡量了在所有实际为积极的评论样本中，模型成功捕捉到的比例，

中国知网 https://www.cnki.net

其公式为：

$$\text{Recall} = \frac{TP}{TP + FN}. \tag{4.8}$$

在模型验证过程中，精确率与召回率往往存在此消彼长的权衡关系。为了在“识别可靠性”与“样本覆盖率”之间寻找平衡，本文采用 F1-Score 作为调和平均指标，其公式为：

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \tag{4.9}$$

该指标越接近 1，表明模型在文本分类任务上既能保持较低的误判率，又能精准地识别出情感分布，体现了模型综合分类性能的优越性。

4.4　大模型情绪标注效果评估与日度指标构建

4.4.1　情绪标注效果检验

为了确保情感分析结果的准确性并构建可靠的验证基准，本文引入了 6194 条在金融 NLP 领域被广泛认可的已标注“积极/消极”的评论语料作为二分类情感验证集。为了满足监督学习类基准模型的训练需求并评估其泛化性能，本文将数据集按 80%与 20%的比例划分为训练集与测试集。

表 4.4 多模型情绪标注结果

Tab. 4.4 Sentiment Labeling Results of Multiple Models

评论语料	参考标注	LR	LSTM	CNN	LLM
还没上天？赶紧的	1	0	1	1	1
没底线了吗？	0	0	0	0	0
星期四今天一定会大涨，下午会涨的更多，	1	0	1	1	1
每天按时还一点。继续做多。买买买	1	1	1	1	1
这么好的趋势没人跟？认购走起	1	0	0	0	1

在对比实验中，本文选取了三种不同复杂度的经典模型——逻辑回归（LR）、文本卷积神经网络（TextCNN）以及长短期记忆网络（LSTM）作为基准对照组。为了保证公平性，基准模型均采用 Word2vec 算法将文本转化为静态词向量作为输入，多模型情绪标注结果如表 4.4 所示。上述基准模型受限于有限的标注训练集与静态词向量表征，而大语言模型得益于海量预训练语料的知识储备，本实验旨在验证 LLM 在金融情感分析任务中的实际适用性，而非严格意义上的公平基准对比。

中国知网　https://www.cnki.net

表 4.5 LLM 情绪标注效果比较

Tab. 4.5 Comparison of LLM-Based Sentiment Annotation Performance

模型类别	F1-Score	Accuracy
LR	57.11%	53.33%
LSTM	67.28%	66.85%
TextCNN	68.23%	67.67%
LLM	90.47%	90.46%

基于人工标注验证集，各模型在二分类情感判别任务上的具体表现如表 4.5 所示。实验数据显示，LR 表现最弱，准确率仅为 53.33%，表明线性模型难以在高维特征空间中划分复杂的非线性情感边界。TextCNN 与 LSTM 虽然表现优于线性模型，但仍未能超过 70%的准确率瓶颈。LLM 的 Accuracy 与 F1-Score 均达到 90%，较表现最好的传统深度学习模型提升了 20 个百分点以上。结果证明，大语言模型能够结合海量金融常识与上下文语境，精准解析“利空出尽”、“技术性回调”等深层语义。因此，利用大模型对全量评论数据进行批量标注，并以此构建高质量情绪指标输入后续的改进模型，在实证层面具有充分的可行性。

4.4.2 日度情绪指标构建

验证了大语言模型在金融语境下的标注效度后，本文利用该模型对清洗后的全量股评文本进行了情感极性标注。随后，严格按照 3.1.2 节所述的流程构建日度情绪指标，将原始的离散标签序列转化为可供量化模型读取的时间序列指标。

表 4.6 股评情绪标注结果及权重

Tab. 4.6 Sentiment Labeling Results and Weights of Stock Comments

阅读量	评论量	评论内容	LLM 情绪标签	权重
765	23	700 股已经卖了也挣了一万 7 了	1	3.18
52	1	会跌到 350 吗	0	0.69
90	3	宁王没有理由不涨！！	1	1.39
266	10	今天追高进来的。不会套我把	0	2.40
232	4	准备 5 日线先买几手吧。	1	1.61

表 4.6 展示了从原始评论到情感标注值的转化样例。完成逐条评论的权重计算与聚合后，本文将生成的“日度情绪指标”与股票基础交易数据按照日期特征进行连接，构建了跨度从 2020 年至 2025 年的多维融合数据集。

中国知网 https://www.cnki.net

表 4.7 多维融合数据集——以宁德时代为例

Tab. 4.7 Multidimensional Integrated Dataset of CATL

日期	开盘价（元）	最高价（元）	最低价（元）	收盘价（元）	成交量	成交额	日度情绪指标
2020-11-02	247.00	265.50	244.5	260.14	18946131	4851443508.00	240.79
2020-11-03	260.00	260.00	247.18	256.02	18456665	4678655503.00	282.73
...	...	...	...	...	...	...	...
2025-10-30	405.98	409.08	396.83	398.29	34306088	13797530228.70	88.12
2025-10-31	398.00	406.80	388.20	388.77	34048350	13515773431.18	75.99

表 4.7 呈现了融合后的最终数据形态。通过上述流程，本文成功将海量、高噪的股评文本提炼为内嵌“投资者注意力机制”的高质量量化指标，实现了与金融量价数据在时序上的严格对齐，为后续的模型预测奠定了坚实的数据基础。

4.5　大模型情绪增强的 TCN-Informer 模型实证结果

4.5.1　实验设置

表 4.8 模型核心超参数设置

Tab. 4.8 Key Hyperparameter Settings of the Model

参数类别	参数名称	设定值	说明
输入配置	输入序列长度(L)	48	对应约一季度的交易日
	预测序列长度(H)	1	单步预测
网络结构	特征维度	256	隐层特征映射维度
	批次大小	32	单次迭代样本数
	注意力头数	8	多头注意力并行数
	编码器层数	2	Informer Encoder 堆叠层数
	解码器层数	1	Informer Decoder 堆叠层数
	TCN 卷积核大小	3	捕捉局部邻域特征
训练策略	初始学习率	0.001	配合余弦退火或衰减策略
	Dropout 比率	0.1	防止神经元过拟合
	最大训练轮数	50	结合 Early Stopping 机制

中国知网　https://www.cnki.net

表 4.8 展示了 LLM-TCN-Informer 模型的核心超参数设置。为了保证实证结果的客观性与可复现性，本文在模型训练与评估过程中遵循了严格的时间序贯原则。具体而言，本文将 4.4.2 中构建的多维融合数据集，按照 80%与 20%的比例划分为训练集与测试集。其中，训练集用于模型参数的梯度更新与特征学习，测试集用于最终的模型泛化性能评估，不参与任何训练过程。所有输入数据在进入模型前均已完成前述的 Z-Score 标准化处理，以加速模型收敛。此外，通过 Early Stopping 机制与 Dropout 策略，模型在训练集与测试集上的性能差距保持在合理范围内，排除了严重过拟合的可能。

4.5.2 预测性能对比

为了直观评估本文提出的 LLM-TCN-Informer 模型在实际股价预测中的有效性，本节选取宁德时代作为典型案例进行详细分析。为了凸显多源信息融合与模型结构改进的优势，本文选取了几类基准模型进行横向对比，预测性能对比结果如表 4.9 所示。

表 4.9 股价预测性能对比——以宁德时代为例

Tab. 4.9 Performance Comparison of Stock Price Prediction of CATL

模型名称	特征输入	MSE	MAE	MAPE	R^2
ARIMA	交易数据	447.05	17.20	5.49%	0.818
LSTM	交易数据	284.03	13.23	4.19%	0.884
Informer	交易数据	173.79	9.84	3.02%	0.929
TCN-Informer	交易数据	82.98	6.61	2.05%	0.966
LLM-TCN-Informer	交易数据+情绪指标	60.95	5.52	1.84%	0.977

表 4.9 显示，基于线性假设的 ARIMA 模型拟合效果最弱，难以捕捉股价的非线性特征。相比之下，LSTM 与 Informer 将 R^2 达到至 0.884 与 0.929，但在缺乏外部情绪信息时，仅依赖交易数据的模型在转折点处存在明显的预测滞后。本文提出的 LLM-TCN-Informer 的 R^2 突破性达到 0.977，MSE 显著降至 60.95，在所有维度上均表现最优。这证明了大模型情绪指标作为价格波动的先行信号，配合 TCN 对局部突变的捕捉，能有效修正传统模型的滞后效应，为股价预测提供关键的增量信息。

4.5.3 消融实验

在前述的总体性能对比中，LLM-TCN-Informer 模型展现出了最优的预测精度。为了进一步打开模型的“黑箱”，本节设计了严格的消融实验。通过控制变量法，逐步剔除模型中的特定模块，观察预测误差指标的边际变化，从而定量验证各创新组件的有效性。各变体模型在宁德时代数据集上的实证结果如表 4.10 所示。

中国知网 https://www.cnki.net

表 4.10 消融实验结果比较——以宁德时代为例

Tab. 4.10 Comparison of Ablation Experiment Results of CATL

模型	核心改动	MSE	MAE	MAPE	R^2	提升幅度
Informer	原始 Informer	173.79	9.84	3.02%	0.929	R^2
LLM-Informer	引入情绪指标	129.41	8.81	2.84%	0.947	R^2 +1.94%
TCN-Informer	引入 TCN 结构	82.98	6.61	2.05%	0.966	R^2 +3.97%
LLM-TCN-Informer	双重改进	60.95	5.52	1.84%	0.977	R^2 +5.09%

通过对比 Informer 模型与 LLM-Informer 模型可以看出，在不改变模型结构的前提下，仅引入由 Qwen-3 提取的情绪指标，MSE 便从 173.79 下降至 129.41，降幅达 25.5%，R^2 提升了 1.94%。这有力地证明了社交媒体情绪中包含了量价交易数据所不具备的“外生增量信息”。

对比 Informer 模型与 TCN-Informer 模型可以发现，引入 TCN 并行架构后，MSE 由 173.79 大幅缩减至 82.98，降幅达 52.3%，R^2 显著提升至 0.966。虽然 Informer 模型擅长捕捉长周期趋势，但在剧烈波动的行情中，短期内的价格跳变往往包含关键的动量信息。TCN 通过因果卷积精细化地提取了这些局部微观特征，弥补了自注意力机制在微观颗粒度感知上的缺陷。

最终的完整的 LLM-TCN-Informer 模型并非两个改进模块的线性叠加，而是展现出了更强的协同效应。数据显示，LLM-TCN-Informer 模型在双重改进下，R^2 最终锁定在 0.977，相比基准提升了 5.09%，各项误差指标均为全场最低。

4.5.4 模型泛化能力验证

一个成熟的金融时间序列预测模型不仅应在单一标的上表现优异，更需具备跨资产类别的普适性以及抗多步预测误差累积的鲁棒性。本节设计了两个维度的扩展实验：一是将模型应用场景拓展至其他具有显著行业异质性的标的；二是将预测视野从单步延伸至多步，以考察模型在长周期预测中的稳定性。

(1)跨标的资产的横向泛化检验

为验证模型在不同波动特征与行业板块下的泛化能力，本文选取了宁德时代、立讯精密及美的集团三只代表性 A 股核心资产进行独立训练与测试。这些标的涵盖了从高波动科技成长股到稳健型低波蓝筹股的不同资产属性，能够全面考验模型对多源异构数据的特征提取效度。

中国知网 https://www.cnki.net

表 4.11 模型跨标的资产预测性能比较

Tab. 4.11 Performance Comparison across Cross-Target Assets

股票名称	波动率特征	MSE	MAE	MAPE	R^2
美的集团	稳健/低波	1.69	0.95	1.47%	0.985
宁德时代	激进/高波	60.95	5.52	1.84%	0.977
立讯精密	成长/中波	2.55	1.13	3.01%	0.953

实验结果如表 4.11 所示。数据显示，LLM-TCN-Informer 模型在三只截然不同的股票上均保持了优异的预测性能，拟合优度 R^2 均高于 0.95。



图 4.1 美的集团预测结果

Fig. 4.1 Prediction Results of Midea Group

如图 4.1 所示，针对波动性最为平稳的美的集团，模型取得了全场最优的拟合表现，R^2 高达 0.985，且 MAE 仅为 0.95。由于该标的属于稳健型蓝筹资产，其价格受长周期基本面与主流情绪主导，模型展现出了极强的绝对预测精度，即便在 2024 年后的价格中轴抬升阶段，预测曲线依然能够严丝合缝地贴合真实价格的微小波动。

中国知网 https://www.cnki.net



图 4.2　宁德时代预测结果

Fig. 4.2 Prediction Results of CATL

如图 4.2 所示，对于波动率最为激进的宁德时代，模型同样展现出了卓越的抗噪能力，其 R^2 达到了 0.977。拟合曲线显示，宁德时代价格包含了大量的脉冲式震荡与波段式上升。该标的在样本区间内经历了极为复杂的宽幅震荡，不仅包含了 2021 至 2022 年间大级别的波段式起伏，更在 2023 年中期及 2024、2025 年出现了多次极端的非连续性价格跳变。预测结果不仅在常规的平稳震荡期表现稳定，更完美捕捉到了每一次由重大事件或极端情绪驱动的价格突变。尽管受其高股价基数影响，MSE 绝对值相对偏高，但极高的拟合优度说明模型能够准确锁定其非线性的波动规律。



图 4.3　立讯精密预测结果

Fig. 4.3 Prediction Results of Luxshare Precision

中国知网　https://www.cnki.net

如图 4.3 所示，在立讯精密这一典型成长型中波资产的测试中，模型表现出极强的连贯性与稳健性，R^2 为 0.953。立讯精密的走势介于前述两者之间，在 2021 年至 2025 年期间历经了估值起伏，尤其是在多次深幅回撤与 V 型反弹中，传统模型极易出现“滞后误差”。然而，本文提出的完整模型在这些关键转折点表现得极为灵敏，红色虚线精准捕捉到了每一个趋势变动。

综上所述，LLM-TCN-Informer 模型展现出了一种“资产自适应”的优异特性：在面对低波资产时，侧重于对数值精度的极致追求；而在面对高波资产时，则侧重于对趋势动量与转折点的深度感知。

(2)跨时间步长的纵向稳定性分析

在实际投资中，除了次日走势，投资者往往更关注未来一周的趋势。为了验证 LLM-TCN-Informer 模型在长序列预测中的优势，本文测试了模型在未来 3 日和未来 5 日的预测表现，并与基准模型进行了对比。

表 4.12 不同预测步长下预测性能衰减比较——以宁德时代为例

Tab. 4.12 Comparison of Prediction Performance Degradation across Different Forecast Horizons of CATL

预测步长 H	模型	MSE	MAE	MAPE	R^2
H =1(1 天)	Informer	173.79	9.84	3.02	0.929
	TCN-Informer	82.98	6.61	2.05	0.966
	LLM-TCN-Informer	60.95	5.52	1.84	0.977
H =3(3 天)	Informer	373.48	16.59	5.73	0.848
	TCN-Informer	266.43	13.37	4.46	0.892
	LLM-TCN-Informer	165.00	9.16	3.09	0.934
H =5(5 天)	Informer	447.25	17.23	6.03	0.813
	TCN-Informer	303.22	14.48	4.64	0.877
	LLM-TCN-Informer	234.20	11.25	3.78	0.905

从实验数据来看，所有模型的预测精度均随步长的增加而出现不同程度的衰减。原始 Informer 模型在 H =5 时的拟合优度 R^2 由短步长的 0.929 大幅下滑至 0.813，对应的 MSE 也从 173.79 跃升至 447.25。相比之下，引入 TCN 模块后的模型在各步长下均实现了性能的结构性提升，其在步长为 5 的情境下的 R^2 依然维持在 0.877。这验证了 TCN 的因果卷积能够有效提取具备趋势惯性的局部特征，从而在一定程度上抑制了误差的逐级放大。

中国知网 https://www.cnki.net

最为显著的性能表现体现在融合了日度情绪指标的完整模型上。数据显示，LLM-TCN-Informer 在 H =5 时的 R^2 达到了 0.905，这一表现甚至优于原始 Informer 模型在 H =3 短步长下的表现。这一逆势领先的现象有力地实证了情绪指标作为价格领先信号的核心价值：在大规模社交媒体舆情中蕴含的群体预期具有更强的长程关联性，能够在量价信号随时间推移而效用递减时，为模型提供关键的中期趋势锚点。

综上所述，LLM-TCN-Informer 模型在多步长预测任务中展现出的稳定性。这种架构使得模型不仅能敏锐捕捉次日的微小脉冲，也能稳健预测下周的价格中枢，为真实金融交易场景中的择时决策提供了有价值的参考。

4.6　本章小结

本章系统验证了 LLM-TCN-Informer 模型在 A 股股价预测中的效度。在数据预处理阶段，引入大语言模型对高噪声社交媒体文本进行情感标注，实验证明其在处理金融复杂语义方面优势显著，标注精度与 F1-Score 均超 90%，远胜传统模型。通过均值比率插补与对数平滑加权算法，本文构建了内嵌投资者注意力机制的日度加权情绪指标，实现了文本特征与量价数据的时序对齐。

在股价预测对比实证中，LLM-TCN-Informer 模型在各项误差指标上均达最优，拟合优度显著领先于 ARIMA、LSTM 及原始 Informer。消融实验进一步证实，情绪指标提供了关键外部先行信号，而 TCN 并行双流架构强化了局部脉冲特征捕捉，两者协同有效修正了股价转折处的滞后效应。此外，通过跨预测步长与跨标的资产的实证检验，全方位评估了模型的鲁棒性。在多步预测窗口下，模型均保持稳健精度，有效抑制了长序列预测中的误差累积。针对宁德时代、立讯精密及美的集团的测试展现了其卓越的自适应能力，对不同波动特征的资产均实现了高水准趋势捕捉。

综合实证有力验证了本文提出方法的有效性：利用大模型赋能非结构化数据并结合改进时序模型进行特征解构，是实现高精度趋势预判并辅助金融决策的高效范式。

中国知网　https://www.cnki.net

5 结论与展望

本文立足于中国资本市场数字化转型与人工智能技术爆发的交叉前沿，围绕“如何利用大语言模型挖掘非结构化情绪价值”以及“如何改进深度学习模型以适应金融时序特征”这两个核心问题，开展了系统性的理论探索与实证研究。通过构建基于 Qwen-3 的日度情绪加权指标与 TCN-Informer 预测模型，本文在一系列对比实验中验证了多源信息融合策略的优越性。本章将对全文的主要研究结论进行系统梳理，总结本文在特征工程与模型架构层面的创新贡献，并探讨研究成果对量化投资实践与市场监管的启示。同时，本章也将客观审视研究过程中存在的局限性，如数据维度的扩展空间、细粒度情绪的挖掘潜力等，并据此对未来的研究方向提出展望，以期为后续相关领域的深入探索提供参考。

5.1 结论

本文的主要结论集中在金融舆情量化特征工程、时序预测模型架构改良以及复杂市场环境下的模型稳健性验证三个方面。

首先，在金融舆情特征挖掘方面，研究证实了大语言模型在解析复杂非结构化数据中的核心价值。传统的自然语言处理工具受制于静态词向量，在面对 A 股市场特有的反讽及专业黑话时，分类准确率均未能突破 70%的瓶颈。而以 Qwen-3 为代表的大语言模型凭借深层逻辑推理能力，在情感判别任务中的 Accuracy 与 F1-Score 分别高达 90.46%和 90.47%，较传统模型实现了逾 20 个百分点的性能跃升。此外，本文结合投资者注意力理论构建的日度加权情绪指标，通过均值比率插补与对数平滑算法，有效修正了社交媒体长尾分布的偏误，为预测模型提供了极具价值的外部先行信号。

其次，在模型架构设计方面，本文提出的大模型情绪增强的 TCN-Informer 模型展现了显著的技术优势。实证结果表明，单纯依赖历史量价数据的预测模型在面对波动剧烈的金融市场时普遍存在“预测滞后”与“误差累积”难题。TCN-Informer 模型通过 TCN 模块的因果卷积捕捉局部情绪脉冲，利用 Informer 的概率稀疏自注意力机制提取全局趋势特征，实现了对市场短期波震与长程趋势的同时刻画。在宁德时代的单步预测对比实验中，传统计量模型 ARIMA 与单一深度学习模型 LSTM 均表现出明显的拟合瓶颈。而本文提出的完整模型将拟合优度显著提升至 0.977。消融实验定量地证明了各组件的边际贡献：情绪因子的引入显著提升了模型在行情转折点处的预判能力，而 TCN 分支则有效弥补了自注意力机制在微观特征捕捉上的颗粒度缺陷。

最后，本文通过多场景下的鲁棒性检验，初步验证了模型的泛化潜能与应用价值。在跨预测步长的对比中，大模型情绪增强的 TCN-Informer 模型在未来 5 日的股价预测窗口下依然能保持 0.9 以上的拟合水准，其表现甚至优于基准模型在单日短步长下的精

中国知网 https://www.cnki.net

度。这说明情绪指标提供的外部增量信息极大缓解了中长线价格走势预测中的不确定性。同时，在针对不同波动特征资产的泛化性测试中，模型对真实股价曲线均展现出了卓越的自适应拟合能力，拟合优度全面高于 0.95。这一系列证据共同支撑了本文的核心结论：利用前沿大语言模型挖掘舆情中的情绪前瞻信号并配合 TCN-Informer 模型，能够精准捕捉 A 股市场中由基本面与情绪面共同驱动的股票价格非线性波动轨迹。该模型不仅有效解决了传统方法在股价转折点预测上的滞后难题，更为实际的股票多空择时交易与中短期投资决策提供了精度极高、切实可靠的价格预测锚点。

5.2 展望

尽管本文在理论构建与实证验证上取得了一定成果，但受限于客观条件与时间精力，仍有诸多方向值得未来进一步深化与拓展。

在数据源的广度与深度方面，本文目前主要侧重于股评文本与历史量价数据的融合。然而，现代金融市场的波动受多维信息的共同驱动。未来研究可以尝试引入多模态异构数据，例如整合宏观经济指标、企业财务报表原文、高频实时交易流数据，乃至通过多模态大模型解析财经新闻中的视频与图像信息。通过构建全方位的“多源信息感知矩阵”，可以更全面地捕捉市场情绪的传导路径。

在模型算法的精细化演进层面，未来的研究重点可聚焦于垂直领域大模型的深度微调。虽然通用大模型在语义理解上表现优异，但针对金融领域特定逻辑的推理深度仍有提升空间。利用海量金融专业语料对模型进行指令微调或引入人类反馈强化学习，有望生成更具专业深度的情绪标注。同时，通过构建端到端的“预测-决策”闭环，不仅能输出预测数值，更能根据预测结果自动优化资产配置与止损策略，从而使研究成果更具实战化价值。

最后，在应用场景的横向拓展上，本框架的迁移能力有待在全球更多市场中得到验证。当前验证仅覆盖了深市 3 只行业龙头，未来可以将该模型应用于香港恒生指数、美股标普 500 指数等具备不同交易机制、涨跌幅限制及投资者结构的交易市场，通过跨国界对比研究，探讨不同文化语境与交易制度下投资者情绪对价格形成机制的影响差异。同时，结合真实的量化回测框架，深入考量交易手续费、滑点冲击成本及市场流动性约束，将学术模型转化为具有竞争力的实盘交易模型。

中国知网 https://www.cnki.net

参 考 文 献

[1] 张宗新,王海亮.投资者情绪、主观信念调整与市场波动[J].金融研究,2013,(04):142-155.

[2] 文凤华,肖金利,黄创霞,等.投资者情绪特征对股票价格行为的影响研究[J].管理科学学报,2014,17(03):60-69.

[3] 部慧,解峥,李佳鸿,等.基于股评的投资者情绪对股票市场的影响[J].管理科学学报,2018,21(04):86-101.

[4] 戴德宝,兰玉森,范体军,等.基于文本挖掘和机器学习的股指预测与决策研究[J].中国软科学,2019,(04):166-175.

[5] 尹海员,王晓晓.投资者情绪是否会影响股票定价效率?——来自股票社区的文本证据[J].北京联合大学学报(人文社会科学版),2024,22(03):96-111.

[6] 黄创霞,温石刚,杨鑫,等.个体投资者情绪与股票价格行为的互动关系研究[J].中国管理科学,2020,28(03):191-200.

[7] 姜富伟,孟令超,唐国豪.媒体文本情绪与股票回报预测[J].经济学(季刊),2021,21(04):1323-1344.

[8] 谢世清,唐思勋.投资者情绪与宏观经济波动对股票市场收益率的影响[J].宏观经济研究,2021,(02):99-107.

[9] Da Z ,Engelberg J ,Gao P .The Sum of All FEARS Investor Sentiment and Asset Prices[J].The Review of Financial Studies,2015,28(1):1-32.

[10] Huang D ,Jiang F ,Tu J ,Zhou G .Investor Sentiment Aligned: A Powerful Predictor of Stock Returns[J].The Review of Financial Studies,2015,28(3):791-837.

[11] Sun L ,Najand M ,Shen J .Stock return predictability and investor sentiment: A high-frequency perspective[J].Journal of Banking and Finance,2016,73:147-164.

[12] Renault T .Intraday online investor sentiment and return patterns in the U.S. stock market[J].Journal of Banking and Finance,2017,84:25-40.

[13] L. S H ,Ranjan N S .News vs. Sentiment: Predicting Stock Returns from NewsStories[J].Financial Analysts Journal,2017,73(3):67-83.

[14] Mu G, Gao N, Wang Y, et al. A stock price prediction model based on investor sentiment and optimized deep learning[J]. Ieee Access, 2023, 11: 51353-51367.

[15] Li S, Sun Y, Lin Y, et al. CausalStock: Deep End-to-end Causal Discovery for News-driven Multi-stock Movement Prediction[J]. Advances in Neural Information Processing Systems, 2024, 37:47432-47454.

[16] Talazadeh S, Peraković D. SARF: Stock Market Prediction with Sentiment-Augmented Ra

中国知网 https://www.cnki.net

ndom Forest[C]//International Conference on Future Access Enablers of Ubiquitous and Intelligent I nfrastructures. Cham: Springer Nature Switzerland, 2024: 54-64.

[17] 胡昌生,池阳春.投资者情绪、资产估值与股票市场波动[J].金融研究,2013,(10):181-193.

[18] 陈健,曾世强.投资者情绪对股票价格波动的影响研究[J].价格理论与实践,2018,(07):99-102.

[19] 唐志武,刘欣.投资者情绪与沪深 300 股指期货定价偏差关系研究[J].价格理论与实践,2020,(01):111-114.

[20] 姜尚伟,金秀.空间交互视角下投资者情绪对股价的影响[J].东北大学学报(自然科学版),2020,41(01):143-147.

[21] 张博,扈文秀,杨熙安.投资者情绪生成机理的研究[J].中国管理科学,2021,29(01):185-195.

[22] 朱莉,刘向丽,杨晓光.投资者情绪影响股指期现货市场的价格动态关系吗?[J].中国管理科学,2022,30(04):52-62.

[23] Eli B ,Lucile F ,S. P M .Can Twitter Help Predict Firm-Level Earnings and Stock Returns?[J].The Accounting Review,2018,93(3):25-57.

[24] 童元松.投资者情绪、股市流动性与波动性的关系研究[J].技术经济与管理研究,2021,(02):76-82.

[25] 胡昌生,夏郭效.投资者情绪累积效应与股票价格波动[J].统计与决策,2023,39(05):152-157.

[26] Audrino F ,Sigrist F ,Ballinari D .The impact of sentiment and attention measures on stock market volatility[J].International Journal of Forecasting,2020,36(2):334-357.

[27] 尹海员,吴兴颖.投资者高频情绪对股票日内收益率的预测作用[J].中国工业经济,2019,(08):80-98.

[28] 赵进文,王倩.上证 180 指数的 GARCH 族模型仿真研究——对上证 300 指数的间接实证建模分析[J].财经问题研究,2008,(03):47-54.

[29] 辛治运,顾明.基于最小二乘支持向量机的复杂金融时间序列预测[J].清华大学学报(自然科学版),2008,(07):1147-1149.

[30] 于志军,杨善林.基于误差校正的 GARCH 股票价格预测模型[J].中国管理科学,2013,21(S1):341-345.

[31] 吴玉霞,温欣.基于 ARIMA 模型的短期股票价格预测[J].统计与决策,2016,(23):83-86.

[32] Zhong X ,Enke D .Forecasting daily stock market return using dimensionality reduction[J].Expert Systems With Applications,2017,67:126-139.

[33] Fischer T ,Krauss C .Deep learning with long short-term memory networks for financial market predictions[J].European Journal of Operational Research,2018,270(2):654-669.

[34] 宋刚,张云峰,包芳勋,等.基于粒子群优化 LSTM 的股票预测模型[J].北京航空航天大学学报,2019,45(12):2533-2542.

中国知网 https://www.cnki.net

[35] Vijh M ,Chandola D ,Tikkiwal A V , et al.Stock Closing Price Prediction using Machine Learning Techniques[J].Procedia Computer Science,2020,167(C):599-606.

[36] 闫洪举.基于深度学习的金融时间序列数据集成预测[J].统计与信息论坛,2020,35(04):33-41.

[37] 贺毅岳,李萍,韩进博.基于 CEEMDAN-LSTM 的股票市场指数预测建模研究[J].统计与信息论坛,2020,35(06):34-45.

[38] Moghar A ,Hamiche M .Stock Market Prediction Using LSTM Recurrent Neural Network[J].Procedia Computer Science,2020,170(C):1168-1173.

[39] 任君,王建华,王传美,等.基于正则化 LSTM 模型的股票指数预测[J].计算机应用与软件,2018,35(04):44-48.

[40] Cao J ,Li Z ,Li J .Financial time series forecasting model based on CEEMDAN and LSTM[J].Physica A: Statistical Mechanics and its Applications,2018,519:127-139.

[41] 曹超凡,罗泽南,谢佳鑫,等.MDT-CNN-LSTM 模型的股价预测研究[J].计算机工程与应用,2022,58(05):280-286.

[42] 陈炜,徐慧琳,汪寿阳,等.基于误差修正与分解的区间值股价时间序列预测研究[J].系统工程理论与实践,2023,43(02):383-397.

[43] Hoseinzade E ,Haratizadeh S .CNNpred: CNN-based stock market prediction using a diverse set of variables[J].Expert Systems With Applications,2019,129:273-285.

[44] Henrique M B ,Sobreiro A V ,Kimura H .Literature Review: Machine Learning Techniques Applied to Financial Market Prediction[J].Expert Systems With Applications,2019,124:226-251.

[45] 任佳屹,王爱银.融合因果注意力 Transformer 模型的股价预测研究[J].计算机工程与应用,2023,59(13):325-334.

[46] 陈东洋,毛力.融合增量学习与 Transformer 模型的股价预测研究[J].计算机科学与探索,2024,18(07):1889-1899.

[47] Li J ,Zhou L ,Li X , et al.Multivariable financial time series forecasting based on phase space reconstruction compensation[J].Neural Computing and Applications,2024,37(3):1-14.

[48] 宋凌云,马卓源,李战怀,等.面向金融风险预测的时序图神经网络综述[J].软件学报,2024,35(08):3897-3922.

[49] 尹海员,南早红.基于深度学习的投资者情绪挖掘及其对股价崩盘风险的影响[J].中央财经大学学报,2024,(03):36-56.

[50] 常峰源.投资者情绪对股票流动性同步性的影响研究[J].价格理论与实践,2022,(09):146-149.

中国知网 https://www.cnki.net



中国知网 https://www.cnki.net