江西财经大学
JIANGXI UNIVERSITY OF FINANCE AND ECONOMICS

学校代码 _____
密　　级 _____
中图分类号 _____
UDC _____

硕士学位论文
MASTER DISSERTATION

论文题目（中文）　基于大语言模型文本情绪的企业财务困境预警研究

论文题目（英文）　Financial Distress Prediction of Firms Based on Textual Sentiment from Large Language Models

作　　者　余安帮　　导　　师　冯凌秉
申请学位　硕　士　　学院名称　金融学院
学科专业　金　融　　研究方向　公司金融

二〇二六 年 六 月

中国知网 https://www.cnki.net

摘要

当今资本市场环境日趋复杂，及时识别企业潜在财务困境风险，对于监管部门、投资者及企业管理层均具有重要意义。传统财务困境预警研究主要依赖财务报表等结构化信息，但受信息披露滞后性和风险信号隐蔽性的影响，模型预测能力仍有较大提升空间。基于此，本文在传统财务指标基础上，引入新闻文本情绪信息，构建融合结构化财务特征与非结构化文本信息的企业财务困境预警框架，系统考察不同情绪指标构建方法及不同预测模型在财务困境识别中的效果差异。

本文以我国 2014—2024 年上市公司为研究样本，选取企业 t-2 年的财务指标与同期新闻文本作为特征变量，以 t 年企业是否被实施特别处理（ST）作为财务困境代理变量。在情绪指标构建方面，分别采用词袋模型（BOW）、预训练语言模型（Fin-Bert、DeepSeek、Qwen）以及微调后的 Qwen 模型（Qwen-SFT）对新闻文本进行情绪识别，并区分新闻标题与新闻正文两类文本来源；在预测模型方面，比较逻辑回归、支持向量机、随机森林、XGBoost 和神经网络五种方法，并以 AUC、准确率、召回率和 F1 值作为综合评价指标。

研究结果表明，仅采用财务特征时，模型已具备一定的财务困境预测能力，其中最优模型 AUC 值为 0.822，F1 值为 0.745；在此基础上引入文本情绪指标后，模型整体预测性能均得到提升，说明新闻文本中蕴含着有助于识别企业潜在风险的重要增量信息。从情绪指标构建方法看，深度语义模型整体优于传统词袋模型。引入 BOW 标题情绪指标后，最优模型 AUC 值提升至 0.835；基于 Fin-Bert 构建的正文情绪指标进一步将最优模型 AUC 值提升至 0.842。相比之下，以 DeepSeek 和 Qwen-SFT 为代表的大语言模型表现更优，其中基于 DeepSeek 情绪指标的最优模型 AUC 值达到 0.883、F1 值达到 0.795，基于 Qwen-SFT 情绪指标的最优模型 AUC 值达到 0.888、F1 值达到 0.795，均显著优于仅使用财务特征的基准模型。进一步比较发现，经领域微调的 Qwen-SFT 在本文研究设定下取得最优表现，表明在专业财务场景中，模型的领域适配能力较单纯扩大模型规模更为关键。

进一步分析表明，本文结论具有较好的稳健性。在全样本并结合 SMOTE 处理的不平衡样本检验中，文本情绪指标仍能显著提升财务困境预警效果；在不同提示词策略下，基于 DeepSeek 构建的文本情绪指标在得分分布和模型表现上均保持较稳定的方向一致性，说明研究结论并不依赖于特定样本设定或单一提示词形式。此外，基于最优 XGBoost

中国知网 https://www.cnki.net

模型的 SHAP 与 LIME 可解释性分析表明，文本情绪指标在模型决策中具有较高重要性，并与盈利能力、偿债能力、现金流等关键财务指标共同影响预测结果。

综上，本文证实了基于大语言模型构建的新闻文本情绪指标在企业财务困境预警中的有效性，为非财务信息在企业风险识别中的应用提供了新的经验证据，也为监管预警、投资决策和企业风险管理提供了有益参考。

关键词：大语言模型；财务困境预警；新闻文本；机器学习；可解释性分析

中国知网 https://www.cnki.net

Abstract

In today's increasingly complex capital market environment, the timely identification of potential corporate financial distress is of great significance for regulators, investors, and corporate managers. Traditional financial distress prediction mainly relies on structured information such as financial statements. However, due to the lag of information disclosure and the hidden nature of risk signals, the predictive performance of existing models still has considerable room for improvement. Against this background, this study incorporates news text sentiment into the traditional financial indicator system and constructs a financial distress early-warning framework that integrates structured financial features with unstructured textual information, so as to systematically examine the differences in predictive performance across sentiment construction methods and forecasting models.

Using Chinese listed companies from 2014 to 2024 as the research sample, this study selects financial indicators in year t-2 and contemporaneous news texts as feature variables, and uses whether a firm is designated as "Special Treatment" (ST) in year t as a proxy for financial distress. In terms of sentiment construction, the study applies the Bag-of-Words model (BOW), pre-trained language models (BERT, DeepSeek, and Qwen), and a fine-tuned Qwen model (Qwen-SFT) to identify sentiment from news texts, while also distinguishing between sentiment measures based on news headlines and news bodies. For prediction models, five methods are compared, including Logistic Regressionion, Support Vector Machine, Random Forest, XGBoost, and Neural Network. Model performance is evaluated using AUC, accuracy, recall, and F1-score.

The empirical results show that models based only on financial features already possess a certain level of predictive ability, with the best baseline model achieving an AUC of 0.822 and an F1-score of 0.745. After incorporating text sentiment indicators, the overall predictive performance improves consistently, suggesting that news texts contain important incremental information for identifying potential corporate risks. In terms of sentiment construction methods, deep semantic models generally outperform the traditional Bag-of-Words approach. Specifically, after introducing the BOW-based headline sentiment indicator, the best model's AUC increases to 0.835, while the BERT-based body sentiment indicator further raises the best AUC to 0.842. By comparison, large language models represented by DeepSeek and

中国知网 https://www.cnki.net

Qwen-SFT perform even better. The best model based on the DeepSeek sentiment indicator achieves an AUC of 0.883 and an F1-score of 0.795, while the best model based on the Qwen-SFT sentiment indicator achieves an AUC of 0.888 and an F1-score of 0.795, both significantly outperforming the baseline model using only financial features. Further comparison shows that the domain-adapted Qwen-SFT achieves the best performance under the research setting of this study, indicating that in professional financial scenarios, domain adaptation is more important than simply increasing model scale.

Additional analyses further confirm the robustness of the findings. In the full-sample test with SMOTE-based treatment for class imbalance, text sentiment indicators still significantly improve financial distress prediction. Under different prompt strategies, the text sentiment indicators constructed by DeepSeek remain broadly consistent in both score distributions and model performance, indicating that the main conclusions do not depend on a specific sample setting or a single prompt design. In addition, SHAP and LIME analyses based on the optimal XGBoost model show that text sentiment indicators play an important role in model decision-making, together with key financial variables such as profitability, solvency, and cash flow.

In conclusion, this study confirms the effectiveness of news text sentiment indicators constructed by large language models in corporate financial distress prediction. It provides new empirical evidence for the application of non-financial information in corporate risk identification and offers useful implications for regulatory early warning, investment decision-making, and corporate risk management.

Key Words: Large Language Models; Financial Distress Prediction; News Text; Machine Learning; Explainable AI

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 研究背景与意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....2
1.2 研究内容与研究方法.....2
1.2.1 研究内容.....3
1.2.2 研究方法.....3
1.3 创新与不足之处.....6
1.3.1 创新.....6
1.3.2 不足之处.....6
2 文献综述.....7
2.1 财务困境预警理论与模型.....7
2.2 公司新闻、文本情绪与企业风险的相关研究.....9
2.3 自然语言处理与大语言模型在金融领域的应用.....9
2.4 机器学习与解释性机器学习在财务困境预测中的应用.....11
2.5 文献评述.....11
3 理论基础与技术方法.....14
3.1 文本信号在财务困境预警的相关理论.....14
3.1.1 信号理论.....14
3.1.2 行为金融理论.....14
3.1.3 信息不对称理论.....15
3.2 词袋模型.....16
3.2.1 基本原理.....16
3.2.2 逆文档频率.....17
3.3 大语言模型相关理论.....17
3.3.1 大模型理论基础.....17
3.3.2 提示词工程.....18
3.3.3 大语言模型微调.....19
4 研究设计.....21
4.1 样本选择和数据来源.....21
4.2 因变量指标选取.....21
4.3 财务指标的选取.....21
4.3.1 盈利能力.....21
4.3.2 偿债能力.....22

中国知网　https://www.cnki.net

4.3.3 营运能力.....22
4.3.4 现金流量.....23
4.3.5 成长能力.....23
4.4 文本情绪指标的构建.....24
4.4.1 基于 BOW 的文本情绪指标构建.....24
4.4.2 基于 Fin-Bert 模型的文本情绪指标构建.....26
4.4.3 基于 DeepSeek 的文本情绪指标构建.....28
4.4.4 基于微调 Qwen 模型的文本情绪指标构建.....30
4.5 财务困境预警模型的选择.....32
4.5.1 逻辑回归模型.....32
4.5.2 支持向量机.....32
4.5.3 随机森林.....33
4.5.4 XGBoost.....34
4.5.5 神经网络.....34
4.6 评估指标.....35
4.6.1 二分类混淆矩阵定义.....35
4.6.2 准确率.....35
4.6.3 召回率.....36
4.6.4 F1 分数.....36
4.6.5 AUC.....37
5 实证结果与分析.....38
5.1 描述性统计.....38
5.2 基准模型的选择.....40
5.3 模型预测结果分析.....40
5.3.1 基于仅财务特征的预测结果分析.....40
5.3.2 基于 BOW 情绪指标的预测结果分析.....42
5.3.3 基于 Fin-Bert 情绪指标的预测结果分析.....44
5.3.4 基于 Qwen 情绪指标的预测结果分析.....45
5.3.5 基于 DeepSeek 情绪指标的预测结果分析.....47
5.3.6 基于微调的 Qwen 情绪指标的预测结果分析.....49
5.4 不同情绪指标构建方法的综合比较与讨论.....50
5.5 机器学习可解释性分析.....51
5.5.1 基于 SHAP 的可解释性分析.....52
5.5.2 基于 LIME 的可解释性分析.....54
6 进一步分析.....57
6.1 基于全样本与不平衡处理技术的稳健性检验.....57
6.2 不同提示词策略下文本情绪指标的稳健性分析.....60
6.2.1 提示词策略设计.....60

中国知网 https://www.cnki.net

6.2.2 不同提示词策略下情绪得分分布比较 62
6.2.3 不同提示词策略下的预警效果比较 63
7 结论及政策建议 66
7.1 结论.....66
7.2 政策建议.....67
参考文献.....69

中国知网 https://www.cnki.net

图目录

图 1.1 技术路线图 5
图 5.1 基于仅财务特征的 ROC 曲线 42
图 5.2 基于 BOW 模型构建的情绪指标 ROC 曲线 43
图 5.3 基于 BERT 模型构建的情绪指标 ROC 曲线 45
图 5.4 基于 Qwen 模型构建的情绪指标 ROC 曲线 47
图 5.5 基于 DeepSeek 模型构建的情绪指标 ROC 曲线 48
图 5.6 基于 Qwen-SFT 模型构建的情绪指标 ROC 曲线 50
图 5.7 SHAP 特征重要性 52
图 5.8 SHAP 瀑布图 54
图 5.9 LIME 特征重要性 56
图 5.10 LIME 局部解释 56
图 6.1 全样本的进财务特征 ROC 曲线 58
图 6.2 全样本下 DeepSeek 构建的指标 ROC 曲线 59
图 6.3 全样本下 Qwen-SFT 构建的指标 ROC 曲线 59
图 6.4 不同提示词策略下情绪得分的核密度分布图 62

中国知网 https://www.cnki.net

表目录

表 4.1 盈利能力指标 22
表 4.2 偿债能力指标 22
表 4.3 营运能力指标 23
表 4.4 现金流量指标 23
表 4.5 成长能力指标 24
表 5.1 描述性统计 38
表 5.2 仅基于财务特征的预测结果 41
表 5.3 基于 BOW 情绪指标的预测结果 43
表 5.4 基于 Fin-Bert 情绪指标的预测结果 44
表 5.5 基于 Qwen 情绪指标的预测结果 46
表 5.6 基于 DeepSeek 情绪指标的预测结果 48
表 5.7 基于 Qwen-SFT 情绪指标的预测结果 50
表 6.1 基于全样本情绪指标的预测结果 58
表 6.2 不同提示词策略下财务困境预警模型结果比较 63

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景与意义

1.1.1 研究背景

随着我国资本市场的不断发展，上市公司数量持续增长，企业经营环境和市场竞争格局日趋复杂，财务风险在企业经营过程中的隐蔽性和传导性不断增强。企业一旦陷入财务困境，不仅会对自身持续经营能力造成严重影响，还可能引发投资者信心下降、金融资源配置效率降低，甚至对资本市场稳定和金融体系安全产生不利冲击。因此，如何对企业财务困境进行有效、及时的识别和预警，始终是公司金融和资本市场研究中的重要议题。

现有财务困境预警研究大多基于财务报表信息构建预测模型，利用企业盈利能力、偿债能力、营运能力和现金流状况等指标对企业未来风险进行判断。这类方法在理论和实践中具有较为坚实的基础，但也面临一定局限性。一方面，财务报表信息具有明显的事后性，难以及时反映企业经营环境的变化；另一方面，在信息披露滞后或财务数据受到盈余管理影响的情况下，单纯依赖财务指标可能低估企业潜在风险，影响预警模型的预测效果。进一步来看，现有财务困境预警模型主要存在以下不足。第一，传统模型高度依赖财务报表数据，而财务报表具有固定披露周期和明显事后性，难以及时反映企业经营环境、融资条件和市场预期的快速变化。第二，财务指标容易受到会计政策选择、盈余管理和信息披露质量差异的影响，在企业潜在风险尚未充分显性化时，模型可能难以及时捕捉隐性财务压力。第三，部分传统统计模型通常建立在线性关系或静态截面假设基础之上，对财务指标之间的非线性关系、风险传导过程以及突发事件冲击的刻画能力相对有限。第四，既有模型对新闻报道、媒体舆情、市场评价等非结构化软信息利用不足，难以充分识别企业声誉风险、融资压力和市场信心变化等前瞻性信号。因此，在传统财务指标基础上引入新闻文本情绪信息，并借助大语言模型提升文本语义识别能力，有助于弥补传统预警模型在时效性、信息维度和风险识别深度方面的不足。

在信息技术快速发展的背景下，新闻报道、媒体舆情等非结构化文本信息已成为资本市场中重要的信息载体。企业经营状况、重大事件及市场预期往往会通过新闻文本形式持续反映出来，其中所蕴含的情绪和风险信号可能早于财务指标变化。如何有效挖掘和利用新闻文本中的情绪信息，成为提升财务困境预警准确性的重要方向。

中国知网 https://www.cnki.net

与此同时，机器学习和自然语言处理技术的迅速发展，为非结构化文本信息的处理和应用提供了新的技术手段。尤其是预训练语言模型在语义理解和情绪识别方面展现出显著优势，为从新闻文本中提取高质量情绪指标提供了可能。然而，不同文本建模方法在专业财务场景中的适用性、预测效果及可解释性仍有待系统检验，这也构成了本文研究的重要现实背景。

1.1.2 研究意义

基于上述背景，本文从理论和实践两个层面对财务困境预警问题展开研究，具有以下几方面的重要意义。

从理论意义上看，本文的研究主要体现在三个方面。第一，本文将新闻文本情绪信息引入企业财务困境预警框架，拓展了传统财务困境预警研究主要依赖结构化财务数据的研究视角，为非结构化信息参与企业风险识别提供了新的经验证据。第二，本文系统比较词袋模型、预训练语言模型、通用大语言模型以及领域微调模型在金融文本情绪识别中的表现，有助于揭示不同文本建模方法在专业财务场景中的适用差异，丰富金融文本分析与财务风险预警交叉研究。第三，本文结合 SHAP 和 LIME 等可解释性方法，对文本情绪指标在模型预测中的作用进行解释，有助于从机制层面理解新闻文本情绪为何能够提升财务困境识别效果，推动财务预警研究由单纯追求预测精度向兼顾预测效果与经济解释转变。

从实践意义上看，本文的研究可为监管部门、投资者、企业管理层和中介机构提供参考。对于监管部门而言，新闻文本情绪指标有助于在财务报表正式披露前识别企业潜在风险，提升风险监测的及时性和前瞻性。对于投资者而言，将文本情绪信息纳入风险判断，有助于更加全面地评估上市公司经营风险和投资风险。对于企业管理层而言，外部新闻情绪变化能够反映市场对企业经营状况、融资能力和声誉风险的评价，有助于企业及时识别风险信号并优化信息披露和风险管理。对于金融机构和中介机构而言，本文发现经领域微调的小规模模型能够取得较好预测效果，说明在成本和算力资源受限的现实场景中，领域适配模型具有较强应用价值。

此外，本文发现经领域微调的小规模模型在专业财务任务中能够取得与通用大模型相近的预测效果，这对于在资源受限或对计算成本较为敏感的实际应用场景具有重要启示意义。相关结论可为监管实践、企业风险管理以及投资决策中智能分析工具的选择和优化提供有益参考。

1.2 研究内容与研究方法

中国知网 https://www.cnki.net

1.2.1 研究内容

围绕财务困境预警这一核心问题，本文在传统财务指标的基础上引入新闻文本情绪信息，系统研究不同文本情绪建模方法与机器学习模型在财务困境预测中的应用效果。具体而言，本文的研究内容主要包括以下几个方面。

第一，构建以财务指标为基础的财务困境预警基准模型。本文选取反映企业盈利能力、偿债能力、营运能力、现金流状况及成长性的多项财务指标，构建仅基于结构化财务数据的预测模型，评估传统财务特征在财务困境识别中的基础预测能力，并为后续引入文本情绪指标提供对照基准。

第二，基于新闻文本构建多种情绪指标，并检验其增量预测价值。本文以企业相关新闻文本为数据来源，分别采用词袋模型以及多种预训练语言模型构建新闻情绪指标，并将其与财务指标相结合，系统比较不同情绪指标在财务困境预警中的预测效果，分析新闻文本情绪信息是否能够为财务困境识别提供超越传统财务指标的补充信息。

第三，比较不同情绪指标构建方法的相对有效性。针对不同文本建模方法，本文进一步比较基于传统词频统计方法与基于深度语义表示方法构建的情绪指标在预测性能上的差异，并重点考察通用预训练语言模型与经领域微调模型在专业财务场景中的适用性，分析模型规模与领域适配性对预测效果的影响。

第四，引入多种预测模型，检验研究结论的稳健性。本文在预测阶段同时采用传统统计模型与机器学习模型，包括逻辑回归、支持向量机、随机森林、XGBoost 和神经网络模型，从不同建模框架出发，对财务困境预测效果进行比较分析，以检验文本情绪指标在不同模型设定下的稳定性和一致性。

第五，对预测模型进行可解释性分析。针对预测性能表现最优的模型，本文进一步采用 SHAP 和 LIME 两种可解释性方法，从全局和个体层面揭示模型的决策机制，分析文本情绪指标和财务指标在模型预测中的作用路径，从而增强模型预测结果的透明度和可信度。

本文第一章为绪论部分，探讨论文的背景与意义、研究内容和方法以及创出与不足；第二章综述相关文献，识别研究缺口；第三章分析相关理论；第四章详述研究设计，包括样本选取、数据来源、变量度量、模型设定及大语言模型指标构建；第五章呈现实证回归结果和机器学习可解性分析；第六章探讨全样本及不同提示此策略下的模型表现；第七章总结主要发现，并给出政策建议。

1.2.2 研究方法

为实现上述研究目标，本文主要采用以下研究方法。

中国知网 https://www.cnki.net

第一，文献分析法。通过系统梳理国内外关于财务困境预警、文本情绪分析及机器学习方法的相关文献，明确现有研究的主要结论和不足，为本文的研究设计和方法选择提供理论依据。

第二，文本挖掘与自然语言处理方法。本文利用自然语言处理技术对新闻文本进行预处理和特征提取，分别采用词袋模型和预训练语言模型构建文本情绪指标，并通过模型微调提高情绪指标对财务语境的适配性。

第三，机器学习建模方法。在预测阶段，本文构建多种分类模型，对企业是否陷入财务困境进行预测，并通过多项评价指标对模型性能进行比较分析，从而识别不同模型和特征组合的相对优势。

第四，可解释性分析方法。本文引入 SHAP 和 LIME 方法，对机器学习模型的预测结果进行解释，从全局和局部层面揭示模型决策依据，为复杂模型在财务风险预警中的应用提供可解释支持。

技术路线图如图 1.1 所示。

中国知网 https://www.cnki.net

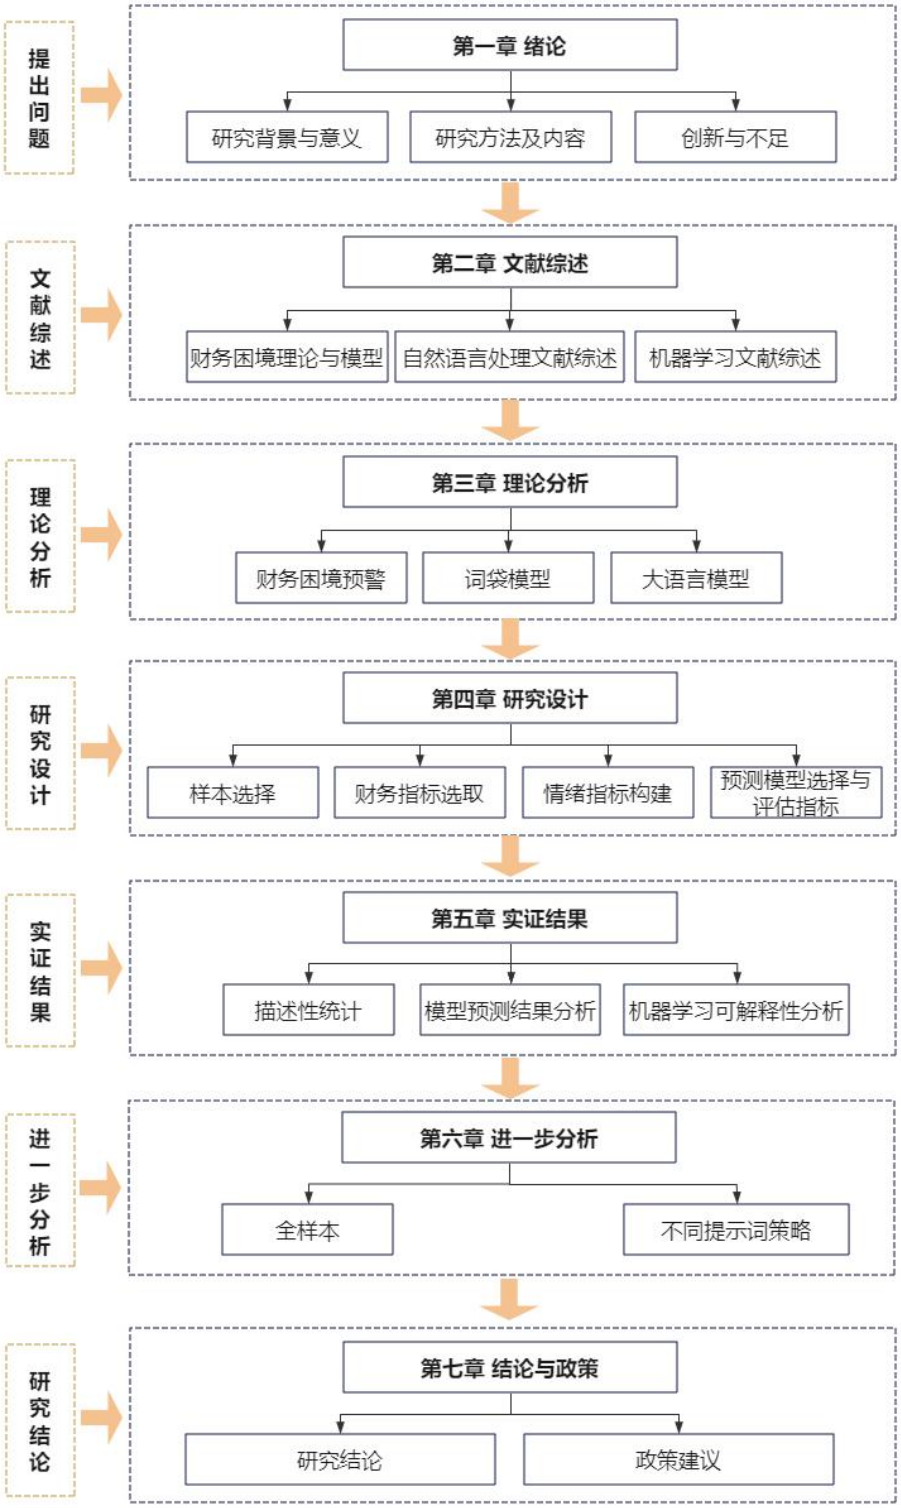


图 1.1 技术路线图

Fig. 1.1 Technical Roadmap

中国知网 https://www.cnki.net

1.3 创新与不足之处

1.3.1 创新

第一，将新闻文本情绪指标系统引入财务困境预警研究。在传统财务指标基础上，本文利用企业新闻文本构建情绪变量，拓展了财务困境预警的信息来源，验证了非结构化文本信息在企业风险识别中的有效性。

第二，对不同情绪指标构建方法进行了系统比较，强调领域微调模型的应用价值。本文在统一实验框架下比较了词袋模型、预训练语言模型及微调模型的预测效果。结果表明，经专业语境微调的小规模模型在预测性能上可达到与通用大模型相近的水平，为金融文本分析中的模型选择提供了经验证据。

第三，引入可解释性分析方法提升模型透明度。本文结合 SHAP 与 LIME 方法，从整体和个体层面解释模型预测结果，揭示了文本情绪变量与核心财务指标在财务困境预警中的作用方向与相对重要性，增强了模型结论的可解释性和可信度。

1.3.2 不足之处

第一，文本数据来源相对单一。本文主要基于新闻文本构建情绪指标，未涵盖社交媒体等其他文本信息，未来研究可进一步引入多源文本数据进行扩展。

第二，财务困境的判定标准具有一定局限性。本文以 ST 企业作为财务困境的代理变量，未来可结合其他困境识别方法对研究结论进行稳健性检验。

第三，模型分析仍以静态预测为主。后续研究可在此基础上引入动态预测或滚动窗口方法，以进一步提升模型的现实适用性。

中国知网 https://www.cnki.net

2 文献综述

2.1 财务困境预警理论与模型

围绕财务困境预警的研究，首先需要明确财务困境的概念边界与事件口径。早期研究中，财务危机、财务困境和破产等概念有时被混用，导致样本选择、模型设定和研究结论之间存在一定偏差。吴星泽等（2007）指出，财务困境研究应重视概念界定、样本口径与理论内涵之间的一致性，否则会削弱不同研究结论的可比性和外推性。吕长江等（2005）进一步从困境—破产的动态过程出发指出，财务困境具有阶段性、累积性和一定可逆性，而破产通常更接近企业经营失败的终局状态。因此，财务困境预警研究不仅要关注企业是否已经发生风险事件，更应关注风险信号在困境形成前的提前识别。基于这一认识，国内早期研究主要以财务恶化或特别处理等事件作为困境代理变量，陈静（1999）、吴世农等（2001）等围绕上市公司财务恶化开展实证分析，为后续财务困境预警研究提供了基础经验框架。

从模型方法看，早期财务困境预警研究主要依赖财务比率和传统统计模型。张玲（2000）采用判别分析构建财务预警模型，体现了我国早期研究以财务指标识别企业风险的基本路径。此类方法通常选取盈利能力、偿债能力、营运能力、现金流量和成长能力等指标，通过判别分析、Logistic 回归等方法判断企业未来是否可能陷入财务困境。随着研究的深入，学者逐渐认识到现金流和偿债约束在企业困境形成过程中的重要作用，周首华等（2022）提出 F 分数模式并强调现金流指标的预警含义，反映出财务困境预警研究从静态财务比率分析向资金链压力和持续经营能力分析的拓展。总体而言，传统统计模型具有变量含义清晰、结果解释性强和实务应用便利等优点，但其不足也较为明显：一方面，财务报表具有固定披露周期，难以及时反映企业经营环境和外部市场预期的变化；另一方面，财务指标可能受到会计政策选择、盈余管理和信息披露质量差异的影响，对隐性风险和早期风险信号的捕捉能力有限。

随着数据环境和计算方法的发展，财务困境预警模型逐渐由传统统计方法向数据挖掘和机器学习方法拓展。程晓秋（2010）将数据挖掘方法引入财务预警研究，强调特征选择、非线性拟合和分类性能提升的重要性。机器学习模型能够在一定程度上突破传统线性模型的限制，更好地刻画财务指标之间的非线性关系和复杂交互效应。在此基础上，研究者开始引入公司治理、经营效率、所有权结构等非财务信息，以弥补单纯依赖财务指标对企业治理结构、信息环境和经营质量刻画不足的问题。田宝新等（2017）、邓晓岚等（2006）均指出，非财务因素的引入有助于增强预警模型的经济解释和预测稳定性。

中国知网 https://www.cnki.net

刘小淇等（2015）采用主成分—逻辑回归方法构建非财务视角下的预警模型，说明在变量相关性较强或样本规模受限的情境下，通过降维方法可以提升模型稳健性。王昱等（2022）从多维效率视角扩展了困境识别的经济含义，强调经营效率、资源配置和治理绩效等因素对风险识别的重要作用。Alam 等（2024）则从所有权结构动态变化角度研究金融韧性和困境预测，表明治理结构变化能够为企业风险识别提供长期增量信息。

近年来，财务困境预警研究进一步关注更贴近现实场景的数据特征和建模问题，包括样本不平衡、动态预测、关联风险和多源异质信息融合等。任婷婷等（2021）针对困境企业样本占比较低的问题，提出改进 AdaBoost 的动态预警模型，体现了不平衡学习和代价敏感思想在风险识别中的应用价值。闫达文等（2024）利用混频数据刻画财务困境动态演化，推动预警模型从年度截面识别向更高频、更及时的风险监测拓展。在特征工程和模型结构方面，徐车等（2026）提出演化特征选择的集成预测模型，强调特征选择与模型集成的协同优化；王建飞等（2025）将高阶关联风险特征引入财务困境预测，说明企业之间的关联结构和风险传导关系可能带来额外预测增益。与此同时，外部软信息也逐渐被纳入财务困境预警框架。张玉等（2025）基于股票论坛 UGC 时序特征刻画市场情绪，吕喜梅等（2023）利用临时报告中的软信息研究新三板企业困境预测，均表明非结构化信息能够在财务指标之外提供补充性风险信号。张涵等（2025）利用图神经网络融合企业异质信息并结合不平衡处理，宋媚等（2025）将 D-S 证据融合与可解释多分类预警结合，进一步体现出当前研究向多源融合、复杂建模和可解释输出方向发展。

综合来看，现有财务困境预警研究已经形成了较为完整的方法体系：传统财务指标模型强调解释性和可操作性，机器学习模型强化非线性拟合和分类性能，非财务信息和外部软信息的引入则拓展了风险识别的信息边界。然而，既有研究仍存在若干不足。第一，传统模型主要依赖财务报表数据，信息披露存在滞后性，难以及时捕捉企业经营环境、融资条件和市场预期的快速变化。第二，部分统计模型建立在线性或静态假设基础上，对财务指标之间的复杂交互、风险传导和动态演化刻画不足。第三，虽然已有研究开始引入非财务信息和文本信息，但多数方法仍依赖词典法、浅层情绪分类或特定披露文本，对新闻文本中的上下文语义、隐含风险、否定表达和行业语境差异识别能力有限。第四，复杂机器学习模型虽然提升了预测精度，但在金融风险管理场景中仍面临解释性不足、跨样本稳健性和实务可用性等问题。因此，如何在保留传统财务指标解释力的基础上，引入能够反映市场预期和外部软信息的文本情绪指标，并借助大语言模型提升复杂语义识别能力，是财务困境预警研究值得进一步拓展的重要方向。基于此，本文在传统财务指标基础上引入新闻文本情绪信息，比较词袋模型、预训练语言模型和领域微调

中国知网　https://www.cnki.net

大语言模型在情绪指标构建中的表现，并结合多种机器学习模型和可解释性方法，检验大语言模型文本情绪指标在企业财务困境预警中的增量价值。

2.2 公司新闻、文本情绪与企业风险的相关研究

关于新闻文本与企业风险的研究，核心在于揭示信息载体—情绪形成—市场反应/融资约束的传导机制。Tetlock（2007）奠定了媒体内容—投资者情绪—市场行为的经典范式，证明新闻语调能够预测市场回报与交易活动，并对情绪驱动的定价偏离提供解释。在此基础上，文献开始细化新闻叙事结构对市场反应的影响。Brière 等（2023）[48]从新闻时态与时间跨度考察市场反应差异，说明同一信息在叙事方式与时间视角改变时可能引致不同的价格反应。Supawat 和 Arnat（2023）和孙玲莉等（2023）比较公司公告与新闻文本的市场反应，提示公告信息与新闻叙事在投资者关注、加工与解读机制上具有互补性与差异性。进一步地，媒体环境也被纳入企业融资与治理的分析框架，Chen（2024）将媒体覆盖与社会信任联系到企业融资效率，表明新闻环境可能通过信息中介与社会资本机制影响融资约束与融资成本；Cheng 等（2024）则将媒体覆盖与债务融资选择联系起来，强调媒体监督与信息披露环境可能影响债务工具选择与融资结构。与信息属性相对应，新闻还具有显著外部性，汝毅等（2025）从声誉溢出效应讨论媒体报道的影响，指出新闻并非中性载体，其叙事可能改变外部评价与外部约束强度。

在文本信息的市场解读层面，研究逐渐强调主体异质性与语义表示的升级。樊瑞鑫等（2025）从公司公告事件出发刻画个人投资者的信息反馈差异，表明文本信息的市场解读存在显著异质性，并进一步影响价格形成过程。与传统词典计数方法相比，唐国豪等（2024）以文本机器学习研究公告溢价与资产定价机制，体现了文本—定价/风险研究从浅层词频统计向模型化语义表示的转向。围绕企业风险的经济机制，相关研究也将文本冲击与财务约束、信息质量风险及经营决策联系起来。Bukalska 和 Maziarczyk（2023）讨论财务约束、财务困境与现金持有关系，提示外部信息冲击与内部融资约束状态往往共同决定企业风险暴露。Martínez-Sola 等（2024）从财务约束影响会计重述的角度强调约束状态与信息质量风险之间的联动，为困境研究补充约束—信息质量—风险的证据链条。在非财务信息方面，Benlemlih（2017）从企业社会责任与债务期限结构讨论软信息与融资合约的关联，为软信息—融资条件机制提供经验证据。同时，困境状态也会反馈至经营层面，Li 和 Wang（2025）讨论财务困境下企业生产决策变化，提示困境不仅体现为财务状态变化，也可能通过经营策略调整呈现为多维风险。

2.3 自然语言处理与大语言模型在金融领域的应用

中国知网 https://www.cnki.net

金融文本分析的研究基础主要由测度工具箱与任务化建模两条路径共同构成。Loughran 和 Mcdonald（2016）系统总结会计金融文本分析方法与应用，奠定了词典、可读性、语调测度等基础工具，并推动文本变量在金融研究中的规范化使用。在风险识别任务中，文本披露的增量信息被不断验证，Hajek 和 Munk（2024）利用年报风险相关信息提升财务困境预测，说明披露文本中风险段落/风险表述具有可量化的增量信息；Stevenson 等（2021）将深度学习引入文本驱动的小企业违约预测，表明在报表质量不一或结构化数据受限的场景下，文本可以作为有效补充信息源。随着生成式模型的发展，研究开始探索 LLM 在风险任务中的语义增强与跨模态对齐能力，Lu 等（2025）提出 LLM 注入的双层语义增强框架，将生成式模型用于语义增强与跨模态对齐，为信用风险预测提供增强、对齐、落地的技术路径。在多源融合方面，Tavakoli 等（2025 从文本与数值数据流的多模态深度学习预测信用评级，进一步验证异质信息融合在信用风险任务中的性能潜力。

面向更细粒度的金融文本任务，实体与事件抽取为后续情绪、风险与机制识别提供基础设施。Li 等（2022）从深度学习命名实体识别角度给出系统综述，为金融文本实体、事件与关系抽取的特征工程与模型选择提供技术参照。Ehrmann 等（2024）综述历史文档的实体识别与分类任务，指出低质量文本、跨域语料与噪声环境下的实体识别挑战及其解决思路具有通用价值。在方法上，Luo 等（2018）提出基于注意力机制的 BiLSTM-CRF 实体识别模型，代表了序列标注与上下文建模的典型技术路径。

在中文情境下，披露文本与困境风险之间的关系也逐渐得到验证并形成可操作的研究范式。陈艺云（2022）以中文年报 MD&A 为样本研究披露文本与财务困境预测，展示了内部披露文本用于风险识别的可行路径。李成刚等（2023）围绕信息披露文本与 MD&A 提供经验证据，进一步拓展了中文披露文本在风险识别中的应用空间与方法路线。在融合建模方面，阮素梅等（2025）强调将上市公司文本信息纳入模型能够提升困境预测表现，支持结构化财务数据和披露文本的融合方向。在具体披露载体上，夏喆等（2024）从内部控制自评报告的文本风险信息出发进行困境预测，表明特定披露文本中的风险表述具有增量信息。文本情绪还可连接到更广义的治理风险，李双燕等（2023）从年报文本情绪研究上市公司违规行为，提示文本情绪不仅与困境风险相关，也可能与合规与治理风险存在关联。行业语境下的证据亦表明文本与结构化指标具有互补性，陈友余等（2025）将文本分析与机器学习用于汽车上市公司信用风险识别，体现了行业语境中文本特征+财务指标的协同作用，周颖刚等（2024）将文本信息融入资产定价的研究。

中国知网　https://www.cnki.net

2.4 机器学习与解释性机器学习在财务困境预测中的应用

机器学习在金融风险预测中的应用扩展，为困境预警研究提供了更丰富的算法选择与评估框架。Leo 等（2019）综述机器学习在银行风险管理中的应用，指出算法在预测、监测与资本配置等环节的扩展趋势，并强调模型治理的重要性。在结构创新层面，Lin 等（2025）将卷积等深度结构与破产预测融合，反映出深度学习在信用风险预测中的进一步深化。与此同时，金融领域对可解释性的需求不断强化，形成高性能模型+可解释输出的实务导向。Wang 和 Zhou（2024）以 SHAP 等解释工具研究系统性金融危机，表明解释工具已成为连接预测结果与经济含义的重要桥梁。在中文语境下，融合框架也持续推进：刘佳佳等（2024）提出 TI-FI-CatBoost 融合文本与财务指标的集成方法并验证预警窗口有效性，为财务+文本的集成建模提供了可复制的方案；乔冰琴等（2023）以多文本特征构建财务风险预警模型，说明文本特征工程在提升模型表现方面仍具有现实价值。

解释性机器学习的研究进一步从方法工具转向金融高风险决策的制度化要求。Chen 等（2023）从计量综述角度总结金融领域 XAI 研究，揭示可解释性在高风险决策场景中的必要性与主要技术路线。从更一般的智能系统视角，Weld 和 Bansal（2019）讨论可理解智能的挑战，指出解释并非附加功能，而涉及表达方式、交互机制与认知负担等系统性设计问题。在用户行为层面，Shin（2021）从信任与接受度出发讨论可解释性与因果可理解性对用户感知的影响，为金融模型部署提供行为学依据。相邻领域的证据也支持解释范式的扩散：Zhang 等（2022）在审计领域综述 XAI 应用，反映出可解释方法在审计、风控与异常识别等领域的融合趋势。从组织与治理角度，Haefner 等（2021）梳理 AI 的创新管理研究框架与议程，提示金融 AI 的落地同样需要组织能力、治理与流程再设计的协同支撑。

2.5 文献评述

现有文献围绕企业财务困境预警已形成清晰的演进脉络。早期研究主要依托财务比率与传统统计判别方法构建预警模型，侧重指标体系的可解释性与实务可操作性。随后，学者逐步引入逻辑回归、正则化等技术以提升模型稳健性与泛化能力，并开始纳入非财务因素，如公司治理、信息环境、经营质量，从而对困境风险形成更全面的解释。近年来，机器学习与集成学习方法成为主流方向，一方面针对不平衡样本、高频动态更新以及多源异质数据等现实挑战持续优化算法设计，另一方面则强调预测性能与解释输出的协同，以满足金融风控场景下的治理与审计需求。与此同时，文本信息研究在金融领域

中国知网 https://www.cnki.net

从最初探讨媒体语调对市场的影响，逐步拓展至文本信息如何塑造企业融资约束、声誉机制与风险暴露，方法上也从词典计数转向上下文语义表征、多模态融合及深度学习框架，为将非结构化文本纳入风险识别体系提供了坚实的证据基础。

总体来看，现有研究呈现出三大突出优势。其一，建模工具箱日益完备，从传统计量经济学到机器学习、图神经网络乃至证据理论融合，预测精度与适用场景不断拓展。其二，变量体系从单一财务指标演进为财务、非财务和外部信息的多维度刻画，显著增强了模型的经济解释力和风险传导机制的揭示能力。其三，可解释性方法的引入使预警模型更贴近金融高风险决策的现实需求，推动其从单纯能预测迈向可用、可审计、可治理。

然而，现有研究仍存在若干亟待填补的空白与局限。首先，尽管文本信息已被广泛证实具备增量预测价值，但在困境预警场景中，其构造仍以词典法、浅层情感分类或特定载体，如年报特定章节为主，对语义细微差别、语境依赖以及隐含态度的捕捉能力有限，尤其难以有效处理否定结构、反讽表达、委婉表述以及跨行业语义差异。其次，外部新闻、监管公告、网络用户生成内容等软信息来源日趋丰富，但不同载体的叙事逻辑、传播机制与时序特征差异显著，现有研究在统一度量口径、跨文本源对齐以及可比性检验方面仍显不足，导致文本指标在不同样本与时期的可迁移性受限。再次，虽有文献日益强调预警的动态化与及时性，但文本变量多停留在低频汇总或粗粒度统计层面，难以与企业困境演化的内在时间结构形成紧密匹配，从而制约了其在提前预警窗口上的实际增量贡献。最后，可解释性研究虽已聚焦结构化变量的重要性分解，却对文本情绪为何有效、哪些具体语义片段驱动模型判断、情绪通过何种机制如融资约束或声誉损害传导风险等核心问题，尚未形成直观、可追溯的解释链条。

有鉴于此，本文拟在现有文献基础上展开针对性拓展与深化，核心贡献在于引入大语言模型构建精细化的文本情绪指标，并将其系统嵌入企业财务困境预警框架。相较于传统词典或浅层分类方法，大语言模型能够在更细粒度的语境中理解语义结构，从而更精准地区分负面事实陈述与负面情绪表达，有效识别风险叙事的隐含态度与强度，并显著提升跨行业、跨文本载体的适配性与迁移能力。更具实质意义的是，本文将大语言模型文本情绪的运用从技术替代层面提升至信息增量识别的研究层面，在严格控制传统财务与非财务因素后，检验大语言模型情绪指标能否提供稳定且显著的边际预测贡献；同时，结合可解释性技术，揭示文本情绪在模型决策中的具体作用路径与驱动来源，从而为外部软信息如何融入困境预警体系提供可验证、可追溯的微观证据。简言之，本文以

中国知网　https://www.cnki.net

大语言模型为核心工具，旨在填补现有研究在高阶语义情绪刻画上的关键缺口，并推动文本风险领域从可用性研究向可解释性与可治理性统一的更高层次迈进。

中国知网 https://www.cnki.net

3　理论基础与技术方法

3.1　文本信号在财务困境预警的相关理论

3.1.1　信号理论

信号理论奠定了信息不对称市场中信息披露机制的分析基础。当企业内部人持有较外部投资者更优越的私有信息时，可通过释放具备成本属性的信号，缓解因信息差距引发的逆向选择问题。在财务困境预警研究中，管理层凭借其信息优势，不仅借助结构化财务指标传递企业状况，亦通过非结构化文本信息释放前瞻信号，从而为市场提供增量信息。

文本信息作为补充信号源，能够克服传统财务指标的滞后性与可操纵性。年报中的“管理层讨论与分析”（MD&A）、业绩说明会文本及企业新闻稿等载体，蕴含管理层对风险暴露、流动性状况与战略方向的主观判断。此类文本信号虽具有一定模糊性，但其前瞻性特质使其在财务困境的早期识别中具有独特作用。研究表明，文本情绪指标能够显著提升基于财务比率预警模型的预测准确性（Li 等，2010），印证了非结构化信息在信号传递中的补充价值。

信号的可信度与其发送成本密切相关。依据信号理论，高成本信号因难以被低质企业模仿而具备更强信息含量。在文本披露中，管理层主动揭示负面信息（如承认经营困难或行业逆境）构成高成本信号——因其可能引发股价波动与监管关注，从而削弱了虚假披露的动机。研究发现，文本中负面词汇的密度对财务困境的预测能力，显著高于净语调或正面表达（Hanley 等，2010），这源于负面信号高成本属性所带来的可信度溢价。

多源文本信号的交叉验证有助于提升预警系统的稳健性。正式披露文件（如年报）通常措辞审慎，而媒体与社交平台则提供更为即时和多元的信息流。尽管各渠道存在噪声，但跨来源文本情绪的一致变动往往预示实质性风险的累积。近期研究指出，当 MD&A 与新闻文本同时呈现情绪负面化转向时，企业后续陷入财务困境的概率显著升高（Loughran 等，2016），表明异质信号源的共振效应可有效过滤单一路径的误报。所以，信号理论为理解财务困境预警中的文本信息披露提供了系统的理论视角。

3.1.2　行为金融理论

行为金融学对传统金融理论的理性人假设提出根本质疑，强调市场参与者的决策常受到认知偏差与情绪驱动的影响，从而偏离完全理性范式。在财务困境预警研究中，这

中国知网　https://www.cnki.net

一视角为文本情绪指标的信息含量提供了深刻解释：情绪不仅反映主观信念的偏误，更会通过定价机制、融资约束与市场反馈循环，实质性地影响企业风险的演化路径。

投资者情绪通过改变风险定价与资本配置效率，直接影响企业脆弱性。Baker 与 Wurgler（2006）将投资者情绪界定为“与基本面无关的未来现金流预期的系统性偏离”，此类情绪波动可能扭曲股权与债权市场的风险溢价。当文本情绪指标（如年报管理层语调或新闻情感倾向）呈现持续负面转向时，往往意味着市场对企业偿付能力的预期趋于恶化，进而推高其融资成本、抑制投资灵活性，加速流动性紧缩。研究表明，市场在情绪高涨期对利好消息反应过度，在情绪低迷期则对负面信息反应放大，此类非对称反应机制显著提高了财务危机发生的可能性。

情绪具有明显的跨主体传染性与反馈放大效应。基于社会网络理论，负面情绪可通过媒体报道、分析师评论及社交媒体等多种渠道迅速扩散，形成“情绪—价格—流动性”的恶性循环。企业负面文本信号一旦广泛传播，不仅可能引发投资者恐慌性抛售，还可能促使债权人收紧信贷条件、供应商要求预付款项等连锁反应，进一步加剧其经营压力。文本分析技术能够量化此类情绪传染的强度与时序特征，例如通过追踪不同信息源之间负面情绪的协同上升，识别财务困境的早期预警窗口。

市场微观结构中的套利限制加剧了情绪驱动的定价偏差。在信息不对称环境中，专业投资者虽能借助文本信号识别基本面风险，但受制于基本面风险、噪声交易者风险以及时间跨度约束，往往难以完全纠正情绪引致的错误定价。尤其当市场情绪高涨与企业潜在财务困境并存时，风险信号可能被暂时掩盖，导致股价与债券价格虚高；而情绪一旦逆转，价格调整往往更为剧烈。文本情绪指标有助于捕捉此类情绪与困境交互效应，识别被市场暂时忽略的结构性风险，从而提升预警模型的前瞻性。

行为金融理论不仅为文本情绪指标的有效性奠定了行为基础，更揭示了情绪如何通过定价扭曲、传染反馈与套利受限等机制，实质性地作用于企业财务健康状况。

3.1.3 信息不对称理论

信息不对称理论为阐释文本情绪在财务困境预警中的作用提供了理论基础。“柠檬市场”模型表明，交易双方信息分布不均将引致逆向选择与道德风险，进而扭曲市场定价效率。在企业融资与估值过程中，管理层拥有外部投资者难以企及的私有信息，而公开披露成为后者研判的主要依据。文本信息以其高频、多维和语义丰富的特点，成为弥合这一结构性信息鸿沟的重要媒介。

文本信息能够提升信息披露的时效性与连续性，有效填补定期财务报告之间的信息真空。传统财务报表受制于季度或年度披露频率，难以及时捕捉企业流动性压力、客户

中国知网 https://www.cnki.net

流失或供应链中断等突发风险。相比之下，新闻报道、监管问询函及社交媒体等非结构化文本以近乎实时的频率传递经营动态，为市场提供了连续的增量信息流。研究表明，在财报空窗期，负面新闻情绪的骤升可提前三至六个月预示后续财务困境（Tetlock，2007），印证了文本信号在缓解动态信息不对称中的独特价值。

管理层的信息披露策略本身构成可识别的信号。依据 Jensen 与 Meckling 的代理理论，面临财务压力的企业存在隐藏负面信息的动机，常表现为刻意模糊化风险表述、过度使用乐观修辞或延迟披露不利事件。文本分析技术可通过检测语义模糊度、负面情绪的抑制程度，以及管理层语调与业绩表现的背离，识别此类策略性披露行为。研究发现，处于财务困境前兆期的企业往往呈现业绩恶化但文本乐观的异常组合，该背离信号对困境预测具有显著的增量解释力。

文本信息与结构化财务指标形成互补验证机制，增强了风险识别的稳健性。当财务指标尚未显著恶化，但管理层讨论与分析或新闻文本已呈现持续的负面情绪转向时，往往预示隐性风险正在累积；反之，若财务数据异常而文本情绪异常乐观，则可能暗示盈余管理或报表操纵。这种指标与文本交叉验证不仅提升了预警的灵敏度，也有助于区分暂时性经营波动与系统性财务脆弱性。近期研究证实，融合文本情绪与财务比率的混合模型，其困境预测准确率较单一模型可进一步提升（Li 等，2020）。

综上所述，信息不对称理论揭示了文本情绪指标的核心价值：它不仅是信息的补充来源，更是识别管理层披露策略、验证财务数据真实性的重要工具。未来研究可进一步探讨文本信息在不同制度环境与行业特征下的信息含量差异，以及深度学习技术在捕捉复杂语义模式中的应用潜力，从而深化对市场信息传导机制的理解。

3.2　词袋模型

在构建基于文本数据的信用风险指标时，本文首先采用词袋模型（Bag-of-Words，简称 BOW）对非结构化的企业新闻进行结构化处理。词袋模型是自然语言处理领域中一种经典的文档表示方法，其核心思想是将文本抽象为由词汇组成的集合，而不考虑词汇在文本中出现的顺序、语法及句法结构。

3.2.1　基本原理

词袋模型将每一篇文档 d 映射为特征空间中的一个高维向量。假设研究样本中所有文档涉及的去重词汇构成的集合为词典 $V = w_1, w_2, ..., w_N$，其中 N 为词典维度。

对于任意一篇文档d_j，其词袋向量表示为：

$$V_j = (f_{1j}, f_{2j}, ..., f_{Nj}) \tag{3.1}$$

中国知网　https://www.cnki.net

其中，f_{ij}代表词项w_i在文档d_j中出现的频数。

3.2.2 逆文档频率

虽然基础的 BOW 模型直接使用词频进行计数，但在学术研究中，为了突出具有判别力的特征词，本文进一步引入了 TF-IDF（Term Frequency-Inverse Document Frequency）权计算法。该方法通过引入逆文档频率，降低了在所有文档中频繁出现（判别力低）的词汇权重，计算公式如下：

$$W_{i,j} = TF_{i,j} \times \log\left(\frac{D}{DF_i}\right) \tag{3.2}$$

其中，D 为文档总数，DF_i为包含词项 i 的文档数量。

3.3 大语言模型相关理论

3.3.1 大模型理论基础

大型语言模型主要依托于 Transformer 架构进行构建，该架构是其实现复杂语言任务处理能力的核心基础。Transformer 模型的结构主要由两个重要模块组成：编码器和解码器，每个模块均包含多层自注意力机制与前馈神经网络。这种设计能够有效应对序列中远距离依赖关系的处理需求。

$$\text{Attention}(q, k, v) = \text{softmax}(\frac{qk}{d_k})v \tag{3.3}$$

自注意力机制的核心特点是通过查询向量（Q）、键向量（K）和值向量（V）的交互实现，这三个向量均由输入数据通过线性变换生成。输入序列中的每个元素经过线性变换后被映射为对应的查询、键与值向量。随后，自注意力机制通过计算查询向量与所有键向量的点积，获取注意力分数，这些分数反映了序列中每个元素对其他元素的关注程度。为了确保注意力分数的总和为 1，自注意力机制采用 softmax 函数对其进行归一化处理，从而形成一个概率分布。最终，自注意力层的输出是值向量的加权和，其中权重由归一化后的注意力分数决定。该流程使得自注意力层的输出能够以加权方式综合输入元素，其中权重代表了每个输入元素的相对重要性。自注意力机制通过灵活的加权策略捕捉输入序列中的复杂关系，例如长距离依赖性，这使得大语言模型在处理需要理解上下文和序列的任务时表现出卓越的能力。

大语言模型的架构主要分为两类：仅解码器架构和编码器-解码器架构。仅解码器模型以单向方式生成文本，输入序列中的每个标记仅关注前面的标记，非常适合文本生

中国知网 https://www.cnki.net

成任务。编码器-解码器模型通过编码输入序列并解码为目标序列，可以处理生成与理解相结合的多种任务。

在大语言模型中，令牌生成是关键环节，涉及词汇构建、概率预测和解码策略。通常使用字节对编码（BPE）方法将单词分解为子词单元，从而优化模型的词汇处理能力。在标记生成过程中，模型通过 softmax 层预测每个标记的概率，并选择下一个标记，常见方法包括贪心解码和束搜索。束搜索通过保留固定数量的候选序列，在概率最大化与多样性之间取得平衡，从而生成连贯且上下文相关的文本。

此外，大语言模型在对话式人工智能中表现出色，驱动了复杂的聊天机器人和虚拟助手。这些技术支持实时生成类似人类的对话，广泛应用于客户服务自动化、学习平台和个性化通信工具。大语言模型还在信息提取和文本总结中发挥重要作用，能够将冗长的文档提炼为简洁的标题，特别适用于新闻业和学术领域。在情感分析任务中，大语言模型对上下文和语言细微差别的理解也展现出优势，包括金融情感分析等场景，为品牌监测、市场研究和社交媒体分析提供了支持。

总体而言，大语言模型从架构到生成技术的复杂性为其广泛应用提供了支撑。这些模型不仅提升了现有任务的效率，还为人类语言的交互和处理方式带来了新的可能性。基于此，本研究旨在运用大语言模型技术对公司新闻中隐藏的信用风险进行提取与分析。

3.3.2　提示词工程

提示技术作为与 LLM 交互的一种独特方式，因其无需对模型进行微调且操作简便，已经发展为一个备受关注的研究领域。这一领域揭示了用户输入与大语言模型输出之间复杂而精细的关系。例如，早期的研究工作深入探讨了不同提示设计对语言模型性能和生成结果的显著影响，这标志着提示工程的兴起。随着研究的深入，该领域迅速扩展，尤其在少样本和零样本学习场景中显示了提示的重要性。Tom 等（2020）的研究表明，通过精心设计的提示，GPT-3 能够在仅有极少量先验示例的情况下完成复杂任务。

近年来，研究重心逐渐从单一任务指令转向提示语义和上下文的细微差异，探索这些变化如何显著影响模型生成的响应。比如，“有问必答”提示技术提出了通过聚合多个不完美提示以提升模型性能的方法，这种方法在问答任务中表现尤为突出。而“思维链”方法则通过引导模型生成一系列中间推理步骤，以提高其在复杂任务中的表现。此外，“最少到最多提示法”提供了一种将复杂问题分解为若干简单子问题的策略，从而显著增强了模型应对超出提示范围的复杂任务的能力。

同时，Lampinen 等（2022）的研究揭示了解释在提示中的有效性，表明解释能够提升模型在复杂任务上的学习能力。而 White 等（2023）则系统性梳理了与 ChatGPT 相

中国知网　https://www.cnki.net

关的提示工程技术，强调提示设计在增强语言模型在软件开发和教育领域中的应用潜力。研究指出，精心设计的提示对于提升模型性能至关重要，尤其在编码实践和学习体验的优化方面。最后，定向刺激提示提出了一个创新框架，通过可调节的策略模型生成辅助提示，引导大语言模型生成符合预期的特定结果。这些多样化的提示策略彰显了大语言模型领域的快速发展，并为更高效地发挥模型潜力提供了多种可能的方向。

本文将主要运用提示词工程对公司新闻的标题文本进行分析，以挖掘其中潜在的负面情绪信息。

3.3.3 大语言模型微调

本研究采用微调技术，旨在将通用大模型中蕴含的语言理解能力迁移至特定的企业信用风险识别任务中。大语言模型的构建通常分为两个阶段，预训练阶段是在大规模无标签语料库上通过自监督学习获取通用的语言表示能力，其目标是预测序列中的下一个词；微调阶段则是基于预训练模型，利用特定领域的少量标注数据对模型参数进行调整。在金融实证研究中，这一过程本质上是领域自适应，即让模型学习金融术语、新闻语境与企业财务困境之间的复杂映射关系。

有监督微调是目前最主流的实现方式。其数学过程可描述为：

给定特定领域的标注数据集 $D = (x_i, y_i)_{i=1}^{n}$（其中 x 为企业新闻，y 为对应的情绪得分），微调的目标是最小化如下交叉熵损失函数：

$$\mathcal{L}(\theta) = -\sum_{(x,y)\in D} \log P(y|x;\theta) \tag{3.4}$$

其中，θ代表模型的参数。通过梯度下降算法，模型在保留预训练通用语义信息的同时，优化了处理金融文本分类任务的权重分布。

考虑到全参数微调对计算资源要求极高且易导致灾难性遗忘，本文引入了高效参数微调中的 LoRA（Low-Rank Adaptation）技术。

LoRA 的核心思想是在原有的预训练参数矩阵W_0旁增加一个旁路，通过两个低维矩阵 A 和 B 的乘积来近似参数的增量更新：

$$W = W_0 + \Delta W = W_0 + B \times A \tag{3.5}$$

在训练过程中，冻结原始权重W_0，仅更新低秩矩阵 A 和 B。这种方法极大地降低了训练成本，并能在保持模型泛化能力的同时，精准捕获金融文本中的微观风险特征。

在信用风险建模领域，通用大模型虽然具备常识，但往往难以准确捕捉金融语境下的细微风险信号。通过微调，模型可以让模型学习金融专用词汇在特定上下文中的真实

中国知网 https://www.cnki.net

含义，将长文本分析转化为结构化的情绪得分预测，通过全面的企业数据微调，使模型具备对当前宏观经济环境下的风险感知能力。

中国知网　https://www.cnki.net

4 研究设计

4.1 样本选择和数据来源

为探究上市公司新闻文本情绪得分在财务困境预警模型中的作用，本研究以 2014 年至 2024 年 A 股上市公司为样本，收集其新闻标题及财务数据。在所选研究时段，共有 301 家企业被列为 ST，一共产生 1198 个研究样本。由于 ST 与非 ST 公司分布不均衡，本文参照李成刚等（2022）的做法，依据行业类别与资产规模为每家 ST 公司匹配一家非 ST 公司。匹配时要求非 ST 公司与对应 ST 公司的总资产之差不超过 20%，同时剔除上市时间不足三年的企业，以确保数据适用于 t-2 期至 t 期的预警框架。行业分类依据 2012 年中国证监会发布的行业分类标准。

考虑到上市公司通常在次年 4 月 30 日前披露上一年度年报，而 t-1 年年报的披露时间与 t 年度是否被 ST 处于同一时期，为缓解内生性问题，本文借鉴李成刚等（2022）的研究设计，采用 t-2 年度的财务数据与新闻文本信息构建财务困境预警模型。研究所需新闻文本与财务数据均来源于国泰安（CSMAR）数据库。最终，经过匹配与筛选，共得到 2330 家 A 股上市公司作为有效研究样本，其中 ST 和非 ST 公司都是 1165 个样本。

4.2 因变量指标选取

本研究中，因变量设定为财务困境。参考吴世农等（2001）与孙玲莉等（2021）的做法，以企业是否被证券监管部门实施特别处理（Special Treatment，ST）作为财务困境的判定标准。具体而言，若企业在 t 年被标记为 ST，则因变量 Y 赋值为 1；否则，Y 赋值为 0。

4.3 财务指标的选取

在财务困境相关研究中，众多学者普遍将企业年度财务指标作为控制变量。本文参考孙玲莉等（2021）和李成刚等（2023）的研究，分别从盈利能力、偿债能力、成长能力、营运能力以及现金流量五个方面选取财务指标。

4.3.1 盈利能力

具体而言，盈利能力是企业在一定会计期间获取经营收益、实现盈利增值的核心能力，是企业生存与发展的基础，直接反映企业资产运营效率、成本控制水平及盈利质量，

中国知网 https://www.cnki.net

也是投资者、债权人及管理层重点关注的财务维度。本文选取总资产净利润率、净资产收益率、留存收益资产比、营业毛利润率、营业净利润率五个指标代表企业的盈利能力。盈利能力指标如表 4.1 所示。

表 4.1 盈利能力指标

Tab. 4.1 Profitability index

财务指标	符号	定义
总资产净利润率	ROA	净利润 / 总资产余额
净资产收益率	ROE	净利润 / 股东权益余额
留存收益资产比	RE_TA	（盈余公积+未分配利润）/ 资产总额
营业毛利润率	GPM	（营业收入—营业成本）/ 营业收入
营业净利润率	NPM	（净利润 / 营业收入

4.3.2 偿债能力

偿债能力是企业偿还自身到期债务（包括短期债务与长期债务）的能力，是衡量企业财务稳健性、规避债务违约风险的重要维度，直接关系到企业的持续经营能力与债权人利益。偿债能力指标主要分为短期偿债能力与长期偿债能力两类，本文选取营运资本资产比、流动比率、速动比率、现金比率、资产负债率、产权比率、权益负债率、利息保障倍数八个指标作为企业的偿债能力指标。偿债能力指标如表 4.2 所示。

表 4.2 偿债能力指标

Tab. 4.2 Solvency index

财务指标	符号	定义
营运资本资产比	WC_TA	（流动资产－流动负债）/ 资产总计
流动比率	Liquid	流动资产 / 流动负债
速动比率	Quick	（流动资产－存货）/ 流动负债
现金比率	Cash_Ratio	现金及现金等价物期末余额 / 流动负债
资产负债率	DAR	负债合计 / 资产总计
产权比率	DER	负债合计 / 所有者权益合计
权益负债率	BVE_TL	所有者权益合计 / 负债合计
利息保障倍数	ICR	（净利润+所得税费用+财务费用）/ 财务费用

4.3.3 营运能力

中国知网 https://www.cnki.net

营运能力是企业对各类资产进行运营、管理，实现资产周转增值的能力，核心反映企业资产的利用效率与管理水平，资产周转效率越高，表明企业资产利用越充分，经营效率越高，越能为企业盈利能力与偿债能力提供支撑。本文共选取总资产周转率、存货周转率、应收账款周转率三个指标作为企业营运能力的指标。营运能力指标如表 4.3 所示。

表 4.3 营运能力指标

Tab. 4.3 Operating capacity index

财务指标	符号	定义
总资产周转率	TAT	营业收入 / 资产总额期末余额
存货周转率	ITR	营业成本/存货净额期末余额
应收账款周转率	ART	营业收入 / 应收账款期末余额

4.3.4 现金流量

现金流量指标是衡量企业现金及现金等价物的流入、流出规模及周转效率的指标，现金流量是企业持续经营的“血液”，直接关系到企业的偿债能力、营运能力及盈利质量，能够真实反映企业的实际经营状况与财务健康水平。本文共选取自由现金流、现金周转率、现金流波动性三个指标作为企业现金流量能力的指标。现金流量指标如表 4.4 所示。

表 4.4 现金流量指标

Tab. 4.4 Cash flow indicator

财务指标	符号	定义
自由现金流	FCF	（现金及现金等价物净增加额—筹资活动产生的现金流量净额）本期值 / 实收资本本期期末值
现金及现金等价物周转率	Cash_ET	营业收入/期末现金及现金等价物余额
现金流波动性	Cash_FV	（现金流/总资产）三年波动率

4.3.5 成长能力

成长能力是企业在长期经营过程中，实现资产规模、营业收入、盈利水平等方面持续增长的能力，反映企业未来的发展潜力与扩张能力，是投资者评价企业投资价值、管理层制定发展战略的重要依据。本文共选取总资产增长率、营业收入增长率、净利润增长率三个指标作为企业的成长能力指标。成长能力指标如表 4.5 所示。

中国知网 https://www.cnki.net

表 4.5 成长能力指标

Tab. 4.5 Growth capability indicator

财务指标	符号	定义
总资产增长率	TAG	（资产总计本期期末值—资产总计本期期初值）/（资产总计本期期初值）
营业收入增长率	RG	（营业收入本年本期单季度金额—营业收入上一个单季度金额）/（营业收入上一个单季度金额）
净利润增长率	NPG	（净利润本年本期单季度金额—净利润上一个单季度金额）/（净利润上一个单季度金额）

4.4 文本情绪指标的构建

4.4.1 基于 BOW 的文本情绪指标构建

词袋模型是自然语言处理中最基础、最常用的文本表示模型，其核心思想是忽略文本中词语的语法结构、语序关系，仅统计文本中各词语的出现频率，将文本转化为基于词语频率的向量表示，进而结合情绪词典完成情绪倾向的量化计算。基于 BOW 模型构建企业文本情绪指标，分别以企业 t-2 年新闻标题与内容为数据基础，具体构建过程分为以下 4 个步骤。

（1）数据收集与筛选

选取研究样本企业 t-2 年全年发布的公开新闻文本作为原始数据，数据来源涵盖主流财经媒体、企业官方公告平台及权威新闻发布渠道，确保数据的真实性、完整性与相关性。新闻文本包含两个核心部分：新闻标题与新闻内容，其中新闻标题是文本核心信息的高度概括，情绪倾向更为鲜明；新闻内容是对事件的详细阐述，包含更丰富的情绪相关信息，二者结合可提升情绪提取的准确性。

数据筛选过程中，剔除无效新闻文本，具体包括：与样本企业无直接关联的新闻、重复发布的新闻、内容残缺或无法识别的新闻、广告宣传类无实质情绪倾向的新闻；同时，对筛选后的新闻文本进行去重处理，避免同一新闻多次计入导致的情绪偏差，最终得到样本企业 t-2 年有效新闻文本集合，作为情绪指标构建的基础数据。

（2）文本预处理

原始新闻文本包含大量无关字符、冗余信息，需通过一系列预处理操作，将文本转化为适合 BOW 模型处理的标准化格式，预处理步骤如下：一是文本清洗，剔除文本中的特殊字符（如标点符号、数字、字母、空格、换行符）、无意义助词（如“的、地、

中国知网 https://www.cnki.net

得”）及网页链接、广告标识等冗余信息，保留纯中文文本内容；二是分词处理，采用 Python 的 jieba 分词工具，将清洗后的新闻标题与内容分别进行分词，将连续的中文文本拆分为独立的词语（词条），同时保留财经领域专用词汇（如“营收、净利润、并购、违约”），确保分词的准确性；三是去停用词，结合通用中文停用词表与财经领域停用词表，剔除分词后无情绪意义、无实质内涵的词语（如“今天、公告、据悉”），减少无关词汇对情绪计算的干扰；四是文本整合，将单条新闻的标题分词结果与内容分词结果进行整合，形成单条新闻的标准化词条集合，兼顾标题的核心情绪与内容的细节情绪。

（3）BOW 模型构建与文本向量表示

在文本预处理完成后，基于标准化词条集合构建 BOW 模型，将每条新闻文本转化为量化向量。首先，构建全局词袋词典，遍历所有样本企业 t-2 年的有效新闻文本词条集合，收集所有不重复的词条，形成全局词袋词典，词典中的每个词条对应一个唯一的索引，作为向量的维度；其次，计算词条频率，对每条新闻文本，统计词典中每个词条在该文本中的出现次数（词频），若词条未在该文本中出现，则词频记为 0；最后，构建文本向量，以全局词袋词典的索引为向量维度，以各词条的词频为向量元素，将每条新闻文本转化为固定维度的词频向量，完成文本的量化表示。

为避免高频词条对情绪计算的过度影响，对词频向量进行归一化处理，采用 Min-Max 归一化方法，将各词条的词频映射至[0,1]区间，计算公式为：

$$w'_{ij} = \frac{w_{ij} - \min(w_j)}{\max(w_j) - \min(w_j)} \tag{4.1}$$

其中，w'_{ij}为第 i 条新闻文本中第 j 个词条的归一化词频，w_{ij}为该词条的原始词频，$\max(w_j)$、$\min(w_j)$分别为第 j 个词条在所有新闻文本中的最大、最小原始词频。归一化后可确保不同长度、不同词频分布的新闻文本向量具有可比性，为后续情绪得分计算奠定基础。

（4）情绪得分计算与指标构建

参考姜富伟等（2021）提出的中文金融语义情感词典，将全局词袋词典中的词条划分为正向情绪词条、负向情绪词条与中性情绪词条三类，其中正向情绪词条对应正向情绪，负向情绪词条对应负向情绪，中性情绪词条不具备明显情绪倾向，不计入情绪得分计算。

对每条新闻文本的归一化词频向量，计算其正向情绪得分与负向情绪得分：正向情绪得分计算公式为：

$$S_{pos,i}^{G} = \sum_{k \in P} w'_{ik} \quad (G = T或C) \tag{4.2}$$

负向情绪得分计算公式为：

中国知网 https://www.cnki.net

$$S_{neg,i}{}^{G} = \sum_{k \in N} w'_{ik} \quad (G = T或C) \tag{4.3}$$

其中，$S_{pos,i}$、$S_{neg,i}$分别为第 i 条新闻的正向、负向情绪得分，w'_{ik}为第 i 条新闻中第 k 个情绪词条的归一化词频，P、N 分别为正向、负向情绪词条集合，T 代表新闻标题，C 代表新闻内容。随后，计算单条新闻的综合情绪得分，计算公式为：

$$S_i^{G} = S_{pos,i}{}^{G} - S_{neg,i}{}^{G} \quad (G = T或C) \tag{4.4}$$

综合情绪得分的取值范围为[0,1]，得分越大表示该新闻文本为偏负向情绪，得分越小表示为偏正向情绪。

最后，构建企业 t-2 年的文本情绪指标：对样本企业 t-2 年所有有效新闻文本的综合情绪得分进行算术平均，得到企业 t-2 年的平均情绪得分，作为基于 BOW 模型的文本情绪指标，计算公式为：

$$EMO_{BOW}{}^{G} = \frac{1}{m}\sum_{i=1}^{m} S_i^{G} \quad (G = T或C) \tag{4.5}$$

其中，$EMO_{BOW}{}^{G}$为基于 BOW 模型的企业文本情绪指标，m 为企业 t-2 年有效新闻文本数量，S_i为第 i 条新闻的综合情绪得分。

4.4.2 基于 Fin-Bert 模型的文本情绪指标构建

Fin-Bert 模型是基于 BERT 预训练模型，针对金融领域文本进行微调后得到的专用自然语言处理模型，相较于通用 BERT 模型，其在金融文本的语义理解、情绪识别上具有更强的针对性与准确性，能够有效捕捉金融新闻文本中隐含的情绪倾向与语义信息。基于 Fin-Bert 模型构建文本情绪指标，同样以企业 t-2 年新闻标题与内容为基础数据，依托模型的预训练优势，无需手动构建情绪词典，直接实现情绪倾向的量化提取，具体构建过程分为 4 个步骤。

（1）数据收集与预处理

数据收集环节与 BOW 模型一致，选取样本企业 t-2 年全年有效新闻文本（含标题与内容），经过筛选、去重处理后，得到标准化原始文本集合，确保数据的相关性与完整性。与 BOW 模型不同，Fin-Bert 模型具备较强的语义理解能力，文本预处理无需进行分词、去停用词等复杂操作，仅需进行简单的标准化处理，具体步骤如下：一是文本清洗，剔除文本中的特殊字符、冗余信息及无效内容，保留纯中文文本，确保文本的可读性；二是文本长度标准化，由于 Fin-Bert 模型对输入文本长度有明确限制，最大输入长度为 512 个 token，所以对拼接后超过 512 个 token 的新闻文本，采用截断处理，保留文本前 512 个 token，确保核心信息不丢失；对不足 512 个 token 的文本，采用 Padding 处理，补充占位符，使文本长度统一，确保输入模型的文本格式一致。

中国知网 https://www.cnki.net

（2）Fin-Bert 模型选型与加载

选取开源的 Fin-Bert 预训练模型（基于金融领域大规模文本语料微调得到），该模型已完成金融文本语义理解、情绪分类等相关任务的预训练，能够直接应用于新闻文本情绪识别。通过 Hugging Face 平台加载 Fin-Bert 模型及对应的分词器（Tokenizer），其中 Tokenizer 的核心作用是将标准化后的文本转化为模型可识别的输入格式，实现文本与模型输入的适配。

加载模型后，设置模型的输出模式为情绪分类模式，明确模型的输出维度为 3 类包括正向情绪、负向情绪、中性情绪，同时设置模型的推理参数，其中批量处理大小根据硬件配置进行调整，确保模型推理的效率与稳定性；学习率设置为 1e-5，迭代次数设置为 3 次，避免模型过拟合或欠拟合，确保情绪识别的准确性。

（3）新闻文本情绪识别与得分计算

将预处理后的新闻文本批量输入 Fin-Bert 模型，模型通过对文本语义的深度挖掘，输出每条文本对应正向、负向、中性三种情绪的概率值，概率值之和为 1，即$P_{pos,i} + P_{neg,i} + P_{neu,i} = 1$，其中$P_{pos,i}$、$P_{neg,i}$、$P_{neu,i}$分别为第 i 条新闻正向、负向、中性情绪的概率值，概率值最高的情绪类别即为该文本的主导情绪倾向。基于模型输出的概率值，计算每条新闻文本的综合情绪得分，具体计算公式为：

$$S_i^G = P_{pos,i}^G - P_{neg,i}^G \quad (G = T或C) \tag{4.6}$$

得分取值范围为[0,1]，与 BOW 模型情绪得分保持一致，便于后续不同模型指标的对比分析。

在情绪识别过程中，为提升结果的可靠性，采用批量推理与交叉验证相结合的方式，对同一批文本进行多次推理，取多次推理结果的平均值作为最终的情绪概率值与综合情绪得分，减少模型随机误差对情绪识别结果的影响；同时，对识别结果进行人工抽样验证，确保模型情绪识别的准确性，若抽样验证准确率低于 90%，则调整模型参数，重新进行情绪识别，直至满足准确性要求。

（4）文本情绪指标构建与标准化

与 BOW 模型一致，基于每条新闻文本的综合情绪得分，计算样本企业 t-2 年所有有效新闻文本的平均情绪得分，作为基于 Fin-Bert 模型的初始情绪指标，计算公式为：

$$\overline{S}_{Fin-Bert}^{\ G} = \frac{1}{m}\sum_{i=1}^{m} S_i^G \quad (G = T或C) \tag{4.7}$$

为确保该指标与其他模型构建的情绪指标具有可比性，对平均情绪得分进行标准化处理，采用 Z-score 标准化方法，将指标值映射至标准正态分布，计算公式为：

中国知网 https://www.cnki.net

$$EMO_{Fin-Bert}{}^{G} = \frac{\overline{S}_{Fin-Bert}{}^{G} - \mu}{\sigma} \quad (G = T或C) \tag{4.8}$$

其中，$EMO_{Fin-Bert}{}^{G}$ 为标准化后的 Fin-Bert 模型情绪指标，μ为所有样本企业初始平均情绪得分的均值，σ为所有样本企业初始平均情绪得分的标准差，该公式可消除不同模型情绪得分分布差异的影响。

4.4.3 基于 DeepSeek 的文本情绪指标构建

DeepSeek 模型是一款开源的基于 MOE 混合架构大语言模型，具备较强的语义理解、上下文关联分析及情绪识别能力，在多方面与最新的 ChatGPT5.2 模型的能力齐平，相较于 Fin-Bert 模型，其参数量得到了巨幅的提升，参数量 300 多亿，在中文文本的处理效率、长文本情绪捕捉上具有一定优势，能够有效挖掘新闻文本中隐含的深层情绪信息（如间接表达的乐观、悲观倾向）。基于 DeepSeek 模型构建企业文本情绪指标，以企业 t-2 年新闻标题与内容为基础，构建过程与 Fin-Bert 模型类似，但结合模型特点优化了预处理与推理环节，具体分为 4 个步骤。

（1）数据收集与针对性预处理

数据收集环节与前两种模型保持一致，选取样本企业 t-2 年有效新闻文本（含标题与内容），经过筛选、去重处理后，得到原始文本集合。结合 DeepSeek 模型的中文处理优势，文本预处理侧重简化冗余操作、保留文本上下文关联性，预处理只包括文本清洗，剔除文本中的特殊字符、网页链接、冗余广告信息，保留纯中文文本，无需过度剔除助词、连词，避免丢失文本上下文语义。

（2）DeepSeek 模型 API 调用与提示词工程设计

本次研究中，DeepSeek 模型采用 API 调用方式实现情绪得分计算，无需本地加载开源模型，通过调用 DeepSeek 官方提供的 API，结合提示词工程（Prompt Engineering）实现 zero-shot 情绪识别——即无需对模型进行领域微调，仅通过精心设计的提示词，引导模型在无标注样本微调的情况下，准确识别财经新闻文本的情绪倾向，适配本研究的任务需求。

具体配置与提示词设计如下：首先，完成 API 调用基础配置，获取 DeepSeek 模型 API 密钥、请求地址，设置 API 调用参数，包括请求方式为 POST、响应格式为 JSON、批量处理大小设置为 32，同时设置超时时间为 30s，避免因网络或 API 响应延迟影响数据处理；其次，设计适配财经新闻情绪识别的 zero-shot 提示词，核心思路是明确任务要求、情绪分类标准与输出格式，引导模型精准输出情绪置信度，提示词示例如下：

“请忘记前面的内容，作为专业财经文本情绪分析师，对以下财经新闻文本进行情绪识别，仅输出正向、负向、中性三种情绪的置信度，置信度之和为 1，无需额外解释。情绪分类标准：正向情绪指企业盈利增长、项目突破、政策利好等积极信息；负向情绪

中国知网 https://www.cnki.net

指企业亏损、违约、违规、业绩下滑等消极信息；中性情绪指无实质情绪倾向的日常公告、客观陈述类信息。新闻文本：{text}”。

该提示词明确了任务身份、情绪分类标准与输出要求，能够有效引导 DeepSeek 模型在 zero-shot 场景下，精准捕捉财经新闻文本的情绪特征，避免无关输出，同时确保不同新闻文本的情绪识别标准统一，为后续得分计算奠定基础。此外，针对 API 调用稳定性，设置重试机制，最多 3 次重试，若单次调用失败，间隔 5s 后重新发起请求，确保所有新闻文本均能完成情绪识别。

无需对 DeepSeek 模型进行本地参数优化或领域微调，zero-shot 场景下，模型的识别精度主要依赖提示词的引导效果。为进一步提升情绪识别的准确性，对提示词进行多次调试优化，重点优化情绪分类标准的表述，补充财经领域典型情绪词汇示例，避免模型对模糊文本的情绪误判；同时，通过少量样本测试，验证提示词的有效性，若情绪识别准确率低于 88%，则调整提示词的表述逻辑、情绪分类细节，直至满足识别精度要求，确保 API 调用与提示词工程的适配性。

（3）文本情绪 API 调用推理与得分量化

将预处理后的新闻文本，按 API 批量处理要求整理为请求数据，批量调用 DeepSeek 模型 API 进行情绪识别推理。API 响应结果为 JSON 格式，包含每条文本对应正向、负向、中性三种情绪的置信度，置信度之和为 1，与提示词要求一致，其中置信度越高，表明模型对该情绪类别的判定越可靠。

对于进行打分的新闻文本，直接以 API 返回的正向、负向置信度计算综合情绪得分，计算公式为：

$$S_i^G = P_{pos,i}^G - P_{neg,i}^G \quad (G = T或C) \tag{4.9}$$

其中$P_{pos,i}$、$P_{neg,i}$分别为 API 返回的第 i 条新闻正向、负向情绪的置信度。

为进一步提升情绪得分的准确性，引入情绪强度系数，对 API 返回的情绪置信度进行修正：若文本中包含强情绪词汇，则对应情绪置信度乘以 1.2 的强度系数；若包含弱情绪词汇，则对应情绪置信度乘以 0.8 的强度系数；中性文本不进行修正，确保情绪得分能够准确反映文本情绪的强弱程度，与前序模型的得分量化逻辑保持一致。

为进一步提升情绪得分的准确性，引入情绪强度系数，对模型输出的情绪置信度进行修正：若文本中包含强情绪词汇，则对应情绪置信度乘以 1.2 的强度系数；若包含弱情绪词汇，则对应情绪置信度乘以 0.8 的强度系数；中性文本不进行修正，确保情绪得分能够准确反映文本情绪的强弱程度。

（4）情绪指标构建与一致性调整

计算样本企业 t-2 年所有有效新闻文本的平均综合情绪得分，作为基于 DeepSeek 模型的初始文本情绪指标，计算公式为：

中国知网 https://www.cnki.net

$$\overline{S}_{DeepSeek}{}^{G} = \frac{1}{m}\sum_{i=1}^{m} S_i{}^{G} \quad (G = T或C) \tag{4.10}$$

为确保该指标与 BOW 模型、Fin-Bert 模型构建的情绪指标具有一致性与可比性，对初始情绪指标进行标准化处理，采用与 Fin-Bert 模型一致的 Z-score 标准化方法，计算公式为：

$$EMO_{DeepSeek}{}^{G} = \frac{\overline{S}_{DeepSeek}{}^{G} - \mu}{\sigma} \quad (G = T或C) \tag{4.11}$$

将指标值映射至标准正态分布。其中，$EMO_{DeepSeek}{}^{G}$为标准化后的 DeepSeek 模型情绪指标，μ、σ含义与 Fin-Bert 模型标准化公式一致。

4.4.4 基于微调 Qwen 模型的文本情绪指标构建

Qwen 模型是阿里集团研发的开源大语言模型，具备较强的中文处理能力与灵活的微调特性，能够基于特定领域的标注数据进行微调，适配具体的任务需求。考虑到前三种模型均为通用或开源预训练模型，可能存在与本研究样本企业、研究场景适配性不足的问题，本文基于 Qwen2.5-7B-Instruct 模型，结合企业新闻文本情绪标注数据进行微调，构建适配本研究的文本情绪指标，具体构建过程分为 5 个步骤，重点突出模型微调环节。

（1）数据收集、筛选与标注

数据收集环节与前三种模型一致，选取样本企业 t-2 年有效新闻文本（含标题与内容），经过筛选、去重处理后，得到原始文本集合。为实现 Qwen 模型的有效微调，需构建情绪标注数据集，具体步骤如下：一是标注样本选取，从不在本文研究样本的集合中随机抽取 2000 条新闻文本，需要涵盖不同行业、不同情绪倾向，确保标注样本的代表性；二是标注标准制定，明确情绪标注的三级标准：正向情绪，如企业盈利增长、项目突破、政策利好等、负向情绪，如企业亏损、违约、违规、业绩下滑等、中性情绪，如企业日常公告、无实质情绪倾向的新闻等，同时明确各类情绪的判定依据，避免标注偏差；三是双重标注与一致性检验，邀请两名具备财经知识与文本标注经验的研究者，对选取的 2000 条文本进行独立标注，计算两名研究者的标注一致性系数，Kappa 系数，若 Kappa 系数大于 0.8，表明标注结果一致，可作为微调数据；若 Kappa 系数小于 0.8，对标注分歧较大的文本进行共同审核，达成一致后重新标注；四是数据集划分，将标注好的 2000 条文本按 8:2 的比例，划分为训练集 1600 条与验证集 400 条，分别用于模型微调与微调效果验证。

（2）Qwen 模型加载与配置

中国知网 https://www.cnki.net

加载开源的原始 Qwen2.5-7B-Instruct 模型，同时加载模型对应的中文 Tokenizer，配置模型的硬件环境，确保模型微调与推理的效率。初始配置模型的核心参数：批量处理大小为 16，学习率为 5e-6（避免微调过程中模型过拟合），迭代次数为 5 次，损失函数采用交叉熵损失函数，优化器采用 AdamW 优化器，提升模型微调的收敛速度与稳定性，本次微调使用了 AutoDL 云计算平台中的一台 RTX4090 服务器进行训练。

（3）Qwen 模型微调过程

模型微调是本次指标构建的核心环节，目的是让 Qwen2.5-7B-Instruct 模型适配本研究的企业新闻文本情绪识别任务，提升情绪识别的准确性与适配性，具体微调过程分为 3 个阶段：一是预微调阶段，将训练集文本输入 Qwen2.5-7B-Instruct 模型，模型基于标注的情绪类别，调整模型内部的参数权重，初步学习财经新闻文本的情绪特征与语义关联，该阶段迭代 2 次，重点让模型适应财经领域的文本风格；二是精细微调阶段，基于预微调后的模型，继续输入训练集文本，同时引入验证集进行实时验证，计算模型在验证集上的情绪识别准确率，若准确率不再提升（连续 3 个批次无提升），则停止微调，避免过拟合；该阶段迭代 3 次，重点优化模型对弱情绪、间接情绪的识别能力，适配本研究样本企业的新闻文本特点；三是微调效果验证，将验证集文本输入微调后的 Qwen2.5-7B-Instruct 模型，计算模型的情绪识别准确率、精确率、召回率与 F1 值，若四项指标均大于 90%，表明模型微调效果良好，可用于后续情绪识别任务；若未达到要求，则调整模型参数，重新进行微调，直至满足效果要求。

（4）微调后模型的情绪识别与得分计算

将样本企业 t-2 年所有预处理后的有效新闻文本批量输入微调后的 Qwen2.5-7B-Instruct 模型，预处理步骤与 DeepSeek 模型一致，模型输出每条文本对应正向、负向、中性三种情绪的概率值，经过微调后，概率值更贴合本研究的情绪标注标准。

综合情绪得分的计算方法与前三种模型保持一致，即综合情绪得分计算公式为：

$$S_i^G = P_{pos,i}^G - P_{neg,i}^G \quad (G = T \text{ 或 } C) \tag{4.12}$$

得分取值范围为[0,1]，采用交叉验证的方式，对情绪识别结果进行验证，确保得分的可靠性与准确性。

（5）文本情绪指标构建与验证

计算样本企业 t-2 年所有有效新闻文本的平均综合情绪得分，作为基于自身微调 Qwen2.5-7B-Instruct 模型的初始文本情绪指标，计算公式为：

$$\overline{S}_{Qwen}^{\ G} = \frac{1}{m}\sum_{i=1}^{m} S_i^G \quad (G = T \text{ 或 } C) \tag{4.13}$$

中国知网 https://www.cnki.net

随后，采用 Z-score 标准化方法，对该指标进行标准化处理，确保与前三种模型构建的情绪指标具有可比性，计算公式为：

$$EMO_{Qwen}{}^{G} = \frac{\overline{S}_{Qwen}{}^{G} - \mu}{\sigma} \quad (G = T \text{ 或 } C) \tag{4.14}$$

其中，$EMO_{Qwen}{}^{G}$为标准化后的 Qwen2.5-7B-Instruct 模型情绪指标，μ、σ含义与前述标准化公式一致。

4.5 财务困境预警模型的选择

为了全面评估文本信用风险指标的预警效力，本文选取了涵盖线性模型、统计学习、集成学习及深度学习四类具备代表性的机器学习算法。

4.5.1 逻辑回归模型

逻辑回归（Logistic Regression）是一种经典的二分类模型，常用于估计样本属于某一类别的概率。虽然其名称中包含“回归”，但在本文财务困境预警任务中，逻辑回归主要用于分类预测。具体而言，逻辑回归通过 Logit 连接函数刻画解释变量与事件发生概率之间的关系，其在对数几率层面具有线性结构，而在概率输出层面则通过 Sigmoid 函数实现非线性映射。作为财务困境研究中最常用的基准模型，逻辑回归 t 模型通过逻辑回归函数将变量的线性组合映射至(0,1)区间，从而估计企业被列入 ST 的概率 P。其基本形式为：

$$\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 X_{financial} + \beta_2 X_{textual} + \epsilon \tag{4.15}$$

其中，$X_{financial}$代表财务指标集，$X_{textual}$为 LLM 构建的新闻文本情绪指标。Logistic 模型的优势在于其强大的统计解释力，可作为后续复杂非线性模型的性能参照。逻辑回归通过最大化观测数据的对数似然函数来求解参数β_i，通常转化为最小化交叉熵损失函数，并采用梯度下降法进行参数优化。模型的回归系数β_i具有明确的经济意义，表示在其他自变量不变的情况下，自变量 x_i每变化一个单位，对数几率的变化量。

4.5.2 支持向量机

支持向量机（Support Vector Machine，SVM）是一种基于统计学习理论的监督学习模型，最初由 Vapnik 等于 1995 年提出。其核心原理是在特征空间中寻找一个最优的超平面，将不同类别的样本分开，并最大化两个类别之间的边界（间隔），以此提高模型的泛化能力。

中国知网 https://www.cnki.net

支持向量机的核心创新在于核函数技术。当数据在原始空间线性不可分时，支持向量机通过核函数将数据映射到高维特征空间，使得原本非线性可分的问题在新空间中变为线性可分。常见的核函数包括线性核、多项式核、高斯核（RBF 核）和 Sigmoid 核等。

在财务预警应用中，支持向量机通过核函数能够有效处理财务数据中的非线性特征，避免维数灾难问题，在处理高维数据时仍能保持较高的准确性和泛化能力 。支持向量是离超平面最近的样本点，它们决定了超平面的位置，只有支持向量对最终的分类结果有影响，这使得模型具有较好的解释性。

支持向量机基于结构风险最小化原则，旨在高维空间中寻找一个最优超平面，以最大化正常样本与 ST 样本之间的分类间隔。针对财务数据中可能存在的复杂非线性边界，本文采用高斯核函数（RBF）进行映射：

$$\min_{w,b,\xi} \frac{1}{2} \| w\|^2 + C \sum_{i=1}^{n} \xi_i \tag{4.16}$$

$$s.t. \quad y_i(w^T \phi(x_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \tag{4.17}$$

其中，C为惩罚参数，ξ_i为松弛变量。支持向量机在处理小样本、高维财务特征空间时具有较强的泛化能力。

支持向量机适用于处理中小样本和高维特征情境，能够通过核函数刻画财务指标与文本情绪指标之间可能存在的非线性边界。因此，本文将其作为非线性分类模型之一，用于检验文本情绪指标在不同模型设定下的稳健性。

4.5.3 随机森林

随机森林（Random Forest）是由 Leo Breiman 于 2001 年提出的一种集成学习算法，其核心思想是集成多个弱分类器形成一个强分类器。该模型基于决策树和套袋法（Bagging），通过构建多棵决策树进行投票或平均预测，具有抗过拟合、处理高维数据等优势 。

随机森林的随机主要体现在两个层面：样本随机和特征随机。样本随机通过 Bootstrap 抽样从原始训练集中有放回地随机抽取多个样本子集；特征随机则是在每棵决策树的每个分裂节点处，不使用全部特征，而是从所有特征中随机选择 K 个特征（通常 K 取$\sqrt{\text{总特征数}}$），再从中选择最优分裂特征。

在预测阶段，对于分类任务，随机森林采用多数投票法，即哪个类别被最多的树预测就选择哪个类别；对于回归任务，则取所有决策树预测结果的平均值。这种集成机制使得随机森林具有较强的泛化能力和对噪声数据的鲁棒性。

中国知网 https://www.cnki.net

随机森林是一种基于自助法（Bootstrap）重采样与随机特征选择的集成学习算法。它通过构建多个决策树并将其预测结果进行投票（或平均）来降低单棵树的方差。对于样本集D，其基分类器的分裂准则基于基尼指数（Gini Index）：

$$Gini(D) = 1 - \sum_{k=1}^{2} p_k^2 \tag{4.18}$$

随机森林通过 Bootstrap 抽样和随机特征选择构建多棵决策树，能够降低单棵树模型的方差并提升模型鲁棒性。由于本文特征同时包含财务指标和文本情绪指标，变量之间可能存在复杂交互关系，随机森林适合用于捕捉此类非线性关系。

4.5.4 XGBoost

XGBoost（eXtreme Gradient Boosting）是一种基于梯度提升决策树（GBDT）的机器学习算法，由陈天奇于 2016 年提出。与传统 GBDT 相比，XGBoost 进行了多项重要改进，包括使用二阶泰勒展开、引入正则化项、支持并行计算等。

XGBoost 的核心创新在于其目标函数设计。目标函数包含两部分：损失函数 L 衡量预测值与真实值的差距，正则化项Ω控制模型复杂度防止过拟合。正则化项为：

$$\Omega(f) = \gamma T + (1/2)\lambda \sum w_j{}^2 \tag{4.19}$$

其中 T 是叶子节点数量，w_j是叶子节点权重，γ和λ分别是控制叶子节点数量和 L2 正则化强度的参数。

XGBoost 是基于梯度提升树的集成学习方法，通过逐步拟合残差提升模型预测能力，并引入正则化项控制模型复杂度。该模型在表格型数据预测任务中表现较好，适合处理财务指标与文本情绪指标融合后的非线性分类问题，因此本文将其作为核心机器学习模型之一。

4.5.5 神经网络

神经网络是一种模拟人脑神经元工作机制的计算模型，通过构建多层非线性映射关系来处理复杂的数据模式。在财务预警应用中，常用的神经网络包括 BP 神经网络、径向基神经网络和多层感知机等。

BP 神经网络基于误差反向传播算法，主要包括前向传播和反向传播两个过程。输入层神经元将数据直接传递给隐藏层，隐藏层神经元对输入信号进行加权求和并通过激活函数进行非线性变换，输出信号再传递给下一层或输出层。在训练过程中，网络根据已知的财务困境样本和非财务困境样本，通过调整权重和偏置不断优化模型。

径向基神经网络采用局部响应机制，能够更敏锐地捕捉不同财务风险模式的细微特征差异，相比全局响应的神经网络方法，能够更准确地对财务风险模式进行分类和识别。

中国知网 https://www.cnki.net

本文采用多层感知器结构的神经网络，利用非线性激活函数捕捉财务困境演变过程中的深度隐含规律。模型通过反向传播算法不断优化权重矩阵W与偏置项b。单个神经元的输出可表示为：

$$y = \sigma\left(\sum_{j=1}^{m} w_j x_j + b\right) \tag{4.20}$$

其中，σ为 Sigmoid 或 ReLU 激活函数。神经网络能够自动学习财务数据与文本信号之间复杂的非线性映射关系，是识别潜在困境信号的有力工具。

神经网络能够通过多层非线性映射自动学习变量之间的复杂关系，适合识别财务困境形成过程中的潜在非线性模式。但神经网络对样本规模、参数设置和训练稳定性要求较高，因此本文将其作为复杂模型的对照方法，并结合多项评价指标综合判断其适用性。

4.6 评估指标

分类模型的性能评估需结合任务特性，避免单一指标带来的片面性。本文针对研究中的二分类任务，选取准确率（Accuracy）、召回率（Recall）、F1 分数（F1-Score）及 AUC 值四类核心指标，从整体正确性、正类识别能力、指标平衡性及综合区分能力四个维度，全面验证模型的预测有效性。在具体阐述各指标前，先明确二分类任务中混淆矩阵的核心定义，为后续指标计算与解读奠定基础。

4.6.1 二分类混淆矩阵定义

混淆矩阵（Confusion Matrix）是量化分类模型预测结果与样本真实标签差异的基础工具，通过四个核心统计量描述模型预测性能，具体定义如下：

真阳性（True Positive，TP）：样本真实标签为正类，模型预测标签也为正类，即预测正确的正类样本数；

真阴性（True Negative，TN）：样本真实标签为负类，模型预测标签也为负类，即预测正确的负类样本数；

假阳性（False Positive，FP）：样本真实标签为负类，模型预测标签为正类，即预测错误的负类样本数（第一类错误）；

假阴性（False Negative，FN）：样本真实标签为正类，模型预测标签为负类，即预测错误的正类样本数（第二类错误）。

基于上述四个统计量，可推导得出本文所用的各类评估指标，具体如下。

4.6.2 准确率

中国知网 https://www.cnki.net

准确率是最直观、最基础的分类模型评估指标，用于衡量模型预测正确的样本占全部样本的比例，反映模型的整体分类正确性。

其计算公式为：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{4.21}$$

准确率的取值范围为[0,1]，取值越接近 1，表明模型的整体预测正确率越高。该指标的优势在于计算简单、物理含义清晰，可快速反映模型的整体性能，适合样本分布相对均衡的二分类任务。但需注意其局限性：在样本不均衡场景下，准确率会失去参考价值。例如，若负类样本占比极高，即使模型将所有样本均预测为负类，也能获得较高的准确率，但模型无法识别出正类样本，完全丧失实际应用意义。因此，本文仅将准确率作为模型整体性能的辅助参考指标。

4.6.3　召回率

召回率又称查全率、灵敏度，用于衡量所有真实正类样本中，被模型正确识别出的比例，核心反映模型对正类样本的“不漏判”能力，是侧重正类识别性能的关键指标。

$$Recall = \frac{TP}{TP + FN} \tag{4.22}$$

其计算公式为：

召回率的取值范围为[0,1]，取值越接近 1，表明模型漏判正类样本的概率越低，对正类样本的识别能力越强。在本文研究任务中，正类样本具有重要的实际意义（如财务困境企业、异常样本等），假阴性的误判代价远高于假阳性，即漏判一个正类样本造成的损失，远大于误判一个负类样本的损失。因此，召回率是评价模型实用性和可靠性的核心指标之一，直接决定模型的实际应用价值。

4.6.4　F1 分数

召回率侧重正类样本的不漏判，而精确率（Precision）侧重正类样本的不误判，二者往往存在权衡关系——提高召回率可能导致精确率下降，反之亦然。F1 分数作为精确率与召回率的调和平均数，可综合平衡二者的性能，避免单一指标偏向带来的评估偏差，更全面地反映模型的分类效果。

$$Precision = \frac{TP}{TP + FP} \tag{4.23}$$

首先定义精确率，其计算公式为：

中国知网　https://www.cnki.net

基于精确率和召回率，F1 分数的计算公式为：

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{4.24}$$

F1 分数的取值范围为[0,1]，取值越高，表明模型的精确率与召回率越均衡，综合分类性能越好。与算术平均数相比，调和平均数更能惩罚极端值——若模型的精确率或召回率极低，F1 分数会显著下降，因此其更适合样本不均衡场景下的模型评估。在本文研究中，F1 分数可综合衡量模型不误判、不漏判的双重能力，弥补单一指标的不足，作为核心辅助评估指标。

4.6.5 AUC

AUC 值即 ROC 曲线（Receiver Operating Characteristic Curve，受试者工作特征曲线）下的面积，是二分类模型最稳健、最常用的综合评估指标，核心反映模型对正类样本与负类样本的区分能力，且不依赖于分类阈值的选择。

ROC 曲线以假正例率（False Positive Rate，FPR）为横轴，以真正例率（True Positive Rate，TPR）为纵轴绘制而成，其中：

假正例率（FPR）反映负类样本被误判为正类的比例，计算公式为：

$$FPR = \frac{FP}{FP + TN} \tag{4.25}$$

真正例率（TPR）与召回率等价，反映正类样本被正确识别的比例，计算公式为：

$$TPR = \frac{TP}{TP + FN} = Recall \tag{4.26}$$

AUC 值的统计意义可解读为：随机抽取一个正类样本和一个负类样本，模型对正类样本的预测得分高于负类样本预测得分的概率。其取值范围为[0,1]，AUC 值的核心优势在于对样本不均衡不敏感，且不受分类阈值的影响——无论样本分布如何，其均可客观反映模型的内在区分能力，因此成为本文研究中最核心的综合评估指标，用于全面验证模型的预测性能。

中国知网 https://www.cnki.net

5　实证结果与分析

5.1　描述性统计

表 5.1 描述性统计

Tab. 5.1 Descriptive statistics

变量名	样本量	均值	标准差	最小值	最大值
ROA	2158	-0.06	0.20	-1.22	0.27
ROE	2158	-0.35	1.44	-10.91	1.11
RE_TA	2158	-0.29	1.16	-8.62	0.53
GPM	2158	0.24	0.19	-0.25	0.86
NPM	2158	-0.35	1.35	-10.52	0.90
WC_TA	2158	0.00	1.08	-7.37	0.95
Liquid	2158	2.16	2.57	0.12	19.60
Quick	2158	1.75	2.41	0.07	19.56
Cash_Ratio	2158	0.59	0.96	0.00	8.80
DAR	2158	0.52	0.28	0.05	1.44
DER	2158	2.69	7.24	-9.88	59.73
BVE_TL	2158	1.99	2.79	-0.31	20.83
ICR	1667	-0.68	753.40	-10917.82	25873.49
TAT	2158	0.52	0.40	0.02	2.31
ITR	2158	20.36	89.73	0.05	867.26
ART	2158	35.57	130.47	0.41	1048.34
FCF	2158	80.74	13.60	-60.16	597.20
CashEquivalentsTurnover	2158	12.18	25.00	0.15	196.42
CashFlowVolatility	2158	0.06	0.06	0.00	0.38
TAG	2158	0.04	0.34	-0.64	1.92
RG	2158	0.74	3.93	-2.01	38.30
NPG	1209	-41.69	618.18	-19115.20	1345.55
News_Count	2158	25.66	37.83	0.00	592.00
ST	2158	0.50	0.50	0.00	1.00
Title_Bow	2158	0.23	0.17	0.00	1.00
Content_Bow	2158	0.31	0.19	0.00	1.00
Title_Bert	2158	0.26	0.15	0.00	1.00
Content_Bert	2158	0.33	0.19	0.00	1.00
Title_Qwen	2158	0.24	0.18	0.00	1.00
Content_Qwen	2158	0.29	0.20	0.00	1.00
Title_Deepseek	2158	0.29	0.22	0.00	1.00

中国知网　https://www.cnki.net

续表 5.1

变量名	样本量	均值	标准差	最小值	最大值
Title_Qwen_sft	2158	0.33	0.24	0.00	1.00
Content_Deepseek	2158	0.27	0.19	0.00	1.00
Content_Qwen_sft	2158	0.31	0.26	0.00	1.00

注：数据来源于国泰安数据库

表 5.1 报告了本文主要变量的描述性统计结果。样本共包含 2158 个公司—年份观测值，其中财务困境变量为虚拟变量，均值为 0.50，表明样本中财务困境企业与非财务困境企业数量大致相当，有助于缓解类别不平衡问题，对后续预测模型的估计具有积极意义。

从财务指标的描述性统计结果来看，样本企业整体盈利能力偏弱。资产收益率和净资产收益率的均值分别为−0.06 和−0.35，且最小值分别达到−1.22 和−10.91，显示部分企业存在较为严重的亏损状况。留存收益占总资产比率均值为−0.29，进一步表明样本中存在较多累计亏损企业，这与本文以 ST 企业刻画财务困境的研究背景相一致。

在偿债能力与资本结构方面，资产负债率均值为 0.52，负债权益比率均值为 2.69，但其标准差和极值较大，表明不同企业在资本结构安排上存在显著差异。利息保障倍数的波动尤为明显，最小值和最大值分别达到−10917.82 和 25873.49，反映出部分企业经营成果和利息负担极不稳定，具有典型的财务风险特征。

营运能力指标同样呈现出较强的异质性。总资产周转率均值为 0.52，而存货周转率和应收账款周转率的标准差和最大值较高，说明企业在经营效率和营运管理水平方面差异较大。现金流相关指标中，自由现金流均值为正，但波动幅度较大，部分企业出现大额负现金流，进一步印证了样本中企业经营状况的不稳定性。

在成长性和风险指标方面，总资产增长率和营业收入增长率均值为正，但其分布范围较广，部分企业存在显著的负增长情形。净利润增长率的极端取值和较大的标准差表明，盈利增长在样本企业间呈现高度不均衡状态。

在文本与情绪相关变量方面，样本企业在 t−2 年期间平均新闻数量（News_Count）为 25.66 篇，但最大值达到 592 篇，显示不同企业受到媒体关注程度存在明显差异。基于新闻文本构建的情绪指标在不同模型和文本层级下呈现出不同的分布特征。总体而言，基于预训练语言模型 BERT、Qwen 及 DeepSeek 构建的情绪指标在均值和标准差上普遍高于基于 BOW 的情绪指标，且经过微调的 Qwen_SFT 对应的情绪指标波动幅度更大，表明其在刻画新闻文本情绪信息方面具有更强的区分能力和信息承载度。

中国知网 https://www.cnki.net

总体来看，描述性统计结果表明，样本企业在盈利能力、偿债能力、营运效率及现金流状况等方面存在显著差异，同时新闻文本情绪指标在不同构建方法下呈现出明显的分布异质性。这些特征为后续基于财务指标与文本情绪指标相结合的财务困境预警模型分析提供了良好的数据基础。

5.2　基准模型的选择

为系统评估财务指标与新闻文本情绪信息在财务困境预警中的预测效果，本文构建以传统财务指标为基础的基准模型，并在此基础上逐步引入基于新闻文本构建的情绪指标，比较不同情绪建模方法与预测模型组合下的预测表现。

在基准设定中，解释变量包括企业在 t−2 年度的 20 个财务指标，涵盖盈利能力、偿债能力、营运能力、现金流状况以及成长性等多个维度；被解释变量为企业在 t 年是否陷入财务困境，若企业在 t 年被认定为 ST，则取值为 1，否则为 0。该设定在一定程度上模拟了现实中基于历史信息对企业未来财务风险进行提前预警的决策场景。

在文本信息的处理方面，本文以企业 t−2 年度公开新闻文本为数据来源，分别基于词袋模型（BOW）以及多种预训练语言模型构建情绪指标。其中，词袋模型作为文本建模的基础方法，用以刻画新闻文本中情绪词的出现频率；预训练语言模型包括 FinBERT、DeepSeek 以及 Qwen，并进一步对 Qwen 模型进行领域微调，以生成更具针对性的财务文本情绪指标。通过将不同文本情绪指标分别引入预测模型，本文能够比较不同情绪建模方法在财务困境预警中的相对有效性。

在预测模型选择方面，本文同时采用传统统计模型与机器学习模型进行对比分析。具体而言，预测模型包括逻辑回归、支持向量机、随机森林、XGBoost 以及神经网络模型。上述模型在假设形式、非线性刻画能力及对高维特征的处理方式方面存在差异，有助于全面检验文本情绪指标在不同建模框架下的适用性与稳健性。

在模型评价方面，本文主要采用 AUC 作为核心评价指标，并辅以准确率和 F1 值进行综合评估。相较于单一的分类准确率，AUC 指标能够在不同分类阈值下衡量模型对正负样本的整体区分能力，尤其适用于可能存在样本比例不均衡的财务困境预测问题，因此被广泛应用于相关研究。后续实证结果部分将重点报告各模型在测试样本上的 AUC 表现，并对不同模型和情绪指标组合的预测效果进行比较分析。

5.3　模型预测结果分析

5.3.1　基于仅财务特征的预测结果分析

中国知网　https://www.cnki.net

作为对照基准，本文首先在不引入任何文本信息的情况下，仅使用企业 t–2 年度的财务指标构建财务困境预警模型，并比较不同预测模型的预测表现。该设定有助于刻画传统财务特征在财务困境识别中的基础预测能力，并为后续引入新闻文本情绪指标后的效果比较提供参考基准。

图 5.1 展示了仅基于财务特征条件下，不同预测模型的 ROC 曲线对比结果。从整体来看，各模型的 ROC 曲线均显著优于随机猜测基准线，表明传统财务指标在识别企业未来财务困境方面具有一定的判别能力。其中，随机森林模型的 ROC 曲线整体位于其他模型之上，其 AUC 值达到 0.822，表现最为突出；支持向量机和 XGBoost 模型的 AUC 值分别为 0.815 和 0.802，也表现出较为稳定的预测能力。相比之下，逻辑回归模型的 AUC 值为 0.794，神经网络模型的 AUC 值为 0.749，预测效果相对较弱。

进一步从多维评价指标进行比较，表 5.2 报告了不同模型在 AUC、准确率、召回率和 F1 值方面的具体表现。结果显示，随机森林模型在准确率、召回率和 F1 值等指标上同样取得了最优或并列最优的结果，其召回率和 F1 值均达到 0.745，表明该模型在识别财务困境企业方面具有较强的稳定性和综合判别能力。逻辑回归和支持向量机模型在准确率和 F1 值方面表现相对接近，但在召回率方面略逊于随机森林模型。神经网络模型在各项指标上的表现均相对较低，可能与样本规模及财务特征的非线性结构复杂性有关。

总体而言，仅基于财务特征的预测结果表明，传统财务指标能够在一定程度上反映企业的财务风险状况，但不同预测模型之间的性能差异较为明显，且整体预测能力仍存在提升空间。这一结果为后续引入新闻文本构建的情绪指标提供了现实动机：即在财务指标信息相对有限的情况下，非结构化文本信息有望作为重要补充，进一步提升财务困境预警模型的预测效果。

表 5.2 仅基于财务特征的预测结果

Tab. 5.2 Prediction based on financial characteristics only

模型	AUC	准确率	召回率	F1 分数
Logistic	0.794	0.738	0.675	0.720
SVM	0.815	0.733	0.679	0.718
随机森林	0.822	0.745	0.745	0.745
XGBoost	0.802	0.731	0.698	0.722
神经网络	0.749	0.700	0.623	0.675

中国知网 https://www.cnki.net

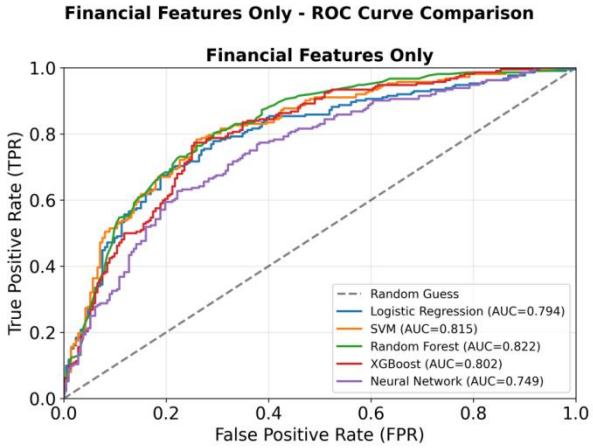


图 5.1 基于仅财务特征的 ROC 曲线

Fig. 5.1 ROC Curve Based on Financial Characteristics Only

5.3.2 基于 BOW 情绪指标的预测结果分析

在基准财务特征的基础上，本文进一步引入基于 BOW 模型构建的新闻文本情绪指标，以检验简单文本表示方法在财务困境预警中的增量预测能力。具体而言，本文分别基于新闻标题和新闻正文内容构建情绪指标，并将其与财务特征相结合，比较不同预测模型下的预测表现。

图 5.2 展示了在引入 BOW 情绪指标后，不同预测模型的 ROC 曲线对比结果。从整体来看，相较于仅使用财务特征的基准模型，引入 BOW 情绪指标后，各预测模型的 ROC 曲线整体向左上方移动，AUC 值普遍有所提升，表明即使采用较为简单的文本建模方法，新闻文本中所包含的情绪信息仍能够为财务困境识别提供有价值的补充。

从具体结果来看，在加入 BOW 模型根据新闻标题构建的情绪指标后，随机森林模型的 AUC 值提升至 0.835，较仅使用财务特征时进一步提高，在所有预测模型中表现最优；支持向量机和 XGBoost 模型的 AUC 值分别为 0.819 和 0.816，也表现出较为稳定的预测能力。逻辑回归模型的 AUC 值为 0.803，神经网络模型的 AUC 值为 0.754，整体排序与仅使用财务特征时基本一致。

在加入 BOW 模型根据新闻内容构建的情绪指标后，各模型的预测性能同样得到一定提升。逻辑回归、支持向量机、随机森林和 XGBoost 模型的 AUC 值分别达到 0.807、0.821、0.824 和 0.823，均高于对应的基准模型结果。相较于基于标题构建的情绪指标，基于新闻正文内容构建的 BOW 情绪指标在部分模型中表现略优，表明正文文本可能包含更为丰富的风险相关信息。

中国知网　https://www.cnki.net

进一步从准确率、召回率和 F1 值等综合评价指标来看，随机森林和 XGBoost 模型在引入 BOW 情绪指标后均取得了较为均衡的表现。其中，加入 BOW 模型根据新闻内容构建的情绪指标后，XGBoost 模型的召回率达到 0.77，F1 值为 0.76，显示其在识别财务困境企业方面具有较强的敏感性和整体判别能力。相比之下，神经网络模型在引入 BOW 情绪指标后虽有所改善，但整体提升幅度相对有限。

总体而言，基于 BOW 方法构建的情绪指标能够在一定程度上提升财务困境预警模型的预测性能，验证了新闻文本情绪信息的有效性。然而，由于词袋模型难以刻画上下文语义关系，其预测能力提升仍相对有限。

表 5.3 基于 BOW 情绪指标的预测结果

Tab. 5.3 Prediction results based on BOW emotion index

特征组	模型	AUC	准确率	召回率	F1 分数
财务+title_bow	Logistic	0.803	0.729	0.670	0.712
财务+title_bow	SVM	0.819	0.738	0.684	0.723
财务+title_bow	随机森林	0.835	0.755	0.750	0.754
财务+title_bow	XGBoost	0.816	0.767	0.750	0.763
财务+title_bow	神经网络	0.754	0.696	0.665	0.686
财务+content_bow	Logistic	0.807	0.738	0.670	0.719
财务+content_bow	SVM	0.821	0.750	0.698	0.736
财务+content_bow	随机森林	0.824	0.755	0.750	0.754
财务+content_bow	XGBoost	0.823	0.757	0.769	0.760
财务+content_bow	神经网络	0.762	0.698	0.599	0.665

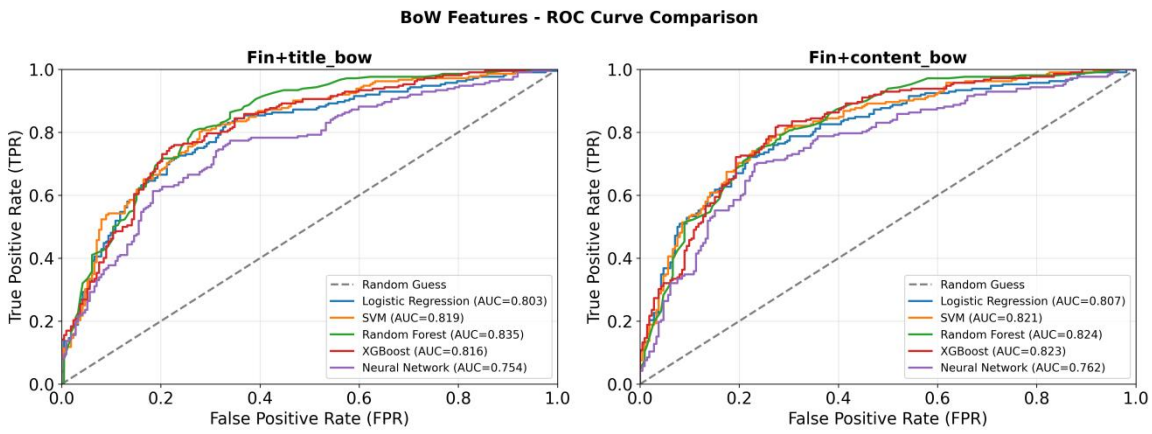


图 5.2 基于 BOW 模型构建的情绪指标 ROC 曲线

Fig. 5.2 ROC Curve of Emotional Index Based on BOW Model

中国知网 https://www.cnki.net

5.3.3　基于 Fin-Bert 情绪指标的预测结果分析

在基于 BOW 模型构建情绪指标的基础上，本文进一步引入预训练语言模型 Fin-Bert，对新闻文本进行深层语义建模，并构建相应的情绪指标，以检验上下文语义信息在财务困境预警中的预测价值。与前文保持一致，本文分别基于新闻标题和新闻正文内容构建情绪指标，并将其与财务特征相结合进行比较分析。

图 5.3 展示了在引入 Fin-Bert 情绪指标后，不同预测模型的 ROC 曲线对比结果。整体来看，相较于基于 BOW 情绪指标的模型，基于 Fin-Bert 构建的情绪指标使各预测模型的 ROC 曲线进一步向左上方移动，AUC 值整体提升，表明 Fin-Bert 模型在捕捉新闻文本中隐含的情绪与风险语义方面具有更强能力。

在加入 Fin-Bert 模型根据新闻标题构建的情绪指标后，各预测模型均取得了较为稳定的预测表现。其中，支持向量机和随机森林模型的 AUC 值分别为 0.824 和 0.823，XGBoost 模型的 AUC 值为 0.817，均高于对应的 BOW 结果。逻辑回归模型的 AUC 值为 0.809，神经网络模型的 AUC 值为 0.763，整体性能排序与前述实验结果保持一致。

在加入 Fin-Bert 模型根据新闻内容构建的情绪指标后，模型预测性能进一步提升。随机森林模型的 AUC 值达到 0.842，在所有模型中表现最优；支持向量机和 XGBoost 模型的 AUC 值均为 0.833，显示出较强的稳定性和判别能力。逻辑回归模型的 AUC 值为 0.825，亦显著高于仅使用财务特征及 BOW 情绪指标的结果。上述结果表明，相较于新闻标题，基于新闻正文构建的 Fin-Bert 情绪指标能够更充分地挖掘文本中的风险相关信息。

进一步从准确率、召回率和 F1 值等综合评价指标来看，基于 Fin-Bert 情绪指标的模型在多项指标上均取得了同步提升。其中，在引入 Fin-Bert 情绪指标后，随机森林模型的准确率和 F1 值均达到了 0.762，召回率为 0.764，体现出较为均衡的预测能力。XGBoost 模型在该设定下的 F1 值亦达到 0.752，表明其在识别财务困境企业方面具有较强的综合表现。

总体而言，基于 Fin-Bert 构建的情绪指标相较于 BOW 方法显著提升了财务困境预警模型的预测性能，验证了深度语义信息在企业风险识别中的重要作用。然而，尽管 Fin-Bert 能够有效捕捉上下文语义特征，其预测性能在不同模型之间仍存在一定差异。

表 5.4 基于 Fin-Bert 情绪指标的预测结果

Tab. 5.4 Prediction results based on Fin-Bert sentiment index

特征组	模型	AUC	准确率	召回率	F1 分数
财务+title_bert	Logistic	0.809	0.741	0.703	0.730

中国知网　https://www.cnki.net

续表 5.4

特征组	模型	AUC	准确率	召回率	F1 分数
财务+title_bert	SVM	0.824	0.745	0.698	0.733
财务+title_bert	随机森林	0.823	0.743	0.755	0.746
财务+title_bert	XGBoost	0.817	0.750	0.755	0.751
财务+title_bert	神经网络	0.763	0.710	0.632	0.685
财务+content_bert	Logistic	0.825	0.757	0.722	0.748
财务+content_bert	SVM	0.833	0.762	0.717	0.751
财务+content_bert	随机森林	0.842	0.762	0.764	0.762
财务+content_bert	XGBoost	0.833	0.755	0.745	0.752
财务+content_bert	神经网络	0.779	0.705	0.656	0.690

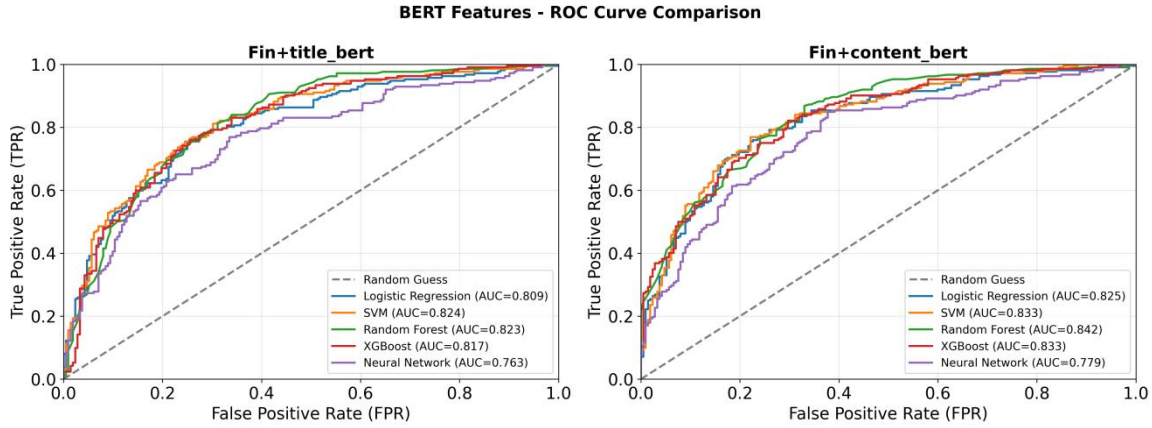


图 5.3 基于 BERT 模型构建的情绪指标 ROC 曲线

Fig. 5.3 ROC Curve of Emotional Index Based on BERT Model

5.3.4 基于 Qwen 情绪指标的预测结果分析

在前文基于 BERT 构建情绪指标的基础上，本文进一步引入大规模通用预训练语言模型 Qwen，对新闻文本进行更高层次的语义建模，并构建相应的情绪指标，以检验更强语义表示能力在财务困境预警中的作用。与前述实验保持一致，本文分别基于新闻标题和新闻正文内容构建情绪指标，并将其与财务特征相结合进行比较分析。

图 5.4 展示了在引入 Qwen 情绪指标后，不同预测模型的 ROC 曲线对比结果。整体来看，相较于基于 BERT 情绪指标的模型，Qwen 构建的情绪指标使各预测模型的 ROC 曲线进一步向左上方移动，AUC 值出现明显提升，表明更大规模预训练模型在捕捉新闻文本中复杂语义和风险信号方面具有更强能力。

中国知网 https://www.cnki.net

在加入 Qwen 模型根据新闻标题构建的情绪指标后，各预测模型均取得了较为稳健的预测表现。支持向量机和随机森林模型的 AUC 值分别为 0.836 和 0.835，逻辑回归模型的 AUC 值为 0.825，均高于对应的 BERT 情绪指标结果。神经网络模型的 AUC 值为 0.781，虽相对较低，但较前述模型设定亦有所提升。

在加入 Qwen 模型根据新闻内容构建的情绪指标后，模型预测性能进一步显著提升。随机森林和 XGBoost 模型的 AUC 值分别达到 0.860 和 0.862，在所有实验设定中处于较高水平；支持向量机和逻辑回归模型的 AUC 值亦分别达到 0.848 和 0.856，显示出较强且稳定的判别能力。上述结果表明，基于新闻正文构建的 Qwen 情绪指标能够更充分地挖掘文本中的深层风险信息。

从准确率、召回率和 F1 值等综合评价指标来看，基于 Qwen 情绪指标的模型同样表现出显著优势。在引入 Qwen 模型根据新闻内容构建的情绪指标后，XGBoost 模型的 F1 值达到 0.773，准确率为 0.781，召回率为 0.745；随机森林模型的 F1 值为 0.764，召回率达到 0.750，表明其在识别财务困境企业方面具有较为均衡的预测能力。相比之下，神经网络模型在各项指标上的提升幅度仍相对有限，但整体趋势与其他模型一致。

总体而言，基于 Qwen 构建的情绪指标在财务困境预警中的预测效果显著优于基于 BERT 和 BOW 的情绪指标，验证了更大规模预训练语言模型在企业风险识别任务中的应用潜力。然而，尽管 Qwen 已表现出较强的预测能力，其作为通用预训练模型仍未针对财务语境进行专门优化。

表 5.5 基于 Qwen 情绪指标的预测结果

Tab. 5.5 Prediction results based on Qwen emotion index

特征组	模型	AUC	准确率	召回率	F1 分数
财务+title_qwen	Logistic	0.825	0.750	0.722	0.743
财务+title_qwen	SVM	0.836	0.752	0.717	0.743
财务+title_qwen	随机森林	0.835	0.738	0.726	0.735
财务+title_qwen	XGBoost	0.815	0.731	0.712	0.726
财务+title_qwen	神经网络	0.781	0.705	0.660	0.691
财务+content_qwen	Logistic	0.856	0.774	0.722	0.761
财务+content_qwen	SVM	0.848	0.759	0.726	0.751
财务+content_qwen	随机森林	0.860	0.769	0.750	0.764
财务+content_qwen	XGBoost	0.862	0.781	0.745	0.773
财务+content_qwen	神经网络	0.808	0.731	0.698	0.722

中国知网　https://www.cnki.net

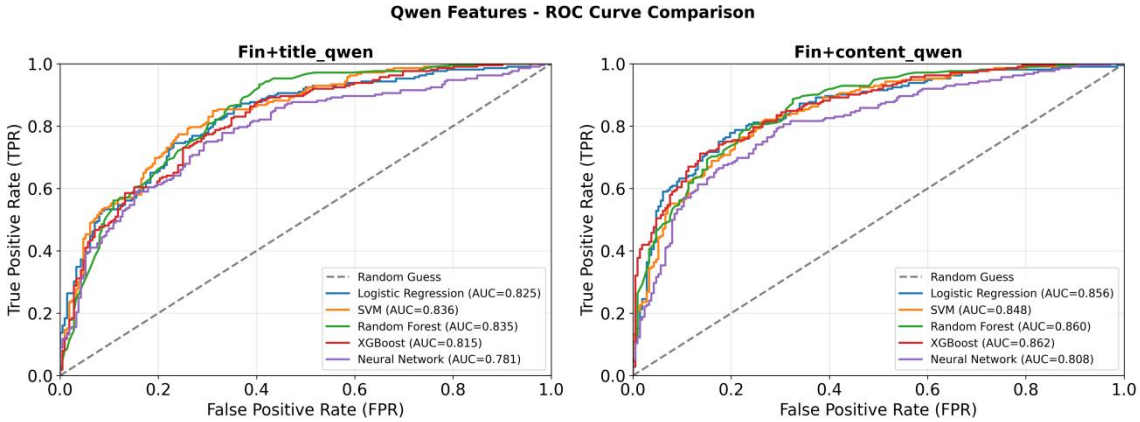


图 5.4 基于 Qwen 模型构建的情绪指标 ROC 曲线

Fig. 5.4 ROC Curve of Emotional Indicators Based on Qwen Model

5.3.5 基于 DeepSeek 情绪指标的预测结果分析

在前文基于 BERT 与 Qwen 构建情绪指标的基础上，本文进一步引入 DeepSeek 预训练语言模型，对新闻文本进行情绪建模，以检验不同大规模语言模型在财务困境预警任务中的表现差异。与前述实验保持一致，本文分别基于新闻标题和新闻正文内容构建情绪指标，并将其与财务特征相结合进行比较分析。

图 5.5 展示了在引入 DeepSeek 情绪指标后，不同预测模型的 ROC 曲线对比结果。整体来看，相较于基于 BERT 情绪指标的模型，DeepSeek 构建的情绪指标进一步提升了模型的整体预测性能，其 ROC 曲线在多数预测模型下均明显优于 BERT 情绪指标对应结果，并在部分设定下接近甚至达到 Qwen 情绪指标的预测水平。

在加入 DeepSeek 模型根据新闻标题构建的情绪指标后，各预测模型均取得了较为稳健且均衡的预测表现。逻辑回归和支持向量机模型的 AUC 值均为 0.840，随机森林模型的 AUC 值为 0.834，XGBoost 模型的 AUC 值为 0.825，神经网络模型的 AUC 值为 0.824。相较于基于 BERT 标题情绪指标的结果，DeepSeek 在各模型下均实现了不同程度的提升，表明其在标题文本语义理解方面具有更强的判别能力。

在加入 DeepSeek 模型根据新闻内容构建的情绪指标后，模型预测性能进一步显著提升。逻辑回归和 XGBoost 模型的 AUC 值均达到 0.883，随机森林模型的 AUC 值为 0.879，支持向量机模型的 AUC 值为 0.862，整体处于较高水平。该结果表明，基于新闻正文构建的 DeepSeek 情绪指标能够更充分地挖掘文本中的风险相关语义信息，并显著增强模型对财务困境企业的识别能力。

从准确率、召回率和 F1 值等综合评价指标来看，DeepSeek 情绪指标同样表现出较强的稳定性和一致性。在加入 DeepSeek 模型根据新闻内容构建的情绪指标后，随机森

中国知网 https://www.cnki.net

林模型的召回率达到 0.783，F1 值为 0.787；XGBoost 模型的 F1 值为 0.789，准确率为 0.795，显示其在不同评价维度下均具备较为突出的综合表现。相比之下，神经网络模型在引入 DeepSeek 情绪指标后虽在 AUC 上有所提升，但其召回率和 F1 值相对较低，表明其在该任务中的稳定性仍有待进一步优化。

总体而言，基于 DeepSeek 构建的情绪指标在财务困境预警中的预测效果显著优于 BERT 情绪指标，并在多数设定下接近基于 Qwen 构建的情绪指标结果，验证了不同大规模预训练语言模型在企业风险识别任务中的有效性。同时，该结果也表明，在未进行专门领域微调的情况下，不同通用语言模型在文本情绪建模能力上仍存在差异。

表 5.6 基于 DeepSeek 情绪指标的预测结果

Tab. 5.6 Prediction results based on DeepSeek emotion indicators

特征组	模型	AUC	准确率	召回率	F1 分数
财务+title_deepseek	Logistic	0.840	0.759	0.736	0.754
财务+title_deepseek	SVM	0.840	0.771	0.750	0.766
财务+title_deepseek	随机森林	0.834	0.774	0.778	0.775
财务+title_deepseek	XGBoost	0.825	0.752	0.745	0.751
财务+title_deepseek	神经网络	0.824	0.759	0.717	0.749
财务+content_deepseek	Logistic	0.883	0.807	0.750	0.795
财务+content_deepseek	Logistic	0.883	0.807	0.750	0.795
财务+content_deepseek	SVM	0.862	0.769	0.741	0.762
财务+content_deepseek	随机森林	0.879	0.788	0.783	0.787
财务+content_deepseek	XGBoost	0.883	0.795	0.769	0.789
财务+content_deepseek	神经网络	0.808	0.715	0.557	0.661

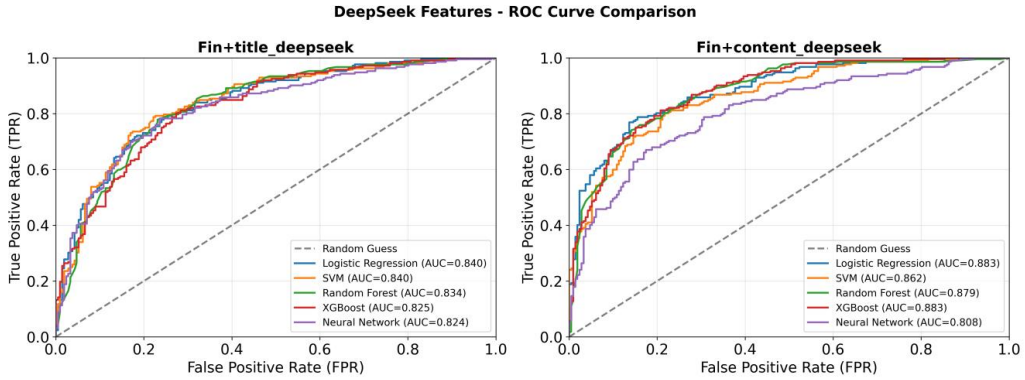


图 5.5 基于 DeepSeek 模型构建的情绪指标 ROC 曲线

Fig. 5.5 ROC Curve of Emotional Indicators Based on DeepSeek Model

中国知网　https://www.cnki.net

5.3.6 基于微调的 Qwen 情绪指标的预测结果分析

在前文基于通用预训练语言模型 Qwen 构建情绪指标的基础上，本文进一步对 Qwen 模型进行领域微调，以增强模型对财务新闻语境中情绪与风险信息的识别能力。在此基础上，本文构建基于微调 Qwen 的情绪指标，并将其与财务特征相结合，系统评估其在财务困境预警任务中的预测效果。与前述实验保持一致，情绪指标分别基于新闻标题和新闻正文内容构建。

图 5.6 展示了在引入 Qwen-SFT 情绪指标后，不同预测模型的 ROC 曲线对比结果。整体来看，相较于未微调的 Qwen 模型以及其他预训练语言模型，Qwen-SFT 构建的情绪指标使各预测模型的 ROC 曲线进一步向左上方移动，AUC 值整体达到本文所有实验设定中的最高水平，表明领域微调能够显著提升模型对财务文本情绪信息的刻画能力。

在加入 Qwen-SFT 模型根据新闻标题构建情绪指标后，各预测模型均取得了较为突出的预测表现。其中，XGBoost 模型的 AUC 值达到 0.888，在所有模型中表现最优；随机森林和逻辑回归模型的 AUC 值分别为 0.882 和 0.881，支持向量机模型的 AUC 值为 0.860。与此同时，各模型在准确率、召回率和 F1 值等指标上亦表现出较强的一致性，表明基于新闻标题构建的 Qwen-SFT 情绪指标已能够有效识别企业潜在财务风险信号。

在加入 Qwen-SFT 模型根据新闻内容构建情绪指标后，模型预测性能同样保持在较高水平。逻辑回归、随机森林和 XGBoost 模型的 AUC 值分别为 0.878、0.868 和 0.865，支持向量机模型的 AUC 值为 0.863。尽管部分模型的 AUC 值略低于标题文本设定，但在准确率、召回率和 F1 值等综合指标上仍表现稳健。例如，在该设定下，随机森林模型的召回率达到 0.807，F1 值为 0.792，XGBoost 模型的 F1 值为 0.770，显示其在财务困境识别中具有较强的综合判别能力。

从整体比较来看，基于 Qwen-SFT 构建的情绪指标在不同预测模型和不同文本层级下均取得了稳定且显著的性能提升，其预测效果不仅显著优于基于 BOW、BERT 和 DeepSeek 构建的情绪指标，也在多数设定下优于未微调的 Qwen 模型。该结果充分表明，针对财务新闻语境对大规模语言模型进行领域微调，有助于进一步释放文本情绪信息在财务困境预警中的预测价值。

总体而言，Qwen-SFT 情绪指标在本文所有实验设定中表现最为优异，验证了领域适配和深度语义建模在企业风险识别任务中的重要作用。该发现不仅为将大语言模型引入财务困境预警研究提供了有力的经验证据，也为后续相关研究在模型选择和文本建模方法上的改进提供了重要参考。

中国知网 https://www.cnki.net

表 5.7 基于 Qwen-SFT 情绪指标的预测结果

Tab. 5.7 Prediction results based on DeepSeek emotion indicators

特征组	模型	AUC	准确率	召回率	F1 分数
财务+title_qwen_sft	Logistic	0.881	0.774	0.722	0.761
财务+title_qwen_sft	SVM	0.860	0.783	0.75	0.776
财务+title_qwen_sft	随机森林	0.882	0.800	0.802	0.800
财务+title_qwen_sft	XGBoost	0.888	0.807	0.75	0.795
财务+title_qwen_sft	神经网络	0.826	0.764	0.75	0.761
财务+content_qwen_sft	Logistic	0.878	0.776	0.741	0.768
财务+content_qwen_sft	SVM	0.863	0.785	0.755	0.779
财务+content_qwen_sft	随机森林	0.868	0.788	0.807	0.792
财务+content_qwen_sft	XGBoost	0.865	0.774	0.759	0.770
财务+content_qwen_sft	神经网络	0.851	0.767	0.764	0.766

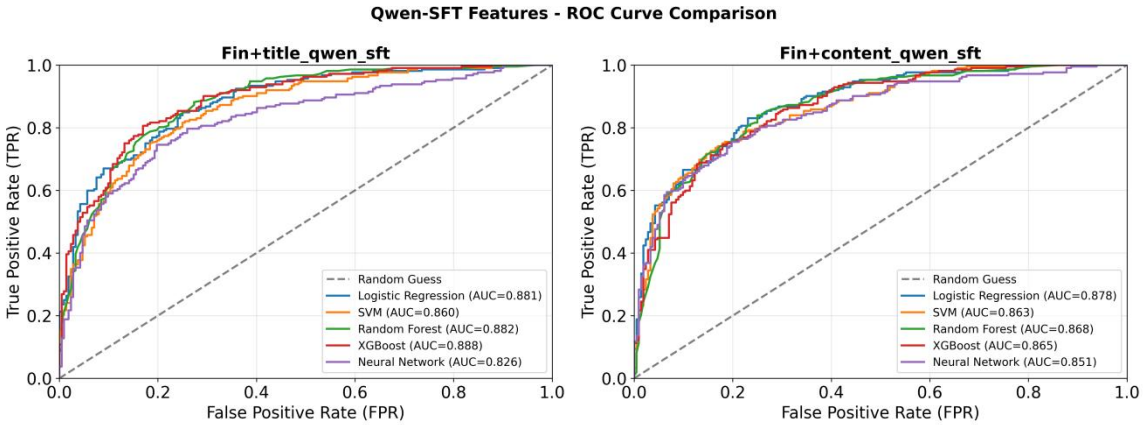


图 5.6 基于 Qwen-SFT 模型构建的情绪指标 ROC 曲线

Fig. 5.6 ROC Curve of Emotional Indicators Based on DeepSeek Model

5.4　不同情绪指标构建方法的综合比较与讨论

与传统财务预警方法相比，基于大语言模型的文本情绪方法并不是对财务指标的简单替代，而是对传统财务信息的补充。传统财务指标能够反映企业已经形成的经营结果和财务状态，但在风险早期识别方面存在一定滞后性；新闻文本情绪则能够反映市场和媒体对企业经营事件、融资压力、治理风险及声誉变化的即时评价，具有更强的前瞻性。与此同时，大语言模型方法也存在计算成本较高、提示词敏感性、文本噪声和解释性不

中国知网　https://www.cnki.net

足等问题。因此，本文采用财务指标与文本情绪指标融合的框架，既保留传统财务指标的稳定性和可解释性，又利用大语言模型增强对外部软信息和隐性风险信号的识别能力。

基于前文实证结果，本文系统比较了不同情绪指标构建方法在财务困境预警任务中的预测表现，包括基于词袋模型、预训练语言模型 BERT、DeepSeek、Qwen 以及经领域微调的 Qwen-SFT。通过在多种预测模型和多项评价指标下的综合分析，可以较为清晰地刻画不同文本建模方法在企业风险识别中的相对优势与适用边界。

首先，从整体性能表现来看，情绪指标构建方法呈现出明显的层级特征。基于 BOW 方法构建的情绪指标相较于仅使用财务特征的基准模型能够实现一定程度的性能提升，验证了新闻文本中情绪信息的预测价值；但其提升幅度相对有限。相比之下，基于深度语义建模的预训练语言模型在多数预测模型下均显著优于 BOW 方法，表明上下文语义信息在财务困境预警中具有重要作用。

其次，在不同预训练语言模型之间，模型规模和语义表示能力的提升能够带来更为明显的预测性能改善。实证结果显示，DeepSeek 和 Qwen 构建的情绪指标整体优于 Fin-Bert，尤其在基于新闻正文构建情绪指标时，其 AUC、召回率和 F1 值均处于较高水平，说明更大规模的预训练模型在捕捉复杂语义关系和隐含风险信号方面具有优势。

更为重要的是，本文的实证结果进一步表明，针对财务新闻语境进行领域微调的小模型在专业任务中的表现，能够在很大程度上逼近甚至达到通用大模型的预测水平。具体而言，经微调后的 Qwen-SFT 模型在多数实验设定下取得了本文所有模型中的最优或次优预测结果，其整体性能不仅显著优于未微调的 Qwen 模型，也与 DeepSeek 等通用大模型在财务困境预警任务中的表现高度接近。这一发现表明，在特定专业领域中，模型是否经过有效的领域适配，往往比模型规模本身更为关键。

从方法论角度看，上述结果具有重要启示意义。一方面，通用大模型凭借其强大的通用语义理解能力，在缺乏领域标注数据的情况下仍能取得较好效果；另一方面，通过引入相对有限的领域监督信息对模型进行微调，可以显著增强模型对专业语境中关键信息的识别能力，从而以较低的模型复杂度和计算成本，获得与通用大模型相近的预测性能。这对于金融等专业领域中模型的实际应用具有重要现实意义。

综合而言，本文的实证结果表明，文本情绪指标的预测能力不仅取决于模型规模和结构，更依赖于模型与具体应用场景之间的匹配程度。经领域微调的小模型在专业任务中具备显著竞争力，为在财务困境预警等实际应用场景中平衡模型性能与实现成本提供了新的思路，也为后续研究在模型选择与文本建模策略方面提供了有益参考。

5.5 机器学习可解释性分析

中国知网 https://www.cnki.net

5.5.1　基于 SHAP 的可解释性分析

为进一步揭示模型预测财务困境的内在机制，本文选取预测性能最优的 XGBoost 模型作为研究对象，采用 SHAP（SHapley Additive exPlanations）方法对模型进行可解释性分析。SHAP 方法基于博弈论中的 Shapley 值思想，能够在保持模型预测精度的同时，对各特征在不同样本中的边际贡献进行一致性分解，从而为复杂非线性模型提供可解释的决策依据。

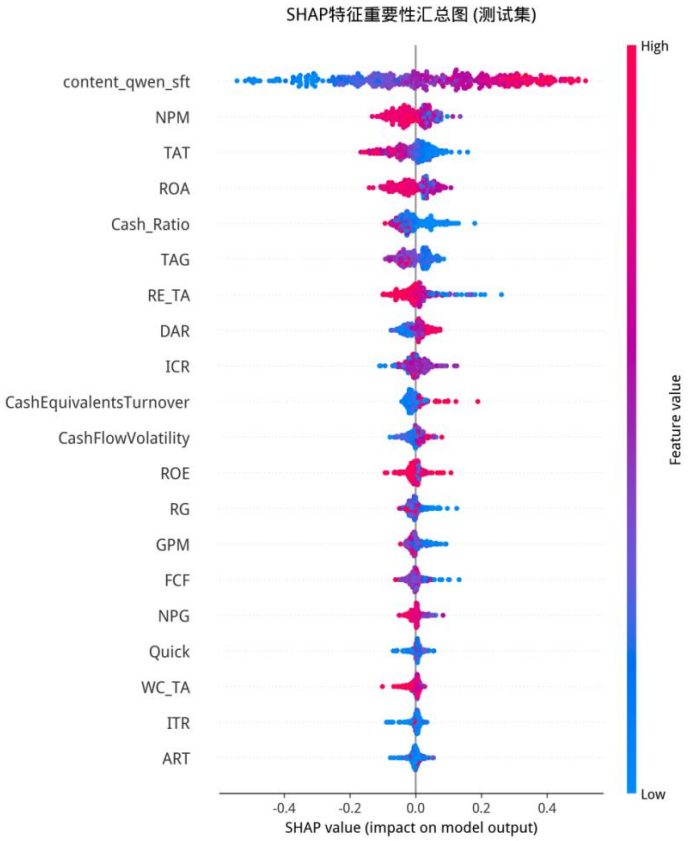


图 5.7 SHAP 特征重要性

Fig. 5.7 SHAP feature importance

图 5.7 展示了基于测试集样本的 SHAP 特征重要性汇总结果。从整体排序来看，基于微调 Qwen 模型构建的 content_qwen_sft 在所有特征中排名第一，其 SHAP 值分布范围显著高于其他变量，表明文本情绪信息在模型预测财务困境过程中发挥了核心作用。这一结果进一步验证了前文实证分析中情绪指标所体现出的显著增量预测能力。

从 SHAP 值的方向性分布可以看出，当 content_qwen_sft 取值较高时，其对应的 SHAP 值主要为正值，显著提高企业被预测为财务困境的概率；而当其取值较低时，则

中国知网　https://www.cnki.net

主要表现为负向贡献，对财务困境预测起到抑制作用。这表明新闻正文中所蕴含的负面情绪和风险信号能够有效反映企业潜在的财务压力，并在模型决策中占据主导地位。

在传统财务指标方面，净利润率、总资产周转率和资产收益率等指标同样具有较高的重要性。其中，盈利能力和经营效率较弱的企业，其对应 SHAP 值多为正值，更容易被模型识别为财务困境企业；而现金比率、留存收益占总资产比率等指标在一定程度上对风险判断产生缓释或放大作用，反映出企业流动性状况和历史盈利积累仍是财务困境识别的重要基础因素。

总体来看，全局 SHAP 分析结果表明，模型在预测企业财务困境时，并非仅依赖单一信息来源，而是通过融合文本情绪信息与传统财务指标形成综合判断。其中，经领域微调的文本情绪指标在特征重要性中占据首要位置，凸显了非结构化文本信息在企业风险识别中的独特价值。

为进一步理解模型在单个企业层面的预测逻辑，本文选取一家具备财务困境特征的 ST 企业样本，对其预测结果进行 SHAP 瀑布图分析，如图 5.8 所示。该图以模型的基准预测值为起点，逐步展示各特征对最终预测结果的正向或负向贡献。

结果显示，content_qwen_sft 是推动该企业被判定为财务困境的最主要因素，其 SHAP 值达到约+0.31，对最终预测结果起到决定性作用。这表明该企业相关新闻正文中所反映的负面情绪信息显著增强了模型对其财务风险的判断。与此同时，留存收益占总资产比率、资产收益率和净利润率等财务指标亦对预测结果产生了正向推动作用，反映出该企业存在盈利能力不足和历史经营积累薄弱的问题。

相比之下，利息保障倍数、资产负债率以及自由现金流等指标在该样本中对预测结果产生了一定的负向影响，在一定程度上缓释了财务困境判断。这表明模型在个体层面并非简单依赖单一变量，而是综合考虑不同方向的财务和文本信息，最终形成对企业风险状况的整体评估。

基于 SHAP 方法的可解释性分析表明，经领域微调的 Qwen 情绪指标不仅在整体预测性能上表现最优，而且在模型决策过程中发挥了实质性、可解释的作用。文本情绪信息与传统财务指标在模型中形成互补关系，共同驱动财务困境预测结果。该分析增强了模型预测结果的透明度和可信度，也为后续基于 LIME 方法的局部解释分析提供了良好的对照基础。

中国知网 https://www.cnki.net

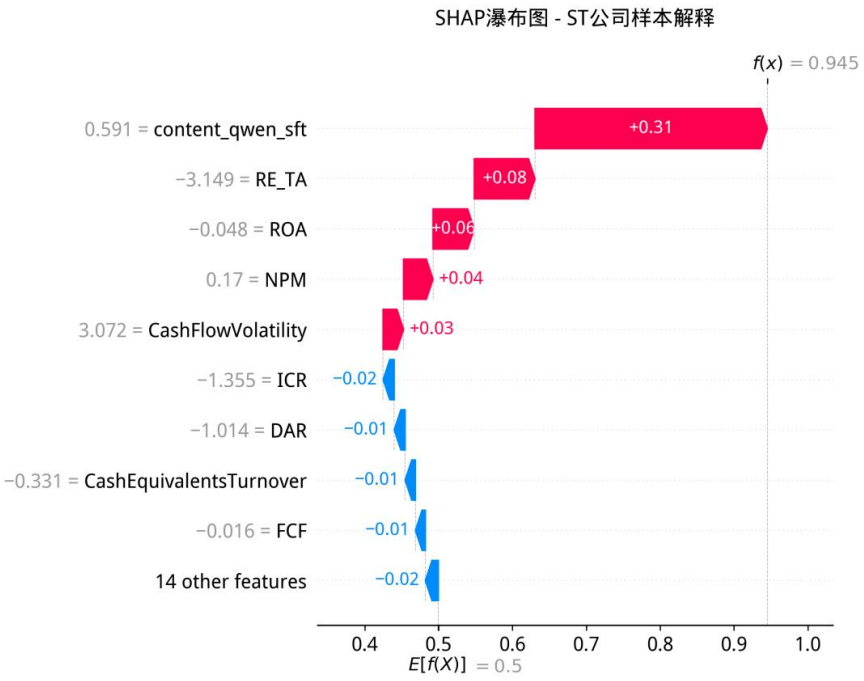


图 5.8 SHAP 瀑布图

Fig. 5.8 SHAP Waterfall Diagram

5.5.2　基于 LIME 的可解释性分析

在基于 SHAP 方法揭示模型全局决策机制的基础上，本文进一步引入 LIME（Local Interpretable Model-agnostic Explanations）方法，对模型在单个样本层面的预测逻辑进行局部可解释性分析。LIME 通过在目标样本邻域内构建局部线性近似模型，刻画各特征在特定预测情境下对模型输出的边际影响，有助于理解模型在具体企业层面的决策依据。

图 6.3 展示了基于测试样本的 LIME 特征重要性排序结果。从整体来看，基于微调 Qwen 模型构建的 content_qwen_sft 在局部解释中同样排名第一，其平均绝对 LIME 权重显著高于其他特征，表明在单个样本层面的预测中，文本情绪信息仍是模型最关键的决策依据。这一结果与前文基于 SHAP 的全局特征重要性分析高度一致，进一步验证了文本情绪指标在模型中的核心作用。

除文本情绪指标外，Cash_Ratio、TAT、CashEquivalentsTurnover）和 NPM 等财务指标在局部解释中亦具有较高的重要性。这表明，在具体企业的风险判断过程中，模型仍会重点关注企业的流动性状况、经营效率和盈利能力，文本情绪信息并未替代传统财务指标，而是与之形成互补关系。

中国知网　https://www.cnki.net

为进一步说明 LIME 方法在个体层面的解释效果，本文选取一家具备财务困境特征的 ST 企业样本进行分析，其预测为 ST 的概率为 0.945，对应的 LIME 局部解释结果如图 6.4 所示。

从解释结果可以看出，content_qwen_sft 位于区间（0.47,0.60]，对模型预测结果产生了最显著的正向影响，是推动该企业被判定为财务困境的首要因素。这表明该企业相关新闻正文中所反映的负面情绪和风险信息在模型决策中发挥了关键作用。与此同时，RE_TA≤0.04、ROA 较低以及 CashFlowVolatility 较高等财务特征亦对预测结果产生了明显的正向贡献，反映出该企业在盈利能力、历史积累和现金流稳定性方面存在潜在风险。

相对而言，DAR 较低、Cash_Ratio 较高以及部分流动性相关指标在该样本中对预测结果产生了一定的负向影响，在局部层面起到一定的风险缓释作用。这表明模型在个体预测时，并非简单依赖单一风险信号，而是综合权衡不同财务指标与文本情绪信息的正负影响，最终形成对企业风险水平的判断。

将 LIME 的局部解释结果与前文基于 SHAP 的分析相结合可以发现，两种方法在核心结论上具有高度一致性：文本情绪指标在模型预测中始终处于最重要位置，而财务指标则在不同样本中发挥差异化的补充作用。不同之处在于，SHAP 更侧重于揭示模型在整体样本层面的平均决策规律，而 LIME 则能够直观展示模型在单个企业情境下的具体判断路径。

这种“全局—局部”相结合的解释框架，有助于增强模型预测结果的透明度和可信度，也使得基于复杂机器学习模型的财务困境预警结果更易于理解和应用。

基于 LIME 方法的可解释性分析表明，XGBoost 模型在单个企业层面的预测决策具有清晰的经济含义，其预测结果由文本情绪信息与传统财务指标共同驱动 LIME 结果与 SHAP 分析在特征重要性和作用方向上保持一致，进一步验证了模型解释结论的稳健性，为模型在实际财务风险识别场景中的应用提供了有力支持。

中国知网 https://www.cnki.net

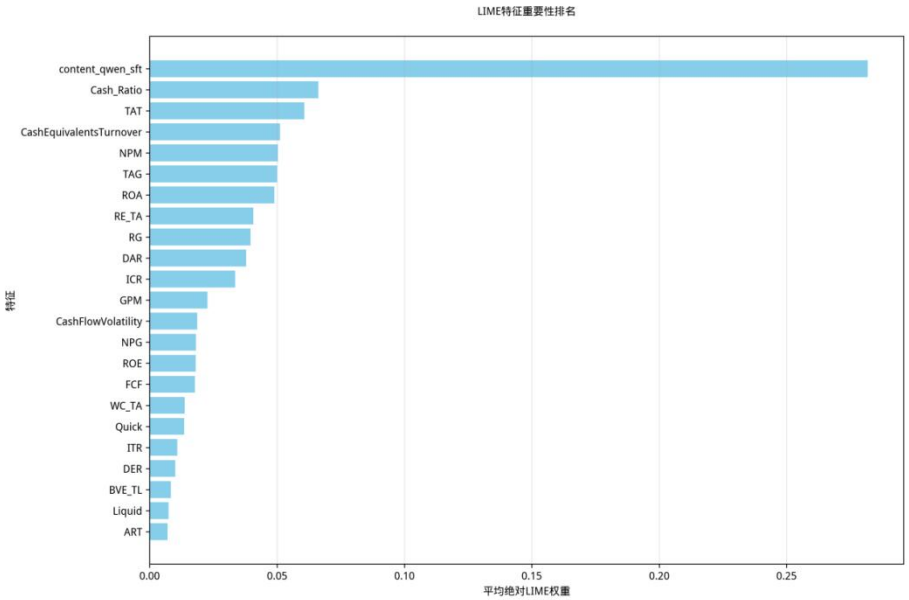


图 5.9 LIME 特征重要性

Fig. 5.9 LIME feature importance

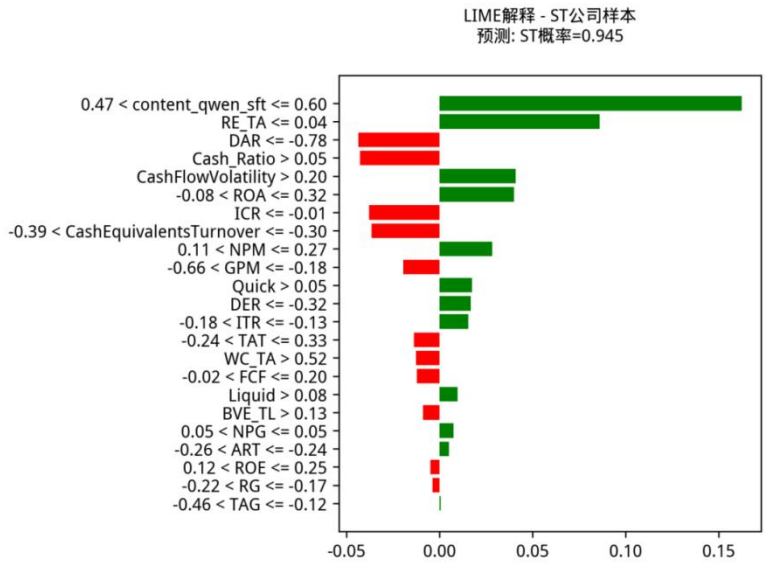


图 5.10 LIME 局部解释

Fig. 5.10 LIME local interpretation

中国知网　https://www.cnki.net

6 进一步分析

6.1 基于全样本与不平衡处理技术的稳健性检验

前文研究主要基于平衡样本展开分析，即通过控制财务困境企业与非财务困境企业的样本数量，使不同模型和不同文本情绪指标的比较结果更加清晰。该设定有助于削弱类别分布差异对模型训练过程的干扰，从而更准确地识别不同特征组合和不同算法在财务困境预警中的相对优势。

然而，在真实资本市场中，陷入财务困境的上市公司数量明显少于正常经营企业，企业财务困境识别本质上属于典型的不平衡分类问题。如果仅依据平衡样本进行模型训练和比较，虽然有利于模型性能的横向分析，但也可能使结论与真实市场场景存在一定偏离。基于此，本文在前文平衡样本分析的基础上，进一步采用全样本进行稳健性检验，并结合 SMOTE 方法对训练集中的少数类样本进行过采样处理，以考察本文结论在更接近真实市场分布条件下是否仍然成立。

具体而言，本文保留全体样本，2014 年至 2024 年企业一共 5592 家企业，总样本 43820 个样本，1198 个 ST 样本，ST 仅占全样本的 2.73%。不再对 ST 企业与非 ST 企业进行一比一匹配，而是直接基于原始样本分布构建预警数据集。在此基础上，仍以企业未来是否被实施 ST 作为财务困境代理变量，以企业 t−2 年财务指标和同期新闻文本情绪指标作为预测特征，并沿用前文的逻辑回归、支持向量机、随机森林和 XGBoost 等模型进行比较分析。考虑到全样本条件下少数类样本占比较低，本文采用 SMOTE 方法在训练阶段对财务困境企业样本进行合成过采样，以缓解模型训练过程中对多数类样本的偏向问题。

从基准结果来看，在仅使用财务特征时，各模型在全样本加 SMOTE 平衡设定下已经具备较好的区分能力，但不同评价指标之间存在一定差异。具体而言，逻辑回归、支持向量机、随机森林和 XGBoost 的 AUC 分别为 0.875、0.876、0.877 和 0.857，准确率分别为 0.930、0.930、0.918 和 0.913，说明仅依赖财务特征时模型在总体判别层面已有一定效果。但从少数类识别能力看，此时模型的精确率和 F1 值仍相对有限，例如四类模型的 F1 值分别为 0.297、0.298、0.236 和 0.247，表明在真实市场的不平衡环境下，仅使用财务特征仍难以充分识别财务困境企业。

中国知网 https://www.cnki.net

表 6.1 基于全样本情绪指标的预测结果

Tab. 6.1 Prediction results based on emotion indicators for the entire sample

特征组	模型	AUC	准确率	召回率	F1 分数
仅财务特征	Logistic	0.8752	0.9301	0.6356	0.2967
仅财务特征	SVM	0.8756	0.9300	0.6400	0.2978
仅财务特征	随机森林	0.8772	0.9180	0.5467	0.2363
仅财务特征	XGBoost	0.8574	0.9132	0.6133	0.2469
财务+content_deepseek	Logistic	0.9216	0.9456	0.6844	0.3684
财务+content_deepseek	SVM	0.9220	0.9460	0.6844	0.3702
财务+content_deepseek	随机森林	0.9139	0.9259	0.6711	0.2958
财务+content_deepseek	XGBoost	0.9072	0.9383	0.6400	0.3251
财务+content_qwen_sft	Logistic	0.9498	0.9515	0.7467	0.4169
财务+content_qwen_sft	SVM	0.9500	0.9513	0.7556	0.4187
财务+content_qwen_sft	随机森林	0.9405	0.9510	0.6533	0.3823
财务+content_qwen_sft	XGBoost	0.9381	0.9497	0.6844	0.3869

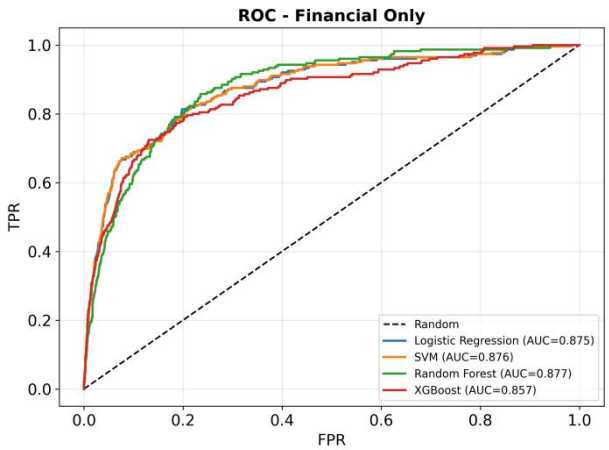


图 6.1 全样本的进财务特征 ROC 曲线

Fig. 6.1 ROC curve of financial characteristics for the entire sample

在此基础上，本文进一步加入基于 DeepSeek 构建的新闻正文情绪指标。结果表明，文本情绪信息能够显著改善模型的预测表现。加入 DeepSeek 情绪指标后，逻辑回归和支持向量机的 AUC 均提升至 0.922，随机森林和 XGBoost 的 AUC 也分别提升至 0.914 和 0.907；准确率则分别提高至 0.946、0.946、0.926 和 0.938。与此同时，模型对少数类样本的识别能力也得到增强，其中逻辑回归和支持向量机的召回率均达到 0.684，F1 值

中国知网　https://www.cnki.net

分别提升至 0.368 和 0.370。上述结果说明，在全样本不平衡环境下，基于大语言模型构建的文本情绪指标仍然具有明显的增量信息价值，能够有效补充传统财务指标在风险识别中的不足。

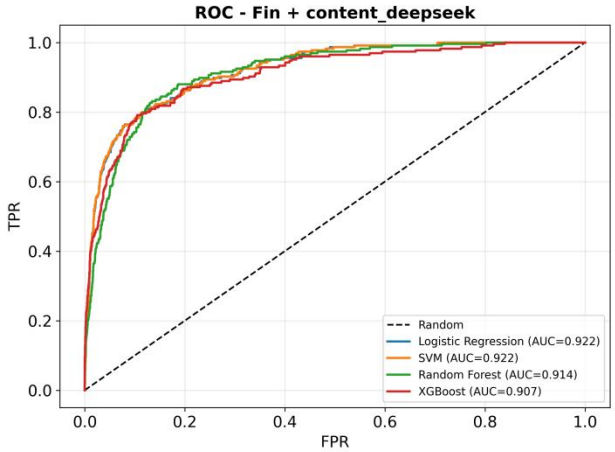


图 6.2 全样本下 DeepSeek 构建的指标 ROC 曲线

Fig. 6.2 ROC curve of metrics constructed by DeepSeek across the entire sample set

进一步地，本文考察基于 Qwen-SFT 构建的新闻正文情绪指标的表现。结果显示，该组特征的预测效果进一步优于 DeepSeek 方案。加入 Qwen-SFT 情绪指标后，逻辑回归和支持向量机的 AUC 均达到 0.950，随机森林和 XGBoost 分别达到 0.940 和 0.938；对应的准确率分别为 0.952、0.951、0.951 和 0.950。更为重要的是，模型对财务困境企业的识别能力显著增强，逻辑回归和支持向量机的召回率分别达到 0.747 和 0.756，F1 值分别提高至 0.417 和 0.419，均明显优于仅使用财务特征时的结果。这表明，经过领域语境适配的微调模型在真实市场样本环境下仍然保持了较强的风险语义识别能力。

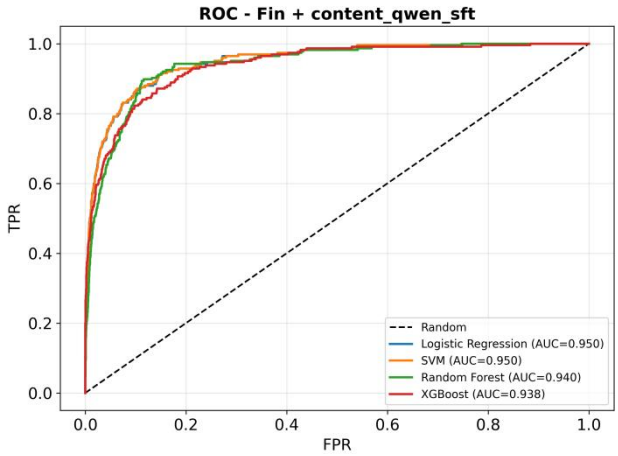


图 6.3 全样本下 Qwen-SFT 构建的指标 ROC 曲线

Fig. 6.3 ROC curve of metrics constructed by Qwen-SFT across the entire sample set

中国知网 https://www.cnki.net

结合 ROC 曲线结果也可以得到相同结论。无论是仅使用财务特征，还是加入 DeepSeek、Qwen-SFT 等文本情绪指标，各模型的 ROC 曲线均明显高于随机分类基准线；其中，加入文本情绪指标后的曲线整体更加靠近左上角，表明模型在不同阈值下均能获得更好的真阳性率与假阳性率权衡。尤其是加入 Qwen-SFT 情绪指标指标后，逻辑回归和支持向量机模型的 ROC 曲线改善最为明显，进一步验证了大语言模型文本情绪信息在真实不平衡样本场景下的预警有效性。

总体而言，基于全样本和 SMOTE 处理的进一步检验表明，前文在平衡样本下得到的主要结论具有较好的稳健性。即使在更接近真实资本市场分布特征的不平衡环境中，新闻文本情绪指标仍能显著提升企业财务困境预警模型的预测效果，且基于大语言模型构建的情绪指标总体上优于仅使用财务特征的基准模型。其中，Qwen-SFT 构建的情绪指标信息的特征组合表现尤为突出。这说明，本文提出的融合财务信息与文本情绪信息的预警框架不仅在平衡样本设定下有效，也具有较强的现实应用价值。

6.2 不同提示词策略下文本情绪指标的稳健性分析

6.2.1 提示词策略设计

前文在构建基于 DeepSeek 的新闻正文情绪指标时，主要采用统一的基准提示词，对企业新闻正文进行情绪识别与量化，并在企业年度层面聚合形成文本情绪指标。该处理方式有助于保持不同模型和不同文本来源之间的可比性，也为前文财务困境预警模型的构建提供了稳定输入。与此同时，前文在理论分析部分已指出，提示词工程是影响大语言模型输出结果的重要因素之一，不同提示词策略可能改变模型对文本信息的关注重点，进而影响情绪识别结果。

因此，为进一步检验本文文本情绪指标构建结果的稳健性，本节以前文平衡样本为基础，以基于 DeepSeek 的新闻正文情绪指标为比较对象，在保持样本划分方式、因变量设定、财务特征和预测模型均不变的前提下，仅对提示词策略进行调整，考察不同提示词设定下情绪得分分布及模型预测效果是否发生明显变化。具体而言，本文选取标准提示词（Standard Prompt）、思维链提示词（Chain-of-Thought，CoT）和少样本学习提示词（Few-shot）三种策略进行比较分析。

其中，标准提示词主要要求模型根据新闻正文内容直接判断文本所反映的情绪倾向，并给出介于 0 到 1 之间的情绪得分；思维链提示词则要求模型先识别文本中的经营变化、风险事件、市场反应及其可能的财务影响，再综合给出最终情绪评分，从而强化模型的中间推理过程；少样本学习提示词则在任务说明中加入若干示例文本及对应情绪标签，

中国知网 https://www.cnki.net

引导模型参照样例完成新文本的评分任务，以增强模型对评分边界的理解和输出一致性。三种提示词的设计分别对应直接判断、分步推理和样例引导三类典型提示方式，能够较好反映提示词策略变化对情绪指标构建的影响。

本文在三种提示词设定下分别对同一批新闻正文文本进行情绪评分，并在企业年度层面聚合生成新的文本情绪指标。在此基础上，本文从两个方面进行稳健性检验：一是比较不同提示词策略下 ST 企业与非 ST 企业情绪得分的分布特征；二是将不同提示词下构建的情绪指标重新纳入财务困境预警模型，对其预测效果进行比较分析。

为便于后续研究复现，本文所使用的三类提示词如下所示：

（1）标准提示词（Standard Prompt）

请忘记前面的内容，作为专业财经文本情绪分析师，对以下财经新闻文本进行情绪识别，仅输出正向、负向、中性三种情绪的置信度，其中置信度之和为 1，无需额外解释。情绪分类标准：正向情绪指企业盈利增长、项目突破、政策利好等积极信息；负向情绪指企业亏损、违约、违规、业绩下滑等消极信息；中性情绪指无实质情绪倾向的日常公告、客观陈述类信息。

新闻文本：{text}

（2）思维链提示词（Chain-of-Thought Prompt）

请阅读以下企业新闻正文，并按照以下步骤完成分析：

第一步，识别文本中是否包含经营恶化、债务压力、流动性紧张、重大诉讼、监管处罚、管理层变动、业绩下滑等风险信息；

第二步，判断这些信息对企业未来经营稳定性和财务状况可能产生的影响；

第三步，综合上述分析，给出该文本所对应的情绪得分。

仅输出正向、负向、中性三种情绪的置信度，其中置信度之和为 1。请先简要给出分析理由，再输出最终情绪得分。

文本：{text}

（3）少样本学习提示词（Few-shot Prompt）

请参考以下示例，对企业新闻正文进行情绪评分。输出正向、负向、中性三种情绪的置信度，其中置信度之和为 1。

示例 1：某公司发布公告称主营业务持续增长，盈利水平明显改善，市场份额稳步提升。

情绪得分：[1,0,0]

示例 2：某公司因债务违约被起诉，部分银行账户被冻结，持续经营能力存在重大不确定性。

中国知网 https://www.cnki.net

情绪得分：[0,1,0]

示例 3：某公司披露年度业绩预减公告，营业收入下降，现金流承压，但尚未出现重大违约风险。

情绪得分：[0.2,0.7,0.1]

现在请阅读以下文本，并给出情绪得分，仅输出数值结果。

文本：{text}

6.2.2　不同提示词策略下情绪得分分布比较

为直观展示不同提示词策略下文本情绪指标的区分能力，本文进一步比较了标准提示词、思维链提示词和少样本学习提示词三种设定下，ST 企业与非 ST 企业情绪得分的核密度分布。结果如图 6.4 所示。

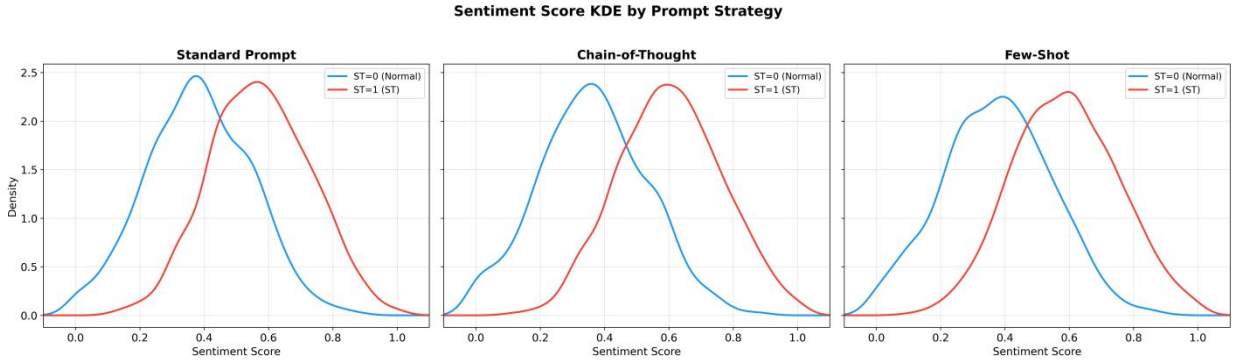


图 6.4　不同提示词策略下情绪得分的核密度分布图

Fig. 6.4 Kernel density distribution maps of emotion scores under different prompt strategies

从整体分布特征来看，三种提示词策略下正常企业与 ST 企业的情绪得分均表现出较为一致的方向性差异。具体而言，非 ST 企业样本的情绪得分分布整体偏向较低区间，而 ST 企业样本的情绪得分分布整体向右移动，说明无论采用何种提示词策略，基于 DeepSeek 构建的新闻正文情绪指标均能够较稳定地区分不同风险状态下的企业样本。这表明，本文前文所使用的正文情绪指标并非仅在特定提示词设定下有效，而是具有较好的提示词稳健性。

进一步比较不同提示词策略下的分布形态可以发现，标准提示词下两类样本已经表现出较明显的错位分布，说明直接评分式提示词能够较好地完成财经新闻情绪识别任务。思维链提示词下，两类样本的峰值位置分离程度进一步增强，其中 ST 企业样本的高分区域更加集中，非 ST 企业样本的低分区域也更加清晰，表明当模型被要求对文本中的风险事件及其潜在财务影响进行逐步分析后，其对隐含风险语义的识别能力有所增强。

中国知网　https://www.cnki.net

这一结果说明，思维链提示词在复杂财经语境下能够更充分地挖掘文本中的负面风险信号。

相比之下，少样本学习提示词下两类样本的分布形态更加平滑，峰值位置也较为稳定，说明示例文本有助于模型更准确地把握情绪评分边界，减少由任务理解差异导致的输出波动。换言之，少样本学习提示词虽然未必在样本区分度上表现最强，但在输出一致性和评分稳定性方面具有一定优势。

总体来看，不同提示词策略确实会对情绪得分分布的局部形态产生影响，但这种影响主要体现在区分程度和分布平滑性的变化上，并未改变情绪得分的总体方向。无论采用标准提示词、思维链提示词还是少样本学习提示词，ST 企业新闻文本对应的情绪得分总体上均高于非 ST 企业，说明本文构建的文本情绪指标在不同提示词设定下均能较稳定地反映企业潜在财务风险。

6.2.3 不同提示词策略下的预警效果比较

在比较情绪得分分布的基础上，本文进一步将三种提示词策略下构建的正文情绪指标重新纳入财务困境预警模型，并对其预测效果进行比较分析，以检验提示词变化是否会对模型结论产生实质影响。为保持与前文一致，本文仍采用逻辑回归、支持向量机、随机森林和 XGBoost 等模型，并以 AUC、准确率、召回率和 F1 值作为主要评价指标。

从模型比较结果来看，如表不同提示词策略下构建的文本情绪指标整体上均能够改善模型对企业财务困境的识别能力，这表明文本情绪信息本身具有较稳定的增量预测价值。也就是说，前文关于基于大语言模型构建的新闻正文情绪指标能够提升财务困境预警效果的核心结论，并不依赖于某一种特定提示词形式，而是在不同提示词设定下均具有较好的方向一致性。

表 6.2 不同提示词策略下财务困境预警模型结果比较

Tab. 6.2 Comparison of Financial Distress Early Warning Model Results under Different Prompt Strategies

特征组	模型	AUC	准确率	召回率	F1 分数
Financial + Standard Prompt	Logistic	0.885	0.816	0.7642	0.806
Financial + Standard Prompt	SVM	0.8883	0.7995	0.7689	0.7932
Financial + Standard Prompt	随机森林	0.8843	0.8019	0.7972	0.8009
Financial + Standard Prompt	XGBoost	0.8894	0.809	0.7877	0.8048
Financial + Chain-of-Thought	Logistic	0.9151	0.8278	0.7783	0.8189
Financial + Chain-of-Thought	SVM	0.9153	0.8396	0.8019	0.8333

中国知网 https://www.cnki.net

续表 6.2

特征组	模型	AUC	准确率	召回率	F1 分数
Financial + Chain-of-Thought	随机森林	0.9138	0.8373	0.816	0.8337
Financial + Chain-of-Thought	XGBoost	0.9165	0.8491	0.8208	0.8447
Financial + Few-Shot	Logistic	0.8889	0.8137	0.7736	0.8059
Financial + Few-Shot	SVM	0.8956	0.7925	0.7689	0.7874
Financial + Few-Shot	随机森林	0.8878	0.7948	0.783	0.7924
Financial + Few-Shot	XGBoost	0.8844	0.7995	0.7689	0.7932

进一步比较三种提示词策略的相对表现，可以发现，思维链提示词构建的情绪指标通常更有利于提升模型对财务困境企业的识别能力，尤其在召回率等少数类识别指标上表现更为突出。这一结果与前述分布分析中思维链提示词下两类样本区分度更高的结论一致，说明通过引导模型对新闻文本中的风险线索进行逐步推理，能够增强其对潜在高风险企业的识别敏感性。

相比之下，少样本学习提示词在整体表现上更为平稳，通常能够在 AUC、准确率和 F1 值等综合指标上保持较好的稳定性。这表明，当模型借助示例文本明确评分标准后，其在批量文本评分任务中具有更强的一致性和可复现性。对于需要长期监测企业新闻情绪变化的应用场景而言，少样本学习提示词具有一定的方法优势。

标准提示词的整体表现则介于二者之间。虽然其在样本区分度和模型表现上略逊于思维链提示词或少样本学习提示词中的最优情形，但由于其结构简洁、执行效率较高，仍然是一种具有较高实用性的基准方案。结合前文结果来看，标准提示词已经能够较好支持基于 DeepSeek 的文本情绪指标构建，而思维链提示词和少样本学习提示词则分别在“增强风险识别敏感性”和“提高评分一致性”方面提供了进一步优化空间。

从方法论角度看，本节结果表明，大语言模型在财经文本情绪识别任务中的表现不仅取决于模型本身的语义理解能力，也与任务指令的组织方式密切相关。思维链提示词通过引导模型展开中间推理，更适合识别包含多重风险线索、语义表达较为隐含的企业新闻；少样本学习提示词通过显式示例强化任务边界，更适合在大规模文本评分中提高输出稳定性。对于企业财务困境预警任务而言，若研究更重视潜在高风险企业的尽早识别，则思维链提示词更具优势；若研究更强调情绪指标构建的标准化和可复现性，则少样本学习提示词同样具有较高应用价值。

总体而言，本节基于前文平衡样本，对不同提示词策略下 DeepSeek 新闻正文情绪指标的分布特征和预测效果进行了稳健性检验。结果表明，尽管提示词设计会在一定程

中国知网 https://www.cnki.net

度上影响情绪得分的分布形态和局部预测表现，但并未改变本文的核心研究结论，即基于大语言模型构建的新闻文本情绪指标能够有效识别企业潜在财务风险，并显著提升财务困境预警模型的预测能力。该结果进一步增强了本文研究结论的稳健性，也说明在后续相关研究中，可以根据研究目标在提示词敏感性与输出稳定性之间进行有针对性的选择。

中国知网 https://www.cnki.net

7　结论及政策建议

7.1　结论

本文以我国上市公司财务困境预警为研究对象，结合结构化财务数据与非结构化新闻文本信息，构建了基于多种文本情绪指标与机器学习模型的财务困境预测框架。通过系统比较不同情绪指标构建方法、预测模型以及可解释性分析手段，本文对文本情绪信息在财务困境识别中的作用进行了较为全面的实证检验，主要结论如下。

第一，传统财务指标仍然是财务困境预警的重要基础，但其预测能力存在一定局限。基于仅包含财务特征的基准模型结果表明，盈利能力、偿债能力和经营效率相关指标对企业财务困境具有较强解释力，但在预测精度和稳定性方面仍有提升空间。这一结果与既有财务困境预警文献的结论基本一致，也为引入非财务信息提供了现实动因。

第二，引入新闻文本情绪指标能够显著提升财务困境预警模型的预测性能。无论采用 BOW 还是基于预训练语言模型构建的情绪指标，在多数预测模型和评价指标下，加入情绪变量后的模型整体表现均优于仅使用财务特征的基准模型，表明新闻文本中蕴含的情绪和风险信号能够为财务困境识别提供有效的增量信息。其中，基于新闻正文构建的情绪指标整体优于基于新闻标题的情绪指标，说明正文文本在风险信息表达方面更为充分。

第三，不同情绪指标构建方法在预测效果上存在显著差异。相比传统词袋模型，基于深度语义表示的预训练语言模型在财务困境预警任务中表现更优，尤其是在 AUC、召回率和 F1 值等综合评价指标上优势明显。进一步比较发现，通用大模型在缺乏领域适配的情况下虽具备较强预测能力，但其优势并非不可替代。

第四，经领域微调的小规模模型在专业财务场景中展现出与通用大模型相近的预测性能。实证结果显示，基于微调 Qwen 模型构建的情绪指标在多数实验设定下取得了最优或次优预测效果，其整体性能与 DeepSeek 等通用大模型高度接近，且显著优于未微调模型。这一发现表明，在特定专业领域中，模型是否经过有效的领域适配往往比模型规模本身更为关键，为金融文本建模中模型选择与资源配置提供了重要启示。

第五，基于 XGBoost 模型的可解释性分析进一步验证了文本情绪指标在模型决策中的实质性作用。通过 SHAP 和 LIME 两种互补的解释方法，本文从全局和个体层面揭示了模型的预测机制。结果表明，经微调的文本情绪指标在特征重要性排序中始终位于前列，并在具体 ST 企业样本的预测过程中发挥了决定性影响。同时，传统财务指标在不

中国知网　https://www.cnki.net

同样本中呈现出差异化作用，与文本情绪信息共同驱动模型决策，增强了预测结果的透明度和可信度。

第六，通过进一步分析，本文验证了在全样本条件下，基于新闻文本构建的情绪指标同样能够为企业财务困境预测提供有效支撑，表明该指标具有较强的适用性和稳健性。进一步地，本文采用不同的提示词构建策略进行同构比较，结果表明，大模型对提示词策略存在一定敏感性，不同策略下的预测效果会有所差异；但从总体来看，各类提示词策略均表现出较好的有效性。因此，在实际应用中，可以根据具体场景选择更为合适的提示词设计方式，以提升模型与使用环境的匹配度。

需要指出的是，基于大语言模型的文本情绪方法并不意味着传统财务预警方法失去价值。相反，本文结果表明，财务指标仍是企业财务困境预警的重要基础，而新闻文本情绪指标则能够在传统财务信息之外提供前瞻性和语义层面的增量信息。二者融合能够在保持模型经济解释基础的同时，提升对隐性风险和早期风险信号的识别能力。因此，未来财务困境预警体系更适合采用财务指标为基础、文本情绪为补充、机器学习模型为工具、可解释性方法为保障的综合框架。

综合而言，本文的研究结果表明，将高质量文本情绪指标与机器学习方法相结合，不仅能够有效提升财务困境预警的预测性能，还能够在可解释性层面为模型结果提供清晰、合理的经济含义。本文构建的研究框架为财务困境预警研究提供了新的实证证据，也为文本信息在公司财务风险识别中的应用提供了可行路径。

7.2 政策建议

基于本文关于文本情绪信息与机器学习方法在财务困境预警中的实证结果，为更好地发挥非财务信息在企业风险识别和监管实践中的作用，本文从监管部门、上市公司以及投资者与中介机构三个层面提出如下政策建议。

（一）对监管部门的政策建议

首先，监管部门可进一步重视非结构化信息在财务风险预警体系中的作用，将新闻文本、公告解读等文本信息作为传统财务指标的重要补充。本文研究表明，基于新闻文本构建的情绪指标能够显著提升财务困境预警的预测能力，且在模型决策中发挥实质性作用。因此，监管部门在构建上市公司风险监测和预警系统时，可探索引入文本情绪分析等技术手段，以更早、更全面地识别企业潜在风险。

其次，监管部门可鼓励和引导金融科技在专业领域中的“定向应用”，推动模型领域适配而非盲目追求大规模通用模型。本文发现，经领域微调的小规模模型在财务困境预警任务中的表现可与通用大模型相媲美，这表明在监管实践中，通过针对财务语境进行

中国知网 https://www.cnki.net

模型优化，能够在控制成本和计算资源的前提下获得较高的预测效果，有助于提升监管技术的可行性和可持续性。

最后，监管部门应关注模型可解释性在风险预警系统中的重要作用。本文通过 SHAP 和 LIME 方法验证了机器学习模型在财务困境识别中的可解释性，为模型结果提供了清晰的经济含义。未来在推广智能监管工具时，应优先采用具有较强解释能力的模型和方法，以增强监管决策的透明度和公信力。

（二）对上市公司的管理启示

对于上市公司而言，本文研究结果表明，企业在资本市场中的风险状况不仅体现在财务报表中，也会通过新闻报道和舆情信息持续向外部传递。负面新闻情绪往往能够在财务困境发生前较早反映企业经营压力，因此企业管理层应更加重视信息披露质量和舆情管理，避免因信息不对称或负面事件积累而放大市场对企业风险的预期。

同时，企业应从内部管理角度关注盈利能力、现金流稳定性和经营效率等关键财务指标。本文的可解释性分析显示，这些传统财务指标在模型决策中仍具有重要作用，并与文本情绪信息共同影响企业财务困境风险。通过改善基本面状况、增强经营稳健性，企业不仅有助于降低实际财务风险，也有助于改善市场对企业的情绪预期。

此外，上市公司可尝试在内部风险管理体系中引入文本分析和智能预警工具，对新闻、公告及外部舆情进行持续监测，从而实现对潜在财务风险的前瞻性识别，为管理决策提供支持。

（三）对投资者与中介机构的实践启示

对于投资者而言，本文研究结果表明，单纯依赖财务报表进行风险判断可能存在信息滞后，而新闻文本中所蕴含的情绪和风险信号能够为投资决策提供重要补充。投资者在进行风险评估和资产配置时，可结合财务指标与文本情绪信息，对企业潜在财务困境进行更为全面的判断，从而降低投资决策的不确定性。

对于审计机构、评级机构和证券分析师等中介机构而言，本文提出的预测框架和解释方法为其开展风险评估和持续监测提供了新的技术路径。通过将机器学习模型与可解释性分析相结合，中介机构不仅可以提升风险识别的准确性，还能够为其专业判断提供更加透明、可追溯的依据，增强分析结论的说服力。

中国知网　https://www.cnki.net

参考文献

[1]陈静.上市公司财务恶化预测的实证分析[J].会计研究,1999(4):32-39.

[2]陈艺云.基于信息披露文本的上市公司财务困境预测:以中文年报管理层讨论与分析为样本的研究[J].中国管理科学,2019,27(07):23-34.

[3]陈友余,赵嘉仪,邓骞杰,等.基于文本分析和机器学习的汽车上市公司信用风险识别研究[J].系统科学与数学,2025,45(2):456-469.

[4]程晓秋.上市公司财务困境预警研究——基于数据挖掘的方法[J].财会通讯,2010,(02):31-32.

[5]邓晓岚,王宗军,李红侠,等.非财务视角下的财务困境预警——对中国上市公司的实证研究[J].管理科学,2006,(03):71-80.

[6]樊瑞鑫,熊熊,高雅,等.各类个人投资者信息反馈的异质性:基于公司公告事件的视角[J].系统工程理论与实践,2026,46(02):599-617.

[7]方匡南,章贵军,张惠颖.基于 Lasso-logistic 模型的个人信用风险预警方法[J].数量经济技术经济研究,2014,31(2):125-136.

[8]龚文,俞丽辉.企业财务困境预警文献评述[J].财会通讯,2010,(36):39-41.

[9]李成刚,贾鸿业,赵光辉,等.基于信息披露文本的上市公司信用风险预警——来自中文年报管理层讨论与分析的经验证据[J].中国管理科学,2023,31(2):18-29.

[10]李双燕,蒋丽华,卞舒晨.年报文本情绪与上市公司违规行为识别——基于机器学习文本分析方法的实证研究[J].当代经济科学,2023,45(06):97-109.

[11]刘佳佳,王雅涵,葛祯祯,等.基于 TI-FI-CatBoost 的公司财务困境的集成预测方法[J].管理现代化,2024,44(01):94-102.

[12]刘小淇,曾繁荣,周鸿.基于非财务视角的上市公司财务困境预警研究——基于主成分逻辑回归的方法[J].财会通讯,2015,(06):90-93.

[13]吕喜梅,蒋翠清,丁勇,等.融合临时报告软信息的新三板企业财务困境预测研究[J].中国管理科学,2023,31(11):140-150.

[14]吕长江,徐丽莉,周琳.上市公司财务困境与财务破产的比较分析[J].经济研究,2004(8):64-73.

[15]乔冰琴,段全虎,赵丹.基于 MD&A 多文本特征的财务风险预警模型研究[J].会计之友,2023,(05):16-23.

[16]任嘉嵩,伍胡星宇,任炜杰.基于类龙伯格预测器的财务困境预警研究[J].会计之友,2023,(05):38-45.

中国知网 https://www.cnki.net

[17]任婷婷,鲁统宇,崔俊.基于改进 AdaBoost 算法的动态不平衡财务预警模型[J].数量经济技术经济研究,2021,38(11):182-197.

[18]汝毅,薛健,张乾.媒体新闻报道的声誉溢出效应[J].金融研究,2019(8):189-206.

[19]阮素梅,孙旭升,李伟.融合上市公司文本信息的财务困境预测——来自年报管理层讨论与分析的经验证据[J].财贸研究,2025,36(06):99-110.

[20]宋媚,李佳蔚,高峰,等.基于 D-S 证据融合的可解释多分类财务危机预警模型[J/OL].系统管理学报,1-17[2026-03-25].https://link.cnki.net/urlid/31.1977.N.20250319.1119.002.

[21]宋睿.内部控制、财务数智化转型与企业财务困境预警研究[J/OL].财会通讯,1-6[2026-03-25].https://doi.org/10.16144/j.cnki.issn1002-8072.20260209.006.

[22]孙洁,李能飞,赵梦茹.媒体负面报道与公司财务困境预警——基于文本分析和机器学习[J].财经论丛,2023,(09):80-90.

[23]孙玲莉,杨贵军,王禹童.基于 Benford 律的随机森林模型及其在财务风险预警的应用[J].数量经济技术经济研究,2021,38(9):159-177.

[24]唐国豪,朱琳,陈世程.公告溢价效应与资产定价：文本机器学习视角[J].经济学动态,2024,(02):72-87.

[25]田宝新,王建琼.基于财务与非财务要素的上市公司财务困境预警实证研究[J].金融评论,2017,9(05):103-115+126.

[26]王德青,薛守聪,芦智昊,等.基于函数型 Logistic 模型的企业财务困境预警研究[J].运筹与管理,2025,34(09):46-52.

[27]王建飞,蒋翠清,丁勇,等.融入高阶关联风险特征的企业财务困境预测[J].系统工程理论与实践,2025,45(07):2145-2162.

[28]王昱,杨珊珊.考虑多维效率的上市公司财务困境预警研究[J].中国管理科学,2021,29(2):32-41.

[29]吴世农,卢贤义.我国上市公司财务困境的预测模型研究[J].经济研究,2001(6):46-55,96.

[30]吴星泽.财务危机预警研究:存在问题与框架重构[J].会计研究,2011(2):59-65,97.

[31]夏秀芳,迟健心.企业财务困境预警研究综述[J].会计之友,2018,(13):2-6.

[32]夏喆,沈郑佳.基于内部控制自评报告的财务困境预测——文本风险信息视角[J].财会月刊,2024,45(22):24-29.

[33]新夫,董萱,高闻婧,等.中国式金融债委会制度演化与企业债务纾困——基于 4 家财务困境企业的多案例研究[J].会计研究,2025,(11):107-121.

[34]徐车,严雨萌,熊熊.基于演化特征选择的企业财务困境集成预测模型研究[J/OL].系统工程理论与实践,1-19[2026-03-25].https://link.cnki.net/urlid/11.2267.N.20260107.1000.002.

中国知网 https://www.cnki.net

[35]闫达文,李存,迟国泰.基于混频数据的中国上市公司财务困境动态预测研究[J].中国管理科学,2024,32(01):1-12.

[36]杨贵军,周亚梦,孙玲莉.基于 Benford-logistic 模型的企业财务风险预警方法[J].数量经济技术经济研究,2019,36(10):149-165.

[37]杨子晖,张平淼,林师涵.系统性风险与企业财务危机预警——基于前沿机器学习的新视角[J].金融研究,2022(8):152-170.

[38]张涵,徐静蕾,俞睿桦,等.基于图神经网络的企业财务困境预测方法[J].北京师范大学学报(自然科学版),2025,61(06):786-796.

[39]张玲.财务危机预警分析判别模型[J].数量经济技术经济研究,2000(3):49-51.

[40]张玉,蒋翠清.融入股票论坛 UGC 时序特征的上市公司财务困境预测方法[J].合肥工业大学学报(自然科学版),2025,48(03):387-394.

[41]周首华,杨济华,王平.论财务危机的预警分析——f 分数模式[J].会计研究,1996(8):8-11.

[42]周颖刚,唐诚蔚,林哲晖.市场情绪、投资因子与资产定价——基于新闻与社交媒体的对比分析[J].计量经济学报,2024,4(3):567-587.

[43]Alam S, Das S K, Dipa U R, et al. Predicting financial distress through ownership pattern: Dynamics of financial resilience of bangladesh[J]. Future Business Journal, 2024, 10(1): 91-110.

[44]Tetlock P C. Giving content to investor sentiment: The role of media in the stock market[J]. The Journal of finance, 2007, 62(3): 1139-1168.

[45]Bukalska E, Maziarczyk A. Impact of financial constraints and financial distress on cash holdings[J]. International Journal of Management and Economics, 2023, 59(1): 13-31.

[46]Baker M, Wurgler J. Investor sentiment and the cross-section of stock returns[J]. The journal of Finance, 2006, 61(4): 1645-1680.

[47]Benlemlih M. Corporate social responsibility and firm debt maturity[J]. Journal of Business Ethics, 2017, 144(3): 491-517.

[48]Brière M, Huynh K, Laudy O, et al. Stock market reaction to news: Do tense and horizon matter?[J]. Finance Research Letters, 2023, 58: 104630.

[49]Chen Q. Media coverage, social trust and corporate financing efficiency[J]. International Review of Economics & Finance, 2024, 96: 103577.

[50]Chen X Q, Ma C Q, Ren Y S, et al. Explainable artificial intelligence in finance: A bibliometric review[J]. Finance Research Letters, 2023, 56: 104145.

[51]Cheng C S A, Jiang L, Song W L. Media coverage and debt financing choice[J]. Journal of Accounting and Public Policy, 2024, 44: 107181.

中国知网 https://www.cnki.net

[52]Ehrmann M, Hamdi A, Pontes E L, et al. Named entity recognition and classification in historical documents: A survey[J]. ACM Computing Surveys, 2023, 56(2): 1-47.

[53]Hanley K W, Hoberg G. The information content of IPO prospectuses[J]. Review of Financial Studies, 2010, 23(7): 2821-2864.

[54]Hajek P, Munk M. Corporate financial distress prediction using the risk-related information content of annual reports[J]. Information Processing & Management, 2024, 61(5): 103820.

[55]Haefner N, Wincent J, Parida V, et al. Artificial intelligence and innovation management: A review, framework, and research agenda☆[J]. Technological forecasting and social change, 2021, 162: 120392.

[56]Leo M, Sharma S, Maddulety K. Machine learning in banking risk management: A literature review[J]. Risks, 2019, 7(1): 29.

[57]Li H, Sun J, Wu J. Predicting business failure using classification and regression tree: An empirical comparison with popular classical statistical methods and top classification mining methods[J]. Expert Systems with Applications, 2010, 37(8): 5895-5904.

[58]Li Y, Wang W. Caught in a debt trap: Financial distress and corporate production decisions[J]. International Journal of Finance & Economics, 2025.

[59]Lin Y C, Padliansyah R, Lu Y H, et al. Bankruptcy prediction: Integration of convolutional neural networks and explainable artificial intelligence techniques[J]. International Journal of Accounting Information Systems, 2025, 56: 100744.

[60]Loughran T, Mcdonald B. Textual analysis in accounting and finance: A survey[J]. Journal of Accounting Research, 2016, 54(4): 1187-1230.

[61]Luo L, Yang Z, Yang P, et al. An attention-based BiLSTM-CRF approach to document-level chemical named entity recognition[J]. Bioinformatics, 2018, 34(8): 1381-1388.

[62]Lu S, Su Y, Zhang X, et al. LLM-infused bi-level semantic enhancement for corporate credit risk prediction[J]. Information Processing & Management, 2025, 62(4): 104091.

[63]Martínez-Sola C, Sanabria-García S, Garrido-Miralles P. The effect of financial constraints on accounting restatements: Spanish evidence[J]. European Research on Management and Business Economics, 2024, 30(2): 100244.

[64]Shin D. The effects of explainability and causability on perception, trust, and acceptance: Implications for explainable AI[J]. International Journal of Human-Computer Studies, 2021, 146: 102551.

[65]Stevenson M, Mues C, Bravo C. The value of text for small business default prediction: A deep learning approach[J]. European Journal of Operational Research, 2021, 295(2): 758-771.

中国知网 https://www.cnki.net

[66]Supawat L, Arnat L. Market reaction to corporate releases and news articles: Evidence from thailand's stock market[J]. International Journal of Financial Studies, 2023, 11(3): 111.

[67]Tavakoli M, Chandra R, Tian F, et al. Multi-modal deep learning for credit rating prediction using text and numerical data streams[J]. Applied Soft Computing, 2025, 171: 112771.

[68]Wang D, Zhou Y. An innovative machine learning workflow to research china's systemic financial crisis with SHAP value and shapley regression[J]. Financial Innovation, 2024, 10(1): 103.

[69]Weld D S, Bansal G. The challenge of crafting intelligible intelligence[J]. Communications of the ACM, 2019, 62(6): 70-79.

[70]Zhang C (Abigail), Cho S, Vasarhelyi M. Explainable artificial intelligence (XAI) in auditing[J]. International Journal of Accounting Information Systems, 2022, 46: 100572.

中国知网 https://www.cnki.net



中国知网 https://www.cnki.net