分类号：　　密级：公开

UDC　　学号：2024022152

华南师範大學

South China Normal University

硕 士 学 位 论 文

（专 业 学 位）

基于大语言模型的股票情感因子与强化学习的量化策略研究

学 位 申 请 人：王振新

学 科 专 业：应用统计

论 文 研 究 方 向：量化投资

所 在 学 院：数学科学学院

导师姓名及职称：杨舟教授

二〇二六 年 六 月

中国知网 https://www.cnki.net

South China Normal University

A Dissertation Submitted for the Degree of Master

Research on Quantitative Investment Strategies Based on Large Language Model Stock Sentiment Factors and Reinforcement Learning

Supervisor: Wang Zhenxin

Candidate: Yang Zhou

Major: Applied Statistics

Research direction: Quantitative Investment

Department/School: School of Mathematical Sciences

JAN 2026

中国知网 https://www.cnki.net

摘 要

大语言模型与深度强化学习的融合为量化投资开辟了新范式。针对通用大模型计算开销大、推理速度慢以及传统模型在金融文本深层语义处理上精度不足的问题，本文构建了融合领域微调 RoBERTa（Robustly Optimized BERT Pretraining Approach）模型与DDPG（Deep Deterministic Policy Gradient）算法的智能量化交易框架。

针对金融文本挖掘中高质量标注数据稀缺及深层语义理解难度大的问题，本文提出一种基于大语言模型构建情绪因子的研究框架。首先，通过定向爬虫采集 2024 年上证 50 成分股的 33 万余条用户评论，构建了高频金融舆情语料库。区别于传统的关键词匹配法，本研究利用大语言模型的深层语义推理能力对无标注语料进行智能化标注，并采用“大模型指导小模型”的知识蒸馏范式对 RoBERTa 模型进行后训练。实验结果显示，该模型在金融情绪分类上的准确率相对 TF-IDF 提高 12%，验证了语义提取的精确性。在此基础上，本文通过特征工程构建了系列情绪指标，经 IC 值检验筛选出移动平均、情绪背离和情绪动量三大核心因子。实证表明，该方法能有效捕捉并提取市场情绪中的预测信息，为金融量化分析提供有力支撑。

为提升量化交易策略的稳健性，本文构建了一种融合情绪因子的 DDPG（深度确定性策略梯度）算法框架。该框架利用卷积神经网络（CNN）对高维数据进行特征表征与降维，将当前持仓权重、情绪因子及历史行情共同嵌入状态空间，使智能体在感知实时仓位的状态下优化调仓决策。针对金融数据的“重尾”特征导致的训练不稳定问题，本文创新性地引入基于 Log-Modulus 变换的 Symlog 奖励函数。该函数通过非线性映射实现收益反馈的尺度压缩，在增强小数值敏感度的同时，有效抑制了金融数据重尾分布下的极端波动干扰，提升了深度强化学习在量化交易环境中的训练稳健性。

实证结果表明，本研究所提策略在多项核心性能指标上均优于 UCRP、EGP 及 OLMAR 等传统基准策略。在风险调整收益方面，模型表现出稳健的盈利能力，其收益率与夏普比率较最优基准策略分别提升了 9.54%、2.15；在风险控制维度，模型最大回撤降低了 1.99%。研究证实，该范式能够有效平衡收益获取与风险规避，为智能化量化交易提供了具有参考价值的解决方案。

关键词：RoBERTa；金融情绪因子；深度强化学习；DDPG；量化交易

中国知网 https://www.cnki.net

ABSTRACT

The fusion of Large Language Models and Deep Reinforcement Learning has pioneered a new paradigm in quantitative investment. Addressing the challenges of high computational overhead and slow inference in general-purpose LLMs, as well as the insufficient precision of traditional models in processing deep financial semantics, this thesis constructs an intelligent quantitative trading framework that integrates a domain-specific fine-tuned RoBERTa（Robustly Optimized BERT Pretraining Approach）model with the Deep Deterministic Policy Gradient (DDPG) algorithm.

To tackle the scarcity of high-quality labeled data and the complexity of deep semantic understanding in financial text mining, this research proposes a sentiment factor construction framework based on LLMs. First, a high-frequency financial sentiment corpus was established by collecting over 330,000 user comments from the SSE 50 index components in 2024 via targeted web crawling. Diverging from traditional keyword-matching methods, this study leverages the deep semantic reasoning capabilities of LLMs to perform intelligent labeling on unannotated corpora and employs a knowledge distillation paradigm—where a "large model guides a small model"—to conduct post-training on the RoBERTa model. Experimental results indicate that the model achieves a 12% increase in sentiment classification accuracy compared to TF-IDF, validating the precision of its semantic extraction. On this basis, a series of sentiment indicators were constructed through feature engineering, from which three core factors—Moving Average, Sentiment Divergence, and Sentiment Momentum—were identified via Information Coefficient (IC) testing. Empirical evidence suggests that this method effectively captures and extracts predictive information from market sentiment, providing robust support for quantitative financial analysis.

To enhance the robustness of trading strategies, this thesis develops a DDPG-based algorithmic framework incorporating sentiment factors. The framework utilizes Convolutional Neural Networks (CNNs) for feature representation and dimensionality reduction of high-dimensional data, embedding current holding weights, sentiment factors, and historical market data into the state space. This enables the agent to optimize rebalancing decisions while

中国知网 https://www.cnki.net

perceiving real-time positions. Addressing the training instability caused by the "heavy-tailed" distribution of financial data, this study innovatively introduces a Symlog reward function based on the Log-Modulus transformation. By implementing scale compression of return feedback through non-linear mapping, this function enhances sensitivity to small values while effectively suppressing extreme volatility interference under the heavy-tailed distribution of financial data, thereby improving the training robustness of deep reinforcement learning in quantitative trading environments.

Empirical results demonstrate that the strategy proposed in this study outperforms traditional benchmark strategies, such as UCRP, EGP, and OLMAR, across multiple core performance indicators. In terms of risk-adjusted returns, the model exhibits robust profitability, with its total return and Sharpe ratio increasing by 9.54% and 2.15, respectively, compared to the optimal benchmark. Regarding risk control, the model achieves a 1.99% reduction in maximum drawdown. The study confirms that this paradigm effectively balances profit acquisition with risk aversion, providing a valuable solution for intelligent quantitative trading.

Keywords: RoBERTa； Financial Sentiment Factor；Deep Reinforcement Learning； DDPG；Quantitative Trading

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....1
1.2 国内外研究现状.....2
1.2.1 金融文本情感分类研究现状.....2
1.2.2 投资组合策略研究现状.....4
1.2.3 LLM 与强化学习量化融合现状.....7
1.3 本文研究内容及贡献.....7
1.4 本文组织结构.....8
第 2 章 相关理论与技术介绍.....11
2.1 投资组合优化理论.....11
2.2 深度学习.....12
2.2.1 词嵌入技术.....13
2.2.2 预训练语言模型：BERT 与 RoBERTa.....13
2.2.3 卷积神经网络.....16
2.3 深度强化学习.....17
2.3.1 马尔可夫决策过程.....17
2.3.2 深度确定性策略梯度.....19
第 3 章 基于 RoBERTa 模型构建股票情绪因子.....23
3.1 文本数据采集与描述.....23
3.2 股评文本数据预处理.....24
3.2.1 数据清洗与去噪.....25
3.2.2 知识蒸馏的数据标注.....25
3.2.3 数据集划分.....27
3.3 股票情感分类模型设计.....27
3.3.1 文本序列化与输入表示.....28
3.3.2 大模型训练.....29
3.3.3 实验评估.....30
3.4 情感因子的生成与有效性检验.....31
3.4.1 价格变动与情感因子的时域相关性分析.....32
3.4.2 基于 Rank IC 的预测能力测度.....33
3.5 本章小结.....35
第 4 章 基于深度确定性策略梯度的股票交易算法.....37

中国知网 https://www.cnki.net

4.1 股票投资组合交易问题描述 37
4.1.1 技术指标 37
4.1.2 股票交易的 MDP 模型 38
4.1.3 纳入股票交易的限制 39
4.2 股票投资组合交易算法的问题建模 40
4.2.1 基于 CNN 的特征提取 40
4.2.2 Actor-Critic 算法框架 40
4.2.3 股票市场环境构建 42
4.3 股票交易策略算法设计与优化 43
4.3.1 情绪因子的消融实验分析 44
4.3.2 非线性 Symlog 奖励函数的消融实验分析 45
4.3.3 与传统基准策略的对比 46
4.4 回测实验与分析 48
4.4.1 数据源 48
4.4.2 评价指标 48
4.4.3 实验结果分析 50
4.5 本章小结 54
第 5 章 总结与展望 55
5.1 工作总结 55
5.2 未来展望 55
参考文献 57

中国知网 https://www.cnki.net

第 1 章 绪论

本章对金融文本挖掘与组合优化领域的文献进行梳理，选择 LLM 驱动的语义识别与深度强化学习的深度融合做量化投资作为本文研究内容，最后阐明贡献和整体研究框架。

1.1 研究背景及意义

在全球金融市场数据快速增长与人工智能算法快速发展的时代下，探索新型量化投资策略成为新的研究方向。本节主要从两个方面展开论述：首先，梳理当前量化投资面临的挑战，介绍本课题的研究背景；其次结合大语言模型与强化学习的前沿优势，探讨本研究在提升金融量化策略理论与应用层面的研究意义。

1.1.1 研究背景

在金融科技迭代的背景中，量化投资的演进路径正由单一的量价数据挖掘向多维信息融合转变。虽然传统模型在捕捉历史线性规律时相对稳健，但它们往往忽略了微观个体的心理溢价，这导致在面对非结构化数据驱动的市场剧变时，模型的鲁棒性明显不足。如今，投资者情绪已不再是外部干扰，而是定价框架中的核心变量。这种集体心理预期不仅解释了短期波动的成因，更在“黑天鹅”事件爆发前，通过社交媒体等文本渠道预先释放出超额收益（Alpha）信号。

早期基于情感词典或浅层学习的情绪测度工具，在触及金融语境的深层含义时往往误判。金融领域的专业词汇密度极高，且频繁出现如“利空出尽”等违背常规语言逻辑的术语，这对依赖特征匹配的初级模型构成了一定挑战。由于无法识别此类复杂的隐喻与动态语义关系，传统方法产出的信号往往掺杂大量噪声，在实盘环境中的信噪比难以支撑高频或高精度的决策需求。

以 BERT 为代表的深度表征学习打破了传统挖掘模式的限制，其上下文敏感特性使得高精度因子的提炼成为可能。在获得这些蕴含市场情绪的特征后，深度强化学习能在与动态市场的实时博弈中，自主寻找不同状态下的最优操作策略，这种非线性的映射机制极大地增强了策略在长期持仓过程中的累积回报。

1.1.2 研究意义

理论意义上，本研究聚焦于中国股市语境下的多模态金融智能量化决策，融合自然语言处理与深度强化学习，具有一定的理论拓展价值。通过在金融文本情感识别中引入

中国知网 https://www.cnki.net

BERT 系列预训练模型进行领域微调，研究提升了模型对中文金融文本中隐性情绪、模糊表达及语境依赖信息的理解能力。进一步地，将情绪因子与股票价格技术指标对齐嵌入 DDPG 强化学习框架中，设计面向金融场景的奖励机制，实现了“市场状态-情绪理解-策略反馈”的闭环建模，推动了金融情绪因子与交易策略优化的协同建模理论发展。

实践意义上，本研究面向中国 A 股市场高波动、高异质性的信息环境，提出了融合文本情感信号的强化学习投资策略，具有一定的现实应用价值。一方面，通过对知识蒸馏获得情绪特征用于 BERT 与 RoBERTa 后训练，结合技术指标进行特征工程处理构建可感知市场情绪变动的情绪因子，提升了策略对非结构化信息的响应能力。另一方面，结合情感驱动机制与 DDPG 的策略优化能力，模型在动态调整持仓与风险控制方面展现出鲁棒性与适应性。多模态信息的引入进一步增强了模型在复杂市场环境中的稳定性与抗干扰能力，为智能投顾、量化基金管理等金融科技场景提供了可行的实现路径。

1.2 国内外研究现状

本研究立足于金融工程与人工智能的深度融合背景。本章将从三个维度构建系统性的文献综述框架：其一，针对非结构化数据的特征提取，剖析金融文本情感分类从传统词典法向预训练语言模型的演进；其二，追溯投资组合策略从经典理论向深度强化学习的转变；其三，深入探究大语言模型与强化学习在量化决策中的协同机制。

1.2.1 金融文本情感分类研究现状

在金融语境中，情感分析尤为重要，其可用于挖掘市场情绪、辅助投资决策。然金融文本具备信息密度高、语言表达复杂、术语结构化程度高等特点，如何准确建模其中隐含的情绪信息成为研究难点。

情感分析模型的发展经历从基于统计学习的传统算法到深度神经网络，再到现阶段主流的预训练语言模型的演变过程，模型性能和方法多样性均有显著提升。早期研究主要依赖于朴素贝叶斯、支持向量机与最大熵等浅层方法。这些模型通常依托 TF-IDF、词袋模型等手工设计的特征表示，难以捕捉金融文本中上下文语义与复杂情绪表达的关系。2009 年，Schumaker 和 Chen 尝试将财经新闻中的投资者情绪特征输入 SVM，用于股票价格预测，验证了情感因子在金融市场建模中的有效性[1]。傅魁等进一步提出将新闻文本的情感倾向强度指标与股票关键指标融合，引入支持向量回归（SVR）模型提升价格预测精度，体现了早期方法对结构性特征的依赖[2]。

随着深度学习的兴起，情感分类方法逐步转向以神经网络为基础的端到端建模框架。

中国知网 https://www.cnki.net

卷积神经网络（CNN）与循环神经网络（RNN）开始在情感分类中展现出强大的特征抽取能力。Kim 将 CNN 应用于文本分类问题，提出了一种 TextCNN 模型，通过词嵌入方式获取中文文本数据的词向量，在多个数据集上获得了较好的情感分类结果[3]。Liu 针对微博短文本进行分类，以词为单位，将词向量送入 CNN 提取句子特征，能够成功判断句子的情感倾向[4]。与传统方法相比，深度神经网络能自动学习文本中的情感表示，尤其在处理社交媒体这类语法不规范、信息密度高的文本时具有更强的鲁棒性。然而，这类模型通常依赖大规模标注数据，且在泛化能力与上下文语义理解方面仍存在不足。

预训练语言模型的出现则显著改善了这一瓶颈。Wu 等指出，大规模语言模型在无监督预训练阶段学习到丰富的上下文语义知识，使其在情感识别任务中具备更强的泛化能力[5]。Nasiopoulos 等和 Xie 等也分别展示了 LLM 在金融情感分析中的应用潜力，尤其是在语义模糊、情绪细粒度表达场景下的表现 [6,7]。为适应金融文本的专业性，研究者尝试将文本摘要技术引入情感分析任务中。齐甜方将 Seq2Seq 模型用于财经新闻摘要生成，并利用摘要的情感值作为股价预测输入特征[8]。相较于直接使用原始文本的做法，该方法提升了对负面情绪信号的识别能力。

在此背景下，基于 BERT 的预训练语言模型在金融情感分析中取得突破性进展。2019 年，Araci 提出 FinBERT 模型，该模型通过在金融新闻与 10-K 财报语料上进行预训练，显著提升了对金融术语与行业表达的理解能力[9]。相较于通用 BERT，FinBERT 在多项金融情感分类任务（如股票评论分析、基于新闻的市场情绪建模）中取得更高的准确率与 F1 分数。但由于 FinBERT 主要针对英文金融语境，在中文场景下的适用性仍有限。

为了进一步提高模型对领域语言的适应能力，研究者逐渐采用在金融语料上微调 LLM 的策略。Wu 等表明通过在财经新闻、社交媒体等金融领域数据上进行微调，可提升 LLM 在复杂语义理解与细粒度情感识别上的表现[5]。Chindukuri 与 Sivanesan 的研究证实通过迁移学习与微调，模型在处理复杂语义分类任务时表现出更高的精确度[10]。Lin 和 Liao 也证实，采用 BERT 和 RoBERTa 对金融文本进行微调，能够构建高性能的情感分类器，进而服务于风险评估与股价预测任务[11]。

Prompt Learning 也逐渐成为 LLM 应用的前沿范式。2023 年，Zhao 等提出，通过精心设计任务导向的 prompt，可以高效引导 LLM 执行特定任务[12]。在情感分析中，构造包含情绪提示词的 prompt 被证明能够提升分类准确性。

尽管金融情感分类研究已取得重要进展，仍面临诸多挑战。其一，高质量的金融情

中国知网 https://www.cnki.net

感标注语料仍十分稀缺，制约了监督模型的泛化性能；其二，金融文本的表达往往具有语义模糊性、含蓄性，与市场行为之间的映射存在非线性与滞后性；其三，跨语种、跨市场的数据分布差异对模型迁移能力构成了重大考验。

1.2.2 投资组合策略研究现状

在金融市场中，投资组合策略的目标在于在风险可控的前提下实现收益最大化。该领域的发展经历了从早期的经典理论到近年来借助人工智能特别是深度强化学习技术的发展。本文将系统梳理该领域的发展脉络，从马科维兹均值-方差理论出发，逐步过渡到基于机器学习与深度强化学习的动态资产配置方法。

（1）传统投资组合策略

投资组合理论最早由哈里·马科维兹（Harry Markowitz）在 1952 年提出，其核心思想是通过对资产的期望收益与协方差矩阵建模，构建均值-方差优化模型[13]。在该模型中，投资者在给定风险水平下追求组合收益的最大化，或在预期收益目标下实现组合风险的最小化。该理论建立了组合多样化的基本逻辑，提出有效前沿的概念，成为现代投资组合理论的奠基石。然而，马科维兹模型假设市场收益服从正态分布、资产之间关系线性等前提，在现实市场中往往难以满足。尤其是在面对高频、多资产、非线性动态的金融数据时，其静态的建模方式和较强的参数敏感性暴露出一定局限性。

为缓解上述问题，后续研究者在马科维兹模型基础上进行了诸多改进。马科维茨的学生 Sharpe 对模型进行了简化 提出了经典的 CAPM 模型[14]。1976 年，Ross 提出了 APT 模型，该模型认为套利是形成价格的决定因素[15]。1990 年，Black 和 Litterman 提出 Black-Litterman 模型，基于概率统计方法，对收益率进行贝叶斯收缩，结合投资者的主动判断来配置资产的权重[16]。该模型将股票投资的收益率分解为股票自身的额外收益和市场外部风险相关的部分，提供了可实际计算的框架，投资者可以根据资产的价值权重配置资产，但该模型假设资产是无限可分的，在现实中难以实现。Arnott 等研究发现，当投资组合模型中加入了交易成本的约束后，投资组合的最优策略也将改变[17]。Konno 等综合考虑了交易成本和最低交易量对投资组合进行优化模型[18]。Suraj 等构建了同时包括交易成本、收益、风险的目标函数，基于多目标进化算法提出了一种新的修复算法，提高了预测的准确性[19]。尽管这些扩展在实践中取得了一定成效，但多数仍基于静态假设或简化的市场机制，难以捕捉资产价格的动态演化过程。随着时间序列建模技术的发展，动态规划与时变贝叶斯等方法逐渐引入到资产配置框架中，为组合策略的动态更新提供理论基础。

中国知网 https://www.cnki.net

进入 21 世纪后，人工智能技术特别是机器学习的迅猛发展为投资组合管理带来新机遇。监督学习被广泛用于收益预测与风险建模，聚类方法用于资产分类与因子提取，主成分分析与降维技术则有助于从高维金融数据中提取结构性信号。McDonald 等将线性的统计学模型与非线性的机器学习相结合，能够有效的对金融数据时间序列进行预测[20]。Wang 等提出了一种由 LSTM 网络和均值-方差模型组成的混合方法，在英国股票市场取得了较好的表现[21]。然而，这些方法大多仍作为预测工具服务于传统优化框架，在决策层面缺乏端到端优化能力。此外，监督学习对标签依赖强，金融市场的非平稳性导致训练样本在时间上的分布漂移，使得策略鲁棒性难以保证。

（2）深度强化学习投资组合策略

为了更好地在不确定环境中进行实时决策，强化学习逐渐成为学术界与业界关注的焦点，强化学习无需预设明确的监督目标，而是通过智能体与环境的交互学习来解决复杂问题。DRL 能够通过与市场环境的交互，在无监督或弱监督信号下自动学习资产配置策略，并动态调整投资行为，以实现风险调整后的收益最大化。

根据学习策略与目标函数设计的差异，现有 DRL 方法大致可划分为三类：基于值函数的方法、基于策略的方法以及基于 Actor-Critic 方法。

基于值函数的方法主要通过估计状态值函数或状态-动作值函数，以评估在特定策略下每个状态或状态-动作对的长期期望回报，从而指导最优策略的选择。该类方法的核心思想是通过近似学习最优值函数，再基于贪婪策略导出相应动作，从而实现策略的优化。其中，具有代表性的算法为深度 Q 网络（Deep Q-Network），它在传统 Q-learning 算法的基础上引入深度神经网络对 Q 值函数进行逼近，显著提升了强化学习在高维状态空间中的应用能力。DQN（Deep Q-Network）的提出使得强化学习在诸如金融交易、智能控制、博弈决策等复杂任务中取得了突破性进展。值函数方法在建模离散动作空间的任务中表现优越，适用于“买入/卖出/持有”这类具有有限选项的交易决策问题。

Hu 进一步完善了 DQN 在量化交易中的应用，在加密货币与股票的实验中，该模型在累计收益率与夏普比率上均显著优于传统基准策略，验证了值函数方法在实盘任务中的潜力[22]。然而，值函数方法在处理连续动作空间场景时，由于面临维度灾难与动作空间离散化带来的精度瓶颈，应用受限于模型结构与优化效率。

与基于值函数的方法不同，基于策略的方法不再显式估计状态或状态-动作的价值函数，而是直接对策略函数进行建模，从当前状态出发输出一个动作概率分布。该类方法通过优化策略参数以最大化期望累计回报，具备更高的表达灵活性。典型代表包括

中国知网 https://www.cnki.net

REINFORCE 算法，它通过采样方式计算策略梯度，实现对策略的迭代优化；信赖域策略优化（TRPO）则引入对策略更新幅度的约束，以避免策略发生剧烈变化而导致训练不稳定；而近端策略优化（PPO）在保留 TRPO 稳定性的同时提升了算法的计算效率与实现简便性，因而被广泛应用于各种实际任务中。由于策略方法天然支持对连续动作空间的建模，较值函数方法在处理复杂高维动作决策问题中更具优势，尤其适用于资产配置比例可连续调整的多资产投资组合优化场景。通过建模资产权重的连续分布，该类方法能够有效捕捉资产间的协同效应与市场动态变化，在金融市场中展现出更高的策略灵活性与收益优化潜力。

2019 年，Li 等提出将深度确定性策略梯度（DDPG）算法引入多资产组合管理中，显著提升了模型在累计收益与夏普比率等指标上的表现[23]。2024 年，Li 等在 PPO 等算法的基础上引入了做空机制并考虑了交易成本，提升了模型在真实复杂交易环境中的适用性[24]。这类方法的优势在于优化稳定性较好，能在复杂金融环境中实现高频决策，但其训练过程对奖励信号高度敏感，易受高方差影响，可能导致收敛缓慢或策略波动。

Actor-Critic 方法综合了基于值函数与基于策略方法的优势，通过协同训练两个子网络实现策略优化。其中，“Actor”模块负责生成动作，即直接输出当前状态下的策略分布；而“Critic”模块则对当前策略下的状态值或动作值进行估计，为 Actor 的更新提供方向性反馈。这种策略与价值的协同学习机制不仅加快了收敛速度，还提升了策略的稳定性与泛化能力。典型算法包括同步优势策略（Advantage Actor-Critic）、异步优势策略（Asynchronous Advantage Actor-Critic）、延迟深度确定性策略梯度（Twin Delayed Deep Deterministic Policy Gradient）以及软策略梯度（Soft Actor-Critic， SAC）等，尤其在处理高维连续控制任务时表现优越，广泛应用于自动驾驶、智能制造与量化投资等领域。

近年来，研究者逐渐将 Actor-Critic 方法应用于更复杂的投资组合优化任务中。2015 年，Lillicrap 等提出 DDPG 算法，该算法在连续动作空间中表现出色，是一种典型的 off-policy 策略梯度方法[25]。Liu 构建了 FinRL 平台，整合包括 DDPG 在内的多种强化学习算法，支持在 A 股、美股实盘数据上进行交易策略开发与评估[26]。

综上所述，DRL 在投资组合优化中的方法不断演进，从早期的值函数估计到策略优化，再到融合双重机制的 Actor-Critic 框架，不仅提升了策略的表达能力，也增强了模型对市场复杂性与风险因素的适应性。在未来研究中，如何构建高质量的奖励设计机制、引入多模态金融信息、提升策略的可解释性与部署能力，将是强化学习在金融投资落地的关键方向。

中国知网 https://www.cnki.net

1.2.3 LLM 与强化学习量化融合现状

近年来，大语言模型（LLM）在自然语言理解与生成领域展现出强大的泛化与推理能力，为金融领域的智能决策系统提供新的可能。将 LLM 与强化学习进行集成，借助 LLM 在语义理解、情绪识别与知识抽取方面的能力，通过强化学习在策略学习、环境交互与自适应决策中的优势，推动金融智能体向“可感知-可学习-可决策”方向演进。

Unnikrishnan 指出，LLM 可以为强化学习系统提供更丰富的状态空间输入，尤其是在金融市场中复杂且难以量化的因素如投资者情绪、政策导向、重大新闻事件等方面，LLM 具备较强的信息抽象与概括能力[27]。Botunac 等提出将 LLM 生成的金融文本特征引入强化学习交易框架，并通过实证实验表明该方法能够提升策略收益表现[28]。Wang 等则在综述研究中系统总结了 LLM 在金融交易中的应用范式，指出融合文本信息与强化学习是重要的发展方向[29]。

在“情感驱动强化学习”方向，已有研究尝试利用 LLM 从金融新闻、社交媒体评论等非结构化文本中提取情感特征，并将其作为 RL 模型的状态变量输入，以实现更符合市场情绪演化的交易行为。Unnikrishnan 构建了融合 LLM 情感分析与 DDPG 算法的股票交易策略框架，通过将 LLM 提取的市场情绪特征作为状态输入，显著提高了策略在不同市场阶段的鲁棒性与敏感性[27]。Etcil 等亦采用类似方法，将 LLM 对社交平台文本的情绪识别结果用于强化学习策略训练，验证了情感信号在捕捉短期市场情绪波动方面的重要价值[30]。

除状态建模外，LLM 在策略探索环节同样展现出潜力。2024 年 Huang 等提出，强化学习训练过程普遍面临“试错效率低、样本利用率不高”等挑战，而 LLM 可以通过生成具备启发性的候选策略、识别高价值交易时机等方式，辅助策略空间的初始探索[31]。Hao 等进一步发展出基于 LLM 引导的策略生成机制，使强化学习代理能够更快接近最优策略，从而减少训练时间与资源消耗[32]。

尽管已有初步研究探索了 LLM 与 DRL 的融合机制，当前多数研究仍以 LLM 与强化学习各自独立应用于量化投资为主，将两者深度融合的研究尚处于起步阶段。

1.3 本文研究内容及贡献

本文旨在构建一个融合大语言模型（LLM）与深度强化学习（DRL）的量化交易决策框架，以实现市场情绪驱动下的投资策略优化。研究先通过定向爬取上证 50 成分股的高频评论数据，构建金融舆情语料库，并利用大模型知识蒸馏与后训练提升 RoBERTa

中国知网 https://www.cnki.net

与 Bert 模型对隐性语义的捕捉精度。本文设计了一种多模态特征融合方案，将提取的情绪因子与历史量价序列、技术指标共同嵌入高维状态空间，并通过卷积神经网络（CNN）实现特征降维。最后通过 DDPG 算法构建交易智能体，在多资产配置场景下动态演化投资决策，实现了对市场波动与持仓状态的深度感知。

论文的创新点主要体现在以下两个方面：第一，在多维情绪表征与因子验证层面，本文克服了金融文本标注数据稀缺的问题，提出一种基于大模型知识蒸馏的情绪因子构建路径。通过大模型对数据进行低延迟、高并发的自动标注，再通过特征工程挖掘出情绪动量、背离及移动平均核心情感因子，并经由 IC 值检验验证了其对市场异动的预测效力，有效捕捉了信息不对称环境下的情绪波动特征。第二，在强化学习算法优化层面，针对金融数据的的“重尾”分布特征，本文创新性地引入基于 Log-Modulus 变换的 Symlog 奖励函数。该函数通过非线性映射实现收益反馈的尺度压缩，在增强小数值敏感度的同时，有效抑制了金融数据重尾分布下的极端波动干扰，提升了深度强化学习在量化交易环境中的训练稳健性。

1.4 本文组织结构

本文依据“问题提出→文献总结→大语言模型构建日度股票情绪多因子→强化学习量化交易策略的消融实验证明情绪因子与 Symlog 奖励函数相对于传统交易策略的优越性→总结与展望”的研究脉络，按照五个章节进行展开并进行细致性研究，如图 1 所示。

中国知网 https://www.cnki.net

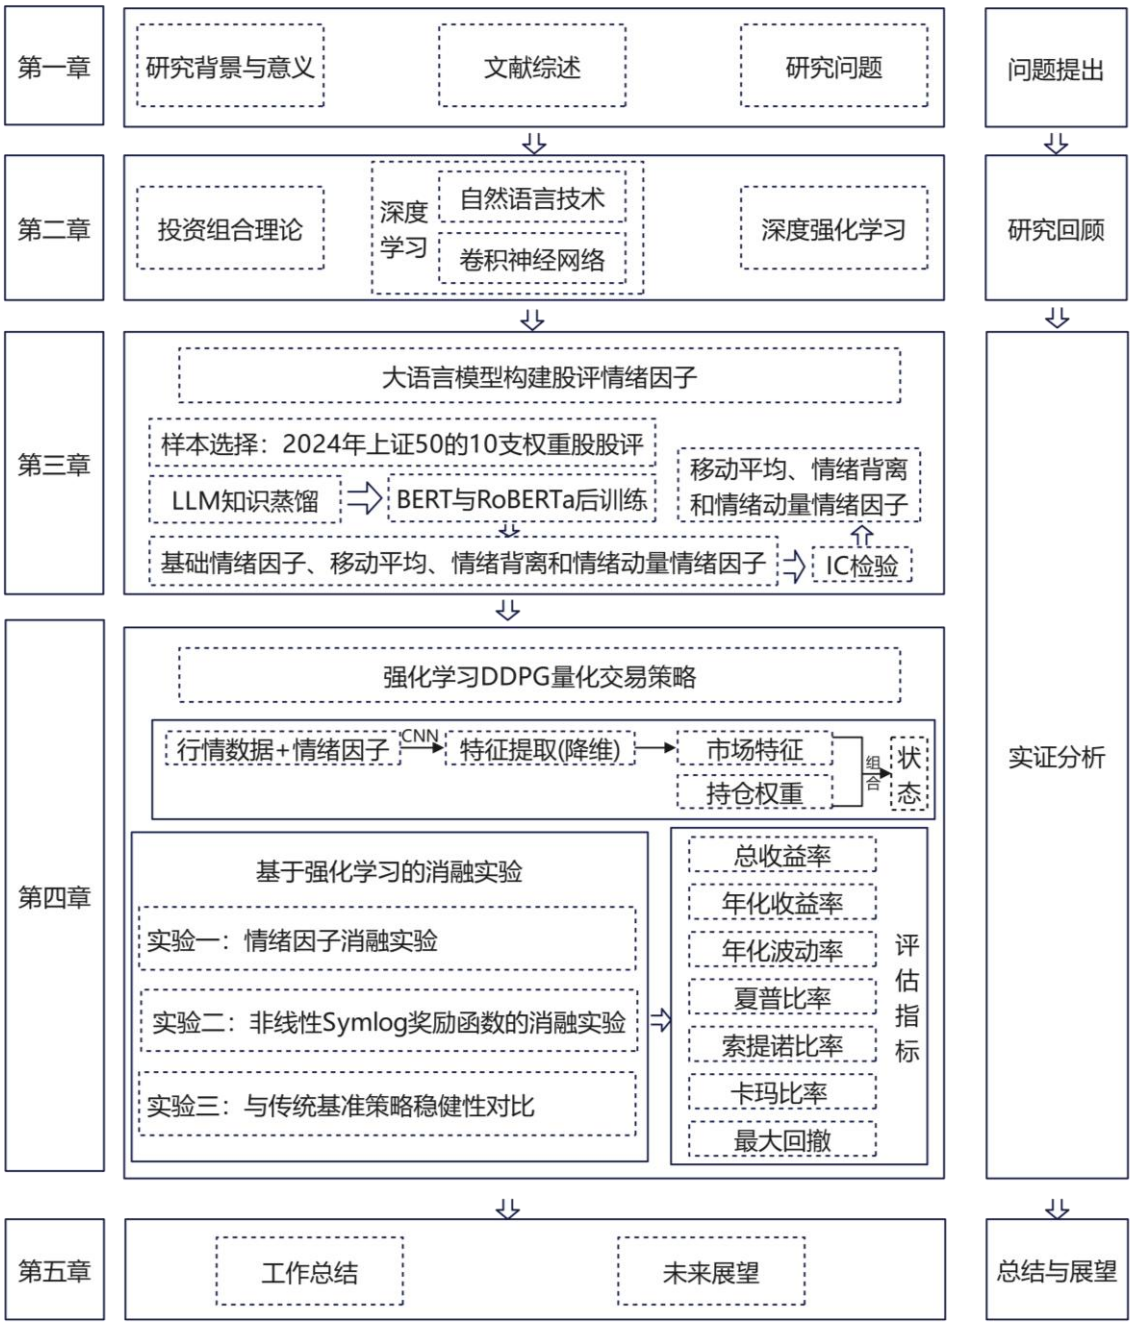


图 1 研究思路框架图

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 2 章 相关理论与技术介绍

本章旨在为后续构建的金融情感分类模型与深度强化学习交易策略奠定理论基础。一方面，本章介绍应用于金融文本情感分析的自然语言处理技术。内容从核心的 Transformer 架构入手，进而阐述作为本研究技术基石的 BERT 预训练语言模型，并详细说明其在特定领域任务中的微调机制。另一方面，本章将聚焦于深度强化学习在量化交易中的应用理论。阐明如何将复杂的股票投资组合管理问题抽象并形式化为马尔可夫决策过程，并深入剖析能够有效处理连续动作空间的深度确定性策略梯度算法，及其所依赖的行动者-评论家框架。

2.1 投资组合优化理论

投资组合问题是现代金融学的核心，旨在研究如何在多个具有不同风险收益特征的资产间进行资本分配，以实现风险与收益的最佳平衡。现代投资组合理论（Modern Portfolio Theory ，MPT）为该类问题奠定了理论基石，这一经典框架可追溯至哈里·马科维茨于 1952 年发表的开创性研究[14]。MPT 理论的核心思想在于，任何单一资产的风险都包含系统性风险和非系统性风险。非系统性风险是特定于公司或行业的风险，可以通过构建一个多元化的资产组合来显著降低甚至消除。因此，理性的投资者不应仅关注单个资产的风险收益特征，而应着眼于整个投资组合的整体表现，MPT 理论使用两个关键指标来度量投资组合的特性。

期望收益率：投资组合的期望收益率是其构成资产期望收益率的加权平均值。假设一个投资组合由 n 种资产构成，其中第i种资产的权重为w_i，第i种资产的收益率为为R_i，其期望收益率$E[R_i]$，投资组合的期望收益率$E[R_p]$，计算如公式（2-1）所示。

$$E[R_p] = \sum_{i=1}^{n} w_i E[R_i]. \tag{2-1}$$

风险：MPT 理论采用方差或标准差来量化风险，即收益率的波动程度。与期望收益率不同，投资组合的风险不仅是各资产风险的加权平均，还受到各资产之间收益率的相关性所影响，通过协方差来体现。投资组合的方差 σ_p^2 计算公式如（2-2）所示。

$$\sigma_p^2 = \sum_{i=1}^{n} \sum_{j=1}^{n} w_i w_j \sigma_{ij}. \tag{2-2}$$

其中，σ_i^2 是资产i的方差，σ_{ij}是资产i和资产j收益率的协方差。协方差衡量了两种资产收益率的同步变动程度。当资产间的协方差为负或较低时，组合的总风险能够被

中国知网 https://www.cnki.net

有效降低。

基于上述定义，马科维茨将投资组合选择形式化为一个“均值-方差”多目标优化问题。如图 2 所示，该模型首先构建了风险资产的有效边界，其呈现为一条向左凸的双曲线。在此边界上的每一个点，均代表在给定风险水平（标准差）下期望回报率最高的投资组合；反之，在给定回报目标下，其承担的风险最小。位于该曲线内部及下方的区域均被视为次优组合。

进一步结合图 2 可见，当引入无风险投资（图中纵轴截距）后，投资者的可行集发生了质的改变。新的有效边界变为一条从无风险收益率出发、与风险资产有效边界相切的射线，即图中标注的“包含无风险投资的有效边界”（通常称为资本配置线，CAL）。该射线与双曲线的切点被称为切点组合或有效投资组合。

相比于仅持有风险资产，理性的投资者可以通过持有无风险资产与切点组合的加权配置，在这条线性的有效边界上获得更高的夏普比率。因此，投资者可根据自身的风险偏好，在这条直线上选择最优的资产配置点，从而实现效用最大化。

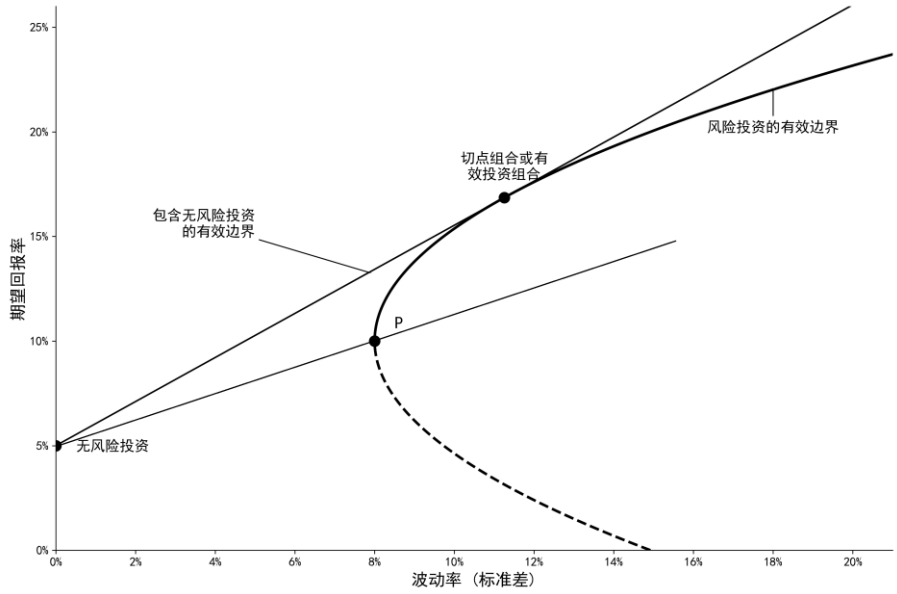


图 2 基于马科维茨均值-方差模型的资产配置与有效前沿图

2.2 深度学习

深度学习可以通过多层神经网络架构实现高维金融数据中隐性非线性规律的深度挖掘。本节探讨三个方面：其一，自然语言处理中词嵌入技术的发展；其二，预训练语言模型 BERT 与RoBERTa；其三，通过卷积神经网络进行特征提取与降维。

中国知网 https://www.cnki.net

2.2.1 词嵌入技术

在利用深度学习处理金融舆情情感分类任务时，需要解决如何将非结构化的文本转换为模型可计算的数值表征。早期的自然语言处理主要依赖规则系统或基于统计学习的N-gram、支持向量机（Support Vector Machine ，SVM）等模型。尽管这些方法在特定领域取得了一定进展，但其高度依赖人工特征工程，且难以捕捉深层语义关联，限制了情感分类任务的上限。为突破人工特征工程的局限并解决文本表征的“维度灾难”问题，词嵌入（Word Embedding）技术应运而生。词嵌入旨在通过神经网络将离散的、高维稀疏的词语映射为低维、稠密的连续向量。其中，Mikolov 等人提出的 Word2Vec 模型利用神经网络通过无监督学习将离散的词语映射为低维稠密向量，有效捕捉了词汇间的语义与语法关系[33]。随后，GloVe、FastText 等技术的出现进一步增强了词向量的表征能力。

词嵌入技术的引入，使得模型具备了自动学习特征的能力，能够根据词语在空间中的距离来衡量语义的相似度。然而，上述早期的静态词向量技术存在一个固有缺陷：每个词被赋予固定的向量表示，无法根据具体的上下文语境动态调整，从而难以有效解决自然语言中普遍存在的“一词多义”问题。这一局限性也催生了后续基于 Transformer 架构的动态预训练模型的发展。

2.2.2 预训练语言模型：BERT 与 RoBERTa

针对上述问题，基于“预训练-微调”的新范式彻底改变了 NLP 领域。其中，由 Google 团队于 2018 年提出的 BERT（Bidirectional Encoder Representations from Transformers）模型是这一领域的里程碑式成果[34]。BERT 摒弃了传统的循环网络结构，完全基于 Transformer 架构，通过在大规模无监督语料上进行预训练，学习到了丰富的语言知识。本实验采用 BERT 模型作为情感分析的核心组件，其整体结构及后训练示意图如图 3 所示。

中国知网 https://www.cnki.net

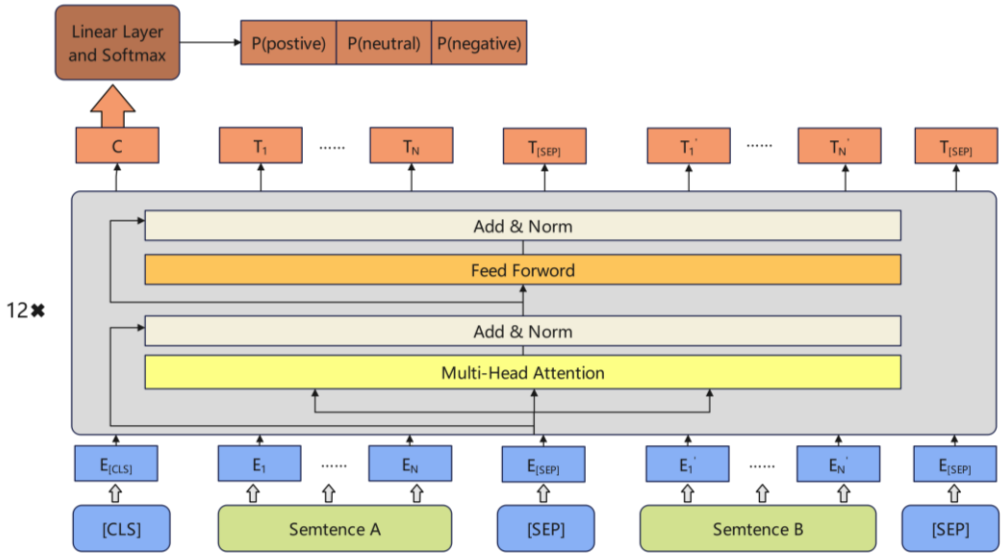


图 3 BERT 模型结构及情感分类微调示意图

BERT 的模型主体由 12 层 Transformer 编码器堆叠而成。其核心创新在于引入了多头自注意力机制（Multi-Head Self-Attention），该机制允许模型在处理序列中任意一个词时，能够同时关注并融合所有其他词的信息，从而捕捉全局依赖关系。

具体而言，自注意力机制通过计算查询向量（Query）、键向量（Key）和值向量（Value）之间的相互作用来动态赋予不同词语以不同的权重。其计算过程如公式（2-3）所示：

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V. \qquad (2\text{-}3)$$

其中，$Q(Query), K(Key), V(Value)$是由输入词向量经过线性变换得到的矩阵，$d_k$是$K$向量的维度，为了规避因向量维度$d_k$过大而引发的 Softmax 梯度爆炸风险，通常会对点积结果实施尺度缩放。所谓的“多头”，即如图 3 中黄色模块所示，通过并行执行多次上述注意力计算，使模型能够从不同的子空间学习词语间多维度的句法和语义关联。

本实验通过利用 BERT 处理金融舆情情感分类任务，具体实施方案如图 3 顶部所示，提取[CLS]标记在最后一层的输出向量，将其输入到一个全连接线性层（Linear Layer），如图 4 所示,并配合 Softmax 激活函数进行分类。模型输出为一个概率分布，分别对应“积极（Positive）”、“中性（Neutral）”和“消极（Negative）”三种情感类别。通过在标注好的金融文本数据上对这一结构进行微调，模型能够根据具体语境动态调整参数，实现对文本深层语义的精确理解与情感判定。

中国知网 https://www.cnki.net

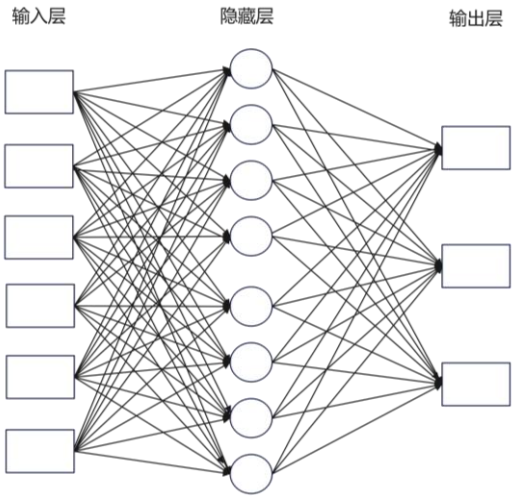


图 4 神经网络结构图

BERT 模型通过其双向 Transformer 结构和预训练策略，可以克服传统方法对特征工程的依赖，以及早期词嵌入模型难以处理一词多义的问题。该模型能够根据具体语境动态调整词向量表示，从而实现对语言更深层次的语义建模。

在 BERT 模型的基础上，RoBERTa（Robustly Optimized BERT Pretraining Approach）对预训练策略进行了系统性优化。RoBERTa 主要从训练数据规模、训练策略以及任务设计等方面对 BERT 进行了改进。

在数据层面，RoBERTa 扩展了预训练语料规模，引入了包括 CC-News、OpenWebText 等在内的大规模文本数据，从而提升了模型对多样化语言模式的建模能力。在训练策略上，RoBERTa 采用更大的批量规模并延长训练时间，以充分挖掘模型容量，缓解 BERT 存在的欠训练问题。此外，RoBERTa 将 BERT 中的静态掩码机制改为动态掩码，在每个训练轮次中随机生成掩码位置，从而提高了训练数据的利用效率。

在任务设计方面，RoBERTa 移除了 BERT 中的下一句预测（Next Sentence Prediction, NSP）任务。RoBERTa 专注于掩码语言模型（Masked Language Model, MLM）任务，从而获得更优的语义表示能力。RoBERTa 采用基于字节级别的 BPE 分词方法，相较于 BERT 的 WordPiece 分词，可以有效地处理未登录词问题并提升跨语种适应性。

综上所述，RoBERTa 通过对预训练策略的系统优化，在保持 Transformer 编码器结构不变的前提下显著提升了语言表示能力。在文本分类、情感分析等下游任务中，其性能通常优于 BERT 模型。因此，本文在后续实验中将综合考虑两种模型的表现，以充分验证不同预训练策略对金融文本情感分类任务的影响。

中国知网 https://www.cnki.net

2.2.3 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）是深度学习领域中最具代表性的模型之一，其设计灵感来源于生物视觉皮层对信息的层级化处理机制。自 LeCun 等人提出经典的 LeNet-5 模型并成功应用于手写数字识别以来，CNN 已成为计算机视觉领域的基石，其应用不仅在图像分类、目标检测等任务中取得了革命性的突破，近年来也逐渐扩展至自然语言处理等领域[35]。

与传统的全连接神经网络不同，CNN 通过特殊的网络结构设计，能够有效地提取输入数据的局部特征并保持空间结构信息。如图 5 所示，一个典型的卷积神经网络主要由卷积层（Convolutional Layer）、池化层（Pooling Layer）和全连接层（Fully Connected Layer）构成，各层之间通常还会穿插非线性激活与归一化操作，共同完成从底层特征到高层语义的抽象过程。

（1）卷积层（Convolutional Layer）

卷积层是本模型提取时序特征的核心组件。如图 5 所示，输入数据为多维时间序列（纵轴为 Features，横轴为 Time），模型采用 Conv1d（一维卷积）对数据进行处理。与图像处理中的二维卷积不同，本研究中的卷积核在“特征”维度上通常覆盖所有的输入特征通道，仅沿“时间”轴方向进行滑动窗口运算。卷积核本质上是一个权重可学习的矩阵，通过在时间轴上的滑动，卷积核与输入数据在局部时间窗口内进行点积运算。这种机制使得模型能够捕捉不同技术因子或情绪指标在特定时间跨度内的非线性组合关系。同时，“局部连接”与“权值共享”的特性不仅显著减少了参数数量，降低了过拟合风险，还赋予了网络对时间平移的不变性。卷积输出后通常连接批归一化层和非线性激活函数，以加速收敛并增强模型对复杂市场模式的非线性表达能力。

（2）池化层（Pooling Layer）

池化层紧随卷积层之后，图 5 展示了 MaxPool（最大池化）的操作过程。在时间序列分析中，池化的主要作用是对特征图在时间维度上进行下采样。如图 5 所示，经过卷积提取的多通道特征序列，通过池化操作被压缩，每个通道仅保留窗口内的最显著特征。这一过程在保留最关键的市场信号的同时，去除了冗余的时间维度信息，从而将变长的或高维的时间序列特征转化为固定长度的特征表示。这种降维操作不仅扩大了后续层的感受野，还增强了模型对输入数据在时间轴上微小位移或噪声的鲁棒性。

中国知网 https://www.cnki.net

（3）全连接层（Fully Connected Layer）

在经过多层“卷积-激活-池化”的堆叠，提取到高度抽象的特征后，数据进入全连接阶段。如图 5 右侧所示，多维特征图首先经过 Flatten（展平）操作，被重塑为一个一维向量，随后输入全连接层。全连接层的结构与多层感知机（MLP）类似，其作用是对提取到的分布式特征进行全局整合与加权，并将最终的学习结果映射到样本的标签空间，用于执行分类或回归任务。

综上所述，卷积神经网络通过“卷积-池化”的堆叠来构建一个深度的特征提取器，实现了从低阶的简单特征到高阶的复杂特征的层级化学习，对原始特征进行降维处理，其局部连接和权值共享的设计理念，使其在处理具有网格结构的数据时具有天然的优势。以 AlexNet[36]、VGG 及 ResNet 为代表的经典 CNN 模型，通过持续优化网络深度与结构设计，不断刷新各项视觉任务的性能标准，已成为深度学习发展史上重要的里程碑。

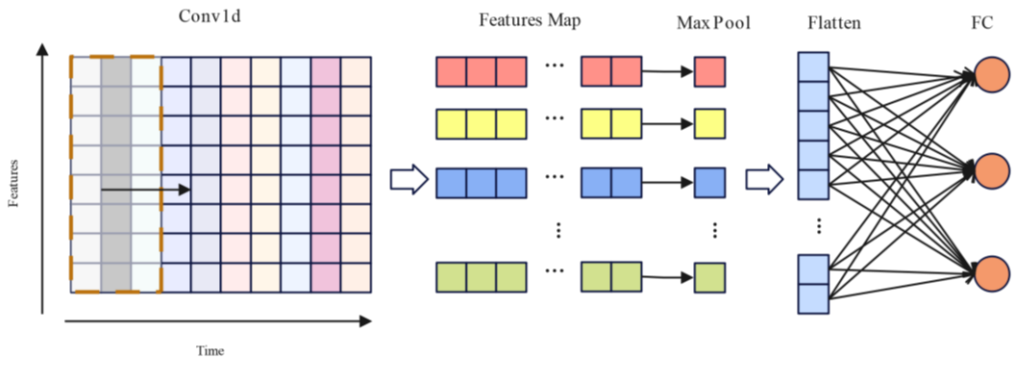


图 5 卷积神经网络基本结构与处理流程示意图

2.3 深度强化学习

本节讲述通过马尔可夫决策过程为量化交易环境提供形式化的数学描述，重点说明深度确定性策略梯度（DDPG）算法和“演员-评论家”（Actor-Critic）架构如何解决连续动作空间下的策略寻优难题，从而为后文的实证建模提供算法支撑。

2.3.1 马尔可夫决策过程

马尔可夫决策过程（Markov Decision Process ，MDP）是强化学习问题在数学上的形式化框架，为智能体在不确定环境中进行序贯决策提供了理论基础，MDP 的核心在于马尔可夫性质，即未来状态的概率分布只依赖于当前状态和动作，而与过去的历史无关。强化学习的目标就是寻找一个最优策略π^*，使得智能体在该策略下与环境交互所能

中国知网 https://www.cnki.net

获得的累积期望奖励最大化[37]。一个标准的 MDP 可以由一个五元组(S,A,P,R,γ)来定义：

状态空间（State Space）S:状态$s\in S$是对环境在某一时刻的完整描述。在量化交易中，状态可以是一个包含多维度信息的向量，如历史 K 线数据（开盘价、收盘价、最高价、最低价）、交易量、一系列技术指标，以及本研究中还引入的情绪因子。

动作空间（Action Space）A:动作$a\in A$是智能体在感知到环境状态后可以采取的行动集合。在量化交易任务中，对于单个资产，动作可以离散化为“买入”、“卖出”、“持有”；更精细的控制则可以定义为连续的动作空间，动作$a\in[-1,1]$可以表示卖出（-1 到 0）或买入（0 到 1）的资金比例。对于投资组合管理，动作则是一个决定各项资产权重分配的向量。

状态转移概率（State Transition Probability）$P(s'|s,a)$:该函数定义了在状态s下执行动作后，环境转移到下一个状态s'的概率，即$P_a(s'|s,a)=P[S_{t+1}=s'|S_t=s,A_t=a]$。

奖励函数（Reward Function）$R(s,a,s')$：奖励函数定义了智能体在状态s执行动作a并转移到状态s'后获得的即时奖励r_t。奖励函数的设计直接关系到学习目标的实现。在量化交易中，奖励函数可以被设计为实现交易后的即时收益率或是考虑了风险因素的复合指标。一个有效的奖励函数能够引导智能体学习到既能盈利又兼顾风险控制的策略。

折扣因子（Discount Factor）γ:折扣因子$\gamma\in[0,1]$体现了未来奖励相对于当前奖励的重要性。一个接近 0 的γ值会使智能体更关注即时奖励，而一个接近 1 的γ值则会使智能体更具远见，追求长期累积奖励的最大化。

强化学习的目标是寻找一个最优策略π^*，这种策略能够最大化从起始状态开始的期望累积折扣奖励，也称为回报。策略π是一个从状态到动作的映射，$\pi(a|s)=P[A_t=a|S_t=s]$，表示在状态s下选择动作a的概率。长期回报的公式定义如 2-4 所示。

$$G_t=\sum_{k=0}^{\infty}\gamma^k R_{t+k+1}. \tag{2-4}$$

为了评估一个策略的优劣，引入了两个核心的价值函数，分别为状态价值函数与动作价值函数。

状态价值函数$V^{\pi}(s)$: 表示从状态s出发，遵循策略π所能获得的期望回报。

中国知网 https://www.cnki.net

$$V^{\pi}(s)=E_{\pi}[G_t|S_t=s]=E_{\pi}\left[\sum_{k=0}^{\infty}\gamma^k R_{t+k+1}|S_t=s\right]. \quad (2\text{-}5)$$

动作价值函数$Q^{\pi}(s,a)$：表示在状态s下执行动作a，然后遵循策略π所能获得的期望回报

$$Q^{\pi}(s,a)=E_{\pi}[G_t|S_t=s,A_t=a]=E_{\pi}\left[\sum_{k=0}^{\infty}\gamma^k R_{t+k+1}|S_t=s,A_t=a\right]. \quad (2\text{-}6)$$

价值函数满足递归关系，即著名的贝尔曼期望方程（Bellman Expectation Equation）：

$$V^{\pi}(s)=\sum_{a\in A}\pi(a|s)\sum_{s'\in S}P(s'|s,a)[R+\gamma V^{\pi}(s')]. \quad (2\text{-}7)$$

$$Q^{\pi}(s,a)=\sum_{s'\in S}P(s'|s,a)\left[R+\gamma\sum_{a'\in A}\pi(a'|s')Q^{\pi}(s',a')\right]. \quad (2\text{-}8)$$

最优策略π^*对应的价值函数 $Q^*(s,a)$是所有策略中最大的，它们满足贝尔曼最优方程（Bellman Optimality Equation）：

$$V^*(s)=\max_a\sum_{s'\in S}P(s'|s,a)[R+\gamma V^*(s')]. \quad (2\text{-}9)$$

$$Q^*(s,a)=\sum_{s'\in S}P(s'|s,a)\left[R+\gamma\max_{a'}Q^*(s',a')\right]. \quad (2\text{-}10)$$

通过求解贝尔曼最优方程，原则上可以找到最优策略。然而，在量化交易这类状态和动作空间巨大甚至连续的复杂问题中，直接求解是不可行的，需要借助函数逼近的方法，即利用深度神经网络来近似价值函数或策略函数——深度强化学习。

2.3.2 深度确定性策略梯度

深度确定性策略梯度（Deep Deterministic Policy Gradient，DDPG）算法是一种专为解决连续动作空间问题而设计的深度强化学习算法。它结合了深度 Q 网络（DQN）和确定性策略梯度（Deterministic Policy Gradient，DPG）的思想，采用演员-评论家（Actor-Critic）架构，并成功地将深度 Q 网络（DQN）的思想与确定性策略梯度（DPG）理论相结合，使其在处理如资产配置、交易量决策等连续型量化交易任务时表现出色[38]。

DDPG 的框架包含四个核心的神经网络，如图 6 所示。演员网络$\mu(s|\theta^{\mu})$是一个策略网络，它接收当前状态s作为输入，输出一个确定的动作a，即$a=\mu(s|\theta^{\mu})$。θ^{μ}是该网络的参数。演员的目标是学习一个最优的确定性策略，以最大化长期回报；评论家网络$Q(s,a|\theta^{Q})$是一个动作价值网络，它接收状态s和演员网络输出的动作a作为输入，评估在

中国知网 https://www.cnki.net

该状态下执行该动作的价值，即$Q(s,a)$。θ^{Q}是该网络的参数。评论家的目标是尽可能准确地估计演员所执行动作的Q值。目标演员网络$\mu'(s|\theta^{\mu'})$结构与演员网络完全相同，其参数$\theta^{\mu'}$定期从演员网络的参数θ^{μ}缓慢更新而来。目标评论家网络$Q'(s,a|\theta^{Q'})$结构与评论家网络完全相同，其参数$\theta^{Q'}$定期从评论家网络的参数θ^{Q}缓慢更新而来。

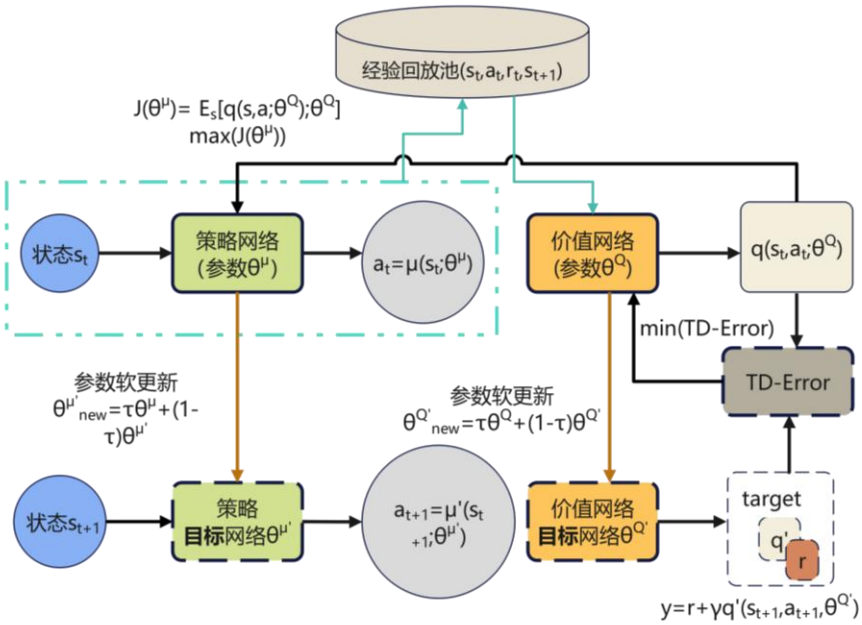


图 6 强化学习 DDPG 原理图

评论家网络的更新遵循时序差分学习的原则。智能体与环境交互，产生一个四元组(s_t,a_t,r_t,s_{t+1})，并将其存入经验回放池。训练时，从池中随机采样一个小批量的样本(s_t,a_t,r_t,s_{t+1}).。评论家网络的目标是最小化以下损失函数$L(\theta^{Q})$

$$L(\theta^{Q})=\frac{1}{N}\sum_{t}(y_t-Q(s_t,a_t|\theta^{Q}))^2. \tag{2-11}$$

其中，y_t是目标Q值，由目标网络计算得出：

$$y_t=r_t+\gamma Q'(s_{t+1},\mu'(s_{t+1}|\theta^{\mu'})|\theta^{Q'}). \tag{2-12}$$

目标演员网络μ'先根据下一状态s_{i+1}预测出最优动作$a'=\mu'(s_{t+1}|\theta^{\mu'})$，然后目标评论家网络$Q'$评估在$s_{t+1}$状态下执行动作$a'$的价值。这种方式避免了在连续动作空间中进行最大化操作的困难。

演员网络的目标是输出能够让评论家网络给出更高Q值的动作。因此，其更新基于确定性策略梯度定理，通过最大化评论家网络输出的Q值来更新策略参数。其目标函数可以表示为：

中国知网 https://www.cnki.net

$$J(\theta^{\mu}) = E_{s\sim\rho^{\beta}}[Q(s,\mu(s|\theta^{\mu})|\theta^{Q})]. \tag{2-13}$$

根据链式法则，目标函数对演员网络参数 θ^{μ} 的梯度为：

$$\nabla_{\theta^{\mu}} J(\theta^{\mu}) \approx \frac{1}{N}\sum_{t} \nabla_{a} Q(s_t,a|\theta^{Q})|_{a=\mu(s_t)} \nabla_{\theta^{\mu}} \mu(s_t|\theta^{\mu}). \tag{2-14}$$

这个梯度指示了演员网络参数应如何调整，以使得输出的动作能够获得更高的Q值。演员网络通过应用这个梯度进行上升来更新其参数。

为了保持学习的稳定性，目标网络采用“软更新”的方式，而不是直接复制主网络的参数。在每个训练步骤后，目标网络的参数会以一个很小的比例$\tau \ll 1$向主网络参数靠拢。这种平滑的更新方式使得目标Q值变化更加平稳，避免了学习过程中的剧烈震荡。

$$\theta^{\mu'} \leftarrow \tau\theta^{\mu} + (1-\tau)\theta^{\mu'}. \tag{2-15}$$

$$\theta^{Q'} \leftarrow \tau\theta^{Q} + (1-\tau)\theta^{Q'}. \tag{2-16}$$

DDPG 算法通过演员-评论家架构，并结合经验回放和目标网络技术，为在量化交易等具有连续决策空间的复杂现实问题中应用深度强化学习提供了强大而有效的解决方案。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 3 章 基于 RoBERTa 模型构建股票情绪因子

本章首先阐述股评文本数据的采集来源与预处理工作，然后通过通用大语言模型进行情绪标注，采用“大模型指导小模型”的知识蒸馏范式，对 RoBERTa 和 BERT 模型进行后训练构建情感分类模型，并对其性能进行评估。最后，结合特征工程构建情感因子，再通过 IC 值检验筛选出移动平均、情绪背离和情绪动量核心情绪因子。

3.1 文本数据采集与描述

本研究的数据采集主要通过 Python 编程语言编写网络爬虫程序以自动化获取所需的公开文本数据。为确保数据采集过程的稳定性与连续性，采用反爬虫策略，该策略通过动态构建并伪装 HTTP 请求头，使爬虫程序的网络请求在服务器端呈现为来自不同类型浏览器的正常访问，为规避基 IP 地址的访问频率限制与封禁，构建并维护了一个动态代理 IP 池，将数据请求通过不同代理服务器进行分发。此外，在连续请求之间引入了随机化的时间延迟，以模拟用户的非同步、非匀速的浏览行为模式，进一步降低了被目标网站的异常流量检测系统识别的风险。通过整合上述技术手段，本研究成功实现了对目标数据源的大规模、高效且稳定的文本语料采集，为后续的实证分析奠定了坚实的数据基础。

本研究的爬取数据来源于东方财富股吧，见图 7，该平台是国内活跃度最高的股票投资者社区之一，其用户评论数据蕴含了丰富的市场情绪与舆情信息，爬取内容包括标题、评论数、阅读数、时间。采集时间范围为 2024 年 1 月至 12 月，采集对象为上证 50 指数中经筛选的 9 支高权重成分股，筛选准则为选取权重排名前十的股票，为平衡行业分布，将其中一支银行股（工商银行）替换为科技股（中芯国际）。这 10 支股票合计权重占比达到 49.28%，权重占比数据为 2024 年 9 月 30 日，来源于理杏仁。经过数据采集，本研究共获得 331938 条用户公开评论及相关元数据，每只股票爬取数据量见下表 1。

中国知网 https://www.cnki.net



图 7 东方财富网网页图

表 1 爬取每支股票数据量

股票编号	股票名	数据量	上证 50 指数权重
600519	贵州茅台	71466	13.78%
601318	中国平安	30663	7.71%
600036	招商银行	14972	5.84%
600900	长江电力	27929	4.61%
601899	紫金矿业	22769	3.75%
601166	兴业银行	12759	3.52%
600030	中信证券	68490	3.33%
600276	恒瑞医药	25569	2.93%
600887	伊利股份	24424	2.32%
688981	中芯国际	32897	1.49%

3.2 股评文本数据预处理

深度学习模型的表征潜力与泛化边界在很大程度上受制于底层数据的质量。考虑到通过网络途径抓取的股评文本具有一定噪声，本研究对文本数据做了严格的预处理，先对原始语料实施噪声过滤与结构化规范，然后利用知识蒸馏框架实现低成本、高精度的语义标注，通过分层抽样完成数据集的切分。

中国知网 https://www.cnki.net

3.2.1 数据清洗与去噪

在数据预处理的整个流程中，数据清洗占据着核心的起始地位。其核心任务在于剔除原始数据集里夹杂的各类噪声干扰及冗余信息，保留与情感分析任务最相关的内容。本研究的数据清洗主要包括以下步骤：

（1）去除重复数据：原始数据中存在大量由用户重复发送或系统原因导致的完全相同的评论文本。本研究对所有评论进行去重处理，以避免模型对高频重复样本产生过拟合，保证样本的独立性，共删除重复 16025 行，总去重后行数 315913。

（2）去除无关字符与符号：股吧评论中包含了大量与文本情感无关的元素，如 HTML 标签、URL 链接、股票代码、@用户信息以及“转发”等标记。本研究利用正则表达式统一匹配并移除了这些无关内容，删除 397 行，删除后行数为 315516。

（3）文本标准化处理：特殊符号与表情清洗移除了无助于情感判断的特殊符号及大部分无法直接解析的 Emoji 表情符号，保留了部分如“[赞]”、“[允悲]”等能明确表征情感的文本化表情。简繁体转换为保证语料库的一致性，将文本中所有的繁体中文字符统一转换为简体中文。

综上，共删除行数为 16422，占原始数据 4.95%，清洗后剩余行数为 315516。

3.2.2 知识蒸馏的数据标注

本实验采用了一种知识蒸馏的思想，将“教师模型”的能力迁移到学生模型，利用大模型对未标注数据进行预测，生成“伪标签”，再用于训练小模型。首先，从 33 万条原始语料中随机抽样 10%分层抽样作为种子数据集。利用 Qwen2.5-32B 大规模语言模型强大的语义理解与生成能力，配合调优后的 Few-shot 提示词工程（见表 2），对数据进行自动化的情感倾向初步标注。随后，引入人工校验环节对预标注结果进行严格清洗与修正，从而构建出高质量的“黄金标准”数据集。

表 2 大语言模型 few-shot 提示词表

Prompt：
Role 你是一位精通中国股市术语和散户心理的高级情感分析专家。 # Task 分析给定的股评文本，判断其对股价的情感倾向（2=看涨，1=中性，0=看跌）。

中国知网 https://www.cnki.net

续表 2 大语言模型 few-shot 提示词表

Prompt
Analysis Steps 1. **识别关键词**：提取文本中的情绪词、股市术语（如"割肉"、"洗盘"）。 2. **判断语气**：分析是否存在反讽、愤怒或过度乐观。注意：反问句通常表示相反情绪。 3. **结合语境**：区分"纯事实陈述"与"带情绪的事实陈述"。 4. **得出结论**：基于上述分析给出最终分类。 # Output Format 你的回答必须严格遵循以下格式： Reasoning: [简短的一句话分析理由] Label: [数字] # Examples 评论: "这主力真行，天天织布，浪费我时间。" 输出: Reasoning: "织布"指股价波动极小，"浪费时间"表达不满，属于消极情绪。 Label: 0 评论: "大跌就是机会，别人恐惧我贪婪。" 输出: Reasoning: 虽然提到"大跌"，但核心观点是视为"机会"并主张买入，属于看涨。 Label: 2 评论: "请问这只股票的分红除权日是哪天？" 输出: Reasoning: 这是一个客观的咨询问题，没有表达看涨或看跌倾向。 Label: 1 # Input Data 评论:{data}

为确保训练数据的可靠性，本研究在自动化标注流程后引入了关键的人工校验抽查

中国知网 https://www.cnki.net

环节。在此阶段，本研究对大规模语言模型输出的初步情感分类结果进行系统性复核与校准，对于 LLM 输出非 0，1，2 的标签且文本内容与股评情感不相关进行筛选删除后得到数据标签分布如下所示。该过程旨在精准识别并修正模型的潜在误判，从而根本上保障标注数据集的准确性与内在一致性。

表 3 数据类别分布表

情感类别	映射标签	样本数量
消极	0	14131
中性	1	7294
积极	2	10093

确立 “以大模型标注驱动小模型训练”这一技术路线，主要基于以下三方面的优势考量。

（1）标注效率与成本控制：相比纯人工标注，利用 LLM 进行预标注大幅降低了人力成本与时间周期；同时，人工校验环节有效弥补了通用大模型在特定领域可能产生的幻觉或一致性偏差，在保证数据精度的前提下实现了标注效率的最大化。

（2）知识蒸馏与范式迁移：该策略本质上是一种知识蒸馏思想的实践。通过将 Qwen2.5-32B（教师模型）的通用泛化知识迁移至 BERT 与 RoBERTA（学生模型），使小模型能够快速习得复杂的语义模式。

（3）工程部署与推理性能：尽管大模型表现优异，但在实际应用场景中，BERT 与 RoBERTa 等轻量级模型具有显著的推理速度优势与低资源消耗特性。通过在高质量标注数据上进行微调（Fine-tuning），小模型能够成为专注于特定任务的“专家模型”，不仅具备了接近大模型的分类性能，更满足了实际工业部署对实时性和算力的要求。

3.2.3 数据集划分

本文将整个数据集按照 8：1：1 的比例随机划分为训练集、验证集和测试集。该划分设置固定的随机种子（random_state=42），以保证每次实验划分结果的一致性。测试集在实验全过程中严格与训练过程隔离，不参与任何参数更新，仅用于客观评估模型训练结束时的泛化能力。

3.3 股票情感分类模型设计

在数据处理完备的基础上，本研究将重心转向情感分类模型的架构设计与逻辑实现。本节从三个层面展开论述：其一，聚焦于文本向量化表示，探讨如何通过嵌入技术将原

中国知网 https://www.cnki.net

始序列映射至高维语义空间；其二，深入剖析大语言模型（LLM）的微调范式，以挖掘预训练模型在金融领域的表征潜力；其三，构建多维度的性能评价指标。

3.3.1 文本序列化与输入表示

作为基于 Transformer 架构的预训练语言模型，BERT 对其输入表征有着严格的结构化要求。此范式与传统的词袋模型或 Word2Vec 等静态词嵌入方法存在本质区别，它要求输入文本必须被转换成一个包含词元 ID （Token IDs）、注意力掩码（Attention Mask）和分段 ID（Segment IDs）的复合输入。这种精巧的设计赋予了 BERT 强大的上下文感知与复杂语义建模能力，同时也对数据预处理流程提出了更高的规范性。本节将详细阐述将原始股评文本转换为 BERT 模型标准输入格式的具体步骤。

（1）WordPiece 分词

BERT 摒弃了传统的全词切分策略，转而采用一种更为灵活且高效的子词切分算法。该算法的核心目标是在词汇表规模与未登录词覆盖率之间取得平衡。WordPiece 算法尝试将词语拆分为词汇表中预定义的、更细粒度的子词单元。

（2）添加特殊标记

为使 BERT 能够统一处理分类、问答等多样化的下游任务，预处理流程中在词元序列中插入特定的功能符为[CLS]与[SEP]。[CLS]（Classification Token）被置于每个输入序列的起始位置。根据 BERT 的设计，其在 Transformer 编码器顶层输出的隐藏状态向量，被用作整个序列的聚合表征。在文本分类任务中，该向量可直接输入一个全连接层以获得最终的分类概率。[SEP]（Separator Token）用于分隔不同的文本片段。对于单句输入任务，[SEP]被添加在句末；对于句子对任务，[SEP]则被置于两个句子之间，其标准格式为 [CLS] 句子 A [SEP]句子 B [SEP]。

（3）转换为输入 ID

经过上述步骤后，得到一个由子词和特殊标记组成的序列。再将这个序列中的每一个 Token 映射为其在词汇表中的唯一索引 ID，每句文本股评数据转换为一个整数序列。

（4）序列填充与截断

实现高效的批量处理，输入 BERT 模型的序列必须具有统一的固定长度。根据对本实验股评语料的统计分析，并考虑到 bert-base 模型的常规配置，本实验设定最大序列长度（max_length）为 128。对于长度超过该值的序列，将进行尾部截断；反之，若长度不足，则在序列末尾使用特殊的[PAD]词元进行填充，直至达到设定长度。

中国知网 https://www.cnki.net

（5）构建注意力掩码

填充操作引入了不含语义信息的[PAD]词元。在 BERT 核心的自注意力机制中，模型必须忽略这些填充位，以避免干扰对真实内容的语义理解。为此，需要构建一个与输入 ID 序列维度相同的二进制注意力掩码。在该掩码中，真实词元（包括[CLS]、[SEP]）的位置被赋值为 1，表示需要参与注意力计算；而[PAD]词元的位置则被赋值为 0，表示在计算中应被忽略。

（6）构建分段 ID

分段 ID 用于区分输入中的不同文本片段。鉴于本研究的任务为单句情感分类，所有输入序列均被视为单一分段。因此，从[CLS]到有效内容末尾（包括[SEP]）的每一个词元，其对应的分段 ID 均被设置为 0。

综上所述，经过一系列严谨的预处理，原始的文本语句最终被编码为三个维度相同（batch_size，sequence_length）的数值张量，即代表词元身份索引的 Input IDs、用于屏蔽填充位的 Attention Mask，以及区分不同文本片段的 Segment IDs。这三个张量并非独立输入，是在模型的第一层——嵌入层（Embedding Layer）被协同处理。它们通过查表、计算与加和，被共同映射成一个融合了词义、位置与句子归属信息的高维三维张量（batch_size，sequence_length，hidden_size）。这个富含信息的张量是最终 Transformer 编码器栈的核心输入，为后续的深度上下文信息提取奠定了坚实基础。

3.3.2 大模型训练

本实验硬件采用 NVIDIA 4090 24G 显卡，支持 NVIDIA GPU 的加速计算；4.49.0 的 Hugging Face Transformers，用于加载和微调预训练的语言模型；版本为 1.6.1 的 scikit-learn，主要用于数据预处理、模型评估以及分类性能的分析。微调参数如表 4 所示。

表 4 模型训练超参数配置的表格

超参数	值	描述
MAX_LEN	128	输入文本的最大长度，超过则截断，不足则填充
BATCH_SIZE	32	每个训练批次和验证批次的样本数量
EPOCHS	5	最大训练轮数
LEARNING_RATE	6e-5	学习率，AdamW 优化器的初始学习率
TEST_SIZE	0.1	从原始数据集中划分出的测试集比例
metric_for_best_model	F1	验证集判断指标选择 F1

中国知网 https://www.cnki.net

本研究从 modelscope 下载 bert-base-chinese 与 chinese-roberta-wwm-ext[39]作为基础预训练模型，RoBERTa 是在 BERT 基础上更大规模语料进行预训练的。这两个模型是基于 Transformer 编码器结构的深度语言表示模型，它通过在海量通用中文语料上进行“掩码语言模型”（MLM）和“下一句预测”（NSP）两个无监督任务的联合训练，使其能够根据上下文生成动态的、包含丰富语义信息的词向量。

为了将 BERT 应用于股评情感分类任务，在其模型结构后增加了用于三分类任务的线性层。具体来说，BERT 模型的输出是每个输入 token 对应的隐藏状态向量。对于分类任务，本文取用第一个特殊 token [CLS]的输出向量$C \in R^H$（其中 H 为隐藏层大小）。此向量可被视为整个输入序列的聚合语义表示。然后，将该向量输入一个全连接层，并通过 Softmax 函数进行激活，得到输入文本属于各个类别的概率分布，如公式 3-1 所示。

$$P = \text{Softmax}(W \cdot C^T + b). \tag{3-1}$$

其中，W 和 b 是分类层需要学习的权重矩阵和偏置项。

在模型微调阶段，本实验将股评标题文本及其对应的情感标签作为模型的输入，并对 BERT 的新增分类层模型参数进行更新。通过反向传播算法，依据分类任务的交叉熵损失函数仅对新增分类层参数进行迭代更新，从而引导模型深度适应并学习股评文本的特定领域特征。

3.3.3 实验评估

为了全面地评估模型的性能，本研究采用以下四个被广泛使用的分类任务评价指标。

准确率 （Accuracy）：模型预测正确的样本数占总样本数的比例。

$$Accuracy = \frac{TP + FN}{TP + TN + FP + FN}. \tag{3-2}$$

精确率 （Precision）：模型预测为正类的样本中，实际也为正类的比例。

$$Precision = \frac{TP}{TP + FP}. \tag{3-3}$$

召回率 （Recall）：实际为正类的样本中，被模型成功预测为正类的比例。

$$Recall = \frac{TP}{TP + FN}. \tag{3-4}$$

F1 分数（F1-Score）：精确率和召回率的调和平均数，用于综合评价模型的性能。

$$F1 = 2 \cdot \frac{Precision \cdot Accuracy}{Precision + Accuracy}. \tag{3-5}$$

针对多分类任务的性能评估，本研究选用了多维度的指标体系以确保评价的客观性

中国知网 https://www.cnki.net

与全面性。实验指标包括准确率(Accuracy)、宏平均 F1 分数(Macro F1)和加权平均 F1 分数(Weighted F1)。针对具体的分类表现，研究详细记录了类别 0、类别 1 以及类别 2 的个体 F1 分数，从而量化模型在不同特定类别上的判别能力与鲁棒性。

本实验通过对东方财富网股吧语料进行深度测试，对比了不同预训练模型在微调后的性能表现。实验结果如表 5 所示，RoBERTa 模型在金融社交媒体语境下展现出稳健的性能优势。具体而言，RoBERTa 的准确率（Accuracy）达到 0.80，宏平均 F1 值（Macro F1）达到 0.79。相较于基础 BERT 模型（准确率 0.79，Macro F1 0.78），RoBERTa 实现了约 1%的整体性能提升。

在具体类别表现上，Bert 与 RoBERTa 相对于机器学习 TF-IDF 各项指标均显著提高。RoBERTa 较 Bert 在类别 1 和类别 2 的 F1 分数上分别提升了 0.01 和 0.02（见表 5）。这表 RoBERTa 凭借更大规模的预训练语料及动态掩码等更优的训练策略，在面对股吧文本中复杂的语义关系时，具备更强的上下文理解能力，能够有效改善模型在难分类别上的识别效果。

表 5 预训练模型在特定金融领域微调后的评价指标统计表

Model	Accuracy	Macro F1	Weighted F1	Class 0 (F1)	Class 1 (F1)	Class 2 (F1)
TF-IDF	0.68	0.67	0.68	0.74	0.60	0.66
BERT	0.79	0.78	0.79	0.84	0.71	0.78
RoBERTa	0.80	0.79	0.80	0.84	0.72	0.80

如表 6 所示，本实验采用 RoBERTa 微调相对于直接使用 qwen2.5-32b 模型进行数据标注的优势体现在，qwen2.5-32b 的参数量是 roberta-base 的 260 倍，大大降低了显存需求，使得推理时间大幅度提升，通过微调后依旧可以保持相当的准确率，不会出现严重误判。

表 6 Qwen2.5-32b 与 Roberta-base 推理效率对比表

模型	参数量	总时间	平均处理每条数据
Qwen2.5-32b	325 亿(32.5B)	28 小时 01 分 24 秒	3.20 秒/条
Roberta-base-SFT	1.25 亿(0.125B)	437.10 秒	0.0139 秒/条

3.4 情感因子的生成与有效性检验

本节主要讲述构建情绪因子，然后通过价格变动与情感因子的相关性分析论证股票情感因子的预测效力，再通过 Rank IC（Rank Information Coefficient）检验筛选出情绪移动平均、背离及动量因子的有效性性。

中国知网 https://www.cnki.net

3.4.1 价格变动与情感因子的时域相关性分析

为精确捕捉市场情绪的动态变化，并增强情感指标的表征效力与稳健性，本实验采用阅读量加权平均法构建日度股票基础情感因子。先对单个交易日内的每条投资者评论文本进行情感分析，将其量化为具体的情感分值，以各条评论的公开阅读量作为其在该日情绪贡献的权重，通过对当日所有评论的情感分值进行加权平均，合成最终的日度情感因子。阅读量越高的评论，往往意味着其观点获得了更广泛的市场关注，更能代表主流投资者的情绪倾向。通过赋予高阅读量评论更大的权重，本实验所构建的情感因子能够有效滤除边缘信息的干扰，从而更真实、更稳健地反映由市场主流舆论驱动的集体情绪状态。阅读量加权后的某天某支股票情感因子公式如 3-6 所示。

$$S_{s,t}=\frac{\sum_{i=1}^{N_{s,t}}\omega_{i,s,t}\cdot Score(C_{i,s,t})}{\sum_{i=1}^{N_{s,t}}\omega_{i,s,t}}. \tag{3-6}$$

其中，s 表示某一只股票，t 表示某一个特定的交易日，$N_{s,t}$ 代表股票 s 在第 t 天股评总数量，$C_{i,s,t}$ 表示股票 s 在第 t 天的第 i 条股评，$\omega_{i,s,t}$ 为第 i 只股评 $C_{i,s,t}$ 的阅读数。$Score(C_{i,s,t})$ 代表对第 i 只股评 $C_{i,s,t}$ 进行情感分析后的情感分数，这个分数被标准化到一个区间 [-1,1]，其中-1 代表极度负面，1 代表极度正面，0 代表中性。

本实验选取中信证券作为分析案例，旨在探究其情感得分与股价变动之间的相关性，从而为情感因子能够辅助股价预测这一核心论点提供实证支持。

如图 8 所示，以中信证券（600030）为例，对情感得分与股价的日变动率进行了时序可视化分析，该图展示在 2024 年 1 月 1 日至 2024 年 12 月 31 日内，中信证券（600030）在样本期间内价格变动百分比与情感得分的动态演化关系。观测结果显示，经过五日指数移动平均处理的情感信号（EMA-5）相较于原始情感得分表现出更强的趋势稳定性与信号连续性。从时间序列的形态共振来看，情感因子在多个关键时间节点表现出对价格波动的显著解释力。特别是在 2024 年第四季度市场大幅波动期间，情感得分的剧烈上升准确捕捉到了投资者情绪的快速修复与扩张，随后价格出现同步或滞后的强劲反弹，初步验证了社交媒体舆情或新闻情感对二级市场价格发现的非对称影响作用。

进一步观察发现，情感因子与收益率之间存在潜在的领先滞后关系。在 2024 年年中及后续的几处局部极值点中，情感曲线的波峰/波谷往往略微领先于价格变动的拐点，

中国知网 https://www.cnki.net

这表明情感得分在一定程度上蕴含了市场预期的前瞻性信息。

基于上述定性观测，为了更客观、定量地衡量情感因子对股票未来收益率的预测效能，本文后续将引入量化投资领域中通用的 IC（Information Coefficient）分析方法。通过计算情感因子值与未来一期标的收益率之间的秩相关系数（Rank IC），可以剔除量纲差异与极端值的干扰，从统计学层面深入剖析该因子在全样本序列上的线性与非线性预测能力。这一分析步骤将为评估情感因子是否具备作为稳定 Alpha 信号的潜力提供关键的实证支撑。

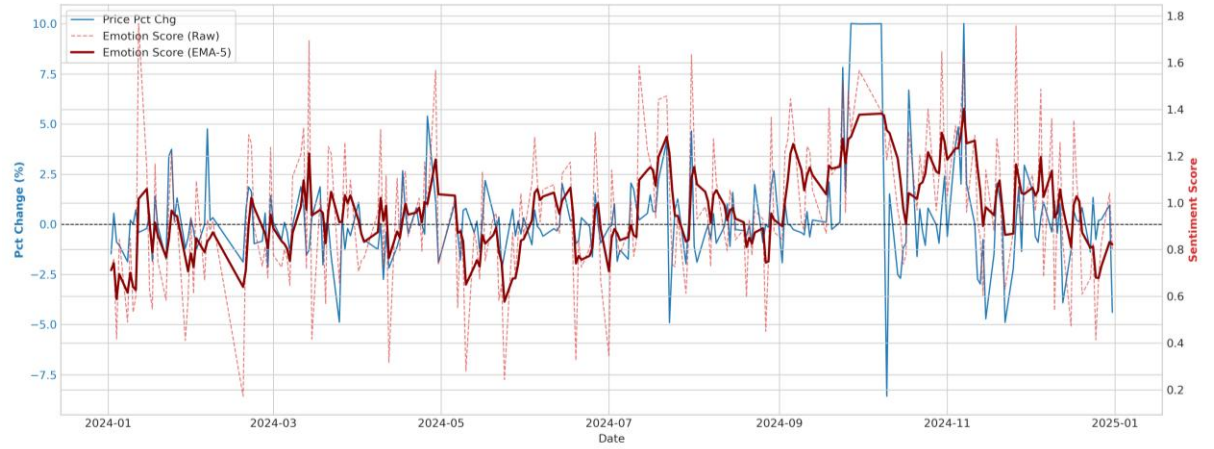


图 8 日度情感得分股价变动时序图

3.4.2 基于 Rank IC 的预测能力测度

在量化投资领域，Rank IC 是衡量量化因子预测能力的灵魂指标之一。它反映了因子排名（情绪因子从低到高排序）与股票未来收益率排名（实际涨幅从大到小排序）之间的相关性。

为了评估情感因子在截面上的选股能力，本文采用 Rank IC 作为核心评价指标。Rank IC 衡量了特定时点上，股票因子的排序值与下期收益率排序值之间的线性相关程度，能够有效剔除异常值的影响，通过非参数方法更稳健地反映因子的预测能力。为了综合考察因子在整个回测区间的表现，本文进一步计算 Rank IC 的时间序列均值 $\overline{RankIC}$。

$$RankIC_t = Corr_s(f_t, r_{t+1}). \tag{3-7}$$

$$\overline{RankIC} = \frac{1}{T}\sum_{t=1}^{T} RankIC_t. \tag{3-8}$$

其中，f_t 为 t 时刻的因子，r_{t+1} 为下期收益，$Corr_s$ 表示斯皮尔曼秩相关系数，T 是总天数。

中国知网 https://www.cnki.net

如表 7 所示，本实验基于构建的情绪指标，进一步衍生出不同维度的情绪因子，并对其进行 IC 值统计及有效性检验。统计指标包括 IC 均值、IC 标准差、ICIR（Information Coefficient Information Ratio）、IC 胜率以及 T 统计量。根据因子在预测能力和逻辑稳健性方面的表现，本实验制定了严格的筛选标准，所有变量均经过均值化后进行特征处理。

（1）$S_{s,t}$（基础情绪因子）：实证数据显示，该因子在 T+0 时点表现出极强的正相关性，IC 均值达到 0.1873，T 统计量高达 8.9519，这证实了当日市场情绪与当日股价走势具有高度的同步性。然而，在考察其对次日（T+1）收益率的预测能力时，IC 均值减至 0.0234，且 T 统计量仅为 1.0871，未能通过显著性检验。这表明原始情绪得分虽然解释能力强，但预测信号衰减过快，难以直接用于指导次日交易，因此本实验未予采纳。

（2）$S_{s,t}^{ma5}$（5 日移动平均情绪因子）：该因子通过对原始情绪得分进行 5 日均线平滑处理，有效剔除了短期情绪噪声。其 T+1 的 IC 均值提升至 0.0514，T 统计量为 2.3116（显著大于 1.96 的临界值），表现出较好的稳健性，本实验予以采纳。

$$S_{s,t}^{ma5} = \frac{1}{5}\sum_{i=0}^{4} S_{s,t-k}. \tag{3-9}$$

（3）$S_{s,t}^{mom}$（情绪动量因子）：该因子旨在捕捉情绪变化的趋势惯性。统计结果显示其表现最为优异，IC 均值高达 0.1271，ICIR 达到 0.3911，T 统计量高达 6.0722，胜率超过 62%。这说明市场情绪具有显著的动量效应，强者恒强的特征在情绪维度同样适用，本实验予以采纳。

$$S_{s,t}^{mom} = S_{s,t} - S_{s,t-1}. \tag{3-10}$$

（4）$S_{s,t}^{div}$（情绪背离因子）。$S_{s,t}$与$R_{s,t}$都经过标准化处理，该因子衡量情绪的变化与价格变动之间的偏差。如果情绪大幅上升而价格未动，或价格大涨而情绪走低，该值会发生显著变化，旨在捕捉市场情绪与资产价格之间的非理性错配。当$S_{s,t}^{div}$为正时，意味着情绪的涨幅超过了价格的涨幅，这种“情绪超前”往往预示着买盘意愿强烈，对未来价格具有正向牵引作用；当$S_{s,t}^{div}$为负时，则意味着价格上涨缺乏足够的情绪支撑，存在诱多风险。

$$S_{s,t}^{div} = (S_{s,t} - S_{s,t-1}) - R_{s,t}. \tag{3-11}$$

其中价格变动R_t的计算方式为：

$$R_{s,t} = \frac{C_{s,t} - C_{s,t-1}}{C_{s,t-1}}. \tag{3-12}$$

中国知网 https://www.cnki.net

其中，$C_{s,t}$表示第 s 只股票第t日的收盘价，$R_{s,t}$表示第t日的涨跌幅。

虽然表 7 显示该因子的 IC 均值（0.0263）和 T 统计量（1.1896）在统计显著性上弱于动量因子，但考虑到其独特的经济学含义，能够提供区别于价格动量的增量信息，有助于提升多因子组合在市场拐点处的表现。因此，本实验决定保留该因子，与其他显著因子共同构成最终的选股因子库。

综上所述，本实验最终采纳 5 日移动平均情绪因子、情绪动量因子和情绪背离因子三个因子进行后续的模型构建。

表 7 情绪因子 IC 值统计及有效性检验结果表

统计指标	$S_{s,t}$ (T+0)	$S_{s,t}$ (T+1)	$S_{s,t}^{ma5}$ (T+1)	$S_{s,t}^{div}$ (T+1)	$S_{s,t}^{mom}$ (T+1)
IC Mean	0.1873	0.0234	0.0514	0.0263	0.1271
IC Std	0.3254	0.3344	0.3420	0.3428	0.3251
ICIR	0.5754	0.0700	0.1502	0.0768	0.3911
IC Win Rate	70.66%	49.79%	59.92%	56.67%	62.24%
T-Stat	8.9519	1.0871	2.3116	1.1896	6.0722
是否采纳	否		是	是	是

数据表明，本实验所构建的情绪因子能够有效捕捉市场参与者的心理波动与预期偏差，并在横截面维度上对未来的价格变动提供具有参考意义的预测信息。这进一步证实了情绪因子在多因子选股体系中的有效性，为其后续作为核心信号参与投资组合的构建奠定了实证基础。

3.5 本章小结

本章系统地阐述了基于 BERT 与 RoBERTa 架构的金融文本情感分析模型的构建流程，并完成了股票情感因子的有效性验证。本章通过构建高质量的金融文本数据集，利用“大模型指导小模型”的知识蒸馏范式及领域适应性后训练。基于模型输出的情绪评分，本章开展了特征工程，通过 Rank IC 检验验证了市场情绪因子的有效性，并筛选出情绪移动平均、情绪背离和情绪动量三个核心因子。上述研究表明，构建的情感因子能够有效捕捉市场情绪的波动特征，这为下一章基于情感因子的量化交易策略设计提供了的数据支持与理论依据。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 4 章 基于深度确定性策略梯度的股票交易算法

本章旨在构建基于强化学习的量化交易策略。先将情绪因子与资产配置问题转化为马尔可夫决策过程（MDP）；利用卷积神经网络（CNN）对高维状态空间进行特征提取与降维；最后基于深度确定性策略梯度（DDPG）算法设计交易策略，并通过在上证 50 成分股的消融实验与传统策略回测，验证了模型的有效性。

4.1 股票投资组合交易问题描述

本节通过构建马尔可夫决策过程（MDP）模型，对交易中的状态（State）、动作（Action）及奖励（Reward）机制进行规范化定义。在此基础上，针对现实市场的制度性约束，环境中引入了佣金成本、印花税以贴近真实市场表现。

4.1.1 技术指标

为了捕捉股票在不同时间维度的价格波动与流动性变化，本文基于日频交易数据构建了以下 5 个基础量价特征。

设t为当前交易日，C_{t-1}为前一交易日收盘价。当日的开盘价、最高价、最低价和收盘价分别记为O_t,H_t,L_t,C_t，当日成交量记为V_t。

（1）隔夜收益率：该指标反映了非交易时段的信息冲击对开盘价格的影响。计算公式如下：

$$r_t^{open}=\frac{O_t}{C_{t-1}}-1. \tag{4-1}$$

（2）日内最高偏离度：该指标衡量当日价格波动的上界，反映了多头力量的日内极值水平：

$$r_t^{high}=\frac{H_t}{C_{t-1}}-1. \tag{4-2}$$

（3）日内最低偏离度： 该指标衡量当日价格波动的下界，反映了空头力量的日内极值水平：

$$r_t^{low}=\frac{L_t}{C_{t-1}}-1. \tag{4-3}$$

（4）日收益率：该指标表示资产当日的整体涨跌幅，是量化模型中最核心的预测目标或输入特征：

中国知网 https://www.cnki.net

$$r_t^{close} = \frac{C_t - C_{t-1}}{C_{t-1}}. \quad (4\text{-}4)$$

（5）成交量异动因子：为了衡量当日流动性的异常变化，本文构建了相对成交量指标。通过将当日成交量与过去 5 个交易日的移动平均成交量（ma5）进行对比，以消除成交量绝对量级的影响，实现标准化。

$$v_t^{chg} = \frac{V_t}{ma5(V)_{t-1}} - 1. \quad (4\text{-}5)$$

其中，$ma5(V)_{t-1}$表示前 5 个交易日成交量的算术平均值，计算方式为：

$$ma5(V)_{t-1} = \frac{1}{5}\sum_{k=1}^{5} V_{t-k}. \quad (4\text{-}6)$$

4.1.2 股票交易的 MDP 模型

为有效应对股票投资组合管理中动态、随机的特性，并寻求最优的长期投资回报，将其构建为一个马尔可夫决策过程（MDP）模型。MDP 为强化学习智能体与环境之间的交互提供了数学化的框架，使其能够通过试错学习来优化序贯决策问题。一个标准的 MDP 由状态（State）、动作（Action）、奖励（Reward）、状态转移概率（Transition Probability）以及折扣因子（Discount Factor）五元组构成。在股票投资组合的场景下，这些核心要素的具体定义如下：

状态（State，S）:状态S_t是智能体在决策时刻t所能观测到的所有信息的集合。在本研究中，为了精准捕捉金融市场的复杂动态并规避原始价格数据的非平稳性干扰，本实验构建了一个融合市场微观变化与情绪因子的多维状态向量。该向量并未直接采用原始的基础行情数据，而是聚焦于价格与成交量的相对变化特征，具体涵盖了开盘价、最高价、最低价、收盘价以及成交量的变化率。此外，为了量化非理性繁荣与市场恐慌对交易的影响，本实验引入了深度的情绪衍生指标，包括反映短期情绪趋势的 5 日移动平均情绪得分（$S_{s,t}^{ma5}$）、衡量情绪变化加速度的情绪动量（$S_{s,t}^{mom}$），以及刻画市场情绪与资产价格走势潜在错位的情绪-价格背离指数（$S_{s,t}^{div}$）。这些来自多源数据的特征在每个决策时刻被整合成一个统一的特征矩阵，随后利用卷积神经网络 CNN 进行深度特征提取。CNN 能够有效识别并学习金融时间序列数据中隐含的局部模式与组合特征，转换为更具判别力的状态表示，并以此作为策略网络与价值网络的最终输入。

动作（Action，A）:动作A_t是智能体在状态S_t下可以执行的操作集合。对于一个包含 D 支股票的投资组合，动作是一个 D 维向量 $a_t = [a_{t,1}, a_{t,2}, \ldots, a_{t,D}]$，其中每个元素$a_{t,i}$

中国知网 https://www.cnki.net

对应第i支股票的操作。DDPG 适用于连续动作空间，本实验将动作定义为在 [0，1] 区间内的连续值，代表每天期望每只股票持仓权重，可以通过规则化运算，计算出当日每只股票买卖份额，允许智能体进行更精细化的资金管理和仓位控制。

奖励（Reward，R）：奖励函数R_t是对智能体在状态S_t执行动作A_t后，环境给予的即时反馈，其目标是引导智能体学习能够最大化长期收益的策略。在投资组合任务中，奖励最直接的定义是投资组合价值的变化。投资组合的价值是由所有持有的股票市值构成。因此，奖励可以表示为公式 4-7。

$$R_t = V_t - V_{t-1}. \tag{4-7}$$

其中V_t和V_{t-1}和分别表示在t和$t-1$时刻的投资组合总价值。为更贴近真实交易场景，本实验的在计算投资组合价值时，当产生交易时会扣除千分之一的交易成本。

强化学习的目标是学习一个最优策略π^*，以最大化长期累积奖励的期望值。本研究的股票交易策略的核心目标是在预设的交易周期内最大化投资回报。在马尔可夫决策过程（MDP）模型中，这一目标被具体化为最大化累积奖励的总和G_t。

$$G_t = \sum_{k=0}^{\infty} \gamma^{k} r_{t+k+1}. \tag{4-8}$$

其中，$\gamma \in [0,1]$是折扣因子，用于平衡当前奖励与未来奖励的重要性。γ值越接近1，表明智能体越看重未来的长期回报。

综上所述，通过将股票投资组合交易问题建模 MDP，为采用深度强化学习算法来求解最优投资策略提供了坚实的理论基础。智能体在这一框架下，通过与真实市场环境进行反复交互，不断优化其交易策略，目标为在复杂的市场动态中实现长期收益的最大化。

4.1.3 纳入股票交易的限制

在构建投资组合策略时，必须考虑现实金融市场中的交易限制，以确保模型的实用性和可行性。这些限制主要包括：

（1）市场流动性：假设所有订单都可以按照市场的收盘价迅速执行，且交易行为不会对市场价格产生显著影响。

（2）非负余额：任何交易操作都不能导致账户的现金余额为负数。这意味着买入股票的总金额不能超过当前可用资金。

（3）交易成本：每一笔买入或卖出交易都会产生费用，如佣金和印花税。这些成本

中国知网 https://www.cnki.net

会直接影响最终的投资回报，本实验采用千分之一的交易成本。

4.2 股票投资组合交易算法的问题建模

本节将深入探讨股票投资组合交易算法的具体实现架构。首先，通过 CNN 对特征进行提取与降维；将提取的特征馈入 Actor-Critic 框架，利用双网络耦合机制动态调整投资组合权重来实现回报最大化。

4.2.1 基于 CNN 的特征提取

在复杂的金融市场中，单一时间点的数据难以全面反映市场状态，而多支股票在特定时间窗口内的数据则构成了蕴含丰富时序依赖关系的信息。为有效捕捉每支股票在时间维度上的深层模式，采用卷积神经网络对投资组合中的每一支股票独立进行特征编码，提取高维度的抽象市场状态，为后续的深度确定性策略梯度（DDPG）智能体提供决策依据。

本实验将智能体在每个时间步 t 观测到的市场状态重构为批次化的时间序列数据。对于投资组合中的 N 支股票，每支股票在长度为 W 的时间窗口内包含 F 个特征。本研究设计的 CNN 特征提取器包含两个级联的卷积块来逐层抽象市场信息。输入数据首先通过第一个卷积层，该层包含 16 个卷积核（Kernel Size=3，Padding=1），配合批量归一化和 ReLU 激活函数，用于捕捉基础的短期时序波动特征。然后数据进入第二个卷积层，卷积核数量增加至 32 个，进一步组合初级特征以构建更复杂的非线性表示。

为了将时序特征转化为低纬状态向量，并提取最显著的特征信号，本实验在卷积层之后引入了自适应全局最大池化层。该操作在时间维度上筛选出激活值最大的特征响应，随后通过全连接层将每支股票的特征映射为 32 维的隐变量。最终，所有股票的深层特征被展平并拼接，并与上一时刻的持仓权重进行融合，共同构成 Actor 和 Critic 网络的输入向量。这种融合方式确保了智能体的决策既基于当前敏锐的市场洞察，又考虑了交易成本与历史持仓状态的连续性。

4.2.2 Actor-Critic 算法框架

本研究基于马尔可夫决策过程（MDP）对该问题旨在构建一个以长期收益最大化为导向的智能交易代理（Agent）。本实验选用 Actor-Critic 算法作为核心决策框架，并结合卷积神经网络（CNN）对高维市场数据进行自动化特征提取，从而构建一个端到端的量化交易决策模型，伪代码如表 8 所示。

Actor-Critic 算法是解决本研究中连续动作空间投资组合优化问题的理想框架。其核

中国知网 https://www.cnki.net

心优势在于能够直接在连续的权重空间中进行策略搜索，同时利用价值函数指导学习过程，提高了样本效率和收敛稳定性。演员（Actor）作为策略网络$\pi_\theta(a_t|s_t)$，输出具体的投资组合权重向量a_t。其优化目标是调整参数θ，以生成能最大化长期累积回报的交易策略。评论家（Critic）作为价值网络$Q_\omega(s_t,a_t)$，负责评估演员策略的优劣。它通过学习精准预测在当前状态下的预期回报，并计算时序差分误差（TD Error），为演员的策略更新提供具有明确导向性的梯度信号。

二者协同工作，演员负责探索和执行，评论家负责评估和反馈，共同推动模型向着最优投资策略收敛。

表 8 DDPG 程序伪代码

基于 DDPG 的投资组合策略算法
输入:CNN 特征提取后的状态+上一交易日持仓权重
输出：$A_t=[w_{t,1},w_{t,2},...,w_{t,10}],w_{t,D}\in[0,1]$,其中$D\in Z^+,1\leqslant D\leqslant 10$
随机初始化 Critic 网络、Actor 网络，权重参数为θ^μ,θ^Q
初始化目标 Critic 网络、目标 Actor 网络，参数分别为$\theta^{\mu'}=\theta^\mu,\theta^{Q'}=\theta^Q$
初始化经验池$\mathcal{D}$
初始资金$V_0=100$万元人民币
for episode 1 *to M*:
重置环境，状态$s_t=\phi(I_t)$,ϕ代表特征提取器 CNN 网络,I_t表示原始数据
for $t=1$ *to* T：
智能体观察状态s_t,输出一个投资组合的权重向量A_t
$A_t=\mathrm{softmax}\left(f(s_t;\theta^\mu)+\epsilon_t\right)$，$f$ 表示 Actor 网络
执行动作a_t，并记录奖励r_t和新的状态s_t
从$\mathcal{D}$随机采样N条经验
若$\lvert\mathcal{D}\rvert\geqslant$ batch_size,则:

中国知网 https://www.cnki.net

续表 8 DDPG 程序伪代码表

基于 DDPG 的投资组合策略算法
存$\mathcal{D} \leftarrow (s_t, a_t, r_t, s_{t+1})$ 计算目标Q值：$y_t = r_t + \gamma\, Q'(s_{t+1}, \mu'(s_{t+1}\|\theta^{\mu'})\,\|\,\theta^{Q'})$; Critic 更新： $\mathcal{L}_Q = \frac{1}{N}\sum_i (Q(s_i, a_i\|\theta^Q) - y_i)^2$; $\theta^Q \leftarrow \theta^Q - \alpha_Q \nabla_{\theta^Q} \mathcal{L}_Q$; Actor 更新： $\mathcal{L}_\mu = -\frac{1}{N}\sum_i Q(s_i, \mu(s_i\|\theta^\mu)\,\|\,\theta^Q)$; $\theta^\mu \leftarrow \theta^\mu - \alpha_\mu \nabla_{\theta^\mu} \mathcal{L}_\mu$; 软更新目标网络： $\theta^{Q'} \leftarrow \tau\theta^Q + (1-\tau)\theta^{Q'}, \theta^{\mu'} \leftarrow \tau\theta^\mu + (1-\tau)\theta^{\mu'}$. end for end for

4.2.3 股票市场环境构建

本实验基于真实的股票历史数据，构建一个股票交易模拟环境。该环境将严格遵循马尔可夫决策过程（MDP）的框架，对状态空间、动作空间以及奖励函数进行精确的定义与设计。通过该环境，强化学习智能体能够模拟真实的交易行为、接收即时的市场反馈，并根据预设的优化目标进行策略学习。本节将详细阐述环境的设计原则、技术实现以及其在后续智能体训练中的核心作用，为构建有效的量化交易策略奠定基础。

（1）状态空间

在强化学习中，状态空间S旨在全面捕捉代理决策所需的全部信息。一个设计良好的状态空间需满足马尔可夫性，即当前状态s_t已充分包含了对未来进行最优决策所需的历史信息，而无需追溯更早之前的状态。本研究的状态s_t设计为一个复合向量，由市场特征张量与投资组合状态向量组成。

市场特征张量是由 CNN 处理的高维数据，它是一个三维张量，维度为 T×N×F，其中，T 为历史回溯期 10 个交易日，N 为资产池中的股票数量 10，F 为每个时间点为每只股票选取的特征数量 8。具体的特征包括：开盘、最高、最低、收盘价的涨跌幅，成

中国知网 https://www.cnki.net

交量变化率，以及三个情感因子（5 日情感均值因子、情感动量因子、情感价格背离因子）。这个张量构成了 CNN 的输入，用于提取深层次的市场模式。

投资组合状态向量描述了自身的持仓情况，是做出下一时刻决策的重要依据。它是一个一维向量w_{t-1}，包含了上一时刻的投资组合权重（维度为N）。将持仓状态纳入观测，可以帮助代理学习交易成本带来的路径依赖影响。

在 t 时刻，完整的状态s_t的处理流程是：首先由 CNN 网络根据$10\times10\times8$的市场特征张量提取出压缩后的特征向量，随后该特征向量与上一时刻的持仓权重w_{t-1}进行拼接，最后输入到 Actor 和 Critic 的全连接网络中进行决策。

（2）动作空间

动作空间A定义了代理可以执行的所有可能操作的集合。由于股票投资组合的核心是资金分配，本研究的动作空间被设计为一个 N 维的连续空间，代表了所有资产的理想权重分布。动作向量 $a_t=[w_{1,t},\ldots,w_{10,t}]$，其中$w_i$是分配给第$i$只股票的资金权重。动作向量权重非负，即$w_i\geq0$ for $i=0,1,\ldots,N$ 与权重和为 1，即$\sum_{i=0}^{N}w_i=1$

为了确保 Actor 网络输出的动作始终满足这些约束，在其输出层使用 Softmax 激活函数。Softmax 函数可以将其前一层网络的原始输出转换为一个和为 1 的概率分布，天然符合投资组合权重的定义。

（3）奖励函数设计

为实现投资组合的稳健增值并有效平抑下行风险，本研究设计了两种不同数学范式的奖励函数以引导智能体的策略梯度更新。首先，构建了基于“收益率-回撤惩罚”的基准线性奖励函数，旨在通过显式的风险约束项迫使智能体建立基础的风险厌恶偏好，保障策略的安全性。进阶地，为了解决金融数据长尾分布导致的训练不稳定性并提升资金利用效率，本研究引入了非线性的 Symlog（Log-Modulus）奖励函数。该机制利用对称对数变换对原始回报进行重塑，在平滑极端波动冲击的同时增强了模型对微小收益变化的敏感度，从而引导智能体在复杂的市场环境中更高效地捕捉高盈亏比的交易机会，实现风险调整后收益（如夏普比率）的最大化。

4.3 股票交易策略算法设计与优化

本节通过重构状态空间，将多维情绪因子有效融入强化学习框架，打破了智能体仅依赖单一价量数据进行观测的局限性；然后通过优化奖励函数，引导智能体权衡即时盈

中国知网 https://www.cnki.net

亏与长远目标，以实现长期累计回报的最大化；最后将本模型与传统量化策略进行了对比分析，回测结果验证了所提算法在复杂市场环境下的稳健性与优越性。

4.3.1 情绪因子的消融实验分析

有效市场假说（EMH）认为价格已反映所有信息，但现实中的市场异象表明其并非时刻有效。行为金融学指出，投资者的认知偏差与情绪波动是导致价格偏离价值的关键。因此，市场情绪已成为金融研究不可或缺的分析维度。本研究引入情绪因子的核心动机在于，社交媒体与财经新闻中蕴含着领先于价格变动的定性信息。通过 NLP 技术将其量化，可为模型提供价量数据之外的增量信息，构建更高维的市场状态表示。将情绪因子纳入模型，旨在增强算法对短期走势及市场拐点的预判能力。融合情绪分析的交易智能体不再机械重复历史数据，而是能感知市场“氛围”并进行动态决策优化，使其交易行为更贴近市场真实逻辑。

为精准评估情绪信息在量化交易中的实际价值，本研究方法设计的核心在于对比验证。本实验通过构建两种不同的输入状态，驱动两个 DDPG 模型进行训练与回测。其中一个作为基准，仅包含传统技术指标；另一个则在基准之上，增补了本研究构建的量化情绪因子。这种设计确保了实验的控制变量原则，使得两个模型最终表现的差异能够直接归因于情绪因子的引入。

基准 DDPG 模型旨在通过捕捉资产价格的微观波动模式来进行决策。为了消除原始价格数据的非平稳性对神经网络训练的干扰，本实验摒弃了开盘价、收盘价等绝对数值，转而采用更能反映市场短期动量的变化率指标构建基础状态空间。其在每个决策时间步 t 所观察到的状态空间 s_t^{base}，由基础行情数据的变化率构成，具体涵盖了开盘价、最高价、最低价、收盘价以及成交量的相对变化幅度。其形式化定义如公式 4-9 所示：

$$s_t^{\text{base}} = \{r_t^{open}, r_t^{high}, r_t^{low}, r_t^{close}, v_t^{chg}\}. \quad (4\text{-}9)$$

其中，$r_t^{open}, r_t^{high}, r_t^{low}, r_t^{close}, v_t^{chg}$ 分别表示 t 时刻隔夜收益率、日内最高偏离度、日内最低偏离度、日收益率、成交量异动因子。

为了深入挖掘舆情信息对资产定价的非线性影响，本实验在基准状态的基础上，引入了经过特征工程处理的高阶情绪因子。不同于简单的原始情绪得分，本研究构建了三个具有明确金融语义的情绪衍生特征：

(1)情绪趋势项 S_t^{ma5}：5 日移动平均情绪得分，用于平滑短期噪音，捕捉市场情绪的中期趋势。

中国知网 https://www.cnki.net

(2)情绪动量项S_t^{mom}：衡量情绪变化的速度与加速度，用于识别市场情绪的爆发点。

(3)情绪-价格背离项S_t^{div}：量化市场情绪与资产价格走势之间的潜在错位，往往作为反转信号的重要依据。

情绪增强模型的状态空间s_t^{emo}定义为基准变化率特征与高阶情绪特征的集合，如下4-10所示。

$$s_t^{\text{emo}} = s_t^{\text{base}} \cup \{S_t^{ma5}, S_t^{mom}, S_t^{div}\}. \quad (4\text{-}10)$$

通过这种构造，智能体的观测窗口不仅覆盖了市场的价格波动，还同时感知市场情绪变化。

4.3.2 非线性 Symlog 奖励函数的消融实验分析

在强化学习驱动的量化交易中，奖励函数是塑造智能体行为模式的根本机制。它通过定义“好”与“坏”的行为，直接引导智能体的策略梯度更新方向。而金融时间序列数据通常具有高噪声和非平稳特性，如何平衡收益追求、风险控制与训练稳定性是一个关键的设计挑战。为了系统性地探究不同奖励结构对模型收敛性及策略稳健性的影响，本研究设计了两组具有不同数学特性的奖励函数方案——线性回撤惩罚机制与非线性对数模（Log-Modulus）变换机制，并通过后续的消融实验进行对比评估。

（1）基准线性奖励：收益与回撤的双重约束

基准奖励函数采用经典的线性组合形式，旨在直接最大化投资组合的风险调整后收益。其数学表达如下：

$$r_t^{\text{linear}} = (R_t - \lambda \cdot DD_t) \cdot \sigma. \quad (4\text{-}11)$$

其中，R_t为t时刻的投资组合收益率，DD_t为当前时刻的资产净值回撤幅度，λ为回撤惩罚系数，用于抑制智能体产生极端亏损行为。σ为奖励缩放因子，用于将奖励值规范化至适合神经网络处理的数值范围。该机制直观地体现了“追求收益、厌恶风险”的投资逻辑。

（2）优化非线性奖励：基于 Log-Modulus 的数值稳定机制

尽管线性奖励逻辑清晰，但在实际训练中，金融数据的“重尾”特性，即偶尔出现的极端涨跌幅，容易导致奖励值剧烈波动，进而引发梯度爆炸或训练不稳定的问题。为解决这一问题，本实验引入了 Log-Modulus（对数模）变换对原始收益率进行非线性重塑。该奖励函数的定义如下：

$$r_t^{\log} = \beta \cdot \text{sgn}(R_t) \cdot \ln(1 + \alpha \cdot |R_t|). \quad (4\text{-}12)$$

中国知网 https://www.cnki.net

在本实验的具体实现中，设定超参数$\alpha=10.0$，缩放系数$\beta=5.0$。这一设计包含两层深层含义：

(1)对数压缩与平滑：$|R_t|$越大时，$r_t^{\log}$奖励函数越大，$|R_t|$越小时，$r_t^{\log}$奖励函数越小，对于较大的收益或亏损（$|R_t|$较大时），对数函数压缩了其数值范围，防止极端市场波动对策略网络造成过度冲击，从而增强了训练过程的鲁棒性。

(2)小数值敏感度增强：参数α的引入使得函数在R_t接近 0 的区域具有更大的梯度。这意味着智能体对于微小的盈利也能获得足够显著的反馈信号，从而在震荡市或低波动环境中也能保持高效的学习能力。

通过引入 Log-Modulus 变换，本研究旨在让智能体在适应多变市场情绪的同时，获得更加平滑且密集的奖励信号，从而在复杂的金融环境中实现更优的策略收敛。

4.3.3 与传统基准策略的对比

在通过实验一与二的消融实验后，初步确证了情绪因子的有效性与奖励函数优化的可行性之后，本研究将进行最终的综合性能评估，旨在将本研究提出的“DDPG+情绪因子”模型与领域内公认的基准策略进行比较，从而全面衡量其在模拟真实投资环境下的综合性能、泛化能力与应用潜力。

本实验参照 Yang（2023）等研究，选取了三种代表不同核心投资逻辑的经典在线投资组合策略作为基准[40]。此类在线策略无需预设模型或离线训练，可直接依据市场信息流进行决策，因而构成了公平的比较对象。

基准一为通用恒定再平衡投资组合（UCRP），其遵循一种准被动的投资范式，在期初为资产组合赋予均等权，并在每个周期结束时通过交易恢复至该初始权重。UCRP 的收益来源于资产的内生增长以及通过周期性再平衡捕获的波动性溢价。它代表了一个强大而稳健的基准，是衡量主动管理型策略能否创造真实超额收益的试金石，计算公式如下 4-13 所示。

$$b=(b_1,b_2,\ldots\ldots,b_m)^{\mathrm{T}}. \tag{4-13}$$

其中，$\sum_{i=1}^{m}b_i=1$且$b_i\geq 0$，m为资产数，投资组合的目标权重向量为b，它是一个不随时间变化的常数向量。

基准二为指数梯度投资组合（EGP），其策略逻辑为一种经典的在线学习算法，体现了 “动量跟随”的投资理念，即认为“强者恒强”并增持近期价格表现优异的资产。作为市

中国知网 https://www.cnki.net

场中最为显著和稳健的金融异象之一，动量策略构成了主流的投资范派。选取 EGP 作为基准，旨在直接评估本研究模型在捕捉市场趋势方面的相对有效性。权重调整公式如公式为 4-14。

$$b_{t+1,i}=\frac{b_{t,i}\exp\left(\eta\frac{x_{t,i}}{b_t\cdot x_t}\right)}{\sum_{j=1}^{m}b_{t,j}\exp\left(\eta\frac{x_{t,j}}{b_t\cdot x_t}\right)}. \tag{4-14}$$

$$x_{t,i}=\frac{P_{t,i}}{P_{t-1,i}},\ b_t\cdot x_t=\sum_{j=1}^{m}b_{t,j}x_{t,j}. \tag{4-15}$$

$b_{t+1,i}$资产i在下一个周期 $t+1$的新权重，$b_{t,i}$资产i在当前周期t的权重，$x_{t,i}$资产i在当前周期t的价格相对值，$b_t\cdot x_t$表示整个投资组合在当前周期的总回报率，$\frac{x_{t,i}}{b_t\cdot x_t}$代表了资产$i$的回报相对于整个组合平均回报的表现。如果这个值大于 1，说明资产i的表现优于平均水平；如果小于 1，则劣于平均水平。η一个大于 0 的常数，称为学习率，它控制了策略对近期市场表现的敏感度。η越大，权重的调整就越激进。分母部分是一个归一化因子，确保所有新权重$b_{t+1,i}$的总和为 1。

基准三为在线移动平均反转策略（OLMAR），其代表了与动量策略相对立的 “均值回归”思想，其核心是利用资产价格短期偏离其局部均值的现象进行套利，从而实现“低买高卖”。均值回归是市场的另一大核心特征，将 OLMAR 纳入对比，旨在考察本模型面对震荡或反转型行情时，相较于主流逆向投资策略的性能差异。计算公式如下所示。

$$b_{t+1,i}=\frac{\hat{x}_{t+1,i}}{\sum_{j=1}^{m}\hat{x}_{t+1,j}}. \tag{4-16}$$

$$\hat{x}_{t+1,i}=\frac{\hat{P}_{t+1,i}}{P_{t,i}}=\frac{\mathrm{MA}_{t,i}(w)}{P_{t,i}}=\frac{\frac{1}{w}\sum_{k=0}^{w-1}P_{t-k,i}}{P_{t,i}}. \tag{4-17}$$

其中，$b_{t+1,i}$资产i在下一个周期$t+1$的新权重，$\hat{x}_{t+1,i}$为预测价格相对值，分数>1，说明当前价格低于历史平均，资产被“低估”，有上涨潜力，吸引力高；分数<1，说明当前价格高于历史平均，资产被“高估”，有下跌风险，吸引力低。$\mathrm{MA}_{t,i}(w)$为第i支股票过去w个周期的移动平均价，用来预测$P_{t,i}$，即资产i在周期t的收盘价。

通过将本研究模型与上述三种分别代表“被动分散”、“动量追涨”与“均值回归”的策

中国知网 https://www.cnki.net

略进行对标，可以从多个维度系统性地检验其在复杂市场环境下的综合适应能力与竞争优势。

4.4 回测实验与分析

为了评估本文提出的策略在真实交易环境中的盈利能力与风险控制水平，本节构建了基于历史数据的回测实验框架。先对实验所依据的数据源进行描述，明确回测的时间跨度与标的范围；随后选取夏普比率、最大回撤等关键评价指标作为衡量策略优劣的标尺；实验通过与基准策略的横向对比，解释引入情绪因子与奖励函数优化对提升强化学习策略泛化性能的贡献。

4.4.1 数据源

本研究的数据来源于 Tushare 金融数据社区。为构建分析所需的面板数据，本实验选取了 10 只 A 股市场的代表性股票，通过 API 接口获取了其在 2024 年 1 月 1 日至 2024 年 12 月 31 日期间的日度交易数据与衍生技术指标。该时间区间共包含 242 个 A 股有效交易日。训练样本取 2024 年前三个季度数据，即 1 月到 9 月，回测取 2024 年第四个季度数据，即 2024 年 10 月到 12 月的数据。

4.4.2 评价指标

本实验量化回测采用七种量化指标，总收益率（%）、年化收益率（%）、年化波动率（%）、夏普比率、索提诺比率、卡玛比率、最大回撤（%）。

总收益率是在特定时期内，投资组合总的价值增长百分比。它反映了从投资开始到结束，资本的整体增值情况，是衡量投资绩效最基础、最直接的指标。它不考虑投资时间的长短，只关注期初和期末的价值变化。

$$R_{\text{total}} = \frac{V_{end} - V_{start}}{V_{start}} \times 100\%. \tag{4-18}$$

其中，R_{total} 为总收益率，V_{start} 为期初资产净值，V_{end} 为期末资产净值。

年化收益率是将总收益率按照时间进行标准化处理，转换为以“年”为单位的复合收益率。它消除了不同投资时长对收益率的不可比性，使得不同策略或基金在同一标准下进行比较。

$$R_{annual} = \left[(1 + R_{total})^{\frac{1}{T}} - 1 \right] \times 100\%. \tag{4-19}$$

其中，R_{annual} 为年化收益率，R_{total} 为总收益率，T 为总投资时长（以年为单位）。

中国知网 https://www.cnki.net

年化波动率是衡量投资组合收益率在一年内的波动幅度的指标，常用收益率的标准差来计算。它反映了投资策略的风险水平，波动率越高，意味着收益率的波动越剧烈，风险也越高。

$$\sigma_{annual}=\sqrt{\frac{1}{N-1}\sum_{t=1}^{N}(r_t-\overline{r})^2}\times\sqrt{M}. \tag{4-20}$$

其中，σ_{annual}为年化波动率，N为收益率数据点的总个数，r_t为第 t 个交易周期的收益率，$\overline{r}$为周期内收益率的平均值，M为每年的交易周期数。

夏普比率是衡量单位总风险下，投资者能获得的超额收益。它同时考虑了收益和风险，是风险调整后收益的核心指标。夏普比率越高，说明在承受相同单位风险的情况下，策略获取的超额回报越高。

$$SharpeRatio=\frac{R_{annual}-R_f}{\sigma_{annual}}. \tag{4-21}$$

其中，R_{annual}为年化收益率，R_f为无风险收益率，σ_{annual}为年化波动率。

索提诺比率是夏普比率的改进版本。它认为只有向下的波动（即亏损）才是真正的风险，而向上的波动（超额盈利）是投资者所期望的，不应被视为风险。它在计算风险时，只使用下行标准差，即只统计那些低于无风险利率或目标收益率的波动。索提诺比率越高，说明策略在控制下行风险方面表现得越好。

$$SortinoRatio=\frac{R_{annual}-R_f}{\sigma_d}. \tag{4-22}$$

$$\sigma_d=\sqrt{\frac{1}{N}\sum_{t=1}^{N}[\min(0,r_t-R_f)]^2}\times\sqrt{M}. \tag{4-23}$$

其中，R_{annual}为年化收益率，R_f为无风险收益率，σ_d年化下行标准差。

最大回撤是指在选定的投资周期内，投资组合净值从任意一个历史高点回落到其后的某个低点的最大跌幅。它衡量了策略可能面临的最大亏损风险，是描述策略极端风险表现的关键指标。

$$MDD=\max_{t\in[0,T]}\left(\frac{V_{peak(t)}-V_t^{port}}{V_{peak(t)}}\right)\times100\%. \tag{4-24}$$

其中，MDD为最大回撤，为T整个投资周期，V_t^{port}在时间t的资产净值，$V_{\text{peak}(t)}$在时间为t之前的资产净值最高点，即$V_{\text{peak}}(t)=\max_{\tau\in[0,t]}V_\tau^{\text{port}}$。

卡玛比率是衡量策略的年化收益与其历史最大回撤之间的关系。它直接反映了策略

中国知网 https://www.cnki.net

的收益与它曾经经历过的最差表现（最大亏损）的比例。这个指标对于风险厌恶型投资者尤为重要，因为它清晰地展示了为了获得年化收益，投资者需要承受多大的历史极端风险。卡玛比率越高，说明策略的风险回报性价比越好，从最糟糕的亏损中恢复的能力也越强。

$$CalmarRatio = \frac{R_{annual}}{MDD}. \tag{4-25}$$

其中，R_{annual}年化收益率，MDD 为最大回撤取绝对值。

4.4.3 实验结果分析

（1）实验一：情绪因子引入的有效性分析

为了验证将情绪因子融入交易决策模型的有效性，本研究设计了一组严格的对比实验。实验将集成情绪因子的 DDPG 模型与未包含情绪因子的基准 DDPG 模型在同一回测周期内进行全方位对比。详细的评估结果如表 9 所示。

实验结果表明，引入情绪因子显著增强了模型的盈利能力。在收益维度上，情绪增强模型的总收益率从基准模型的 4.68%提升至 5.45%，年化收益率从 25.39%增长至 30.00%。这一超额收益证明，情绪因子为智能体提供了独立于量价数据之外的高价值信息增益，使其能够更敏锐地捕捉市场非理性波动带来的套利机会。

在风险调整后收益方面，集成情绪因子的模型展现出了压倒性的优势。作为衡量单位风险超额回报的核心指标，夏普比率从基准的 1.37 提升至 1.89；索提诺比率（Sortino Ratio）是从 2.09 提升至 3.19。索提诺比率的提升尤为关键，它表明模型在获取高收益的同时，极好地控制了下行风险（Downside Risk）。卡玛比率（Calmar Ratio）从 6.63 上升至 7.63，进一步印证了策略在收益与最大回撤比率上的优越性。

与通常“高收益伴随高波动”的认知不同，本实验中情绪因子的引入反而降低了策略的整体波动性。年化波动率从基准模型的 17.03%下降至 14.80%。这说明情绪特征有效地充当了“市场噪音过滤器”的角色，帮助智能体规避，了部分震荡行情中的无效交易，从而平滑了资产净值曲线。而最大回撤仅出现微幅上升，从 3.83%微增至 3.93%，考虑到年化收益率近 5 个百分点的增长以及波动率的显著降低，这一微小的回撤成本在可接受范围之内，且并未改变策略整体稳健的风险特征。

综上所述，实验一证实了将市场情绪作为量化因子引入 DDPG 模型的有效性。该方法不仅提升了策略的绝对收益，更重要的是通过降低波动率和提升夏普、索提诺比率，实现了风险调整后收益的优化，验证了情绪增强型 DDPG 策略在复杂市场环境下的鲁

中国知网 https://www.cnki.net

棒性。

表 9 情绪增强模型与基准模型对比表

评价指标	DDPG +情绪因子	DDPG（无情绪因子）
总收益率 (%)	5.45	4.68
年化收益率 (%)	30.00	25.39
年化波动率 (%)	14.80	17.03
夏普比率	1.89	1.37
索提诺比率	3.19	2.09
卡玛比率	7.63	6.63
最大回撤 (%)	3.93	3.83

（2）实验二：非线性 Symlog 奖励函数的消融实验

在实验一验证了情绪因子对提升基准模型表现的有效性后，本研究进一步设计了消融实验，旨在探究奖励函数的数学结构对策略最终绩效的深层影响。为此，本实验将实验一中表现最优的线性奖励模型（作为基准，记为“线性奖励函数”）与引入了 Log-Modulus 变换的优化模型（记为“Symlog 奖励函数”）进行直接对比，以评估非线性奖励机制的贡献。评估结果见表 10。

实验数据表明，Symlog 奖励函数提升了模型的盈利能力。与线性基准相比，采用 Symlog 机制的模型在收益维度上表现更佳：总收益率从 5.45%增至 8.92%，年化收益率从 30.00%升至 52.52%。这反映出 Symlog 变换通过对数压缩机制调节了数值敏感度，使智能体能够更有效地捕捉市场中的盈利机会，在相同的回测窗口内积累了更多的超额收益。

在风险维度上，Symlog 模型表现出明显的“高风险高回报”特征。该模型的年化波动率从 14.80%上升至 25.63%，最大回撤也从 3.93%增加至 6.86%。这说明 Symlog 奖励函数引导智能体采取了更为积极的交易风格，通过提高对短期波动的容忍度来换取上行趋势中的收益增长。

在风险调整后收益指标方面，模型表现有所分化。夏普比率从 1.89 提升至 1.97，卡玛比率由 7.63 微增至 7.66，显示出模型在承受额外风险的同时，整体收益效率得到了一定程度的改善。而索提诺比率从 3.19 下降至 2.97，表明在针对下行风险的获利能力上，Symlog 模型相较于线性基准略有减弱。

消融实验结果显示了 Symlog 奖励函数的特征。它通过非线性变换机制，改变了智

中国知网 https://www.cnki.net

能体的风险收益偏好，使策略表现出更高的波动性。尽管增加了回撤代价，但其在绝对收益和夏普比率上的提升，验证了该设计在构建进攻性量化策略方面的应用价值。

表 10 不同奖励函数指标对比表

评价指标	Symlog 奖励函数	线性奖励函数
总收益率（%）	8.92	5.45
年化收益率（%）	52.52	30.00
年化波动率（%）	25.63	14.80
夏普比率	1.97	1.89
索提诺比率	2.97	3.19
卡玛比率	7.66	7.63
最大回撤（%）	6.86	3.93

（3）实验三：与经典投资组合策略的对比

为全面评估本研究提出的“Symlog 情绪增强模型”在真实市场环境下的综合性能与实用价值，本实验遵循 Yang 的对比框架[40]，将该模型与三种经典的在线投资组合基准策略以及上证 50 指数（SZ50 Index）进行了严格的回测对比。基准策略包括：作为风险分散基准的通用恒定再平衡投资组合（UCRP）、代表动量跟随逻辑的指数梯度投资组合（EGP），以及体现均值回归思想的在线移动平均反转策略（OLMAR）。本次测试的回测区间为 2024 年 10 月至 2024 年 12 月，该时段数据严格独立于训练集，以确保评估的客观性。

实验结果如表 11 所示，本研究提出的模型展现出了良好表现。在收益维度上，Symlog 模型是唯一实现显著正收益的策略，其总收益率达到 8.92%。与之形成鲜明对比的是，同期市场环境表现出明显的停滞特征，上证 50 指数仅微涨 0.14%，而传统的 UCRP、EGP 和 OLMAR 策略均未能适应当前的市场风格，分别取得-0.62%、-0.63% 和 -0.92% 的负收益。这一绩效差异证明了情绪增强 DDPG 模型在捕捉市场非线性 Alpha 收益方面的能力，它并未追随市场的平庸表现，而是走出了独立的超额收益曲线。

在风险调整后收益方面，这种优势更为显著。如表 11 所示，本模型的夏普比率（1.97）、索提诺比率（2.97）及卡玛比率（7.66）均处于高水平。相比之下，由于基准策略均为负收益，其对应的风险比率均为负值。

在风险控制机制上，Symlog 模型的年化波动率（25.63%）略高于 UCRP 和 EGP（19.13%），但这主要归因于其在捕捉上行趋势时的活跃交易。模型对下行风险的控制

中国知网 https://www.cnki.net

较为严苛，最大回撤仅为 6.86%，为所有对比策略中的最低值，优于 OLMAR 的 15.49%、UCRP 的 8.85%和 EGP 的 8.86%。这表明，模型增加的波动率主要贡献于资产净值的向上增长，而在面临市场不利波动时，其内置的情绪感知机制能够迅速止损，体现了一定的鲁棒性。

综上所述，本次对比测试表明，结合 Symlog 奖励函数的情绪增强 DDPG 模型在关键维度上超越了传统数学模型及市场指数。在其他策略普遍失效的震荡市况下，该模型依然得到 3 个月的 8.92%的可观回报，且保持了最低的历史回撤，充分证实了其强大的市场适应性与实际应用潜力。

表 11 不同交易策略的投资表现对比表

评价指标	Symlog Reward	UCRP	EGP	OLMAR	SZ50 Index
总收益率 (%)	8.92	-0.62	-0.63	-0.92	0.14
年化收益率 (%)	52.52	-3.04	-3.05	-4.46	0.69
年化波动率 (%)	25.63	19.13	19.13	35.82	16.31
夏普比率	1.97	-0.26	-0.26	-0.18	-0.08
索提诺比率	2.97	-0.38	-0.38	-0.31	-0.12
卡玛比率	7.66	-0.34	-0.34	-0.29	0.09
最大回撤 (%)	6.86	8.85	8.86	15.49	7.71

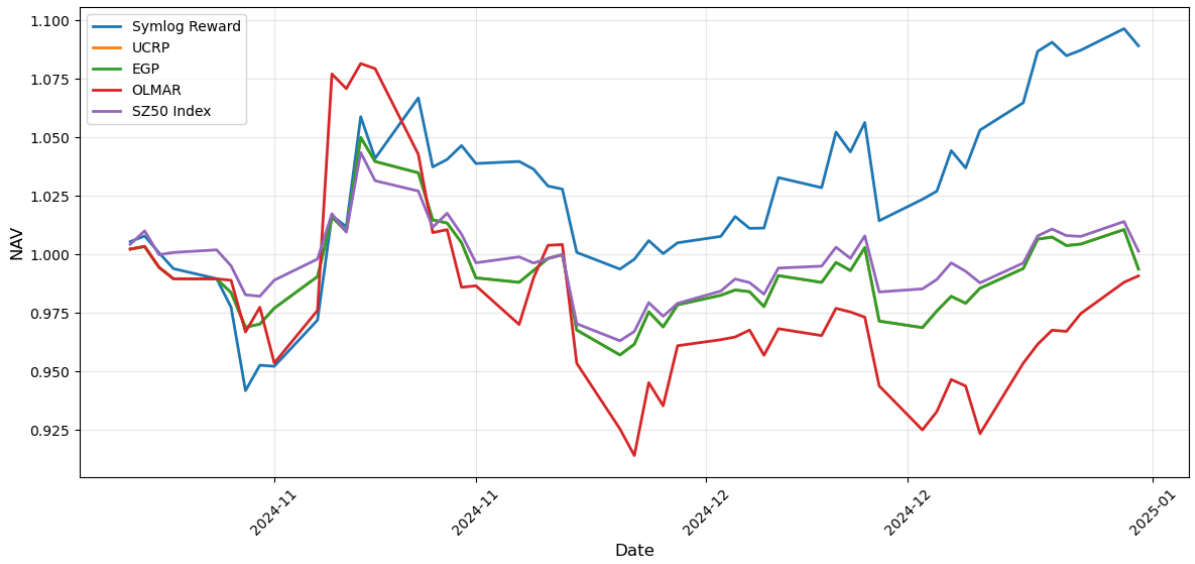


图 9 不同交易策略回测对比图

中国知网 https://www.cnki.net

4.5 本章小结

本章通过三个递进式实验，系统性地构建了从因子有效性验证、内部机制优化到外部环境适应性测试的论证闭环。

实验一旨在验证情绪因子引入量化决策系统的基础价值。通过对比集成情绪因子的DDPG 模型与基准模型，实证结果表明，情绪因子的融入提升了收益率，并起到了一定的市场噪音过滤作用，使策略的年化波动率有所下降。该结果证实，将非结构化舆情信息量化并应用于决策过程，能够改善模型的风险调整后收益，确立了本文所构建情绪因子的有效性。

实验二在实验一的基础上，聚焦于奖励函数的消融研究。针对线性奖励函数在捕捉市场极端波动时敏感度不足的问题，本实验引入了非线性的 Symlog 变换机制。实验数据表明，该优化设计提升了模型的年化收益率。尽管策略展现出更为积极的交易风格，但在承担相应风险的前提下，获取超额回报的效率得到了优化。这一结果验证了 Symlog 奖励函数在平衡收益潜力与资金利用效率方面的作用，确立了其作为模型核心内部构造的合理性。

实验三将经由上述优化的模型与 UCRP、OLMAR 等多种经典量化投资策略进行了性能对比测试。实验结果显示，在基准策略普遍呈现负收益的震荡市场环境下，本模型实现了稳健的正向回报，且最大回撤指标优于所有对比组。这一对比结果证明了模型在面对不同市场环境时具备较好的泛化能力与抗风险韧性。

综上所述，本章的系列实验从因子的引入到机制的改良，再到实战的检验，多角度证明了本研究构建的“情绪增强型 DDPG 策略”是一种高效、稳健且具备市场竞争力的智能资产配置方案，验证了本研究方法论的科学性与应用价值。

中国知网 https://www.cnki.net

第 5 章 总结与展望

本文围绕金融文本挖掘与强化学习在量化投资中的应用展开了深入的研究。在完成了理论构建、模型设计及实证分析之后，本章将对全文的研究成果与核心观点进行总结。对研究内容、创新点及主要结论三个方面对工作总结进行梳理，然后客观分析研究中存在的不足与局限，并结合金融科技领域的最新发展趋势，对后续的研究方向提出未来展望。

5.1 工作总结

本文围绕“金融舆情情绪因子构建”与“强化学习量化交易”两个核心环节展开研究，构建并实现了一个融合自然语言处理与深度强化学习的智能化量化投资决策框架。主要研究成果与结论如下：

多源异构金融数据集的构建。针对量化领域对高质量文本与行情数据的耦合需求，利用爬虫技术采集了东方财富网 2024 年度上证 50 成分股共计 33 万余条用户评论。通过针对性的噪声清洗、文本去重及格式标准化，构建了面向金融舆情的专题数据集，为后续研究奠定了数据基础。

基于知识蒸馏与领域微调的情绪因子建模。针对金融语境标注数据稀缺的难题，利用通用大模型实现原始语料的自动化标注，采用“教师-学生”模型的知识蒸馏范式对 RoBERTa 模型进行领域深度微调，相对基准大模型大幅提高了推理速度与效率。实验证明，该分类器识别准确率达 80%，较传统 TF-IDF 模型提升 12%。通过 IC 值检验，本文成功筛选并构建了移动平均、情绪背离和情绪动量三大具有预测能力的量化因子。

基于改进 DDPG 算法的交易策略与实证分析。本文将情绪因子、行情数据与技术指标协同输入深度确定性策略梯度（DDPG）框架。针对金融数据“重尾”分布导致的训练不稳定问题，创新性地引入 Log-Modulus 变换构建 Symlog 奖励函数，有效平衡了收益反馈的敏感度与极端波动的干扰。回测结果显示，该策略在夏普比率与最大回撤控制上均优于基准指数及单纯基于行情数据的对比模型，证明了情绪因子在增强策略的稳健性方面的核心价值。

5.2 未来展望

本文构建的融合大语言模型与深度强化学习的交易框架在回测中取得了一定成效，但受限于客观条件及金融市场的复杂性，本研究仍存在以下局限性值得后续研究。

（1）样本数据的覆盖面与时效性扩展。受限于高质量长周期金融文本数据的获取

中国知网 https://www.cnki.net

成本，本研究实证部分主要聚焦于 2024 年度上证 50 成分股数据，时间跨度尚不足以完整覆盖牛熊转换周期及突发性全球经济动荡。未来的研究可致力于构建更长周期的跨市场数据集，通过引入包含牛市、熊市及宽幅震荡市的多元历史场景，进一步验证并优化模型在极端市场环境下的泛化能力与参数鲁棒性。

（2）多模态因子的深度融合与权重动态分配。目前模型对市场情绪的捕捉主要依赖于主流财经门户的文本数据，尚未充分整合社交媒体实时热度、宏观经济指标、政策变动及产业链上下游等多源异构数据。未来的研究方向可探索多模态注意力机制，实现文本语义、图像趋势与数值序列的深度融合。

中国知网 https://www.cnki.net

参考文献

[1] Schumaker R P, Chen H. Textual analysis of stock market prediction using breaking financial news: The AZFin text system[J]. ACM Transactions on Information Systems (TOIS), 2009, 27(2): 1-19.

[2] 傅魁,刘玉洁,陈美丽.基于财经新闻情感倾向值的股票价格预测[J].北京邮电大学学报(社会科学版),2019,21(01):87-100.

[3] Kim Y. Convolutional neural networks for sentence classification [C] // Proc of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2014: 1746–1751.

[4] Liu Longfei, Yang Liang, Zhang Shaowu, et al. Convolutional neural networks for Chinese Micro-blog sentiment analysis [J]. Journal of Chinese Information Processing, 2015, 29(6): 159–165.

[5] Wu X-K, Chen M, Li W, et al. LLM fine-tuning: Concepts, opportunities, and challenges[J]. Big Data and Cognitive Computing, 2025.

[6] Nasiopoulos D K, Roumeliotis K I, Sakas D P, Toudas K, Reklitis P. Financial sentiment analysis and classification: A comparative study of fine-tuned deep learning models[J]. International Journal of Financial Studies, 2025.

[7] Xie Q, Han W, Zhang X, et al. Pixiu: A comprehensive benchmark, instruction dataset and large language model for finance[J]. Advances in Neural Information Processing Systems, 2023, 36: 33469-33484.

[8] 齐甜方,蒋洪迅.基于 Seq2Seq 文本摘要和情感挖掘的股票波动趋势预测[J].管理 评论,2021,33(05):257-269.

[9] Araci D. FinBERT: Financial sentiment analysis with pre-trained language models [J]. arXiv preprint arXiv:1908.10063, 2019.

[10] Chindukuri M, Sivanesan S. Transfer learning for Bloom's taxonomy-based question classification[J]. Neural Computing and Applications, 2024.

[11] Lin W, Liao L-C. Lexicon-based prompt for financial dimensional sentiment analysis[J]. Expert Systems with Applications, 2023.

[12] Zhao B, Jin W, Zhang Y, Huang S, Yang G. Prompt learning for metonymy resolution: Enhancing performance with internal prior knowledge of pre-trained language models[J]. Knowledge-Based Systems, 2023.

[13] Markowitz H. Portfolio selection. e Journal of Finance, 7 (1), 77-91[J]. 1952.

中国知网 https://www.cnki.net

[14] Sharp W F. Capital asset prices: A theory of market equilibrium under conditions of risk[J]. Journal of Finance, 1964, 19(3):425-442.

[15] Ross S R. The Arbitrage Pricing Theory of Capital Asset Pricing[J]. Journal of Economic Theory, 1976, 13(3):341-360.

[16] Black F, Litterman R. Global portfolio optimization[J]. Financial Analysts Journal, 1992, 48(5):28-43.

[17] Arnott R D, Wagner W H. The Measurement and Control of Trading Costs[J]. Financial Analysts Journal, 1990, 46(6):73-80.

[18] Konno H, Wijayanayake A. Portfolio optimization problem under concave transaction costs and minimal transaction unit constraints[J]. Mathematical Programming, 2001, 89(2):233-250.

[19] Suraj S M, Manoj T. Multi-objective heuristic algorithms for practical portfolio optimization and rebalancing with transaction cost[J]. Applied Soft Computing, 2018, 67:865-894.

[20] McDonald S, Coleman S, Mcginnity T, et al. A Comparison of Forecasting Approaches for Capital Markets[C]//2014 IEEE Conference on Computational Intelligence for Financial Engineering & Economics. IEEE, 2014:32-39.

[21] Wang W, Li W, Zhang N, et al. Portfolio formation with preselection using deep learning from long-term financial data[J]. Expert Systems with Application, 2020, 143(Apr.):113042.1-113042.17.

[22] Hu G. Advancing algorithmic trading: A multi-technique enhancement of deep q-network models[J]. arXiv preprint arXiv:2311.05743, 2023.

[23] Li X, Li Y, Zhan Y, Liu X-Y. Optimistic bull or pessimistic bear: Adaptive deep reinforcement learning for stock portfolio allocation[J]. Statistical Finance, 2019.

[24] Li Y, Wang J, Cao Y. A General Framework on Enhancing Portfolio Management with Reinforcement Learning[C]//Proceedings of the 2024 7th International Conference on Computers in Management and Business. 2024: 119-125.

[25] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning[J]. arXiv preprint arXiv:1509.02971, 2015.

[26] Liu X Y, Yang H, Chen Q, et al. FinRL: A deep reinforcement learning library for automated stock trading in quantitative finance[J]. arXiv preprint arXiv:2011.09607, 2020.

[27] Unnikrishnan A. Financial news-driven LLM reinforcement learning for portfolio

中国知网 https://www.cnki.net

management[J]. Computational Finance, 2024.

[28] Botunac I, Petković T, Bosna J. Automated Trading Framework Using LLM-Driven Features and Deep Reinforcement Learning[J]. Big data and cognitive computing, 2025, 9(12): 317.

[29] Wang Y, et al. Large Language Model Agent in Financial Trading: A Survey[J]. arXiv preprint arXiv:2408.06361, 2024.

[30] Etcil M, Kolukisa B, Bakir-Gungor B. Evaluating the impact of sentiment analysis on deep reinforcement learning-based trading strategies[A]. In: Proceedings of the 2024 9th International Conference on Computer Science and Engineering (UBMK)[C]. 2024: 456–461.

[31] Huang S, Yang K, Qi S, Wang R. When large language model meets optimization[J]. Swarm and Evolutionary Computation, 2024.

[32] Hao Q, Song Y, Liao Q, Yuan J, Li Y. LLM-Explorer: A plug-in reinforcement learning policy exploration enhancement driven by large language models[J]. Machine Learning, 2025.

[33] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.

[34] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.

[35] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 2002, 86(11): 2278-2324.

[36] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.

[37] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. Cambridge: MIT press, 1998.

[38] Silver D, Lever G, Heess N, et al. Deterministic policy gradient algorithms[C] //International conference on machine learning. Pmlr, 2014: 387-395.

[39] Cui Y, Che W, Liu T, et al. Revisiting pre-trained models for Chinese natural language processing[J]. arXiv preprint arXiv:2004.13922, 2020.

[40] Yang S. Deep reinforcement learning for portfolio management[J]. Knowledge-Based Systems, 2023, 278: 110905.

中国知网 https://www.cnki.net