单位代码	10445
学　　号	2023313028
分 类 号	O213

山东师范大学

硕士学位论文

（专业学位）

基于金融新闻情感分析的市场波动研究

Research on Market Volatility Driven by Financial News Sentiment Analysis

学位类别：应用统计硕士

领　　域：应用统计

学习方式：全日制

研 究 生：巩广鑫

指导教师：赵玉那

提交时间：2026年6月

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....2
1.2 相关文献综述.....3
1.2.1 国内研究现状.....3
1.2.2 国外研究现状.....4
1.3 论文组织结构.....5
1.4 研究创新点.....7
第二章 相关理论概述.....9
2.1 循环神经网络与 LSTM 理论基础.....9
2.1.1 循环神经网络的基本特征与局限.....9
2.1.2 LSTM 的门控记忆机制.....9
2.1.3 BiLSTM 的上下文扩展.....10
2.1.4 注意力机制与关键时序信息聚合.....11
2.2 基于二分类与树模型的预测方法基础.....12
2.2.1 Logit 模型的概率刻画.....12
2.2.2 LightGBM 的非线性补充作用.....12
2.3 基于 Transformer 的金融领域预训练语言模型理论.....13
2.3.1 Transformer 编码器与上下文语义表示.....13
2.3.2 金融领域预训练编码器基座的理论定位.....13
2.3.3 下游任务适配机制.....14
2.4 金融领域预训练模型的持续适配机制.....14
2.4.1 金融文本的语义特殊性.....14
2.4.2 持续预训练(DAPT)的理论作用.....15
2.4.3 持续适配在本文研究中的方法定位.....15
2.5 金融文本情绪量化与情绪因子构建原理.....16
2.5.1 从分类概率到连续情绪信号.....16
2.5.2 日度聚合与情绪因子的统计构造.....16
2.5.3 降噪、平滑与因子可用性.....17
2.6 时间序列预测中的滚动验证与防信息泄露.....18
2.6.1 金融时间序列的顺序依赖与信息泄露问题.....18
2.6.2 滚动验证与扩展窗口评估机制.....18
2.6.3 样本外评价的必要性.....19

中国知网 https://www.cnki.net

第三章 数据收集与处理 20
3.1 数据来源.....20
3.2 基于 TuShare API 的新闻数据采集策略.....21
3.3 数据预处理.....24
3.4 数据分布与质量控制的可视化说明 25
3.5 本章小结.....27
第四章 金融新闻情绪识别与情绪因子构建 28
4.1 模型的选择与领域适应.....28
4.1.1 领域自适应预训练(DAPT) 30
4.1.2 冻结-微调 32
4.2 情感概率推理与情感因子家族构建 33
4.2.1 模型推理输出与新闻级情感得分.....33
4.2.2 日内时段划分与聚合口径.....34
4.2.3 情感因子家族的构建.....34
4.2.4 EOD 与隔夜窗口因子的组织方式 35
4.3 情感输出特征与聚合因子的统计结构 37
4.3.1 新闻级情感输出的分布特征.....37
4.3.2 聚合后情感变量的时间结构与可用性 39
4.3.3 日内时段差异与因子家族构造的统计依据 41
4.4 本章小结.....43
第五章 情绪因子驱动的市场波动预测与样本外检验 44
5.1 数据集构造与信息输入口径 44
5.2 市场变量与情绪变量设定 45
5.3 预测任务与目标变量定义 46
5.4 评估设计.....47
5.4.1 模型.....47
5.4.2 扩展式滚动样本外评估.....48
5.4.3 区间与安慰剂.....48
5.5 结果分析.....49
5.5.1 主线结果.....49
5.5.2 方向补充.....51
5.6 本章小结.....52
第六章 研究结论与展望 53
6.1 研究结论.....53
6.2 研究展望.....54
参考文献.....56

中国知网 https://www.cnki.net

摘要

本文围绕金融新闻情绪与 A 股市场波动之间的关系展开研究，构建了“文本情绪提取—情绪因子构建—市场预测检验”的分析框架。本文以新浪财经 7×24 快讯为文本来源，结合市场交易数据，基于中文金融领域预训练模型提取新闻级三分类情绪概率，并进一步映射为连续情绪得分，构造包含方向、分歧、信息量、尾部压力及平滑扩展形式在内的情绪因子家族。在此基础上，本文将情绪因子与市场特征结合，采用滚动样本外评估方法，检验其对市场波动预测的增量作用。

研究结果表明，金融新闻情绪可以被稳定地结构化为可用于实证检验的情绪变量，但其预测价值具有明确的场景边界。本文围绕“文本情绪提取—情绪因子构建—市场预测检验”的流程展开：在情绪识别阶段，以 FinBERT2-base 模型为基座，先进行领域自适应预训练（DAPT）以增强对金融语境的表征，再采用部分层冻结的下游微调策略完成三分类训练，输出新闻级别的正/中/负概率，并据此构造方向、分歧、信息量、尾部压力及平滑扩展等一组互补的情绪因子。在市场预测阶段，本文在严格的信息可得性约束下，分别构造开盘前（OV）、盘中与收盘后等决策口径的数据集，并以扩展式滚动样本外评估为统一实验框架，比较仅含市场特征的基线与加入情绪因子的完整模型表现；任务层面同时覆盖极端事件识别与连续波动幅度刻画，其中分类任务以 PR-AUC、ROC-AUC、F1 等指标衡量，回归任务以 RMSE 与相关系数等指标衡量。实证结果显示，情绪因子的主要增量集中在与次日开盘再定价直接相关的分类任务中，尤其在开盘跳空等尾部事件识别上更为敏感，且该增量依赖于严格的时间对齐与信息窗口划分；方向细化的检验进一步表明，情绪变量对大幅高开型再定价的识别能力强于对大幅低开型再定价的识别能力。相比之下，在连续波动幅度的回归设定下，加入情绪因子并未在 RMSE 与相关性指标上给出同等强度的支持，说明新闻情绪更适合用于尾部风险与异常状态的判别，而不适合作为连续波动幅度的精细点预测工具。总体来看，本文认为金融新闻情绪更适合作为盘前监控、隔夜信息识别和开盘阶段风险判断的补充信号，而非对各类市场波动均普遍有效的预测因子。

关键词：金融新闻；情感分析；市场波动；情绪因子家族；样本外预测

分类号： O213

中国知网 https://www.cnki.net

Abstract

This study investigates the relationship between financial news sentiment and volatility in China’s A-share market, and develops an analytical framework comprising “text-based sentiment extraction—sentiment factor construction—market prediction evaluation.” Using Sina Finance 7×24 news flashes as the textual source in conjunction with market trading data, the study derives news-level tri-class sentiment probabilities from a Chinese financial-domain pretrained language model. These probabilities are further mapped to continuous sentiment scores, based on which a family of sentiment factors is constructed, including directional, disagreement, informativeness, tail-pressure, and smoothed/expanded variants. Building on this foundation, the study integrates sentiment factors with market features and evaluates their incremental predictive value for market volatility under a rolling out-of-sample evaluation protocol.

The results show that financial news sentiment can be stably structured into sentiment variables suitable for empirical testing, yet its predictive utility exhibits clear context dependence. Following the workflow of “sentiment extraction—factor construction—prediction evaluation,” the sentiment modeling stage uses FinBERT2-base as the backbone, applies domain-adaptive pretraining (DAPT) to enhance representations in financial contexts, and then performs tri-class fine-tuning with partial layer freezing. The resulting model outputs news-level probabilities for positive/neutral/negative sentiment, which are used to construct a set of complementary sentiment factors such as direction, disagreement, informativeness, tail pressure, and smoothed/expanded forms. In the market forecasting stage, under strict information-availability constraints, the study builds datasets aligned with decision timings—pre-open (OV), intraday, and post-close—and adopts an expanding rolling out-of-sample framework to compare a baseline using only market features with a full specification that additionally incorporates sentiment factors. The empirical tasks cover both extreme-event identification and continuous-volatility modeling: classification performance is assessed using PR-AUC, ROC-AUC, and F1, while regression performance is evaluated using RMSE and correlation coefficients. The evidence indicates that the incremental contribution of sentiment

中国知网 https://www.cnki.net

factors concentrates on classification tasks directly related to next-day opening repricing, with particularly strong sensitivity to tail events such as opening gaps; moreover, the gains rely on strict time alignment and information-window design. Directional analyses further suggest that sentiment variables identify large upward opening repricing more effectively than large downward opening repricing. By contrast, in continuous-volatility regression settings, adding sentiment factors does not deliver comparably strong improvements in RMSE or correlation, implying that news sentiment is better suited to detecting tail risks and abnormal states than to precise point prediction of volatility magnitude. Overall, the study argues that financial news sentiment serves more appropriately as a supplementary signal for pre-open monitoring, overnight information identification, and risk assessment around the market open, rather than as a universally effective predictor across volatility-related targets.

Keywords: financial news; sentiment analysis; market volatility; sentiment factor family;out-of-sample forecasting

Classification number: O213

中国知网 https://www.cnki.net

第一章　绪论

1.1　研究背景及意义

1.1.1　研究背景

在实际的市场运作过程中，情绪方面所带来的冲击一般是借助新闻报道、舆论传播以及社交媒体来持续扩散的，而且还会让价格的波动情况变得更加严重[40, 44, 45]，尤其是当出现重大经济事件、政策进行调整、地缘政治发生冲突或者行业突然出现意外事件的时候，市场里参与者们的情绪反应往往会比基本面的变化更早地表现出来，并且会在短时间内让资产价格出现十分突出的波动现象。就像近年来国际地缘政治形势慢慢变得紧张、通胀预期不断发生改变，在这个时间段里，和黄金有关的资产在新闻以及舆论情绪不断发展的推动下，出现了阶段性的上涨趋势，有一部分散户投资者因为情绪的影响而集中进入市场，这又提高了价格的波动程度。再像航空、能源等这些行业，在受到安全事件、油价波动或者政策预期变化等因素的影响时，与之相关的板块也大多时候会在相对较短的时间里出现十分突出的由情绪驱动的价格涨跌情况。这些现象很清晰地表明，市场的运行并非完全由理性的预期来主导，情绪信息同样也在价格形成的过程中深入地参与进来[3, 11]。

再进一步来讲，情绪对市场波动产生影响的内在机制，在近些年已然受到学术界以及实务界的广泛关注了。在金融学领域当中，像“羊群效应”“过度反应”这类理论，给理解这种现象提供了一个相对比较清晰的解释框架。当市场情绪处于高涨的状态之时，投资者很可能会因为过度乐观的心态而集中去进行买入操作，如此一来便有可能把资产价格给推高了；而一旦负面新闻开始密集地涌现出来的时候，那种恐慌的情绪又极有可能会快速地蔓延开来，进而引发集中抛售的行为，最终导致价格出现下跌的情况。所以说，由情绪扩散所引发的价格偏离情况，渐渐地就成为了用来解释市场短期波动的一个颇为重要的分析视角了[3, 10, 38]。

在如今这个信息传播速度不断加快的时代，金融市场揭示出了更强的“信息-情绪-价格”联动特征，新闻媒体、财经资讯平台以及社交媒体，已经成为投资者获取信息、形成预期的关键途径，要是情绪性信息在很大范围内广泛传播开，市场的波动就会表现出十分突出的非线性特点，尤其是在中国的 A 股市场里，个人投资者占的比例比较高，市场对新

中国知网　https://www.cnki.net

闻和舆论情绪往往会更加敏感。在这种情形下，金融新闻所包含的情感倾向很有可能直接对投资者的心理预期以及他们的交易行为产生作用，正是由于这个原因，如何更系统地去描述金融新闻情绪，进而深入分析它和市场波动之间存在的内在联系，这已经成为当前金融领域相关研究以及投资实践活动中的一个非常关键的问题[11, 22, 36]。

在这样的情况之下，情感分析属于自然语言处理领域当中的一个重要方向，它给量化文本里面的情绪因素带来了全新的技术途径。凭借机器学习以及深度学习的方法，研究者能够从数量众多的金融新闻文本当中提取出情感信号，在此基础上再去深入地考察它跟股票市场波动之间所存在的关联[4, 6, 25, 26]。就本文来讲，它一方面为识别并刻画市场情绪给予了可以实际操作的分析工具，另一方面也给理解价格波动产生的源头提供了不一样的研究角度。

1.1.2 研究意义

从理论角度来讲，开展基于金融新闻情感分析的市场波动研究，能够有利于我们拓展传统金融资产定价与波动理论的研究范畴，把文本情绪变量有系统地添加到市场波动分析的框架里面，这样就能够更加全面、更加细致地刻画投资者的行为特点，这能够弥补仅仅依靠价格信息和基本面变量进行分析时所存在的解释不够充分的问题，还可以为行为金融学和信息金融学相关的理论提供全新的经验依据，而且也有利于我们更深入地去理解市场微观结构视角下的情绪传导机制[3, 11, 40]。

从方法角度来说，随着自然语言处理和深度学习技术持续不断地发展，金融新闻情感识别的准确性以及可操作性都有了非常显著的提高，把情感分析的结果和机器学习模型结合在一起，有利于构建起更加多维、更具动态性的市场波动预测体系，这能够为金融时间序列建模提供新的技术途径和研究思路，并且能够提升模型在复杂市场环境之下的刻画能力和预测潜力[16, 17, 25, 27]。

从实践这个方面来看，对金融新闻情绪给 A 股市场波动带来的影响机制展开研究，这是利于把短期价格波动里情绪因素所发挥作用的路径揭示出来的，能够为投资者去识别市场情绪的变化、理解非理性波动的来源提供量化方面的依据，在市场情绪频繁出现波动的这种背景之下，依据新闻情感构建而成的情绪指标能够当作辅助决策的信号，帮助投资者

中国知网 https://www.cnki.net

更加审慎地去判断市场的走势，在市场情绪过于火热的时候保持警惕，在市场过度悲观的时候识别出潜在的错配机会，这样就可以降低情绪驱动类型的风险，提升投资决策的理性程度[10, 22]。再来说，对于金融机构以及监管部门而言，金融新闻情感分析同样能够作为衡量市场情绪状态的一个关键工具，为识别市场过热或者过冷的信号提供一定的参考，借助对新闻情绪进行持续不断的量化监测，监管部门能够更加及时地识别出潜在系统性风险的积聚过程，并且为逆周期调节政策以及市场预期管理提供数据方面的支持，进而提高宏观审慎监管的前瞻性以及有效性[11, 22]。

从社会这个层面去看，如今信息传播变得便捷，而且自媒体也广泛参与到市场舆论的形成过程中，在这样的背景之下，金融新闻对公众投资行为所产生的影响变得越来越明显，对新闻当中的情感信息开展系统的研究，能够帮助投资者提升对金融信息进行理性解读的能力，让他们减少做出情绪化决策的倾向，进而促进社会整体金融素养得到提升，并且还可以推动资本市场实现长期的健康与稳定发展[44, 45]。

总的来说，开展基于金融新闻情感分析的 A 股市场波动研究，它有着明确的理论拓展价值，也有较强的现实意义和应用前景。

1.2 相关文献综述

金融文本情感分析及其在股票市场预测中的应用，是近年来金融计量与金融科技领域的重要研究方向。相关研究大体经历了从情感词典与统计模型，到机器学习方法、深度学习模型，再到预训练语言模型的演进过程。本章将在梳理国内外相关文献的基础上，对现有研究的主要观点、方法路径及其不足进行归纳，以进一步明确本文的研究定位与可能的创新空间。

1.2.1 国内研究现状

情感词典与传统方法研究。在早期的时候，国内进行的相关研究大多是建立在中文情感词典、规则方法以及传统分类模型基础之上的。吴江等[4] 基于语义规则对 Web 金融文本开展了情感分析，黄进等[6] 将支持向量机与依存句法结合起来用于金融领域舆情分析，延丰等[8] 则借助情感词典与 LDA 模型对股市文本情绪进行了识别。在情绪因素与市场表现关系的研究方面，俞庆进、张兵[36] 和孙书娜、孙谦[39] 分别基于百度指数和雪球关注度等

中国知网 https://www.cnki.net

投资者关注指标，讨论了投资者关注与股票收益、市场表现之间的联系；岑咏华等[11]、胡国强和肖志超[37] 以及黄波、姜华东[38] 则从财经媒介信息、媒体关注和情绪化噪声等角度，对情绪因素在市场定价、企业投资以及波动机制中的作用进行了检验，这为国内情绪金融研究提供了较为直接的经验证据。

深度学习与融合建模研究。随着深度学习技术在中文自然语言处理领域的应用不断深入，国内学者开始把情感语义特征和市场数据结合起来开展相关建模工作。许雪晨、田侃[16] 提出了 SA-BERT-LSTM 模型，将 BERT 提取的情感特征与交易数据结合起来，用于沪深 300 指数走势预测。朱鹤等[25]、季玉文和陈哲[34] 将 BERT 用于金融文本情感分析，赵亚南等[15] 进一步融合多头自注意力机制来提升金融新闻极性识别效果；刘薇等[32] 基于 FinBERT-CNN 开展了股吧评论情感分析，段魏诚、薛涛[26] 则提出了 FinBERT-RCNN-ATTACK 模型。在预测层面，于孝建等[27] 将 LSTM 网络与文本情感特征结合起来用于股票指数预测。除了直接使用文本情绪来开展建模以外，也有一些研究从投资者关注度和市场情绪代理变量的角度进行分析，例如王娜等[22] 对基于股吧帖文的投资者情绪指数构建及其有效性进行了讨论。

1.2.2 国外研究现状

基于情感词典的早期研究。国外早期的研究主要依靠情感词典和统计回归模型，考察金融文本中的情绪与资本市场表现之间的关系。Tetlock[40] 借助对《华尔街日报》财经新闻的分析构建媒体情绪指标，实证发现新闻文本中的负面情绪与股票收益存在显著联系，较早揭示了媒体情绪影响市场行为的可能路径。Baker 和 Wurgler[3] 提出了投资者情绪指数，并从资产定价偏差等角度验证了情绪因素的解释能力，为情绪金融理论提供了重要的实证支持。在方法层面，Hatzivassiloglou 和 McKeown[47] 以及 Turney[48] 分别借助词汇关系和语义极性推断来实现情感判别，为后续的情感词典构建和文本极性分析奠定了基础。不过，这类方法对语境依赖的刻画相对有限，在面对更复杂的金融语义时往往存在一定局限。

机器学习情感分类阶段。随着文本挖掘技术和机器学习方法的发展，研究者开始将情感分析作为监督分类问题来建模。Pang 等[49] 将支持向量机等方法引入情感分类任务，明显提高了文本情绪判别的准确性，这也是该阶段较有代表性的研究之一。在语义建模方面，

中国知网 https://www.cnki.net

Wiebe[50] 和 Nasukawa、Yi[51] 分别从主观性分析和句法结构角度刻画文本情绪，为识别财经文本中的隐含情绪提供了方法上的支持。在金融市场应用方面，Antweiler 和 Frank[44] 基于互联网股票留言板数据讨论了网络讨论的信息含量，Das 和 Chen[45] 则从网络交流文本中提取投资者情绪，进一步拓展了金融情感分析的数据来源。

深度学习与语义建模阶段。在金融文本情感分析中，引入深度学习模型之后，文本表征能力得到了明显提升。Kim[52] 提出的 TextCNN 能够较好捕捉文本中的局部语义特征；Hochreiter 和 Schmidhuber[41] 提出的长短期记忆网络，以及 Cho 等[53] 提出的 RNN Encoder–Decoder 框架，提升了模型对时间依赖和序列特征的处理能力，并逐渐成为相关预测任务中的常用结构。在此基础上，Bao 等[42] 将堆叠自编码器与 LSTM 结合用于金融时间序列预测，验证了深度特征提取在复杂金融环境中的有效性；Hillert 等[43] 则指出，媒体报道强度会影响投资者预期，并对市场动量效应产生显著影响。

预训练语言模型阶段。近年来，预训练语言模型的出现明显改变了金融文本分析的研究模式。Devlin 等[62] 提出的 BERT 模型通过双向上下文建模显著提升了文本语义表示能力，Lan 等[63] 提出的 ALBERT 则在减少参数规模的同时保持了较稳定的性能。在金融预测与市场应用中，相关研究更强调将文本情绪特征与市场变量结合起来分析市场表现。Rupande 等[10] 从投资者情绪与收益波动关系的角度提供了经验证据，Gite 等[17] 则利用金融新闻情绪开展了可解释的股价预测。总体来看，国外研究更加注重从语义层面刻画金融文本情绪，并强调文本情绪与市场行为之间的内在联系。

1.3 论文组织结构

本节对本文主体部分的研究思路与行文安排作整体说明。

本文围绕金融新闻情绪与 A 股市场波动之间的关系展开，整体按照“理论基础-数据处理与研究设计-情绪提取与因子构建-市场预测检验-结论总结”的顺序推进。全文的重点不在于单纯完成文本情感分类，而在于将新闻中的非结构化情绪信息转化为可用于市场建模的结构化变量，并在严格控制信息时序的前提下，检验其对市场波动的增量解释能力。

从具体的研究流程方面来看，本文会先对金融新闻文本以及市场交易数据进行整理，并且在统一的时间口径之下，完成新闻发布时间、交易日历与市场数据这三者之间的匹配工

中国知网 https://www.cnki.net

作，在完成了这些匹配之后，结合中文金融领域的预训练模型来完成新闻级情绪概率的提取工作，接着从单条新闻的概率输出过渡到向日度聚合变量，构造出一个情绪因子家族，这个家族里面包含了方向、分歧、信息量、尾部压力以及平滑扩展形式等内容。之后，本文会把情绪因子和历史交易特征结合起来，建立一个面向样本外预测的市场波动分析框架，着重考察情绪信息在不同的信息窗口、不同的任务设定的情况下，是不是能够带来稳定的边际增量，考虑到金融时间序列有着十分突出的顺序依赖特点，全文在实证的部分都会把滚动样本外评估当作基本原则，并且尽可能避免未来信息出现泄露的情况。

在市场预测部分，本文以稳健、可解释的基准模型为主，同时引入非线性方法与短窗口序列模型作为补充，用于比较不同方法在极端波动识别中的表现差异。结果分析不仅关注样本外预测效果本身，也关注情绪信号是否依赖严格的时间对齐、其增量是否集中于特定任务，以及这种增量在方向上是否存在不对称性。基于这一思路，本文将情绪变量的作用放在“何时有效、对什么目标更有效”的框架下加以判断，而不是将其简单视为普适性的预测因子。

从全文结构来看，第一章为绪论，主要介绍研究背景、研究意义、文献综述以及本文的整体研究思路。第二章为相关理论概述，围绕序列模型、金融领域预训练语言模型、情绪量化方法以及时间序列样本外评估等内容，梳理本文所依赖的理论基础。第三章为数据收集与处理，主要说明新闻数据与市场数据的来源、清洗方法、时间对齐规则以及后续实证所使用的变量与研究框架。第四章为金融新闻情绪识别与情绪因子构建，重点讨论模型选择、领域适配、冻结微调策略，并在此基础上完成新闻级情绪概率输出、情绪得分构造及情绪因子家族的组织。第五章为情绪因子驱动的市场波动预测与样本外检验，主要在滚动样本外评估框架下检验情绪因子对市场波动预测的增量作用，并进一步结合安慰剂设定、方向细化和模型比较对结果进行展开。第六章为研究结论与展望，对全文研究发现进行归

中国知网 https://www.cnki.net

纳，并结合本文结果讨论后续仍可继续推进的方向。

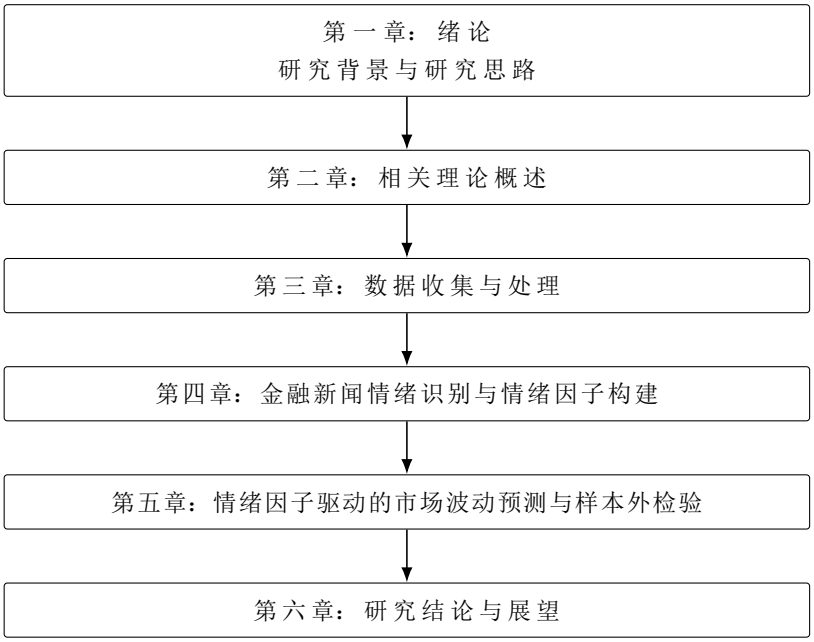


图 **1-1** 本文行文结构

总体而言，本文试图在统一方法链条下，将金融新闻中的情绪信息转化为可量化、可聚合、可进入市场模型的结构化因子，并据此更系统地考察新闻情绪在 A 股市场波动形成过程中的作用边界及其预测价值。

1.4 研究创新点

本文围绕金融新闻情绪与 A 股市场波动之间的关系展开研究，将新闻文本情绪识别、情绪因子构造与市场预测检验纳入同一分析框架，并在严格信息时序约束下考察其样本外预测价值。相较于仅停留在文本分类层面或仅使用单一情绪指标的研究，本文更关注金融新闻情绪如何转化为可用于市场分析的结构化变量，以及其在不同预测场景中的实际作用。本文的主要创新点如下：

（1）在情绪测度方面，本文基于中文金融领域预训练模型提取新闻级三分类情绪概率，并进一步映射为连续情绪得分，在此基础上构造了方向、分歧、信息量、尾部压力及平滑扩展形式等情绪因子。相较于单一情绪标签或简单均值指标，这一处理方式能够更完整地

中国知网 https://www.cnki.net

保留金融新闻中的方向、强度与异质性信息。

（2）在研究设计方面，本文围绕真实决策时点对新闻发布时间、交易日历与市场变量进行了严格对齐，区分盘前、盘中和盘后等不同信息窗口，构建了与信息可得性一致的数据口径，并采用滚动样本外评估方法检验情绪变量的增量作用。这样的设计有助于避免未来信息泄露，也使实证结果更贴近实际市场环境。

（3）在实证结论方面，本文进一步识别了金融新闻情绪发挥作用的具体场景。研究发现，情绪因子的预测价值并不具有普遍性，其增量作用主要体现在与次日开盘再定价相关的尾部识别任务中，尤其在异常跳空和高开型跳空识别中更为明显。本文因此不仅检验了情绪变量是否有效，也进一步说明了其更可能在哪类市场情境下发挥作用。

中国知网 https://www.cnki.net

第二章　相关理论概述

2.1　循环神经网络与 LSTM 理论基础

2.1.1　循环神经网络的基本特征与局限

循环神经网络是一种专门用来对序列数据进行建模的神经网络，它的核心特点在于，这个模型能够顺着时间维度递归地传递隐含状态，这就导致当前时刻的表示不只是取决于当期输入，还会受到历史信息的作用，也正是由于这个原因，RNN 在文本处理、时间序列分析等这些任务当中，有比较强的结构适配性，不过，传统 RNN 在运用时间反向传播算法进行训练的时候，随着序列长度持续变多，梯度在多步传播的过程中很容易出现衰减或者放大的状况，进而就会产生梯度消失或者梯度爆炸的问题。这个缺陷会降低模型对远距离依赖关系的刻画能力，让它更适合去处理短期依赖，而在那些需要反映短期扰动和阶段性趋势的复杂序列任务中，训练的稳定性和预测的表现一般都会受到一定程度的制约。

对于本文所研究的金融市场预测任务来说，输入并非是可以无限延展的长序列，而是由好几个历史窗口组合而成的有限的时序片段，就算是这样，市场变量和情绪信号之间还是有可能存在跨期传导以及非线性交互的情况，依旧需要一种能够在有限的历史窗口里面保留关键信息的序列建模结构，长短期记忆网络恰恰就是在这样的背景之下，对传统的 RNN 做出的有效的改进。

2.1.2　LSTM 的门控记忆机制

LSTM 通过引入记忆单元（cell state）与门控结构，对信息的保留、更新与输出进行显式控制，从而缓解传统 RNN 在长期依赖建模中的梯度衰减问题。设在时间步 t 的输入为 $\boldsymbol{x}_t$，上一时刻的隐含状态为 $\boldsymbol{h}_{t-1}$，上一时刻的记忆状态为 $\boldsymbol{C}_{t-1}$，则 LSTM 的核心计算过程

中国知网　https://www.cnki.net

可表示为：

$$\boldsymbol{f}_t = \sigma\big(\boldsymbol{W}_f[\boldsymbol{h}_{t-1}, \boldsymbol{x}_t] + \boldsymbol{b}_f\big), \tag{2.1}$$

$$\boldsymbol{i}_t = \sigma(\boldsymbol{W}_i[\boldsymbol{h}_{t-1}, \boldsymbol{x}_t] + \boldsymbol{b}_i), \tag{2.2}$$

$$\tilde{\boldsymbol{C}}_t = \tanh(\boldsymbol{W}_C[\boldsymbol{h}_{t-1}, \boldsymbol{x}_t] + \boldsymbol{b}_C), \tag{2.3}$$

$$\boldsymbol{C}_t = \boldsymbol{f}_t \odot \boldsymbol{C}_{t-1} + \boldsymbol{i}_t \odot \tilde{\boldsymbol{C}}_t, \tag{2.4}$$

$$\boldsymbol{o}_t = \sigma(\boldsymbol{W}_o[\boldsymbol{h}_{t-1}, \boldsymbol{x}_t] + \boldsymbol{b}_o), \tag{2.5}$$

$$\boldsymbol{h}_t = \boldsymbol{o}_t \odot \tanh(\boldsymbol{C}_t). \tag{2.6}$$

其中，$\sigma(\cdot)$ 为 Sigmoid 激活函数，$\tanh(\cdot)$ 为双曲正切函数，$\odot$ 表示 Hadamard 逐元素乘积。上述结构中，遗忘门 $\boldsymbol{f}_t$ 与输入门 $\boldsymbol{i}_t$ 共同决定历史信息与当前信息在记忆状态中的相对权重，输出门 $\boldsymbol{o}_t$ 则控制当前时刻隐含表示的形成。由于记忆状态在时间维度上保留了近似线性的传递路径，LSTM 能够在一定程度上缓解梯度消失问题，从而增强模型对跨期动态关系的建模能力。

在本文的研究框架中，LSTM 的作用主要是从有限的历史窗口中提取短中期动态模式，捕捉市场变量与情绪信号在时间上的非线性传导关系。

2.1.3 BiLSTM 的上下文扩展

在部分序列建模任务中，仅依赖单一方向的信息传递，可能不足以刻画同一历史窗口内部的局部上下文关系。双向长短期记忆网络（Bi-directional LSTM，BiLSTM）在标准 LSTM 的基础上引入正向与反向两个独立的 LSTM 分支，分别对同一序列进行前向与后向编码。设正向与反向隐含状态分别为 $\boldsymbol{h}_t^{\rightarrow}$ 与 $\boldsymbol{h}_t^{\leftarrow}$，则时间步 t 的双向表示通常写为：

$$\boldsymbol{h}_t = [\boldsymbol{h}_t^{\rightarrow}; \boldsymbol{h}_t^{\leftarrow}], \tag{2.7}$$

其中，$[\cdot;\cdot]$ 表示向量拼接。该结构能够在同一历史窗口内部同时利用前后时序关系，从而提升对局部模式的刻画能力。

需要说明的是，BiLSTM 是否造成未来信息泄露，并不取决于其“双向”结构本身，而取

中国知网 https://www.cnki.net

决于输入窗口的定义方式。若模型输入仅由预测时点之前已经观测到的历史样本构成，则反向传播只作用于该历史窗口内部，并不会调用预测目标时点之后的信息，因此不构成严格意义上的未来信息泄露。基于这一点，BiLSTM 在本文中更适合作为有限历史窗口内部的扩展性特征提取工具，而不是市场预测部分的主线建模框架。

2.1.4 注意力机制与关键时序信息聚合

虽然 LSTM 和 BiLSTM 能够对序列进行动态的编码操作，不过在不同的时间步当中，它们对预测目标所起到的贡献一般是不一样的，为了提高模型对于关键时间点的识别和判断能力，可以在序列编码的结果之上，引入注意力机制，从而对不同的隐含状态进行加权之后再聚合起来。

设 BiLSTM 在各时间步输出的隐含状态为 $\{\boldsymbol{h}_1, \boldsymbol{h}_2, \ldots, \boldsymbol{h}_T\}$，则可先定义每一时刻的重要性评分为：

$$e_t = \boldsymbol{v}^\top \tanh(\boldsymbol{W}\boldsymbol{h}_t + \boldsymbol{b}), \tag{2.8}$$

其中，$\boldsymbol{W}$、$\boldsymbol{v}$ 和 $\boldsymbol{b}$ 为可学习参数。进一步通过 Softmax 将评分归一化为注意力权重：

$$\alpha_t = \frac{\exp(e_t)}{\sum_{\tau=1}^{T} \exp(e_\tau)}, \tag{2.9}$$

并构造全序列的上下文向量：

$$\boldsymbol{c} = \sum_{t=1}^{T} \alpha_t \boldsymbol{h}_t. \tag{2.10}$$

其中，$\boldsymbol{c}$ 为经过加权聚合后的序列表示。与简单平均或末端时刻抽取相比，注意力机制能够使模型在训练过程中自适应地突出对预测更为关键的时间步信息。

在本文的研究框架中，这一机制主要提供一种可扩展的时序信息聚合思路，用于强化对局部冲击阶段或关键变化节点的表征。需要指出的是，注意力权重反映的是模型内部的表示分配，并不等同于严格意义上的因果解释。

中国知网 https://www.cnki.net

2.2 基于二分类与树模型的预测方法基础

2.2.1 Logit 模型的概率刻画

在本文第五章的市场预测部分，若干核心任务被表述为极端事件识别问题，其目标变量本质上属于二分类设定。对于这类任务，Logit 模型能够直接刻画事件发生概率，因此具有较好的适配性。设二分类目标变量为 $y_t \in \{0,1\}$，特征向量为 $\boldsymbol{x}_t$，则 Logit 模型可写为：

$$P(y_t = 1 \mid \boldsymbol{x}_t) = \frac{1}{1 + \exp\left(-(\beta_0 + \boldsymbol{\beta}^{\top}\boldsymbol{x}_t)\right)}, \tag{2.11}$$

其中，β_0 为截距项，$\boldsymbol{\beta}$ 为待估参数向量。其对数几率形式可进一步写为：

$$\log \frac{P(y_t = 1 \mid \boldsymbol{x}_t)}{1 - P(y_t = 1 \mid \boldsymbol{x}_t)} = \beta_0 + \boldsymbol{\beta}^{\top}\boldsymbol{x}_t. \tag{2.12}$$

该模型的优点在于结构清晰、可解释性较强，能够较直接地反映各类特征对极端事件发生概率的边际影响。在本文场景下，Logit 更适合作为主线基准模型，用于检验情绪因子在控制市场特征之后是否仍能提供稳定的增量信息。尤其在样本规模有限、强调样本外稳健性时，采用结构相对克制的概率模型更有利于识别情绪变量是否确实具有边际解释力。

2.2.2 LightGBM 的非线性补充作用

与 Logit 这类线性概率模型相比，基于梯度提升树的模型更擅长刻画变量之间的非线性关系与高阶交互。LightGBM（Light Gradient Boosting Machine）即属于这一类方法。其基本思想是在加法模型框架下，通过逐步叠加决策树来逼近目标函数。若记第 m 轮迭代后的模型为 $F_m(\boldsymbol{x})$，则其更新形式可表示为：

$$F_m(\boldsymbol{x}) = F_{m-1}(\boldsymbol{x}) + \nu h_m(\boldsymbol{x}), \tag{2.13}$$

其中，$h_m(\boldsymbol{x})$ 表示第 m 轮学习得到的树模型，ν 为学习率。模型通过沿着损失函数负梯度方向不断拟合残差，实现对复杂映射关系的逐步逼近。

在本文的研究框架里面，LightGBM 的意义其实主要并不是要去替代处于主线地位的线性基准，而是要当作一个补充模型来用，目的是检验一下情绪因子和市场状态之间是不是存在线性模型很难捕捉到的非线性交互情况，就例如同样强度的情绪冲击，在不同的波

中国知网 https://www.cnki.net

动背景之下，或者是不同的成交活跃度情况中，又或者是不同的价格状态当中，有可能会对应不一样的市场反应方式。把树模型引入进来，是利于对这类潜在的非线性关系进行补充识别的，不过要考虑到金融预测任务本身带有比较强的噪声，而且样本规模也是有限的，树模型的作用更加适合用来对主线结果进行补充验证，而不适合去替代那种以可解释性和稳健性作为导向的基准框架。

2.3 基于 Transformer 的金融领域预训练语言模型理论

2.3.1 Transformer 编码器与上下文语义表示

预训练语言模型的重要进展之一在于以 Transformer 编码器替代传统递归结构，从而显著增强对长距离语义依赖的并行建模能力。其核心机制是自注意力（Self-Attention）。给定输入序列表示后，模型通过线性映射分别构造查询（Query）、键（Key）和值（Value）向量，记为 $\boldsymbol{Q}$、$\boldsymbol{K}$ 与 $\boldsymbol{V}$，则缩放点积注意力可表示为：

$$\mathrm{Attention}(\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V}) = \mathrm{softmax}\left(\frac{\boldsymbol{Q}\boldsymbol{K}^{\top}}{\sqrt{d_k}}\right)\boldsymbol{V}, \tag{2.14}$$

其中，d_k 为键向量维度。该机制使模型在生成任一位置表示时，能够同时访问序列中其他位置的信息，从而突破传统递归结构在长距离信息传递上的路径限制。进一步地，多头注意力机制可在不同子空间中并行建模多种语义关系，为深层上下文表示学习提供结构基础。

2.3.2 金融领域预训练编码器基座的理论定位

在本文里，我们选择了 `valuesimplex-ai-lab/FinBERT2-base` 作为主要的基座模型，这里需要专门说明一下，这个模型属于在中文金融领域经由预训练的 BERT/RoBERTa 类编码器基座，它最主要的作用是为金融文本提供上下文语义方面的表示，而不是那种可以直接输出情感类别、拿来就能用的任务分类器。从这个模型的定位来看，它更像是一个“领域化语义编码底座”，而不是“已经完成特定下游任务适配的分类终端”，和直接针对情感分类任务的金融文本分类模型进行比较，编码器基座是有一定优势的，它的方法衔接会更加自然，它一方面能够作为持续预训练的承接基础，这样就能吸收目标语料里的领域信息；另一方面，在后续的阶段，也很方便结合冻结微调、轻量任务头或者概率映射等方式，统一为“文本表征-情绪信号提取-情绪因子构建”这样的两阶段研究框架来服务。本文对于这

中国知网 https://www.cnki.net

类模型理解的重点，并不是某一个特定预训练目标的历史细节，而是它作为 Transformer 编码器在金融语境下所有的双向上下文表示能力，换一种说法来讲，本文所依靠的核心理论基础是“金融领域预训练编码器所形成的上下文语义表征”，而不是把它当作已经完成情感分类适配的现成任务模型。

2.3.3 下游任务适配机制

在完成预训练后，编码器基座可通过多种方式适配下游任务。设预训练参数为 $\boldsymbol{\theta}$，下游任务损失函数为 $\mathcal{L}_{\text{task}}$，则其一般形式可表示为：

$$\boldsymbol{\theta}^{*} = \arg\min_{\boldsymbol{\theta}} \mathcal{L}_{\text{task}}(\boldsymbol{\theta}). \tag{2.15}$$

在实际的具体应用当中，下游任务的适配其实并不只是局限于全参数监督微调这种方式，考虑到任务目标和标注数据规模存在不同的情况，还可以采用持续预训练的方法，或者是把主体编码器冻结之后仅仅训练轻量任务头，也可以进行部分层的微调，又或者是利用领域化基座模型直接开展推理等不同的方式，就本文所研究的金融新闻情绪识别这个问题来说，采用领域化编码器基座当作统一的语义底座，并且在这个基础之上进行后续任务的适配，这样做更加符合样本规模、方法衔接以及实验扩展性等综合要求。

2.4 金融领域预训练模型的持续适配机制

2.4.1 金融文本的语义特殊性

金融文本在术语分布、叙事结构以及情绪表达方式这些方面，存在着十分突出的领域特征，在财经新闻、研究报告、公告解读以及市场评论这些内容当中，绝大多数时候都会包含数量不少的专业术语、政策表述以及事件性语言，而且同一个词语在金融语境里的语义倾向，很多时候会随着具体的情境而发生变化，即便模型已经有了一般性的语义理解能力，它内部的表示空间也不一定就能够完全与金融文本里的细粒度语义差异相契合。对于情绪识别任务来说，这个问题是相当关键的，金融情绪并非总是借助非常突出的情感词直接揭示出来，而是更多的时候会嵌入在业绩变化、政策预期、风险提示以及市场叙事这些内容里面，要是缺乏足够的领域语义适配，模型虽然能够完成一般性的文本理解，但是在金融语境之下仍然有可能出现情绪极性判断不稳定、专业词义识别存在偏差等问题。

中国知网 https://www.cnki.net

2.4.2 持续预训练（DAPT）的理论作用

在领域预训练基座之上进一步引入目标金融语料进行持续预训练（Domain-Adaptive Pre-Training, DAPT），其目的在于继续缩小模型当前参数分布与目标任务语料分布之间的差距。该过程通常仍以掩码语言建模为核心目标，其优化形式可表示为：

$$\mathcal{L}_{\mathrm{DAPT}} = -\sum_{i \in M} \log P(x_i \mid \boldsymbol{x}_{\setminus M}; \boldsymbol{\theta}), \tag{2.16}$$

进一步地，更新后的参数可记为：

$$\boldsymbol{\theta}' = \arg\min_{\boldsymbol{\theta}} \mathcal{L}_{\mathrm{DAPT}}(\boldsymbol{\theta}). \tag{2.17}$$

需要指出的是，在本文框架下，DAPT 并非“从通用语言模型重新转向金融语料”的第一次领域迁移，而是在已有金融领域预训练基座之上进行更贴近研究任务语料分布的再适配。因此，其作用重点不在于从零建立金融语言能力，而在于进一步增强模型对目标财经语境、新闻表述模式与任务相关术语搭配的敏感性。

2.4.3 持续适配在本文研究中的方法定位

就本文所采用的“文本表征-情绪因子构建-市场预测验证”这种两阶段的研究框架而言，持续适配的意义，主要体现在它能够为后续要开展的情绪识别工作提供更加稳定的语义基础，在金融领域的预训练基座的基础之上，模型可以去吸收目标语料当中所包含的信息，这样模型就能够更加充分地贴合财经新闻里的专业表达方式以及潜在的情绪线索。如此一来，就能够提高后续概率输出的一致性以及可用性，接着看，这一过程也为冻结微调、轻量任务头构建以及后续的情绪信号映射提供了统一的参数依据，进而让文本表征层、情绪识别层与因子构建层这几个层面之间的方法衔接变得更加紧密，持续适配是模型层面的一种性能优化办法，它还搭建起了本文从文本分析过渡到市场预测的关键方法桥梁。

中国知网 https://www.cnki.net

2.5 金融文本情绪量化与情绪因子构建原理

2.5.1 从分类概率到连续情绪信号

金融文本情绪识别的直接输出一般表现为类别标签或者与之对应的类别概率，和单纯使用离散标签的情况比起来，根据概率分布去构建连续情绪信号，能够更加全面地保留模型针对情绪方向以及置信程度做出判断的相关信息，这种方式更适合作为后续进行日度聚合以及开展市场预测时的中间表示形式，假设在第 d 日的第 j 条新闻所对应的情感预测概率分别是 $p_{d,j}^{(+)}$、$p_{d,j}^{(0)}$ 以及 $p_{d,j}^{(-)}$，那么就能够把它映射为单条文本的连续情绪得分。这类映射的核心思路是，凭借正负概率之间存在的相对差异来描述情绪方向，并且依靠概率的大小来保留有关情绪强弱的信息，这样的话，文本层面的离散分类结果就可以被转化为适合后续进行统计聚合的连续信号，在本文里，这种连续化处理的目标并非直接形成最终的预测变量，而是充当从“单条文本输出”向“日度结构化因子”过渡的中间层。它能为后续构建有方向性、强度性、分歧性以及活跃度等不同类型的情绪指标提供一个统一的基础。

2.5.2 日度聚合与情绪因子的统计构造

由于市场预测通常以交易日为基本分析单位，文本层面的情绪信号需要进一步聚合为日度指标。设第 d 日共有 N_d 条新闻，对应单条文本的情绪得分为 $s_{d,j}$，若引入新闻权重 $\omega_{d,j}$（可由文本重要性、来源权威性、篇幅或其他标准确定），则日度情绪均值因子可定义为：

$$S_d = \frac{\sum_{j=1}^{N_d} \omega_{d,j} s_{d,j}}{\sum_{j=1}^{N_d} \omega_{d,j}}. \tag{2.18}$$

当不设置额外权重时，上式退化为等权平均。该指标反映了某一交易日整体新闻环境的情绪方向，可视为市场信息环境的情绪代理变量。

除方向性均值外，还可进一步构建用于刻画情绪强度、分歧程度与信息数量的辅助因子。例如，情绪强度可表示为：

$$I_d = \frac{1}{N_d} \sum_{j=1}^{N_d} |s_{d,j}|, \tag{2.19}$$

中国知网 https://www.cnki.net

其反映当日新闻情绪表达的绝对强弱；情绪分歧度可表示为：

$$D_d = \sqrt{\frac{1}{N_d - 1}\sum_{j=1}^{N_d}(s_{d,j} - S_d)^2}, \tag{2.20}$$

其刻画同一交易日内不同文本情绪判断的一致性或离散程度；而新闻数量本身 N_d 亦可作为市场关注度或信息活跃度的近似度量。由此，文本情绪不再仅表现为单一指数，而是可扩展为包含方向、强度、分歧与活跃度在内的情绪因子集合，为后续市场预测提供更丰富的解释维度。

2.5.3 降噪、平滑与因子可用性

金融新闻情绪信号一般会有高噪声、异质性比较强，以及日内样本数不均衡这样的特征，单条文本也许会受到标题风格、媒体立场、重复报道以及语义歧义等因素的影响，要是直接把原始分类结果用在市场预测方面，就很容易引入比较大的随机波动，鉴于此，对日度情绪信号进行一定程度的平滑或者收缩处理是有合理性的。

例如，可对日度情绪因子进行指数平滑处理：

$$\tilde{S}_d = \lambda S_d + (1 - \lambda)\tilde{S}_{d-1}, \quad 0 < \lambda \leq 1, \tag{2.21}$$

其中，$\tilde{S}_d$ 为平滑后的情绪因子，λ 为平滑参数。该处理能够在保留情绪方向变化的同时，降低偶发性噪声对序列稳定性的干扰。

从研究的逻辑方面来看，情绪因子的构建实际上是一个“从微观的文本输出转变为宏观的日度特征提炼”的过程，一开始会由金融领域的预训练编码器得到文本层的概率表示，接着凭借连续化的映射、日度的聚合，以及必要的降噪处理，把原始的情绪输出转变为能够进入市场预测模型的结构化时序特征，就变量的类型来说，这类特征一般还可以分化成方向性指标、强度性指标、分歧性指标、信息活跃度指标，以及经由平滑或者收缩以后的稳健指标。在本文后续的实证部分，会依据这些给出具体的变量定义和实现形式。

中国知网 https://www.cnki.net

2.6 时间序列预测中的滚动验证与防信息泄露

2.6.1 金融时间序列的顺序依赖与信息泄露问题

金融市场的数据有着十分突出的时间顺序方面的特征，不同时间点所进行的观测并不是相互独立且有相同分布情况的，像价格、收益、成交量以及情绪因子这些变量，大多时候会凭借跨期的机制对彼此产生影响，在进行模型训练和评价的时候，一定要严格按照时间的先后顺序来，要是采用把样本随机打乱的方式去划分训练集和测试集，就有可能让未来某个时间点的信息以一种隐含的形式进入到训练的过程当中，这样一来，就会造成未来信息发生泄露的情况，最终导致模型在样本之外的性能被高估了。

从预测任务角度看，任一时刻的预测应满足以下基本约束：

$$\hat{y}_{t+1} = f(\boldsymbol{x}_{1:t}), \tag{2.22}$$

即对 $t+1$ 时点的预测只能基于 t 时点及其之前已经观测到的信息。若在特征构造、标准化、窗口切分或模型评估过程中不加区分地使用全样本数据，则可能违反这一约束，削弱实证结果的可信度。

对于本文所研究的“情绪因子 + 市场变量”联合预测问题，上述约束尤为关键。因为情绪因子本身已由新闻文本经聚合而来，若在因子构造或后续训练阶段引入未来日期的信息，便会使模型性能呈现不真实的乐观偏差。

2.6.2 滚动验证与扩展窗口评估机制

为更贴近真实预测场景，时间序列建模通常采用滚动验证（walk-forward validation）、滚动窗口（rolling window）或扩展窗口（expanding window）等方式进行样本划分。其基本思路是，在每一轮评估中只使用当前时点之前的历史数据完成训练，再对后续时点进行样本外预测。

中国知网 https://www.cnki.net

以扩展窗口为例，设第 k 轮训练样本截至时点为 T_k，测试窗口长度为 m，则可定义：

$$\mathcal{D}_{\text{train}}^{(k)} = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_{T_k}, y_{T_k})\}, \tag{2.23}$$

$$\mathcal{D}_{\text{test}}^{(k)} = \{(\boldsymbol{x}_{T_k+1}, y_{T_k+1}), \ldots, (\boldsymbol{x}_{T_k+m}, y_{T_k+m})\}. \tag{2.24}$$

随着 k 不断推进，训练集的边界会持续地向前扩展，然而测试集一直处于训练集的后面，这样的方式符合在真实预测里依靠已经有的历史情况去推断未来的信息结构，还可以在样本数量有限的条件下，最大程度地利用历史数据，进而提升模型估计的稳定性，与之相比，滚动窗口方法一般会让训练窗口的长度保持相对固定，它更适合用在关注近期分布变化的场景当中。这两种方法的共同特点是，都把时间顺序当作前提，着重进行样本外评估，而不是借助随机切分来得到表面上更高的拟合结果，考虑到金融市场存在阶段性变化以及潜在的非平稳性，采用滚动式样本外验证能够体现模型在不同阶段的泛化能力。

2.6.3 样本外评价的必要性

对于金融预测任务来说，研究的重点不是去解释历史样本里面的拟合优度情况，而是要去评估模型对未来那些未知样本的预测能力怎么样，判断模型是好还是坏，应该建立在样本外的表现上面，不能仅仅根据训练集或者随机划分的测试集上得到的结果来判断，样本外评价的意义主要有三个方面的体现。第一个方面，样本外的结果能够更加真实地把模型在实际应用当中的泛化能力反映出来。第二个方面，在时间顺序的约束之下进行滚动验证，这样可以有效地降低未来信息泄露的风险，进而提高实证结论的可信度。第三个方面，在样本数量有限的条件下，多轮滚动评估能够减弱单次划分所带来的偶然性，让模型比较变得更有稳健性，在本文第五章的市场预测这一部分，采用滚动验证或者扩展窗口评估的方法，并且把样本外的预测表现当作主要的评价依据，这是时间序列方法论上的基本要求，也是保证情绪因子有效性检验有学术可信度的必要前提。

中国知网 https://www.cnki.net

第三章　数据收集与处理

3.1　数据来源

本文所使用的数据主要是由新闻文本数据和市场交易数据这两部分共同构成的，文本数据的来源是新浪财经的“7×24 小时全球实时财经新闻直播”这个栏目，这个栏目有着较高的更新频率，信息覆盖的范围也比较广，并且发布时间的记录十分明确，能够比较及时地反映出宏观政策的变化、产业的动态、资本市场发生的事件以及国际金融的波动情况。和深度评论类的报道相比较，这类财经快讯更加侧重于事实性的陈述，文本的篇幅一般都比较短，整体的结构也相对比较规整，更适合用来进行后续的情感推断以及时序聚合处理工作，作为国内比较有代表性的财经信息平台当中的一个，新浪财经的新闻内容囊括了宏观经济、产业政策、资本市场的运行以及国际金融动态等多个不同的方面，为本文刻画市场信息冲击以及情绪变化提供了相对比较完整的文本基础。



图 **3-1** 新浪财经 7×24 小时全球实时财经新闻直播页面示意

在数据获取的方式方面，本文没有直接去采用网页解析式抓取这种方法，而是借助 TuShare 平台所提供的标准化财经数据接口来进行程序化的采集工作，TuShare 在金融研

中国知网　https://www.cnki.net

究领域的应用是比较广泛的，它能够提供结构化的新闻以及行情数据接口，这对于保持字段格式、时间戳结构以及后续批量处理方式的一致性是有帮助的，本文里的新闻数据就是凭借它的 news 接口来获取的，并且新闻来源被限定为新浪财经。

在市场数据的选取上，本文主实验最终以沪深 300 指数作为市场代表指标，用来刻画核心股票市场的整体波动特征。沪深 300 指数同时覆盖沪深两市中市值较大、流动性较强的代表性股票，因此更适合作为本文衡量市场整体状态的核心代理变量。

在时间范围方面，本文最终所采用的实证样本区间是从 2025 年 1 月 1 日开始，一直到 2025 年 6 月 30 日结束，按照这样的一个时间区间完成程序化采集工作之后，所得到的原始有效新闻样本总共有 150,347 条，经由后续开展的基础清洗以及字段整理等工作，最终用于进行情感分析以及市场预测建模的样本数量为 150,298 条。因为在数据采集阶段就已经嵌入了显式去重的逻辑，前后样本的数量差异是非常小的，这也能够说明原始数据在结构上有较高的可用性。

需要说明的是，考虑到本文关注的重点是金融新闻情绪在短期信息到达、隔夜传导以及次日开盘再定价过程中的作用，该样本期内较为密集的新闻记录能够支撑新闻级情绪提取、日度聚合以及样本外预测检验。与此同时，本文结论首先反映的是这一观察窗口内的经验特征。由于样本时间跨度相对有限，不同市场状态、政策阶段与波动周期下情绪因子作用的稳定性，仍有待在更长样本区间中进一步考察。换言之，本文结果更适合被理解为在既定样本窗口与研究设定下得到的阶段性证据，其外推边界需要结合后续扩展样本继续检验。

3.2 基于 TuShare API 的新闻数据采集策略

在本文中，新闻数据是凭借 TuShare 的 news 接口来进行程序化采集的，其核心的调用形式和传统接口 pro.news(...) 有关，在这个调用里，src='sina' 是用来指定新闻来源的，而 start_date 和 end_date 则是用来限定时间区间的。和传统的网页爬虫相比较，基于 API 的采集方式不会依赖对 HTML 页面进行解析，在字段结构、时间戳格式以及返回结果的组织方式这些方面，一般会更加稳定，对于本文来说，这种采集方式更加便于开展批量获取、结构化存储以及后续的时间对齐处理等工作，它也更利于形成可以复现的数据

中国知网 https://www.cnki.net

采集流程。

需要说明的是，该接口单次请求的返回条数存在上限，且本身不提供分页参数。如果直接按照较长时间区间一次性请求，就可能出现返回结果被截断的情况，进而造成样本缺失，而且这类缺失往往不易在事后立即发现。基于这一点，本文没有采用按月或按季度整体请求的方式，而是将采样区间进一步拆分为按自然日划分的子区间，并以“天”为单位逐日调用接口。这样处理后，单次请求的数据规模能够被控制在较小范围内；即便某一日期出现接口异常，也可以只对该日进行补采，从而更好地保证整体样本的完整性。

在具体的实现过程当中，本文专门设置了可以进行配置的起止日期参数，然后，凭借循环的方式，一天一天地生成与对应日期相匹配的起止时间窗口，之后，再按照顺序依次发起接口请求，要是在某一个日期发起请求的时候失败了，程序就会把异常信息记录下来，并且跳过这个日期，接着继续去执行后续日期的采集任务，这样做的话，就算在局部日期出现了接口错误的情况，也不会让整段时间区间的数据获取工作被迫中断。采集流程的稳定性和鲁棒性就得到了相应的提升，考虑到 TuShare 接口存在着访问频率方面的限制，本文在相邻的请求之间设置了固定的等待间隔，这样做的目的是尽量降低触发限频约束这种情况出现的风险，这样的设置的确会在一定的程度上让整体的采集速度变慢，不过，对于那种跨越较长时间区间、并且需要按照日期连续执行的数据采集任务而言，能够稳定地完成任务往往要比单纯地追求速度更加关键。这样的处理是很有必要的，而且也有现实方面的合理性。

在数据存储这一方面，本文采用的是增量式合并策略，而不是直接把原来的文件覆盖掉，要是本地的新闻数据文件已经存在了，程序就会先把有的样本读取出来，然后把新获取到的数据和历史样本拼接在一起，并且在合并完成之后统一进行去重和保存，和覆盖式保存比起来，这种方式更适合多次运行的情况，还可以支持程序中断之后继续采集，也能让研究区间逐步扩展，更有利于保持数据获取流程的连续性，也能让数据获取流程有可复现性。除此之外，本文的去重处理并不是完全等到预处理阶段结束之后才进行的，而是在采集程序内部同步完成，代码在每次进行增量合并之后，都会直接把新闻标题和正文内容的组合当作联合唯一标识，对样本进行显式去重，考虑到财经快讯在实际发布的过程中经

中国知网 https://www.cnki.net

常会出现重复推送的情况，不同批次请求之间也有可能出现时间区间重叠的问题，这种前置处理能够在数据进入主分析流程之前就先把大多数重复的记录剔除掉，让采集阶段输出的数据本身就有比较高的整洁度。这也就解释了为什么本文“原始有效样本”和“最终可用样本”在数量上的差异比较小，重复样本实际上在采集和合并阶段就已经被提前清除了，而不是完全留到后续集中处理。

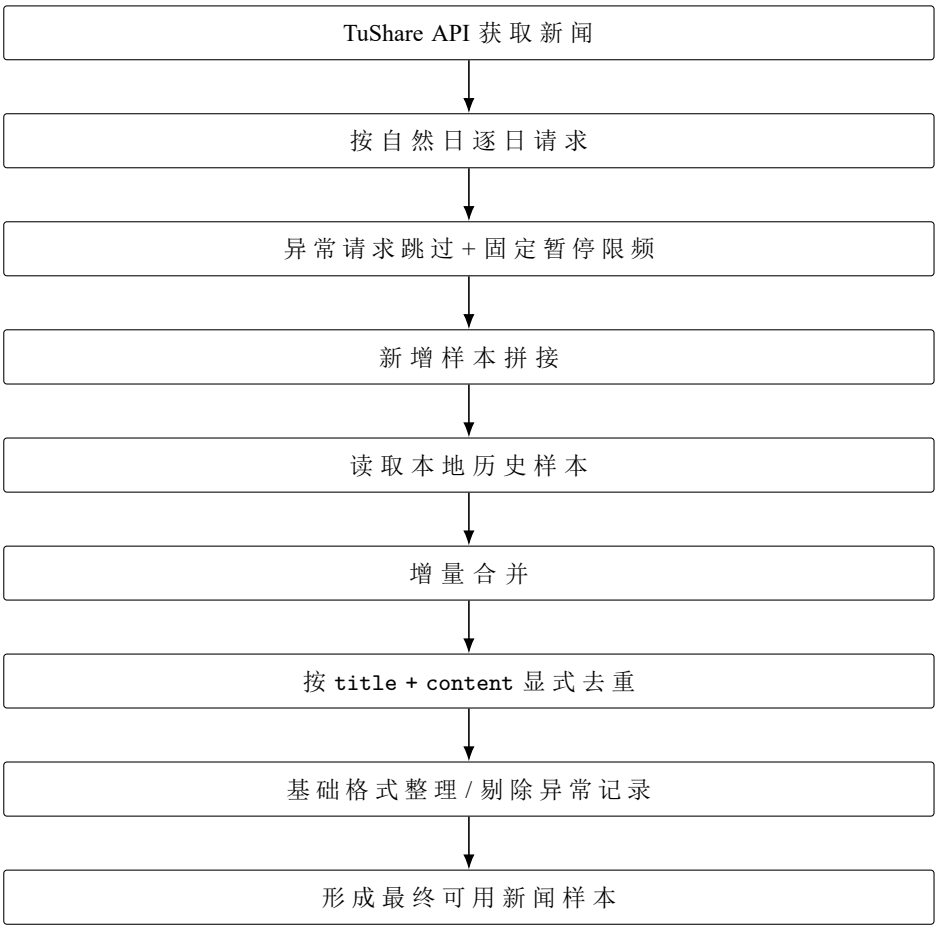


图 **3-2** 新闻数据增量抓取与清洗流程

总体而言，本文在接口访问受限的条件下，构建了一套具有稳定性、扩展性与可复现性的新闻数据采集方案。该方案在保证新闻样本完整性的同时，有效控制了重复样本与接

中国知网 https://www.cnki.net

口风险，为后续金融新闻情感分析及市场波动预测提供了可靠的数据基础。



图 **3-3** 原始采集数据样例（部分）

3.3 数据预处理

在完成原始新闻数据的采集之后，本文针对样本开展了基础预处理工作，在处理过程中，重点聚焦于结构的一致性，而不是过度依赖那些复杂的文本改写规则，之要这样处理，主要是由于新浪财经 7×24 快讯整体的篇幅比较短，其内容大多是事实更新和事件播报，文本格式本身就比较规整，要是在预处理阶段引入过多的启发式改写规则，反而有可能破坏原始事件的信息，这样一来就会影响后续预训练语言模型对上下文语义的直接识别和利用。基于这样的思路，本文的预处理工作主要从几个方面来展开。第一个方面，对多次运行之后形成的增量样本进行统一的整理。第二个方面，对时间字段、文本字段以及基础格式进行统一的处理，借助这样的方式来保证后续按照日期和时段聚合的时候口径能够保持一致。第三个方面，对空文本以及明显异常的记录进行检查并且剔除。第四个方面，对文本当中的无关标记、冗余空白以及部分格式噪声进行基础的清理，从而提高字段的可读性，并且提高模型输入的规范性。

另外，因为采集程序在增量合并的过程当中，已经同步把去重工作完成了，后续的预处理阶段，并不存在需要集中清除的大规模重复样本这种情况，也就是说，本文的数据质

中国知网 https://www.cnki.net

量控制并不是单纯依靠后处理来完成的，而是在“采集-合并-去重”这一连贯的流程里面就已经提前完成了，正因为是这样，从样本数量的变化情况来看，原始有效数据和最终可用数据之间仅仅存在很小的差异。这也能够表明，在进入正式的分析流程之前，本文的数据已经有了较好的结构完整性以及实际可用性，在文本这个层面，考虑到后续的情感分析还是需要保证模型输入的质量，本文保留了必要的基础清洗步骤，这些步骤包括去除无关的标记、统一空白字符、规范字段的格式，并且对明显缺失或者内容异常的样本进行排查，这里处理的重点并不是对新闻正文进行大幅度的改写，而是要提升文本字段的可读性、可解析性以及整体的一致性。总体来说，本文在预处理阶段遵循“以结构性清洗为主、以语义保留为优先”的原则，也就是在尽量保留原始信息的基础之上，提高样本在后续建模当中的可用性。

为保证模型输入文本的语义有效性与一致性，本文对新闻文本执行如下清洗规则：

- 去除 HTML 标签及无关标记；
- 保留中文字符、英文字符、数字及常见金融符号；
- 合并多余空格，统一文本格式；
- 删除重复新闻文本；
- 剔除空文本或异常样本。

形式化地，对原始文本 x 进行清洗映射：

$$x^{*} = C(x), \tag{3.25}$$

其中，$C(\cdot)$ 表示文本清洗算子。

经上述处理后，最终保留的可用新闻样本为 150,298 条，为后续情感推断、情感因子构造及市场预测模型提供了稳定的数据基础。

3.4 数据分布与质量控制的可视化说明

为更直观地展示样本期内新闻数据的时间覆盖情况，本文进一步统计了 2025 年 1 月 1 日至 2025 年 6 月 30 日期间的按日新闻数量，并绘制时间序列图。该图能够从整体上反映

中国知网 https://www.cnki.net

新闻流在样本期内的到达强度及其波动特征，同时也为后续情感聚合与市场变量对齐提供必要的直观依据。

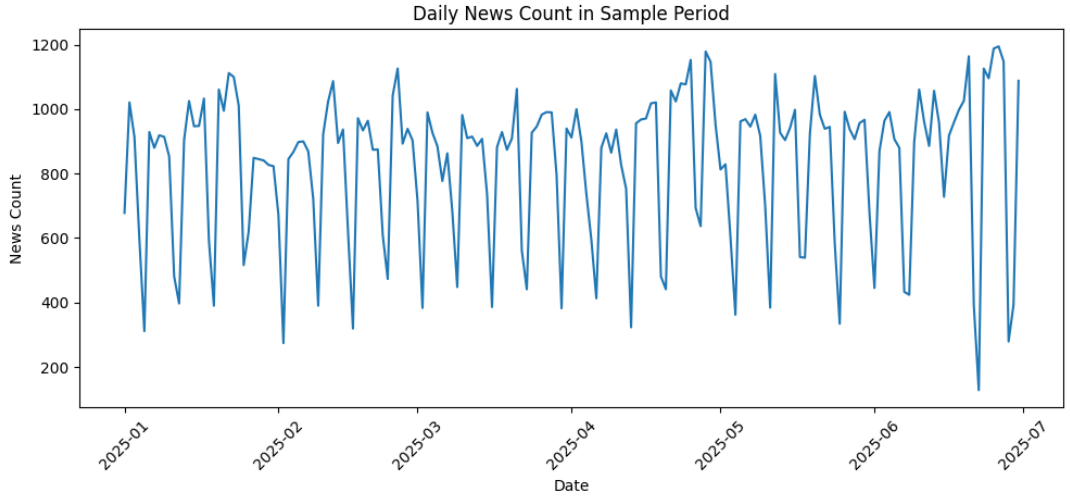


图 **3-4** 样本期内按日统计的新闻数量

从图 3-4 可以看出，在样本所涉及的时期之内，新闻的数量并不是仅仅围绕着某一个固定的水平去做简单的随机性质的波动，而是呈现出十分突出的有周期性的起伏情况，这种现象主要是和图里面所采用的统计口径存在关联，本文是依照新闻自然的发布日期来开展统计工作的，并没有把交易日和非交易日重新进行归并处理，周末以及节假日的相关信息也都被一起纳入到了这个序列当中。在交易日历所产生的影响之下，在工作日期间和 A 股市场相关联的政策方面的信息、公司发布的公告以及市场的动态情况往往会更加集中地进行发布，新闻的数量一般是处在比较高的水平，到了周末或者是其他的非交易日的时候，虽然仍然会有国际市场以及宏观方面的资讯持续不断地进行更新，但是和国内市场直接相关的信息供给就会相对来说有所减少，新闻的总量也会跟着出现阶段性的回落。正是因为这种高低变化会反复不断地出现，序列从整体上来看就呈现出近似于按照周来重复的那种锯齿形状的波动。

还需要特别说明一下的是，在图里面个别偏低的点并不一定就意味着数据存在异常情况，它有可能是和节假日期间信息的密度下降有关系，也有可能是局部日期新闻发布量减少导致的，又或者是和接口采集过程当中出现的短时波动存在关联，不过要是从整体的走势情况来看，在样本期之内的新闻供给依旧保持着比较强的连续性和稳定性，这样的情况是完全能够支撑后续情感分析以及市场预测建模的基本需求的。这张图还表明了，新闻流

中国知网 https://www.cnki.net

在时间这个维度上存在着十分突出的日历效应，在后续开展情感因子构造以及市场数据对齐工作的时候，还是需要对周末以及非交易日的信息进行的处理，这样做是为了避免仅仅按照自然日简单累积之后，让情绪信号被稀释掉。

3.5 本章小结

本章主要说明了本文所使用的数据来源、新闻采集方式、预处理规则以及样本分布情况。本文以新浪财经 7×24 快讯为文本来源，借助 TuShare API 完成程序化采集，并在此基础上进行了去重、清洗、时间字段标准化以及与交易日历的对齐处理；与此同时，市场交易数据也按照后续实证所需的时间口径完成了整理。进一步的可视化结果表明，样本期内新闻数量与发布时点具有较为明显的时间分布特征，数据整体能够满足后续情绪推理、因子聚合与市场建模的需要。本章的工作为第四章的情绪提取和第五章的预测检验提供了数据基础。

中国知网 https://www.cnki.net

第四章　金融新闻情绪识别与情绪因子构建

4.1　模型的选择与领域适应

本文专门设置了情感分析模块，这个模块的作用并不只是单纯完成文本分类，它更关键的目的是要为后面的情绪因子构建以及市场波动预测提供稳定的、能够解释清楚的概率输出。按照这样的要求，在选择模型的时候，不能只看单一的分类精度，还得考虑语言适配性的问题、金融领域的先验知识、模型处于什么样的层级，以及它和后续研究流程是怎么衔接起来的。针对这一点，本文把比较的对象归纳成了三类，分别是英文金融情感分类模型、中文通用情感分类模型，以及中文金融领域预训练基座模型。

yiyanghkust/finbert-tone 可以看作是英文金融情绪或者语气分析中比较有代表性的一个方案，这个模型是针对英文金融文本设计的，它围绕金融语气识别做了专门的设计，而且已经完成了下游三分类的微调，能够直接输出正面、中性和负面这三类标签。在英文场景下，它有比较强的工程可用性，不过本文的研究对象是中文财经新闻，如果直接使用这类模型，一般还得经由机器翻译或者跨语言迁移，这样就会引入额外的不确定性，这种不确定性特别体现在金融术语对应、语义强弱表达，以及否定结构和政策措辞的识别方面，对于本文来说，它更适合当作英文金融情感分析的参照，不太适合作为中文场景下的主线模型。

IDEA-CCNL/Erlangshen-RoBERTa-110M 更适合归入中文通用情感分类模型。这个模型在中文表达方面的适配性是比较好的，它能够相对轻松地完成情感分类推理的任务，并且在工程实现方面的成本也比较低，它适合当作本文里的中文基线模型，不过，它的局限也比较明显，这类模型虽然有着比较强的通用情感识别能力，但是当面对财经新闻里经常出现的那种“表面上是中性，实际上偏向利空”或者“表面上是中性，实际上偏向利好”这类更加依赖领域语境的表达时，不一定能够稳定地呈现出足够的识别优势。把它放在对照的位置上，更利于检验金融领域模型和中文通用情感模型相比，是不是真的存在实际的增益。

在主线模型的选择上，本文最终采用 valuesimplex-ai-lab/FinBERT2-base。这里需要说明，本文使用的 FinBERT2-base 属于中文金融领域预训练的 BERT/RoBERTa 类编码器基

中国知网　https://www.cnki.net

座（base encoder），它本身并不是即用的情感分类器。虽然它与 yiyanghkust/finbert-tone 都属于金融文本建模方向的 BERT 家族模型，但两者在语言语料、模型层级和使用目的上并不相同。yiyanghkust/finbert-tone 面向英文金融语气分类任务，属于已经完成下游微调的任务模型；valuesimplex-ai-lab/FinBERT2-base 更接近中文金融文本建模的领域预训练底座，更适合承接后续 DAPT、冻结微调以及情绪因子构建等一整套流程。对于本文“文本表征-情绪因子构建-市场预测验证”的两阶段框架而言，FinBERT2-base 在方法衔接和后续扩展上都更符合研究需要。

当然，FinBERT2-base 在中文金融语料上的领域适配优势，并不意味着它在下游市场预测任务中一定优于中文通用情感模型。作为基座模型，它的最终表现仍会受到下游任务头设计、训练策略、样本质量以及概率校准方式等因素的共同影响。因此，模型优劣不能仅凭名称或领域属性作先验判断，而应放在统一的数据划分、统一的因子构造方式以及统一的滚动样本外评估框架下检验。

为避免命名上的混淆，本文将 yiyanghkust/finbert-tone 统一记作“英文 FinBERT（任务模型）”，将 valuesimplex-ai-lab/FinBERT2-base 记作“中文 FinBERT2（领域基座模型）”。两者名称相近，但并不属于同一模型谱系下的不同检查点，因此在比较时，需要从语言场景、模型层级和研究用途这三个维度加以区分。

表 **4-1** 本文模型选择的比较框架

候选方案	语言侧重点	主要优势	在本文场景中的主要约束
yiyanghkust/finbert-tone	英文金融文本	英文金融语气任务成熟；三分类可直接推理	中文场景需翻译或迁移；跨语言语义偏差风险较高
IDEA-CCNL/Erlangshen-RoBERTa-110M 等中文通用情感模型	中文通用文本/情感表达	中文适配较好；实现成本低；适合作为对照基线	金融领域先验较弱；细粒度金融情绪识别能力有限
valuesimplex-ai-lab/FinBERT2-base（本文基座）	中文金融领域取向的 BERT 系基座	中文金融领域预训练；便于 DAPT/冻结微调；适配因子构建流程	非现成分类器；需下游任务头与训练校准；增益需实证验证

由表 4-1 可见，本文选择主线模型，并不是基于“领域模型一定更优”的预设，而是基于中文财经新闻语境、方法链条衔接以及后续因子构建与实证检验的一致性综合判断。在此基础上，后文将以 FinBERT2-base 作为统一基座，继续考察 DAPT 与冻结策略对下游情

中国知网 https://www.cnki.net

感分类及情绪因子质量的影响。

4.1.1 领域自适应预训练（DAPT）

在本文里，在进行下游情感分类训练之前，引入了领域自适应预训练，这么做的目的是为了缩小基座模型和目标中文金融新闻语料之间在分布上的差异，虽然论文中选用的 `FinBERT2-base` 已经有了一定的金融领域基础，不过它的预训练语料和论文所使用的中文财经新闻相比，在表达习惯、事件叙述的方式以及语义重心方面，依旧存在着差异。在金融新闻当中，情绪信息往往不会直接附着在显性情感词上面，更多的是体现在事件的描述、因果结构以及语气的变化里面，要是仅仅依靠原始的预训练表示，不一定能够充分地刻画这类有语境化的情绪特征，基于这样的考虑，论文先利用没有标注的金融文本进行持续预训练，让模型的参数朝着论文任务对应的金融语义空间靠近，这样就能提高模型的领域语言建模能力和领域表征能力。

从方法属性上看，DAPT 属于迁移学习框架下的持续预训练（continued pre-training）。其优化目标并不直接对应情感分类标签，而是通过掩码语言模型（MLM）任务提高模型对领域文本分布的拟合能力。其目标函数可表示为

$$\mathcal{L}_{\mathrm{MLM}} = -\mathbb{E}_{x\sim\mathcal{D}} \sum_{i\in\mathcal{M}} \log P_\theta\left(x_i \mid x_{\setminus\mathcal{M}}\right), \tag{4.26}$$

其中，$\mathcal{D}$ 表示金融文本语料分布，$\mathcal{M}$ 表示掩码位置集合，θ 为模型参数。

结合本文的实现流程来看，DAPT 主要包含四个步骤，第一步，把 `FinBERT2-base` 以及和它对应的分词器当作初始化的基础来操作；第二步，对那些没有标注的金融新闻进行统一的编码处理，这其中覆盖了长度截断、padding 操作以及 token 化等工作；第三步，在动态掩码机制的规则下，开展 MLM 持续预训练的相关工作；第四步，将预训练完成之后的模型参数以及分词器进行保存，这样做是为了方便后续开展下游分类实验的时候可以进行调用。为了避免把 DAPT 自身所起到的作用，和下游冻结策略、分类头结构以及弱标注噪声这些因素混合在一起，本文分别从 MLM 层面以及下游迁移层面来对它展开评价，从 MLM 层面的评价，是用来考察 DAPT 有没有让领域语言建模能力得到改善；从下游迁移层面的评价，则是用来检验这种改善能不能转化成为下游分类的收益。

中国知网 https://www.cnki.net

表 **4-2** DAPT 在 MLM 层面的效果对比

模型配置	Eval_Loss	PPL
Base MLM	1.5848	4.8784
DAPT MLM	1.3146	3.7233

表 4-2 表明，经过 DAPT 后，模型在统一领域验证集上的评估损失由 1.5848 降至 1.3146，困惑度由 4.8784 降至 3.7233，两个指标都出现了明显下降。这说明持续预训练确实增强了模型对目标金融语料分布的拟合能力。就 MLM 指标而言，DAPT 在本文中是有效的，其直接作用主要体现在领域语言建模能力的提升上。

在此基础上，本文进一步在完全一致的下游训练协议下比较 DAPT 前后的迁移表现。具体做法是只替换编码器初始化来源，其余设置保持不变，统一采用 `freeze 0--3 + linear` 的配置，在弱标注保留验证集上进行评估，结果如表 4-3 所示。

表 **4-3** DAPT 对下游分类性能的影响

配置	冻结策略	分类头	Macro-F1	Micro-F1	Weighted-F1	Brier	ECE
Base encoder	0–3	Linear	0.9450	0.9504	0.9507	0.0738	0.0192
DAPT encoder	0–3	Linear	0.9440	0.9501	0.9504	0.0767	0.0189
差值（DAPT-Base）	0–3	Linear	-0.0010	-0.0004	-0.0003	0.0029	-0.0003

由表 4-3 可见，在当前下游设定下，DAPT 并未带来显著的分类性能提升。与 Base encoder 相比，DAPT encoder 的 Macro-F1、Micro-F1 与 Weighted-F1 仅出现极小幅波动，整体差异接近于零。概率指标方面，DAPT 后 Brier 分数略有上升，ECE 略有变化，说明其收益并未直接体现在当前情感分类任务的预测性能与概率质量改善上。也就是说，DAPT 在下游分类层面的增益并不突出，但同时也未造成明显的性能损失。

为进一步考察模型在更高质量标签条件下的表现，本文在 100 条人工标注外部评估集上进行了补充比较。结果表明，Base encoder 与 DAPT encoder 的 Macro-F1 和 Micro-F1 保持一致，均未观察到明确的分类性能提升；与此同时，DAPT 模型在 Brier 分数和 ECE 上略有波动，整体仍延续了保留验证集中的结论。由此可见，DAPT 的作用并未充分传导为下游分类指标上的优势，但其负向影响也较为有限，模型总体表现保持稳定。

综合来看，DAPT 在本文中的价值主要不应理解为对下游分类指标的直接拉升，而应

中国知网 https://www.cnki.net

定位为对金融文本领域表征能力的补充增强。结合前面 MLM 阶段的结果，可以判断 DAPT 在领域语言建模方面有效，它让模型参数更贴合金融语料的分布，形成领域适配性更强的初始化基础，这一改进没有在当前下游设定中转变为分类收益，考虑到指标变化幅度小，没有出现明显性能下降，还可以增强模型对金融语境的对齐程度，本文最终仍将 DAPT 保留为整体建模流程中的预训练增强步骤。换而言之，在本文框架下，DAPT 的直接贡献主要体现为领域建模能力提高，不是下游分类指标改善。

4.1.2 冻结-微调

在选择冻结策略的时候，需要以对基座模型分层功能的合理假设作为基础，本文所使用的基座是 BERT 系结构，在实际的应用过程中，不同的层一般会承担不同粒度的表征任务，而这种分层的特性恰恰就是冻结策略设计的前提条件。

在本文所设定的实验里，可以把 12 层编码器根据功能近似地划分成三个区间：第 0 到第 3 层这个区间，偏向于进行词汇级和局部句法级的表征，它主要负责比较基础的 token 组合以及局部上下文模式；第 4 到第 7 层这个区间，偏向于短中程语义组合以及句内结构的整合，在这个区间开始形成比较稳定的上下文语义表示；第 8 到第 11 层这个区间，更接近与任务相关的语义以及决策边界，它对具体的分类目标会更加敏感。

在这一分层假设下，冻结策略的关键不在于冻结越多越好或全部放开越好，而在于如何在保持底层表示稳定性与释放高层任务适配能力之间取得平衡。若冻结过多（如全冻结），模型对本文标签体系的适应能力会受到限制；若完全不冻结，中高层则更容易受到弱标注噪声的扰动，训练稳定性也可能随之下降。

结合冻结网格实验（以弱标签验证集 Macro-F1 作为选择指标）的结果，本文最终选择

中国知网 https://www.cnki.net

冻结第 0–3 层。结果如下表所示。

表 **4-4** 冻结策略网格比较

冻结策略	Macro-F1
all（全冻结）	0.8444
0–3	0.9440
0–7	0.9333
none（不冻结）	0.9309

从表 4-4 可以看到，0–3 冻结策略在当前实验中取得了最高的验证集 Macro-F1（0.9440），略优于 0–7 和不冻结方案。这个结果说明，在本文的数据与标签条件下，保留底层基础表示的稳定性，同时释放更多中高层进行任务适配，比“冻结过深”或“全部放开”都更合适。0–3 因而不是经验上的默认设定，而是当前实验下更稳妥的折中方案。基于这一结果，后续情感分类及推理流程均以该冻结策略作为主方案展开。

4.2 情感概率推理与情感因子家族构建

4.2.1 模型推理输出与新闻级情感得分

在本文最终流程中，情感模型的主要作用是对新闻文本进行前向推理并输出三分类概率，而不是在本章继续进行新的监督训练。对于第 i 条新闻，模型输出

$$p_{\mathrm{neg},i},\quad p_{\mathrm{neu},i},\quad p_{\mathrm{pos},i}, \tag{4.27}$$

并满足

$$p_{\mathrm{neg},i} + p_{\mathrm{neu},i} + p_{\mathrm{pos},i} = 1. \tag{4.28}$$

在类别标签层面，可定义预测标签为

$$\hat{y}_i = \arg \max_{c\in\{\mathrm{neg},\mathrm{neu},\mathrm{pos}\}} p_{c,i}. \tag{4.29}$$

为尽量保留概率信息，并避免直接离散化带来的信息损失，本文采用连续型新闻情感

中国知网 https://www.cnki.net

得分

$$s_i = p_{\mathrm{pos},i} - p_{\mathrm{neg},i}, \tag{4.30}$$

其中 $s_i \in [-1, 1]$。这一设定具有较直观的解释：当正向概率高于负向概率时，s_i 为正；反之为负；中性概率则主要通过压缩正负概率差来体现“情绪不确定性”与“方向弱化”。

4.2.2 日内时段划分与聚合口径

本文会先按照新闻的时间戳来进行日内时段的划分，这样做的目的是方便后续去构造更有交易语义的情绪聚合变量，设新闻时间对应小时为 h_i，则时段标签定义为如下

$$m_i = \begin{cases} \mathrm{pre_open}, & 0 \le h_i < 9, \\ \mathrm{trading}, & 9 \le h_i < 15, \\ \mathrm{post_close}, & 15 \le h_i < 24. \end{cases} \tag{4.31}$$

这种划分并不是对交易所微观时段进行严格的复刻，它实际上是为了服务于文本聚合以及后续因子构造而采用的一种工程化的分段方法，在市场当中，开盘前的信息、交易时段的信息和收盘后的信息，它们所起到的作用机制是不一样的，如果直接把这些信息混合在一起进行处理，一般会让情绪变量的解释性变弱，按照时段去区分信息到达的顺序，这是后续进行因子组织很关键的一个前提条件。

4.2.3 情感因子家族的构建

如果仅仅使用单一的日均情感指数，新闻数量、情绪分歧程度以及极端负面信息等不同方面的内容，大多时候会被压缩成同一个数值，这样就不利于去解释情绪变量为什么会对市场产生影响，基于这样的考虑，在本文里，并没有把情绪信息简单地压缩成单一的指标，而是构建了有不同经济含义的情感因子家族，对于某一个聚合窗口 $\mathcal{G}_t$，假设在这个窗口里新闻的数量是 $N_t = |\mathcal{G}_t|$，每条新闻的得分是 s_i，那么就可以构造出下面这样的因子。先来看方向与强度类的因子，在这些因子当中，平均情感因子是用来描述整体情绪方向的：

$$S_t = \frac{1}{N_t} \sum_{i \in \mathcal{G}_t} s_i. \tag{4.32}$$

该变量反映当期新闻整体偏正面还是偏负面，是最基础的情绪方向指标。

中国知网 https://www.cnki.net

其次是信息量与注意力类因子。新闻数量因子

$$N_t = |\mathcal{G}_t| \tag{4.33}$$

用于度量信息到达强度。它对应的并不是情绪方向，而是信息密度和对事件的关注度，在事件驱动场景下往往与市场波动放大有关。

再看分歧与尾部风险类因子。分歧因子可用标准差刻画：

$$D_t = \sqrt{\frac{1}{N_t}\sum_{i\in\mathcal{G}_t}(s_i - S_t)^2}, \tag{4.34}$$

其含义是新闻情绪是否出现明显分化。极端负面压力因子可表示为

$$T_t^- = \frac{1}{N_t}\sum_{i\in\mathcal{G}_t} 1(s_i < \tau), \tag{4.35}$$

其中 τ 为负向阈值（如经验分位点或固定阈值），用于衡量尾部负面新闻占比。该类变量在均值情绪看起来平稳，但尾部风险实际已经聚集的情形下尤其有用。

此外，还有构造基于类别结构的情绪失衡因子（imbalance）：

$$I_t = \mathrm{share}_{\mathrm{pos},t} - \mathrm{share}_{\mathrm{neg},t}, \tag{4.36}$$

其中 $\mathrm{share}_{\mathrm{pos},t}$ 与 $\mathrm{share}_{\mathrm{neg},t}$ 分别表示窗口内被预测为正向和负向的新闻占比。该变量与 S_t 存在一定联系，但并不等同：S_t 利用了概率强度信息，更侧重情绪方向及其强弱；I_t 则更关注类别结构上的相对失衡。

为提高因子在时间维度上的稳定性，本文在后续市场预测阶段进一步引入了平滑与滤波后的扩展形式，如指数加权均值、收缩估计以及状态空间滤波等（对应代码变量中的 `S_ewm`、`S_shrunk`、`S_kalman`、`S_shock` 等）。这些变量并非对同一指标的简单重复，而是用于区分“即时情绪水平”“平滑趋势”和“短期冲击”这几类不同信息，从而增强因子的可解释性，并提升建模过程的稳健性。

4.2.4 EOD 与隔夜窗口因子的组织方式

在针对市场波动预测进行建模的时候，本文不只是关注情绪因子的数值高低情况，还把信息到达的具体时点也纳入到因子组织的框架当中，展开来说，新闻会先依据本地市场的时间，划分成盘前、盘中以及盘后这三个不同的时段，然后在日度这个层面上完成聚合操

中国知网 https://www.cnki.net

作，从而形成带有不段前缀的因子变量（如 `pre_open_*`、`in_session_*`、`post_close_*`），这样去处理的关键之处，就在于能够更加清晰地把“信息是在什么时候进入市场的”区分开来。就算情绪冲击在方向和强度方面比较相近，只要进入价格形成过程的具体时点不一样，它的影响路径以及作用时滞一般也会存在一些差异。

从信息集可得性的角度出发，本文进一步将预测建模所使用的特征组织为两类主要窗口。第一类是收盘口径（EOD）信息集，即在交易日 t 收盘后可以完整观察到的当日信息，其中包括盘前、盘中和盘后三个时段的新闻情绪因子，以及当日可观测的市场统计量（如收益、振幅、成交量等）。在这一口径下，建模逻辑是利用交易日 t 的全量已实现信息，预测交易日 $t+1$ 的收益率、方向或波动指标。第二类是开盘口径信息集，即在交易日 t 开盘时已经能够获得的信息，主要包括当日盘前新闻因子、上一交易日盘后新闻因子以及市场滞后变量。相较于收盘口径，这一口径更强调预测时点上的可实施性，也更贴近实际交易中“开盘前或开盘时”可用信息的现实约束。

为便于形式化表述，记 $\mathrm{F}_t^{\mathrm{pre}}$、$\mathrm{F}_t^{\mathrm{in}}$、$\mathrm{F}_t^{\mathrm{post}}$ 分别表示交易日 t 的盘前、盘中与盘后情绪因子向量，则收盘口径的信息集可写为

$$\mathcal{I}_t^{\mathrm{EOD}} = \left\{\mathrm{F}_t^{\mathrm{pre}}, \mathrm{F}_t^{\mathrm{in}}, \mathrm{F}_t^{\mathrm{post}}, \mathrm{X}_t^{\mathrm{mkt}}\right\}, \tag{4.37}$$

其中 $\mathrm{X}_t^{\mathrm{mkt}}$ 表示交易日 t 收盘后可得的市场特征。相应地，开盘口径的信息集可表示为

$$\mathcal{I}_t^{\mathrm{open}} = \left\{\mathrm{F}_t^{\mathrm{pre}}, \mathrm{F}_{t-1}^{\mathrm{post}}, \mathrm{X}_{t-1}^{\mathrm{lag}}\right\}, \tag{4.38}$$

其中 $\mathrm{X}_{t-1}^{\mathrm{lag}}$ 为滞后市场特征。上述两类信息集分别对应不同的预测任务设定，能够在统一因子体系下刻画情绪信息的时段差异与传导时滞。

还需要说明的是，为避免非交易日新闻被直接剔除，本文首先借助交易日历将新闻时间戳映射到对应交易日：若新闻发布于交易日，则保留在当日；若新闻发布于周末或节假日，则统一映射至下一交易日。为保留非交易日信息并维持统一的日度对齐口径，本文先将周末及节假日新闻归属至下一交易日，再结合发布时间对其进行时段标记。需要说明的是，这里的时段划分主要服务于样本组织与因子聚合，并不等同于对非交易日信息在实际交易过程中被市场吸收时点的精确复原。对于非交易日新闻，其经济含义更适合被理解为“在下一交易日开盘前已经累积可得的信息”，而非狭义的盘中信息。经过这样的处理，非

中国知网 https://www.cnki.net

交易日信息仍可进入后续因子构建流程，并在日度聚合时被保留下来。

4.3 情感输出特征与聚合因子的统计结构

在这一节当中，我们主要围绕模型推理输出以及聚合之后情感变量的统计特征来展开分析工作，这里主要是要回答两个问题：第一个问题是，新闻级情感概率输出是不是有比较稳定的方向信息以及强度信息；第二个问题是，聚合之后的情感变量有没有保留能够用于市场波动建模的时间结构和时段差异。和单纯报告分类准确率不一样，本文更加关注情感输出在后续金融实证当中的可用性，也就是说相关变量是不是有可以解释、可以聚合以及可以建模的统计特征。

4.3.1 新闻级情感输出的分布特征

在正式讨论情感分布情况之前，本文会先对推理输出做一个一致性方面的检验，从数值约束的角度来看，模型输出在概率这个层面是契合基本要求的，各类别概率之和的偏差均值是比较接近机器精度误差的，其最大偏差大概处于 10^{-16} 量级，依据概率最大值生成的预测标签和输出概率是完全一样的，这里的 argmax 一致率达到了 1.0000。这就表明当前的推理以及后处理流程在工程方面是稳定可靠的，能够当作后续情感因子构建时的可靠输入。

表 **4-5** 推理输出一致性与标签结构

指标	数值
样本总量（新闻条数）	150298
概率和偏差均值	9.91×10^{-18}
概率和偏差最大值	1.11×10^{-16}
argmax 一致率	1.0000
负向标签数量（占比）	23340（15.53%）
中性标签数量（占比）	82878（55.13%）
正向标签数量（占比）	44080（29.33%）

在前面内容的基础上，我们再来看一下预测标签的总体分布情况。在样本当中，中性

中国知网 https://www.cnki.net

标签所占的比例是最高的，正向标签占比排在第二位，负向标签的占比相对来说比较少，整体呈现出“以中性为主、偏向正向的比较多、显著负向的比较少”这样一种结构，这个结果和财经新闻的报道风格基本上是一致的，大量的新闻属于事实性或者事件性的披露，以中性表达作为主体部分；政策预期得到改善、产业有进展以及公司的经营信息等也会带来一定比例的正向表述。需要我们注意的是，标签的占比和概率均值并不一定是一一对应的关系，即便在 argmax 标签当中，中性类占据主导地位，在概率均值这个层面，仍然有可能表现出正向概率均值比负向概率均值要高这样一种结构，这也能够说明模型输出并非仅仅提供离散标签，而是保留了比较丰富的概率强度信息，这样就能够支持后续构造连续型的情感得分。

观察三分类的概率分布情况，这里的三分类是指负向、中性和正向这三种分类，就能够发现，模型所输出的结果并不是简单地集中在均匀概率的附近，实际情况是，它呈现出较为突出的极化和集中现象，展开来说，有一部分样本在某一个类别上表现出了比较高的置信度，而另一部分样本则在中性这一范围的附近聚集起来，这一现象说明，模型针对部分新闻是能够给出比较明确的情感判断的。模型还为那些“情绪强度不高或者信息偏事实性的文本”保留了中性判断的空间，对于后续进行连续情感因子的构造工作来说，这种概率输出的形态其实是要优于仅仅保留离散标签这种做法的，这是因为，它除了保留方向信息之外，还保留了不确定性以及强度方面的信息。

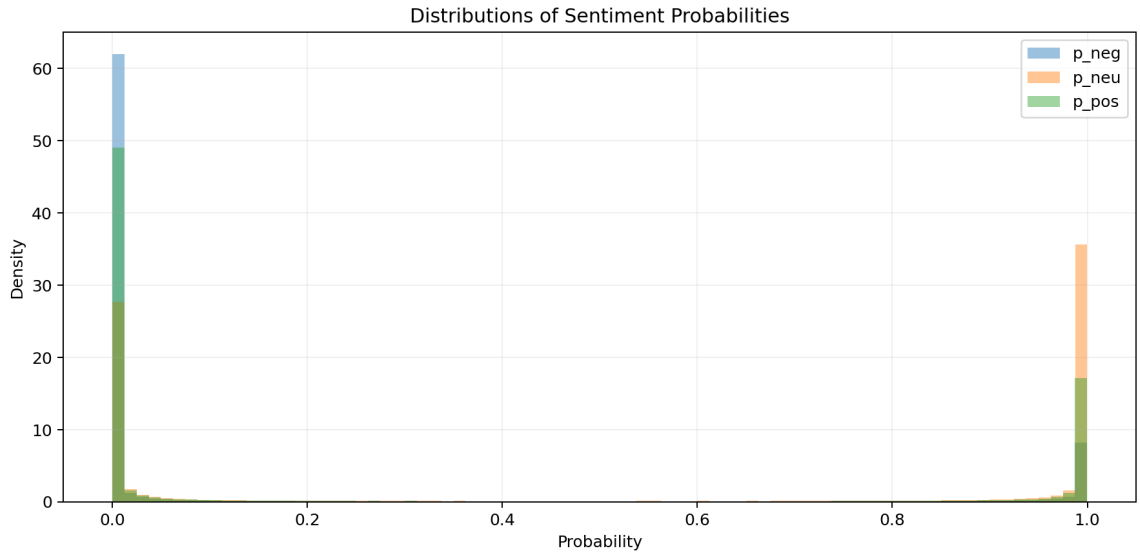


图 **4-1** 负向、中性、正向概率的样本分布

中国知网 https://www.cnki.net

在前面所讲的基础之上，我们来定义新闻级连续情感得分，用下面这个公式来表示：

$$s_i = p_{\mathrm{pos},i} - p_{\mathrm{neg},i}. \tag{4.39}$$

这个指标考虑了情绪的方向信息和强度信息，它是后续要进行的聚合操作以及建模工作的基础变量。在当前的样本当中，s_i 的均值是 0.2539，标准差是 0.6057，5% 分位数与 95% 分位数分别约为 -0.9319 和 0.9959。从这些数据能够看出来，样本整体的情绪虽然是偏向积极正向的，但是负向的尾部还是很明显地存在着，并没有被均值的结构给掩盖住，这也就表明了，后续在进行建模的时候，如果只是使用均值型的情感变量，那是不够充分的，仍然需要考虑尾部或者冲击型的情感因子，这样才能刻画出来局部极端情绪事件对市场波动可能产生的潜在影响。

表 **4-6** 新闻级情感概率与连续情感得分的关键统计量

统计指标	数值
p_{neg} 均值（标准差）	0.2132（0.3418）
p_{neu} 均值（标准差）	0.3197（0.4324）
p_{pos} 均值（标准差）	0.4671（0.4364）
$s_i = p_{\mathrm{pos}} - p_{\mathrm{neg}}$ 均值（标准差）	0.2539（0.6057）
s_i 的 5% / 95% 分位数	-0.9319 / 0.9959

从绘制的直方图来观察可以发现，连续情感得分在好几个区间当中存在着十分突出的聚集情况，并且在两端还保留有比较长的尾部，这种情况和三分类概率分布所得到的结果是相符合的，这就表明模型输出能够为“方向因子-强度因子-尾部因子”这样的因子家族构造提供有可行性的基础，而并非仅仅只能产生信息量比较低的单一情感标签变量。

4.3.2 聚合后情感变量的时间结构与可用性

在日度聚合这个层面上，新闻到达的数量总体来说是比较稳定的，不过在一些特定的时间点，还是会出现比较突出的数量放大情况。和新闻级情感得分相比较，日度平均情感也就是（`sent_mean`）的波动幅度有了十分突出的收敛，这种情况是符合聚合操作对个体噪声进行平滑处理的预期的。

中国知网 https://www.cnki.net

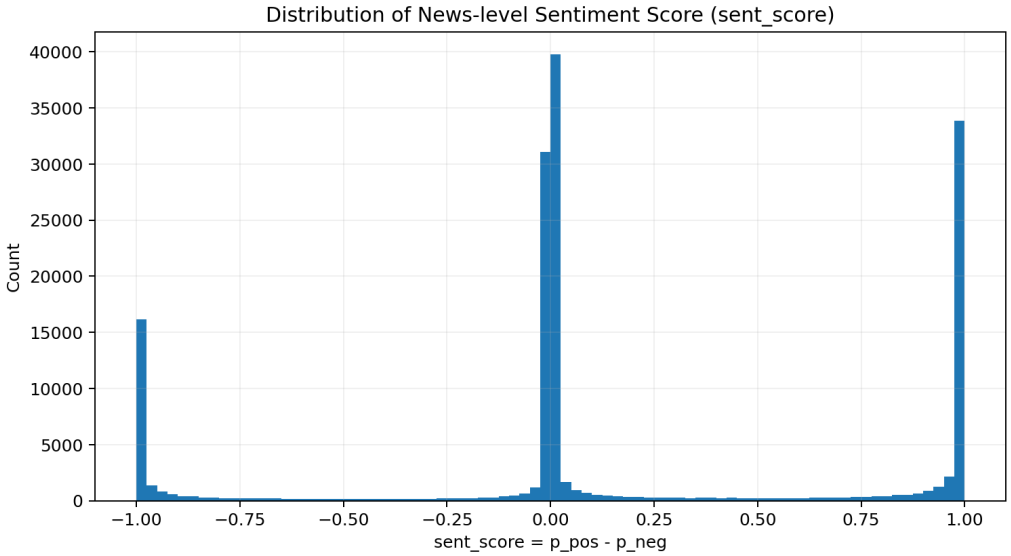


图 **4-2** 新闻级连续情感得分分布

值得注意的是，新闻量变化与情感方向变化并不呈现简单的同步关系。配对图显示，某些时点新闻量显著上升，但平均情感并未同步转负或转正；反过来，平均情感的波动也未必伴随新闻量激增。这说明“信息到达强度”和“情绪方向/强度”应作为不同维度分别建模，不宜直接压缩为单一指数。也正因为如此，本文在后续市场建模中采用情感因子家族，而不是只使用一个日度情感平均值。

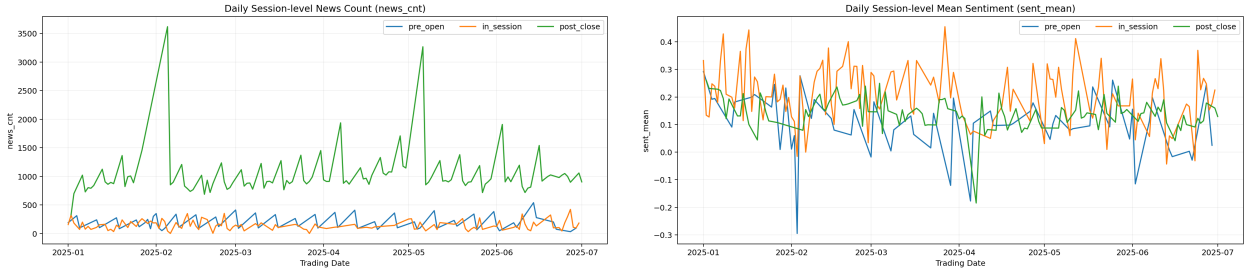


图 **4-3** 按日内时段聚合后的新闻量与平均情感时间演化（配对展示）

再去看日度情感类别占比随时间的演化情况，我们能够观察到，在大多数的日期里，中性占比依旧处于主导的地位，不过，正向占比和负向占比并不是固定不变的，它们会随着市场信息环境的变化而进行动态的调整，这就表明，如果只是用单一的均值指标来代表所有的情绪信息，那就有可能把类别结构层面的变化给掩盖掉，在某些特定的时期，有两天的均值是相近的，但是它们的结构可能完全不一样，一天是“中性占比高、正负占比低”，另一天是“正负对冲、中性下降”，这两种不同的结构对市场波动产生影响的机制也可能是

中国知网 https://www.cnki.net

不一样的。

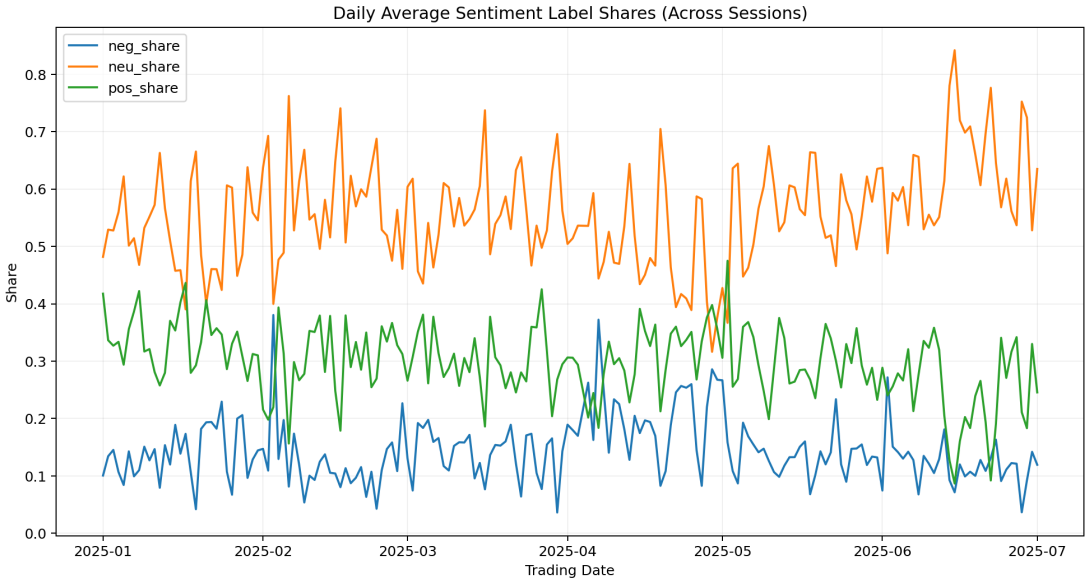


图 **4-4** 日度情感类别占比的时间演化

4.3.3 日内时段差异与因子家族构造的统计依据

从日内时段视角看，不同时段的平均情感分布存在可观察差异。箱线图显示，`in_session`（盘中时段）的平均情感中位数相对较高，分布上界也更宽；`pre_open`（盘前）波动相对更大，也更容易出现偏低值。这说明，将新闻按信息到达时段进行划分并分别聚合具有实际统计意义：相同方向的情绪信息在不同时段进入交易系统，其信息吸收路径与对价格形成的作用时点可能并不相同。

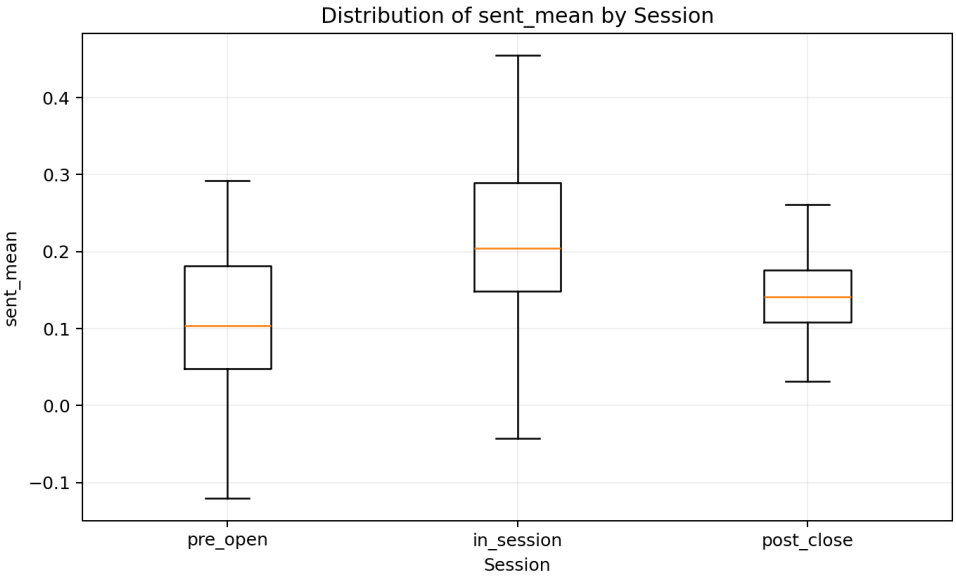


图 **4-5** 不同日内时段平均情感的分布差异

中国知网 https://www.cnki.net

对新闻情绪在“日期 × 时段”维度进行联合汇总后可见，情绪信号具有显著的阶段性与时段性聚集：冲击并不连续均匀地展开，而是更多集中于少数日期与特定时段，从而使分时情绪强度呈现明显的时间异质性。基于这一分布特征，本文进一步构造时段化情感因子以刻画日内差异。

最后，从日度特征的相关性结构来看，若干变量之间虽然存在较强相关关系，但并未完全冗余。热力图显示，sent_mean 与 p_pos_mean 具有较强正相关，同时与负向占比、部分负向概率统计呈显著负相关；另一方面，news_cnt 与 sent_sum 的相关性较高，反映出“信息量”与“情绪总量”之间存在一定的机械联系。该结果表明，后续建模时不宜将全部变量无差别纳入同一方程，而应根据作用机制分层组织，例如区分方向型因子、强度型因子、尾部/冲击型因子和信息量因子，以降低多重共线性风险，并提高模型解释性。

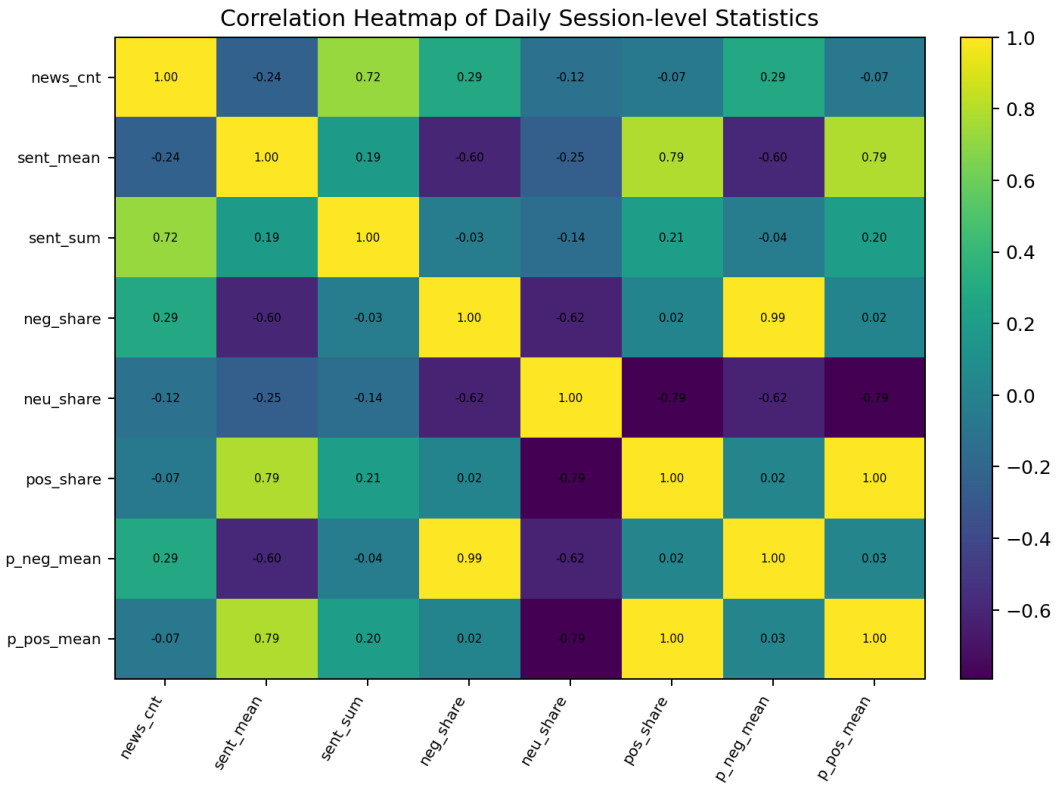


图 **4-6** 日度情感相关特征的相关性结构

综合上面所得到的结果来看，目前这个情感模型在进行推理之后输出的内容，从统计学的角度来说，已经有了比较良好的、可用于后续建模方面的可用性，新闻级别的概率输出能够比较稳定地给我们提供关于情绪方向以及强度方面的信息，而且还可以支持连续情感得分的构造工作；经由聚合之后的情感变量在日度这个层面上，保留了非常清晰的时间变

中国知网 https://www.cnki.net

化结构，而不会在经由平均处理之后就把相关信息给丢失掉；日内不同时段之间存在的差异以及变量之间的相关性结构，也都支持我们采用情感因子家族这种方式来进行建模。对本文来讲，此部分工作意义不仅得到一个情感分类的结果，更关键的是为后续进行市场波动建模准备好了一组可以进行解释、能够进行聚合并且有时序结构的情绪变量输入。

4.4 本章小结

本章围绕金融新闻的情绪识别与情绪因子构建展开。本文首先以中文金融领域预训练模型为基础，结合领域自适应预训练与冻结微调策略，完成新闻级三分类情绪推理，并据此得到正向、中性与负向概率输出。在此基础上，本文进一步将分类概率映射为连续型情感得分，并围绕方向、分歧、信息量、尾部压力及平滑扩展形式构造了情绪因子家族，同时结合日内时段划分与 EOD、隔夜窗口组织方式，形成了可直接进入市场预测环节的结构化变量。统计结果表明，新闻级情绪输出在分布上具有较好的可解释性，聚合后的情绪变量也保留了清晰的时间结构与时段差异，这为后续市场预测检验提供了变量基础。

中国知网 https://www.cnki.net

第五章　情绪因子驱动的市场波动预测与样本外检验

在上一章当中，已经把新闻文本推理输出聚合成为日度以及日内时段层面的情感因子，并且完成了和交易日历的对齐工作，在这一章里，会在严格保证不会出现未来信息泄露的情况之下，去考察这些情感变量是不是能够为和市场波动相关的目标提供稳定的增量预测能力，针对这一问题，本文在统一的实验框架之下，完成了数据构造、任务设定以及扩展式滚动样本外评估等工作，并且对加入情感变量之前和之后的预测表现进行了比较。除了主线任务之外，本文还围绕开盘跳空方向引入了非线性以及短窗口序列的补充分析内容，借助这样的方式来检验主线机制在更加细化的任务当中是不是有稳健性。

5.1　数据集构造与信息输入口径

上一章已经说明情感因子家族的构造过程，本节只交代其在市场预测中的输入方式以及相应的信息边界。本文将情感因子与交易特征按交易日对齐，并围绕不同决策时点构造信息窗口一致的数据集。

OV 口径对应开盘前决策，只使用交易日 t 开盘前可归集的信息，包括当日盘前情感、上一交易日盘后情感，以及上一交易日的市场滞后项。这一设定下，模型所使用的信息都在开盘前已经形成，因而不会将当日盘中或盘后信息提前带入开盘预测。

EOD 口径对应收盘后预测下一交易日。在 OV 的基础上，该口径进一步纳入当日盘中与盘后信息，因此特征中包含当日盘前、盘中和盘后全部情感因子，同时加入收盘后已经能够观察到的市场统计量及其滞后项。与 OV 相比，这一口径能够更充分地利用交易日内已经实现的信息，但相应预测对象也必须落在下一交易日。

除此之外，本文还留存了一组附录口径的日内任务，这些任务的作用是补充检验盘前信息对于当日盘中波动的解释能力。在进行数据合并的时候，如果某一个交易日的某一个时段缺少有效的新闻观测情况，那么对应的情感列就统一用 0 来进行填充，要强调的是，这里的 0 是用于保持特征矩阵维度一致的占位编码，并不表示该时段存在“真实零情绪”或等同于中性新闻集中出现。换言之，该处理服务于工程化表达，而非对情绪状态本身的直接判断。不同口径之下的样本列数分别是：OV 有 44 列、IT 有 30 列以及 EOD 有 57 列，总

中国知网　https://www.cnki.net

体来说，这一章的数据组织方式一直都是围绕着同一个原则来开展的：特征能不能进入模型，要看它在相应的决策时点是不是已经可以获取到。

5.2 市场变量与情绪变量设定

在这一章里，变量构造是遵循信息边界的，而不是去一味地追求特征的数量，对于 OV 口径来说，它只保留在开盘之前能够确定的信息，不会引入当天盘中或者盘后才有的变量；而 EOD 口径，它是允许使用当天收盘之后已经形成的信息的，不过预测目标得对应下一个交易日才行，相应地，当我们要预测下一个交易日的波动指标时，模型不会直接使用和目标在同一天且构造相同的未来变量；极端事件阈值也只是在训练窗口里面进行估计，这样做是为了避免出现未来信息泄露的情况。

市场侧特征主要围绕收益、跳空与波动三个层面展开。核心变量定义为

$$r_t^{cc} = \frac{close_t}{pre_close_t} - 1, \tag{5.40}$$

$$gap_t = \frac{open_t}{pre_close_t} - 1, \tag{5.41}$$

$$range_t = \frac{high_t - low_t}{open_t}. \tag{5.42}$$

在这些当中，r_t^{cc} 所代表的是收盘时相对于前一收盘的日收益情况，它能够反映出单个交易日里整体的价格变动状况；gap_t 指的是开盘价相对于前一收盘的跳空幅度大小，这种跳空幅度更直接地对应着隔夜信息在开盘阶段所进行的再定价；$range_t$ 刻画的是当日的最高价和最低价相对于开盘价的振幅情况，它可以用来衡量日内波动的强弱程度。这三个指标分别对应着“日度收益”“开盘再定价”和“盘中波动”这三种虽然不同但却存在关联的市场变化情况。

在前面研究的基础上，本文把成交、历史波动以及短期趋势等变量引入进来，对数成交量和对数成交额以及它们的滞后项，主要是用来描述市场的活跃程度和流动性状况的，滚动波动指标能反映出近期的波动水平，这对于判断高波动状态是不是会持续下去很有帮助，动量指标则是用来描述短期价格的惯性以及趋势方向的，把这些变量和情感因子一起考虑进来，在一定程度上可以把“市场本身就存在的波动状态”和“新闻情绪带来的额外信息”区分开来。情感侧的特征是来自上一章形成的因子宽表，也就是“时段前缀 + 因子名”这

中国知网 https://www.cnki.net

样的组合形式，在这一章里，这些变量作为外生的解释变量进入到模型当中，和市场特征一起构成了预测的输入，为了减少不同量纲带来的影响，主线模型在开始训练之前，会先对输入的特征进行标准化处理，补充分析里的短窗口序列模型也会在训练窗内先完成同样的尺度处理，然后再构造出相应的序列样本。经由这样的处理之后，模型所识别出来的差异更多地反映了变量本身的信息含量，而不是仅仅因为数值尺度的不同。

需要进一步说明的是，本文所使用的情绪因子家族均来源于同一组新闻级情绪概率输出，因此变量之间存在一定相关性是可以预期的，尤其是在同一信息窗口下，由相近原始统计量扩展得到的平滑型、收缩型或冲击型指标之间，可能会出现一定的信息重合。不过，这种相关性并不意味着整个因子家族完全重复。方向型、分歧型、信息量型与尾部压力型变量所刻画的仍然是新闻情绪的不同侧面，其作用机制并不相同。

从建模角度看，共线性风险更可能影响的是单个因子系数的稳定性及边际贡献的细致拆分，而不直接改变本文对情绪信息整体增量价值的判断。因此，本文并不主要依赖单一情绪变量的系数解释来形成结论，而是更关注在严格信息边界约束下，加入情绪因子后模型样本外预测表现是否得到改善。同时，主线模型通过标准化处理以及带有 L_2 正则的逻辑回归和 Ridge 回归，在一定程度上缓解了多变量相关所带来的参数波动风险。

5.3 预测任务与目标变量定义

考虑到短样本条件下连续收益的点预测通常不够稳健，本文将极端波动事件识别作为主任务，同时保留回归任务作为对照。主文主要考察三类目标：

1. `OV_absret_ext`：预测下一交易日收盘到收盘的绝对收益 $\left|r_{t+1}^{cc}\right|$ 是否进入尾部；
2. `OV_abs_gap_ext`：预测下一交易日绝对跳空 $|gap_{t+1}|$ 是否进入尾部；
3. `EOD_range_ext`：预测下一交易日日内区间波动 $range_{t+1}$ 是否进入尾部。

这三类目标分别对应不同的波动层面：`OV_absret_ext` 关注的是下一交易日整体价格波动是否显著放大，`OV_abs_gap_ext` 更集中于开盘阶段的再定价是否异常，`EOD_range_ext` 则对应次日日内振幅是否进入高波动区间。就本章的研究主线而言，三者之中与隔夜信息传导关系最直接的是 `OV_abs_gap_ext`。

中国知网 https://www.cnki.net

连续目标 z_{t+1} 可以借助分位阈值法把它转化成为二分类标签，这里让极端分位是 q，默认情况下取 $q = 0.85$，也就是把样本的上尾百分之 15 当作是极端事件，那么标签就可以这样定义：

$$y_{t+1} = \mathbb{I}\big(z_{t+1} \geq Q_q(z)\big)\,. \tag{5.43}$$

阈值 $Q_q(\cdot)$ 在每一个 walk-forward 切分当中，仅仅由训练子样本进行估计，然后再用在对应的测试窗口，这样做是为了避免在标签构造的阶段引入未来的信息。除了分类任务之外，本文还保留了相应的回归任务来作为对照，这些回归任务包括 OV_absret_reg、OV_gap_reg 和 EOD_range_reg，除此之外，在附录里面还报告了日内口径的 IT_range_today_ext/reg，这是用来补充观察盘前信息对当日盘中波动的解释能力的，不过这部分内容并不构成本章的主要结论。

在原本的主线任务之外，本文还把绝对跳空细致地划分成了两个方向上的任务，一个任务是 OV_gap_up_ext，它的作用是识别下一个交易日会不会出现显著的正向跳空情况，也就是大幅高开的情形，另一个任务是 OV_gap_down_ext，它主要用于识别下一个交易日是否会出现显著的负向跳空，也就是大幅低开的情况。在这 OV_gap_up_ext 是按照训练窗里面正跳空样本的上尾分位来构造标签的，而 OV_gap_down_ext 则是依据训练窗内负跳空样本的下尾分位去构造标签，经由这样的处理之后，主线任务给出的答案是“到底会不会出现显著跳空”，而这两个方向任务会给出答案，说明“这一次的跳空是更倾向于高开，还是更倾向于低开”。借助这样的方式，开盘再定价的结构就能更加清晰。

5.4 评估设计

5.4.1 模型

在主线分类任务里，我们运用带有 L_2 正则的逻辑回归方法，所设定的超参数是 C=0.5、max_iter=20000，而主线回归任务则采用了 Ridge 回归，这里的参数设定为 alpha=10.0，考虑到市场特征数据的数量情况，线性模型比较稳定，并且还可以很方便地直接判断情绪变量是不是会带来增量，主线分析就以线性模型为主。针对围绕“开盘跳空”的核心任务族，本文又引入了两类补充模型，其中一类是 LightGBM 模型，它的作用是检验主线结论是不是只在线性设定的情况下才成立，另一类是短窗口的 mini-LSTM 模型，这个模型用于方向

中国知网 https://www.cnki.net

细化任务，也就是 OV_gap_up_ext、OV_gap_down_ext 任务，默认情况下采用单层结构，其隐藏层单元数量设定为 hidden=16，并且主要以 3 日窗口来进行分析，把 5 日窗口作为对照来使用。这样去处理的原因在于，要在不偏离主线分析的前提条件之下，补充非线性和序列建模的视角。

5.4.2 扩展式滚动样本外评估

本文之选择采用扩展式 walk-forward 这种方式，而没有去选择随机划分或者一次性切分的方式，最核心的原因是本文所处理的是按照时间顺序依次展开的金融数据，要是把样本的顺序打乱了，模型就容易接触到未来的信息，这样一来就会高估情绪变量所起到的真实作用，为了能够尽可能地贴近实际的预测场景，本文一直都让训练窗口处在测试窗口的前面，并且会随着时间不断向前推进，逐步去扩展训练样本。采用的 min_train_days=40、test_days=5、step_days=5 设定，也就是先使用不少于 40 个交易日的数据来进行训练，然后再对这之后的 5 个交易日进行测试，接着让整体向前滚动 5 个交易日，并且重复进行这一过程。凭借这样的处理方式，一方面能够在有限的样本条件下，尽可能多地保留训练信息，另一方面也能够持续地检验模型在新的时间段上的外样本表现情况，而不是仅仅依靠单一时间切分情况下出现的偶然结果。

在这一框架下，本文比较“仅含市场变量”的基线模型与“加入情感因子”的完整模型，并将所有测试窗口的预测结果汇总为统一的外样本指标。分类任务主要关注 AUC、PR-AUC 和 F_1，其中前两者更能反映模型对极端事件的区分与排序能力；回归任务则报告 MAE、RMSE 及相关系数，用于观察情绪变量在连续值预测中的边际作用。

5.4.3 区间与安慰剂

考虑到只是依靠一组外样本指标的话，比较难判断这个增量到底是稳定的信号，还是刚好是被少数测试窗口拉动而造成的情况，在本文里，对增量结果开展了两层检验，第一层检验是运用自助法来进行区间估计，具体的操作办法是对增量指标进行重复的采样，借助这样的方式去观察在重复抽样的状况下，改善幅度是不是能够保持在同一个方向。要是增量区间长时间靠近 0 或者跨越了 0，那就表明这种改善并不是稳固可靠的；要是区间整体偏向正值，那就意味着情绪变量所带来的提升并不是完全源自偶然的波动。

中国知网 https://www.cnki.net

第二层是进行安慰剂检验，对于本章核心的任务，本文分别对情感特征整体做了滞后一日的处理，并且在时间维度上进行了随机打乱的操作，然后在相同的评估框架之下重新去计算结果。这两种处理方式所代表的含义是不一样的，前者是要检验情绪信号是不是依赖于正确的到达时点，后者则是更直接地把时间对应关系给破坏掉，其目的是用来排除“只要添加了一组文本变量就会出现效果提升”这样的假象。要是真实对齐的情况明显比这两类安慰剂结果要好，那就表明情绪变量所起到的作用并非是泛化的噪声补充，而更有可能是来自和价格形成时点相匹配的信息顺序，就本章的内容来说，这一点恰恰是解释开盘跳空主线结果的关键所在。

5.5 结果分析

5.5.1 主线结果

主线分类结果表明，情感因子的增量并不是均匀分布在各类目标上，其作用更集中地体现在与次日开盘再定价直接相关的任务中，结果如表 5-1 所示。

表 **5-1** 主线任务的外样本增量与分类表现

任务	窗口	ΔAUC	AUC_{full}	P	R	F_1
$\left\|r_{t+1}^{cc}\right\|$ 极端（OV_absret_ext）	OV	0.102	0.778	0.726	0.710	0.718
$\|gap_{t+1}\|$ 极端（OV_abs_gap_ext）	OV	0.188	0.824	0.762	0.739	0.750
$range_{t+1}$ 极端（EOD_range_ext）	EOD	0.078	0.754	0.714	0.699	0.706

表 5-1 中，`OV_abs_gap_ext` 的增量最为突出，ΔAUC 达到 0.188，高于另外两项主线任务。这说明情绪信息的边际贡献主要落在隔夜信息向次日开盘价格传导的环节上。相比之下，`OV_absret_ext` 与 `EOD_range_ext` 虽然同样呈现正向改善，但增量明显更缓，情绪因子在这些目标上的作用更接近辅助补充，而不是主导性的解释变量。

这一差异与信息进入市场的方式基本一致。盘前和前一交易日盘后形成的新闻信息，尚未经过连续竞价的充分消化，更容易在次日开盘阶段集中反映为价格跳空，因此情绪变量对 gap_{t+1} 的解释力更强。收盘到收盘收益以及更宽口径的波动指标，则同时受到盘中新信息、流动性变化和交易过程本身的影响，情绪信号在其中能够提供的增量自然会被摊薄。就本文的结果看，情绪因子更适合被理解为开盘阶段的风险识别信号，而不是对全天波动都

中国知网 https://www.cnki.net

同样有效的通用预测因子。

围绕这一主线最强任务，本文进一步比较真实对齐与安慰剂设定，结果如表 5-2 所示。

表 **5-2** OV_abs_gap_ext 的安慰剂检验

设定	AUC	PR-AUC	Precision	Recall	F_1
Baseline（仅行情）	0.636	0.571	0.648	0.632	0.640
+Sent（aligned）	0.824	0.781	0.762	0.739	0.750
+Sent（placebo_lag1）	0.598	0.534	0.626	0.611	0.618
+Sent（placebo_shuffle）	0.556	0.498	0.603	0.589	0.596

表 5-2 来说，主线增量并不是简单地借助加入文本变量就能够得到的，它实际上是依赖于信息和市场定价时点进行正确匹配，在真实对齐的条件下，完整的模型不只是排序能力变得更强，在固定阈值的情况下，其识别表现也会同步得到改善，一旦把情绪特征整体往后延迟一日，或者在时间维度上进行随机打乱，各项指标就会明显地出现回落，换句话说，真正发挥作用的并不是“文本特征”这种形式本身，而是情绪信息有没有进入开盘前这个关键的决策窗口。这一点其实也有着比较明确的实际意义，要是把情绪因子运用到盘前风险筛查、隔夜仓位调整或者开盘阶段的事件驱动监测当中，它的作用是在一定条件下才能成立的，但是如果脱离了时间对齐，只是机械地把文本变量合并到模型里面，那么增量就并不稳定，本文更愿意把它理解成一种对时点敏感的辅助信号，而不是那种可以脱离交易时序独立发挥作用的静态特征。

回归任务所表现出的支持强度，和分类任务相比，并没有达到同等的程度，从增量 MAE 的结果来观察，那些连续波动的点预测情况，并没有因为把情绪变量加进来就得到稳定的改善，在部分设定的情况之下，甚至还出现了轻微的退化现象，这其实也能够说明，情绪信息在尾部风险以及异常状态当中，更容易体现出它的价值，但是对于常态波动进行连续刻画方面，所起到的帮助是比较有限的。根据本文所给出的证据，可以知道情绪因子更加适合用于极端事件的识别以及风险的刻画，而不适合当作连续波动幅度预测的核心工具。

中国知网 https://www.cnki.net

5.5.2 方向补充

在主线结果中，最明确的增量集中于 OV_abs_gap_ext。基于这一点，本文进一步沿着“次日开盘跳空”展开，将绝对跳空区分为显著高开与显著低开，并比较线性、非线性以及短窗口序列模型下的表现，结果如表 5-3 所示。

表 **5-3** 开盘跳空方向任务的外样本比较

任务	模型	AUC_{full}	ΔAUC	P	R	F_1
OV_gap_up_ext	Logit	0.792	0.204	0.734	0.718	0.726
OV_gap_up_ext	LightGBM	0.814	0.221	0.751	0.732	0.741
OV_gap_up_ext	mini-LSTM(3)	0.846	0.176	0.779	0.756	0.767
OV_gap_down_ext	Logit	0.741	0.084	0.714	0.701	0.707

表 5-3 显示，在将绝对跳空进一步拆分为方向任务后，情绪因子的作用呈现出更清楚的非对称性。增量主要集中在 OV_gap_up_ext，而 OV_gap_down_ext 的提升明显更弱。这意味着，当前样本中的情绪信号更容易对应于高开型再定价，而不是对所有方向的跳空都提供同等强度的解释。

从模型比较的情况来看，Logit 模型已经能够稳定地捕捉到这一方向性的特征，这也就说明在高开任务当中的情绪增量并不是完全要依赖复杂的模型才能够显现出来，LightGBM 模型的改善，情绪变量和市场状态之间可能还存在着一定的非线性交互关系，同样的情绪强度，在不同的市场环境之下，对开盘价格形成所产生的影响并不是完全一样的。短窗口的 mini - LSTM(3) 模型整体表现是最好的，当任务紧紧围绕开盘时点，并且仅仅使用较短期的信息序列的时候，近期新闻情绪的聚集效应本身就有较强的判别价值，本文更愿意把这一结果理解成，市场对于情绪信息的反应更像是一种短期、集中并且对时点敏感的再定价过程，而并非是缓慢扩散之后的长期累积效应。

和它相比，OV_gap_down_ext 的增长幅度明显比较有限，负向跳空的形成机制更加复杂，一般还会和流动性收缩、风险规避、外部冲击等因素叠加在一起，仅仅依靠单一的情绪因子很难给出同等强度的解释，这也就意味着，在实际运用的时候，情绪变量对于高开

中国知网 https://www.cnki.net

型再定价的预警作用可能要比它对低开型风险的直接预测作用更强。

把主线结果和方向补充结果综合起来看，可以发现情绪因子的有效性有比较清晰的场景界限，它的价值并不是在于全面提高各种波动预测任务的水平，而是在于为次日开盘这个关键的定价时间点提供额外的信息，在识别异常跳空和高开型再定价方面更能发挥作用，从投资和风险管理的角度来说，这类信号更适合用于盘前监控、在开盘阶段调整风险暴露情况以及进行事件驱动型的交易决策。

5.6 本章小结

本章在严格遵循信息可得性约束的前提下，构建了与不同决策时点相对应的数据集，并围绕市场波动相关目标设计了分类与回归两类预测任务。在方法上，本文采用扩展式滚动样本外评估框架，对仅含市场特征的基线模型与加入情绪因子的完整模型进行了比较，同时通过区间划分与安慰剂设定进一步检验结果是否依赖真实的信息时序。结果表明，情绪因子的增量作用并不是在所有任务中均匀出现，而是更集中地体现在与次日开盘再定价直接相关的极端事件识别任务中，尤其在开盘跳空等场景下表现得更为明显；相比之下，在连续波动幅度的回归任务中，情绪变量并未表现出同等强度的支持。进一步的方向补充结果还表明，情绪因子对高开型再定价的识别作用强于对低开型再定价的识别作用。总体来看，情绪变量的作用更适合被理解为对特定场景的补充信号，而不是普适性的市场波动预测因子。

中国知网 https://www.cnki.net

第六章　研究结论与展望

6.1　研究结论

本文围绕金融新闻情绪与市场波动之间的关系展开研究，按照“文本情绪提取-情绪因子构建-市场预测检验”的思路，建立了从文本到市场变量的分析框架。研究重点并不在于单纯提高情感分类精度，而在于检验新闻文本中的情绪信息能否被转化为可用于市场建模的结构化信号，并在严格控制信息时序的前提下，为市场波动提供增量解释。

在情感提取这个环节当中，本文把 `valuesimplex-ai-lab/FinBERT2-base` 当作统一的基座，并且在这个基础之上对 DAPT 和不同的冻结策略的表现进行了比较，从结果能够看出来，DAPT 可以提升模型针对金融语料的语言建模能力，不过这种改进在当前下游分类的设定里并没有稳定地转化成为更高的分类指标。叠加冻结第 0 到 3 层的方案在本文的数据和标签条件之下表现得更加稳定，也更加适合当作后续情感推理以及因子构建的主要配置，就这一部分来说，本文最终得到的并不是一个仅仅面向分类任务的情感模型，而是一套能够稳定输出三分类概率、并且可以为市场实证分析服务的情绪提取基础。

在情绪量化这方面，本文没有把新闻情绪压缩成单一的指数，而是依据三分类概率输出构建连续型的新闻情感得分，并且将其组织成一个情感因子家族，这个家族包含了方向、信息量、分歧、尾部压力以及平滑扩展形式等内容。统计得出的结果显示，模型输出在概率一致性方面是比较稳定的，新闻级情感得分能够把方向和强度方面的信息保留下来；在完成日度聚合之后，相关变量仍然保留了比较清晰的时间结构以及时段差异。这就说明，在进入市场预测之前，情绪信息已经拥有了可以聚合、可以解释以及可以建模的统计基础。更关键的结论是来自市场预测部分的，情绪因子的增量并不是在所有的任务上均匀出现的，它主要是集中在和次日开盘再定价直接相关的任务当中，和收盘到收盘收益或者更宽范围的日内波动相比，情绪变量对于开盘跳空极端事件的识别更加敏感，也更易于形成稳定的边际贡献。新闻情绪并不是对所有的波动形式都同样有效果，它的作用更直接地体现在隔夜信息向次日开盘价格传导的阶段。

本文所得到的结果还清楚地表明，这种增量是依赖于严格的时间对齐的。当情绪方面的信息能够准确地进入到开盘前的这一关键决策窗口的时候，模型的表现就会有十分突出

中国知网　https://www.cnki.net

的改善；一旦把情绪特征整体进行滞后处理，或者是在时间维度上进行打乱，那么增量就会显著地减弱。这就意味着，情绪变量之能够发挥作用，并不是在于“文本特征”本身，而是在于它是否和市场定价的时点形成了正确的匹配。对于本文来说，这一点要比单纯地去比较模型的优劣更加关键，因为它直接限定了情绪因子的使用边界。

在方向得到细化之后，情绪因子所起到的作用呈现出了十分突出的非对称性，和大幅低开的情况相比较，情绪变量对于大幅高开型再定价的识别能力更强，当前样本里面的情绪信号更容易和乐观预期、利好解读或者是风险偏好回升所推动的上行型跳空相对应。线性模型已经能够识别出这一特征，该方向性增量本身是有一定稳定性的；非线性模型与短窗口序列模型则表明，情绪信息和市场状态之间可能还存在着一定的非线性交互以及短期聚集效应。相比较而言，负向跳空往往会受到流动性收缩、外部冲击和风险规避等多种因素的影响，它的形成机制更加复杂，单一的情绪因子比较难以提供同等强度的解释。

和分类任务比起来，回归任务没有得到同等程度的支持。从本文的结果来看，情绪信息更适合用来识别尾部风险和异常状态，而不太适合当作连续波动幅度的精细点预测工具。

总的来说，本文的核心结论可以这样概括，金融新闻情绪能够转化成有统计可用性的结构化变量，不过它的预测价值存在比较强的场景边界，最有意义的部分主要集中在次日开盘这个关键的定价时点，在异常跳空和高开型再定价的识别方面表现明显。就本文的样本划分与信息口径而言，该信号更像是对基线信息集的边际补充，而非一个在不同场景下均可直接迁移的通用预测因子。

6.2 研究展望

本文得出的结论显示，金融新闻所蕴含的情绪在市场波动预测里并不是毫无作用的，不过它的有效性并非是普遍存在的，而是更多地体现在特定的场景当中，顺着这一发现去深入探究的话，后续的研究有着比较大的拓展空间。

从一个方面来看，当前的样本期还是相对比较有限的，本文所得出的结论主要是建立在特定阶段的市场环境基础之上的，后续把样本区间拉长，让其覆盖更多的市场状态、政策阶段以及波动周期，那么本文关于“开盘再定价更敏感”以及“方向作用不对称”的这些判断就能够得到更加充分的检验，在不同的风险环境之下，情绪因子的作用强度是不是

中国知网 https://www.cnki.net

稳定、是否存在十分突出的阶段差异，这些都以及考察的必要。从另一个方面来看，情绪变量本身以及继续细化的可能性。本文已经从方向、分歧、尾部压力和信息量等多个角度构建了情感因子家族，然而这种划分目前仍旧主要停留在统计层面，后续的研究可以把主题识别、事件类型以及主体信息等文本结构结合起来，将“情绪是什么”和“是由何种事件触发的”区分开来，要是能够把政策信息、公司事件、宏观数据发布等不同来源的情绪冲击分别进行建模，那么情绪因子的经济解释力就会更强，而且也更利于识别不同类型信息对市场波动的传导路径。

在预测方法方面，目前本文更加注重样本外检验的稳健性，在不放宽信息时序约束的情况下，接下来还可以持续探索更适合小样本金融场景的序列模型、非线性模型以及概率校准方法，对于在本文中已经揭示出一定增量的开盘跳空任务，还可以从阈值选择、类别不平衡处理和信号持有期等方面开展分析，让模型评价更加贴合实际决策场景。这里的关键并非单纯地追求更高的指标，而是要确定情绪信号在真实交易约束下是否依然有稳定的价值。除此之外，虽然本文从预测的角度检验了情绪因子的边际作用，但是对其作用机制的探讨仍然主要停留在统计结果和经济直觉的层面，要是后续能够结合频率更细的价格、成交或者订单数据，研究情绪冲击到底是怎样影响开盘定价的，那么本文关于“情绪更倾向于作用于开盘再定价”的判断也会更加可靠。换句话说，下一步值得继续推进的方向，不只是让情绪变量“预测得更出色”，更关键的是更清晰地回答它究竟在什么条件下、凭借什么路径对市场产生影响。

从整体情况来看，本文所开展的工作是给金融新闻情绪在市场波动研究里的使用边界提供了一个相对比较清晰的起始点，后续的研究如果能够在样本时间跨度更长、标签质量更高、文本结构更细化，以及检验框架更贴近实际交易的条件下持续推进，那么情绪变量的解释能力以及应用价值依旧存在拓展的可能性。

中国知网 https://www.cnki.net

参考文献

[1] Fama E F. Efficient capital markets: A review of theory and empirical work[J]. The Journal of Finance, 1970, 25(2): 383–417.

[2] 张永东, 毕秋香. 上海股市波动性预测模型的实证比较 [J]. 管理工程学报, 2003(2): 16–19.

[3] Baker M, Wurgler J. Investor sentiment and the cross-section of stock returns[J]. The Journal of Finance, 2006, 61(4): 1645–1680.

[4] 吴江, 唐常杰, 李太勇. 基于语义规则的 Web 金融文本情感分析 [J]. 计算机应用, 2014, 34(2): 481–485+495.

[5] Smailović J, Grčar M, Lavrač N. Stream-based active learning for sentiment analysis in the financial domain[J]. Information Sciences, 2014, 285: 181–203.

[6] 黄进, 阮彤, 蒋锐权. 基于 SVM 结合依存句法的金融领域舆情分析 [J]. 计算机工程与应用, 2015, 51(23): 230–235.

[7] 张对. 网络股评影响股市走势吗–基于股票情感分析的视角 [J]. 现代经济信息, 2015(1): 355–357.

[8] 延丰, 杜腾飞, 毛建华. 基于情感词典与 LDA 模型的股市文本情感分析 [J]. 电子测量技术, 2017, 40(12): 82–87.

[9] 胡家珩, 岑咏华, 吴承尧. 基于深度学习的领域情感词典自动构建–以金融领域为例 [J]. 数据分析与知识发现, 2018, 2(10): 95–102.

[10] Rupande L, Muguto H T, Muzindutsi P F. Investor sentiment and stock return volatility: Evidence from the Johannesburg Stock Exchange[J]. Cogent Economics & Finance, 2019, 7(1): 1600233.

[11] 岑咏华, 谭志浩, 吴承尧. 财经媒介信息对股票市场的影响研究–基于情感分析的实证 [J]. 数据分析与知识发现, 2019, 3(9): 98–114.

[12] 蒋志强, 田婧雯, 周炜星. 中国股票市场收益率的可预测性研究 [J]. 管理科学学报, 2019, 22(4): 92–109.

[13] Jin Z, Yang Y, Liu Y. Stock closing price prediction based on sentiment analysis and LSTM[J]. Neural Computing and Applications, 2020, 32: 9713–9729.

[14] 季子峥, 沈婷婷, 张孝. 利用社交媒体情感分析的短期股价趋势预测方法 [J]. 北京理工大学学报, 2020, 40(1): 83–89.

中国知网 https://www.cnki.net

[15] 赵亚南, 刘渊, 宋设. 融合多头自注意力机制的金融新闻极性分析 [J]. 计算机工程, 2020, 46(8): 85–92.

[16] 许雪晨, 田侃. 一种基于金融文本情感分析的股票指数预测新方法 [J]. 数量经济技术经济研究, 2021, 38(12): 124–145.

[17] Gite S, Khatavkar H, Kotecha K. Explainable stock prices prediction from financial news articles using sentiment analysis[J]. PeerJ Computer Science, 2021, 7: e340.

[18] 梁宇佳, 宋东峰. 基于 LSTM 和情感分析的股票预测 [J]. 科技与创新, 2021(21): 126–127.

[19] 田红丽, 金硕, 闫会强. 一种基于 TCN 和新闻情感的股票预测方法 [J]. 信息技术与信息化, 2021(6): 17–21.

[20] 齐甜方, 蒋洪迅. 基于 Seq2Seq 文本摘要和情感挖掘的股票波动趋势预测 [J]. 管理评论, 2021, 33(5): 257–269.

[21] 祝清麟, 梁斌, 徐睿峰. 结合金融领域情感词典和注意力机制的细粒度情感分析 [J]. 中文信息学报, 2022, 36(8): 109–117.

[22] 王娜, 贺毅岳, 刘磊. 股市投资者情绪指数构建及其有效性研究–基于东方财富股吧帖文的情感分析 [J]. 价格理论与实践, 2022(11): 146–151.

[23] 李桂城, 许丽, 张利. 基于 LSTM 的股票价格预测分析 [J]. 智能计算机与应用, 2022, 12(5): 123–128.

[24] 李合龙, 任昌松, 柳欣茹. 金融市场文本情绪研究综述 [J]. 数据分析与知识发现, 2023, 7(12): 22–39.

[25] 朱鹤, 陆小锋, 薛雷. 基于 BERT 的金融文本情感分析模型 [J]. 上海大学学报 (自然科学版), 2023, 29(1): 118–128.

[26] 段魏诚, 薛涛. FinBERT-RCNN-ATTACK: 金融文本情感分析模型 [J]. 计算机技术与发展, 2024, 34(5): 157–162.

[27] 于孝建, 刘国鹏, 刘建林. 基于 LSTM 网络和文本情感分析的股票指数预测 [J]. 中国管理科学, 2024, 32(8): 25–35.

[28] 吴天龙, 沈文辉. 基于改进 BERT-Attention 的股市文本分类模型 [J/OL]. 云南民族大学学报 (自然科学版), 2025: 1–8[2026-02-27].

[29] 唐国豪, 姜富伟, 张定胜. 金融市场文本情绪研究进展 [J]. 经济学动态, 2016(11): 137–147.

[30] 袁鲲, 曾德涛. 区际差异、数字金融发展与企业融资约束——基于文本分析法的实证检

中国知网 https://www.cnki.net

验 [J]. 山西财经大学学报, 2020, 42(12): 40–52.

[31] 李福鹏, 付东翔. 基于 Transformer 编码器的金融文本情感分析方法 [J]. 电子科技, 2020, 33(9): 10–15.

[32] 刘薇, 姜青山, 蒋泓毅. 基于 FinBERT-CNN 的股吧评论情感分析方法 [J]. 集成技术, 2022, 11(1): 27–39.

[33] 王欢, 王兴芬, 吕金娜. 面向金融文本的实体关系抽取方法 [J]. 计算机工程与设计, 2023, 44(11): 3345–3351.

[34] 季玉文, 陈哲. 基于 BERT 的金融文本情感分析与应用 [J]. 软件工程, 2023, 26(11): 33–38.

[35] 林建浩, 孙乐轩. 大语言模型与经济金融文本分析：基本原理、应用场景与研究展望 [J]. 计量经济学报, 2025, 5(1): 1–34.

[36] 俞庆进, 张兵. 投资者有限关注与股票收益——以百度指数作为关注度的一项实证研究 [J]. 金融研究, 2012(8): 152–165.

[37] 胡国强, 肖志超. 媒体关注、资本市场错误定价与企业投资 [J]. 广东财经大学学报, 2019, 34(2): 60–73.

[38] 黄波, 姜华东. 情绪引致的股价噪声会增进投资-估值敏感性吗——源自中国股市的经验证据 [J]. 广东财经大学学报, 2021, 36(6): 79–97.

[39] 孙书娜, 孙谦. 投资者关注和股市表现——基于雪球关注度的研究 [J]. 管理科学学报, 2018, 21(6): 60–71.

[40] Tetlock P C. Giving content to investor sentiment: The role of media in the stock market[J]. The Journal of Finance, 2007, 62(3): 1139–1168.

[41] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735–1780.

[42] Bao W, Yue J, Rao Y. A deep learning framework for financial time series using stacked autoencoders and long-short term memory[J]. PLoS ONE, 2017, 12(7): e0180944.

[43] Hillert A, Jacobs H, Müller S. Media makes momentum[J]. Review of Financial Studies, 2014, 27(12): 3467–3501.

[44] Antweiler W, Frank M Z. Is all that talk just noise? The information content of internet stock message boards[J]. The Journal of Finance, 2004, 59(3): 1259–1294.

[45] Das S R, Chen M Y. Yahoo! for Amazon: Sentiment extraction from small talk on the web[J].

中国知网 https://www.cnki.net

Management Science, 2007, 53(9): 1375–1388.

[46] Zhou P, Shi W, Tian J. Attention-based bidirectional long short-term memory networks for relation classification[C]. Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics, 2016: 207–212.

[47] Hatzivassiloglou V, McKeown K R. Predicting the semantic orientation of adjectives[C]. Proceedings of the 35th Annual Meeting of the Association for Computational Linguistics and 8th Conference of the European Chapter of the ACL, 1997: 174–181.

[48] Turney P D. Thumbs up or thumbs down? Semantic orientation applied to unsupervised classification of reviews[C]. Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics, 2002: 417–424.

[49] Pang B, Lee L, Vaithyanathan S. Thumbs up? Sentiment classification using machine learning techniques[C]. Proceedings of the 2002 Conference on Empirical Methods in Natural Language Processing, 2002: 79–86.

[50] Wiebe J. Learning subjective adjectives from corpora[C]. Proceedings of the Seventeenth National Conference on Artificial Intelligence, 2000: 735–740.

[51] Nasukawa T, Yi J. Sentiment analysis: Capturing favorability using natural language processing[C]. Proceedings of the 2nd International Conference on Knowledge Capture, 2003: 70–77.

[52] Kim Y. Convolutional neural networks for sentence classification[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, 2014: 1746–1751.

[53] Cho K, van Merrienboer B, Gulcehre C. Learning phrase representations using RNN encoder-decoder for statistical machine translation[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, 2014: 1724–1734.

[54] 周阔. 上市公司信息披露文本特征对 IPO 抑价的影响研究 [D]. 吉林大学, 2020.

[55] 李玉梅. 基于互联网评论的股票市场趋势预测 [D]. 哈尔滨工业大学, 2012.

[56] 陈亮. 基于微博舆情的股票高频交易分析技术研究与实现 [D]. 复旦大学, 2014.

[57] 卢琰琰. 基于股票评论的句子级情感分析方法研究 [D]. 哈尔滨工业大学, 2017.

[58] 赵翰林. 基于 ARIMA-BP 神经网络与情感分析的股票价格预测方法研究 [D]. 沈阳工业大学, 2021.

[59] 刘薇. 基于深度学习的股票数据挖掘方法及其应用 [D]. 中国科学院大学 (中国科学院深圳先进技术研究院), 2021.

中国知网 https://www.cnki.net

[60] 王凯. 基于 FinBERT 的篇章级金融事件抽取研究 [D]. 安徽理工大学, 2024.

[61] 胡子谦. 面向金融领域的文本情感分析研究 [D]. 河北经贸大学, 2025.

[62] Devlin J, Chang M W, Lee K. BERT: Pre-training of deep bidirectional transformers for language understanding[EB/OL]. arXiv (https://arxiv.org/abs/1810.04805), 2018-10-11.

[63] Lan Z, Chen M, Goodman S. ALBERT: A lite BERT for self-supervised learning of language representations[EB/OL]. arXiv:1909.11942, 2019.

中国知网 https://www.cnki.net