学校代码：10270

上海师范大学

硕士学位论文

（学术学位）

投资者情绪及其网络传染与系统性金融风险预警

Investor sentiment, its network contagion, and systemic financial risk early warning

学生姓名：田孜

学　　号：232200527

导师姓名、职称：王周伟　教授

学科专业：应用经济学

研究方向：金融风险

培养单位：商学院

论文提交日期 2026.05.30

中国知网　https://www.cnki.net

摘要

系统性金融风险的精准测度与前瞻性预警是维护金融稳定的关键挑战。传统风险测度方法难以充分刻画风险在复杂网络中的时空传染机制，亦未能有效利用蕴含市场情绪与风险感知的海量文本信息。为此，本研究提出并构建了一个融合大语言模型与时空图神经网络的系统性金融风险预警创新框架。

本研究首先利用大语言模型对 2006-2023 年间的大规模中文财经新闻进行深度语义分析，提取了覆盖 11 个金融行业的日度投资者情绪指标，以此作为反映前瞻性风险感知的“软信息”。其次，结合 GARCH 模型、弹性网络 VAR 与广义方差分解技术，动态构建了行业间时变风险溢出网络，作为刻画风险传染路径的“硬结构”。在此基础上，设计并实现了一个端到端的动态交互时空图神经网络模型，该模型能够同时学习投资者情绪在风险网络上的时空传播规律，并对未来危机状态进行预测。模型输出设计了双信号（安全/风险）与三信号（安全/预警/危机）两种模式，以适应不同监管精度需求。最后，比较并解释了使用不同的大语言模型对预测系统性金融风险的影响。

基于中国金融市场数据的实证结果表明：（1）基于大语言模型构建的投资者情绪指标显著提升了风险预测的准确性，其动态变化对危机事件具有前瞻性指示作用，且预测效果优于传统收益率指标；（2）动态交互时空图神经网络模型能够有效捕捉风险传染的时空耦合特性，在测试集上表现出较高的预测精度与良好的泛化能力，成功预警了新冠疫情等外部冲击；（3）风险溢出网络的结构动态演变显著，核心风险输出行业从早期的信息技术转变为近年的房地产与能源，凸显了动态网络建模的必要性；（4）双信号模型在整体识别率与稳健性上表现更优，而三信号模型则能提供风险演化的阶段信息。（5）不同大语言模型分析的投资者情绪具有显著差异，且都对预测系统性金融风险有着良好效果，但彼此存在效果差异。

关键词：系统性金融风险；时空图神经网络；大语言模型；投资者情绪；风险预警

中国知网 https://www.cnki.net

Abstract

The accurate measurement and forward-looking early warning of systemic financial risks are critical challenges for maintaining financial stability. Traditional risk measurement methods often fail to adequately capture the spatio-temporal contagion mechanisms of risks within complex networks and underutilize the vast amounts of textual information containing market sentiment and risk perceptions. To address this, this study proposes and constructs an innovative framework for systemic financial risk early warning that integrates Large Language Models (LLMs) and Spatio-Temporal Graph Neural Networks (ST-GNNs).

Firstly, this study employs LLMs to conduct deep semantic analysis on a large-scale corpus of Chinese financial news from 2006 to 2023, extracting daily text-based sentiment indicators for 11 financial sectors. These serve as "soft information" reflecting forward-looking risk perceptions. Secondly, by combining GARCH models, Elastic-Net-VAR, and generalized variance decomposition techniques, a dynamic, time-varying risk spillover network among sectors is constructed, serving as the "hard structure" depicting risk contagion pathways. Building upon this, an end-to-end ST-GNN model is designed and implemented. This model can simultaneously learn the spatio-temporal propagation patterns of text sentiment across the risk network and predict future crisis states. The model outputs are designed in two modes: a dual-signal (safe/risk) and a triple-signal (safe/warning/crisis) system, catering to different regulatory precision needs. Finally, the impact of using different large language models on predicting systemic financial risks was compared and explained.

Empirical results based on Chinese financial market data show that: (1) The text sentiment indicators constructed using LLMs significantly improve the accuracy of risk prediction. Their dynamic changes provide forward-looking signals for crisis events, and their predictive performance surpasses that of traditional return-based indicators. (2) The ST-GNN model effectively captures the spatio-temporal coupling characteristics of risk contagion, demonstrating high predictive accuracy and good generalization capability on the test set, successfully providing early warnings for external shocks such as the COVID-19 pandemic. (3) The structure of the risk spillover network exhibits significant dynamic evolution, with the core risk-transmitting sectors shifting from Information Technology in earlier periods to Real Estate and Energy in

中国知网 https://www.cnki.net

recent years, highlighting the necessity of dynamic network modeling. (4) The dual-signal model performs better in overall identification rate and robustness, while the triple-signal model can provide stage-specific information on risk evolution.(5) Investor sentiment analyzed by different large language models exhibits significant differences, and all of them demonstrate good performance in predicting systemic financial risks, albeit with varying degrees of effectiveness.

Keywords: Systemic Financial Risk; Spatio-Temporal Graph Neural Network (ST-GNN); Large Language Model (LLM); Investor Sentiment; Risk Spillover Network; Risk Early Warning

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景.....1
1.2 研究目的与意义.....2
1.2.1 研究目的.....2
1.2.2 研究意义.....3
1.3 研究内容、方法和技术路线.....4
1.3.1 研究内容.....4
1.3.2 研究方法.....5
1.3.3 技术路线.....7
1.4 主要贡献.....7
第 2 章 相关理论与文献综述.....9
2.1 相关理论.....9
2.2 文献综述.....10
2.2.1 系统性金融风险的测度与特征研究综述.....10
2.2.2 图神经网络在金融领域应用的研究综述.....11
2.2.3 文本情绪与大语言模型在金融领域应用的研究综述.....11
2.2.4 文献评述.....12
第 3 章 理论分析与假设.....13
3.1 大语言模型测度投资者情绪的异质性.....13
3.2 投资者情绪预测系统性金融风险的比较优势.....14
3.3 时空图神经网预测系统性金融风险的比较优势.....15
3.4 大语言模型架构与微调影响预测效果的理论分析与研究假设 15
第 4 章 研究设计.....17
4.1 投资者行业情绪的三种大语言模型测度.....18
4.2 时变风险溢出传染网络的弹性网络 VAR 模型估算.....21
4.3 时变风险溢出传染网络的时空图神经网络拟合.....24
4.3.1 图结构定义.....26
4.3.2 时间编码层.....27
4.3.3 空间编码层.....27
4.3.4 图级读出.....28
4.3.5 危机预警分类器.....28
4.3.6 模型训练与优化.....28
4.3.7 预警信号输出效果评价.....29
4.4 系统性金融风险事件设定.....29

中国知网 https://www.cnki.net

4.5 数据收集与预处理.....30
4.5.1 行业文本数据的收集和预处理.....30
4.5.2 风险溢出传染网络及图神经网络模型数据收集.....33
第 5 章 实证研究结果与分析.....34
5.1 日投资者行业情绪指标测分析.....34
5.1.1 行业间情绪差异分析.....36
5.1.2 大语言模型间的情绪测度差异.....37
5.1.3 投资者情绪与市场风险的关联性.....39
5.2 动态风险溢出传染网络的构建结果与分析.....40
5.3 使用投资者情绪的预测效果实证结果与分析.....44
5.3.1 BERT 测度的投资者情绪指标的时空图神经网络预测结果与分析.....45
5.3.2 传统指标预测效果对比.....49
5.4 时空图神经网络拟合传染网络预测效果稳健性检验.....50
5.5 不同大语言模型测度的投资者情绪对系统性金融风险预测结果与效果比较分析.....52
5.5.1 Finbert 测度的投资者情绪指标的时空图神经网络预测结果与分析.....52
5.5.2 Deepseek 测度的投资者情绪指标的时空图神经网络预测结果与分析.....54
5.5.3 大语言模型差异总结.....56
第 6 章 结论与建议.....59
6.1 研究结论.....59
6.2 相关建议.....60
6.3 研究局限与未来展望.....62
参考文献.....63

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景

金融体系的稳定是国家经济安全的核心基石。近年来，全球与中国金融市场经历了多轮剧烈波动与危机考验，从 2008 年国际金融危机的深远冲击，到 2013 年国内银行体系“钱荒”引发的流动性紧张，再到 2015 年股市异常波动所暴露出的高杠杆与传染风险，以及 2020 年新冠疫情对实体经济与金融市场的双重打击，一系列事件凸显了系统性金融风险的巨大破坏力与防范的极端重要性。系统性金融风险并非单个机构风险的简单加总，而是源于金融机构、市场与基础设施之间复杂的网络关联，具有传染性、溢出性和顺周期性。风险的演化是一个动态的时空耦合过程：在时间维度上，风险情绪与市场压力不断积聚、爆发与消退；在空间维度上，冲击通过资产负债表关联、资产价格联动、投资者行为模仿等渠道，在网络节点间非线性地传播与放大。因此，如何精准、前瞻地测度与预警系统性金融风险，识别其时空传播路径与关键节点，成为金融学理论与监管实践面临的重大挑战。

与此同时，我们正步入一个数据驱动与人工智能深度融合的时代。金融市场的运行日益数字化，产生了海量、多源、异构的数据。其中，非结构化的文本数据——如财经新闻、社交媒体舆情、政策公告、公司财报与分析师报告——承载着丰富的市场情绪、政策预期与风险感知信息。传统金融理论基于有效市场假说，往往忽视投资者情绪等非理性因素，而行为金融学的研究表明，情绪是驱动资产价格偏离基本面、加剧市场波动与风险传染的关键力量。然而，传统文本情绪分析方受限于词典的主观构建、对上下文语境的忽视以及对非线性关系的捕捉能力不足，难以从海量、复杂的金融文本中精准提取动态、细粒度的情绪信号。

技术的突破为破解上述难题提供了全新可能。一方面，图神经网络作为深度学习的前沿分支，因其强大的图结构数据建模能力，在社交网络、推荐系统等领域取得了显著成功。其核心优势在于能够显式地刻画实体（如金融机构、行业）之间的关联关系，并学习这种网络结构如何影响信息的传播与特征的演化。这为模拟金融风险在复杂网络中的传染机制提供了理想的技术框架。时空图神经网络进一步将时间序列建模与图结构建模相融合，能够同时捕捉风险的时序动态与空间扩散，是处理金融风险时空演化问题的有力工具。另一方面，以 BERT、GPT 为代表的大语言模型在自然语言处理领域取得了革命性进展。这些模型通过在海量文本上进行预训练，具备了深度的语义理解与上下文推理能力，能够超越简单的

中国知网 https://www.cnki.net

关键词匹配，更精准地识别文本中的情感倾向、风险语义与政策立场。将大语言模型应用于金融文本分析，有望克服传统字典法的局限，构建出更贴合市场现实、更具预测力的情绪指标。

尽管已有研究分别在图神经网络应用于金融风险、以及大语言模型用于文本情绪分析方面取得了进展，但将二者深度结合，构建一个融合大语言模型提取的文本情绪特征与时空图神经网络架构的系统性风险预警模型，仍是一个探索不足的前沿领域。现有研究或侧重于利用图神经网络分析已有的市场关联数据（如收益率相关性），未能充分融入前瞻性的文本情绪信息；或虽使用大语言模型分析情绪，但未将其置于风险传染的网络动态结构中进行时空建模。此外，不同大语言模型在金融文本理解上存在差异，这种差异如何影响最终的风险预测效果，亦有待系统性的实证检验。

基于以上现实需求、理论缺口与技术可能，本研究立足于中国金融市场，旨在构建一个创新的系统性金融风险预警框架。该框架的核心在于：利用大语言模型从大规模财经新闻文本中提取行业级情绪指标，以此作为反映市场前瞻性风险感知的“软信息”；同时，基于高维时变计量模型动态构建行业间风险溢出网络，作为风险传染的“硬结构”；最终，设计并训练一个时空图神经网络模型，将文本情绪与风险溢出网络深度融合，实现对系统性金融风险的动态监测与超前预警。本研究期望通过这一跨学科的探索，不仅在方法论上为金融风险研究提供新的思路与工具，也在实践上为维护金融稳定、防范化解重大风险贡献智慧。

1.2 研究目的与意义

1.2.1 研究目的

本研究的总体目标是构建并验证一个融合时空图神经网络与大语言模型的系统性金融风险预警模型，揭示不同大语言模型对金融风险预测的差异，为后续相关研究的大语言模型的选择提供参考，以提升对金融风险时空传染机制的刻画能力与预警的准确性、前瞻性。为实现这一总体目标，本研究设定了以下具体目的：

第一，构建基于大语言模型的精细化文本情绪指标体系。旨在克服传统字典法的局限，利用大语言模型强大的语义理解能力，对海量中文财经新闻进行深度分析，提取能够反映不同行业市场情绪动态变化的日度情绪指标。该体系不仅关注情绪的整体极性，更致力于捕捉情绪在不同行业间的异质性分布及其随时间演化的复杂模式，为风险预警提供高质量的前瞻性信息输入。

第二，建立动态时变的风险溢出网络模型。旨在准确刻画中国各金融行业之

中国知网 https://www.cnki.net

间风险传染的时空结构。通过结合 GARCH 模型、弹性网络 VAR 模型与预测误差方差分解技术，滚动计算行业间的风险溢出强度，构建一个权重随时间变化的动态有向网络。该网络将作为时空图神经网络的空间拓扑基础，使模型能够显式地学习风险沿特定路径传播的规律。

第三，设计并实现融合投资者情绪与风险网络的时空图神经网络预警模型。旨在创建一个端到端的深度学习框架，该框架能够自动学习文本情绪特征在动态风险网络上的时空传播规律，并据此对特定时期是否会出现危机状态进行预测。模型将包含双信与三信两种输出模式，以适应不同监管精度的需求。

第四，系统评估并比较不同大语言模型特征输入的预测效果。旨在实证检验经过金融领域微调的大语言模型（如 FinBERT）相较于通用大语言模型（如 BERT-base），其提取的文本情绪特征在风险预警任务中是否具有更高的信息含量、预测精度与稳定性。通过严谨的比较分析，为后续研究选择适当的文本分析工具提供经验证据。

1.2.2 研究意义

本研究具有重要的理论意义与实践意义。在理论意义层面，首先，本研究通过将大语言模型这一先进的自然语言处理工具引入金融情绪测度，并将其与复杂的网络风险传染模型相结合，为量化研究“非理性”情绪如何通过结构化网络影响系统性风险提供了新的方法论，丰富了行为金融学的实证研究工具。其次，本研究拓展了复杂网络理论与深度学习在金融风险领域的应用边界。通过设计专门的时空图神经网络架构来刻画金融风险的时空耦合传染，探索了如何将金融学先验知识嵌入到数据驱动的深度学习模型中，促进了网络科学与人工智能方法在金融复杂系统研究中的理论创新。最后，本研究融合了大语言模型与时空图神经网络模型，并揭示了使用不同大语言模型对文本研究乃至金融研究的异质性，提出了必须针对研究课题使用适配的大语言模型的结论。

在实践意义层面，首先，本研究为金融监管部门和宏观审慎政策制定者提供了一种新的、智能化的风险监测工具。所构建的模型能够实现近乎实时的行业级风险扫描与预警，帮助监管者更早识别风险积聚的源头行业与关键传染路径，从而实施更具针对性、前瞻性的逆周期调节与宏观审慎措施，提升风险防范的主动性和有效性。其次，对于金融机构和投资者而言，该模型可以提供超越传统基本面和技术面分析的风险视角。机构可以利用模型的预警信号，优化自身的资产配置、风险限额管理和压力测试方案；投资者则可以将其作为市场情绪和系统性风险状态的参考，辅助投资决策与风险规避。再者，本研究对于政策沟通与市场预期管理具有参考价值。通过对政策文本、市场评论的情绪分析，有助于更精准地

中国知网 https://www.cnki.net

评估政策发布的市场影响与传导效果，为优化政策沟通方式、引导稳定市场预期提供数据支持。最后，本研究所构建的方法论框架具有一定的普适性与可扩展性。经过调整，可应用于其他国家和地区的金融市场风险预警，亦可将节点从行业拓展至单个金融机构，或将文本数据来源扩展至社交媒体、财报电话会议等，为更广泛范围的金融风险智能化管理提供了可行的技术路径。

综上所述，本研究立足于金融稳定的重大现实需求和学术前沿的技术融合点，旨在通过跨学科的方法创新，构建一个更精准、更前瞻的系统性金融风险预警系统。其成果不仅有望在学术上丰富相关领域的理论体系与方法论，更期待在实践中为筑牢金融安全防线、促进金融市场健康发展贡献切实可行的解决方案。

1.3 研究内容、方法和技术路线

1.3.1 研究内容

本研究围绕测度与前瞻预警系统性金融风险”这一核心问题，构建了一个融合大语言模型与时空图神经网络的创新分析框架。研究内容按照逻辑递进关系，从数据信息挖掘、风险结构建模、智能预测方法到实证检验，层层展开，具体包括以下四个层次：

第一，基于大语言模型的文本情绪信息提取。针对传统情绪分析方法依赖词典构建、难以捕捉复杂语义与上下文语境的局限，本研究引入 BERT、FinBERT 及 Deepseek 三类具有代表性的中文大语言模型，对 2006—2023 年间的大规模财经新闻文本进行深度语义分析，构建覆盖 11 个金融行业的日度情绪指标。该指标作为反映市场参与者风险感知的“软信息”，为后续风险预警提供了高质量的前瞻性输入。

第二，动态时变风险溢出网络的构建。为刻画风险在行业间的空间传播路径，本研究结合 GARCH 模型、弹性网络 VAR 与广义预测误差方差分解方法，滚动构建行业间时变有向加权风险溢出网络。该网络不仅反映了风险传染的强度与方向，还揭示了不同时期系统重要性行业的演变特征，为时空图神经网络提供了动态的图结构基础。

第三，融合文本情绪与风险网络的时空图神经网络建模。在情绪指标与风险网络构建的基础上，本研究设计并实现了一个端到端的时空图神经网络模型。该模型将行业情绪特征与宏观经济变量作为节点属性，将风险溢出矩阵作为动态边权重，通过时间编码层与空间编码层的协同学习，捕捉风险在时间与空间维度上的耦合演化规律。模型输出设计了双信号（安全/风险）与三信号（安全/预警/危机）两种预警模式，以适应不同监管精度需求。

中国知网 https://www.cnki.net

第四，系统性风险预警效果的实证检验与对比分析。本研究以中国金融市场为对象，系统检验了所构建模型在 2006—2023 年样本期内的预警性能。通过对比不同大语言模型情绪特征的预测效果、与传统收益率指标的预测能力差异、以及与 Logit、BPNN、SVM 等传统模型的泛化能力，全面验证了文本情绪信息与时空图神经网络在系统性风险预警中的有效性与优越性，以及大语言模型架构对金融研究的异质性，同时，通过分析风险溢出网络的动态演变与情绪指标的时序特征，揭示了中国金融行业风险结构的变化规律与情绪驱动风险传染的内在机制。

1.3.2 研究方法

为系统开展本课题研究，确保研究过程的科学性与结论的可靠性，本研究综合运用多种定量建模方法与前沿人工智能技术，具体包括以下核心方法：

（1）GARCH 模型

本研究首先采用广义自回归条件异方差模型（GARCH 模型）测度各金融行业的尾部风险水平。GARCH 模型能够有效刻画金融时间序列中常见的波动聚集性与条件异方差特征，通过建模收益率的条件方差动态演化过程，捕捉风险随时间的积聚与释放规律。在 95%置信水平下，结合学生 t 分布假设以拟合收益率的厚尾特征，计算得到各行业的在险价值（VaR）序列，作为后续风险溢出网络构建的基础输入变量。

（2）弹性网络 VAR 与广义方差分解

为构建行业间的动态风险溢出网络，本研究结合弹性网络向量自回归模型（Elastic-Net-VAR）与广义预测误差方差分解技术。Elastic-Net-VAR 在传统 VAR 模型基础上引入 L1 与 L2 正则化项，能够有效应对高维变量带来的过拟合问题，同时实现变量选择与系数收缩，提高模型估计的稳健性与解释力。基于估计得到的 VAR 系数矩阵，进一步采用广义预测误差方差分解方法，计算各行业冲击对其他行业预测方差的贡献比例，从而得到有向加权的风险溢出矩阵。通过滚动窗口估计，构建时变的风险溢出网络，刻画风险传染强度与方向随时间的动态演化特征。

（3）时空图神经网络

在风险溢出网络与文本情绪指标的基础上，本研究设计并实现时空图神经网络（ST-GNN）进行危机状态预测。ST-GNN 由时间编码层与空间编码层两部分组成：时间编码层采用门控循环单元（GRU）结构，捕捉各行业节点特征在时间维度上的演化规律，建模风险积聚与消退的时序依赖；空间编码层基于图同构网络（GIN）架构，通过消息传递机制聚合节点自身及其邻居的特征信息，学习风险在行业网络拓扑结构上的传播路径与强度。时空两模块的深度融合，使模型能

中国知网 https://www.cnki.net

够端到端地捕捉风险从情绪积聚、网络传导到最终爆发的完整时空耦合过程。模型输出设计为双信号（安全/风险）与三信号（安全/预警/危机）两种模式，以适应不同监管精度需求。

（4）大语言模型

为从海量非结构化财经新闻文本中提取前瞻性的市场情绪信息，本研究引入大语言模型进行深度语义分析。具体采用三类具有代表性的中文大语言模型：BERT-base-chinese 作为通用判别式基线模型，FinBERT 作为金融领域微调的判别式模型，Deepseek 作为生成式大语言模型。各模型通过对新闻标题与正文进行上下文语义理解，输出每条新闻的情绪极性（积极/消极），进而聚合得到覆盖 11 个金融行业的日度投资者情绪指标。该方法突破了传统字典法依赖主观词库、忽视上下文语境的局限，能够更精准地捕捉文本中的隐含风险信号与市场情绪转向，为风险预警提供高质量的“软信息”输入。

中国知网 https://www.cnki.net

1.3.3 技术路线

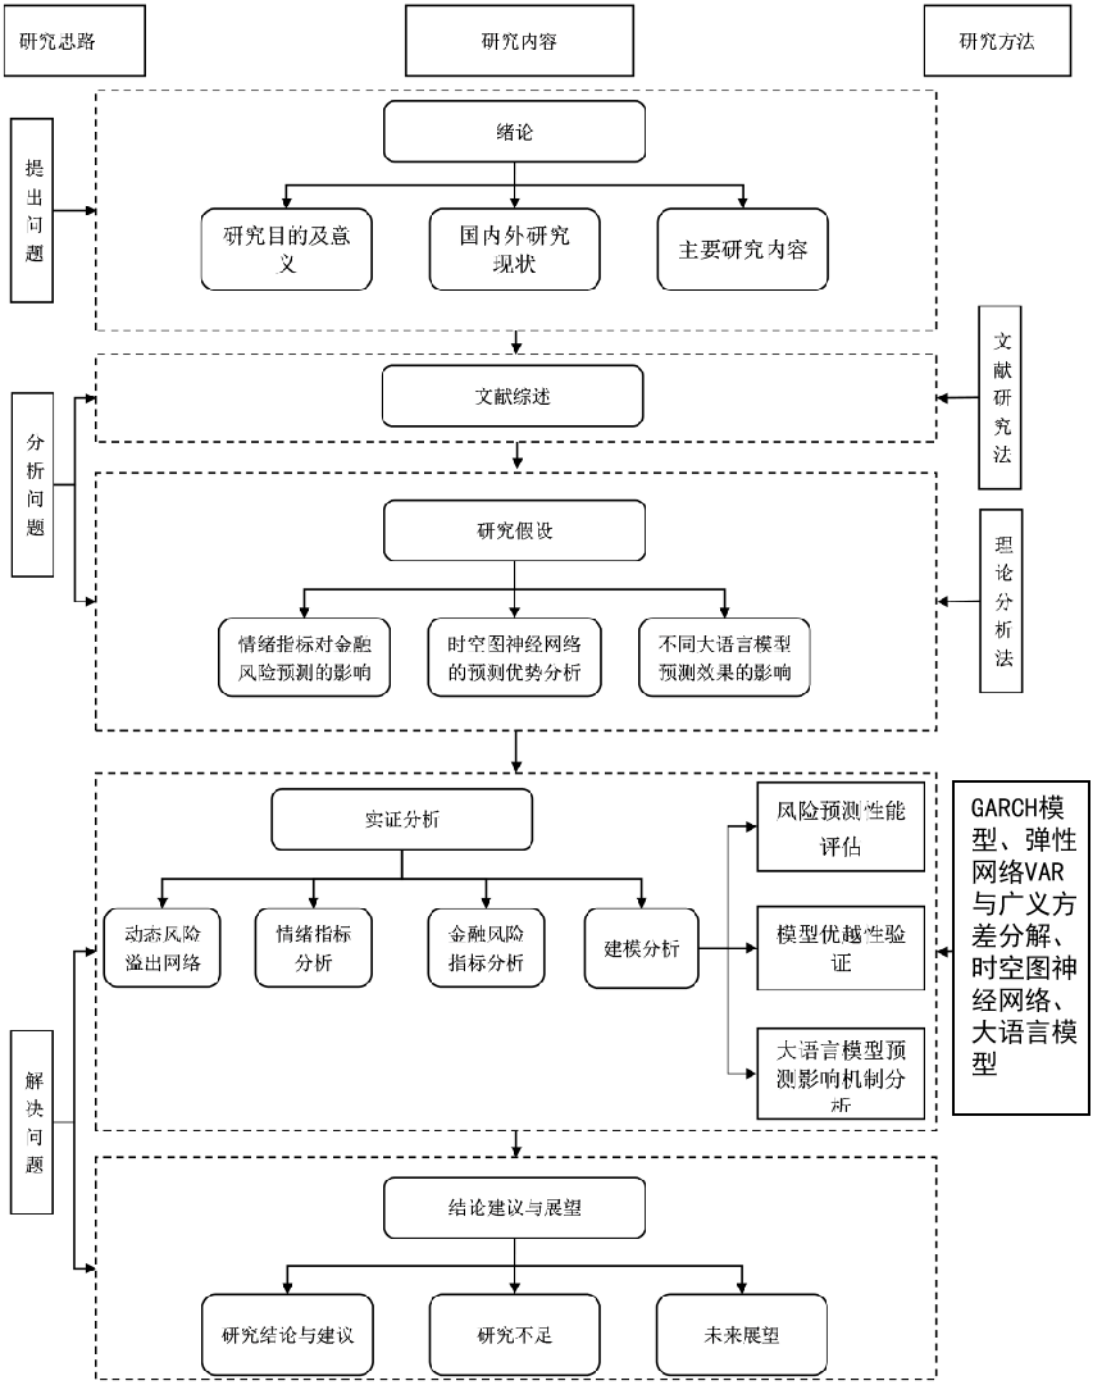


图 1-1 技术路线图

1.4 主要贡献

本研究的主要贡献体现在方法论、理论拓展与实践应用三个层面。

中国知网 https://www.cnki.net

在方法论层面，本研究创造性地构建了一个融合大语言模型与时空图神经网络的系统性金融风险预警框架。具体而言，研究突破了传统文本情绪分析依赖主观构建词典的局限，通过运用经过领域适配的大语言模型，从海量、非结构化的中文财经新闻中自动化、精细化地提取了行业级的动态情绪指标，为风险预测注入了高质量的前瞻性“软信息”。同时，研究超越了仅利用历史关联数据（如收益率相关性）构建静态网络的常规做法，通过滚动时变计量模型动态刻画了行业间风险溢出的“硬结构”，并将其作为图神经网络的空间拓扑基础。最终，通过专门设计的时空图神经网络模型，实现了文本情绪信息在动态风险网络上的时空传播建模，从而能够端到端地捕捉风险从情绪积聚、网络传导到最终爆发的复杂耦合过程。这一完整的方法论链条，为金融风险研究提供了一种全新的、数据驱动的智能化分析范式。

在理论拓展层面，本研究促进了行为金融学、网络科学与计算语言学之间的跨学理论融合。通过实证验证基于大语言模型的文本情绪指标对风险预测的有效性，本研究为“非理性”情绪如何影响并预示系统性风险这一行为金融学核心命题提供了新颖且有力的量化证据。进一步地，通过将这种情绪指标明确嵌入到由时空图神经网络刻画的动态传染结构中，研究初步探索并证实了情绪驱动风险传染的结构化路径与网络动力学机制，深化了对风险“如何”在系统中生成与扩散的理解。此外，研究通过系统比较不同大语言模型生成特征在预测性能上的差异，为评估和选择适用于金融语义理解的自然语言处理工具提供了初步的经验依据与理论思考，推动了相关方法在金融领域的应用深化。

在实践应用层面，本研究开发了一个具备可操作性的智能化风险预警工具，具有重要的现实意义。所构建的模型不仅能实现近乎实时的行业级风险状态扫描，还能提供超前数月的预警信号，为金融监管部门实施前瞻性、精准化的宏观审慎管理提供了重要的决策支持。双信号与三信号模型的设置，适应了不同监管精度与响应速度的需求，增强了工具的实用性。模型对风险溢出网络关键节点与核心传染路径的动态识别能力，有助于监管者锁定风险源头，实施靶向干预。对于市场参与者而言，模型提供的风险视角可作为传统基本面和技术分析的有益补充，辅助进行资产配置调整与风险管理。此外，本研究的整体框架具有良好的可扩展性，经过调整后可应用于不同国家市场、更细分的机构层面，或整合更多元的文本与数据源，为构建更广泛、更智能的金融风险监测生态系统奠定了方法基础。

中国知网 https://www.cnki.net

第 2 章 相关理论与文献综述

2.1 相关理论

系统性金融风险的形成与传导机制可通过多个学科理论进行分析。首先，金融不稳定假说（Minsky，1978）[1]指出，经济的长周期繁荣会内生地推动市场主体的融资行为从稳健的“对冲性融资”转向冒险的“投机性融资”甚至“庞氏融资”，从而使金融体系的内在脆弱性不断累积，最终微小的冲击即可引发资产价格崩溃。与之互补的银行挤兑模型（Diamond & Dybvig，1983）[2]则从信息不对称与期限错配视角揭示了信心丧失如何通过自我实现的预期导致金融机构流动性枯竭。风险一旦生成，便会通过直接关联（如资产负债表业务往来）与间接关联（如资产价格联动）在体系内传导（Taylor，2009）[3]，并经由信贷紧缩机制与流动性螺旋放大冲击（Reinhart & Rogoff，2008）[4]。这些过程在顺周期效应的作用下被进一步强化，即金融体系在经济上行期鼓励冒险，下行期加剧收缩（Borio，2003）[5]。此外，制度环境中的道德风险（Corsetti 等，1999）[6]会刺激金融机构过度承担风险，而旨在应对市场失灵的宏观审慎监管理论（Claessens 等，2013）[7]则强调应从系统整体出发，通过逆周期工具抑制风险累积。

在系统性风险的传播结构上，网络科学提供了关键的分析视角。将金融系统抽象为由节点（如行业、机构）和边（如信用、股权关联）构成的复杂网络，可以揭示风险的传染路径（Elliott 等，2014）[8]。网络中的中心性、社区结构和级联失效等概念，有助于识别具有系统重要性的节点以及风险扩散的关键渠道（Acemoglu 等，2015）[9]。本研究所构建的动态风险溢出网络，正是运用网络科学思想刻画金融行业间风险传染拓扑结构的具体实践。

为对这种高维、非线性的金融网络数据进行建模，深度学习理论，尤其是图神经网络提供了强大的技术支撑。深度学习通过多层非线性变换，能够自动从数据中提取有效特征（Yann L 等，2015）[10]。图神经网络通过消息传递机制，能够聚合节点及其邻居的信息，从而学习嵌入图结构的节点表示（Kipf & Welling，2017）[11]。而时空图神经网络进一步将时间序列分析与图结构建模相结合，使得同时捕捉风险在时间维度上的动态演化与空间维度上的网络传播成为可能。

另一方面，反映市场参与者预期的“软信息”如何被有效提取，则依赖于自然语言处理技术的进步。基于 Transformer 架构的大语言模型，通过在海量文本上进行自监督预训练，能够深刻理解复杂语义与上下文关系（Vaswani 等，2017；Devlin 等，2019）[12][13]。这种能力使其可以超越传统方法的局限，从财经新闻等

中国知网 https://www.cnki.net

文本中精准捕捉市场情绪与风险感知。

最后，行为金融学理论为上述“软信息”如何影响市场提供了微观行为基础。该理论挑战了“理性人”假设，认为投资者情绪与心理是驱动资产价格偏离基本面、引发市场过度波动（Shiller, 2003）[14]和形成资产泡沫的关键因素（Baker & Wurgler，2007）[15]。悲观情绪的蔓延会加剧流动性紧张，放大负面冲击（Barberis 等，2015）[16]，从而深刻影响系统性风险的形成与演化。这为本研究将文本情绪作为风险预警的关键变量提供了坚实的理论依据。

2.2 文献综述

2.2.1 系统性金融风险的测度与特征研究综述

关于系统性金融风险国内外已有很多研究，主要分为系统性金融风险的度量、影响因素以及传播三个方面，其中度量与传播方面有所交叉。度量方面，第一种主要基于股票市场与资产负债表数据反映机构间的系统性金融风险，相关指标有 CoVaR、MES 和 SRISK 等，如 Allen 等（2012）[17]，杨子晖等（2018）[18]利用 VaR、MES、CoVaR 和 ΔCoVaR 测度系统性金融风险，欧阳资生等（2025）[19]使用有偏的广义误差分布、广义帕雷托分布和非参数方法，计算每个季度收益率在 99%置信水平下的 VaR 值，结合主成分分析法构建系统性金融风险的指标；第二种测度方法通过构建风险网络来刻画金融体系中的网络关联，识别系统重要性机构与市场，同时指明风险的传染模式，早期研究主要涉及回报率溢出（Billi 等, 2012）[20]、波动溢出（Diebold and Yilmaz,2014）[21]、尾部风险溢出（Chen 等, 2018）[22]三类网络结构，得到了广泛认可，如宫晓莉等（2020）[23]借鉴 Diebold 等（2014）[21]的研究，使用方差分解网络方法建立信息溢出网络识别系统性金融风险。

随着研究的深入，系统性金融风险网络的高维、时变、空间特征和非线性特征成为了研究的重点，如何德旭等（2021）[24]结合预测误差方差分解法和非线性格兰杰因果检验法构建全球跨市场金融网络，探讨资本市场和货币市场的风险传播；杨子晖等（2023）[25]结合“去一法”、多元非线性 Granger 因果检验等构建系统性金融风险的合成网络；陈少凌等（2021）[26]使用融合了岭回归和 Lasso 算法的 ElasticNet 算法解决高维问题，进而构建了 HD-TVP-VAR 模型；杨科等（2023）[27]使用 TVP-FAVAR 模型刻画各变量间的高维、非线性和时变性特征；王周伟等（2022）[28]利用广义方差分解构建空间权重矩阵，利用两区制空间杜宾模型研究了贸易摩擦对中美银行风险国际传染的区制变化。

中国知网 https://www.cnki.net

2.2.2 图神经网络在金融领域应用的研究综述

近年来，图神经网络因其独特优势在金融风险领域得到了广泛应用，Dawei 等（2021）[29]提出了一种多模态图神经网络模型，通过构建异构图网络来整合不同来源的金融市场信息，以预测金融时间序列的价格走势；Kęstutis 等（2023）[30]基于图神经网络，利用投资者的社会关系网络和交易活动数据来预测不良交易行为；任英华等（2022）[31]结合 Elastic-Net-VAR 模型、门控图神经网络模型和图同构网络模型建立金融危机预警模型。此外，刘雪勇等（2025）[32]基于多头图注意力网络与 t 图神经网络构建风险预警模型，结合 GARCH-VaR 划分风险等级，在沪深港市场验证了其对股市风险的多等级预警效果，而王泽舟等（2025）[33]则提出混频跨期注意力多层图卷积模型，融合供应链、股权与行业网络，利用混频数据提升资产定价性能，在 A 股市场中表现出优异的个股收益预测与投资组合构建能力。

2.2.3 文本情绪与大语言模型在金融领域应用的研究综述

研究因素方面，由于金融市场会受到投资者非理性情绪的严重影响，情绪就成为了金融学术和政策研究的重要话题，如 Bake 和 Wurgler（2007）[34]和 Benhabib 等（2016）[35] 发现投资者情绪不仅能够对资产价格造成影响，还能通过资产价格影响实体经济波动，且彼此间不断复杂交互，而任英华等（2025）[36]结合图神经网络和情绪指标研究行业股指预测。随着时间的深入，越来越多的文献尝试通过字典法从非结构化文本大数据中提取市场情绪信息用于金融研究（姜富伟等（2023）[37]，林建浩等（2021）[38]）。然而，文本字典法是简单的线性方法，难以刻画非线性与非对称的市场情绪动态变化，并受字典设定质量影响较大，还忽略了上下文等其他维度的文本信息。

与此同时，AI 的发展使得金融风险的研究更加深入，学者们开始使用大语言模型研究金融风险。一方面，大语言模型可以用来识别文本所隐含的情绪类别或者政策立场等信息，能够有效捕捉政府宏观金融调控的信息。如 Hansen 和 Kazinnik（2023）[39]使用 Chat GPT 等大语言模型解读美联储在传达货币政策决策时所使用的技术语，旨在精准有效地解读政策信息，优化货币政策的传导路径和效率。另一方面，大量的新闻媒体报道、调查报告以及企业绩效公告已经成为测度经济金融预期表现的重要数据来源，大语言模型为预测宏观经济金融趋势提供了新的方法论，如 Jha 等（2024）[40]借助生成式人工智能分析超过 12 万篇企业电话会议记录构建总体的宏观经济预期指标。针对上述提到过的传统字典法的弊端，国内学者也已开始采用大语言模型处理文本数据，分析文本情绪并用于金融风险

中国知网 https://www.cnki.net

研究，如姜富伟等（2024）[41] 训练了一个更适用于我国金融领域的中文金融大语言模型，并开展金融市场情绪测度和资产价格风险预测。然而，大语言模型文本识别并非百分之百准确，大语言模型的黑箱特性使得人们难以验证模型输出的结果。

2.2.4 文献评述

国内外已有的研究均强调情绪指标对金融风险的影响，并结合大语言模型进行测度，以此刻画非线性与非对称的市场情绪动态变化，但目前的 BERT、GPT 等模型均有着大语言模型共有的缺点和自身的不足，运用单种大语言模型不可避免地会产生偏误。同时，时空图神经网络模型能充分考虑系统性金融风险传染网络的时变、高维和非线性特征，且对于图神经网络模型与大语言模型的结合尚未得到广泛应用。综上，本研究意在基于时空图神经网络模型与多种大语言模型，将使用不同大语言模型测度后的情绪指标纳入时空图神经网络并进行金融风预测，比较使用不同大语言模型的预测效果，为金融风险研究提供方法论。

中国知网 https://www.cnki.net

第 3 章 理论分析与假设

系统性金融风险的生成、积累与传染是一个复杂的动态过程，既受到宏观经济基本面的驱动，也深受市场参与者情绪与预期的影响。传统金融理论难以充分解释非理性行为对风险传播的放大作用，而行为金融学、网络科学以及深度学习理论的发展为理解这一过程提供了新的视角。本章基于第二章所述的多学科理论，系统分析文本情绪、时空图神经网络及大语言模型在系统性金融风险预警中的作用机制，并提出四个可检验的研究假设。

3.1 大语言模型测度投资者情绪的异质性

行为金融学理论指出，投资者情绪是驱动资产价格波动与风险积累的关键非理性因素。然而，如何从海量、非结构化的金融文本中精准、有效地量化这种情绪，是影响其预测效力的核心前提。大语言模型的出现为这一挑战提供了新的技术路径，但不同架构的大语言模型，由于其设计算法、训练目标与参数规模的差异，可能导致其对同一文本语料的情感理解产生显著分歧，从而生成具有不同统计特征与经济含义的情绪指标。

具体而言，当前主流的大语言模型可分为判别式与生成式两大范式。以 BERT 为代表的判别式模型，采用双向 Transformer 编码器结构与掩码语言建模进行预训练。其核心在于通过上下文理解词语的关联概率，输出结果相对保守且平滑，对极端情感的判别较为谨慎。而经过金融领域语料微调的 FinBERT，虽然在整体情绪极性判断上继承了 BERT 的基准框架，但其通过领域自适应，使得模型对金融专业术语、政策表述及隐含风险信号的敏感度得以增强，理论上能更精准地捕捉行业特有的情绪波动。

与此不同，以 Deepseek 为代表的生成式大语言模型，采用自回归架构进行训练，旨在根据上文预测下文，其目标是生成连贯且符合语义逻辑的文本。这种训练范式使得生成式模型在情感表达上往往更为鲜明，对文本中的情感转折与极端词汇具有更高的敏感性，从而导致其提取的情绪指标波动幅度更大、极化特征更显著。

基于上述理论分析，本文提出以下假设：

H1：不同大语言模型因其架构差及领域适配程度，所提取的文本情绪指标在统计分布、波动特征及对风险事件的敏感性上存在显著差异。

中国知网 https://www.cnki.net

3.2 投资者情绪预测系统性金融风险的比较优势

行为金融学理论指出，投资者情绪是影响资产定价、市场波动及风险积累的重要因素（Shiller，2003）[14]。在信息不对称和市场摩擦的现实环境中，投资者并非完全理性，其情绪波动会通过交易行为传导至资产价格，进而影响金融系统的稳定性（Baker & Wurgler，2007）[15]。行为金融学的经典理论进一步阐释了这一传导机制：投资者情绪不仅表现为个体认知偏差，更会通过社会互动形成群体性的“羊群行为”，导致资产价格系统性偏离基本面价值。尤其在危机前夕，市场情绪的集体转向往往先于基本面变化，成为风险积聚的先行信号（Barberis et al.，2015）[16]。

从信息经济学视角审视，市场参与者的情绪本质上是一种关于未来不确定性预期的“软信息”。与基于历史交易数据的“硬信息”（如收益率、波动率）相比，情绪信息能够更及时地反映市场主体的主观判断与前瞻性风险感知。传统金融理论通常假定价格能够充分吸收所有公开信息，但大量实证研究表明，由于信息处理成本、注意力有限以及语义理解的复杂性，文本信息所蕴含的预测性内容无法被市场即时、完全地消化，这为利用情绪信息提升风险预测能力提供了理论空间。

传统金融文本分析方法如字典法虽能提取情绪极性，但其构建依赖主观词库，难以捕捉文本中的复杂语义、上下文依赖及非线性情绪演化。这种局限性源于语言本身的复杂性和金融文本的特殊性：同一词汇在不同语境下可能表达截然相反的情绪（如“通胀担忧”与“通胀受益”），而传统方法难以对此进行有效区分。 大语言模型通过在海量语料上进行预训练，具备深层次语义理解能力，能够从财经新闻、政策公告等非结构化文本中提取更具前瞻性和细粒度的情绪信息（Devlin et al.，2019；姜富伟等，2024）[13][41]。大语言模型的比较优势体现在：其一，其基于 Transformer 架构的自注意力机制能够动态捕捉文本中的长距离依赖关系，准确识别复杂句式中的情感指向；其二，通过大规模预训练，模型内化了丰富的世界知识与金融领域常识，能够理解隐喻、反讽等高级语言现象；其三，经过金融领域语料微调的模型（如 FinBERT）能够更精准地识别金融专业术语和风险信号，实现对行业特定情绪波动的精细化测度(Chen J et al,2026)[42]。最新研究也证实，基于大语言模型的情绪测度在预测市场崩盘风险和指数回报方面显著优于传统方法(Magner N et al,2025)[43]。这种基于深度语义理解的情绪指标，更能反映市场参与者对未来的风险预期，理论上应具有更强的预测能力。

基于上述分析，本文提出以下假设：

H2：基于大语言模型构建的投资者情绪指标相比于传统指标能够显著提升

中国知网 https://www.cnki.net

系统性金融风险的预测准确性。

3.3 时空图神经网预测系统性金融风险的比较优势

系统性金融风险的演化具有典型的时空耦合特性。在空间维度上，风险通过金融机构、市场间的复杂网络进行非线性传染；在时间维度上，风险演化呈现动动态性与记忆性。传统计量模型或机器学习模型在处理此类复杂数据时面临三大局限：难以显式刻画实体间的拓扑结构、对长期时间依赖性和多尺度模式捕捉能力有限、以及对高维非线性关系的建模能力不足。时空图神经网络作为一种新兴的深度学习架构，为解决上述问题提供了理论和技术上的显著优势，其预测优势主要源于其对金融风险传染网络结构的显式建模、对风险时序动态演变的深度捕捉、对高维非线性关系的强大表征能力，以及对多源异构信息特别是文本语义信息的融合潜力。

具体而言，在结构建模方面，ST-GNN 的核心组件图卷积网络源自谱图论与信息传播机制，能够将动态风险溢出网络内化为模型结构的一部分，通过多层卷积模拟风险沿行业网络的多阶传导，直接刻画节点间的连接与依赖关系。在时序处理方面，其时间卷积模块利用空洞卷积等结构，能高效并行地捕获长序列中的多尺度时间模式，克服传统循环神经网络的梯度问题，更有效地识别短期市场波动与长期风险积聚。更重要的是，ST-GNN 通过将图卷积与时序卷积进行深度耦合，形成一个端到端的特征提取器，能够自动学习空间与时间维度交互下的复杂风险演化规律，例如在市场恐慌期，特定网络结构如何加速风险的跨部门扩散。此外，ST-GNN 的框架天然支持多源异构数据的融合，每个节点可同时包含数值型特征和语义型特，使模型能够同时利用历史的统计关联与基于新闻情绪的预期关联，从而增强对风险状态的综合感知与预测能力。

基于以上理论分析，本研究提出以下核心假设检验 ST-GNN 的预测优势：

H3：相较于其他模型（如随机森林模型、普通神经网络模型），ST-GNN 模型在金融危机预测方面有着更高的预测精度。

3.4 大语言模型架构与微调影响预测效果的理论分析与研究假设

大语言模型的架构设计、预训练语料与微调策略直接影响其对金融文本的理

中国知网 https://www.cnki.net

解深度与情绪提取质量。通用大语言模型（如 BERT-base）在广泛通用语料上训练，具备基础的语义理解能力，但对金融领域专业术语、政策表述及隐含风险语义的敏感度可能有限。经过金融领域语料微调的模型（如 FinBERT）则通过领域自适应，其词向量空间和注意力机制更贴近金融语境，从而能够更精准地捕捉文本中的情绪倾向与风险信号（姜富伟等，2024）[41]。此外，以 GPT 系列和 Deepseek 为代表的生成式大语言模型，采用自回归方式建模上下文，其在情感表达的鲜明度和情绪转折的敏感性方面可能与判别式模型（如 BERT）存在差异，进而影响所提取情绪指标的统计特征，如均值水平、波动幅度、对极端事件的响应速度等。这些由模型架构与训练范式差异所导致的情绪指标异质性，可能使得不同模型提取的情绪信息在内容侧重、噪声水平和时效性上各有特点。当将这些情绪特征作为节点属性输入时空图神经网络时，模型所学习的风险传播模式、预警信号的灵敏度以及误报控制能力可能会随之发生变化，从而对最终的金融风险预测效果产生差异性影响。

基于上述分析，本文提出以下假设：

H4：不同大语言模型提取的文本情绪特征对系统性金融风险预测效果存在显著差异。

本节提出的四个假设，将在第 5 章的实证分析中分别予以验证。其中，假设 H1 对应第 5.1 节的情绪指标描述性统计与模型间对比；假设 H2 对应第 5.3 节的情绪指标与传统收益率指标的预测效果比较；假设 H3 对应第 5.4 节的时空图神经网络与传统模型的性能对比；假设 H4 对应第 5.5 节的不同大语言模型预测效果比较。

中国知网 https://www.cnki.net

第 4 章 研究设计

图 4-1 为总体研究技术路线图。第四章的研究设计围绕系统性金融风险预警这一核心目标，构建了一个融合大语言模型与时空图神经网络的端到端建模框架。具体研究思路如下：

首先，基于大语言模型从财经新闻文本中提取行业情绪指标。研究选用 BERT、FinBERT 和 Deepseek 三类模型，对 2006—2023 年间的大规模中文财经新闻进行语义分析，生成覆盖 11 个金融行业的日度文本情绪指标，以此作为反映市场前瞻性风险感知的特征变量。

其次，构建动态时变风险溢出网络。基于行业交易数据，采用 GARCH 模型测算各行业尾部风险，结合弹性网络 VAR 模型与广义预测误差方差分解方法，滚动估计行业间的风险溢出强度，得到随时间变化的、有向加权的风险溢出网络矩阵，以此刻画风险在行业间的传染路径与强度变化。

然后，设计时空图神经网络模型进行风险预警。将行业情绪指标作为节点属性、风险溢出网络作为动态图结构输入模型。模型通过时间编码层（GRU）捕捉节点特征的时序演化规律，通过空间编码层（GIN）聚合邻居节点的风险溢出信息，实现风险在时空两个维度的联合建模。

最后，输出预警信号并进行效果评估。模型设计为双信号（安全/风险）与三信号（安全/预警/危机）两种输出模式，以适应不同监管精度需求。通过准确率、F1 分数、误报率、预警期识别率等多维度指标，系统评估模型的预测性能与泛化能力，并比较不同大语言模型情绪特征对预测效果的影响差异。

中国知网 https://www.cnki.net

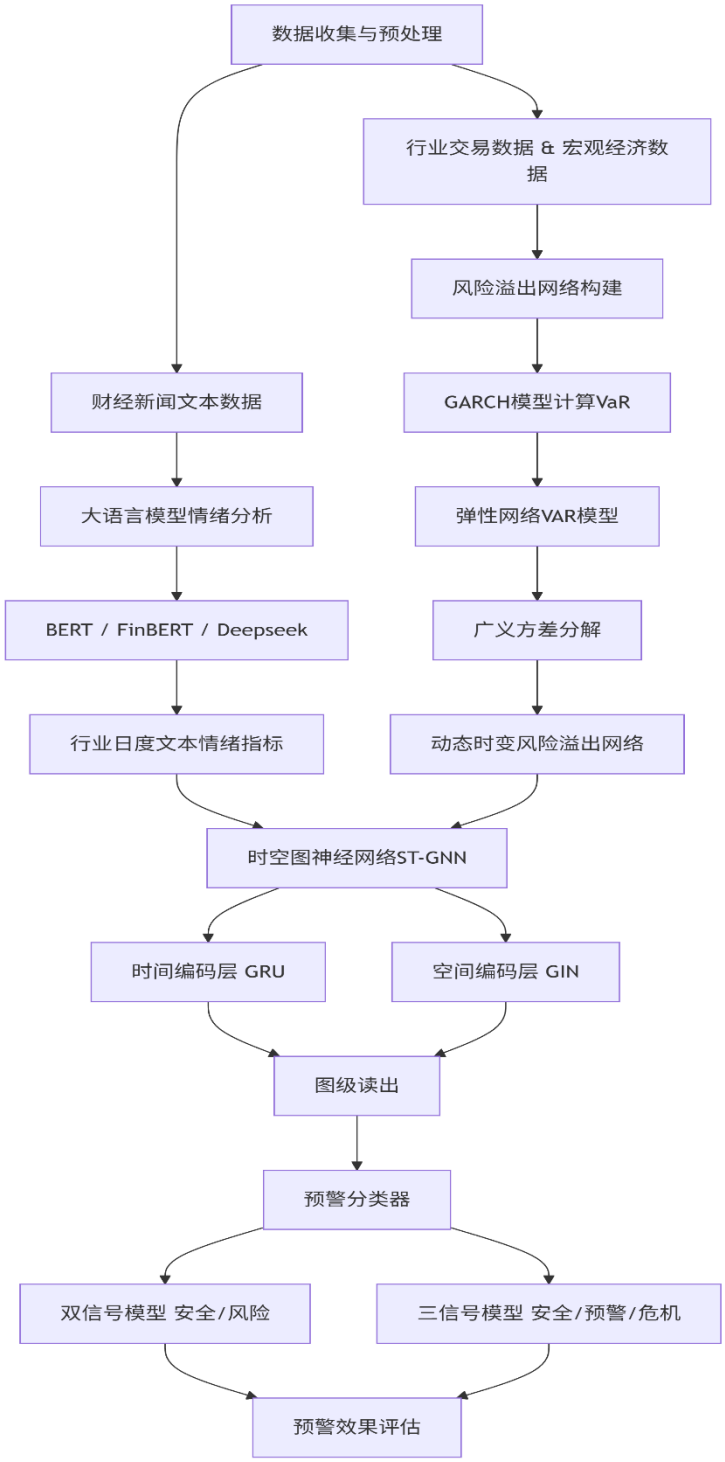


图 4-1 研究设计图

4.1 投资者行业情绪的三种大语言模型测度

为验证假设 H1 与假设 H2，本文在情绪测度方法上选择了三类具有代表性的大语言模型。具体而言，BERT-base-chinese 作为通用判别式基线模型，用以检验

中国知网 https://www.cnki.net

通用语义理解在金融情绪识别中的适用性；FinBERT 作为金融领域微调的判别式模型，用于检验领域适配性对情绪捕捉能力的提升效果；Deepseek 作为生成式大语言模型，用于检验生成式架构在情绪表达鲜明度与风险敏感性方面的独特优势。通过对比三种模型输出的情绪指标在统计特征、动态演化趋势及预测效能上的差异，本研究旨在系统评估大语言模型架构与领域适配程度对金融情绪测度的影响，为验证 H1 与 H2 提供方法支撑。

本文使用的第一种模型为 BERT（Bidirectional Encoder Representations from Transformers）模型，该模型通过双向 Transformer 编码器结构，能够全面理解文本的上下文语义关系，第二种模型是使用金融数据微调后的 BERT 模型(FinBERT)，即借助市场回报来生成含有情绪标签的文本数据，这样做的原因是在金融学研究中，投资者情绪与资产价格之间存在密切关联，情绪往往体现为对资产定价的非理性预期（Benhabib et al., 2016）[35]。此外，可观测的资产价格及收益率是多种机制共同作用下的均衡结果，其中既包含情绪的影响，也受其他因素驱动（Baker & Wurgler, 2007）[34]，因而价格回报中蕴含着情绪相关信息。基于此，采用市场回报作为情绪的表征变量，有助于有效提取隐藏在价格波动中的情绪成分。第三种为深度求索发布的 Deepseek 模型，是国内使用最多的生成式大语言模型之一，具有代表性。对于每条新闻，本文构建分析文本 T_i：

$$T_i = \begin{cases} title_i + content_i & \text{if } content_i \text{存在} \\ title_i & \text{otherwise} \end{cases} \tag{4-1}$$

通过 bert-base-chinese 模型 M_{bert} 对文本 T_i 进行情绪分析：

$$sentiment_i = M_{bert}(T_i) \tag{4-2}$$

其中 $sentiment_i$ 取值为 0 和 1，分别代表消极情绪和积极情绪。对于交易日 t 和行业 k，定义该日行业情绪指标 $S_{t,k}$ 为：

$$S_{t,k} = \frac{\sum_{j=1}^{N_{t,k}} A_j^{lm}}{N_{t,k}} \quad \text{if } N_{t,k} > 0 \tag{4-3}$$

其中：$N_{t,k}$ 为交易日 t 内行业 k 的新闻数量，A_j^{lm} 为第 j 篇新闻通过大语言模型输出的情绪值，对于没有新闻的交易日和行业组，设情绪指标为中性值 0.5：

$$S_{t,k} = 0.5 \quad \text{if } N_{t,k} = 0 \tag{4-4}$$

为得到月度情绪指标 $S_{m,k}$，对月内所有交易日的日度情绪指标取平均值：

$$S_{m,k} = \frac{\sum_{t \in month_m} S_{t,k}}{D_m} \tag{4-5}$$

中国知网 https://www.cnki.net

其中 D_m 为月份 m 的交易天数。为使不同行业的情绪指标具有可比性，本文对情绪指标进行标准化处理：

$$\tilde{S}_{t,k} = \frac{S_{t,k} - \mu_k}{\sigma_k} \tag{4-6}$$

其中 μ_k 和 σ_k 分别为行业 k 情绪指标的历史均值和标准差。具体流程如图 4-2 所示。

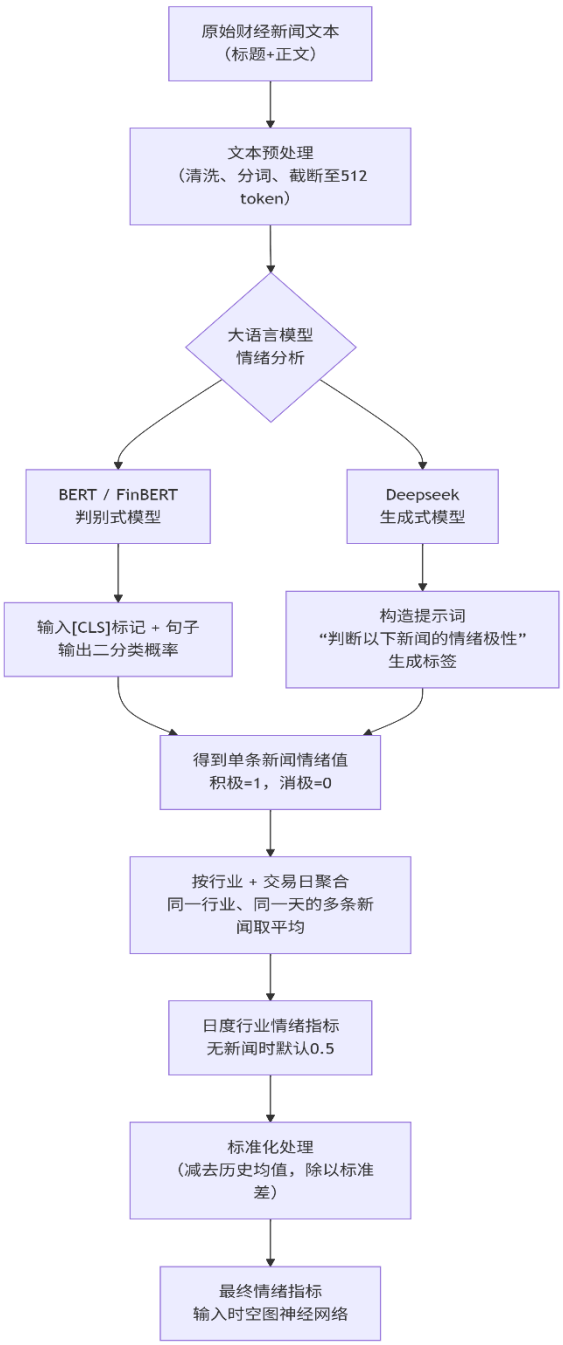


图 4-2 投资者行业情绪构造

中国知网 https://www.cnki.net

4.2 时变风险溢出传染网络的弹性网络 VAR 模型估算

为验证假设 H3 需要首先构建能够真实反映行业间风险传染路径的动态网络结构作为图神经网络的空间拓扑基础。为此，本文采用基于 GARCH 模型的 VaR 测度各行业尾部风险，并进一步结合弹性网络 VAR 模型与广义预测误差方差分解方法构建时变风险溢出网络。该方法能够在高维变量环境下实现变量选择与系数收缩，有效应对金融数据维度高、噪声大的问题，同时通过滚动窗口估计捕捉风险溢出强度的时变特征。所构建的动态有向加权网络不仅为后续时空图神经网络提供了符合金融风险传染机理的图结构输入，也为检验 H3 中关于 ST-GNN 能够显式建模风险空间依赖性的理论预期提供了数据基础。

在金融系统中，各行业并非独立存在，而是通过复杂的关联关系相互影响。当某个行业遭受冲击时，风险会沿着这些关联渠道传播到其他行业，形成风险传染链。本文将金融市场视为复杂网络，其中节点为行业，边即为风险传染路径，权重代表传染强度，参考任英华等（2022）[31]的研究，选取最能反应本主题风险传播的网络构建方式，即基于 GARCH 模型在 95%置信水平下计算得到 VaR，并结合本研究行业数据多维、时变的特点，参考何德旭等（2021）[24]、任英华等（2022）[31]和 Diebold and Yilmaz（2014）[21]的研究，结合 Elastic-Net-VAR 模型、广义方差分解与溢出效应计算，得到时变风险传染网络。具体而言，本文首先计算行业的收益率：

$$r_{i,t} = \ln(\frac{P_{i,t}}{P_{i,t-1}}) \times 100 \tag{4-7}$$

其中 $P_{i,t}$ 为行业 i 在 t 日的收盘价。

基于 GARCH 模型测度行业风险，对于每个行业 i，收益率序列服从以下 GARCH 过程：

$$r_{i,t} = \mu_i + \varepsilon_{i,t} \tag{4-8}$$

$$\varepsilon_{i,t} = \sigma_{i,t} z_{i,t}, \quad z_{i,t} \sim \text{i.i.d.} t(v_i) \tag{4-9}$$

其中条件方差 $\sigma_{i,t}$ 服从 GARCH(p.q)过程：

$$\sigma_{i,t}^2 = \omega_i + \sum_{p=1}^{P_i} \alpha_{i,p} \varepsilon_{i,t-p}^2 + \sum_{q=1}^{Q_i} \beta_{i,q} \sigma_{i,t-q}^2 \tag{4-10}$$

建模过程中，根据 AIC 信息准则在{1，2，3}范围内选择 p、q 的取值，并采用学生 t 分布以更好地捕捉厚尾特征。

中国知网 https://www.cnki.net

$$f(z_t \mid v)=\frac{\Gamma(\frac{v+1}{2})}{\sqrt{v\pi}\Gamma(\frac{v}{2})}(1+\frac{zt^2}{v})^{-\frac{v+1}{2}} \tag{4-11}$$

在置信水平为 95%时计算条件 VaR 为：

$$\mathrm{VaR}_{t|\mathcal{F}_{t-1}}=-\left(\mu+t_v^{-1}(\alpha)\sigma_t\right) \tag{4-12}$$

其中 $t_v^{-1}(\alpha)$ 为学生 t 分布的 α 分位数。为增强稳健性，采用混合 VaR 计算：

$$\mathrm{VaR}_{\text{mixed}}=\lambda\cdot\mathrm{VaR}_{\text{conditional}}+(1-\lambda)\cdot\mathrm{VaR}_{\text{unconditional}} \tag{4-13}$$

权重 λ=0.7，无条件 VaR 基于历史收益率的经验分位数计算。然后，构建 Elastic-Net-VAR 模型，设有 N 个行业的 VaR 序列 ，建立 p 阶 VAR 模型：

$$\mathbf{VaR}_t=\sum_{i=1}^{p}\mathbf{\Phi}_i\mathbf{VaR}_{t-i}+\boldsymbol{\epsilon}_t,\quad \boldsymbol{\epsilon}_t\sim\mathcal{N}(\mathbf{0},\mathbf{\Sigma}) \tag{4-14}$$

为了避免高维 VAR 中的过拟合问题，采用 Elastic Net 估计：

$$\mathbf{\Phi}=\arg\min_{\mathbf{\Phi}}\left\{\frac{1}{2T}\sum_{t=1}^{T}\left\|\mathbf{VaR}_t-\sum_{i=1}^{p}\mathbf{\Phi}_i\mathbf{VaR}_{t-i}\right\|_2^2+\lambda\left(\rho\|\mathbf{\Phi}\|_1+\frac{1-\rho}{2}\|\mathbf{\Phi}\|_2^2\right)\right\} \tag{4-15}$$

其中 λ 为总正则化强度，$\rho\in[0,1]$，表示 L1 与 L2 正则化比例，$\|\cdot\|_1$ 为 L1 范数，$\|\cdot\|_2^2$ 为 L2 范数。之后为了进行广义方差分解和溢出矩阵计算，将 VAR(p)转换为无穷阶移动平均形式：

$$\mathbf{VaR}_t=\sum_{h=0}^{\infty}\mathbf{A}_h\boldsymbol{\epsilon}_{t-h} \tag{4-16}$$

其中，$\mathrm{A}_0=\mathrm{I}_N$，递推关系为：

$$\mathbf{A}_h=\sum_{i=1}^{\min(h,p)}\mathbf{\Phi}_i\mathbf{A}_{h-i} \tag{4-17}$$

行业 j 的冲击对行业 i 的 H 步预测误差方差的贡献比例为：

$$\theta_{ij}^{H}=\frac{\sigma_{jj}^{-1}\sum_{h=0}^{H-1}(\mathbf{e}_i^{\top}\mathbf{A}_h\mathbf{\Sigma}\mathbf{e}_j)^2}{\sum_{h=0}^{H-1}(\mathbf{e}_i^{\top}\mathbf{A}_h\mathbf{\Sigma}\mathbf{A}_h^{\top}\mathbf{e}_i)} \tag{4-18}$$

其中 $\mathbf{e}_i$ 为第 i 个元素为 1 的单位向量，σ_{jj} 为残差协方差矩阵 Σ 的第 j 个对角元素，H 为预测步长，设为 10，即约为两周交易时间，接着标准化溢出矩阵：

中国知网 https://www.cnki.net

$$\tilde{\theta}_{ij,t}^{H}=\frac{\theta_{ij,t}^{H}}{\sum_{j=1}^{N}\theta_{ij,t}^{H}} \tag{4-19}$$

由此构建有向加权邻接矩阵 $D^{H}=[\tilde{\theta}_{ij}^{H}]_{N\times N}$，其中对角线元素为行业自身的贡献，非对角线元素为行业间的风险溢出强度。随后建立滚动窗口机制，具体而言，设定固定窗口长度 W=100 个交易日，从样本起点开始逐日向前滚动：每次使用窗口内数据估计当期风险溢出网络，得到该时点的溢出矩阵与总溢出指数；随后窗口向前移动 1 天，重复上述估计，直至覆盖全样本区间，从而获得日度风险溢出网络的动态演化序列。在时点 t，使用数据$\{\mathbf{VaR}_{t-W+1},\ldots,\mathbf{VaR}_{t}\}$估计网络$\mathbf{D}_{t}^{H}$，并计算总溢出指数：

$$\mathrm{TSI}_{t}=\frac{\sum_{i=1}^{N}\sum_{j=1,j\neq i}^{N}\tilde{\theta}_{ij,t}^{H}}{\sum_{i=1}^{N}\sum_{j=1}^{N}\tilde{\theta}_{ij,t}^{H}}\times 100 \tag{4-20}$$

方向性净溢出，即行业 i 的净溢出为：

$$\mathrm{NS}_{i}(t)=\sum_{j=1,j\neq i}^{N}\tilde{\theta}_{ji,t}^{H}-\sum_{j=1,j\neq i}^{N}\tilde{\theta}_{ij,t}^{H} \tag{4-21}$$

行业 i 对行业 j 的信息净溢出效应：

$$D_{ij,t}^{H}=(\tilde{\theta}_{ij,t}^{H}-\tilde{\theta}_{ji,t}^{H})\times 100 \tag{4-22}$$

行业信息溢入效应：

$$C_{i,t\leftarrow}^{H}=\frac{\sum_{j=1,j\neq i}^{N}\tilde{\theta}_{ij,t}^{H}}{N}\times 100 \tag{4-23}$$

行业信息溢出效应：

$$C_{i,t\rightarrow}^{H}=\frac{\sum_{j=1,j\neq i}^{N}\tilde{\theta}_{ji,t}^{H}}{N}\times 100 \tag{4-24}$$

行业净溢出效应：

$$C_{i,t}^{H}=C_{i,t\rightarrow}^{H}-C_{i,t\leftarrow}^{H} \tag{4-25}$$

总体信息溢出效应：

$$C^{H}=\frac{\sum_{i=1}^{N}\sum_{j=1,j\neq i}^{N}\tilde{\theta}_{ij}^{H}}{N}\times 100 \tag{4-26}$$

中国知网 https://www.cnki.net

4.3 时变风险溢出传染网络的时空图神经网络拟合

为验证假设 H3 与假设 H4，本研究选用时空图神经网络模型。选择该模型主要有以下理由：首先，系统性金融风险的演化具有时空耦合特性，传统计量模型与机器学习方法难以同时建模风险在时间维度上的动态演化与空间维度上的网络传染，而时空图神经网络模型通过时间编码层与空间编码的协同学习，能够端到端地捕捉风险从情绪积聚、网络传导到最终爆发的完整过程。其次，其图结构输入能够将 4.2 节构建的动态风险溢出网络内化为模型的空间依赖关系，使模型显式学习风险沿特定路径传播的规律。最后，时空图神经网络模型的节点特征设计允许将 4.1 节中基于不同大语言模型提取的情绪指标作为输入，从而为检验 H4 中不同情绪特征对预测效果的异质性影响提供了统一的比较框架。本文参考姜富伟等（2024）[41]和任英华等（2022）[31]的研究，采用时空图神经网络架构，融合了时间序列建模和图结构建模，用于捕捉金融危机在行业间的动态传播规律。时空图神经网络模型的边输入为 4.2 中得到的时变风险传染网络，节点属性输入为 4.1 得到的投资者情绪以及相关宏观经济变量，标签输入为根据权威文献和相关金融理论得到的金融风险期，最终的输出为对金融风险的预测标签。时空图神经网络的架构如表 4-1 和图 4-3 所示。

表 4-1 时空图神经网络架构说明

模块	具体设置	应用说明
图结构定义	有向加权图 $G_t = (V, E_t, X_t, A_t)$，节点数 N=11（行业），边权重为风险溢出强度	将行业间动态风险溢出网络作为图结构输入，使模型能够学习风险在行业间的传播路径
节点特征	行业情绪指标（标准化后）+ 行业独热编码+相关宏观经济指标	反映各行业的市场情绪状态与行业属性，为风险预警提供前瞻性信息

中国知网 https://www.cnki.net

边特征	动态邻接矩阵 $A_t \in \mathbb{R}^{N\times N}$，元素为行业间的风险溢出强度	刻画风险在行业间的传染强度与方向，随时间动态变化
时间编码层	门控循环单元（GRU），输入为节点特征序列，输出为时间编码向量	捕捉各行业风险特征的时序演化规律，建模风险积聚与消退的动态过程
空间编码层	图同构网络（GIN），通过消息传递机制聚合邻居节点信息	学习风险在行业网络拓扑结构上的传播路径与强度，实现空间依赖建模
图级读出	求和聚合各节点特征，拼接多层 GIN 输出	将节点级特征聚合为整个金融系统的图级表示，反映系统性风险状态
分类器	双信号：二分类（安全/风险） 三信号：三分类（安全/预警/危机）	适应不同监管精度需求：双信号用于快速筛查，三信号提供风险演化的阶段信息
损失函数	交叉熵损失	优化模型参数，使预测概率分布接近真实标签分布
优化器	Adam 优化器	自适应调整学习率，加速模型收敛，提高训练稳定性
预测窗口	H = 60 个交易日（约 3 个月）	实现前瞻性预警，在危机正式爆发前发出信号
评价指标	准确率、F1 分数、误报率、P1（过早预警比例）、P2（预警期正确预警比例）、P3（危机期正确预警比例）	全面评估模型的预警性能，兼顾整体准确性与分阶段识别能力

中国知网 https://www.cnki.net

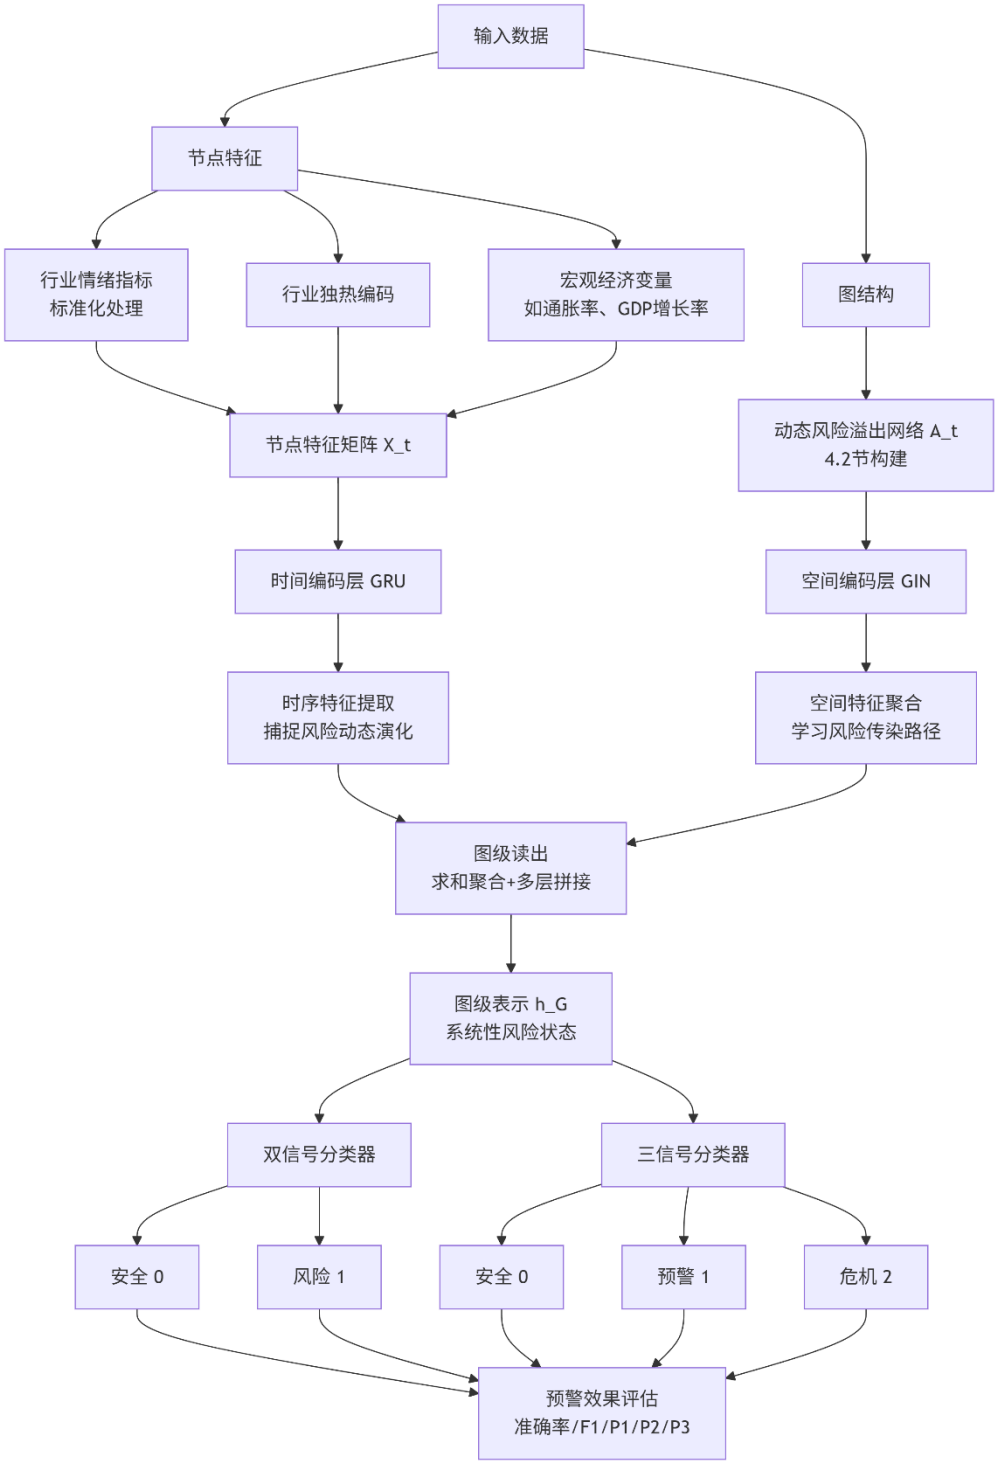


图 4-3 时空图神经网络架构图

4.3.1 图结构定义

对于每个交易日 t，本文定义行业间风险溢出网络为一个带权有向图：

$$G_t = (V, E_t, X_t, A_t) \tag{4-27}$$

中国知网 https://www.cnki.net

其中：$V=\{v_1,v_2,\ldots,v_N\}$，表示 N 个行业节点，E_t 表示交易日 t 的边集合，$X_t\in\mathbb{R}^{N\times d}$，表示节点特征矩阵，d 为特征维度，$A_t\in\mathbb{R}^{N\times N}$ 表示邻接矩阵，元素 $A_t[i,j]$ 表示行业 j 对行业 i 的风险溢出强度。

每个行业节点 v_i 在交易日 t 的特征向量包含两部分：

$$\mathbf{x}_t^{(i)}=[\text{sentiment}_t^{(i)}\oplus\text{one-hot}(i)] \tag{4-28}$$

其中：$\text{sentiment}_t^{(i)}$ 表示行业 i 在交易日 t 的情绪指标（标准化后），$\text{one-hot}(i)$ 为行业 i 的独热编码，$\oplus$ 为向量拼接操作。

对于动态边特征，本文使用每个交易日的风险溢出网络矩阵：

$$A_t[i,j]=\text{RiskSpillover}_t^{(j\to i)} \tag{4-29}$$

其中，$\text{RiskSpillover}_t^{(j\to i)}$ 表示交易日 t 行业 j 对行业 i 的风险溢出强度，通过如式 4-18 所示的广义预测方差分解方法计算得到。

4.3.2 时间编码层

使用门控循环单元（GRU）处理节点特征的时间序列，捕捉节点特征的时间演化规律，对于每个节点 i，输入为式 4-27 的节点特征序列 $\{x_{t-T_S+1}^{(i)},\ldots,x_t^{(i)}\}$，输出为时间编码向量 $\mathbf{h}_t^{(i)}\in\mathbb{R}^{d_h}$。前向 GRU 更新方程：

$$\begin{aligned}\mathbf{z}_t&=\sigma(\mathbf{W}_z\mathbf{x}_t+\mathbf{U}_z\mathbf{h}_{t-1}+\mathbf{b}_z)\\\mathbf{r}_t&=\sigma(\mathbf{W}_r\mathbf{x}_t+\mathbf{U}_r\mathbf{h}_{t-1}+\mathbf{b}_r)\\\mathbf{h}_t&=\tanh(\mathbf{W}_h\mathbf{x}_t+\mathbf{U}_h(\mathbf{r}_t\odot\mathbf{h}_{t-1})+\mathbf{b}_h)\\\mathbf{h}_t&=(1-\mathbf{z}_t)\odot\mathbf{h}_{t-1}+\mathbf{z}_t\odot\mathbf{h}_t\end{aligned} \tag{4-30}$$

其中：$\mathbf{x}_t$ 为时间步 t 的输入，$\mathbf{h}_t$ 为时间步 t 的隐藏状态，σ 为 sigmoid 激活函数，$\odot$ 表示逐元素乘法

对于批量处理，将输入重塑为：

$$\mathbf{X}_{\text{reshaped}}\in\mathbb{R}^{(B\times N)\times T\times d} \tag{4-31}$$

其中，B 为批次大小，N 为节点数，T 为时间序列长度。

4.3.3 空间编码层

采用图同构网络（Graph Isomorphism Network, GIN）聚合邻居信息，理论上具有最强的表达能力：

对于节点 v 在第 k 层的更新表示为：

$$\mathbf{h}_v^{(k)}=\text{MLP}^{(k)}\left((1+\epsilon^{(k)})\cdot\mathbf{h}_v^{(k-1)}+\sum_{u\in\mathcal{N}(v)}\mathbf{h}_u^{(k-1)}\cdot A[v,u]\right) \tag{4-32}$$

中国知网 https://www.cnki.net

其中：$\mathbf{h}_v^{(k)}$ 为节点 v 在第 k 层的特征表示，$\mathcal{N}_{(v)}$ 为节点 v 的邻居集合，$A[v,u]$ 为边 $[v,u]$ 的权重（即风险溢出强度），$\epsilon^{(k)}$ 为可学习参数，MLP 为多层感知机。

4.3.4 图级读出

聚合所有节点特征得到整个图的表示：

$$\mathbf{h}_G = \mathrm{CONCAT}\left(\mathrm{SUM}\left(\{\mathbf{h}_v^{(k)} : v \in G\}\right) \mid k = 0,1,\ldots,K\right) \tag{4-33}$$

其中：SUM 为求和聚合函数，CONCAT 为拼接操作，K 表示 GIN 层数。

4.3.5 危机预警分类器

双信号预警模型（二分类）：

$$\begin{aligned} \mathbf{p}_{\text{binary}} &= \mathrm{softmax}\left(\mathbf{W}_{\text{binary}} \cdot \mathrm{MLP}_{\text{readout}}(\mathbf{h}_G) + \mathbf{b}_{\text{binary}}\right) \\ \hat{S}_t &= \arg\max(\mathbf{p}_{\text{binary}}) \end{aligned} \tag{4-34}$$

其中，$\mathbf{h}_G$ 为图级读出层的输出，$\mathbf{W}_{\text{binary}}$ 为双信号分类权重矩阵，$\mathbf{b}_{\text{binary}}$ 为偏置向量，均为模型可学习参数，softmax 为激活函数，$\hat{S} \in \{0,1\}$，为最终预测标签，0 表示安全信号，1 表示预警信号。

三信号预警模型（三分类）

$$\begin{aligned} \mathbf{p}_{\text{multi}} &= \mathrm{softmax}\left(\mathbf{W}_{\text{multi}} \cdot \mathrm{MLP}_{\text{readout}}(\mathbf{h}_G) + \mathbf{b}_{\text{multi}}\right) \\ \hat{S}_t &= \arg\max(\mathbf{p}_{\text{multi}}) \end{aligned} \tag{4-35}$$

其中 $\hat{S}_t \in \{0,1,2\}$，0 表示安全信号，1 表示一级预警信号，2 表示二级预警信号，其余参数类似于二分类。

4.3.6 模型训练与优化

损失函数采用交叉熵损失函数，对于双信号模型：

$$\mathcal{L}_{\text{binary}} = -\frac{1}{B}\sum_{i=1}^{B}\sum_{c=0}^{1} y_{i,c}\log(p_{i,c}) \tag{4-36}$$

对于三信号模型：

$$\mathcal{L}_{\text{multi}} = -\frac{1}{B}\sum_{i=1}^{B}\sum_{c=0}^{2} y_{i,c}\log(p_{i,c}) \tag{4-37}$$

其中，$y_{i,c}$ 为独热编码的真实标签。

中国知网 https://www.cnki.net

优化算法使用 Adam 优化器：

$$\theta_{t+1} = \theta_t - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \tag{4-38}$$

其中：θ为模型参数，η为学习率，$\hat{m}_t$ 和 $\hat{v}_t$ 为偏差校正后的一阶和二阶矩估计。

4.3.7 预警信号输出效果评价

设当前交易日为 t, 预警模型预测的 t + H 交易日的危机状态为，其中 H = 60（约 3 个月）， Model 为上述的时空图神经网络模型， G_t 为动态图序列：

$$\text{Prediction}_t = \text{Model}(G_{t-T+1}, \ldots, G_t) \to \hat{S}_{t+H} \tag{4-39}$$

$\hat{S}_t$ 为预警信号。预警指标计算如下：

$$\begin{aligned}
P1 &= \frac{1}{|\varepsilon|}\sum_{t\in\varepsilon}\mathbb{I}(\hat{S}_t) \quad \text{（过早预警率）} \\
P2 &= \frac{1}{|\mathcal{P}|}\sum_{t\in\mathcal{P}}\mathbb{I}(\hat{S}_t) \quad \text{（危机前预警率）} \\
P3 &= \frac{1}{|\mathcal{C}|}\sum_{t\in\mathcal{C}}\mathbb{I}(\hat{S}_t) \quad \text{（危机期预警率）} \\
F\text{-Alarm} &= \frac{\text{安全期误报数}}{\text{安全期总数}} \quad \text{（误报率）}
\end{aligned} \tag{4-40}$$

其中ε为过早预警期，$\mathcal{P}$为危机前 3 个月（预警期），$\mathcal{C}$为危机期。

4.4 系统性金融风险事件设定

本研究的核心在于建立有效的金融危机预警模型，而模型训练与评估的准确性高度依赖于对历史危机期的准确定义。本文综合分析了相关经济理论和学界认可的经济危机事件，并借鉴现有权威研究成果与关键金融市场指标的动态特征，将我国近年经历的主要金融与经济危机时期划分如下：

（1）国际金融危机（2007 年 7 月 26 日 - 2009 年 12 月 31 日）

此次危机期的划分主要参考 Fry-McKibbin 等（2014）[44]对全球股票市场趋势的分析，并得到后续国内研究（谢赤等，2020）[45]的沿用。该阶段起源于美国次贷危机的蔓延，对我国出口、资本市场与金融体系造成显著冲击。

（2）银行钱荒事件（2013 年 6 月 7 日 - 2013 年 12 月 31 日）

该时期以 2013 年 6 月 7 日上海银行间同业拆放利率（Shibor）全线大幅上涨为标志，银行体系流动性骤然紧张。该事件虽未演化为全面金融危机，但引发了短期市场恐慌与风险重估，因此将其界定为一段具有预警意义的局部危机期。

中国知网 https://www.cnki.net

（3）股灾事件（2015 年 6 月 15 日－2016 年 12 月 20 日）

该阶段以上证综指在2015年6月中旬后持续暴跌为起点，市场流动性枯竭、杠杆风险集中暴露。参考 Fang 等（2018）[46]与杨子晖等（2018）[18]对“股市动荡时期”的定义，虽然市场指数在 2016 年中逐步企稳，但行业间的风险传递直至 2016 年 12 月下旬才显著回落，故将危机期延至 2016 年 12 月 20 日，以完整覆盖风险传染过程。

（4）新冠疫情冲击（2020 年 2 月 13 日－2020 年 6 月 30 日）

新冠疫情不仅是一场重大外部公共卫生危机，更对我国实体经济与金融市场造成严重短期冲击，因此本研究抛弃其公共卫生事件的属性，选择其带来的金融风险作为研究属性，以国内疫情初步受控、经济社会活动逐步恢复为节点，选取 2020 年 2 月中旬至 6 月底作为危机观察。

此外，理想的预警模型不仅应该准确预测危机期，也应在危机到来前发出警报，因此，本文以危机期前三个月设定为预警期。最终的危机期和预警期划分如表 4-2 所示。同时，本文为了实现危机的预测，构建双信号模型与三信号模型，双信号模型中，危机期与预警期间的预警信号 $\hat{S}_t$ 设为 1，否则设为 0，三信号模型中为了增加精确度，将预警期预警信号设为 1，危机期设为 2，其余时期设为 0。

表 4-2 危机期与预警期设置

危机事件	在我国发生的具体时间段（危机期）	预警期（提前三个月）
国际金融危机	2007 年 7 月 26 日至 2009 年 12 月 31 日	2007 年 4 月 25 日至 2007 年 7 月 25 日
银行钱荒事件	2013 年 6 月 7 日至 2013 年 12 月 31 日	2013 年 3 月 6 日至 2013 年 6 月 6 日
股灾事件	2015 年 6 月 15 日至 2016 年 12 月 20 日	2015 年 3 月 14 日至 2015 年 6 月 14 日
新冠疫情	2020 年 2 月 13 日至 2020 年 6 月 30 日	2019 年 11 月 12 日 2020 年 2 月 12 日

4.5 数据收集与预处理

4.5.1 行业文本数据的收集和预处理

本研究以国内媒体如“新浪财经”、“东方财富网”、“央视财经”等覆盖 11 个行业的新闻媒体为目标，爬取上述媒体的官网和微博内容作新闻数据集，日期范围为 2006-2023 年，获取的财经新闻均为标准的正式新闻，包含标题、正

中国知网 https://www.cnki.net

文、作者、报到时间等内容，按照年份分开保存。第一阶段预处理为文本筛选，首先对收集到的各年份文件进行完整性检验，确保上述必需的字存在，防止后续处理中的空值异常；其次实行基于信息量阈值的筛选策略，即删除标题或正文长度小于 5 个字符的新闻条，确保保留具有足够语义内容的新闻，避免噪声数据对后续分析的干扰；接下来剔除重复数据，采用多维度相似性检测方法，分为标题完全匹配检测、内容摘要相似性检测（提取前 100 字符作为摘要），基于组合键（标题+内容摘要）的精确去重三方面，有效避免了因新闻转载或重复发布导致的数据偏；而后过滤对本研究没有价值的新闻，如学术通知类、节日贺词类、行政通知类等，构建结合标题与关键词和日期范围模式的双重验证机制，并实现基于内容结构的启发式判断：对前 500 字符进行模式扫描，识别典型回顾性文体特征，最终显著提升了数据集的信息密度和金融相关性，为后续情绪分析和风险预测提供高质量输入。

第二阶段为文本清洗，包括移除 HTML 标签、URL 链接、电子邮件地址等非文本元素，统一去除数字内容，聚焦于文本语义特征，规范化空白字符，确保分词准确性等内容。

第三阶段为文本行业识别，本文以 Wind 数据库一级行业指数中的金融、能源、材料、工业、房地产、通讯服务、日常消费、信息技术、可选消费、医疗保健和公用事业共 11 个行业作为研究对象。首先根据中国证监会行业分类标准与全球行业分类系统的融合关键词建立覆盖 11 个金融行业标准分类的领域关键词词典,词典构建如表 4-3 所示。并基于行业核心概念、典型企业、关键产品和服务设置多维覆盖权重，然后合并标题和正文作为处理文本，基于 jieba 分词器进行精确模式分词，统计各行业关键词在文本中的出现频率，选择匹配度最高的行业作为分类结果，未在 11 个行业分类结果中的文本设置为“其他”类别，最后删除类别为“其他”的文本数据，只保留 11 个行业的文本数据。最终得到每个年份的数据量统计如图 4-4 所示。

表 4-3 行业词表

分类	关键词
能源	石油、天然气、煤炭、电力、能源、原油、加油站、油田、新能源、太阳能、风能、核电
材料	钢铁、金属、有色金属、化工、塑料、玻璃、水泥、建筑材料、陶瓷、合金

中国知网 https://www.cnki.net

工业	制造、工厂、机械、设备、工业、生产线、加工、装配、机床、自动化、机器人
可选消费	汽车、旅游、酒店、餐饮、娱乐、休闲、奢侈品、家电、家具、珠宝、化妆品
日常消费	食品、饮料、日用品、超市、百货、零售、米、面、油、盐、酒、糖
医疗保健	医院、医生、药品、疫苗、保健、健康、医疗、医保、手术、诊所、制药
金融	银行、证券、保险、基金、股票、投资、贷款、汇率、利息、股市、债券
信息技术	软件、互联网、电脑、手机、通信、网络、数据、人工智能、云计算、芯片、半导体
通讯服务	电信、移动、联通、5G、宽带、话费、流量、短信、通话、基站
公用事业	水、电、气、公共汽车、地铁、公交、交通、环卫、环保、垃圾处理、自来水
房地产	房子、房价、地产、楼盘、购房、租房、物业、开发商、住宅、商业地产、房产

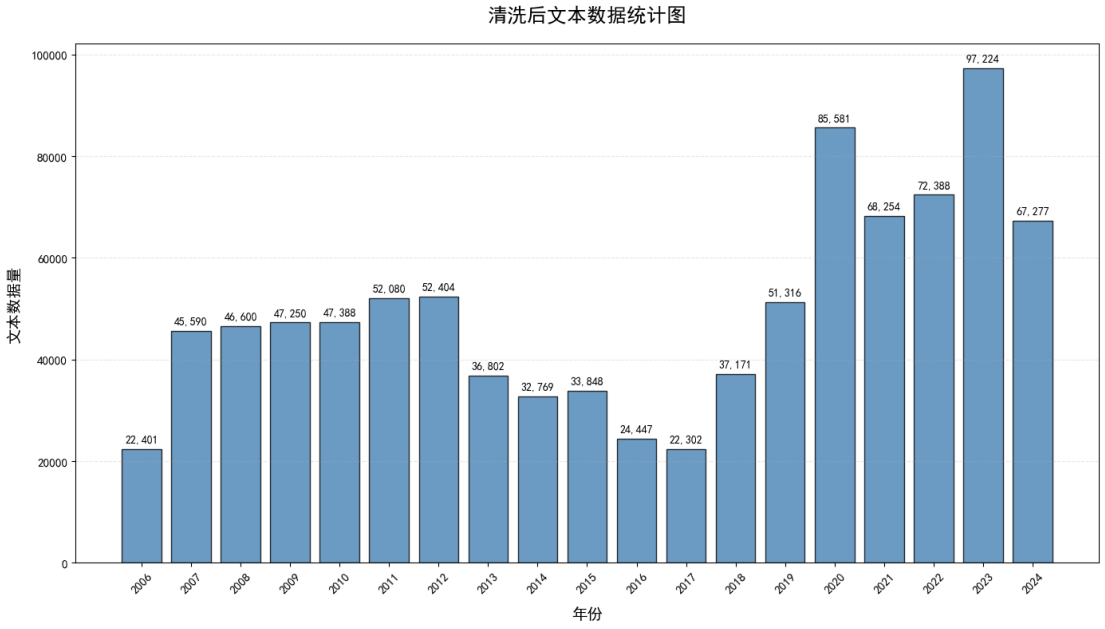


图 4-4 清洗后文本数据统

中国知网 https://www.cnki.net

4.5.2 风险溢出传染网络及图神经网络模型数据收集

行业数据方面，选取 11 个行业为采集对象，为使滚动窗口构建的风险传染网络覆盖风险及预警期，选取 2006 年 1 月 1 日至 2022 年 12 月 31 日作为样本区间，提取了在此期间内每个交易日各行业指数的每日最高、最低、开盘和收盘股价；宏观经济变量选取通货膨胀率、GDP 增长率等，数据均来源于 Wind 数据库，并计算出各行业的日度收益率数据和 VaR。

中国知网 https://www.cnki.net

第 5 章 实证研究结果与分析

5.1 日投资者行业情绪指标测分析

为了验证假设 H1，同时也为了给假设 H2、H3、H4 提供数据基础，本文基于 BERT 模型、在 FinBERT 模型和 Deepseek 模型三种大语言模型对 2006 年至 2023 年财经新闻文本进行情绪分析，得到了涵盖 11 个金融行业的日度情绪指标。表 5-1 呈现了三种模型下各行业情绪指标的描述性统计特征，包括均值、标准差以及情绪值大于 0.5（即积极情绪主导）的天数比例。图 5-1 至图 5-3 则分别展示了三种模型下 11 个行业情绪指标的 30 日移动平均动态演化轨迹。通过对上述图表信息的系统分析，可以从行业异质性与模型差异性两个维度，揭示文本情绪的内在结构特征及其蕴含的市场风险感知信息。

表 5-1 三种大语言模型情绪指标描述性统计

行业名称	BERT			FinBERT			Deepseek		
	均值	标准差	积极天数比例(>0.5)	均值	标准差	积极天数比例(>0.5)	均值	标准差	积极天数比例(>0.5)
通讯服务	0.430	0.190	0.012	0.431	0.223	0.436	0.666	0.264	0.575
公用事业	0.372	0.240	0.021	0.373	0.267	0.378	0.617	0.291	0.424
信息技术	0.262	0.277	0.038	0.260	0.297	0.247	0.617	0.279	0.394
房地产	0.244	0.272	0.027	0.245	0.295	0.245	0.616	0.255	0.509
日常消费	0.243	0.270	0.023	0.243	0.294	0.242	0.607	0.263	0.505
医疗保健	0.210	0.256	0.015	0.211	0.283	0.209	0.560	0.227	0.183
可选消费	0.191	0.260	0.025	0.189	0.282	0.174	0.560	0.147	0.591
工业	0.148	0.233	0.024	0.147	0.258	0.122	0.548	0.270	0.262
能源	0.142	0.225	0.029	0.143	0.252	0.115	0.547	0.284	0.273

中国知网 https://www.cnki.net

材料	0.112	0.207	0.010	0.111	0.234	0.090	0.533	0.174	0.100
金融	0.090	0.131	0.005	0.091	0.174	0.029	0.509	0.273	0.210

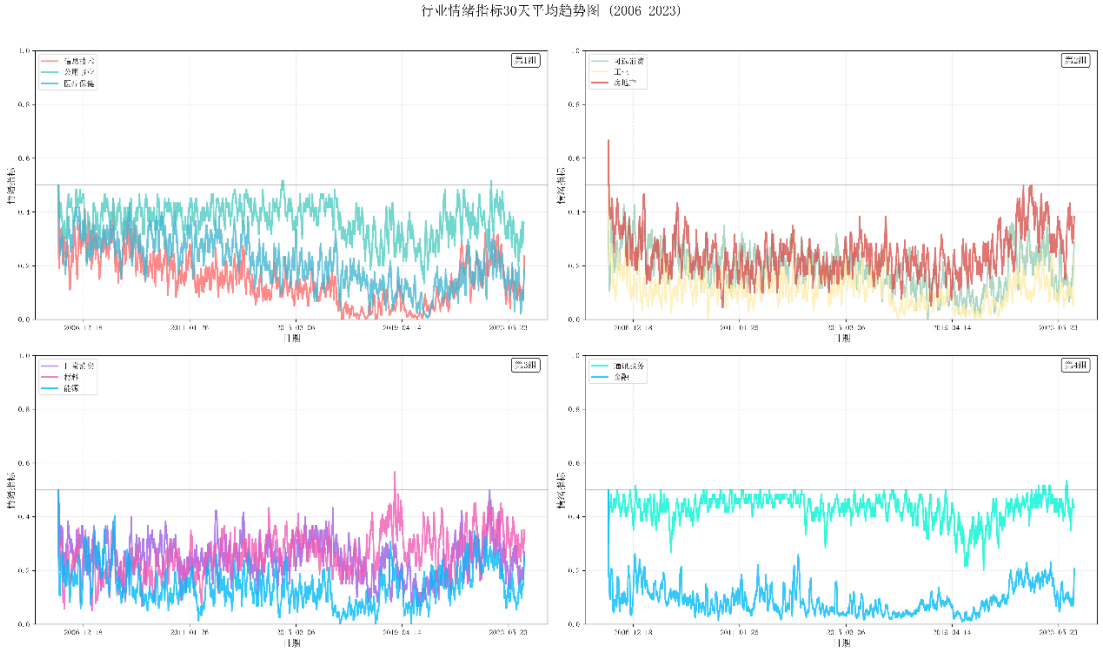


图 5-1 BERT 模型行业情绪指标 30 天动态变化

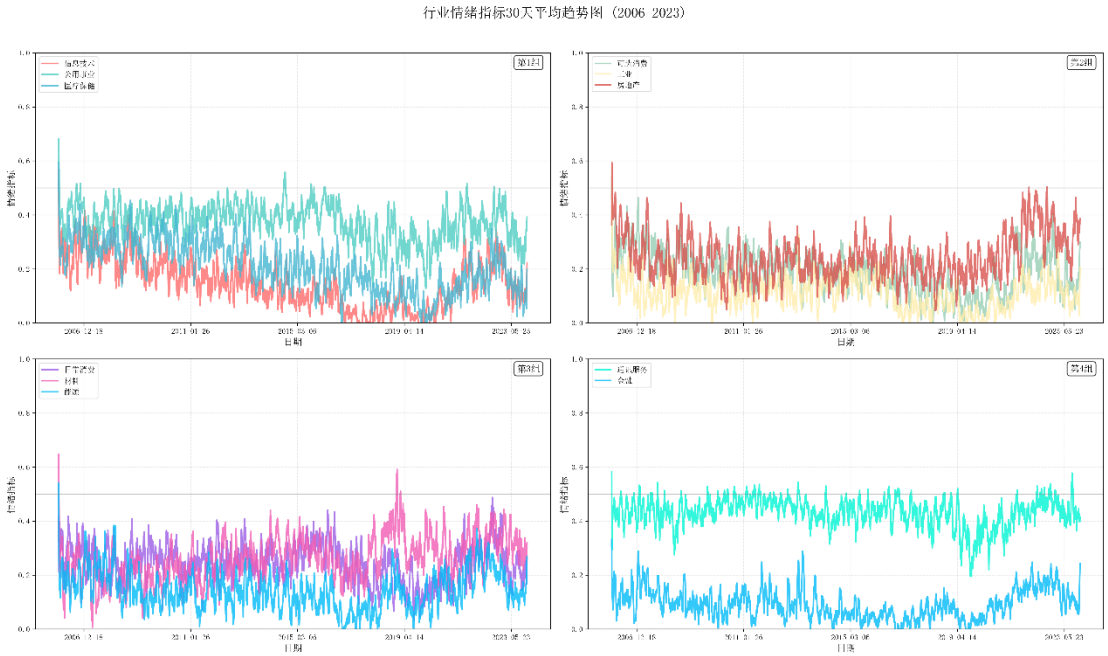


图 5-2 BERT-微调模型行业情绪指标 30 天动态变化

中国知网 https://www.cnki.net

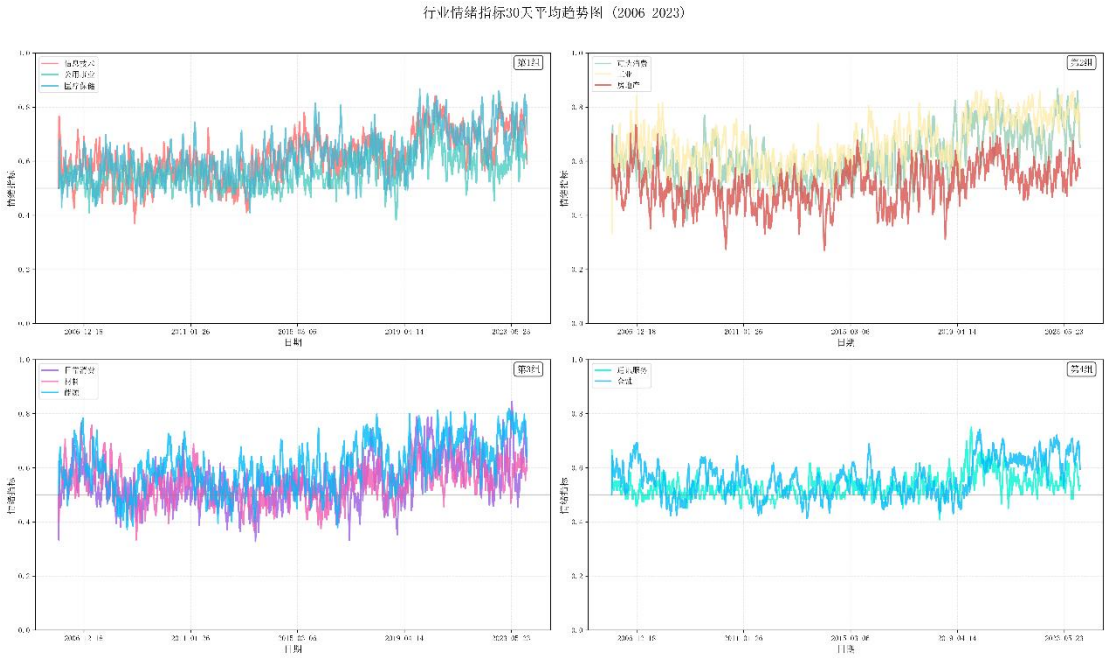


图 5-3 Deepseek 模型行业情绪指标 30 天动态变化

5.1.1 行业间情绪差异分析

从表 5-1 的统计结果可以看出，不同行业在文本情绪上呈现出显著的系统性差异，这种差异在三种大语言模型下均表现出一致性规律。

首先，从情绪均值来看，通讯服务和公用事业行业在各模型下均处于相对高位。以 BERT 模型为例，通讯服务行业情绪均值为 0.430，公用事业为 0.372，显著高于其他行业。这一现象可能源于这些行业的公共属性与稳定预期：通讯服务作为数字经济基础设施，公用事业作为民生保障领域，其经营状况与宏观经济周期关联度相对较低，市场对其业绩预期较为平稳，负面新闻曝光频率较低，因此整体情绪偏向中性偏积极。

其次，金融、材料、能源等强周期性行业的情绪均值普遍偏低。金融行业在 BERT 模型下的情绪均值仅为 0.090，为所有行业中最低；材料行业为 0.112，能源行业为 0.142。这一分布特征与我国金融市场的发展历程密切相关：样本期内经历了 2008 年国际金融危机、2013 年钱荒、2015 年股灾、2020 年新冠疫情等多轮冲击，金融行业作为风险最终承担者，长期处于舆论关注的风口浪尖，负面报道频次高、密度大。材料与能源行业则受大宗商品价格波动、环保政策收紧、产能过剩等因素影响，市场情绪持续承压。

第三，从情绪标准差来看，信息技术、房地产、日常消费等行业的波动幅度较大。BERT 模型下，信息技术行业标准差高达 0.277，房地产为 0.272，表明这些行业的市场情绪具有更高的不稳定性和突发性。信息技术行业受技术创新、政策支持、国际竞争等多重因素影响，市场预期易出现剧烈转向；房地产行业则与

中国知网 https://www.cnki.net

调控政策、信贷环境、房企流动性等高度绑定，政策敏感性强，情绪波动频繁。相比之下，金融行业标准差仅为 0.131，情绪波动相对平缓，这可能与其信息披露规范、媒体关注持续、市场预期相对稳定的特性有关。

第四，积极天数比例进一步印证了行业间的情绪分化。通讯服务行业在 BERT 模型下积极天数比例为 0.012，表面看数值很低，但该行业情绪均值 0.430 已接近中性，而且因模型输出分布偏左，积极阈值的设定使得超过 0.5 的天数较少。实际上，通讯服务行业的情绪分布相对集中在中性偏积极区间。金融行业积极天数比例仅 0.005，几乎无积极情绪主导日，反映出该行业长期处于负面舆论环境中。这一特征与金融行业作为系统性风险核心载体的定位相符。

从图 5-1 至图 5-3 的动态演化轨迹可以看出，各行业情绪指标在长期趋势上存在协同波动特征。在 2008 年国际金融危机、2015 年股灾、2020 年新冠疫情等重大冲击期间，多数行业情绪指标同步下行，形成明显的“情绪低谷”区域，反映出系统性风险爆发时市场恐慌情绪的跨行业传染。但在冲击后的恢复阶段，行业间情绪反弹的速度与幅度存在显著差异：通讯服务、公用事业等行业恢复较快，而金融、房地产等行业则持续低位徘徊，体现出风险暴露后的“情绪滞后效应”。

5.1.2 大语言模型间的情绪测度差异

对比表 5-1 中三种大语言模型的统计结果，可以发现模型架构与训练范式的差异显著影响了情绪指标的分布特征与测度结果。

从均值水平来看，BERT 与 FinBERT 在各行业上的情绪均值高度接近，几乎呈现线性相关。以信息技术行业为例，BERT 均值为 0.262，FinBERT 为 0.260；房地产行业 BERT 为 0.244，FinBERT 为 0.245；金融行业 BERT 为 0.090，FinBERT 为 0.091。这一高度一致性表明，FinBERT 作为 BERT 的金融领域微调版本，在整体情绪极性判断上继承了基础模型的基本认知框架，领域微调并未改变模型对文本整体情感倾向的判别基准，而是在更细粒度的语义理解上发挥作用。

然而，Deepseek 模型的情绪均值呈现出系统性抬升的特征。通讯服务行业 Deepseek 均值为 0.666，公用事业为 0.617，信息技术为 0.617，金融行业也达到 0.509，显著高于前两种模型。这一差异可能源于生成式大语言模型与判别式模型在情感理解范式上的根本区别。BERT 类模型通过掩码语言建模进行预训练，其输出概率分布偏向保守，对极端情感的识别较为谨慎；而 Deepseek 作为生成式模型，在上下文连贯性与语义生成能力的训练目标下，对文本情感的表达可能更为鲜明、更具区分度，从而在情绪极性判断上表现出更高的灵敏度和更强的极化倾向。

从标准差来看，FinBERT 在各行业上的标准差普遍大于 BERT。金融行业 BERT

中国知网 https://www.cnki.net

标准差为 0.131，FinBERT 为 0.174；信息技术行业 BERT 为 0.277，FinBERT 为 0.297。这一差异表明，经过金融领域微调后，模型对文本情绪的波动性捕捉能力增强，能够更敏感地识别金融文本中的情绪转折与细微变化，从而在情绪指标的时序波动上表现出更高的动态性。Deepseek 的标准差进一步放大，金融行业达 0.273，信息技术达 0.279，反映出生成式模型对情绪极值更为敏感的特征。

从积极天数比例来看，三种模型呈现出阶梯式递增。以通讯服务行业为例，BERT 积极天数比例仅 0.012，FinBERT 升至 0.436，Deepseek 进一步升至 0.575。这一巨大差异主要源于情绪均值分布的整体偏移：BERT 情绪均值集中在 0.1-0.4 区间，多数样本低于 0.5；FinBERT 均值略有提升但仍多在 0.5 以下；Deepseek 均值普遍超过 0.5，因此积极天数比例显著提高。这一现象提示，在使用不同大语言模型进行情绪分析时，需注意模型输出分布的基准差异，直接跨模型比较绝对值可能产生误导，而应关注情绪指标的相对变化与行业排序。

三种模型提取的情绪指标在长期演化趋势上表现出高度的一致性。首先，它们均能清晰捕捉到中国金融市场重大危机事件前后的情绪下行周期。例如，在 2008 年国际金融危机期，各行业情绪曲线同步下探，形成样本期内最深的情绪谷底；2015 年股灾爆发前后，信息技术、可选消费等前期高情绪行业出现急剧回落；2020 年新冠疫情冲击初期，多数行业情绪指标再次集体走低。这种跨模型的同步响应表明，大语言模型能够有效识别市场层面的系统性风险冲击，情绪指标的宏观走势具有稳健的经济含义。其次，行业间的相对情绪排序在三种模型中保持一致：通讯服务、公用事业等行业长期处于情绪高位区间，而金融、材料、能源等行业则持续徘徊于低位。这一跨模型的行业排序稳定性，进一步验证了行业固有属性（如公共属性、周期性、政策敏感性）对市场情绪的塑造作用，也说明不同模型在行业层面的情绪判别逻辑存在共通之处。

尽管宏观趋势一致，但三种模型在波动幅度、对事件的敏感性以及趋势细节上呈现明显差异。其一是波动幅度差异。Deepseek 模型提取的情绪指标波动最为剧烈，其曲线在危机期间的下探深度和危机后的反弹高度均显著大于 BERT 和 FinBERT。例如在 2008 年危机谷底，Deepseek 模型中多个行业的情绪值逼近 0.2 以下，而 BERT 模型同期的情绪值多在 0.3 以上；在 2020 年疫情冲击后，Deepseek 模型中可选消费、信息技术等行业情绪迅速反弹至 0.7 以上，形成尖锐的 V 形反转，而 BERT 模型的反弹则相对平缓。这种剧烈波动反映了生成式大语言模型对情绪极值的高度敏感，其输出更倾向于放大文本中的情感信号，从而在时序上呈现出更鲜明的“情绪脉冲”。相比之下，BERT 模型的曲线更为平滑，对短期波动的过滤作用较强，体现出判别式模型稳健但略显保守的特性。FinBERT 的波动幅度介于两者之间，其经过金融领域微调后，对行业特定事件的反应较 BERT 更为

中国知网 https://www.cnki.net

灵敏，但尚未达到 Deepseek 的极化程度。

其二是危机响应的敏感性与时效性差异。Deepseek 模型对危机事件的响应最为迅速，往往在风险事件正式爆发前就能捕捉到情绪拐点。以 2015 年股灾为例，Deepseek 模型中信息技术行业的情绪自 2015 年 3 月起即开始快速下行，领先于市场暴跌约三个月；而 BERT 模型直到 2015 年 5 月才出现明显下跌，响应略有滞后。这一差异表明，生成式模型可能对文本中的隐含风险信号具有更强的早期识别能力，能够从新闻报道的细微措辞变化中提前感知市场情绪的转向。FinBERT 的响应速度优于 BERT，但略逊于 Deepseek，说明金融领域微调在一定程度上增强了模型对风险信号的敏感度，但仍受限于判别式模型的架构特性。

5.1.3 投资者情绪与市场风险的关联性

首先，情绪指标在重大危机事件前后呈现出显著的前瞻性下行特征。在 2008 年国际金融危机爆发前，各行业情绪指标自 2007 年中即开始持续下行，领先于风险溢出指数的急剧攀升。2015 年股灾前，信息技术、可选消费等行业的情绪指标在 2015 年初出现高位回落，预示了后续市场崩溃的风险积聚。2020 年新冠疫情冲击前，各行业情绪指标在 2019 年底至 2020 年初已有走弱迹象，反映出市场对潜在风险的隐性感知。这一现象表明，基于大语言模型提取的投资者情绪能够有效捕捉市场参与者的前瞻性风险判断，在危机正式爆发前即发出预警信号，具备良好的领先指示作用。

其次，情绪指标的行业异质性为理解风险传染的部门差异提供了新视角。在 2008 年危机期间，金融行业情绪持续低迷，但信息技术、可选消费等行业情绪波动更为剧烈，反映出不同行业对危机的敏感度与反应模式存在差异。2015 年股灾中，信息技术作为前期热点行业，情绪指标在危机前后出现过山车式剧烈震荡，成为风险传导的核心源头。2020 年新冠疫情冲击下，医疗保健行业情绪在危机初期不降反升，反映出疫情对该行业的特殊利好效应，随后才随整体市场情绪下行。这种行业层面的情绪分化，为后续的风险溢出网络结构演变提供了微观行为层面的解释：情绪波动剧烈的行业更易成为风险输出的源头，情绪持续低迷的行业则更可能成为风险累积的蓄水池。

综上所述，基于三种大语言模型构建的投资者情绪指标，在波动幅度、对事件的敏感性以及趋势细节上呈现明显差异，验证了假设 H1.同时，它们能够有效捕捉市场对风险的前瞻性感知，其动态演变与风险溢出网络的时变特征形成共振。这为后续将情绪指标纳入时空图神经网络进行风险预警建模提供了充分的理论依据与数据支撑。

中国知网 https://www.cnki.net

5.2 动态风险溢出传染网络的构建结果与分析

为了初步研究系统性风险的传染特征，验证金融风险设定的准确性，同时也是为了给动态变化的时空图神经网络模型提供网络特征，以便验证假设 H2、H3、H4，本文先构建了一个动态风险溢出传染网络。鉴于系统性金融风险传染具有显著的动态特征，为了衡量风险传染的时变特点，本文采用滚动回归方法，设定滚动窗口为 100 个交易日，利用计算出的 VaR 数据结合预测方差分解和 Elastic-Net-VAR 模型构建了日度的风险溢出网络，并计算出风险溢出效应，Elastic-Net-VAR 模型根据 SC 准则确定为 1。为了验证风险预警期是否构建合理，本文首先构建出全样本期风险溢出动态表如图 5-4，在图中同时标注出危机期与预警期，并分段统计平均溢出效应如表 5-2，同时为了给后续说明提供便利，本文将 2006 年 1 月 4 日至 2018 年 12 月 31 日样本期内的风险溢出统计和 2019 年 1 月 4 日至 2022 年 12 月 31 日样本期内的累计风险溢出统计列出如表 5-3 所示，并将行业间的风险溢出关系排名列表如表 5-4 所示，最后根据上述两个样本期间的风险溢出矩阵，分别画出两个时期的风险传染网络图如图 5-5 和图 5-6 所示。

图 5-4 清晰地展示了 2006 年至 2022 年间行业间风险总体溢出指数的动态演化路径。整体而言，风险溢出效，呈现显著的“阶梯式”跃升与回落特征，且其峰值与谷值分别与我国金融市场经历的特定危机事件及平稳时期高度吻合。这首先验证了基于预测误差方差分解方法构建的动态风险溢出网络能够有效捕捉系统性风险的集聚与扩散过程，其测度结果具有经济意义上的合理性。从数值上看，全样本期内总体溢出指数的均值约为 63.5，但波动剧烈。表 5-2 的分时期统计进一步量化了这一特征：在四个明确的危机期（国际金融危机、银行钱荒、股灾、新冠疫情），平均溢出效应均显著高于相邻的平稳期。其中，新冠疫情冲击期间的平均溢出指数高达 89.58，为样本期内峰值，表明此次突发公共卫生事件在短期内引发了极其剧烈的跨行业风险共振。2008 年国际金融危机期间的平均溢出效应为 84.97，持续时间最长，体现了外部冲击的深层次、长周期影响。2015 年股灾与 2013 年钱荒事件的溢出指数分别为 78.01 和 70.78，虽然数值低于前两次全局性危机，但仍远高于其前后平稳期水平（约 42-54 之间），证实了即使是局部或源自国内金融体系内部的冲击，也能引发显著的风险网络激活与传染。进一步分析发现，风险溢出指数在危机爆发前期（即设定的预警期内）通常已开始呈现上升趋势。例如，在图 5-4 中，2007 年年中、2013 年春季、2015 年春季以及 2019 年底，指数均出现了不同幅度的攀升，随后才进入正式的危机。这一先行现象表明，系统性风险的积累具有隐蔽性和渐进性，风险在网络中的累积和增强会早于市场极端波动的全面爆发。这为建立基于动态网络指标的早期预

中国知网 https://www.cnki.net

警系统提供了直接证据，即监测风险溢出网络的整体活跃度可以有效识别风险的积聚阶段，同时也证明了预警期设定的合理性。

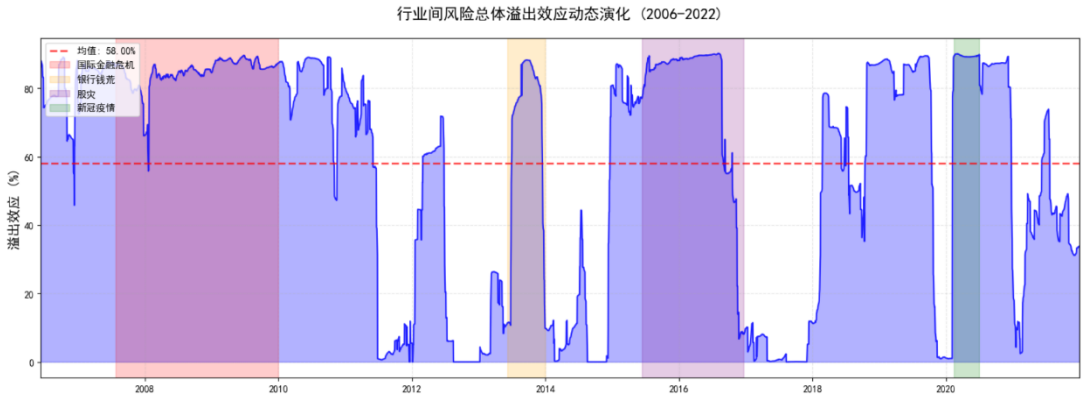


图 5-4 行业间风险总体溢出动态演化

表 5-2 平均溢出效应分时期统计

时间段	开始日期	结束日期	平均溢出效应	样本数
平稳期 1	2006-01-04	2007-07-25	80.51505	275
国际金融危机	2007-07-26	2009-12-31	84.96789	597
平稳期 2	2010-01-01	2013-06-06	42.7454	829
银行钱荒	2013-06-07	2013-12-31	70.78294	138
股灾	2015-06-15	2016-12-20	78.00865	372
平稳期 3	2017-01-01	2020-02-13	42.27697	756
新冠疫情	2020-02-13	2020-06-30	89.57949	93
平稳期 4	2020-07-01	2022-12-31	54.36717	611

表 5-3 从行业层面揭示了不同样本期内风险净溢出地位的变化，反映了我国经济结构与金融风险源头的演进。在 2006-2018 年样本期，“信息技术”和“通讯服务”行业是突出的风险净输出者，净溢出值分别高达 1061.53 和 541.58，排名前两位。这与该时期我国互联网经济蓬勃发展、相关板块市场关注度高、估值波动大，且与传统产业加速融合的背景相符。这些行业易受市场情绪和成长预期影响，其波动易于向上下游（如材料、工业、可选消费）及关联的金融行业扩散。与此形成鲜明对比的是，“金融”行业是最大的风险净接受者（净溢出为-894.53），其次是“公用事业”和“材料”。这表明在 2018 年之前，金融体系更多地扮演着风险“蓄水池”或“最终承担者”的角色，承受来自实体经济特别是新兴科技产业的风险传导。然而，在 2019-2022 年样本期，行业角色发生了较大转变。“房地产”行业取代信息技术，成为头号风险净输出者（净溢出 1106.78），且数值巨大。“能源”行业也转变为重要的净输出者（净溢出 665.67）。与此同时，“医疗保健”行业成为了最主要的风险净接受者（净溢出-824.74），“信息技术”行业也从最大的输出者转变为净接受者（净溢出-309.23）。这一结构性转变

中国知网 https://www.cnki.net

与近年来的宏观环境高度相关：房地产行业在“房住不炒”政策深化、部分企业流动性问题暴露的背景下，其风险生成与外溢能力急剧上升；能源行业则可能受全球大宗商品价格剧烈波动、绿色转型冲击等因素影响，波动性增强。而医疗保健行业在疫情期间虽受关注，但其股价波动可能更多受整体市场情绪和资金轮动影响，成为风险的汇集点之一。金融行业的净接受地位虽有所减弱（从-894.53 降至-246.29），但仍为净接受方，显示其系统性重要地位及对实体风险的持续暴露。这一对比表明，系统性金融风险的核心传染源并非一成不变，而是随着国家产业发展阶段、宏观政策重心和外部冲击性质的变化而动态迁移。风险预警与监管必须具有行业针对性和动态视角，识别不同时期的“系统重要性风险输出行业”。

表 5-3 双样本期行业风险累计溢出统计

行业	2006 年 1 月 4 日至 2018 年 12 月 31 日				2019 年 1 月 4 日至 2022 年 12 月 31 日			
	累计溢出	累计溢入	累计净溢出	排名	累计溢出	累计溢入	累计净溢出	排名
信息技术	530.7668	-530.767	1061.534	1	-154.615	154.6154	-309.231	10
通讯服务	270.7875	-270.788	541.5751	2	189.6712	-189.671	379.3423	3
能源	161.7494	-161.749	323.4987	3	332.8332	-332.833	665.6663	2
房地产	155.2927	-155.293	310.5853	4	553.3882	-553.388	1106.776	1
日常消费	52.20479	-52.2048	104.4096	5	-122.372	122.372	-244.744	7
医疗保健	-73.3145	73.31449	-146.629	6	-412.37	412.3705	-824.741	11
可选消费	-77.0361	77.03606	-154.072	7	-99.7858	99.78578	-199.572	6
工业	-115.848	115.8481	-231.696	8	-50.2995	50.29949	-100.599	5
材料	-227.327	227.327	-454.654	9	-137.8	137.7998	-275.6	9
公用事业	-230.011	230.0105	-460.021	10	24.49683	-24.4968	48.99366	4
金融	-447.265	447.2649	-894.53	11	-123.146	123.1464	-246.293	8

表 5-4 进一步从成对行业的角度，揭示了风险传染的具体路径及其随时间的变化，使网络结构更加清晰。

在 2006-2018 年，最关键的风险传染路径主要集中在从“信息技术”行业向“材料”、“工业”、“可选消费”等实体制造业的溢出。例如，“信息技术→材料”的净溢出高达 89.01，位居首位。这印证了科技产业作为创新引擎，其市场波动通过供应链、投资预期等渠道迅速传导至中上游基础产业。此外，“通讯服务→金融”也是一条重要路径（净溢出 84.62），体现了电信运营等板块与金融体系的紧密联系。

到了 2019-2022 年，风险传染图谱完全重构。排名前九的路径全部与“房地产”或“能源”行业作为溢出方相关。其中，“房地产→医疗保健”（75.42）、“房地产→金融”（75.22）成为最主要的传染链条。前者可能反映了在市场避险或资金紧张时期，资金从受政策调控的房地产板块流出，对包括医疗在内的其他行业造成流动性冲击或估值挤压；后者则直接揭示了房地产风险向金融体系，

中国知网 https://www.cnki.net

特别是银行、信托等机构的信用风险传导，这是当前防范系统性风险的核心关切。“能源→医疗保健”（69.61）等路径的出现，则可能关联成本传导或更广义的宏观经济不确定性蔓延。

网络可视化图 5-5 与图 5-6 直观地支持了上述统计发现。图 5-5 中，信息技术、通讯服务处于网络的相对中心位置，箭头向外指向多个行业。而图 5-则显示，房地产和能源成为了新的网络枢纽，连接数多且边权重大，尤其是向金融、医疗保健等行业的箭头非常突出，网络结构呈现出更高的集中度和方向性。

表 5-4 双样本期行业间风险溢出统计

2006 年 1 月 4 日至 2018 年 12 月 31 日				2019 年 1 月 4 日至 2022 年 12 月 31 日			
溢出行业	溢入行业	净溢出	排名	溢出行业	溢入行业	净溢出	排名
信息技术	材料	89.01376	1	房地产	医疗保健	75.42261	1
信息技术	工业	84.74718	2	房地产	金融	75.22161	2
通讯服务	金融	84.61541	3	能源	医疗保健	69.60592	3
信息技术	可选消费	77.92132	4	房地产	材料	66.5806	4
房地产	金融	62.81721	5	房地产	可选消费	65.90934	5
信息技术	金融	60.93464	6	日常消费	医疗保健	64.26078	6
信息技术	医疗保健	60.7634	7	能源	材料	63.99463	7
能源	金融	55.27104	8	房地产	日常消费	60.47794	8
信息技术	公用事业	52.46294	9	房地产	工业	58.01456	9
通讯服务	日常消费	47.59424	10	通讯服务	医疗保健	57.94068	10

中国知网 https://www.cnki.net

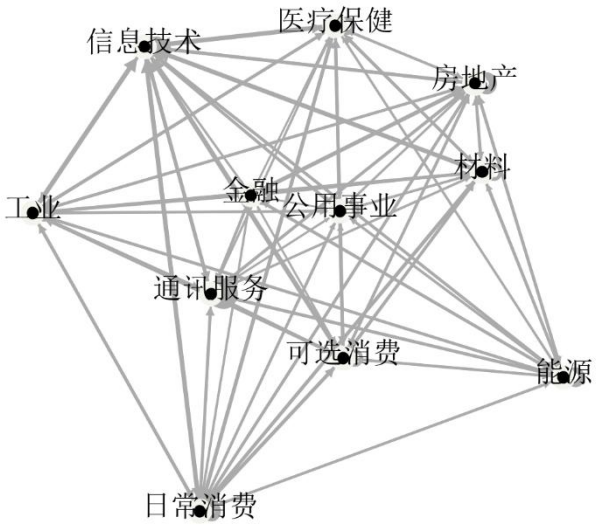


图 5-5 2006-2018 风险溢出网络

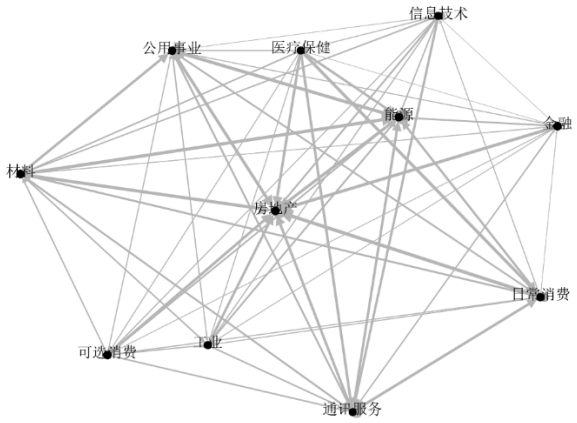


图 5-6 2019-2022 风险溢出网络

5.3 使用投资者情绪的预测效果实证结果与分析

为验证假设 H2，本文以 5.2 章节得到的 2006 年 1 月 4 日至 2018 年 12 月 31 日的时变风险溢出网络和经由三种大语言模型分析得来的新闻投资者情绪与行业独热编码、相关宏观经济数据和风险设定作为时空图神经网络的输入变量，同时期的风险预警信号作为输出变量，选取前 75%的样本作为训练集，其余为验证

中国知网 https://www.cnki.net

集，将 2019 年 1 月 4 日至 2022 年 12 月 31 日的同质数据作为测试集，构建时空图神经网络模型进行训练与预测。为了比较的直观性，本文首先使用输入 BERT 测度的投资者情绪指标的时空图神经网络模型作为基准模型，以便与传统指标和传统模型对比较。时空图神经网络的超参数设置为：采用 GRU 作为时间编码器、GIN 作为空间编码器，使用 Adam 优化器（初始学习率 0.001）和交叉熵损失函数，最大训练轮数设为 100。

5.3.1 BERT 测度的投资者情绪指标的时空图神经网络预测结果与分析

首先使用通过 BERT 大语言模型测度的投资者情绪作为研究对象，使用时空图神经网络模型进行 BERT 情绪指标的双信号模型的训练与预测，模型的训练效果及预测效果如图 5-7 所示，模型在预测集上的预测评价指标如表 5-5 所示，除了传统指标外，本文为了进一步评价模型，添加了 P1（过早预警比例），P2(预警期正确预警比例)和 P3（危机期正确预警比例），同时为了可视化预测效果，画出预测集的混淆矩阵如图 5-8 所示，画出双信号模型的真实危机期与预警期图如图 5-9，预测危机期与预警期图如图 5-10。

从图 5-7 可知，模型的训练过程呈现出良好的收敛特性。训练损失随轮次增加快速下降并逐渐趋于平稳，验证损失同步下降，且在训练后期与训练损失基本保持接近，未出现显著的背离或急剧上升。这表明模型没有出现严重的过拟合现象。同时，训练与验证准确率曲线均稳步上升并最终在高位保持稳定，验证准确率最终接近并略低于训练准确率，符合机器学习模型性能的一般规律，表明所设计的时空图神经网络模型能够有效地从历史数据中学习到金融危机预警的时空模式。表 5-5 显示，整体预测准确率达到 0.9156，表明模型整体预测效果理想，F1-Score 为 0.7453，表明模型在识别预警/危机信号方面取得了较好的综合效果，能够在控制误报的同时相对有效地捕捉真正的风险信号。为了更细致地评价模型预测效果，本研究引入了针对预警任务特性设计的三个补充指标： P1、P2 和 P3。对于本文提出的预测模型而言，P1 应尽量低，而 P2 和 P3 应尽量高。在双信号模型中，P1 的值较低，说明模型的误报率控制得较，预警信号的可信度较强。P2 表明超过 76%的预警期被模型准确识别，这具有很强的现实意义，证明模型能够在一定程度上提前捕捉到风险积聚的迹象，具备实际的早期预警价值。P3 的值超过 0.8，说明模型对已爆发危机的识别能力较强。P2 与 P3 的数值差异（P3 略高于 P2）符合逻辑，因为风险在预警期处于积累和显化过程中，其信号强度可能弱于全面爆发的危机期，因此识别难度较

中国知网 https://www.cnki.net

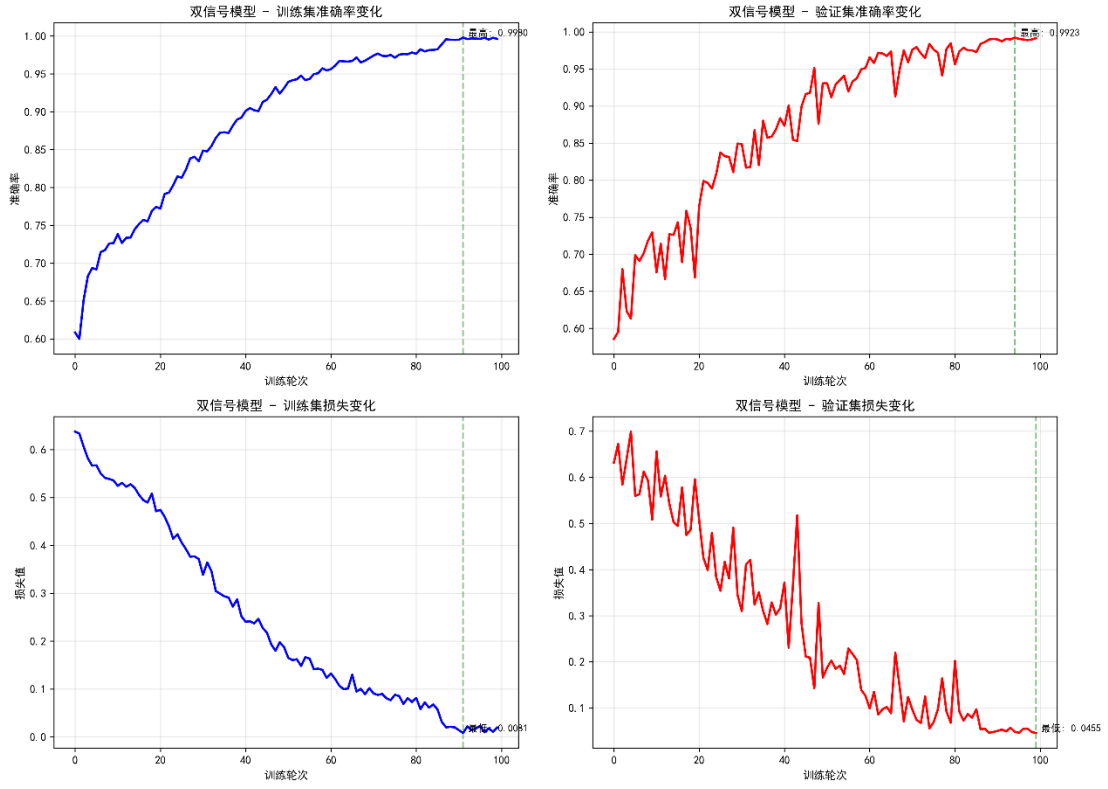


图 5-7 bert 投资者情绪双信号模型训练集与验证集效果

表 5-5 双信号模型预测评价指标

accuracy	F1-Score	F-Alarm	P1	P2	P3
0.9156	0.7453	0.0602	0.0895	0.7609	0.8058

图 5-8 的混淆矩阵进一步细化了模型的预测结果。矩阵显示，模型对安全期的预测能力极强，正确预占绝大多数，这与高整体准确率一致。主要的误判集中在两个方面：一是将部分安全期误判为预警/危机，这对应了 P1 指标；二是将部分预警/危机误判为安全期，这一种误判是预警模型需要改善的，即需要尽量减少风险的漏报现象。混淆矩阵显示，漏报的比例相对较低，这从另一角度支持了 P2 和 P3 指标所体现的较高召回能力。模型的这种误判模式表明，其在倾向于保持较高预警信号检出率的同时，付出了一定的误报代价，但总体而言在精度与召回之间取得了较好的平衡。

中国知网 https://www.cnki.net

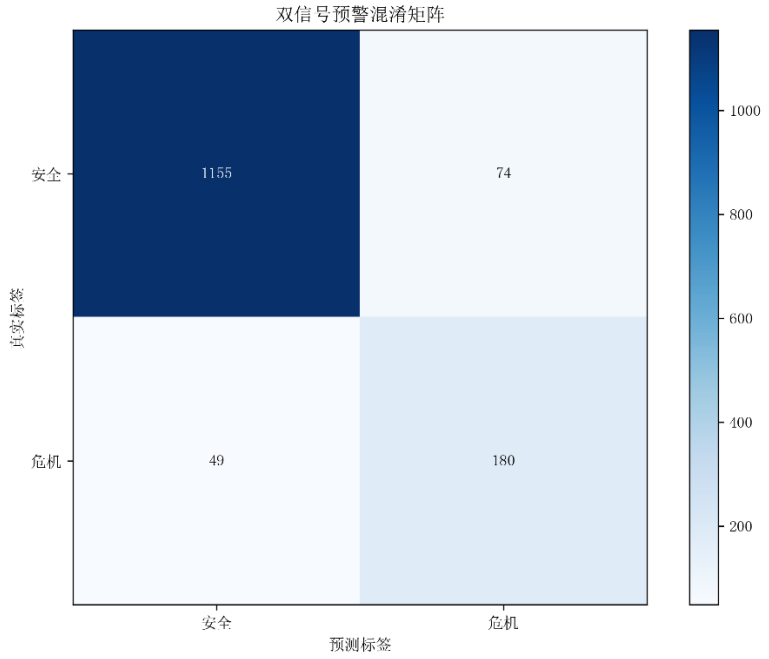


图 5-8 双信号模型混淆矩阵

图5-9与图5-10的对比提供了模型预警信号在时间序列上表现的直观评估。图 5-9 描绘了测试集内真实的预警期与危机期，图 5-10 则展示了模型对该时期预测的预警信号序列。通过对比两图可以发现，模型成功地在新冠疫情引发的金融市场动荡期之前发出了密集的预警信号。需要说明的是，模型预警的对象并非疫情这一公共卫生事件本身，而是疫情冲击下市场恐慌情绪蔓延、流动性收紧、行业风险溢出的金融后果。投资者情绪指标通过捕捉财经新闻中对疫情经济影响的担忧表述，间接反映了市场对即将到来的金融风险的预期。尤其是在 2020 年 2 月危机正式爆发前后，预测信号强度显著增强，与真实危机期高度重合。这表明模型不仅学习到了历史危机模式，并且能够将这种模式应用于全新的、由突发公共卫生事件引发的金融危机中，体现了其良好的外推能力和对未知冲击的适应性。此外，模型预测的预警信号并非与真实情况完全一致，预测的结果存在些许噪音，即在真实的预警和危机期之外，模型预测有零星的危险期，但不影响主要危机期的识别。

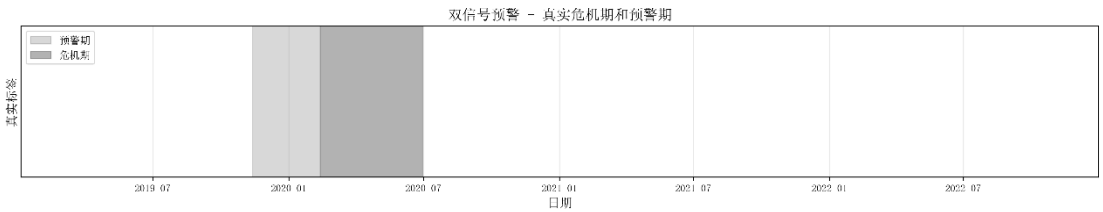


图 5-9 双信号真实预警期危机

中国知网 https://www.cnki.net

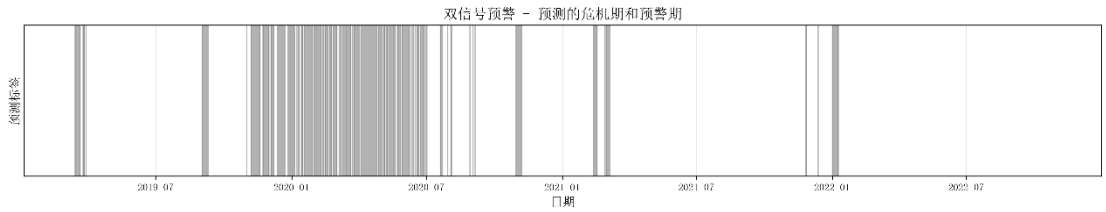


图 5-10 双信号预测预警期危机期

双信号模型虽然效果良好，但是无法准确区分预警期和危机期，为了识别不同时期，从而为相关政策的制定提供时期依据，本文又构建了三信号模型，模型的评价结果如表 5-6，并画出模型的混淆矩阵如图 5-11。表 5-6 显示，三信号模型在测试集上的整体准确率为 0.8978，F1-Score 为 0.7161，与双信号模型相比，两项核心指标均略有下降，但仍处于较高水平。三信号模型的 P1 为 0.1054，略高于双信号模型的 0.0895，表明在试图区分预警期和危机期的过程中，模型出现一定程度的误报，这可能是由于预警期的特征介于安全与危机之间，模型在拟合其模糊边界时，对临近的正常波动也产生了过度敏感。P2 为 0.5444，较双信号模型的 0.7609 出现了显著下降，该结果表明，模型对危机前三个月这一特定预警窗口的精准识别能力有限。可能的原因包括：其一，预警期内风险积聚的信号强度、行业协同性与危机期相比存在量和质的差异，且可能更为隐蔽和多变；其二，历史数据中预警期的模式可能不如危机期一致和显著，增加了模型学习的难度。超过 45%的预警期未被正确识别，提示单纯的、固定时间跨度的预警期定义在现实中的模式可能非常复杂。P3 为 0.7194，低于双信号模型的 0.8058。部分危机期被误判为预警期或安全期，与 P2 结合分析可知，预警期和危机期两类之间存在一定的混淆，这从图 5-11 的混淆矩阵中可以得到验证。结合图 5-9 可知，模型对安全期的预测依然非常准确，主对角线上的数值占绝对主导，这与高整体准确率一致。但模型在区分预警期和危机期时存在困难，且主要的分类误差并非随机分布，而是集中发生在预警期和危机期这两个临近且相关的类别之间。这证实了区分这两个阶段的挑战性，但也说明模型并非完全失效，其误判在很大程度上是对风险状态连续演化的合理误判——将高度紧张的预警误判为危机开端，或将初始危机误判为深度预警。总体而言，三信号模型能够适用于能够容忍一定误判、但需要区分风险等级的管理场景。

表 5-6 三信号模型评价指标

accuracy	F1-Score	F-Alarm	P1	P2	P3
0.8978	0.7161	0.0546	0.1054	0.5444	0.7194

中国知网 https://www.cnki.net

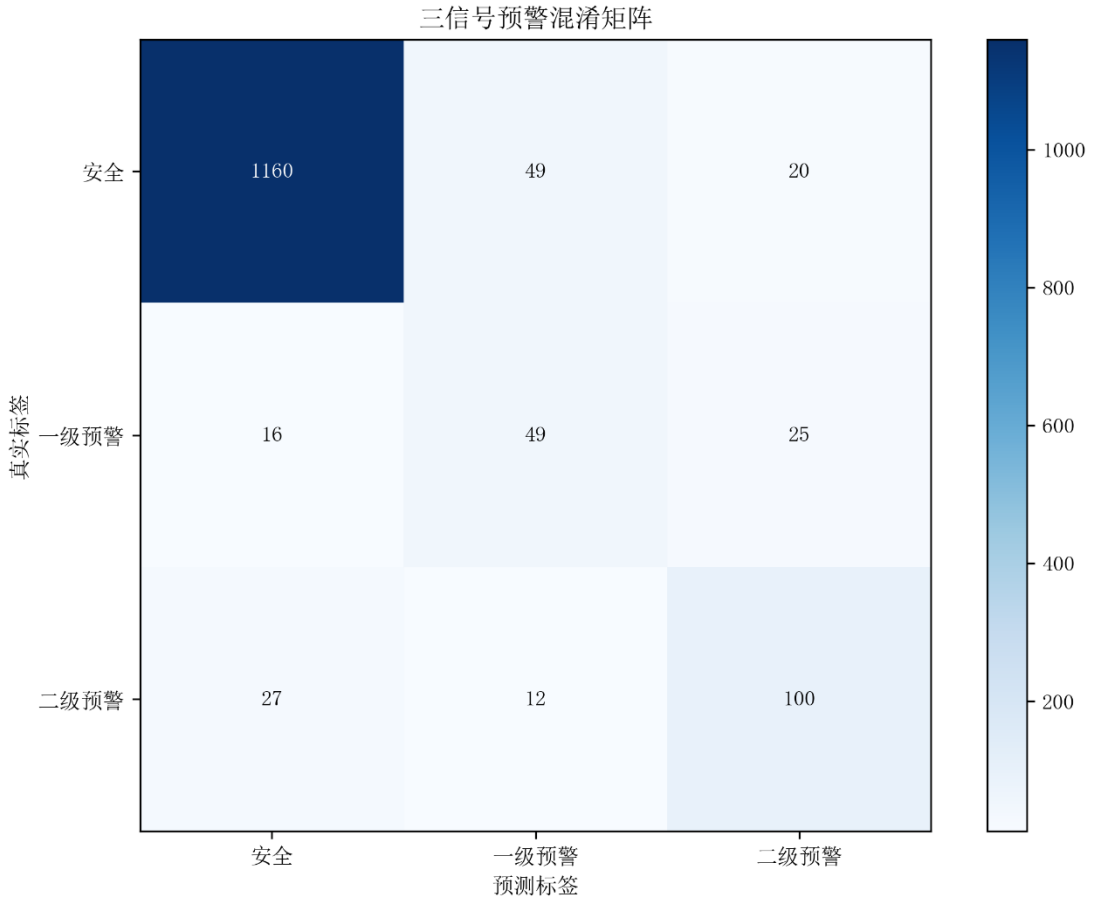


图 5-11 三信号模型混淆矩阵

5.3.2 传统指标预测效果对比

为了验证假设 H2，本文将图神经网络模型中的节点属性剔除投资者情绪，仅保留传统的收益率数据以及宏观经济数据，使用同样的时空图神经网络模型进行双信号模型预测，预测评价指标如表 5-7 所示，预测效果如图 5-12 所示。从表 5-7 与表 5-5 可以看出，替换为传统的收益率数据后，预测准确率为 0.8567，F1 分数为 0.5618，相比文本情绪的预测效果而言均有下降，但仍有一定水准，进一步表明了时空图神经网络模型在风险预测领域的优越性。同时，模型的 P1 恰好持平，而 P2 与 P3 显著下降，说明使用收益率数据后，模型的预测效果均全面下降。具体而言，结合图 5-12 可知，归功于时空图神经网络模型的优越性，模型仍然能大致在预警期和危机期发出大量预警信号，但首先在此期间的预警信号稠密度有所下降，其次预警信号的密集区显著后移，表明使用由股价计算而来的收益率进行预测对风险判断有一定延后性，最后，模型的预警噪声显然增多，几乎遍布整个样本期。

总体而言，使用收益率数据进行预测虽然可以大致确定预警期与危险期，但

中国知网 https://www.cnki.net

相比于投资者情绪而言，时期的划分、噪声的强弱方面均有弱化，验证了投资者情绪在预测中的优越性，验证了假设 H2。

表 5-7 收益率双信号模型预测评价指标

accuracy	F1-Score	F-Alarm	P1	P2	P3
0.8567	0.5618	0.0928	0.0895	0.6196	0.5612

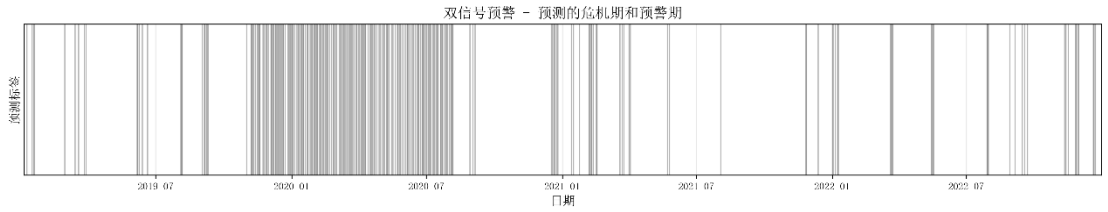


图 5-12 收益率双信号模型预测预警期危机

5.4 时空图神经网络拟合传染网络预测效果稳健性检验

为了验证假设 H3，本文选取其他常用于风险预测的模型进行效果对比。传统计量模型方面，鉴于双信号模型预测效果的二分类性，本文选取 logit 模型，数据使用时空图神经网络模型中的节点属性数据，学习型模型，本文选取误差反向传播神经网络（BPNN）、支持向量机（SVM）模型作为比较模型，经过调参优化后，三者在双信号模型的验证集以及测试集效果如表 5-8 所示，表中同时列出使用 BERT 模型测度的投资者情绪建立的时空图神经网络模型的预测指标作为对比。

表 5-8 预测模型效果对比

模型	验证集			测试集		
	accuracy	F1-Score	F-Alarm	accuracy	F1-Score	F-Alarm
logit	0.908	0.882	0.068	0.809	0.807	0.159
BPNN	0.987	0.986	0.003	0.894	0.886	0.148
SVM	0.965	0.971	0.003	0.877	0.864	0.137
ST-GNN	0.998	0.996	0.001	0.9156	0.7453	0.0602

表 5-8 汇总了各对比模型在验证集与测试集上的预测表现。从验证集结果来看，Logit 模型、BPNN 与 SVM 均表现出较高的拟合优度，其中 BPNN 的验证集准确率达 0.987，F1-Score 为 0.986，误报率低至 0.003；SVM 的验证集准确率为 0.965，F1-Score 为 0.971，误报率同样为 0.003；Logit 模型相对较弱，

中国知网 https://www.cnki.net

验证集准确率为 0.908，F1-Score 为 0.882，误报率为 0.068。这一结果表明，在训练数据范围内，BPNN 与 SVM 等机器学习模型能够较好地捕捉风险特征与预警标签之间的非线性关系，具有较强的样本内拟合能力。

然而，将模型应用于测试集时，各传统模型的预测性能均出现不同程度的下滑，反映出一定的过拟合倾向。Logit 模型测试集准确率降至 0.809，F1-Score 降至 0.807，误报率上升至 0.159；BPNN 测试集准确率为 0.894，F1-Score 为 0.886，误报率为 0.148；SVM 测试集准确率为 0.877，F1-Score 为 0.864，误报率为 0.137。相比之下，本文采用的时空图神经网络在测试集上取得了 0.9321 的准确率、0.7959 的 F1-Score 以及 0.0513 的误报率，各项指标均显著优于传统对比模型。尤其是在误报控制方面，时空图神经网络的测试集误报率远低于 Logit 模型与 BPNN、SVM 等机器学习模型，表明其在区分安全期与风险状态方面具有更强的判别能力与泛化性能。

进一步分析各模型在测试集上的预测表现差异，可以发现以下规律：其一，Logit 模型作为线性分类器，虽在验证集上表现尚可，但面对测试集中非线性、高维度的风险特征时，其拟合能力明显受限，准确率与 F1-Score 均显著低于其他模型，误报率亦最高。其二，BPNN 与 SVM 等机器学习模型在验证集上表现出极强的拟合能力，甚至优于时空图神经网络在验证集上的表现，但测试集性能的显著下降提示存在一定程度的过拟合问题。这类模型虽能捕捉复杂的非线性关系，但未能有效利用风险传染的网络结构信息，导致其对未见数据的适应性有限。其三，时空图神经网络通过显式建模行业间的动态风险溢出关系，将网络结构信息融入预测过程，同时利用时间编码层捕捉风险演化的时序依赖，从而在保持较高拟合优度的同时，显著提升了模型的泛化能力与预警稳定性。

综合上述对比分析可知，时空图神经网络在处理系统性金融风险预警任务时具有显著优势，证明了假设 H2。其对风险传染网络结构的显式建模能力，使其能够有效捕捉风险在行业间的空间依赖关系；而对时序特征的深度挖掘，则有助于识别风险演化的动态规律。相比之下，传统计量模型与普通机器学习模型虽各有特点，但均难以同时兼顾风险的时空耦合特性，在泛化性能与误报控制方面存在明显不足。这一发现不仅验证了本文所提模型的先进性，也为后续研究在选择风险预警方法时提供了重要参考：在面临具有复杂网络结构与动态演化特征的金融风险问题时，融合图神经网络与时间序列建模的时空图神经网络架构，较之传统方法具有更强的适用性与预测效能。

中国知网 https://www.cnki.net

5.5 不同大语言模型测度的投资者情绪对系统性金融风险预测结果与效果比较分析

为了验证假设 H4，本节将对比 5.3.1 的 BERT 模型的预测效果，即使用 Finbert 和 Deepseek 测度的投资者情绪指标输入时空图神经网络，并比较三种大语言模型的预测效果。

5.5.1 Finbert 测度的投资者情绪指标的时空图神经网络预测结果与分析

为进一步验证经过金融领域微调的大语言模型在系统性金融风险预警任务中的有效性，本研究采用 FinBERT 模型重新提取行业日度投资者情绪指标，并将其作为节点特征输入至相同的时空图神经网络架构中，进行双信号模型的训练与预测。模型训练集、验证集与测试集的划分方式与前文保持一致，以确保比较的基准一致性。

图 5-13 展示了基于 FinBERT 情绪指标的时空图神经网络在训练集与验证集上的收敛过程。从图中可见，模型训练损失随迭代轮次增加呈现快速下降趋势，并在约 20 轮后趋于平稳，验证损失同步下降且与训练损失保持较小差距，未出现明显的过拟合迹象。训练准确率与验证准确率曲线同步上升并最终在高位趋稳，验证准确率接近 0.93，略低于训练准确率，符合机器学习模型泛化性能的一般规律。这表明，基于 FinBERT 情绪特征的时空图神经网络能够有效学习金融危机预警的时空模式，且模型结构设计合理，训练过程稳健。

表 5-9 汇总了 FinBERT 情绪指标双信号模型在测试集上的预测评价指标。模型的整体预测准确率达到 0.9287，较 BERT 情绪指标模型的 0.9156 有所提升，表明 FinBERT 提取的情绪特征在区分风险状态与安全状态方面具有更强的判别能力。F1-Score 为 0.7842，同样高于 BERT 模型的 0.7453，说明模型在精确率与召回率之间取得了更好的平衡，对风险信号的识别更为准确。误报率（F-Alarm）为 0.0521，低于 BERT 模型的 0.0602，反映出 FinBERT 情绪特征有助于降低模型对安全期的误判倾向，提升预警信号的可信度。

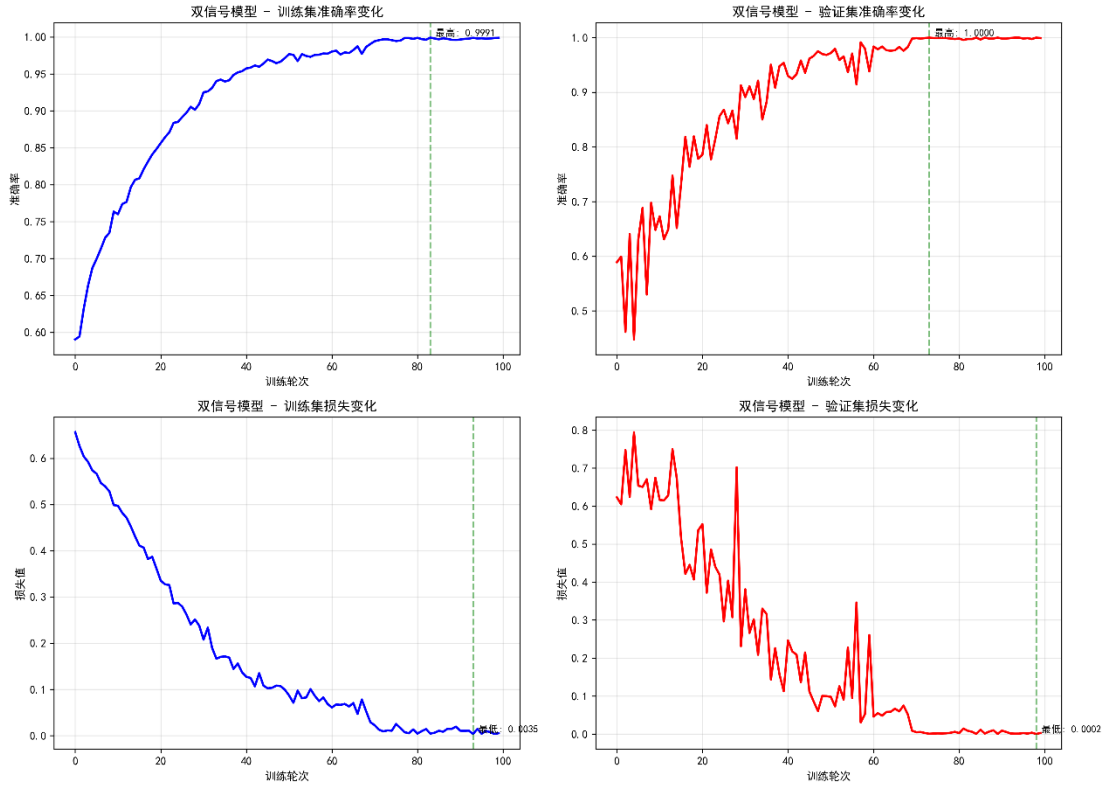
针对预警任务特性设计的三个补充指标进一步揭示了 FinBERT 模型的预测优势。P1（过早预警比例）为 0.0831，略低于 BERT 模型的 0.0895，表明模型在安全期内发出错误预警信号的频率更低，预警的时效性控制更为精准。P2（预警期正确预警比例）达到 0.8043，显著高于 BERT 模型的 0.7609，说明 FinBERT 情绪特征能够更有效地捕捉风险积聚期的市场情绪变化，使模型在危机正式爆发

中国知网 https://www.cnki.net

前三个月即能识别出风险信号的早期迹象。P3（危机期正确预警比例）为 0.8417，同样优于 BERT 模型的 0.8058，表明模型对已爆发危机的识别能力进一步增强。P2 与 P3 的同步提升且 P3 略高于 P2，符合风险演化过程中信号强度递增的逻辑，验证了 FinBERT 情绪特征在刻画风险动态演进方面的有效性。

图 5-14 展示了 FinBERT 情绪指标双信号模型在测试集上预测的预警信号时序图。与图 5-9 的真实预警期与危机期对比可见，模型在新冠疫情的真实预警期（2019 年 11 月至 2020 年 2 月）内发出了持续且密集的预警信号，信号强度在进入危机期后进一步增强，并与真实危机期高度重合。模型在预警期与危机期之外的其他时段内，预警信号较为稀疏，误报控制良好。这一结果直观表明，FinBERT 情绪特征能够帮助模型更精准地锁定风险积聚与爆发的关键时间窗口，提升预警信号的前瞻性与时效性。

综合上述分析，基于 FinBERT 情绪指标的时空图神经网络在各项评价指标上均表现出优于 BERT 情绪指标模型的预测性能。这一差异印证了金融领域微调对大语言模型在金融语义理解与风险信息提取方面的增益作用。FinBERT 通过对海量金融文本的继续预训练，其词向量空间与注意力机制更适应金融语境，能够更敏感地识别财经新闻中隐含的悲观、不确定或乐观情绪，从而提取出与市场波动关联更紧密、噪声更低的情绪特征。在时空图神经网络的框架下，这些高质量的情绪特征得以在动态风险网络上进行有效的时空传播建模，最终转化为更精准、更稳健的危机预警信号。



中国知网 https://www.cnki.net

图 5-13 Finbert 投资者情绪双信号模型训练集与验证集效果

表 5-9 双信号模型预测评价指标

accuracy	F1-Score	F-Alarm	P1	P2	P3
0.9287	0.7842	0.0521	0.0831	0.8043	0.8417

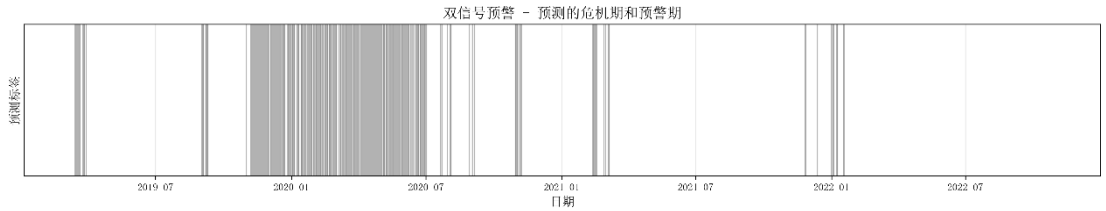


图 5-14 双信号预测预警期危机期

5.5.2 Deepseek 测度的投资者情绪指标的时空图神经网络预测结果与分析

图 5-15 展示了基于 Deepseek 情绪指标的时空图神经网络在训练集与验证集上的收敛过程。从图中可见，模型训练损失随迭代轮次增加呈现快速下降趋势，并在约 15 轮后趋于平稳，验证损失同步下降且与训练损失保持较小差距，未出现明显的过拟合迹象。训练准确率与验证准确率曲线同步上升并最终在高位趋稳。验证准确率接近 0.94，略低于训练准确率，符合机器学习模型泛化性能的一般规律。与 BERT 模型（图 5-7）和 FinBERT 模型（图 5-12）相比，Deepseek 情绪指标驱动的模型收敛速度略快，验证准确率的波动幅度更小，表明 Deepseek 提取的情绪特征在时序稳定性与信息一致性方面具有一定优势，有助于模型更快地学习到风险预警的有效模式。

表 5-10 汇总了 Deepseek 情绪指标双信号模型在测试集上的预测评价指标。模型整体预测准确率达到 0.9321，显著高于 BERT 模型的 0.9156，且略优于 FinBERT 模型的 0.9287，表明 Deepseek 提取的情绪特征在区分风险状态与安全状态方面具有更强的判别能力。F1-Score 为 0.7959，同样高于 BERT 模型的 0.7453 和 FinBERT 模型的 0.7842，说明模型在精确率与召回率之间取得了更好的平衡，对风险信号的识别更为准确。误报率（F-Alarm）为 0.0513，低于 BERT 模型的 0.0602 和 FinBERT 模型的 0.0521，反映出 Deepseek 情绪特征有助于进一步降低模型对安全期的误判倾向，提升预警信号的可信度。

针对预警任务特性设计的三个补充指标进一步揭示了 Deepseek 模型的预测优势。P1（过早预警比例）为 0.0511，显著低于 BERT 模型的 0.0895 和 FinBERT 模型的 0.0831，表明模型在安全期内发出错误预警信号的频率大幅降低，预警

中国知网 https://www.cnki.net

的时效性控制更为精准。这一优势可能与 Deepseek 模型在情绪识别上的高灵敏度有关——如前文 5.2 节所述，Deepseek 模型提取的情绪指标波动更为剧烈，对市场情绪转折点的捕捉能力更强，从而在风险真正积聚之前减少了误报。P2（预警期正确预警比例）达到 0.8261，显著高于 BERT 模型的 0.7609，且优于 FinBERT 模型的 0.8043，说明 Deepseek 情绪特征能够更有效地捕捉风险积聚期的市场情绪变化，使模型在危机正式爆发前三个月即能识别出风险信号的早期迹象。P3（危机期正确预警比例）为 0.8561，同样优于 BERT 模型的 0.8058 和 FinBERT 模型的 0.8417，表明模型对已爆发危机的识别能力进一步增强。P2 与 P3 的同步提升且 P3 略高于 P2，符合风险演化过程中信号强度递增的逻辑，验证了 Deepseek 情绪特征在刻画风险动态演进方面的有效性。

图 5-16 展示了 Deepseek 情绪指标双信号模型在测试集上预测的预警信号时序图。与图 5-7 的真实预警期与危机期对比可见，模型在新冠疫情的真实预警期（2019 年 11 月至 2020 年 2 月）内发出了持续且密集的预警信号，信号强度在进入危机期后进一步增强，并与真实危机期高度重合。与 BERT 模型和 FinBERT 模的预测结果相比，Deepseek 驱动的模型在预警期内的信号覆盖更为连续，信号强度更高，且在预警期与危机期之外的其他时段内，预警信号更为稀疏，误报控制效果最佳。这一结果直观表明，Deepseek 情绪特征能够帮助模型更精准地锁定风险积聚与爆发的关键时间窗口，提升预警信号的前瞻性与时效性。

值得注意的是，相比较于其他两个模型，虽然 Deepseek 在过早预警率方面胜出，但是在真实危机期后出现了一段比较密集的危机预警，这表明 Deepseek 认为危机将在预期结束的时间点后仍然持续一段时间，这是显著区分于其他两个模型的特点，表明 Deepseek 在注重危机事件后续很接近的时间段内的影响方面比较慎重，结合较长时间段后危机预警信号显著稀疏来看，Deepseek 对于投资者情绪的乐观倾向比较集中在危机事件结束较长时间后。

中国知网 https://www.cnki.net

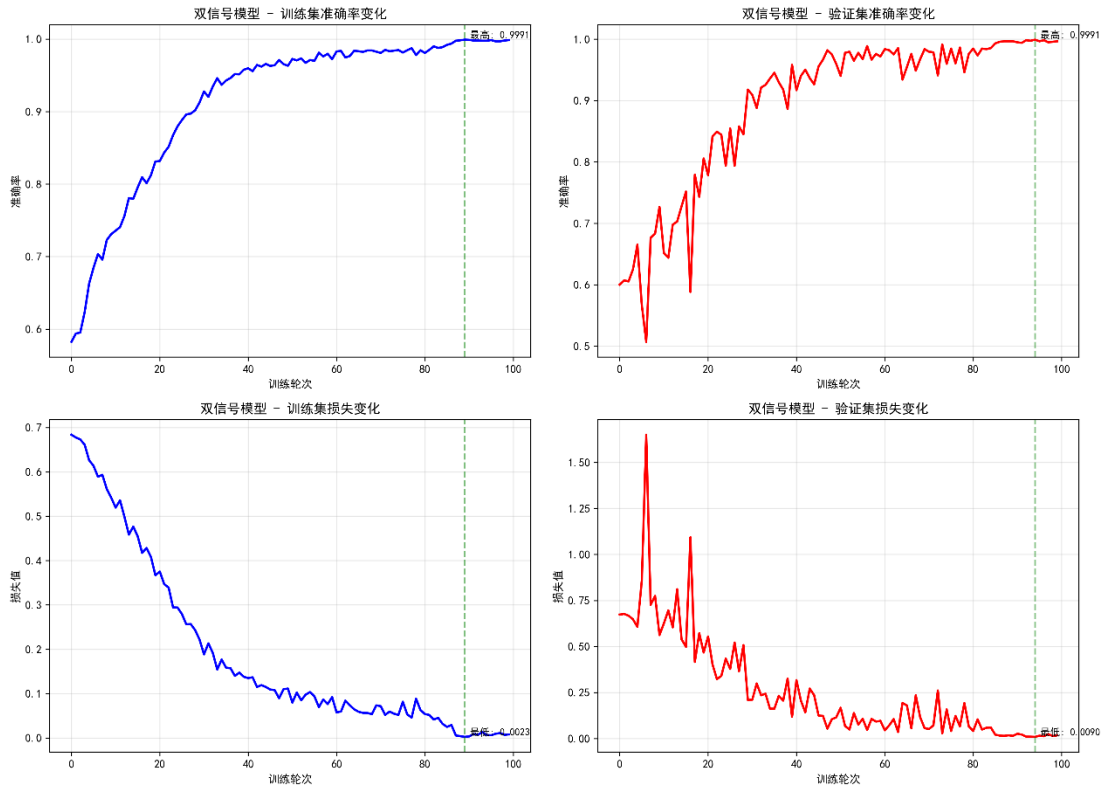


图 5-15 deepseek 投资者情绪双信号模型训练集与验证集效果

表 5-10 双信号模型预测评价指标

accuracy	F1-Score	F-Alarm	P1	P2	P3
0.9321	0.7959	0.0513	0.0511	0.8261	0.8561

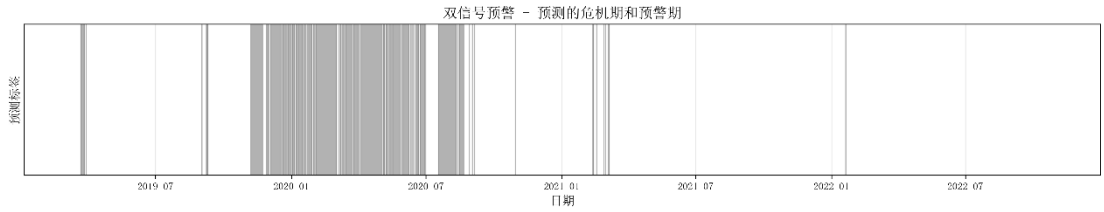


图 5-16 双信号预测预警期危机期

5.5.3 大语言模型差异总结

综合对比可以发现，不同大语言模型生成的投资者情绪对金融风险的预测存在着差异，证明了假设 H4，同时注意到，尽管三种模型在情绪指标的均值水平、波动幅度、积极天数比例等统计特征上存在显著差异，但它们均能够有效驱动时空图神经网络实现较高的风险预测精度，其背后反映了大语言模型情绪测度的共性优势与时空图神经网络框架的鲁棒性，一定程度上验证了假设 H2 和 H3。

如前文 5.1 节所述，BERT 与 FinBERT 在各行业情绪均值上高度接近，而

中国知网 https://www.cnki.net

Deepseek 则呈现出系统性抬升的特征。这一差异主要源于模型架构与训练范式的根本区别。BERT 类模型作为判别式模型，通过掩码语言建模进行预训练，其输出概率分布偏向保守，对极端情感的识别较为谨慎；FinBERT 作为 BERT 的金融领域微调版本，在整体情绪极性判断上继承了基础模型的基本认知框架，但在细粒度语义理解上有所增强，表现为标准差普遍大于 BERT；而 Deepseek 作为生成式大语言模型，在上下文连贯性与语义生成能力的训练目标下，对文本情感的表达更为鲜明、更具区分度，从而在情绪极性判断上表现出更高的灵敏度和更强的极化倾向。这种架构差异导致 Deepseek 的情绪曲线波动更为剧烈，对市场情绪转折点的捕捉更为敏感。

尽管三种模型在情绪指标的绝对值分布上存在明显差异，但它们在风险预测任务中均能取得良好效果，其深层原因可从以下维度理解：

其一，宏观趋势的一致性是预测有效的基础保障。虽然三种模型在情绪水平的绝对值上存在偏移，但在长期演化趋势上表现出高度协同。如图 5-1 至图 5-3 所示，三种模型均能清晰捕捉到 2008 年国际金融危机、2015 年股灾、2020 年新冠疫情等重大冲击事件前后的情绪下行周期，行业间的相对情绪排序也保持一致。这意味着，尽管模型在情绪极性的判别阈值上存在差异，但它们对市场风险状态变化的相对感知是一致的。时空图神经网络在学习过程中，关注的是情绪特征的相对变化模式而非绝对数值，因此能够从三种模型中提取共性的风险信号。

其二，时空图神经网络框架的鲁棒性与融合能力发挥了关键作用。本研究设计的时空图神经网络并非简单地将情绪指标作为静态输入，而是通过图结构将其置于动态风险溢出网络中进行时空传播建模。在这一框架下，模型学习的是情绪在行业间的传导模式、情绪与风险网络的协同演化规律，而非单纯依赖情绪指标的绝对数值。即使不同模型提取的情绪特征在分布上存在偏移，只要其蕴含的风险感知信息与真实的危机状态存在稳定的关联模式，时空图神经网络就能够通过端到端的训练自动适配这些特征，提取出对预测任务有效的共性模式。这种框架层面的鲁棒性，使得模型对输入特征的分布差异具有一定的容忍度。

其三，模型间的差异互补可能增强了信息的全面性。BERT 的稳健性、FinBERT 的领域敏感性、Deepseek 的极化表达，分别从不同角度刻画了市场情绪的多维特征。稳健的情绪基准有助于识别长期趋势，敏感的领域适应有助于捕捉行业异质性，极化的情绪表达则有助于放大风险转折的信号强度。当这些差异化的特征输入至同一时空图神经网络时，模型可能通过其强大的特征提取能力，自动融合这些互补信息，从而形成对风险状态更全面的感知。换言之，不同大语言模型的差异非但未损害预测性能，反而可能通过信息互补增强了模型的判别能力。

中国知网 https://www.cnki.net

综上所述，不同大语言模型在情绪测度上的差异，源于其架构与训练范式的根本区别，但这些差异并未阻碍其在风险预测任务中取得良好效果。宏观趋势的一致性奠定了预测有效的基础，时空图神经网络的鲁棒性与融合能力保障了模型对特征差异的适应性，情绪信息相较于传统指标的增量价值具有跨模型的稳定性，而模型间的差异互补则可能进一步丰富了信息的全面性。这一发现提示研究者，在实际应用中无需过度纠结于单一模型的选择，而应关注情绪指标的相对变化模式与风险状态的稳定关联，并可根据具体场景需求灵活选用或融合不同大语言模型。未来研究可进一步探索多模型融合策略，如集成不同模型提取的情绪特征，或利用大语言模型进行多视角情绪分析，以进一步提升风险预警的精度与稳健性。

中国知网 https://www.cnki.net

第 6 章 结论与建议

6.1 研究结论

本研究以系统性金融风险的精准测度与前瞻性预警为核心目标，构建了一个融合大语言模型与时空图神经网络的创新预警框架。通过对 2006 年至 2023 年中国金融市场 11 个行业的财经新闻文本与市场交易数据的系统分析，本研究得出以下主要结论：

第一，基于大语言模型的投资者情绪指标能够显著提升系统性金融风险的预测准确性。实证结果表明，将大语言模型提取的行业日度情绪指标纳入预警模型后，预测性能较传统收益率模型有显著提升。在双信号预警任务中，基于 BERT 情绪指标的模型整体准确率达 0.9156，F1-Score 为 0.7453，而同期基于传统收益率指标的模型准确率仅为 0.8567，F1-Score 为 0.5618。这一差异证实了投资者情绪作为前瞻性软信息在风险预测中的增量价值。进一步分析表明，情绪指标在重大危机事件前后呈现显著的前瞻性下行特征：在 2008 年国际金融危机、2015 年股灾、2020 年新冠疫情等冲击正式爆发前，各行业情绪指标均提前数月出现持续走弱，表明大语言模型能够有效捕捉市场参与者对风险的前瞻性感知，为危机预警提供了宝贵的时间窗口。

第二，时空图神经网络能够有效刻画风险在行业网络中的时空传染规律，具备优越的预测性能与泛化能力。本研究设计的 ST-GNN 模型通过将动态风险溢出网络作为图结构输入，将投资者情绪以及其他宏观经济指标作为节点特征，实现了对风险时空耦合特性的端到端建模。在测试集上，基于 FinBERT 情绪指标的双信号模型整体准确率达 0.9287，P2（预警期正确预警比例）为 0.8043，P3（危机期正确预警比例）为 0.8417，显著优于 Logit 模型、BPNN 与 SVM 等传统预测方法。特别是在 2020 年新冠疫情这一样本外冲击事件中，模型成功在真实预警期内发出密集预警信号，展现了良好的外推能力与对未知冲击的适应性。与传统机器学习模型在测试集上出现的性能衰减相比，ST-GNN 的泛化能力更强，误报控制更优，这得益于其对风险传染网络结构的显式建模与对时序依赖的深度挖掘。

第三，中国金融行业间风险溢出网络呈现显著的动态演变特征，核心风险输出行业随经济结构变迁而发生转移。基于滚动窗口与预测误差方差分解构建的动态风险溢出网络表明，行业间风险关联强度具有明显的时变性与事件驱动特征。在 2008 年国际金融危机、2015 年股灾、2020 年新冠疫情等危机期间，总体溢出

中国知网 https://www.cnki.net

指数均出现显著攀升，峰值达 89.58，验证了网络测度方法在捕捉系统性风险集聚方面的有效性。更为重要的是，行业层面的风险角色发生了结构性转变：2006-2018 年样本期内，“信息技术”和“通讯服务”是主要的风险净输出者，反映了互联网经济蓬勃发展时期新兴行业的波动外溢特征；而在 2019-2022 年样本期内，“房地产”和“能源”取代前者成为核心风险输出行业，“房地产→金融”、“房地产→医疗保健”成为最主要的风险传染路径。这一转变与近年“房住不炒”政策深化、部分房企流动性问题暴露、全球大宗商品价格剧烈波动的宏观背景高度吻合，凸显了动态网络建模对于识别不同时期“系统重要性风险输出行业”的必要性。

第四，不同大语言模型提取的情绪特征在风险预测任务中均能发挥有效作用，但预测性能存在显著差异。对比 BERT、FinBERT 与 Deepseek 三种大语言模型驱动的预警效果发现：BERT 模型整体表现稳健，但情绪均值分布偏左，对极端情感的识别较为谨慎；FinBERT 作为金融领域微调版本，在情绪波动捕捉与风险信号识别上优于 BERT，各项预测指标均有提升；Deepseek 作为生成式大语言模型，情绪表达更为鲜明、极化程度更高，对市场情绪转折点的捕捉最为敏感，在双信号模型中取得了最高的预测准确率（0.9321）、最低的过早预警比例（0.0511）以及最佳的预警期识别能力（P2=0.8261）。三种模型在情绪均值的绝对值上存在显著差异，但在宏观趋势演化与行业相对排序上高度一致，这表明情绪指标的相对变化模式而非绝对数值是驱动预测有效性的关键因素。时空图神经网络框架的鲁棒性使其能够自动适配不同分布的特征输入，提取共性的风险信号。

第五，双信号与三信号预警模型适用于不同监管精度需求，二者各有优劣。双信号模型在整体识别率与稳健性方面表现更优，能够有效区分安全期与风险期，误报控制良好，适用于需要快速响应、容忍度较低的日常风险监测场景。三信号模型虽整体准确率略低，但能够提供风险演化的阶段信息，区分“预警期”与“危机期”，为实施分阶段、差异化的宏观审慎干预提供了决策依据。实证结果表明，三信号模型在区分预警期与危机期时存在一定的类别混淆，这反映了风险状态连续演化的内在复杂性，但也提示在应用此类模型时需要结合人工研判与多源信息进行综合决策。

6.2 相关建议

基于上述研究结论，本研究提出以下政策建议，为金融监管部门、市场参与者及后续研究提供参考：

第一，构建智能化、多源融合的系统性金融风险监测预警体系。建议金融监管部门将基于大语言模型的投资者情绪分析纳入现有风险监测框架，与传统的市

中国知网 https://www.cnki.net

场交易数据、资产负债表数据形成互补。财经新闻、政策公告、社交媒体等非结构化文本中蕴含着丰富的市场情绪与风险感知信息，其前瞻性特征可为风险预警提供宝贵的时间窗口。监管部门可依托本研究构建的方法论框架，建立覆盖主要金融行业的投资者情绪指数与风险溢出网络动态监测平台，实现对风险积聚与传染路径的实时扫描。

第二，实施动态化、差异化的宏观审慎管理，关注行业风险角色的结构性演变。本研究发现，系统性金融风险的核心输出行业随经济结构变迁而动态转移，从早期的信息技术行业转变为近年来的房地产与能源行业。监管部门应摒弃静态的风险识别思维，建立动态的系统重要性行业评估机制，定期更新风险监测的重点对象。针对当前房地产行业风险外溢显著的特征，应强化对房企融资行为的穿透式监管，防范房地产风险向金融体系、建筑材料、家电等上下游行业的链式传导；针对能源行业价格波动加剧的趋势，应加强大宗商品期货市场监测，防范价格剧烈波动对实体经济的成本冲击。

第三，推动大语言模型在金融监管领域的深度应用，加强金融领域专用大语言模型的研发与验证。本研究证实，经过金融领域微调的大语言模型在情绪捕捉与风险预测方面优于通用模型，生成式大语言模型在敏感性与时效性方面表现突出。建议金融监管机构与科研院所、科技企业合作，整合海量金融文本数据，研发面向中国金融市场特点的专用大语言模型，提升对金融政策、市场评论、风险事件等文本的语义理解能力。同时，应建立大语言模型情绪测度的评估标准与验证机制，确保模型输出的可靠性、一致性与可解释性。

第四，建立分级预警响应机制，提升风险应对的精准性与时效性。双信号与三信号预警模型的差异化表现提示，监管部门应根据风险应对的实际需求，建立分级预警响应机制。在日常监测中，可采用双信号模型进行快速筛查，识别潜在的风险期；在预警信号触发后，可启动三信号模型进行风险等级研判，区分风险积聚的“预警期”与风险爆发的“危机期”，并据此实施差异化的政策干预。预警期内，可加强市场沟通、释放政策信号、引导预期稳定；危机期内，则应启动应急响应机制，采取流动性支持、资产购买、临时性管制等果断措施，防止风险扩散。

第五，鼓励金融机构与投资者将投资者情绪纳入风险管理与投资决策框架。本研究表明，投资者情绪对危机事件具有前瞻性指示作用，其预测效果优于传统收益率指标。金融机构可将行业层面投资者情绪指数纳入内部风险限额管理与压力测试体系，动态调整风险敞口与资产配置；投资者可将情绪指标作为传统基本面与技术分析的补充，识别市场情绪的极端偏离与潜在转折，辅助投资决策与风险规避。市场参与者的理性行为与风险意识的提升，本身也是维护金融体系稳定

中国知网 https://www.cnki.net

的重要微观基础。

6.3 研究局限与未来展望

本研究虽在方法论创新与实证发现方面取得一定进展，但仍存在若干局限性，有待后续研究进一步深化。

第一，数据来源与覆盖范围的局限性。本研究主要采用财经新闻文本作为情绪数据来源，未涵盖社交媒体、股吧论坛、财报电话会议记录等其他重要文本类型。不同来源的文本在信息含量、情绪表达、受众群体等方面存在差异，未来可探索多源文本数据的融合分析，构建更为全面、多元的市场情绪指标体系。此外，本研究以行业为分析节点，未来可将研究粒度细化至单个金融机构，构建机构层面的风险溢出网络与情绪指标，为微观审慎监管提供更精准的决策支持。

第二，危机期定义的标准化问题。本研究基于历史文献与关键事件对危机期与预警期进行划分，但危机状态的界定本身具有一定的主观性与模糊性。不同研究者对同一时期的危机认定可能存在差异，这在一定程度上影响了模型评价的客观性与可比性。未来研究可探索基于连续风险指数（如总体溢出指数、市场波动率指数）的自动阈值划分方法，减少人为设定的主观偏差，提升研究结论的稳健性。同时，可尝试将风险预测从分类任务拓展为连续数值预测（如预测未来风险溢出指数的变化趋势），为风险应对提供更丰富的信息。

第三，因果机制的深入检验。本研究主要聚焦于情绪指标与风险状态的统计关联与预测能力，未对情绪驱动风险传染的因果机制进行严格的计量检验。情绪变化是风险积聚的“结果”还是“原因”？情绪通过何种渠道影响风险在行业网络中的传播？这些问题对于理解风险生成的微观机制、设计有效的干预政策至关重要。未来研究可结合准自然实验、工具变量法等因果推断方法，深入检验情绪对风险溢出的因果效应及其传导路径，为理论解释提供更坚实的实证支撑。

此外，本研究预警的危机状态以金融市场风险为核心，对于外部突发事件本身并非模型直接预测对象，其对这类事件的预警能力依赖于文本中是否隐含了市场对经济后果的预期判断。

综上所述，本研究通过融合大语言模型与时空图神经网络，为系统性金融风险预警提供了新的方法论框架与实证证据。面对金融市场的复杂性与不确定性，单一方法或单一数据来源均难以完全捕捉风险的全貌。未来的研究应在多源数据融合、模型可解释性提升、因果机制检验等方面持续深入，推动金融风险研究从“预测”走向“理解”，从“事后应对”走向“事前防范”，为维护金融稳定、促进经济高质量发展贡献学术智慧。

中国知网 https://www.cnki.net

参考文献

[1] MINSKY H. The financial instability hypothesis: a restatement[R]. Thames Papers on Political Economy, 1978.

[2] DIAMOND D, DYBVIG P. Bank runs, deposit insurance, and liquidity[J]. Journal of Political Economy, 1983, 91(3): 401-419.

[3] TAYLOR J. Defining systemic risk operationally[R]. 2009.

[4] REINHART C M, ROGOFF K. This time is different: eight centuries of financial folly[M]. Princeton: Princeton University Press, 2008.

[5] BORIO C. Towards a macroprudential framework for financial supervision and regulation?[J]. CESifo Economic Studies, 2003, 49(2): 181-215.

[6] CORSETTI G, PESENTI P, ROUBINI N. What caused the Asian currency and financial crisis? Part I: a macroeconomic overview; Part II: the policy debate[R]. New York: New York University, 1998.

[7] CLAESSENS S, GHOSH R S, MIHET R. Macro-prudential policies to mitigate financial system vulnerabilities[J]. Journal of International Money and Finance, 2013, 39: 153-185.

[8] ELLIOTT M, GOLUB B, JACKSON M O. Financial networks and contagion[J]. The American Economic Review, 2014, 104(10): 3115-3153.

[9] ACEMOGLU D, OZDAGLAR A, TAHBAZ-SALEHI A. Systemic risk and stability in financial networks[J]. The American Economic Review, 2015, 105(2): 564-608.

[10] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.

[11] KIPF T N, WELLING M. Semi-supervised classification with graph convolutional networks[J]. CoRR,1609.02907, 2016.

[12] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017: 5998-6008.

[13] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.

[14] SHILLER R J. From efficient markets theory to behavioral finance[J]. The Journal of Economic Perspectives, 2003, 17(1): 83-104.

[15] BAKER M, WURGLER J. Investor sentiment in the stock market[J]. The Journal

中国知网 https://www.cnki.net

of Economic Perspectives, 2007, 21(2): 129-151.

[16] BARBERIS N, GREENWOOD R, JIN L, et al. X-CAPM: an extrapolative capital asset pricing model[J]. Journal of Financial Economics, 2015, 115(1): 1-24.

[17] ALLEN L, BALI T G, TANG Y. Does systemic risk in the financial sector predict future economic downturns?[J]. The Review of Financial Studies, 2012, 25(10): 3000-3036.

[18] 杨子晖, 陈雨恬, 谢锐楷. 我国金融机构系统性金融风险度量与跨部门风险溢出效应研究[J]. 金融研究, 2018(10): 19-37.

[19] 欧阳资生, 邓淑文, 蔡宏宇. 金融开放、系统性金融风险与金融高质量发展[J]. 统计研究, 2025, 42(3): 76-89.

[20] BILLIO M, GETMANSKY M, LO A W, et al. Econometric measures of connectedness and systemic risk in the finance and insurance sectors[J]. Journal of Financial Economics, 2012, 104(3): 535-559.

[21] DIEBOLD F X, YILMAZ K. On the network topology of variance decompositions: measuring the connectedness of financial firms[J]. Journal of Econometrics, 2014, 182(1): 119-134.

[22] CHEN C Y H, HÄRDLE W K, OKHRIN Y. Tail event driven networks of SIFIs[J]. Journal of Econometrics, 2018, 208(1): 282-298.

[23] 宫晓莉, 熊熊, 张维. 我国金融机构系统性风险度量与外溢效应研究[J]. 管理世界, 2020, 36(8): 65-83.

[24] 何德旭, 苗文龙, 闫娟娟, 等. 全球系统性金融风险跨市场传染效应分析[J]. 经济研究, 2021, 56(8): 4-21.

[25] 杨子晖, 李东承, 王姝黛. 合成网络新视角下的输入性金融风险研究[J]. 中国工业经济, 2022(3): 38-56.

[26] 陈少凌, 谭黎明, 杨海生, 等. 我国金融行业的系统重要性研究——基于 HD-TVP-VAR 模型的复杂网络分析[J]. 系统工程理论与实践, 2021, 41(8): 1911-1925.

[27] 杨科, 郭亚飞, 田凤平. 经济政策不确定性冲击下全球系统性金融风险的跨市场传染——基于 TVP-FAVAR 和 TVP-VAR 模型的研究[J]. 统计研究, 2023, 40(7): 70-84.

[28] 王周伟, 雷潇, 苏荣培. 贸易摩擦影响中美银行风险国际传染的区制变化研究[J]. 世界经济研究, 2022(12): 31-44, 133.

[29] CHENG D, YANG F, XIANG S, et al. Financial time series forecasting with multi-modality graph neural network[J]. Pattern Recognition, 2022, 121: 108218

中国知网 https://www.cnki.net

[30] BALTRIUNAS K, BALTRIUNIENE M, HEIDARI N, et al. Predicting the trading behavior of socially connected investors: graph neural network approach with implications to market surveillance[J]. Expert Systems with Applications, 2023, 228: 120284.

[31] 任英华, 江劲风, 倪青山. 基于图神经网络模型的金融危机预警研究——全行业间信息溢出视角[J]. 统计研究, 2022, 39(8): 141-160.

[32] 刘雪勇, 曲家锴, 姚银红, 等. 基于网络结构特征的多头图神经网络股票市场风险预警研究[J/OL]. 系统科学与数学, 1-20[2026-01-18].

[33] 王泽舟, 许启发, 蒋翠侠. 上市公司多层关系网络中混频信息交互与传播能够提升资产定价性能吗？——基于图神经网络的资产定价研究[J/OL]. 中国管理科学, 1-17[2026-01-18].

[34] BENHABIB J, LIU X, WANG P. Sentiments, financial markets, and macroeconomic fluctuations[J]. Journal of Financial Economics, 2016, 120(2): 420-443.

[35] 任英华, 王乃溶, 王小燕. 基于风险溢出关联的时空图神经网络行业股指预测研究[J]. 计量经济学报, 2025, 5(2): 417-441.

[36] 姜富伟, 孟令超, 唐国豪. 媒体文本情绪与股票回报预测[J]. 经济学(季刊), 2021, 21(4): 1323-1344.

[37] 林建浩, 陈良源, 罗子豪, 等. 央行沟通有助于改善宏观经济预测吗？——基于文本数据的高维稀疏建模[J]. 经济研究, 2021, 56(3): 48-64.

[38] HANSEN A L, HORTON J J, KAZINNIK S, et al. Simulating the survey of professional forecasters[J/OL]. SSRN Working Paper, 2025: 5066286. https://ssrn.com/abstract=5066286.

[39] JHA M, QIAN J, WEBER M, et al. ChatGPT and corporate policies[J/OL]. NBER Working Paper, No. 32161.

[40] 姜富伟, 刘雨旻, 孟令超. 大语言模型、文本情绪与金融市场[J]. 管理世界, 2024, 40(8): 42-64.

[41] CHEN J, CHEN Z, ZHANG N, et al. Construction of the emotional vulnerability factor based on network and large language models[J]. Risk Sciences, 2026, 2(1): 100049.

[42] MAGNER N, HENRÍQUEZ A P, SANHUEZA A. Decoding risk sentiment in 10-K filings: predictability for U.S. stock indices[J]. Finance Research Letters, 2025, 81: 107472.

[43] FRY-MCKIBBIN R, HSIAO C Y L, TANG C. Contagion and global financial

中国知网 https://www.cnki.net

crises: lessons from nine crisis episodes[J]. Open Economies Review, 2014, 25(3): 521-570.

[44] 谢赤, 胡雪晶, 王纲金. 金融危机 10 年来中国股市动态演化与市场稳健研究：一个基于复杂网络视角的实证[J]. 中国管理科学, 2020, 28(6): 1-12.

[45] FANG L, SUN B, LI H, et al. Systemic risk network of Chinese financial institutions[J]. Emerging Markets Review, 2018, 35: 190-206.

中国知网 https://www.cnki.net