管理学硕士学位论文

考虑金融舆情的深度强化学习投资组合研究

刘钦

哈尔滨理工大学

2026 年 6 月

中国知网 https://www.cnki.net

国内图书分类号：F830.59

管理学硕士学位论文

考虑金融舆情的深度强化学习投资组合研究

硕 士 研究生：刘钦

导　　师：田世海

申请学位级别：管理学硕士

学 科、专 业：管理科学与工程

所　在 单 位：经济与管理学院

答　辩 日 期：2026 年 5 月

授予学位单位：哈尔滨理工大学

中国知网　https://www.cnki.net

Classified Index：F830.59

Dissertation for the Master Degree in Management

Research on Portfolio Optimization Based on Deep Reinforcement Learning in the Context of Financial Public Sentiment Analysis

Candidate： Liu Qin

Supervisor： Tian Shihai

Academic Degree Applied for： Master of Management

Speciality： Management Science and Engineering

Date of Oral Examination： May, 2026

University： Harbin University of Science and Technology

中国知网 https://www.cnki.net

考虑金融舆情的深度强化学习投资组合研究

摘　要

移动互联网时代社交媒体与财经新闻平台的海量文本信息使金融舆情呈爆发式增长，其对投资者情绪与股票市场波动的深刻影响日益凸显。然而，传统投资组合理论多依赖于静态模型与线性假设，难以适应复杂多变的动态市场环境。因此，如何有效利用非结构化舆情信息优化投资决策势在必行，将舆情数据与投资组合方法深度融合以实现风险精准把控和收益提升，成为了智能投资研究的关键所在。

鉴于此，本文旨在构建一种融合金融舆情，且兼具动态适应与自主优化能力的智能投资组合模型，从而精准把控市场风险和有效提升投资回报。首先梳理相关文献，剖析舆情通过情绪积累影响资产价格的作用路径。在此基础上构建金融舆情信号生成体系，进行效力分析界定影响力范围，引入基于决策树与模型检测的可信度验证框架甄别舆情质量，采用 FinBERT（financial bidirectional encoder representations from transformers）技术结合大语言模型生成标签进行监督微调以实现情感测度，进而通过热度加权聚合形成综合舆情信号。在模型构建层面，设计融合金融舆情的深度多智能体强化学习投资组合模型。集成基于 Transformer 与卷积神经网络的历史行情特征提取模块，引入多阈值方向性变化方法和遗传算法进行市场趋势预测，通过早融合机制将行情特征与舆情时序特征进行多模态融合。构建包含乐观、均衡、悲观三类风险偏好基智能体的多智能体决策框架，各基智能体均采用独立近端策略优化网络并由差异化奖励函数引导，其输出经集成网络融合后，输入基于风险预算策略的可微凸优化层进行风险约束调整，最终实现资产配置的风险收益平衡。

最后，以沪深 300 指数与道琼斯工业平均指数成份股为标的，选取 2015 年至 2025 年数据，与八种基准模型进行实证对比。结果表明，本文模型在中美市场测试期内年化收益率、夏普比率均显著优于基准模型，且在最大回撤与风险控制方面表现优异。消融实验也验证了多源舆情融合和多智能体结构的有效性。

关键词 投资组合；金融舆情分析；FinBERT；深度强化学习；多智能体系统

中国知网　https://www.cnki.net

Research on Portfolio Optimization Based on Deep Reinforcement Learning in the Context of Financial Public Sentiment Analysis

Abstract

In the era of mobile internet, the massive amount of text information from social media and financial news platforms has led to explosive growth in financial public opinion. Its growing influence on investor sentiment and stock market dynamics has become increasingly apparent. However, traditional portfolio theory often relies on static models and linear assumptions, which makes it challenging to adjust to complex and ever-changing market conditions. Therefore, how to effectively utilize unstructured public opinion information to optimize investment decisions has become a necessity. Deeply integrating public opinion data with portfolio methods to achieve precise risk control and return enhancement has emerged as a key focus in intelligent investment research.

In view of this, this paper aims to construct an intelligent portfolio model that integrates financial public opinion and possesses dynamic adaptation and autonomous optimization capabilities, in order to achieve precise control of market risks and effective improvement of investment returns. Firstly, relevant literature is reviewed to analyze the pathway through which public opinion influences asset prices via the accumulation of sentiment. On this basis, a financial public opinion signal generation system is built. Its sphere of influence is defined through effectiveness analysis. A credibility verification framework based on decision trees and model checking is introduced to filter the quality of public opinion. FinBERT technology, combined with labels generated by large language models, is used for supervised fine-tuning to achieve precise sentiment measurement. Subsequently, comprehensive public opinion signals are formed through weighting aggregation. At

中国知网 https://www.cnki.net

the model construction level, a deep multi-agent reinforcement learning portfolio model integrating financial public opinion is designed. It incorporates a historical market feature extraction module based on Transformer and Convolutional Neural Networks. A multi-threshold directional change method and genetic algorithm are introduced for market trend prediction. Multimodal fusion of market features and public opinion temporal features extracted via Long Short-Term Memory networks is achieved through an early fusion mechanism. A multi-agent decision-making framework is constructed, including three types of base agents with optimistic, balanced, and pessimistic risk preferences. Each base agent uses an independent Proximal Policy Optimization network and is guided by a differentiated reward function. Their outputs are fused by an integration network and then input into a differentiable convex optimization layer based on a risk budgeting strategy for risk constraint adjustment, ultimately outputting asset allocation weights that satisfy the risk-return balance.

Finally, the constituent stocks of the CSI 300 Index and the Dow Jones Industrial Average are selected as the research targets, data from 2015 to 2025 is selected for empirical comparison with eight benchmark models. The findings indicate that the proposed model yields significantly higher annualized returns and Sharpe ratios compared to the benchmark models in both the Chinese and US market test periods, and performs excellently in terms of maximum drawdown and risk control. Ablation experiments also verify the effectiveness of multi-source public opinion fusion and the multi-agent structure.

Keywords portfolio; financial sentiment analysis; FinBERT；deep reinforcement learning; multi-agent system

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景.....1
1.2 研究目的与意义.....2
1.2.1 研究目的.....2
1.2.2 研究意义.....2
1.3 国内外研究现状及评述.....3
1.3.1 传统投资组合研究现状.....3
1.3.2 金融舆情研究现状.....4
1.3.3 深度强化学习投资组合研究现状.....7
1.3.4 国内外研究现状评述.....8
1.4 研究内容与方法.....9
1.4.1 研究内容.....9
1.4.2 研究方法.....11
1.4.3 技术路线.....11
第 2 章 考虑金融舆情的深度强化学习投资组合机理.....13
2.1 考虑金融舆情的深度强化学习投资组合内涵.....13
2.1.1 金融舆情内涵.....13
2.1.2 投资组合内涵.....14
2.1.3 深度强化学习投资组合内涵.....16
2.2 考虑金融舆情的深度强化学习投资组合动因.....17
2.2.1 深度强化学习内部驱动.....17
2.2.2 投资者行为效应内部驱动.....18
2.2.3 资产价格舆情传导外部协同.....20
2.2.4 股票市场舆情传导外部协同.....22
2.3 考虑金融舆情的深度强化学习投资组合要素.....24
2.3.1 投资组合历史行情要素.....24
2.3.2 投资组合金融舆情要素.....25
2.3.3 投资组合建模假设要素.....26
2.4 考虑金融舆情的深度强化学习投资组合流程.....26
2.4.1 金融舆情信号生成流程.....26
2.4.2 深度学习特征识别流程.....28
2.4.3 单智能体强化学习投资决策流程.....30
2.4.4 多智能体强化学习集成决策流程.....33
2.4.5 深度强化学习增强决策流程.....35

中国知网 https://www.cnki.net

2.5 本章小结.....39
第 3 章 考虑金融舆情的深度强化学习投资组合舆情信号生成.....40
3.1 金融舆情效力分析.....40
3.1.1 金融舆情效力判别路径.....40
3.1.2 金融舆情可信度指标构建.....41
3.1.3 金融舆情影响力范围确定.....42
3.2 金融舆情可信度模型检测.....45
3.2.1 金融舆情可信度模型检测框架.....45
3.2.2 金融舆情可信度检测规则建立.....46
3.2.3 金融舆情可信度待检测模型构建.....49
3.2.4 金融舆情可信度模型检测执行.....50
3.3 金融舆情 FinBERT 情感测度.....51
3.3.1 金融舆情 BERT 编码分类.....51
3.3.2 金融舆情 FinBERT 情感识别.....53
3.3.3 金融舆情情感指数计量.....54
3.4 金融舆情信号指数加权聚合.....56
3.4.1 金融舆情热度指数构建.....56
3.4.2 金融舆情热度情感聚合.....56
3.5 本章小结.....57
第 4 章 考虑金融舆情的深度强化学习投资组合模型构建.....58
4.1 投资组合历史行情特征提取.....58
4.1.1 历史行情特征提取网络.....58
4.1.2 行情全局特征提取模块.....59
4.1.3 行情局部特征提取模块.....60
4.1.4 行情市场趋势特征引入.....61
4.2 投资组合金融舆情信号融合.....63
4.2.1 金融舆情信号融合机制.....63
4.2.2 投资组合环境状态集合.....64
4.3 投资组合强化学习智能体决策.....65
4.3.1 投资组合基智能体决策生成.....65
4.3.2 投资组合多智能体决策融合.....68
4.3.3 风险控制智能体协同决策.....71
4.4 投资组合模型结构与算法实现.....72
4.4.1 考虑金融舆情的投资组合模型结构.....72
4.4.2 考虑金融舆情的投资组合模型算法.....74
4.5 本章小结.....75
第 5 章 考虑金融舆情的深度强化学习投资组合实证.....76
5.1 数据准备与预处理.....76

中国知网 https://www.cnki.net

5.1.1 标的股票选取划分.....76
5.1.2 多源股票数据获取.....78
5.1.3 股票数据预处理.....80
5.2 投资组合实证环境及评价基准.....80
5.2.1 实证环境设定.....80
5.2.2 对比模型选择.....81
5.2.3 模型评价标准.....83
5.3 考虑金融舆情的深度强化学习投资组合模型对比分析.....84
5.3.1 中美股市投资组合模型绩效对比.....84
5.3.2 投资组合模型交易策略行为对比.....87
5.3.3 投资组合模型资产数量扩展对比.....89
5.4 考虑金融舆情的深度强化学习投资组合模型消融分析.....90
5.4.1 投资组合模型金融舆情消融分析.....90
5.4.2 投资组合模型多智能体消融分析.....92
5.5 本章小结.....93
结论.....94
参考文献.....96

中国知网 https://www.cnki.net

第1章 绪　论

1.1　研究背景

随着移动互联网的全面覆盖， 2025 年 12 月数据显示，我国网民总数攀升至 11.25 亿，推动互联网普及率达到 80.1%，其中手机上网比例持续增长至 99%以上。相应我国证券市场投资者数量亦呈持续攀升态势，越来越多的人开始关注并参与股票市场，2025 年我国新增投资者超过 900 万，全市场投资者总数突破 2.46 亿，值得注意的是，其中自然人占比高达 99%以上。同时大量的投资者活跃于股吧和微博等社交平台，他们围绕上市公司和行业政策以及市场走势发表观点，并且其生成的内容在互联网上快速扩散，进而形成了规模庞大和情绪鲜明的金融舆情数据。

金融舆情通常包含投资者情绪与关注度信息两个层面，其中情绪表征投资者对市场信息的即时心理反应，关注度则反映其对特定资产或事件的注意力程度。在信息爆炸时代，舆情热度直接决定了其市场影响力。舆情情绪与股票收益率和波动率等市场指标之间也存在显著关联，积极舆情往往伴随资金流入与股价上涨，消极舆情则可能引发恐慌抛售。另一方面，网络舆情鱼龙混杂，常伴随虚假和噪声信息充斥其中，若未经甄别直接使用，可能会误导投资决策。因此如何对金融舆情进行可信度判别，筛选出真正具有信息含量的信号，是构建金融舆情信号的关键环节。同时传统投资组合理论难以合理解释羊群效应与动量反转等市场异象。行为金融学顺势兴起，对传统理论进行修正，揭示了投资者决策并非遵循严格理性，而是在很大程度上受到心理偏差、情绪起伏以及社会互动等复杂因素的交织影响，而金融舆情正是投资者集体心理的外在表征。此外在金融时序分析中，方向性变化方法能够捕捉价格幅度变动进而识别市场趋势转向， FinBERT 预训练语言模型也可以精准测度舆情情感。

与此同时，人工智能技术作为当前全球科技创新发展的最前沿，在我国各个领域数字化转型中扮演了重要角色。2026 年国务院《政府工作报告》明确提出，持续推进“人工智能+”行动，支持大模型广泛应用，将 AI 作为培育新质生产力和激发数字经济活力的关键抓手。深度强化学习兼具深度学习的特征提取能力与强化学习序贯决策优势，在量化交易和投资组合优化等领域具有广阔前景。与传统的先预测后优化的两阶段方法不同，深度强化学习方法凭借智能体与环境的动态交互，将预测与决策集成于一体，从而能够适应复杂的市场变

中国知网 https://www.cnki.net

化，实现端到端的策略优化。然而单一智能体的观察视角相对有限，难以全面应对复杂多变的市场环境。因此本文引入多智能体结构，通过不同风险偏好交易智能体的协同与集成，更有效地适应复杂市场态势，提升投资策略的稳健性。

1.2 研究目的与意义

1.2.1 研究目的

为突破传统投资组合理论在动态市场环境中的局限性，本文融合金融舆情信号和深度多智能体强化学习，通过决策树和模型检测对舆情信息进行自动甄别，并结合 FinBERT 预训练语言模型对舆情文本进行情感测度，进一步设计包含乐观、均衡与悲观三类基智能体在内的多智能体投资框架，同时引入方向性变化方法捕捉价格趋势的关键转折点，将市场趋势信息与舆情信号和历史行情数据深度融合。从而剔除虚假与噪声信息的影响，实现高质量金融舆情信号的提取与聚合以及在上涨、震荡和下跌等复杂市场态势的适应能力，最终构建了考虑角度更综合、优化能力更全面的投资组合模型。

1.2.2 研究意义

（1）理论意义

本文基于金融舆情数据构建了面向投资组合的金融舆情指标体系并加以改进和优化，对于如何有效度量和利用金融舆情进行了梳理和探索。通过文本挖掘和模型检测获取并甄别网络金融文本等非结构化数据，利用预训练大语言模型技术测量出每条信息中投资者的情绪，结合舆情情感和关注度共同构建金融舆情信号，更加全面准确地理解和利用金融舆情，优化投资决策。进而结合多智能体强化学习对投资组合管理问题进行建模，将融合舆情信号的深度策略神经网络作为投资决策智能体。同时对舆情信号和多智能体结构的效果进行消融研究，对比分析了有无金融舆情信号和多智能体结构的投资组合表现，发现引入舆情信号和多智能体结构时投资组合模型表现更好、收益更高，说明了金融舆情信号和多智能体结构的有效性，为融合非结构化舆情信息和强化学习算法的投资组合研究提供了新思路。

（2）实践意义

金融舆情信息可以为不同市场主体提供决策支持。金融机构可以借助金融舆情信息进行监控和研判，了解投资者动向与情绪，制定更为准确的投资决策

中国知网 https://www.cnki.net

和风险管控方案。对于普通投资者而言，金融舆情信息能够为其提供丰富知识和调节情绪的渠道，从而更好把握市场趋势变化，减少非理性行为，提升自身投资决策的质量。此外金融舆情也能够为监管部门提供重要的辅助信息，在系统性风险监测和市场异常波动预警中，反映出投资者情绪的集中变化，帮助监管部门及时采取应对措施，增强金融市场稳定性。因此本文考虑金融舆情构建的深度强化学习投资组合模型来源于现实又回归于现实，具有重要的实践意义。

1.3 国内外研究现状及评述

1.3.1 传统投资组合研究现状

在瞬息万变的金融市场中，如何在风险可控的前提下实现资产的有效增值，始终是投资组合研究的核心命题，更是现代金融理论持续探索的难点。现代投资组合理论之先河是诺贝尔经济学奖得主马科维茨创建的均值-方差模型[1]，其首次利用投资组合的期望收益和协方差进行统计建模，依据风险与收益之间的动态权衡关系，将资金配置于不同类型的资产之中。然而均值方差模型在理论预设上存在明显局限，其对市场环境的刻画过度依赖理想化假定，对输入数据较为敏感，模型效度高度依赖于资产收益率及其协方差矩阵的精确估计，同时输出结果不稳定。因此大量学者开始对模型的改进完善进行了深入研究。

（1）传统投资组合策略演进

考虑投资预期收益率的决定因素，套利定价理论和资本资产定价模型分别被创立提出[2-3]。同时为捕捉资产收益率的非对称分布特征, 学者们尝试引入偏度、峰度等高阶矩信息，其中 Lai 系统研究了引入偏度约束后的投资组合优化问题[4]。为克服传统方差在度量风险上的不足，半方差被学界引入作为风险测度指标，精准刻画资产收益的下行波动，并由此构建了均值-半方差投资组合模型[5-9]。基于此 Mandal 等进一步在投资组合问题中探讨了用广义半方差-低阶偏矩替代传统方差风险度量的可能性[10]。均值-绝对偏差模型形式简洁，保留了均值-方差模型的优势且可向线性规划转化，获得了广泛关注。Federica 等和曾永泉等研究了基于均值-半绝对偏差的投资组合模型[11-12]，通过测算实际收益率低于期望收益率的绝对偏差，对组合下行风险进行了更具体的刻画。除以均值-方差为核心的分析框架外，还衍生出了基于风险度量改进的优化模型。Ahna 等学者考虑了在静态条件下如何实现在险价值 VAR 最小化问题[13]。张鹏等提出一致性均值-CVaR 可信性投资组合模型，以一致性模糊数刻画资产收益率，并将 V

中国知网 https://www.cnki.net

型交易成本与借贷约束纳入模型框架[14]。此外投资组合也与统计学持续融合，其中 Black-Litterman 模型开创性将贝叶斯先验思想引入资产配置，实现了主观观点与客观均衡的有机结合[15]，Sahamkhadam 等进一步将 Copula 模型嵌入该框架，有效克服了其对资产收益正态分布假设的依赖[16]。

（2）多目标动态投资组合策略进展

区别于传统均值-方差模型追求单一最优解，多目标优化更侧重于对投资决策多维权衡，寻求收益与风险乃至更多目标之间的动态平衡。Korotkov 与 Wu 引入帕累托精度函数作为帕累托最优解的判别准则，有效提升了投资策略的稳健性[17]。侯胜杰等则从算法求解角度切入，借助粒子群智能优化算法，实现了对熵-CVaR 多目标模型的有效求解[18]。李鹤等则在可信性框架下，将损失厌恶心理、资产流动性以及下方风险同时纳入考量，构建了一种基于目标优先级的多目标模糊投资组合模型[19]。另一方面针对传统均值-方差模型的静态局限性，学者们开始进行动态化改进。借助 GARCH 族模型对市场波动率的刻画能力，Díaz 与 Esparcia 将时变风险厌恶参数引入投资组合，实现了资产配置策略随市场情绪同步调整的动态优化[20]。周春阳等引入方差波动率资产，推导出动态最优投资组合的显式解，发现方差波动率是影响组合权重的重要状态变量[21]。同时金融资产收益往往呈现显著的随机波动特征，促使学者们开始聚焦于不确定性条件下的投资组合决策问题。Zhang 等运用模糊数区间近似方法构建投资组合目标规划模型，讨论了区间数方法在投资组合选择中的应用路径[22]。周晓光等则在犹豫模糊语言环境中构建投资组合，避免了评价过程中信息丢失问题[23]。因此经过持续演进与拓展，投资组合研究已经形成了较为系统的理论体系。

1.3.2 金融舆情研究现状

（1）金融舆情基础理论演进

行为金融学主要考虑投资者心理等要素，是金融舆情分析的重要理论基础。20 世纪 80 年代以来，一系列金融市场异象表明传统金融理论还不够完善，其将投资者视为绝对理性的决策主体，并假设股价能随机反映新信息，然而学者证实股价变动并非完全遵循随机游走[24-25]。行为金融学认为投资者决策必然受舆情情绪影响，外部市场情绪激发认知偏差会导致公司价值感知波动，舆情情绪驱动的价值判断最终会传导至股票市场价格[26-28]。同时投资者对自己预测未来股票能力过于自信，存在从众行为。国内对于行为金融学理论研究亦涌现出诸多成果。以新冠疫情引发的注意力分散为切入点，李晓等探究了投资者有限关

中国知网 https://www.cnki.net

注如何在个股层面影响市场定价效率，实证表明当某只股票的关注程度降低时，其收益率将更紧密地追随市场整体走势，即股价同步性显著上升[29]。李伯华等将股市参与者划分为理性、非理性与有限理性三种类型，并研究了这三类投资者在市场中的动态演化过程，结果发现投资者整体理性结构呈现出动态均衡特征，且非理性投资者的存在具有市场必要性[30]。

（2）金融舆情影响机制研究

金融舆情中蕴含投资者情绪信息，在股价走势和股票收益等多方面影响投资组合。现有研究主要围绕两条路径展开。其一论证了投资者情绪作用及其与股市指标的相关关系。Tetlock 揭示了舆情新闻的影响作用[31]，进而大量学者开始研究舆情与股市趋势的相关性。Fang 等将百度指数作为投资者情绪变量引入 GARCH 模型，发现其能改善股市波动率预测精度[32]；游家兴和吴静研究发现，在信息不对称程度较高的公司中，媒体情绪会显著加剧股价对其基本面价值的偏离[33]；陈镇喜等基于投资者异质性发现，公司特质信息等金融舆情融入会显著减弱股价同步性[34]；李少育等检验了投资者情绪和异质信念与波动率等市场微观结构变量的关联，论证了金融舆情对市场崩盘风险的影响机制，发现金融舆情与累计收益率正相关，与波动率和非流动性负相关[35]。其二是探究舆情对投资者行为的塑造及其市场效应。Cookson 基于 StockTwits 数据研究证实，在线投资者情绪对日内股指回报具有显著预测能力[36]；姚尧之等发现混频情绪的引入能够有效解释股市收益率与波动的联动变化[37]；张宗新等研究发现媒体乐观情绪会正向影响分析师的盈利预测，进而影响股价波动[38]；相反 Tetlock 则通过构建媒体悲观情绪指标，证实负面舆情是诱发市场指数下行的关键因素[31]。

（3）金融舆情投资组合应用

金融舆情中的投资者状况和市场信息与股市数据形成天然的优势互补，基于此大量学者开始引入多模态学习框架以整合舆情与股市数据等多源异构数据，从而实现更精确的投资分析。Lee 等通过多模态深度学习技术将非结构化信息融入股票预测模型，显著提升了模型性能[39]。Li 等提出事件驱动的多模态 LSTM 模型，有效解决了多模态数据采样时间异质性问题[40]。Sawhney 团队则开发了结合领域专用文本特征和音频注意力对齐的多任务框架，并成功应用于金融风险与价格联合建模[41]。同时部分学者开始尝试将多模态策略应用到投资组合建模中。Xing 利用贝叶斯网络和 Black-Litterman 模型构建投资组合框架，首创 ECM-LSTM 预期收益学习机制和情感计算的句级分析[42]；Koyano 等运用基于股票微博半监督学习策略的跟输反买模型实现累计收益最大化[43]；Cambria 等提出情感极性检测框架，通过符号逻辑加强了投资组合的逻辑推理能力[44]。

中国知网 https://www.cnki.net

（4）金融舆情情感分析现状

文本情感分析技术近年来飞速发展，在金融舆情研究中应用广泛，其主要分析方法包括词典法、机器学习和大语言模型三类[45-46]。

词典法通过统计文本中积极与消极词汇频次度量情感。早期研究多采用 Harvard IV-4 等通用词典，但其金融领域适用性有限，进而学者相继构建了 Henry 词典及影响力广泛的 LM 词典[47-48]。在中文语境下，通用情感词典也因语料来源非金融领域而存在偏差。针对该问题，姜富伟等结合 word2vec 模型和 LM 词典构建了中文金融情绪词典[49]；姚加权等基于词典重组和深度学习构建了适用于年报和社交媒体的专用情感词典[50]；范小云等基于新闻报道和股吧舆情构建了混合情绪词典[51]。词典法的核心在于词汇的情感极性和规则组合，具有可重复使用的优点，但难以处理词汇歧义及上下文特征。

机器学习法将情感分析视为文本分类问题，判别文本的积极或消极情绪概率，利用大量文本数据进行训练，建立文本情感与情感评级之间的映射关系。Santi 运用朴素贝叶斯方法对推特发帖进行情绪判断，实现了较高的样本内外准确率[52]。Audrino 等采用最大熵法对 StockTwits 平台发帖进行分类，同样取得了高样本外表现[53]。张宗新等运用朴素贝叶斯分类器对上市公司百度新闻报道进行情感测算，结果表明媒体情绪对分析师乐观偏差存在显著影响[54]。钱宇等比较了支持向量机和随机森林等多种分类器对股吧评论的情绪分类效果，发现卷积神经网络分类效果最好[55]。相较于词典法，机器学习法能够自动感知舆情文本情感，并结合词语情感推测语句情感。机器学习的缺点也较为明显，其依赖大量含情绪人工标注语料，且分类精度受训练数据规模和算法选择的显著影响。

大语言模型（Large Language Models，LLMs）是一类基于深度学习的自然语言处理模型，凭借海量语料预训练与深层网络架构，使其能够通过轻量化微调即可实现出色的下游任务表现[56]。LLMs 也为金融领域挖掘非结构化数据、开展情感分析提供了全新的研究视角，广泛应用于投资组合和风险管理研究[57]。其中以 GPT、BERT 为代表的模型通过预训练与微调，能够有效捕捉金融文本中的语义与情绪特征。Huang 等利用美国市场数据，实证 BERT 模型对金融文本的情绪分类精度显著优于传统的机器学习和词典法[58]。Shi 等检验了 BERT 模型在中文金融文本上的分析效果，表明 BERT 模型对个股股吧投资者情绪的分类精度更高[59]。因此使用先进的大语言模型可以提升非结构化金融文本的分析精度，从而增强投资组合策略的表现性能。

中国知网 https://www.cnki.net

1.3.3 深度强化学习投资组合研究现状

（1）深度学习投资组合应用

随着 AI 技术爆发式发展，深度学习（Deep Learning，DL）在投资组合领域的应用也相应受到广泛关注。卷积神经网络（Convolutional Neural Network，CNN）和长短期记忆神经网络（Long Short Term Memory，LSTM）等深度神经网络在金融市场数据分析中具有强大的特征提取与表示能力，能够从复杂金融数据中有效提取时空特征信息[60-61]。Fischer 等将 LSTM 应用于股票收益率预测，并与随机森林及深度多层感知机等无记忆模型进行比较，表明 LSTM 具有更优的预测性能，基于 LSTM 的投资组合模型表现最好[62]。张鹏等运用机器学习筛选高预期收益股票，采用均值-下半方差模型、均值-方差模型和等比例模型确定最优资产配置比例[63]。刘伟龙等利用 LSTM 预测信息并构建专家策略，提出了集成专家意见的在线投资组合交易策略[64]。在信息融合与模型优化方面，黄羿等通过深度神经网络融合知情交易者和噪声交易者的决策行为，为投资者提供了更稳健的方案[65]。宋正阳等提出多种预测算法的集成混合策略，通过生成投资者观点提前筛选优质资产，进而构建更为有效的投资组合[66]。

（2）强化学习投资组合现状

投资组合管理（Portfolio Management, PM）旨在通过动态调整资产配置实现长期收益最大化，传统的 PM 策略具备基于坚实的金融理论基础，但泛化能力有限，而基于强化学习（Reinforcement Learning，RL）的 PM 策略则能直接输出交易头寸，通过环境交互规避了显式预测步骤[67]，并将交易成本和风险约束灵活融入奖励函数中，从而实现更优的风险收益平衡[68-69]。胡文伟等通过在中国债券市场构建基于 SARSA 算法的协整配对交易模型并进行仿真验证，发现该模型能够显著增强交易系统的收益表现[70]。Deng 等将强化学习应用于模糊学习和循环强化学习，在股票和商品期货市场中验证了投资组合模型的稳健性[71]。邹杰等采用级联 LSTM 捕获股票日频数据中的隐藏信息，进而构建了强化学习投资组合模型[72]。

（3）深度强化学习投资组合演进

深度强化学习（Deep Reinforcement Learning，DRL）有机融合深度学习与强化学习，通过智能体与股市环境持续交互实现了从高维数据感知到交易决策输出的端到端学习，为解决投资组合问题提供了新范式。Betancourt 等构建的动态 DRL 投资组合模型可在引入新资产时自适应调整，无需额外训练[73]。Carta 等将 CNN 引入函数逼近器，验证了 A3C 算法在投资组合优化中的有效性[74]。

中国知网 https://www.cnki.net

许杰等提出融合 CNN 和 LSTM 的自动交易算法，采用 CNN 捕捉股票行情特征，并通过 LSTM 学习动态时序信息，最后利用强化学习积累收益[75]。张善凡等依据基本面与技术指标构建时序股票关联网络，以端到端方式生成预测信号集，从而融入行为评估反馈以优化策略[76]。由于投资组合的连续动作空间特性，DDPG 算法近年受到广泛关注[77]。Conegundes 等基于 DDPG 算法构建日交易系统，有效解决了多股票配置问题[78]。Wang 等将其引入风险感知投资组合，采用 Sortino 比率和回报进行评价[79]。Wu 等从概率视角度量回撤风险，并基于指数函数与最大回撤融合构建了约束奖励函数[80]。

（4）多智能体强化学习投资组合进展

相较于单一智能体与环境的交互模式，许多实际问题更类似于多智能体系统[81]。多智能体强化学习框架得以建立，为处理复杂市场环境下的投资组合问题提供了新思路。在面对高维且复杂的金融数据时，单智能体处理能力有限，难以全面捕捉市场信息，而多智能体强化学习则通过协同决策能够更有效地应对多变的市场形势。现有研究主要从模型架构、行为设计与集成策略等方面展开。Ma 等人构建了多智能体强化学习投资组合模型，旨在市场持续变化中实现收益最大化[82]；Lee 等通过设计损失函数引导智能体执行多样化动作，提升了系统的鲁棒性[83]；LIN 等基于两级嵌套的智能体结构设计了具备多样化交易风格的智能体群，有效解决了不同市场趋势的投资组合问题[84]；Liu 等进一步整合三种 Actor-Critic 算法，构建集成式深度强化学习交易模型，实证表明以夏普比率衡量的深度集成策略的风险调整回报优于其他单一算法和基准策略[85]。

1.3.4 国内外研究现状评述

本小节首先从投资组合理论的研究现状进行梳理，然后对金融舆情在投资组合中的应用进行研究现状总结；最后对深度强化学习投资组合相关文献进行了梳理。总体来说，基于机器学习方法特别是深度强化学习投资组合优化研究成为焦点，舆情中市场情绪因素的影响逐渐受到重视，但是在已有投资组合研究中，从金融文本中挖掘投资者情绪信息并应用于投资组合模型中的研究较少。上述相关研究现状评述总结具体如下：

（1）均值-方差投资组合模型的创建开创了现代投资组合理论的先河，但该模型存在一定的不足。故此对 MV 模型进行改进的研究不断涌现，分别从风险测度方法、优化指标、多目标优化、动态优化、模糊不确定性等角度进行多方面综合改进。随着技术的进步，投资组合模型也与机器学习算法不断结合。

中国知网 https://www.cnki.net

然而既有投资组合模型本质还是一个先预测后优化的两阶段方法，仍有若干待改善之处。特别是在非结构化舆情信息日益丰富的背景下，如何将深度多智能体强化学习与金融舆情有效结合，已经成为进一步优化的良策。

（2）随着时代发展和技术进步，社交媒体逐渐成为新一代投资者交流的主要途径。金融舆情信息富含投资者情绪和市场预期，对股票收益和市场波动具有显著影响，因此成为了学者研究的热点议题。舆情情感分析方法经历了从词典法到机器学习再到大语言模型的技术跃迁，同时舆情文本与市场结构化数据也不断整合。然而当前研究大多集中于金融舆情与市场表现间的关联，将金融舆情系统融入投资组合的研究仍相对有限，舆情信号的信度判别和生成机制及在投资组合中的应用还需进一步探索。

（3）综合深度强化学习在投资组合中的应用，可知融合深度强化学习的投资组合研究主要集中于两大维度：其一围绕真实交易环境展开，通过调整改进市场状态、动作空间、交易约束以及奖励函数等环节优化模型，其二则致力于深度强化学习智能体结构改进，包括智能体数量增加与网络结构的重构。然而多数模型仍主要依赖历史价格和技术指标等传统结构化数据，对金融舆情等非结构化信息关注不足，对于将多智能体强化学习应用于国内市场也少有研究，同时利用金融舆情改进深度强化学习投资组合的研究也有待深入。

综合考虑上述问题，本文将有效融合金融舆情信息，充分发挥深度强化学习决策优势，并兼顾风险控制与收益目标，从而构建一个性能更优、鲁棒性更强的考虑金融舆情的深度强化学习投资组合模型。

1.4 研究内容与方法

1.4.1 研究内容

（1）考虑金融舆情的深度强化学习投资组合机理

从金融舆情与投资者情绪的内在关联入手，阐释金融舆情通过情绪积累对市场预期及资产价格的作用机制。通过对投资组合定义及交易过程的量化，将投资组合问题表征为马尔可夫决策过程，进而从深度强化学习内部驱动、投资者行为效应及资产价格与股票市场的舆情传导协同三个维度剖析模型构建的理论动因。围绕历史行情与金融舆情两类核心要素提出建模假设，设计投资组合建模完整流程，阐明各流程中的算法原理，从而构建融合金融舆情的深度强化学习投资组合理论框架。

中国知网 https://www.cnki.net

（2）考虑金融舆情的深度强化学习投资组合舆情信号生成

围绕舆情效力分析、可信度模型检测、FinBERT 情感测度及热度加权聚合四个环节展开对金融舆情信号生成的研究。探讨投资者认知与情绪在舆情判别中的作用路径，构建包含一般信息可信度指标与企业指标的可信度评价体系，并通过舆情影响力曲线确定以发布日为中心前后各五天的舆情影响力时间窗口。引入决策树算法从舆情特征中自动生成分类规则路径，基于 Kripke 结构构建状态转移模型并采用 NuSMV 工具执行模型检测以验证规则的有效性与一致性。采用 FinBERT 模型对舆情文本进行动态编码，利用大语言模型生成情感标签并对金融领域预训练模型进行监督微调，进而构建日度情感指数并引入影响力窗口进行加权修正以增强情绪度量的稳健性。最后基于日度发帖量与评论量构建舆情热度指数，将热度作为权重与情感指数聚合生成金融舆情信号指数。

（3）考虑金融舆情的深度强化学习投资组合模型构建

设计历史行情特征提取网络，通过 Transformer 与卷积神经网络分别提取全局时序特征与局部形态特征，引入多阈值方向性变化方法结合遗传算法对市场趋势进行预测并生成方向性变化指标。建立金融舆情信号融合机制，将经可信度检测与 FinBERT 情感分析生成的舆情指数通过 LSTM 提取时序特征后与行情特征进行早融合拼接。在此基础上提出多智能体决策框架，设置乐观、均衡、悲观三种不同风险偏好的基于独立 Actor-Critic 网络的基智能体，随后经集成网络融合后输入基于风险预算策略的可微凸优化层进行风险约束调整并输出最终资产配置权重。最后给出融合金融舆情的深度强化学习投资组合模型的整体结构与算法流程。

（4）考虑金融舆情的深度强化学习投资组合实证

以沪深 300 指数与道琼斯工业平均指数成份股为标的资产，选取 2015 年至 2025 年历史行情数据及对应金融舆情文本，经数据清洗与预处理构建实验样本。设定交易成本、初始资金及时间窗口等实验环境参数，选取涵盖经典投资组合模型、在线投资组合模型及深度强化学习模型三大类共八种基准模型作为对比对象，采用夏普比率、年化收益率、最大回撤及组合风险作为评价指标。在中美两个市场分别开展绩效对比实验，分析模型在不同市场趋势下的投资组合价值变化与交易策略行为特征，并通过资产数量扩展实验检验模型在高维资产空间中的泛化能力，进一步设计金融舆情模块与多智能体模块的消融实验，验证各模块对模型性能的贡献。

中国知网 https://www.cnki.net

1.4.2 研究方法

（1）文献研究法

对国内外学者的相关研究进行搜集、汇总和整理。首先对投资组合相关理论进行梳理；其次对金融舆情在投资组合中的应用进行总结，了解当前主流方法的理论基础和应用；然后对深度强化学习在投资组合中的研究成果进行梳理；最后对相关研究进行系统归纳后确定本文的最佳研究框架。

（2）文本挖掘法

以财经新闻及东方财富网股吧论坛为数据源，运用网络爬虫程序获取金融舆情文本，并对所采集的非结构化数据进行降噪清洗、缺失值剔除及重复过滤等预处理操作。

（3）舆情分析法

采用 BERT-BiLSTM 架构对金融舆情文本进行深层语义特征提取，通过 FinBERT 模型结合大语言模型生成标签进行监督微调以实现情感分类与舆情因子量化输出，引入模型检测技术验证舆情可信度，并结合热度指数加权聚合形成结构化金融舆情信号。

（4）多智能体深度强化学习法

利用深度神经网络对股票历史行情数据与金融舆情信号进行多模态特征提取与融合表示，构建包含基智能体生成、多智能体集成及风险预算控制的投资组合决策模型。

（5）实证研究法

以中美股市标的资产为研究对象，运用考虑金融舆情的深度强化学习投资组合模型开展实证分析，通过与经典投资组合与深度强化学习等多种基准模型对比及消融分析验证模型的有效性。

1.4.3 技术路线

本文的技术路线见图 1-1 所示。

中国知网 https://www.cnki.net

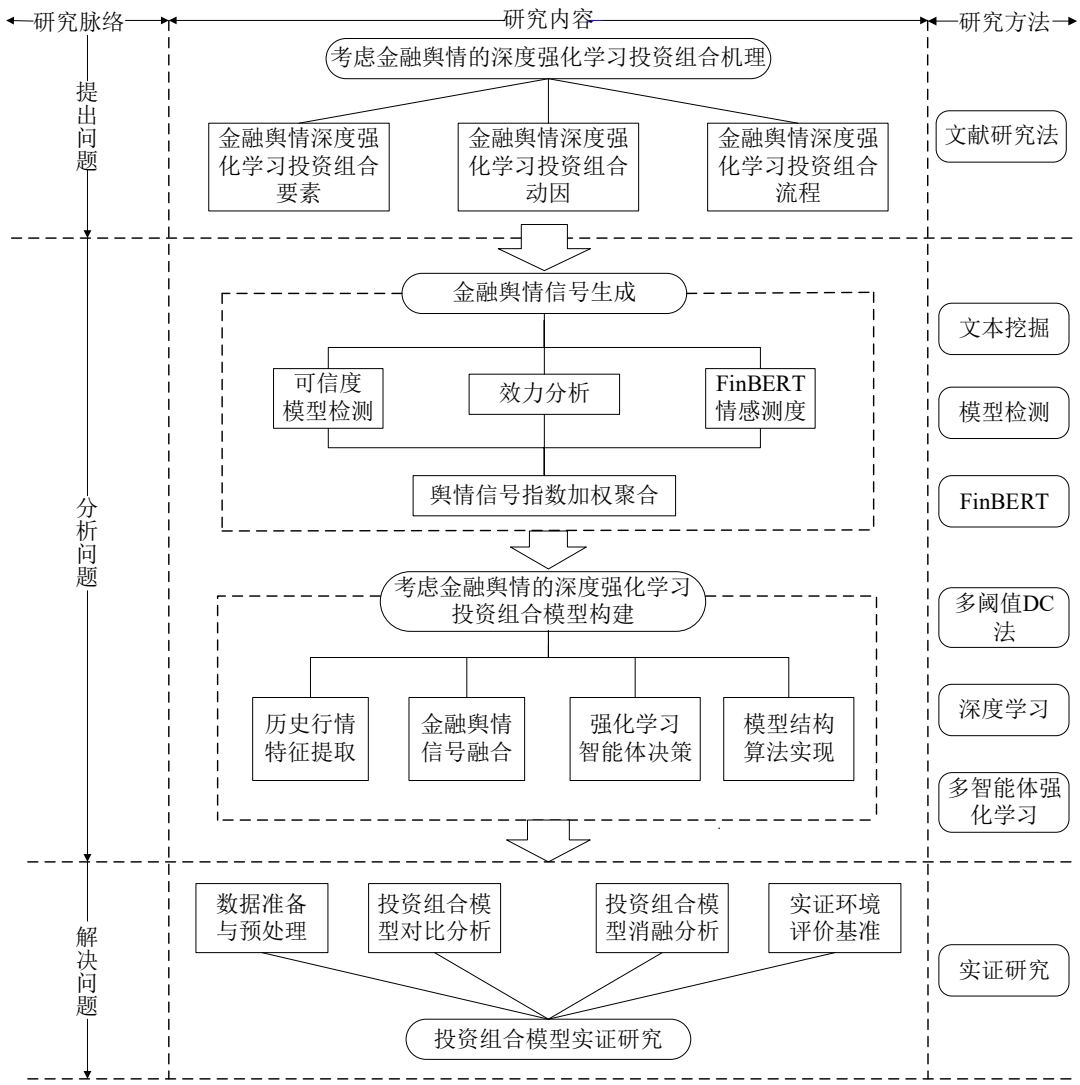


图 1-1 技术路线图

Fig. 1-1 The technology road map

中国知网 https://www.cnki.net

第2章 考虑金融舆情的深度强化学习投资组合机理

2.1 考虑金融舆情的深度强化学习投资组合内涵

2.1.1 金融舆情内涵

（1）投资者情绪

金融舆情与投资者情绪密切相关，故有必要理清投资者情绪的基本含义。从广义上看，情绪是个体行为和思想感觉相互影响形成的心理状态。同时就投资者而言，人的情绪可分为正面、负面和中性，但是无论是何种情绪均会影响人们的行动和决策。投资者情绪亦是如此，虽不直接参与投资决策，但不可避免地会对决策结果产生影响。投资者情绪在很大程度代表着投资者情感，目前学术界对其尚未形成完全统一的界定。不少学者从投资者对市场的预期和行为偏差两方面做出定义。部分观点认为投资者情绪源于其在信息处理过程中非理性运用贝叶斯法则或对主观预期效用理论错误套用，进而形成带有偏差的信念或价值判断[86]。亦有研究将投资者情绪定义为投资者因心理或认知偏差而做出的情感性判断，或是反映在股票市场错误定价中的投机性需求与盈利预期[87-89]。同时基于心理学角度定义，投资者情绪可被视作投资者基于对市场信息的主观感知，所形成的对市场及企业未来走势的自我判断[90]。进一步地，投资者情绪的形成往往遵循一定的认知路径，首先寻找投资者关注度最高的市场信息，并基于信息的好坏做出判断，然后进一步形成投资者情感[91]。投资者主要关注宏观政策和市场新闻等客观信息，以及其他投资者和投资机构对市场的不同观点与态度。故当大量投资者对同一市场信息形成了类似的个人判断时，便可能引发群体性情绪共鸣，从而形成具有一定市场影响力的投资者情绪。因此，本文认为投资者情绪是投资者在信息处理过程中，因有限理性和认知偏差等心理机制，对市场信息形成的一种带有预期与主观判断的情绪反应。

（2）金融舆情形成机制

舆情即为公众的言论与舆论情况，是人们受到事件刺激时，通过介质载体传播形成的对事件认知、看法、态度和情感的集合。在当今互联网时代，舆情更多以网络舆情的形式存在，其通过网络传播与表达人们不同的情绪态度和意见。本文金融舆情表示公众或相关机构对市场中金融信息、事件或趋势的线上线下反应和讨论，且与投资者情绪密切相关，反映了集体心理在金融市场中的

中国知网 https://www.cnki.net

重要作用。随着金融舆情中投资者情绪快速传播，尤其在社交媒体和金融论坛的推动下，这种情绪迅速在投资者群体中扩散，从而形成集体情感反应。这种集体情感不仅基于个体对市场的预期和判断，还受到分析师意见、分析师报告和专家的影响，最终推动总体情绪的变化。当情绪被广泛接受并开始形成舆论时，公众对这种情绪的认同度会逐渐提高，影响力不断扩大，最终形成强烈的金融舆情。特别地，个体投资者的决策和行为受到金融舆情的显著影响。当媒体广泛炒作某个行业的前景时，投资者就可能纷纷涌入该行业，形成资金的集中流入，反之亦然。因此投资者情绪积累形成的金融舆情可以对市场产生影响。积极金融舆情可以促进市场牛市，推动资产价格上涨，给投资者带来利润；反之投资者负面的金融舆情则可能引发恐慌抛售，导致市场崩溃。

2.1.2 投资组合内涵

（1）投资组合定义

投资组合是指投资者持有的各类资产的集合。以股票资产为例，一个投资组合往往分散配置于不同行业、地区或市场，旨在借助不同股票价格走势的差异性，使个别资产的损失能够被其他资产的收益所弥补，从而平抑整体组合的波动幅度。故投资组合管理需在投资者设定的风险容忍度与收益预期双重约束下进行策略设计，既配置低风险低收益资产以保障基础收益，也要纳入高风险高收益品种以拓展收益空间，从而实现风险与回报的动态平衡。

（2）投资组合交易过程

投资组合交易过程中，投资者往往会动态调整资产头寸，在未来规定时间内并考虑交易成本的情况下，使得投资组合价值最大化，以实现增加投资回报和降低风险的目的。假设投资组合固定资产为 m 项，以 t 时期所有资产的收盘价构建价格向量 p_t，其中元素 p_{ti} 表示资产 i 在 t 时期的收盘价。由此推之，开盘价、最高价以及最低价可分别表示为 p_t^o, p_t^h, p_t^l。另外投资组合中的无风险资产通常设定为现金，所有资产在转移过程中均以现金为媒介，其资产价格向量恒为 1。在一天的时间段内市场环境是不连续的，第二天的开盘价并不等于前一天的收盘价。第 t 期的相对价格变化向量 y_t 由第 t 期价格向量和第 t-1 期价格向量元素逐个相除得到：

$$y_t = p_t \otimes p_{t-1} = \left(1, \frac{p_{1,t}}{p_{1,t-1}}, \frac{p_{2,t}}{p_{2,t-1}}, \ldots, \frac{p_{m,t}}{p_{m,t-1}}\right) \tag{2-1}$$

相对价格变化向量反映的是一段时期内总投资组合价值的变化情况。因此

中国知网 https://www.cnki.net

不考虑交易成本的情况下第 t 期末的投资组合价值 v_t 为：

$$v_t = v_{t-1} y_t \cdot w_{t-1} \tag{2-2}$$

其中 w_{t-1} 为 t-1 期交易后的权重向量，也是第 t 期开盘时的投资组合权重向量。同时权重向量 w_t 满足归一性，各项相加和为 1。故投资组合第 t 期的收益率和对数收益率分别为：

$$\begin{aligned} \rho_t &= \frac{v_t}{v_{t-1}} - 1 = y_t \cdot w_{t-1} - 1 \\ r_t &= \ln \frac{v_t}{v_{t-1}} = \ln\left(y_t \cdot w_{t-1}\right) \end{aligned} \tag{2-3}$$

同时初始投资组合权重向量 w_0 设置为 $w_0 = (1,0,\ldots,0)^T$，即资本在进入市场前均以现金的形式存在，最终投资组合的总价值为：

$$v_{\mathrm{f}} = v_0 \exp\left(\sum_{t=1}^{t_{\mathrm{f}}+1} r_t\right) = v_0 \prod_{t=1}^{t_{\mathrm{f}}+1} y_t \cdot w_{t-1} \tag{2-4}$$

其中，v_{f} 表示投资组合最终价值，v_0 为投资组合初始价值。

现实交易环境中，交易成本并不是免费的，需要花费佣金，其中佣金率可固定不变。第 t-1 期末的资产组合权重表示为 w_{t-1}，后续的交易日价格会产生变动，故第 t 期的权重为：

$$w_t' = \frac{y_t \odot w_{t-1}}{y_t \cdot w_{t-1}} \tag{2-5}$$

其中：记运算符⊙为向量逐元素乘法，通过该运算将 t 时刻的价格变化向量 y_t 与 t-1 时刻权重向量 w_{t-1} 进行对应元素相乘，生成各项资产的相对权重调整量。分母则用于对结果进行归一化，确保权重相对调整后总和仍为 1。投资组合权重 w_{t-1} 表示在 t 时刻未发生资产交易的权重；而在 t 时刻进行买进和卖出操作，从而完成资产再配置后的投资组合权重则表示为 w_t'。

在进行交易行为后投资组合的总价值会相应减少，应用交易剩余系数 u_t 计算资产总额减少程度，则交易后的资产组合价值表示为 $v_t = \mu_t v_t'$，其中 v_{t-1} 为 t 时刻交易前的总价值，v_t' 是 t 时期交易结束时的资产组合总价值。考虑交易成本情况下，式 2-3 和式 2-4 的收益率、对数收益率和投资组合总价值相应修改为：

$$\rho_t = \frac{v_t}{v_{t-1}} - 1 = \frac{\mu_t v_t}{v_{t-1}} - 1 = \mu_t y_t \cdot w_{t-1} - 1 \tag{2-6}$$

$$r_t = \ln \frac{v_t}{v_{t-1}} = \ln\left(\mu_t y_t \cdot w_{t-1}\right) \tag{2-7}$$

中国知网 https://www.cnki.net

$$v_{\mathrm{f}}=v_0\exp\left(\sum_{t=1}^{t_{\mathrm{f}}+1}r_t\right)=v_0\prod_{t=1}^{t_{\mathrm{f}}+1}\mu_t y_t\cdot w_{t-1} \tag{2-8}$$

其中交易剩余系数u_t需要进一步确定，当资产组合从w_t变化到w_t'，买进卖出操作会产生相应的费用，对于交易花费具体规定为千分之三费率。因此u_t可表示为两个交易周期间权重向量和价格变化向量的函数$\mu_t=\mu_t(w_{t-1},w_t,y_t)$，进而通过计算不同时期的股票持有数量可以计算得到交易成本。

2.1.3 深度强化学习投资组合内涵

（1）深度强化学习投资组合定义

深度强化学习投资组合本质上是建立一个端到端和持续优化的智能投资决策系统。其利用深度神经网络从高维、非平稳的原始金融数据中提取抽象特征，并构建有效的状态表征。同时通过梯度反向传播和强化学习算法，使智能投资系统能够在大规模状态-动作空间中高效搜索并逼近最优投资策略。

（2）投资组合马尔科夫表示

深度强化学习投资组合管理中需要定义交易智能体和投资环境，分别对应强化学习中的智能体与环境, 交易智能体需要满足交易条件限制,投资环境需要遵循马尔科夫性。强化学习以马尔科夫决策过程（Markov Decision Process，MDP）为基本框架来求解问题，依据过程序贯连续进行决策。由有效市场假设可知，投资组合问题状态序列包含了有效充分的历史信息且连续稳定，并且可以提取未来信息趋势，因此可以用 MDP 描述投资组合问题。在证券市场中，未进行融资融券的情况下，股票投资的一般过程可以描述为：投资者根据当前市场状态s_t在交易日 t 进行股票买入卖出等操作a_t。如此往复，在交易日 t+1 根据市场状态s_{t+1}执行股票买卖操作a_{t+1}，同时两交易日之间的资产涨跌幅可以视为奖励参考。为了更清楚地描述 MDP 在投资组合问题中的应用，首先将其引入单智能体强化学习场景，然后再将其扩展至多智能体强化学习场景。单智能体情况中，投资组合的 MDP 表示为四元组(S,A,R,γ)，其中元素的含义分别为：

状态集合 S：$s_t\in S$ 表示 t 时刻市场上观测到的股票信息，主要包括前文提到的股票历史行情类和金融舆情类等数据。

动作集合 A：$a_t\in A$ 表示对每支股票进行的行为操作，a_{ti} 大于 0 时表示第 i 支股票在 t 时刻进行买进操作,反之 a_{ti} 为负则表示 t 时刻对股票 i 进行卖出操作。

奖励集合 R：$r_t\in R$ 表示 t 时刻经过动作 a_t 后，从环境中返回的奖励集合。

折扣系数 γ：表示累积奖励的折扣系数。

中国知网 https://www.cnki.net

然而在实际投资场景中，强化学习智能体不仅要观测市场数据，其自身产生的动作也会影响到其持仓分布，因而需要考虑智能体的状态转移情况。因此本文定义多智能体强化学习投资组合系统输入为六元组$(S_e, S_o, A, R, f, \gamma)$。其中$S_e$表示股票市场环境状态信息的集合，$S_o$表示智能体自身资产状态的分布空间，$A$表示所有智能体动作的联合集合，$R$是各智能体对应的奖励函数族，$f$为资产状态的转移函数，$\gamma$为智能体奖励的折扣系数。

2.2 考虑金融舆情的深度强化学习投资组合动因

2.2.1 深度强化学习内部驱动

将深度强化学习应用于投资组合管理，是量化金融领域解决方法的一次重要范式变革。其驱动力不仅源于传统投资组合方法的局限性，更在于 DRL 技术本身与投资问题的内在契合性。以下主要从驱动力和优势两个层面对深度强化学习投资组合动因进行系统分析。具体深度强化学习内部驱动示意见图 2-1。

（1）驱动力分析

在金融市场这个高维、非线性、非平稳且充满噪声的复杂动态系统中，均值-方差模型等传统量化方法，依赖于正态分布和线性关系等强假设以及静态参数，难以捕捉市场的真实演化规律。然而 DRL 并不依赖先验模型假设，其试错-学习机制能直接从数据中学习动态环境下的复杂模式，能够有效处理序贯类的决策问题。投资组合管理是一个典型的多期序贯决策过程，投资者通过观察市场状态和执行调仓动作，以追求获取往往并不稳定和延迟的高额收益回报。这一过程与强化学习的四大核心要素（状态、动作、奖励、延迟反馈）完美契合。同时 DRL 通过设计奖励函数，能够将长期性和全局性的投资目标直接嵌入到日常的调仓动作决策中，从而实现全局优化。最后深度学习强大的表征学习能力，使得DRL智能体能够自动从价格序列和金融舆情等原始或轻度处理的数据中提取有效特征，并且可以融合多模态信息。

（2）优势分析

DRL 构建了一个从原始数据输入到投资决策输出的端到端闭环过程，将预测和投资组合决策这两个传统上分离的步骤统一在一个框架内进行联合优化，从而避免了预测误差在决策环节的传递与放大，直接优化了最终的投资目标。同时通过设计灵活的奖励函数，DRL 可以解决各类复杂的现实投资目标和约束。例如可以将最大化收益、控制下行风险、降低交易成本和保持行业中性等多种

中国知网 https://www.cnki.net

目标融合进一个优化框架内，这是传统投资组合优化方法难以实现的。深度 Q 网络等基于价值的 DRL 算法或近端策略优化等演员-评论家架构具备评估长期累积回报的能力，使得智能体在进行当前决策时，能够考量其对未来状态的长期影响，从而执行更优的投资行为。最后训练良好的 DRL 智能体也可以部署在模拟或实盘环境中进行在线学习与微调，使得其能够适应复杂的市场状态变化。

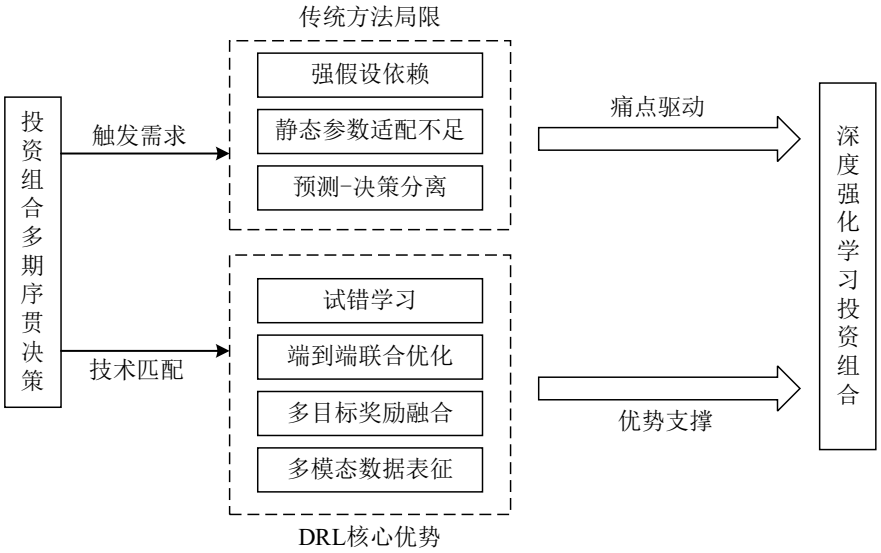


图 2-1 深度强化学习内部驱动示意

Fig. 2-1 Schematic diagram of internal drivers in deep reinforcement learning

2.2.2 投资者行为效应内部驱动

资本资产定价模型和有效市场假说共同构筑了经典金融学的理论基石，二者皆以市场参与者的完全理性为基本预设。然而投资者情绪累积形成的金融舆情会促使其做出非理性的投资决策。行为金融学则从有限理性视角出发，揭示了认知偏差和心理因素对市场非有效性的深层影响。在投资组合中，人们总是关注投资预期与收益的比较以及对风险的规避，同时会不同程度地表现出厌恶损失和过度自信等心理特征，进而形成相应的金融预期行为效应。这些行为偏差不仅是金融市场异象的根源，也是本文将金融舆情信号与多智能体强化学习框架相融合的理论内部动因。投资组合行为效应内部驱动示意如图 2-2 所示：

中国知网 https://www.cnki.net

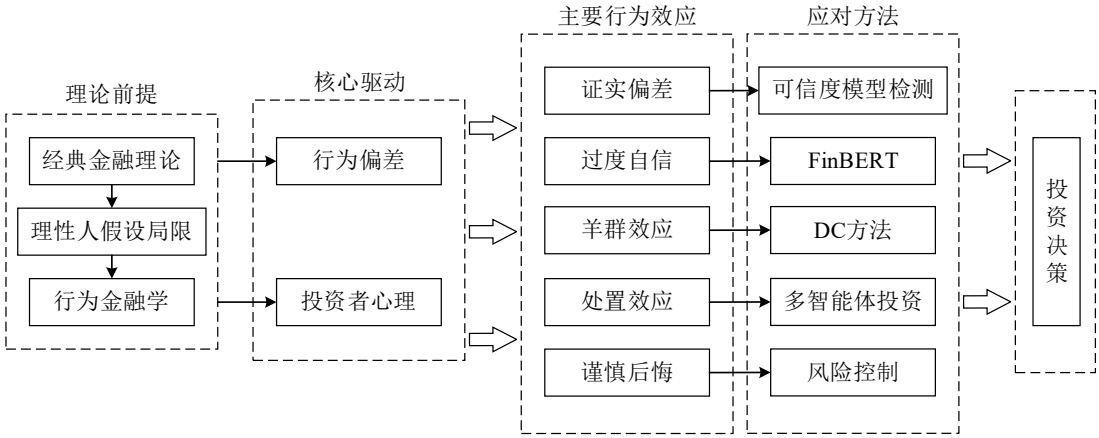


图 2-2 投资者行为效应内部驱动示意

Fig. 2-2 Schematic diagram of internal drivers for behavioral effects

（1）证实偏差效应

投资者在形成既定判断后，往往会表现出证实偏差的行为。他们倾向于优先接受支持自身观点的证据，而忽视不利的反驳信息。在资本市场运行过程中，证实偏差作为一种普遍存在的现象，对投资者的行为决策产生着深刻影响。当股市处于上涨阶段时，投资者会过度关注利好舆情，而忽视可能表明股价被高估的负面信号。这种偏差可能导致股价持续攀升，并使市场与股票的实际价值之间产生偏离，最终形成泡沫。相反在股市下跌时，投资者又更容易放大悲观信息的影响，从而加剧市场的低迷状态。由此可见，金融舆情数据中存在大量因投资者选择性关注而产生的偏向性信息，原始舆情难以客观反映市场实情。因此本文引入基于决策树与模型检测的可信度验证框架，过滤偏向性与噪声内容，为后续情感测度提供可靠的数据基础。

（2）处置效应

处置效应的产生主要源于投资者在决策过程中存在认知偏差，即对盈利与亏损采取不同态度。持仓盈利时表现出风险厌恶倾向，倾向于提前止盈锁定收益；持仓亏损时则转向风险偏好，倾向于继续持有以期价格反弹。这种盈亏两域的风险偏好不对称性使得投资者在不同市场状态下呈现出异质化的决策行为模式。鉴于此，本文通过构建乐观、均衡、悲观三类差异化风险偏好的基智能体，分别对应市场上涨、震荡和下跌状态下的异质决策倾向，并为各基智能体配置差异化的奖励函数，从而提升投资组合模型在复杂市场态势下的覆盖能力。

（3）过度自信效应

中国知网 https://www.cnki.net

过度自信是指投资者往往高估自己对信息的理解能力与判断准确性，在牛市中倾向于高估未来收益预期，在熊市中则低估潜在下行风险，同时过度依赖个人主观判断而轻视外部客观信息来源。这种认知偏差会导致投资者对舆情信息的解读产生主观失真，使得依赖人工判断的情感评估难以保持客观性与一致性。对此，本文采用基于 FinBERT 预训练语言模型的监督微调方法，以深度神经网络替代主观情感判断，对大规模舆情文本进行客观的情感极性测度，同时引入热度加权聚合机制，综合考量舆情影响力差异。

（4）羊群效应

在经济学领域中羊群效应通常指在信息不充分或市场不确定性较高的环境中，投资者放弃独立判断，转而追随多数人行为的群体从众现象。羊群行为促使大量投资者在相近时间内做出趋同的买卖决策，其所催生的集体情绪态势在投资者于社交媒体发布的大规模文本中得到了充分体现，为舆情信号捕捉市场集体情绪提供了直接的行为学依据。与此同时，羊群行为在价格序列中还会形成显著的趋势动量特征。进而本文引入多阈值方向性变化方法并结合遗传算法，捕捉价格趋势的关键转折点，从而识别因羊群行为形成的市场趋势惯性，并将其纳入历史行情特征中。

（5）谨慎后悔效应

谨慎后悔效应涵盖了市场中两类相反的非理性反应模式：过度反应与反应不足。前者源于投资者因后悔情绪引发的矫枉过正行为，表现为对新信息的激进超常应对；后者则源于对新信息消化不足或保守惰性，导致调仓行为滞后于市场变化。二者均会在价格序列中形成超调或欠调的非线性运动特征。为系统应对这一双向非理性行为对资产配置的影响，本文在差异化奖励函数中引入收益激励与回撤惩罚的非对称结构，以约束过度反应带来的仓位集中风险。同时在模型输出端引入基于风险预算策略的可微凸优化层，对各智能体的资产配置权重进行显式风险约束调整，从机制层面抑制过度反应与反应不足所诱发的极端仓位偏差，实现了风险收益的动态平衡。

2.2.3 资产价格舆情传导外部协同

金融市场中各类资产的价格变化与金融舆情或投资者情绪紧密关联。金融舆情可视为投资者非理性预期的集中体现，其影响强度取决于预期在市场中的传播广度与共识程度，共识越强对资产价格的冲击力越大。市场上的噪声交易者往往被非理性情绪所裹挟，其噪声交易行为成为价格波动的重要推手。当市场情绪向悲观或乐观方向集聚时，噪声交易需求随之收缩或扩张，进而驱动资

中国知网 https://www.cnki.net

产价格同向变动。特别在不完全竞争市场结构中，噪声交易对资产价格的影响会更加显著。故而资产价格与舆情传导之间的协同关系，构成了投资环境的外部动态核心。这种协同效应不仅表现为非线性的价格影响路径，更体现为在市场压力下的非对称放大机制。因此分析资产价格与金融舆情的协同传导机制，本质上是赋予智能体理解市场的能力，使其决策能更适应真实世界中由情绪和信息交织驱动的复杂价格形成过程。资产价格舆情传导外部协同机制示意详见图 2-3：

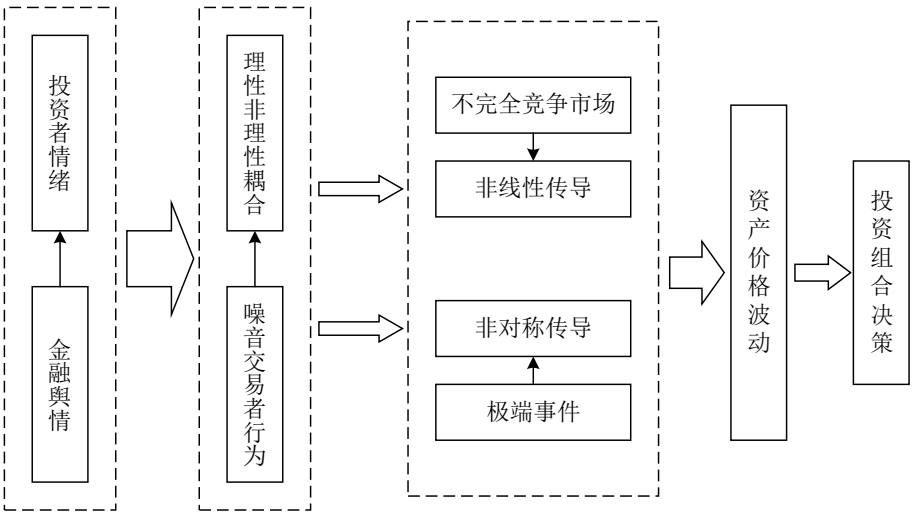


图 2-3 资产价格舆情传导外部协同机制

Fig. 2-3 External synergistic mechanism in the transmission of public opinion on asset prices

（1）非线性传导

金融舆情对资产价格的影响复杂，呈现显著非线性特征。投资者非理性预期的时变特征，会诱发资产价格的无序波动。国内市场散户占大多数，极易受媒体舆情的影响，由此引发的非理性交易往往掩盖了理性投资者与基本面因素对价格的锚定作用。这一过程中的关键协同强化机制在于：当非理性交易策略因舆情驱动而取得收益时，部分理性投资者会改变原有交易逻辑，转向参与噪声交易，从而形成理性与非理性行为的动态耦合。这一耦合机制不仅放大了金融舆情对价格的非线性冲击，也加剧了资产价格对内在价值的偏离。

（2）非对称传导

另一方面金融舆情对资产价格的干预表现出显著的非对称性特征，其传导机制可归结为两条：其一通过资产价格信号渠道发挥作用，其二借助经济周期预期自我实现机制形成反馈。金融舆情能够作用于资产价格的基本面信息[92]，

中国知网 https://www.cnki.net

当金融舆情情绪较为积极时，市场需求自然增加，进而推动资产价格上升。此外金融舆情对资产价格的影响存在沉默的螺旋效应，其作用强度随市场状态与经济周期切换而呈现非对称变化[33]。尤其在市场下行期或极端事件冲击下，消极舆情的非对称影响力更为凸显。其深层逻辑在于，信号渠道与预期自我实现机制的双重叠加，使基本面微幅波动在舆情催化下被急剧放大，最终驱动资产价格严重偏离基本面，甚至触发价格暴跌。

2.2.4 股票市场舆情传导外部协同

金融舆情与股票市场两者之间通过投资者情绪和行为相互关联。投资者存在于金融舆情的整个生命周期，其既生产制造舆情，也是传播着舆情，更是舆情的接受者。金融舆情的变化传递着投资者情绪的变化，同时投资者情绪受金融舆情的影响，进而形成具有共同心理倾向的交易群体。该群体对市场走势的集体预期会形成趋同的群体交易行为，最终影响股票供需关系和股市稳定性。整个过程中存在两条关键反馈路径，不同股市趋势下具有不同的协同效果。金融舆情对股票市场的协同作用机制如图 2-4。

（1）舆情驱动的股市波动协同

金融舆情主要通过影响资产价格作用于股市稳定性，而股价波动的内在动力则是市场供需变化。国内股市实行核准制，短期内股票发行量基本稳定，股价变动更多是由投资者需求的强弱所驱动。需求上涨时，投资者大量买进股票，推动股价上涨，反之亦反。同时国内实行竞价交易机制，其基本准则为价格优先和时间优先。竞价中及时成交的订单称为主动买盘或者主动卖盘。因此影响股市波动的因素主要有两种，即为主动买盘的推力和主动卖盘的压力。主动买盘和卖盘由资金的流入和流出决定，资金流入量即为主动买盘成交量，相应地流出量即为卖盘成交量。由此可知资金流入流出的强弱程度直接决定了股价波动的幅度与方向，主动买盘时价格上涨，反之则价格下跌，两者差额越大则股市越不稳定。如图 2-4 所示，舆情较为消极时，投资者就会主动抛售手中资产，从而流出资金大于流入，需求减少；舆情较为积极时，投资者就会加大持仓，使流入资金大于流出，需求增加。因此当股票需求侧发生剧烈变化时，必然引致价格波动，从而形成金融舆情→投资者情绪→交易行为→供需关系→价格波动的协同传导链，直接影响投资组合所面临的外部市场环境。

（2）反馈作用与波动强化协同

在金融舆情与股票市场的整体系统中，存在着反馈机制放大了这种协同效应，进而加剧市场波动。如图 2-4 中，正反馈 1 路径较短，直接作用于投资者

中国知网 https://www.cnki.net

情绪，其产生效果速度也更快。当金融舆情影响投资者情绪，并做出投资行为后，若股市走势与投资者情绪变化方向一致，则正反馈 1 将进一步加强投资者原有的情绪。正如消极舆情致使投资者情绪低迷，从而抛售持有股票，造成股票需求降低和股价下跌。而当消极投资者得知股价下跌时，会进一步导致其情绪更加低迷。正反馈 2 路径则相对较长，直接作用于金融舆情，故其影响时间也相应更长。股票市场自身大涨或大跌等显著波动常常成为新金融舆情的源头之一。这意味着金融舆情通过投资者情绪影响股票市场稳定性后，股市波动又正反馈影响舆情变化，如此反复循环进而造成更广泛的影响，推动舆情向极端转变，进而导致股市更为急剧的波动，最终形成舆情→市场波动→新舆情→更强波动的强化循环。

由本节分析可知金融舆情并非外生于市场的孤立信息，而是通过投资者情绪和行为，与股票市场形成深度协同的动态系统。这种协同效应通过直接的供需传导以及两条正反馈回路，显著影响资产价格的波动性与市场状态，构成了深度强化学习智能体所必须感知和应对的关键外部环境动态。因此，在投资组合模型中引入金融舆情，本质上是将这一重要的市场协同动因内生化，以提升智能体对复杂市场环境的理解与适应能力。

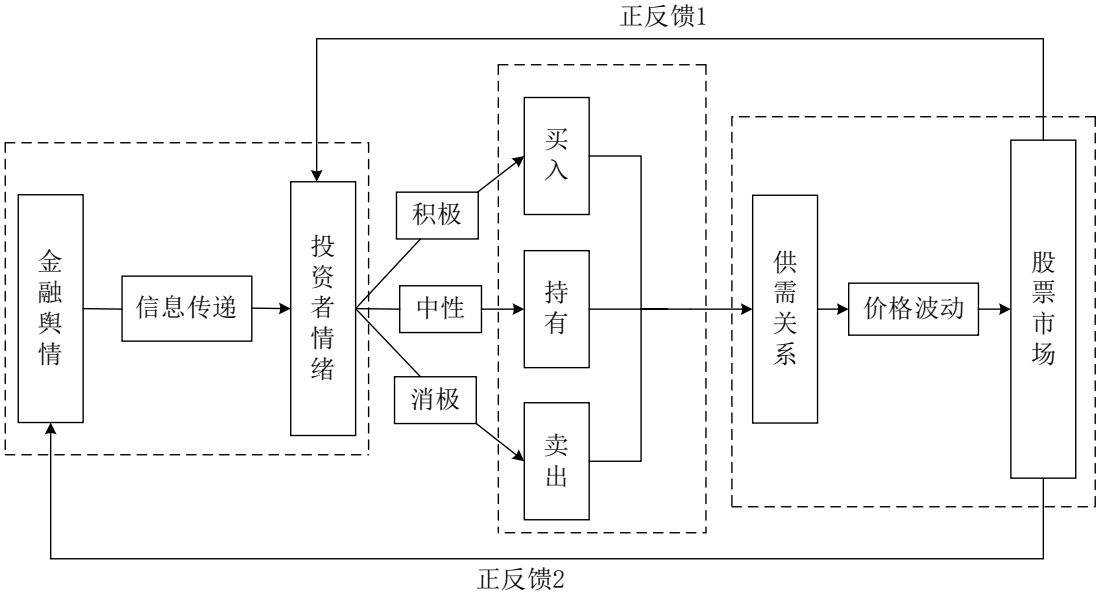


图 2-4 金融舆情对股票市场外部协同机制

Fig. 2-4 The external synergy mechanism between financial public opinion and the stock market

中国知网 https://www.cnki.net

2.3 考虑金融舆情的深度强化学习投资组合要素

2.3.1 投资组合历史行情要素

资本市场的有效性并不完全，股票市场的历史数据可为投资决策提供有效支撑，技术分析类数据在当前交易实践中同样发挥着重要作用。故本节从基本面和技术面两大类对投资组合历史行情数据进行总结划分。

（1）数据筛选原则

投资组合历史行情数据是投资组合模型的关键要素，其数据选取的质量在很大程度会影响投资组合模型的回测效果。因此针对当前量化投资的现状，对历史行情数据的选取需要遵循以下原则：

其一，全面性。在选取投资组合量化指标时，要全面综合考量宏观经济、金融市场等多维指标。然而指标体系的过度扩充将导致模型复杂度攀升，进而干扰影响投资决策，因此需要在指标全面性和有效性之间做好权衡。

其二，相关性。所有投资组合量化指标必须具备与股票市场的内在关联性，方能实现对资产未来收益的有效预测，并据此精准识别买卖时点。而这一相关性的存在，通常以经济逻辑作为其内在依据。

其三，一致性。投资组合量化指标的更新频率要与金融舆情指标的更新速度一致。投资组合量化指标与宏观经济指标通常具有一定的滞后性，其往往按照月度甚至年度进行更新。然而舆情指标一般基于日度频率，因此在筛选投资组合量化指标时应当消除更新频率不一致指标的影响。

（2）基本面数据

历史数据主要包括开盘价、收盘价、最高价、最低价等构成 K 线图的核心要素，其反映了市场供需与情绪。收盘价判断趋势强弱，开盘价衡量市场情绪，最高和最低价则体现价格波动范围。

基础数据则涵盖涨跌幅、成交量、成交金额和换手率。其中涨跌幅反映的是指数在相邻交易日之间的波动情况，通常由当日与前一日的收盘价比较所得。成交量反映了市场成交规模，是计算其他技术指标的基础。成交金额综合考虑交易价格和交易量，反映了市场成交规模。换手率反映了市场交易的活跃程度。

（3）技术面数据

趋势指数主要包扣简单移动平均（MA）和异同移动平均（MACD）。MA 指标能够有效捕捉市场趋势的演进，凭借其平滑稳定的特征，既可呈现当前趋势状态，也有助于研判潜在的趋势转折信号。MACD 则表示价格与移动平均线

中国知网 https://www.cnki.net

的偏离距离，由快线与慢线的差值得到。当 MACD 剧烈变化时，表明快慢移动平均线差距迅速拉开，反映了市场趋势正在转变。故本文选取 MACD 作为主要的趋势指数。

波动指数主要选取方差（VAR），反映了特定时间段内市场的价格波动强度，其计算依赖于该时段每日涨跌幅序列。VAR 指数水平与市场波动程度呈正相关关系，数值越大，波动越显著。历史行情数据要素具体见表 2-1。

表 2-1 投资组合历史行情数据要素

Table 2-1 Elements of historical market data for investment portfolios

历史行情数据	具体类型	主要代表
基本面	历史数据	开盘价、收盘价、最高价、最低价
	基础数据	涨跌幅、成交量、成交金额、换手率
技术面	趋势指数	MA、MACD
	波动指数	VAR

2.3.2 投资组合金融舆情要素

（1）金融舆情信息分类

金融舆情在形式上大致可分为新闻舆情和股吧舆情两大类，两者均包含其主体对金融对象或事件的意见和态度。对于新闻舆情来源，本文选取具有较大影响力、权威性和可信性的官方媒体，如第一财经和华尔街日报等。新闻舆情也往往包含国家经济政策等内容，在一定程度上揭示了金融市场的系统性信息。同时新闻舆情具有舆论引导作用，能够影响市场主体信心，进而可能对未来市场趋势造成影响。通过对投资者产生影响，新闻舆情也可以进一步影响股票市场。股吧舆情则是由散户投资者在股吧发表的评论等信息组成。相较于客观、规范和高密度信息的新闻舆情，股吧舆情内容更为主观，信息较为分散，且可信度相对不高，但是也会存在着较为关键的内部信息。其反映了散户投资者对市场未来的心理预期和支持倾向，揭示了市场收益与波动状况。

（2）多源舆情作用分析

市场主体信心与舆情情绪在市场波动和政策传导中发挥着重要作用，新闻舆情也是预测市场波动的重要变量。新闻舆情是市场政策的重要传播者，通过对投资者情绪进行引导作用，进而影响市场波动。新闻舆情中的积极政策信息也能对冲投资者的非理性情绪，稳定市场基本信心。当新闻舆情包含乐观信息时，投资者情绪高涨，加大资金投入，从而促进股市高涨；当新闻舆情较为谨

中国知网 https://www.cnki.net

慎时，投资者也就降低投资意愿，股市相应低迷。在国内股票市场中，散户投资者占据 80%的交易份额，市场相对不成熟。股吧舆情中的信息大多也具有较高的投机成分，因此其造成的影响规模远不如新闻舆情。同时在不同的交易日和不同的经济周期，股吧舆情对市场的影响作用也相异。其具有较为明显的周一效应，在刚开市时的影响效果最为显著，与工作日形成的影响截然不同。

2.3.3 投资组合建模假设要素

针对股票市场交易实际操作中的一些问题，为了简化投资问题，同时降低因买进或卖出资金量过大而导致的价格严重偏离价值的问题，并且增强模型对金融舆情信息的响应能力，作出以下相关假设：

（1）股票交易的成交价格均以当日收盘价为准，每笔交易均假定在当日内一次性完成，并且股市不受深度强化学习交易智能体的影响。

（2）交易操作不会引起股价波动，为更贴近实际交易中的隐性成本，设置买入交易费率为 0.3%，卖出交易费率为 0.15%。

（3）设置单次买进和卖出的资产上限，进一步减小实际场景股价波动与智能体环境中股价不变之间的差异，避免资金集中导致的回撤大幅波动。

（4）影响公司股票的相关事件会真实地呈现在可信金融舆情中，这些信息能够客观体现公司经营状况，并可能对投资者信心产生影响。

（5）每条金融舆情信息对股票具有其特定程度的影响和作用，且不同信息对股票的影响效应是可叠加的。

2.4 考虑金融舆情的深度强化学习投资组合流程

2.4.1 金融舆情信号生成流程

金融舆情是影响投资者决策与市场动态的关键信息源，其信号生成的有效性与准确性直接关系到投资组合策略的优劣。为实现对金融舆情信息的系统性利用，本章设计了一套从原始舆情数据到结构化信号的完整生成流程。该流程以“数据获取—特征提取—信号合成”为主线，对舆情信息进行多维度解析与量化整合，为后续的深度强化学习投资组合模型提供了可靠、可解释的输入信号。具体流程如图 2-5 所示，包含以下四个核心环节：

中国知网 https://www.cnki.net

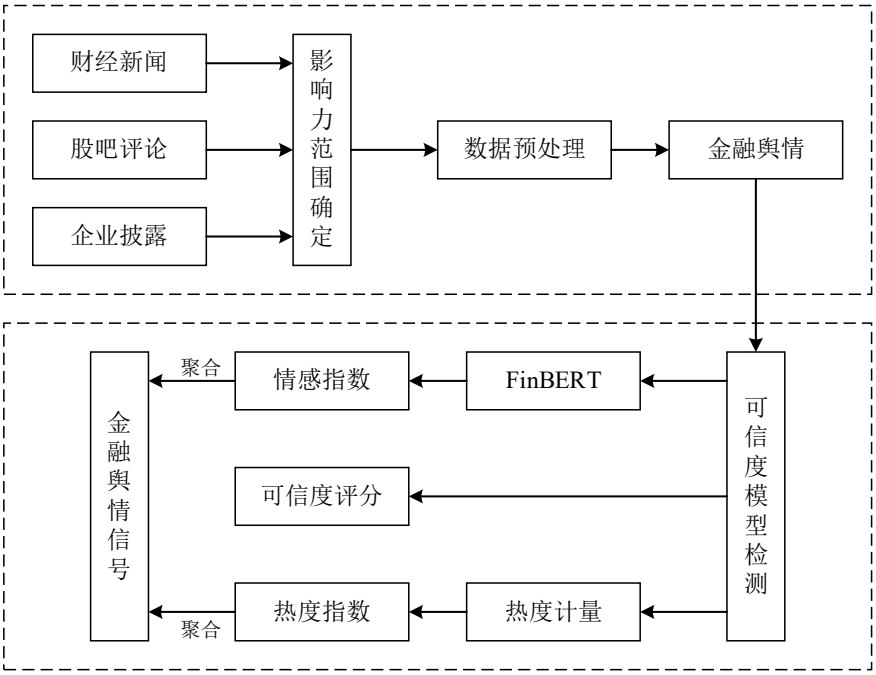


图 2-5 金融舆情信号生成流程

Fig. 2-5 Process of generating financial public sentiment signals

（1）多源舆情数据效力分析与预处理

金融舆情信号覆盖财经新闻、社交媒体、股吧论坛等多渠道的原始舆情文本，通过定向网络爬虫与 API 接口，系统化采集与目标资产相关的实时及历史舆情数据。随后进行效力分析和预处理，即确定舆情的影响力时间范围，并且进行文本清洗、去重、分词以及情感实体识别，为后续分析提供可靠的数据。

（2）舆情可信度模型检测与情感识别

在特征工程层面，执行可信度评估和情感分析两项核心任务。一方面，基于可信度模型，从信源权威性、内容客观性、情感极性及市场反应等多个维度对每条舆情进行可信度评分，筛除低可信度信息以降低噪声干扰。另一方面，采用 FinBERT 模型对文本进行细粒度情感分类，输出积极或消极的情感倾向及对应的概率强度，从而获取舆情的情绪价值信号。

（3）舆情热度指数构建与情感加权聚合

为反映市场关注度的差异化分布，基于日度发帖量与评论量计算舆情热度指数，衡量投资者对特定资产的集体注意力。进而将情感指数与热度指数进行耦合，通过热度加权生成综合情绪信号。不仅强化了高关注度舆情在情绪形成中的权重，也使得最终金融舆情信号兼具情绪方向和市场影响力的双重信息。

中国知网 https://www.cnki.net

（4）结构化信号序列生成与输出

将各资产在时间序列上的可信度评分、基础情感指数、热度指数及加权聚合的金融舆情信号进行对齐与整合，形成以时间为索引的多维信号矩阵。进而形成标准化、结构化的舆情特征表示，可直接输入至后续的深度强化学习投资组合模型，最后用于驱动投资决策模型的训练与优化。

2.4.2 深度学习特征识别流程

在投资组合建模中，深度学习特征识别流程是将原始市场数据逐步转化为高维抽象特征的过程，通常包含数据输入、浅层特征提取、时序依赖建模与特征融合等环节。该流程旨在从异构金融数据中自动学习与投资决策相关的状态表征，为后续强化学习智能体提供了信息丰富的输入。

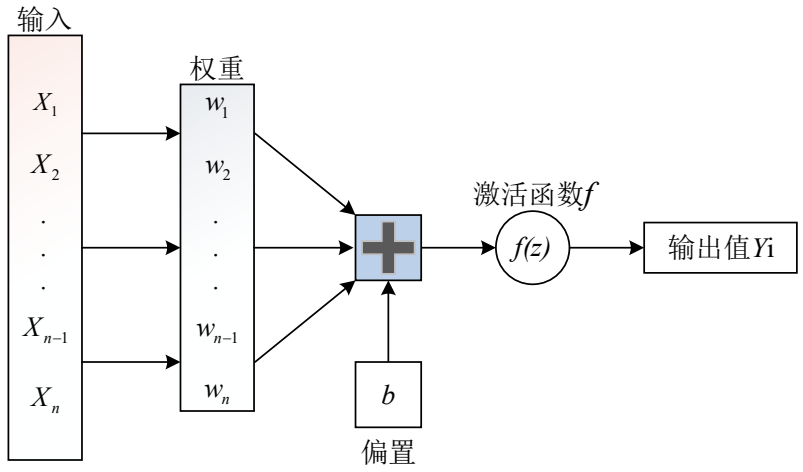


图 2-6 神经元基本模型

Fig. 2-6 The basic model of neuron

深度学习（Deep Learning，DL）是机器学习的关键算法之一，通过构建多层非线性结构模拟人脑信息处理方式，能够对非线性和高维数据的进行特征提取与模式识别。其基本构成单元为人工神经元，先对输入向量 $X=[x_1,x_2,\cdots,x_n]$ 与权重向量 $W=[w_1,w_2,\cdots,w_n]$ 进行内积，随后与偏置 b 求和，再经由激活函数 f 完成非线性映射，得到输出 $y=f\left(w^{\mathrm{T}}x+b\right)$，见图 2-6。神经网络的激活函数主要为 Sigmoid、ReLU 和 Tanh 等，其显著提升了模型表达能力。多个神经元按层排列进而形成深度神经网络（Deep Neural Network, DNN），其结构包含输入

中国知网 https://www.cnki.net

层、输出层和若干隐藏层，见图 2-7。在特征识别流程中，DNN 通过逐层前向传播对输入数据进行线性加权与非线性激活，逐步抽象出高层次特征，从而完成浅层特征提取任务。神经网络训练则依托于反向传播算法，通过链式求导法则，依次计算损失函数相对于每一网络层参数的梯度，随后利用梯度下降法对权重和偏置进行迭代更新，不断缩小模型输出与真实值的差距。然而，DNN 的全连接结构在处理序列数据时存在参数冗余且难以捕捉时序依赖。

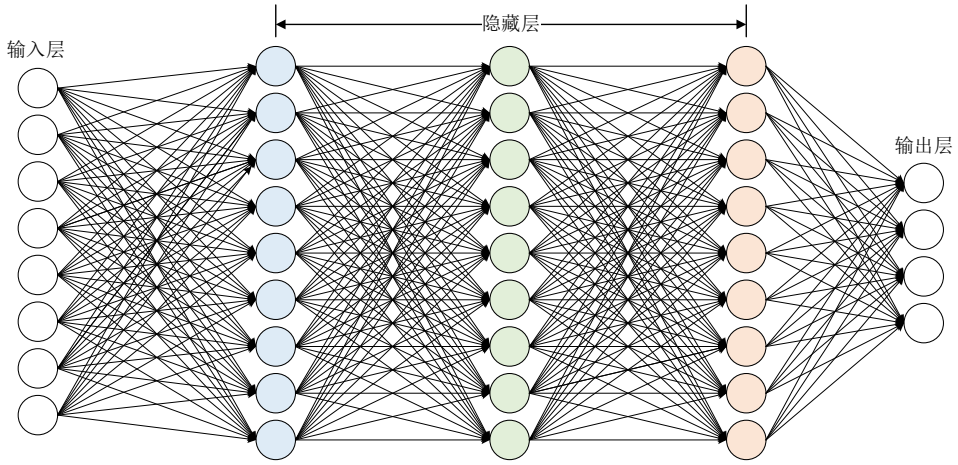


图 2-7 深度神经网络

Fig. 2-7 Deep neural network

金融舆情与行情数据本质上是时间序列，其内在的时序依赖关系对投资决策至关重要。为此，在特征识别流程中需引入时序依赖建模环节。循环神经网络（Recurrent Neural Network, RNN）通过循环连接使网络能够保留历史信息，由此可实现对建模序列的动态演化过程进行刻画。然而标准 RNN 在时间序列处理中易遭遇梯度爆炸问题，限制了其对序列中长期依赖关系的学习能力。进而长短期记忆网络（Long Short-Term Memory, LSTM）通过引入门控机制和记忆单元，有效解决了长期依赖问题，成为时间序列处理分析的主流模型。LSTM 单元可以选择性保留或遗忘历史信息，在金融数据建模中表现出色。同时为进一步增强序列特征的提取能力，双向长短期记忆网络（Bidirectional LSTM, BiLSTM）应运而生。其架构由前向与后向 LSTM 组合构成，分别从正向和反向两个维度对序列进行编码，并将两个方向产生的隐藏状态进行拼接，作为该层的综合输出。进而模型能够同时整合前后文信息，从而更全面有效地捕捉序列中的双向依赖特征。在特征融合环节，BiLSTM 输出的时序特征可与舆情情

中国知网 https://www.cnki.net

感得分与市场趋势指标等其他模态特征进行拼接或加权组合，从而形成最终的状态特征向量，直接输入至强化学习智能体的策略网络与价值网络。因此，本文选取 BiLSTM 作为深度强化学习投资组合模型中特征融合模块的核心组成部分，并在整个特征识别流程中承担关键角色。

2.4.3 单智能体强化学习投资决策流程

单智能体强化学习的本质在于智能体通过与环境持续交互，不断试错并从中学习最优策略。与传统监督学习依赖于静态标注数据不同，强化学习的核心在于通过试错-反馈-优化的闭环机制，使智能体能够在动态环境中逐步提升其决策性能，以实现长期累积收益的最大化。同时因其在序贯决策问题上的通用性与优越性，已被广泛应用于金融投资组合管理领域。强化学习投资决策流程主要包括智能体与环境交互，马尔可夫决策过程以及强化学习求解。

（1）智能体与环境交互

在强化学习框架中，一个标准的决策流程通常由六大核心要素组成。状态（State）：智能体对当前环境的观测与感知，在投资问题中指资产价格、收益率、波动率及持仓数据等信息。动作（Action）：智能体基于当前状态的可执行操作集合，在投资中通常指资产配置权重的调整。状态转移概率（P）：指当前状态环境转移到下一状态的概率分布，反映了环境的不确定性。奖励（Reward）：环境对智能体动作的即时反馈信号，在投资组合管理中通常与收益率等投资目标直接相关。策略（Policy）：是智能体决策的核心依据，体现为从状态空间到动作空间的映射。值函数（Value）：用于量化在某一状态下遵循当前策略所获得的长期累积奖励期望，反映策略的整体性能。

单智能体强化学习与环境的交互过程如图 2-8 所示：当智能体处于状态 S_t 时，其策略 policy 对 S_t 进行评估并采取相应的动作 A_t，从而使得状态 S_t 转移至新状态 S_{t+1}，同时奖励函数结合 A_t 和 S_{t+1} 计算出奖励值 R_t，并将其反馈回智能体。进而智能体将此次交互经验 (S_t, A_t, R_t, S_{t+1}) 存入记忆库，利用这些经验不断优化其策略或值函数，逐步提升累积奖励，从而学习到最优策略 π^*。策略函数见式（2-9），π 为策略、γ 为折扣因子，T 为时期总数。

$$\pi^* = \arg\max_{\pi} E_{\pi}\left\{\sum_{T=0}^{\infty}\gamma^T r_{t+T}\,|S_t = S\right\}, \forall s \in S, \forall t \geq 0 \tag{2-9}$$

中国知网 https://www.cnki.net

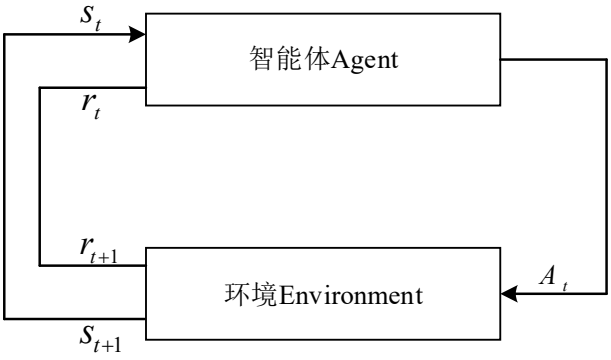


图 2-8 单智能体交互过程

Fig. 2-8 The interaction process of a single agent

（2）马尔可夫决策过程

马尔可夫决策（Markov Decision Process，MDP）是大多数强化学习问题的通用架构之一，已被研究人员广泛应用于各类问题。MDP 表明在随机过程的 S_{t+1} 时，环境的反馈取决于 S_t 和 A_t，而与之前的状态和动作无关。这种无后效性大大降低了强化学习问题的运算难度。具备此性质的随机过程也被称为马尔可夫过程，并由有限状态序列 S 和状态转移概率 P 定义。t 时刻状态 S_t 的转移概率为：

$$P\left[S_{t+1}\middle|S_t\right]=P\left[S_{t+1}\middle|S_1,\cdots,S_t\right] \tag{2-10}$$

可知马尔可夫状态 s 和后序状态 s' 的转移概率为：

$$P_{ss'}=P\left[S_{t+1}=s'\middle|\ S_t=s\right] \tag{2-11}$$

其表示状态 S 转移到所有状态 S' 的转移概率，具体状态转移矩阵 P 定义如下：

$$P=\begin{bmatrix} p_{11} & \cdots & p_{1n} \\ \cdots & \cdots & \cdots \\ p_{n1} & \cdots & p_{nn} \end{bmatrix} \tag{2-12}$$

MDP 过程包括智能体和环境两个部分，智能体基于对环境状态的观测开展学习，进而采取相应行动，并根据环境反馈实现对策略的动态优化。环境可定义为智能体外部所有要素的总和，其状态演化受智能体动作的直接影响。MDP 由策略（π）、状态（s）、动作（a）、奖励（r）和回报（G）五大部分组成，因此可将 MDP 定义为五元组（S，A，P，R，G）。MDP 的状态转移概率受到状态 s 和动作 a 的共同影响，故而从状态 s 到 s' 的转移概率为：

中国知网 https://www.cnki.net

$$P_{ss'} = P(S_{t+1} = s' | S_t = s, A_t = a) \tag{2-13}$$

基于策略 π 的智能体的状态转移概率为：

$$\begin{aligned} &P_{SS'}^{\pi} = \sum_{a \in A} \pi(a|s) P_{SS'}^{a}, R_S^{\pi} \sum_{a \in A} \pi(a|s) R_S^{a} \\ &\pi(a|s) = P[A_t = a | S_t = s] \end{aligned} \tag{2-14}$$

累积奖励回报定义为：

$$G = \sum_{t=0}^{T-1} R_{t+1} \tag{2-15}$$

然而在实际情况中，当时间步长较大时，其动作对智能体的影响理应随着时间步长减弱，否则将会导致奖励函数趋于无穷，因此也就失去了优化效果。故而采用折扣因子 γ 来控制，t 时刻的折扣回报 G_t 为：

$$G_t = R_{t+1} + \gamma R_{t+2} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \tag{2-16}$$

$\gamma \in [0,1]$ 越接近 0 时则越考虑当前利益，越趋于 1 则更加重视后续价值。

（3）**求解强化学习**

贝尔曼方程为价值函数提供了迭代求解的基础。其以科学家 Richard E. Bellman 命名，是动态规划中的核心优化条件，在强化学习中用于指导策略更新与算法设计。现定义关键变量 $R_{ss'}^{a}$ 用于衡量经过状态转移 $P_{ss'}^{a}$ 后的期望即时奖励：

$$R_{ss'}^{a} = E\left[R_{t+1} | S_t = s, A_t = a, S_{t+1} = s' \right] \tag{2-17}$$

基于马尔可夫决策过程性质可知，下一时刻状态仅依赖于当前状态与动作。贝尔曼方程通过递归形式分别定义了状态价值函数和动作价值函数的表达式：

$$V^{\pi}(s) = \sum_{a} \pi(a|s) \sum_{s'} P_{ss'}^{a} \left[R_{ss'}^{a} + \gamma V^{\pi}(s') \right] \tag{2-18}$$

$$Q^{\pi}(s,a) = \sum_{s'} P_{ss'}^{a} \left[R_{ss'}^{a} + \gamma \sum_{a'} \pi(a'|s') Q^{\pi}(s',a') \right] \tag{2-19}$$

强化学习的核心目标是获得最优策略，其可由最优值函数表征。最优状态价值函数 $v^*(s)$ 定义为策略空间中能最大化状态 s 价值的函数：

$$v^*(s) = \max_{\pi} v^{\pi}(s) \tag{2-20}$$

类似地，最优动作价值函数 $q^*(s,a)$ 定义为：

中国知网 https://www.cnki.net

$$q^*(s,a)=\max_{\pi} q^{\pi}(s,a) \tag{2-21}$$

最优值函数反映了智能体在马尔可夫决策过程中所能达到的理论性能上限。获得最优值函数后，即可确定每个状态对应的最优价值，从而完成对整个决策过程的求解。

若在状态 s 下策略 π 的价值函数不劣于任何其他策略 π'，则称 π 为该状态下的最优策略，即：

$$\pi \geq \pi', v^{\pi}(s) \geq v^{\pi'}(s), \forall s \tag{2-22}$$

由此，最优策略可以通过对最优动作价值函数执行最大化操作来获得，其具体定义如下：

$$\pi^*(a \mid s)=\begin{cases}1, & \text{if } a=\arg\max_{a\in A} q^*(s,a)\\ 0, & \text{otherwise}\end{cases} \tag{2-23}$$

最大化动作值函数的动作构成最优策略的决策输出。任意马尔可夫决策过程的最优策略皆具有确定性表示。对于状态空间较小的情形，可通过值函数的精确求解获取最优策略。而对于大规模问题，常采用动态规划和蒙特卡洛等迭代方法来对贝尔曼方程近似优化。其需在探索与利用之间权衡，探索旨在尝试新动作以获取更多环境信息，利用则是基于当前知识选择最优动作。在基于模型的任务中，环境信息完全已知，因此无需探索。而在无模型任务中，探索与利用均至关重要，此时需要 ε −贪婪算法来处理两者的权衡问题，其数学定义如下式所示：

$$A=\begin{cases}\arg\max_{a} Q(a), & P=1-\varepsilon\\ \text{Random Action}, & P=\varepsilon\end{cases} \tag{2-24}$$

其中：智能体以概率 $P=\varepsilon$ 随机选择动作进行探索，以概率 $P=1-\varepsilon$ 选择当前价值最大的动作执行以利用已有经验。可知贪婪算法能够依据动作执行结果及所获奖励动态调整策略，从而有效避免陷入局部最优。

2.4.4 多智能体强化学习集成决策流程

多智能体强化学习决策融合流程的实质，是多个智能体在环境中通过协同或竞争机制进行序贯决策，并在交互过程中不断优化自身策略的动态过程。与单智能体强化学习不同，多智能体强化学习系统（Multi-Agent System，MAS）遵循随机博弈过程，通常由多元组 $\left(S, A_1, A_2, \cdots, A_n, R_1, R_2, \cdots, R_n, f, \gamma\right)$ 构成。其中

中国知网 https://www.cnki.net

环境状态空间为 S，系统中智能体总数为 n，第 i 个智能体的动作空间记为 A_i，表达式 $(A = A_1 \times A_2 \times \cdots \times A_n)$ 即为所有智能体的联合动作空间。进而联合状态转移概率函数可表示为：

$$P\left(s'|s,a\right): S \times A \times S \to [0,1] \tag{2-25}$$

上式描述了当智能体采取联合动作 a 后，环境状态由 $s \in S$ 转移到状态 $s \in S'$ 的概率分布，进而各智能体的奖励函数可表示为：

$$R_i\left(s,a,s'\right): S \times A \times S \to \mathbb{R}, i = 1,2,\cdots,n \tag{2-26}$$

在 MAS 中，状态转移由所有智能体的联合行为共同决定，其决策融合流程首先体现为各智能体基于当前局部或全局观测，分别执行其相应的个体策略以选择动作，具体如下式所示：

$$a_k = \left[a_{1,k}^{\mathrm{T}}, a_{2,k}^{\mathrm{T}}, \cdots, a_{n,k}^{\mathrm{T}}\right]^{\mathrm{T}}，\ a_k \in A, a_{i,k} \in A_i \tag{2-27}$$

$$\pi_i : S \times A_i \to [0,1] \tag{2-28}$$

所有智能体动作和策略共同构成联合策略 π，联合动作决定了各智能体下一时刻获得的回报 $r_{i,k+1}$，各智能体通过联合动作空间进行交互。因此智能体 i 遵循联合策略 π 所获得的期望总收益，也即其状态价值函数可表示为：

$$R_i^{\pi}(s) = E_{\pi}\left\{\sum_{k=0}^{\infty}\gamma^k r_{i,k+1} \,\middle|\, s_0 = s\right\} \tag{2-29}$$

同时各智能体的联合动作价值函数取决于联合动作 $Q_i^{\pi} : S \times A \to R$，其表达式如下式所示：

$$Q_i^{\pi}(s,a) = E\left\{\sum_{k=0}^{\infty}\gamma^k r_{i,k+1} \,\middle|\, s_0 = s, a_0 = a, \pi\right\} \tag{2-30}$$

上述过程构成了多智能体强化学习中环境观察→策略制定→联合动作选择→状态更新与反馈的决策融合流程。此外根据回报函数的差异，MAS 可分为完全竞争型、完全合作型与混合型三种类型。完全合作型中各智能体协同合作且目标一致，回报函数完全相同。相应的完全竞争型方法中各智能体则是相互竞争，致力于实现自身利益最大化和尽可能削弱对方回报。而混合型方法中各智能体的回报函数不存在明确的正负关系，每个智能体均为自利型，既可竞争可能合作。综上可知 MAS 通过多智能体之间的决策融合机制，既能相互配合解决高复杂高纬度问题，亦可通过相互博弈学习对手策略。因此本文选用 MAS 来解决不同市场趋势下的投资组合问题，其具体框架结构如图 2-9：

中国知网 https://www.cnki.net

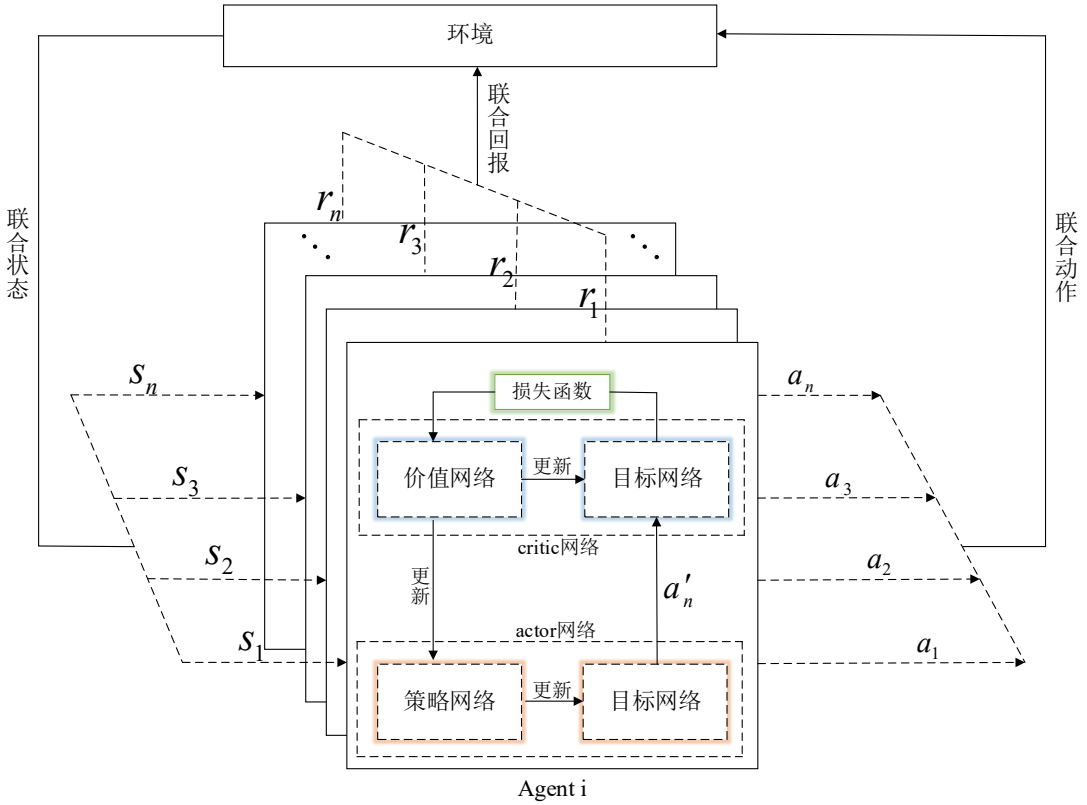


图 2-9 MAS 框架

Fig. 2-9 The structural framework for multi-agent systems

2.4.5 深度强化学习增强决策流程

深度强化学习（Deep Reinforcement Learning，DRL）有机结合深度学习的感知能力和强化学习的决策能力，实现了从数据感知到动作决策的端到端学习，使智能体能在复杂环境中采取最优策略。深度强化学习增强决策的核心流程包括：首先智能体获取当前状态 s_t，进而依据策略 $\pi(a|s)$ 执行动作 a_t，环境返回奖励 r_t 并输出下一状态 s_{t+1}。完成后将经验 (s_t, a_t, r_t, s_{t+1}) 存入回放缓冲区，便于智能体从中随机采取数据，以训练神经网络。通过不断重复动作过程，智能体逐步优化收敛至最优策略。DRL 的核心在于利用深度神经网络对强化学习中的价值函数与策略函数进行表征和拟合，据此可分为基于价值函数和基于策略函数 DRL 两大类。前者利用深度神经网络模拟状态-动作值函数，进而优化深度神经网络的输出动作值以获取最优决策。而基于策略函数的 DRL 则通过神经网络直接模拟策略分布进而执行相应的动作决策。基于价值函数的 DRL 算法有深

中国知网 https://www.cnki.net

度 Q 网络（Deep Q-Network，DQN）和改进 Double DQN 与 Dueling DQN。基于策略函数的 DRL 算法有 Actor-Critic 算法以及改进的 A3C 算法。此外，结合价值函数和策略函数的两方优势，出现了在各项性能上也明显提升的 DDPG 算法。DRL 基本框架见图 2-10。

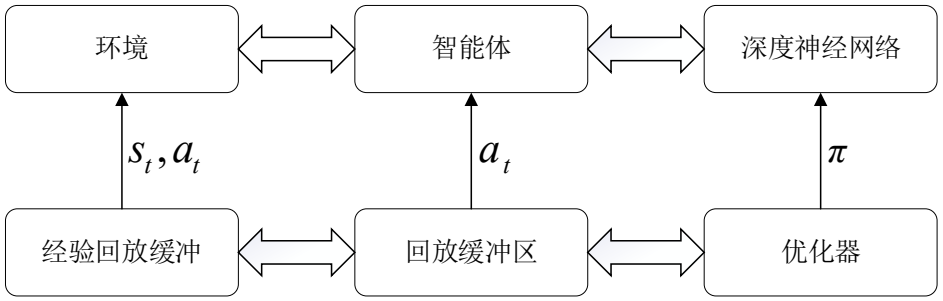


图 2-10 DRL 基本框架

Fig. 2-10 The basic framework of deep reinforcement learning

(1) **决策增强机制**

DRL 增强决策流程的核心在于利用深度网络提升决策能力，同时通过经验回放和目标网络机制有效增强了学习过程的效率与稳定性，从而优化了决策流程。其中 DQN 通过经验回放机制使智能体储存每一时间节点的经验 $e_t\left(s_t,a_t,r_t,s_{t+1}\right)$，进一步生成回放记忆序列，在训练中分批小量地从神经网络中采取经验信息，并利用梯度下降更新参数，有效降低了数据间的关联性并极大提高了数据使用率。DQN 中的目标网络由卷积神经网络构成，也称为 Q 网络，不断逼近值函数，将值函数表示为 $Q\left(s,a,\theta_i\right)$，$\theta_i$ 指第 i 次迭代时的网络参数。Q 网络中迭代更新公式见下式（2-31），其中所有可能的动作记为 a'，s' 表示下一时刻的状态，目标网络参数设为 θ_i^-。

$$y = r + \gamma \max Q\left(s', a', \theta_i^-\right) \tag{2-31}$$

DQN 的具体实现流程可概括为：首先将当前状态输入网络，经由卷积神经网络 CNN 和全连接层的非线性变换后，最终由输出层映射为动作和状态的对应的 Q 值函数。DQN 结构如图 2-11 所示。

中国知网 https://www.cnki.net

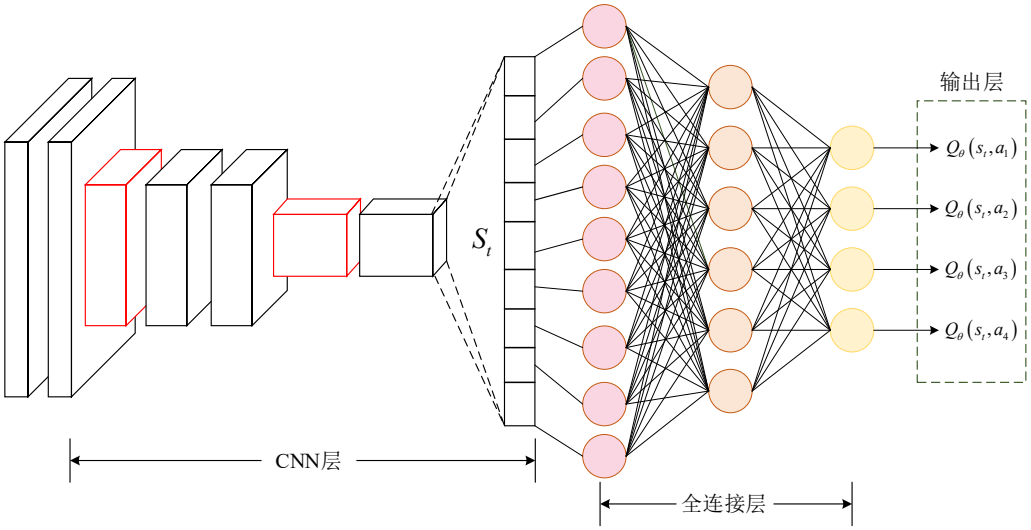


图 2-11 深度 Q 网络结构

Fig. 2-11 The structural diagram of deep Q-network

（2）决策协同优化

深度强化学习增强决策流程中的关键方法为演员评论家方法（Actor-Critic，AC），通过将策略优化与价值评估分离，形成了 Actor 与 Critic 协同迭代的决策优化流程。AC 算法通过整合 Q-Learning 算法和策略梯度算法（Policy Gradient Algorithm，PG），构建了一个由 Actor 策略网络与 Critic 价值网络组成的双网络架构。其中，Actor 网络以 PG 算法为原型，经过演化形成其策略学习模块，然后输入状态，并输出相应的动作。其拟合了动作和环境的交互，使智能体能够采取合适的行动。Critic 则主要基于深度 Q 网络，输入来自 Actor 网络的状态和动作，并输出相应的 Q 值来评估 Actor 网络的性能。Critic 价值网络通过值迭代方法实现单时间步更新，用偏差换取更小偏差，并运用环境与奖励函数的关系计算当前状态的潜在奖励。Critic 网络的损失函数主要为：状态价值，时序差分法，优势函数等，其中大部分基于时序差分法。AC 算法的主要步骤为：Actor 网络通过概率分布选择合适的动作，Critic 网络利用 Actor 中的动作判断其价值，同时反馈到 Actor 网络，完成动作选取的优化，经过不断迭代和参数更新，最终得到收敛的 AC 网络。AC 网络具体框架如图 2-12 所示：

中国知网 https://www.cnki.net

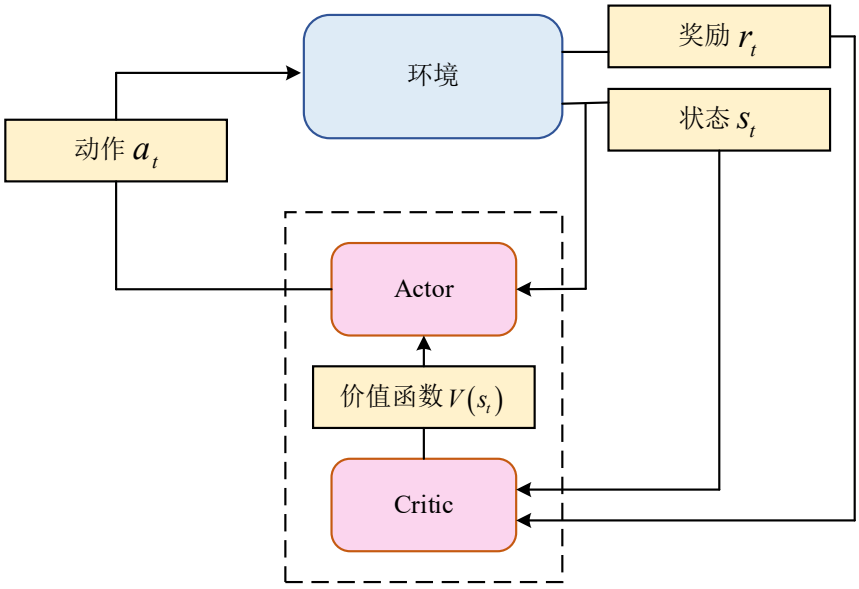


图 2-12 AC 网络基本框架

Fig. 2-12 The fundamental architecture of Actor-Critic networks

具体来说，AC 算法中价值网络的评估公式和梯度公式更新分别如下式（2-32）和（2-33）：

$$\begin{aligned} R(t^n)-b &= Q^{\pi_\theta}(S_t^n,a_t^n)-V^{\pi_\theta}(S_t^n) \\ &= r_t^n+V^{\pi}(s_{t+1}^n)-V^{\pi}(s_t^n) \end{aligned} \tag{2-32}$$

$$\nabla \bar{R}_\theta = \frac{1}{N}\sum_{n=1}^{N}\sum_{t=1}^{T_n}\left(r_t^n+V^{\pi}(s_{t+1}^n)-V^{\pi}(s_t^n)\right)\nabla_\theta \log \pi_\theta(a_t^n \mid s_t^n) \tag{2-33}$$

相较于传统的策略梯度算法，AC 算法通过分离策略优化与价值评估，提高了学习率，同时使用 Critic 价值减少了策略梯度的方差，故其广泛适用于连续和离散的动作空间。但是 AC 算法的缺点也很明显，由于 Critic 神经网络很难收敛，因此 AC 网络一起更新则更难收敛。为解决收敛问题研究者们提出了改进的 A2C，PPO 和 DDPG 方法。

（3）近端策略优化稳定决策

近端策略优化算法（Proximal Policy Optimization，PPO）在 Actor-Critic 框架基础上，通过引入裁剪机制约束策略更新步长，有效增强了决策流程的稳定性与收敛性能。因此，本文采用 PPO 作为基础算法和核心框架，利用策略网络解决投资组合权重分配问题，通过评价网络处理资产权重分配的评价问题。

中国知网 https://www.cnki.net

设一个策略π_θ从状态空间到动作空间的参数化映射为：$S\times A\to[0,1]$，PPO的目标函数实现了带裁剪的目标函数，通过裁剪机制 Clip 限制新旧策略比值的变化范围，防止策略过于激进，其目标函数为：

$$L(\theta)=\hat{E}_{\pi_\theta}\left[\min\left(\frac{\pi_\theta(a_t|s_t)}{\pi_{\theta'}(a_t|s_t)}A_t^{\theta'},clip\left(\frac{\pi_\theta(a_t|s_t)}{\pi_{\theta'}(a_t|s_t)},1-\varepsilon,1+\varepsilon\right)A_t^{\theta'}\right)\right] \tag{2-34}$$

其中优势函数$A_t^{\theta'}$由 Critic 估计，衡量动作a_t相较于平均表现的优越性，其表达式为：

$$A_t^{\theta'}=Q^{\theta'}(s_t,a_t)-V^{\theta'}(s_t) \tag{2-35}$$

优势函数中的状态-动作价值函数$Q^{\theta'}(s_t,a_t)$可表示为：

$$Q^{\theta'}(s_t,a_t)=E_{\pi_{\theta'}}\left[\sum_{k=0}^{\infty}\gamma^k r_{t+k+1}|s_t=s,a_t=a\right] \tag{2-36}$$

价值函数$V^{\theta'}(s_t)$为：

$$V^{\theta'}(s_t)=E_{\pi_{\theta'}}\left[\sum_{k=0}^{\infty}\gamma^k r_{t+k+1}|s_t=s\right] \tag{2-37}$$

2.5 本章小结

本章系统阐述了考虑金融舆情的深度强化学习投资组合机理。首先界定了金融舆情、投资组合及深度强化学习投资组合的内涵，明确其概念边界；进而从深度强化学习内部驱动、投资者行为效应及资产价格与股票市场的舆情传导协同三个维度剖析了模型构建的动因；随后梳理了历史行情与金融舆情两类核心要素，并提出了建模假设；最后详细设计了金融舆情信号生成、深度学习特征识别、单智能体与多智能体决策以及深度强化学习增强的完整流程。本章论述为后续模型构建提供了必要的理论支撑与逻辑铺垫。

中国知网 https://www.cnki.net

第3章 考虑金融舆情的深度强化学习投资组合舆情信号生成

金融舆情影响投资者决策与市场波动，其有效识别与量化是构建智能投资组合的前提。但网络舆情鱼龙混杂，虚假与噪音并存，直接使用可能误导投资。为此，本章设计金融舆情信号生成框架：先进行舆情效力分析，构建可信度判别指标；再引入模型检测实现可信度自动验证；然后采用 FinBERT 进行情感测度，结合热度加权聚合，最终生成可用于投资决策的舆情信号，为后续模型提供高质量输入。

3.1 金融舆情效力分析

3.1.1 金融舆情效力判别路径

财经金融舆情通过网络的广泛传播已成为影响投资者态度和行为的主要因素。当资本市场存在虚假舆情或上市公司盈利信息失实等情况时，虚假的金融舆情会导致投资者产生错误的决策行为，进而损害投资者正当权益，亦动摇了公众对媒体的信任基础。故在投资决策前对金融舆情的真实性进行判别尤为重要，有助于从源头上控制其对资本市场可能造成的重大损失，并且能够帮助投资者合理利用财经金融舆情。

情绪和认知是研究个体信息行为的重要线索，也是金融舆情效力判别的重要线索，其共同驱动虚假舆情信息的识别。其中认知涉及个体对信息的接收、编码、存储与调用，涵盖注意、记忆、推理及决策等一系列心理过程。个体对信息的识别判断，本质上取决于其综合认知水平。在此基础上，可进一步提炼出卷入度、感知可信度、感知价值、感知风险与自我效能等认知要素。情绪则被视为对舆情认知判断的结果，由效价与唤醒两个维度构成。在金融舆情效力判别中，投资者主要依赖注意、记忆、推理与决策等认知过程，即认知路径构成判别的主渠道。与此同时，情绪状态也会反向调节投资者的注意广度、记忆偏向、推理方式与决策倾向，即情绪因素是投资者进行金融舆情效力判别的影响因素，构成金融舆情效力判别的边缘路径。因此投资者通过借助认知机制对舆情信息的内容质量及其信源声誉加以判断，并由此产生特定的行为倾向和情

中国知网 https://www.cnki.net

绪反应，进而对金融舆情信息进行识别判别。该过程是个体认知、信息与情绪的复杂交互过程，具体关系模型如下图 3-1 所示：

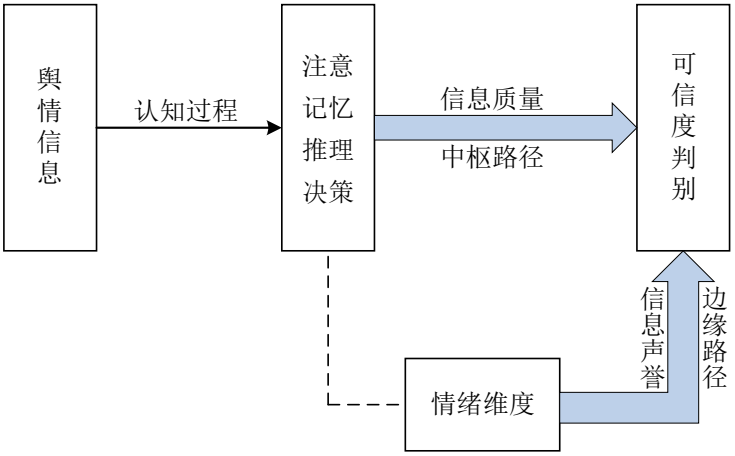


图 3-1 舆情判别交互过程

Fig. 3-1 The interaction process of public opinion judgment

3.1.2 金融舆情可信度指标构建

尽管金融舆情可信度的相关研究尚不丰富，但在线信息可信度的评估方法已有较为成熟的发展。信息可信度本质上是用户对信息质量的主观认知判断。针对社交网络平台，现有评估框架主要从信息源和传播途径两个维度切入，进一步整合为包含内容线索、社会线索及信源线索的静态模型[93]。用户在判断信息可信度时，多借助内容线索与主观感知，后者因缺乏客观性而使得信源与内容线索成为可信度评估的核心要素。金融舆情的主要来源为财经新闻报道，既有研究对网络舆情可信度的检测多从创作者特征、新闻内容与社交背景信息三个维度切入。考虑到金融舆情内在关联企业与投资者两类主体，本文从一般性信息可信度指标和企业相关指标两个层面构建评估框架，具体指标见表 3-1。

（1）一般信息可信度指标

财经新闻报道作为金融舆情的主要传播载体，既承载企业基本面数据，也包含能够左右市场预期的定性信息。投资者对企业前景的判断，取决于其所能获取的信息集合的完整程度。该信息集合以新闻内容为主体，整合了公司公告、媒体报道与分析师报告等渠道的定性定量信息。在可信度方面，官方来源的信息可信度普遍高于商业或民间等非官方渠道，表述的客观程度越高，信息可信度也随之增强。此外，新闻报道的情感倾向与股票收益率之间存在正向关联。

中国知网 https://www.cnki.net

因此，金融舆情来源、内容客观程度以及内容情感极性成为判断金融舆情可信度的关键依据。

（2）企业相关指标

企业财报数据和市场层数据是企业指标的两大组成部分。公司财报虽能较为全面地反映企业的财务状况与发展趋势，却因行业差异与发展阶段不同而难以形成统一评判标准。相较而言，股价、换手率、大股东及机构投资者行为等市场指标，能够更直观地反映企业在证券市场的运行状态。股价本质上是市场对新闻信息与投资者行为的即时反应，新闻情感极性也与股价波动、舆情期间成交量之间存在显著关联。换手率作为流动性的重要表征，其下降往往伴随着企业负面舆情与市场悲观情绪。依据行为金融学的羊群效应可知，信息不对称条件下个体投资者的决策往往倾向于追随其他投资者行为。机构投资者与大股东凭借其在信息处理能力与利益诉求方面的天然优势，其交易行为对于舆情可信度判别同样具有较强的参考价值。据此，股价波动、市场换手率及股东持股情况等市场数据，可作为研判金融舆情可信度的重要企业指标。这些指标从市场参与者的实际交易行为出发，为舆情可信度判断提供了客观的量化依据。

表 3-1 金融舆情可信度指标

Table 3-1 Indicators for the credibility assessment of financial public opinion

舆情可信度指标	指标对应内容
一般信息可信度指标	金融舆情来源
	内容客观程度
	内容情感极性
企业指标	股价变化
	市场换手率
	股东持股情况

3.1.3 金融舆情影响力范围确定

（1）舆情影响力曲线

研究捕捉随时间推移而变化的舆情影响力特征，有助于更深入地理解市场动态。考虑到社会信息传播及其影响的复杂性，对舆情影响力特征的分析研究有必要了解其理论基础：其一，舆情发布时间构成事件的锚定点，而非事件实际发生时间，事件信息需要时间完成社会传播，其影响力随公众反应程度的提升而增强到达峰值后，随时间推移呈现衰减特征；其二，事件影响可能早于舆

中国知网 https://www.cnki.net

情发布时间产生，因此需要建立基于锚定点的逆向影响力机制。例如某些特定事件在信息公开前，知悉此类未公开内部信息的投资者，则可通过预先交易实现超额收益。这种现象虽然符合上述理论框架，但信息传播时序与舆情发布点的非一致性可能导致事件影响力在舆情新闻公开前已作用于股价波动。因此理想化公开信息与内部信息呈现出明显的差异特征，相关对比关系如图 3-2 所示：

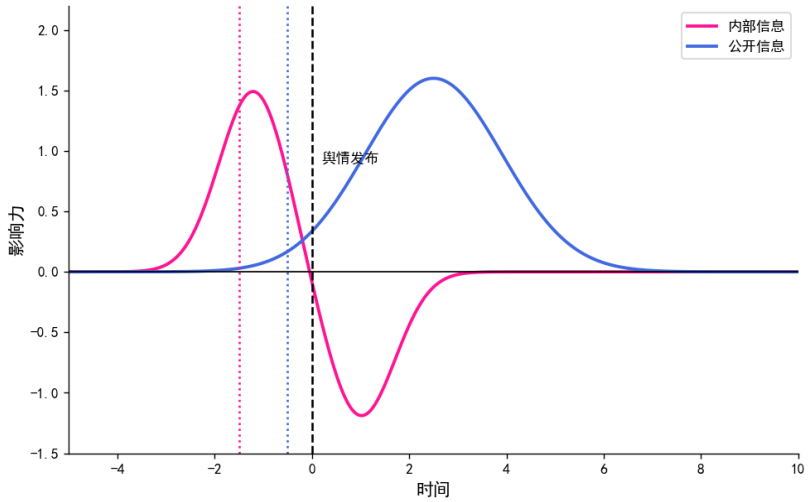


图 3-2 舆情影响力曲线

Fig. 3-2 The influence curve of message

其中蓝色曲线代表理想化公开信息影响力曲线，当事件发生时，舆情信息影响力开始累积，至黑色虚线标记的舆情新闻正式发布时，影响力持续增强至顶峰，随后随时间推移逐渐衰减至消失。代表内部信息的粉色影响力曲线则呈现差异化特征：在舆情新闻发布前，内幕知情者已通过非公开渠道获取信息并进行交易，导致信息影响力提前作用于市场，舆情新闻公开后，市场则出现过度反应，甚至产生反向调节效应。此类信息传播路径的非对称性，本质上反映了舆情信息质量对市场影响传导机制的差异。因此本文将舆情新闻影响力定义为驱动市场价格波动的外生动力，以舆情发布日期为核心锚定点，假设信息影响力在锚定日前后相同时间范围内对称分布。根据单条舆情新闻情绪影响力具有等权可加性，总影响力可通过下式计算：

$$\gamma_t = b + w_{t-r}S_{t-r} + \cdots + w_{t+r}S_{t+r} \tag{3-1}$$

其中 t 为舆情新闻发布时间，r 表示单条舆情对市场价格的影响时间半径，ω 为舆情情绪对市场价格的动态影响权重，S 是当日舆情情绪评分总和，b 为影响力基准调节参数。

中国知网 https://www.cnki.net

（2）舆情影响力范围

舆情文本主要由标题和主体构成，两者对于市场的影响力不尽相同。为测试两者的影响力差异，结合上文的影响力公式，以 APPL 公司为例进行简单测验。其中对于舆情文本主体仅提取正文中与目标公司相关的情感特征，而对照组则整合舆情标题内相关的情感特征。测试结果如图 3-3 所示：

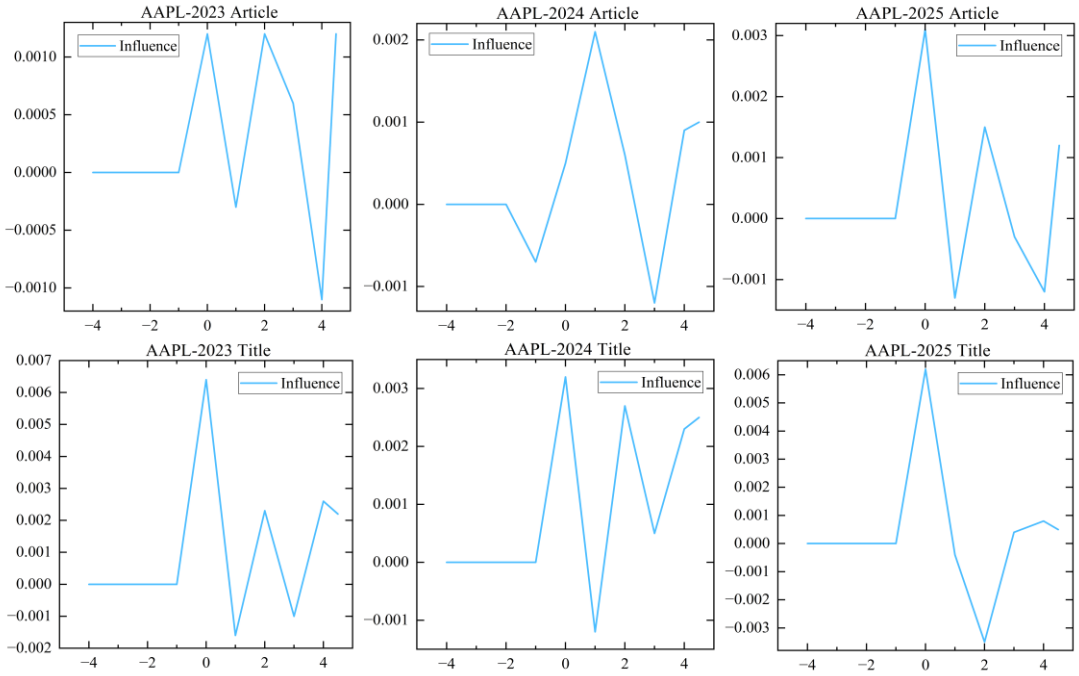


图 3-3 舆情文本主体与标题影响力对比

Fig. 3-3 The comparison of influence between main body and title of public opinion texts

测验结果表明，舆情标题的情感影响力显著高于正文。据此，本文设定标题与正文情感评分的权重配比为 6:4，从而强化标题信息在决策过程中的权重。考虑到舆情影响力的持续周期通常不超过两周，最终确定最优时间窗口为±5 天，即以舆情新闻发布日期 t 为锚点，向前后各延伸 5 天。通过该参数配置有效捕捉了市场短期反应，也兼顾了对长期噪声的抑制能力，从而在模型的灵敏度与稳健性之间实现了合理平衡。

中国知网 https://www.cnki.net

3.2 金融舆情可信度模型检测

3.2.1 金融舆情可信度模型检测框架

（1）可信度模型检测方法

信息可信度检测方法可划分为实践导向型与研究导向型两类。在研究导向型方法中，又可依据研究对象、数据挖掘技术和实现方式等不同维度进行划分。现有可信度检测方法虽具备较高精度，但多数未设定清晰的评判规则，难以满足决策者的深度分析需求。模型检测作为一种针对有限状态系统的形式化验证方法，旨在检验系统行为是否满足给定的逻辑规范。模型检测流程一般涵盖系统模型构建、检测规则生成以及模型验证三个阶段，具体如下：

系统模型构建，该环节基于源数据提取系统状态信息，据此构建能够刻画状态转移关系的模型。通常采用 Kripke 结构对目标系统进行形式化描述，将有穷状态转移系统的行为表达为一种模型结构。

检验规则提取，依据客观规律对检测规则进行提取，并将其形式化表达，为逻辑异常识别提供量化依据。检验规则主要源于既有规律与数据统计分析，并采用分支时序逻辑的计算树逻辑 (computing tree logic，CTL)对检验规则形式化表示，最后将系统状态的演化可能路径组织为树状结构。

模型检测执行，此阶段的核心任务是对状态转移关系在时序逻辑层面的有效性进行验证。符号模型检测（symbolic model checking，SMC）作为当前处理复杂系统与高维数据模型的主流方法，此阶段发挥着关键作用。

本文将模型检测算法引入金融舆情可信度检测领域。然而，当前数据检测规则多依赖人工对既有规律的归纳总结，难以有效应对金融舆情可信度检测所面临的高维性与动态性挑战，实现规则构建的自动化已成为必然趋势。决策树（decision tree, DT）作为一种从样本数据中归纳分类规则的机器学习方法，其学习结果的规则形式天然具有可解释性强的特点。此外决策树可通过子树融合的方式表征模型检测中 Kripke 结构的状态行为，从而自动生成用于验证模型正确性的检测规则。基于上述特性，决策树算法能够实现可信度评估规则的自动构建，在降低人工成本的同时，显著提升模型检测过程的效率与自动化水平。

（2）金融舆情模型检测框架

本节提出的金融舆情可信度检测框架，旨在建立一个能够对金融舆情进行自动化评估与验证的可信度模型。该框架由数据准备、模型检测与结果分析三个模块构成，其结构如图 3-4 所示。在数据准备阶段，首先对原始数据进行清

中国知网 https://www.cnki.net

洗与预处理，随后采用决策树算法生成可信度检测所需的规则路径。依据决策树中各特征节点的先后顺序，结合时序关系对各类金融舆情数据进行状态建模，进而构建金融舆情检测状态集，并对状态转移关系进行归并处理，形成待验证的系统模型。在模型检测阶段，将形式化规则与系统模型共同输入检测器，执行模型检测过程，识别并标记舆情信息中的不可信部分。结果分析阶段，对检测结果进行统计分析与归纳总结，为可信度评估提供量化支撑。

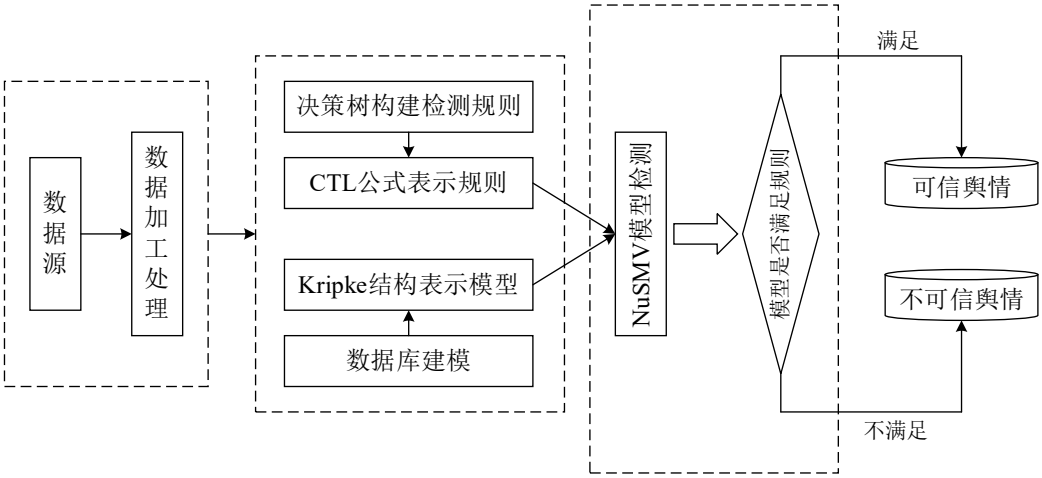


图 3-4 金融舆情可信度检测框架

Figure 3-4 Framework for credibility detection of financial public opinion

3.2.2 金融舆情可信度检测规则建立

检测规则作为财经舆情可信度的评判依据，其构建过程包含规则设计与形式化描述两个前后衔接的环节。在规则设计环节，借助决策树算法自动生成检测路径，经合并与精简处理后，形成可供使用的检测规则集。在形式化描述环节，则运用计算树逻辑（CTL）对系统状态及其演化路径进行形式化表述，从而为模型检测提供支撑。

（1）基于决策树的检测规则生成

在金融舆情可信度判别中，决策树（DT）能够依据金融舆情特征值实现对可信度的自动判别，其关键在于从训练数据中筛选出最具区分能力的特征值及相应的切分点。相较于 ID3 与 C4.5 算法，CART 决策树的显著优势在于采用基尼指数作为特征选择准则，通过确定最优特征及其最佳二值切分点，构建出结构简洁且分类精度较高的决策模型。假设样本包含 n 个类别，样本点归属于第 i 个类的概率记为 p_i，则该概率分布下的基尼指数计算公式如下：

中国知网 https://www.cnki.net

$$Gini(p)=\sum_{i=1}^{n}p_i(1-p_i)=1-\sum_{i=1}^{n}p_i^2 \tag{3-2}$$

为缓解决策树易出现的规则结构复杂、局部最优及过拟合等缺陷，本文采用类别变量离散化方式对模型加以改进，将其划分为 2 至 4 类，并通过参数调优与剪枝策略进一步优化模型结构。图 3-5 展示了决策树对数据进行分类后得到的结果，其中舆情特征可划分为描述方式（Description）、舆情来源（Source）及信息倾向（Emotion）。对于最后的分类结果，本文设定 1 为可信舆情，0 为不可信舆情。

金融舆情	来源	描述	信息	可验证性	用户历史信誉	可信度
A	企业	主观	正			0
B	企业	主观	负			1
C	媒体	客观	正			1
D	媒体	客观	负			1
E	个人	主观	正			0
F	个人	客观	负	可		1
G	个人	主观	负	可	优秀	1
…	…	…	…	…	…	…

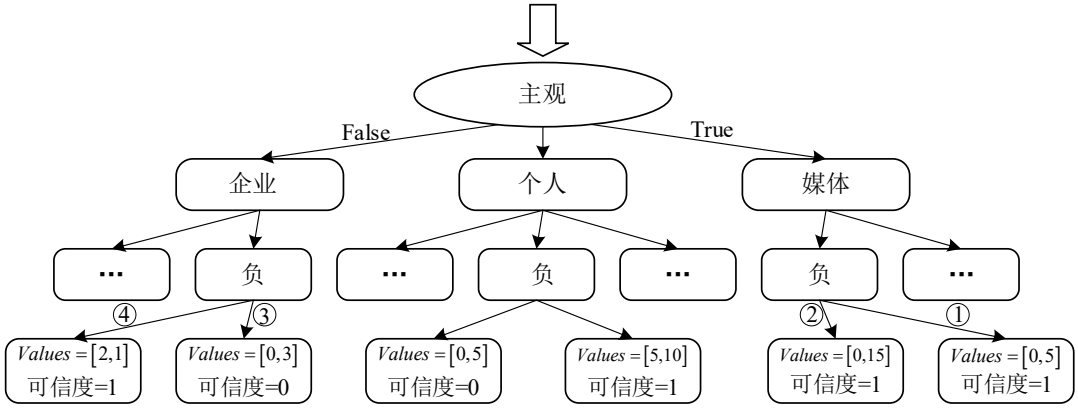


图 3-5 金融舆情决策树检测路径

Figure 3-5 Detection paths of the financial public opinion

采用 CART 算法对总舆情数据进行决策树分析，得到部分检测路径表述为：

① Source =媒体，Description =客观，Emotion =负，可信；

② Source =媒体，Description =客观，Emotion =正，可信；

③ Source =企业，Description =主观，Emotion =负，可信；

④ Source =企业，Description =主观，Emotion =正，不可信；

中国知网 https://www.cnki.net

⑤ Source =个人，Description =主观，Emotion =正，不可信；

⑥ Source =个人，Description =客观，Emotion =负，可信。

其中路径①②③均输出一致且确定的检测结果，而路径④的检测结果则存在差异，具体表现为 2 条判定为不可信舆情与 1 条判定为可信舆情。依据多数原则，将该类路径的最终结果归属于样本占多数的类别。对于个人股吧舆情，原始的舆情描述、来源、信息三个特征可能不足以做出精准判断。为了提高检测效果，现在决策树模型中额外引入信息可验证性和用户历史信誉等高阶特征。将决策树生成的检测路径中分类结果相同的子树分支进行合并，经归并简化后，即将简化后的检测规则归纳为以下集合：

① Source =媒体，Description =客观，可信；

② Source =企业，Description =主观，Emotion =负，可信；

③ Source =企业，Description =主观，Emotion =正，不可信。

④ Source =个人，Description =主观，Emotion =正，不可信；

⑤ Source =个人，Description =客观，Emotion =负，可信

（2）检测规则的 CTL 形式化表示

作为一种兼具离散时间与分支时间双重特征的逻辑体系，计算树时序逻辑 CTL 广泛用于模型检测中描述系统状态随时间的演化行为。在模型检测过程中，CTL 对时序逻辑具有非常强的描述能力，能够表达状态路径上的时序属性，其计算树将初始状态为根，后续节点作为系统可能状态转移序列。将不可信舆情的检测规则中的最终状态标记为 $I = True$，并利用 CTL 公式对各检测规则进行形式化表达，图 3-5 所示检测路径转换得到的 CTL 公式见表 3-2。

表 3-2 规则检测 CTL 形式化示例

Table 3-2 The examples of formalized CTL expressions for rule detection

路径	相应 CTL 公式
①	AG (State = $State_0$ & Description = objective -> AX (State = $State_1$));
	AG (State = $State_1$ & Source I = media) -> AX (State = $State_3$);
	AF (AG(State=$State_3$-> State = True))
②	AG (State = $State_0$ & Description = subjective -> AX (State = $State_2$));
	AG (State = $State_2$ & Source = firm) -> AX (State = $State_4$);
	AG (State = $State_4$ & Emotion = negative) -> AX (State = True)
③	AG (State = $State_2$ & Source = media) -> AX (State = $State_5$);
	AG (State = $State_5$ & Emotion I= negative) -> AX (State I= True))

中国知网 https://www.cnki.net

其中在路径①中，第一条规则对应的 CTL 公式逻辑可表述为：从源状态 $State_0$ 出发，凡满足“舆情描述=客观”条件的路径，其下一个状态均为 $State_1$，后续规则依此类推；而该路径中的第三条规则表示，从状态 $State_3$ 出发的所有路径，最终都将汇聚至状态 $I = True$。

3.2.3 金融舆情可信度待检测模型构建

（1）数据库模型描述

在模型检测中，建模的核心在于将金融舆情数据库抽象化为一个有限状态系统，并依据既定规则对其结构进行形式化描述。具体步骤包括如下几点：

在预处理阶段，首先对原始舆情数据进行清洗，去除冗余记录并完成同类合并，从而得到 c 行 m 列的数据矩阵，其中 m 代表特征数量。依据舆情类别将数据集划分为 n 个子集，本文中 n 取 3。依据决策树分类过程中各特征在节点中的排序，可获得各特征按重要性的降序序列，在此基础上，用 f_{ij} 表示第 i 个子数据集中重要性位列第 j 的特征。

对任意子数据集 d_i，建模过程以初始状态 $State_0$ 为起点，依据以下步骤构建状态序列模型：①设 $j=1$，以第 j 个重要特征的不同取值作为转移条件，生成相应的后续状态；②若 $j<m$，则令 $j=j+1$，并重复步骤①；③若 $j=m$，则构造终止状态 True，建模结束。最终建立的检测状态序列模型示例如图 3-6 所示。其中，$V\left(f_{ij}\right)$ 表示第 i 个子数据集中第 j 个重要特征值；$V_k\left(f_{ij}\right)$ 表示该特征的第 k 种取值类型。例如特征“信息倾向”包含积极、中立和消极三类取值，则 k 为 $(1,2,3)$，$State_0$ 表示系统初始状态。

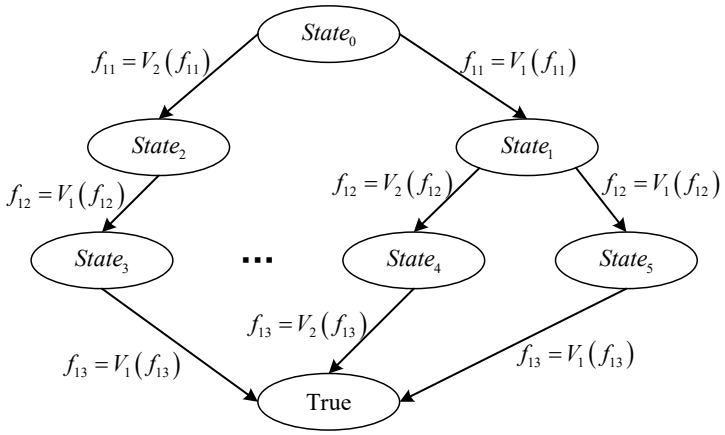


图 3-6 可信度检测状态序列模型示例

Fig. 3-6 The example of a credibility detection state sequence model

中国知网 https://www.cnki.net

（2）基于 Kripke 结构的模型表示

Kripke 结构作为一种对有限状态系统进行形式化建模的方法，在模型检测领域广泛应用，主要用于刻画系统的状态转移行为。其形式化定义如下：

定义 1：Kripke 结构可表示为一个三元组 $K=(S,R,I)$。其中 S 表示有限状态集；$R\subseteq S\times S$ 是状态之间的转移关系；$I\subseteq S$ 为初始状态子集。Kripke 结构的基本约束在于其系统中的每个状态都必须存在至少一个后续状态。

定义 2：在 Kripke 结构 $K=(S,R,I)$ 中，一条迹（trace）是有限状态序列，可表示为 $t=(s_1,s_2,\ldots,s_n)$，满足对于任意 $i\in[1,n-1]$，都有 $(s_i,s_{i+1})\in R$。

本文将可信度检测模型映射为 Kripke 结构。图 3-5 的形式化描述如下：

模型表示为三元组 $K=(S,R,I)$，其中 $S=\{State_0,State_1,State_2,\ldots,State_n\}$；$R=\{r_0,r_1,r_2,r_3,\ldots\}=\{(State_0,State_1),(State_0,State_2),(State_1,State_4),(State_1,State_5),(State_2,State_3),(State_3,True),(State_4,True),(State_5,True),\cdots\}$，$I=\{State_0\}$。

其中转移条件由特征取值决定：

$$\begin{aligned} r_0 &= \mathrm{State}_0 \xrightarrow{f_1=V_k(f_1)} \{\mathrm{State}_1,\mathrm{State}_2\} \\ r_1 &= \mathrm{State}_1 \xrightarrow{f_1=V_k(f_1)} \{\mathrm{State}_4,\mathrm{State}_5\} \\ r_2 &= \mathrm{State}_2 \xrightarrow{f_1=V_k(f_1)} \{\mathrm{State}_3\} \\ r_3 &= \{\mathrm{State}_3,\mathrm{State}_4,\mathrm{State}_5\} \rightarrow \mathrm{True} \end{aligned} \tag{3-3}$$

在该结构中，一条迹 t 表示为一条舆情可信度检测路径,进而记为 $t=\{state_0,state_1,state_4,True\}$。通过将所有检测路径转化为 Kripke 结构，即可构建出基于状态转移的金融舆情可信度检测形式化模型。

3.2.4 金融舆情可信度模型检测执行

完成基于 Kripke 结构的状态转移模型构建与 CTL 规则形式化描述后，即可执行模型检测以验证可信度判定规则的有效性。本文运用 NuSMV 模型检测工具实现检测流程的自动化，将 Kripke 结构描述的有限状态系统和 CTL 公式表示的检测规则共同转换为 SMV 语言，以此作为输入自动遍历整个状态空间，并逐一验证每条 CTL 规则在模型中的全局成立性。若某条规则成立，则输出结果为 True，表明该规则在当前舆情数据库模型中得到满足，可作为有效的可信度判别依据。反之，若输出为 False，则系统将自动生成并列出此反例所对应的具体状态转移路径，即一条舆情检测路径，辅助定位规则冲突或数据异常所在。通过系统检测全部规则，能够验证决策树提取的检测逻辑在形式化模型中的一致性，从而确保了可信度评估系统的可靠性与逻辑完备性。

中国知网 https://www.cnki.net

3.3 金融舆情 FinBERT 情感测度

3.3.1 金融舆情 BERT 编码分类

传统文本特征提取方法有 Word2Vec 与 GloVe 等基于神经网络的方法，然而这些方法通常基于静态词向量表示，难以处理不同语境下的词语多义性问题。相比之下，BERT 等预训练语言模型的核心优势在于其动态词向量机制，该机制使得模型能够根据词语的上下文信息对向量表示进行动态调整，从而有效捕捉语义的灵活性与上下文依赖，显著提升了对一词多义等问题的处理能力。因此，本文选用 BERT 作为基础模型，对金融舆情文本进行编码。

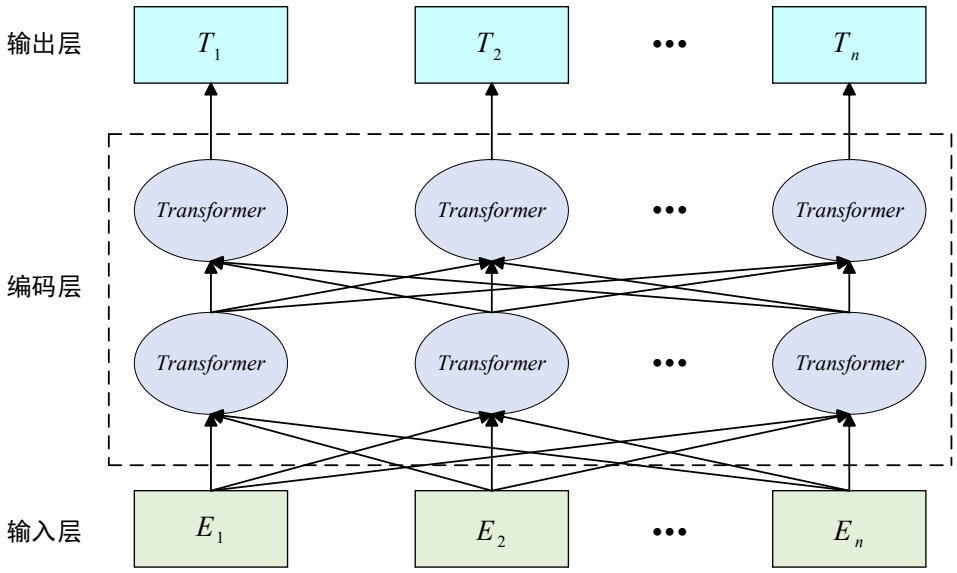


图 3-7 BERT 模型结构

Fig. 3-7 The model architecture of BERT

BERT 模型的整体架构可划分为输入层、编码层与输出层三个部分，如图 3-7 所示。输入层将原始文本转化为计算机可读的嵌入式向量表示。为全面编码文本信息，BERT 输入层采用了三要素融合的策略，即通过词向量（Token Embedding）、段向量（Segment Embedding）和位置向量（Position Embedding）的综合编码来全面表征文本信息，具体结构见图 3-8。假设第 i 条文本包含 L_i 个词语，且由 S_i 个句子组成。在输入处理阶段的文本起始处添加特殊分类标记[CLS]，并在句子之间或文本末尾添加[SEP]标记进行分隔。经过输入层处理后，得到的文本向量 X_i，其维度可表示为 $(L_i + S_i + 1) \times H$，其中 H 表示 BERT 模型

中国知网 https://www.cnki.net

的隐藏层维数。编码层则由多个 Tansformer 模块以堆叠方式构成其主体结构，每一模块内部集成了自注意力机制、残差连接及前馈神经网络等核心组件。编码计算步骤如下：首先对输入向量 X_i 进行线性变换，由此分别生成查询矩阵 Q、键矩阵 K 以及值矩阵 V，具体计算公式为：

$$\begin{aligned} Q &= X_i W_Q \\ K &= X_i W_K \\ V &= X_i W_V \end{aligned} \tag{3-4}$$

其中 W_Q, W_K, W_V 均为为可学习训练的权重矩阵。随后通过缩放点积注意力机制计算得到加权注意力矩阵，以融合序列中所有向量的信息：

$$\text{Attention}\left(Q,K,V\right) = \text{soft}\max\left(\frac{QK^{\mathrm{T}}}{\sqrt{d_k}}\right) \tag{3-5}$$

式中 d_k 表示隐藏层维度。进而引入残差连接并进行层归一化，用于稳定训练过程、加速模型收敛。最后经由前馈神经网络进一步转化得到 X_i 的隐藏层矩阵 X_{hiden}。

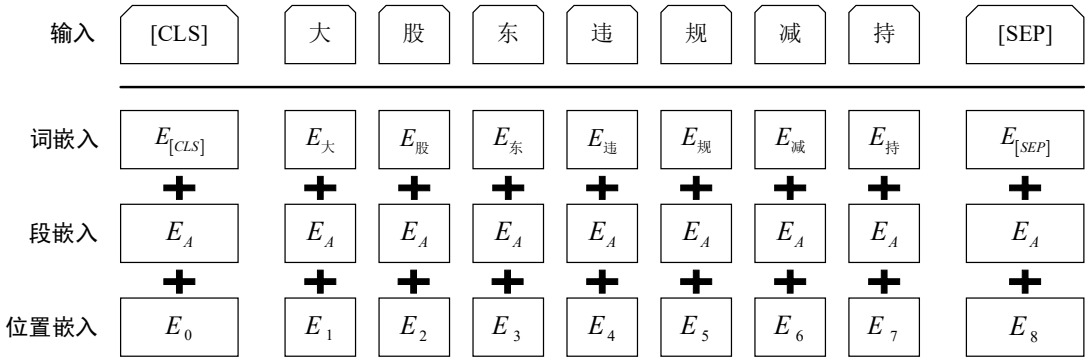


图 3-8 BERT 模型输入

Fig. 3-8 Input of the BERT model

BERT 模型的输出通常包括两类：其一为汇集输出（Pooler Output），对应[CLS]标记的隐藏状态，该状态经过全连接层与 tanh 激活函数处理，用于捕捉整个输入序列的全局语义信息以及情感特征，适用于文本分类等任务；其二为序列输出（Sequence Output），包含序列中每个标记的上下文相关表示，适用于命名实体识别等词级任务。结合研究目标，本文采用第一类输出，即使用[CLS]标记的汇集输出作为金融舆情文本的特征表示和情感分类。

中国知网 https://www.cnki.net

3.3.2 金融舆情 FinBERT 情感识别

BERT 模型在处理文本分类任务时，通常采用预训练-微调的两阶段结构。在预训练过程中，模型依托无监督学习机制，从而在大规模语料上学习完成语言表示，其核心包含遮罩语言模型（Masked Language Model, MLM）和下文预测任务（Next Sentence Prediction, NSP）两项自监督任务。在 MLM 任务中，模型采用随机掩码按一定比例对输入文本中词汇进行遮蔽，其中 80%的选定词汇改为[MASK]标记、10%改为随机词、10%保持原词不变。模型通过上下文信息预测被遮蔽的词汇，从而习得词汇间的语义依赖与局部语法结构。NSP 任务则接收成对出现的句子，并判断第二句是否为第一句的连贯下文，以此学习句子层面的逻辑关联与篇章连贯性。经过预训练阶段后，所获得的模型参数将作为下游任务模型的初始化参数使用。在微调阶段，通过引入特定任务的有标注数据，以有监督方式对整个模型进行端到端的参数优化，使其适应具体应用场景。

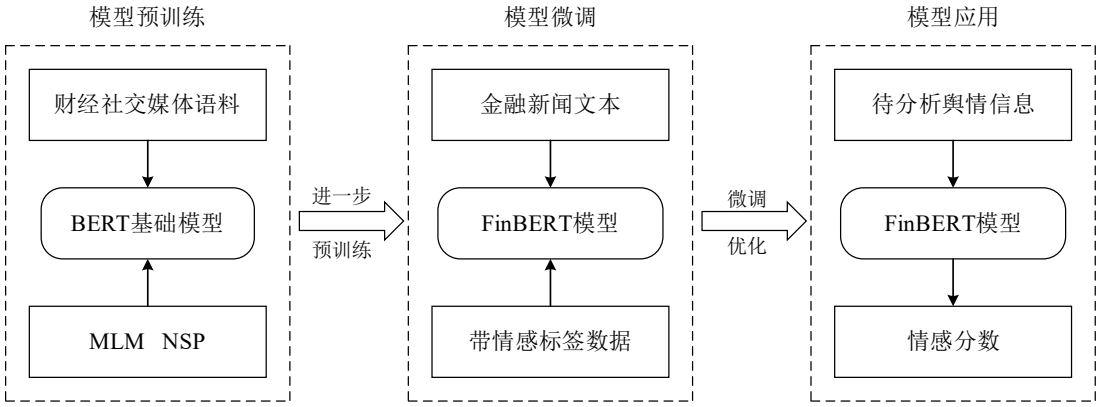


图 3-9 中文金融大语言模型流程图

Fig. 3-9 The architectural workflow for Chinese financial large language models

然而 BERT 基础模型为通用预训练模型，其在金融领域文本的表现性能有待提高，因此有必要通过专业金融文本进一步训练 BERT 基础模型得到适用金融领域的中文金融模型（FinBERT）。将基础模型训练至特定领域主要有两种方法。其一是通过高质量特定领域文本数据集，从零构建一个特定领域预训练模型。其二是以通用预训练模型为基础，通过引入特定领域文本数据继续进行预训练，从而增强特定领域的文本分析效果。鉴于计算可行性约束，选取第二种方法作为金融领域预训练模型的构建方案。本文借助东方财富股吧评论和财新网金融新闻训练基础模型，在微调阶段提升基础模型的金融文本情绪分类性能。

中国知网 https://www.cnki.net

获得面向金融文本优化的预训练模型后，进一步采用监督微调方法。建立基于FinBERT 金融舆情情感分类器，同时引入大语言模型生成高质量的标注数据，最后执行模型微调操作，提升了金融文本情感分类的准确性。FinBERT 模型情感识别的具体流程如图 3-9 所示。

（1）基于大语言模型情感标签生成

为解决金融领域标注数据稀缺及人工标注一致性问题，本文创新性地采用Deep-Seek 大语言模型作为标签生成器。具体流程如下：首先，构建包含金融情感分类指令的提示模板，明确分类标准为积极和消极两类；随后将预处理后的证券关联金融舆情文本输入 Deep-Seek，获取情感倾向判断结果；最后，将得到的情感标签转换为二进制形式，积极为 1，消极为 0。这种方法不仅利用了大语言模型强大的情感语义理解能力，同时确保了标签生成过程具有高度可重复性和一致性，有效避免了传统人工标注中的主观偏差问题。

（2）模型微调与优化

对金融领域预训练模型的监督微调，本文借助于 DeepSeek 所生成的标签集来实现。微调过程中运用交叉熵作为损失函数，并基于反向传播更新包含预训练层在内的全部模型参数，从而学习金融文本与情感标签之间的映射关系。训练阶段的数据集划分采用分层抽样策略，依次生成分布均衡的训练集、验证集及测试集。模型优化方面，引入 Adam 优化器完成参数更新，设置初始学习率为 3×10^{-5}，批量大小设为 32，并结合早停策略以控制过拟合风险。

（3）FinBERT 模型输出

微调完成后，FinBERT 情感分类模型被应用于已剔除训练与验证样本的金融舆情信息集，输出各舆情信息的情绪概率值。具体而言，模型对每条金融舆情文本计算其属于积极情绪类别的概率，并将其作为该金融舆情的情绪得分，用于后续构建高频文本情绪指数。

3.3.3 金融舆情情感指数计量

在完成对单条金融舆情文本的情感分类后，需进一步将微观层面的情感判断结果聚合为宏观、连续的情绪指标，以量化投资者情绪的日度波动。本部分基于 FinBERT 情感分类输出，构建适用于股票市场的金融舆情情感指数。

金融舆情的形成源于投资者在信息不对称环境下表达观点、寻求认同的心理需求，尤其在市场波动期间，投资者情绪通过在线平台交互与扩散，形成了具有复杂情感特征的舆情场。情感倾向是金融舆情的核心维度之一，其每日变化与个股价格走势之间存在内在关联。因此，通过对个股相关舆情文本进行逐

中国知网 https://www.cnki.net

条情感分析，可得到每日积极与消极情绪帖子的数量，进而可以构建反映市场情绪整体走向的合成指标。情感指数计量需兼顾直观性、稳健性与理论意义。本文首先参考 Ashtiani 提出的基础看涨指标形式[94]，其基本构造如式(3-6)所示：

$$S_{it}=\frac{T_{it}^{P}-T_{it}^{N}}{T_{it}^{P}+T_{it}^{N}} \tag{3-6}$$

其中，S_{it} 表示股票 i 在第 t 日的情感指数；T_{it}^{P} 和 T_{it}^{N} 分别表示当日该股票对应的积极帖子数与消极帖子数。情感指数取值范围为[1,-1]，越接近 1 表示市场情绪越积极，越接近-1 则表示情绪越消极。然而，式 (3-6)仅考虑了积极与消极帖子的相对比例，并未考虑本文 3.1.3 小节中的金融舆情影响力范围和情绪表达的强度以及总规模信息。因此为提高情感指数的信息含量和舆情信息的影响效力，进一步对其进行相应改进。由 3.1.3 可知中心第 t 日的舆情影响效力最为显著，同时为平滑结合舆情影响前后期的金融舆情，引入加权函数 $w(\Delta)$，其中 Δ 表示与第 t 日的天数差，具体为：

$$w(\Delta)=\frac{K+1-|\Delta|}{K+1},\quad \Delta\in[-K,K] \tag{3-7}$$

其中 K 为窗口半径，在本文中即为 5。同时设 $T_{i,t+\Delta}^{P}$ 表示股票 i 在第 $t+\Delta$ 日的积极帖数，$T_{i,t+\Delta}^{N}$ 为股票 i 在第 $t+\Delta$ 日的消极帖数。则窗口内加权积极帖总数 WTP_{it} 和加权消极帖总数 WTN_{it} 分别为：

$$\begin{aligned} WTP_{it}&=\sum_{\Delta=-K}^{K} w(\Delta)\cdot T_{i,t+\Delta}^{P} \\ WTN_{it}&=\sum_{\Delta=-K}^{K} w(\Delta)\cdot T_{i,t+\Delta}^{N} \end{aligned} \tag{3-8}$$

进而结合上述加权总和，改进后的情感指数 S_{it}^{*} 为：

$$S_{it}^{*}=\frac{WTP_{it}-WTN_{it}}{WTP_{it}+WTN_{it}+\epsilon} \tag{3-9}$$

其中，为防止分母为零，确保公式的数值稳定性，在式中加入极小数 ε。该式在保留方向信息的同时，融入了金融舆情的影响力范围，故而可以更稳健地反映情绪强度的边际变化。此外，考虑到 FinBERT 情感分类模型本身具备较高的准确率，一般超过 70%。因此在日度汇总过程中，误分类帖子所导致的正负情绪误差能够在加总过程中部分抵消，从而提升了情感指数在日度层面上的判断可靠性。

中国知网 https://www.cnki.net

3.4 金融舆情信号指数加权聚合

3.4.1 金融舆情热度指数构建

在金融舆情分析体系中，舆情热度是衡量市场关注程度的关键维度之一，其反映了投资者对特定股票或市场信息的集体注意力分配。依据有限注意力理论可知，由于时间和认知的约束，投资者往往倾向于关注并处理舆情热度较高的信息，进而影响其交易决策。因此，构建合理有效的舆情热度指数，对增强舆情情绪指数的稳健性具有重要意义。在股吧、财经论坛等网络平台中，投资者的关注行为往往通过发帖、评论及点击等交互行为得以体现。其中，发帖量直接反映信息供给的活跃程度，评论量则体现信息引发的讨论深度与交互强度。相比之下，阅读量或点击量因包含大量非投资者游客的被动访问，难以准确捕捉目标投资者的真实关注路径，故本文未将其纳入舆情热度测度。

基于上述考量，本文以股票的日度发帖总量与评论总量为基础构建舆情热度指数，具体计算过程如下：设股票 i 在第 t 日的积极帖子数为 P_{it}，消极帖子数为 N_{it}，对应评论数分别为 C_{it}^{P} 与 C_{it}^{N}。则当日总发帖量 V_{it} 与总评论量 C_{it} 分别为：

$$\begin{aligned} V_{it} &= P_{it} + N_{it} \\ C_{it} &= C_{it}^{P} + C_{it}^{N} \end{aligned} \tag{3-10}$$

进而将舆情热度原始指数 H_{it} 定义为二者之和：

$$H_{it} = V_{it} + C_{it} \tag{3-11}$$

该指标从信息生成与交互两个维度综合捕捉投资者对股票 i 的关注强度。为进一步平滑数据分布并降低数量级影响，对 H_{it} 取自然对数，得到最终的对数化舆情热度指数：

$$\Phi_{it} = \ln(1 + H_{it}) \tag{3-12}$$

为避免当 $H_{it} = 0$ 时对数无定义，对上式进行加一处理，同时也保留了原指数的单调性与差异性。

3.4.2 金融舆情热度情感聚合

在分别构建了金融舆情情感指数与热度指数的基础上，为进一步综合反映舆情中情绪与关注度的交互效应，本节提出基于热度加权的情感聚合方法。该方法旨在将投资者关注度的差异化分布融入情绪计量体系，构建更贴近真实市

中国知网 https://www.cnki.net

场情境的复合型舆情指数。理论上，投资者对个股的关注程度直接影响其情绪表达的传播广度与市场影响深度。高关注度股票的情绪信号往往具有更强的市场渗透力与信息传递效率，应在整体情绪评估中赋予更高权重。为此，本文定义热度调整后的情绪聚合指数如下：设股票 i 在第 t 日的情感指数为式 3-9 计算出的 S_{it}^{*}，舆情热度指数为式 3-10 计算出的 Φ_{it}，则热度加权的金融舆情情绪聚合指数 $\tilde{S}_{it}$ 可表示为：

$$\tilde{S}_{it} = S_{it}^{*} * \Phi_{it} \tag{3-13}$$

该式运用情绪方向×关注强度的合成逻辑，既保留了情感指数的正负方向与相对强度，又通过热度指数对其进行了规模调整，从而能够更准确地捕捉那些同时具备高情绪强度与高关注度的股票在整体市场情绪形成中的突出作用。图 3-10 体现了综合金融舆情指数的构建过程，具体步骤为：首先运用 FinBERT 中文金融大语言模型处理相关舆情信息，得到舆情情感类别；随后基于网络爬虫数据计算舆情热度指标；最后将舆情热度作为权重系数对舆情情感指数进行聚合加权计算。

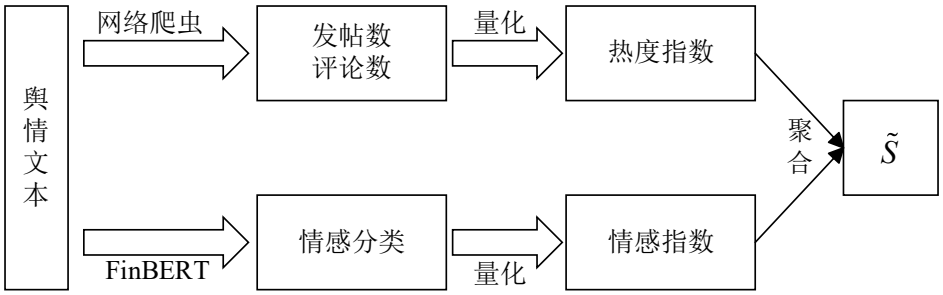


图 3-10 金融舆情指数聚合过程

Fig. 3-10 The aggregation process of financial public sentiment index

3.5 本章小结

本章构建了完整的金融舆情信号生成体系。通过舆情效力分析明确了可信度判别路径与影响力范围；引入基于决策树与模型检测的可信度验证框架，实现了舆情质量的自动甄别；采用 FinBERT 模型进行情感分类，结合大语言模型生成标签进行微调，提升了情感识别的准确性；最后通过热度加权聚合，将情感与关注度融合为复合舆情指数。本章生成的金融舆情信号为后续深度强化学习投资组合模型提供了数据支撑与方法基础。

中国知网 https://www.cnki.net

第4章 考虑金融舆情的深度强化学习投资组合模型构建

传统投资组合模型多聚焦历史行情数据，忽视金融舆情且难以动态适应市场。为此，本章构建融合金融舆情的深度强化学习模型。首先设计历史行情特征提取网络，引入方向性变化捕捉趋势；其次建立舆情信号融合机制，量化多源文本情绪；进而提出多智能体决策框架，包含基智能体生成、集成及风险协同；最后给出模型结构与算法流程，为实证分析奠定基础。

4.1 投资组合历史行情特征提取

4.1.1 历史行情特征提取网络

（1）状态特征张量构造

股票历史行情状态特征一般由股票行情数据、公司财报数据和宏观经济数据组成，本小节主要描述股票状态特征使用三阶张量表示和构建过程。张量本质上可概括为多维数组，其中向量即为一阶张量，矩阵属于二阶张量，而三阶及更高阶的张量则归属于高维数组。本文投资组合模型输入的状态特征主要由2.3.1 小节总结提出的量化数据指标组成，其中基本面数据包括开盘价、收盘价、最高价与最低价等指标；技术面指标则包括趋势和波动数据。因此模型的输入特征为$S_t=(F_t,T_t)$，具体的模型状态张量如下图 4-1：

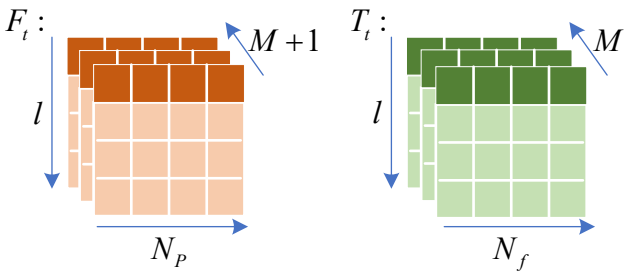


图 4-1 状态特征张量

Fig. 4-1 The state feature tensor

其中F_t表示股票在$[t-l,t]$时间段内基本面数据特征向量，大小为$(M+1,l,N_P)$，其中 M 表示股票资产个数，N_P表示基本面指标特征个数，l表

中国知网 https://www.cnki.net

示时间窗口大小，T_t为技术面指标在$[t-l,t]$时间范围内的特征张量，大小为(M,l,N_f)，N_f为技术面指标的特征个数。

（2）特征提取网络结构

投资组合历史行情数据特征提取网络主要由卷积神经网络和 Transfomer 编码器结合构成，融合二者对多维时间序列数据不同维度的表征优势，继而提取投资组合模型的相关历史行情数据特征信息。具体网络结构内容在后续小节会详述，图 4-2 为历史行情数据特征提取网络具体结构：

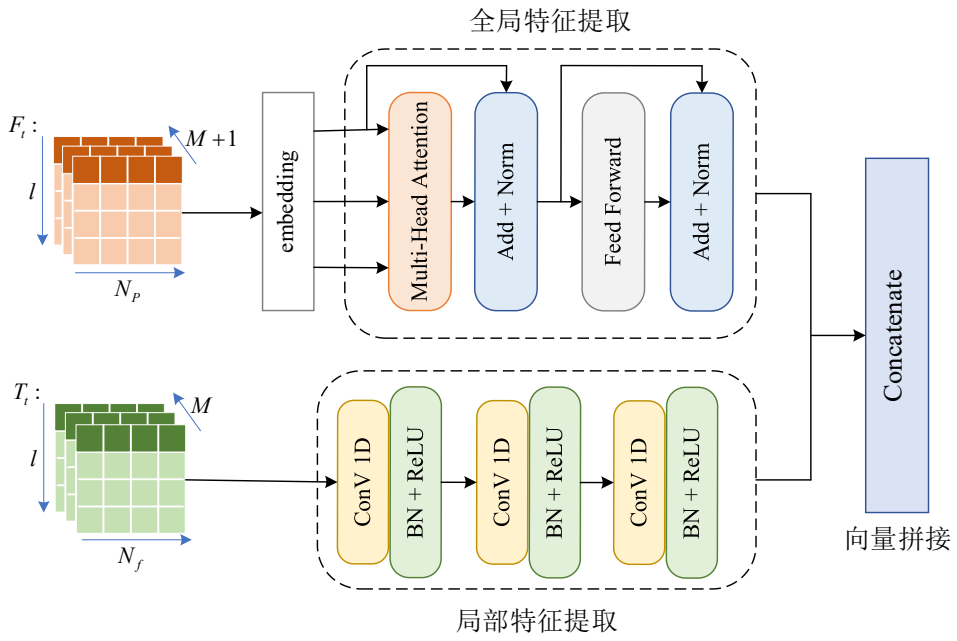


图 4-2 历史行情特征提取网络整体结构

Fig. 4-2 The overall structure of the historical market trend feature extraction network

4.1.2 行情全局特征提取模块

历史行情数据$P_i=\{D_1^i,D_2^i,\ldots,D_n^i\}$作为典型的时间序列数据，其时序依赖性是不可忽视的关键因素之一。由于距离较远的时间点之间关联性通常较弱，如较早时期的行情信息对当前投资组合的影响有限，因此建模时需要着重考虑时间衰减效应。针对这类问题，传统方法一般通过时间窗口或滞后因子构建手工特征，但这类方法往往依赖专家经验且灵活性不足。同时 Transformer 在自然语言处理中通过位置编码引入了顺序信息，但金融时序数据不仅包含顺序属性，还具有周期波动、趋势演变等固有时间模式，因此需要设计一种适合时序结构

中国知网 https://www.cnki.net

的时间嵌入方法。本文运用一种融合周期性与非周期性模式的时间嵌入表示，解决了应对时间缩放的不变性问题，并且能同时反映趋势成分与周期波动。具体地，将时间信息分解为线性项和周期项，其定义为：

$$\text{Embedding}(\tau)=\begin{cases}\rho\tau+\phi\\ F(\rho\tau+\phi)\end{cases} \tag{4-1}$$

其中，线性部分 $\rho\tau+\phi$ 用于捕捉非周期趋势特征，周期项则由周期激活函数 F 实现，参数 ρ 和 ϕ 可学习。两项拼接后直接形成时间特征向量，并与原始行情数据连接，共同构成 Transformer 编码器的输入。Transformer 编码器通过多头自注意力机制建立不同时间点之间的依赖关系，用于提取长程时序特征。其每个编码器层包含残差连接与层归一化：

$$\text{sub_layer_output=LayerNorm(x+subLayer(x))} \tag{4-2}$$

随后通过前馈网络进行非线性变换：

$$X_{\text{hidden}}=\max(0,X_{\text{hidden}}W_1+b_1)W_2+b_2 \tag{4-3}$$

最终，对编码器输出进行全局平均池化，得到全局时序特征 P_F。

4.1.3 行情局部特征提取模块

在利用 Transformer 提取全局时序特征的同时，同步进行局部特征提取，从而捕捉历史行情价格序列中的短期波动与形态模式。该模块基于全卷积网络（Fully Convolution Network，FCN）实现，利用其堆叠卷积层的局部感知能力有效提取局部时序特征，其整体架构包含卷积结构与全局池化两部分。卷积部分由三层一维卷积堆叠而成，每层均融合卷积运算（convolution layer）、批归一化（Batch Normalization, BN）与非线性激活操作，每个子层具体可表示为：

$$\begin{aligned}y&=W*x+b\\ s&=\text{BN}(y)\\ h&=\text{ReLU}(s)\end{aligned} \tag{4-4}$$

其中， $\text{BN}(\cdot)$ 指代批归一化处理，$*$ 表示卷积运算，$\text{ReLU}(\cdot)$ 则为激活函数。对于股票等序列数据而言，一维卷积结构能够更有效地提取局部相邻时间点间的依赖关系。为逐步增强特征的表达能力，本文将卷积运算中的三层卷积核数量分别设为 128、256 与 128。随后进行批归一化以增强模型对类别差异的识别能力，并采用 ReLU 作为激活函数引入非线性变换。进而全局平均池化层对卷积层输出的各特征矩阵执行均值化处理，得到局部特征向量 P_{FCN}。最后将 Transformer 编码所得的全局特征 P_{TF} 与全卷积模块捕获的局部特征 P_{FCN} 进行拼接融合，再通过全连接层完成映射整合，输出历史行情特征向量 P：

中国知网 https://www.cnki.net

$$P = W_p \left[P_{TF}; P_{FCN} \right] + b_p \tag{4-5}$$

其中 W_p 为权重值矩阵，b_p 表示偏置项，$\left[P_{TF}; P_{FCN} \right]$ 为全局特征和局部特征的拼接向量。

4.1.4 行情市场趋势特征引入

（1）方向性变化方法预测标签构建

目前投资组合输入数据大多集中在技术面和基本面等历史数据，且历史市场数据本质上是静态的，并不能反映离散时间点的市场动态行为。因此本文引入方向性变化方法（Directional Change, DC），通过捕捉股市中的显著价格变动，计算股票趋势预测值，并将其作为特征运用于深度强化学习投资组合模型。DC 方法是一种基于事件驱动的方法，其关注的是价格随时间变化而发生的变化大小。它通过捕捉资产价格的显著变动，同时过滤特定周期内的微小波动来实现市场分析。由 DC 方法定义可知，存在两种基本事件即下跌趋势事件（downtrend event）与上涨趋势事件（uptrend event）作为表征资产当前状态的特征指标。当 $p_t \le p_{t-1}^h \times (1 - \Delta p_{dc})$ 时，资产被确认进入下跌趋势；而当 $p_t \ge p_{t-1}^l \times (1 + \Delta p_{dc})$ 时，则表明资产呈回归上涨趋势。其中 p_{t-1}^h 和 p_{t-1}^l 分别表示截至时间 $t-1$ 当前趋势周期内的最高收盘价与最低收盘价，Δp_{dc} 为 DC 阈值，用于控制价格变动的捕捉灵敏度。因此当 DC 事件被确认后，可推测未来股价走势与该事件方向相同，即构成超调事件（Overshoot Even，OS）。

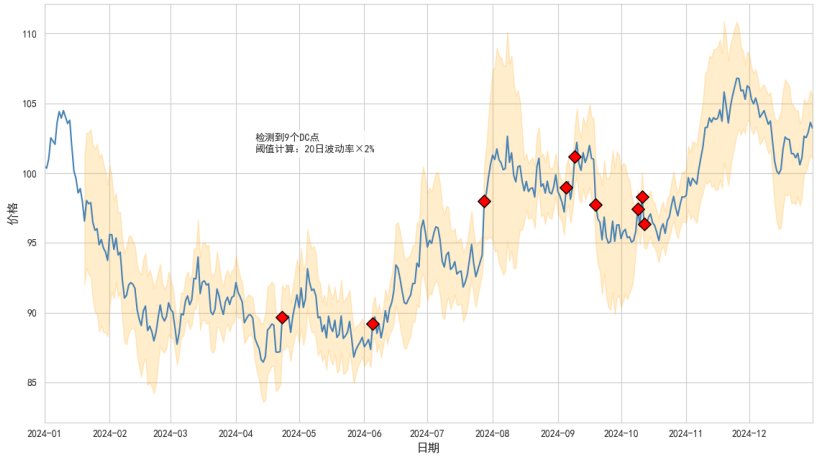


图 4-3 DC 方法示意图

Fig. 4-3 The schematic diagram of the DC method

中国知网 https://www.cnki.net

图 4-3 展示了 Δp_{dc} 为 0.03 时 DC 方法的识别过程，当价格变化达到阈值时，即出现 DC 事件点，共识别出 9 个 DC 事件点。由于 DC 方法相对于金融时间序列分析具有实时敏锐的价格趋势转折和市场状态转换识别能力，因此本文将其应用于市场趋势预测模块，以实现对市场微观结构变化的有效识别。

（2）多阈值 DC 方法市场趋势预测

一般情况下 DC 方法通常采用固定阈值，其性能完全依赖单一特定阈值，并且对于阈值的选取并不容易。因此基于上述情况，本文选取多动态阈值的 DC 方法。同时为克服单阈值模型在捕捉复杂股价波动模式时的局限性，并提升 DC 方法判定的稳健性，进一步引入遗传算法。通过模拟自然进化过程，在广阔的参数空间内自动寻优，构建一个多阈值-权重对的最优判别规则集合，并基于此进行股票方向性变化分析和预测。其中阈值通常由相对强弱指数 RSI 等技术指标临界值构成，用于判断股票的状态，而权重则是预测过程中的可靠性程度。图 4-4 展示了多阈值 DC 方法市场趋势预测流程，具体流程如下：

首先，初始化种群：在区间(0,1)内随机生成初始阈值-权重对集合，每一个 population 内包含五组一一对应的阈值-权重对，构成一个完整的参数配置单元。

其次，执行遗传算法：首先进行参数设定，种群大小设为 100，取 50 为进化代数，变异概率与交叉概率分别设置为 0.1 和 0.45。随后通过适应度函数对各个体进行性能评估，并采用锦标赛选择策略筛选个体，进而执行交叉与变异操作。交叉操作以 0.45 的概率交换个体间的基因信息以生成后代，变异操作则以 0.1 的概率引入随机扰动。且每代进化后，使用子代种群更新当前种群。

再次，适应度评估与优选：利用适应度函数对经遗传操作后的阈值-权重组合进行评估。该函数基于多阈值方向性变化算法，实现对每组阈值对应上升与下降趋势数量的求解，构成趋势统计列表。进一步结合交易模拟函数，并基于趋势信号执行模拟交易，最终将模拟收益率作为适应度评价准则。算法迭代完成后，输出适应度最优的五组阈值-权重结果。

最后，指标合成与输出：将优选出的五组阈值-权重对输入多阈值方向性变化算法，分别计算各阈值对应的方向性变化信号，并通过加权平均方法整合为最终的方向性变化指标。输出结果涵盖日期、股票代码、指标值、上升趋势数及下降趋势数五个字段，但仅有日期、股票代码与指标值被选入投资组合模型的状态空间。与之相比，单阈值方向性变化算法的输出则为四个事件标签：上升趋势事件（up-DC）、下降趋势事件（down-DC）、上升超调事件（up-OS）与下降超调事件（down-OS）。

中国知网 https://www.cnki.net

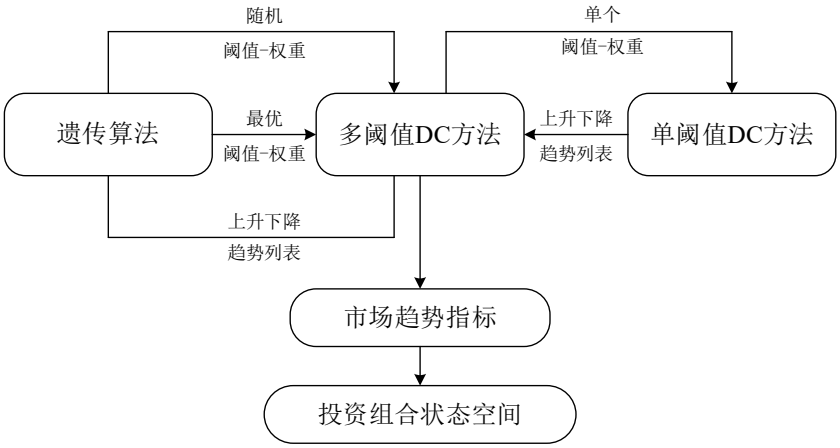


图 4-4 多阈值 DC 方法市场趋势预测流程

Fig. 4-4 Market trend prediction process of the multi-threshold DC method

4.2 投资组合金融舆情信号融合

4.2.1 金融舆情信号融合机制

针对传统投资组合模型忽视反映市场情绪的金融舆情信息这一缺陷，结合第三章生成的金融舆情信号，本节将对金融舆情信号与股票历史行情数的特征融合机制进行阐述。本质上这种融合范式是一种多模态学习，投资组合模型处理并整合来自数据或者文本的多种模态信息。特征融合策略主要分为三种类型，即早融合、晚融合以及混合融合。其中混合融合通过对早融合与晚融合的输出进行整合，兼具二者优势，已被成功应用于多媒体分类、事件检测和视听识别等领域。由于晚融合会同时输出两个变量，本文采用早融合方式对提取的特征进行合并，即在投资决策前将特征融合成一个联合向量表示。随后强化学习智能体基于此联合特征向量做出交易决策，并获得相应的奖励。

图 4-5 展示了金融舆情信号等特征融合机制的整体框架。在特征融合前，对于金融舆情等文本数据，首先进行预处理和舆情影响力范围确定，然后对舆情文本数据进行可信度模型检测，过滤掉噪音的影响，紧接着通过 FinBERT 和热度计量确定金融舆情信号并量化。同时，清洗股票历史交易行情数据，用 0 补充股票历史行情缺少的数据，之后利用 Transformer 和 CNN 进行相关特征提取。特征提取后的金融舆情通过 LSTM 网络获取其时序性特征。最后拼接融合历史行情数据特征和金融舆情数据特征作为股市状态的最终向量表示，强化学习智

中国知网 https://www.cnki.net

能体依据最终状态特征生成交易行为决策，并在完成交易后获得相应的奖励反馈。随后以此为依据动态修正其动作选择策略，进而在迭代过程中不断优化交易策略的性能，以获取更高的投资利润。

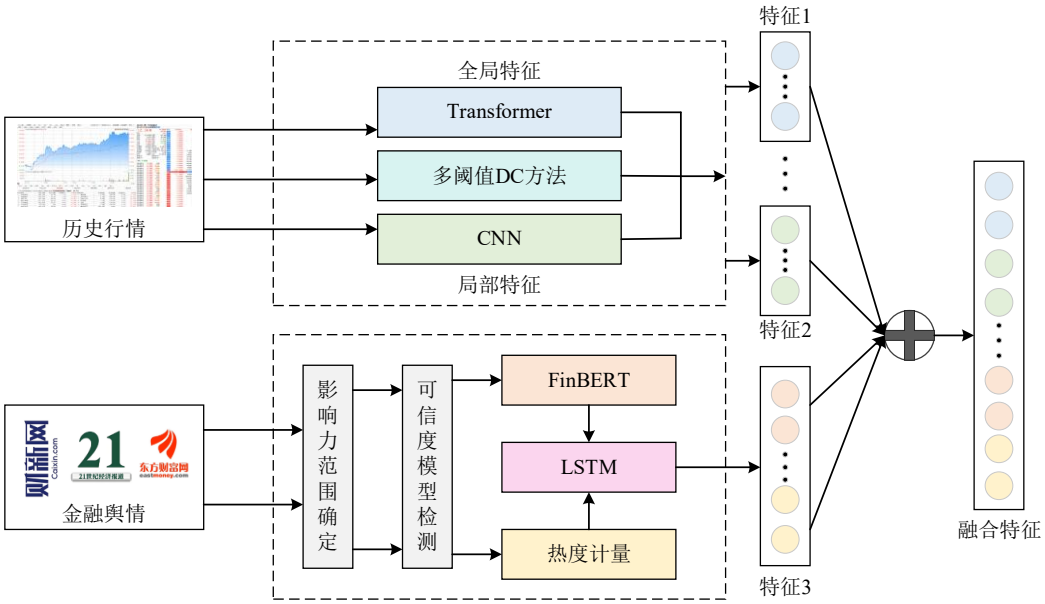


图 4-5 金融舆情信号融合机制示意

Fig. 4-5 Schematic diagram of the fusion mechanism for financial public opinion signals

4.2.2 投资组合环境状态集合

在强化学习框架中，环境状态是对当前交易市场环境的动态刻画与量化描述，需要准确地反映市场环境的变化。智能体在环境中的每个决策不仅影响当前状态，其采取的行动也会反馈到环境中，引发新的状态转移。环境与奖励函数之间密切相关，每一步的即时回报取决于当前状态与所选动作的共同作用。强化学习的核心目标在于最大化长期累积奖励的期望值，故环境状态空间的设计质量直接关系到学习策略的有效性。

鉴于此，环境状态空间的设计优先考虑基础历史数据，即开盘价、收盘价与成交量等基本信息。然而金融市场还受到宏观经济、政策调整、金融舆情及市场波动等多重因素的综合作用，致使数据普遍呈现高噪声、结构复杂与非平稳等特征。故此在环境状态设计引入了技术指标作为辅助决策依据。技术指标基于原始金融数据，通过数理建模方法提取能够反映市场运行状态的有效信息。

中国知网 https://www.cnki.net

本文将交易日作为时间步长单位，在每个交易时刻 t 强化学习智能体观察到的有限环境信息为状态 S_t，其包含所有可能影响股票与市场价格的因素。S_t 包含 193 维特征向量，其维度计算为 16×(5+5+1+1)+1，该向量整合了现金余额、各股持仓量、技术指标及金融舆情等多源信息。环境状态的数学表达如下式所示：

$$S_t = \{D_t, I_t, N_t, H_t, c_t\} \tag{4-6}$$

其中 D_t 表示投资组合的历史行情数据，D_t^i 则定义为智能体在时刻 t 获取的第 i 只股票在最近一个时间窗口 $[t-\Delta t, t]$ 内的日频市场数据，具体由开盘价、最高价、最低价、收盘价以及成交量等五项基础交易数据构成，表达式为：

$$\mathcal{D}_t^i = \{p_t^O, p_t^H, p_t^L, p_t^C, v_t\} \tag{4-7}$$

其中 $p_t^O, p_t^H, p_t^L, p_t^C$ 分别对应窗口内的开盘、最高、最低和收盘价格，v_t 则为同一窗口内的成交总量。

I_t 为投资组合的技术指标集合，I_t^i 对应第 i 只股票在时刻 t 的若干技术指标值。金融分析中技术指标种类繁多，常用于刻画资产价格动量与趋势特征。本文选取了五类常用指标作为行情数据的补充，分别为相对强弱指数、指数移动平均、异同移动平均线、威廉指标以及平均方向移动指数。

N_t 表示基于文本的金融舆情数据，N_t^i 为时刻 t 第 i 只股票相关的基本面文本所蕴含的舆情信息。此类文本数据可来源于社交媒体、新闻报刊、行业报告等多种渠道。

H_t 为持仓数据，H_t^i 表示智能体第 i 只股票在 t 时刻持有的数量。

c_t 则表示智能体在时刻 t 所持有的现金资产余额。

4.3 投资组合强化学习智能体决策

4.3.1 投资组合基智能体决策生成

基智能体是深度强化学习投资组合模型的核心决策单元，直接生成投资组合决策动作。其通过输入资产价格、收益率和波动率等历史行情数据和金融舆情信号进行处理，进而生成相应的资产配置权重。

（1）基智能体网络结构

强化学习投资组合模型的中的三类基智能体均采用独立的 Actor-Critic 架构，包含策略网络和评价网络两部分。策略网络 Actor 输入状态信息，输出连

中国知网 https://www.cnki.net

续动作向量；评价网络 Critic，输入状态信息，输出一个标量值 Q，用于评估当前状态的长期期望回报。两个网络的输入状态信息均来自于环境状态模块。通过 CNN 处理输入 s_t，捕捉每只股票的短期局部模式和形态特征，输出维度为 $L\times C_{out}$ 的序列张量，C_{out} 为 CNN 输出的通道数。随后利用 BiLSTM 同时从前后两个方向学习序列的依赖关系，从而更全面地理解每只股票的长期趋势、周期性和动态演化。将 BiLSTM 在最终时间步的隐藏状态提取为个股的时序特征向量，并通过 Concat 操作完成每只股票的时序特征拼接，拼接特征随后被分别馈入策略网络与评价网络，两者均构建为两层全连接层结构以实现非线性映射，最终分别输出动作 a_t 和价值函数值。基智能体的网络结构具体如图 4-6：

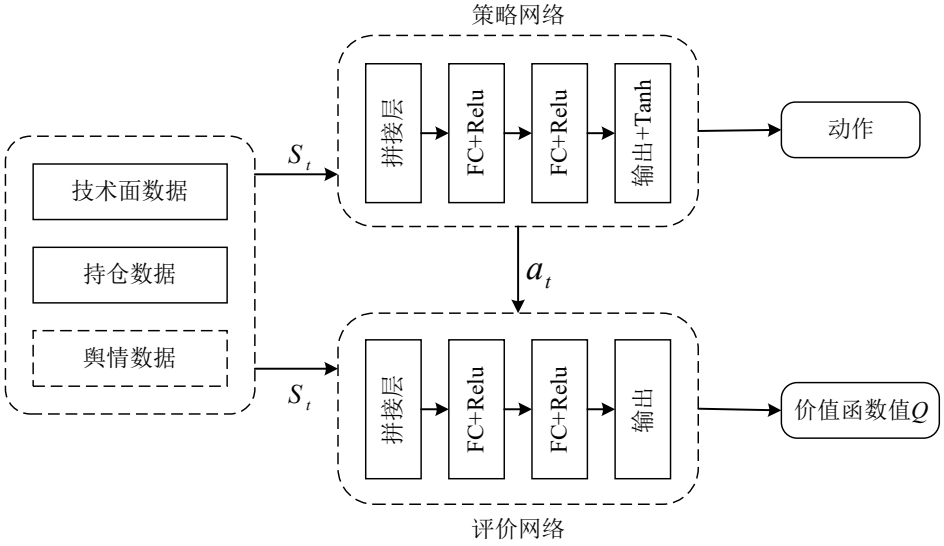


图 4-6 基智能体网络结构

Fig. 4-6 The network structure of basic agent

（2）基智能体奖励函数

为了适应不同的市场环境以及模拟不同交易风格投资者在股票市场中的交易行为，分别设置乐观、均衡和悲观三种不同的交易智能体。借助神经网络对投资组合期望收益进行拟合，并基于反向传播机制对各交易基智能体的网络参数进行学习。每个基智能体均以近端策略优化网络（PPO）作为其基础架构。其中，乐观智能体的奖励函数由收益率 R 和最大回撤 MDD 共同构成，如下：

$$\begin{aligned} r(s_t,a,s_{t+1})_t^1 &= R-\lambda\cdot MDD \\ &= R-\lambda\cdot \max_{m\in(0,t)}\left\{\max_{n\in(0,m)}\frac{v_n-v_m}{v_n}\right\} \end{aligned} \tag{4-8}$$

中国知网 https://www.cnki.net

最大回撤是衡量投资组合风险水平的重要指标，该值越小越好。MDD 作为风险惩罚项，约束以收益率 R 为导向的乐观智能体，防止其在追求高收益的同时，避免出现过大的回撤。

差分夏普比率 DSR 是夏普比率的动态和增量式的变换，与传统夏普比率相比，DSR 更注重最新交易决策如何影响当前的夏普比率。以 DSR 作为奖励函数的智能体，其投资决策会在收益和风险之间进行权衡，进而与追求持续和稳定增值的悲观保守投资者不谋而合。因此悲观智能体的奖励函数可用差分夏普比率定义为：

$$r(s_t,a,s_{t+1})_t^2=\frac{\beta_{t-1}\Delta\alpha_t-\frac{1}{2}\alpha_{t-1}\Delta\beta_t}{(\beta_{t-1}-\alpha_{t-1}^2)^{3/2}} \tag{4-9}$$

其中 α_t,β_t 分别为价格波动 Δv_t 的一阶和二阶指数移动估计，设 η 为适应率，其计算过程分别如下式：

$$\begin{aligned}\alpha_t&=\alpha_{t-1}+\eta(\Delta v_t-\alpha_{t-1})=\alpha_{t-1}+\eta\Delta\alpha_t\\ \beta_t&=\beta_{t-1}+\eta(\Delta v_t^2-\beta_{t-1})=\beta_{t-1}+\eta\Delta\beta_t\end{aligned} \tag{4-10}$$

均衡智能体将乐观和悲观智能体两者综合考虑，其奖励函数定义为：

$$r(s_t,a,s_{t+1})_t^3=r(s_t,a,s_{t+1})_t^2+r(s_t,a,s_{t+1})_t^1 \tag{4-11}$$

均衡智能体对投资组合的风险和高额收益同等看待，注重收益的同时兼顾投资风险。由于已将各基智能体分为不同类型交易策略，为确保其在特定环境下能做出相应的决策，所以它们之间的网络参数是非共享的。

（3）基智能体目标函数

每个交易基智能体均以寻求自身最优策略 π 为核心任务，以奖励函数最大化作为优化目标，投资组合的累计折扣收益 R_t^i 可表示为：

$$R_t^i=r_{t+1}^i+\gamma r_{t+2}^i+\gamma^2 r_{t+3}^i+\cdots=\sum_{k=0}^{\infty}\gamma^k r_{t+k+1}^i \tag{4-12}$$

此处 r_{t+1}^i 为智能体 i 在 t+1 时刻所获奖励。策略 π_{θ^i} 由参数为 θ^i 的策略神经网络进行表征。为使评价网络与策略网络实现参数共享，在基智能体中引入 LSTM 网络结构。以 $V_{\theta^i}\left(s_t^a\right)$ 表示评价网络输出的价值函数，通过泛化优势估计方法计算得到的优势函数值 $\hat{A}_t^i$ 用于衡量策略 π_θ 的优劣程度，具体计算方式如下：

中国知网 https://www.cnki.net

$$\begin{aligned}&\hat{A}_t^i = Q_{\theta^i}(s_t^a, a_t^i) - V_{\theta^i}(s_t^a)\\&Q_{\theta^i}(s_t^a, a_t^i) = \mathrm{E}_{\theta^i}[R_t^i |\ s_t^a, a_t^i; \pi_{\theta^i}]\\&= \mathrm{E}_{\theta^i}\left[\sum_{k=0}^{\infty}\gamma^k r_{t+k+1}^i |\ s_t^a, a_t^i; \pi_{\theta^i}\right]\end{aligned} \tag{4-13}$$

其中 $Q_{\theta^i}(s_t^a, a_t^i)$ 表示智能体在状态 s_t^a 下执行动作 a_t^i 时所获得的收益期望值。由此，基智能体的目标函数可表示为：

$$\begin{aligned}&L(\theta^i) = \frac{1}{T}\sum_{t=1}^{T}\hat{A}_t^i\left(\min\left(ratio_t(\theta^i), clip\left(\rho_t(\theta^i), 1-\varepsilon, 1+\varepsilon\right)\right)\right)\\&ratio_t(\theta^i) = \frac{\pi_{\theta^i}(a_t^i |\ s_t^a)}{\pi_{\theta_{old}^i}(a_t^i |\ s_t^a)}\end{aligned} \tag{4-14}$$

其中 $ratio_t(\theta^i)$ 为基智能体新旧策略之间的概率比值。考虑到动作评估网络存在参数共享的情况，需在目标函数中增加价值函数估计误差项以作修正，最终得到的基智能体目标函数如下：

$$L(\theta^i) = \frac{1}{T}\sum_{t=1}^{T}\hat{A}_t^i\left(\min\left(ratio_t(\theta^i), clip\left(\rho_t(\theta^i), 1-\varepsilon, 1+\varepsilon\right)\right)\right) + \frac{1}{T}\sum_{t=1}^{T}\left(V_{\theta^i}(s_t^a) - R_t^i\right)^2 \tag{4-15}$$

4.3.2 投资组合多智能体决策融合

（1）多智能体网络结构

多智能体投资组合模块主要由两部分组成，第一部分包含不同交易风格的基智能体，第二部分则为各基智能体策略的集成融合，最后通过全连接 FC 网络输出投资动作。从特征状态感知模块输入数据之后，基智能体给出各自投资动作，随后多智能体模块进一步利用全连接 FC 网络对策略与评价网络进行非线性映射，以生成最终的投资分配动作与动作价值函数值。为区分多智能体模块中的参数，本文将 φ 定义为策略网络参数，设 ψ 为评价网络参数。下图 4-6 展示了多智能体模块策略网络的具体结构：

中国知网 https://www.cnki.net

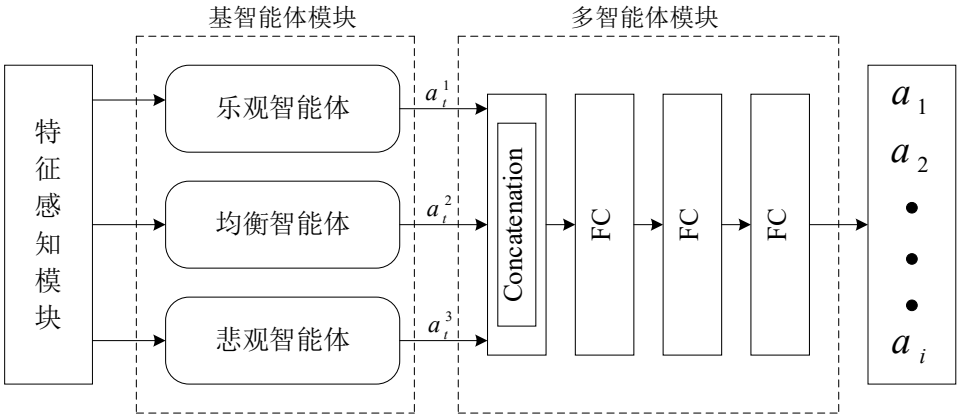


图 4-6 多智能体模块策略网络结构

Fig. 4-6 The structure of integrated strategy agent network

由图可知，基智能体经过预训练后得到其策略网络的参数θ^i，进而将各基智能体的输出动作进行 *Concat* 拼接得到多智能体模块输入$Concat\left(a_t^1,a_t^2,a_t^3\right)$，其中$a_t^i=f\left(s_t^a,\theta^i\right),i=1,2,3$。随后利用 3 层 FC 网络非线性映射处理输出，将基智能体的特征动作融合输入到多智能体策略网络，得到多智能体模块输出的投资组合动作$\hat{a}_t=f\left(a_t^1,a_t^2,a_t^3;\varphi\right)$。进一步考虑投资风险，利用风险控制模块处理多智能体模块的投资组合动作，得到投资组合动作$\hat{a}_t'$。最后根据市场状态和市场趋势预测值计算最终动作$a_t=K\left(\hat{a}_t',\hat{y}_t\right)$，计算公式如下：

$$a_t=K(\hat{a}_t',\hat{y}_t)=\begin{cases}\dfrac{\hat{a}_t'+|\hat{a}_t'|}{2} & ,\hat{y}_t^1>0.5\\ \dfrac{\hat{a}_t'-|\hat{a}_t'|}{2} & ,\hat{y}_t^2>0.5\\ \hat{a}_t' & ,\text{ else}\end{cases} \tag{4-16}$$

其中$\hat{y}_t^1$是上升事件得分，与之对应的$\hat{y}_t^2$为下降事件的得分，a_t为输出的动作向量。因此多智能强化学习投资组合模型不仅考虑单个股票的权重配比，同时考虑到了整体市场环境波动。

（2）多智能体奖励函数

多智能体模块用于投资组合决策，其目标是最大化收益，可能会忽视潜在风险；风险控制模块则注重最小化风险，可能会因此牺牲过多利益。因此为避免多智能体投资模块和风险控制模块相互竞争，导致投资组合模型陷入局部最

中国知网 https://www.cnki.net

优，有必要引入奖励机制，促使模型既注重高收益，也要考虑低风险，从而产生能够适应高波动市场和多样化的动作集合。多智能体模块的奖励函数如下：

$$J(\theta)=\lambda_1 J_r(\theta)+\lambda_2 J_A(\theta) \tag{4-17}$$

其中 λ_1 和 λ_2 分别是回报奖励 $J_r(\theta)$ 和动作奖励 $J_A(\theta)$ 的学习率。具体地，奖励回报函数计算回测期内的每日资产增长率对数和的平均值，具体如下式：

$$\begin{aligned} J_r(\theta)&=\frac{1}{T}\log C_0\Pi_{t=1}^{T} r_t \\ &=\frac{1}{T}\left(\log C_0+\sum_{t=1}^{T}\log r_t\right) \end{aligned} \tag{4-18}$$

其中 C_0 为初始投资组合价值，T 为交易天数，$r_t=\dfrac{c_t}{c_{t-1}}$ 为投资组合在 t 时的增长率。同时为促进动作集的多样性，防止策略僵化，设计动作奖励函数如下：

$$J_A(\theta)=-\frac{1}{T}\sum_{t=1}^{T} D_{JS}\left(\hat{a}_t \| \hat{a}_t'\right) \tag{4-19}$$

其中 $\hat{a}_t$ 为多智能体模块在 t 时刻的动作，$\hat{a}_t'$ 为综合考虑风险控制模块后的调整动作，D_{JS} 是衡量 $\hat{a}_t$ 和 $\hat{a}_t'$ 两者间相似度的 JS 散度（Jensen-Shannon）。如果两者差异很大，则相应对 $J(\theta)$ 进行惩罚；反之如果两者相似，惩罚就较轻。

（3）多智能体目标函数

多智能体模块策略网络的目标函数为：

$$\begin{aligned} L(\varphi)&=\frac{1}{T}\sum_{t=1}^{T}\hat{A}_t\left(\min\left(\text{ratio}_t(\varphi),\text{clip}\left(\rho_t(\varphi),1-\varepsilon,1+\varepsilon\right)\right)\right) \\ \text{ratio}_t(\varphi)&=\frac{\pi_\varphi(\hat{a}_t'\mid s_t^a,a_t^1,a_t^2,a_t^3)}{\pi_{\varphi_{\text{old}}}(\hat{a}_t'\mid s_t^a,a_t^1,a_t^2,a_t^3)} \end{aligned} \tag{4-20}$$

进而 Critic 评价网络的优势函数 $\hat{A}_t$ 计算方式转变为：

$$\begin{aligned} &\hat{A}_t=Q_{(\varphi,\phi)}(s_t^a,a_t)-V_\psi(s_t^a)=Q_{(\varphi,\phi)}(s_t^a,K(\hat{a}_t',\hat{y}_t))-V_\psi(s_t^a), \\ &V_\psi(s_t^a)=\mathbb{E}_{\pi_\varphi}\left[\sum_{k=0}^{\infty}\gamma^k r_{t+k+1}\mid s_t^a=s\right] \\ &Q_{(\varphi,\phi)}(s_t^a,K(\hat{a}_t',\hat{y}_t))=\mathbb{E}_{(\varphi,\phi)}[R_t\mid s_t^a,K(\hat{a}_t',\hat{y}_t);\pi_\phi,\phi] \\ &=\mathbb{E}_{(\varphi,\phi)}\left[\sum_{k=0}^{\infty}\gamma^k r_{t+k+1}\mid s_t^a,a_t;\pi_\varphi,\phi\right] \end{aligned} \tag{4-21}$$

中国知网 https://www.cnki.net

其中$Q_\varphi(s_t^a,a_t)$表示在资产状态s_t^a下，在决策π_φ和趋势预测模块ϕ共同作用下，深度强化学习投资组合模型执行动作a_t后所获得的期望收益值。多智能体模块评价网络目标函数的定义如下：

$$L(\psi)=\frac{1}{T}\sum_{t=1}^{T}\left(V_\psi(s_t^a)-R_t\right)^2 \tag{4-22}$$

其中$\left(V_\psi(s_t^a)-R_t\right)^2$是价值函数估计值$V_\psi(s_t^a)$的误差项。

4.3.3 风险控制智能体协同决策

自从 2008 年全球性金融危机以来，投资者越来越重视资产风险管理的重要性。同时随着证券市场波动率的提升以及短周期波动趋势变得更加明显，如何在高波动环境下获得稳定收益并避免尾部风险，已成为智能投资策略设计的关键问题。因此，在多智能体投资组合模型中构建稳健的风险控制模块至关重要。本文主要采用风险预算策略进行风险控制模块的构建，并将其嵌入多智能体投资组合模型的策略优化过程，使智能体在给定的风险预算框架内学习最优资产配置策略。风险预算策略依据实际情况设计分配每项资产的目标风险贡献。当市场舆情呈现极端负面或正面时，该模块能够对投资组合权重进行校正，避免单一资产或单一情绪驱动导致的过度风险暴露。设多智能体模块输出的投资组合权重为$w_t=\left(w_1,\ldots,w_n\right)$，协方差矩阵$\sum_t$和资产收益向量$r_t$，则资产 i 的边际风险贡献MRC_i定义为：

$$MRC_i=\left(\sum x\right)_i \tag{4-23}$$

进一步资产 i 的风险贡献为：

$$RC_i=x_i\cdot MRC_{\ i}=x_i\left(\sum x\right)_i \tag{4-24}$$

风险预算策略要求各资产的相对风险贡献满足：

$$\begin{aligned}&\frac{RC_i}{\sum_{j=1}^{n}RC_j}=b_i\\&\sum b_i=1,b_i\geq 0\end{aligned} \tag{4-25}$$

其中b_i为给定的风险预算，可以结合舆情强度、波动率水平和历史收益表现等因素综合确定。例如当负面舆情较强时，对应资产风险预算b_i则降低；当正面舆情较强时，对应资产风险b_i则升高。

中国知网 https://www.cnki.net

由于比例风险贡献目标是非凸的，为实现可微求解并嵌入深度网络，需要将其转换为等价的凸优化问题。因此可以设如下变化：

$$x_i = \frac{y_i}{\sum_{j=1}^{n} y_j}, y_i > 0 \tag{4-26}$$

进而风险预算问题可等价转化为如下凸优化形式：

$$\begin{aligned} &\min_{y} y^{\top} \sum y \\ &s.t. \sum_{i=1}^{n} b_i \ln y_i = c, y_i > 0 \end{aligned} \tag{4-27}$$

其中 c 为常数，由约束规范化条件确定。因此该问题具备唯一最优解，适合嵌入端到端深度神经网络。为了将风险预算策略与多智能体强化学习模型联合训练，本文采用 CvxpyLayer 将上式 (4-27) 嵌入深度网络。CvxpyLayer 是一个将 CVXPY 优化问题嵌入到 PyTorch 或 TensorFlow 计算图中的工具，使得优化问题本身可以成为一个神经网络中的可微分层。为确保可微性，CvxpyLayer 内部利用 KKT 形式求解 (4-27)，构造 Newton 系统求解该 KKT 系统，并提供对输入的梯度，使整个风险控制模块可进行端到端训练。端到端风险控制网络的输入包括：各资产最近的样本协方差矩阵 $\sum_t$、金融舆情因子、历史收益波动率和多智能体模块产生的初始建议权重。然后经过 CvxpyLayer 凸优化层，最终输出风险控制后的投资组合权重。

4.4 投资组合模型结构与算法实现

4.4.1 考虑金融舆情的投资组合模型结构

本文提出的考虑金融舆情的深度强化学习投资组合（Deep Reinforcement Learning Portfolio Model Incorporating Financial Sentiment Analysis，DRL-FS）模型主要由数据特征提取融合和强化学习智能体投资决策两部分组成。其中股票历史行情数据和金融舆情信号的提取融合在上述有关章节已做详细阐述，在此不再赘述。执行投资决策的强化学习多智能体模块整体架构由 PPO 算法结构搭建而成，通过系统内的各模块分工协作，将决策、收益和风险控制由不同模块处理，避免了不同模块间的目标冲突问题。其中多智能体投资模块由 3 个基智能体构成，每个基智能体均为独立的交易者，由不同的奖励函数引导，从而能

中国知网 https://www.cnki.net

够适应不同的交易情景。最后构建一个集成智能体，运用 Concat 方法集成各基智能体的输出。同时在多智能体投资模块内部嵌入市场趋势预测模块和风险控制模块，进而综合考虑投资风险和市场动态趋势。趋势预测模块充分考虑整体市场的趋势信息，为多智能体投资模块补充完善输入状态信息。风险控制模块基于风险预算策略进一步分析了各资产的风险配比，并将多智能体投资模块生成的投资组合策略进行调整，从而降低其潜在风险水平。因此 DRL-FS 通过各模块明确高效的分工协作，持续从动态金融市场获取信息，实时调整策略，实现了收益和风险的动态平衡优化，从而提升了投资组合模型的整体收益和策略稳定性。图 4-8 展示了 DRL-FS 的整体结构。

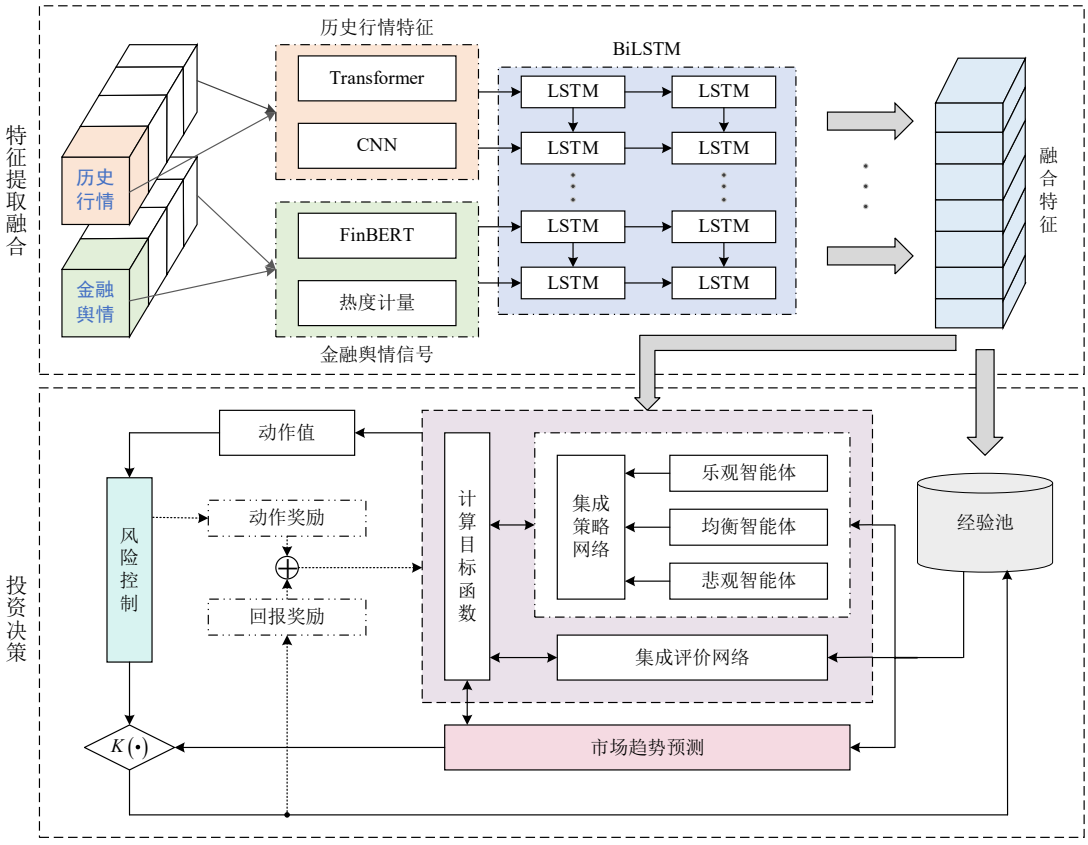


图 4-8 考虑金融舆情的深度强化学习投资组合模型结构

Fig. 4-8 Architecture of deep reinforcement learning-based portfolio optimization model integrated with financial sentiment

中国知网 https://www.cnki.net

4.4.2 考虑金融舆情的投资组合模型算法

在4.4.1小节中系统构建了融合金融舆情信号的深度强化学习投资组合模型结构的基础上，本节将具体阐述该模型在实盘与回测环境中的完整算法。从数据输入开始，依次经过特征提取、状态构建、智能体决策、风险控制直至权重输出，形成一个端到端、可迭代优化的决策闭环。算法主要分为七个主要步骤，具体见表 4-1 算法示意。以交易日为基本步长进行循环迭代，智能体根据当前状态做出资产配置决策，执行后环境反馈收益与新的状态，进而驱动策略更新。

首先获取当日及历史窗口内的个股行情数据（开盘、最高、最低、收盘、成交量），清洗并处理缺失值，然后进行标准化，同时获取经预处理的金融舆情文本数据。随后行情数据输入特征提取网络，以生成历史行情特征向量 P，同时经处理后的舆情信号数据传入 LSTM 网络提取其时序特征 S。并将 P 与 S 进行早融合拼接，形成联合特征向量。其三，基于多阈值 DC 方法并结合遗传算法优化，对当前市场状态进行趋势分析，计算出方向性变化指标 DC_t，并将其作为辅助特征。其四，将拼接融合后的多模态特征、市场趋势指标 DC_t、当前持仓量 H_t、现金余额 C_t 及技术指标集合，构成当前时刻的环境状态向量 s_t。其五，将状态 s_t 输入三个独立训练的基智能体（乐观、均衡、悲观），分别输出相应的建议投资动作。随后使基智能体输出经拼接后，输入多智能体融合网络，生成初步投资组合权重 a_t。其六，将初步权重 a_t、资产协方差估计 $\sum_t$、金融舆情信号等输入基于风险预算策略的可微凸优化层（CvxpyLayer），求解满足风险约束的最终投资权重 a_t^*。最后，根据 a_t^* 执行调仓操作，且环境计算该步的即时奖励 r_t 并转移至新状态 s_{t+1}。同步存储经验元组 $\left(s_t, a_t^*, r_t, s_{t+1}\right)$ 到经验回放池，然后定期采样并使用 PPO 算法更新所有智能体网络参数。

表 4-1 考虑金融舆情的深度强化学习投资组合模型算法

Table 4-1 Algorithm of financial sentiment-integrated DRL portfolio optimization model

初始化：	经验池 *buffer*，参数 φ, ψ, θ
输入：	交易日 t，历史窗口 w，预训练参数 $\left(\theta_1, \theta_2, \theta_3, \varphi, \psi\right)$
输出：	投资权重 w_t^*，更新后的参数
1：	数据获取与预处理
2：	$\tilde{P}_t \leftarrow$ 获取并预处理的行情数据 $\left(t, w\right)$
3：	$\tilde{S}_t \leftarrow$ 获取并预处理的金融舆情 $\left(t, w\right)$
4：	多模态特征提取与融合

中国知网 https://www.cnki.net

续表（4-1）

5：	$P_t \leftarrow CNN-Transformer-FCN\left(\tilde{P}_t\right)$
6：	$S_t \leftarrow LSTM\left(\tilde{S}_t\right)$
7：	$F_t \leftarrow \left[P_t; S_t\right]$
8：	市场趋势预测
9:	$DC_t \leftarrow$ 多阈值 $DC-GA\left(\tilde{P}_t\right)$
10：	状态构建
11：	$S_t \leftarrow \left[F_t, DC_t, H_t, C_t, TC_t\right]$
12：	多智能体决策
13：	$w_1, w_2, w_3 \leftarrow \pi_{\theta_1}(s,t), \pi_{\theta_2}(s,t), \pi_{\theta_3}(s,t)$
14：	$\hat{w}_t \leftarrow \pi_\phi\left[w_1, w_2, w_3\right]$
15：	风险控制调整
16：	$\sum_t \leftarrow CovEstimate\left(\tilde{P}_t\right)$
17：	$\lambda_t \leftarrow SentimentIntensity\left(S_t\right)$
18：	$w_t^* \leftarrow RiskBudgetOpt\left(\hat{w}_t, \sum_t, \lambda_t, DC_t\right)$
19：	训练阶段：交互与学习
20：	If training
21:	执行 w_t^*
22：	$r_t, s_{t+1} \leftarrow env-step(\cdot)$
23：	经验池存储$\left(s_t, w_t^*, r_t, s_{t+1}\right)$
24：	If 经验池准备就绪$(\cdot)$
25：	$batch \leftarrow$经验池采样$(\cdot)$
26：	$\varphi, \psi, \theta \leftarrow$PPO 更新 batch

4.5 本章小结

本章系统构建了融合金融舆情的深度强化学习投资组合模型。通过历史行情全局与局部特征提取、多阈值方向性变化趋势预测、金融舆情信号融合等模块，实现了多源信息的有效整合。基于不同风险偏好的基智能体设计及多智能体集成策略，结合风险预算的可微凸优化层，使模型在动态市场中兼顾收益与风险控制。完整的算法流程为模型的自适应优化提供了实现路径，为第五章的实证分析提供了方法基础和理论支撑。

中国知网 https://www.cnki.net

第5章 考虑金融舆情的深度强化学习投资组合实证

5.1 数据准备与预处理

5.1.1 标的股票选取划分

在投资组合实证研究中，数据集的选取、获取与划分对模型的实验设计与结果评价具有关键影响，直接关系到研究结论的可靠性与推广性。本节将系统阐述样本股票的选择依据、数据来源及划分方法，以保障模型在有效性及稳健性等方面的充分验证。

（1）选股标准

为构建适用于实证分析的投资组合，所选股票需符合以下几项原则：①行业分布：在投资组合中纳入不同行业的上市公司，能够有效提升投资组合的分散化，从而减少非系统性风险影响，增强整体抗波动能力。②规模和流动性：主要选取市值较大且交易活跃的股票，以确保投资组合在实际操作中具备良好的流动性与可执行性。③业绩表现：选取近期表现优异的个股有助于获得更佳的投资回报。但需注意，历史业绩并不能完全预示未来走势，故仍需结合基本面状况与市场环境等因素进行综合考量。④深度强化学习建模需求：由于本文采用深度强化学习方法，选股还需满足模型构建的技术需求，例如股票数量设定和历史数据长度与完整性。本文实证数据时间窗口覆盖 2015 年至 2025 年，因此上市时间较短、数据不完整的股票未纳入样本范围。同时通过选取跨越多个市场周期的长时间序列数据，可全面检验训练后的智能体在不同市场环境下的稳健性与风险管理能力。

（2）标的股票选取

沪深 300 指数（CSI300）成份股总市值约占沪深两市总市值的 60%，是 A 股市场中的标杆性宽基指数，能够较为全面地反映我国证券市场整体价格走势。故本文中国股市部分的标的股票选自该指数的成份股范围。对于美国股市标的股票，本文选用道琼斯工业平均指数（Dow Jones Industrial Average, DJIA）的成份股作为研究对象。该指数由美国道琼斯公司编制，由 30 家具有重要影响力的工业类上市公司股票构成，通常被视为衡量美国股市表现及经济整体走势的蓝筹股指标，也是全球投资者观察美国市场动态的重要参照。因此综合考虑前文所述的行业分布、市值规模与流动性等选股标准，最终分别以沪深 300 指数与

中国知网 https://www.cnki.net

道琼斯工业平均指数为样本池，从其中成份股中选取相应股票作为实证分析的标的，具体名单见下表 5-1 所示：

表 5-1 中美股市标的股票

Table 5-1 Underlying stocks in Chinese and U.S. stock markets

中国股市 CSI300			美国股市 DJIA		
公司名称	股票代码	行业分类	公司名称	股票代码	行业分类
贵州茅台	600519	主要消费	微软	MSFT	科技
中国平安	601318	金融	苹果	AAPL	科技
招商银行	600036	金融	英伟达	NVDA	信息技术
美的集团	000333	可选消费	亚马逊	AMZN	非必需消费
长江电力	600900	公用事业	元平台	META	通信服务
隆基绿能	601012	工业	摩根大通	JPM	金融
紫金矿业	601899	原材料	雪佛龙	CVX	能源
恒瑞医药	600276	医药卫生	特斯拉	TSLA	非必需消费
海康威视	002415	信息技术	强生公司	JNJ	医疗保健
比亚迪	002594	新能源汽车	谷歌	GOOGL	通信服务

（3）数据集时间划分

本文股票历史数据的时间范围划分为 2015 年 1 月至 2025 年 12 月，共计 11 年，以覆盖包含不同市场态势的完整周期。为提高模型泛化能力与评价的可靠性，将总体数据按时间顺序划分为以下三个子集：2015 年 1 月至 2020 年 12 月为训练集，用于深度强化学习模型的参数训练与策略学习，使智能体能够从历史行情中捕捉市场规律与特征；2021 年 1 月至 2023 年 12 月为验证集，用于在训练过程中进行超参数调优与模型选择，避免过拟合，并初步评估模型在不同市场阶段的表现；2024 年 1 月至 2025 年 12 月为测试集，作为样本外数据，用于最终评价模型的泛化能力、稳健性与实际应用效果。具体时间划分见表 5-2，同时图 5-1 也展示了 CSI300 和 DJIA 的市场趋势。

表 5-2 股票数据集时间划分

Table 5-2 Temporal segmentation of the stock dataset

市场	训练集	验证集	测试集
CSI300	2015.01-2020.12	2021.01-2023.12	2024.01-2025.12
DJIA	2015.01-2020.12	2021.01-2023.12	2024.01-2025.12

中国知网 https://www.cnki.net

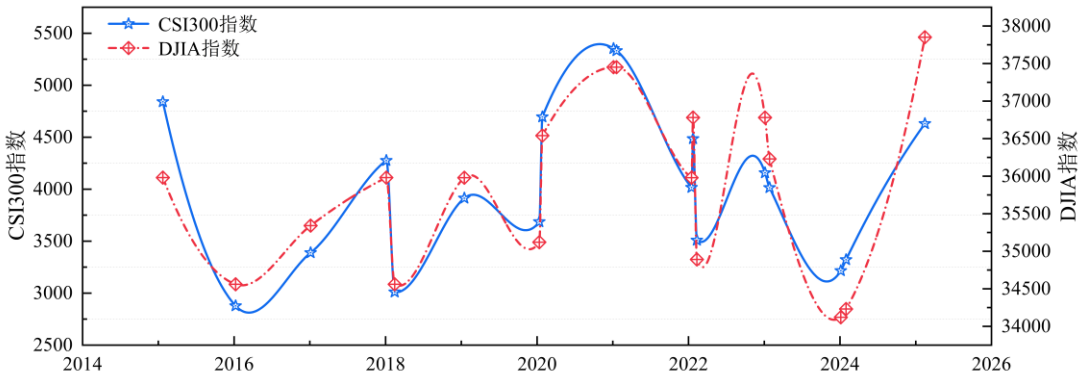


图 5-1 中美市场股指趋势示意

Fig. 5-1 Schematic illustration of stock index trends in the Chinese and U.S. markets

5.1.2 多源股票数据获取

（1）历史行情数据

对于股市历史行情数据的获取应选取多个不同特征，涵盖 2.3.1 中的基本面和技术面等多方面信息，同时也要考虑数据收集的难度。具体包括开盘价、收盘价、涨跌幅和成交量等在内的基本面数据，以及异同平均指数（MACD）和波动指数（VAR）等技术面数据。同时针对实证研究中的样本数据缺失问题，采用向后填充历史数据的方法进行处理。作为一款开源免费的 Python 财经数据接口工具，Tushare 提供了从数据获取到清洗、加工及存储的全流程支持，能够为金融研究人员与投资者提供高效、丰富且易于分析的数据支持。故本文所采用的国内标的股票历史行情数据，均来源于 Tushare 所提供的免费接口。此外 Yahoo Finance 作为国际金融服务平台，可支持获取美国股票历史数据、基金数据及宏观经济数据等信息，故对于 DJIA 股市标的股票的历史行情数据本文选用 Yahoo Finance 进行收集。数据的时间跨度为 2015 年 1 月至 2025 年 12 月，确保数据集涵盖完整的市场周期，包括股价上涨或下跌等不同市场趋势，并且规避模型评估对特定市场环境的偏好。历史行情数据样本见图 5-2。

（2）金融舆情数据

新闻媒体在信息发布与传播中扮演着关键角色，其报道与文本情绪容易在公共网络空间迅速扩散，并被自媒体及社交平台等多方机构过度聚焦或强化解读，从而形成舆论热点。本文选取的舆情信息数据主要包括新闻与股吧评论。综合考虑舆情与个股的相关性、实时性和可靠性三个角度，采用新浪财经作为

中国知网 https://www.cnki.net

新闻资讯来源。新闻舆情的发布时间、股票代码、标题以及正文共同构成舆情数据主体。基于网络爬虫和相关 HTTP 请求库爬取 2015 年 1 月至 2025 年 12 月共 4018 个自然日的标的股票相关资讯 425931 条。此外，比较各股吧的用户活跃度、发帖量及回复量，本文选取东方财富网和社媒 X 分别作为中美股评数据来源。股评主要包括发表用户、发表时间、股评内容、阅读量和股评数等，共爬取股吧评论 634512 条。相比权威性更高的新闻资讯，股评舆情中掺杂着较多语气词和表情等噪声成分，故有必要对股评进行数据清洗，主要包括标注、分词和停用词过滤等预处理工作。标的股票金融舆情数据样本如图 5-3。

日期	股票代码	开盘	收盘	最高	最低	成交量	成交额	振幅	涨跌幅	涨跌额	换手率
2020/4/30	600519	1271	1265.7	1285.01	1258.88	24661	3134408880	2.05	-0.72	-9.2	0.2
2020/5/6	600519	1251	1300	1300	1250	35835	4598589696	3.95	2.71	34.3	0.29
2020/5/7	600519	1299.4	1312	1314.99	1293	27935	3647628304	1.69	0.92	12	0.22
2020/5/8	600519	1317	1314.61	1338	1308.51	29079	3839218032	2.25	0.2	2.61	0.23
2020/5/11	600519	1320	1323.01	1335	1313.67	23671	3135990960	1.62	0.64	8.4	0.19
2020/5/12	600519	1318	1333	1334.99	1316	19722	2621824688	1.44	0.76	9.99	0.16
2020/5/13	600519	1333	1335.95	1337.99	1322.88	22014	2931464944	1.13	0.22	2.95	0.18
2020/5/14	600519	1330	1326.59	1334.88	1325.11	18575	2467976352	0.73	-0.7	-9.36	0.15
2020/5/15	600519	1329	1313	1333.5	1301.88	26398	3469736816	2.38	-1.02	-13.59	0.21
2020/5/18	600519	1306	1346.21	1351.5	1305.13	34362	4587989760	3.53	2.53	33.21	0.27
2020/5/19	600519	1364	1346.11	1364	1338	24787	3342210480	1.93	-0.01	-0.1	0.2
2020/5/20	600519	1346.11	1351	1359.18	1336.81	21183	2859455104	1.66	0.36	4.89	0.17
2020/5/21	600519	1355	1366.1	1371.96	1352.86	23052	3147105456	1.41	1.12	15.1	0.18
2020/5/22	600519	1366	1328.2	1366.1	1322.88	34427	4608696064	3.16	-2.77	-37.9	0.27
2020/5/25	600519	1330	1362.9	1366.58	1321	31561	4260387680	3.43	2.61	34.7	0.25
2020/5/26	600519	1369.88	1358	1369.95	1355	22470	3056188320	1.1	-0.36	-4.9	0.18
2020/5/27	600519	1359	1338	1360	1333	26777	3596654304	1.99	-1.47	-20	0.21

图 5-2 股票历史行情数据样本

Fig. 5-2 Sample of historical stock market data

股吧	股票代码	当前时间	标题	作者	阅读数	评论数	点赞数	帖子正文	列1	列2	列3	列4
贵州茅台吧	600519	2026-01-23 11:39:26.280	敢当时评丨错版马茅的收藏潜力不能掩	贵州茅台资讯	81	0		来源：海报新闻　海报新闻评论员张静宁　茅台可能也没想到，				
贵州茅台吧	600519	2026-01-23 11:39:26.280	中信证券：春节白酒实际动销有望维持	贵州茅台资讯	1851	14	9	来源：中国证券报·中证金牛座　中信证券研报称，白酒行业即将				
贵州茅台吧	600519	2026-01-23 11:39:26.280	大V亏损700万清仓五粮液	二马由之	6.2万	46	55	00:00/00:00视频播放器 is loading.播放视频播放静音当前时间　0				
贵州茅台吧	600519	2026-01-23 11:39:26.280	2026年01月12日【数据看盘】深沪北百	哈尼老茶客阿龙	3.3万	34	3	四大权益礼包，开户即送#复盘记录# $贵州茅台(SH600519)$　$中				
贵州茅台吧	600519	2026-01-23 11:39:26.280	段永平：最后一次晒单买入茅台（图）	巴芒录段	4.0万	107	91	炒股第一步，先开个股票账户				1
贵州茅台吧	600519	2026-01-23 11:39:26.280	别上当	我不是音恶	1	0		下午又要绿，收盘继续-0.8%？？？				
贵州茅台吧	600519	2026-01-23 11:39:26.280	放着十年一百倍的股我没买，在这里看	股友791d99c787	1	0		$贵州茅台(SH600519)$　放着十年一百倍的股我没买，在这里看这				
贵州茅台吧	600519	2026-01-23 11:39:26.280	年轻人，谁喝茅台啊？	花生毛豆666	113	28	1	年轻人，谁喝茅台啊？				
贵州茅台吧	600519	2026-01-23 11:39:26.280	2025年基金四季报披露完毕 基金规模	中际旭创资讯	1.0万	6	16	来源：证券时报 作者：吴琦　2025年基金四季报1月22日披露完毕，				
贵州茅台吧	600519	2026-01-23 11:39:26.280	那么多阴线，改名贵州阴茅吧	被ST的股民	1	0		那么多阴线，改名贵州阴茅吧				
贵州茅台吧	600519	2026-01-23 11:39:26.280	你们都没刷到新闻么	名字越长股票越涨	42	0	1	$贵州茅台(SH600519)$　你们都没刷到新闻么2026-01-23 11:27:57				
贵州茅台吧	600519	2026-01-23 11:39:26.280	要跌就好好的跌，每天零点几跌幅不过	回到A股的贾跃亭	7	1		$贵州茅台(SH600519)$　要跌就好好的跌，每天零点几跌幅不过熄				
贵州茅台吧	600519	2026-01-23 11:39:26.280	管理规模跌破500亿元，减持白酒股！	贵州茅台资讯	1.1万	56	20	来源：每日经济新闻　1月22日，易方达张坤管理的多只基金披露了				
贵州茅台吧	600519	2026-01-23 11:39:26.280	段永平又买入贵州茅台，从140元/股买	大道无形我更行	28	0		$贵州茅台(SH600519)$　段永平又买入贵州茅台，从140元/股买入				
贵州茅台吧	600519	2026-01-23 11:39:26.280	跌跌不休呀	股友253V39279w	10	0		跌跌不休呀				
贵州茅台吧	600519	2026-01-23 11:39:26.280	飞天茅台属于航天领域	春晖九鼎	13	0	1	$贵州茅台(SH600519)$　飞天茅台属于航天领域				
贵州茅台吧	600519	2026-01-23 11:39:26.280	飞天茅台不算商业航天吗？	主力进村啦	29	3	2	飞天茅台不算商业航天吗？				
贵州茅台吧	600519	2026-01-23 11:39:26.280	现在是下跌趋势，要相信趋势，不要轻	悟空道人	256	4	6	$五　粮　液(SZ000858)$　$贵州茅台(SH600519)$　现在是下跌趋				
贵州茅台吧	600519	2026-01-23 11:39:26.280	少写一瓢让“马茅”成错版，更有收藏	前瞻视点	7704	7	0	00:00/00:00视频播放器 is loading.播放视频播放静音当前时间　0				
贵州茅台吧	600519	2026-01-23 11:39:26.280	价投者没死，确实难受，26年再这么走	accident1234567	4	0	1	价投者没死，确实难受，26年再这么走势，99.99%价投者都会扛不住				
贵州茅台吧	600519	2026-01-23 11:39:26.280	2026年茅台将回到二十年前	天涯202201	9	0		$贵州茅台(SH600519)$　2026年茅台将回到二十年前				
贵州茅台吧	600519	2026-01-23 11:39:26.280	让他自己去i茅台卖吧，经销商，倒货	气宇轩昂的魏小达	16	1	2	让他自己去i茅台卖吧，经销商，倒货的都是傻的				
贵州茅台吧	600519	2026-01-23 11:39:26.280	又砸指数，老登股祭天	鳃晶龖	17	2	3	又砸指数，老登股祭天				

图 5-3 股票金融舆情数据样本

Fig. 5-3 Sample of financial public sentiment data on stocks

中国知网　https://www.cnki.net

5.1.3 股票数据预处理

（1）历史行情数据预处理

股票行情数据采集过程中可能受到股票停盘、数据库异常等情况影响，原始行情数据集中往往包含缺失值、异常数值或非数值型记录。若直接将其输入强化学习智能体模型，可能导致训练过程中网络参数或损失函数无法正常计算。因此，须对原始数据实施预处理，以增强其完整性与可靠性。具体步骤包括去重、缺失数据插补以及异常值修正等环节。针对停牌及后续交易日的股价，本文统一采用停牌前最后一个交易日的收盘价作为其取值，以保持数据连续性。对于周末及法定节假日等非交易日，则将其视为缺失值进行处理。其中缺失值与无穷值可采用向前或向后填充的方法进行插补。若数据中存在非数值型字符，则需对整表进行筛查，并将其转换为数值类型以确保数据格式统一。

（2）金融舆情数据预处理

通过网络爬虫获取的金融舆情数据中常混杂噪声及无关信息，因此需对原始文本进行预处理，剔除无价值内容，以提取更为有效的金融舆情数据。具体处理规则如下：对标题相同的文本仅保留一条，其余重复内容予以删除；移除表情包、图片等无法用于语言分析的内容；剔除转载自其他网站的文本，如标题中包含“转发”字样的帖子；删除标题缺失的帖子及诱导性广告；同时筛除官方发布的公告信息。按照上述流程完成数据预处理后，保留的有效文本将用于后续模型训练。经过数据清洗之后，还需利用大语言模型 Deepseek 对文本进行数据标注以确保分类有效性。标注体系将情感倾向划分为积极与消极两类，分别赋值为 1 和 0，并且运用随机选取方式对数据进行标注。最终输出结果已剔除缺失值部分，从而将所得分类作为最后的分类结果。

5.2 投资组合实证环境及评价基准

5.2.1 实证环境设定

实证部分需综合考虑算法的复杂度、数据规模与训练效率，进而构建相应的软硬件实验环境。本文实验主要在一台高性能 GPU 电脑上运行，具体配置为：处理器 Intel® Xeon® Gold 6226R CPU @ 2.90GHz，内存为 128 GB DDR4，硬盘 1TB，显卡 NVIDIA RTX 4070。实验基于 Windows 操作系统，主要采用 Python 3.10 作为编程语言。对于强化学习环境主要采用 OpenAI Gym 创建环境基础，

中国知网 https://www.cnki.net

同时结合 Stable-Baselines3 实现与主流强化学习算法进行基准对比和模块化调用，并在此基础上实现多智能体协作。为构建神经网络与训练框架，本文采用 PyTorch 1.12.1 作为深度学习框架。基于 Tushare 与 yfinance 获取股票历史行情数据与基本面数据。最后经过多轮调参和验证，本文采用的模型关键超参数设置如下表 5-3 所示：

表 5-3 实验环境超参数

Table 5-3 Hyperparameters of the experimental environment

参数类别	参数名称	参数值	参数类别	参数名称	参数值
环境参数	交易成本率	0.0015	训练参数	学习率	0.0003
	初始资金	1000000		折扣因子	0.99
	时间窗口长度	30		经验回放池容量	100000
	舆情特征维度	3		批处理大小	256
模型结构	行情特征维度	15		训练总步数	500000
	智能体隐藏层	[256，128]			

5.2.2 对比模型选择

在投资组合优化的研究实践中，选取适当的基准方法对于客观评估投资组合模型性能至关重要。基准模型提供了衡量不同模型表现优劣的统一参照，其选择需综合考虑数据来源的可信度、交易规则的一致性以及市场环境模拟的真实性等多个维度。只有确保这些条件得到严格控制，方能在同等基础上对不同模型的实际效果进行可靠比较。因此为确保评估过程的客观性与结果的可比性，本文所有基准模型均在相同的交易环境、统一的交易规则及一致的参数配置下完成训练与测试。本节将对所选用的基准方法进行系统梳理与分析，这些方法涵盖了多样化的策略类型与技术路径，旨在全面验证本文所提模型的相对优势与性能提升。

具体基准对比模型主要涵盖经典投资组合方法、在线投资组合和深度强化学习投资组合三大类别的 8 种基准对比模型，包括时序预测、均值回复和深度强化学习等主流方法。经典投资组合对比方法包括恒定再平衡组合模型（Constant Rebalanced Portfolios，CRP）、相关性驱动非参数学习模型

中国知网 https://www.cnki.net

（Correlation-driven Nonparametric Learning，CORN）以及鲁棒中值回复模型（Robust Median Reversion，RMR）。其中 CRP 策略基于固定权重分配理论，定期将资产比例重置到初始配置，以检验策略对市场均衡状态的适应能力；CORN 策略则基于历史收益相关性构建非参数相似性度量，从而动态选择最优资产子集；RMR 策略引入中值统计量替代均值估计，通过 Huber 损失从而增强对极端收益的鲁棒性。在线学习投资组合模型包括在线移动平均回复模型（Online Moving Average Reversion，OLMAR）和被动攻击均值回复模型（Passive Aggressive Mean Reversion，PAMR）。其中 OLMAR 策略结合移动平均滤波与均值回复假设，通过自适应窗口捕捉中短期价格趋势；PAMR 策略则通过在线学习框架动态调整投资组合，利用价格序列的均值回复特性构建正则化约束项。深度强化学习投资组合模型则包括近端策略优化模型（Proximal Policy Optimization，PPO）、关系感知 Transformer 模型（Relation-Aware Transformer，RAT）以及利润最大化双延迟确定性策略梯度模型（TD3 with Profit Maximization，TD3-Profit）。其中 PPO 是一种基于策略梯度的 DRL 算法，通过引入裁剪机制对策略更新幅度进行限制，从而在训练稳定性与策略高效优化间取得良好平衡；RAT 则基于 Transformer 构建多头自注意力机制，建立资产间的高阶相关性及长期价格模式；最后 TD3-Profit 则利用改进 TD3 算法，将收益-风险联合指标作为策略梯度更新目标，进而优化投资组合的长期累积收益。各类对比模型总结如下表所示：

表 5-4 实证对比模型总结

Table 5-4 Summary of empirical comparative models

对比模型	模型分类
恒定再平衡组合模型（CRP） 相关性驱动非参数学习模型（CORN） 鲁棒中值回复模型（RMR）	经典投资组合模型
在线移动平均回复模型（OLMAR） 被动攻击均值回复模型（PAMR）	在线投资组合模型
近端策略优化模型（PPO） 关系感知 Transformer 模型（RAT） 利润最大化双延迟确定性策略梯度模型（TD3-Profit）	深度强化学习投资组合

中国知网 https://www.cnki.net

5.2.3 模型评价标准

为全面评估各投资组合模型的盈利与风险管理能力，本文采用累计收益率（Cumulative Return, CR）、年化收益率（Annualized Return，AR）、最大回撤（Maximum Drawdown，MDD）、夏普比率（Sharpe Ratio，SR）以及投资组合风险（Risk）作为评价指标，并选取年化波动率度量投资组合风险值。同时为确保统计结果的显著性，所有结果取 10 次独立实验的平均值。

累计收益率是指投资组合模型在相关期限内获得的总回报率：

$$CR_T = \frac{b_t - b}{b} \tag{5-1}$$

其中 b 为本金，b_t 表示流动资产价值。

年化收益率：AR 代表的是投资组合在测试期间每年的平均收益率，去除了时间价值的影响。给定一个包含 N 种资产的投资组合，其中第 i 种资产在时刻 t 的权重为 $w_{i,t}$，收盘价格为 $p_{i,t}$，则该投资组合在 t 时刻的价值可表示为：

$$C_t = \sum_{i=1}^{N} w_{i,t} p_{i,t} \tag{5-2}$$

在此基础上，年化收益率(AR)的计算公式为：

$$AR = \left(\left(\frac{C_T}{C_1} \right)^{\frac{T_y}{T}} - 1 \right) \times 100\% \tag{5-3}$$

其中，T_y 表示年度交易日总数，T 为整个交易周期的总交易日数。为满足交易监管要求，投资组合权重需满足以下约束条件：多头限制约束 $\forall \omega_{i,t} \in w_t$，$\omega_{i,t} \geq 0$；资本预算约束 $\sum_{i=1}^{N} w_{i,t} = 1$，$w_t \in \mathbb{R}^N$ 表示时刻 t 的投资组合权重向量。

最大回撤：MDD 作为衡量交易周期内极端风险的关键指标，其量化了投资组合从前期峰值到后期谷值的最大相对损失，进而能有效反映极端市场条件下的潜在风险敞口。具体计算公式如下：

$$MDD_t = \max_{t_1 < t_2 \leq t} \left(\frac{C_{t_1} - C_{t_2}}{C_{t_1}} \right) \tag{5-4}$$

其中，t_1 和 t_2 为满足 $t_1 \leq t_2 \leq t$ 的时间点，C_{t_1} 表示投资组合在 t_1 时刻的净值峰值，C_{t_2} 表示后续出现的净值低谷值。

中国知网 https://www.cnki.net

夏普比率：累积资产组合价值和年平均收益率体现了测试期间的收益，但并未考虑收益的波动。收益来源于向上波动，向下波动也会带来损失。进而选择 SR 综合考虑资产组合的收益和风险，其表示投资组合收益增长对单位风险增长的程度，衡量了单位风险溢价，该指标数值越高意味着风险调整后的收益表现越佳。具体的计算公式如下所示：

$$SR = \frac{AR - r_f}{\mathrm{Vol}} \tag{5-5}$$

其中，r_f 表示无风险利率（risk-free rate），通常为 0.03，Vol 为年化波动率（Annualized Volatility，AVOL），其计算公式如下：

$$Vol = \sqrt{\frac{T_y}{T-1}\sum_{t=1}^{T}\left(r_t^T a_{t-1} - \overline{r}_t^T \overline{a}_{t-1}\right)^2} \tag{5-6}$$

其中 T 为总交易日数，T_y 为年度交易日数，r_t 为第 t 日收益率向量，a_{t-1} 代表 t-1 时刻投资组合权重向量。

5.3 考虑金融舆情的深度强化学习投资组合模型对比分析

5.3.1 中美股市投资组合模型绩效对比

为验证本文提出的考虑金融舆情的深度强化学习投资组合模型（DRL-FS）的有效性，本小节进行投资组合模型绩效对比实验。表 5-5 为各类所选基准对比模型与 DRL-FS 模型在中美股市测试数据集中的评价指标对比实验结果。其中符号↑表示指标值越大越好，如 AR 和 SR；而符号↓则表示指标偏好较小值，如 MDD 和 Risk。

从沪深 300 数据集的结果来看，DRL-FS 模型的年化收益率 AR 显然比所有其他投资组合模型均高，获得了最高的 AR（8.87%）和最高夏普比率 SR（0.27），同时也将投资组合风险 Risk 保持在 0.0119 这一相对较低的水平，由此可知 DRL-FS 中提出的多智能体结构在平衡投资组合收益和风险等不同目标之间具有更强的性能。同时测试期间国内一年期定存等低风险 AR 均值为 1.63%，由表 5-5 可知 CORN、OLMAR 和 PAMR 均未跑赢定存方案。进而在波动剧烈的市场中，通过执行较为保守的交易策略 CRP，获得了相对较高的利润，实现 7.19% 的年化收益率和 0.19 的夏普比率。PPO 模型也凭借策略更新的约束机制，能够根据市场状态实时调整，避免持续暴露于下跌风险，故取得了最低的最大回撤

中国知网 https://www.cnki.net

MDD（31.19%）。相比之下 DRL-FS 模型可能因多个智能体间的复杂交互而引入了额外的策略波动，从而在某些情况下增加些微回撤。对于在道琼斯数据集上获得的结果，考虑金融舆情的深度强化学习投资组合模型 DRL-FS 在所有评价指标上均显著优于其他基准对比模型。DRL-FS 模型获得的 AR 比单智能体 TD3-Profit 模型高出 26%，同时在 MDD 方面相比 TD3-Profit 减少了 18% 的最大可能损失。此外，在 DJIA 数据集中 DRL-FS 模型的 MDD 也超过了 PPO 模型。

表 5-5 中美股市基准模型绩效对比

Table 5-5 Benchmark model performance comparison between Chinese and U.S. stock markets

市场	CSI300				DJIA			
评价指标	AR(%)↑	MDD(%)↓	SR↑	Risk↓	AR(%)↑	MDD(%)↓	SR↑	Risk↓
CRP	7.19	33.96	0.19	0.0131	11.44	19.66	0.58	0.0095
CORN	-2.06	59.28	-0.13	0.0219	1.62	41.76	0.08	0.0122
RMR	5.77	41.96	0.07	0.0215	-12.98	61.23	-0.51	0.0180
OLMAR	-3.50	55.67	-0.17	0.0217	-13.89	59.89	-0.54	0.0179
PAMR	-14.24	49.32	-0.47	0.0223	-37.72	81.72	-1.35	0.0174
PPO	6.84	**31.19**	0.18	0.0122	10.81	18.24	0.58	0.0089
RAT	6.78	31.48	0.18	0.0121	10.62	18.19	0.57	0.0088
TD3-Profit	7.18	33.97	0.19	0.0128	11.45	19.65	0.58	0.0095
DRL-FS	**8.87**	31.83	**0.27**	**0.0119**	**15.52**	**16.21**	**0.80**	**0.0086**

图 5-4 和图 5-5 分别展示了 2024 年至 2025 年整个模型测试期间，所有基准对比模型及市场指数在中美股市上的投资组合价值趋势。DRL-FS 在上涨期、下跌期和震荡期等不同市场条件下均取得了较为优异的表现。特别是在 2024 年市场指数大幅下跌时，DRL-FS 能够很好地管理风险，避免在此期间遭受巨大损失。故整合多个智能体从不同层面观察资产变化，能够有效增强投资组合模型适应不同市场趋势条件的能力。

同时为了验证 DRL-FS 策略在不同市场趋势中的鲁棒性和适应能力，在 DJIA 数据集呈上涨和下跌趋势时分别对该策略进行对比分析，组合风险如图 5-6 所示。在行情上涨时，DRL-FS 策略不仅保持了收益竞争力，投资组合净值一直处于较高水平，还将风险值控制在较低水平；而在市场处于下跌趋势时，DRL-FS 通过动态调整策略使得投资组合净值超过所有基准策略，同时组合风险保持稳定。特别是在市场指数单日跌幅超过 10%的极端下行行情中，模型利用 DC 方

中国知网 https://www.cnki.net

法能够实时捕捉环境变化，为风险控制智能体提供及时反馈，使投资组合风险波动幅度维持稳定，有效实现了多目标间的动态平衡。因此，对比分析充分验证了 DRL-FS 模型在风险收益平衡和市场环境适应性的稳健鲁棒性，以及跨市场应用的强大泛化能力。

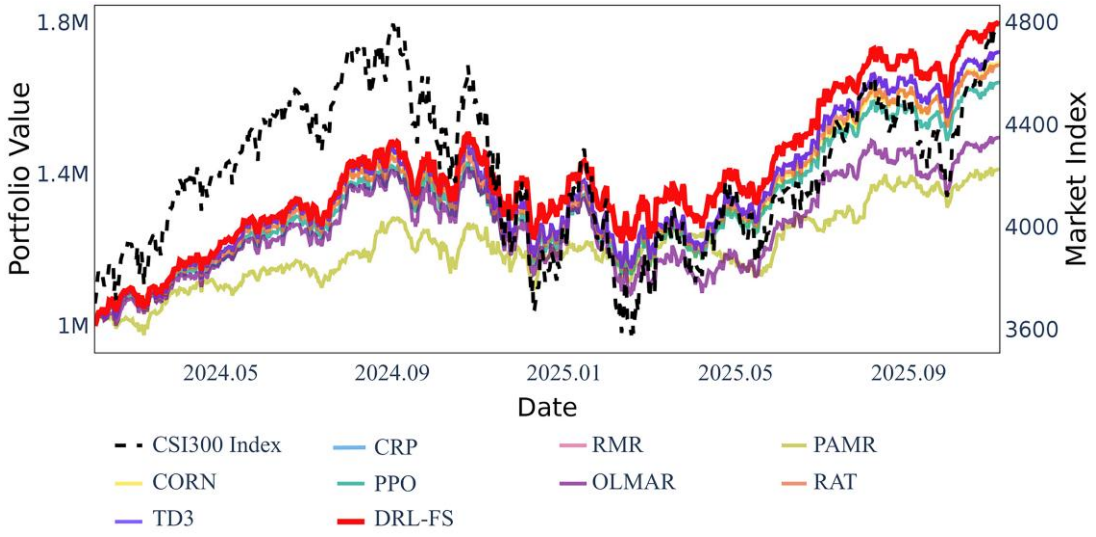


图 5-4 中国股市投资组合价值变化曲线

Fig. 5-4 Value change curve of the chinese stock market investment portfolio

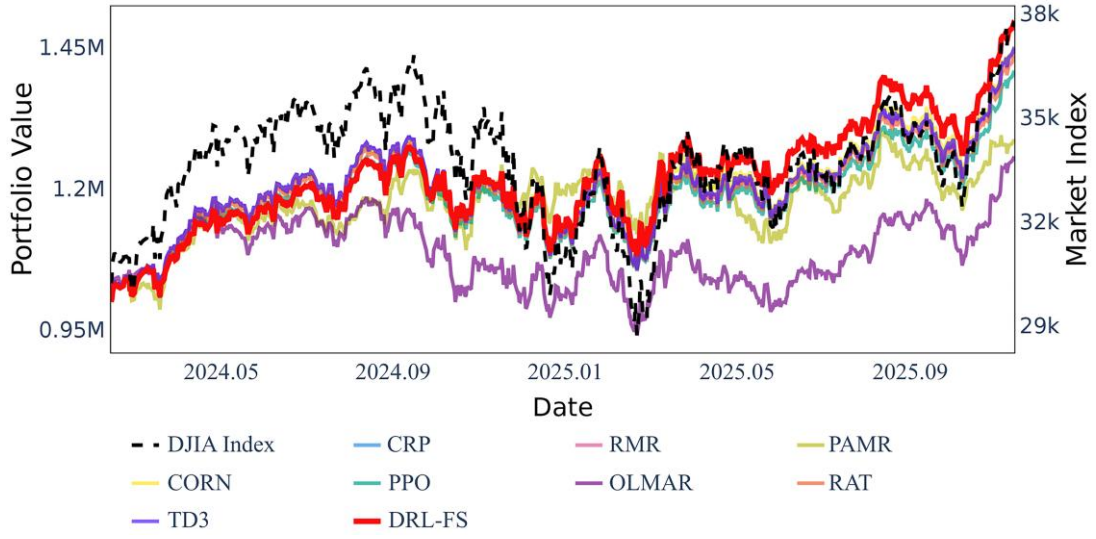


图 5-5 美国股市投资组合价值变化曲线

Fig. 5-5 Value change curve of the U.S. stock market investment portfolio

中国知网 https://www.cnki.net

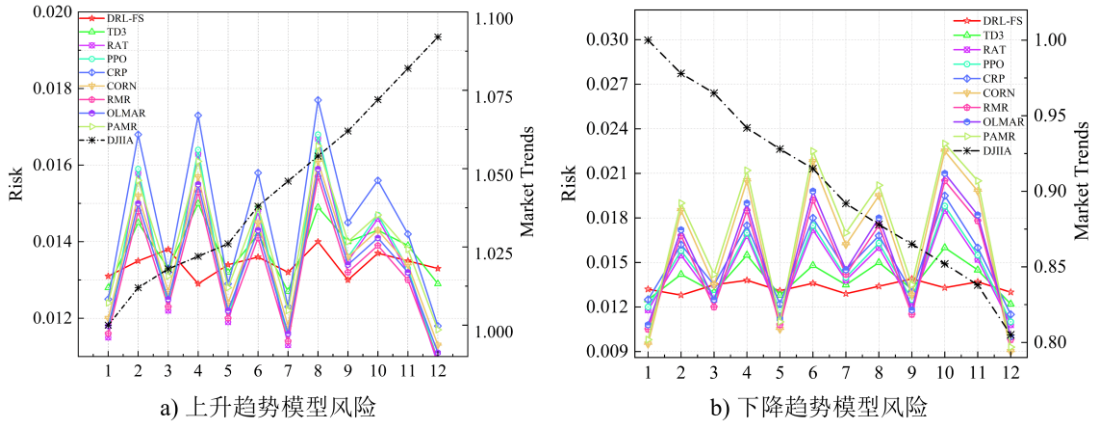


图 5-6 DJIA 不同市场趋势投资组合风险对比

Fig. 5-6 Comparison of investment portfolio risks under different market trends in the DJIA

5.3.2 投资组合模型交易策略行为对比

在基于投资组合净值趋势分析了 DRL-FS 投资组合模型相对基准模型之间的差异与优势后，需进一步从交易行为层面，验证模型内各单智能体在测试数据集上的操作特征，是否与对应奖励函数的理论性能预期相契合。图 5-7 与 5-8 将 DRL-FS 模型中各组成智能体的交易操作标注于股价趋势图中，直观地呈现了智能体依据价格波动制定交易决策的内在逻辑，现结合示意图对各智能体交易行为展开具体分析。

其一，各智能体的交易操作频率与奖励函数设计特征高度匹配。从图表局部放大区域可观察到，风险智能体在相同交易日区间内的交易操作次数更多，这与该智能体奖励函数所倡导的风险规避目标相契合，能够通过增加交易决策的执行频次，及时调整投资组合头寸以规避潜在损失。与之相反，投资基智能体的奖励函数聚焦于长期收益获取，因此其交易操作频率显著降低，更倾向于长期持仓以捕捉趋势性收益。而集成多智能体作为两类子智能体策略的融合载体，同时兼顾交易基智能体的长期收益导向与风险智能体的风险控制需求，其交易操作次数介于交易基智能体与风险智能体之间，实现了收益获取与损失预防的初步平衡。

其二，集成多智能体可通过权衡子智能体决策建议，选择适配股价趋势的最优交易方案。以图 5-7 的局部放大区域为例，在第 432 天左右，当股价触及阶段性低点时，交易基智能体基于长期收益判断执行做多决策，而风险智能体

中国知网 https://www.cnki.net

出于风险规避考量选择不交易；集成多智能体在综合两方决策逻辑后，认可收益智能体的做多判断，并于同日同步执行做多操作。在后续股价攀升至阶段性高点的区间内，收益智能体与风险智能体均做出做空决策，从收益获取角度分析，两类子智能体的决策均具备盈利可能性，但风险智能体的做空时机更贴合价格波动规律，决策合理性更优，集成多智能体则据此选择遵循风险智能体的做空建议。

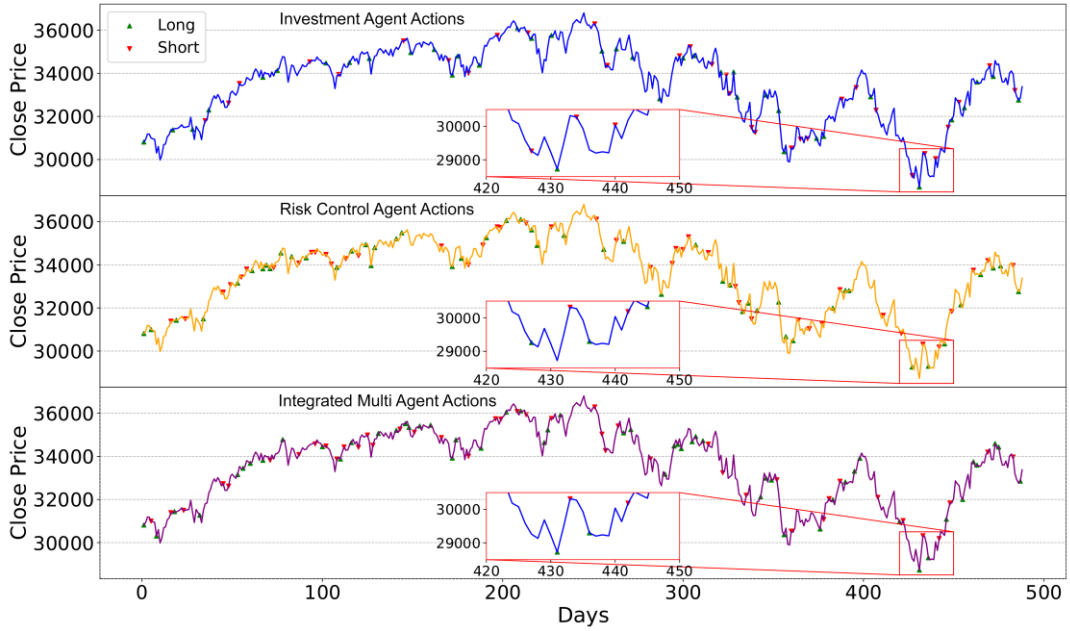


图 5-7 美国股市强化学习智能体交易策略行为对比

Fig. 5-7 Comparison of trading strategy behaviors of RL agents in U.S. stock market

其三，集成多智能体具备基于市场趋势的自主决策能力，可在子智能体决策非最优时做出独立判断。如图 5-8 所示，在第 397 天附近的股价阶段性高点区域，因前期已完成做空操作，收益智能体与风险智能体均选择持仓观望；但从价格趋势来看，该时点前的做空操作已形成浮亏，两类子智能体的观望决策并非最优选择。在此情形下，集成多智能体凭借对股价趋势的精准感知，突破子智能体的决策建议约束，自主执行做空操作，该决策与同期两类子智能体的操作均形成显著差异。尽管集成多智能体的自主交易决策无法实现绝对最优，但相较于同期子智能体的决策表现，其操作能够为投资组合带来更高的收益回报，体现了自主决策机制对模型收益能力的提升作用。

中国知网 https://www.cnki.net

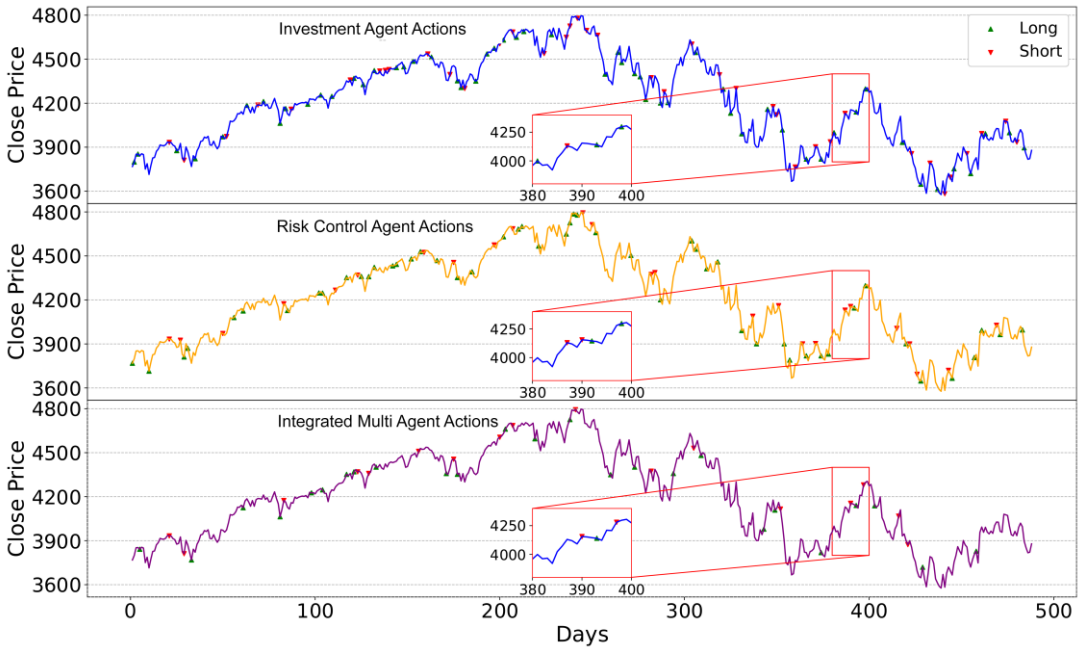


图 5-8 中国股市强化学习智能体交易策略行为对比

Fig. 5-8 Comparison of trading strategy behaviors of RL agents in China's stock market

5.3.3 投资组合模型资产数量扩展对比

为检验 DRL-FS 投资组合模型在不同资产规模下的鲁棒性与泛化能力，本小节在基准模型基础上，将投资池分别扩展至 20 支与 30 支股票，以对比实验中表现较优的 CRP、PPO 和 TD3 模型为对照组，并结合选股策略，分别在中美股市选取相应股票进行多维度性能扩展测试。

由图 5-9 和图 5-10 扩展对比结果可得：在 20 支、30 支两种资产规模下，DRL-FS 在中美市场中均保持绝对领先地位。20 支规模时，DRL-FS 在中国市场 AR 为 8.50%，超出第二位的 CRP（7.05%）1.45 个百分点，在美国市场 AR 为 15.00%，超出 CRP（11.20%）3.80 个百分点；30 支规模时，该优势收窄至 1.30 与 3.60 个百分点，但仍显著领先。其他模型中，CRP 与 TD3 表现高度趋近，中美市场各规模下四项指标差异均小于 0.05，表明 TD3 收敛最终将近似到等权组合的局部最优解；PPO 则因训练过程过度拟合 10 支股票分布，扩展至 20 支与 30 支后绩效衰减最为显著，始终位列末位。从策略相对排名看，DRL-FS 始终居首，CRP 与 TD3 居中，PPO 居末，该排序在中美市场完全一致。更为关键的是，DRL-FS 的相对优势在资产扩展过程中并未发生实质性衰减：中美市场 20

中国知网 https://www.cnki.net

支规模超额收益分别为 1.45%与 3.80%，30 支规模为 1.30%与 3.60%，与 10 支规模的 1.68%与 4.08%基本持平。由此可知，DRL-FS 模型中金融舆情信息为其提供了稳定且跨规模泛化的超额收益来源，多智能体框架亦有效提升了模型在高维动作空间下的优化效率。以上结果充分验证了 DRL-FS 投资组合模型的先进性、鲁棒性和跨市场和规模适用性。

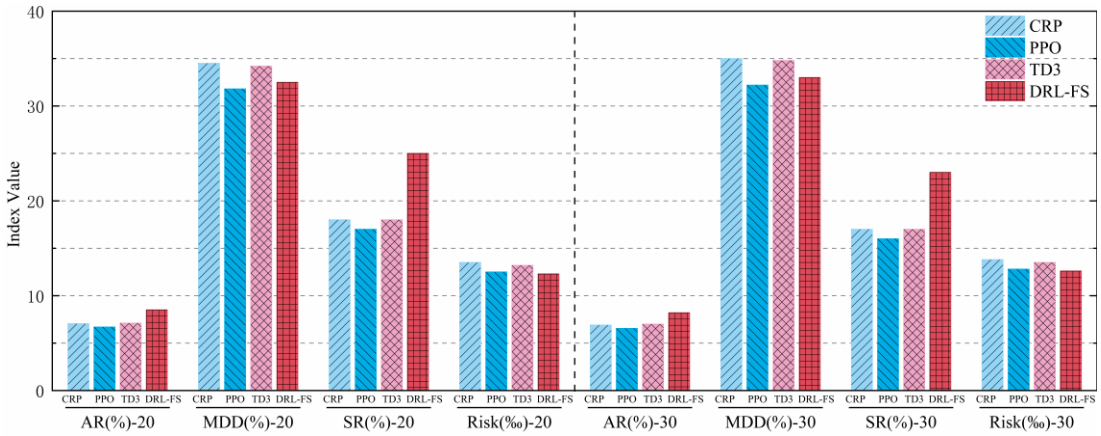


图 5-9 CSI300 市场中资产数量扩展对比

Fig. 5-9: Comparison of asset quantity expansion in the CSI 300 market

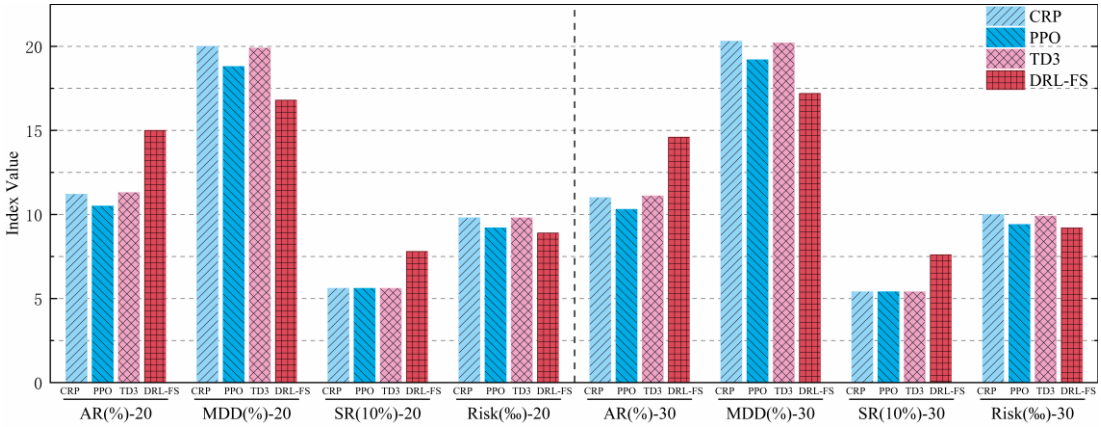


图 5-10 DJIA 市场中资产数量扩展对比

Fig. 5-10: Comparison of asset quantity expansion in the DJIA market

5.4 考虑金融舆情的深度强化学习投资组合模型消融分析

5.4.1 投资组合模型金融舆情消融分析

为厘清金融舆情对投资组合性能的实际有效影响，同时探究 DC 方向性因

中国知网 https://www.cnki.net

素的引入有效性，本小节采用消融实验方法对两者进行验证分析。在基准模型基础上，依次添加或替换所提的关键输入信息，并通过滚动时间窗回测对比不同消融组合的年化收益率、夏普比率、最大回撤及组合风险变化。

表 5-6 金融舆情消融分析结果表明，同时融合股吧评论与新闻两类舆情信息的策略（FS），其绩效表现显著优于仅使用单一舆情源（S1 或 S2）的策略。在中国市场 CSI300 中，DRL-FS 策略的年化收益率（AR%）达到 7.91%，夏普比率（SR）为 0.24，风险值（Risk）为 0.0130；而仅使用股吧评论的 DRL +S1 策略，其 AR%下降至 6.84%，SR 降至 0.20，Risk 则升高至 0.0142。不考虑金融舆情的基准模型 DRL 则实现了最低的年化收益 5.47 和夏普比率 0.15，风险也为所有消融实验中最高。这一现象在美国市场 DJIA 中同样显著，表明单一舆情源往往存在信息片面性问题，股吧评论虽反映散户情绪但噪声较大，新闻报道权威性强但存在滞后性。多源舆情融合则实现了信息的优势互补，既捕捉市场的即时情绪波动，又能获取宏观基本面变化，从而可以构建更完整的市场认知图谱。

同时方向性变化（DC）模块的引入也显著提升了策略的风险调整后收益。对比 DRL-FS 与 DRL-FS +DC 两组策略，在中国市场中，加入 DC 模块后，AR%从 7.91%提升至 8.72%，SR 从 0.24 上升至 0.27，同时 Risk 从 0.0130 下降至 0.0121。可知 DC 模块能够识别舆情走势的趋势转折点，而非简单地对舆情强度做出反应。在金融市场中，舆情方向的转变往往预示着价格趋势的拐点，DC 模块通过捕捉这一关键信息，使策略能够在市场情绪反转前及时调整仓位，从而既提升了收益能力，又有效控制了回撤风险。此外 TD3 框架下的消融实验结果同样验证了以上结论的稳健性。

表 5-6 投资组合模型金融舆情消融分析表

Table 5-6: Ablation study of financial sentiment in the portfolio model

市场	CSI300				DJIA			
评价指标	AR(%)	MDD(%)	SR	Risk	AR(%)	MDD(%)	SR	Risk
DRL+FS+DC	8.72	31.83	0.27	0.0121	15.52	16.21	0.80	0.0089
DRL+FS	7.91	33.12	0.24	0.0130	14.38	17.45	0.73	0.0095
DRL+S1	6.84	34.56	0.20	0.0142	12.97	18.93	0.65	0.0103
DRL+S2	6.12	35.21	0.18	0.0148	11.86	19.74	0.59	0.0109
DRL+DC	7.23	33.89	0.22	0.0135	13.41	18.12	0.68	0.0098
DRL	5.47	36.78	0.15	0.0156	10.23	21.34	0.51	0.0117

中国知网 https://www.cnki.net

续表（5-6）

TD3+FS+DC	8.46	32.26	0.25	0.0131	11.45	19.65	0.58	0.0098
TD3+FS	7.68	33.54	0.22	0.0140	10.72	20.43	0.53	0.0104
TD3+S1	6.59	34.98	0.18	0.0151	9.84	21.67	0.47	0.0112
TD3+S2	5.93	35.67	0.15	0.0158	8.91	22.38	0.42	0.0119
TD3+DC	6.98	34.12	0.20	0.0145	10.13	21.02	0.50	0.0107
TD3	5.12	37.21	0.13	0.0165	8.24	23.15	0.38	0.0125

5.4.2 投资组合模型多智能体消融分析

为系统评估 DRL-FS 模型中多智能体模块的有效性，设计消融实验对比分析乐观、均衡和悲观三类基智能体及其集成策略。实验选取沪深 300 指数和道琼斯工业指数的测试集数据，采用夏普比率、最大回撤、累积收益率和年化收益率作为评价指标。其中各智能体设置如下：乐观智能体（DRL-P）采用高风险偏好策略，均衡智能体（DRL-M）基于风险平价原则设计，悲观智能体（DRL-N）以防御为导向，DRL-mean 为三者交易操作的简单平均值，DRL-FS 为本文提出的融合多智能体模块的深度强化学习模型。

由实验结果表 5-7 可知，不同风险偏好的智能体呈现出显著的分化特征。在 CSI300 市场中，乐观智能体实现了 7.22%的年化收益率，但最大回撤高达 38.51%，表明其收益潜力与风险暴露并存；均衡智能体的夏普比率为 0.23，其在 6.21%的年化收益与 31.71%的 MDD 间取得了最佳平衡；悲观智能体虽将回撤控制在 29.45%，但年华化收益率仅 5.81%，存在着明显收益差距。在 DJIA 市场中，悲观智能体展现出了较强的防御能力，其将 MDD 控制在最低水平，而乐观智能体则获得三者最高收益 11.19%，但伴随着较大回撤 33.52%。此外，均值集成策略在中美股市中均实现夏普比率超 0.18，并将回撤控制在正常水平，验证了多智能体集成可有效平滑极端风险。集成多智能体模块的 DRL-FS 模型则在双市场中均展现出显著优势。在 CSI300 市场，DRL-FS 的夏普比率达 0.26，较最优基智能体（DRL-M）提升了 15.4%；年化收益率为 8.62%，较 DRL-mean 提升 43.3%；累计收益率高达 1.91，较 DRL-mean 提升 66.1%。在 DJIA 市场，DRL-FS 的夏普比率达 0.73，较 DRL-P 提升 39.3%；年化收益率则为 15.38%，较 DRL-mean 提升 63.0%；最大回撤也控制在 16.09%，显著优于除悲观智能体外其他模型。值得注意的是，DRL-FS 在双市场均实现了最高收益与次低回撤，表明多智能体模块在提升收益的同时未引入额外风险。

中国知网 https://www.cnki.net

表 5-7 DRL-FS 多智能体消融实验评价指标对比

Table 5-7 Comparison of evaluation metrics for ablation experiments on MAIDRL-based agents

市场	CSI300(24-25)				DJIA(24-25)			
模型	SR	AR(%)	CR	MDD(%)	SR	AR(%)	CR	MDD(%)
CRP	0.15	7.03	0.33	33.85	0.42	11.05	0.50	19.63
DRL-P	0.21	7.22	1.38	38.51	0.52	11.19	1.60	33.52
DRL-M	0.23	6.21	1.26	31.71	0.55	8.04	1.45	20.11
DRL-N	0.17	**5.81**	0.71	29.45	0.62	**6.99**	0.90	13.41
DRL-mean	0.18	6.01	1.15	32.77	0.50	9.44	1.30	22.79
DRL-FS	**0.26**	8.62	**1.91**	**31.71**	**0.73**	15.38	**2.12**	**16.09**

进一步分析多智能体模块的作用机制，其贡献主要体现在三个维度：收益增强、风险预警和决策优化。对比 DRL-P 与 DRL-FS，在 CSI300 牛市阶段，多智能体帮助模型额外捕获 7%超额收益，验证了其对趋势确认的增强作用；对比 DJIA 市场中 DRL-mean 与 DRL-FS，多智能体模块使回撤从 22.79%降至 16.09%，说明负面舆情信号有效触发风险规避；由累计收益 CR 可知，DRL-FS 在 CSI300 市场中达 1.91，远超其他模型，反映了多智能体模块能够根据市场状态动态调整策略权重，从而有效提升交易决策的稳健性与适应性。同时跨市场对比表明，DRL-FS 在 CSI300 的改进幅度高于 DJIA，这可能与中美市场投资者结构差异有关，A 股市场散户占比较高且情绪驱动特征更为明显，故多智能体模块在情绪波动较大的环境中发挥了更强的策略优化作用。

5.5 本章小结

本章针对考虑金融舆情的深度强化学习投资组合模型（DRL-FS）开展实证研究。首先系统阐述了数据选取、预处理及实验环境设定，并选取涵盖经典、在线及深度强化学习三大类共 8 种基准模型进行对比。通过中美股市的绩效对比、交易行为分析、资产数量扩展及消融实验，验证了 DRL-FS 在年化收益率、夏普比率及风险控制上均显著优于基准模型。多源金融舆情与多智能体框架有效提升了策略的收益能力与鲁棒性，模型在不同市场趋势和资产规模下均展现出良好的泛化能力。

中国知网 https://www.cnki.net

结　论

本研究聚焦于移动互联网时代金融舆情对股票市场的深刻影响以及传统投资组合理论难以适应动态市场环境的现实困境，通过融合金融舆情分析与深度多智能体强化学习技术，构建具备动态适应的智能投资组合决策框架，实现了对市场风险的精准把控与投资回报的有效提升。围绕金融舆情信号生成、多模态特征融合、多智能体协同决策及风险预算控制等核心环节展开深入研究。

本文主要创新成果和结论如下：

（1）构建了融合舆情信号与市场数据的多模态投资决策框架，提出基于决策树与模型检测的可信度验证机制及双重置信规则，实现了金融舆情的自动甄别与噪声过滤。采用 FinBERT 模型进行精确情感分析，结合大语言模型生成标签监督微调提升了分类准确性，并通过热度加权聚合形成综合舆情信号，为非结构化舆情数据的量化利用提供了方法支持。

（2）设计并实现融合金融舆情的深度多智能体强化学习投资组合模型，提出基于不同风险偏好的基智能体生成与集成策略。构建乐观、均衡与悲观三类基智能体并由差异化奖励函数引导，实现对不同市场态势的自适应响应。集成智能体通过权衡子智能体决策并做出独立判断，提升策略稳健性与收益表现，突破了单一智能体的局限性。

（3）引入多阈值方向性变化方法与遗传算法进行市场趋势预测，捕捉价格显著变动和识别趋势转折点，并作为辅助特征融入决策过程。方向性变化模块使模型在市场情绪反转前及时调整仓位，提升了收益能力并控制回撤风险。将基于风险预算的可微凸优化层嵌入深度网络，实现了端到端的风险约束调整，有效控制过度风险暴露。

（4）通过中美股市多周期数据实证验证了模型的有效性与鲁棒性。以沪深 300 与道琼斯指数成份股为标的，与八种基准模型对比分析表明，模型在年化收益率、夏普比率等指标上显著优于基准，且风险控制表现优异。同时资产数量扩展实验证实模型在不同规模下保持绩效优势，消融实验也验证了多源舆情融合与多智能体结构的有效性。

尽管本研究在金融舆情与历史行情融合和多智能体决策等方面取得了一定进展，但仍存在若干局限性，未来研究可从以下三个方向持续深化改进。一是进一步丰富异构数据源，将宏观政策文本、国际财经新闻等多源信息纳入融合框架以构建更全面的市场认知图谱。二是探索在线学习与增量更新机制，使模

中国知网　https://www.cnki.net

型能够实时吸收新进舆情数据并动态调整策略参数以缩短信息滞后时间。三是结合可解释人工智能技术，通过注意力机制可视化与策略归因分析等方法提升模型决策的透明度与可信度以满足金融监管要求。

中国知网 https://www.cnki.net

参考文献

[1] H. Markowitz. Portfolio selection[J]. The Journal of Finance, 1952, 7:77–91.

[2] Sharpe W F. A Simplified Model for Portfolio Analysis[J]. Management Science, 1963, 9(2): 277–293.

[3] Ross S A. The Arbitrage Theory of Capital Asset Pricing[J]. Journal of Economic Theory, 1976, 111(3): 341–360.

[4] Lai T Y. Portfolio Selection with Skewness: A Multiple Objective Approach[J]. Review of Quantitative Finance and Accounting, 1991, 1: 293–305.

[5] Rigamonti A, Lučivjanská K. Mean-semivariance Portfolio Optimization Using Minimum Average Partial[J]. Annals of Operations Research, 2024, 334(1): 185-203.

[6] Cheng G, Ahmadzade H, Farahikia M, et al. Uncertain Random Portfolio Optimization via Semi-variance[J]. International Journal of Machine Learning and Cybernetics, 2022, 13(9): 2533-2543.

[7] 刘勇军, 周敏娜, 张卫国. 考虑背景风险的均值-半方差投资组合优化模型[J]. 系统工程理论与实践, 2020, 40(09): 2282-2291.

[8] 张鹏, 崔淑琳, 李璟欣. 具有基数约束的多阶段均值-半方差可信性投资组合优化[J]. 运筹与管理, 2023, 32(12): 138-143.

[9] Cui S, Zhang P. Multi-period Mean–variance Portfolio Selection with Real Constraints Based on Machine Learning[J]. International Journal of Machine Learning and Cybernetics, 2024: 1-19.

[10] Mandal P K, Thakur M, Mittal G. Analysing Skewness of Credibilistic Coherent Trapezoidal Fuzzy Numbers: Implications for Portfolio Selection[J]. International Journal of Systems Science, 2024: 1-28.

[11] Federica Ricca, Andrea Scozzari, Portfolio Optimization through a Network Approach: Network Assortative Mixing and Portfolio Diversification[J]. European Journal of Operational Research, 2024, Volume 312, Issue 2: 716.

[12] 曾永泉, 张鹏. 具有熵约束的多阶段均值—半绝对偏差投资组合优化[J]. 中国管理科学, 2021, 29(09): 36-43.

[13] Atmaz A, Gulen H, Cassella S, et al. Contrarians, Extrapolators, and Stock Market Momentum and Reversal[J]. Management Science, 2024, 70(9): 5949.

中国知网 https://www.cnki.net

[14] 张鹏, 崔淑琳, 李璟欣. 一致性均值-CVaR 可信性投资组合优化[J]. 中国管理科学, 2023, 31(06): 111-121.
[15] Black F, Litterman R. Global Portfolio Optimization[J]. Financial Analysts Journal, 1992, 48(5): 28-43.
[16] Sahamkhadam M, Stephan A, Ostermark R. Copula-based Black-Litterman Portfolio Optimization[J]. European Journal of Operational Research, 2022, 297(3): 1055–1070.
[17] Korotkov V, Wu D. Benchmarking Project Portfolios Using Optimality Thresholds [J]. Omega, 2021, 99: 102166.
[18] 侯胜杰, 关忠诚, 董雪璠. 基于熵和 CVaR 的多目标投资组合模型及实证研究[J]. 系统科学与数学, 2021, 41(03): 640-652.
[19] 李鹤, 金秀, 侯羽婷. 基于投资者动态损失厌恶模糊多目标投资组合问题研究[J]. 运筹与管理, 2024, 33(07): 200-207.
[20] Díaz A, Esparcia C. Dynamic Optimal Portfolio Choice under Time-varying Risk Aversion [J]. International Economics, 2021, 166: 1-22.
[21] 周春阳, 吴冲锋. 引入方差/波动率资产的动态最优投资组合[J]. 管理科学学报, 2023, 26(01): 105-115.
[22] Zhang C, Gong X, Zhang J, et al. Dynamic Portfolio Allocation for Financial Markets: A Perspective of Competitive-cum-compensatory Strategy[J]. Journal of International Financial Markets, Institutions and Money, 2023, 84: 101737.
[23] 周晓光, 何欣, 王晓岭. 基于犹豫模糊语言环境的投资组合优化研究[J].运筹与管理, 2022, 31(12): 136-142.
[24] Lo A W, MacKinlay A C. Stock Market Prices Do not Follow Random Walks: Evidence from a Simple Specification Test[J]. The Review of Financial Studies, 1988, 1(1): 41-66.
[25] Fama E F. The Behavior of Stock-market Prices[J]. The Journal of Business, 1965, 38(1): 34-105.
[26] Abdullah M, Sulong Z, Chowdhury M A F. Explainable Deep Learning Model for Stock Price Forecasting Using Textual Analysis[J]. Expert Systems with Applications, 2024, 249: 123740.
[27] Goodell J W, Kumar S, Rao P, et al. Emotions and Stock Market Anomalies: A Systematic Review[J]. Journal of Behavioral and Experimental Finance, 2023, 37: 100722.

中国知网 https://www.cnki.net

[28] Huynh N, De Mello L, Li K. Evolution of Investor Sentiment: A Systematic Literature Review and Bibliometric Analysis[J]. International Review of Economics & Finance, 2025: 104115.
[29] 李晓, 刘以琏. 投资者关注度分配与股价同步性: 来自中国市场的经验证据[J]. 系统工程理论与实践, 2024, 44(12): 3862-3876.
[30] 李伯华, 赵宝福, 贾凯威, 等. 谁主“沉浮”?——基于投资者理性变动对股市波动的影响分析[J]. 运筹与管理, 2023, 32(09): 193-199.
[31] Tetlock P C. Giving Content to Investor Sentiment: The Role of Media in the Stock Market[J]. The Journal of finance, 2007, 62(3): 1139-1168.
[32] Fang J , Gozgor G , Lau C , et al. The Impact of Baidu Index Sentiment on the Volatility of China's Stock Markets[J]. Finance Research Letters, 2020, 32.
[33] 游家兴, 吴静. 沉默的螺旋: 媒体情绪与资产误定价[J]. 经济研究, 2012, 47(7): 141–152.
[34] 陈镇喜, 李京翰, 张维. 股价同步性——信息与噪声的统一框架[J]. 中国管理科学, 2026, 34(01): 41-59.
[35] 李少育, 朱春辉, 宁凯旋, 等. 投资者文本情绪、文本异质信念与市场崩盘风险[J]. 管理科学, 2023, 36(04): 147-163.
[36] Cookson J A, Fox C, Gil-Bazo J, et al. Social Media as a Bank Run Catalyst[J]. Journal of Financial Economics, 2026, 176: 104218.
[37] 姚尧之, 王坚强, 刘志峰. 混频投资者情绪与股票价格行为[J]. 管理科学学报, 2018, 21(2): 104–113.
[38] 张宗新, 吴钊颖. 媒体情绪传染与分析师乐观偏差——基于机器学习文本分析方法的经验证据[J]. 管理世界, 2021, 37(01): 170-185.
[39] Lee S I, Yoo S J. Multimodal Deep Learning for Finance: Integrating and Forecasting International Stock Markets[J]. The Journal of Supercomputing, 2020, 76: 8294-8312.
[40] Li Q, Tan J, Wang J, et al. A Multimodal Event-driven LSTM Model for Stock Prediction Using Online News[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 33(10): 3323-3337.
[41] Sawhney R, Mathur P, Mangal A, et al. Multimodal Multi-task Financial Risk Forecasting[C]//Proceedings of the 28th ACM International Conference on Multimedia. 2020: 456-465.
[42] Xing F. Designing Heterogeneous LLM Agents for Financial Sentiment

中国知网 https://www.cnki.net

Analysis[J]. ACM Transactions on Management Information Systems, 2025, 16(1): 1-24.

[43] Koyano S, Ikeda K. Online Portfolio Selection Based on the Posts of Winners and Losers in Stock Microblogs[C]//2017 IEEE Symposium Series on Computational Intelligence (SSCI). IEEE, 2017: 1-4.

[44] Cambria E, Li Y, Xing F Z, et al. SenticNet 6: Ensemble Application of Symbolic and Subsymbolic AI for Sentiment Analysis[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. 2020: 105-114.

[45] 唐国豪, 姜富伟, 张定胜. 金融市场文本情绪研究进展[J]. 经济学动态, 2016, 11: 137-147.

[46] 沈艳, 陈赟, 黄卓. 文本大数据分析在经济学和金融学中的应用：一个文献综述[J]. 经济学(季刊), 2019, 18(4): 1153-1186.

[47] Henry E. Are Investors Influenced by How Earnings Press Releases are Written[J]. The Journal of Business Communication, 2008, 45(4): 363-407.

[48] Loughran T, McDonald B. When is a Liability not a Liability? Textual Analysis, Dictionaries, and 10-Ks[J]. The Journal of Finance, 2011, 66(1): 35-65.

[49] 姜富伟, 孟令超, 唐国豪. 媒体文本情绪与股票回报预测[J]. 经济学(季刊), 2021, 21(04): 1323-1344.

[50] 姚加权, 冯绪, 王赞钧, 等. 语调、情绪及市场影响:基于金融情绪词典[J]. 管理科学学报, 2021, 24(05): 26-46.

[51] 范小云, 王业东, 王道平, 等. 不同来源金融文本信息含量的异质性分析——基于混合式文本情绪测度方法[J]. 管理世界, 2022, 38(10): 78-101.

[52] Santi C. Investor Climate Sentiment and Financial Markets[J]. International Review of Financial Analysis, 2023, 86: 102490.

[53] Audrino F, Sigrist F, Ballinari D. The Impact of Sentiment and Attention Measures on Stock Market Volatility[J]. International Journal of Forecasting, 2020, 36(2): 334-357.

[54] 张宗新, 吴钊颖. 媒体情绪传染与分析师乐观偏差——基于机器学习文本分析方法的经验证据[J]. 管理世界, 2021, 37(01): 170-185+11+20-22.

[55] 钱宇, 李子饶, 李强, 等. 在线社区支持倾向对股市收益和波动的影响[J]. 管理科学学报, 2020, 23(02): 141-155.

[56] 王颖洁, 朱久祺, 汪祖民, 等. 自然语言处理在文本情感分析领域应用综述

中国知网 https://www.cnki.net

[J]. 计算机应用, 2022, 42(4): 1011–1020.
[57] 汪寿阳, 李明琛, 杨昆, 等. ChatGPT+金融: 八个值得关注的研究方向与问题[J]. 管理评论, 2023, 35(4): 3–11.
[58] Huang A H, Wang H, Yang Y. FinBERT：A Large Language Model for Extracting Information from Financial Text[J]. Contemporary Accounting Research, 2023, 40: 806-841.
[59] Shi Y, An Y, Zhu X, Jiang F. Better to Hear All Parties：Understanding the Impact of Homophily in Online Financial Discussion[J]. Electronic Commerce Research and Applications, 2022, 54: 1-18.
[60] SHARMA M， SHEKHAWAT H S. Portfolio Optimization and Return Prediction by Integrating Modified Deep Belief Network and Recurrent Neural Network[J]. Knowledge-Based Systems, 2022, 250: 109024.
[61] LIN Y-F，HUANG T-M，CHUNG W-H，et al. Forecasting Fluctuations in the Financial Index Using a Recurrent Neural Network Based on Price Features[J]. IEEE Transactions on Emerging Topics in Computational Intelligence, 2020, 5（5）: 780-791.
[62] Fischer T, Krauss C. Deep Learning with Long Short-term Memory Networks for Financial Market Predictions[J]. European Journal of Operational Research, 2018, 270: 654-669.
[63] 张鹏, 党世力, 黄梅雨, 等.基于机器学习预测股票收益率的两步骤 M-SV 投资组合优化[J]. 中国管理科学, 2023, 31(12): 96-106.
[64] 刘伟龙, 张永, 杨兴雨. 基于 LSTM 预测信息的在线融资融券组合交易策略[J]. 系统工程理论与实践, 2024, 44(08): 2493-2511.
[65] 黄羿, 祝炜, 朱书尚, 等. 结合“向后看”和“向前看”信息的投资组合优化[J]. 系统工程理论与实践, 2021, 41(04): 861-881.
[66] 宋正阳, 周忠宝, 余乐安, 等. 基于混合集成预测算法和 Black-Litterman 模型的投资组合优化策略研究[J/OL]. 中国管理科学: 1-12[2026-03-10]. https://doi.org/10.16381/j.cnki.issn1003-207x.2023.1895.
[67] Wang R, Wei H, An B, et al. Commission Fee is not Enough: A Hierarchical Reinforced Framework for Portfolio Management[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2021, 35(1): 626-633.
[68] Jang J, Seong N Y. Deep Reinforcement Learning for Stock Portfolio Optimization by Connecting with Modern Portfolio Theory[J]. Expert Systems

中国知网 https://www.cnki.net

with Applications, 2023, 218: 119556.

[69] Wang F, Li S, Niu S, et al. A Survey on Recent Advances in Reinforcement Learning for Intelligent Investment Decision-making Optimization[J]. Expert Systems with Applications, 2025, 282: 127540.

[70] 胡文伟, 胡建强, 李湛, 等. 基于强化学习算法的自适应配对交易模型[J]. 管理科学, 2017, 30(02): 148-160.

[71] Deng Y, Bao F, Kong Y, et al. Deep Direct Reinforcement Learning for Financial Signal Representation and Trading[J]. IEEE Transactions on Neural Networks and Learning Systems, 2016, 28(3): 653-664.

[72] Zou J, Lou J, Wang B, et al. A Novel Deep Reinforcement Learning Based Automated Stock Trading System Using Cascaded LSTM Networks[J]. Expert Systems with Applications, 2024, 242: 122801.

[73] BETANCOURT C，CHEN W-H. Deep Reinforcement Learning for Portfolio Management of Markets with a Dynamic Number of Assets[J]. Expert Systems with Applications, 2021, 164: 114002.

[74] Carta S, Corriga A, Ferreira A, et al. A Multi-layer and Multi-ensemble Stock Trader Using Deep Learning and Deep Reinforcement Learning[J]. Applied Intelligence, 2021, 51(2): 889-905.

[75] 许杰, 祝玉坤, 邢春晓. 基于深度强化学习的金融交易算法研究[J]. 计算机工程与应用, 2022, 58(07): 276-285.

[76] 卜湛, 张善凡, 李雪延, 等. 基于深度强化学习的自适应股指预测研究[J]. 管理科学学报, 2023, 26(04): 148-174.

[77] 齐岳, 黄硕华. 基于深度强化学习 DDPG 算法的投资组合管理[J]. 计算机与现代化, 2018 (05): 93.

[78] Conegundes L, Pereira A C M. Beating the Stock Market with a Deep Reinforcement Learning Day Trading System[C]. 2020 International Joint Conference on Neural Networks (IJCNN). IEEE, 2020: 1-8.

[79] Wang M, Ku H. Risk-sensitive Policies for Portfolio Management[J]. Expert Systems with Applications, 2022, 198: 116807.

[80] Wu J M T, Lin S H, Syu J H, et al. Embedded Draw-down Constraint Reward Function for Deep Reinforcement Learning[J]. Applied Soft Computing, 2022, 125: 1091.

[81] Zhang K, Yang Z, Başar T. Multi-agent Reinforcement Learning: A Selective

中国知网 https://www.cnki.net

Overview of Theories and Algorithms[J]. Handbook of Reinforcement Learning and Control, 2021: 321-384.

[82] Ma C, Zhang J, Li Z, et al. Multi-agent Deep Reinforcement Learning Algorithm with Trend Consistency Regularization for Portfolio Management[J]. Neural Computing and Applications, 2023, 35(9): 6589-6601.

[83] Lee J, Kim R, Yi S W, et al. MAPS: Multi-agent Reinforcement Learning-based Portfolio Management System[J]. Applied Soft Computing, 2023, 116: 981.

[84] LIN Y-C，CHEN C-T，SANG C-Y，et al. Multi-agent Based Deep Reinforcement Learning for Risk-shifting Portfolio Management[J]. Applied Soft Computing, 2022, 123(C): 108894.

[85] Yang H, Liu X Y, Zhong S, et al. Deep Reinforcement Learning for Automated Stock Trading: An Ensemble Strategy[C]//Proceedings of the First ACM International Conference on AI in Finance. 2020: 1-8.

[86] Gupta R, Nel J, Pierdzioch C. Investor Confidence and Forecastability of US Stock Market Realized Volatility: Evidence from Machine Learning[J]. Journal of Behavioral Finance, 2023, 24(1): 111-122.

[87] Lee C M C, Shleifer A, Thaler R H. Investor Sentiment and the Closed-end Fund Puzzle[J]. The Journal of Finance, 2015, 46(1): 75-109.

[88] Gong X, Zhang W, Wang J, et al. Investor Sentiment and Stock Volatility: New Evidence[J]. International Review of Financial Analysis, 2022, 80: 102028.

[89] 奚玉芹, 韩立岩, 张晓晖, 等. 乐观与悲观：投资者情绪的跨市传染[J]. 管理科学, 2024, 37(06): 147-159.

[90] Gao Y, Zhao C, Sun B, et al. Effects of Investor Sentiment on Stock Volatility: New Evidences from Multi-source Data in China's Green Stock Markets[J]. Financial Innovation, 2022, 8(1): 77.

[91] Gaies B, Nakhli M S, Ayadi R, et al. Exploring the Causal Links between Investor Sentiment and Financial Instability: A Dynamic Macro-financial Analysis[J]. Journal of Economic Behavior & Organization, 2022, 204: 290-303.

[92] Perri F, Quadrini V. International Recessions[J]. American Economic Review, 2018, 108: 935-984.

[93] 冯缨, 唐慧, 孙晓阳. 基于 DEMATEL 的企业社交媒体信息效用的关键影响因素研究[J]. 情报理论与实践, 2022, 45(04): 137-145+153.

中国知网 https://www.cnki.net

[94] Ashtiani M N, Raahemi B. News-based Intelligent Prediction of Financial Markets Using Text Mining and Machine Learning: A Systematic Literature Review[J]. Expert Systems with Applications, 2023, 217: 119509.

中国知网 https://www.cnki.net