分类号_____ 学号 M202374767

学校代码 10487 密级_____

华中科技大学

硕士学位论文

（学术型□ 专业型☑）

基于 LSTM-Informer 模型的行业轮动策略

学位申请人：张敬雷

学 科 专 业：金融

指 导 教 师：欧阳红兵 教授

答 辩 日 期：2025 年 4 月 25 日

中国知网 https://www.cnki.net

A Dissertation Submitted in Partial Fulfillment of the Requirements for the Degree of Master of Finance

Industry Rotation Strategy Based On LSTM-Informer Model

Candidate : ZHANG JingLei
Major : Finance
Supervisor : Prof. OUYANG HongBing

Huazhong University of Science and Technology
Wuhan 430074, P. R. China
April, 2025

中国知网 https://www.cnki.net

摘 要

行业轮动策略是一种择时类量化交易策略，其理论基础在于不同行业的相关资产在经济周期、政策导向及市场环境变化下表现具有明显差异。通过对不同行业资产配置的动态调整，投资者可以在不同行业间进行轮动交易，获取超额收益。然而，传统行业轮动策略主要依赖历史数据进行交易信号判断，例如行业资产的选择通常基于经济周期或历史动量，难以有效捕捉市场行情趋势变化，导致在市场环境发生突变时响应滞后，而缺乏对未来市场走势的深度预测能力，限制了交易策略的适应性与稳定性。

为解决上述问题，提升行业轮动策略的综合效果，本文提出基于 LSTM-Informer 深度学习模型的行业轮动策略，利用深度学习方法提升行业趋势判断的准确性，进而提升行业轮动策略的适应性与稳定性。具体而言，首先基于长短时记忆神经网络（Long Short-Term Memory, LSTM）模型与 Informer 模型构建组合模型对申万一级行业指数收盘价进行时间序列预测，以获取未来市场走势的趋势信号。LSTM 模型擅长处理长序列依赖问题，Informer 模型在捕捉全局依赖关系与提高计算效率方面具有优势，二者结合可充分挖掘金融时间序列中的潜在模式。其次，基于预测的行业指数收盘价计算未来区间收益率，并根据收益率排序选择强势行业进行轮动交易，以优化资产配置。由于行业指数不能直接交易，本文筛选与行业指数高度相关的交易型开放式指数基金（Exchange Traded Fund，ETF）作为交易标的，在确定强势行业后，轮动交易与行业指数最为相关的行业 ETF，使策略更具实用性。预测结果表明，LSTM-Informer 模型在不同预测步长下均优于传统机器学习方法以及单一深度学习模型。基于模型结果构建的行业轮动策略回测分析显示，基于该模型构建的行业轮动策略在 1 日、2 日持有期内表现最佳，并在所有持有期均显著优于基准指数，也优于基于对比模型构建的行业轮动策略，验证了其有效性。研究结果表明，结合深度学习的行业轮动策略能够提升趋势判断能力，提高投资收益，并为量化交易提供新的方法论支持。

关键词：LSTM；Informer；金融时间序列分析；量化交易；行业轮动

中国知网 https://www.cnki.net

Abstract

The sector rotation strategy is a timing-based quantitative trading approach grounded in the varying performance of assets across different industries depending on economic cycles, policy changes, and market conditions. By dynamically reallocating assets among these sectors, investors can achieve excess returns. Traditional sector rotation strategies rely heavily on historical data for trading signals, often based on economic cycles or past momentum, which can lead to delayed responses during sudden market shifts and limits their adaptability.

To enhance the effectiveness of these strategies, this thesis proposes a sector rotation strategy using the LSTM-Informer deep learning model. This model improves trend prediction accuracy, thereby increasing strategy adaptability and stability. Specifically, it combines LSTM(Long Short-Term Memory) and Informer model for time series forecasting of the Shenwan first-level industry indices. LSTM handles long sequences effectively, while Informer excels at capturing long-term dependencies and improving computational efficiency. Future returns are calculated based on predicted closing prices, and strong industries are selected for rotation based on sorted returns. Since the Shenwan indices cannot be directly traded, highly correlated ETF(Exchange Traded Fund) are chosen as trading targets. The LSTM-Informer model consistently outperforms traditional machine learning methods and single deep learning models. Backtesting results show that the proposed strategy performs best over 1-day and 2-day holding periods, significantly surpassing benchmark indices and other comparison strategies, confirming its effectiveness. Overall, integrating deep learning enhances trend assessment, improves investment returns, and provides new methodological support for quantitative trading.

Key words: LSTM, Informer,Financial Time Series Analysis,Quantitative Trading, Sector Rotation

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 研究背景与意义.....1
1.2 文献综述.....3
1.3 存在问题.....7
1.4 研究思路与框架.....8
1.5 主要的创新点.....10
2 研究理论与技术基础.....11
2.1 行业轮动策略理论.....11
2.2 量化交易相关理论.....14
2.3 深度学习模型相关理论.....15
3 基于 LSTM-Informer 模型的价格预测分析.....24
3.1 数据收集与预处理.....24
3.2 基于 LSTM- Informer 模型的价格预测.....30
3.3 稳健性分析.....37
4 基于 LSTM-Informer 模型的行业轮动策略构建.....44
4.1 行业轮动现象的存在性检验.....44
4.2 量化策略的构建与回测.....48
4.3 行业轮动策略的稳健性分析.....55
5 结论与展望.....66
5.1 研究结论.....66
5.2 研究不足与展望.....68
参考文献.....69

中国知网　https://www.cnki.net

1 绪论

1.1 研究背景与意义

1.1.1 研究背景

中国资本市场经过三十余年的发展，已逐步形成多层次、广覆盖的市场体系，包括主板、科创板、创业板、北交所及新三板等市场结构，并涵盖股票、债券、基金、衍生品等多种金融资产。在投资者结构方面，我国资本市场投资者主要由机构投资者与个人投资者构成，其中个人投资者占比较高，但个人投资者信息获取与分析能力的不足导致中小投资者在面对海量市场数据时难以精准判断，容易受短期市场情绪影响，追涨杀跌现象较为普遍，导致遭受损失。因此，如何运用例如量化交易等科学方法提高投资决策质量，降低投资风险，成为当前亟须解决的问题。

量化交易策略是一种利用数学、统计和计算机算法来分析市场数据并进行自动化交易的投资方法。相比于传统的主观交易，量化交易依赖数据驱动的决策，以减少人为情绪影响，提高交易效率和执行精准度。量化交易策略可以分为择时策略、套利策略、选股策略等。行业轮动策略本质上属于择时策略，通过分析不同行业在经济周期或市场环境中的表现，动态调整投资组合，以在不同阶段获取超额收益，其核心思想是利用中国资本市场中出现的行业轮动现象构建交易策略。行业轮动现象是指不同行业在不同经济周期或市场环境下呈现出相对强势或弱势的交替，这一现象在宏观经济周期、流动性环境、政策导向以及投资者情绪等多重因素的驱动下呈现规律性。针对行业轮动现象的理论解释主要包括美林时钟理论、行业生命周期理论、行为金融理论等。针对行业轮动现象构建的策略方法包括基于经济周期的行业轮动策略、基于历史动量的行业轮动策略、基于未来趋势的行业轮动策略等，这些行业轮动策略的交易信号与轮动周期都有所不同，但都在不同条件下动态调整持仓资产，以获取超额收益，目前已广泛应用于证券投资领域。但行业轮动策略在实际应用中也面临诸多挑战：首先，利用经济周期判断轮动信号过程中，由于经济周期划分较为主观，且投资者对经济周期的判断较不敏感，导致错判误判情况增多，

中国知网 https://www.cnki.net

在周期转换过程中无法及时调整，造成损失；其次，在利用历史数据构建轮动策略时，无法对未来可能发生的趋势变化形成认识，导致交易决策出现滞后问题，产生风险；最后，虽然基于未来趋势预测的行业轮动策略对以上两种缺点进行克服，但金融市场的多样性、非线性和噪声数据给资产价格的预测中的应用带来了诸多挑战，诸如过拟合、预测精度等问题依然需要解决，这导致投资决策的有效性受模型精度的影响较大。

以神经网络模型与 Transformer 类模型为代表的深度学习模型已广泛运用于多个领域，而金融领域数据具有多维度与复杂性的特点，适合引入深度学习模型提升处理效果，因此基于深度学习模型构建行业轮动策略具备可行性。本文探索基于 LSTM-Informer 模型的行业轮动策略，通过发挥深度学习模型在金融数据处理分析的优势，提升对不同行业未来趋势判断的准确性，进而提升提高行业轮动策略的交易即时性和市场适应性，克服传统投资方法中的局限性，为投资者提供更科学的投资策略以及更稳定的投资回报。

1.1.2 研究意义

从理论意义上看，深度学习模型已广泛应用于各种领域的研究，当前将深度学习模型引入金融研究与量化投资领域也较为普遍，行业轮动策略作为一种典型的择时量化交易策略，与深度学习模型相结合的研究较少，以往基于经济周期与历史数据的行业轮动策略往往因市场的变化导致时效性不足。本文引入 LSTM-Informer 深度学习模型构建行业轮动策略，利用深度学习模型对行业未来趋势作出判断，再根据结果做出行业轮动交易决策。基于 LSTM-Informer 模型的行业轮动策略具有更高的准确性和实时性，通过对日数据的跟踪，LSTM-Informer 模型能够更快速地识别和预测行业的轮动趋势，进而提高交易频率，使得行业轮动策略变得更加即时有效。因此，将前沿的深度学习模型引入到行业轮动策略构建问题当中，并进行模型的适用性改进具有重要意义，也为中国量化交易策略的开发提供新的研究视角。

从实践意义来看，行业轮动策略的有效性往往受到投资者情绪波动及羊群效应的影响，导致投资决策偏离理性。本文提出的基于 LSTM-Informer 模型的行业轮动策略，旨在解决传统投资决策中主观性强、非理性因素影响显著的问题，以提升行

中国知网 https://www.cnki.net

业选择的科学性与有效性。通过 LSTM 模型对行业表现的动态预测，并结合 Informer 模型的高效时序特征提取能力，本文构建了一个数据驱动的行业轮动策略框架。相较于传统方法，该策略能够更准确地捕捉行业间的轮动规律，提供系统化的交易信号，提高投资决策的前瞻性与稳定性，从而减少主观判断对投资决策带来的风险。本策略不仅提供了一种可行的行业轮动交易决策方法，也为投资者构建了一个可以获取超额收益的交易策略，助力构建更加稳健和高效的资本市场投资体系。

1.2 文献综述

1.2.1 行业轮动相关研究

（1）行业轮动现象理论研究

国内外都有针对行业轮动的具体原因进行理论研究。从国内来看，何诚颖（2001）发现，中国股市存在一种显著的板块轮涨现象，在某一时期内，“板块事件”会引起相关联的股票齐涨齐跌，这一事件可能与行业，地域等内在特质相关。引起板块轮动现象的具体原因是中国股市投资者的行为特征。陈梦根和曹凤岐（2005）通过对沪市行业分类股价指数进行分析指出，不同行业板块之间股价存在着明显的联动特征，不同行业板块股价波动的市场性显著强于其独立性。造成这种行业股价联动的原因是中国市场效率问题以及投资者的盲目性。刘博和皮天雷（2007）认为，由于投资者普遍具有“补涨”概念，认为没有发生上涨的应该上涨，没有发生下跌的应该下跌，这就造成了行业股票齐涨齐跌的现象。金秀等（2020）研究显示市场状态影响安全投资转移，安全投资在高波动状态下转移强度更高；安全投资转移导致资金在行业间流动，引起行业轮动效应和风险溢出。

从国外来看，关于测量行业内证券收益率协变性的实证研究始于 King（1966），研究发现行业内特有的相关性解释了行业内企业间价格变动 10%至 15%。Livingston（1977）发现，行业内企业相关性为 0.1178，大约 20%的行业的行业内企业相关性超过 0.30。De Bondt & Thaler（1985）的研究表明投资者对过去表现不佳的股票的反应存在延迟，而投资者在表现较好的股票上反应过度，导致其价格高于其基本面价值。这些研究表明，行业内企业存在相关性，不同行业间存在差异性，行业内特定

中国知网 https://www.cnki.net

因素会对股票价格产生显著影响。Sorensen & Burke（1986）通过在多种情况下的研究，发现市场情况会很大程度上影响行业轮动的效果，例如重大熊市和市场恐慌情绪等。Yang & Shi（2023）研究结合了因子模型与基本面指标的双重视角对各行业的收益表现进行了实证分析，证明了动量效应与短期反转在推动行业轮动中的重要作用。

（2）行业轮动策略应用研究

行业轮动策略通过在不同投资品种强势时间错位的情况下，对行业品种进行切换，以达到投资收益最大化的目的。其本质是利用不同行业在不同经济周期和市场环境下的表现差异，灵活调整投资组合中的行业比例。在实际操作中需要投资者把握市场变化的节奏和热点轮动，根据行业间的相对表现差异进行轮动配置，力求抓住表现较好的行业、剔除表现不佳的行业。国外研究者在轮动的识别中运用了动量策略的思想，它基于股票或其他金融资产过去的表现来预测其未来的表现。这种策略的核心思想是，资产的价格趋势，无论是上升还是下降，都倾向于持续一段时间。因此，投资者可以通过识别并投资于近期表现良好的资产，或者卖空近期表现不佳的资产，来尝试获得超额回报（Jegadeesh & Titman, 1993）。行业动量效应作为一种投资策略，其核心逻辑在于通过买入前期表现优异的行业组合并卖出表现较差的行业组合来获取超额收益。实证研究表明，即便在控制了公司规模、账面市值比、个股动量效应、横截面收益离散度以及市场微观结构等影响因素后，仍然非常有利可图（Fama & French, 1993）。Moskowitz & Grinblatt（1999）发现，行业动量投资策略控制多个变量之后，也显示出很高的盈利能力，要优于普通的动量策略。Gayed（2014）利用动量策略的思想，通过使用基于跨市场分析和动量原则的贝塔轮换策略，可以在许多市场周期中持续超越静态的买入并持有策略。背后的原理是公用事业板块的信号能力是一个随时间持续存在的市场异常现象。与其他板块相比，公用事业板块的经济敏感性较低，且更依赖于资本成本。因此，其相对价格波动可能对宏观经济因素产生广泛影响。然而，与有效市场假说相反，领先滞后动态所蕴含的关于近期未来的信息可能不会立即被广泛市场平均指数完全定价。作者通过交易相关ETF来实现策略。

中国知网 https://www.cnki.net

但是这种基于动量或惯性的行业轮动策略可能并不适用于中国市场，因为动量在中国市场表现不明显。王永宏和赵学军（2001）对1993年以前在深沪两市上市的所有股票进行了研究，实证结果表明，深沪股票市场存在显著的收益反转现象，而收益动量现象则未能得到明显证实。这就说明，需要根据中国市场的实际情况设计行业轮动交易策略。基于惯性和动量的行业轮动本质上基于历史数据的轮动，往往在实际中缺乏时效性，对于出现的风险不能及时的识别。部分研究者也考虑利用各种模型对行业未来走势进行预测判断，通过预测结果进行行业轮动。郑力等（2024）了一个基于分解、重构与集成框架的股指收益率复合预测模型，并根据预测结果构建行业轮动策略。Karatas & Hirsa（2021）利用机器学习与深度学习技术本文构建了两阶段的方法预测各行业的ETF价格，并根据其预测收益率计算的行业排序构建行业轮动策略。本文考虑利用深度学习预测数据，基于未来趋势进行判断以提高交易策略的实用性。本文通过申万一级行业指数对各行业进行研究，通过对行业指数收盘价的预测判断，利用预测结果计算各申万一级行业指数在一定时期内的收益率，根据收益率的大小排序得到不同行业未来发展趋势，判断申万一级行业在未来一段时间内的强势情况，轮动交易表现较好的行业的相关资产。

1.2.2 深度学习相关应用研究

（1）神经网络模型相关研究

最早将神经网络应用于股票价格预测的研究可以追溯到 White（1988）。在该研究中，股票数据被用作特征来建模收益率。然而，在模型训练过程中出现了梯度爆炸的问题，导致未能获得全局最优解，进而影响了实证结果的表现。Ticknor（2013）采用贝叶斯正则化技术对神经网络算法进行优化，从而显著提升了对收盘价预测的准确性。Soutner & Müller（2014）研究表明，具有“记忆”能力的长短期记忆神经网络在解决长期依赖问题方面表现优越，并且在翻译等时序任务中得到广泛应用。Hu et al.（2018）等通过改进的神经网络模型来预测标普 500 指数的涨跌情况，并且开创性考虑了网络舆论与股市的关系，使模型的预测精度有了显著提高。Zhu et al.（2023）将具有注意力机制的长段记忆神经网络模型与各种模型组件集成在一个非线性连接中，发现神经网络模型的高度非线性泛化特性具有效预测股票价格的能力。

中国知网 https://www.cnki.net

国内学者也对神经网络模型进行深入研究。黄卿和谢合亮（2018）利用高频 IF 期货数据，结合 BP 神经网络、XGBoost 及 SVM 等算法进行预测研究，证实 XGBoost 在时间序列数据预测上更优。欧阳红兵等（2020）将小波降噪后的道琼斯工业指数收盘价输入 LSTM 深度学习模型，发现 LSTM 深度学习模型的点预测能力、短期动态预测能力、长期动态预测能力相较于 KNN，SVM 以及 Garch 模型效果更好。

（2）Transformer 类模型相关研究

Transformer 模型凭借其卓越的结构设计，已在自然语言处理、语音识别以及计算机视觉等多个研究方向中展现出广泛的应用价值。其核心自注意力机制，具备捕捉时间序列中复杂动态关系与深层依赖特征的能力，尤其在建模长距离依赖信息方面表现突出。在处理时间序列预测任务时，围绕 Transformer 注意力机制的相关研究逐渐深入，为理解序列内部潜在规律和提升预测精度提供了新的技术路径。国外的有关研究中，针对长时间序列预测问题，研究者们提出了一系列基于 Transformer 的改进模型，以优化计算效率并提升预测精度。Zhou et al.（2021）构建了 Informer 模型，该模型通过引入稀疏注意力机制（ProbSparse Self-attention）有效降低了计算过程中的空间复杂度，同时提升了对长序列数据的建模能力。Wu et al.（2021）设计了 Autoformer 模型，该模型结合了自回归机制与时间序列分解方法，能够更精准地提取长期趋势信息，并在长时间序列预测任务中展现出良好的性能。Zhou et al.（2022）提出了 FEDformer，即频率增强 Transformer 模型。该模型在 Transformer 架构中融合了傅立叶变换及季节与趋势分解技术，以增强对时间序列数据的频率特征捕捉能力，从而提升预测精度并进一步降低计算资源的占用。国内学者也将 Transformer 类模型引入多个领域的研究中，李新等（2024）利用改进 Transformer 模型进行景区短时客流预测研究，在提升景区管理效率和支持决策制定等方面具有重要意义。深度学习模型还可以进行组合，将两个或者多个模型融合，充分发挥各模型的优势。陈东洋和毛力（2024）利用增量学习和持续注意力机制构建改进 Transformer 模型，并利用模型捕捉股票时间序列的趋势和波动。

当前也有学者将 Transformer 类模型与其他模型进行组合，以提升模型效果。Riaz et al.（2024）建立 LSTM-Transformer 结合的混合模型，用于细粒度建议挖掘

中国知网 https://www.cnki.net

（fine-grained suggestion mining）。Cao et al.（2024）利用 Transformer 模型与神经网络模型结合，实现对复杂工程系统的高效、准确、实时预测，并通过在线学习与知识蒸馏，进一步提升模型的可适应性和计算效率。组合模型既能学习序列信息，又能建模全局依赖关系，在跨领域任务中表现突出。

（3）深度学习模型金融领域应用研究

通过计算机技术，机器学习和深度学习方法也被应用到金融研究与量化策略之中，为投资者带来更有效的因子，有助于构建更稳定的策略模型。机器学习与深度学习不仅有助于交易，更有助于金融与经济的学术研究。苏治等（2017）指出，深度学习优化技术在金融领域的预测与分析方法上带来了显著改进，促使实证研究的范式从线性模型向非线性模型转变，并从关注参数的显著性转向关注模型结构及其动态特征。黄乃静和于明哲（2018）对机器学习在经济学研究中的影响进行了系统的综述，重点分析了在大数据背景下机器学习如何促进经济数据多样性的丰富，指出机器学习技术与经济学研究的融合将改变传统经济学的研究方式。李斌等（2019）提出，机器学习和深度学习技术可以自动地寻找数据中的复杂结构和模式来辅助预测，适合用来分析异象因子与超额收益之间关系。研究利用多种机器模型在中国市场进行实证研究并筛选出了 16 个重要的因子。马甜等（2022）创造性地利用生成式对抗网络模型（Generative Adversarial Network，GAN）应用于我国股票市场预测与交易，获得了良好效果。重要性分析显示，前十大特征的贡献大约占所有 148 个因子的 40%。

1.3 存在问题

在针对行业轮动的有关研究中，国内外相关学者都对行业轮动现象产生机理做出阐述，并构建行业轮动策略获取超额收益。但国内有关研究显示，国内市场环境与国外有所差别，我国的行业轮动产生机理与策略构建应符合中国资本市场特点。除此之外，当前研究中构建的行业轮动策略大多基于历史数据，对未来趋势判断能力不足，在市场行情发生转换时无法及时调整策略规避风险。

中国知网 https://www.cnki.net

在深度学习模型的有关研究中，国内外学者不断构建先进深度学习模型，同时也将深度学习模型引入多个领域的研究应用。深度学习模型在金融领域的研究也处于高速发展之中，如量化交易策略构建与投资决策分析等。但当前研究中，将深度学习模型引入行业轮动的研究较少，将 LSTM 模型与 Transformer 类模型组合应用于金融研究领域也较少。本文基于 LSTM-Informer 深度学习模型构建行业轮动策略，扩展深度学习在金融领域的应用边界，同时也更加深入探究行业轮动的原理，以构建更为有效获取超额收益的行业轮动策略。

1.4 研究思路与框架

本文的组织结构图如图 1-1 所示。

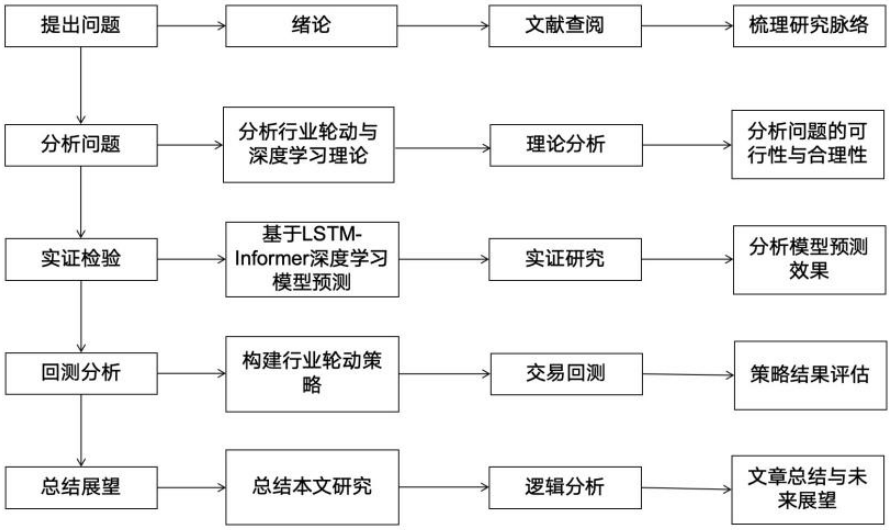


图 1-1　组织结构图

本文在开篇介绍了选题的背景和意义，接着对国内外相关研究领域的文献进行了梳理，并对研究的进展进行了综述。在对已有的文献大量阅读的基础上，对深度学习时间序列预测相关理论和行业轮动的构建进行了阐述。本文综合多方面因素考虑后，确定以申万一级行业指数为切入点，通过对申万一级行业指数收益率的预测，以识别行业轮动，利用指数收益率构建轮动策略。首先在收集数据后，对数据进行清洗，随后进行小波降噪、归一化处理；然后利用 LSTM-Informer 模型对申万一级行业指数进行预测，之后利用预测结果计算收益率，并根据收益率预测结果的大小

中国知网 https://www.cnki.net

排序识别行业轮动；最后通过 Spearman 相关和 Pearson 相关确定与申万一级行业指数最为相关的 ETF 作为策略的交易对象，进行回测并分析结果，具体研究框架如下，共六个章节：

第一章是引言部分。本章对本文的研究背景和意义进行了介绍，梳理了国内外深度学习、量化交易策略的相关文献，同时对行业轮动相关的文献也进行了整理，最后进行综述。

第二章是理论技术部分。本章首先对行业轮动策略相关研究进行了梳理，然后对深度学习模型进行整理，首先介绍了量化投资与行业轮动相关理论，之后对 LSTM 模型与 Informer 的模型理论分别进行了整理分析，对 LSTM-Informer 模型构建原理与方法进行阐述。

第三章是基于 LSTM-Informer 模型的行业轮动策略的提出与数据处理。本章首先构思设计行业轮动策略的实现路径，并构建 LSTM-Informer 模型对行业轮动策略进行实现。基于深度学习模型预测利用申万一级行业指数的收盘价，并根据结果判断行业发展趋势，以确定轮动方案。在确定输入模型的特征指标后，利用 Wind 数据库获取数据，并利用小波降噪（Wavelet Thresholding Denoising）的方式，提升深度学习模型的效能。本章之后基于 LSTM-Informer 模型进行实证分析，对模型进行参数优化以获得更佳预测结果，利用模型得到预测结果并对模型进行评价，并与其他多个机器学习，深度学习模型进行对比。根据模型结果判断行业未来趋势，以得到行业轮动的具体方案。

第四章是量化策略设计与回测部分。本章首先证明申万一级行业存在轮动现象，并说明基于深度学习模型构建行业轮动策略的可行性与科学性。之后本章基于深度模型的预测结果得到一段时期内的强势行业，由于申万一级行业指数不能直接交易，因此考虑在得到强势行业后，交易与该行业最为相关的 ETF。本文利用 Spearman 相关和 Pearson 相关确定与申万一级行业指数最为相关的 ETF 作为策略的交易对象，基于相关系数与 ETF 的规模筛选出行业 ETF，在回测区间上轮动交易行业 ETF，并对行业轮动策略进行评价与优化。本章还构建不同调仓频率的行业轮动策略、构建基于对比模型的行业轮动策略、对行业轮动策略在回测周期各区间上表现进行分析，

中国知网 https://www.cnki.net

以验证策略的稳健性。

第六章为总结与展望部分。对研究结果进行了概括，同时分析了研究中的不足之处，并对未来的研究方向提出了展望。

1.5 主要的创新点

（1）本文将 LSTM 模型与 Informer 模型融合应用于金融时间序列分析领域，构建了兼具趋势判断能力与全局特征提取能力的组合深度学习模型。通过并行提取数据序列的局部与全局特征，提升了模型对多维金融数据的适应性与预测准确性。本文在实证分析基础上基于预测结果构建量化行业轮动策略，有效提升了策略的实时性与交易决策质量。

（2）以往针对行业轮动策略研究大多是基于经济周期，动量等历史数据，例如基于美林时钟理论，利用动量与反转效应构建行业轮动策略。但是这些方法都较为主观，无法对市场运行趋势有效捕捉，不能对行业在未来的表现形成判断，在发生风险时也无法及时调整。基于 LSTM-Informer 模型的行业轮动策略利用模型的预测结果判断行业在未来的涨跌幅以确定强势行业，根据市场变化情况进行轮动交易强势行业 ETF，使策略的趋势判断能力增强，让轮动交易更具收益性与风险抗性。

中国知网 https://www.cnki.net

2 研究理论与技术基础

2.1 行业轮动策略理论

行业轮动策略是一种基于行业间表现差异的资产配置策略，是择时量化交易策略的一种，其核心思想是在不同的市场环境之下，行业的盈利能力和市场表现存在周期性差异，因此可以通过合理的行业配置获取超额收益。其本质是利用行业间相对强弱关系，动态调整投资组合，以在不同市场环境中捕捉最优行业表现。在构建行业轮动策略过程中，最重要的是轮动信号的识别，判断轮动信号可以根据经济周期判断，金融资产的历史动量和对未来的趋势判断，以构建基于经济周期、历史数据和预测判断的行业轮动策略。

2.1.1 基于经济周期的行业轮动策略

宏观经济活动在长期运行中通常呈现出的周期性波动特征，构建基于经济周期的行业轮动策略，要对经济周期的运行情况进行识别，识别后根据经济阶段配置不同的行业资产，以获取超额收益。通常将经济周期划分为复苏、扩张、衰退和萧条等阶段。在不同的经济周期阶段，不同行业的盈利能力、市场表现及资金流向均存在显著差异。因此，基于经济周期的行业轮动策略旨在通过识别经济周期的阶段性特征，调整投资组合在不同行业间的配置比例，以获取超额收益并控制下行风险。

例如，可以在经济上行期配置$\beta > 1$的周期行业资产，在经济下行期配置$\beta < 1$的非周期行业资产。例如公用事业行业就属于$\beta < 1$的非周期行业，在经济衰退期，可以交易公用事业行业 ETF，在经济上行期将其卖出。除此之外，还可以将选股策略融入到基于经济周期的行业轮动策略中，首先对经济运行周期进行判断，之后根据β值对行业进行划分，若经济处于上行周期，可以筛选并交易周期行业的优质股票；若经济处于下行周期，可以筛选并交易非周期行业的优质股票。

但是基于经济周期的行业轮动策略也存在诸多问题，例如对于经济周期的划分较为主观，投资者对于经济运行情况的判断不一定准确，这就会影响投资决策的准确性。除此之外，基于经济周期的行业轮动策略在筛选过交易资产后，往往需要在

中国知网 https://www.cnki.net

一定时期内持有，这就导致其调仓频率的不足，一旦市场发生转换，无法及时进行转换以控制风险。

2.1.2 基于历史动量的行业轮动策略

基于历史动量的行业轮动策略依赖于资产价格的趋势延续性，假设短期内市场表现优异的行业在未来一段时间内仍将持续取得超额收益，而表现不佳的行业则可能继续低迷。该策略源于动量理论，该理论表明资产价格的历史收益率对未来收益具有显著的预测能力。该策略的构建通常包括以下几个步骤：首先，选取合适的动量衡量指标，如过去一段时间的行业指数累计收益率或风险调整后收益率。其次，根据动量排名选择表现最强的行业进行投资，并定期（如每月或每季度）对持仓进行调整，以保持对高动量行业的敞口。基于历史动量的行业轮动策略的思路包括打分法和映射法，打分法先把不同行业的资产进行筛选，再根据如历史动量等各种要素进行打分，轮动交易得分最高的资产以获取超额收益，映射法先对行业指数进行趋势判断，得到未来一段时期内强势的行业，再选出行业内最为优质轮动交易。

打分法通过多个指标对行业进行评分，并据此决定投资方向。其核心思想是利用不同的评估因子，对各行业进行评分排序，选择得分最高的行业进行投资。其核心步骤包括选取评估因子，例如基本面因子，技术指标因子，投资者情绪因子等；构建模型并计算行业得分，选取合适的分析模型进行分析，每个行业的因子得分计算后，可以采用不同的方式进行合并，如等权重打分和加权打分等；行业排序与投资决策，根据计算得分，对行业进行排序，根据设定轮动周期选择得分最高的行业进行投资，例如每周或每月重新计算一次评分，并调整投资组合。

映射法的核心思想是利用特定的评分或指标体系，将行业市场数据映射到金融资产上，从而构建投资组合。该方法主要用于解决交易资产选择的问题，确保策略能够有效捕捉行业轮动的收益，同时减少选择的主观性，提高投资组合的分散度和稳定性。该方法首先根据各种指标进行建模，根据行业指数判断行业的未来的趋势，再寻找与行业指数最为相关的资产轮动交易。

基于历史动量的行业轮动策略仍存在一定的局限性，例如动量策略对市场趋势的依赖性较强，在市场风格发生剧烈切换时，可能导致趋势反转风险，从而引发显

中国知网 https://www.cnki.net

著回撤，特别是在金融危机或突发事件期间，市场动量特征可能迅速逆转，使得基于历史动量的行业配置策略失去有效性。

2.1.3 基于预测判断的行业轮动策略

基于预测判断的行业轮动策略旨在利用模型预测手段对未来行业表现进行预测，并据此动态调整行业配置，以获取超额收益。与前两种轮动策略不同，基于预测判断的轮动策略更加强调前瞻性分析，在行业趋势判断后进行提前布局相关资产。

该策略的核心在于建立一套能够有效捕捉行业表现驱动因素的预测体系。一方面，需要选择能对行业未来趋势进行精准预测的模型，例如机器学习模型，深度学习模型等；另一方面，也要选择合适的特征变量对金融时间序列进行拟合，例如基本面特征变量，技术面特征变量等。除此之外，还可以加入市场情绪变量以捕捉市场特征。基于预测判断的行业轮动策略可以对未来的宏观经济形势、市场情绪进行判断，之后根据预测市场情况进行配置；也可以通过判断行业资产未来一段区间的涨跌，配置上涨行业，交易下跌行业；还可以对行业未来一段时期资产收益率进行预测，选择收益率大的进行配置，交易收益率低的行业资产。

但预测模型的精确度将很大程度上影响策略的有效性，特征变量的选择也应最大程度上捕捉行业序列的有关特征，同时也要避免特征变量之间的相关性。以往的资产定价模型，例如因子模型和统计模型，对于金融时间序列的预测效果并不佳，随着计算机技术的发展，机器学习、深度学习等模型在金融时间序列预测领域取得较好效果，将机器学习与深度学习引入行业轮动策略的构建将提升策略效果。但深度学习模型也面临着运行时间长，序列过拟合等问题，因此构建适用于不同行业的预测模型至关重要。

本文对以上方法进行参考，首先选择多个特征变量输入构建的 LSTM-Informer 深度学习模型，对申万一级行业指数进行预判，为提升判断效果，本文运用小波降噪等方法优化数据，提升模型的泛化能力。之后根据预测结果计算不同行业在一段时期内的收益率，根据收益率排序选择强势行业后，轮动交易与申万一级行业指数最为相关的行业 ETF，以实现行业轮动策略。

中国知网 https://www.cnki.net

2.2 量化交易相关理论

量化投资作为一种融合数理统计知识与计算机程序的投资方式，通过精准的数据分析和策略实施，在投资领域广泛运用。这种投资方式的核心理念在于运用先进的数学模型和计算机技术来制定和执行投资策略。在过去的数十年间各类量化投资技术飞速发展，在全世界投资界中占据了一席之地。在美国资本市场中，量化投资策略已深入人心，特别是在对冲基金和私募股权领域，其应用尤为广泛。近年来，中国的量化投资市场也呈现出蓬勃的发展态势，私募基金市场尤为活跃。据 Wind 数据库有关数据显示，截至 2022 年年底，中国私募基金市场上量化对冲类基金的数量已突破 2000 只，标志着中国量化投资领域的崛起。

根据量化交易策略的核心原理与交易执行方式，量化交易策略大致可分为以下三类：择时策略、套利策略和选股策略。

（1）择时策略

择时策略主要关注市场价格的趋势与波动，试图通过分析市场数据识别合适的买入与卖出时机，以获取超额收益。该类策略通常依赖技术分析、统计分析或机器学习方法构建信号，以判断市场趋势的变化。例如，动量策略利用资产价格的历史趋势预测未来走势，而均值回归策略则基于价格偏离历史均值后回归的假设进行交易。此外，宏观因子模型也被用于择时策略中，以分析经济指标对市场走势的影响。行业轮动策略就是一种典型的择时量化交易策略。

（2）套利策略

套利策略利用市场中的价格错配机会，构建低风险或无风险的交易组合，以获取稳定收益。套利策略可进一步细分为统计套利、跨市场套利和无风险套利等类型。统计套利利用历史数据挖掘资产之间的统计关系，如配对交易，其中交易者寻找具有协整关系的资产对，当价差偏离正常水平时进行交易。跨市场套利利用不同市场之间的价格差异，例如 A 股与 H 股的价差套利。无风险套利则主要依赖市场机制的不完善，例如期现套利利用期货与现货市场的定价差异进行套利。

（3）选股策略

选股策略旨在通过分析个股基本面、技术面或其他因素，构建优质投资组合，

中国知网 https://www.cnki.net

以期获得长期稳定收益。基本面选股策略基于财务报表、盈利能力、估值水平等指标筛选股票，如 Fama-French 三因子模型或多因子选股模型。技术面选股策略则主要依赖于价格走势、成交量及其他市场行为指标，如相对强弱指数（RSI）、移动平均线（MA）等。此外，近年来机器学习选股策略逐渐受到关注，通过深度学习、强化学习等方法挖掘复杂的市场模式，提高选股的精确性和收益稳定性。

除此之外，量化交易策略的研究与实践还涉及风险管理、交易执行优化以及交易成本控制等关键环节。例如需综合考虑市场风险、流动性风险以及模型风险，利用多种指标评估和控制风险暴露。在执行策略过程中，滑点、手续费以及市场冲击均需纳入考量以控制成本。

2.3 深度学习模型相关理论

深度学习（Deep Learning）作为机器学习的重要分支，其核心是一种以人工神经网络为基础的多层结构建模方法，能够从海量数据中自动提取深层次特征表示。近年来，受益于计算资源的快速发展和大规模数据集的广泛应用，深度学习在图像识别、自然语言处理、语音识别等多个领域取得了突破性进展。相较于传统方法依赖人工构造特征的模式，深度学习模型通过多层非线性映射，实现了从原始输入到抽象语义表示的端到端学习，大幅增强了模型的表达能力和泛化性能。

深度学习模型具有对复杂非线性关系建模能力和对高维数据的高效处理能力。传统金融模型在面对金融市场数据中普遍存在的高噪声、非线性和非平稳性时，往往难以实现准确建模与预测。而深度神经网络凭借其多层次结构，能够自动学习数据中的高阶特征表示，有效提取潜藏的规律信息。将深度学习技术应用于量化投资领域，可以提升策略的稳定性和有效性。

2.3.1 LSTM 模型

德国学者 Hochreiter 和 Schmidhuber 于 1997 年提出长短时记忆神经网络模型（Long Short-Term Memory，LSTM），该模型是一种用于序列建模的深度学习模型。LSTM 通过引入门控机制来调节信息的流动，使其能够有效捕捉序列数据中的长期依赖关系，相比于普通递归神经网络模型，LSTM 结构设计更加优化，能够更准确

中国知网 https://www.cnki.net

地学习时间序列数据的特征，提高模型的泛化能力和预测精度。

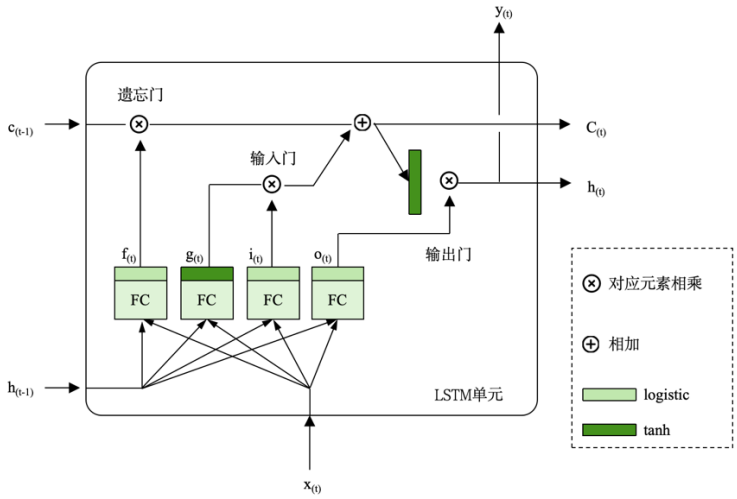


图 2-1　LSTM 单元结构图

LSTM 的核心思想在于网络能够学习长期存储的信息、需要遗忘的信息以及需要读取的信息，其原理图如图 2-1。当长期状态c_{t-1} 在网络中从左向右传递时，首先经过遗忘门，筛除一部分记忆。随后，输入门决定添加哪些新的信息，并通过加法运算更新长期状态，从而得到c_t。这一状态可直接输出，无需额外转换。因此，在每个时间步长，都会丢弃部分旧记忆，同时引入新的记忆。此外，长期状态在加法更新后会被复制，并通过 tanh 函数处理，随后经由输出门筛选，最终得到短期状态h_t，即当前时间步长的单元输出y_t。

在 t 时刻输入的x_t和前一时刻的短期状态h_{t-1}共同输入到每个层承担不同的功能的四个全连接层中。模型最主要的层负责计算输出g_t，通常用于分析当前输入x_t和之前的短期状态h_{t-1}。在基本神经网络单元中，这一层的输出直接作为y_t和h_t输出。而在 LSTM 单元中，该层的输出并不会直接传递，而是将其重要部分存入长期状态，其余部分则被丢弃。另外三个层作为门控机制，起到调节作用。由于它们采用逻辑激活函数 Sigmoid，其输出值介于 0 到 1 之间。这些输出值会参与逐元素乘法运算，从而控制信息流通：当输出为 0 时，门关闭，信息被阻断；当输出为 1 时，门完全打开，信息可自由通过。各门的作用如下：

（1）遗忘门，由f_t控制，其决定去除c_t中的哪些长期记忆样本。

中国知网　https://www.cnki.net

（2）输入门，由i_t控制，其决定把g_t的哪些内容输入进c_t。

（3）输出门，由o_t控制，其决定在该步长学习c_t的哪些部分并输入进 h_t和y_t。

LSTM 模型在 t 时刻的计算公式如下

$$i_t = \sigma(W_{xi}^T x_t + W_{hi}^T h_{t-1} + b_i) \quad (2-1)$$

$$f_t = \sigma\left(W_{xf}^T x_t + W_{hf}^T h_{t-1} + b_f\right) \quad (2-2)$$

$$o_t = \sigma(W_{xo}^T x_t + W_{ho}^T h_{t-1} + b_o) \quad (2-3)$$

$$g_t = tanh\left(W_{xg}^T x_t + W_{hg}^T h_{t-1} + b_g\right) \quad (2-4)$$

$$c_t = f_t \otimes c_{t-1} + i_t \otimes g_t \quad (2-5)$$

$$y_t = h_t = o_t \otimes tanh(c_t) \quad (2-6)$$

其中，W_{xi}，W_{xf}，W_{xo}，W_{xg}是四层中的每层与输入向量x_t连接的权重矩阵。W_{hi}，W_{hf}，W_{ho}，W_{hg}是四层中的每层与先前的短期状态h_{t-1}连接的权重矩阵。b_i，b_f，b_o和b_g是四层中每层的偏置项。

2.3.2 Informer 模型

Informer 机制是一种近年来应用于时间序列预测分析的创新深度学习模型。作为对 Transformer 结构的改进，Informer 旨在解决 Transformer 在处理长序列时存在的限制，使其能够更有效地捕捉输入与输出之间的远程依赖关系。该模型引入了一种分层结构设计，通过将完整的时间序列划分为若干长度不一的子序列，结合上下文中序列长度的动态信息，实现了对不同时间尺度数据的灵活建模与高效处理。这种机制使得模型在面对长时间序列时，能够有针对性地调整处理策略，从而显著提升了对复杂时序数据的表达能力与建模精度。Informer 模型在结构设计上具备多项优势，具体特性如下所述：

（1）引入稀疏自注意力机制（ProbSparse Self-Attention），优化时间复杂度和空间复杂度至 *(O(L\log L))*，显著降低了计算成本，与传统自注意力机制相比具有明显优势。

（2）利用改进的多头注意力机制，通过逐层级联减少输入规模，使模型能够突

中国知网 https://www.cnki.net

出关键注意力区域，从而有效应对超长序列，提高对不同区域的关注能力。

（3）结合基于 Transformer 的生成式解码器，采用一次性前向推理方式对长时间序列进行预测，而非逐步预测（step-by-step），大幅提升长序列预测的推理效率。Informer 模型的主要结构，如图 2-2 所示。

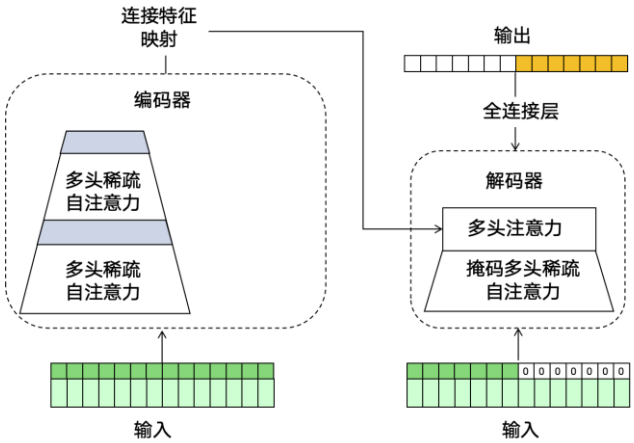


图 2-2　Informer 模型原理图

Informer 模型的结构由两个关键部分构成：编码器和解码器。在该架构中，编码器负责提取输入的长序列信息特征，并通过 ProbSparse 稀疏自注意力机制捕捉关键注意力区域，同时降低网络的计算复杂度。解码器接收长序列输入，并填充 0 作为占位符，随后将连接的特征图与注意力机制提取的信息进行融合，以便直接进行长序列输出的预测。编码器通常由多个层（Layer）构成，每一层包含多个子层，例如自注意力机制（Self-Attention）、前馈神经网络（Feed-Forward Neural Network）以及多头注意力模块。解码器结构与编码器类似，两者结构如图 2-3 所示。

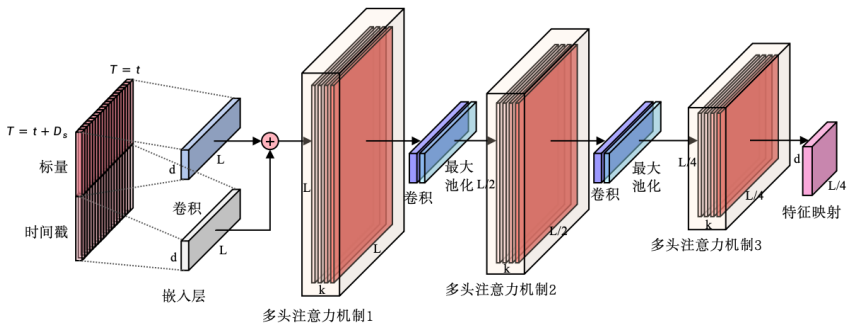


图 2-3　编码器、解码器原理图

Informer 模型下引入 ProbSparse 自注意力机制用于处理输入序列中各元素间的

中国知网　https://www.cnki.net

依赖关系。改进后的机制引入了概率稀疏性策略，以控制注意力权重矩阵的稀疏程度，从而在保持建模能力的同时，有效减少了计算资源的消耗与模型参数量，其原理图如图 2-4。

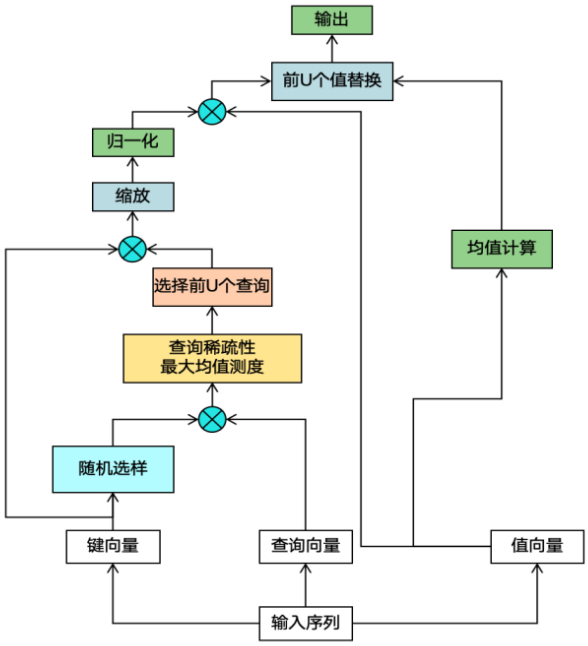


图 2-4　稀疏自注意力机制原理图

在 ProbSparse 在自注意力机制中，通常首先对查询向量（Query, Q）与键向量（Key, K）进行点积运算，并通过 Softmax 函数对结果进行归一化，以构建初步的注意力权重矩阵。下一步引入查询向量与均匀分布查询向量之间的 KL 散度（Kullback-Leibler Divergence）作为衡量指标，用以评估查询向量的信息分布差异，以此避免注意力过于集中在某些特定位置， KL 散度计算公式如下。

$$D_{KL}(P \parallel Q) = \sum_i P(i) \, log \frac{P(i)}{Q(i)} \qquad (2-7)$$

其中，P(x) 表示第 i 个查询对应的概率分布，而 Q(x) 则表示参考的均匀概率分布。KL 散度用于度量这两种概率分布之间的差异程度，其数值越大，说明两者之间的差异越显著，表明分布的不相似性更强。

接着，基于稀疏度得分对注意力权重进行修正，生成优化后的注意力权重矩阵。最终，将调整后的注意力权重矩阵与值向量相乘，得到最终的 ProbSparse 自注意力

中国知网 https://www.cnki.net

机制结果，计算公式如下。

$$ProbSparse(Q) = \frac{\sum_i Q(i)\, log \frac{Q(i)}{1/N}}{N} \qquad (2-8)$$

ProbSparse 自注意力机制的引入使得注意力计算更加高效，减少了计算复杂度和参数数量，尤其适用于长序列数据的处理，提高了模型的计算效率和整体性能。此外，ProbSparse 自注意力机制还提供了对稀疏度得分的灵活控制，使得模型能够根据不同任务和结构需求，动态调整注意力的分布，以适应不同的应用场景。

前馈神经网络（Feed-Forward Network， FFN）核心特点在于信息在网络中单向流动，即从输入层经由一个或多个隐藏层传递到输出层，中间不包含反馈连接。FFN 通常由多个线性变换和非线性激活函数（如 ReLU、Gelu 等）交替组成，通过多层特征变换，逐步提取数据中的特征。在训练过程中，网络通过反向传播算法（Backpropagation）来更新参数，使预测输出逐渐逼近真实标签，从而优化模型性能。其计算过程可如下表示。

$$FFN(X) = \max(0，XW_1 + b_1)W_2 + b_2 \qquad (2-9)$$

其中 X 代表输入变量，W_1，W_2分别代表两个全连接层的权重矩阵，b_1，b_2分别代表两个全连接层的偏置向量。max 代表激活函数，作用是引入非线性。

FFN 进一步处理模型输出，对模型的复杂度和表示能力进行提升。这种结构优化使模型能够更有效地学习复杂的特征关系，提高整体预测能力。

在收盘价预测应用中，Informer 深度学习模型通过在数据输入中加入位置编码，以确保模型能够准确捕捉输入序列的时间顺序。位置编码分为本地时间戳（Local Time Stamp）和全局时间戳（Global Time Stamp），时间序列 $[X_t,\ldots,X_{t+i},\ldots,X_T]$ 将金融时间序列的特征信息作为输入引入到 Informer 网络中，并通过位置编码机制充分挖掘时间序列在局部与全局维度上的时间依赖性。借助多头注意力机制，模型能够聚焦于关键特征。此外，为实现对未来信息的屏蔽，引入填充的零值元素，并配合掩蔽机制，以确保解码过程的合理性。随后，数据通过多头注意力机制传递，并经过全连接层处理，最终实现对股价的精准预测。

中国知网 https://www.cnki.net

2.3.3 LSTM-Informer 模型

Informer 模型擅长处理长时间序列，能够并行计算，提高了计算效率和预测性能。LSTM 模型在捕捉序列数据的短期和长期依赖性方面表现出色，能够很好地处理序列数据中的时序关系。通过将这两种模型并行使用，可以更好地捕捉不同时间尺度上的模式，提高预测的准确性和鲁棒性。并行使用 Informer 和 LSTM，通过两个分支并行学习，可以使模型在不同的时间尺度上进行信息提取和处理。Informer 分支部分处理全局时序模式，能够有效处理长时间序列数据，LSTM 分支部分处理局部时序模式，能够有效捕捉短期依赖性和序列数据的动态变化。其原理如图 2-5。

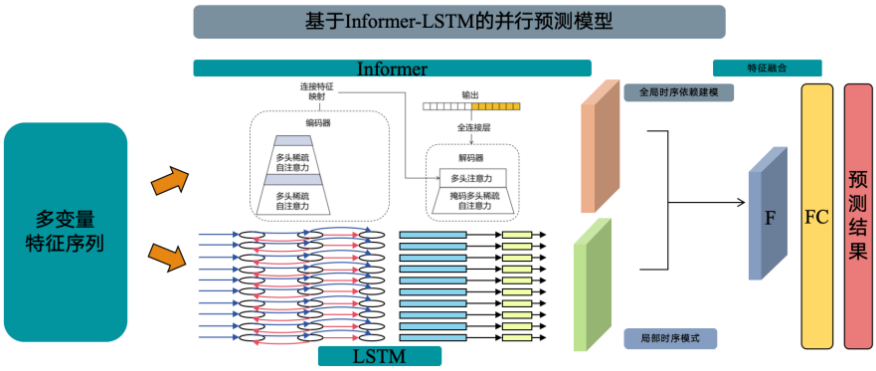


图 2-5 LSTM-Informer 模型原理图

LSTM-Informer 模型构建两个分支架构，分别是 LSTM 模型分支与 Informer 模型分支，将进行小波降噪后的数据输入到模型中，模型将利用这两个深度学习分支框架并行计算处理数据，并进行预测输出。图中上半部分分支为 Informer 模型框架，通过 Informer 编码器—解码器模型网络，利用 Informer 的长时间依赖建模能力来提取序列全局特征；下半部分分支为 LSTM 模型分支，数据同时通过 LSTM 模型，利用其短期依赖捕捉能力来提取局部特征。在并行处理之后将特征融合，两个分支提取的全局特征和局部特征通过堆叠融合，使模型能够更好地融合不同层次的特征表示，提高模型预测精度和泛化能力。

（1）LSTM 分支

在构建 LSTM 分支架构中通过引入几个门控制单元（如输入门、遗忘门和输出门）来调节信息的流动，这些门控制单元决定了在每个时间步哪些信息应该被保留、

中国知网 https://www.cnki.net

忽略或更新。输入门决定了哪些新信息被加入到细胞状态；遗忘门决定了哪些旧信息应该被丢弃或保留；输出门决定了下一个隐藏状态应包含哪些信息，即基于当前的细胞状态决定输出什么。

在设计 LSTM 分支架构部分的程序代码过程中，主要包含如下几个部分：input_size 代表输入特征的维度；hidden_size 是 LSTM 隐藏层的大小，也是输出特征的维度；num_layers 是堆叠的 LSTM 层的数量；batch_first 则确保输入和输出的 Tensor 格式为 batch 格式、seq 格式或者 feature 格式；bidirectional 设置为 False 表示使用单向 LSTM。在模型中使用了前向传播的方法，在每次前向传播时，都会初始化一个隐状态 h_0 和细胞状态 c_0，这些状态被随机初始化并放置到正确的设备上，例如 CPU 或者 GPU。LSTM 分支架构接收输入变量并输出两部分：output 输出和（h, c）矩阵，分别代表所有时间步的隐藏状态和最终时间步的隐藏状态和细胞状态。LSTM 层的输出为 LSTM-Informer 模型的编码器和解码器提供了一个富含历史信息的序列表达，增强了整个模型对时间序列数据的理解和预测能力。

（2）Informer 分支

Informer 分支架构中主要包含数据嵌入层部分、编码器部分和解码器部分，Informer 分支部分分别为编码器和解码器提供了数据嵌入层。这些嵌入层使用了线性层和时间编码，通过正弦和余弦函数的变体来实现功能。

1. 数据嵌入层（Data Embedding）：数据嵌入层的目的是将时间序列的原始特征转换为模型能够更有效处理的形式。在这一部分中，不仅包括特征的线性变换，还包括时间编码的引入，使模型能够更好学习时间序列的周期性和趋势。

2. 编码器（Encoder）：编码器负责处理经过数据嵌入层的输入数据，通过多层的注意力机制和全连接层深入分析和提取关键信息。编码器由多个 EncoderLayer 组成，每个层都包含注意力机制和全连接层。稀疏概率注意力机制通过随机采样方法降低计算复杂度，同时保持性能。

3. 解码器（Decoder）：解码器结合编码器的输出和解码器自身的输入，通过多层的注意力机制和全连接层，生成未来时间点的预测。解码器的核心组件同样由 DecoderLayer 组成，其中每层包括两种类型的注意力机制——自注意力（处理解码

中国知网 https://www.cnki.net

器输入）和交叉注意力（结合编码器输出），这有助于模型在生成预测时综合利用过去和现在的信息。

（3）模型组合方法

LSTM 分支部分首先处理输入的编码序列 x_enc，输出一组捕捉了长期依赖关系的特征（lstm_out）；同时，原始输入序列经过 Informer 模型的数据嵌入层，利用编码器转换为适合进一步处理的嵌入向量 enc_out 和 dec_out。之后进行特征组合，将 LSTM 的输出与 Informer 编码器的嵌入输出进行组合，这里使用融合叠加（concatenation）方式进行组合，以融合 LSTM 捕获的即时特征和 Informer 模型嵌入层的全局特征。最后是解码器处理，组合后的特征送入解码器，用来生成对未来时间点的预测，形成组合双分支的 LSTM-Informer 模型。

在 LSTM-Informer 模型中，LSTM 层和 Informer 层的组合使用提供了以下优势：

1. 双重特征抽取：LSTM 层与 Informer 层首先并行处理原始时间序列数据，抽取和编码关键的长期依赖特征。

2. 增强的时间序列分析能力：Informer 层接收来自 LSTM 的输出和原始嵌入，结合两者的信息进行结合分析。通过这种结构设计，模型不仅能够利用 LSTM 处理局部时序信息的能力，还能利用 Informer 高效处理大规模数据的优势。

中国知网 https://www.cnki.net

3 基于 LSTM-Informer 模型的价格预测分析

3.1 数据收集与预处理

本文从 Wind 数据库获取数据，首先获取 31 个申万一级行业，综合考虑建模所需数据量和数据波动情况，本文收集 2010 年 1 月 4 日至 2024 年 12 月 31 日的申万一级行业指数数据，申万一级行业指数名称及代码见表。本文获取的 ETF 在 Wind 数据库中为中国市场中上市的所有股票型 ETF，这些股票型 ETF 在 Wind 数据库中主要分为：1.主题指数类 ETF；2.行业指数 ETF；3.规模指数 ETF；4.策略指数 ETF；5.风格指数 ETF。本文中深度学习模型的训练集，验证集，测试集划分为 7:1:2，行业轮动量化策略的回测区间与测试集区间保持一致。考虑到回测区间内的数据需求，将 2022 年 1 月没有数据的 ETF 剔除，最终剩下 316 个 ETF。将申万一级行业指数数据与所选 ETF 数据从数据库中输出并保存。在深度学习模型中，样本数据通常被划分为训练集、验证集和测试集，其划分如表 3-1 所示，三者的比例为 7:1:2。其中，训练集用于对模型参数进行拟合，验证集用于辅助模型结构的优化与调参过程，而测试集则用于检验训练完成后的模型在样本外序列的预测性能。申万一级行业指数的时间序列图如图 3-1 所示。

表 3-1 数据集划分表

数据	比例	交易天数	时间
训练集	7	2555	2010/1/4—2020/7/9
验证集	1	365	2020/7/10—2022/1/3
测试集	2	730	2022/1/4—2024/12/31

3.1.1 输入特征变量选择

金融市场是一个高度复杂且动态变化的系统，受到众多因素的影响，包括宏观经济状况、政策变动、市场情绪等。这些因素之间相互作用，共同决定着金融资产的价格波动。因此，仅仅依靠单一的特征指标进行预测往往难以捕捉到市场的全貌和深层次规律。通过将多维度特征指标输入深度学习模型，可以充分利用模型的多层非线性变换结构，自动提取并融合这些特征中的有效信息。这种综合考量多个维度的方式，能够更全

中国知网 https://www.cnki.net

面地揭示金融市场的内在规律和潜在趋势，从而提升预测的准确性和可靠性。将多维度特征指标输入深度学习模型进行金融时间序列预测还有助于增强模型的泛化能力，在金融市场复杂多变的环境中，模型可以从中学习到更丰富的模式和关联关系，能够在多种情况下做出合理的预测。借鉴学界现有的研究以及考虑数据可得性，本文从基本行情指标、技术面指标等维度选取以下 14 个指标为特征输入向量，采用 LSTM-Informer 深度学习模型，提取影响指数变动的深层次特征表示，以实现对申万一级行业指数的趋势预测。对于输入模型的变量，本文选择如下：

表 3-2　输入变量名称

特征变量	指标名称	特征变量	指标名称
Close	前日收盘价	MA（5）	5 日移动平均线
High	前日最高价	MA（20）	20 日移动平均线
Low	前日最低价	EXPMA（12）	12 日指数移动平均
Open	前日开盘价	MACD	指数平滑移动平均线
Volume	前日成交量	RSI（9）	相对强弱指标
VMA（5）	5 日平均成交量	DMI	动向指标
VMA（20）	20 日平均成交量	QRR	量比

在进行深度学习模型的训练和预测之前，需要对原始数据清洗。由于时间跨度较长，申万一级行业指数相关数据可能会出现缺失和异常，这些极端值会对模型训练造成影响。针对异常值，本文利用 3σ准则，当申万一级行业指数有关数据在区间（ σ- 3 ,σ ＋3 ）之外时，即被判定为异常值。对于这些异常值，本文采取均值填充的方法进行处理。针对缺失值，本文数据来源为 Wind 数据库，缺失情况较少。首先对缺失值进行排查，之后利用均值填充方式处理缺失值。

申万一级行业指数共有 31 个，不同行业指数的收盘价及指标数据变量的取值差别极大，同时不同指标之间由于计算方式的差别也会有特别大的差距。在预测过程中，不论是较小还是较大的量纲数据都会影响预测的精度，所以本文在利用模型训练预测股价之前，先对股价序列数据和各个输入特征序列数据都进行了归一化处理，将所有数据值控制在[0,1]区间内，公式如下所示:

中国知网　https://www.cnki.net

$$X_i = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (3-1)$$

其中X_i分别是在归一化处理前后的时间序列数据，X_{max}和X_{min}分别表示原数据在时间序列当中的最大值和最小值。

3.1.2 序列小波降噪

序列小波降噪是一种有效的数据预处理方法，广泛应用于金融、电力、气象等领域，用以降低高频噪声的干扰，提升后续模型的预测精度。该方法的基本思想是利用小波变换将原始时间序列分解为多个不同频率和时间尺度的子序列，从而实现信号与噪声的分离。小波分析技术具有在不同尺度下对信号进行细致处理的能力，能够在金融时间序列建模中，有效去除价格数据中的短期扰动成分，保留具有预测意义的长期趋势。其数学表达式如下：$C_0 = C_t + D_t + D_{t-1} \ldots + D_2 + D_1$ ，C_0为原始的金融时间序列信号，C_1，C_2，…，C_t和D_1，D_2，…,D_t分别为其小波分解的第 1，2,…,t 层低频和高频信号,小波降噪原理如图 3-3 所示。

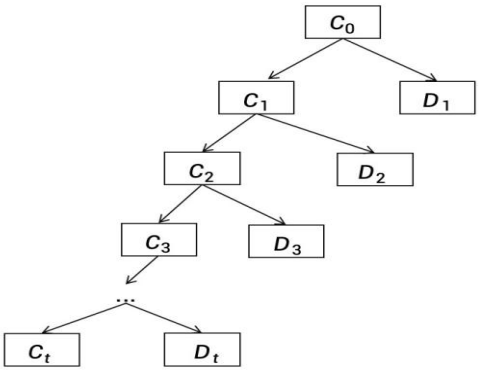


图 3-1　小波降噪原理图

为了实现降噪效果，采用基于小波分解的 Mallat 重构方法，通过第 N 层的低频系数与 1 到 N 层的高频系数进行重构，且将高频部分设置为零。金融时间序列数据的小波分解中的低频成分反映了数据序列的整体趋势，而高频成分则揭示了序列的短期波动与噪声。因此，在使用小波降噪处理数据时，关键在于选择合适的小波降噪函数，并确定最佳的分解层数。Db 小波函数具有紧支撑的特性，适用于时频局部化要求高的信号处理任务，但其对称性较差，平滑性较低，可能引入伪影。Coif 小波函数在保持紧支撑的基础上，提供更好的平滑性和对称性，适合对信号平滑要求

中国知网　https://www.cnki.net

较高的应用，尤其在降噪任务中表现较好。Sym 小波函数则具有更高的对称性和较好的平滑性，比 Db 和 Coif 小波函数更加平滑，适合需要对称性和平滑度较高的任务，如图像降噪。此外，小波分解层数越多，细节信号和近似信号的平稳性越好，但会导致分解过程的误差越大，故层数不宜过多也不宜过少。本文采用 4 层分解，分别利用 Db，Sym，Coif 三个小波函数分别处理 31 个申万一级行业指数，通过比较降噪后序列的信噪比（Signal-to-Noise Ratio，SNR）值与 RMSE 值的大小来确定对每个一级行业指数的降噪函数，表示信号在传输过程中相对于噪声的清晰度。SNR 值越高，表示信号越清晰，噪声对信号的影响越小；SNR 值越低，则噪声对信号的干扰越大，信号质量较差。SNR 通常以分贝（dB）为单位来表示，计算公式为：

$$SNR = 10\,log_{10}\left(\frac{P_{signal}}{P_{noise}}\right) \qquad (3-2)$$

均方根误差（Root Mean Square Error，RMSE）是衡量预测值与实际值之间差异的一个常用指标，特别适用于回归分析和模型评估。它表示预测值与实际值之间的平均误差大小，通过计算误差的平方根来获得。RMSE 的值越小，表示模型的预测误差越小，预测精度越高，其计算公式见后文公式（3-4）。

因此，SNR 值大且 RMSE 小的降噪结果最好。基于此，本文针对 31 个申万一级行业指数所选取的小波降噪函数以及处理结果如表 3-3 和图 3-4 所示：

表 3-3　最佳小波函数

行业名称	RMSE	SNR	最佳小波函数
传媒	5.48	36.39	coif4
电力设备	35.47	37.11	db8
电子	20.25	35.12	db8
房地产	22.85	33.27	db8
纺织服饰	11.01	36.55	coif4
钢铁	15.21	31.79	db8
公用事业	10.90	33.92	db8
国防军工	9.67	32.06	db8
环保	13.66	35.81	db8
机械设备	8.15	32.06	coif4
基础化工	17.48	34.23	db8

中国知网 https://www.cnki.net

续表 3-3　最佳小波函数

行业名称	RMSE	SNR	最佳小波函数
计算机	26.96	35.06	coif4
家用电器	30.39	37.92	coif4
建筑材料	33.74	33.17	db8
非银金融	10.73	31.90	coif4
建筑装饰	12.56	34.09	db8
交通运输	11.56	33.96	db8
煤炭	17.72	33.45	sym4
美容护理	32.06	33.91	coif4
农林渔牧	16.36	33.45	coif4
汽车	27.18	33.53	db8
轻工制造	12.82	34.59	coif4
商贸零售	20.27	34.91	coif4
社会服务	34.01	39.06	db8
石油石化	13.10	28.14	coif4
食品饮料	60.37	42.29	db8
通信	15.08	31.95	db8
医药生物	41.66	35.69	coif4
银行	15.08	32.71	coif4
有色金属	27.84	30.59	coif4
综合	14.27	33.42	coif4

图 3-4 是针对申万传媒指数的小波降噪结果，可以看出，通过对时间序列进行小波降噪操作，在减少申万一级行业指数收盘价原始数据噪声的同时较好的保留了原始数据的信息。

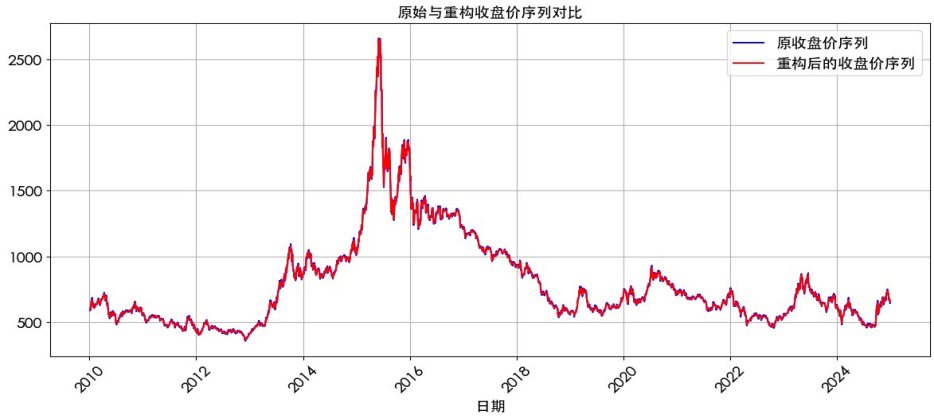


图 3-2　小波降噪处理结果

中国知网　https://www.cnki.net

3.1.3 深度学习模型评价指标

本文设计了基于 LSTM 与 Informer 融合结构的预测模型，用于对申万一级行业指数的收盘价进行建模预测，并据此构建行业轮动的量化交易方案。针对模型预测准确性的评估，本文选取了五项评估指标，可决系数（R^2）、均方根误差（RMSE）、平均绝对误差（MAE）、平均绝对百分比误差（MAPE）以及方向准确率（DA），从多个维度衡量预测性能的优劣。

可决系数（R-squared）是一种用于衡量回归模型拟合优度的指标，常用于评估模型对数据的解释能力。决定系数的值反映了自变量在多大程度上能够解释因变量的变异性。决定系数的值范围从 0 到 1，其中值越接近 1，表示模型对数据的拟合效果越好，预测能力越强；值越接近 0，表示模型未能有效地解释因变量的变异性，预测效果较差。其计算方法是：首先计算总变异（即真实值与真实值均值之间的平方差的总和），然后计算回归变异（即预测值与真实值均值之间的平方差）。计算公式如下：

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y_i})^2}{(y_i - \bar{y})^2} \qquad (3-3)$$

其中，n 表示样本数，y_i表示第 i 个样本的真实值，$\hat{y_i}$表示第 i 个样本的预测值。

均方根误差（Root Mean Square Error，RMSE）指标广泛应用于机器学习与深度学习中的回归任务，能够反映模型预测的精确度。RMSE 值越小，则模型对时间序列的预测结果与真实数据间差距越小，说明预测能力更强。计算 RMSE 时，首先求出预测值与实际值差异的平方，然后将这些平方差值求和并除以数据集中的样本数，最后取平方根。RMSE 的计算公式如下：

$$RMSE = \sqrt{\sum_{i=1}^{n}(y_i - \hat{y_i})^2/n} \qquad (3-4)$$

其中，n 表示样本数，y_i表示第 i 个样本的真实值，$\hat{y_i}$表示第 i 个样本的预测值。

平均绝对误差（Mean Absolute Error，MAE）是一种衡量预测结果与实际观测值之间差异的回归评估指标，相比于其他误差指标，MAE 受极端值影响较小，能够更稳定地反映模型整体的预测精度。计算 MAE 时，首先求出每个预测值与实际值之间

中国知网 https://www.cnki.net

差异的绝对值，然后将所有差值相加并除以样本数量，从而得到平均绝对误差。MAE 的公式如下：

$$MAE = \frac{\sum_{i=1}^{n}|y_i - \hat{y_i}|}{n} \quad (3-5)$$

其中，n 表示样本数，y_i表示第 i 个样本的真实值，$\hat{y_i}$表示第 i 个样本的预测值。

平均绝对百分比误差（Mean Absolute Percentage Error，MAPE） 是一种衡量预测准确度的指标，通过计算预测值与实际值之间误差占实际值的百分比并取平均得到。它直观反映了预测误差在真实值中的相对大小，便于不同量纲下的对比分析。MAPE 值越低，说明模型的预测结果越精确。MAPE 的计算公式如下：

$$MAPE = \frac{1}{n}|\sum_{i=1}^{n}\frac{y_i - \hat{y_i}}{y_i}| \times 100\% \quad (3-6)$$

其中，n 表示样本数，y_i表示第 i 个样本的真实值，$\hat{y_i}$表示第 i 个样本的预测值。

准确率（Directional Accuracy, DA）是一项用于衡量预测趋势方向是否正确的评估指标，主要反映模型在走势判断方面的能力。当该指标值较低时，意味着模型在判断上涨或下跌方向上的准确性较差；相反，DA 数值越高，说明模型在把握未来价格变动方向上表现越出色，具备更强的趋势预测能力。该指标能够有效辅助分析模型对市场波动趋势的捕捉效果。DA 值计算公式如下：

$$DA = \frac{100}{n} \times \sum_{i=1}^{n} d_i \quad (3-7)$$

$$d_i = \begin{cases} 1, & \frac{(y_i - y_{i-1})}{(\hat{y_i} - \hat{y_{i-1}})} \geq 0 \\ 0, & \frac{(y_i - y_{i-1})}{(\hat{y_i} - \hat{y_{i-1}})} < 0 \end{cases} \quad (3-8)$$

其中，n 表示样本数，y_i表示第 i 个样本的真实值，$\hat{y_i}$表示第 i 个样本的预测值。

3.2 基于 LSTM-Informer 模型的价格预测

3.2.1 模型训练与优化

本文将参照现有学者的研究，将初始数据样本按照 7：1：2 的比例划分为训练集、验证集和测试集。模型的训练和学习将使用训练集的数据，模型参数的优化将

中国知网 https://www.cnki.net

利用验证集与测试集的数据进行，模型的回归预测结果将与测试集的数据进行对比。

（1）激活函数选取

在深度学习模型中，激活函数是一种非线性变换，用于添加决策边界并使模型能够捕捉数据中的复杂模式和关系。本文在构建 LSTM-Informer 模型中使用了高斯误差线性单元（Gaussian Error Linear Unit，Gelu）函数。Gelu 激活函数由 Dan Hendrycks 和 Kevin Gimpel 在 2016 年提出，其数学表达式是：

$$Gelu(x) = x \cdot \Phi(x) \qquad (3-9)$$

其中$\Phi(x)$为标准正态分布的累积分布函数（CDF）。

Gelu 具有非线性和非单调性，其通过将输入与其在标准正态分布下的累积概率相乘，提供了一种自适应的门控机制。当输入接近于 0 时，Gelu 的输出接近于 0，而当输入远离 0 时，输出则趋近于输入值，这使得它具有 ReLU-like 的行为。与 ReLU 和 Leaky ReLU 等其他激活函数相比，Gelu 提供了一个平滑的激活曲线，这有助于梯度下降优化算法更有效地找到误差表面的最小值。Gelu 的输出取决于输入值在标准正态分布中的累积概率，这种动态门控机制可以在网络中引入更复杂的决策边界。这些特性使得模型在训练过程中更加稳定，同时提高了模型对输入特征的利用效率，在 Transformer 等多个深度学习模型架构中有广泛的应用。

（2）参数优化

在将激活函数选为 Gelu 函数后，下一步对深度模型的各种参数进行优化调整，以获得更好的预测结果。本文中利用网格搜索法（Grid Search）进行参数优化，Grid Search 是一种用于模型超参数优化的方法，它尝试遍历所有给定的超参数组合以找到最佳的参数设置，在利用 Grid Search 进行参数优化时，应首先定义参数网格，遍历所有参数组合并评估参数效果，得到最优参数组合。LSTM-Informer 模型涉及到需要优化的参数主要如下：

1. 模型结构参数

enc_in（编码器的输入特征维度）：决定了模型输入数据的特征数量。

dec_in（解码器的输入特征维度）：用于解码器接收的特征数量。

d_model（模型中间表示的维度）：Transformer 类架构模型中的关键参数，决定

中国知网 https://www.cnki.net

了模型的宽度。

n_heads（注意力机制中的头数）：多头注意力可以让模型在不同的表示子空间中学习信息。

e_layers（编码器的层数）：决定了编码器的深度，影响模型能捕捉的依赖关系的复杂度。

d_layers（解码器的层数）：解码器深度，影响模型的学习能力来输出预测序列。

d_ff（内部前馈网络的维度）：控制前馈网络的容量，通常设置为模型维度的两倍。

dropout（在模型中使用的 dropout 比率）：防止过拟合的正则化手段，常用于训练复杂网络模型。

factor（ProbAttention 中的缩放因子）：影响注意力机制的缩放，调节信息流动。

2. 超模参数

batch_size（每个批次的样本数量）：影响模型训练的速度和稳定性。

learning_rate（优化器的学习率）：决定参数更新的步长，对训练速度和效果有直接影响。

num_epochs（训练过程中数据集遍历的次数）：影响模型训练的充分性。

scheduler_patience（学习率调度器的耐心参数）：控制学习率的动态调整，即性能不提升时等待的周期数，有助于优化训练过程。

early_patience（早停策略的耐心参数）：即在验证集上性能不提升时等待的周期数，用于早期停止训练以防过拟合，节约计算资源。

本文参考 Zhou et al.（2021）与李新等（2024）有关研究，选择参数范围如下表所示，在下表中的参数组合中组建深度学习模型参数组合，经过 Grid Search 网格搜索法寻找最优参数。本文利用 Python 的 sklearn 库中的 GridSearchCV 函数实现 Grid Search 网格搜索法，GridSearchCV 函数将使用表中的模型参数范围数据执行交叉验证，以评估每一种参数组合的性能并选择最佳参数。以申万一级传媒行业指数为例，最优取值见表 3-4。

中国知网 https://www.cnki.net

表 3-4　LSTM-Informer 模型参数寻优表

参数名称	参数范围	最优取值
seq_len	{1,2,6,12,24,48,96}	12
label_len	{1,2,4,8,16}	16
d_model	{256,512,1024}	512
n_heads	{1,2,4,8,16}	8
e_layers	{0,1,2,3,4,5}	2
dropout	{0.1,0.5,0.01,0.05}	0.05
batch_size	{8,16,32,64}	64
learning_rate	{0.01,0.001,0.0001}	0.001

（3）过拟合控制

过拟合（Overfitting）是指模型在训练数据上表现优异，但在测试或新数据上预测效果较差的现象。这是因为模型学习了训练数据中的噪声或偶然性特征，导致泛化能力下降。过拟合发生的原因是模型过于复杂或训练时间过长。本文控制模型的过拟合是通过优化器和早停机制。

1. 优化器

优化器根据模型在训练数据上的表现（即损失函数的值）来更新模型的权重和偏置。模型使用的学习率（learning_rate）参数是通过优化器传递的，它决定了在每次权重更新时对梯度的缩放程度，即步长大小。本文使用 Adam 优化器，是一种基于梯度下降的算法，其可以自动调整学习率，同时考虑了梯度的一阶矩（均值）和二阶矩（未中心化的方差）。

此外，模型代码中还配置了一个学习率调度器，它根据验证集上的性能来动态调整学习率，帮助模型更有效地收敛。学习率调度器的作用包括性能监控与动态调整学习率，在训练过程中监控模型的性能，如验证集上的损失。如果模型的性能在一定数量的训练周期内没有改善，则学习率会乘以一个 factor 因子，以帮助模型跳出局部最小值或加速收敛。

2. 早停机制

早停机制（Early Stopping）是一种在训练神经网络模型时常用的方法。这种方法的核心思想是在训练过程中监控模型在一组独立的验证数据上的表现，以防止模型过拟合。在训练过程中，会选择一个指标来监控模型在验证集上的表现，常见的

中国知网　https://www.cnki.net

指标有损失函数、准确率等。在每一个训练周期（epoch）结束时，模型会被评估。如果所监控的指标在连续几个周期内没有改进，例如验证损失没有下降，则可以推断出模型已经开始过拟合训练数据。

实现早停机制的关键超模参数是耐心参数（Patience），定义了在停止训练之前模型指标可以连续多少个训练周期没有改善。耐心参数的设置取决于具体的训练动态和数据，太小可能导致模型在达到最优之前就停止训练，太大则可能导致过拟合。在本文中，根据总的训练周期（num_epochs） 计算实际的耐心周期数。在代码中 early_patience 被设置为 0.15，这意味着如果在 15%的训练周期内验证损失没有改善，训练将被终止。early_stop_counter 作为计数器跟踪自上次验证损失改善以来经过的周期数。终止条件为如果连续 early_stop_counter 周期没有改善，则触发早停。

3.2.2 模型预测结果

本文分别利用 LSTM-Informer 深度学习模型进行 1 步、2 步、3 步、5 步预测，代表对未来 1、2、3、5 个交易日收盘价进行预测，以探究深度学习模型在不同预测步长下的泛化能力。LSTM-Informer 模型的预测结果如表 3-5 所示：

表 3-5 LSTM-Informer 模型预测结果

	1 步预测					2 步预测				
行业名称	R^2	RMSE	MAE	MAPE	DA	R^2	RMSE	MAE	MAPE	DA
传媒	0.97	17.12	12.55	2.05	74.93	0.96	18.63	13.84	2.28	75.77
电力设备	0.99	181.50	128.89	1.51	77.31	0.99	207.07	144.43	1.68	73.53
电子	0.96	84.32	61.53	1.64	75.77	0.95	98.23	70.41	1.87	74.09
房地产	0.99	54.96	39.72	1.56	77.17	0.99	62.86	44.73	1.75	73.81
纺织服饰	0.97	23.78	17.17	1.13	72.13	0.96	26.51	18.95	1.25	71.71
钢铁	0.98	37.19	26.97	1.18	74.51	0.98	41.54	29.62	1.30	73.25
公用事业	0.92	28.49	21.19	0.92	73.81	0.91	30.86	23.11	1.01	72.27
国防军工	0.97	28.22	20.54	1.44	77.73	0.96	32.39	23.54	1.65	75.49
环保	0.98	31.54	22.74	1.33	75.21	0.97	35.40	24.56	1.44	72.27
机械设备	0.96	26.29	19.61	1.39	73.67	0.93	32.40	23.21	1.65	73.11
基础化工	0.99	59.79	43.17	1.17	75.91	0.99	68.58	49.69	1.35	76.47
计算机	0.97	109.61	78.64	1.93	77.87	0.97	115.51	82.50	2.02	75.77
家用电器	0.97	108.35	78.86	1.11	75.07	0.96	116.32	83.78	1.18	77.59
建筑材料	0.99	89.30	66.60	1.23	76.61	0.99	101.95	75.87	1.40	75.21
非银金融	0.97	28.43	19.47	1.24	75.35	0.97	30.59	20.76	1.33	74.51
建筑装饰	0.98	31.97	22.97	1.13	73.25	0.97	36.09	25.62	1.26	74.37
交通运输	0.97	27.31	19.64	0.89	74.09	0.96	29.12	20.89	0.94	72.69
煤炭	0.96	49.68	37.91	1.31	75.21	0.95	51.85	39.81	1.38	72.27
美容护理	0.99	105.33	77.49	1.39	76.33	0.99	117.82	85.80	1.55	74.93

中国知网 https://www.cnki.net

续表 3-5　LSTM-Informer 模型预测结果

	1 步预测					2 步预测				
行业名称	R^2	RMSE	MAE	MAPE	DA	R^2	RMSE	MAE	MAPE	DA
农林渔牧	0.99	46.36	34.92	1.17	76.33	0.99	50.90	38.08	1.27	75.77
汽车	0.95	106.28	76.77	1.35	76.05	0.94	119.04	87.13	1.53	74.79
轻工制造	0.98	40.30	29.74	1.40	73.81	0.97	45.36	32.96	1.56	72.27
商贸零售	0.99	46.52	33.04	1.49	73.67	0.99	50.22	36.20	1.63	71.99
社会服务	0.98	178.12	126.17	1.46	70.03	0.98	200.02	142.68	1.65	68.77
石油石化	0.91	33.20	25.12	1.10	77.31	0.89	36.31	27.46	1.21	75.21
食品饮料	0.98	356.07	267.09	1.31	76.75	0.98	406.86	296.03	1.45	75.07
通信	0.98	49.27	35.66	1.55	73.39	0.97	51.11	37.57	1.65	71.85
医药生物	0.98	143.63	103.03	1.24	75.07	0.97	169.41	119.08	1.44	72.41
银行	0.97	41.24	30.55	0.93	77.03	0.97	44.34	32.53	0.99	76.75
有色金属	0.97	90.24	67.99	1.45	73.11	0.96	97.13	73.38	1.57	72.83
综合	0.97	55.49	38.75	1.56	68.77	0.97	62.17	42.82	1.73	67.51
Average	0.97	74.51	54.34	1.34	74.94	0.96	83.44	60.23	1.48	73.69
	3 步预测					5 步预测				
行业名称	R^2	RMSE	MAE	MAPE	DA	R2	RMSE	MAE	MAPE	DA
传媒	0.95	20.32	14.90	2.44	76.33	0.93	24.42	18.01	2.95	69.33
电力设备	0.99	223.22	154.41	1.79	73.39	0.98	263.67	175.75	2.06	73.95
电子	0.94	106.67	74.71	1.99	75.63	0.92	125.61	84.96	2.25	74.93
房地产	0.98	68.67	49.01	1.93	75.49	0.98	83.15	56.98	2.23	75.35
纺织服饰	0.95	28.83	20.39	1.35	70.03	0.93	34.61	23.29	1.55	67.65
钢铁	0.97	44.17	31.59	1.39	73.81	0.96	53.16	37.03	1.63	72.69
公用事业	0.89	33.83	25.50	1.11	73.53	0.86	38.73	29.24	1.27	74.09
国防军工	0.95	35.50	25.03	1.75	75.49	0.93	42.05	28.56	2.00	75.07
环保	0.97	36.69	25.55	1.50	72.83	0.95	45.33	30.40	1.79	71.29
机械设备	0.92	34.76	24.35	1.72	72.69	0.89	41.86	28.72	2.03	72.69
基础化工	0.98	75.52	54.88	1.48	74.23	0.98	90.32	63.38	1.72	74.93
计算机	0.96	131.52	93.53	2.30	77.87	0.94	159.27	109.89	2.70	75.63
家用电器	0.96	124.98	90.99	1.27	77.03	0.93	152.19	104.97	1.47	74.65
建筑材料	0.99	108.31	80.58	1.49	74.51	0.99	132.77	97.87	1.82	75.21
非银金融	0.95	35.38	22.72	1.45	71.99	0.93	43.45	26.29	1.68	74.51
建筑装饰	0.96	39.31	27.55	1.36	73.25	0.95	45.15	31.68	1.57	74.23
交通运输	0.96	30.91	22.43	1.01	71.15	0.94	38.36	26.77	1.21	71.29
煤炭	0.95	55.80	42.60	1.48	70.31	0.94	60.29	46.28	1.61	72.83
美容护理	0.99	131.12	93.49	1.68	75.91	0.98	157.24	105.54	1.91	77.17
农林渔牧	0.98	54.26	40.66	1.36	74.09	0.97	66.22	47.96	1.61	72.97
汽车	0.93	128.24	93.41	1.65	76.19	0.89	153.81	106.91	1.88	77.03
轻工制造	0.97	48.90	35.52	1.68	69.61	0.95	57.71	41.44	1.96	70.03
商贸零售	0.99	52.92	37.90	1.71	71.85	0.98	62.04	44.41	2.00	68.35
社会服务	0.97	249.14	174.73	1.99	69.89	0.96	283.00	192.45	2.20	68.07
石油石化	0.87	39.19	29.34	1.29	73.81	0.82	45.82	33.60	1.48	73.25
食品饮料	0.97	419.19	298.83	1.46	73.81	0.95	558.01	377.71	1.86	72.69
通信	0.96	59.32	41.81	1.82	72.41	0.95	70.18	48.84	2.13	73.95
医药生物	0.97	187.14	132.71	1.60	72.13	0.96	215.43	147.02	1.78	71.71
银行	0.96	48.66	35.68	1.08	74.65	0.95	54.09	39.59	1.20	76.05
有色金属	0.96	103.60	77.46	1.65	71.71	0.94	123.36	92.70	1.98	72.27
综合	0.96	68.37	47.78	1.93	67.65	0.95	78.10	52.50	2.13	66.39
Average	0.96	91.11	65.16	1.60	73.33	0.94	109.66	75.83	1.86	72.91

中国知网 https://www.cnki.net

从表中可以看出，LSTM-Informer 深度学习模型在 1、2、3、5 步预测中都展现出了较好的预测能力，除对石油石化等部分行业的预测效果一般，其余申万一级行业的预测值的R^2的单步与多步预测都能保持在 0.95 左右，说明预测值与真实值能够有较好的拟合；大部分行业的单步与多步预测的 DA 值也保持在 70%以上，说明模型对申万一级行业指数收盘价的趋势有一定的判断能力；各步预测的 MAPE 平均值分别为 1.34%、1.48%、1.60%和 1.86%，处于一个较为合理的区间；各行业预测值的 RMSE 和 MAE 较大，说明模型的预测仍存在误差，并且由于各行业指数收盘价的数量级不尽相同，不同行业之间利用这两个指标进行比较并不合理，因此 RMSE 和 MAE 值用于各模型对不同行业指数不同步数预测的效果对比，对于每个行业模型预测来说，RMSE 和 MAE 值较小的有较好的预测效果。从各指标的平均值来看，单步预测的效果整体优于 2、3、5 步预测，随着预测步数的增加，模型的整体表现趋于下降，R^2值，DA 值趋于减少，RMSE，MAE，MAPE 值趋于增加。

为了进一步验证模型在不同步数上的预测能力，检验单步预测是否显著优于多步预测，本文对 LSTM-Informer 模型的 1 步预测与 2、3、5 步预测做 DM 检验。DM 检验，全称为 Diebold-Mariano 检验，是统计学中用来比较两个或多个预测模型准确性的方法。它由 Francis X. Diebold 和 Roberto S. Mariano 在 1995 年提出，主要用于检验两个预测模型在相同数据集上的预测误差是否存在显著差异，并利用该差异的统计显著性来比较两者的预测精度。

表 3-6　DM 检验结果

	1 VS 2	2 VS 3	3 VS 5		1 VS 2	2 VS 3	3 VS 5
行业名称	DM 值	DM 值	DM 值	行业名称	DM 值	DM 值	DM 值
传媒	-5.72***	-3.66***	-7.95***	交通运输	-2.81***	-2.24**	-4.5***
电力设备	-5.77***	-2.49**	-4.59***	煤炭	-2.8***	-4.04***	-2.97***
电子	-6.4***	-1.77*	-3.52***	美容护理	-3.73***	-2.4**	-2.33**
房地产	-5.62***	-3.64***	-5.26***	农林渔牧	-4.4***	-2.58***	-4.41***
纺织服饰	-5.88***	-3.34***	-4.7***	汽车	-5.69***	-2.77***	-4.34***
钢铁	-5.16***	-2.31**	-4.05***	轻工制造	-5.68***	-3.45***	-5.03***
公用事业	-5.84***	-5.22***	-5.48***	商贸零售	-4.85***	-2.35**	-5.73***
国防军工	-6.31***	-2.59***	-4.65***	社会服务	-4.7***	-5.44***	-4.05***
环保	-5.29***	-1.49	-5.8***	石油石化	-7.52***	-3.54***	-4.8***

中国知网 https://www.cnki.net

续表 3-6　DM 检验结果

	1 VS 2	2 VS 3	3 VS 5		1 VS 2	2 VS 3	3 VS 5
行业名称	DM 值	DM 值	DM 值	行业名称	DM 值	DM 值	DM 值
机械设备	-5.68***	-2.06**	-4.72***	食品饮料	-4.61***	-0.98	-4.7***
基础化工	-6.04***	-3.53***	-4.08***	通信	-1.87*	-2.98***	-4.38***
计算机	-2.48**	-3.0***	-5.02***	医药生物	-5.54***	-2.54**	-2.89***
家用电器	-3.85***	-2.89***	-4.36***	银行	-4.77***	-5.04***	-4.52***
建筑材料	-6.47***	-2.59***	-5.23***	有色金属	-5.49***	-3.27***	-5.98***
非银金融	-1.91*	-2.05**	-2.31**	综合	-5.8***	-4.42***	-4.99***
建筑装饰	-5.46***	-2.92***	-3.97***				

注：*、**、***分别表示在 10%、5%和 1%水平显著。

检验结果见表 3-6。根据 DM 检验结果可知，除非银金融、通信行业指数的 1 步预测结果在 5%的显著性水平上优于 2 步预测，计算机行业的一步预测结果在 10%的显著性水平上优于 2 步预测，其余行业均在 1%的显著性水平上显著，说明基于 LSTM-Informer 模型的 1 步预测显著优于 2 步预测。在 2 步预测与 3 步预测的比较中，环保与食品饮料行业不显著，电子行业在 10%的显著性水平上显著，其余行业均在 5%或 1%的显著性水平上显著，说明绝大部分行业的 2 步预测效果优于 3 步预测。在 3 步预测与 5 步预测的比较中，非银金融、美容护理行业在 5%的显著性水平上显著，其余行业均在 1%的显著性水平上显著，说明 3 步预测效果优于 5 步预测。综上，LSTM-Informer 模型在申万一级行业指数收盘价预测中，1 步预测优于 2 步预测，2 步预测优于 3 步预测，3 步预测优于 5 步预测，与描述性统计分析的结果基本相符。

3.3　稳健性分析

为进一步比较 LSTM-Informer 模型的性能，本文分别构建深度学习模型与机器学习模型与 LSTM-Informer 模型进行对比。本文构建的深度学习模型为 LSTM 模型与 Informer 模型，构建的机器学习模型为 SVM 模型与 KNN 模型。模型的评价指标与前文类似，分别为R^2，RMSE，MAE，MAPE，DA，分别利用各深度学习模型与机器学习模型对 31 个申万一级行业指数进行 1、2、3、5 步预测，得到预测结果与评价指标值，将结果 LSTM-Informer 模型预测结果做对比，得到初步结论，之后将

中国知网　https://www.cnki.net

LSTM-Informer 模型的预测结果与深度学习模型和机器学习模型的结果做 DM 检验，利用统计检验的结果证明 LSTM-Informer 模型的性能。

3.3.1 对比模型的构建

本节分别构 LSTM 与 Informer 两个深度学习模型以及 KNN 与 SVM 两个机器学习模型对申万一级行业指数收盘价分别进行预测分析，与前文预测结果形成对比，以验证 LSTM-Informer 模型在金融时间序列分析领域应用的稳健性。各模型的构建方法如下。

LSTM 深度学习模型的基本原理在前文已经进行介绍，本文参照前文内容构建模型，分别对 31 个申万一级行业指数进行 1、2、3、5 步预测。LSTM 模型的超参数寻优的方法为 Grid Search 网格搜索法，以申万一级传媒指数为例，LSTM 模型的参数寻优范围与寻优结果如表 3-7。所示为防止模型过拟合，参考前文建模方法，为 LSTM 模型加入早停机制。

表 3-7 LSTM 模型参数寻优表

参数名称	参数范围	最优取值
units	{32,64,128,256}	128
l2_lambda	{0.1,0.01,0.001}	0.001
activation	{tanh, relu}	relu
stacked	{True,False}	True
n_layers	{1,2,3}	2
dropout	{0.1,0.5,0.01,0.05}	0.05
batch_size	{8,16,32,64}	64
learning_rate	{0.01,0.001,0.0001}	0.001

Informer 深度学习模型的基本架构与构建方法在前文已经进行介绍，在本节中构建 Informer 模型对 31 个申万一级行业指数进行 1、2、3、5 步预测，参数寻优的方法为 Grid Search 网格搜索法，以申万一级传媒指数为例，Informer 模型的参数寻优范围与寻优结果如表 3-9 所示。为防止模型过拟合，同样为 Informer 模型加入早停机制。

中国知网 https://www.cnki.net

表 3-8　Informer 模型参数寻优表

参数名称	参数范围	最优取值
seq_len	{1,2,6,12,24,48,96}	12
label_len	{1,2,4,8,16}	16
d_model	{256,512,1024}	512
n_heads	{1,2,4,8,16}	8
e_layers	{0,1,2,3,4,5}	2
dropout	{0.1,0.5,0.01,0.05}	0.01
batch_size	{8,16,32,64}	64
learning_rate	{0.01,0.001,0.0001}	0.001

KNN（K-Nearest Neighbors，KNN）算法是一种基本且广泛使用的分类和回归方法。它的工作原理为对于给定的测试数据点，KNN 算法找到训练集中与之最近的 K 个点，然后根据这些邻近点的信息来预测测试点的属性。KNN 机器学习模型的参数寻优方法利用 Grid Search 网格搜索法，参数寻优范围与最优取值见表 3-11。

表 3-9　KNN 模型参数寻优表

参数名称	参数范围	最优取值
n_neighbors	{3, 5, 7, 10, 15}	10
weights	{uniform, distance}	uniform
metric	{euclidean, manhattan, minkowski}	manhattan
p	{1,2}	2
leaf_size	{10, 20, 30, 40}	20

支持向量机（Support Vector Machine，SVM）是属于监督学习模型，其基本思想是构造一个超平面来区分不同的类别，并使得到超平面的最近的训练数据点的距离,即边界或间隔尽可能大。超平面的构建仅依赖于那些最靠近超平面的点，这些点被称为支持向量。当数据非线性可分的时候，SVM 可以通过核技巧将数据映射到更高维的空间中，以找到一个能有效分隔数据的超平面。SVM 机器学习模型的参数寻优方法利用 Grid Search 网格搜索法，参数寻优范围与最优取值见表 3-13。为防止机器模型产生过拟合，为 SVM 模型与 KNN 模型都加入早停机制。

表 3-10 SVM 模型参数寻优表

参数名称	参数范围	最优取值
C	{1, 10, 100}	10
kernel	{linear, rbf, sigmoid}	rbf
degree	{1, 2, 3, 4, 5}	5
gamma	{scale, auto}	scale
tol	{0.001, 0.0001, 0.00001}	0.001

中国知网　https://www.cnki.net

3.3.2 预测结果对比分析与统计检验

各模型对31个申万一级行业指数收盘价预测结果的评价指标均值如表3-11所示。

表3-11 模型预测结果评价

	1步预测					2步预测				
模型名称	R^2	RMSE	MAE	MAPE	DA	R^2	RMSE	MAE	MAPE	DA
LSTM-Informer	0.97	74.51	54.24	1.34	74.94	0.96	83.44	60.23	1.48	79.69
Informer	0.96	85.02	61.85	1.52	59.22	0.95	100.48	72.61	1.74	57.57
LSTM	0.95	113.24	90.57	2.06	79.78	0.90	150.09	114.12	2.68	49.64
SVM	0.89	383.23	306.10	4.06	67.55	0.69	491.99	390.92	6.10	49.55
KNN	0.74	625.92	467.57	5.77	50.84	0.62	694.82	569.05	6.9	50.25
	3步预测					5步预测				
模型名称	R^2	RMSE	MAE	MAPE	DA	R^2	RMSE	MAE	MAPE	DA
LSTM-Informer	0.96	91.11	65.16	1.60	73.33	0.94	109.66	75.83	1.86	72.91
Informer	0.94	107.10	76.37	1.90	59.05	0.92	123.18	85.99	2.03	58.81
LSTM	0.88	161.01	118.04	2.74	49.64	0.85	193.05	144.13	3.23	49.86
SVM	0.66	501.78	399.51	6.30	50.16	0.61	517.8974	412.4603	6.68	49.63
KNN	0.60	705.14	578.06	7.10	49.69	0.56	721.1761	592.6429	7.48	50.57

LSTM深度学习模型在一步和两步预测中也展现出了较好的预测能力，31个申万一级行业指数预测的R^2平均值在0.9以上，这表明LSTM模型的一步和两步预测有较好的拟合效果，从DA值也可以看出，LSTM模型对申万一级行业指数的趋势判断也有较好表现，在部分行业的趋势预测能力甚至优于LSTM-Informer模型。但LSTM在三步和五步预测的效果下降较快，大多数行业R^2下降至0.9以下，其余评价指标均有下降，在多步预测过程中整体表现不如LSTM-Informer模型。

Informer模型的预测表现相对比较稳定，与LSTM模型相比，虽然各评价指标也随预测步数的增加而降低，但降低幅度相对较小。除DA指标以外，其余四个评价指标与LSTM-Informer模型接近，说明模型对申万一级行业指数拟合预测效果较好。但从DA指标来看，Informer模型的趋势判断能力不如LSTM-Informer模型。

KNN与SVM模型在一步预测中具有一定的效果，但不如深度学习学习模型LSTM与Informer，更不如LSTM-Informer模型的效果。机器学习模型的一步预测结果的R^2仅有部分能达到0.9以上，部分申万一级行业指数还出现R^2为负的情况，这说明发生了欠拟合的情况，即便使用网格搜索法也没有寻找到最优参数组合。随着预测步数的增加，机器学习模型的预测效果下降较为迅速，绝大部分行业预测值的R^2都下降到0.9以下，在多步预测中，机器学习模型的预测效果更不如深度学习模型，也

中国知网 https://www.cnki.net

明显不如 LSTM-Informer 模型。

综上所述，从指标的具体数值来看，LSTM-Informer 模型效果最好，在多步预测中也能保持模型效果。深度学习模型行中，LSTM 模型在单步预测中有较好效果，对申万一级行业指数的收盘价趋势有较好判断；Informer 模型的预测效果在不同的预测步长中均有稳定表现。机器学习模型 KNN，SVM 模型在单步预测中有一定效果，但整体不如深度学习模型，并且在对部分行业指数进行预测中出现了欠拟合情况，在多步预测中，机器学习模型表现下降较快。为了进一步探究 LSTM-Informer 模型是否显著优于所构建的对比模型，本节对预测结果做 DM 检验，以说明 LSTM-Informer 模型的优越性。

表 3-12　DM 检验结果

LSTM-Informer VS	行业名称	1步预测	2步预测	3步预测	5步预测	行业名称	1步预测	2步预测	3步预测	5步预测
		DM值	DM值	DM值	DM值		DM值	DM值	DM值	DM值
LSTM	传媒	-0.83	-3.32***	-3.63***	-5.89***	交通运输	-2.29**	-7.94***	-8.21***	-8.41***
KNN		-4.28***	-16.99***	-17.71***	-16.82***		-5.1***	-11.81***	-10.89***	-10.57***
SVM		-5.25***	-5.9***	-6.22***	-6.18***		-6.68***	-7.64***	-7.95***	-8.54***
Informer		2.82***	-3.74***	-3.84***	-4.11***		-4.59***	-6.67***	-6.7***	-4.83***
LSTM	电力设备	-16.08***	-10.9***	-13.6***	-13.05***	煤炭	1.08	-13.27***	-13.87***	-14.21***
KNN		-15.95***	-21.32***	-21.65***	-22.29***		-7.49***	-15.06***	-14.26***	-14.17***
SVM		-15.32***	-20.97***	-21.18***	-21.49***		-9.0***	-10.08***	-10.15***	-11.97***
Informer		-5.51***	-7.35***	-7.38***	-8.19***		-8.21***	-8.38***	-9.59***	-8.62***
LSTM	电子	-8.24***	-6.52***	-9.75***	-6.97***	美容护理	-9.41***	-9.35***	-5.66***	-9.31***
KNN		-7.25***	-8.79***	-8.77***	-8.87***		-12.1***	-10.57***	-10.74***	-10.89***
SVM		-4.39***	-7.88***	-7.97***	-8.16***		-8.51***	-20.62***	-20.67***	-20.81***
Informer		-5.83***	-2.73***	-3.94***	-4.13***		-3.57***	-4.79***	-5.15***	-8.23***
LSTM	房地产	-18.65***	-21.7***	-13.7***	-18.5***	农林渔牧	-8.1***	-13.02***	-10.07***	-15.18***
KNN		-11.93***	-14.81***	-14.61***	-14.11***		-2.27**	-11.45***	-11.01***	-11.77***
SVM		-11.08***	-11.35***	-11.47***	-11.46***		-5.62***	-5.96***	-6.6***	-6.41***
Informer		-5.36***	-7.11***	-5.13***	-2.73***		-4.28***	-6.75***	-8.88***	-4.92***
LSTM	纺织服饰	-2.43**	-8.71***	-10.44***	-10.99***	汽车	-2.1**	-9.44***	-10.05***	-7.71***
KNN		-7.93***	-13.21***	-13.39***	-12.5***		-11.18***	-12.49***	-12.73***	-13.34***
SVM		-4.85***	-4.88***	-5.11***	-5.01***		-0.81	-12.77***	-12.91***	-12.66***
Informer		-5.38***	-5.21***	-5.01***	-5.48***		-6.17***	-6.98***	-8.66***	-8.9***
LSTM	钢铁	-0.89	-6.01***	-6.71***	-6.03***	轻工制造	-0.61	-6.37***	-5.15***	-5.19***
KNN		-4.15***	-9.14***	-9.7***	-9.35***		-6.23***	-15.18***	-14.67***	-14.11***
SVM		-8.33***	-6.11***	-6.47***	-6.7***		-3.19***	-3.74***	-4.24***	-4.86***
Informer		-5.83***	-3.78***	-5.33***	-3.42***		-3.42***	-3.19***	-3.27***	-5.15***
LSTM	公用事业	2.33**	-6.78***	-7.31***	-6.79***	商贸零售	-20.3***	-16.43***	-7.36***	-10.29***
KNN		-4.48***	-16.99***	-15.81***	-15.27***		-18.25***	-19.29***	-19.39***	-19.52***
SVM		-5.56***	-7.08***	-8.39***	-8.82***		-13.54***	-15.83***	-15.88***	-15.9***
Informer		-3.64***	-6.19***	-5.48***	-4.23***		-3.67***	-3.46***	-6.08***	-5.59***
LSTM	国防军工	-6.39***	-6.41***	-8.47***	-8.35***	社会服务	-13.43***	-14.68***	-12.85***	-12.61***
KNN		-5.24***	-11.16***	-12.12***	-12.82***		-28.86***	-34.09***	-34.15***	-34.44***
SVM		-8.6***	-1.78*	-3.09***	-3.92***		-30.24***	-31.64***	-31.81***	-32.13***
Informer		-5.33***	-5.24***	-3.95***	-4.14***		-4.62***	-6.72***	-2.27**	1.14

中国知网 https://www.cnki.net

续表 3-12　DM 检验结果

LSTM-Informer VS	行业名称	1步预测	2步预测	3步预测	5步预测	行业名称	1步预测	2步预测	3步预测	5步预测
		DM值	DM值	DM值	DM值		DM值	DM值	DM值	DM值
LSTM	环保	-5.62***	-8.42***	-7.11***	-8.26***	石油石化	7.73***	-8.35***	-6.86***	-7.62***
KNN		-5.77***	-19.62***	-19.83***	-19.2***		-5.84***	-11.86***	-11.35***	-11.84***
SVM		-10.56***	-7.33***	-7.48***	-7.79***		-8.42***	-6.62***	-7.34***	-8.63***
Informer		-2.14**	-5.25***	-5.47***	-3.39***		-7.61***	-7.41***	-7.61***	-3.93***
LSTM	机械设备	-3.48***	-4.54***	-3.76***	-2.72***	食品饮料	-16.64***	-7.27***	-7.31***	-9.84***
KNN		-4.05***	-8.42***	-9.68***	-10.25***		-28.68***	-25.88***	-25.89***	-25.5***
SVM		-5.1***	-0.21	-1.32	-0.97		-25.83***	-38.11***	-38.22***	-38.35***
Informer		-4.93***	-2.26**	-5.0***	-2.36**		-4.01***	-5.26***	-7.25***	-5.1***
LSTM	基础化工	-12.77***	-12.4***	-15.76***	-17.35***	通信	-1.98**	-6.33***	-8.29***	-6.73***
KNN		-20.07***	-22.26***	-22.32***	-21.98***		-2.52**	-8.12***	-9.26***	-9.06***
SVM		-17.87***	-18.1***	-18.21***	-18.44***		-4.53***	-2.64***	-2.88***	-3.55***
Informer		-6.06***	-4.13***	-5.9***	-3.83***		-5.43***	-6.69***	-5.36***	-5.89***
LSTM	计算机	-3.17***	-7.88***	-8.45***	-8.11***	医药生物	-3.53***	-11.33***	-9.65***	-10.34***
KNN		-5.38***	-11.82***	-12.44***	-10.27***		-9.19***	-10.84***	-11.17***	-12.85***
SVM		-2.49**	-2.55**	-2.64***	-1.8*		-16.66***	-9.14***	-9.34***	-9.72***
Informer		-2.11**	-6.18***	-2.89***	-3.44***		-6.47***	-4.3***	-4.78***	-4.54***
LSTM	家用电器	-8.16***	-6.57***	-8.98***	-10.62***	银行	-7.51***	-8.47***	-5.59***	-6.58***
KNN		-8.11***	-9.95***	-10.05***	-9.5***		-4.04***	-10.2***	-9.36***	-10.21***
SVM		-8.99***	-7.83***	-7.84***	-8.02***		-4.7***	-5.19***	-5.54***	-6.51***
Informer		-4.29***	-5.66***	-5.16***	-4.36***		-5.85***	-5.68***	-5.6***	-5.51***
LSTM	建筑材料	-2.05**	-9.76***	-7.85***	-10.28***	有色金属	-2.7***	-14.13***	-11.43***	-10.7***
KNN		-6.36***	-8.93***	-9.21***	-9.59***		-3.69***	-10.24***	-10.17***	-10.0***
SVM		-8.9***	-8.92***	-8.93***	-9.02***		-10.52***	-10.1***	-10.21***	-10.44***
Informer		-5.1***	-6.69***	-7.04***	-5.34***		-7.54***	-7.53***	-7.42***	-7.09***
LSTM	非银金融	-2.36**	-8.61***	-9.04***	-7.57***	综合	-7.27***	-3.52***	-2.86***	-3.32***
KNN		-5.91***	-12.0***	-9.46***	-9.84***		-3.76***	-11.6***	-12.0***	-12.03***
SVM		-3.12***	-3.88***	-4.22***	-4.56***		-0.91	-0.93	-0.9	-1.88*
Informer		-1.09	-6.78***	-3.77***	-6.51***		-0.49	-1.66*	0.26	-3.03***
LSTM	建筑装饰	-6.0***	-9.59***	-9.45***	-9.19***					
KNN		-2.76***	-12.97***	-13.38***	-12.24***					
SVM		-10.8***	-9.93***	-8.88***	-8.72***					
Informer		-4.97***	-7.61***	-6.12***	-4.84***					

注：*、**、***分别表示在 10%、5%和 1%水平显著。

从表 3-12 中可以观察到，LSTM-Informer 模型在单步预测值，大部分优于对比机器学习模型与深度学习模型，仅有在部分行业的预测中优势并不显著。随着预测步数的增加，显著性也趋于上升，在五步预测中，绝大部分的对比都在 10%的显著性水平上显著。说明 LSTM-Informer 模型对申万一级行业指数收盘价的预测效果最好，且随着预测步数的增加，模型的预测性能将保持优越性。

在 1 步预测中，LSTM-Informer 模型在对大部分行业收盘价预测效果显著优于其他对比模型，但在对传媒与钢铁行业的预测效果相较 LSTM 模型优势不明显，对传媒行业收盘价的预测效果不如 Informer 模型，对汽车、综合、非银金融行业的收盘

中国知网 https://www.cnki.net

价预测没有显著优势。整体而言，深度学习模型的 DM 统计量的绝对值小于机器学习模型，说明深度学习模型的预测效果更好。

在 2 步和 3 步预测中，DM 统计量的绝对值逐渐增大，显著性逐渐增加，说明对比模型的预测效果与 LSTM-Informer 模型的预测效果之间的差距逐渐扩大。除综合、机械设备行业外，LSTM-Informer 模型对收盘价的预测均显著优于其他对比模型。Informer 模型在对传媒行业进行 1 步预测中优于 LSTM-Informer 模型，但在 2 步、3 步预测中，LSTM-Informer 模型在 1%的显著性水平下优于 Informer 模型。这说明对比模型随着预测步数的增加预测效果出现下滑，而 LSTM-Informer 模型能够稳定执行预测。

在 5 步预测中，DM 统计量的绝对值继续增加，且显著性水平提升。通过对比发现，Informer 模型的预测效果虽然不如 LSTM-Informer 模型，但 DM 统计量波动不大，说明 Informer 模型在多步预测中保持稳定。LSTM 模型效果不如 Infomer 模型，DM 值较大，但相比机器学习模型预测效果较好。机器学习模型在 5 步预测中显著弱于 LSTM-Informer 模型。通过 DM 检验发现，相较于对比模型，LSTM-Informer 模型在 1、2、3、5 步预测中的优势显著，在多步预测中具有稳健性，预测优势随着预测步数的增加而提升。

中国知网 https://www.cnki.net

4 基于 LSTM-Informer 模型的行业轮动策略构建

本章首先利用描述性统计分析与聚类分析验证申万一级行业指数存在行业轮动现象，以证明利用申万一级行业指数的区间收益率构建行业轮动策略的可行性。之后根据 LSTM-Informer 模型的预测结果构建行业轮动量化交易策略，本文分别构建调仓周期为 1 日，2 日，3 日，5 日的行业轮动策略，将分别利用 LSTM-Informer 模型的 1、2、3、5 步预测的结果计算 1 日、2 日、5 日内的收益率，根据收益率情况进行排序得到强势行业，在每个周期上持仓强势行业。由于申万一级行业指数不能直接交易，本节筛选出与行业指数最为相关的行业 ETF 为交易对象。对不同轮动周期上的策略进行对比分析，并对策略进行稳健性检验。

4.1 行业轮动现象的存在性检验

4.1.1 行业轮动现象的描述性统计分析

行业轮动现象在资本市场的表现为在一定区间内，不同行业的相关金融资产交替涨跌，一些行业表现出上涨趋势，而另一些行业则表现为下跌，在市场运行一段时间之后，之前上涨的行业出现反转，而下跌的行业开始反弹。本文以半年为一个周期划分回测区间，利用申万一级行业指数的收盘价计算区间累计收益率，根据区间累计收益率反映行业在一定周期内的涨跌幅大小。申万一级行业指数在不同周期下的收益率排序如表 4-1 所示。

分别将六个区间内各行业指数累计收益率进行排序，分别将收益率最高与收益率最低的五个行业标为红色和绿色，可以看出各行业在回测周期存在交替涨跌现象。

表 4-1 行业区间收益率排名表

	2022.1-2022.6		2022.7-2022.12		2023.1-2023.6		2023.7-2023.12		2024.1-2024.6		2024.7-2024.12	
行业名称	收益率（%）	排名	收益率（%）	排名	收益率（%）	排名	收益率（%）	排名	收益率（%）	排名	收益率（%）	排名
传媒	-22.47	31	-7.14	14	42.78	2	-20.76	29	-21.81	27	34.94	6
电力设备	-1.44	3	-20.55	30	-4.91	18	-24.02	31	-15.59	21	24.41	10
电子	-21.53	29	-15.45	27	8.63	7	-5.96	10	-10.67	13	36.19	5
房地产	-7.87	15	-9.19	19	-14.77	30	-14.12	24	-19.73	24	25.09	9
纺织服饰	-14.53	24	-5.02	7	1.57	12	-4.53	6	-16.74	23	14.25	20

中国知网 https://www.cnki.net

续表 4-1　行业区间收益率排名表

	2022.1-2022.6		2022.7-2022.12		2023.1-2023.6		2023.7-2023.12		2024.1-2024.6		2024.7-2024.12	
行业名称	收益率（%）	排名	收益率（%）	排名	收益率（%）	排名	收益率（%）	排名	收益率（%）	排名	收益率（%）	排名
钢铁	-14.29	23	-8.82	18	0.22	13	-3.61	3	-7.37	10	48.33	3
公用事业	-12.73	20	-12.22	24	-5.26	19	-4.79	9	-10.62	12	14.4	19
国防军工	-6.54	12	-6.76	12	7.05	8	-7.94	15	9.57	3	-0.78	30
环保	-13.04	21	-6.76	13	5.02	10	-14.12	23	-13.14	15	22.08	14
机械设备	-16.29	27	-8.73	17	-0.03	14	-9.01	18	-15.94	22	22.29	13
基础化工	-14.68	25	-6.65	9	12.04	5	-10.67	20	-14.42	20	23.71	11
计算机	-5.84	11	-13.63	25	-9.59	25	-8.26	16	-12.4	14	10.5	24
家用电器	-22.14	30	-3.17	4	26.26	3	-16.34	26	-24.59	30	45.63	4
建筑材料	-14.15	22	-11.04	22	13.48	4	-9.43	19	7.72	4	17.19	17
非银金融	-8.39	16	-20.62	31	-10.67	28	-13.93	22	-13.84	18	11.14	21
建筑装饰	-4.7	9	-9.54	21	8.87	6	-14.37	25	-9.43	11	17.42	16
交通运输	-3.15	6	-3.7	5	-8.34	23	-8.81	17	1.8	6	10.7	23
煤炭	28.54	1	-14.76	26	-6.07	20	8.52	1	10.35	2	-6.24	31
美容护理	-0.67	2	-5.02	8	-14.37	29	-21.3	30	-13.73	17	6.93	26
农林渔牧	-8.54	17	-8.09	15	-9.99	26	-4.76	8	-13.42	16	3.1	27
汽车	-1.7	4	-17.03	28	4.91	11	-4.4	5	-4.86	9	22.51	12
轻工制造	-16.59	28	-6.69	11	-2.48	15	-6.71	12	-19.95	25	19.54	15
商贸零售	-4.94	10	-3.17	3	-24.02	31	-10.76	21	-24.55	29	53.2	2
社会服务	-6.86	13	3.4	2	-8.1	22	-16.58	27	-24.32	28	28	8
石油石化	-9.16	18	-9.3	20	5.85	9	-3.93	4	5.85	5	-0.43	29
食品饮料	-3.6	7	-11.64	23	-8.65	24	-6.79	13	-14.06	19	8.62	25
通信	-11.25	19	-4.41	6	47.35	1	-18.31	28	1.3	7	28.29	7
医药生物	-14.86	26	-6.68	10	-6.82	21	-2.83	2	-20.71	26	10.83	22
银行	-7.26	14	-8.64	16	-3.31	16	-6.4	11	17.32	1	16.02	18
有色金属	-2.52	5	-17.21	29	-4.07	17	-7.08	14	0.65	8	2.41	28
综合	-3.7	8	11.99	1	-10.3	27	-4.6	7	-33.99	31	58.14	1

以电力设备行业为例，在 2022 年 1 月至 2022 年 6 月，其累计收益率在 31 个行业中排名第三，而在 2022 年 7 月至 2022 年 12 月排名倒数第二；传媒行业在 2022 年 1 月至 6 月表现不佳，但在 2022 年 7 月至 12 月呈现上涨趋势，在 2023 年 1 月至 6 月的涨幅达到 42.78%，在 31 个行业中排名第二，但在之后的两个区间内表现均不佳，排名分别为 29 名和 27 名。整体来看，在回测区间内，不存在某个行业能够一直保持正向收益，也不存在某个行业持续下跌。一些行业在某个区间上涨幅出色，在之后的区间很有可能剧烈下跌。如综合行业，在 2022 年 7 月至 12 月的累计收益率为 11.99%排名第一，但在之后的两个区间内分别下跌了 10.3%和 33.99%。而一些

中国知网 https://www.cnki.net

表现不佳的行业在之后的区间内也会转亏为盈。从表中可以看到，表现最好的行业与表现最差的行业在每个区间内不尽相同，呈现出不同的行业交替涨跌的状态，说明申万一级行业指数存在行业轮动现象。

4.1.2 行业轮动现象的聚类分析

本文利用聚类分析实证检验行业轮动现象的存在性。聚类是将数据对象归类为不同类别或簇的过程，其核心思想在于距离准则和相似度准则，对物理实体或抽象目标进行合并或分割。在这一过程中，聚类旨在最小化同一类内部的距离，同时最大化不同类别之间的距离，从而优化数据的组织结构和可解释性。参照前文将回测周期划分为六个区间，在每个区间上根据不同行业的区间收益率做聚类，以判断不同行业在上涨和下跌过程中的联系。聚类分析的步骤如下：首先对数据进行处理。采用标准化方法对所有变量进行一致化处理，以消除量纲的影响。其次，计算日收益率相关系数的均值。对每一个研究区间内 31 个行业求出每个行业与其他行业日收益率相关系数的均值。选择能够反映行业间股价相关性强弱的日收益率相关系数的均值作为变量，从而增强聚类结果的说服力。最后设置聚类参数。采用的聚类方法为组间连接方式，运用系统聚类分析中的 Q 型聚类方法，度量标准为区间欧式距离，聚类结果如图 4-1 所示。

各时期树状图的横轴表示聚类距离，纵轴展示行业分类，分支颜色差异反映簇内相似性水平。结果显示，行业聚类结构呈现显著的阶段性重构，具体表现为以下特征：在 2022 年 6 月至 12 月中，食品饮料、家用电器等与周期类行业（钢铁、煤炭）形成稳定簇群，聚类距离阈值维持在 18-22 区间，显示宏观经济周期主导的行业关联逻辑。然而，2023 年 1-6 月的树状图出现显著分化，科技类行业（电子、计算机）从原有簇群剥离，形成独立紫色分支，其簇内距离降至 12.5。至 2024 年下半年，聚类结构进一步复杂化：新能源相关行业（电力设备、汽车）与传统能源（煤炭、石油石化）跨越原始分类界限，在距离阈值 25 处融合为混合簇群。

中国知网 https://www.cnki.net

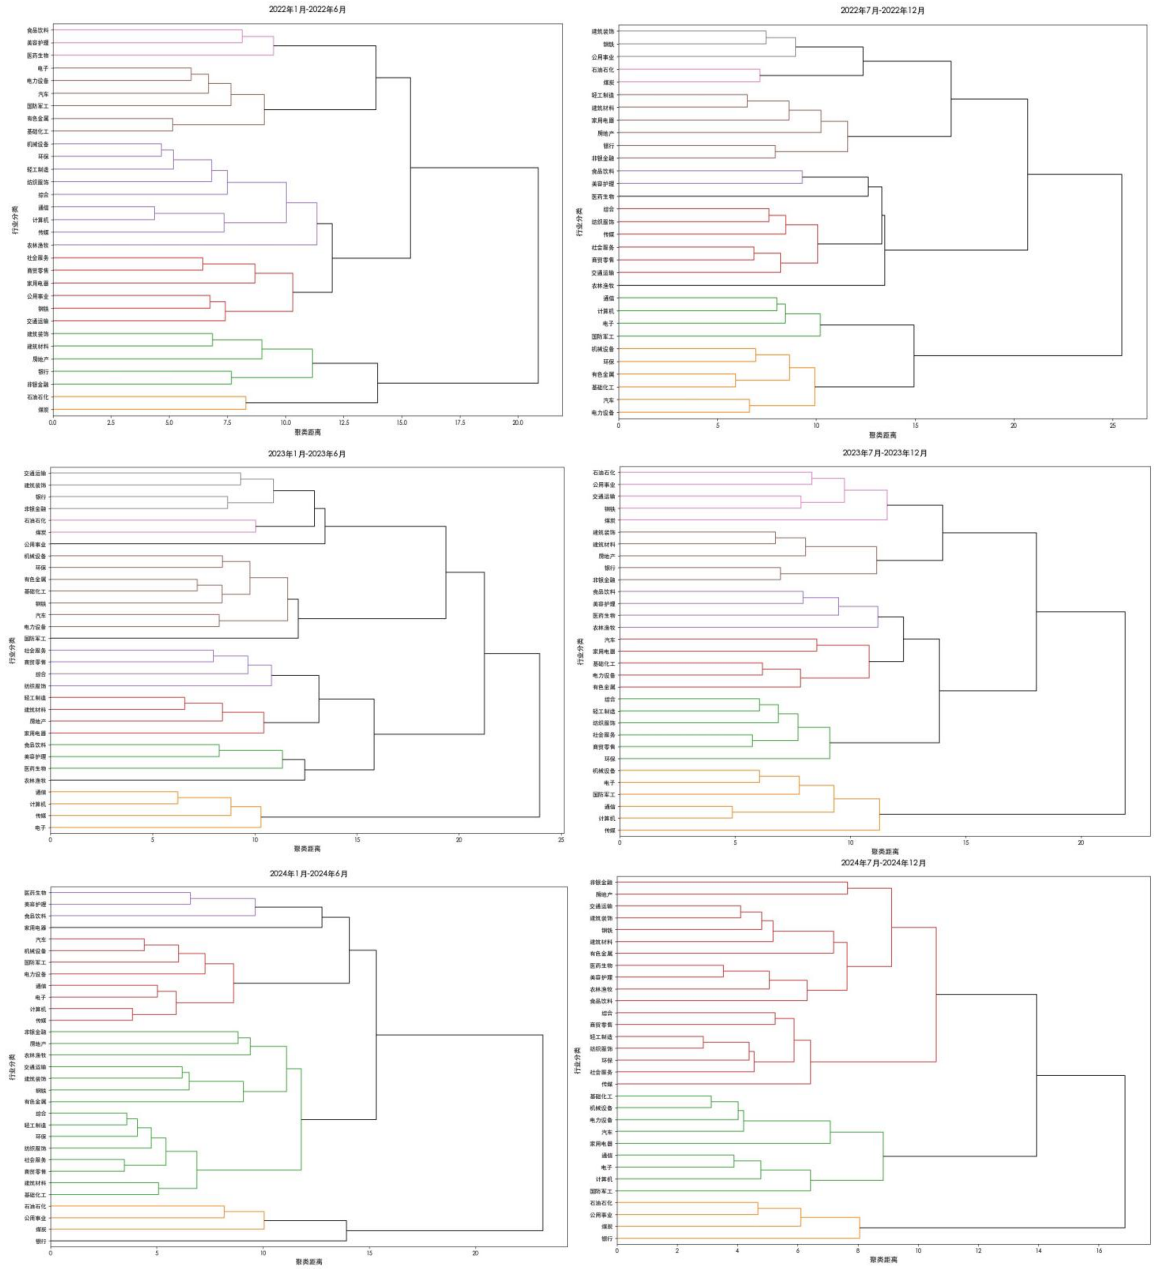


图 4-1　聚类结果图

跨期对比发现，行业簇群的持续性呈现不对称特征。医药生物行业在 2023 年 7 至 12 月与公用事业形成距离阈值 15.3 的稳定簇，但在 2024 年同期转为与传媒、计算机行业联动距离阈值为 19.8，显示其产业驱动逻辑从防御属性向科技创新属性迁移。金融类行业的聚类轨迹更具典型性：银行与非银金融在 2022 年紧密聚合，其距离阈值为 10.5，但随着地产政策调整，2024 年下半年的树状图中，非银金融与建筑装饰行业形成新簇（红色分支，距离阈值 17.2），而银行则独立于主要簇群之外，

中国知网　https://www.cnki.net

印证了金融行业内部的分化趋势。上述动态聚类特征为行业轮动现象提供了结构层面的证据，根据区间收益率进行聚类的结果显示，行业在不同区间下的涨跌情况不同，在回测周期中，不同的行业交替涨跌，收益率呈现轮动状态，说明申万一级行业中存在轮动的现象。除此之外，行业之间的关联性呈动态变化趋势，每个区间内的聚类结果有所不同，说明在不同的时间节点下，行业收益表现之间的关联性有所不同，“齐涨齐跌”的板块在动态变化，依据经济周期或者某几个行业的表现去推断其他行业的走势是不可靠的，因此对不同行业的未来趋势做出精确判断是构建有效交易策略的重要依据。前文中构建的 LSTM-Informer 模型能够对申万一级行业指数收盘价进行预测，根据预测结果判断各行业的区间收益率并生成交易信号，有助于提升行业轮动策略的科学性与稳健性。

4.2 量化策略的构建与回测

4.2.1 行业轮动策略设计方案

基于 LSTM-Informer 模型的行业轮动策略的构建方法如下：分别构建基于 1 日、2 日、3 日、5 日的行业轮动策略，根据 LSTM-Informer 模型的预测结果，计算 31 个申万一级行业指数 1 日、2 日、3 日、5 日的收益率，以 2 日的行业轮动策略为例，在第 n 个交易日，LSTM-Informer 模型预测出第 n+1 交易日，第 n+2 交易日的收盘价，2 日收益率计算公式为：

$$\frac{Close_{n+2} - Close_{n+1}}{Close_{n+1}} \qquad (4-1)$$

Close 代表申万一级行业指数第 n 交易日预测的未来两交易日收盘价，得到未来两日收益率预测结果后，对 31 个行业的收益率进行排序，得到收益率最大的五个行业。在第 n 交易日得到排序结果后，在第 n+1 交易日等权持有 5 个收益率最大的申万一级行业相关资产，在 n+2 日收盘时卖出，以此类推。3 日、5 日的行业轮动交易策略思路与之类似，2 日的行业轮动策略每 2 个交易日进行一次调仓；3 日的行业轮动策略每 3 个交易日进行一次调仓；5 日的行业轮动策略每 5 个交易日进行一次调仓，2 日、3 日、5 日行业轮动策略分别利用 LSTM-Informer 模型的 2 步、3 步、5 步的预

中国知网 https://www.cnki.net

测值计算预测收益率。1 日的行业轮动策略构建思路与 2 日、3 日、5 日类似，但由于第 n 交易日在收盘后才能预测第 n+1 交易日，这时第 n 交易日已经收盘无法交易，因此本文构建 1 日行业轮动策略思路如下：在第 n 交易日利用 LSTM-Informer 模型分别预测 31 个申万一级行业指数第 n+1 交易日的开盘价和收盘价，利用预测的收盘价与开盘价计算各申万一级行业指数的日内收益率并进行排序，得到收益率最大的五个行业，在 n+1 交易日开盘时等权持有这 5 个行业的相关资产，在收盘时卖出，以此类推。日内收益率的计算公式如下：

$$\frac{Close_{n+1} - Open_{n+1}}{Open_{n+1}} \qquad (4-2)$$

Close 和 *Open* 分别代表第 n 交易日预测的未来一交易日申万一级行业指数收盘价预测值与开盘价预测值。这里需要说明的是，由于交易规则所限，本文所筛选 ETF 无法执行 T+0 交易，即使在开盘时买入，在当日收盘时也无法卖出，因此 1 日行业轮动交易的回测仅是在理论层面上进行的，2、3、5 日行业轮动交易在实际的交易中是可行的，构建 1 日轮动策略回测的目的是对比模型的在不同步数上的预测结果对策略的影响，进而将行业轮动策略结论推广到诸如美国市场、香港地区市场等其他可以进行 T+0 交易的资本市场中。

由于申万一级行业指数无法直接交易，利用申万一级行业指数的区间收益率作为轮动条件后，在实际交易中还需要交易申万一级行业指数相关资产来实现策略。本文选择与行业相关的 ETF 作为交易标的。但由于上市 ETF 较多，每个行业内部也有较多的 ETF，因此需要对 ETF 进行筛选，得到与申万一级行业指数最为相关的 ETF 作为行业 ETF。本文利用 Spearman 相关和 Person 相关作为筛选依据，Spearman 相关系数和 Person 相关系数的计算公式如下：

$$\rho = 1 - \frac{6 \cdot \sum_{i=1}^{n} {d_i}^2}{n(n^2-1)} \qquad (4-3)$$

其中ρ代表 Spearman 相关系数，d_i代表两个变量的秩次之差。

$$r = \frac{Cov(x,y)}{\sigma x \cdot \sigma y} \qquad (4-4)$$

其中 *Cov* 代表两个变量的协方差计算，σ代表变量序列标准差计算。

中国知网 https://www.cnki.net

在计算 Spearman 相关系数和 Person 相关系数后，选择 Spearman 相关系数和 Person 相关系数最大的，以及资金规模相对最大的 ETF 作为行业 ETF，若判断在一定时期某几个行业较为强势，就按照前文行业轮动策略流程，轮动交易行业 ETF。各申万一级行业指数的行业 ETF 如表 4-2 所示：

表 4-2　行业 ETF 名称

行业名称	ETF 代码	Pearson 系数	Spearman 系数	行业 ETF 名称
传媒	512980.SH	0.9815	0.9777	传媒 ETF
电力设备	561910.SH	0.9943	0.9976	电池 ETF
电子	159997.SZ	0.9791	0.9661	电子 ETF
房地产	515060.SH	0.9972	0.9972	房地产 ETF
纺织服饰	516560.SH	0.9057	0.8734	养老 ETF
钢铁	515210.SH	0.9922	0.9911	钢铁 ETF
公用事业	159611.SZ	0.6873	0.7897	电力 ETF
国防军工	512560.SH	0.9921	0.9902	军工 ETF
环保	517330.SH	0.9561	0.9604	长江保护 ETF
机械设备	562500.SH	0.9593	0.9428	机器人 ETF
基础化工	159870.SZ	0.9821	0.9806	化工 ETF
计算机	515400.SH	0.9811	0.9893	大数据 ETF
家用电器	159996.SZ	0.9709	0.9545	家电 ETF
建筑材料	159745.SZ	0.9432	0.9327	建材 ETF
非银金融	159993.SZ	0.9884	0.9768	证券 ETF 龙头
建筑装饰	516970.SH	0.9444	0.9546	基建 50ETF
交通运输	516910.SH	0.9414	0.9275	物流 ETF
美容护理	159736.SZ	0.9615	0.9610	饮食 ETF
农林渔牧	159865.SZ	0.9944	0.9929	养殖 ETF
汽车	516110.SH	0.9129	0.8763	汽车 ETF
轻工制造	516560.SH	0.9534	0.9262	养老 ETF
商贸零售	159766.SZ	/	0.9500	旅游 ETF
社会服务	562510.SH	0.9323	0.9355	旅游 ETF
食品饮料	515170.SH	0.9940	0.9944	食品饮料 ETF
通信	515880.SH	0.9583	0.9450	通信 ETF
煤炭	159945.SZ	0.6631	0.6111	能源 ETF
石油石化	510270.SH	0.7194	0.7279	国企 ETF
医药生物	159929.SZ	0.9905	0.9898	医药 ETF
有色金属	512400.SH	0.9953	0.9947	有色金属 ETF
银行	512800.SH	0.8218	0.8469	银行 ETF
综合	159766.SZ	0.8331	0.8596	旅游 ETF

中国知网 https://www.cnki.net

由于煤炭、石油石化行业所筛选出的行业 ETF 两个相关系数都较低，都低于 0.75，与其他行业 ETF 相比，其与申万一级煤炭、石油石化指数的相关性较差。除此之外，申万一级综合指数所筛选出的 ETF 与商贸零售行业重复，都为 159766.SZ，但其与申万一级综合指数的相关性不如其与商贸零售的相关高。因此在执行行业轮动策略时，将煤炭、石油石化、综合行业剔除。行业轮动策略交易流程如图 4-2 所示。

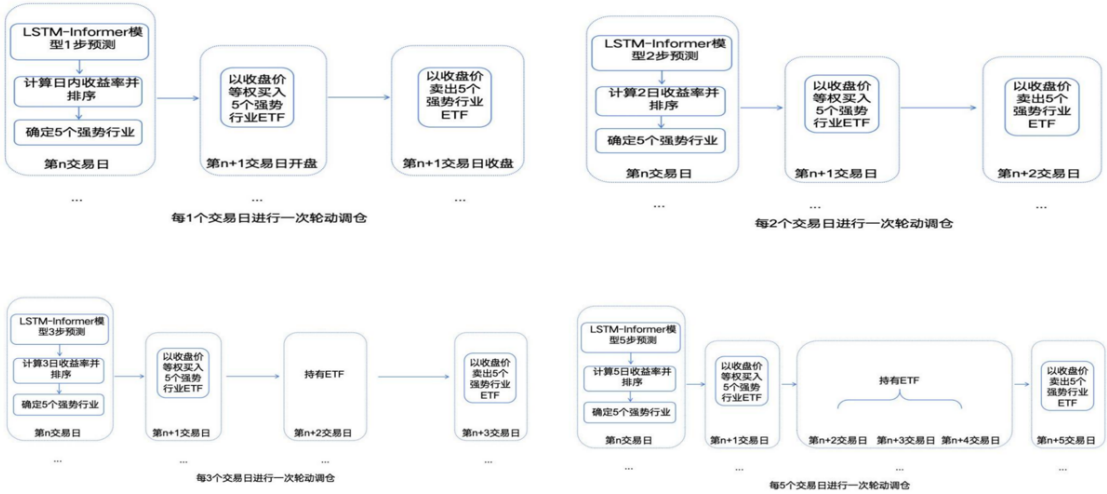


图 4-2　1、2、3、5 日行业轮动策略原理

考虑到在行业轮动量化交易策略的回测研究时与在大盘中的实际交易中存在的差异，本文做出了如下三个假设：

假设 1：零市场影响。假定行业轮动策略所涉及的资金规模相对较小，尚不足以干扰其他市场参与者的交易决策，也不会对标的资产的市场价格造成实质性的波动或冲击。

假设 2：零滑点假设。假设市场上所有资产的流动性都足够高，在执行行业轮动策略过程中可以在当日收盘价时立刻下单完成交易。

假设 3：固定比例交易成本。行业轮动策略在每次调仓中的交易成本为成交额的固定比例。

在实际的资本市场运作中，若市场的整体成交量相对于单个投资者的交易规模而言足够大，则前述假设 1 与假设 2 在多数情形下近似于市场中的实际情况。尽管在现实交易过程中，不同时间点、不同买卖方向下的成本可能略有差异，并呈现一定波动性，但在本研究所进行的回测分析中，将交易成本简化设定为成交金额的一

中国知网 https://www.cnki.net

定比例，作为统一的成本模型。此种处理方式在学术研究交易回测中较为常见，具有现实的合理性，可在不影响结论有效性的前提下近似反映实际交易情况。

4.2.2 行业轮动策略评价指标

本文对量化交易策略的评价从收益与风险的角度进行，综合使用年化收益率、波动率、最大回撤和夏普比例等四个指标来对本文的行业轮动策略进行评价。

年化收益率（Annualized Return）是衡量投资在一年内的平均回报率的指标，用于评估投资的长期表现。它将投资回报率标准化为一年期的收益，以便于不同时间跨度的投资比较。年化收益率考虑了时间因素，能够消除投资期长度的影响，使得不同时间周期的投资回报具有可比性。其计算公式如下：

$$AR = (\frac{N}{1})^{\frac{1}{T}} - 1 \qquad (4-5)$$

其中初始投入为 1，V 为期末累计价值，T 为年份数。由于样本外测试集包含了 3 年，这里 T=3。

最大回撤（Maximum Drawdown）是衡量投资组合或资产在某一段时间内，从最高点到最低点的最大损失幅度，通常用来评估投资风险。最大回撤是衡量风险和投资稳定性的一个重要指标，投资者可以通过它了解潜在的亏损风险，从而做出更加谨慎的投资决策。最大回撤越小，意味着该投资组合或资产在不利市场条件下的表现越稳定。其计算公式如下：

$$MaxDrawdown = Max(\frac{p_i - p_j}{p_i}) \qquad (4-6)$$

其中 P 是第 t 天的价格或净值。

夏普比率（Sharpe Ratio）是衡量投资回报相对于其风险的一个重要指标，用于评估投资组合的表现。它通过比较投资的超过无风险利率的部分与其波动性来衡量风险调整后的收益。夏普比率越高，表示在承担单位风险的情况下，投资的回报越高，投资表现越好。其计算公式如下：

$$ShapeRatio = \frac{E(R_p) - R_f}{\sigma_p} \qquad (4-7)$$

其中$E(R_p)$是投资组合的期望收益率，R_f为无风险利率，σ_p为投资组合的波动率。

中国知网 https://www.cnki.net

累计胜率（Cumulative Win Rate）是衡量投资策略或交易系统在一段时间内成功交易的比例。它反映了成功交易（获利交易）占所有交易的比重。累计胜率越高，表示交易策略或投资方法的成功率越高，通常意味着更稳定的投资表现。

$$累计胜率 = \frac{盈利交易次数}{总交易次数} \tag{4-8}$$

其中盈利交易代表能够获取正收益的交易。

4.2.3 行业轮动策略回测结果

为深入探究深度学习模型预测结果与行业轮动策略的有效性，除了筛选出 5 个最为强势的行业轮动交易其行业 ETF，本文还筛选出最为弱势的 5 个行业轮动交易其行业 ETF，分别作为多头组合和空头组合，本文选择沪深 300ETF 作为基准，以与行业轮动策略形成对比。基于 LSTM-Informer 模型的行业轮动策略结果如图 4-3 所示。从图中可以明显看到，1 日、2 日、3 日、5 日的行业轮动策略多头组合表现远超过基准策略，空头组合表现远逊于基准策略，这充分体现了行业轮动策略的有效性，也充分体现了 LSTM-Informer 模型的预测效果，对一定时期的强势行业和弱势行业均具有识别效果能力。

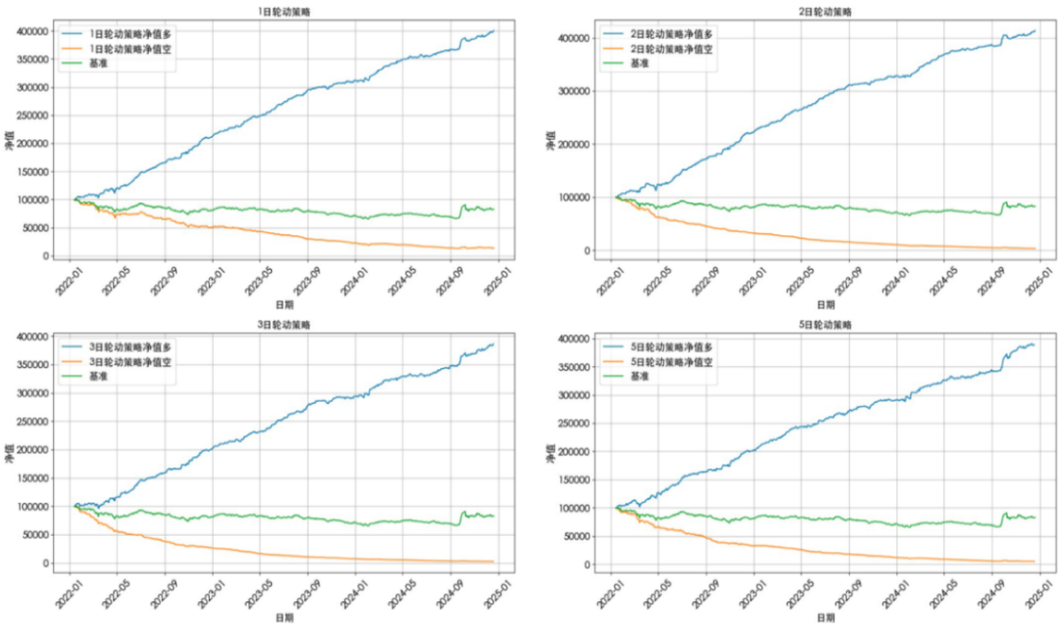


图 4-3　行业轮动策略回测结果

中国知网　https://www.cnki.net

1 日、2 日、3 日、5 日的行业轮动策略对比结果如图 4-4 和表 4-3 所示。可以看出，1 日与 2 日轮动策略效果最好，其中 2 日轮动策略的年化收益率、夏普比率、累计净值指标最高，说明 2 日行业轮动策略效果较好，远远优于基准收益；1 日轮动策略的收益指标基本接近 2 日轮动策略，但在此基础上控制了回撤，1 日轮动策略的回撤在四个交易策略中最低，但在胜率方面表现不佳。3 日、5 日行业轮动策略整体表现不如 1 日、2 日行业轮动策略，3 日行业轮动策略最大回撤指标优于 5 日行业轮动策略，虽然二者收益情况较为接近，但考虑到 3 日行业轮动策略交易频率高于 5 日行业轮动策略，其交易累计手续费更高，因此 3 日行业轮动策略效果更好。综上，1 日、2 日行业轮动策略效果最好，3 日、5 日行业轮动策略效果次之，均能显著优于基准收益，跑赢大盘，结果也符合深度学习模型在不同步长下的预测精度。以上结果充分说明策略的有效性，也说明 LSTM-Informer 模型对行业趋势判断的准确性。

表 4-3　行业轮动策略评价指标

1 日轮动策略		2 日轮动策略		3 日轮动策略		5 日轮动策略	
胜率	63.56%	胜率	72.75%	胜率	70.30%	胜率	74.35%
最大回撤	-5.22%	最大回撤	-10.23%	最大回撤	-9.39%	最大回撤	-11.66%
年化收益率	61.07%	年化收益率	62.14%	年化收益率	58.56%	年化收益率	60.19%
夏普比率	86.27%	夏普比率	91.46%	夏普比率	79.40%	夏普比率	81.10%
累计净值	4.002	累计净值	4.134	累计净值	3.867	累计净值	3.888

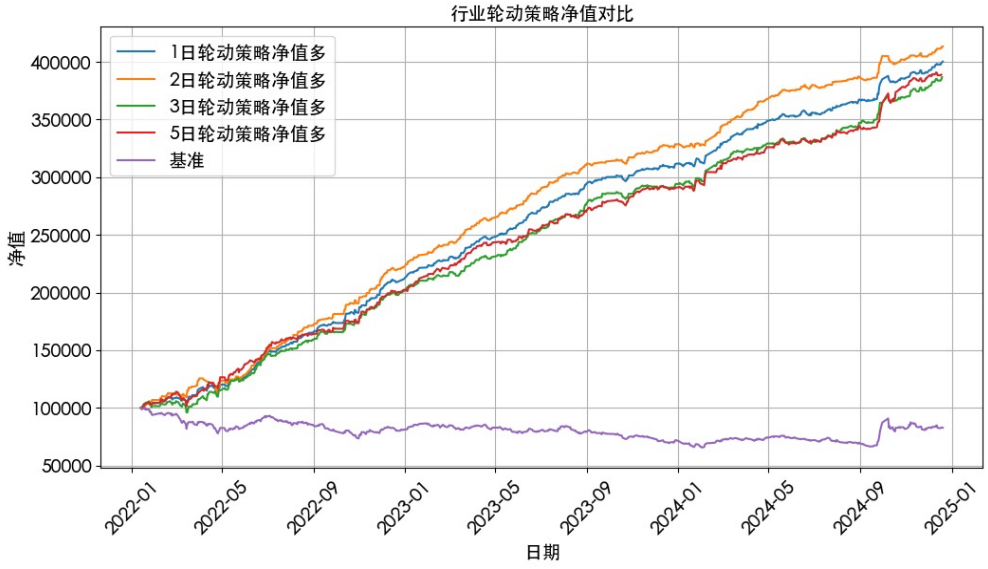


图 4-4　行业轮动策略对比分析

中国知网　https://www.cnki.net

4.3 行业轮动策略的稳健性分析

为进一步探究基于 LSTM-Informer 模型的行业轮动策略的稳健性，本节首先分析行业轮动策略的收益与风险，之后分别构建基于前文机器学习、深度学习对比模型的行业轮动策略，通过对各行业轮动策略表现进行对比，进一步验证 LSTM-Informer 模型在金融时间序列预测中的高精度表现，为行业轮动策略的构建提供支持。除此之外，本节还进一步探究行业轮动策略在不同市场环境下的表现，以验证策略的适应能力。

4.3.1 行业轮动策略风险—收益分析

（1）收益率

为分析基于 LSTM-Informer 模型构建的行业轮动策略在测试集上的收益分布情况，本节通过收益率分布结构图对策略在不同区间的收益率进行了分析。

行业轮动策略的月度收益图如图 4-5 所示。

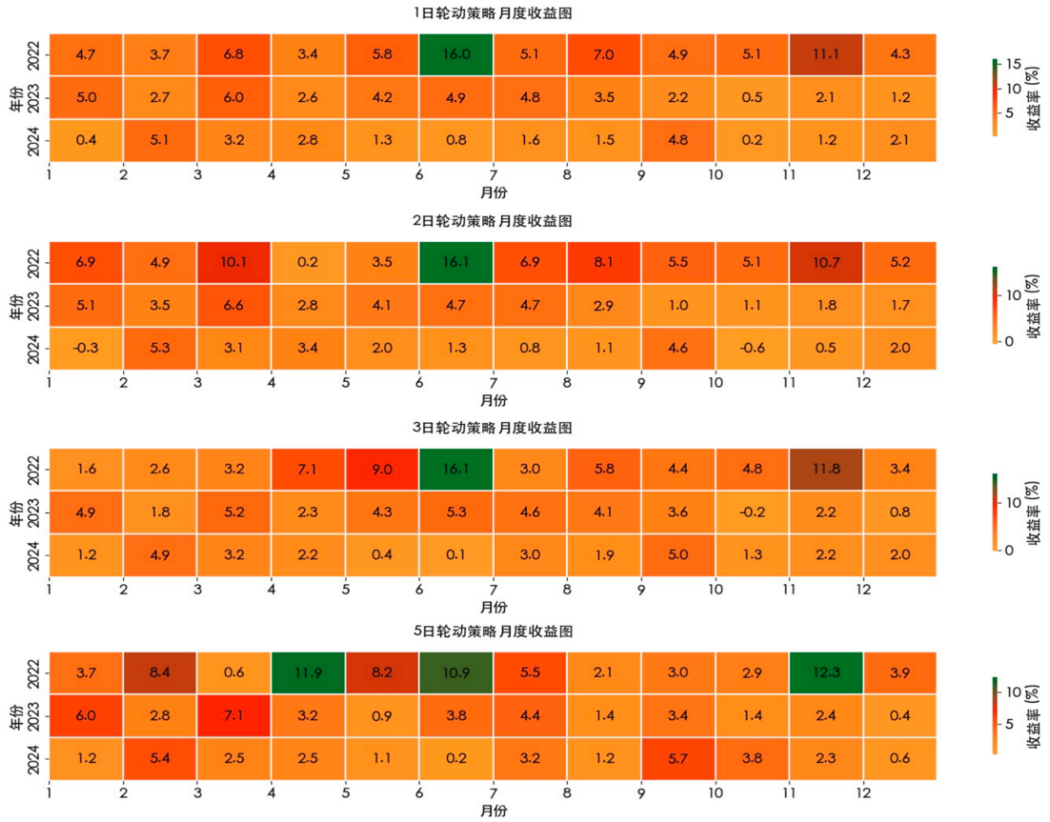


图 4-5 行业轮动策略月度收益图

中国知网 https://www.cnki.net

从图中可以看出，行业轮动策略的月度收益情况有相似之处，例如 2022 年 6 月与 12 月，轮动策略均取得了较大收益。行业轮动策略在 2022 年的月度收益波动较大，2024 年的月度收益波动较为平稳。整体来看，行业轮动策略在大部分月份中均能取得正向收益，仅有极少月份收益为负，如 2 日轮动策略在 2024 年 1 月与 10 月的收益分别为-0.3%和-0.6%，3 日轮动策略在 2023 年 10 月收益为-0.2%，亏损幅度较小，远小于策略的收益。

行业轮动策略季度收益图如图 4-6 所示。各行业轮动策略在 2022 至 2024 年的每个季度均有正收益，2 日轮动策略在 2022 年的四个季度均有超过 20%的季度收益率，3 日、5 日行业轮动策略的最大值产生于 2022 年第二季度，达到 35%，高于 1，2 日行业轮动测的最大值。2 日行业轮动策略于 2024 年第四季度产生最小值 1.9%，低于其他三个策略的最小值。整体而言，各行业轮动策略在回测周期各季度中均有捕获市场趋势获取超额收益的能力。1 日、2 日轮动策略的季度收益波动较小，3 日、5 日轮动策略的季度收益波动较大。

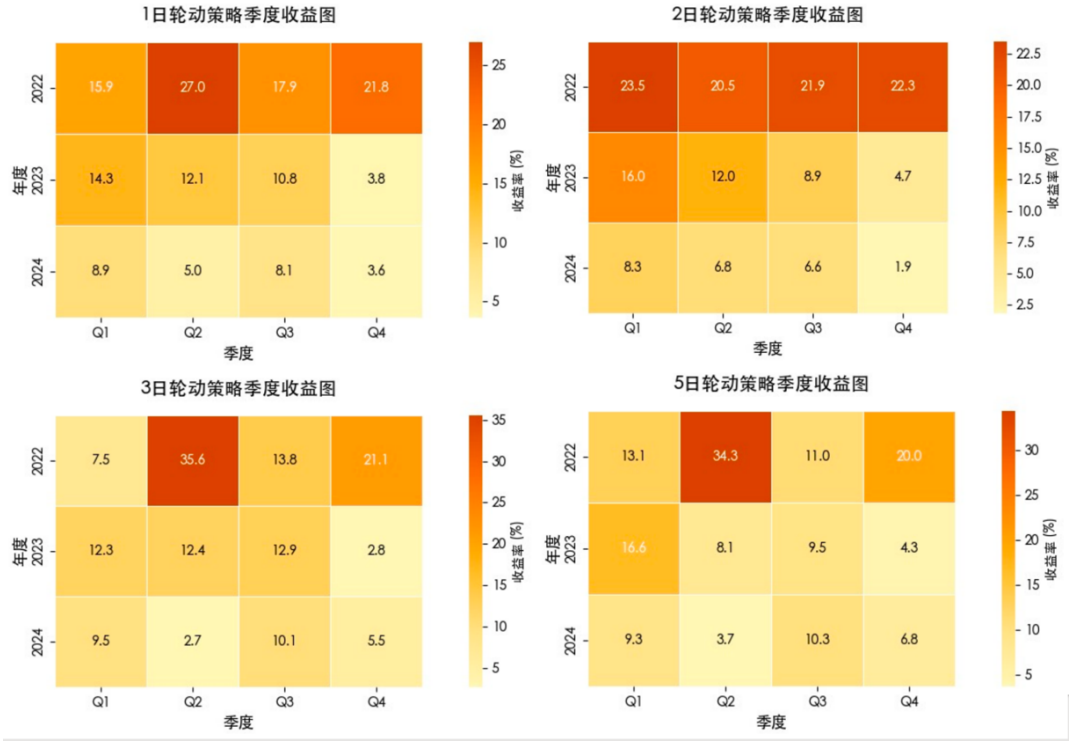


图 4-6　行业轮动策略季度收益图

行业轮动策略的年度收益如图 4-7 所示。

中国知网　https://www.cnki.net

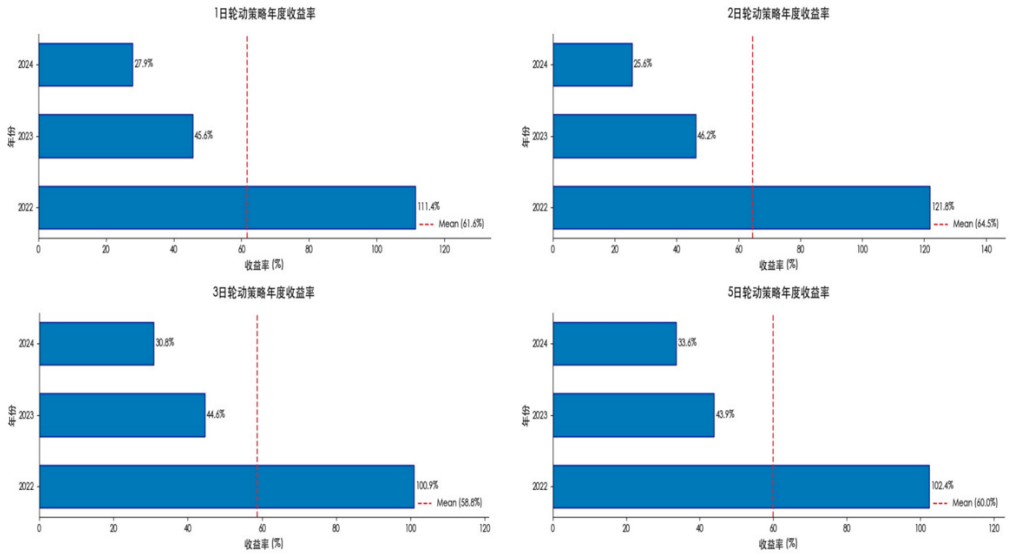


图 4-7　行业轮动策略年度收益率

各行业轮动策略在 2022 至 2024 年均能取得正收益，没有发生亏损情况。综上所述，基于 LSTM-Informer 模型构建的行业轮动策略具有获取收益的稳定性。

（2）波动率

波动率通常用于衡量投资组合收益率的波动幅度，是评估其风险水平的重要指标之一。为分析行业轮动策略在收益表现上的稳定性，本文选取以 6 个月为窗口期的滚动波动率分析策略在不同时间阶段中收益波动的变化趋势。行业轮动策略的波动率走势如图 4-8 所示。

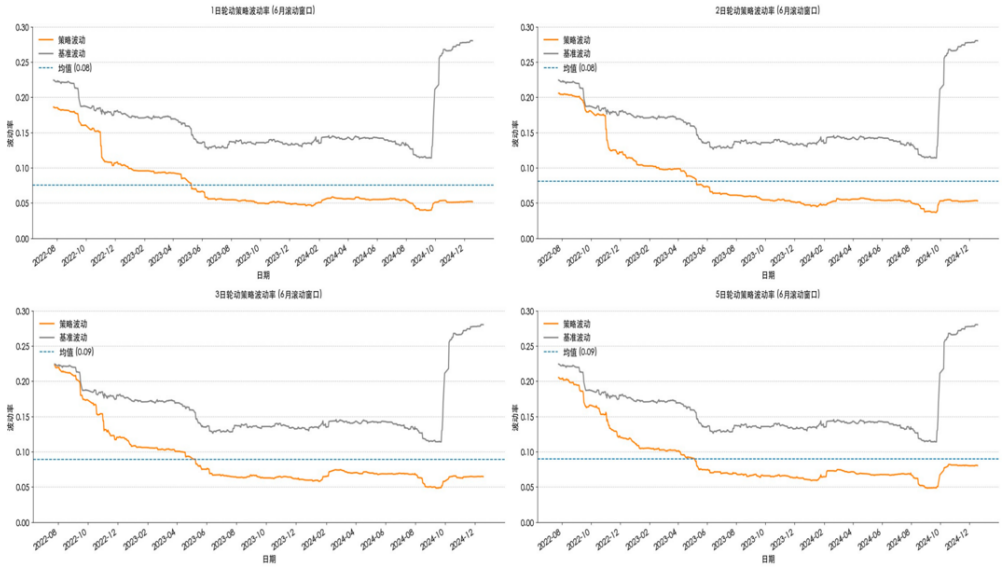


图 4-8　行业轮动策略波动率

中国知网　https://www.cnki.net

行业轮动策略的波动率走势与大盘基准波动趋势相近，但波动率大小明显小于大盘基准波动。行业轮动策略在 2022 年 8 月至 2023 年 5 月波动率较高，与大盘基准波动相近，但随后持续下降，从 2023 年下半年至 2024 年，行业轮动策略的波动率始终保持在较低水平，在 2024 年 10 月市场出现较大波动时，行业轮动策略依然能够保持稳定，说明策略能够识别大盘风险并控制风险，保证自身能够稳定获取超额收益。1 日，2 日轮动策略的波动率均值为 0.08，小于 3 日，5 日的 0.09，说明 1 日，2 日行业轮动策略表现更为稳定。

（3）最大回撤

由于多数市场参与者具有风险规避倾向，一旦投资组合的损失程度超过其心理承受阈值，往往会选择提前止损离场。即便部分投资者具备较强的持仓意愿，能够持有至投资期末，但若投资策略在运作过程中存在较大回撤，通常也难以被认定为优质的资产配置方式，因为它要求投资者具备较高的风险抗性。行业轮动策略的月度最大回撤走势如图 4-9 所示。

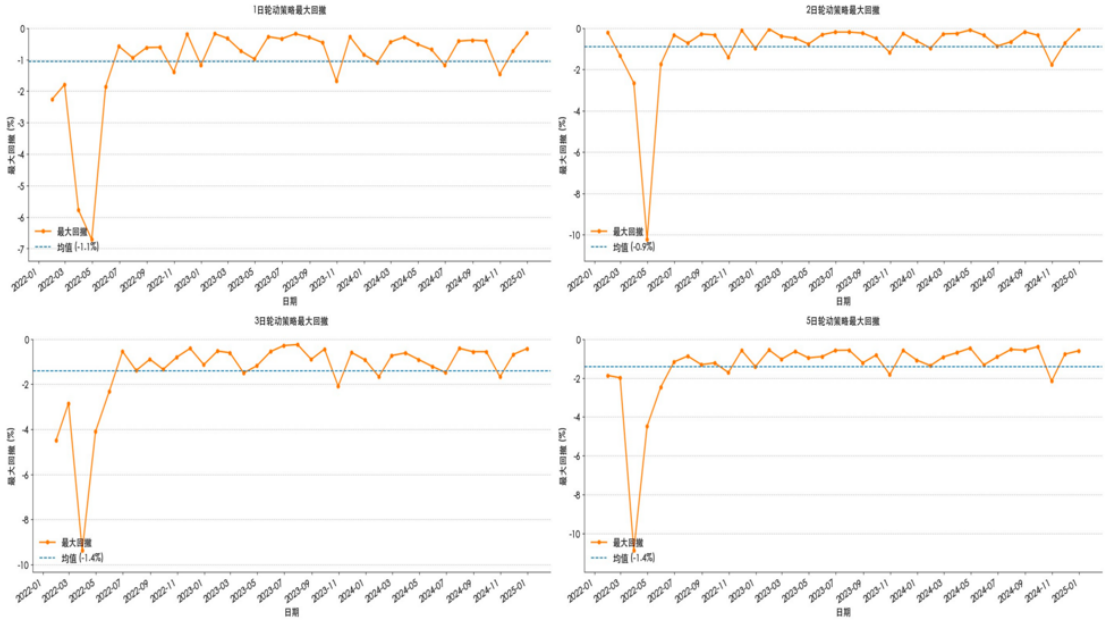


图 4-9　行业轮动策略回撤图

2 日轮动策略的月度最大回撤均值较小，为-0.9%，3 日与 5 日行业轮动策略的月度最大回撤均值最大，为-1.4%。从图中可以看出，各行业轮动策略最大回撤均产生于 2022 年上半年，在 2022 年 7 月后回撤逐渐减小，围绕均值波动。去除极端值

中国知网　https://www.cnki.net

后，策略每个月的最大回撤均在-1%附近波动，策略在执行中净值损失较少，跌幅在投资者承受范围之内。策略最大回撤的产生是由于市场波动，虽然远远大于策略月度回撤的均值，但也远远小于市场的平均跌幅，说明行业轮动策略能够很好的识别并控制由市场波动带来的风险，以实现减少回撤并增加收益。

4.3.2 行业轮动策略对比分析

前文中分别构建 LSTM，Informer 深度学习模型与 KNN，SVM 机器学习对申万一级行业指数进行 1、2、3、5 步预测，并与 LSTM-Informer 模型进行对比，对比结果显示，LSTM-Informer 模型在不同步数的预测精度要优于其他对比模型，深度学习的预测精度整体优于机器学习模型，特别是随着预测步长的增加，机器学习的预测效果下降较快。为进一步探究模型预测精度对行业轮动策略的影响，以验证基于 LSTM-Informer 模型的稳健性，进而探究将深度学习模型引入行业轮动策略的可行性，本文参考前文的行业轮动策略构建方法，分别基于各模型构建 1、2、3、5 日行业轮动策略，行业轮动策略的结果如表 4-4 和图 4-10 所示。

表 4-4　基于不同模型构建的行业轮动策略回测结果

1 日行业轮动策略					
	LSTM-Informer	Informer	LSTM	SVM	KNN
胜率	63.56%	55.01%	57.75%	52.11%	52.11%
最大回撤	-5.22%	-15.98%	-18.50%	-17.73%	-32.68%
年化收益率	61.07%	45.83%	39.32%	18.64%	7.88%
夏普比率	86.27%	53.78%	38.42%	13.94%	5.01%
累计净值	4.002	3.022	2.643	1.650	1.249
2 日行业轮动策略					
	LSTM-Informer	Informer	LSTM	SVM	KNN
胜率	72.75%	64.56%	51.76%	44.99%	44.85%
最大回撤	-10.23%	-19.82%	-13.52%	-24.47%	-31.49%
年化收益率	62.14%	49.26%	32.61%	1.73%	-3.31%
夏普比率	91.46%	47.14%	38.27%	1.56%	-2.44%
累计净值	4.134	3.239	2.287	1.052	0.906

中国知网 https://www.cnki.net

续表 4-4　基于不同模型构建的行业轮动策略回测结果

3 日行业轮动策略					
	LSTM-Informer	Informer	LSTM	SVM	KNN
胜率	70.30%	66.90%	56.12%	44.61%	44.78%
最大回撤	-9.39%	-14.65%	-14.81%	-56.64%	-60.29%
年化收益率	58.56%	42.06%	25.10%	-24.09%	-26.87%
夏普比率	79.40%	50.09%	26.85%	-22.90%	-24.86%
累计净值	3.867	2.799	1.929	0.446	0.556
5 日行业轮动策略					
	LSTM-Informer	Informer	LSTM	SVM	KNN
胜率	74.35%	66.20%	56.34%	46.84%	44.30%
最大回撤	-11.66%	-19.20%	-16.63%	-61.69%	-52.47%
年化收益率	60.19%	41.67%	22.12%	-24.05%	-18.07%
夏普比率	81.10%	38.03%	26.10%	-15.68 %	-11.81%
累计净值	3.888	2.776	1.796	0.432	0.399

从回测结果来看，基于深度学习模型构建的行业轮动策略要优于基于机器学习模型构建的行业轮动策略，基于 LSTM-Informer 模型的行业轮动策略优于 LSTM 与 Informer 模型构建的行业轮动策略。深度学习模型在 1，2，3，5 日行业轮动策略中均能获取超额收益，都能优于基准策略，机器学习模型仅能在 1 日轮动策略中获取超额收益，随着持仓周期的增加效果下降较快，弱于市场平均表现，说明机器学习模型未能较好捕捉行业发展趋势。基于深度学习模型构建的行业轮动策略在回撤控制上也优于机器学习模型，其中基于 LSTM-Informer 模型的行业轮动策略回撤控制最好，LSTM 与 Informer 模型次之。总体而言，基于 LSTM-Informer 模型的行业轮动策略效果最好，基于 LSTM 模型的行业轮动策略能够获取超额收益，基于 Informer 模型的行业轮动策略表现较为稳定，基于机器学习的行业轮动策略表现不佳。回测结果与模型的预测能力相符，模型的预测精度越大，构建的行业轮动策略表现越好，这充分说明了引入更加精确的深度学习模型到行业轮动策略中的意义。

中国知网　https://www.cnki.net

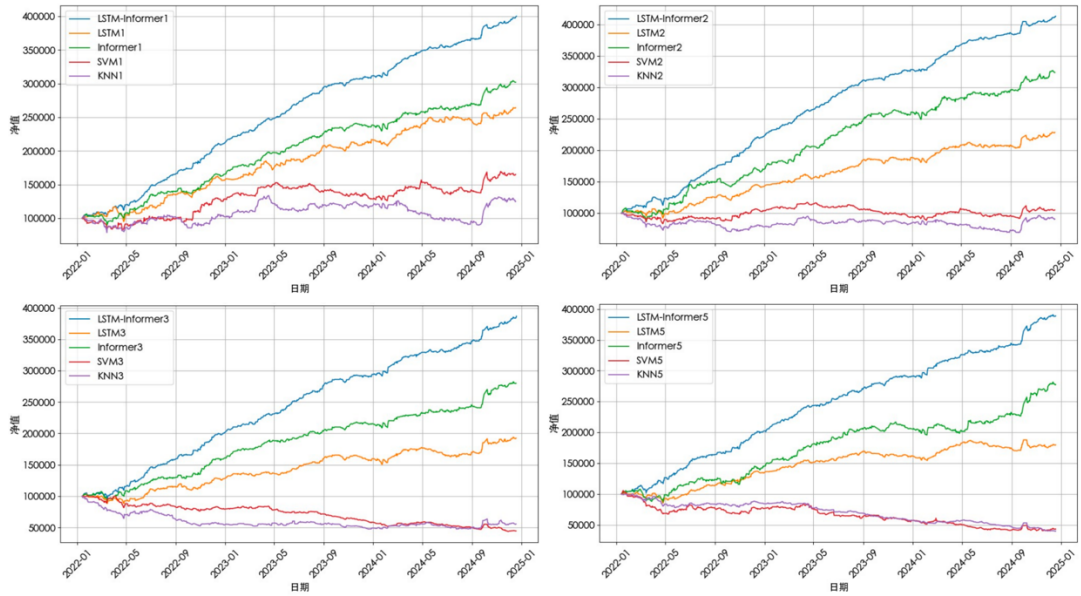


图 4-10　行业轮动策略对比分析

4.3.3　行业轮动策略在不同市场环境的表现

本文构建的行业轮动策略回测周期为 2022 年 1 月至 2024 年 12 月共三年时间，在回测周期中，基于 LSTM-Informer 模型的行业轮动策略显著优于基准策略。在实际交易中，市场波动将对交易策略产生较大影响。例如 2024 年 9 月市场行情较好，可能会放大策略的收益。为进一步探究策略在不同市场行情下的表现，以验证行业轮动策略在多种情况下均能获得超额收益，本文根据上证指数收盘价走势，在回测周期内筛选出上涨周期与下跌周期，并将策略在上涨周期与下跌周期分别回测，证明基于 LSTM-Informer 模型的稳健性。上证指数收盘价如图 4-11 所示

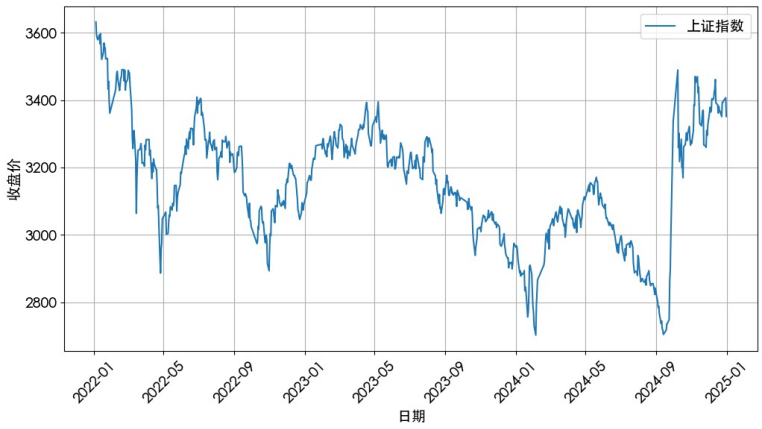


图 4-11　上证指数走势图

中国知网　https://www.cnki.net

从图上可以看出，上证指数处于震荡波动的状态，因此根据整体趋势进行周期划分。划分结果如表 4-5 所示。

表 4-5　回测周期划分

日期	周期	日期	周期
2022.1-2022.5	下跌周期	2022.5-2022.7	上涨周期
2022.7-2022.11	下跌周期	2022.11-2023.5	上涨周期
2023.5-2024.2	下跌周期	2022.2-2022.6	上涨周期
2024.10-2024.12	下跌周期	2024.6-2024.10	上涨周期

基于 LSTM-Informer 模型在下跌周期的回测结果如表 4-6 和图 4-12 所示，在上涨周期的回测结果如表 4-7 和图 4-13 所示。

表 4-6　下跌周期回测结果

2022.1-2022.5				
	1 日	2 日	3 日	5 日
胜率	60.87%	64.62%	68.94%	68.65%
最大回撤	-6.72%	-10.23%	-9.39%	-10.88%
年化收益率	86.86%	108.43%	62.41%	125.18%
夏普比率	60.68%	70.09%	37.00%	82.70%
累计净值	1.199	1.238	1.151	1.266
2022.7-2022.11				
	1 日	2 日	3 日	5 日
胜率	67.90%	77.40%	75.27%	63.61%
最大回撤	-1.39%	-1.41%	-1.39%	-1.72%
年化收益率	102.79%	126.79%	79.81%	60.51%
夏普比率	157.55%	172.31%	115.28%	80.12%
累计净值	1.269	1.318	1.219	1.173
2023.5-2024.2				
	1 日	2 日	3 日	5 日
胜率	62.90%	69.67%	74.60%	67.39%
最大回撤	-1.68%	-1.18%	-2.08%	-1.83%
年化收益率	35.98%	32.87%	40.10%	28.69%
夏普比率	109.86%	98.42%	98.74%	69.92%
累计净值	1.258	1.237	1.287	1.208
2024.10-2024.12				
	1 日	2 日	3 日	5 日
胜率	54.90%	71.44%	71.50%	70.87%
最大回撤	-1.32%	-1.76%	-1.67%	-2.16%
年化收益率	15.63%	10.08%	20.94%	24.43%
夏普比率	58.55%	38.73%	57.00%	55.86%
累计净值	1.029	1.019	1.038	1.043

中国知网　https://www.cnki.net

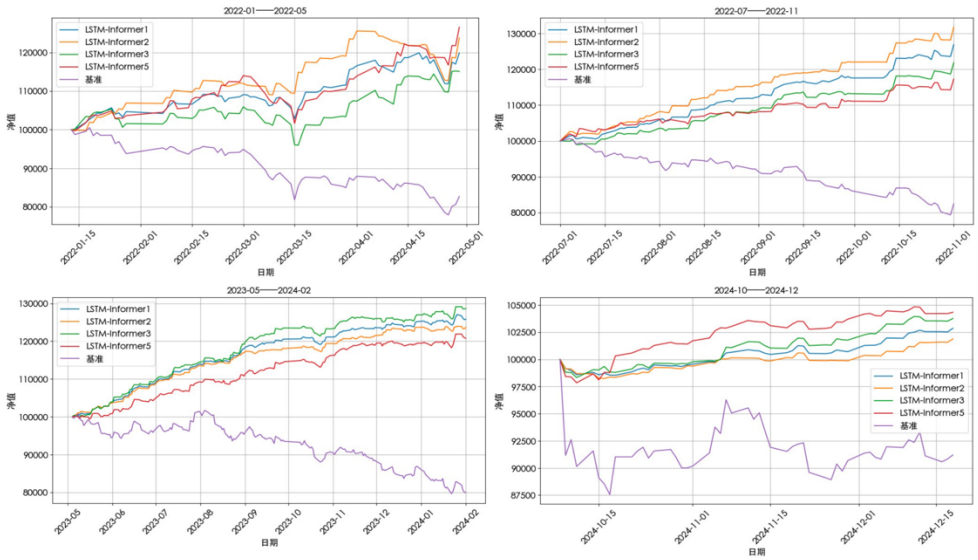


图 4-12　下跌周期回测结果

表 4-7　上涨周期回测结果

2022.5-2022.7				
	1 日	2 日	3 日	5 日
胜率	75%	76.69%	85.86%	75.43%
最大回撤	-1.86%	-1.74%	-2.33%	-2.46%
年化收益率	267.73%	225.01%	316.17%	229.24%
夏普比率	339.93%	232.78%	314.97%	221.91%
累计净值	1.226	1.202	1.249	1.200
2022.11-2023.5				
	1 日	2 日	3 日	5 日
胜率	66.12%	77.99%	73.81%	78.26%
最大回撤	-1.17%	-0.97%	-1.50%	-1.41%
年化收益率	77.35%	84.97%	69.44%	89.87%
夏普比率	172.90%	176.87%	131.95%	176.34%
累计净值	1.322	1.350	1.293	1.367
2022.2-2022.6				
	1 日	2 日	3 日	5 日
胜率	65.33%	75.52%	75.03%	71.46%
最大回撤	-0.68%	-0.34%	-1.21%	-1.32%
年化收益率	44.11%	49.61%	37.02%	41.09%
夏普比率	128.67%	142.99%	83.56%	96.06%
累计净值	1.128	1.142	1.110	1.113
2024.6-2024.10				
	1 日	2 日	3 日	5 日
胜率	63.41%	68.70%	69.82%	66.71%
最大回撤	-1.18%	-0.87%	-1.48%	-0.91%
年化收益率	30.11%	26.22%	34.49%	36.16%
夏普比率	87.89%	71.92%	89.98%	76.42%
累计净值	1.090	1.079	1.101	1.106

中国知网　https://www.cnki.net



图 4-13　上涨周期回测结果

从回测结果可以看出，基于 LSTM-Informer 模型的行业轮动策略无论在上涨周期还是下跌周期都能稳定获取超额收益，并且可以控制收益的波动。在市场剧烈震荡的情况下，策略可以在一定程度规避市场带来的影响，走势较为稳定。从回测结果来看，策略在下跌周期产生的回撤相较于上涨周期较大，而获取的超额收益较小，在上涨周期中，基准收益在部分区间内要优于行业轮动策略，但波动都比较大，无法持续获取收益，而行业轮动策略在多种情况下表现稳定，收益较好。综上所述，基于 LSTM-Informer 模型的行业轮动策略在不同的市场行情下表现稳定，收益优于基准，受大盘波动影响较小，说明利用 LSTM-Informer 模型对行业趋势进行精准判断后再投资可以很大程度上规避风险，具有科学性与稳健性。

4.3.4　行业轮动策略的参数分析

本文构建行业轮动策略的关键在于识别强势行业后在一定调仓频率下动态轮动交易强势行业 ETF，因此本策略的关键参数是调仓频率和持仓权重。上文将调仓频率分别调整为 1、2、3、5 日进行回测，发现行业轮动策略均可获取超额收益。本节对持仓资产权重进行分析。等权轮动交易收益率排名前五的行业可以获取超额收益，但最为强势的行业交易权重与其他较不强势的行业交易权重相同，无法放大强势行业的优势，同时在遇到风险时，也无法减小风险。本节对量化交易策略持仓权重进

中国知网　https://www.cnki.net

行调整，进行加权构建新的投资策略，将相对较为强势的行业资产在交易过程中赋予更高权重，放大其优势。这里采取简单加权方式，根据排名前五的强势行业分别赋予 5:4:3:2:1 的权重，回测周期与等权策略相同，对比结果如图 4-14 和表 4-8 所示。

表 4-8　加权策略结果

1 日等权策略		1 日加权策略		2 日等权策略		2 日加权策略	
胜率	63.56%	胜率	63.56%	胜率	72.75%	胜率	72.75%
最大回撤	-5.22%	最大回撤	-4.11%	最大回撤	-10.23%	最大回撤	-9.62%
年化收益	61.07%	年化收益	68.31%	年化收益	62.14%	年化收益	69.98%
夏普比率	86.27%	夏普比率	96.56%	夏普比率	91.46%	夏普比率	98.88%
累计净值	4.002	累计净值	4.612	累计净值	4.134	累计净值	4.740
3 日等权策略		3 日加权策略		5 日等权策略		5 日加权策略	
胜率	70.30%	胜率	70.30%	胜率	74.35%	胜率	74.65%
最大回撤	-9.39%	最大回撤	-7.00%	最大回撤	-11.66%	最大回撤	-10.84%
年化收益	58.56%	年化收益	66.77%	年化收益	60.19%	年化收益	64.14%
夏普比率	79.40%	夏普比率	91.93%	夏普比率	81.10%	夏普比率	90.31%
累计净值	3.867	累计净值	4.274	累计净值	3.888	累计净值	4.485

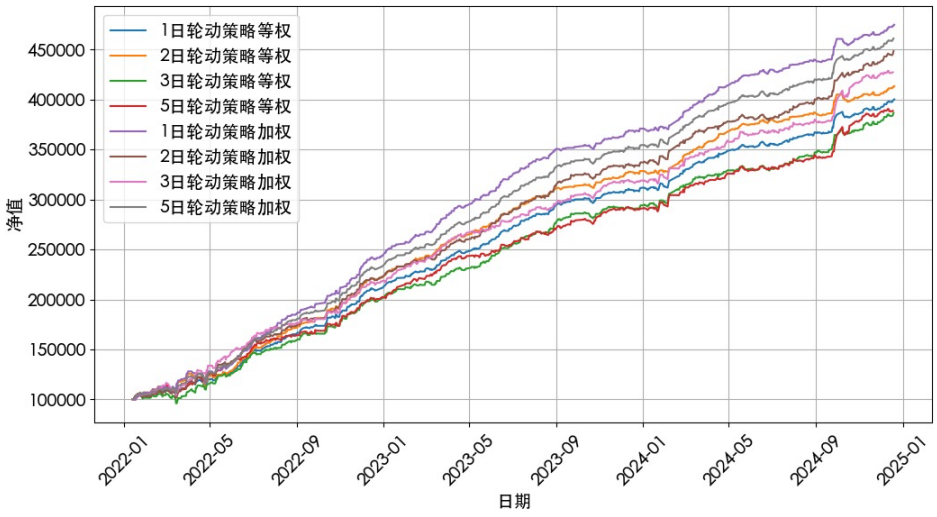


图 4-14　加权策略结果

从回测结果可以看出，在回测周期开始时加权和等权策略差距不明显，但随着交易的持续推进，两种策略的收益差距增大，改进后的加权策略在年化收益率、最大回撤和夏普比率上要优于等权策略，在策略胜率上略有提升。这充分说明在执行轮动交易过程中如果能给予较强势行业资产更高的权重，可以放大收益并控制风险。

中国知网　https://www.cnki.net

5 结论与展望

5.1 研究结论

本文通过判断申万一级行业指数未来发展趋势，来判断各行业在未来的强势情况，作为资产配置的依据。本文行业轮动的识别方法本质上是基于深度学习模型的金融时间序列预测，通过构建 LSTM-Informer 模型对申万一级行业指数收盘价进行预测判断，并基于预判结果构建行业轮动策略。

在模型构建过程中，本文的主要工作为构建了 LSTM-Informer 深度学习模型，预测未来 1 日、2 日、3 日、5 日的申万一级行业指数收盘价。在将行业指数数据输入到 LSTM-Informer 模型之前，对数据进行了清洗、小波降噪，最后进行归一化。对模型预测效果的评价，本文选择R^2，RMSE，MAE，MAPE 和 DA 指标进行评价。为了深入研究模型的预测效果，本文分别构建 LSTM、Informer 深度学习模型与 KNN、SVM 机器学习模型，与 LSTM-Informer 模型的预测结果进行对比分析。

在策略构建过程中，本文分别构建 1 日、2 日、3 日、5 日行业轮动策略，分别利用 LSTM-Informer 模型的 1 步、2 步、3 步、5 步预测值计算未来 1 日、2 日、3 日、5 日收益率，并根据收益率大小进行排序，轮动持有在未来一定时期内收益率最大的 5 个行业 ETF。本文选取沪深 300ETF 作为基准收益与构建的 1 日、2 日、3 日、5 日行业轮动策略对比分析，通过前文的实证研究和策略回测，可以得到以下结论：

（1）在对申万一级行业指数收盘价的预测中，LSTM-Informer 模型在R^2，RMSE，MAE，MAPE，DA 评价指标上表现较好，对行业指数数据有一定的拟合预测效果。根据描述性统计分析与 DM 统计检验的结果看，LSTM-Informer 模型的 1 步预测效果最佳，模型预测效果随预测步数的增加而递减；与 LSTM、Informer 深度学习模型和 KNN、SVM 机器学习模型对比分析可知，LSTM-Informer 模型在各预测步数上都占优，随着预测步数的增加优势更加明显。深度学习模型在各预测步上都优于机器学习模型，随着预测步数增加优势突出，LSTM 模型在短期预测中趋势判断能力较强，Informer 模型在预测步数的增加中效能保持稳定预测，LSTM-Informer 深度学习

中国知网 https://www.cnki.net

模型充分结合两个模型的优势，可以发挥更好的效果。

（2）在进行行业轮动策略的回测中，利用 LSTM-Informer 模型预测的收盘价计算预测收益率，根据收益率大小排出最大和最小的五个行业作为强势和弱势行业，分别作为行业轮动的多头策略和空头策略，经过回测，1 日、2 日、3 日、5 日行业轮动多头策略显著优于基准收益，1 日、2 日、3 日、5 日行业轮动空头策略显著逊于基准收益，说明建立的行业轮动策略有效，具有识别风险与提升收益的效果。将 1 日、2 日、3 日、5 日行业轮动多头策略进行对比分析可得，1 日，2 日行业轮动策略效果较好，3 日、5 日行业轮动策略次之。1 日行业轮动策略净收益小于 2 日轮动策略，但在回撤控制上表现最好，3 日、5 日行业轮动策略的净收益接近，3 日行业轮动策略回撤控制优于 5 日行业轮动策略，但在策略胜率上不如 5 日行业轮动策略。

（3）对行业轮动策略进行稳健性分析发现，1、2、3、5 日行业轮动策略在回测周期各月度、季度、年度中均能稳定获取收益。波动率与回撤相较于市场基准处于低位，说明策略能够在控制风险的前提下获取收益。与其他模型对比分析可知，基于深度学习构建的行业轮动策略优于基于机器学习构建的行业轮动策略，基于组合深度学习模型构建的行业轮动策略优于基于单一深度学习模型构建的策略。深度学习模型在 1、2、3、5 日行业轮动策略中均能获取超额收益，而机器学习模型表现不佳，整体而言，基于 LSTM-Informer 模型的行业轮动效果最好。将策略在不同的市场环境下再进行回测发现，在下跌周期中，策略可以克服大盘下行带来的影响，识别在市场状态低迷的情况下仍能盈利的行业进行配置；在上涨周期中，策略可以识别优势最为明显的行业进行配置，以在市场资产普遍上涨中放大收益优势。为进一步优化模型，本文对各策略中的交易资产进行简单加权，经过回测发现，简单加权策略净值曲线走势与等权策略趋势相似，但累计收益远优于等权策略，在保持胜率不变的情况下，对回撤也有控制能力。根据结果可得，基于 LSTM-Informer 模型构建的行业轮动策略具有识别风险，判断收益的能力，显著优于持有大盘指数在回撤周期的收益。

中国知网 https://www.cnki.net

5.2 研究不足与展望

资本市场纷繁复杂，量化交易策略严密精细，关于本文构建基于 LSTM-Informer 深度学习模型的行业轮动策略，虽然从回测的结果来看是可行的，但是仍然存在许多的不足和改进方向：

首先，本文选取的输入模型的特征变量主要包括行情基本面因子变量与技术分析因子变量，这些特征变量在金融时间序列分析领域已经被广泛运用。市场中的一些量化机构在实际交易中还会在此基础上构建出新的更加有效的特征变量，在未来的研究中可以尝试将更多有效的特征变量输入模型，以提升策略效果。

其次，本文建立的 2 日、3 日、5 日行业轮动策略在国内资本市场中理论上是可行的，但由于交易规则所限，本文所构建的 1 日行业轮动策略在我国资本市场上是无法实现的。其他资本市场，如美国市场，可以进行日内交易，本文构建的 1 日轮动策略理论上是可行的，未来可以将策略推广到其他资本市场中。

最后，本文采用的数据是申万一级行业指数的日频数据，未来的研究或可尝试使用日内 5 分钟、1 分钟甚至 tick 级别的高频次的交易数据对价格变化趋势进行预测分析，形成更为高频的行业轮动交易策略。

在实际投资交易中，投资者在不同时段轮动配置强势行业资产，可以控制风险并获取超额收益。在未来的投资中，建议投资者从如下几个方面提升策略稳健性：

一方面，应利用能对行业发展趋势进行精确判断的模型进行预测分析，选择在未来一定时间内表现优异的行业资产进行配置。

另一方面，应对策略的关键参数进行不断优化。例如策略的交易频率，调仓周期，止盈止损点等，以在控制风险的前提下获取更大收益。

中国知网 https://www.cnki.net

参考文献

[1] 陈东洋, 毛力. 融合增量学习与Transformer模型的股价预测研究[J]. 计算机科学与探索, 2024, 18(07): 1889-1899

[2] 陈海强, 陈丽琼, 李迎星, 等. 高频数据是否能改善股票价格预测?——基于函数型数据的实证研究[J]. 计量经济学报, 2021, 1(02): 426-436

[3] 陈梦根, 曹凤岐. 中国证券市场价格冲击传导效应分析[J]. 管理世界, 2005, (10): 24-33

[4] 高波, 任若恩. 基于主成分回归模型的行业轮动策略及其业绩评价[J]. 数学的实践与认识, 2016, 46(19): 82-92

[5] 何诚颖. 中国股市“板块现象”分析[J]. 经济研究, 2001, (12): 82-87

[6] 黄乃静, 于明哲. 机器学习对经济学研究的影响研究进展[J]. 经济学动态, 2018, (07): 115-129

[7] 黄卿, 谢合亮. 机器学习方法在股指期货预测中的应用研究——基于BP神经网络、SVM和XGBoost的比较分析[J]. 数学的实践与认识, 2018, 48(08): 297-307

[8] 金秀, 尘娜, 王佳. 安全投资转移视角下的跨行业投资组合模型及实证[J]. 中国管理科学, 2020, 28(11): 12-22

[9] 李斌, 邵新月, 李玥阳. 机器学习驱动的基本面量化投资研究[J]. 中国工业经济, 2019, (08): 61-79

[10] 李新, 张旭, 余乐安, 等. 基于改进Transformer模型的景区短时客流预测研究[J]. 中国管理科学, 2025, 33(02): 105-117

[11] 李志冰, 杨光艺, 冯永昌, 等. Fama-French五因子模型在中国股票市场的实证检验[J]. 金融研究, 2017, (06): 191-206

[12] 刘博, 皮天雷. 惯性策略和反转策略：来自中国沪深A股市场的新证据[J]. 金融研究, 2007, (08): 154-166

[13] 马甜, 姜富伟, 唐国豪. 深度学习与中国股票市场因子投资——基于生成式对抗网络方法[J]. 经济学(季刊), 2022, 22(03): 819-842

中国知网 https://www.cnki.net

[14] 欧阳红兵, 黄亢, 闫洪举. 基于 LSTM 神经网络的金融时间序列预测[J]. 中国管理科学, 2020, 28(4): 27-35

[15] 潘和平, 张承钊. FEPA-金融时间序列自适应组合预测模型[J]. 中国管理科学, 2018, 26(06): 26-38

[16] 潘莉, 徐建国. A股市场的风险与特征因子[J]. 金融研究, 2011, (10): 140-154

[17] 苏治, 卢曼, 李德轩. 深度学习的金融实证应用: 动态、贡献与展望[J]. 金融研究, 2017, (05): 111-126

[18] 王永宏, 赵学军. 中国股市惯性策略和反转策略的实证分析[J]. 证券市场导报, 2001, (06): 28-33

[19] 尹隽, 彭艳红, 陆怡, 等. 基于深度神经网络的企业信息系统用户异常行为预测[J]. 管理科学, 2020, 33(01): 30-45

[20] 郑力, 李明琛, 魏云捷, 等. 基于分解-重构-集成框架的股指预测及行业轮动策略[J]. 计量经济学报, 2024, 4(03): 673-698

[21] Bernanke B S, Kuttner K N. What explains the stock market's reaction to Federal Reserve policy?[J]. The Journal of finance, 2005, 60(3): 1221-1257

[22] Cao K, Zhang T, Huang J. Advanced hybrid LSTM-transformer architecture for real-time multi-task prediction in engineering systems[J]. Scientific Reports, 2024, 14(1): 4890

[23] De Bondt W F M, Thaler R. Does the stock market overreact?[J]. The Journal of finance, 1985, 40(3): 793-805

[24] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186

[25] Dong L, Xu S, Xu B. Speech-transformer: a no-recurrence sequence-to-sequence model for speech recognition[C]//2018 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2018: 5884-5888

[26] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv: 2010.11929, 2020

中国知网 https://www.cnki.net

[27] Durham J B. More on monetary policy and stock price returns[J]. Financial Analysts Journal, 2005, 61(4): 83-90

[28] Fama E F, French K R. Common risk factors in the returns on stocks and bonds[J]. Journal of financial economics, 1993, 33(1): 3-56

[29] Gayed M. An Intermarket Approach to Beta Rotation: The Strategy, Signal, and Power of Utilities[J]. 2014

[30] Hu H, Tang L, Zhang S, et al. Predicting the direction of stock markets using optimized neural networks with Google Trends[J]. Neurocomputing, 2018, 285: 188-195

[31] Jegadeesh N, Titman S. Returns to buying winners and selling losers: Implications for stock market efficiency[J]. The Journal of finance, 1993, 48(1): 65-91

[32] Jensen G R, Mercer J M, Johnson R R. Business conditions, monetary policy, and expected security returns[J]. Journal of Financial Economics, 1996, 40(2): 213-237

[33] Karatas T, Hirsa A. Two-stage sector rotation methodology using machine learning and deep learning techniques[J]. arXiv preprint arXiv:2108.02838, 2021

[34] Kim K. Financial time series forecasting using support vector machines[J]. Neurocomputing, 2003, 55(1-2): 307-319

[35] King B F. Market and industry factors in stock price behavior[J]. the Journal of Business, 1966, 39(1): 139-190

[36] Kothari S P, Shanken J, Sloan R G. Another look at the cross-section of expected stock returns[J]. The journal of finance, 1995, 50(1): 185-224

[37] Liu J, Stambaugh R F, Yuan Y. Size and value in China[J]. Journal of financial economics, 2019, 134(1): 48-69

[38] Livingston M. Industry movements of common stocks[J]. The Journal of Finance, 1977, 32(3): 861-874

[39] Moskowitz T J, Grinblatt M. Do industries explain momentum?[J]. The Journal of finance, 1999, 54(4): 1249-1290

[40] Raskoti C, Li W. Exploring Transformer-Augmented LSTM for Temporal and Spatial Feature Learning in Trajectory Prediction[J]. arXiv preprint arXiv: 2412.13419, 2024

[41] Riaz S, Saghir A, Khan M J, et al. TransLSTM: A hybrid LSTM-Transformer model for

中国知网 https://www.cnki.net

fine-grained suggestion mining[J]. Natural Language Processing Journal, 2024, 8: 100089

[42] Sorensen E H, Burke T. Portfolio returns from active industry group rotation[J]. Financial Analysts Journal, 1986, 42(5): 43-50

[43] Soutner D, Müller L. Continuous distributed representations of words as input of LSTM network language model[C]//Text, Speech and Dialogue: 17th International Conference, TSD 2014, Brno, Czech Republic, September 8-12, 2014. Proceedings 17. Springer International Publishing, 2014: 150-157

[44] Ticknor J L. A Bayesian regularized artificial neural network for stock market forecasting[J]. Expert systems with applications, 2013, 40(14): 5501-5506

[45] White H. Economic prediction using neural networks: The case of IBM daily stock returns[C]//ICNN. 1988, 2: 451-458

[46] Wu H, Xu J, Wang J, et al. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting[J]. Advances in neural information processing systems, 2021, 34: 22419-22430

[47] Yang R, Shi B. Sector Rotation by Factor Model and Fundamental Analysis[J]. arXiv preprint arXiv:2401.00001, 2023

[48] Zhen H, Niu D, Wang K, et al. Photovoltaic power forecasting based on GA improved Bi-LSTM in microgrid without meteorological information[J]. Energy, 2021, 231: 120908

[49] Zhou H, Zhang S, Peng J, et al. Informer: Beyond efficient transformer for long sequence time-series forecasting[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(12): 11106-11115

[50] Zhou T, Ma Z, Wen Q, et al. Fedformer: Frequency enhanced decomposed transformer for long-term series forecasting[C]//International conference on machine learning. PMLR, 2022: 27268-27286

[51] Zhu R, Yang Y, Chen J. XGBoost and CNN-LSTM hybrid model with Attention-based stock prediction[C]//2023 IEEE 3rd International Conference on Electronic Technology, Communication and Information (ICETCI). IEEE, 2023: 359-365

中国知网 https://www.cnki.net