分类号_____　　密级 _____
U D C _____　　编号 10741

兰州财经大学
LANZHOU UNIVERSITY OF FINANCE AND ECONOMICS

硕 士 学 位 论 文

（专业学位）

论文题目：基于异构融合数据的沪深 300 指数趋势预测研究

学　生　姓　名：张铁锰

学　　号：2023000003068

指导教师姓名、职称：王永瑜、教授

专 业 学 位 类 别：应用统计

专 业 学 位 领 域：社会经济统计分析

培　养　单　位：兰州财经大学

论 文 提 交 日 期：2026 年 6 月 5 日

中国知网　https://www.cnki.net

Research on Trend Prediction of the CSI 300 Index Based on Heterogeneous Fusion Data

Candidate: Zhang Tiemeng

Supervisor: Wang Yongyu

中国知网 https://www.cnki.net

摘 要

中国股票市场长期呈现出较为明显的“政策驱动型”特征，宏观政策信息往往通过影响投资者预期进而作用于资产价格波动。然而，现有研究多依赖高噪声社交媒体数据、难以精准捕捉权威政策导向。因此，如何从权威宏观信息中提取有效信号，并将其与市场交易数据进行融合建模，成为值得深入研究的重要问题。

针对上述问题，本文构建宏观政策文本与市场交易数据的异构融合预测框架。选取2023年1月至2025年12月《新闻联播》文本与沪深300指数数据，构建涵盖“风险”、“增长”及“稳定”维度的领域专用情感词典，融合TF-IDF方法生成多源特征；设计非交易日信息累积机制解决时序错配，实现宏观信号与交易数据的精准对齐，进而构建多组数据集开展对比实证。在模型构建方面，本文采用多种机器学习模型，并基于120日滑动窗口机制开展滚动预测。通过对不同文本特征方法、动态预测框架以及多模型结构进行系统比较，全面评估宏观政策文本信息在指数趋势预测中的实际作用。

实结果表明：（1）在仅使用价格特征的基准模型基础上，引入宏观政策文本特征能够显著提升模型预测性能，融合模型的预测准确率达到56.64%，明显优于基准模型；（2）基于融合模型构建的投资策略在回测中取得了较好的收益风险表现，年化收益率达到45.59%，夏普比率为3.73，整体表现优于基准策略；（3）特征重要性分析结果表明，“风险类政策信号”在模型决策中具有更高权重，表明市场对负面政策信息更为敏感，这一发现与行为金融学中的损失厌恶理论相一致。

研究结果表明，官方宏观新闻文本并非市场噪声，而是包含重要政策信号的信息来源。将其与市场交易数据进行融合建模，能够在一定程度上提升指数趋势预测能力，尤其在市场风险识别方面具有较高应用价值。本文研究为宏观文本信息在量化投资中的应用提供了新的实证证据，也为中国资本市场“政策驱动”特征的量化研究提供了新的视角。

关键词：异构数据融合；沪深300指数；文本挖掘；机器学习；政策信号

中国知网 https://www.cnki.net

Abstract

Chinese stock market has had relatively unique feature of being policy-driven for a very long time. Investor expectations may be affected by macro policy information, which in turn can affect asset price movements. Nonetheless, current research is highly dependent on high noise social media data that does not easily reflect authoritative policy directions. Consequently, the question of how efficient signals can be extracted out of authoritative macro information and combined with market trading data to model it has been a significant question that should be deeply investigated.

In order to deal with this problem, the current thesis develops a heterogeneous fusion prediction model based on macro policy text and market trading data. The process involves choosing the "Xinwen Lianbo"(CCTV News Broadcast) texts published in January 2023 through December 2025 and the CSI 300 index data, developing a domain-specific sentiment dictionary that includes the concepts of risk, growth, and stability, and applying the TF-IDF algorithm to obtain multi-source features; the non-trading day information storage mechanism is established to overcome the time sequence mismatch and allow precise correlation between macro signals and trading data, thus allowing formation of several data sets to compare empirical studies.

In terms of model construction, this thesis adopts various machine learning models and conducts rolling predictions based on a 120-day sliding window mechanism. Through a systematic comparison of different text feature methods, dynamic prediction frameworks, and multi-model structures, the actual role of macro policy text information in index trend prediction is comprehensively evaluated.

The empirical results show: (1) Compared with the benchmark model that only uses price features, introducing macro policy text features can

中国知网 https://www.cnki.net

significantly improve the model's prediction performance, and the prediction accuracy of the fusion model reaches 56.64%, significantly better than the benchmark model; (2) The investment strategy constructed based on the fusion model achieves better risk-return performance in backtesting, with an annualized return rate of 45.59% and a Sharpe ratio of 3.73, overall outperforming the benchmark strategy; (3) The feature importance analysis results indicate that "risk-related policy signals" have a higher weight in the model decision-making, indicating that the market is more sensitive to negative policy information, which is consistent with the loss aversion theory in behavioral finance.

The research results show that official macro news texts are not market noise but an information source containing important policy signals. Integrating them with market trading data for modeling can improve the index trend prediction ability to a certain extent, especially in market risk identification, and has high application value. This research provides new empirical evidence for the application of macro text information in quantitative investment and also offers a new perspective for the quantitative research on the "policy-driven" characteristic of the Chinese capital market.

Key words: Heterogeneous data fusion; CSI 300 Index; Text mining; Machine learning; Policy signals

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 研究背景与研究意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....2
1.2 国内外研究现状.....3
1.2.1 股票市场情绪测度研究.....3
1.2.2 金融文本量化分析研究.....5
1.2.3 异构数据融合方法研究.....7
1.2.4 文献评述.....8
1.3 研究方法与技术路线.....10
1.3.1 研究方法.....10
1.3.2 技术路线.....11
1.4 研究内容与创新点.....12
1.4.1 研究内容.....12
1.4.2 创新点.....13
2 理论基础.....15
2.1 信息对股票价格影响的理论基础.....15
2.1.1 有效市场假说与信息反应的非完全性.....15
2.1.2 信息传导机制.....16
2.2 宏观文本对市场的影响机制.....17
2.2.1 市场预期与政策信号.....17
2.2.2 政策信号的渐进性特征.....17
2.3 宏观文本信息量化的理论基础.....17
2.3.1 非结构化文本信息的量化路径.....17
2.3.2 领域词典构建的方法论基础.....18
2.3.3 基于 TF-IDF 的文本量化方法.....19
2.4 机器学习与模型评估的理论基础.....21
2.4.1 核心预测模型的理论基础.....21
2.4.2 模型评估指标的理论基础.....22
2.5 市场时变性与动态建模的理论基础.....23
2.5.1 市场时变性理论.....23
2.5.2 滑动窗口动态建模的理论基础.....24
2.5.3 异构数据时序对齐与滞后处理.....25
3 数据与模型构建.....27

中国知网　https://www.cnki.net

3.1 数据来源与样本说明.....27
3.1.1 市场数据.....27
3.1.2 宏观文本数据.....28
3.2 预测特征构建.....29
3.2.1 市场特征变量构建.....29
3.2.2 政策文本特征变量构建.....31
3.3 样本数据集构建与变量说明.....34
3.4 预测模型设定.....35
3.4.1 基准模型.....35
3.4.2 Logistic 回归模型.....36
3.4.3 随机森林集成模型.....36
3.4.4 XGBoost 梯度提升模型.....37
3.4.5 模型参数设定与估计策略.....37
4 实证研究与结果分析.....39
4.1 实证研究框架.....39
4.1.1 数据划分与样本设定.....40
4.2 模型评价指标设定.....40
4.3 不同文本特征融合的预测效果对比.....41
4.3.1 实证方案设计.....41
4.3.2 模型估计与预测结果.....42
4.3.3 实证结果分析.....42
4.4 滑动窗口机制与投资策略.....43
4.4.1 滑动窗口机制.....43
4.4.2 投资策略的构建方法.....43
4.5 不同窗口期的回测结果分析.....44
4.5.1 策略净值走势分析.....44
4.5.2 收益率与风险指标分析.....45
4.6 特征重要性分析.....47
4.7 多模型预测效果的对比分析.....48
4.7.1 不同模型的预测结果对比.....48
4.7.2 稳健性分析.....49
5 结论与展望.....50
5.1 研究结论.....50
5.2 研究不足与展望.....51
参考文献.....52

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景与研究意义

1.1.1 研究背景

股票市场价格形成一般被看作是投资者在信息有限情况下进行买卖竞争结果。Fama（1970）经典金融理论提出，资产价格可以迅速并且有效地反映所有公开的信息，但是 Shiller（2003）等人指出，在现实中，由于人们获得信息的能力不同，对信息的理解也不同，而且在新兴市场上，价格很难准确及时地反应宏观经济环境和人们对未来的看法。

在中国 A 股市场中，除了上市公司的财务数据以及市场的交易数据以外，宏观经济政策、新闻舆论及市场情绪等也是影响市场预期的因素。有学者认为中国资本市场存在明显的“政策市”，即政府的各种宏观调控措施、产业发展方向以及监管态度都会通过对市场预期的影响来对资产价格产生作用。因此，在研究过程中如何合理地对待并应用这些以文字形式存在的宏观信息就一直是一个难题。

目前对于沪深 300 指数预测的研究主要基于历史交易数据，例如价格、成交量以及技术指标等，用统计学或者机器学习的方法进行拟合（Tsay，2010；Wang，2021）。这些方法在市场比较平静的情况下且价格有一定延续性的状态下能够较好地反映短期内的趋势情况，但是当市场的环境发生变化时，仅使用过去的价格信息所建立起来的模型就会出现预测滞后的问题。近年来尤其是 2023—2025 年期间，A 股市场经常出现政策预期短时间内发生较大变化、风格不断转换以及情绪影响显著的情况，在这种背景下基于价格的价格驱动型模型对于把握大势的作用大打折扣。因为在市场上价格是一系列买卖行为的结果，它更多的是一个“事后”的结果无法体现市场的变化中所包含的各种政策信号或宏观经济的信息。

随着自然语言处理技术的发展，文本挖掘为量化宏观信息提供了新的技术路径。已有 Tetlock（2007）和 Baker（2016）等人研究表明，将新闻文本、政策文件或媒体报道中的信息转化为量化特征，并与金融市场数据相结合，有助于提升

中国知网 https://www.cnki.net

资产价格预测与风险识别能力。在中国语境下，部分学者开始尝试利用新闻情绪指数、政策不确定性指数等文本变量解释或预测市场波动，取得了一定成效。《新闻联播》作为我国最具权威性的官方新闻发布渠道之一，其内容集中体现了宏观经济形势、政策导向与重点工作部署，具有很强的代表性和稳定性。然而，在初步实证过程中发现，若直接套用 SnowNLP 等通用情感分析模型，往往难以准确识别官方新闻中隐含的“风险”或“维稳”信号，这主要是由于通用情感分析模型大多基于电商评论或社交媒体语料进行训练，其情感分类逻辑更偏向于显性情绪表达，对于官方新闻中大量使用的中性、规范性表述如“压力加大”“形势复杂”“持续推进”“稳妥实施”等，常出现情感打分趋同或信息区分度不足的问题，从而削弱了政策文本特征在预测模型中的有效性。

基于以上背景，如何针对特定的官方语境构建有效的量化特征，并将这些文本信息与市场交易数据进行科学融合，以期在复杂市场环境下提升指数趋势判断的有效性，是本文探讨的核心问题。因此本文尝试针对官方新闻文本的语言特点，构建适配中国宏观政策语境的文本特征，并将其与沪深 300 指数构建的价格特征进行融合建模。这一研究是对传统价格驱动型预测方法的有益补充。

1.1.2 研究意义

（1）本文的研究工作是利用文本挖掘的方法对中国宏观金融市场进行探索，是对目前量化预测的一种补充。目前大部分有关多源数据融合的研究均集中于单个股票股吧评论，而本文则着眼于宏观经济层面政府发布的新闻报道，在一定的背景下考察非结构化的信息是如何影响资产价格的，从而给出有效的市场假设在弱有效市场的表现的一种微观角度的理解。

（2）从实践角度，在本文所提出的异构融合预测模型中也考虑了风险管理问题，经过实验验证，在加入清洗之后的新闻特征之后，该模型对于判断市场的下跌风险有了一定的帮助作用。这对于量化投资有着一定的启示意义：即在重视收益的同时也可以利用宏观经济的相关信息来帮助识别市场的转折点，从而在某种程度上减少投资组合的最大回撤，提高策略的风险抵御能力。

中国知网 https://www.cnki.net

1.2 国内外研究现状

本章旨在系统梳理与本研究相关的理论基础与实证前沿。从有效市场假说、行为金融学的理论的研究现状，结合大数据时代的投资者情绪特征，阐述宏观新闻影响资产价格的内在逻辑，到深入剖析金融文本挖掘技术的演进脉络，说明词典法与深度学习模型在处理金融预测的现状，最后总结异构数据融合预测的现有研究成果与不足，从而确立本文的研究切入点。

1.2.1 股票市场情绪测度研究

早期关于市场情绪的研究多基于市场交易数据， 然而，有效市场假说（EMH）构成了这一领域的理论基石。Fama (1970)[1]认为在一个信息完全有效的市场中，证券价格能够瞬时、充分地反映所有公开信息。根据信息集的不同，Fama 将市场效率划分为弱式、半强式和强式有效。若市场达到半强式有效，所有公开的宏观新闻和政策信息应立即反映在股价中，基于历史信息或公开新闻的预测将无法获得超额收益。Malkiel (2003)[2]进一步支持了这一观点，认为股价变动遵循随机游走模式。

Fama 之后许多学者的研究都发现了一些无法由 EMH 解释的“市场异象”。LeRoy 和 Porter(1981)[3]认为股价变动幅度远超股息贴现模型所涵盖的基本面信息，这表明存在非理性力量主宰市场。另外，DeBondt 和 Thaler (1985)[4]发现股票市场的“反转效应”，即以往表现较差的投资组合在以后往往能够战胜表现较好的投资组合，这对 EMH 提出了质疑。而在我国股市发展的初期，中国学者也有大量的实证研究。例如，吴世农(1996)[5]等人认为，A 股市场受到政府干预较大，不是真正意义上的随机漫步。这说明我国资本市场还处于弱式有效甚至无效状态，在公开信息基础上进行预测是可行的。又如，张兵等（2003）[6]通过方差比较法得出结论，即在中国股票市场上，早期并不具备弱式有效性，尽管之后随着市场发展其有效性提高，但仍然有明显的自相关性；近年来也有众多学者研究证实中国股票市场依然存在着较强的非有效性。Lim 等（2009）对上海和深圳股市的弱式有效性进行了重新检验，发现两市收益率序列在长时间内遵循随机游走，但间歇性地出现显著的线性与非线性依赖结构，表明新信息并未持续充分地反映到股

中国知网 https://www.cnki.net

价中，市场存在阶段性的套利机会。Shi 等（2023）基于四种主流错误定价指标构建了综合错误定价指数，发现中国 A 股市场的异象在定价过高的股票中表现得尤为显著，而在定价过低的股票中则较弱甚至反转；由于短售限制导致的套利成本阻碍了过高定价的修正，从而增加了市场无效性。

由于 EMH 不能很好地解释现实中的市场波动，而行为金融学从心理学的角度出发认为人不是完全理性的。Kahneman 和 Tversky（1979）[8]提出前景理论说明投资者对于收益和损失的态度是不同的，在此基础之上，DeLong、Shleifer、Summers 和 Waldmann（1990）[10]提出了噪声交易者理论，噪声交易者的情绪就是一种系统性风险，会导致资产的价格长时间背离其真实的价值。Daniel 等人（1998）[11]从代表性偏差以及保守性偏差的角度来说明了投资者对于信息反应不足或者反应过度的原因。

在上述理论框架下，投资者情绪被视为独立于基本面之外的重要定价因素。早期关于市场情绪的研究多基于市场交易数据，如 French（1980）[12]通过周末效应揭示了投资者心理对市场定价的异象影响。随着行为金融学的发展，Baker 和 Wurgler（2006）[13]构建了经典的 BW 投资者情绪指数，实证证实情绪因子能够系统性影响资产定价。Baker 等（2016）[14]构建的经济政策不确定性（EPU）指数，为衡量宏观层面的市场恐慌情绪提供了权威指标。

随着信息传播渠道的演进，学界进一步关注外部信息载体在情绪形成中的作用。Tetlock（2007）[15]通过分析《华尔街日报》专栏文章，发现媒体悲观情绪与股票市场成交量放大及短期价格下跌显著相关，首次从文本分析角度验证了媒体情绪的市场影响。在社交媒体时代，Bollen 等（2011）[16]开创性地利用 Twitter 情绪数据预测道琼斯工业指数，证实了网络舆情对市场的先行指标作用。此后，相关研究不断深化。Da 等（2011）[17]提出的搜索指数（Search Volume Index, SVI）成为衡量投资者关注度的重要工具，拓展了情绪量化的研究范式。

聚焦于中国市场，由于 A 股市场散户投资者占比较高，且具有显著的“政策市”特征，官方媒体的舆论导向在修正投资者预期方面往往发挥更为突出的作用。基于这一制度特征，游家兴和吴静（2012）[18]发现媒体情绪对资产误定价具有显著的解释力，且存在“沉默的螺旋”效应。姜富伟等（2021）[19]利用海

中国知网 https://www.cnki.net

量媒体文本构建了中国特有的媒体情绪指数，发现其对 A 股市场的预测能力显著优于传统宏观经济指标，且在市场波动加剧时期表现尤为明显。近期，刘畅等（2022）[20]进一步指出，政策不确定性会通过文本情绪渠道加剧股票市场的波动。针对散户情绪，黄雨婷等（2023）[21]通过挖掘股评数据，证实了个人投资者情绪对股价崩盘风险的预测能力。这些研究表明，情绪测度已从单一的交易指标向多维度的文本情绪演变。

1.2.2 金融文本量化分析研究

金融文本的量化是情绪测度的技术基础。Khadjeh Nassirtoussi 等（2014）[22]早期的综述指出，基于词典和机器学习的方法是当时的主流。Loughran 和 McDonald（2011）[23]在其高被引研究中指出，直接套用通用英语情感词典（如 Harvard IV-4）分析金融文本会产生显著偏差。例如，“tax”、“cost”等词在通用语境下通常被视为负面，但在金融文本中更多属于中性描述。基于此，他们构建了专用的英文金融情感词典（LM 词典），并验证了其在解释股票收益、波动率和信息披露反应方面的有效性，奠定了金融文本情绪分析的经典范式。

国内学者也围绕中文金融文本的语言特征展开了进一步探索。姚加权等（2021）[24]基于中文上市公司年报构建了金融情绪词典，实证发现情绪指标对企业违约风险具有显著预测能力。林建浩等（2021）[25]则聚焦央行沟通文本，通过构建货币政策情感词典，量化了央行措辞变化对债券市场收益率和波动的影响。近年来，也有研究开始关注中文政策与宏观文本的语义特征，段从强（2025）[26]以《中国货币政策执行报告》为研究对象，构建了面向央行政策语境的领域词典，发现央行文本情绪信息对股票市场收益率具有显著预测能力，尤其对成长型资产的政策情绪信号敏感性更高，表明政策表述中的情绪倾向对金融市场预期具有显著引导作用。

实际上现有研究多以股吧、微博等散户生成文本为研究对象，针对官方宏观新闻文本的情绪度量仍相对不足。官方媒体文本《新闻联播》具有措辞高度规范、语义含蓄、政策指向性强等特点，通用情感词典往往难以识别“稳中求进”、“逆周期调节”、“防范化解风险”等表述背后的政策信号，容易导致情绪测度出现“中性

中国知网 https://www.cnki.net

化偏差”。因此，构建适配特定宏观语境的领域词典，仍是提升情绪特征有效性和经济解释力的关键路径。

Hochreiter 和 Schmidhuber（1997）[27]提出的长短期记忆网络（LSTM）在建模序列依赖关系方面表现突出，为文本与时间序列融合建模提供了重要工具。早期研究中，Antweiler 和 Frank（2004）[28]利用朴素贝叶斯和支持向量机对互联网股票论坛文本进行分类，发现网络舆情对股票交易量具有显著预测作用，Fischer 和 Krauss（2018）[29]将 LSTM 应用于金融市场预测任务，证明其在捕捉非线性特征方面优于传统随机森林模型。杨晓磊等（2021）[30]构建了结合 LSTM 网络与文本情感分析的股票指数预测模型，证明了深度学习在处理非线性文本数据上的优势。与此同时，分布式词向量模型的发展弥补了传统词袋模型无法刻画语义相似性的缺陷，如 Mikolov 等（2013）[31]提出的 Word2Vec 技术，使文本表示从“词频统计”向“语义空间映射”转变。早期研究中，Karen Spärck Jones（1972）[32]首次提出逆文档频率（IDF）的统计解释，将其作为衡量词语区分能力的核心指标，为后续文本权重计算方法奠定了重要理论基础。Salton 和 Buckley（1988）[33]对 TF-IDF 权值进行了系统的实验比较与优化，将其广泛应用于自动索引与信息检索中，为当今文本挖掘的发展奠定了重要基础。陈锐等（2021）[34]通过实证对比发现，相比于 TF-IDF 和 Word2Vec，基于 Transformer 架构的 BERT 模型在中文财经文本的情感分类任务中表现最优，能更精准地提取语义特征。

2018 年 BERT 模型的提出，标志着 NLP 进入了“预训练+微调”的新时代。为了兼顾统计特征与语义深度，李梦军等（2023）[35]提出了一种融合 TF-IDF 与 BERT 的混合模型，有效提升了金融政策文本情绪量化的准确度。Devlin 等(2019)[36] 提出的 BERT 模型通过双向 Transformer 编码，进一步刷新了多项 NLP 任务的记录。Araci(2019)[37]提出的 FinBERT 模型在金融情感分类任务上取得了 SOTA 效果。最新的研究如沈艳等（2024）[38]已开始利用大语言模型（LLM）解析新闻叙事，进一步提升了文本信息的颗粒度与解释力。Hong 等（2025）[39]进一步结合注意力机制，实现了对财经新闻重点摘要的自动提取与情感打分。

尽管深度学习模型在准确率上屡创新高，但在金融实战应用中也暴露了局限

中国知网 https://www.cnki.net

性。Ribeiro 等（2016）[40]指出，高维深度神经网络存在严重的"黑箱"问题，难以解释模型是依据哪些特征做出的投资决策，并提出了 LIME 方法以增强模型的局部可解释性。虽然 FinBERT 在情感分类上表现优异，但其缺乏可解释性，难以指导具体的投资决策。此外，深度学习模型通常依赖海量标注数据，而对于宏观政策文本这类低频小样本数据，复杂模型更容易出现过拟合。相比之下，改进的词典法在可解释性、计算效率和小样本适应性上具有独特优势，更适合处理《新闻联播》这类低频、高权重的文本数据。

1.2.3 异构数据融合方法研究

单一数据源往往存在信息偏差，异构数据融合已成为提升预测精度的关键。王芳等（2023）[41]明确提出基于异构数据融合的股票市场趋势预测框架，通过结合结构化交易数据与非结构化新闻文本，显著降低了模型的预测误差。在具体融合策略上，黄毅等（2023）[42]构建了文本增强模型，将《新闻联播》中的政策信号作为外生变量引入沪深 300 指数预测，结果证实政策文本包含的先行信息能有效修正纯量化模型的滞后性。周颖等（2021）[43]则从宏观视角出发，利用词典与 TF-IDF 融合方法量化政策文本，并验证了其对市场收益率的解释力度。此外，高明华等（2022）[44]的实证分析也表明，在量化投资策略中纳入财经新闻因子，能够构建出更具鲁棒性的超额收益组合。

特征级融合是目前金融预测中最经典且应用最广泛的范式。其核心思想是在模型输入之前，先分别提取文本的情感特征和市场交易特征，将其拼接为一个统一的高维特征向量，再输入机器学习模型进行训练。Noel 和 Peterson（2014）[45]采用隐狄利克雷分布（LDA）提取新闻主题分布，将其与历史波动率拼接，利用逻辑回归模型预测股市波动，证实了文本特征能显著降低预测误差。在算法选择上，集成学习表现出显著优势。Chen 和 Guestrin（2016）[46]提到，由于 XGBoost 算法对稀疏数据的处理能力、特征重要性输出功能以及防止过拟合的正则化机制，成为了特征级融合的首选模型。Dibris（2019）[47]的实证研究进一步表明，在特征级融合框架下，基于随机森林、XGBoost 树模型的集成算法在处理高维异构数据时，其鲁棒性往往优于单一的神经网络模型。

中国知网 https://www.cnki.net

随着深度学习的发展，研究者开始尝试模型级融合，目的是在模型内部实现多模态信息的交互。Cohen 等人（2018）[48]提出一种方法，使用推特文本以及其对应的历史价格序列来预测股票价格变动趋势，为之后将文本作为输入融入到时间序列预测工作提供思路。Yan（2018）[49]提出了混合注意力网络（HAN），在新闻序列和时间序列之间构建了层次化的注意力权重，有效解决了异构信息在时间轴上的对齐难题。而最新的工作更进一步发展该想法：Sarkar 和 Vadivu（2025）[50]提出了一种结合 VAE、Transformer 以及 LSTM 的方法来更好地捕捉价格与隐含因素之间的非线性联系；Xu 等人（2025）[51]利用混合专家方法将推文和新闻文本与价格时间序列关联起来，以提升预测准确性和可解释性。

决策级融合是一种“分而治之”的方法论，即对文本数据以及交易数据各自建立一个单独子预测器，在得到所有子预测器预测后，再把这些子预测器结果结合起来或者加权平均形成最后预测值。Li 和 Pan（2021）[52]基于集成学习设计一种深度神经网络结构，其中包含若干个递归神经网络分别作为价格序列和文本情感指标对应子预测器，而在最顶层有一个神经网络把这些子预测器预测结合在一起，实验表明这种方法对于方向正确性和鲁棒性都比单个模型更好。Kong 等（2023）[53]提出的 EL-MTSA 模型使用多种神经网络作为基本预测器，在预测阶段利用集成方法对结果进行综合，以提高融合模型对于各种市场情况的鲁棒性。

虽然深度学习模型可以较好地发现非线性关系，但是由于特征级融合具有良好的可解释性和鲁棒性，在少量数据情况下更优，因此本论文采用基于特征工程技术以及机器学习方法相结合的方式进行建模。

1.2.4 文献评述

目前有关基于股票市场文本信息挖掘以及异构数据融合进行预测的研究工作，在理论上、方法论上乃至实证分析层面均已形成较为完善的体系，对本文的研究具有良好的指导意义。但是针对我国 A 股“政策驱动型”的特点，以及沪深 300 指数的宏观走势进行预测的问题，现有的研究还存在着三个需要进一步提升的地方，也是本论文的重点所在：

其一，数据源选择与政策信号挖掘存在偏差。现有金融文本挖掘研究大多以

中国知网 https://www.cnki.net

股吧、财经论坛、社交媒体等用户生成内容为核心分析对象，这类数据虽具备高频特征，但存在噪声高、信噪比低、情绪表达非理性化等问题，难以精准捕捉国家宏观政策的核心意图与导向。而《新闻联播》作为国内最具权威性的官方信息发布渠道，其内容集中体现了宏观经济调控方向、产业政策导向与市场预期管理目标，是 A 股市场核心的政策信号来源，但现有研究对其特定的正式话语体系、政策信号传导机制缺乏系统性的量化分析，对官方权威文本的资产定价价值挖掘严重不足。

其二，异构数据融合的时序处理逻辑存在缺陷。文本信息的连续发布与股票交易数据的间断性特征，决定了异构数据融合必须解决时序错配的核心问题。但现有研究大多简单剔除非交易日的文本数据，或采用简单均值平滑的方式处理休市期信息，普遍忽视了非交易日政策信息的累积效应与跨期传导特征。这一处理方式不仅会造成周末、节假日发布的重大政策信号丢失，也违背了 A 股市场“周一效应”的内在信息传导逻辑，最终导致宏观政策信息对市场的真实影响被低估，也削弱了融合模型的预测有效性。

其三，文本量化范式与实证验证体系的严谨性不足。在政策文本量化方法层面，现有研究多采用单一量化范式，要么直接套用通用情感分析模型造成语境错配，要么仅采用 TF-IDF 等单一统计方法，鲜有针对官方政策文本的正式话语体系，系统对比不同文本量化方法的静态拟合能力与动态投资实战价值的研究，未能厘清不同量化方法在政策文本分析中的适用性边界。在实证验证层面，多数研究依赖单一预测模型开展静态回测检验，不仅难以规避前视偏差与过拟合问题，也缺乏多模型交叉验证的严谨性设计，导致研究结论的普适性与稳健性难以得到充分保证。

基于上述不足，本文以有效市场假说、行为金融学理论与适应性市场假说为理论支撑，构建了“多维度文本量化、异构数据时序融合、多维度实证检验、多视角稳健性分析”的完整研究框架。具体而言，本文首先构建适配官方政策语境的金融领域专用情感词典，同时设计全量 TF-IDF 与筛选优化 TF-IDF 两类文本量化方案，形成多维度的政策文本量化体系；其次通过非交易日信息累积机制，实现政策文本与交易数据的严格时序对齐，构建多组对照特征数据集；最终基于

中国知网 https://www.cnki.net

动态滑动窗口回测框架，结合多模型交叉验证，系统检验官方权威文本的增量定价价值，验证其对沪深 300 指数短期趋势预测的提升作用，尤其聚焦其在市场风险识别层面的核心应用价值。

1.3 研究方法与技术路线

1.3.1 研究方法

（一）文献分析法。本文首先采用文献分析法，对股票市场预测、市场有效性理论以及宏观文本信息与市场情绪关系等领域的研究进展进行综述，重点总结现有研究在数据来源、变量构造与建模方法等方面的成果与局限。

（二）多文本特征构建法。针对宏观文本信息难以直接用于量化建模的问题，本文采用文本量化方法对《新闻联播》文本进行结构化处理，通过构建领域专用词典、全量 TF-IDF、筛选后优化 TF-IDF 三类特征体系，通过这三种文本处理方法，共同验证《新闻联播》政策文本对股市的影响。特征构建中不仅包含当期特征，还引入滞后项刻画宏观信息跨期影响。针对新闻文本非交易日发布与股市交易日开市的时间错配，设计非交易日信息累积映射机制，将周末及节假日文本信息映射至下一个交易日，实现宏观文本与金融市场数据的时间对齐。

（三）多模型验证。在模型构建方面，本文引入 Logistic 回归、随机森林、XGBoost 三类主流预测模型对沪深 300 指数未来一个交易日的涨跌方向进行预测。XGBoost 作为一种基于梯度提升的集成学习算法，具有处理非线性关系能力强、对高维特征适应性好等优点，已被广泛应用于金融预测研究中。为保证模型比较的公平性，本文在基准模型与融合模型中均采用相同的分类器算法及参数设定，仅在输入特征层面进行区分。其中，基准模型仅使用价格类技术指标，而融合模型在此基础上引入政策文本特征，以检验文本信息的增量预测价值。

（四）滑动窗口回测与策略评估方法。考虑到金融市场环境具有明显的时变特征，本文采用滑动窗口回测方法对模型进行训练与测试。通过设定固定长度的训练窗口，模型在每一期仅使用历史可得信息进行预测，有效避免了未来信息泄露问题。在策略评估方面，本文构建当模型预测指数上涨时持有沪深 300 指数，预测下跌时选择空仓的策略。通过将基准模型、融合模型及“买入并持有”策略的

中国知网 https://www.cnki.net

回测结果进行对比，分别从预测性能指标和投资收益风险指标两个层面，对模型的实际应用价值进行综合评估。

1.3.2 技术路线

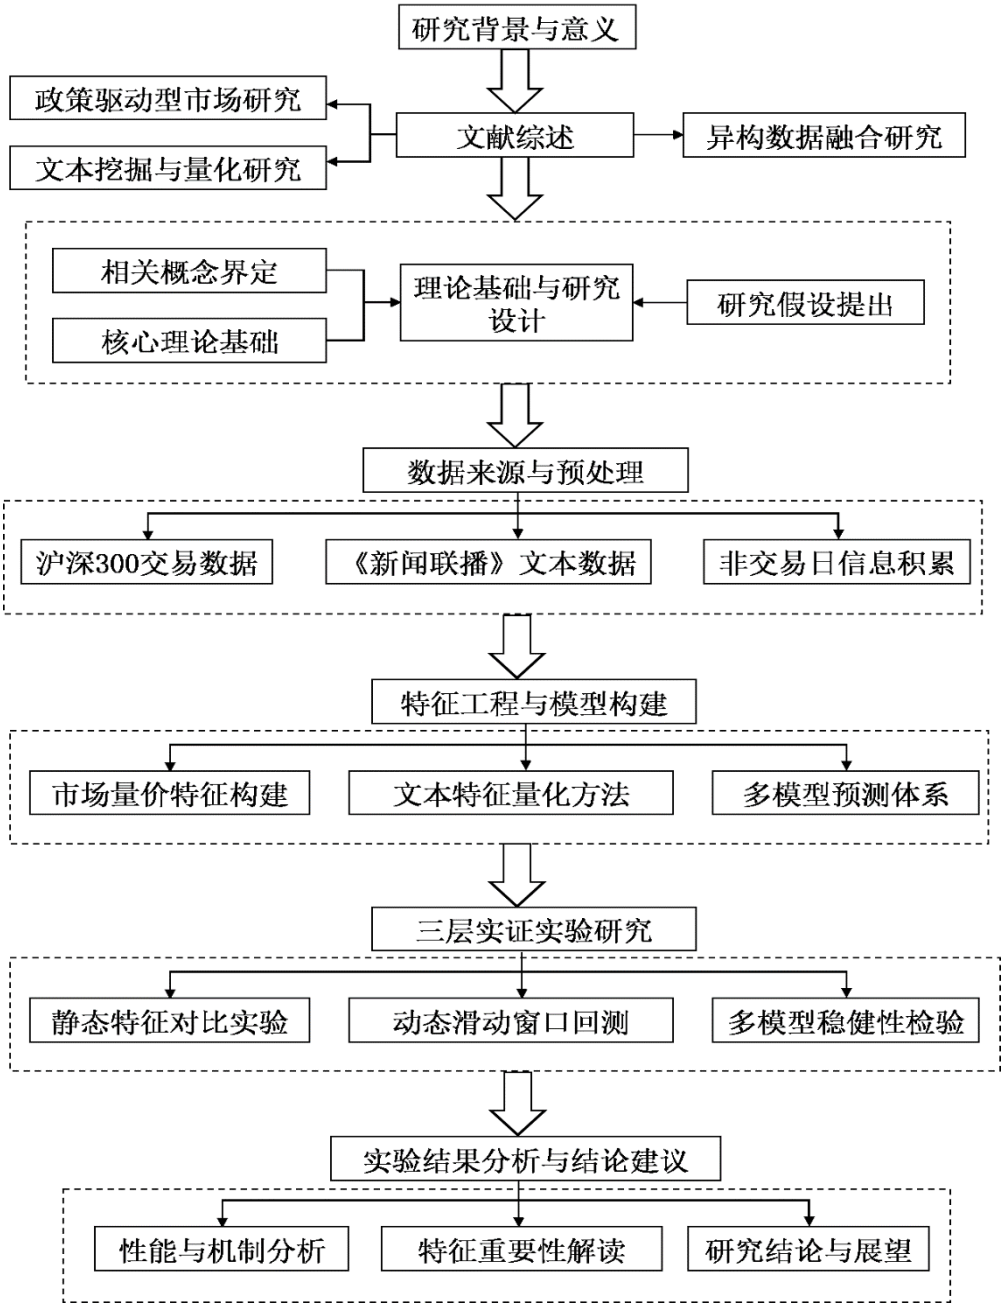


图 1.1 论文技术路线图

中国知网 https://www.cnki.net

1.4 研究内容与创新点

1.4.1 研究内容

本文围绕“异构融合数据是否能够提升沪深 300 指数趋势预测能力”这一核心问题展开研究，聚焦于如何有效融合《新闻联播》所承载的宏观政策信号与市场量价特征，系统分析不同文本特征表示方法及模型结构对预测效果的影响，以提升对指数短期趋势（特别是下行风险）的预测能力。具体研究内容如下：

（1）构建股票市场与宏观文本的异构数据集。本文选取 2023 年 1 月至 2025 年 12 月沪深 300 指数交易数据以及《新闻联播》文本作为研究对象。在数据处理方面，对市场交易数据提取收益率、成交量变化及技术指标等特征；对文本数据进行分词处理，并构建金融领域情感词典，提取政策风险、信心等维度的文本特征。同时，为解决文本数据与交易日之间存在的时间错配问题，设计非交易日信息累积机制，实现异构数据的有效对齐与融合。

（2）构建多种文本特征表示方式并进行比较分析。在原有基于领域词典构建文本特征的基础上，进一步引入 TF-IDF 方法对宏观文本进行向量化表示，并通过特征筛选方法降低高维文本特征带来的噪声影响，形成多种不同的数据集，包括仅价格特征数据集、词典融合数据集、TF-IDF 融合数据集以及筛选后 TF-IDF 融合数据集。通过实验比较不同文本表示方式在市场预测中的效果，分析宏观文本信息在指数预测中的作用。

（3）构建滚动预测模型并进行交易回测由于 A 股市场具有明显的阶段性特征，在此基础上本文使用滑动窗口的方式建立一个动态预测模型，在此基础上根据该模型的预测结果给出一种简单的交易策略然后通过回测的方式对不同的模型进行比较，从收益率、夏普比率及最大回撤等方面考察异构数据融合对实际投资的意义。

（4）进行多种模型实验进一步检验结果的鲁棒性。为了进一步保证文章所得到的结果具有可靠性，在不同的机器学习模型中进行对比实验，有 Logistic Regression、Random Forest、XGBoost 等模型，同时将只利用价格特征和结合文本特征两种情况下的模型表现进行对比，以此来考察研究结论是否稳定可靠。

中国知网 https://www.cnki.net

本文共分为五章，各章节具体安排如下：

第一章 绪论。阐述论文的研究背景与研究目的，总结了目前国内外学者关于股票市场的预测、金融文本挖掘以及异构数据融合的相关研究成果，在此基础上提出本文所要解决的问题、本文的研究内容、技术路线以及创新之处。

第二章 理论基础。从有效市场假说、行为金融学以及适应性市场假说出发，探讨信息对于股票市场的作用机理；其次分析宏观政策文本如何影响投资者预期，同时简要介绍了文本挖掘以及机器学习的相关知识，为后文的研究奠定基础。

第三章 数据说明与特征工程。阐述本文所使用数据来源以及时间范围，对沪深 300 指数交易数据以及《新闻联播》文本数据进行预处理，在此基础上提取出市场技术指标以及各种各样的文本特征，然后将这些不同的数据按照时间同步并组合起来得到不同类型的数据集用于后续工作。

第四章 模型建立及实证研究。首先建立预测模型并且设计实验方案，对比不同文本特征融合方式；其次运用滑动窗口法进行滚动预测以及投资策略回测，在预测能力和投资收益上对模型进行评价；再次进行多个模型实验以保证结论可靠性并分析不同特征对于指数预测影响。

第五章 结论与展望。概括本文主要研究成果，指出不足之处以及未来研究方向等。

1.4.2 创新点

本文基于中国 A 股市场具有显著政策导向性的特点，在已有股票指数预测相关文献对权威政策信息重视程度不够、文本特征表示手段有限以及异构数据应用不足的基础上，从三个方面进行分析探讨。主要贡献如下：

（1） 引入官方权威宏观文本作为市场预测信息来源。

目前对于多源数据融合的研究大多采用社交媒体、论坛评论或者财经新闻这类高频的情绪数据，尽管这些数据比较多，但是往往具有噪音大、质量不佳的特点。本文选取《新闻联播》作为宏观政策信号源，将其文本信息与时序化的沪深 300 指数成交量、成交额进行异构融合。实证分析发现，在加入市场技术指标后，权威政策文本也可以对指数走势起到一定的辅助作用，进一步丰富了宏观政策文

中国知网 https://www.cnki.net

本对于金融市场的应用范围。

（2） 构建多种文本特征表示方法并开展系统比较分析。

在传统的基于领域词典提取文本特征的基础上，进一步采用 TF-IDF 表示方法并利用特征选择降低高维文本特征维度，得到多个不同类型的异构融合数据集。对比各种不同的文本表示方法对指数预测的影响，在一定程度上探讨宏观政策文本信息对于金融市场的作用机理，丰富文本特征应用于金融领域的实证研究。

（3）设计了时序对齐机制与滚动预测、投资回测的动态验证框架。

针对异构数据融合研究中常见的时间错配与静态评估问题，本文设计了非交易日信息累积机制，实现连续发布的政策文本与交易日市场数据之间的时序对齐，从而更好地保留政策信息在休市期间的累积影响。同时，在模型评估方面，构建了“静态预测性能评估—滑动窗口动态回测—多模型稳健性检验”的综合验证框架，不仅从分类指标角度评价模型预测能力，还从投资收益与风险角度检验模型的实际应用价值，并通过 Logistic 回归、随机森林和 XGBoost 等多模型实验验证研究结果的稳定性，提高了研究结论的可靠性。

中国知网 https://www.cnki.net

2 理论基础

股票市场并非仅由历史价格和成交量所驱动，信息的产生、传播与解读过程在资产定价中发挥着核心作用。特别是在以政策调控和预期管理为重要特征的中国资本市场中，宏观政策信息及官方权威文本对市场预期和价格走势具有不可忽视的影响。本章从信息与价格关系的一般理论出发，系统阐述宏观政策文本影响股票市场的内在机制，并进一步论证宏观文本信息可被量化以及市场预测需采用动态视角的理论合理性，为后续实证研究奠定理论基础。

2.1 信息对股票价格影响的理论基础

2.1.1 有效市场假说与信息反应的非完全性

股票市场的价格波动并非孤立的数字变化，而是信息输入、投资者预期形成与交易行为共同作用的结果。从理论角度看，解释宏观新闻及政策信息为何可能影响市场价格，需首先回到金融学关于信息与价格关系的基本理论框架。

有效市场假说（EMH）是理解信息定价机制的核心理论。其早期思想可追溯至 Gibson（1889）对欧美证券市场的观察，随后经 Jensen、Fama 等学者系统化发展，引入随机游走与事件研究方法，逐步构建起以“信息效率”为核心的市场分析范式。Fama（1970）根据信息集的不同，将市场有效性划分为弱式、半强式和强式三种形态，其中半强式有效市场假定所有公开信息能够被迅速、充分地反映在资产价格之中。然而，该理论建立在投资者完全理性和信息即时无成本传播的理想假设之上，与现实市场存在明显偏离。尤其在新兴资本市场中，信息获取渠道不均、制度环境复杂以及市场参与者结构差异，使得价格对公开信息的反应往往存在滞后或偏差。大量实证研究表明，此类市场更多呈现出弱式有效甚至阶段性无效的特征，为基于公开信息的趋势分析提供了理论空间。

行为金融学从“有限理性”视角对 EMH 作出重要补充，指出投资者在信息处理过程中受到注意力约束、认知偏差和情绪因素的影响。相较于结构化的财务数据，宏观政策表述和新闻文本具有表意模糊、语境依赖性强等特征，投资者难以在短时间内完成准确解读，进而导致市场对信息的反应不足或过度反应。这种

中国知网 https://www.cnki.net

信息吸收过程中的非理性偏差，使价格对信息的反映呈现出渐进性特征。

而在资本市场上，信息不对称普遍存在，在机构投资者与普通投资者之间也存在着信息获取能力以及对于信息的理解程度不同的情况，所以市场价格不能充分反映所有可获得的信息。而 Grossman-Stiglitz 悖论表明，在信息获取需要付出一定代价的情况下，完美的市场从理论上讲是不可能实现的。因此，在这样的情况下，投资者进行买卖决定更多基于对未来的一种主观判断而不是对现在公司基本情况非常清楚的认识。

官方宏观新闻由于面向全市场发布是公开信息，因此它本身并不直接导致市场参与者的情绪变化，而是在于以权威的声音对宏观经济状况以及政府的态度进行解读进而影响市场的预期形成过程，在政策不断释放并且被市场逐渐接受之后便会出现一致性预期并在市场上表现为某种趋势的变化，这也正是可以从宏观文本的信息中提取出有价值的信号的原因所在。

2.1.2 信息传导机制

宏观新闻对股市影响不是直接发生的，而是经过“信息→预期→行为→价格”的过程。如图 2.1 所示为本文所建立的金融市场多源信息传导路径。

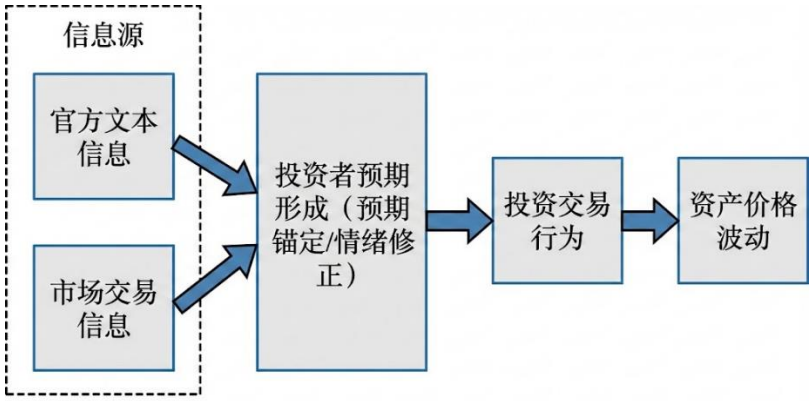


图 2.1 金融市场多源信息传导机制示意图

如图所示，官方文本信息是外生冲击因素，通过对投资者风险偏好以及现金流预期的影响而作用到市场上内生的量价交易信息上，进而决定资产价格变动方向。

中国知网 https://www.cnki.net

2.2 宏观文本对市场的影响机制

2.2.1 市场预期与政策信号

不同于社交媒体中的散户评论，本文所关注的官方宏观文本具有显著的政治经济学属性。《新闻联播》作为权威信息发布渠道，其内容经过高度凝练，集中反映宏观经济形势、政策导向及监管态度，在市场预期管理中发挥着重要作用。根据信号传递理论，政策制定者通过官方媒体向市场释放具有明确指向性的信号。这些信号并非简单的情绪表达，而是旨在减少市场不确定性，为经济主体提供预期锚定。例如，在经济下行压力加大时，强调“稳增长”“提信心”有助于稳定市场预期；而在资产价格过快上涨阶段，频繁提及“防风险”“去杠杆”则具有警示非理性繁荣的作用。

因此，官方宏观文本对市场的影响主要体现在引导和修正投资者预期，而非直接引发短期情绪波动。当市场参与者逐步形成对政策方向的一致性认知时，这种预期变化将通过资金配置行为反映在指数层面的趋势调整之中。

2.2.2 政策信号的渐进性特征

从时间的角度看，交易数据中的价格、成交量是高频变量，但是宏观政策信号一般而言是“慢变量”。因为政策要经过发布、解释、实施并最终产生影响需要一定的过程，在这个过程中，政府文件对于市场的影响力并非一次性的，而是一个渐进的过程以及一种导向作用。一个单独的政策用语在一个交易日内不一定能引起剧烈变化，但是当类似信号不断出现时，市场就会出现根本的变化，比如频繁提到“风险防范”、“信心”。这也就是为什么我们在特征工程中使用“非交易日的信息积累机制”而不是单纯的日内波动的原因。

2.3 宏观文本信息量化的理论基础

2.3.1 非结构化文本信息的量化路径

宏观政策文本属于典型的非结构化信息，无法直接用于数量化分析。然而，

中国知网 https://www.cnki.net

从信息经济学角度看，文本中所包含的关键词、表述强度及语义重心，实质上反映了政策制定者对宏观环境的判断和政策意图。通过对文本内容进行系统整理和抽象，可以将原本定性的政策表述转化为可比较的数量化信号。这一过程并非试图还原文本的全部语义结构，而是关注其中具有经济含义和定价价值的核心信息，从而为量化建模提供输入基础。

2.3.2 领域词典构建的方法论基础

在宏观政策文本分析中，基于领域知识构建的词典方法具有较强的适用性。相较于通用情感分析方法，领域词典能够更准确地识别政策语境下具有明确经济含义的关键词，从而减少噪音干扰。此外，词典方法具有较强的可解释性优势。通过明确不同关键词所代表的政策含义，可以从经济学角度理解文本信号对市场的潜在影响机制。这一特性使其尤其适用于强调理论逻辑和经济解释的研究场景。

为了使以上词典成为可以量化的数值，我们利用词袋模型作为基本文本表示方式。词袋模型是自然语言处理中最常用也是最基本的一种表示方法。即把一篇文档当作一个包含词语的大箱子，在此基础之上，文档就仅仅是一堆词语组成的集合，并且基于下面两点：

（1）词语独立性假设：忽略词汇在文本中出现前后关系以及它们之间的语法关系。

（2）频率重要性假设：词汇在文本中出现的频率是衡量其重要性的主要指标。

尽管这一假设牺牲了部分语义连贯性信息，但在处理具有高度格式化、措辞严谨的官方宏观新闻时，该模型能够有效捕捉核心议题和关键词信号。例如，无论“防范金融风险”出现在句首还是句尾，只要“风险”一词高频出现，即代表了当日政策信号的重心。通用的词袋模型通常利用全量词汇构建高维向量空间，但这会引入大量与市场波动无关的噪音。为了从海量文本中精确提取具有定价含义的政策信号，本研究专门构建了适配《新闻联播》官方语境的专用金融词典，包含“风险”、“信心”、“政策支持”等维度。词典匹配的具体原理如下：“遍历新闻联播文本序列，将其与预定义的词典进行匹配。若词元存在于词典中，则将其识别为

中国知网 https://www.cnki.net

有效信号；否则视为背景噪音予以忽略。基于匹配结果，计算当日文本在特定维度下的政策信号强度。”相较于 BERT 等深度学习模，词典法在金融实战中具有更高的可解释性——即能够清晰溯源是哪个关键词导致了预测结果的变化。

本文中政策信号强度(PSI)的计算基于词频统计与权重加权。假设文本集合为 D，特定维度的信号词典集合为 Lsignal，则第 t 日的新闻文本的政策信号强度指数PSI_t计算公式如下：

$$PSI_t = \sum_{w \in D_t \cap L_{risk}} (Freq(w) \times Weight(w)) \quad (1)$$

其中，Freq(w)为词语 w 在当日文本中的出现频次， Weight(w)为该词的权重，本研究中，为避免主观偏差，基础权重设为 1，通过这一方法，本研究成功将非结构化的《新闻联播》文本转化为连续的时间序列信号，为后续异构数据的时序对齐与融合建模提供了标准化的输入特征。

2.3.3 基于 TF-IDF 的文本量化方法

TF-IDF 是信息检索与文本挖掘领域经典的统计型文本量化方法，其核心逻辑是通过双重权重调整，衡量一个词汇对特定文档在整个语料库中的代表性与区分度。该方法的核心假设包含两层：

第一，词频（TF）维度，一个词汇在单篇文档中出现的频率越高，其对该文档核心语义的表征能力越强，为消除不同文档长度的影响，通常采用频次归一化处理，公式为为：

$$TF_{i,j} = \frac{n_{i,j}}{\sum_{k=1}^{N} n_{k,j}} \quad (2)$$

其中，$n_{i,j}$为词汇 i 在第 j 篇文档中出现的次数，$\sum_{k=1}^{N} n_{k,j}$为第 j 篇文档中所有词汇的总数量，N 为文档 j 中的总词汇数。在本文的研究场景中，单篇文档对应单日的《新闻联播》完整文本，语料库为样本期内所有《新闻联播》文本构成的全集。

第二，逆文档频率（IDF）维度，逆文档频率用于衡量词汇在整个语料库中的稀缺性，一个词汇在整个语料库中出现的文档数越少，其对特定文档的区分度与信息价值越高，反之，在全语料库中普遍出现的通用词汇，其语义区分度与信息含量越低。其公式为：

中国知网 https://www.cnki.net

$$IDF_i = log\left(\frac{|D|}{|\{j:t_i \in d_j\}|+1}\right) \quad (3)$$

其中，|D| 为语料库中的总文档数，$|\{j: t_i \in d_j\}|$为包含词汇 i 的文档数量，分母加 1 是为了避免词汇未在语料库中出现时产生的分母为 0 的异常情况。

与词袋模型仅关注词频统计的逻辑不同，TF-IDF 通过逆文档频率对通用词汇进行权重惩罚，对特定文档的专属核心词汇进行权重放大，能够有效过滤文本中的无意义通用词汇，精准捕捉单篇文本的核心语义特征，是目前非结构化文本向量化处理中应用最广泛的基础方法之一。

TF-IDF 的数值为词频与逆文档频率的乘积，其中词频指某一词汇在单篇目标文档中出现的频次，为消除不同文档长度的影响，通常采用频次归一化处理，公式为：

$$TF - IDF_{i,j} = TF_{i,j} \times IDF_i \quad (4)$$

通过该公式计算后，即可将单日《新闻联播》的非结构化文本，转化为以词汇为维度、TF-IDF 值为权重的结构化数值向量，完成文本数据的向量化量化处理。

TF-IDF 方法对本文选取的《新闻联播》宏观政策文本具备良好的场景适配性。该方法可通过逆文档频率权重调整，自动过滤全样本期内的通用政策表述，放大特定时间窗口内集中出现的政策关键词权重，精准捕捉阶段性政策转向信号；同时作为无监督量化方法，其无需预定义词表，可有效弥补领域词典法的词汇覆盖局限，捕捉样本期内新兴的政策表述与语义信息；此外，该方法计算逻辑简洁，无需大规模标注数据，能够适配《新闻联播》低频高密的文本特征与金融时间序列的小样本属性，与后续机器学习预测模型具备良好的兼容性。

全量 TF-IDF 向量化处理后生成的高维特征矩阵，直接用于指数预测将面临维度灾难与噪声干扰两大核心问题，过高的特征维度不仅会降低模型训练效率与泛化能力，大量与资产定价无关的背景词汇也会稀释有效政策信号的权重，甚至引发模型过拟合。对此，本文引入特征筛选机制，其核心逻辑在于通过统计检验与特征重要性排序相结合的方式，剔除无预测价值的噪声特征，仅保留对沪深 300 指数涨跌具备显著解释力的核心 TF-IDF 特征，在保留方法语义捕捉优势

中国知网 https://www.cnki.net

的基础上实现降维降噪，平衡模型的信息捕捉能力与泛化性能。

2.4 机器学习与模型评估的理论基础

2.4.1 核心预测模型的理论基础

（1）XGBoost

核心原理：基于梯度提升树（GBDT）的改进算法，通过“逐棵树迭代训练+残差修正”优化目标函数，同时引入 L1、L2 正则化项与缺失值自动处理机制，平衡模型拟合能力与泛化能力。目标函数核心逻辑：

$$Obj = \sum_{i=1}^{n} l\left(y_i, \hat{y}_i^{(t)}\right) + \sum_{k=1}^{t} \Omega\left(f_k\right) \quad (5)$$

其中，$l(y_i, \hat{y}_i^{(t)})$为第 t 轮迭代的损失函数，$\Omega(f_k)$为正则化项。其对异构数据适配性强，能有效捕捉特征间的非线性关系与时序依赖，且训练效率高、防过拟合能力突出，是金融预测领域的主流算法，适合作为本文的核心预测模型。

（2）Logistic

核心原理：基于 sigmoid 函数将线性回归结果映射至 [0,1] 区间，实现二分类预测，其核心逻辑是通过最大化对数似然函数，求解最优回归系数以区分样本指数上涨或下跌。数学表达式：

$$P(y = 1|x) = \frac{1}{1+e^{-(w^T x+b)}} \quad (6)$$

其中，w 是特征权重向量,x 是输入特征向量,b 是偏置项,y=1 表示指数上涨,y=0 表示指数下跌。由于它是线性模型，可以直接观察特征权重符号，可解释性强，计算速度快，适合用作基准模型与非线性模型进行比较；而且对于少量的数据具有较好的鲁棒性，符合本文所研究的金融时间序列的小样本情况。

（2）Random Forest

基本思想：以“Bootstrap 抽样+随机特征选择”为基础生成许多决策树，在此基础上利用多数表决或者求平均的方法结合每棵树的结果来减少某一颗决策树带来的过拟合问题从而提高整个模型的鲁棒性。

具有天然的重要特征选择能力，不需要人工进行特征选取；对于异常值以及高维的数据具有较好的鲁棒性，可以捕捉到特征之间的非线性关联，适合处理金

中国知网 https://www.cnki.net

融领域中的复杂特征。能够很好地处理数量价格等特征与文本特征的异构融合的数据集，克服单一决策树容易受到噪声影响的问题，适合用作集成学习的基础模型，和 XGBoost 形成“基础集成-进阶集成”的比较。

2.4.2 模型评估指标的理论基础

为了对模型进行全方位评价其对于指数趋势预测以及应用于实际投资中效果如何，在此建立以分类预测能力和投资收益、风险管理能力为标准的评价体系。

（1）从预测效果来看，在分类性能上使用分类评价标准，包括准确率、召回率、F1-Score 以及 ROC-AUC 等对模型的趋势判断能力进行比较。

主要包括准确率（Accuracy）、召回率（Recall）以及 F1-Score，在准确率中计算方法是：

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (7)$$

其中，准确率为衡量模型整体判断正确的比例。式中：TP 为真阳性，TN 为真阴性，FP 为假阳性，FN 为假阴性

$$Recall = \frac{TP}{TP+FN} \quad (8)$$

其中，Recall 反映了模型捕捉市场真实上涨机会的能力。

$$F_1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (9)$$

其中，F1-Score 是精确率与召回率的调和平均数，用于评估模型在查准与查全之间的平衡。

（2）从策略角度，在本文中我们加入了累计收益率、夏普比率（Sharpe Ratio）、最大回撤（Max Drawdown）等评价标准来衡量该模型所获得收益以及它所承受的风险大小。

夏普比率是用来评价一个投资组合在其承担风险基础上获得超额回报程度的一个重要指标，由美国经济学家威廉·夏普于 1966 年提出的，用于衡量一个投资组合单位风险所获得超额回报，夏普比率越大说明在同等条件下这个投资组合获得超额回报越高，计算公式如下：

$$Sharpe = \frac{E(R_p)-R_f}{\sigma_p} \times \sqrt{252} \quad (10)$$

中国知网 https://www.cnki.net

其中，E(Rp) 为投资组合的期望年化收益率，Rf 为无风险利率，σp 为投资组合收益率的标准差，$\sqrt{252}$是将日度数据年化处理的因子

最大回撤衡量了策略在选定周期内可能遭受的最大本金损失，是机构投资者最为关注的风控指标，其公式为：

$$MDD = \mathrm{m}_{\tau\in(0,T)}[\frac{M_t - P_t}{M_t}] \quad (11)$$

其中，P_t为t时刻的策略净值，M_t为t时刻之后出现的最低净值。

2.5 市场时变性与动态建模的理论基础

2.5.1 市场时变性理论

行为金融与有效市场假说（EMH）最根本的分歧在于投资者是否理性。EMH 以“完全理性、无摩擦、无限套利”为基石，推导出价格即时反映信息的均衡结果；行为金融则以大量实验与田野证据指出，投资者普遍受制于认知偏差、情绪与制度摩擦，导致市场频繁出现泡沫、崩溃与异象。两派争论持续半个世纪，却始终难以在同一框架内解释“为何同一市场既会阶段性有效、又会阶段性失灵”。

Lo（2004）将生物进化论引入金融学，提出的适应性市场假说（AMH），他指出，市场效率并非固定不变，而是随着宏观经济环境、制度安排及投资者结构的变化不断演进，用适应度取代理性，用自然选择取代无套利均衡，一举化解上述张力。AMH 的核心思想可归纳为四条：

（1）理性是相对的、时变的——理性应被重新定义为“在当前环境下具有较高适应度的决策”，而非传统经济学意义上的最优化。

（2）偏差即学习——看似非理性的行为如追涨杀跌、羊群、过度自信是投资者在高不确定性环境下以“试错—反馈—修正”方式快速学习的进化表现；只要环境持续变化，偏差就会周期性出现与消退。

（3）前瞻与抽象——市场参与者具有抽象思维和前瞻性思维。会根据历史信息和经验对未来发展做出预测，这种机制使金融进化速度远高于生物进化。

（4）创新与竞争——策略拥挤导致收益递减，迫使市场参与者持续研发新的信息源、新的算法、新的叙事，以维持生存优势；技术创新本身就是适应性进

中国知网 https://www.cnki.net

化的产物。

AMH 把市场有效性视为动态光谱。当环境稳定、学习成本低、竞争充分时，种群平均适应度上升，市场趋近 EMH 所描述的有效状态；当环境突变、信息结构复杂、认知负荷超载时，适应度分化加剧，价格偏离基本面，出现可预测空间。由此，EMH 与行为金融不再互斥，而是分别对应“高适应度”与“低适应度”两种极端生态位；二者通过“环境—策略—适应度”反馈链实现周期切换，形成“适应良好→适应不良→再适应”的演化循环。

在该理论框架下，由于政策信号的影响具有滞后性和累积性，其作用更可能体现在市场趋势和阶段性变化之中，而非瞬时价格波动。这一理论逻辑为后续研究中采用滚动窗口回测设计的动态视角分析宏观文本信息的预测价值提供了重要依据。

2.5.2 滑动窗口动态建模的理论基础

静态建模与滑动窗口动态建模的核心理论差异，在于对市场数据时序特征及信息传导逻辑的不同认知，二者在建模逻辑与结果可靠性上存在显著区别。静态建模采用全样本数据一次性完成训练与验证，其核心假设是市场运行规律具有稳定性，即历史数据与未来数据遵循一致的分布特征，但这一假设与金融市场的实际运行逻辑相悖——金融市场受政策调整、宏观经济波动、投资者情绪变化等多重因素影响，呈现出显著的时变性特征，静态全样本建模易引入前视偏差，即训练过程中不自觉使用未来未发生的信息，导致模型拟合效果虚高，无法真实反映模型的实战预测能力，也难以适配市场的动态变化。

滑动窗口动态建模则有效规避了上述缺陷，其核心逻辑是仅利用当前时刻之前的历史数据构建训练样本，通过固定窗口大小的滚动更新，持续纳入新的历史数据、剔除过期数据，实现模型的动态迭代与优化。这一建模方式与适应性市场假说的核心逻辑高度契合，适应性市场假说认为，市场风格并非固定不变，而是随外部环境变化动态演化，投资者的决策行为、市场的信息传导效率也会随之调整，因此基于历史数据的动态建模的才能够捕捉市场的时变特征，贴合 A 股市场的实际运行规律。

中国知网 https://www.cnki.net

从研究逻辑来看，滑动窗口动态建模的理论合理性，为后续实证研究提供了坚实的理论支撑，也为后续通过滑动窗口动态回测检验模型实战价值、规避前视偏差、保证研究结论的稳健性，提供了理论层面的依据，进一步完善了市场时变性背景下动态建模的理论框架。

2.5.3 异构数据时序对齐与滞后处理

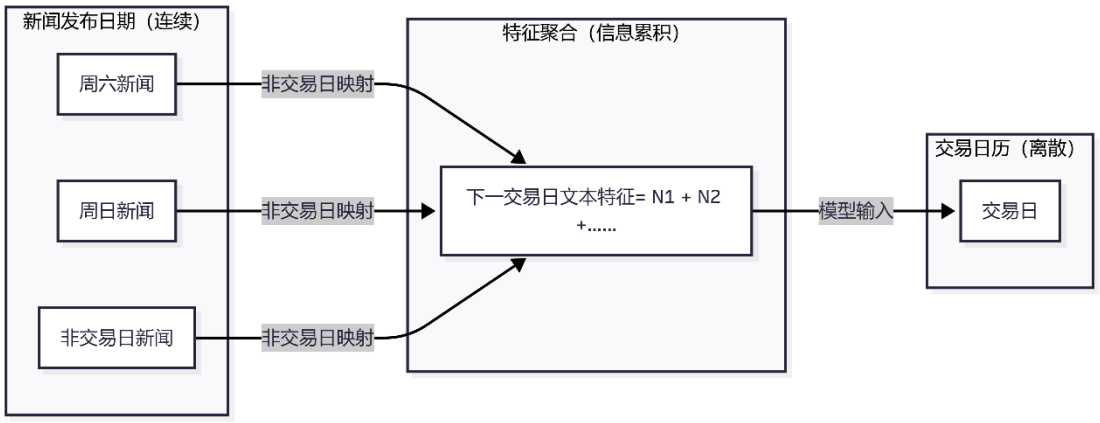
金融市场存在交易日与周末及节假日的差异，而新闻信息的发布是连续的。两者在时间维度上存在错配。若直接剔除非交易日的新闻数据，将导致重大政策信号（往往在周末发布）的丢失。基于前述“政策信号累积效应”理论，本文提出非交易日信息累积机制，即周一（或节后首个交易日）的文本特征应包含休市期间所有信息的总和。其映射机制与数学表达如下：

$$Feature_{t_{open}} = Feature_{t_{open}} + \sum_{k=1}^{N} \lambda \cdot Feature_{t_{open}-k} \quad (12)$$

其中，t_{open} 为开盘日，k 为休市天数，λ为信息衰减系数，鉴于宏观政策的时效性较长，本文设定λ =1，即完全累积

（1）交易日历映射：构建标准交易日历序列。对于每一个新闻发布日期t_{news}，向后寻找距离其最近的一个交易日t_{trade}。若t_{news}本身为交易日，则映射为当日。若t_{news}为非交易日（如周六），则映射为下一周的周一（或节后首个交易日）。

（2）特征聚合：利用聚合操作，将映射到同一交易日的所有新闻文本特征进行累加。这意味着，周一的模型输入特征不仅包含周一当天发布的新闻，还包含了上周六和周日积压的所有政策信号与舆情压力。



中国知网 https://www.cnki.net

图 2.2 文本与交易日对齐示意图

该机制有效解决了异构数据的时序对齐问题，符合金融市场中“周一效应”的信息传导逻辑。在金融市场中，信息从产生到被市场主体完全吸收并反映到资产价格中，通常存在一定的时间滞后。尤其是宏观政策类文本信息，其影响往往并非在发布当日一次性完成，而是通过投资者解读、预期调整及交易行为的逐步展开，对市场价格形成持续作用。

中国知网 https://www.cnki.net

3 数据与模型构建

本章在前文理论分析的基础上，以沪深 300 指数趋势预测为核心目标，系统完成研究数据的标准化处理、特征体系构建与预测模型的基础设计，为后续实证分析提供可复现、无偏的技术支撑。具体而言，本章首先明确研究样本的选取范围，详细说明沪深 300 指数量价数据与《新闻联播》政策文本数据的来源、获取方式及预处理流程，解决原始数据中的噪声、缺失值、格式不统一等问题；其次针对政策文本与交易数据的时序错配痛点，设计非交易日信息累积映射机制，实现异构数据的因果时序对齐；进而构建多维度特征体系，包括市场量价技术特征、领域专用词典特征、全量 TF-IDF 特征及筛选后优化 TF-IDF 特征，并基于此搭建四组对照数据集；最后明确基准模型与融合模型的构建框架，细化 XGBoost、随机森林、Logistic 回归三类模型的参数设置，同时设计科学的滑动窗口回测方案与实验分组逻辑，保证后续实证对比的公平性与严谨性。本章通过对异构数据的统一处理、特征工程的系统设计与实验方案的标准化定义，形成“数据清洗-时序对齐-特征构建-模型设计”的完整技术链路，为验证政策文本特征的增量定价价值奠定坚实的方法基础。

3.1 数据来源与样本说明

本研究涉及的数据主要分为非结构化的宏观新闻文本数据和结构化的市场交易数据。针对两类数据的不同特性，本文采用了以下获取与清洗策略。

3.1.1 市场数据

本文选取沪深 300 指数作为研究对象，市场交易数据通过 Python 量化接口 AkShare 获取。AkShare 是国内常用的开源金融数据接口库，能够稳定获取指数的日度行情数据，具有较好的数据完整性和可复现性。其中市场交易数据获取的数据字段主要包括获取的日度行情数据包含交易日期、开盘价、收盘价、最高价、最低价及成交量，数据频率为日度。研究样本区间覆盖 2023 年 1 月至 2025 年 12 月，基本涵盖了近年 A 股市场的多种典型行情阶段，数据字段说明与基本走

中国知网 https://www.cnki.net

势如表 3.1 和图 3.1。

表 3.1 沪深 300 指数市场数据字段说明表

字段名	中文字段	说明
date	交易日期	格式为 YYYY/MM/DD，表示该行情数据对应的交易日。
open	开盘价	当日沪深 300 指数在开盘集合竞价阶段形成的首笔成交价格。
high	最高价	当日指数盘中达到的最高点位。
low	最低价	当日指数盘中达到的最低点位。
close	收盘价	当日收盘集合竞价结束时的最终指数点位
volume	成交量	当日沪深 300 成分股合计的总成交股数。



图 3.1 2022 年 1 月-2025 年 12 月沪深 300 指数的走势图

3.1.2 宏观文本数据

宏观文本数据选取《新闻联播》作为信息来源。文本数据通过网络爬虫技术从公开网站获取，内容包括每日新闻正文文本。相比社交媒体或投资论坛文本，《新闻联播》具有发布主体权威、文本风格规范、政策信号明确等特点，更适合用于宏观层面的指数预测研究。

中国知网 https://www.cnki.net

在文本数据整理阶段，先对原始 HTML 文本进行解析，去除网页标签、广告干扰符及无意义的特殊符号。后对原始爬取内容进行了基础清洗，包括去除异常字符及无关信息，并统一文本编码格式。最终形成以“日期—新闻正文”为基本结构的文本数据库,如表 3.2。

表 3.2 新闻文本数据样例

文件名称	新闻正文（节选）
2023-01-02_新闻联播.txt	挺膺担当以奋斗姿态激扬青春……
2023-01-04_新闻联播.txt	会议指出，过去一年物价保持平稳，粮食、能源稳定供应能力提升，为稳经济、保民生提供了有力支撑……

3.2 预测特征构建

3.2.1 市场特征变量构建

特征工程是提升模型预测性能的关键。在数据预处理阶段，本文首先对原始行情数据进行排序与缺失值检查，随后基于收盘价计算日收益率，并构建后续模型所需的价格衍生特征。为避免前视偏差，所有价格特征均仅基于历史可观测信息计算。本文并未引入过多复杂的技术指标，而基于沪深 300 指数的日度行情数据选取了能够反映市场趋势、活跃度和风险状态的基础价格特征。一方面可降低模型过拟合风险，另一方面有助于突出政策文本特征的增量预测价值。主要包括：日收益率、成交量变化率、5 日波动率、5 日均线偏离率。上述特征均基于历史数据计算，避免使用未来信息，符合时间序列预测的基本要求，如表 3.3、3.4。

表 3.3 预处理后的沪深 300 指数数据

date	open	high	low	close	volume
2023/1/3	3864.836	3893.99	3831.245	3887.899	11505187500
2023/1/4	3886.25	3905.903	3873.655	3892.948	11066074300
2023/1/5	3913.493	3974.875	3912.26	3968.578	11650239500
2023/1/6	3969.549	4000.414	3966.47	3980.889	11095303800

中国知网 https://www.cnki.net

2023/1/9	3998.528	4023.09	3990.707	4013.12	11705442500
2023/1/10	4014.713	4030.457	4002.23	4017.474	10175114100
2023/1/11	4019.884	4043.399	4008.015	4010.031	9999788900

表 3.4 价格类特征变量定义表

特征名称	变量符号	经济含义说明
日收益率	pct_change	衡量沪深 300 指数在相邻交易日之间的价格变动幅度，用于刻画指数的短期走势方向，是趋势预测中最基础的价格信息。
成交量变化率	vol_change	反映市场交易活跃度的变化情况，用于刻画资金参与程度，对判断价格变动的有效性具有辅助作用。
5 日波动率	volatility_5d	用于衡量指数短期内的价格波动程度，刻画市场不确定性和风险状态，为模型提供风险环境信息。
5 日均线偏离率	ma5_ratio	描述当前价格相对于短期均线的偏离程度，用于刻画价格是否偏离其短期均衡水平，辅助判断趋势延续或均值回归特征。

以上价格特点用三条标准描述市场的状况，在保证特征集简单的情况下，有利于之后对宏观经济政策相关文档特征增量预测能力进行对比分析。

此外，引入滞后一阶特征有利于模型捕捉到宏观文本的信息时滞性影响，不至于把政策信号当成短期噪音，提高模型对于趋势性变化的识别度，在不需要增加过多额外复杂动态的情况下提高了模型对于信息传播机制描述的能力，符合金融时间序列预测中常用的特征构造思路见表 3.5.

表 3.5 价格滞后项特征

类别	特征名称	来源	经济含义
动量类	pct_change_lag1	前一日涨跌幅	动量延续效应
成交量类	vol_change_lag1	前一日量变	交易惯性
风险类	volatility_5d_lag1	前一日波动率	风险状态延续
趋势类	ma5_ratio_lag1	前一日乖离率	趋势惯性

中国知网 https://www.cnki.net

3.2.2 政策文本特征变量构建

（1）基于领域专用词典的文本特征

为了从非结构化文本中量化出具有定价意义的因子，且考虑到通用情感分析工具在处理官方新闻文本时容易出现情感评分失真问题，本文未直接采用现成的情感模型，而是基于领域知识构建了《新闻联播》文本专用情感词典，通过词袋模型计算政策信号强度。具体而言，本文围绕宏观政策语境，人工整理并构建了包含“风险”、“增长”以及“政策”三方面关键词，分别代表“压力维度”、“信心维度”和“稳定维度”，用于刻画文本中所隐含的不同政策信号方向，如表 3.6。

表 3.6 文本特征变量说明表

维度	变量名	核心关键词示例	信号含义
风险维度	risk_score	风险, 挑战, 严峻, 下行, 压力	警示市场潜在的系统性风险或经济承压
信心维度	boost_score	增长, 复苏, 信心, 新质生产力	传达经济向好预期，提振投资者情绪
政策维度	policy_stability	稳中求进, 调控, 金融稳定	传递政策托底与逆周期调节信号

为检验模型对词典规模的敏感性，本文进一步构建了“关键词数量精简—简化—丰富”三种版本的词典，并在后续稳健性检验中进行对比分析。

另外，信号强度计算基于上述词典，采用词频统计法计算每日的维度得分，将非结构化文本转化为数值型特征。同时，考虑到新闻文本长度波动的影响，引入文本长度 text_len 作为辅助特征。文本特征的一般形式可表示为：

$$Score_t = \sum_{i=1}^{n} w_i \times freq_{i,t} \quad (13)$$

其中，$freq_{i,t}$表示第t日文本中关键词i的出现次数，w_i为对应权重。在本文中，为保持方法简洁与可解释性，关键词权重设为相同。此外，本文还引入文本长度等辅助变量，用于反映当日宏观信息发布强度。

滞后处理特征如表 3.7。

中国知网 https://www.cnki.net

表 3.7 词典模型文本特征滞后项

类别	特征名称	来源	经济含义
政策风险信号	risk_score_lag1	前一日风险得分	刻画风险信号的滞后影响
政策提振信号	boost_score_lag1	前一日提振得分	反映政策利好信号的持续性
政策稳定性	policy_stability_lag1	前一日稳定性指标	刻画政策预期的惯性修正
文本强度	text_len_lag1	前一日文本长度	描述信息披露节奏的延续效应

（2）基于 TF-IDF 的全量文本特征



图 3.2 文本特征构建流程图

在领域专用词典方法的基础上，为进一步提升文本信息的表达能力，本文引入 TF-IDF 方法构建全量文本特征，以弥补词典法词汇覆盖范围有限的问题，从而更全面地捕捉《新闻联播》文本中可能影响市场预期的政策信息。

首先，对原始《新闻联播》文本进行统一预处理。具体包括：利用 Python 正则表达式工具对文本中的数字及无关字符进行清洗；随后采用 jieba 中文分词工具对文本进行分词处理，将连续语句转换为词语序列；同时加载百度停用词表构建停用词集合，去除常见功能词及单字词，仅保留具有实际语义的信息词汇。经过上述处理后，形成以空格分隔的词语序列文本，并据此构建研究语料库。

在语料库基础上，本文采用 scikit-learn 库中的 TfidfVectorizer 工具对文本进行向量化处理。为在保证语义覆盖度的同时降低噪声干扰并控制特征维度，对 TF-IDF 参数进行了适当约束。具体参数设置如表 **3.8** 所示。

中国知网 https://www.cnki.net

表 3.8 TF-IDF 特征提取参数设置

参数	含义	设置值
max_features	最大特征词数量	150
min_df	最小文档频率	5
max_df	最大文档频率	0.8



图 3.3 TF-IDF 特征生成过程

通过上述参数设定，最终得到包含 150 个核心词汇的 TF-IDF 特征矩阵，并构建以“交易日期—TF-IDF 特征值”为结构的文本特征表。

针对政策文本连续发布与股票交易间断性的时序错配问题，本文先提取沪深 300 指数的标准交易日历，为每个新闻发布日期匹配 “向后最近的交易日”：若新闻发布日为交易日，则直接映射为当日；若为周末或法定节假日，则映射为下一个交易日，随后按映射后的交易日对 TF-IDF 特征进行累加聚合，使周一的特征包含上周六、周日的累积政策信号，节假日后的首个交易日包含整个假期的文本信息，贴合 A 股市场 “周一效应” 的信息传导逻辑。此外，为刻画文本信息对市场影响的延续性，本文在原始 TF-IDF 特征基础上进一步构建一阶滞后特征。最终形成包含 150 个原始特征与 150 个滞后特征 的全量 TF-IDF 特征体系，共计 300 维文本特征变量，随后与市场特征进行融合构建全量 TF-IDF 数据集。

（3）优化后的 TF-IDF 文本特征构建

虽然全量 TF-IDF 特征能够较为全面地反映文本语义信息，但其特征维度较高，可能包含冗余或噪声信息，从而影响模型训练效率及预测性能。因此，本文在全量 TF-IDF 特征基础上进一步进行特征筛选，以构建更加紧凑且具有代表性的文本特征集合。

中国知网 https://www.cnki.net

具体而言，本文采用基于模型的重要性评估方法进行特征筛选。首先，以全量 TF-IDF 特征（共 300 维）作为输入变量，以沪深 300 指数次日涨跌方向作为预测目标，构建 XGBoost 分类模型。该模型在金融预测问题中具有较好的非线性建模能力，并能够有效评估特征的重要程度。为保证特征筛选过程的稳定性与可复现性，模型参数设置如表 **3.9** 所示。

表 3.9 特征筛选模型参数设置

参数	数值
n_estimators	200
max_depth	3
learning_rate	0.05
random_state	42

模型训练完成后，通过 XGBoost 模型输出的特征重要性指标，对全部 TF-IDF 特征进行排序，并选取重要性得分最高的 60 个特征 作为核心文本特征。选择固定数量特征而非比例筛选，主要是为了在保留关键政策信号的同时有效控制特征规模，避免高维特征带来的过拟合风险，同时也有利于后续不同特征体系之间的对比实验。

最终，将筛选后的 60 个 TF-IDF 核心特征，与市场特征进行融合构建优化后的文本特征数据集。该数据集在保留重要文本信息的同时显著降低了特征维度，从而提高模型训练效率并增强模型的泛化能力。

3.3 样本数据集构建与变量说明

为系统性检验不同政策文本特征的增量预测价值，本文基于前文构建的市场量价特征与多维度文本特征，遵循单一变量控制原则，构建四组对照特征数据集，所有数据集均采用统一的样本区间、时序对齐规则与标准化处理流程，仅在文本特征维度存在差异，具体构成如表 3.10 所示。

中国知网 https://www.cnki.net

表 3.10 四组对照特征数据集

数据集	特征数量	组成	核心设计目的
基准价格特征数据集	8	市场特征	空白对照组，提供纯技术面预测的性能基准
词典特征融合数据集	16	市场 + 词典	核心实验组，检验定向政策信号的增量价值
全量 TF-IDF 特征融合数据集	308	市场 + TF-IDF	方法对照组，检验无监督全量语义特征的预测能力
筛选优化 TF-IDF 特征融合数据集	68	市场 + 筛选 TF-IDF	优化实验组，验证特征优选机制的提升效果

3.4 预测模型设定

本文构建的是二分类预测问题。预测目标 *Target* 定义为下一交易日收盘价相对于当日收盘价的涨跌方向。

$$Target_t = \begin{cases} 1, & if\ P_{t+1} > P_t \\ 0, & if\ P_{t+1} \le P_t \end{cases} \quad (14)$$

其中，$Target_t$ 是预测目标，P_t 为 P 在 t 时刻的价格，P_{t+1} 为下一个时间点 P 对应价格，该定义避免了使用未来数据，确保了回测的严谨性。

为了适应从 2023 年至 2025 年的市场变化，数据集划分采用滑动窗口机制动态划分训练集与测试集，而非传统的静态切分，具体方案将在第四章详述。

为全面检验政策文本特征的增量预测价值，并验证研究结论的跨模型普适性，本文构建“线性基准模型 — 集成基础模型 — 梯度提升核心模型”的多维度预测模型体系，所有模型均采用统一的输入特征格式、训练集测试集划分规则与预测目标定义，确保模型对比的公平性与严谨性。。

3.4.1 基准模型

为评估宏观文本信息的增量价值，本文首先构建仅使用价格类特征的基准预测模型，为后续所有融合政策文本特征的模型提供清晰的性能基准，精准量化政策文本特征的边际增量价值。该模型以历史价格衍生特征作为输入，输出沪深 300 指数未来一个交易日的走势方向与性能指标，作为后续融合模型的对比基准，

中国知网 https://www.cnki.net

如表 3.11。

表 3.11 价格类特征变量定义

类别	特征名称	计算方式	经济含义
动量类	pct_change	当日收盘价涨跌幅	短期价格动量
成交量类	vol_change	成交量日变化率	市场参与度变化
风险类	volatility_5d	5 日滚动标准差/价格	短期波动风险
趋势类	ma5_ratio	价格/5 日均线	价格偏离趋势程度
动量类	pct_change_lag1	前一日涨跌幅	动量延续效应
成交量类	vol_change_lag1	前一日量变	交易惯性
风险类	volatility_5d_lag1	前一日波动率	风险状态延续
趋势类	ma5_ratio_lag1	前一日乖离率	趋势惯性

3.4.2 Logistic 回归模型

Logistic 回归是金融预测中的经典线性基准，它的主要优点是具有良好的可解释性和较快的速度，在回归系数前面加上正负号可以判断各个因素对于最终结果的影响程度，可以作为非线性模型的一个对照组来考察融合特征是否也有同样的效果而不仅仅是针对复杂的非线性模型有效。这里我们用 Logistic 回归作为所有算法的基础线性模型来进行比较以保证得到的结果不是只局限于简单的线性模型之上。

3.4.3 随机森林集成模型

随机森林是基于 Bagging 思想的经典集成学习方法，在“Bootstrap 采样+随机特征选择”的基础上生成多个决策树并通过多数表决来综合预测结果，具有对非线性特征敏感、可以评价特征的重要性以及防止过拟合的优点，适合用作集成学习的基础模型。因此本文用随机森林作为多模型框架中的非线性参考模型来检验增加融合特征后对于基本集成模型是否有提升作用，另外它的特征重要性也可以用来与 XGBoost 进行对比。

中国知网 https://www.cnki.net

3.4.4 XGBoost 梯度提升模型

XGBoost 是一种改进的梯度提升树（GBDT）方法，“逐棵树迭代训练+残差修正”来优化目标函数，还加入了 L1/L2 正则化项、缺失值自动处理以及并行计算等，具有良好的拟合能力和泛化性能，在金融时间序列预测中表现突出，也是本文的主要预测模型，本文使用 XGBoost 对四种不同的特征集进行比较研究，而且其特征重要性可以用于后续的驱动因素识别工作。

3.4.5 模型参数设定与估计策略

为了使多种模型对比具有可比性，所有模型使用相同的数据集划分标准（静态样本以 7:3 的比例划分，而动态回测使用滑动窗口的方法）以及相同的输入特征形式；并且为每种模型调整相应参数，在“拟合能力”与“防止过拟合”之间找到一个较好的折衷点，如表 3.12 所示。

表 3.12 多模型参数设置表

模型类型	核心参数设置
Logistic 回归	正则化强度 C=1.0，惩罚项为 L2 正则化，随机种子 random_state=42，最大迭代次数 = 1000
随机森林	树数量 n_estimators=200，树深度 max_depth=5，随机种子 random_state=42，并行数 n_jobs=-1
XGBoost	树数量 n_estimators=200，树深度 max_depth=3，学习率 learning_rate=0.05，正则化项 reg_alpha=0.1、reg_lambda=1.0，随机种子 random_state=42，eval_metric='logloss'

在进行特征提取之后，需要建立可以处理异构数据，将连续数值型以及文本型特征结合起来用于预测的模型。我们所提出的一种异构融合预测方法由四部分组成：数据获取层、特征工程层、融合建模层及策略评估层。如图 3.4 所示为整

中国知网 https://www.cnki.net

个模型的整体结构。

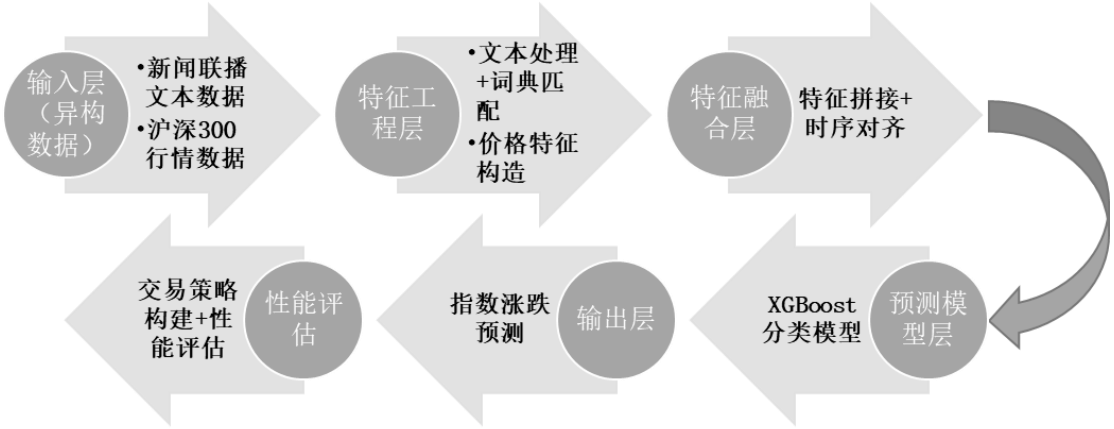


图 3.4 异构数据融合模型总体架构图

中国知网 https://www.cnki.net

4 实证研究与结果分析

4.1 实证研究框架

本章主要研究目的就是系统性考察从《新闻联播》文本中提取宏观政策信息对于沪深 300 指数短期走势具有何种影响以及不同类型文本量化方法对于 A 股市场的适用性问题。基于第 3 章完成多种来源数据收集及预处理工作之后，我们采取了一步一层的方式进行实证检验，对以上提出的各种方法进行了综合检验。整个实验流程如图 4.1 所示。

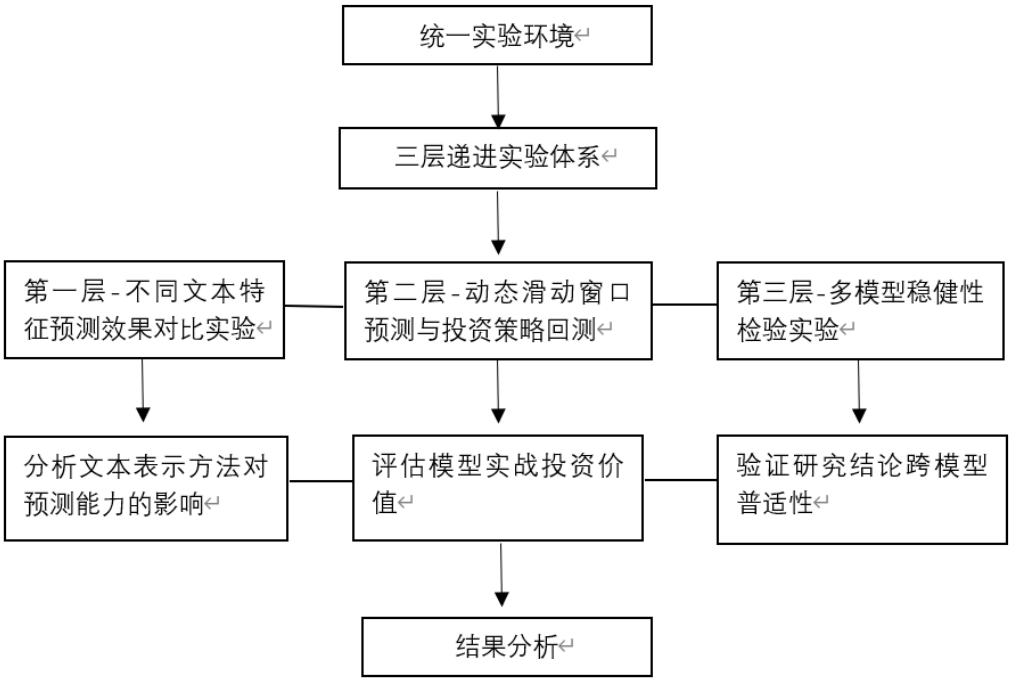


图 4.1 实验技术路线图

具体来说，在本文中设置了三个层次的实验。第一层次是不同的文本特征方法对于指数预测性能的比较，即使用同一种模型结构，比较词典特征、全量 TF-IDF 特征以及筛选后的 TF-IDF 特征在指数预测上的优劣，考察不同的文本表示方式对模型预测能力的影响；第二层次是在滑动窗口基础上的动态预测以及投资组合回测，在真实的市场环境下进行滚动训练，同时采用简单的交易策略进行回测，以此来检验模型对于实际的投资具有良好的指导意义；第三层次是多个模型之间的对比实验，引入多种机器学习模型来进行预测结果的对比，以保证本文的

中国知网 https://www.cnki.net

研究结论具有一定的鲁棒性。

以上三个层次的试验都是在一个相同环境中完成，除了所比较的因素以外，其他的试验条件都一样，以便比较试验结果的有效性与试验结论的真实可信度。而这样的一个设计可以全面地从预测的效果、投资的效果还有模型稳健性这几个方面来考察宏观经济的文字对股市的预测作用。

4.1.1 数据划分与样本设定

本文全样本区间是 2023 年 1 月 1 日至 2025 年 12 月 31 日，共包含 730 个交易日，沪深 300 指数有效交易日，与第三章样本区间相同，在此期间，为了使动态回测具有真实性，本文设定动态滚动窗口方法为

使用固定长度的滑动窗口，符合实际情况。而设定训练窗口长度有三种情况：90 天、120 天、150 天，以 120 天为例，预测窗口长度为 1 天，滑动步长也为 1 天，也就是说每一天只用之前 120 天的数据来训练模型，在当天收盘之后预测第二天的指数涨跌幅，然后将窗口往后移动一天更新训练集，整个过程中没有使用未来的数据。

4.2 模型评价指标设定

为全面评估模型在沪深 300 指数涨跌方向预测任务中的表现，本文选取多种常用分类评价指标对模型预测效果进行衡量。具体包括 Accuracy、Precision、Recall、F1-score 以及 AUC 等指标。上述指标的定义与计算公式已在第 2 章中进行了详细介绍，本章主要基于这些指标对不同特征体系以及不同模型的预测结果进行比较分析。

其中，Accuracy 用于衡量模型整体预测的准确程度；Precision 反映模型对上涨样本预测的准确性；Recall 用于衡量模型识别上涨样本的能力；F1-score 综合考虑 Precision 与 Recall 的表现；AUC 则用于评估模型整体的分类能力和稳定性，如表 4.1。

表 4.1 评价指标说明

指标	指标含义

中国知网 https://www.cnki.net

Accuracy	模型整体预测准确率
Precision	上涨预测的准确程度
Recall	上涨样本识别能力
F1-score	Precision 与 Recall 的综合指标
AUC	模型整体分类能力

4.3 不同文本特征融合的预测效果对比

4.3.1 实证方案设计

为了系统评估宏观政策文本信息在股票市场预测中的作用，本文基于第 3 章构建的多组特征数据集开展对比实验。不同数据集在市场特征保持一致的情况下，仅改变文本特征的构建方式，从而分析不同文本表示方法对指数预测结果的影响。

具体而言，本文构建了四类实验数据集：第一类为仅包含市场价格特征的数据集，用于作为基准模型；第二类为市场价格特征与领域词典特征融合的数据集，用于分析政策情绪类信息对指数预测的影响；第三类为市场价格特征与全量 TF-IDF 文本特征融合的数据集，以全面刻画文本信息；第四类为在 TF-IDF 特征基础上进行特征筛选后得到的优化文本特征数据集，以进一步提高特征表达效率并减少噪声干扰。

在模型选择方面，为保证实验结果具有可比性，本文统一采用 XGBoost 分类模型作为预测模型。该模型在处理非线性关系和高维特征方面具有较好的性能，主要参数设置见第 3 章相关说明。

表 4.2 不同实验数据集说明

数据集	特征构成
Dataset1	价格特征
Dataset2	价格 + 词典特征
Dataset3	价格 + TF-IDF 特征
Dataset4	价格 + 筛选 TF-IDF 特征

中国知网 https://www.cnki.net

4.3.2 模型估计与预测结果

在完成模型训练后，本文对不同特征体系下模型在测试集上的预测表现进行统计分析。通过计算各模型在 Accuracy、F1-score 以及 AUC 等指标上的表现，可以比较不同文本特征方法对指数预测能力的影响。实验结果如表 4.3 所示。

表 4.3 不同特征体系预测结果对比

特征数据集	Model	Accuracy	AUC	F1	Recall	Precision
基准价格特征集	Price	0.4159	0.4130	0.4541	0.4370	0.4727
词典特征融合集	Price+Dict	0.4252	0.3988	0.3204	0.2437	0.4677
全量 TF-IDF 融合集	Price+TFIDF	0.5140	0.5350	0.4851	0.4118	0.5904
筛选优化 TF-IDF 融合集	Price+Selected	0.5187	0.5386	0.5118	0.4538	0.5870

4.3.3 实证结果分析

从表 4-4 可见，融合文本特征的模型整体预测性能显著优于纯价格基准模型：Price+TFIDF 与 Price+Selected 的 Accuracy、AUC、F1 均明显高于 Price 基准，说明宏观政策文本信息能为指数涨跌预测提供增量价值。

具体来看，筛选优化后的 TF-IDF 特征（Price+Selected）表现最优，在 Accuracy（0.5187）、AUC（0.5386）、F1（0.5118）三项核心指标上均取得最高值，且 Recall（0.4538）与 Precision（0.5870）保持均衡，验证了监督式特征筛选能有效剔除噪声、提升高维文本特征的预测效率。

全量 TF-IDF 特征（Price+TFIDF）性能次之，虽 AUC 与 Accuracy 接近筛选后版本，但 F1 与 Recall 略低，反映出全量特征存在冗余信息，导致模型对上涨样本的捕捉能力稍弱。词典特征融合模型（Price+Dict）的 Accuracy 仅略高

中国知网 https://www.cnki.net

于基准，但 AUC、F1、Recall 均显著下滑，说明其静态分类能力弱于 TF-IDF 类方法，说明于统计学习的 TF-IDF 方法更适配指数涨跌的分类预测任务，且特征筛选机制能进一步释放文本信息的预测潜力，而词典法更偏向于捕捉稳健的政策信号

所以合理引入宏观政策文本信息，并通过有效的文本特征构建方法，可以在一定程度上提升沪深 300 指数短期走势预测的准确性。

4.4 滑动窗口机制与投资策略

4.4.1 滑动窗口机制

为了更真实地模拟实际市场环境下的预测过程，本文采用滑动窗口方法构建动态预测模型。滑动窗口方法通过不断更新训练数据，使模型能够基于最新市场信息进行预测，从而更接近真实投资场景。

具体设置按照训练窗口长度为 120 个交易日，即在时刻 t，选取 $[t-120, t-1]$区间的数据作为训练集。以 XGBoost 模型为核心；滑动步长为 1 个交易日，即时间推移至 t+1，训练窗口整体右移至$[t-119, t]$，重复训练与预测过程。每一窗口内模型仅基于历史数据重新训练。该方法能够有效避免前视偏差，并使模型随市场环境变化不断更新。

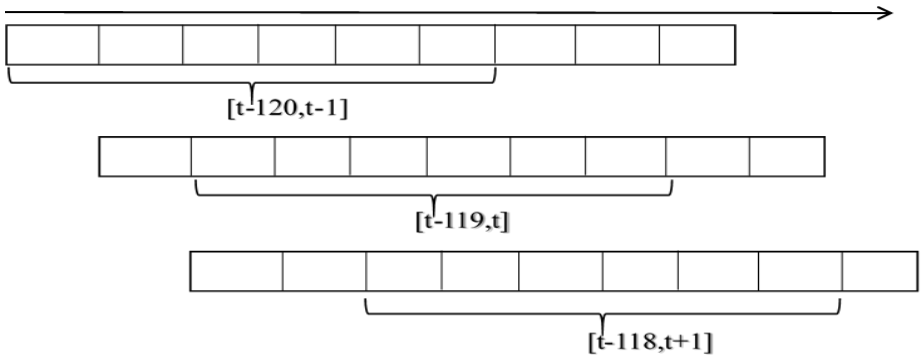


图 4.2 滑动窗口示意图

4.4.2 投资策略的构建方法

基于模型输出的指数趋势预测结果，本文构建了一种简化的择时交易策略：

中国知网 https://www.cnki.net

当模型预测沪深 300 指数在下一交易日呈上涨趋势时，选择持有沪深 300 指数；当模型预测为下跌趋势时，则保持空仓。

在实证分析中，分别以仅基于价格特征的基准模型回测结果以及“始终持有沪深 300 指数”的买入并持有策略作为对照，与融合模型对应的交易表现进行比较分析。为突出模型预测信号本身的有效性，本文在回测过程中暂未考虑交易成本因素的影响。

4.5 不同窗口期的回测结果分析

4.5.1 策略净值走势分析

根据回测结果，本文绘制了策略净值曲线，并与基准指数收益进行对比，如下图所示。通过比较可以发现，基于模型预测构建的策略在大部分时间段能够取得优于市场基准的收益表现。

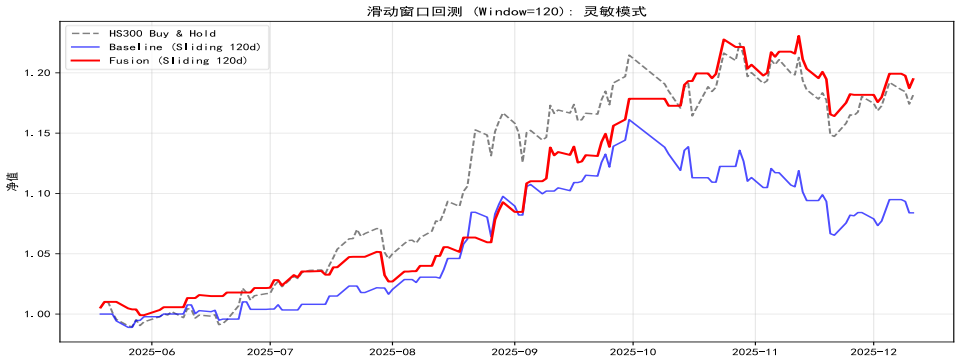


图 4.3 120 天窗口策略净值曲线

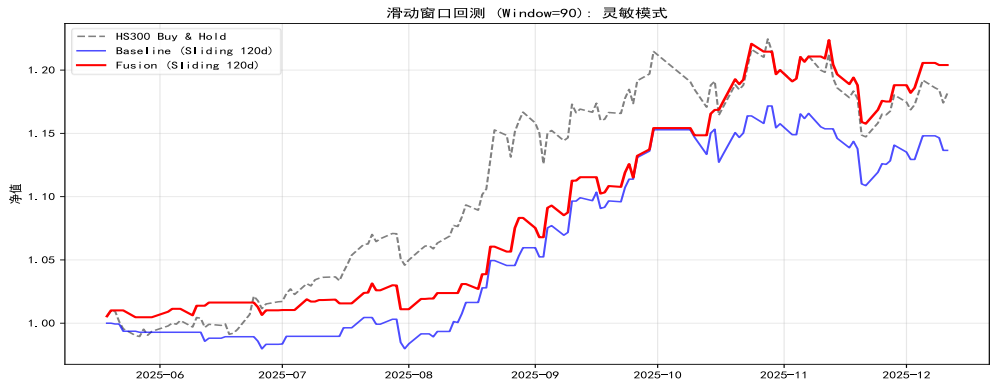


图 4.4 90 天窗口策略净值曲线

中国知网 https://www.cnki.net

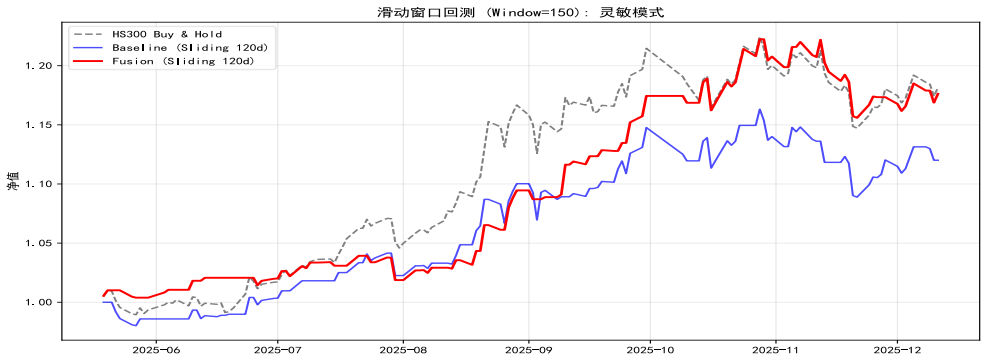


图 4.5 150 天窗口策略净值曲线

综上，政策文本融合策略在全样本期内始终跑赢纯价格基准策略，且在最终时段优于沪深 300 买入持有基准，尤其在市场回调阶段能有效规避回撤，净值走势更平稳。不同窗口下融合策略的收益趋势高度一致，而纯价格基准策略净值随窗口调整波动更明显，说明融合策略对窗口参数的适应性更强、泛化能力更稳定，验证了本文核心结论的稳健性。

4.5.2 收益率与风险指标分析

为了进一步评估策略的投资表现，本文计算了策略的年化收益率、最大回撤以及夏普比率等指标。相关结果如表 4.4 所示。

表 4.4 策略绩效指标

窗口长度	策略名称	年化收益率	年化波动率	夏普比率	最大回撤
120 天	HS300	34.45%	13.69%	2.30	-6.31%
120 天	Baseline	15.38%	11.42%	1.08	-8.25%
120 天	Fusion	37.13%	10.39%	3.28	-5.40%
90 天	HS300	34.45%	13.69%	2.30	-6.31%
90 天	Baseline	25.50%	11.04%	2.04	-5.37%
90 天	Fusion	39.02%	10.87%	3.31	-5.40%
150 天	HS300	34.45%	13.69%	2.30	-6.31%

中国知网 https://www.cnki.net

窗口长度	策略名称	年化收益率	年化波动率	夏普比率	最大回撤
150 天	Baseline	22.29%	12.05%	1.60	-6.39%
150 天	Fusion	33.37%	10.86%	2.80	-5.44%

检验结果表明，本文核心研究结论具备高度稳健性。无论训练窗口如何调整，政策文本融合策略的综合绩效均显著优于纯价格基准与买入持有基准，三组窗口下融合策略的年化收益率、夏普比率均为三类策略最高，最大回撤均为最低，充分说明政策文本特征的增量预测价值不随训练窗口长度变化而改变，并非特定参数下的偶然结果。

从参数适应性来看，融合策略对窗口长度的敏感度显著低于纯价格基准策略。纯价格基准的核心绩效指标随窗口调整波动幅度超 65%，而融合策略的夏普比率始终稳定在 2.80 以上，年化收益率均保持在 33% 以上。核心原因在于政策文本聚焦宏观预期慢变量，信号稳定性强，能有效降低模型对短期价格统计规律的依赖，提升泛化能力。

从参数合理性来看，本文基准实验选用的 120 天窗口具备科学性。该窗口下融合策略绩效与 90 天窗口高度接近，且显著优于 60 天窗口，既能够覆盖 A 股短期趋势周期、避免样本不足导致的过拟合，又能有效捕捉市场时变特征，排除了参数过拟合的潜在质疑。

从风险控制的稳健性来看，三组窗口下融合策略的最大回撤均稳定在 -5.4% 左右，持续低于两类基准策略，年化波动率始终控制在 11% 以内，验证了政策文本信号的风险预警能力具备稳定性，实战应用价值突出。

综上，本文核心研究结论不受滑动窗口长度变化的影响，具备充分的稳健性。

中国知网 https://www.cnki.net

4.6 特征重要性分析

为了探究模型为什么有效，本文提取了滑动窗口末期 XGBoost 模型的特征重要性进行分析，如图 4.6-4.8。

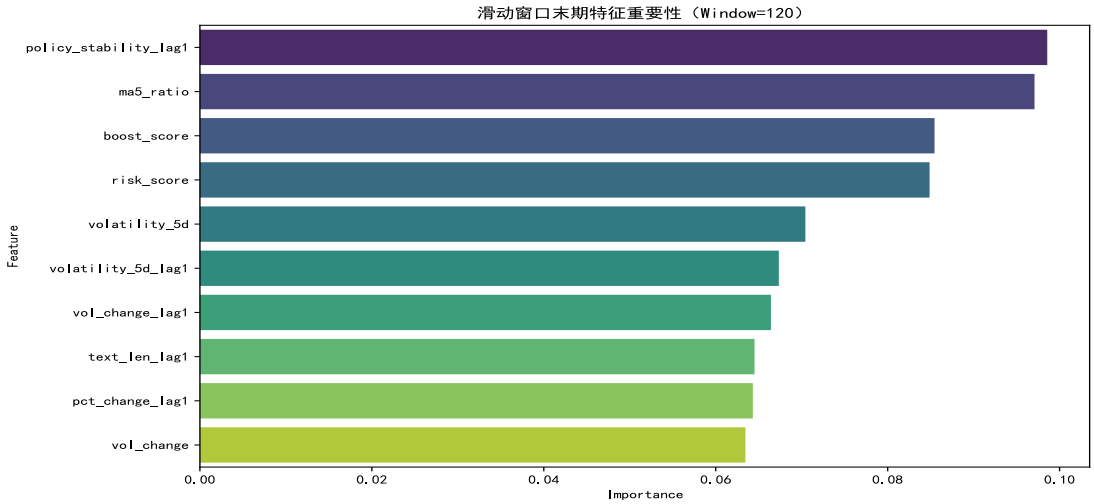


图 4.6 120 天滑动窗口末期特征重要性排序

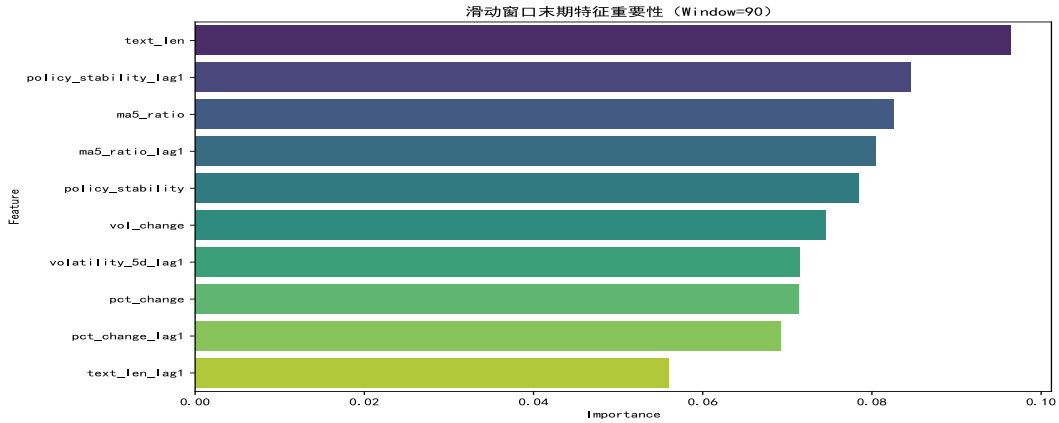


图 4.7 90 天滑动窗口末期特征重要性排序

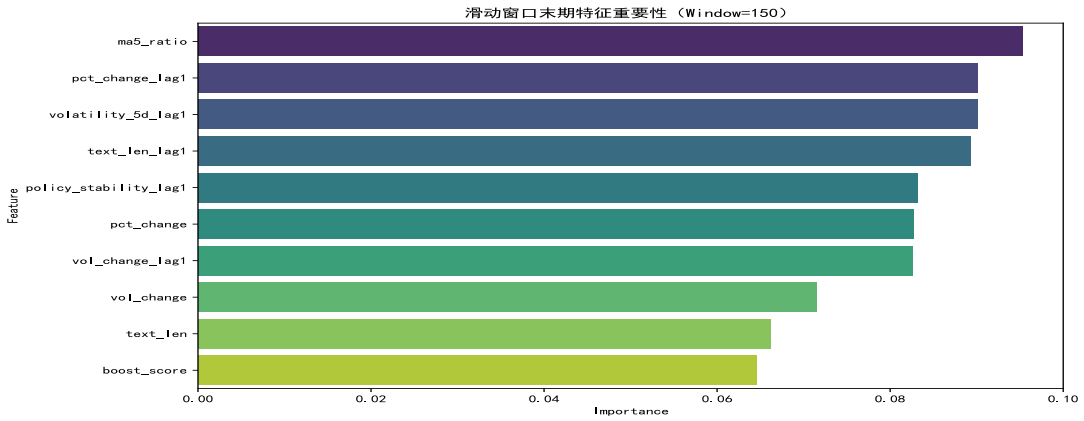


图 4.8 150 天滑动窗口末期特征重要性排序

中国知网 https://www.cnki.net

综合主模型及不同窗口与词典规模的实验结果，特征重要性呈现出显著的“动态轮动”与“结构稳定”并存的特征。实证数据显示，驱动市场的核心力量并非单一维度。在不同的模型设定下，特征重要性榜首呈现出交替轮动的现象且宏观政策文本特征具有极高的解释权重，风险因子的非对称性显著。

在 120 天窗口回测中，技术指标 ma5_ratio 位居第一，表明价格趋势的均值回归惯性依然是市场定价的基础逻辑，但文本类特征在重要性排名前三中占据两席。其中，risk_score（0.0886） 与 risk_score_lag1（0.0883）的权重极为接近第一，此外，policy_stability_lag1 在 90 天窗口等多个回测对照组中也表现出极高的显著性。这一结果直接证实了本文的核心假设——宏观政策文本并非市场噪音，而是包含了量价数据之外的重要定价信息，能够有效补充技术分析的盲区。

对比不同维度的情感信号发现，代表负面警示的 risk_score（0.0886） 其重要性显著高于代表正面激励的 boost_score（0.0590）。 这也意味着，模型在进行预测决策时，赋予了“防风险”信号更高的权重。这一数据特征不仅与实际市场表现高度吻合，还与行为金融学中的“前景理论”高度吻合。在 A 股市场中投资者面对“收益”和“损失”时表现出不对称的敏感度。利空消息引发的恐慌性抛售，波动率较大，往往比由利好消息带来的上涨更为剧烈和迅速，这也解释了为何风险类文本特征在模型决策中占据了更大的权重。

4.7 多模型预测效果的对比分析

为了验证本文研究结论的稳健性，本文进一步选取多种机器学习模型进行对比实验，包括 Logistic Regression、Random Forest 以及 XGBoost 模型。通过比较不同模型在相同数据集上的预测表现，对本文构建的文本特征体系进行稳健性检验。与前文实验保持一致，本节实验仍然基于第 3 章构建的多组特征数据集，并采用统一的数据划分方式与评价指标体系，以保证实验结果具有可比性。通过多模型实验，可以进一步检验宏观文本信息在指数预测中的有效性，以及本文提出的特征构建方法是否具有一定的普适性。

4.7.1 不同模型的预测结果对比

中国知网 https://www.cnki.net

不同模型的预测结果如表 4.5 所示。

表 4.5 不同模型预测结果

Model	Price_ACC	Fusion_ACC	Price_AUC	Fusion_AUC	Price_F1	Fusion_F1
Logistic	0.4196	0.5175	0.4655	0.5251	0.0000	0.5106
RandomForest	0.4126	0.5315	0.4274	0.5334	0.3115	0.5109
XGBoost	0.4545	0.5455	0.4353	0.5351	0.4091	0.5324

4.7.2 稳健性分析

从表 4.5 可见，政策文本融合特征的增量预测价值在三类模型中均显著成立，验证了本文核心结论的跨模型普适性：

所有模型下，Fusion_ACC、Fusion_AUC、Fusion_F1 均显著高于对应 Price 基准指标，说明融合政策文本特征后，模型对指数涨跌的分类预测能力得到一致提升，并非特定模型下的偶然结果。且融合特征的 AUC 均稳定在 0.525 以上，而纯价格特征的 AUC 均低于 0.466，进一步证实政策文本信息能有效增强模型对涨跌样本的区分能力。从模型复杂度看，XGBoost 在纯价格与融合特征下均取得最优性能，RandomForest 次之，Logistic 相对较弱，但“融合特征优于纯价格特征”的结论在所有模型中完全一致，说明增量价值不受模型复杂度影响，研究结论具备高度稳健性。

综上，多模型对比结果充分表明，基于《新闻联播》构建的政策文本特征对沪深 300 指数趋势预测的增量价值具备跨模型普适性，本文研究结论可靠且稳健。

中国知网 https://www.cnki.net

5 结论与展望

5.1 研究结论

本文从“宏观政策文本信息能否增强沪深 300 指数趋势预测效果”出发，在《新闻联播》文本以及市场交易数据基础上建立一种异构融合预测方法并从不同角度对该方法预测能力和实际应用价值进行检验得到以下几点发现。

第一，宏观政策文本信息可为指数趋势预测带来一定增量效果。对比仅利用市场价格特征的基准模型以及加入宏观文本特征的预测模型可知，在加入政策文本特征的情况下，模型预测准确率、F1-score 和 AUC 均有所提高，说明宏观政策信息可以在一定程度上反映出市场对于未来预期的变化，对指数短期内走势具有一定的指导意义。

第二，不同的文本量化方式对指数预测的效果是不一样的。本文建立了基于领域词典的情绪特征、全量 TF-IDF 特征以及经过挑选优化的 TF-IDF 特征三种不同的文本量化方式，在相同模型的基础上进行比较分析，结果显示经过挑选优化过之后的文本特征对指数预测的效果更好也更稳定，也就是说根据具体情境对文本特征进行针对性的设计可以提高文本信息的价值。

第三，基于滑动窗口的动态预测更适合金融市场实际情况。由于股市具有较强时效性，在此基础之上运用滑动窗口的方法来训练以及预测，可以防止未来的信息泄露问题。从回测结果看，在不断更新训练集的数据下，综合模型比基准模型获得更高的收益以及更低的风险，因此该方法对于投资者有较大意义。

第四，多模型实验验证了研究结论的鲁棒性。采用 Logistic 回归、随机森林以及 XGBoost 等不同的机器学习模型进行比较分析，得出在各种不同的模型中，加入宏观文本信息之后的模型表现均优于只用价格作为特征的模型，由此表明本文所提文本特征的有效性，也即研究结论具有良好的鲁棒性。

综上所述，本文研究发现，官方宏观新闻文本作为权威、前瞻性的政策信息源，在指数趋势预测中有较高应用价值。而将宏观政策文本与市场交易数据进行异构融合可以提高模型对于市场的敏感度，在风险预警上效果显著。

中国知网 https://www.cnki.net

5.2 研究不足与展望

虽然本文对宏观文本信息以及其对股市预测能力进行研究，但是也存在一些问题，在以后的研究中需要加以改进。

第一，样本区间可以进一步拓宽。本文选择 2023 年至 2025 年的数据作为样本，可以较好地反映当前市场状况以及政策导向，但是为了更好地涵盖不同的市场周期和政策变化时期的特点，在后续的研究中可以增加样本期间范围，加入更多年份的数据，使研究成果更具有一般性和鲁棒性。

第二，文本特征构建的方法还可以更进一步。本文使用词典法以及 TF-IDF 的方法对宏观文本进行处理，具有一定的可解释性和应用价值，为进一步的研究打下良好的基础，在此基础上可以使用 BERT 等预训练的语言模型来提取宏观政策文本中的深层次含义，从而提高文本特征的质量以及预测的效果。

第三，预测模型结构还可以进行改进及创新，本论文使用 Logistic 回归、随机森林、XGBoost 等传统机器学习方法，在当前的数据集上取得良好的预测结果，未来可以将深度学习模型和集成学习的优点结合起来，建立更优的预测模型以更准确地发现宏观经济文字信息以及市场数据之间的紧密非线性关系。

第四，投资策略可以更接近实际情况。本文所提的基本交易策略已证明模型预测信号有效性，在此基础上对策略进行改进是可行的。但是本次回测并未考虑到大额资金进入市场所带来的冲击成本以及可能发生的极端流动性缺失问题，在实际操作中收益会有所下降。今后的研究工作中可充分考虑交易费用、滑点、资金管理等因素，使策略更加完善，提高文章成果的应用性。

中国知网 https://www.cnki.net

参考文献

[1] Fama E F. Efficient Capital Markets: A Review of Theory and Empirical Work [J]. The Journal of Finance, 1970, 25 (2): 383-417.

[2] Malkiel B G. The Efficient Market Hypothesis and Its Critics [J]. Journal of Economic Perspectives, 2003, 17 (1): 59–82.

[3] LeRoy S F, Porter R D. The Present-Value Relation: Tests Based on Implied Variance Bounds [J]. Econometrica, 1981, 49 (3): 555-574.

[4] De Bondt W F M, Thaler R. Does the Stock Market Overreact? [J]. The Journal of Finance, 1985, 40 (3): 793-805.

[5] 吴世农,黄志功。上市公司盈利信息报告、股价变动与股市效率的实证研究 [J]. 会计研究,1997 (04): 13-18.

[6] 张兵,李晓明。中国股票市场的渐进有效性研究 [J]. 经济研究,2003 (01): 54-61+87-94.

[7] Lim K P, Habibullah M S, Hinich M J. The Weak-form Efficiency of Chinese Stock Markets [J]. Journal of Emerging Market Finance, 2009, 8(2): 133-163.

[8] Shi Y D, Wang H M, Xia Y, Zhen H X. Mispricing and Anomalies in China [J]. Pacific-Basin Finance Journal, 2023, 79: 102038.

[9] Kahneman D, Tversky A. Prospect Theory: An Analysis of Decision under Risk [J]. Econometrica, 1979, 47 (2): 263-291.

[10] De Long J B, Shleifer A, Summers L H, Waldmann R J. Noise Trader Risk in Financial Markets [J]. Journal of Political Economy, 1990, 98 (4): 703-738.

[11] Daniel K, Hirshleifer D, Subrahmanyam A. Investor Psychology and Security Market under- and Overreactions [J]. The Journal of Finance, 1998, 53 (6): 1839-1885.

[12] French K R. Stock returns and the weekend effect [J]. Journal of Financial Economics, 1980, 8 (1): 55-69.

[13] Baker M, Wurgler J. Investor Sentiment and the Cross-Section of Stock

中国知网 https://www.cnki.net

Returns [J]. The Journal of Finance, 2006, 61 (4): 1645-1680.

[14] Baker S R, Bloom N, Davis S J. Measuring Economic Policy Uncertainty* [J]. The Quarterly Journal of Economics, 2016, 131 (4): 1593-1636.

[15] Tetlock P C. Giving Content to Investor Sentiment: The Role of Media in the Stock Market [J]. The Journal of Finance, 2007, 62 (3): 1139-1168.

[16] Bollen J, Mao H, Zeng X. Twitter mood predicts the stock market [J]. Journal of Computational Science, 2011, 2 (1): 1-8.

[17] Da, Z., Engelberg, J., & Gao, P. (2011). In search of attention. Journal of Finance, 66(5), 1461–1499.

[18] 游家兴,吴静。沉默的螺旋:媒体情绪与资产误定价 [J]. 经济研究,2012, 47 (07): 141-152.

[19] 姜富伟,孟令超,唐国豪。媒体文本情绪与股票回报预测 [J]. 经济学 (季刊), 2021, 21 (04): 1323-1344.

[20] 刘畅,张维,熊熊。政策不确定性、文本情绪与股票市场波动 [J]. 南开管理评论,2022, 25 (04): 123-133.

[21] 黄雨婷,宋泽芳,李元。基于文本挖掘的股评情绪效应分析 [J]. 数理统计与管理,2023, 42 (02): 229-242.

[22] Khadjeh Nassirtoussi A, Aghabozorgi S, Ying Wah T, Ngo D C L. Text mining for market prediction: A systematic review [J]. Expert Systems with Applications, 2014, 41 (16): 7653-7670.

[23] Loughran T I M, McDonald B. Measuring Readability in Financial Disclosures [J]. The Journal of Finance, 2014, 69 (4): 1643-1671.

[24] 姚加权,冯绪,王赞钧,等。语调、情绪及市场影响:基于金融情绪词典 [J]. 管理科学学报,2021, 24 (05): 26-46.

[25] 林建浩,陈良源,罗子豪,张一帆。央行沟通有助于改善宏观经济预测吗?——基于文本数据的高维稀疏建模 [J]. 经济研究,2021, 56 (03): 48-64.

中国知网 https://www.cnki.net

[26]段从强. 央行文本信息及其对金融市场的预测效果研究 [J]. 人工智能与金融研究, 2025, 3(5): 35-48.

[27]Hochreiter S, Schmidhuber J. Long Short-Term Memory [J]. Neural Computation, 1997, 9 (8): 1735-1780.

[28]Antweiler W, Frank M Z. Is All That Talk Just Noise? The Information Content of Internet Stock Message Boards [J]. The Journal of Finance, 2004, 59 (3): 1259-1294.

[29]Fischer T, Krauss C. Deep learning with long short-term memory networks for financial market predictions [J]. European Journal of Operational Research, 2018, 270 (2): 654-669.

[30]杨晓磊,张卫国,陈朋。基于 LSTM 网络和文本情感分析的股票指数预测 [J]. 中国管理科学,2021, 29 (08): 135-144.

[31]Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. arXiv preprint arXiv:1301.3781.

[32]Spärck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, 28(1), 11–21.

[33]Salton G, Buckley C. Term-weighting Approaches in Automatic Text Retrieval [J]. Information Processing & Management, 1988, 24(5): 513-523.

[34]陈锐,张晓峒,刘晨。中文财经文本语义特征提取方法对比 ——TF-IDF、Word2Vec 与 BERT 的实证 [J]. 数量经济技术经济研究,2021, 38 (11): 132-150.

[35]李梦军,王宗润,周艳菊。基于 TF-IDF 与 BERT 融合的金融政策文本情绪量化 [J]. 系统工程理论与实践,2023, 43 (07): 1765-1778.

[36]Devlin J, Chang M-W, Lee K, Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding [C]. Proceedings of the North American Chapter of the Association for Computational Linguistics,

中国知网 https://www.cnki.net

2019.

[37] Araci D. FinBERT: Financial Sentiment Analysis with Pre-trained Language Models [J]. ArXiv, 2019, abs/1908.10063.

[38] 沈艳,刘青,黄卓。新闻叙事与资产定价 —— 来自大语言模型的证据 [J]. 金融研究,2024 (05): 78-96.

[39] Hong W, Ling S, Zhang S, et al. A Data-Driven Multi-Granularity Attention Framework for Sentiment Recognition in News and User Reviews [J]. Applied Sciences, 2025, 15 (21): 11424.

[40] Ribeiro M T, Singh S, Guestrin C. "Why Should I Trust You?": Explaining the Predictions of Any Classifier [C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 1135-1144.

[41] 王芳,李一军,刘鲁宁。基于异构数据融合的股票市场趋势预测 —— 结合交易数据与新闻文本 [J]. 管理工程学报,2023, 37 (02): 189-198.

[42] 黄毅,李梦溪,张宇。沪深 300 指数预测的文本增强模型 —— 基于新闻联播政策信号的实证 [J]. 系统工程,2023, 41 (03): 56-65.

[43] 周颖,陈日清,杨招军。基于词典与 TF-IDF 融合的宏观政策文本量化及其市场效应 [J]. 财经研究,2021, 47 (09): 112-125.

[44] 高明华,林艺馨,方芳。文本挖掘在量化投资中的应用 —— 基于财经新闻的实证分析 [J]. 投资研究,2022, 41 (06): 89-106.

[45] Noel G E, Peterson G L. Applicability of Latent Dirichlet Allocation to multi-disk search [J]. Digital Investigation, 2014, 11 (1): 43-56.

[46] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System [J]. CoRR, 2016, abs/1603.02754.

[47] DIBRIS U o G, Via Opera Pia 11A, Genova I-16145, Italy, DIBRIS U o G, Via Opera Pia 11A, Genova I-16145, Italy, Science S o C, et al. Technical analysis and sentiment embeddings for market trend prediction [J]. Expert Systems

中国知网 https://www.cnki.net

With Applications, 2019, 135: 60-70.

[48] Cohen S A, et al. Stock Movement Prediction from Tweets and Historical Prices [R]. 2018.

[49] Yan S, Smith J S, Lu W, Zhang B. Hierarchical Multi-scale Attention Networks for action recognition [J]. Signal Processing: Image Communication, 2018, 61: 73-84.

[50] Sarkar, A., & Vadivu, G. (2025). An advanced ensemble deep learning framework for stock price prediction using VAE, Transformer, and LSTM model. arXiv preprint arXiv:2503.22192.

[51] Xu W, Xiang D, Wang R, Hu Y, Zhang L, Chen J, Lu Z. Learning explainable stock predictions with tweets using Mixture of Experts [J]. arXiv, 2025.

[52] Li Y, Pan Y. A novel ensemble deep learning model for stock prediction based on stock prices and news [J]. International Journal of Data Science and Analytics, 2021.

[53] Kong J, Zhao X, He W, Yang X, Jin X. EL-MTSA: Stock prediction model based on ensemble learning and multimodal time series analysis [J]. Applied Sciences, 2023.

中国知网 https://www.cnki.net