硕士学位论文

（学术学位论文）

基于随机森林算法的多因子选股模型研究

RESEARCH ON MULTI FACTOR STOCK SELECTION MODEL BASED ON RANDOM FOREST ALGORITHM

胡松

哈尔滨工业大学

2022 年 6 月

中国知网 https://www.cnki.net

国内图书分类号：F830　　学校代码：10213
国际图书分类号：336.7　　密级：公开

硕士学位论文

基于随机森林算法的多因子选股模型研究

硕 士 研 究 生：胡松
导　　师：李嵩松副教授
申 请 学 位：经济学硕士
学　　科：应用经济学
所 在 单 位：经济与管理学院
答 辩 日 期：2022 年 6 月
授予学位单位：哈尔滨工业大学

中国知网　https://www.cnki.net

Classified Index: F830
U.D.C: 336.7

Dissertation for the Master Degree

RESEARCH ON MULTI FACTOR STOCK SELECTION MODEL BASED ON RANDOM FOREST ALGORITHM

Candidate： Hu Song
Supervisor： Vice Prof. Li Songsong
Academic Degree Applied for： Master of Applied Economics
Speciality： Applied Economics
Affiliation： School of Management
Date of Defence： June, 2022
Degree-Conferring-Institution： Harbin Institute of Technology

中国知网 https://www.cnki.net

摘 要

本文的研究目的是将随机森林算法引入以往的多因子模型中，构造基于随机森林分类算法的多因子选股模型，并以此为基础选出具有投资空间的资产构成资产池，以试图获得超额收益。

本文以全部科创板上市公司为样本，选用原始因子和构造因子两大类共 15 个指标，选取从 2020 年元旦到 2022 年元旦共 24 个月，105 组周数据构建原始样本，经过数据预处理共获得 300 组有效样本数据。其中以 2020 年元旦到 2021 年二季度结束共 18 个月数据为训练集，以 2021 年三季度到 2022 年元旦共 6 个月的数据作为预测集，与基准指数对比以分析选股效果。通过对模型参数的 AUC 均值计算比较，将随机森林的分裂特征数量设为 5，将决策树数量设为 50，建立随机森林模型，对因子进行打分，并按照重要性进行排序，并以此为基础计算股票综合得分，选取排名靠前的股票构建资产池，按照股票池中不同股票数量和不同调仓周期对模型拟合结果进行分析，从而寻找出最优解。

在模型的 6 个月预测期中，考虑到模型收益率的同时兼顾资产收益率波动程度，试图在资产价值波动与收益率之间寻找动态平衡，能够获得超越基准指数的收益率，并将资产波动控制在可承受范围内。在多因子模型中，设置多组不同参数，兼顾模型拟合结果和整体回测结果，计算模型收益率平均值和收益率波动程度。经过不断调整，最终模型拟合结果在跑赢科创 50 的同时较好的控制住了收益率波动程度，证明该模型在一定的时间范围内具有较好的选股能力，能够获得超越基准指数的收益率，同时能够较为有效的保持收益的稳健性。

关键词：随机森林算法；多因子选股模型；因子分类

中国知网 https://www.cnki.net

Abstract

The purpose of this paper is to introduce the random forest algorithm into the previous multi-factor model, construct the multi-factor stock selection model based on the random forest classification algorithm, and select the assets with investment space to form the asset pool on this basis, in order to try to obtain excess returns.

This paper takes all listed companies on the Science and Innovation Board as samples, selects two categories of original factor and construction factor altogether 15 indicators, selects 24 months from The New Year's Day of 2020 to the New Year's Day of 2022, 105 groups of weekly data to construct original samples, and obtains 300 groups of valid sample data through data pretreatment. The 18-month data from the New Year's Day of 2020 to the end of the second quarter of 2021 are used as the training set, and the 6-month data from the third quarter of 2021 to the New Year's Day of 2022 are used as the prediction set to compare with the benchmark index to analyze the stock selection effect. By calculating and comparing the AUC mean values of model parameters, the number of split features of random forest was set as 5, and the decision tree was set as 60. The random forest model was established, and the factors were scored and sorted according to the importance. The comprehensive score of stocks was calculated based on this, and the top stocks were selected to construct the asset pool. According to the different number of stocks in the stock pool and different periods of transfer, the model fitting results are analyzed to find the optimal solution.

In the 6-month forecast period of the model, considering the volatility of asset return rate and the volatility of asset return rate, we try to find a dynamic balance between asset value volatility and return rate, so that the return rate beyond the benchmark index can be obtained, and the asset volatility can be controlled within the tolerable range. In the multi-factor model, multiple groups of different parameters were set, and the model fitting results and the overall test results were taken into account to calculate the average yield of the model and the volatility of yield. After constant adjustment, the final model fitting results beat kEChuang 50 and better controlled the volatility of the return rate, which proves that the model has a good stock selection ability in a certain time range, can obtain a return rate beyond the benchmark index, and can effectively maintain the robustness of returns.

Keywords：random forest algorithm, multi-factor stock selection model，factor classification

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 研究背景与意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....1
1.2 国内外研究现状.....3
1.2.1 量化投资理论研究现状.....3
1.2.2 机器学习及数据挖掘有效性研究现状.....3
1.2.3 多因子选股模型研究现状.....4
1.2.4 随机森林算法研究现状.....6
1.2.5 文献评述.....9
1.3 研究内容与框架.....9
1.3.1 主要研究内容.....9
1.3.2 技术路线图.....12
第 2 章 量化选股模型与分类算法.....13
2.1 量化投资.....13
2.2 选股模型.....15
2.2.1 风格轮动模型.....15
2.2.2 行业轮动模型.....15
2.2.3 动量反转模型.....15
2.2.4 多因子选股模型.....16
2.2.5 选股模型比较.....17
2.3 分类算法.....17
2.3.1 KNN 算法.....17
2.3.2 神经网络算法.....18
2.3.3 XGBoost 算法.....20
2.3.4 随机森林算法.....20
2.4 本章小结.....25
第 3 章 数据选取与因子池构建.....26
3.1 样本数据选取及预处理.....26
3.2 因子池构建.....28
3.2.1 原始因子选取.....28
3.2.2 因子选取原因.....29
3.3 因子相关性检验.....33
3.4 因子回归显著性.....35

中国知网 https://www.cnki.net

3.4.1 原始因子回归检验.....35
3.4.2 调整后因子回归检验.....36
3.5 本章小结.....38
第 4 章 随机森林的多因子选股模型构建.....40
4.1 随机森林参数调整.....40
4.1.1 AUC 均值计算.....40
4.1.2 原始因子重要性排序.....41
4.1.3 因子重要性排序优化.....42
4.2 选股模型构建.....42
4.2.1 原始模型构建.....42
4.2.2 提高持仓集中程度.....45
4.2.3 调整调仓周期.....47
4.3 模型改进与优化.....49
4.4 本章小结.....51
结论.....52
参考文献.....54

中国知网 https://www.cnki.net

第 1 章 绪 论

1.1 研究背景与意义

1.1.1 研究背景

量化投资起源于上世纪五十年代，从诞生之初就引领学界业界将数量化方法与金融市场投资相结合，但是由于条件的限制，早期的量化投资发展缓慢。从上世纪七十年代开始，随着计算机技术的发展，人们能够处理海量多维数据，量化投资引起专家学者的重视。股票市场是典型的高风险高收益，各种信息交织叠加，变幻莫测，传递出的信息模糊不清，往往令投资者难以做出正确的投资决策。量化投资基础建立在数学模型上，利用统计方法来设计投资策略，试图寻找股价波动的潜在规律，实质是利用数量模型进行定量投资，与技术分析和价值投资最大的不同是不依赖于主观判断，而是通过模型来决策。

量化投资在国外发展了半个多世纪，除主动权益基金，货币基金以外，量化投资基金在美国资本市场上占据重要的份额，其中佼佼者—文艺复新公司的大奖章基金，三十多年的年化收益率远超巴菲特，达到了 38.5%。量化基金在国外的快速发展，也让国内意识到这是一片新兴的蓝海。但是我国的量化投资才刚刚起步，整个发展历程相当缓慢，市场上的主流方法仍然是基本面研究。随着金融市场的发展，市场整体复杂程度提升，信息容量迅速扩容，依靠人工的主观投资存在效率低下，覆盖满狭窄的问题，同时依赖科技发展，将信息技术与统计理论结合起来，通过电脑进行大数据处理并得出分析结果。另一方面，近些年机器学习的完善也为量化提供了一件有利的武器，虽然易于传统主观投资，却以优异的收益率在市场中占据重要的地位。

1.1.2 研究意义

（1）理论意义

多因子选股在量化领域得到了快速普及，是目前比较完善并发挥作用的模型。多因子模型的基本原理是聚类很多类型的因子从而组成因子池，利用因子的满足条件来选取合适的股票，从而达到多因子选股的目的。在深入研究模型的基础上，进行因子构造和因子选择，利用数量化的方法，发现有效的因子进行股票选取，其中最核心的部分是有效因子的组合，并获得行业的阿尔法和个股的贝塔收益。为了得到有效因子组合，最初的单因子模型扩展为多因子模型，同时将非线性的方法也引入了模型中以取代传统的线性因子模型。股票市场波动起伏，交错复杂，

中国知网 https://www.cnki.net

传统的投资模型难以发现海量金融数据的收益规律，近几年比较热的量化投资方法能够发现市场投资机会，而且当下国内的量化市场中，比较主流的都是将因子挖掘与策略构建组合起来，试图获得持续收益。

股票市场投资的关注点主要集中在选取出具有投资价值的公司股票，在此基础上选择合适的买入时间。一般分为择时和选股两个方向，目前途径覆盖基本面和技术面。其中，基本面分析是通过对上市公司的基本面展开研究，包含公司的各阶段的财报，公告等，分析公司的财务状况，产品情况，行业概况和政策导向，从整体层面判断公司是否具有投资价值，如果企业证券价格明显低于公允价值，则有一定的上升范围。基本面分析的基础是公司的各种信息，包括财报，公告，交流纪要及会议纪要等，借助这些信息可以对一家公司的优劣有清楚的认识。

与之相对的是技术分析则着眼于市场行为，包括股票成交量，开收盘价，最高最低价，均价，MACD 等，在盘口数据的基础上，依靠 K 线，均线等对股票价格进行预测。利用技术分析往往会出现偏差，因为技术分析是基于历史会重演这个假设基础来的，同时由于信息不对称的存在，所有的市场行为不一定都会反映到盘面上，此外散户的交易也会带来股票价格的无规律波动，以上这些，都会影响技术分析的有效性。量化投资的独特性在于，利用数据和数学模型来分析市场，形成投资框架，组合策略并选取有投资价值的股票，在很大程度上将投资框架固化，通过机器精准实现，从而摆脱不确定因素的影响，尤其是人性的弱点带来的主观认知偏差。

（2）实际意义

量化模型如百花齐放，层出不穷，多因子模型属于其中发展比较成熟，使用较多的那种。通过对原始数据的分析寻找与资产收益率相关的因子，按照相关性由高向低排列，选取排名靠前的因子带入后续的模型预测中，从而能够有效预测未来收益。这其中，对因子的选取至关重要，所选用的因子最好能够全面有效的覆盖各个方面，具有较好实际效果的同时也能用理论进行解释，这样选出来的因子具有普遍适用性和较好的现实意义。多因子模型考虑的较为全面，收益率较为稳定，同时能够有效控制风险，被越来越多的买方，卖方机构所采用。随着注册制的放开，我国上市公司的数量呈现出快速增长，在众多的潜在目标中选取有效的投资标的，并同时做出投资决策的难度越来越大，要想覆盖整个市场，所需的研究员数量不断增长。

机器学习，数据挖掘，计算机硬件设备的发展减少了量化投资从理论到实际应用的障碍，在资金的背书下，量化策略快速在市场上打开一片天地。当量化策略在国外市场带来超额收益之后，国内众多的投资者和机构也开始了在量化领域

中国知网 https://www.cnki.net

的投入，多因子模型也在不断的创新和发展，其复杂程度和有效性远远超过原始模型，量化产品也层出不穷，并涌现出像九坤，幻方，灵均这种量化巨头。多因子模型在兼顾广泛适用性的同时带来了相对不错的收益率，在学界和业界都得到了关注，相关研究也较为成熟。

随机森林把自助重抽样与决策树组合，在统计学习理论的基础上构建了组合分类器，实质是树形分类器集合前提下展开数据分类与预测。与其他方法相比，随机森林算法在应对单分类器性能瓶颈的问题上比较理想，因而在分类器的筛选与预测中得到了广泛的应用。通过对数据进行预处理，调整模型构建过程，从而能够对原始算法进行一定的优化[1]。

1.2 国内外研究现状

1.2.1 量化投资理论研究现状

七十年前，马科维茨在资产组合学说基础上提出经典均值方差理论，利用数量化方法，将单独资产的收益率进行平均来表示整体的收益率，用单独资产收益率方差来表示整体组合收益率波动，即风险，初次将数理统计引入了资产收益，为量化发展开拓了理论基础。十多年后，另一位诺奖获得者夏普又提出了资本资产定价模型（CAPM），引入预期的概念，将预期收益与组合的波动联系起来，由无风险利率和风险溢价两部分组合当做整体的收益率，并利用 β 系数衡量系统性风险，为量化发展做了进一步铺垫。

1970 年，芝加哥学派代表人物法玛提出有效市场假说，根据对信息的获得性和反应程度，将市场分为弱式有效市场，半强式有效市场，强式有效市场三类，并且认为利用价格，基本面和内幕信息对股价进行预测存在很大的难度，多数时候不可以获取有效的结果。两年多以后，布莱克联合斯科尔斯研究出期权定价理论，把影响期权价格因素简化，并给出具体数学公式，简化期权定价问题，公式的发现也助推期权市场快速成长。Ross（1976）提出套利定价理论，将资产定价影响因素由单个放开到多个，同时将因素进行分类，分析因素类别不同对资产收益的影响，扩展了纳入资产定价中的因子数量[2]。

1.2.2 机器学习及数据挖掘有效性研究现状

除了经典模型在不断改进外，随着计算机技术和信息处理方法的发展，量化选股模型逐渐采用数据挖掘机器学习的相关理论方法。

Kim（2003）首先将支持向量机和未来股价变动结合到一起，利用实盘数据来分析模型判断的精准度，并且在其他条件相同情况下，和神经网络模型展开比

中国知网 https://www.cnki.net

较，证明支持向量机模型成绩更好[3]。

Peilin Zhao（2012）为了解决二分类问题，将随机森林引入对股票重要特征的筛选中，同时利用以往数据实盘模型回测，改进后的模型效果较为理想[4]。Bin Li（2013）将机器学习方法引入选股模型，利用信心加权法分别建立不同的模型，以此为依据进行选股并与传统选股方法进行比较，证明了这种方法的有效性[5]。

Michel（2015）将多种不同的分类方法引入到对股价收益预测中，在回测基础上对预测结果进行追踪对比，发现集成学习的效果优于单分类器，整体偏误更小，得出集成学习方法比单分类器的效果更好，偏误更小[6]。Heatona（2017）在传统资产定价，资产组合与风险控制理论的基础上，将深度学习的方法加入到模型中，尝试将深度学习理论与市场行为相结合，验证这种方法的实用性，实验取得了较为理想的结果[7]。

罗超（2016）将高维数据可视化理论引入随机森林算法当中，并探讨在原始模型基础上，进行监督降维，尤其是在处理高维度方面的应用，为后续的处理结果提供一种标准[8]。

李凌宇（2019）利用 2006 年 4 月开始的 26 个月全市场数据建立数据库，借鉴决策树在变量间非线性关系分析的长处，利用随机森林和 XGBOOST 算法建立选股模型，并且按照纯多头和市场中性两个策略进行数据回测，试图寻找模型之间的差异性。结果表明，通过控制训练集的长度，并利用模型融合方法，可以显著的提高整体模型对市场反应变化的灵敏度，同时提高准确性[9]。

谭筝（2020）将机器学习技术引入股价预测与股票选择，并与用来描述股票远期收益与公司特征之间关系的传统线性回归方法相比较，金融界在描述复杂的股票动态时经历了基于树形算法和神经网络范式的快速发展，并且这些非线性方法在预测股价和选择上的表现优于一般市场的股票[10]。

李倩，郑玥（2020）借鉴指数增强基金采用的定性和定量方法，引入机器学习的选股策略，对股票的进行打分排序，选取得分高的前 30 支股票作为样本进行实证分析，选择中证 500 作为基准进行模型回测。结果表明模型在保证不错的收益率同时可以有效控制整体回撤，能够降低收益率的波动[11]。

1.2.3 多因子选股模型研究现状

多因子选股模型发展较早，因子数量从最开始的个位数发展到现在的几百个，涵盖范围也扩大到公司的各个方面，极少出现遗漏，而模型有效性也不断的提升。

Fama（1993）基于对历史数据的分析，将证券收益的影响因素归结为三个，并且在此理论基础上提出经典的三因子模型。这三个因子分别是市场资产组合，

中国知网 https://www.cnki.net

规模和账面市值比，后来出现的多因子模型也多基于 APT 和三因子模型，在此基础上发展变化而来。Asenss（1997）提出应该注重公司的基本面因素，在此基础上对其他因素进行分析对股票进行估值，从而减小估值的误差[12]。

Joseph（2001）构建的一个含有九个影响因子的选股模型，包括流动性，成长性，交易情况，财务状况等，并利用这些因子作为模型基础，对单支证券进行打分，按照得分将所有证券排名，选取排名靠前的证券建立目前资产池，并且对池中资产的收益进行追踪，从而研究选股模型的实用性与准确性[13]。Mohanram（2005）根据 Joseph 的的研究结果对模型中的资产池进行重新筛选，按照市净率为衡量基准筛选出排名为前五分之一的证券组成资产池，在此基础上再次利用 Joseph 所选定的九个因子对股票进行分数判定，建立优化过的资产组合，从而取得了较为理想的效果[14]。

Kariya（2013）提出成长价值理论，首先在市场上寻找被低估股票，组成一个集合，选取集合中具有一定成长空间的股票构成资产池，以此为依据进行投资，本质上是一种混合型方案，结果较为理想[15]。Marx（2013）首先从理论上论证公司毛利率水平与证券收益率可能存在的关联，并通过实证检验证实了这种相关性，结果表明两者之间存在较强的相关性，且利用盈利能力作为指标来预测证券收益能够取得不错的效果[16]。由于三因子模型存在一些不完善地方，Fama（2015）在初代理论上进行演变，推出五因子模型，与时俱进增添因子数量，扩大覆盖范围，新加入盈利与投资因素，对原始模型优化进而提高模型判断有效性[17]。

曹正凤，纪宏（2014）在前人研究成果上，叠加价值和成长两种策略，以此为基础研究价值成长投资策略（GARP），并建立相应的指标体系进行模型选股。具体方法上创新采用等频算法对原始样本预处理，并使用随机森林模型进行证券分类，从而保证分类的准确性，最后实证研究模型选股结果的行业平均收益率，最大收益率的对比情况，证明该模型性能优异，有较好的实际意义[18]。

林启敏（2016）针对股票市场的高维、非线性、多噪音的特点，构建以价值投资为导向的财务指标体系并引入数据挖掘方法，具体指标涵盖 6 大类共 16 项，作为特征变量输入模型，利用随机森林进行选择，以此为基础搭建 RF-QGA-SVR 模型，完成对股票收益的预测，并对结果进行实证检验，为选股模型在市场中的实际应用提供了一种新的方式[19]。

苏靖宇（2018）在多因子选股模型的基础上，结合量化选股的相关理论，选取 15 个候选因子构成选股的因子池，原始数据涵盖从 2009 年开始的 8 年时间里的交易和财务数据，相比之前的旧算法，本模型中的随机森林算法可以有效适应市场规律[20]。

中国知网 https://www.cnki.net

张馨予（2019）在利用多因子选股模型中，对因子选取和因子分类进行优化，大幅扩充因子数量和种类，在利用随机森林进行因子分类基础上，注重关注因子的相关性和重要性，结果表明在容错性和对过拟合的处理方面，随机森林算法更为理想。据此方法构建的模型所得收益率也跑赢市场和基准指数，为算法的实际应用提供了可行性指导[21]。

Haoxuan Li（2020）通过实证研究证明多因子选股模型和机器学习算法在股票选择上优异表现，并对比 6 种经典的机器学习算法，使用 19 个因子进行股票选择，样本范围包括沪深 500 指数成分股。在六种算法多次测试的基础上，分析算法性能，并提出模型的改进方案[22]。

Yihua Zhong 等（2021）利用沪深 300 股票为标的，建立基于多分类器和基于多分类 XGBoost 算法的两种多因子选股模型，并且与利用等权重线性方法获得结果进行比较，结果表明这两种算法都能够获取较为准确的结果，且通过对算法进行优化的多因子模型精准度显著提高[23]。

Dou Changsheng 等（2021）将支持向量机与对多因子选股模型结合，利用中国股票市场作为样本进行研究。通过主成分分析进行因子降维，选取 13 个因子，采用径向基核函数对其进行分类，得到的选股模型有效性较好，且利用模型预测值对股票进行排序，结果可靠性高[24]。

1.2.4 随机森林算法研究现状

随机森林算法的兴起给量化投资提供了一个新的解决思路，作为一种高灵活度的分类算法，从一开始就在学界和业界得到了广泛的关注与应用。

雍凯（2008）首先对比了集成学习和随机森林算法，在对随机森林的优缺点进行分析的基础上提出改进特征算法，所设计的模型基于层次聚类方案，为后续随机森林的优化提供了参考[25]。

吴琼，李运田（2013）分析了传统的数据挖掘技术在非平衡训练集进行处理过程中存在的不足之处，利用 Neighborhood Cleaning Rule 对原始样本开展预处理，再利用随机森林实现样本分类，并与原始模型结果对比，证明改进的随机森林分类效果显著比原始模型更加理想[26]。

曹正凤（2016）采用指标相关性分析的方法，在以往对量化选股指标研究结果的基础上，研究了具有独创性的选股模型，共包涵八个有效因子。模型样本包括 200 只股票，利用随机森林算法进行分类，将 2013 年 3 月的数据为训练集，对 2013 年 4 月样本股票的涨跌情况进行预测，并对模型样本股票的行业平均收益率和极端值表现进行分析，结果表明构造的八因子模型在国内证券市场上有较

中国知网 https://www.cnki.net

为理想的表现[27]。

刘凯（2018）在原始随机森林算法基础上提出改进的自适应特征选择分类方法。由于存在随机森林参数选择上，也存在最优参数组合选取较为困难，整个模型参数选取效率低的问题，采用改进自适应特征算法之后，这些问题被妥善解决解决，改进后的算法可以有效提高提高模型的有效性和准确性[28]。

吴卫星（2018）采用随机森林算法，在由完全是技术指标构成的样本数据集中，共包涵二十二个因子指标，构建的量化选股模型将时间跨度上的基点设置为回测年份开始日期，利用此前两年样本当做模型训练集对随机森林展开训练，同时对训练数据池开展交叉对比校验，由此获得的累计收益超过同时期中证 500 累计收益[29]。

朱青（2018）在原有国内开放式基金风险评级的基础上进行改进，新模型共选取十四个因子，包括管理人择时能力，选股水平，机构持仓占比，净申购赎回情况等，采用层次聚类法进行整体风险评级，并引入随机森林搭建改进的中国开放式基金的综合风险评级模型，同时与采用支持向量机，决策树，logistic 算法的综合风险评级模型进行横向对比，最终结果显示四者当中的利用随机森林进行分类的效果最理想[30]。

李东，贾郭军（2018）在随机森林算法的基础上，叠加遗传算法并提出一种改进的子森林分类法，利用高质量决策树与初始种群的结合得到子森林，一方面可以提高模型的分类精度，另一方面可以减小随机森林的规模，并且利用 UCI 数据集对整个模型开展实证检验，提高整体准确性[31]。

贾秀娟（2019）利用随机森林算法对变量进行预处理，在原始算法基础上使用支持向量机以增强初始算法判别准确性，并将模型结果和采用主成分方法降维结果横向比较，结果显示在分类精准度上，利用随机森林的支持向量机要显著好于主成分的支持向量机模型[32]。

唐思佳（2019）利用因子分析模型筛选最优因子，组成共七个有效因子的因子池，利用机器学习构建随机森林模型，并对股票波动情况进行历史数据回测。使用从 2016 年元旦至 2018 三季度结束的全 A 市场数据对算法性能进行评估，获取最大回撤的超额收益[33]。

李杰（2019）在以往多因子模型的基础上改进，叠加机器学习构造随机森林的多因子模型，采用随机森林对单只股票开展类别评定，主要利用预测概率加权来计算资产组合中单个资产的权重，按照重要性对因子排序并选取排名靠前的因子以完成筛选，叠加因子轮动对整体模型优化，从而提高原有模型准确率，获得更高的资产超额收益率[34]。

中国知网 https://www.cnki.net

王慎敏（2020）通过随机森林模型预测个股的月度超额收益，构建一套多因子选股模型，以中证 800 成分股为股票池，使用了 40 多个技术因子和财务因子，选取 2008 到 2017 年的数据，并对其进行了标准化和中性化等预处理，每个月底根据前两年的数据使用随机森林算法建模，将当月数据输入模型预测下一个月中证 800 每个成分股的超额收益，并在后续的模拟组合跟踪中证实其有效性，验证了随机森林模型在多因子选股中有着较高的实际应用价值[35]。

邓晶，李路（2020）参考主动权益策略对股票的研究方法，利用卖方和买方的投研指标，按照相对强弱，能量潮，MACD，变动速率等作为选取的指标来进行预测，在对随机森林参数进行优化的前提下搭建利用技术指标作为有效因子的股票预测模型。样本由包括平安银行在内的 5 家上市公司共 26 个月的日交易数据构成，数据起始日期为 2017 年 5 月 1 号，经过实证检验之后，模型的整体评价也优于其他，为后续的研究提供了借鉴[36]。

周亮（2021）建立了包含 23 个因子的随机森林模型，预测中证 500 收益率，以此为基础构建投资组合，发现随机森林模型能够对个股的相对收益率进行较好的拟合和预测，其中动量因子在随机森林模型中的作用最强，而长期的流动性水平最不重要[37]。

Abraham Rebecca 等（2022）在随机森林的基础上讨论了每日股票的变动趋势，利用今天的收盘价来预测第二天的开盘价变化，分别构建了基于遗传算法和随机森林的分类器，以此来揭示股票指数和特定股票的趋势之间的隐藏关系，并证明随机模型对于预测股票指数的有效性[38]。

Li Wei 等（2022）为了应对随机森林在不平衡数据分类中分类性能差，DT 规模大等问题，提出改进的随机森林算法，通过添加随机性来确保每棵树的有效性，降低彼此相关性，并且用实验证明改进后模型较好的外推性和良好的预测能力[39]。

Zhang Qingyang 等（2022）将随机森林算法引入到异常样本的检测中，提出了异常点尺度的概念，将样本相似度作为指标来判断样本异常状况，并选出异常值从而改进数据模型。通过实证结果表明，采用随机森林算法的异常样本检测方法，能够显著提高模型精度，并大幅缩短模型运行所需要的时间，在大数据处理方面有显著优势[40]。

Behr Merle 等（2022）利用随机森林算法对影响投资者情绪波动从而影响股票价格的因子进行指标进行重要性排序，通过主成分分析法来衡量情绪变动与证券收益率之间的关系，并不断提高模型预测准确度，且优化后的模型效果提升非常明显[41]。

中国知网 https://www.cnki.net

Kumano So 等（2022）比较了随机森林、BDDs 和神经网络在节点数量方面的优劣。结果表明在大多数情况下，当需要处理大量数据时，尤其是当节点呈指数级增长的情况下，相比于其他算法那，利用随机森林算法可以有效减少数的数量，证明了在大数据处理方面存在的优势[42]。

Illa Pavan Kumar（2022）等利用随机森林和支持向量机来构建股票价格预测模型，通过计算股票的现在价格是否高于它某一天的成本来制定套利交易。实验证明，利用随机森林和支持向量机构建的股票价格预测模型，将人工智能和数据挖掘方法引入股票价格预测中可以获得较好的收益率[43]。

1.2.5 文献评述

国外量化起步早，发展成熟，对多因子选股有着系统完善的研究，也涌现出了很多成熟稳定的模型和策略，在市场中的作用越来越大，这些给我国的量化投资提供了很好的参考，具有重要的借鉴作用。与国外成熟的金融市场不同，我国的市场具有弱有效市场的特点，大量的散户交易带来了很多的噪声，容易产生羊群效应，同时我国股票市场的 T+1，交易手续费和涨跌停板制度意味的国外的研究在我国不具有完全的适用性。在探索适合我国国情的多因子选股策略时，需要考虑到国内外市场的差异，做一定的调整和改进。

近几年多因子选股模型发展十分迅速，很多模型的实盘收益相当可观，基于量化模型的私募、基金产品也越来越多，但同时，还存在一些不足与缺陷：

第一，由于目前的模型主要利用财务指标来构建，并没有包括影响股票价格的其他因子，造成影响因素维度的缺失，有较大的预测偏误；同时，财务数据有较长的时滞，并不能及时反映到股价上，这种模型的效果一般不好，而且往往与市场联系不是很紧密，难以反应盘面变化。

第二，目前国内学界倾向于使用线性模型或者打分法来构建模型，而股票市场是非线性的，从模型自身而言，这种数据挖掘有很大的系统误差。第三，国内的研究往往基于对算法的优化，或者是模型准确性的检验，并没有对整个模型进行数据回测或者是实盘验证，缺乏完整的从模型建立，股票选取，数据回测，实盘验证这样一个完整的体系，所以很多的研究结果在实际生活中并没有得到很好的应用，或者适用性不强。

1.3 研究内容与框架

1.3.1 主要研究内容

当下，本文的选股模型问题主要包括下面三个部分。

中国知网 https://www.cnki.net

第一，有效因子的组成与筛选。多因子选股能取得较好收益前提是所选因子有效，主要包括原始因子池的选取以及如何从筛选有效因子作为模型参数这两个部分。如何保证原始选取的因子池覆盖范围较广，准确性高，同时不会造成重要因子的遗漏，以及利用何种方式从因子池中将有效的因子筛选出来是多因子选股模型需要着重注意的地方，也是影响模型准确性的前提。

通过 wind 收集科创板周交易数据，时间跨度为 2020 年元旦到 2022 年元旦，共 24 个月，包括交易开收盘价，成交量，换手率，市盈率，总市值，总股本等，为反应股价真实情况，采用不复权的原始数据。数据预处理包括去除无效数据，处理缺失值，极端值处理，数据标准化等，减小交易噪声对模型的影响。剔除所有 ST，*ST，停牌，以及不能正常交易的股票。因子池构建参考 wind 指标与国君金工研报，分为原始因子与构建因子两大类，按照论文所需的利用原始数据为基础进行检验，完成数据预处理之后对因子相关性进行检验，利用因子重要性构建选股模型。

第二，采用随机森林确定因子权重及计算股票综合得分。随机森林对因子进行分类判别，计算因子有效性，并利用因子重要性计算股票得分。这其中对随机森林的参数选择能显著影响模型准确性，在此基础上，对因子重要性进行判别时进行排序，同时舍弃不重要的因子，并根据股票得分筛选排名靠前的证券构成资产池。如何调整随机模型参数达到最优，对因子进行有筛选的重要性排序是需要解决的问题。整体模型搭建使用 SPSS，同时在预处理数据的基础上，进行随机森林参数寻优与窗口长度的确定。

利用随机森林算法构建的选股模型始终处在变化中，是一种动态模型，需要根据数据进行不断的学习，对于每一个回测周期都需要对模型进行训练，并进行数据测试，不同的参数与持仓时间的选取对模型效果的影响较大。借鉴前人的研究成果，利用网格搜索寻找最优参数，对每组参数进行交叉验证并计算整体收益率来评判效果。在持仓时间方面，预设一系列长度值，分别比较不同持仓时间下收益率情况以确定最优模型参数。

模型训练数据从 2020 年元旦开始到 2021 年二季度结束，利用 2021 年三季度开始到 2022 年元旦的数据对模型效果进行回测，整体共 105 周的数据，将证券涨跌幅变化数据与所选用的的因子数据结合，以达到完成模型的训练的目的，基于周数据对未来一周的证券涨跌幅的变化进行预测，同时从高到低进行排序，将排序靠前的的证券选取出来，作为下个周期的资产池，再次带入模型中，进行预测和筛选，重复迭代，完成整个模型的训练和预测。

第三，多因子模型的拟合回测及收益率优化分析。在得出股票综合得分的基

中国知网 https://www.cnki.net

础上，计算收益率与资产波动程度。资产池中股票数量的多少意味着资产集中程度，资产集中度高，获得潜在收益的可能性就大，但是波动程度也高，同时调仓周期长短也会影响收益和波动。如何选择资产池的构成及调仓时间长短，寻找资产波动与收益率之间的平衡点，从而使模型具有实际应用价值，是模型优化的重要思路。将基准指数与模型的累计收益率大小进行比较，判断二者之间的差异，同时考虑收益率的波动程度及稳定性等，综合起来对选股模型的效果进行评价。同时考虑调整组合权重，调仓期限效应，T+1 机制的影响等，对模型进行动态的调整与优化，更加接近现实市场。

本文的研究内容主要围绕上述问题展开。

第 1 章绪论，文献综述部分，对多因子选股模型的发展，分类算法的应用，以及国内外在量化选股方面所作的研究进行了总结，并对目前研究的不足之处进行了评述。

第 2 章介绍了随机森林算法与多因子选股模型的相关理论。首先介绍了量化模型的特点，分析了不同量化选股模型的优缺点，以及多因子模型的发展变化和优势所在。其次对常见分类算法的主要原理进行简析，包括 KNN，神经网络，XGBoost 等，并详细分析了随机森林算法的构成，指标评价体系以及与其他分类算法相比所具有的长处。

第 3 章介绍了样本选取，因子池构建及因子相关性检验。本章建立了一个基于技术和财务的因子池，尽量覆盖主要的指标，包括原始因子和构建因子两大类共 15 个。在对所选因子给出理论解释的同时，考虑因子的实用性价值，对因子的相关性及回归显著性进行分析，得到因子是否有效的简易判断，与后续的随机森林结果进行交叉验证。

第 4 章对随机森林进行训练，同时对多因子模型进行调整。在因子重要性排序的基础上，选取随机森林模型最适合的决策树棵树和决策分裂特征数量，并选取证券构成资产池，计算多因子选股收益率。由于资产池中股票数量和调仓周期都会影响总的收益率与波动程度，本文多因子模型进行了多情况讨论，并按照讨论结果对模型进行了优化，从而得到较为理想的结果，在保证收益率的同时降低收益波动程度。

中国知网 https://www.cnki.net

1.3.2 技术路线图

本文的技术路线如图 1-1 所示。

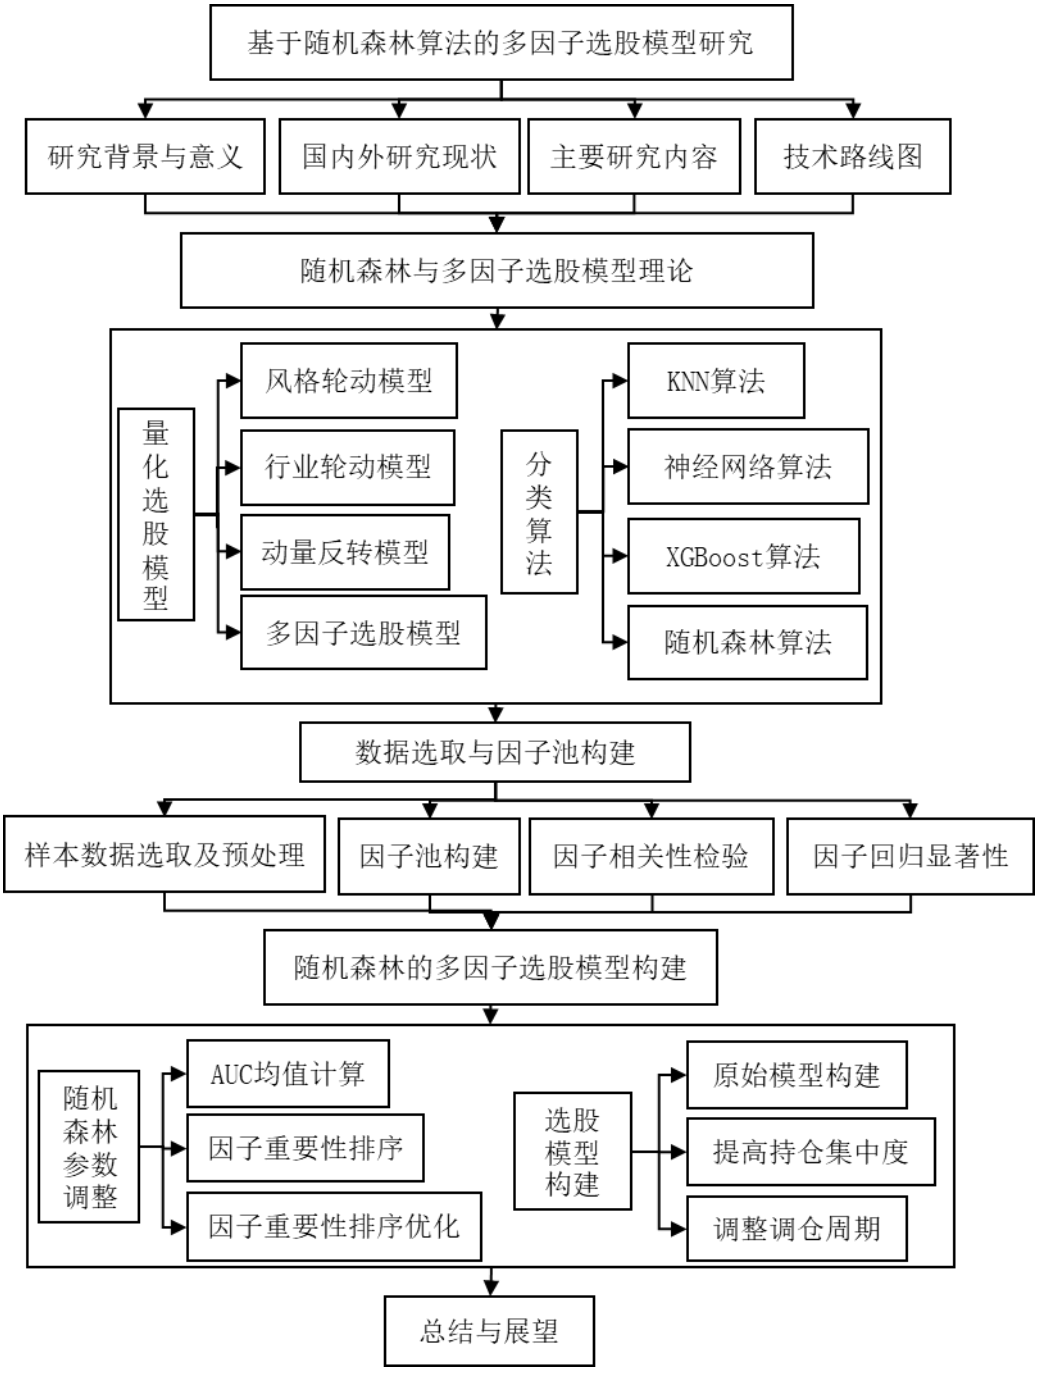


图 1-1 技术路线图

中国知网 https://www.cnki.net

第 2 章 量化选股模型与分类算法

2.1 量化投资

所谓量化投资，就是将数量统计学的知识应用到金融市场中，利用数量化的研究工具，将投资标的的各个指标进行衡量，从而提取出有效的交易数据，以此为基础进行投资行为的决策，从而获得超额收益。由于股票市场的各种指标繁杂多样，宏观数据，财务数据，交易数据，市场信息，公司公告等，而且其中掺杂着大量的无效信息与噪声，要从大量金融数据中分辨噪声干扰和有价值的信息，是对量化投资的巨大挑战。同时，还需要保证一定的时效性，如果从收集数据到发现有效信息的时滞过大，则信息的价值性会大打折扣。在此基础上，需要将计算机与数据挖掘技术联系起来，寻找数据背后隐藏的规律与统计特性，从而找到潜在的投资机会。

作为一种主动性投资策略，量化投资虽然也是基于弱式有效市场假说，但是与传统定性投资存在一定的区别。量化投资将数理模型和统计方法结合到一起，寻找最优的指标构成因子池从而构成投资基础，试图获得超额收益率，从而将情绪，偏好等主观因素排除在外，投资决策稳定且有规律可循。

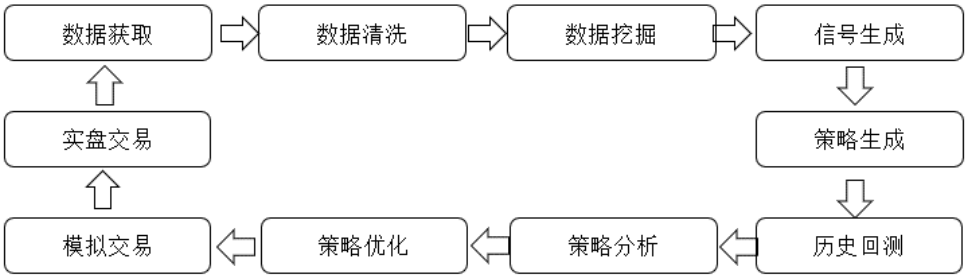


图 2-1　量化投资选股流程

在美国二级市场除大额交易以外的交易中，采用量化投资方法的资金占整个市场的五分之一，各家量化机构大显神通，市场影响力巨大，其中以西蒙斯创建的文艺复兴科技公司最为出名。包括花旗，摩根在内的各大金融机构，都加大了在量化方面的技术人才投入，量化策略不断成熟，所承担的交易量也与日俱增。国内的基本面投资依然是主流，但是随着金融市场体量的扩大，证券数量的增加，传统的投资方式难以持续获得超额收益；另一方面是国内的量化基金的高回报率，让大家对量化所能带来的财富有了直接的认识，券商，公募，私募都不断发行量化产品，在 2008 年前后，量化基金的发行达到前所未有的热度，在 2014 年，又达到了新的高峰。

量化投资有以下几方面的特点：

中国知网　https://www.cnki.net

（1）规律性

不用于其他方法，量化策略的选定之前需要经过长时间的调整以适应市场，在策略定型后更是通过计算机去精准实现买进卖出，所有的操作都是在前期模型的运行基础上进行判定，从而最大限度减小主观情绪产生的影响，避免了人性的各种弱点。程序可以在大量的交易中获得超过平均水平的收益率，即使出现部分亏损，其总收益依旧是可观的。同时，利用大量的数据进行训练，并不断调整优化回测，可以降低模型出现偏差的概率。

（2）套利性

套利基础是市场价格和实际价值的差额，可正可负，量化的做多策略是买入价格被低估资产，待其价格上涨后卖出获利，而做空策略是卖出价格被高估资产，待其价格下降后买回平仓。由于中国股市的特殊性，目前国内量化策略主要以做多为主，融资融券占比较少。量化投资的每一次交易获利可能并不多，通过多次交易的累计收益极其可观。由于是程序化交易，每次交易的边际人力成本几乎为零，具有人工交易无可比拟的优势。

（3）系统性

量化投资需要一个非常完善的框架来支持投资决策，涵盖多维度，多层次，多数据，需要较大的前期投资才能有产出，这点和传统的投研体系有很大区别。将资产在行业和个股之间进行配置，赚取行业的阿尔法，同时收获个股的贝塔，多层次建立交易模型。在因子选取方面包涵估值因子，动量因子，成长因子，反转因子等一系列全方位，多角度，宏微观并存的因素，这些因子如同基石共同构成量化模型的万里长城，每一个因子对整体而言作用虽小，却不可或缺。多数据即量化模型的数据量巨大，动辄以 TB 计量的数据量让系统承受了巨大的运算压力，而且数据有效密度低，存在大量的无效噪声数据，如何有效的寻找出有用信息同时同时兼顾系统稳定性，以最低成本完成信息挖掘，是需要注意的问题。

（4）概率性

量化投资并非每次都可以盈利，试图达到每笔交易都获利几乎不可能，而是通过投资一个股票集合，在这个集合中，有亏有赚，但是总的获利超过总的亏损，或者总的交易盈利超过总的交易亏损，从而获得超额收益，其中亏损和盈利占比是概率事件，通过不断以历史数据进行回测或学习，从中寻找统计规律，对模型进行修正，增大盈利概率并尽量减少亏损概率，从而提高模型的收益率，提升盈利概率也是目前大家孜孜不倦的动力。

中国知网 https://www.cnki.net

2.2 选股模型

量化投资的选股模型较多，各种模型的改进方法层出不穷，无论是机构还是散户，都开始关注量化投资策略，对模型的不断改进，对数据的不断扩充，快速推动了量化行业的发展。

2.2.1 风格轮动模型

风格轮动模型借助市场风格变化的趋势，对市场整体交易进行追踪从而完成选股。市场风格变化主要分为市场中拥有分立特性的资产组成资产集合，如大小盘，ST 和非 ST 板块。由于随着时间变化，国际形势，政府政策，宏观经济及人们偏好都存在差异，由此导致市场整体风格可能发生变化，不同时期追捧的焦点，炒作的对象都不同。风格轮动模型可以进行察觉到投资趋势，收益超过集中持仓某一类型的股票。风格变化的判定极度依赖于投资者的主观判断，无法摆脱人性的缺点，容易造成误判，同时背后的驱动因素很难分析，需要同时囊括多个模型。

2.2.2 行业轮动模型

行业轮动模型主要是将特定行业周期变化作为投资依据。由于经济运行变化，不同行业也会有波动，且存在波动幅度，波动时间等方面的差异。领头行业变化通常能推动其他行业的进步，而跟随行业，由于波动时间存在一段时滞，往往处于行业变动的末期。

在一个完整的经济周期中，通过追踪行业板块轮动的边际变化情况，从而对行业未来的走势作为预测与判断，在此基础上对特定行业的资产进行选择并构建资产组合，这样在分析某行业在经济周期中的变动规律，按照行业的变化趋势，选择优于市场平均水平的行业来调整资产池的构成以获得权益增强，增大获得超额收益的概率。由于行业的划分具有一定的主观性，目前就有多种划分方式，包括申万，wind 等，会在不同程度受到标准不统一的影响，同时宏观因素对行业的影响也较大。行业划分存在区别，同时对不同行业划分没有完全相同的策略，需要按照具体的情况进行调整，如 M2 行业轮动仅适用于周期和非周期性行业，如果用到其他的划分当中，就会出现较大偏差。

2.2.3 动量反转模型

动量反转模型是追踪股票价格的人气与态势变化，利用预先选取的基准作为参考指标进行选股。根据动量效应和反转效应，前期的强势股票在未来会大概率继续走强，前期的弱势股在后期也将大概率走弱。动量反转模型将行为金融学的

中国知网 https://www.cnki.net

相关内容融入到股票价格中，考虑到投资情绪带来的非理性投资，也就是俗称的追涨杀跌，更加贴近中国市场的现实情况。但是这种强弱势的变化以及幅度不容易度量，很难做到精确的量化。

2.2.4 多因子选股模型

多因子选股发展最早，相比其他模型较为简单，理论研究全面，基础比较成熟且应用范围广，主要用于选股方面，通过选取和股票盈利有关的因子构成原始因子池，按照因子之间相关性进行排序筛选，从而建立多因子选股模型。股票的收益受到很多因素的影响，财务状况，经济状况等，并且由于不同国家证券市场的差异，因子的有效性也会受到国别差异的影响[44]。

多因子选股模型在弱有效或者非有效市场条件下使用，同时需要假定影响因子对股票收益的影响具有持续性，即在过去发现的有效因子，在未来一定时间内是有效的。在此基础上，追踪股票市场中的有效因子，选取被低估的股票，同时综合各方面有用的信息，构建稳定可行的策略进行实盘验证[45]。

目前的量化模型中，主要的改进方向集中于两点：选取的因子需要具有较好的有效性，尽可能提升模型对数据拟合的准确性，从而达到提高预测精确度的目的；在尽量保证因子有用，同时提高精确度的前提下，建立择股模型。不管是CAPM 采用的无风险利率和风险溢价还构成最原始的模型函数，还是 Fama 后来在三因子模型中拓展的市值，账面市值比，市场风险，都不能完整的权衡股票收益因素，在现代模型中，将价值，动量，成长，技术等几类指标加进模型中，涵盖多维度并具有合理的理论解释[46]。

多因子模型进行评价存在多种办法，其中主要包括打分法和回归法，且各有优劣。打分法原理较为简单，容易上手并可以快速实现，按照所选因子与模型收益率相关性大小进行排序，将正相关因子相关性由高到低降序排列，而负相关因子升序排列，将所属统一大类的因子进行得分加总，定义为大类因子得分，最后将所有大类因子加权求和计算总的分数，并且选取分数排名靠前的资产组合开展投资。

打分法简单易行，操作难度低，不容易受到极端值的影响，但是各个因子的权重分配方面，不容易确定，受到人为因素的影响较大，意见也不容易统一，需要多年的投资经验才能给出合理的权重。

回归法相对复杂，在实施难度上也高于打分法。回归法首先建立因子池中每个因子与证券收益率之间的关系，利用多元回归模型将多个因子与证券收益率之间进行回归，进而能够将因子与收益之间的联系进行量化[47]。利用模型的回归系

中国知网 https://www.cnki.net

数来确定不同因子之间的组合权重构成，同时依据仓位变化周期带入新因子，在原始模型基础上不断迭代，多次迭代后得到单只证券收益预测值，将股票池中所有证券的预测值进行排序并利用排序结果进行筛选，选取排名靠前的证券组成资产池，按照选取数量不同，还可以组成不同的资产池，从而进行横向之间的比较，回归方程如公式 2-1 所示：

$$\begin{aligned} r_i &= k_1 f_1 + k_2 f_2 + \cdots + k_j f_j + \cdots + k_n f_n + u_i \\ &= \sum_{j=1}^{n} k_j f_j + u_i \end{aligned} \tag{2-1}$$

上式中k_j为j的参数权重，f_j为j的收益率水平，u_i为其他因素提供的收益。

回归法在因子与股票收益关系的基础上，定量分析各个因子对股票收益贡献率的影响，能够有效对单个因子和综合因子进行评价，但是容易受到极端值误差影响，实际应用时需要注意偏误的控制。

2.2.5 选股模型比较

这几种模型各有特点，风格轮动模型能够按照市场风格的变化来配置资产，行业轮动模型按照不同的指标分类，从而以宏观经济的运行为参考进行资产配置，资金流动模型利用主力资金方向进行投资标的的选取，动量模型在市场基本因素之外，加入投资者的行为因素，将行为学的内容考虑进去，比如包括非理性人，羊群效应等，更加贴近国内股市运行背景。但是现阶段，这些模型的因子和参考标准的选取会被个人认知，偏好和投资经历影响，具有主观性，需要负责人具有数十年的投资经验，历经市场起伏，周期变换，而不能做到完全依靠数据的量化。

2.3 分类算法

分类算法的选股对量化模型的效果尤为重要，目前的策略模型都致力于提高预测的准确性，这就对分类算法提出来较高的要求，市场常见和成熟的分类算法包括 KNN，神经网络和 XGBoost 等。

2.3.1 KNN 算法

KNN 算法最早出现在 1968 年，在深度学习，人工智能，量化投资等方面得到较为常见的应用，算法适用性强，灵活度高，可以并行分析分类和回归问题，在模式识别，算法检测，数据统计等方面很多的研究，是比较典型的的分类方法。KNN 算法的基本原理是通过测量不同数据特征值之间的类欧式距离，然后采用投票法对输入向量的类别实现判别，算法整体的核心思路来自于极限定理。由此可见，在完整样本特征的组成空间中，样本 M 存在 K 个最相邻样本，而特定类样本类别 J 的数目明显超过其他类别样本数目，这样就可以判定为这个特定样本

中国知网 https://www.cnki.net

有较大可能性拥有 J 类别特征，以此为依据，将这个特定样本归入其中。

在使用 KNN 算法的时候，第一步将某未知分类样本带入模型中去，并算出样本与其他全部已知样本的距离，以此为依据进行排序，按照距离大小由低到高排列，在其他全部已知分类采样的结果中，筛选 K 个距离待分类最近样本，设置为最近邻样本，进一步的，算出 K 个最邻近样本各自归属特定类别数目，对类别依照数目排序，数量最多的判定为类别 J，把未知样本判定为 J 类。在整个过程中，最关键的因素是 K 值的确定和距离度量方法的选取。目前一般利用交叉验证来确定 K 值，其中需要注意到极端值对模型的影响，K 值偏小会导致算法的过度拟合，K 值过大会导致算法的拟合不理想[48]。

KNN 算法的优点：（1）原理存在理论完备性，利用代码进行实操较为容易，无需反复的参数和特征搜索，整体门槛较低。（2）训练速度较快，KNN 算法不需要十分冗长的数据训练，模型所需时间相对较短。（3）异常数据不敏感，对数据容错性较好，极端值带来的偏误较小。在进行分类时，如果整体样本集合中某一类别样本占比高，而其他类别样本占比小，样本有分布失衡风险，会造成算法出现较大偏误，对陌生样本处理效果不理想。除此之外，在对样本的处理过程中，由于是欧式距离排序，会消耗大量的计算机资源，对硬件的要求较高。

2.3.2 神经网络算法

在 KNN 之后，分类算法得到空前发展，包括神经网络在内的分类方法层出不穷。其中神经网络算法参考神经突触联接结构，构建大量节点并将节点之间两两连接形成一个巨大的网络，即“神经网络”，来完成信息的处理。神经网络需要经过提前训练，对模型的参数进行优化，利用训练去调整不同网络连接点之间的权重，从而用于对象的识别，从而用于对样本的分类，需要大量的训练才能确保完整模型的精准程度。神经网络虽然较为理想，但是也存在一些问题，比如为了达到预定的目标，往往需要大量的数据进行训练，动辄几天甚至几周，同时神经网络的计算量大，需要高昂的硬件投入才能满足性能要求，同时网络收敛速度慢，结果不可解释等难也在不同程度给使用者造成困扰。

神经网络在向前传播过程中，利用σ激活函数完成输出函数的计算，因此神经网络模型的输出结果如公式 2-2 所示

$$f(x;\theta)=\sigma\left(w^{(L)}\dots\sigma\left(w^{(2)}\sigma\left(w^{(1)}x+b^{(1)}\right)+b^{(2)}\right)\dots+b^{(L)}\right) \tag{2-2}$$

其中 L 是神经网络的输出层

$$\theta=\left\{w^{(1)},b^{(1)},w^{(2)},b^{(2)},\dots,w^{(L)},b^{(L)}\right\} \tag{2-3}$$

定义模型的训练集

中国知网 https://www.cnki.net

$$\left(x^{(1)},y^{(1)}\right),\left(x^{(2)},y^{(2)}\right),\ldots,\left(x^{(r)},y^{(r)}\right),\ldots,\left(x^{(m)},y^{(m)}\right) \tag{2-4}$$

损失函数的计算方法如公式 2-5，公式 2-6 所示

$$C^{(i)}(\theta)=\frac{1}{m}\sum_{r=1}^{m}\left\|f\left(x^{(r)};\theta\right)-y^{(r)}\right\| \tag{2-5}$$

$$C(\theta)=\frac{1}{N^{(L)}}\sum_{i=1}^{N^{(L)}}C^{(i)}(\theta) \tag{2-6}$$

在神经网络模型第二个阶段，反向传播中，利用参数梯度的计算来追踪参数的边际变化，从而完成相关数据的更新，损失函数对神经网络权重w的偏导数为

$$\begin{aligned}\frac{\partial C(\theta)}{\partial w_{jk}^{(l)}}&=\frac{\partial C(\theta)}{\partial z_j^{(l)}}\frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}\\&=\delta_j^{(l)}a_k^{(l-1)}\end{aligned} \tag{2-7}$$

将损失函数对偏置b求偏导，得到公式 2-8

$$\begin{aligned}\frac{\partial C(\theta)}{\partial b_j^{(l)}}&=\frac{\partial C(\theta)}{\partial z_j^{(l)}}\frac{\partial z_j^{(l)}}{\partial b_j^{(l)}}\\&=\delta_j^{(l)}\end{aligned} \tag{2-8}$$

更新神经网络权重w和偏置b

$$\begin{cases}w_{jk}^{(l)}=w_{jk}^{(l)}-\alpha\dfrac{\partial C(\theta)}{\partial w_{jk}^{(l)}}\\b_j^{(l)}=b_j^{(l)}-\alpha\dfrac{\partial C(\theta)}{\partial b_j^{(l)}}\end{cases} \tag{2-9}$$

其中α为学习率。

表 2-1 为模型中各个符号的含义：

表 2-1　模型符号及含义列表

模型中的符号	所代表的含义
$\mathcal{W}_{jk}^{l}$	位于l层j位置的神经元与前一层的k位置神经元的权重
$w^{(l)}$	第l层与前一层的权重矩阵组成
$b_j^{(l)}$	位于l层j位置的神经元偏置参数
$b^{(l)}$	偏置向量（第l层）
$z_j^{(l)}$	位于l层j位置神经元的输入取值
$z^{(l)}$	输入向量（第l层）
$a_j^{(l)}$	位于l层j位置神经元激活值
$a^{(l)}$	激活值输出向量（第l层）
$N^{(l)}$	第l层中神经元总数
$C^{(i)}(\theta)$	第i个输出所对应的损失函数
$C(\theta)$	损失函数
$\delta_j^{(l)}$	损失函数在位于l层j位置神经元上的偏差
$\delta^{(l)}$	损失函数在第l层中的误差向量

中国知网 https://www.cnki.net

2.3.3 XGBoost 算法

XGBoost 是 boosting 算法的一种，由陈天奇在 2016 年提出，组成 XGBoost 的决策树是 CART 回归树模型，通过添加一棵树与已存在的回归树有关，这棵新树旨在对前次计算残差进行参数拟合。XGBoost 主要包括原始目标函数的构建，泰勒展开，树参数化和最后目标函数的化简与优化。

XGBoost 的目标函数公式 2-10 所示

$$Obj = \sum_{i=1}^{n} l(y_i, \hat{y}_i) + \sum_{k=1}^{K} \Omega(f_k) \tag{2-10}$$

由上式可见，目标函数包括两部分，第一部分$\sum_{i=1}^{n} l(y_i, \hat{y}_i)$用来评价模型的预测能力，称之为目标函数的损失函数；第二部分$\sum_{k=1}^{K} \Omega(f_k)$是目标函数基于树复杂度的正则项，通过添加这一项来防止模型过度拟合，当模型结果进行纠偏。

在前一次预测残差的基础上，对新生成的树进行拟合，这样当 t 棵树生成时，预测的结果公式 2-11 所示

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i) \tag{2-11}$$

将原始的目标函数改写下，得到公式 2-12

$$L^{(t)} = \sum_{i=1}^{n} l\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) + \Omega(f_t) + c \tag{2-12}$$

原始目标函数直接优化比较难，为了找到满足函数最小条件的$f_t(x)$，将$L^{(t)}$二阶泰勒展开，从而简化目标函数，降低计算量，从而得到要找的$f_t(x)$，公式 2-13 为$L^{(t)}$二阶泰勒展开式

$$\tilde{L}^{(t)} = \sum_{i=1}^{n} \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)\right] + \Omega(f_t) \tag{2-13}$$

在对样本加和的基础上，对上式进行调整，对树模型参数化，另一方面对树的复杂度参数化，在叶子结点加和，利用近似值代替精确值，得到公式 2-14

$$\begin{aligned} Obj^{(t)} &\approx \sum_{i=1}^{n} \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)\right] + \Omega(f_t) \\ &= \sum_{i=1}^{n} \left[g_i w_{q(x_i)} + \frac{1}{2} h_i w_{q(x_i)}^2\right] + \gamma T + \lambda \frac{1}{2} \sum_{j=1}^{T} w_j^2 \\ &= \sum_{j=1}^{T} \left[\left(\sum_{i \in I_j} g_i\right) w_j + \frac{1}{2}\left(\sum_{i \in I_j} h_i + \lambda\right) w_j^2\right] + \gamma T \end{aligned} \tag{2-14}$$

对关于w的一元二次函数求解，直接用目标函数对w求导，从而得到最优的w值，将w反带入原始目标函数中，得到目标函数值，化简后得到公式 2-15

$$\begin{aligned} w_j^* &= -\frac{G_j}{H_j + \lambda} \\ Obj &= -\frac{1}{2} \sum_{j=1}^{T} \frac{G_j^2}{H_j + \lambda} + \gamma T \end{aligned} \tag{2-15}$$

2.3.4 随机森林算法

随机森林（RF）最早被业界熟知是本世纪初，当时 Breiman 将决策树组合成

中国知网 https://www.cnki.net

RF，是利用决策树对数据改造的方法。在实际使用中，首先利用决策树当做初始分类器，通过自助法重采样方法，在初始样本数据中任意选取部分样本当做模型训练集，数据选取采用有放回抽样，采用训练集对决策树展开训练，多次重复以上过程就能得到多棵决策树，从而完成样本分类判别。

由于随机森林是在决策树的基础上演变而来，而整个模型中的每个决策树都是通过单独选取训练样本来生成，在这种情况下，虽然单棵决策树的分类效果并不理想，存在分类效果弱的问题，但是当存在多棵随机生成的决策树之后，组合成完整的决策树林，分类效果会显著提高，整个模型分类的偏误也会得到显著的改善。

目前流行的方法主要包括两种，其一是单分类器，只含有单个分类器，比如决策树方法；另一种是包涵多个分类器的多分类器方法，比如随机森林方法。单分类器的局限较多，性能较弱，多分类器以单分类器为基础建立，在分类技术中加入了集成学习思想，在分类过程中同时使用多个分类器来降低模型偏误，减小分类误差，从而提高模型性能。

由于随机森林由多棵决策树构成，且单棵树利用的是整个训练样本的部分数据和特征，从而消除模型过拟合现象的出现。由于决策树的训练样本特征是随机选取的，所以能够保证模型的稳定性。同时，在没有特征选择约束的情况下，随机森林可以支持并行计算且可很好的应用于高维数据，在大量数据处理方面有显著的优势。

与此同时，由于数据集的噪声干扰比较严重，很容易出现由噪音带来的偏差，且存在不同的划分属性导致取值数目不同对模型的平衡容易产生干扰，取值数目多的影响力较大，而取值数目小的影响力较小，如何选取合适的取值数目，也是模型所需要解决的问题。

随机森林模型的建立较为简单。首先，利用有放回抽样，在原始数据样本中任意抽取 N 个数据作为样本，之后选取原始数据中 K 个特征原始数据集，按照有放回的方式，任意抽取 N 个样本，最后选取原始数据中的 K 个特征，由此建立决策树，再反复进行 M 次，汇总 M 棵决策树之后可以得到整个随机森林。

随机森林是由多个决策树组合而成，其中单个决策树的构成主要有多个内部节点和叶节点，在具体应用中利用单个叶节点来表示单个分类结果，利用单个内部节点表示单个分类属性，从而利用分类属性的不同取值，将单个内部节点样本进行划分，分别对应每个分支的子节点上，汇总到根节点之后，每一条由根节点到叶节点的路径都代表一种分类方法，而根节点的样本集合则表示完整的样本集合，从而构成决策树。将新样本带入随机森林中，利用投票或者打分法确定其类

中国知网 https://www.cnki.net

别，原理如图 2-2 所示。

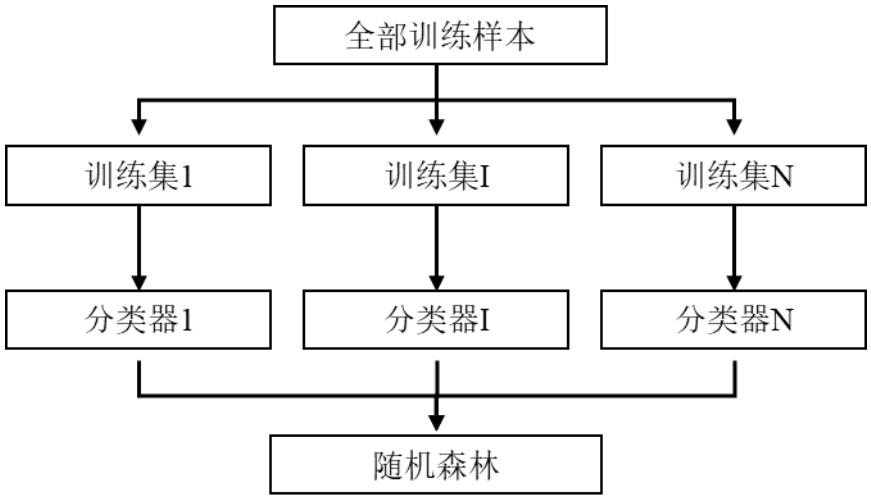


图 2-2　随机森林原理示意图

决策树通过训练对单棵树进行训练从而使其具有对未知样本的分类能力和泛化能力，以达到较理想的效果。具体原理上，先利用递归方式生成决策树，以根节点为出发点对同个迭代的不同属性生成不同的叶节点，再以新建的叶节点为为根节点向下继续生成新的叶节点，直到每个叶节点的样本集合类别是相同的[49]，决策树原理如图 2-3 所示。

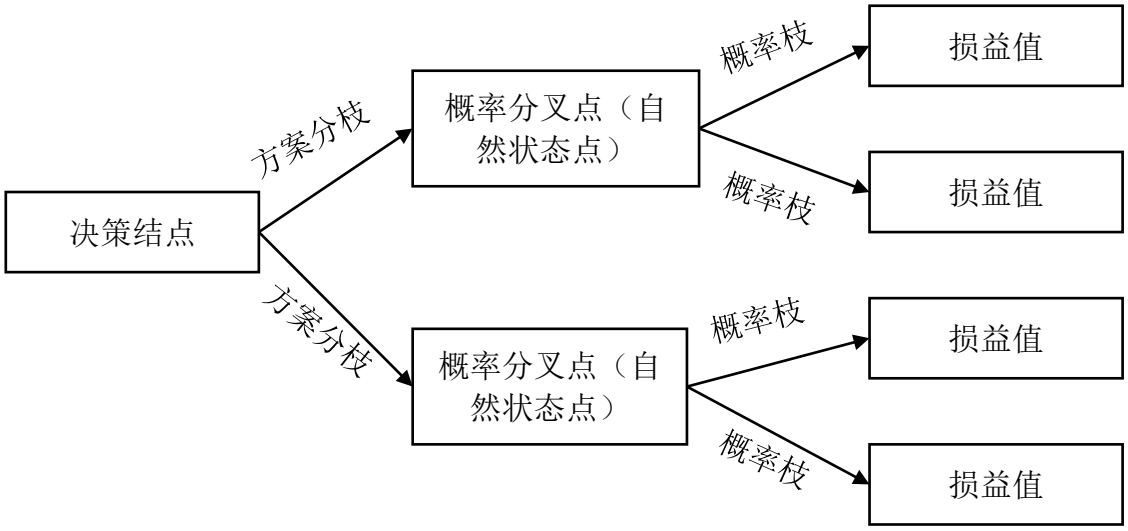


图 2-3　决策树原理示意图

决策树主要是完成结点的优化，在最优属性分类的基础上，通过分裂产生两侧子树，目前应用较多的分类属性算法包括 ID3，C4.5 和 CART。

ID3 方法主要通过信息熵来衡量刻画样本的集纯度。其原理是首先假设样本集合U有 N 个类别个数，其中样本i数量在总样本数量中所占比例为p_i(i=1,2, … , N)，则对于集合U，其信息熵为：

中国知网　https://www.cnki.net

$$I(U) = -\sum_{i=1}^{N} p_i \log_2 p_k \tag{2-16}$$

其中$I(U)$表示集合U的纯度，其值越大纯度越小，不确定性越高，而值越小纯度越高，不确定性越小，所以 ID3 模型尽量追求较小的$I(U)$值。

假设属性 D 由 K 个不同属性构成，从而使用 D 来对集合 U 进行划分之后，将集合 U 变为子集合的构成，共 K 个不同子集合，将集合 U 中属性 D 取值为 i 的样本集记作U^i，利用集合 U，以信息熵为基础，将不同子集合中包含数量不一致的样本提取出来，对有差异的子集合U^i给予不同的权重$\frac{|U^i|}{|U|}$，从而将样本个数与样本产生的影响直接挂钩，样本容量越大，效果越理想，据此可得到在 D 基础上对 U 划分的信息增益，如公式 2-17 所示：

$$\text{Gain}(U, D) = I(U) - \sum_{i=1}^{K} \frac{|U^i|}{|U|} I\left(U^i\right) \tag{2-17}$$

信息增益越大，其所衡量的不确定性就越小，这是因为信息增益本质上是衡量属性划分样本集合带来的样本纯度提升，通过不断调整模型获取较大的信息增益是对模型优化的有效途径。ID3 的核心思路就是通过信息增益识别最优属性，从而达到较好分类效果，但是这也会产生一个问题，在实际应用中不可能保证不同属性每次取值数目都相同，大多数情况下不同属性取值数目都不同，这种条件下信息增益会偏向含有较多属性取值数目的属性划分。在 C4.5 算法中对这个缺点进行了优化，有效规避不平衡在模型分类过程中的影响，按照这种思路，对提出信息增益率的新计算方式，如公式 2-18 所示：

$$\text{Gain_ratio}\ (U, D) = \frac{\text{Gain}(U,D)}{R(D)} \tag{2-18}$$

公式 2-18 中

$$R(D) = -\sum_{i=1}^{K} \frac{|U^i|}{|U|} \log_2 \frac{|U^i|}{|U|} \tag{2-19}$$

即基本公式为：

$$\text{Gain_ratio}\ (U, D) = \frac{\text{Gain}(U,D)}{-\sum_{i=1}^{K} \frac{|U^i|}{|U|} \log_2 \frac{|U^i|}{|U|}} \tag{2-20}$$

由公式 2-20 可知，属性 D 的可取个数 K 与$R(D)$成正相关，即 K 越大，$R(D)$数值越大，从而通过控制 K，可以对$R(D)$进行调整。C4.5 利用启发式思维，在筛选待选划分属性信息增益的时候，选用高于平均水平的数据，在此范围内寻找具有最高增益的数据，这点和信息增益偏向可取值个数变化带来的属性变化不同。

Cart 方法将基尼指数当做判别指标，来完成对决策树属性的划分，通过基尼值得到集合 U 的纯度，公式为：

$$\text{Gini}(U) = \sum_{i=1}^{N} \sum_{j \neq i}^{N} p_i p_j = 1 - \sum_{k=1}^{N} P_k^2 \tag{2-21}$$

公式 2-21 中集合 U 中所含有的类别数量用 N 表示，而 k 类样本数量在总样

中国知网 https://www.cnki.net

本数量中所占比例用P_k 表示。

面对二分类问题时，利用真类（positive）和负类（negative）两种结果来衡量某一类新样本的分类结果，但是在实际应用中并不会单单出现 P 或者 N 的情况，而是会相互组合，共产生四种不同的情况，如表 2-2 所示。

真实类别实际结果为正，而模型预测结果也为正，即真阳（TP，true positive）。

真实类别实际结果为正，但是模型预测结果为负，即假阳（FP，false positive）。

真实类别实际结果为负，但是模型预测结果为正，即假阴（FN，false negative）。

真实类别实际结果为负，而模型预测结果也为负，即真阴（TN，ture negative）。

表 2-2　真假值结果列表

		预测值		
		真	假	合计
实际值	真	TP	FN	TP+FN
	假	FP	TN	FP+TN
	合计	TP+FP	FN+TN	TP+FN+FP+TN

利用 ROC 来度量随机森林算法的分类效果，ROC 的 X 轴代表 FPR 概率，Y 轴代表 TPR 概率。其中真阳概率 TPR=TP/(FN +TP)，代表在全部总实际正类样本，预测类别是正并且实际类别也是正的样本数量所占比例。而与之相对的假阳性率 FPR=FP/(TN+FP)，代表在所有总的实际负类样本中，预测类别为负且实际类别也是负的样本数量所占比例。当预测值为正而实际值为负的样本数量越多，则 FRP 越大；当预测值为正而实际值为正的样本数量越多，则 TRP 越大。

在实际应用随机森林分类器时，首先需要计算出每个样本被判定为正的概率，按照事先设定好的基准线，将分类概率与基准线进行对比，当分类概率超过基准线，则将样本划分为正类，当分类概率低于基准线，则将样本划分为负类，由此可以获得一组坐标（FPR,TPR）。为了得到合适的基准线，对测试样本进行横向对比，将左右测试样本按照概率从大到小排列，依次采用排列之后的概率值作为基准线，就可以得到一系列坐标值。这其中有两个极端点分别是（1,1）和（0,0），平面中（0,0）坐标对应的是最大基准值，而（1,1）坐标对应的是最小基准值，当基准值不断缩小时，越来越多的样本会被判定为正，这种情况下，正类样本中所包含的负类样本数量会不断增加，进而导致 TRP 和 FRP 的值也会不断变大。在这种情况下，将（0,0），（1,1）与平面中的（FPR,TPR）点按顺序全部用曲线连接起来，就得到了 ROC 曲线[50]，如图 2-4 所示。

中国知网 https://www.cnki.net

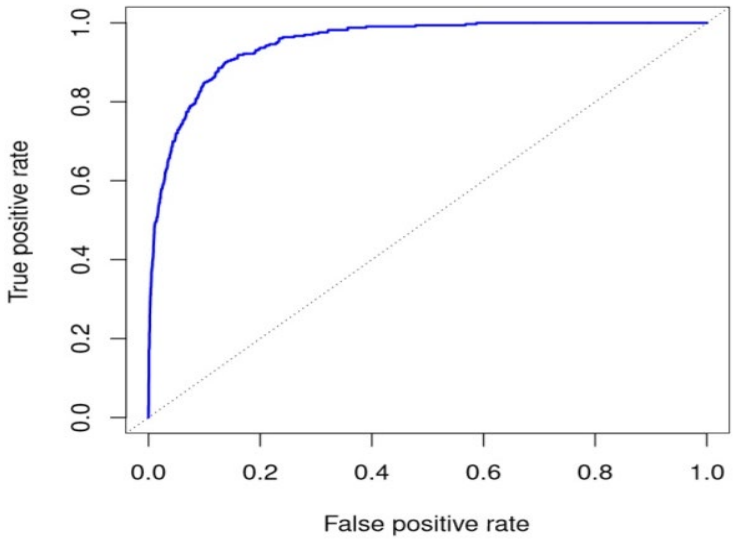


图 2-4　ROC 曲线示意图

定义 AUC 是 ROC 曲线下方和 X 轴围成的不规则区域的面积。

由图 2-4 可知，AUC 数值在 0 和 1 之间变化，因为 AUC 是个一个概率结果，理论意义就是随便选取一个正负样本的情况下，正样本的顺序在负样本之前的可能性。利用 AUC 实现对分类器分类结果有效性的判断，AUC 值越大，所组成区域的面积就越多，则分类器有效性就越好，而 AUC 值越小，表明分类器还存在改进空间。在实际应用中，样本类别会存在不平衡情况，当原始测试集正负类样本分布产生变动时，ROC 曲线能维持不发生变化，这也意味着当对正负样本根据平衡性进行调整的时候，ROC 曲线大体上不会发生变化，AUC 也可以保持不变，从而利用 AUC 来评价分类效果的有效与否有一定的广泛性。

2.4 本章小结

本章首先对量化投资的发展进行了概述，对整体的量化选股模型流程进行分析，现在的量化具有规律性，套利性，系统性，概率性特点。对常见的量化选股模型进行横向对比分析，多因子模型具有实用性好，原理简单，应用广泛的特点，作为本文的首选模型。在此基础上讨论了不同的分类算法，包括 KNN 算法，神经网络算法，XGBoost 算法和随机森林算法的优劣性。由于随机森林算法能够消除过拟合现象，保证模型稳定性，同时支持并行计算并应用于高维数据，在大数据处理方面有优势，所以本文选用随机森林作为分类算法，对因子重要性进行排序。后续将在本章的理论基础上，完成因子选取，重要性排序，并计算模型收益率。

中国知网　https://www.cnki.net

第 3 章 数据选取与因子池构建

3.1 样本数据选取及预处理

本文所有数据从 WIND 终端获取，由于原始数据存在缺失值，异常值，零值以及错误值等，需要提前对数据进行预处理。数据预处理的质量对后续机器学习算法的优劣性有很大影响，噪声数据的存在会造成模型训练的偏差。本文所使用的是科创板的上市股票数据，数据提取时间段为 2020 年 1 月 1 日到 2021 年 12 月 31 日，由于科创板 2019 年 7 月 22 日才迎来第一批上市公司，且前期上市公司数量较少，数据选取中将 2019 年 7 月 22 日到 2019 年 12 月 31 日跳过，避免科创板刚设立时交易数据偏差给样本带来的影响。整体数据收集间隔为周，利用周数据为样本进行验证，经过预处理后共得到约 300 组有效数据，如表 3-1 所示。

表 3-1 模型样本股票代码列表

样本股票代码					
688001.SH	688078.SH	688177.SH	688315.SH	688500.SH	688607.SH
688002.SH	688079.SH	688178.SH	688316.SH	688505.SH	688608.SH
688003.SH	688080.SH	688179.SH	688317.SH	688508.SH	688609.SH
688004.SH	688081.SH	688180.SH	688318.SH	688510.SH	688611.SH
688005.SH	688083.SH	688181.SH	688319.SH	688513.SH	688613.SH
688006.SH	688085.SH	688183.SH	688321.SH	688516.SH	688616.SH
688007.SH	688086.SH	688185.SH	688323.SH	688517.SH	688617.SH
688008.SH	688088.SH	688186.SH	688328.SH	688518.SH	688618.SH
688009.SH	688089.SH	688188.SH	688329.SH	688519.SH	688619.SH
688010.SH	688090.SH	688189.SH	688330.SH	688520.SH	688621.SH
688011.SH	688092.SH	688191.SH	688333.SH	688521.SH	688625.SH
688012.SH	688093.SH	688195.SH	688335.SH	688526.SH	688626.SH
688013.SH	688095.SH	688196.SH	688336.SH	688528.SH	688628.SH
688015.SH	688096.SH	688198.SH	688338.SH	688529.SH	688630.SH
688016.SH	688097.SH	688199.SH	688339.SH	688533.SH	688633.SH
688017.SH	688098.SH	688200.SH	688345.SH	688536.SH	688636.SH
688018.SH	688099.SH	688201.SH	688350.SH	688538.SH	688639.SH
688019.SH	688100.SH	688202.SH	688355.SH	688550.SH	688655.SH
688020.SH	688101.SH	688215.SH	688356.SH	688551.SH	688656.SH
688021.SH	688106.SH	688216.SH	688357.SH	688555.SH	688658.SH
688022.SH	688108.SH	688217.SH	688358.SH	688556.SH	688659.SH
688023.SH	688109.SH	688218.SH	688359.SH	688557.SH	688660.SH
688025.SH	688111.SH	688219.SH	688360.SH	688558.SH	688661.SH
688026.SH	688113.SH	688221.SH	688363.SH	688559.SH	688662.SH
688027.SH	688116.SH	688222.SH	688365.SH	688560.SH	688663.SH

中国知网 https://www.cnki.net

表 3-1（续表）

688028.SH	688117.SH	688228.SH	688366.SH	688561.SH	688665.SH
688029.SH	688118.SH	688233.SH	688367.SH	688565.SH	688667.SH
688030.SH	688122.SH	688256.SH	688368.SH	688566.SH	688668.SH
688033.SH	688123.SH	688258.SH	688369.SH	688567.SH	688669.SH
688036.SH	688126.SH	688260.SH	688377.SH	688568.SH	688676.SH
688037.SH	688127.SH	688266.SH	688378.SH	688569.SH	688677.SH
688038.SH	688128.SH	688268.SH	688379.SH	688571.SH	688678.SH
688039.SH	688129.SH	688269.SH	688383.SH	688575.SH	688679.SH
688050.SH	688131.SH	688276.SH	688386.SH	688577.SH	688680.SH
688051.SH	688133.SH	688277.SH	688388.SH	688578.SH	688681.SH
688055.SH	688135.SH	688278.SH	688389.SH	688579.SH	688682.SH
688056.SH	688136.SH	688286.SH	688390.SH	688580.SH	688683.SH
688057.SH	688138.SH	688288.SH	688393.SH	688585.SH	688685.SH
688058.SH	688139.SH	688289.SH	688395.SH	688586.SH	688686.SH
688059.SH	688155.SH	688298.SH	688396.SH	688588.SH	688687.SH
688060.SH	688156.SH	688299.SH	688398.SH	688589.SH	688689.SH
688063.SH	688157.SH	688300.SH	688399.SH	688590.SH	688690.SH
688065.SH	688158.SH	688301.SH	688408.SH	688595.SH	688696.SH
688066.SH	688159.SH	688308.SH	688418.SH	688596.SH	688698.SH
688067.SH	688160.SH	688309.SH	688425.SH	688597.SH	688699.SH
688068.SH	688161.SH	688310.SH	688456.SH	688598.SH	688700.SH
688069.SH	688165.SH	688311.SH	688466.SH	688599.SH	688777.SH
688070.SH	688166.SH	688312.SH	688468.SH	688600.SH	688788.SH
688076.SH	688168.SH	688313.SH	688488.SH	688601.SH	688819.SH
688077.SH	688169.SH	688314.SH	688499.SH	688606.SH	688981.SH

从 2020 年元旦到 2021 年二季度末，共 78 周的数据为模型训练集，利用 2021 年三季度开始到 2022 年元旦六个月共 27 周的数据进行模型拟合。模型整体数据时间跨度两年，共 105 周。基准数据选用科创 50 指数，上证 180 指数，上证 50 指数，所选择的因子选股模型累计收益率最后与科创 50，上证 180 和上证 50 进行综合比较，从而对比模型的效率，在收益率大小与波动之间寻求最佳平衡点，整个模型的样本数据时间跨度如图 3-1 所示。

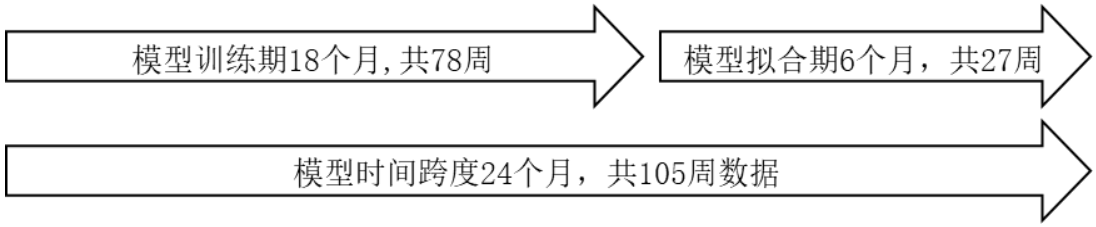


图 3-1 样本数据时间跨度示意图

中国知网 https://www.cnki.net

3.2 因子池构建

3.2.1 原始因子选取

多因子模型的一个假设是过去的事情在将来会重复发生，即历史会重演，在此基础上，对过去指标的分析，寻找出对股价变化有影响力的因子，通过对这些因子进行追踪，从而对股价的变化进行预判。利用以往数据搜寻可以带来一定收益空间的因子，以此构建资产组合，因此因子池的构建对超额收益具有十分重要的影响。候选因子需要有一定的代表性，涵盖市场的各个角度，同时具有一定的金融学解释意义，对股价变化能做出合理分析，以及带来超额收益的原因是什么。

在候选因子的选择上，一方面依据因子的经济学解释，同时考虑股票市场投资者从实践中得到指标，并借鉴前人的研究成果。因子有效性是选股基础，只有因子具有足够的有效性，才有可能获得潜在的巨大收益。

表 3-2　候选因子名称及含义列表

因子类别	因子名称	因子符号	含义
原始因子	市盈率	PE	股票价格/每股收益
	市净率	PB	每股股价/每股净资产
	市销率	PS	每股股价/每股销售额
	换手率	TR	周转率，某个时间范围股票换手的频率
	涨跌幅	AD	涨跌值/前收盘价
	均价	AP	某个时间范围股票成交价均值
	成交金额	GMV	某个时间范围股票成交总额
	A 股流通市值	MA	一定时间内 A 股可流通的股票市值
	市现率	PCF	股票价格/每股现金流
构建因子	流通市值占比	RCMV	A 股流通市值/总市值
	成交额占流通市值比	TCMV	成交额/A 股流通市值
	当期股价上升动量	HP	（最高价-开盘价）/开盘价
	交易量异常变化	UTV	当个交易量/前一个交易量
	量价背离	VPD	((当期成交量-前期成交量)/前期成交量)/((当前股价-前期股价)/前期股价)*100
	开盘缺口	OG	（当期开盘价-上一期收盘价）/上一期收盘价

由表 3-2 可知，在具体因子的选择上，包括 A 股流通市值，换手率，市销率，

中国知网 https://www.cnki.net

市净率，涨跌幅，市盈率，均价，市现率等 9 个原始因子，并在原始因子的基础上，借鉴以往学者的论文成果，叠加市场中实际应用要求，获得构建因子。构建因子包括流通市值占比，成交额占流通市值比，当期股价上升动量，交易量异常变化，量价背离，开盘缺口等 6 个，合计共 15 个候选因子。

3.2.2 因子选取原因

所选用的原始因子均为市场中常见的因子且经过长时间的实盘检验，同时为增大模型因子覆盖面，增加构建因子，其中构建因子选取学界业界常用的指标，以保证实用性。由于所选用的样本数据为科创板股票，所选取的 15 个因子中部分因子值与常见的主板股票存在差异，可能有偏大或者偏小的现象，同时科创板股票的高溢价性，高流动性也意味着不能用衡量主板股票的眼光来这些指标，下面对这 15 个因子选取的原因以及可能存在的差异进行分析。

（1）市盈率：即证券的价格除以每股盈利的比值，被广泛用来判断证券价格是否在合理区间的指标，包括静态和动态两种市盈率，通常在市场中得到广泛使用的是静态市盈率。从市盈率定义可以看出，市盈率其实是当一个企业在保持每股盈利不变时，将素有的盈利以股息的方式派给股东，而股东将这些再次全部投入到资本市场中，进行再投资条件下，初始投资通过股息可以全部收回来所需的时间年限。通常，单只股票的市盈率较低意味着短时间内就可以收回原始投资，也即市场价格对于这只股票的盈利能力越强。这种背景下的投资风险就会很小，而股票的潜在投资收益空间就很大。而当证券市盈率偏高，需要较长时间才能收回初始投资，证券的潜在价值相对较低。

由于科创板的特殊性，在科创板上市的公司市盈率相较于主板和创业板都较高，一方面是科技属性加持，另一反面也反映了市场对高科技成长企业的成长预期较高，PE 高达数百倍。但是并不影响利用市盈率衡量上市公司的股价，在一个 PE 普遍被高估的市场里，利用市盈率进行横向对比，能得到较为理想的效果。

（2）市净率：定义为每股股价与每股净资产的商。其中的每股股价为交易当日的收盘价，而每股净资产则是根据上市公司的营运状况来确定，是全体股东共同享有的资产。上市企业的营收良好，复合增长率快，资产增值速度快，股票的每股净值较大，而反应到报表上，持股股东具有的权益随之变大。市净率能够较为理想的识别风险，对能够利用较少投入获取较高产出企业，投资者往往不断追捧，反之，则被市场所嫌弃。

对市净率较高的股票，其投资空间往往较小，而市净率较低的股票，其投资空间较大。因为市净率考虑了公司的净资产，所以在评估上市公司风险，尤其是

中国知网 https://www.cnki.net

当企业具有较高比例实物资产时会受到格外重视。对于科创板企业而言，由于大多是高科技成长企业，实物资产占比较低，而股价受追捧往往较高，从而总体市净率也高于主板和创业板水平，但是与同在科创板的公司相比，仍然具有一定的参考价值。

（3）市销率：即证券全部市值除以主营收的比值。人们通常利用市销率来判断一家企业的营收与股价的关系，市销率越低，上市企业隐含的投资空间越大；市销率越高，上市企业隐含的投资空间越小。由于收入分析在公司经营前景评估中占据重要的地位，没有销售就不可能有收益。

科创板公司没有硬性的盈利要求，很多公司还处于亏损状态，市盈率的有效性没有主板那么好，因此，利用市销率可以选出那些主要利用非经常性损益来增加公司利润，而主营业务缺乏核心优势的上市公司，这些公司往往具有很低的市盈率。在辨别公司营收稳定可靠的同时，兼顾公司的盈余质量。市销率不会小于零，能够兼顾对亏损的企业的衡量，同时稳定可靠，难以通过人为修改报表进行操纵，并且对价格和战略变化比较敏感，在科创板的高科技企业比较中，利用市销率来评价尚未盈利的高成长企业，比其他指标更为可靠。

（4）换手率：表示某时间范围内上市公司股票周转换手的频率，是反应证券流动性的主要指标，也是反应市场投资活跃程度的重要技术指标。热门股票往往受到市场的追捧，对该股票的买卖操作频繁，投资交易非常活跃，这种股票的股票的换手率往往也较高。与之对应的是冷门股，市场关注度不高，人们的买卖意愿不强，由此导致股票换手率往往很低。高换手率股票资金在其中腾挪较为容易，流动性非常好，投机价值较大，变现能力强，股价起伏波动大，风险也较高，通常是短线交易所追捧的对象。若某只股票在某个时间点股价较低，成交量突然快速放大，且换手率居高不下，说明市场中的筹码在频繁交易，这种情况下极有可能是有人在大量吸取筹码，往往伴随着股价的上涨。

而当某只股票在大幅上涨之后换手率突然变大，往往意味着筹码被大量卖出，这时候股价很容易被砸下来，此时继续持有股票风险较高，后市看空，需要及时卖出。在科创板市场中，股价波动较大，股性活跃，利用换手率的变化推测后续股价的变化具有重要的参考价值，同时结合股价的高低，能提升推测的准确性。

（5）涨跌幅：通常一期的涨跌值除以前一期的收盘价，由百分比表示，涨跌幅表示在一定区间内，投资者对股票的追捧程度[51]。市场看好，则股票上涨，否则股票下跌，由于中国特有的涨跌停板制度，涨跌幅收到限制。对于科创板来说，单日涨跌幅限制在 20%，由于一周之中五连板的概率极其罕见，因此忽略不计，本文只考虑周涨跌幅。在复权上，才用不复权的真实数据，考虑到科创板企

中国知网 https://www.cnki.net

业的拆分，除权等较为少见，利用前复权或者后复权数据会产生持仓成本变化的差异。在股价上扬初期，涨跌幅波动较小，而股价高位往往波动较为剧烈，利用涨跌幅判断股价变化具有重要的参考性。

（6）均价：股票在一定交易时期内的平均交易价格，用来表示一定时间的持仓成本，是绝对值指标。由于股价波动偏差，利用均价来衡量股票的变化，并衡量市场持仓成本，是一种简单易行且准确率高的方法。

科创板的普通小散户较少，主要是机构和大户，对股价的绝对值敏感度没有主板市场高。通过分析不同时期股价均值的高低来判断未来股价的走势，可以消除股价日波动带来的偏差，趋势性明显，参考价值大。

（7）成交金额：某个时间范围内证券交易金额总和。股市的潮涨潮落离不开背后资金的支持，在行情上行期间，成交金额显著放大，尤其在大行情来临之际，成交金额会突然放大。成交额较大的，交易投资较为热门，为热门股，尤其是在股价低点出现大成交量，股价上升概率更大；而股价在高位出现大成交额，则大概率会下行。

科创板公司股性较为活跃，每日成交额都在一定的范围波动，且资金量较大，巨量的成交额出现较为少见。但是分析不同时期成交金额之间的变化，配合股价的变化进行分析，依旧有相当程度的参考意义。

（8）A 股流通市值：某时间范围内流通股票数量与该时间范围内股票价格的乘积。因为在国内的上市公司股权构成中，只有个人股可以自由流通，包括国有股，法人股等在内都受到限制，同时受股权锁定，封闭期等影响，自由流通市值只占总市值的一部分。流通市值意味着在市场流动的筹码数量，可流通市值越大，大量的筹码在市场中流动，股价上涨相对较难，可流通市值越小，只需要少量资金就可以控制流动筹码数量，带动股价上扬，因此相对来说上涨容易。在科创板中有很多中小市值股票，且流通盘很小，相比主板这点尤其突出，投资者也更加关注流通市值对科创板上市公司股价的影响。

（9）市现率：股票价格除以每股现金流的比值，常用来衡量证券价格高低和证券风险程度大小，并反应上市企业资本运作效率[52]。市现率越小，表示企业每股现金增加额越多，较高的现金流能保证企业的稳定运行，同时企业所承担营收压力较小。对于科创板的高成长性企业而言，由于分红较少，主要资金使用于研发，设备购买等项目，在衡量企业未来的发展情况以及运营质量分析时，具有一定的参考意义。

（10）流通市值占比：即流通市值在总市值中所占的比例，流通市值是绝对指标，而流通市值占比是相对比例。由于上市公司在公开发行股票时，为了避免

中国知网 https://www.cnki.net

对市场的冲击，通常将股票分为流通部分和限制流通部分。当流通市值占比提高时，股票的流动性较好，更容易收到追捧，资金的进入和退出也流畅，股价波动较小流通市值股票小。由于科创板市场的特殊性，极少出现大幅解禁，除权等现象，顾采用流通市值占比，而非流通股占比。将市值占比作为衡量标准，在科创板市场的适用性要好于流通股占比。本文采用一周中每个交易日的流通市值占比均值为指标进行衡量。

（11）成交额占流通市值比：即当期成交额除以当期流通市值的比值。成交额占流通市值占比是衡量市场对股票追捧度的常用指标，受关注度较高的股票，其当期成交额占流通市值占比较高，同时也会带来股价的上扬；而成交额占流通市值比非常低的股票，几乎没有交易盘，股价上升动力较小，且下降风险较大。由于本文使用的是科创板的周数据，股价出现连板的可能性极小，顾不考虑无量封涨停板的特殊情况。采用一周中每个交易日的成交额占流通市值比的平均数值作为周成交额占流通市值比的数据。

（12）当期股价上升动量：当期内股价上升最高点与开盘价的差价与开盘价的比值定义为当期股价上升动量[53]。由于下单策略，羊群效应，动量效应等原因，当市场开始抢筹码时，会造成股价一路冲高。随着订单的成交，股价可能会渐渐回落，但是当期股价冲高，反映出市场对单只股票的追捧。

通过计算当期股价上升动量，可以推测下期股票的走势。当股票在当期上升动量较大时，后续股价上扬概率较大，反之，后续股价下降概率较大。由于在股价上扬后期也可能会出现大幅冲高回落并下跌，顾需要结合其他指标进行考虑，但其在多因子选股中依然能起到一定的指标作用。

（13）交易量异常变化：交易量是最常用的一个指标，用当期交易量/上期交易量作为交易量异常变化的指标来衡量交易量的变化情况。通常情况下，交易量显著放大或者缩小，都是行情转变的表现。在股价低点交易量显著放大是股价上扬的前兆，而股价高点交易量显著放大则是股价下行的前兆，尤其是高点交易量突然缩小，极有可能无量下跌，引起股价大幅下滑。交易量异常变化是市场中很重要的指标，每家所使用的计算方法也不尽相同，这里选取国泰君安金融工程所使用的计算方法，同时由于所选用的是科创板的周交易数据，连续封板，或者是跌停板即为罕见，忽略不计，本文不做考虑。

（14）量价背离：当期成交量与前期成交量差值除以前期成交量，和当前股价与前期股价差值除以前期股价的值相除，所得结果乘以 100。量价背离衡量的是股价变化与成交量呈反方向变化的情形，由于存在缩量上涨，或者是放量下跌的情形，当整体市场趋势比较明显的时候，此种现象亦比较明显。本文采用华泰

中国知网 https://www.cnki.net

金工所提供的一种计算方法，由于所采用的是比例数值，且初始数值较小，在本文中将初始结果放大 100 倍，并不影响最终结果，仅仅提高数据精度同时方便后续数据处理。量价背离现象在科创板市场出现评率并没有主板市场频繁，但是不可忽略，可以为提高模型精度做出一定的帮助。

（15）开盘缺口：当前开盘价和前一期收盘价的差值再除以前一期收盘价[54]。开盘缺口较为特殊，由于集合竞价期间，只有有资格的机构和大户可以报价，普通散户无法影响集合竞价的价格，游资对开盘缺口指标的影响较为有限，顾当期开盘缺口代表了主流资金对股票的看法。开盘缺口越大，则表明市场对股票的追捧越高，开盘缺口很小甚至为负缺口，表明市场资金对股票的态度较为冷漠，甚至低价出逃，所以开盘缺口对于中短期投资具有重要的意义。本文所采用的开盘缺口为相对值，相比绝对值在比较不同股价的股票上升趋势时覆盖性，可比性更好，同时减小因为股价日内或日间波动给模型精度带来的影响。

在因子池选定的基础上，结合所选用的数据，对所选因子进行分析与筛选，从而为下一步的随机森林模型构建做准备。

3.3 因子相关性检验

虽然随机森林在数据处理上不受多重共线性的影响，能够摆脱传统回归模型中由于因子多重共线性问题带来的偏误问题，但是在后续数据解释上会受到多重共线性的干扰，所以在对数据进行预处理的基础上，先对因子进行自相关性检验，观察所选变量的自相关性，为后续随机森林选择因子提供参照。同时对整个回归检验，检测模型是不是有效及准确。

由于在模型中存在的一定自相关性，AP，PB，PE，PS 等自相关性较为明显，而 VPD，OG 等指标的不存在明显的自相关性，因子选取较为理想。由于股价涨跌的各种指标都存在一定的关联性，尤其是盘口的指标，相当部分是通过对基本指标，利用不同的测算方式计算出来的新的指标，在利用不同方法对基本指标计算过程中，存在一定自相关性和多重共线性很难避免，这点和传统线性回归模型不同，这给模型的搭建带来了困难，影响了模型的准确性。

受限于因子数量及来源，目前主要的做法是通过构建新的因子以及选用适当的因子处理算法来解决这个问题，其中构建新的因子可能会没有收到市场的检验而缺乏通用性，且受时间节点的影响，可能会出现在不同时期，因子无法正常使用的情况，所以调整因子处理算法是更为常见的一种方法，前人的处理效果也较为理想，本文也采取这种方法。其中因子自相关检验的结果表 3-3 所示。

中国知网 https://www.cnki.net

表 3-3　因子自相关性检验结果

	CP	GMV	AD	AP	TR	MA	PE	PB	PS	PCF	RCMV	TCMV	HP	UTV	VPD	OG
CP	1.000															
GMV	0.618	1.000														
AD	0.151	0.428	1.000													
AP	0.991	0.620	0.102	1.000												
TR	0.488	0.873	0.429	0.489	1.000											
MA	0.719	0.433	0.095	0.712	0.203	1.000										
PE	0.797	0.538	0.146	0.790	0.453	0.591	1.000									
PB	0.894	0.703	0.240	0.889	0.615	0.589	0.763	1.000								
PS	0.949	0.611	0.153	0.941	0.515	0.654	0.842	0.884	1.000							
PCF	0.559	0.381	0.101	0.554	0.330	0.426	0.663	0.537	0.582	1.000						
RCMV	0.544	0.283	0.038	0.542	0.097	0.912	0.450	0.423	0.488	0.329	1.000					
TCMV	0.478	0.871	0.410	0.485	0.996	0.192	0.445	0.608	0.506	0.325	0.089	1.000				
HP	0.483	0.598	0.554	0.444	0.591	0.365	0.422	0.478	0.477	0.304	0.284	0.563	1.000			
UTV	0.025	-0.185	0.014	0.018	-0.161	0.030	0.018	-0.008	0.024	0.016	0.063	-0.163	-0.091	1.000		
VPD	0.004	0.012	0.005	0.003	0.015	0.003	0.000	0.007	0.004	0.000	0.010	0.015	0.017	0.019	1.000	
OG	0.102	0.373	0.669	0.117	0.357	0.082	0.100	0.217	0.109	0.075	0.065	0.373	0.129	0.002	0.001	1.000

虽然随机森林算法可以有效避免自相关性和多重共线性的问题，但是结论解释上，还是需要关注因子自身带来的问题，可能会给结论解释造成偏误。因为最终还是要回到多因子模型中，利用因子选取股票机型收益率计算，如果单纯考虑随机森林的优势，最终的结果可能缺乏合理的解释，模型的结果也有待商榷，因此需要注意因子背后的理论意义与实践意义，不能执念于随机森林的特点而不顾

中国知网 https://www.cnki.net

建模的目的是获取超额收益率，在后续论文中会对此进行讨论。

3.4 因子回归显著性

3.4.1 原始因子回归检验

在因子自相关结果的基础上，对全部数据变量进行回归统计，查看各个因子的基本情况，为后续随机森林提供参考。在整体变量的回归统计结果中，调整后的 R 方接近 0.9，接近 1，F 检验明显可以通过，整体结果较为理想。除了常数项以外，所有的因子 P 值基本较小，其中仅 VPD 和 TR 的 P 值超过 0.4，对因子的检验也较为理想，结果如表 3-4，表 3-5，表 3-6 所示。

表 3-4　变量总体回归统计结果

	结果
Multiple R	0.899965
R Square	0.89993
Adjusted R Square	0.897466
标准误差	0.037215
观测值	104

表 3-5　变量总体方差分析

	df	SS	MS	F	Significance F
回归分析	15	360741.5	24049.43	1.03E+30	8.50E-97
残差	88	2.77	0.03		
总计	103	360744.3			

表 3-6　全部变量回归检测结果

	Coefficients	标准误差	t Stat	P-value	Lower 95%	Upper 95%	下限 95.0%	上限 95.0%
Intercept	-0.0812	0.0927	-0.0867	0.8346	-0.2654	0.1029	-0.2654	0.1029
GMV	0	0	0.1827	0.3841	0	0	0	0
AD	0.5113	0.1761	0.2451	0.3813	0.1613	0.8613	0.1613	0.8613
AP	0.012	0.0021	0.3427	0.3958	0.0077	0.0162	0.0077	0.0162
TR	0.4893	0.4242	0.1084	0.4093	-0.3537	1.3324	-0.3537	1.3324
MA	0	0	1.57E+11	0.3442	0	0	0	0

中国知网 https://www.cnki.net

续表 3-6

PE	6.2321	26.6279	29465.64	0.0733	-46.6852	59.1494	-46.6852	59.1494
PB	0.0294	0.0147	2.1846	0.3233	0.0001	0.0587	0.0001	0.0587
PS	39.9538	112.6319	389.213	0.2458	-183.8785	263.7861	-183.8785	263.7861
PCF	0.6157	19.3488	1.25E+09	0.0725	-37.836	39.0674	-37.836	39.0674
RCMV	0.1269	0.4004	0.2016	0.3728	-0.6687	0.9225	-0.6687	0.9225
TCMV	-0.414	0.4225	-0.1612	0.399	-1.2536	0.4256	-1.2536	0.4256
HP	-0.2952	0.1758	-0.1291	0.398	-0.6445	0.0541	-0.6445	0.0541
UTV	0.0027	0.0059	0.0726	0.3898	-0.0089	0.0144	-0.0089	0.0144
VPD	-0.0045	0.0195	-0.0424	0.4132	-0.0432	0.0343	-0.0432	0.0343
OG	-0.4174	0.2333	-0.2186	0.3853	-0.8811	0.0463	-0.8811	0.0463

在所有的变量因子的回归系数中，GMV 和 MA 的系数接近于 0，而系数较大的前三个因子分别是 PS，PE，PCF，其中 TCMV，HP，VPD，OG 的系数为负，据此推测，在因子有效性中，PS，PE，PCF 对模型由正向作用，且作用效果较为明显，而 TCMV，HP，VPD，OG 对模型由反向作用效果，且作用效果相对较小。在后续的分类算法的分析中，需要考虑到这些变量的变动情况及对因子影响方向。

3.4.2 调整后因子回归检验

在全部变量因子的回归处理基础上，将 MA，GMV 两个变量删除，重新进行回归检验，得到调整后的结果。由于随机森林算法的因子越多，训练时间越长，复杂程度变大，且不相关大的因子还会对结果产生干扰，因此预调对模型因子进行筛选，可以有效提高随机森林的训练效率和准确性。同时，由于前人并未以此做过相应的研究，具体因子之间的关系不清楚，提前进行回归检验可以为后续的随机森林结果进行参照。整后的结果中调整后的 R 方约为 0.8， F 检验明显可以通过，标准误差未超过 0.1，整体模型的拟合效果较为理想，在删除部分变量之后，模型的变量 P 值由部分上升，除常数项以外，超过 0.4 的变量有 AD，AP，

中国知网 https://www.cnki.net

TR，TCMV，HP，VPD，数量有所增加的，模型精度略有缺失，但整体结果在可接纳的区间内。系数影响最大的三个因子是 PS，PE，TR，而 HP，VPD，OG 对模型是反向作用，且反向作用较小。调整后的模型回归结果如表 3-7，表 3-8，表 3-9 所示。

表 3-7　调整后的变量总体回归统计结果

	结果
Multiple R	0.799962
R Square	0.799924
Adjusted R Square	0.797695
标准误差	0.041198
观测值	104

表 3-8　调整后的变量总体方差分析

	df	SS	MS	F	Significance F
回归分析	13	360741	27749.31	8.03E+28	1.90E-99
残差	90	3.23159	0.035898		
总计	103	360744.3			

表 3-9　调整后的全部变量回归检测结果

	Coefficients	标准误差	t Stat	P-value	Lower 95%	Upper 95%	下限 95.0%	上限 95.0%
Intercept	-2.30E-05	0.042813	0.01987	0.784759	-0.08508	0.085032	-0.08508	0.085032
AD	0.521737	0.187462	0.208567	0.407428	0.149318	0.894157	0.149318	0.894157
AP	0.012738	0.002132	0.405651	0.400476	0.008501	0.016974	0.008501	0.016974
TR	0.505454	0.453544	0.266364	0.429546	-0.39557	1.406481	-0.39557	1.406481
PE	4.18218	28.07171	35912.29	0.073006	-51.5872	59.95152	-51.5872	59.95152
PB	0.030044	0.014274	2.647446	0.326627	0.001686	0.058402	0.001686	0.058402
PS	28.19312	121.5703	-1124.34	0.252789	-213.327	269.7137	-213.327	269.7137
PCF	0.109552	21.66809	3.38E+08	0.072469	-42.9379	43.15699	-42.9379	43.15699
RCMV	0.068767	0.129855	-0.35494	0.35316	-0.1892	0.326738	-0.1892	0.326738

中国知网　https://www.cnki.net

续表 3-9

TCMV	-0.44705	0.456017	-0.25243	0.421639	-1.35299	0.458885	-1.35299	0.458885
HP	-0.2962	0.184223	-0.10988	0.405464	-0.66219	0.069785	-0.66219	0.069785
UTV	0.003677	0.006338	0.129806	0.394508	-0.00891	0.016269	-0.00891	0.016269
VPD	-0.01196	0.021587	-0.07783	0.421621	-0.05484	0.03093	-0.05484	0.03093
OG	-0.4664	0.2422	-0.1479	0.3926	-0.9476	0.0149	-0.9476	0.0149

调整前后的模型对比中，删除变量之后模型的拟合效果略有降低，但是剩余因子的有效性略有上升。此外因为因子数量降低，在数据预处理中删除作用较小的因子可以为后续的随机森林减小工作量并提高准确性，当样本数据总量比较大时，可以明显减轻工作量。在本文中，出于严谨考虑，在回归分析的基础上，会对所有因子和调整过后的因子以同样的参数运用随机森林算法计算因子重要性，并借鉴数据回归的结果，对模型结果进行一定的解释，在下文中分别比较了两种结果的差异性。

3.5 本章小结

本章构建了两大类包括市盈率，市净率等在内的共 15 个因子的因子池，增大因子覆盖范围，在实际应用的基础上给出因子的理论解释。数据选取上，利用 wind 搜集周数据作为样本，对数据进行预处理，共获得 300 组有效数据。由于不确定因子的实际效果，在因子池和数据池的基础上，对因子进行自相关分析和回归显著性分析，为后续随机森林结果做参照。由于部分因子之间存在较强的自相关性，在后续的模型中对因子进行适当删选，剔除显著性较低的因子，提高因子有效性，保证模型的准确性。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 4 章 随机森林的多因子选股模型构建

4.1 随机森林参数调整

随机森林主要依靠多棵决策树得出分类结果，因此在利用随机进行分类时，M 棵决策树通过独立投票实现对样本的分类步骤，在此基础上形成 N 个结果并按照投票数进行排序，最后的结果就是在决策树投票中数量最大的那个分类。随机森林的随机特性主要包括两个方面，分别是训练样本集和分裂属性集的随机性。首先，在每棵决策树采用自助重采样技术，在训练集中有放回的选取相同数量的样本，这样能确保所选取的训练样本是随机的；同时，对于单棵决策树而言，其特征值集合由随机选取的特征值构成，由此确保了特征的随机性，从而很好的避免了过拟合问题。

有两个数值主要影响随机森林算法的最终分类效果，即决策树棵数 M 和决策树分裂特征个数 N。其中 N 棵决策树组成随机森林，通常情况下，决策树数量和模型的准确性成正相关，即决策树数目越大，模型的精准度也会提升。但是随着 M 的不断增大，对模型精确性提升的边际效应不断递减，同时还回影响到模型的训练速度，因为大量的决策树意味着大量的运算消耗，往往需要很长时间的训练才能获取比较满意的结果。而 N 是决策树特征集合的特征个数，这也意味这通常情况下 N 会以全部特征个数为区间上限，这个范围内，提高 N 可以改善模型效果，但是代价是模型的训练效率会降低，而且 N 过大会造成随机森林的多样性降低，导致单棵决策树的特征集合差异性缩小，导致决策树的差异化程度降低，从而增加整体偏误，影响准确度。

4.1.1 AUC 均值计算

本文的训练数据时间跨度从 2020 年元旦到 2021 年二季度结束，样本共包括 18 个月的数据，并对样本数据进行预处理，避免缺失值，异常值给模型带来的影响，共得到 300 组完整数据。在参数选择上，借鉴前人的研究成果，同时将网格搜索的结果依次进行对比，将随机森林的分裂特征个数 N 设为 3，4，5，6，将决策树棵树 M 的分别设定为 30,40,50,60，共计 16 组数据，计算其平均 AUC，并以此为判别标准对单组数据进行评价。

当保持分类特征个数 N 不变时，缓慢增大策树棵数 M 的值，平均 AUC 也会缓慢增大；而当保持 M 不变时，缓慢增大分类特征个数 N，平均 AUC 会先缓慢增大，到达峰值后缓慢下降，这是因为分类特征 N 达到一定值时，决策树之间

中国知网 https://www.cnki.net

的差异反而会缩小，虽然 N 的变大可以带来模型精度提升，但是边际变化是不断递减的，叠加每棵树的差异缩小，最终导致平均 AUC 下降，如表 4-1 所示。

表 4-1　不同参数设置的 AUC 均值对比

特征数（N）	3	3	3	3	4	4	4	4	5	5	5	5	6	6	6	6
决策树（M）	30	40	50	60	30	40	50	60	30	40	50	60	30	40	50	60
AUC 平均值	0.519	0.522	0.523	0.522	0.521	0.524	0.525	0.523	0.522	0.525	0.526	0.524	0.522	0.522	0.524	0.521

综合表中结果，当 N=5，M=50 时，平均 AUC 达到最大值，从而在后续的处理中将 N 设为 5，M 设为 50，完成随机森林算法训练。

4.1.2 原始因子重要性排序

在随机森林中，计算不同特征值在决策树分类时作用效果的大小，以此为基础对均值实施排序，从而评估不同特征对算法的效用程度。排名靠前的说明贡献大，对模型的越重要，排名靠后的说明对模型的贡献相对较小，重要性也相对较弱，通过对基尼系数的计算可以对不同特征值的重要性程度进行量化，从而方便比较。在模型拟合中，将得到的因子重要性实施排序，结果如图 4-1 所示。

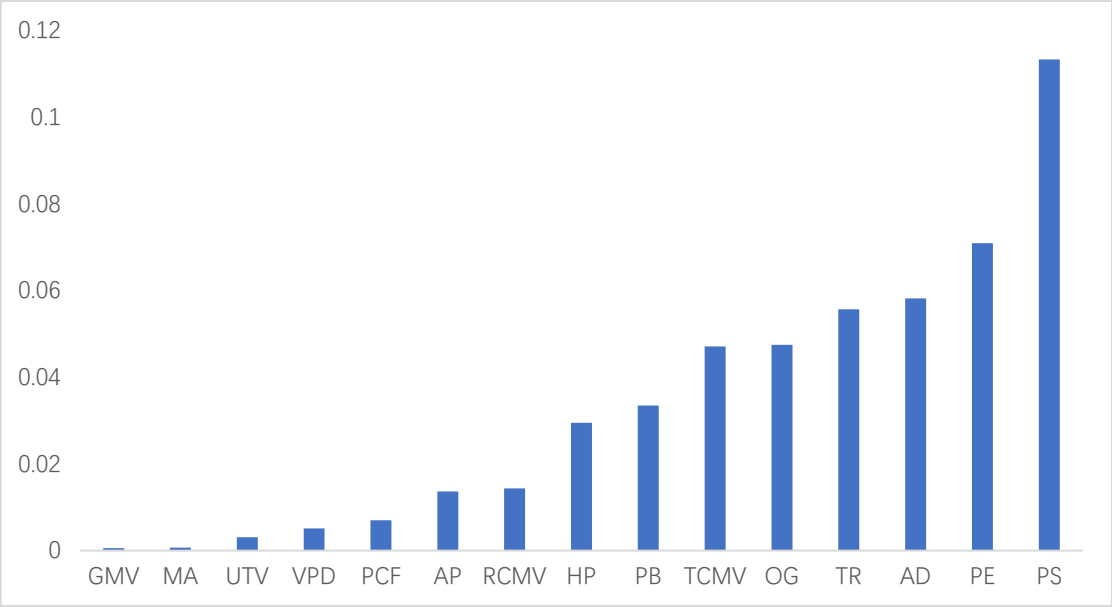


图 4-1　因子重要性排序

此为将所选 15 个因子全部利用随机森林进行估算因子重要性的结果，由上图可知，GMV 和 MA 的因子重要性最小，对选股模型几乎没有什么贡献；而重要性排名前三的因子分别是 PS，PE 和 AD，对模型的贡献较大，也相对重要。

中国知网　https://www.cnki.net

有前述的因子相关性分析中可以得知，GMV 和 MA 存在多重共线性，对模型的共线性较小，根据随机森林的结果，证实了这一点。

4.1.3 因子重要性排序优化

既然这两个因子在对模型的重要性不足，还存在干扰，在进一步的分析中，将这两个因子删除，减小模型因子数量，在其他参数不变的情况下，重新通过随机森林进行因子分析，相关结果如图 4-2 所示。

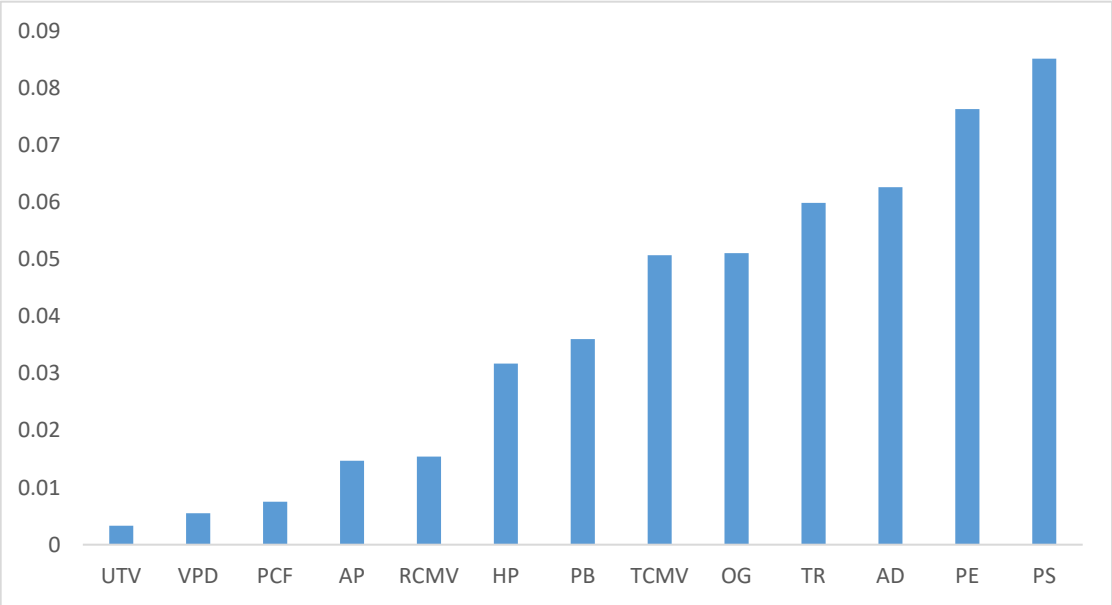


图 4-2　调整后的因子重要性排序

由上图可知，调整后的因子找重要性排序得到了一定的优化，没有出现重要性的突变，呈现逐渐增大的趋势，也没有重要性接近 0 的因子，整体结果较为理想。在调整后的结果中，对选股模型贡献排名前三的因子分别是 PS，PE，AD，其中 PS 的重要性贡献最大；对选股模型贡献排名最后三名的因子分别是 UTV，VPD，PCF。将所有因子按照重要性排序，算出单只证券在不同时期的综合得分，并按照得分对每个时期的股票进行排序，选取排名靠前的股票来构成资产池，带入下一步多因子模型的构建及收益率计算。

4.2 选股模型构建

4.2.1 原始模型构建

在模型所选用因子的基础上，计算不同周期（共 105 个）所有股票样本的得分，从中选取得分最高的 25 只股票，以 5 周为调仓周期，共 21 轮调仓周期，从而得到模型的收益率变化曲线。由于模型选用的是从 2021 年 7 月到 2021 年 12

中国知网　https://www.cnki.net

月的数据为测试数据，同时选用同时期的上证 180 指数和上证 50 指数以及科创 50 指数进行对比。其中科创 50 指数最能代表科创板上市公司的表现，这 50 只证券在科创板中流通市值最大，流动性也最好，非常具有代表性。上证 180 是在上证 30 的基础上演变而来，由全 A 股市场中最具代表性的 180 个样本股票组成，反应的是上海证券市场的整体运行情况，是能够评价投资尺度的基准指数，能够全面反应股价的走势；而上证 50 由是上证市场中头部 50 家企业的组成，市值规模大，流动性极佳，股性活跃，认可度高，极具市场代表性，反应的是对整个市场产生巨大影响力的上市公司集合，投资指导意义明显，具体收益率对比如图 4-3 所示。

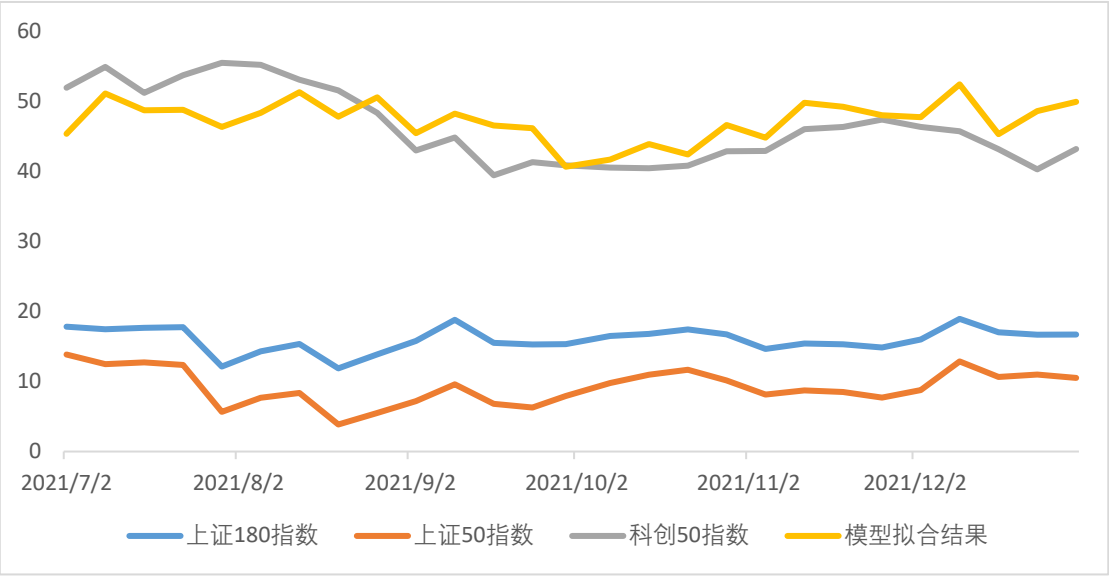


图 4-3　第一次模拟期拟合结果对比图

由上图可知，模型拟合结果在一段时间里跑赢科创 50，同期远远跑赢上证 180 和上证 50。主要原因可能是科创板市盈率较高，股价波动大，成交量活跃，同期收益率远远超过主板，带来模型结果与上证 180 和上证 50 之间的显著差异。但是与科创 50 相比，虽然部分时间收益率略高，但是总体优势不明显，部分收益率明显低于科创 50，即原始模型拟合结果与科创 50 相比没有明显趋势。在此情况下，利用模型进行选股与购买科创 50ETF 相比，对投资者并没有很明显的吸引力。将数据的模拟区间放宽到整个完整的数据周期，得到两年之内的模型拟合结果，如图 4-4 所示。

中国知网　https://www.cnki.net

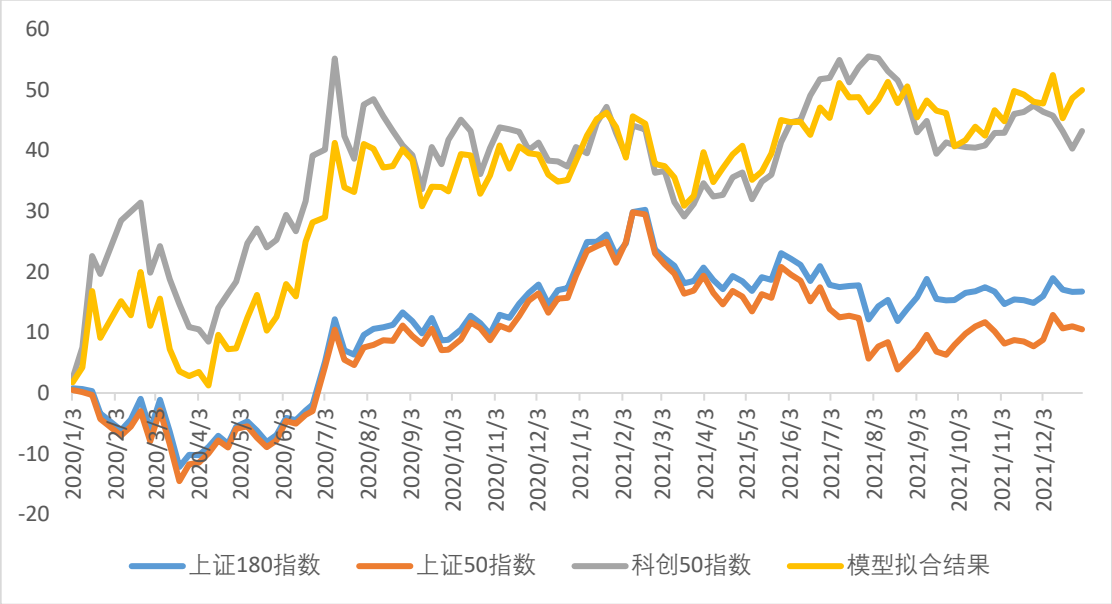


图 4-4　第一次整体拟合结果对比图

由上图可知，将数据回测时期拉长，所得到的结果优势更加不明显。模型拟合结果在初期回撤幅度超过了科创 50，且短期高点收益也远小于科创 50 高点收益，中后期拟合结果较为理想，与科创 50 相近，部分时间段跑赢科创 50。虽然总体时间段依然明显超过上证 180 和上证 50 指数，但是整体结果不理想。分别计算在四组数据的均值和方差，可以准确的比较其中的收益率，如 4-2 表所示。

表 4-2　第一次拟合结果参数对比

		上证 180 指数	上证 50 指数	科创 50 指数	模型拟合结果
整体结果	均值	11.26	8.37	37.25	34.26
	方差	106.64	96.67	129.07	200.22
模拟期结果	均值	16.00	9.25	46.33	47.25
	方差	2.90	6.21	26.65	8.33

由上表数据可知，在模拟期中，科创 50 指数的均值为 46.33，而模型拟合结果的均值为 47.25，模型拟合结果略高于科创 50 指数收益率；同时科创 50 的方差为 26.65，而模型拟合结果的方差为 8.33，从波动角度来说，科创 50 波动要远高于模型的拟合结果，仅从模拟期结果分析，搭建的多因子模型有实际价值。

对比整体回测结果，科创 50 的收益率为 37.25，而模型的拟合结果仅为 34.26，在为期两年的周期里，模型跑输了指数收益率三个点左右；同时模型拟合的方差为 200.22，而科创 50 指数的方差为 129.07，模型拟合波动率也高于科创 50 指数，鉴于此结果，长期来看，所构建的多因子模型无法跑赢科创 50 指数。

中国知网　https://www.cnki.net

4.2.2 提高持仓集中程度

为了能够提高收益率从而跑赢科创 50，在多因子模型的参数选择中，减小股票数量，即原来模型中所选用的得分最高的 25 只股票减少为得分最高的 10 只股票，依旧选用 5 周为调仓周期，共 21 轮调仓，从而得出新的收益率曲线。由于之前选用的是 25 只股票，平均每只股票占总仓位的 4%，将持股数量降为 10 后，相当于将高得分股票的仓位提高一倍多，每只股票仓位达到了 10%，根据马科维茨的资产组合理论，分散化投资可以带来风险的降低，同时收益率也会降低，而集中持股会带来收益率的提高，但是也会带来风险的集中，从而模型的波动会变大，也非常挑战投资者的心理承受能力，将参数调整后的收益率如图 4-5 所示。

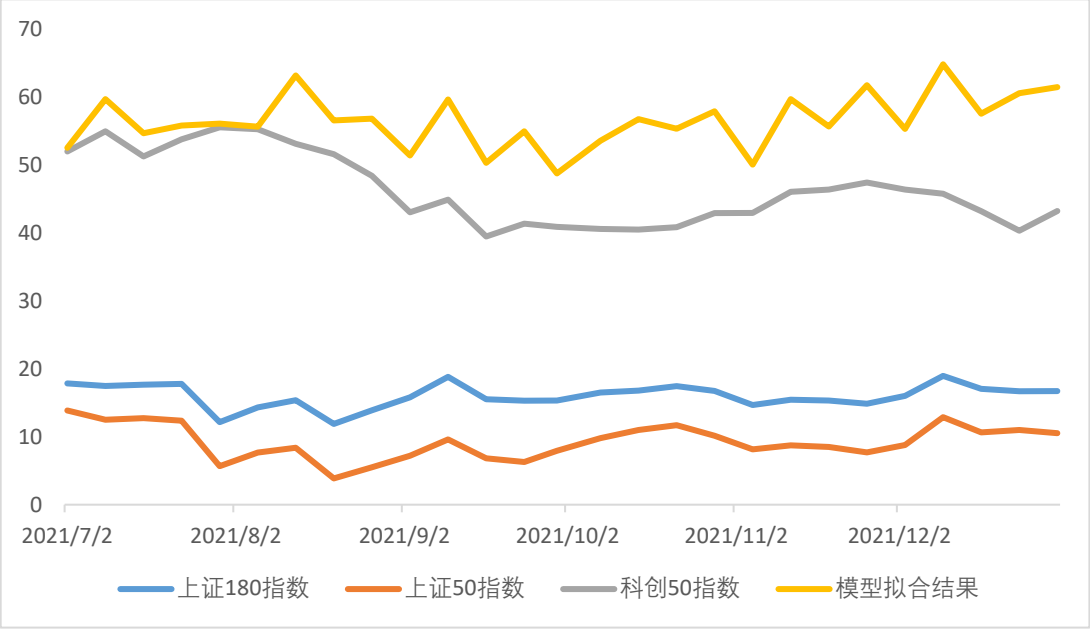


图 4-5　第二次模拟期拟合结果对比图

由上图可知，减小持股数量，增大单只股票仓位之后的模型拟合收益率基本跑赢科创 50。在相同的时期内，集中持股可以带来收益率的提高，但是波动率也明显放大，从曲线中可以非常直观的看到，模型拟合结果的曲线远没有科创 50 指数平滑，呈锯齿状，起伏波动剧烈。为了更加清晰的对比整体的收益率情况，将数据区间拉长，由半年改为两年得到整个统计周期的收益率对比，如图 4-6 所示。

中国知网　https://www.cnki.net

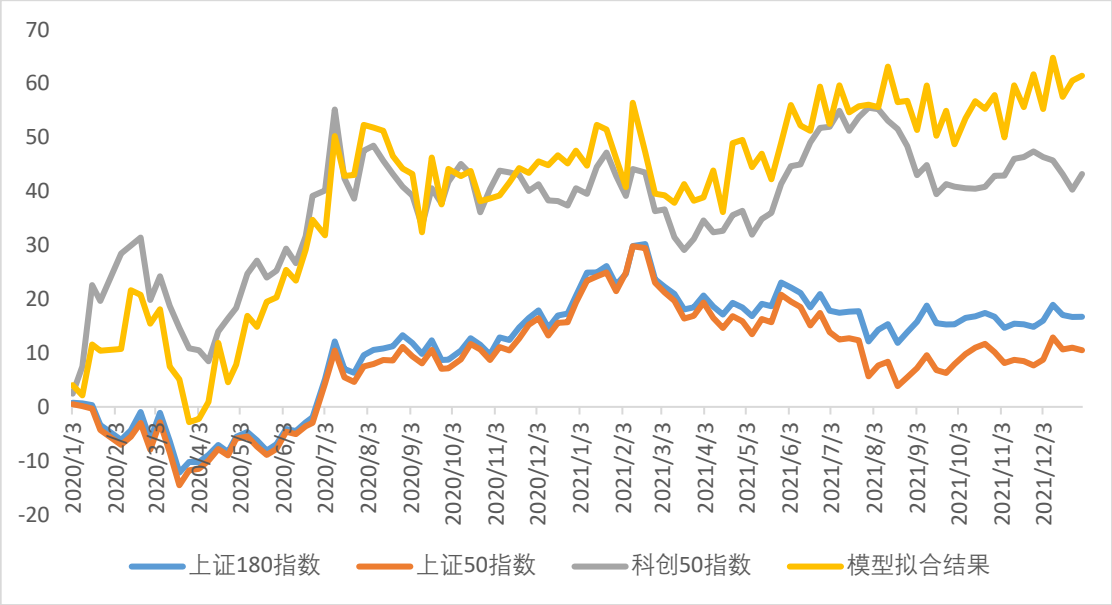


图 4-6　第二次整体拟合结果对比图

由上图可知，将数据回测周期变为 2 年后，模型拟合收益率相比分散持仓，得到了提升，在整个周期内跑赢科创 50 的时间约为三分之二，同时前期的下跌回撤幅度也较小，且出现了多个收益率阶段峰值，高点与科创 50 高点几乎持平，整体走势较为理想。但是曲线的跳变较为剧烈，波动较大，在长周期中表现的更加明显，出现过多次突变，振幅接近 15%，且突变频率较高，对于投资模型来说极其不理想。这总情况下的模型是依靠对风险控制的放弃来获得收益率的提高，对于个人投资者来说可能是一种选择的，对于机构来说则极不可取。具体统计数据如表 4-3 所示。

表 4-3　第二次拟合结果参数对比

		上证 180 指数	上证 50 指数	科创 50 指数	模型拟合结果
整体结果	均值	11.26	8.37	37.25	40.29
	方差	106.64	96.67	129.07	297.06
模拟期结果	均值	16.00	9.25	46.33	56.49
	方差	2.90	6.21	26.65	15.40

由上表可知，集中持仓后的模型，模拟期收益率均值为 56.49，对比科创 50 的收益率 46.33，接近 10 个点的盈利优势，即使在整个回测区间中，模型拟合收益率均值为 40.29，比科创 50 的收益率均值 37.25 高出将近 3 个点，收益率提升效果显著。另一方面，在模拟期的方差为 15.4，虽然相比科创 50 的 26.65 有一些优势，但是相比之前模型的 8.33，波动率变动极大；同时整体模型的拟合结果方差达到了 297.06，显著增大，远没有科创 50 指数变动平滑。

中国知网　https://www.cnki.net

4.2.3 调整调仓周期

如何对模型进行调整，从而能够在收益率提升的同时降低收益率波动率，在收益与波动之前找到一个平衡，从而具有现实意义。在保持持仓期不变的情况下，集中持股提高收益率，但是同时也会增加波动率，但是分散投资虽然可以降低波动，但是也会降低收益率，从而陷入困境。但是考虑到科创板的特殊性，由于科创板额交易非常活跃，同时股价波动幅度较大，极少存在封板的情形。极好的流动性，较大的振幅空间意味着可以较为容易的以理想的价格区间买到理想的仓位，对于资金的流出流入比较友好。有鉴于此，将调仓时间从原来的 5 周，缩短为 3 周，调仓周期数量由 21 增加到 35，由于不考虑交易费用及税费，增加调仓费用并不会增加交易成本，也不会对模型拟合收益率造成影响，同时利用集中持股可以提高收益率的结论，将股票池控制在 20 只股票，与最开始的 25 只股票相比，减小 5 只。缩短调仓时间之后，可以更加有效地抓住股价的短期波动，交易更加灵活，相比于长持仓期政策，在科创板这种活跃的市场更加有优势，修改参数之后模型的模拟结果如图 4-7 所示。

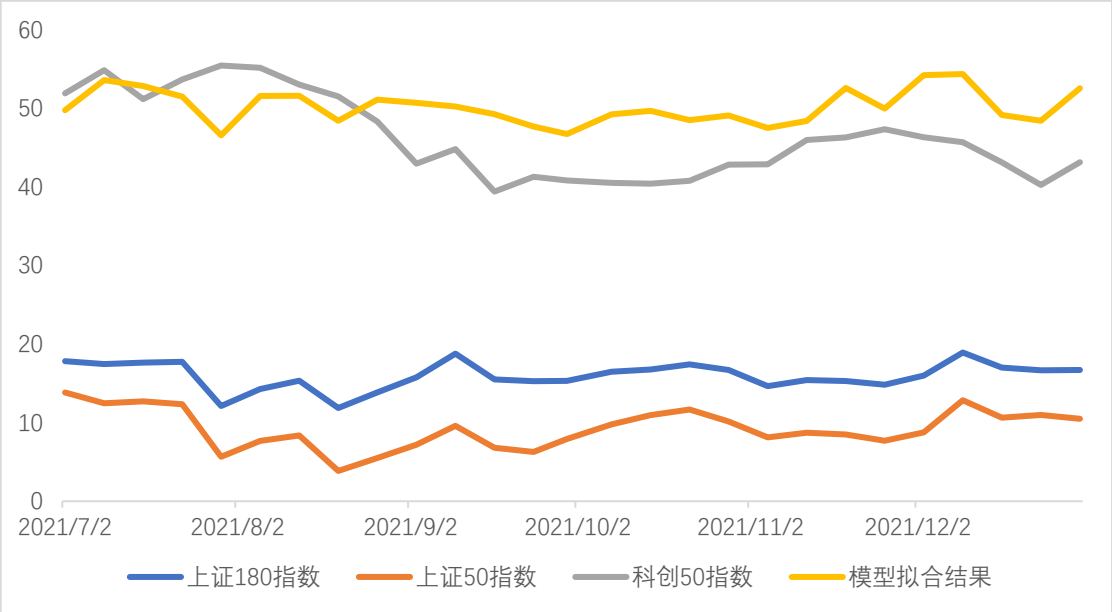


图 4-7　第三次模拟期拟合结果对比图

缩短单次持仓时间之后，虽然调仓次数增加，收益率也不如集中持股高，不过股价波动控制的较为理想。从上图可以看出，与 10 只股票相比，这次模型拟合结果的收益率较低，但是波动率也了下来，整体曲线较为平滑，没有出现剧烈波动。其中有部分时间模型并没有跑赢科创 50 指数，但是到模型结束，总体累计收益率比指数高接近 10 个点，拟合效果相对理想。将模型拟合区间扩张到整体数据时间段，得到下列的收益率对比图 4-8。

中国知网　https://www.cnki.net

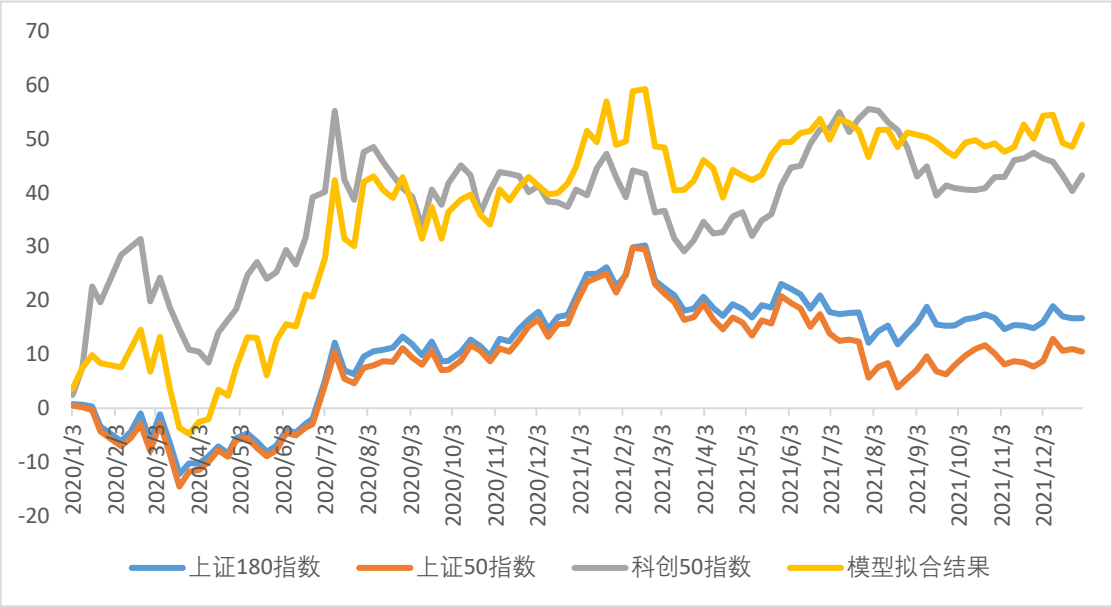


图 4-8　第三次整体拟合结果对比图

从整体回归结果看，模型的拟合结果在部分阶段跑赢科创 50 指数，想较于前两次模型得到了改进，同时模型拟合收益率的波动也控制的较为理想，没有出现锯齿状曲线，整体较为缓和。且模型拟合最高点超出科创 50 指数最高点，回撤方面控制较为理想，与上证 180 指数和上证 50 指数相比，超额收益率更高，具有较好的实际意义。具体的参数如表 4-4 所示。

表 4-4　第三次拟合结果参数对比

		上证 180 指数	上证 50 指数	科创 50 指数	模型拟合结果
整体结果	均值	11.26	8.37	37.25	38.45
	方差	106.64	96.67	129.07	299.16
模拟期结果	均值	16.00	9.25	46.33	50.24
	方差	2.90	6.21	26.65	4.67

由上表可知，无论是整体结果还是模拟期结果，模拟拟合结果的收益率均值都高于科创 50 的收益率均值，其中整体结果均值高出 1 个点，模拟期结果均值高出 4 个点。而在模拟期，波动控制的非常理想，模型拟合结果方差仅为 4.67，科创 50 指数的方差达到 26.65，模拟期模型的波动控制的非常好。整体结果中，科创 50 指数的方差为 129.07，而模型拟合结果的方差为 299.16，总体波动控制依旧不如科创 50 指数。考虑到前半部分数据作为训练数据在使用，而后半年数据才是模型的拟合结果，因此后半年数据结果更具有真实性和可靠性。根据模拟期的结果数据，在改进模型参数之后，模拟拟合结果相对来说较为理想。

中国知网　https://www.cnki.net

4.3 模型改进与优化

在此前模型的基础上，一味追求降低波动率，虽然模拟期模型拟合结果方差达到较为理想的水平，但是也带来了收益率的降低，将近两个月的时间区间中，并没有跑赢科创 50 指数，且在模拟期中无法达到科创 50 指数的最高点。对于投资者来说，一味的降低风险，消除波动率未必是好事，波动率的降低也意味着放弃了获取超额收益得机会。有鉴于此，对模型进行进一步的调整，在前述实验的基础上，将模型重点持仓股数量变为 15 只，调仓时间依旧是 3 周，共 35 个周期，得到新的拟合曲线，如图 4-9 所示。

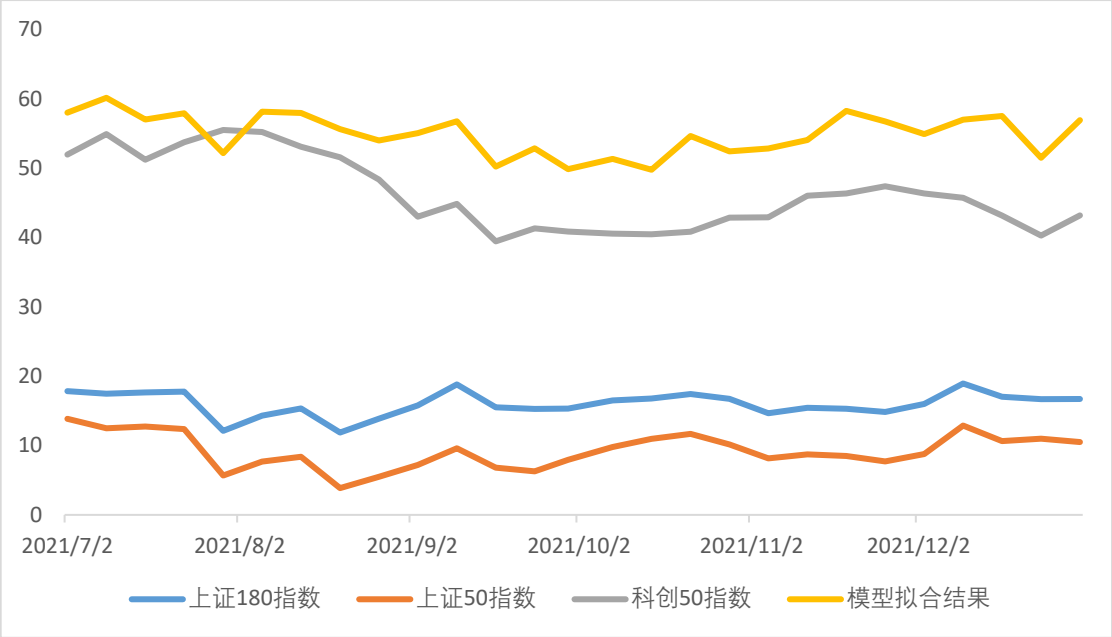


图 4-9　改进模型模拟期拟合结果对比图

与前述模型相比，本次模拟期模型拟合结果基本跑赢科创 50 指数，且出现剧烈收益率波动的情况较少，走势较为平缓。到模拟期结束，模型拟合结果累计收益率超出科创 50 接近 11%，现实意义较强。将模拟拟合周期放宽，得到整体的拟合结果，如图 4-10 所示。

中国知网　https://www.cnki.net

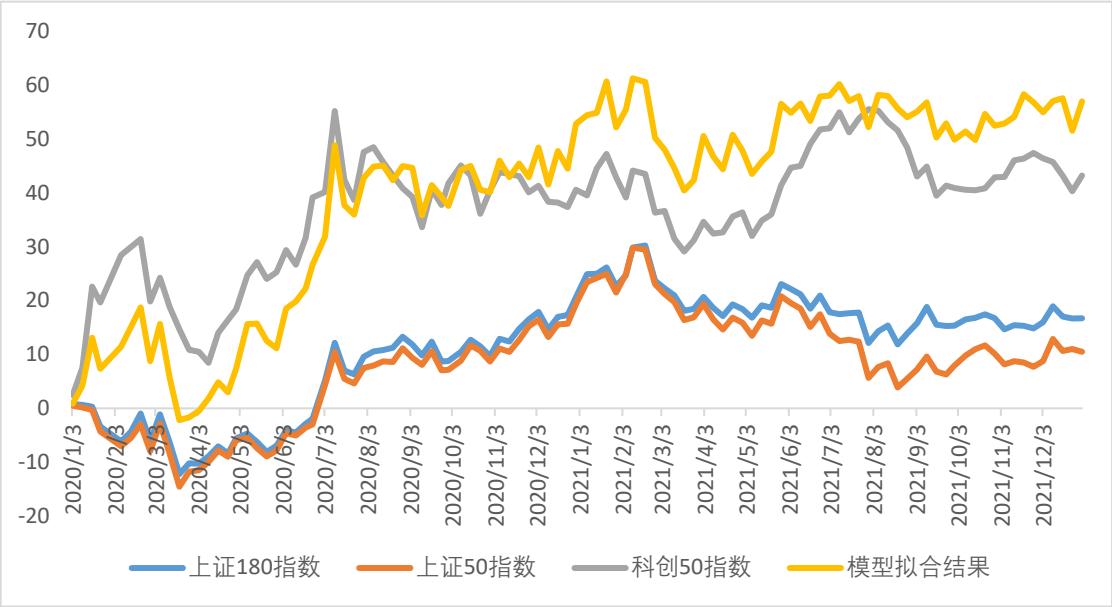


图 4-10　改进模型整体拟合结果对比图

由上图可知，总体回测结果中模型拟合收益率大部分跑赢科创 50，同时在收益率峰值上，超过科创 50 的最高点，整体收益率提升幅度较之前较大。虽然出现锯齿状收益曲线，但是波动控制的较为良好，较前述模型有一定的改进。通过具体的统计数据，可以准确对比曲线的变化，如表 4-5 所示。

表 4-5　改进模型拟合结果参数对比

		上证 180 指数	上证 50 指数	科创 50 指数	模型拟合结果
整体结果	均值	11.26	8.37	37.25	40.14
	方差	106.64	96.67	129.07	333.44
模拟期结果	均值	16.00	9.25	46.33	54.94
	方差	2.90	6.21	26.65	8.36

在模拟期，模型拟合结果均值为 54.94，超出科创 50 指数收益率均值 8%，较前述模型提升了 4%。与此同时，模型的波动有所上升，方差变为 8.39，但是相较科创 50 指数方差 26.65 依然有较大优势。调整参数后，在适当放开收益率波动的基础上，获得收益率的提高，从而达到收益与波动的微妙平衡，在可忍受的回撤范围内追求超额收益。

美中不足的是对于整体拟合结果而言，虽然模型拟合收益率均值达到 40.14，超过了科创 50 指数平均收益率 37.25 接近 3%，获得超额收益。但是整体波动控制的似乎不理想，科创 50 的方差为 129.07，而模型拟合结果的方差达到 333.44，不仅远远超过科创 50 的方差，而且在本文所列举的四个结果中，也是波动最大的一次。

从图中还可以看出，虽然模型的收益率得到一定提升，但是依然摆脱不了大

中国知网　https://www.cnki.net

盘走势的影响，指数大跌时模型收益率急剧下降，指数大涨时模型收益率急速上升。主动权益多因子选股追求尽量减小大盘对期望收益率的干扰。在股价上涨时超过大盘上涨幅度，在股价下跌时小于大盘下跌幅度，才能够取得较好的收益率，目前的模型无法完全做到这点。如何在保证收益率的情况下控制整体波动，同时尽量减小大盘走势对模型拟合结果的影响，保持稳定的收益收益率增长，带来可靠的正投资收益，是下一步进行优化的方向，也是未来需要解决的问题。

4.4 本章小结

本章在选定因子池的基础上，对随机森林模型进行构建，确定决策树数量和分裂特征数量，对比 AUC 均值大小，选取其中极大值为最终模型选用的参数，以此为基础对因子重要性进行排序，同时计算股票综合得分。由于在多因子模型中，资产池中股票数量不同，调仓周期不同都会影响到模型的最终收益率，本文对模型尝试了多组参数，并进行改进，在保证收益率跑赢基准指数的同时，降低模型的收益波动程度，达到二者之间的平衡点，经过优化的模型可以在拟合期获得较好收益率，并且波动控制的较为理想，具有一定的实际应用价值。

中国知网 https://www.cnki.net

结　论

近年来量化模型迅速发展，涌现出一大批依靠量化进行投资的机构，总资金量也在与日俱增。其中多因子模型发展较早，理论较为完善，本文主要在以往多因子选股的研究上加以改进，将随机森林与多因子模型相结合，利用随机森林算法完成对证券的判别分类，组成具有潜在投资空间的股票池，试图在一定时间范围内获取超越基准指数的收益率，得出以下结论。

（1）构建了高覆盖，多角度的因子池。以往的研究中多以财务或者技术因子为主，本文对因子进行扩充，包括原始因子和构建因子两部分，适当增大因子覆盖面，并对因子进行预筛，尽量减小因为因子选取带来的偏误。选用全部科创板上市公司为原始样本，两大类共包括交易开盘价，成交量，换手率，市盈率，总市值，总股本等 15 个指标进行数据收集，整个数据样本时间范围从 2020 年元旦到 2022 年元旦共 24 个月，105 周不复权数据。为了数据准确性，减小噪音度模型的影响，对数据进行预处理，共得到有效样本 300 组。

（2）搭建了随机森林模型并按照因子有效性进行筛选排序。利用随机森林在高维数据和非线性问题处理方面的优势，避免了过拟合问题，同时基于打分法构建的模型可以有效的筛选出合适的资产池，具有广泛性和通用性。利用 2020 年元旦到 2021 年二季度结束，共 18 个月的数据，作为模型的训练样本数据。通过计算平均 AUC，将分裂特征数量设为 5，决策树数量设为 50，并对因子重要性进行排序，计算单只证券在不同时期的综合得分，得出不同时期证券排名顺序。

（3）构造多因子选股模型，同时进行优化，并检验模型效果。本文在理论基础上建立了完整的选股模型，并且利用实际数据进行了多次测试，对回测过程中的问题进行优化。模型预测期为 2021 年 7 月到 2021 年 12 月共 6 个月。选取 25 只股票，5 周为调仓周期，模型拟合结果仅能在部分时间内跑赢科创 50，且波动较大。为了提高收益率，将股票数量选为 10 只， 5 周为调仓周期，单只股票占比从 5%提升到 10%，显著提高拟合期收益率，但资产组合波动较大，突变频率变高。将股票池中股票数量设为 20，调仓周期从 5 周变为 3 周，此时模型的波动得到有效的控制，明显小于科创 50，整体回测期波动依旧较大，且收益率不具备显著优势。进一步，保持调仓周期 3 周不变，设置股票数量为 15，改进后的模型在拟合期收益率显著高于科创 50，且收益率波动比较理想，整体回测收益率也高于科创 50，在平衡收益与波动之间达到了较为理想的平衡。

本文基于随机森林建立了多因子选股模型，并且实证验证了模型的可行性，

中国知网 https://www.cnki.net

但是也有一些不足之处。虽然拟合期数据较为理想，但是在完整回测期，模型的回撤要高于大盘的下跌，如何在纯多头市场中，通过调整选股组合在熊市中抵御回撤，并超越指数，需要进一步的研究与调整。科创板设立时间较短，估值普遍偏高，本文也只选取了两年的数据，建立的模型仅能保证在一定范围内的特定市场可以获得超越指数的收益。如何调整模型，让资产池在穿越牛熊之后依旧能保持较为理想的收益率，也是后续需要解决的难点。

中国知网 https://www.cnki.net

参考文献

[1] 曹正凤. 随机森林算法优化研究[D]. 首都经济贸易大学, 2014.

[2] Ross Stephen A. The arbitrage theory of capital asset pricing[J]. Academic Press, 1976, 13(3):341-360.

[3] Kyoung-jae Kim. Financial time series forecasting using support vector machines[J]. Neurocomputing, 2003, 55(1):307-319.

[4] Bin Li,Peilin Zhao,Steven C. H. Hoi, et al. PAMR: Passive aggressive mean reversion strategy for portfolio selection[J]. Machine Learning, 2012, 87(2):221-258.

[5] Bin Li,Steven C. H. Hoi,Peilin Zhao, et al. Confidence Weighted Mean Reversion Strategy for Online Portfolio Selection[J]. Acm Transactions on Knowledge Discovery From Data , 2013, 7(1):1-38.

[6] Michel Ballings,Dirk Van den Poel,Nathalie Hespeels, et al. Evaluating multiple classifiers for stock price direction prediction[J]. Expert Systems with Applications, 2015, 42(20):46-56.

[7] J. B. Heaton,N. G. Polson,J. H. Witte. Deep learning for finance: deep portfolios[J]. Applied Stochastic Models in Business and Industry, 2017, 33(1):3-12.

[8] 罗超. 面向高维数据的随机森林算法优化探讨[J]. 商, 2016: 199-207.

[9] 李凌宇. 基于机器学习方法的量化多因子选股研究[D]. 厦门大学, 2019.

[10] 谭筝,Yan Ziqin,Zhu Guangwei. 随机森林选股：中国股市超额收益的开发[J]. 科学新闻, 2020(2): 149.

[11] 李倩,郑玥. 基于深度森林的指数增强策略研究[J]. 全国流通经济, 2020 (34): 148-150.

[12] The Interaction of Value and Momentum Strategies[J]. Financial Analysts Journal, 1997, 53(2):29-36.

[13] Value Investing: The Use of Historical Financial Statement Information to Separate Winners from Losers[J]. Journal of Accounting Research, 2000, 38(2):1-41.

[14] Partha S. Mohanram. Separating Winners from Losers among LowBook-to-Market Stocks using Financial Statement Analysis[J]. Review of Accounting Studies, 2005, 10(2):133-170.

[15] Takeaki Kariya. Quantitative Methods for Portfolio Analysis[M], 1993.

[16] Robert Novy-Marx. The other side of value: The gross profitability premium[J]. Journal of Financial Economics, 2013, 108(1):1-28.

[17] Eugene F. Fama,Kenneth R. French. A five-factor asset pricing model[J]. Journal

中国知网 https://www.cnki.net

of Financial Economics, 2015, 116(1):1-22.
[18] 曹正凤,纪宏,谢邦昌. 使用随机森林算法实现优质股票的选择[J]. 首都经济贸易大学学报, 2014, 16(2): 21-27.
[19] 林启敏. 基于随机森林和 QGA-SVR 的量化选股研究[D]. 华南理工大学, 2016.
[20] 苏靖宇. 多因子选股模型在 A 股市场上的实证研究[D]. 安徽大学, 2018.
[21] 张馨予. 基于随机森林算法的多因子量化选股方案策划[D]. 上海师范大学, 2019.
[22] Haoxuan Li,Xueyan Zhang,Ziyan Li, et al. Overview of Machine Learning for Stock Selection Based on Multi-Factor Models[J]. E3s Web of Conferences, 2020：214.
[23] Yihua Zhong,Lan Luo,Xinyi Wang, et al. Multi-factor Stock Selection Model Based on Machine Learning[J]. Engineering Letters, 2021, 29 (1):20-26.
[24] Dou Changsheng,Zhao Tengzhe,Guo Ziheng. Establishment and Analysis of Multi-Factor Stock Selection Model Based on Support Vector Machine in CSI 300 Index Constituent Stocks Market[J]. 6th International Conference on Financial Innovation and Economic Development, 2021,166:746-754.
[25] 雍凯. 随机森林的特征选择和模型优化算法研究[D]. 哈尔滨工业大学, 2008.
[26] 吴琼,李运田,郑献卫. 面向非平衡训练集分类的随机森林算法优化[J]. 工业控制计算机, 2013, 26(7): 89-90.
[27] 王淑燕,曹正凤,陈铭芷. 随机森林在量化选股中的应用研究[J]. 运筹与管理, 2016, 25(3): 163-168, 177.
[28] 刘凯. 随机森林自适应特征选择和参数优化算法研究[D]. 长春工业大学, 2018.
[29] 吴卫星. 随机森林在技术指标量化选股中的应用[D]. 电子科技大学, 2018.
[30] 朱青. 开放式基金风险评级研究——层次聚类法和随机森林算法的应用[J]. 金融管理研究, 2018(1): 137-152.
[31] 李东,贾郭军. 基于遗传算法的随机森林算法优化研究[J]. 首都师范大学学报(自然科学版), 2018, 39(4): 15-21.
[32] 贾秀娟. 基于随机森林的支持向量机量化选股[J]. 区域金融研究, 2019 (1): 27-30.
[33] 唐思佳,熊昕,谢满,等. 基于机器学习的优化股票多因子模型[J]. 信息与电脑(理论版), 2019, 31(23): 30-32.
[34] 李杰. 基于随机森林算法的多因子选股模型研究[D]. 哈尔滨工业大学, 2019.
[35] 王慎敏. 随机森林模型在选股策略中的应用[J]. 科技经济导刊, 2020, 28(33):

中国知网 https://www.cnki.net

188-190.
[36] 邓晶,李路. 参数优化随机森林在股票预测中的应用[J]. 软件, 2020, 41(1): 178-182.
[37] 周亮. 基于随机森林模型的股票多因子投资研究[J]. 金融理论与实践, 2021 (7): 97-103.
[38] Abraham Rebecca,Samad Mahmoud El,Bakhach Amer M., et al. Forecasting a Stock Trend Using Genetic Algorithm and Random Forest[J]. Journal of Risk and Financial Management, 2022,15(5):188.
[39] Li Wei,Chen Chin-Ling. Optimization and Application of Random Forest Algorithm for Applied Mathematics Specialty[J]. Security and Communication Networks, 2022(2022):268-272.
[40] Zhang Qingyang,Chen Miaochao. Financial Data Anomaly Detection Method Based on Decision Tree and Random Forest Algorithm[J]. Journal of Mathematics, 2022(2022):216-218.
[41] Behr Merle,Wang Yu,Li Xiao, et al. Provable Boolean interaction recovery from tree ensemble obtained via random forests.[J]. Proceedings of the National Academy of Sciences of the United States of America, 2022, 119(22):119.
[42] Kumano So,Akutsu Tatsuya. Comparison of the Representational Power of Random Forests, Binary Decision Diagrams, and Neural Networks[J]. Neural Computation, 2022, 34(4):1019-1044.
[43] Illa Pavan Kumar,Parvathala Balakesavareddy,Sharma Anand Kumar. Stock price prediction methodology using random forest algorithm and support vector machine[J]. Materials Today: Proceedings, 2022, 56(4):1776-1782.
[44] 杨育欣. 中国证券市场量化投资研究——量化择时选股策略[J]. 中国市场, 2017 (30): 39-42.
[45] 王珊,王锋. 我国开放式股票型基金择时选股能力的实证研究[J]. 时代金融, 2014 (2): 80, 84.
[46] 俞孙泽. 对随机森林算法的优化改进的分析[J]. 中国新通信, 2020, 22(13): 126.
[47] 许启发,侯奇华,蒋翠侠. 基于广义加性分位数回归的基金经理选股与择时能力评价[J]. 财会月刊, 2017 (35): 102-108.
[48] 王伦,李路. 基于 gcForest 的多因子量化选股策略[J]. 计算机工程与应用, 2020, 56(15): 86-91.
[49] 林永峰,沈彦,李禹汉,等. 基于择时的多因子选股模型[J]. 信息技术与标准化, 2021 (6): 44-50.
[50] 魏立波. 基于 T-M 模型的我国开放式基金择时与选股能力实证研究[J]. 北

中国知网 https://www.cnki.net

京交通大学学报(社会科学版), 2010, 9(2): 73-77.

[51] 严骏宏. 中国证券投资基金择时选股能力研究和实证分析[J]. 现代营销(学苑版), 2012 (6): 168-169.

[52] 国胜铁,钟廷勇,李江娜. 中国开放式证券投资基金选股与择时能力实证研究[J]. 学习与探索, 2013 (6): 115-118.

[53] 张珺,陈卫斌. 我国 QDII 基金经理的选股择时能力研究[J]. 投资研究, 2012, 31(1): 153-160.

[54] 杨育生. 开放式基金择时选股能力的实证分析[J]. 统计与决策, 2010 (10): 132-133.

中国知网 https://www.cnki.net